

ADPro: 一种基于流形约束去噪与任务感知初始化的测试时自适应扩散策略，用于机器人操作

Zezeng Li[✉], Rui Yang[✉], Ruochen Chen[✉], ZhongXuan Luo[✉], and Liming Chen[✉], *Senior Member, IEEE*,

摘要——扩散策略近年来已成为机器人操作中一类强大的视觉运动控制器，具有稳定的训练过程和富有表现力的多模态动作建模能力。然而，现有方法通常将动作生成视为无约束的去噪过程，忽略了关于几何与控制结构的有价值的先验知识。本文提出自适应扩散策略（ADP），这是一种测试时自适应方法，在扩散过程中引入两个关键的归纳偏置。首先，我们嵌入几何流形约束，使去噪更新与任务相关子空间对齐，利用末端执行器与目标场景之间的相对位姿提供自然梯度方向这一事实，并引导去噪沿操作流形的测地路径进行。其次，为减少不必要的探索并加速收敛，我们提出一种解析引导的初始化方法：不再从无信息先验中采样，而是计算夹爪与目标场景之间的粗略配准，以提出结构化的初始噪声动作。ADP 与预训练扩散策略兼容，无需重新训练，能够实现测试时自适应，使策略适应特定任务，从而增强在新任务和新环境中的泛化能力。在 RL Bench、CALVIN 和真实世界数据集上的实验表明，ADP 的一种实现 ADPro 提高了成功率、泛化能力和采样效率，与强扩散基线相比，执行速度最高提升 25%，成功率提升 9 个百分点。

索引词——扩散策略，机器人操作，测试时自适应，免训练，任务感知引导。

1. 引言

在非结构化环境中的自主机器人操作要求策略不仅能预测精确的动作，还能在多样的任务和场景中具有良好的泛化能力。早期基于规则控制器 [1]–[4] 或密集判别模型 [5]–[19] 的方法难以扩展，原因在于缺乏灵活性或穷举搜索的计算成本过高。近年来，扩散策略（Diffusion Policies, DPs）[20]–[34] 已成为一个有前景的方向，通过迭代去噪实现多模态动作生成，并在多个操作基准上取得了最先进的性能。然而，现有的扩散策略通常在离线状态下训练，并在执行时不进行测试时自适应，使用去噪扩散概率模型（DDPM）[35] 或去噪扩散隐式模型（DDIM）[36] 进行去噪，并将动作生成视为无约束的随机过程（见图 1.a）。这忽略了测试时可用的关键先验知识和任务特定结构。例如，相对位姿




图 1: (a) 普通扩散策略与 (b) 本文提出的自适应扩散策略（ADP）的比较。普通扩散策略通过从随机初始化逐步去噪来生成机器人动作，但该过程通常在无约束的欧几里得空间中展开。相比之下，本文提出的自适应扩散策略采用任务感知初始化，并沿任务流形和球面流形约束更新，从而产生更具泛化能力的策略。

机器人（Robot）与目标物体之间的相对关系自然地优化提供了方向，而粗略的几何对齐（Geometric Alignment）则能提供更优的初始状态。此外，标准的各向同性高斯先验（Isotropic Gaussian Prior）在整个动作空间中均匀注入噪声，迫使策略从忽略测试数据具体特征的无信息初始化中恢复，导致效率低下并增加失败率。本文提出在测试时引入任务特定约束与先验知识，使学习到的扩散策略（Diffusion Policy）无需重新训练即可动态适应任务结构。如图 1.b 所示，沿已知几何或控制相关流形（例如物体相对位姿、接触轨迹）引导去噪过程，有助于模型避开动作空间中的不合理区域，从而实现更高效的推理并提升成功率。此外，这种结构化自适应使同一策略能够跨多样化任务与环境进行泛化，因为它可以通过有原则的约束而非记忆行为来调整自身行为以适应新情境。实际上，测试时自适应（Test-Time Adaptation）将通用策略即时转化为任务专用策略，同时提升了鲁棒性（Robustness）与样本效率（Sample Efficiency）。具体而言，我们引入了 ADP，一种测试时自适应扩散策略，通过三种互补机制将结构注入去噪过程：• 我们嵌入由末端执行器与目标物体之间相对位姿引导的流形约束，提供类似梯度的引导，将去噪轨迹导向动作空间中与任务相关的区域。

- 我们使用高斯球面先验（Gaussian Spherical Prior）优化反向扩散动力学，将去噪步骤约束在捕捉噪声分布高置信区域的高维球面上，从而减少回溯并提高动作采样效率。

- 我们提出一种基于快速（Fast）的粗略初始化策略

在测试时对夹爪与目标场景的点云进行全局配准，确保扩散过程从几何上有意义的配置开始。ADP 无需训练且即插即用，能够与现有扩散策略无缝部署。基于预训练的 3D 扩散执行器 [29]，我们开发了 ADPro，提升了样本效率、任务成功率和零样本泛化能力，在长时程任务上以最多减少 25% 的推理步骤和提升 9 个百分点的成功率，超越了最先进的基于扩散的基线方法。

II. 相关工作

a) 用于机器人控制的扩散策略：扩散策略 [20] – [33] 是一种新型机器人操作方法，将扩散模型 [35] – [38] 与模仿学习相结合，因其能够生成复杂且逼真的轨迹而受到广泛关注。这些模型通过行为克隆进行训练，以视觉输入、机器人状态甚至语言指令为条件生成动作序列。现有方法根据输入数据类型大致可分为两大类。第一类依赖 2D 观测 [20], [22], [25], [27], [30]，通常使用单张或多张 RGB 图像。由于 2D 图像受视角和纹理影响较大，此类方法对视角变化以及物体颜色和纹理的变化较为敏感，导致鲁棒性有限。第二类利用 3D 视觉信息 [21], [23], [26], [28], [29], [31] – [33]，如点云或 RGB-D 图像，提供更丰富的环境表示，并对视角和外观变化具有更强的泛化能力。然而，这些方法面临两个关键挑战：

- (1) 对物体形状、位置和任务的泛化能力有限。大多数方法仅依赖扩散模型的梯度估计，未结合目标物体的引导来更新动作。
- (2) 推理速度慢。

逆向扩散过程通常需要约 100 次迭代，限制了动作生成的效率。本文通过利用测试数据的引导，并施加球面流形和初始动作约束，有效解决了这两个挑战。

b) 机器人策略泛化：在机器人策略学习中，实现可泛化的策略一直是一个长期目标 [39], [40]。通常采用两种主要方法来提高控制器的泛化能力：在大规模多样化数据集上训练模型，以及利用大型视觉语言基础模型的广泛泛化能力。例如，一些研究者通过包含更多物体实例或类别 [23], [41] – [45]、新颖物体组合 [46], [47]、多样化语言指令 [21], [48] – [50] 以及多种机器人形态 [51] 来扩展其训练数据集。

近期工作如 RT-2 [52]、RoboFlamingo [53]、 $\pi 0$ [54]、ECoT [55] 和 Robouniview [56] 已采用预训练的视觉语言模型作为机器人策略的主干，以增强鲁棒性和泛化能力。其他研究探索了替代视角，包括领域自适应 [57] – [62]、持续学习 [63] – [65] 以及先验约束的使用 [31], [66], [67]。尽管近期取得了进展，大多数方法侧重于在训练期间改进策略学习，而在推理期间对测试时数据的潜在指导利用不足。一个关键挑战在于如何利用观测数据有效构建指导以提升泛化能力，这一问题在很大程度上仍未得到探索，也是本文旨在解决的核心问题。

III. 方法

动作生成本质上涉及产生非欧几里得数据，因为动作位于 SE(3) 李群中。因此，将更高效的扩散策略与精心设计的初始噪声动作提议相结合，可以显著提升生成效率。如图 2 所示，所提出的用于操作动作生成的自适应扩散策略通过两项关键改进加速了过程。第一，流形约束去噪——引导更新沿任务流形和球面流形进行，有效增强其泛化能力并防止不必要的回溯（见图 4）。第二，任务感知初始化——驱动扩散过程朝向更准确的方向而非随机噪声，有效减少所需的去噪步骤数。这些组件共同将动作生成从盲目的随机采样转变为几何感知的自适应优化过程。

A. 问题定义。

给定一组包含连续值动作-观测对的专家演示，记为 $\mathcal{D} = \{(\mathbf{O}^k, \mathbf{A}^k)\}_{k=1}^N$ ，我们的目标是拟合一个视觉运动策略，将观测空间 $\mathbf{O}$ 映射到动作空间 $\mathbf{A}$ 。在本文中，每个观测 $\mathbf{O}$ 是两幅带位姿的 RGB-D 图像或点云。每个动作 $\mathbf{A} := (\mathbf{v}, \mathbf{R}, w)$ 是一个 7D 位姿由位置 (x, y, z) 、旋转 $(roll, pitch, yaw)$ ，和夹爪宽度 w 定义。因此，动作的位姿 $(\mathbf{v}, \mathbf{R})$ 位于 SE(3) 流形上，其中 $\mathbf{R} \in \text{SO}(3)$ 是旋转矩阵， $\mathbf{v} \in \mathbb{R}^3$ 是平移向量。设 $\mathbf{P}^k \in \mathbb{R}^{4 \times 4}$ 为夹爪在世界坐标系中的当前位置，动作 $\mathbf{A}^k$ 指定夹爪的期望位姿。该位姿可以是绝对的（ $\mathbf{P}^k = (\mathbf{R}^k, \mathbf{v}^k)$ ，也称为位置控制）或相对的（ $\mathbf{P}^k = (\prod_{i=1}^k \mathbf{R}^i + \sum_{i=1}^k \mathbf{v}^i)$ ，也称为速度控制）。为了便于在标准扩散过程中使用加法和减法进行噪声注入和去除，我们在扩散和去噪过程中将 $\mathbf{A}^k$ 向量化为向量 $\mathbf{a}^k$ 。去噪后，无噪声的动作向量被转换回 $\mathbf{R}$ 、 $\mathbf{v}$ 和 w 以进行操作。对于轨迹生成， $\mathbf{O} = \{\mathbf{O}^{k-(m-1)}, \dots, \mathbf{O}^{k-1}, \mathbf{O}^k\}$ ， $\mathbf{a} = \{\mathbf{a}^k, \mathbf{a}^{k+1}, \dots, \mathbf{a}^{k+(n-1)}\}$ ，其中 m 是观测的历史步数， n 是未来动作步数。由于扩散策略既涉及跨时间的多步动作轨迹，也涉及每个动作的去噪轨迹

鉴于视觉语言模型（Vision-Language Models, VLMs）强大的表示和泛化能力




图 2: 我们的自适应扩散策略 ADPro 的流程。我们首先通过粗略配准模块提出合理的初始噪声动作 $\mathbf{a}_M$ ，然后在观测和流形约束的指导下对 $\mathbf{a}_M$ 进行去噪（详见公式 (9)）。

单个动作，我们遵循标准符号约定以避免歧义：上标表示操作轨迹中的单个动作 $\mathbf{a}^k$ ，而下标表示单个动作扩散去噪过程中的噪声动作轨迹 $\mathbf{a}_t$ 。

B. 预备知识

a) 扩散策略：扩散策略 (DP) [20] 将操作过程建模为马尔可夫过程，并利用去噪扩散概率模型 (DDPM) [35] 对具有多模态视觉运动输入 $\mathbf{O}$ 的操作策略进行建模。它使用由 θ 参数化的网络 ε_θ 学习噪声预测函数 $\varepsilon_\theta(\mathbf{O}, \mathbf{a} + \varepsilon_t, t) = \varepsilon_t$ 。为了训练网络 ε_θ 准确预测输入 $\mathbf{a} + \varepsilon_t$ 的噪声分量，将随机噪声 ε_t （以随机采样的去噪步骤 t 为条件）添加到 $\mathbf{a}$ 上。然后，DP 最小化损失 $\mathcal{L} = \|\varepsilon_\theta(\mathbf{O}, \mathbf{a} + \varepsilon_t, t) - \varepsilon_t\|^2$ ，这等价于匹配去噪得分 $\nabla_{\mathbf{a}} \log p(\mathbf{a}|\mathbf{O})$ [20]。在推理过程中，给定观测 $\mathbf{O}_k$ ，DP 从随机动作 $\mathbf{a}_T^k \sim \mathcal{N}(0, I)$ 开始执行一系列 T 个去噪步骤，以生成由下式定义的动作 $\mathbf{a}_0^k$

$$\mathbf{a}_{t-1}^k = \alpha_t(\mathbf{a}_t^k - \gamma_t \varepsilon_\theta(\mathbf{O}^k, \mathbf{a}_t^k, t) + \epsilon), \quad (1)$$

其中 $\epsilon \sim \mathcal{N}(0, \sigma_t^2 I)$ 。 $\alpha_t, \gamma_t, \sigma_t$ 是去噪步骤 t （也称为噪声调度）的函数。动作 $\mathbf{a}_0$ 预期为来自专家策略 $\pi: \mathbf{O} \mapsto \mathbf{a}$ 的对应动作。b) 免训练引导扩散模型：分类器引导 [68] 是首个以免训练方式利用预训练扩散模型进行条件图像生成的工作。具体而言，考虑贝叶斯规则 $p(x|y) = p(y|x)p(x)/p(y)$ ，它通过附加似然项 $p(x_t|y)$ 引入给定条件：

$$\nabla_{x_t} \log p(x_t|y) = \nabla_{x_t} \log p(x_t) + \nabla_{x_t} \log p(y|x_t), \quad (2)$$

其中 y 是类别标签， $x_t \sim \mathcal{N}(\bar{\alpha}_t x_0, (1 - \bar{\alpha}_t)I)$ ， $\bar{\alpha}_t := \prod_{s=1}^t \alpha_s$ 。无需训练时间相关分类器来估计 $p(y|x_t)$ ，这些免训练引导扩散模型 [68]–[70] 仅需预训练扩散先验 ε_θ 和定义在支撑集上的可微损失 $L(x_0, y)$

的 x_0 。它们使用特威迪公式，通过基于 x_t 估计 $\hat{x}_0$ 来计算 $\nabla_{x_t} \log p(y|x_t)$ ：

$$\begin{aligned} \hat{x}_0(x_t) &\approx \mathbb{E}[x_0|x_t] = (x_t + \sqrt{1 - \bar{\alpha}_t} \nabla_{x_t} \log p(x_t)) / \sqrt{\bar{\alpha}_t}, \\ \nabla_{x_t} \log p(y|x_t) &\approx \nabla_{x_t} \log p(y|\hat{x}_0(x_t)) = \eta \nabla_{x_t} L(\hat{x}_0(x_t), y). \end{aligned} \quad (3)$$

然后它们使用 $L(x_0, y)$ 的估计似然进行额外校正步骤：

$$x_{t-1} = \underbrace{DDIM(x_t, \varepsilon_\theta(x_t, t), t)}_{\text{sampling step}} - \underbrace{\eta \nabla_{x_t} L(\hat{x}_0(x_t), y)}_{\text{correction step}}. \quad (4)$$

C. 流形约束去噪

引导式扩散模型在推理阶段展现出强大的泛化能力，在生成图像等欧几里得数据方面取得了显著成功。然而，现有方法大多局限于图像领域，而在机器人操作中，构建有效的引导仍是一项关键挑战。在机器人操作中，普通扩散策略（非引导式）采用 $\varepsilon_\theta(\mathbf{O}^k, \mathbf{a}_t^k, t)$ 作为去噪方向，这是动作细化的主要更新方式。然而，该方法并未显式利用目标物体来更有效地优化动作。为解决这一问题，我们提出了 ADP，它引入了几何感知更新。具体而言，我们确定了两个互补的流形来约束和引导去噪过程：任务流形和球面流形。a) 任务流形：机器人动作位于 SE(3) 李群上，末端执行器与目标物体之间的相对位姿定义了朝向任务成功的自然梯度方向。为利用这一结构，我们将观测引导 $\nabla_{\mathbf{a}} L(\cdot, \cdot)$ 融入扩散过程，沿任务流形的测地路径引导更新。由此得到以下引导式扩散策略变体：

$$\tilde{\mathbf{a}}_{t-1}^k = DDPM(\mathbf{a}_t^k, \varepsilon_\theta(\mathbf{O}^k, \mathbf{a}_t^k, t), t), \quad (5)$$

$$\mathbf{a}_{t-1}^k = \tilde{\mathbf{a}}_{t-1}^k - \eta \nabla_{\mathbf{a}} L(\tilde{\mathbf{A}}_{t-1}^k \mathbf{O}^{k,0}, \mathbf{O}^{k,1}). \quad (6)$$

此处， $\mathbf{O}^{k,0}$ 和 $\mathbf{O}^{k,1}$ 分别表示从 $\mathbf{O}_k$ 中提取的夹爪点云和场景点云。 $\tilde{\mathbf{A}}_{t-1}^k$ 表示 $\tilde{\mathbf{a}}_{t-1}^k$ 的矩阵形式，而 $L(\cdot, \cdot)$ 是倒角距离。然而，由于 $\tilde{\mathbf{A}}_{t-1}^k$ 是含噪动作而非机器人执行的最终动作，式 (6) 提供的引导不够精确。受 DDPM[35] 启发，我们得到

the noise-free action $\hat{\mathbf{a}}_0^k$ from $\hat{\mathbf{a}}_{t-1}^k$ using the diffusion function, and reformulate Eq. (6) as

$$\hat{\mathbf{a}}_0^k = (\hat{\mathbf{a}}_{t-1}^k - \sqrt{1 - \bar{\alpha}_t} \varepsilon_\theta(\mathbf{O}^k, \mathbf{a}_t^k, t)) / \sqrt{\bar{\alpha}_t}, \quad (7)$$

$$\mathbf{a}_{t-1}^k = \hat{\mathbf{a}}_{t-1}^k - \eta \nabla_{\mathbf{a}} L(\hat{\mathbf{A}}_0^k \mathbf{O}^{k,0}, \mathbf{O}^{k,1}), \quad (8)$$

其中 $\hat{\mathbf{A}}_0^k$ 表示 $\hat{\mathbf{a}}_0^k$ 的矩阵形式 $\mathbf{O}^{k,0}$ 。在观测引导下， $\nabla_{\mathbf{a}} L(\cdot, \cdot)$, Eq. (8) 约束了逆扩散过程的更新方向并缩短了扩散轨迹。此外，通过将测试阶段的观测点云纳入引导，式 (8) 有效增强了扩散策略的泛化能力。然而，它隐含地依赖一个强假设——线性流形，这可能导致流形偏差和轨迹中不必要的回溯。b) 球形流形：为最小化扩散过程中的不必要回溯（如图 4 中的扩散器所示），我们在逆向扩散策略中引入流形约束，确保去噪更新更贴近流形的测地路径。具体而言，我们采用高斯球形先验 [70] 来细化逆向扩散步长。高斯球形先验将噪声采样空间约束为半径为 $\sqrt{d\sigma}$ 的超球面上的均匀分布，使更新步长保持在置信区间内。此处， d 是动作维度、批大小和待预测动作数 n 的乘积。如 [70] 所述，当 d 足够大时， $\sqrt{d\sigma}$ 维各向同性高斯分布 $\mathcal{N}(0, \sigma^2 I)$ 近似于半径为 $\sqrt{d\sigma}$ 的超球面上的均匀分布。于是，精炼后的免训练自适应扩散策略可表示为：

$$\mathbf{a}_{t-1}^k = \hat{\mathbf{a}}_{t-1}^k - \sqrt{d\sigma} \frac{\nabla_{\mathbf{a}} L(\hat{\mathbf{A}}_0^k \mathbf{O}^{k,0}, \mathbf{O}^{k,1})}{\|\nabla_{\mathbf{a}} L(\hat{\mathbf{A}}_0^k \mathbf{O}^{k,0}, \mathbf{O}^{k,1})\|}, \quad (9)$$

通过在同一流形约束去噪原理下统一这些约束，自适应扩散策略将逆向扩散过程转化为结构化轨迹：任务流形提供方向性，球形流形提供稳定性，二者共同实现更高效、更鲁棒的动作生成。

D. 任务感知初始化

给定末端执行器 $\mathbf{O}^{k,0}$ 和目标场景 $\mathbf{O}^{k,1}$ ，初始动作的搜索空间应限制在特定局部区域，而非像现有扩散策略那样跨越整个噪声空间。依赖预定义噪声分布在整个噪声空间采样不仅增加了后续去噪的复杂度，还降低了操作成功率。更有效的方法是通过计算粗略配准来提出合理的初始动作，从而简化去噪并减少所需扩散步数。

为此，自适应扩散策略 (ADP) 引入了一个任务感知的初始化模块。我们并非从无信息的先验分布中采样，而是计算夹爪与目标场景点云之间的粗略对齐。在实现中，我们采用快速全局配准 (Fast Global Registration, FGR) 算法 [71] 来对齐观测数据 $\mathbf{O}^{k,0}$ 与 $\mathbf{O}^{k,1}$ 。FGR 输出一个旋转矩阵 $\mathbf{R} \in \text{SO}(3)$ 和一个平移向量 $\mathbf{v} \in \mathbb{R}^3$ ，二者共同定义了

初始含噪动作 $\mathbf{a}_M^k$ ，对应于原始扩散过程第 M ($M \leq T$ 步) 的含噪输出。与经典的迭代最近点 (Iterative Closest Point, ICP) 算法 [72] 相比，FGR 具有更高的效率和鲁棒性，尤其在处理含噪或大规模点云时表现突出。

$$\mathbf{a}_M^k = \text{FGR}(\mathbf{O}^{k,0}, \mathbf{O}^{k,1}) \quad (10)$$

在实践中，我们从每个点云中随机采样 4096 个点，并使用 FGR 将末端执行器点云对齐到场景点云。由于仅需粗略估计，最多 6 至 10 次迭代即可满足要求。通过将扩散过程初始化为任务相关区域内，我们有效缩小了搜索空间并加速了收敛。消融研究证实，移除该组件会显著降低成功率和效率。

E. 统一自适应扩散策略与误差分析

综合上述组件，ADP 作为预训练扩散策略的测试时优化器发挥作用：(i) 初始化将过程置于合理区域附近，(ii) 流形约束引导更新沿几何结构而非噪声方向进行，(iii) 球形约束正则化步长幅度以防止不稳定。在机器人操作中，ADP 生成控制动作，并以即插即用的方式与现有扩散策略无缝集成，无需重新训练。具体而言，我们首先利用式 (10) 生成初始含噪动作 $\mathbf{a}_M^k$ ，然后通过式 (5)、式 (7) 和式 (9) 迭代去噪，直至获得最终无噪动作 $\mathbf{a}_0^k$ 。

考虑到三维机器人策略在不同相机视角下展现出优于二维策略的泛化能力，并且在测试中更有效地处理新视角 [26], [29], [32]，我们采用三维扩散行为者 (3D Diffuser Actor) 实现自适应扩散策略 (ADP)，从而创建 ADPro。ADPro 的条件噪声预测器 ε_θ 利用预训练的三维变换器 (Transformer) 网络。为进一步增强模型在不同任务上的泛化能力，我们将任务指令作为文本提示，由视觉语言模型 CLIP 的文本编码器编码 [73]。随后，通过交叉注意力机制将文本特征与视觉特征融合，实现语义与视觉信息更有效的整合。

错误分析。 所提出的 ADP 的鲁棒性依赖于 FGR 算法和预训练扩散模型。当式 (10) 中的 $\mathbf{a}_M^k$ 满足 $\|\mathbf{a}_M^k - \mathbf{a}_0^k\| < \delta_1$ ，时，预训练 ε_θ 在步骤 M 的噪声动作 $\hat{\mathbf{a}}_M^k$ 满足，则 $\|\hat{\mathbf{a}}_M^k - \mathbf{a}_0^k\| < \delta_2$ $\|\mathbf{a}_M^k - \hat{\mathbf{a}}_M^k\| < \delta_1 + \delta_2$ 。此外， δ_1 是可控的，可通过增加 FGR 算法的迭代次数来减小，从而降低 δ_1 并减小误差上界。这确保了所提出的 ADP 的鲁棒性。

四、实验

我们设计实验以回答以下问题：

i) 所提出的扩散策略是否提升了操作性能？ii) ADPro 在泛化性和效率方面表现如何？iii) ADPro 能否应用于真实世界的机器人操作任务？我们首先在




图 3: 原始扩散策略与我们的 ADPro 之间的轨迹比较。我们展示了两个不同的任务: “形状分类”和“插销”。对于每个任务, 我们可视化初始状态, 随后是每个动作后从腕部相机捕获的连续观测。ADPro 仅用三个动作就完成了第一个任务, 展示了效率和准确性。

RLBench [74] 和 CALVIN [75]。随后, 在第四-C 节和第四-D 节中, 我们在 CALVIN 和一个真实世界数据集上验证了其在泛化性和效率方面的提升。最后, 我们在第四-E 节进行了消融研究, 以验证每个核心模块的有效性。

一、基线

我们在四个数据集上使用十三个基线评估了所提出的方法, 包括 C2F-ARM [76]、PerAct [77]、Hive-Former [78]、PolarNet [79]、RVT [80]、Act3D [81]、HULC [82]、RoboFlamingo [53]、SuSIE [83]、GR-1 [84], 以及三个扩散策略: 3D 扩散策略 (DP3) [26]、3D 扩散行为器 (Diffuser) [29]、VPDD [22]。对于 VPDD, 我们使用其官方论文中报告的结果。由于不存在公开可用的 CALVIN 上 DP3 的预训练模型, 我们在 CALVIN 上训练它以确保公平比较。对于其余基线, 我们采用 3D 扩散行为器的结果。首先, 我们利用基准 RLBench 和 CALVIN 来展示所提出的 ADP 在任务成功率和推理速度方面的有效性。同时, 我们展示了我们的策略在 Franka Panda 机器人真实世界场景中的泛化能力。我们还比较了

与不考虑流形或初始噪声约束的消融版本。

二、RLBench 上的性能

RLBench 是一个仿真环境, 其中使用 Franka Panda 机器人以 BiRRT [85] 作为其运动规划器来操纵场景。在 RLBench 上, 所有方法都需要预测下一个末端执行器关键姿态。我们在 18 个任务上评估 ADPro, 如 [29] 所示, 每个任务有 2-60 个变体。我们通过任务完成成功率来评估策略, 即达到语言指令中指定目标条件的执行轨迹比例 [77]、[81]。表 I 给出了评估指标。基线性能报告自 Diffuser, 我们的结果是三个随机种子的平均值。如表 I 所示, 我们的方法始终优于普通扩散策略 (Diffuser), 在“扫入簸箕”、“形状分类”和“插入销钉”任务上增益尤为显著, 平均成功率提高了 2.6 个百分点。图 3 进一步说明了这些优势: 在“形状分类”上, ADPro 通过三个直接动作完成任务, 而 Diffuser 需要四个动作且存在绕行; 在“插入

表 I: RLBench 上三个随机种子的平均成功率。ADPro 在大多数任务上大幅优于所有先前技术。粗体表示最佳；下划线表示次佳。

	Avg. Success $\uparrow$	open drawer	slide block	sweep to dustpan	put in safe	turn tap	put in drawer	place wine	stack cups	sort shape	insert peg	drag stick	place cups	close jar	meat off grill	stack blocks	push buttons	screw bulb	put in cupboard
C2F-ARM	20.1	20	16	0	12	68	4	8	0	8	4	24	24	0	20	0	72	8	0
PerAct	49.4	88.0	74.0	52.0	86.0	88.0	51.2	44.8	2.4	16.8	5.6	89.6	2.4	55.2	70.4	26.4	0	17.6	28.0
HiveFormer	45	52	64	28	76	80	68	80	0	8	0	76	0	52	100	8	84	8	32
PolarNet	46	84	56	52	84	80	32	40	8	12	5	92	0	36	100	4	96	44	12
RVT	62.9	71.2	81.6	72.0	91.2	93.6	88.0	91.6	26.4	36.0	11.2	99.2	4.0	52.0	88.0	28.8	100	48.0	49.6
Act3D	63.2	78.4	96.0	<u>86.4</u>	95.2	94.4	91.2	59.2	9.6	29.6	24.0	80.8	3.2	96.8	95.2	4.0	93.6	32.8	67.2
Diffuser	81.3	<u>89.6</u>	<u>97.6</u>	84.0	<u>97.6</u>	<u>99.2</u>	<u>95.0</u>	<u>93.6</u>	47.2	<u>44.0</u>	65.6	100.0	24.0	96.0	96.8	<u>66.8</u>	98.4	<u>82.4</u>	<u>85.6</u>
VPDD	56.2	-	70.7	40.0	70.7	88.7	24.0	60.0	<u>56.0</u>	-	<u>73.7</u>	66.7	30.7	37.3	73.3	56.0	58.7	61.3	30.67
Ours	83.9	93.1	100.0	97.0	98.5	99.5	95.2	94.0	56.5	50.0	74.5	100.0	<u>25.4</u>	<u>96.2</u>	95.6	67.3	<u>98.6</u>	83.1	85.9




图 4: 针对任务“打开抽屉”和“扫入簸箕”的完整动作所有分量 ($x, y, z, r_1, r_2, r_3, r_4, w$) 的比较。横轴和纵轴分别表示动作步骤和参数值。本文提出的 ADPro 有效缓解了原始扩散策略中的坐标和角度回溯行为。

在任务“peg”中，ADPro 实现了早期对齐并直接插入，无需回溯，而 Diffuser 则需要额外的对齐动作才能完成任务。这一可视化比较进一步证明了本文方法在效率和稳定性方面的优势。此外，图 4 比较了 7 自由度机械臂的所有参数——包括位置 (x, y, z)、旋转 (r_1, r_2, r_3, r_4) 和夹爪宽度 (w)——在不同任务中的表现。本文方法能够更快、更准确地收敛到目标抓取构型，而 Diffuser 则表现出显著的回溯。这些结果验证了本文引导机制和初始化策略的有效性。

值得注意的是，ADPro 以更少的步骤完成任务，展示了在生成高质量操作轨迹方面的卓越效率。

在图 5 中，本文考察了每次动作预测的逆向扩散过程。为增强可读性，本文计算了预测动作与真实值之间的均方误差 (MSE)，值越接近零表示预测越好。结果表明，在生成过程中引入本文的引导显著减少了不必要的回溯并提高了稳定性，从而产生了更加平滑的轨迹。




图 5: 任务“扫入簸箕”中前四个动作的扩散步骤演化。Diffuser 的 MSE 表现出较大波动, 表明其轨迹中存在显著的回溯行为。

表 II: 在 CALVIN 上的零样本长时程评估。

Method	Task completed in a row					Avg. Len $\uparrow$	Avg. Time(s) / NDS $\downarrow$
	1	2	3	4	5		
HULC	41.8	16.5	5.7	1.9	1.1	0.67	
RoboFlamingo	82.4	61.9	46.6	33.1	23.5	2.48	
SuSIE	87.0	69.0	49.0	38.0	26.0	2.69	
GR-1	85.4	71.2	59.6	49.7	40.1	3.06	
DP3	53.9	44.7	38.0	34.3	29.0	2.00	36.1 / 25
DP3+ADP	78.4	63.7	54.9	39.8	30.2	2.67	27.3 / 10
Diffuser	93.8	80.3	66.2	53.3	41.2	3.35	48.3 / 25
Ours	94.7	83.0	73.6	61.4	51.1	3.64	36.2 / 10

生成轨迹。值得注意的是, 对于“动作 2”和“动作 4”, 由于对齐, 扩散过程的初始位置更接近真实值, 这有助于更快地收敛到准确预测, 并减少所需的扩散步骤数。在图 6 的左面板中, 我们改变用于生成的扩散步骤数, 并评估在 RLbench 上的平均成功率。我们发现, 我们的方法显著优于基线, 特别是在使用少量扩散步骤时。值得注意的是, 我们的方法仅用 20 步就达到了 72% 的成功率, 而基线至少需要 50 步才能达到相当的性能。此外, 我们的方法在所有扩散步骤设置下都一致地优于基线。

C. 在 CALVIN 上的泛化

CALVIN 基准建立在 PyBullet [86] 模拟器上, 具有一个 Franka Panda 机器人手臂与其场景交互。它包含四个环境 (A、B、C 和 D) 中的 34 个任务, 每个环境都配备了一张桌子、滑动门、抽屉、LED 按钮、灯泡开关和三个彩色积木。环境在桌子纹理和物体放置上有所不同。CALVIN 提供了 24 小时的非结构化游戏数据, 其中 35% 用自然语言标注。我们在零样本泛化设置下评估模型: 在环境 A、B 和 C 上训练, 在 D 上测试。由于 CALVIN 缺乏运动规划器, 模型必须直接预测机器人姿态轨迹。为了公平比较, 我们遵循与 Diffuser 相同的评估协议。每种方法每个序列最多预测 60 个动作, 并在三个随机种子上进行评估。我们报告成功率和完成的连续任务的平均数量。此外, 我们比较了 DP3 和 Diffuser 在任务完成时间 (秒) 和所需的扩散步骤数 (NDS) 方面的表现, 结果




图 6: 评估扩散步骤对两个基准的影响: RLbench 和 Acronym。

如最后一列所示。其他方法因未采用基于扩散的策略而被排除在此比较之外。如表二所示, 本文方法 (最后一行) 在零样本长时程预测任务上始终优于现有方法, 第 5 个关键姿态的成功率提升约 10 个百分点, 并生成平均长度最长的轨迹。此外, DP3 与 DP3+ADP (将本文提出的 ADP 集成到 DP3 中) 之间的成对比较, 以及 Diffuser 与本文方法 (Diffuser 结合 ADP) 之间的比较, 凸显了 ADP 作为即插即用模块的有效性。对于 DP3+ADP, 本文仅调整输入格式和评估协议以对齐 CALVIN 基准, 未改动核心模型。总体而言, ADP 显著提升了扩散策略的泛化能力, 同时提高了生成效率, 计算时间减少约 25%。

D. 真实世界数据上的泛化性

Real_World_Play (RealWP) [87] 包含专家使用 Franka Panda 机器人采集的 9 小时非结构化真实世界数据。该数据集涵盖超过 25 种不同的操作技能, 因其非结构化且有时次优的特性而高度多样且具有挑战性。共有 3605 个回合标注了机器人行为的语言描述。每个回合包含来自静态相机和夹爪安装相机的 RGB-D 图像、本体感知数据以及 7 自由度动作。由于 RealWP 缺少运动规划器, 本文预测夹爪姿态轨迹, 与 CALVIN 类似。为此, 本文使用 3D Diffuser Actor 的算法提取具有显著运动变化的帧作为关键姿态。该过程为每个回合生成 6、7 或 8 步的轨迹。为评估 ADP 的泛化能力, 本文直接将 CALVIN 上训练的模型应用于顺序预测五个关键姿态。连续五步的准确率

表三：评估 ADPro 在 RealWP 上五个连续关键姿态预测的泛化能力，包括微调与未微调的情况。

Methods	with fine-tuning						without fine-tuning						Avg. Time(s)
	1	2	3	4	5	Avg. Len	1	2	3	4	5	Avg. Len	
Diffuser	66.0	49.5	36.6	26.8	18.5	1.97	38.8	26.5	16.3	8.2	2.1	0.92	0.95
Ours	86.5	67.5	52.1	39.0	27.7	2.73	53.1	40.8	32.7	24.5	16.3	1.18	0.85

表四：4 个 Acronym 物体类别中抓取成功率和推理时间的比较。

	Bottle		Laptop		Book		ToyFigure	
	Avg. Success	Avg. Time	Avg. Success	Avg. Time	Avg. Success	Avg. Time	Avg. Success	Avg. Time
SEDF(S=20)	48.0	0.019	37.1	0.028	61.2	0.020	38.6	0.024
SEDF(S=120)	51.4	0.133	41.9	0.116	66.8	0.113	44.0	0.110
SEDF+ADP(S=20)	52.7	0.025	43.0	0.032	73.1	0.027	44.0	0.029

轨迹（如图三右侧所示）表明，我们的方法在无需微调的情况下，也能增强跨任务和跨环境的泛化能力。我们进一步使用 3,605 个回合中的 80% 对模型进行微调，并在剩余的 20% 上进行评估。结果（如图三左侧所示）显示，经过微调后，我们的 ADPro 将策略的单步成功率大幅提升了 20 个百分点。

E. 消融研究

所提出的自适应策略可以以即插即用的方式无缝集成到现有的扩散策略中。为了评估其在提高操作成功率和效率方面的有效性，我们将其集成到三个基线模型中：DP3、SE(3)-扩散场（SEDF）[88] 和 **Diffuser**。随后，我们对它们的结果进行了定量比较，如表二和表四所示。对于 SEDF，我们在 Acronym 数据集 [89] 上评估预训练模型，该数据集为各种 ShapeNet [90] 对象提供了成功的六自由度抓取。抓取成功率在仿真中使用 Isaac Gym [91] 进行评估，遵循与 [88] 相同的评估协议。我们在四个代表性对象类别上评估模型：瓶子、笔记本电脑、书籍和玩具图形，每个类别从数据集中选择前 50 个实例。对于每个类别，我们报告平均抓取成功率和每次抓取的平均生成时间（以秒为单位），分别在低步数 (S=20) 和全步数 (S=120) 扩散设置下。结果总结在表四中。我们的方法（SEDF+ADP）与基线 SEDF (S=20) 和高步数 SEDF (S=120), 相比，取得了相当或更优的成功率，同时与 SEDF (S=120). 相比，抓取生成速度最高可提升 5× 倍。此外，我们在 61 个不同类别的多样化对象集上评估多对象模型，每个对象执行 200 次生成的抓取。如图六所示，集成 ADP 在所有扩散步数设置下均持续提升性能。平均而言，与相同步数的 SEDF 相比，我们的方法成功率提高了 2.7%。此外，为了评估我们 ADPro 主要组件的有效性，我们考虑了以下消融版本模型：i) 无初始噪声约束（INC），ii) 无球面高斯约束（SGC），

iii) 无观测引导（OG）。在 RLbench 和 CALVIN 基准上的消融研究表明，所有三个模块都对模型性能有有效贡献。值得注意的是，移除

如表五所示，原始生成模块导致性能显著下降并增加时间成本。

表五：消融实验。本文模型显著优于未使用初始噪声约束、高斯流形约束或观测引导的对照模型。

版本	RLBench CALVIN	平均成功率	平均时间（秒）	平均长度	平均时间（秒）
w/o INC	82.4	421.6	3.60	35.2	
w/o SGC	82.1	418.4	3.57	35.8	
w/o OG	81.6	488.7	3.38	49.3	
ADPro	83.9	435.8	3.64	36.2	

五、结论

本文提出了一种新颖的自适应扩散策略（ADPro），该策略利用观测数据中的观测引导并约束扩散过程，以提升机器人操作中的泛化能力。与传统方法不同，ADPro 无需重新训练即可为未见任务生成可迁移的动作。通过施加球形流形约束，扩散轨迹减少了回溯并提高了效率。此外，通过使用快速高斯上升（FGR）算法而非随机噪声初始化动作，ADPro 受益于更具信息量的起始点。大量实验表明，本文提出的免训练方法在泛化性和效率上均优于现有方法，证实了该方法的潜力。本文方法的局限性在于依赖末端执行器和场景点云作为输入，这可能限制其适用场景。然而，此类数据在某些数据集中易于获取，并且在实际机器人平台上也可行地采集。在未来的工作中，我们将探索更灵活的引导形式，以减少对特定输入模态的依赖。

参考文献

[1] A. T. Miller and P. K. Allen, “Graspit! a versatile simulator for robotic grasping,” *IEEE Robotics & Automation Magazine*, vol. 11, no. 4, pp. 110–122, 2004.

[2] Y. Li, J. L. Fu, and N. S. Pollard, “Data-driven grasp synthesis using shape matching and task-based pruning,” *IEEE Transactions on visualization and computer graphics*, vol. 13, no. 4, pp. 732–747, 2007.

[3] H. Dang, J. Weisz, and P. K. Allen, “Blind grasping: Stable robotic grasping using tactile feedback and hand kinematics,” in *2011 IEEE international conference on robotics and automation*. IEEE, 2011, pp. 5917–5922.

[4] W. Sun, Y. Wu, and X. Lv, “Adaptive neural network control for full-state constrained robotic manipulator with actuator saturation and time-varying delays,” *IEEE Transactions on Neural Networks and Learning Systems*, vol. 33, no. 8, pp. 3331–3342, 2021.

- [5] A. Ten Pas, M. Gualtieri, K. Saenko, and R. Platt, “Grasp pose detection in point clouds,” *The International Journal of Robotics Research*, vol. 36, no. 13–14, pp. 1455–1473, 2017.
- [6] H. Liang, X. Ma, S. Li, M. Görner, S. Tang, B. Fang, F. Sun, and J. Zhang, “Pointnetgpd: Detecting grasp configurations from point sets,” in *2019 International Conference on Robotics and Automation (ICRA)*. IEEE, 2019, pp. 3629–3635.
- [7] A. Mousavian, C. Eppner, and D. Fox, “6-dof graspnet: Variational grasp generation for object manipulation,” in *Proceedings of the IEEE/CVF international conference on computer vision*, 2019, pp. 2901–2910.
- [8] A. Murali, A. Mousavian, C. Eppner, C. Paxton, and D. Fox, “6-dof grasping for target-driven object manipulation in clutter,” in *2020 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2020, pp. 6232–6238.
- [9] H.-S. Fang, C. Wang, M. Gou, and C. Lu, “Graspnet-1billion: A large-scale benchmark for general object grasping,” in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2020, pp. 11 444–11 453.
- [10] Z. Bing, E. Alvarez, L. Cheng, F. O. Morin, R. Li, X. Su, K. Huang, and A. Knoll, “Robotic manipulation in dynamic scenarios via bounding-box-based hindsight goal generation,” *IEEE Transactions on Neural Networks and Learning Systems*, vol. 34, no. 8, pp. 5037–5050, 2021.
- [11] M. Gou, H.-S. Fang, Z. Zhu, S. Xu, C. Wang, and C. Lu, “Rgb matters: Learning 7-dof grasp poses on monocular rgbd images,” in *2021 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2021, pp. 13 459–13 466.
- [12] B. Zhao, H. Zhang, X. Lan, H. Wang, Z. Tian, and N. Zheng, “Regnet: Region-based grasp network for end-to-end grasp detection in point clouds,” in *2021 IEEE international conference on robotics and automation (ICRA)*. IEEE, 2021, pp. 13 474–13 480.
- [13] A. Depierre, E. Dellandréa, and L. Chen, “Scoring graspability based on grasp regression for better grasp prediction,” in *2021 IEEE international conference on robotics and automation (ICRA)*. IEEE, 2021, pp. 4370–4376.
- [14] W. Wei, Y. Luo, F. Li, G. Xu, J. Zhong, W. Li, and P. Wang, “Gpr: Grasp pose refinement network for cluttered scenes,” in *2021 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2021, pp. 4295–4302.
- [15] H. Ma and D. Huang, “Towards scale balanced 6-dof grasp detection in cluttered scenes,” in *Conference on robot learning*. PMLR, 2023, pp. 2004–2013.
- [16] B. Wei, X. Ye, C. Long, Z. Du, B. Li, B. Yin, and X. Yang, “Discriminative active learning for robotic grasping in cluttered scene,” *IEEE Robotics and Automation Letters*, vol. 8, no. 3, pp. 1858–1865, 2023.
- [17] R. Qin, H. Ma, B. Gao, and D. Huang, “Rgb-d grasp detection via depth guided learning with cross-modal attention,” in *2023 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2023, pp. 8003–8009.
- [18] H. Ryu, H.-i. Lee, J.-H. Lee, and J. Choi, “Equivariant descriptor fields: Se (3)-equivariant energy-based models for end-to-end visual robotic manipulation learning,” in *The Eleventh International Conference on Learning Representations*, 2023.
- [19] A. Vahabpour, T. Wang, Q. Lu, O. Pooladzandi, and V. Roychowdhury, “Diverse imitation learning via self-organizing generative models,” *IEEE Transactions on Neural Networks and Learning Systems*, vol. 36, no. 4, pp. 7145–7157, 2024.
- [20] C. Chi, Z. Xu, S. Feng, E. Cousineau, Y. Du, B. Burchfiel, R. Tedrake, and S. Song, “Diffusion policy: Visuomotor policy learning via action diffusion,” *The International Journal of Robotics Research*, p. 02783649241273668, 2023.
- [21] Y.-L. Wei, J.-J. Jiang, C. Xing, X.-T. Tan, X.-M. Wu, H. Li, M. Cutkosky, and W.-S. Zheng, “Grasp as you say: Language-guided dexterous grasp generation,” *Advances in Neural Information Processing Systems*, vol. 37, pp. 46 881–46 907, 2025.
- [22] H. He, C. Bai, L. Pan, W. Zhang, B. Zhao, and X. Li, “Learning an actionable discrete diffusion policy via large-scale actionless video pre-training,” *Advances in Neural Information Processing Systems*, vol. 37, pp. 31 124–31 153, 2025.
- [23] Y. Wang, X. Zhang, R. Wu, Y. Li, Y. Shen, M. Wu, Z. He, Y. Wang, and H. Dong, “Adamanip: Adaptive articulated object manipulation environments and policy learning,” in *The Thirteenth International Conference on Learning Representations*, 2025.
- [24] S. Li, R. Krohn, T. Chen, A. Ajay, P. Agrawal, and G. Chaitatzaki, “Learning multimodal behaviors from scratch with diffusion policy gradient,” *Advances in Neural Information Processing Systems*, vol. 37, pp. 38 456–38 479, 2025.
- [25] Z. Hou, T. Zhang, Y. Xiong, H. Pu, C. Zhao, R. Tong, Y. Qiao, J. Dai, and Y. Chen, “Diffusion transformer policy,” *arXiv preprint arXiv:2410.15959*, 2024.
- [26] Y. Ze, G. Zhang, K. Zhang, C. Hu, M. Wang, and H. Xu, “3d diffusion policy: Generalizable visuomotor policy learning via simple 3d representations,” in *ICRA 2024 Workshop on 3D Visual Representations for Robot Manipulation*, 2024.
- [27] D. Wang, S. Hart, D. Surovik, T. Kelestemur, H. Huang, H. Zhao, M. Yeatman, J. Wang, R. Walters, and R. Platt, “Equivariant diffusion policy,” *8th Annual Conference on Robot Learning*, 2024.
- [28] J. Yang, Z. Cao, C. Deng, R. Antonova, S. Song, and J. Bohg, “Equibot: Sim (3)-equivariant diffusion policy for generalizable and data efficient learning,” in *8th Annual Conference on Robot Learning*, 2024.
- [29] T.-W. Ke, N. Gkanatsios, and K. Fragkiadaki, “3d diffuser actor: Policy diffusion with 3d scene representations,” in *8th Annual Conference on Robot Learning*, 2024.
- [30] M. Zhu, Y. Zhu, J. Li, J. Wen, Z. Xu, N. Liu, R. Cheng, C. Shen, Y. Peng, F. Feng *et al.*, “Scaling diffusion policy in transformer to 1 billion parameters for robotic manipulation,” *arXiv preprint arXiv:2409.14411*, 2024.
- [31] X. Yao, Y. Zhou, Y. Meng, L. Dong, L. Hong, Z. Zhang, Z. Bing, K. Huang, F. Sun, and A. Knoll, “Pick-and-place manipulation across grippers without retraining: A learning-optimization diffusion policy approach,” *arXiv preprint arXiv:2502.15613*, 2025.
- [32] Y. Jia, J. Liu, S. Chen, C. Gu, Z. Wang, L. Luo, L. Lee, P. Wang, Z. Wang, R. Zhang *et al.*, “Lift3d foundation policy: Lifting 2d large-scale pretrained models for robust 3d robotic manipulation,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025.
- [33] J. Cao, Q. Zhang, J. Sun, J. Wang, H. Cheng, Y. Li, J. Ma, Y. Shao, W. Zhao, G. Han *et al.*, “Mamba policy: Towards efficient 3d diffusion policy with hybrid selective state models,” *arXiv preprint arXiv:2409.07163*, 2024.
- [34] Z. Liu, Y. Liu, and Y. Fang, “Diffusion model-based path follower for a salamander-like robot,” *IEEE Transactions on Neural Networks and Learning Systems*, 2025.
- [35] J. Ho, A. Jain, and P. Abbeel, “Denoising diffusion probabilistic models,” in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 6840–6851.
- [36] J. Song, C. Meng, and S. Ermon, “Denoising diffusion implicit models,” in *International Conference on Learning Representations*, 2021.
- [37] Y. Song, J. Sohl-Dickstein, D. P. Kingma, A. Kumar, S. Ermon, and B. Poole, “Score-based generative modeling through stochastic differential equations,” in *International Conference on Learning Representations*, 2021.
- [38] Z. Li, S. Li, Z. Wang, N. Lei, Z. Luo, and X. Gu, “Dpm-ot: A new diffusion probabilistic model based on optimal transport,” in *Proceedings of the IEEE International Conference on Computer Vision*, 2023.
- [39] L. P. Kaelbling, “The foundation of efficient robot learning,” *Science*, vol. 369, no. 6506, pp. 915–916, 2020.
- [40] Z. Li, A. Chapin, E. Xiang, R. Yang, B. Machado, N. Lei, E. Dellandrea, D. Huang, and L. Chen, “Robotic manipulation via imitation learning: Taxonomy, evolution, benchmark, and challenges,” *arXiv preprint arXiv:2508.17449*, 2025.
- [41] C. Finn and S. Levine, “Deep visual foresight for planning robot motion,” in *International Conference on Robotics and Automation (ICRA)*, 2017, pp. 2786–2793.
- [42] S. Levine, P. Pastor, A. Krizhevsky, J. Ibarz, and D. Quillen, “Learning hand-eye coordination for robotic grasping with deep learning and large-scale data collection,” *The International journal of robotics research*, vol. 37, no. 4–5, pp. 421–436, 2018.
- [43] A. Depierre, E. Dellandréa, and L. Chen, “Jacquard: A large scale dataset for robotic grasp detection,” in *2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. IEEE, 2018, pp. 3511–3516.
- [44] S. Young, D. Gandhi, S. Tulsiani, A. Gupta, P. Abbeel, and L. Pinto, “Visual imitation made easy,” in *Conference on Robot Learning*, 2021, pp. 1992–2005.
- [45] A. Stone, T. Xiao, Y. Lu, K. Gopalakrishnan, K.-H. Lee, Q. Vuong, P. Wohlhart, S. Kirmani, B. Zitkovich, F. Xia *et al.*, “Open-world object manipulation using pre-trained vision-language models,” *arXiv preprint arXiv:2303.00905*, 2023.
- [46] S. Dasari and A. Gupta, “Transformers for one-shot visual imitation,” in *Conference on Robot Learning*. PMLR, 2021, pp. 2071–2084.
- [47] E. Jang, A. Irpan, M. Khansari, D. Kappler, F. Ebert, C. Lynch, S. Levine, and C. Finn, “Bc-z: Zero-shot task generalization with robotic imitation learning,” in *Conference on Robot Learning*. PMLR, 2022, pp. 991–1002.

- [48] Y. Jiang, A. Gupta, Z. Zhang, G. Wang, Y. Dou, Y. Chen, L. Fei-Fei, A. Anandkumar, Y. Zhu, and L. Fan, "Vima: General robot manipulation with multimodal prompts," in *NeurIPS 2022 Foundation Models for Decision Making Workshop*, 2022.
- [49] S. Nair, E. Mitchell, K. Chen, S. Savarese, C. Finn *et al.*, "Learning language-conditioned robot behavior from offline data and crowd-sourced annotation," in *Conference on Robot Learning*. PMLR, 2022, pp. 1303–1315.
- [50] P. Ren, K. Zhang, H. Zheng, Z. Li, Y. Wen, F. Zhu, S. Ma, and X. Liang, "Surfer: A world model-based framework for vision-language robot manipulation," *IEEE Transactions on Neural Networks and Learning Systems*, 2025.
- [51] Q. Vuong, S. Levine, H. R. Walke, K. Pertsch, A. Singh, R. Doshi, C. Xu, J. Luo, L. Tan, D. Shah *et al.*, "Open x-embodiment: Robotic learning datasets and rt-x models," in *Towards Generalist Robots: Learning Paradigms for Scalable Skill Acquisition@ CoRL2023*, 2023.
- [52] A. Brohan, N. Brown, J. Carbajal, Y. Chebotar, X. Chen, K. Choromanski, T. Ding, D. Driess, A. Dubey, C. Finn *et al.*, "Rt-2: Vision-language-action models transfer web knowledge to robotic control," *arXiv preprint arXiv:2307.15818*, 2023.
- [53] X. Li, M. Liu, H. Zhang, C. Yu, J. Xu, H. Wu, C. Cheang, Y. Jing, W. Zhang, H. Liu *et al.*, "Vision-language foundation models as effective robot imitators," in *The Twelfth International Conference on Learning Representations*, 2024.
- [54] K. Black, N. Brown, D. Driess, A. Esmail, M. Equi, C. Finn, N. Fusai, L. Groom, K. Hausman, B. Ichter *et al.*, " π 0: A vision-language-action flow model for general robot control, 2024," *arXiv preprint arXiv:2410.24164*, 2024.
- [55] M. Zawalski, W. Chen, K. Pertsch, O. Mees, C. Finn, and S. Levine, "Robotic control via embodied chain-of-thought reasoning," in *8th Annual Conference on Robot Learning*, 2024.
- [56] F. Liu, F. Yan, L. Zheng, C. Feng, Y. Huang, and L. Ma, "Robouniview: Visual-language model with unified view representation for robotic manipulation," *arXiv preprint arXiv:2406.18977*, 2024.
- [57] K. Bousmalis, A. Irpan, P. Wohlhart, Y. Bai, M. Kelcey, M. Kalakrishnan, L. Downs, J. Ibarz, P. Pastor, K. Konolige *et al.*, "Using simulation and domain adaptation to improve efficiency of deep robotic grasping," in *2018 IEEE international conference on robotics and automation (ICRA)*. IEEE, 2018, pp. 4243–4250.
- [58] K. Fang, Y. Bai, S. Hinterstoisser, S. Savarese, and M. Kalakrishnan, "Multi-task domain adaptation for deep learning of instance grasping from simulation," in *2018 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2018, pp. 3516–3523.
- [59] R. Jeong, Y. Aytar, D. Khosid, Y. Zhou, J. Kay, T. Lampe, K. Bousmalis, and F. Nori, "Self-supervised sim-to-real adaptation for visual robotic manipulation," in *2020 IEEE international conference on robotics and automation (ICRA)*. IEEE, 2020, pp. 2718–2724.
- [60] H. Ma, R. Qin, M. Shi, B. Gao, and D. Huang, "Sim-to-real grasp detection with global-to-local rgb-d adaptation," in *2024 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2024, pp. 13910–13917.
- [61] Z. Wu, Y. Zhou, X. Xu, Z. Wang, and H. Yan, "Momanipvla: Transferring vision-language-action models for general mobile manipulation," *arXiv preprint arXiv:2503.13446*, 2025.
- [62] S. Wu, Y. Zhu, Y. Huang, K. Zhu, J. Gu, J. Yu, Y. Shi, and J. Wang, "Afforddp: Generalizable diffusion policy with transferable affordance," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025.
- [63] R. Yang, M. Grard, E. Dellandréa, and L. Chen, "When continual learning meets robotic grasp detection: a novel benchmark on the jacquard dataset," in *18th International Conference on Computer Vision Theory and Applications (VISAPP)*. SCITEPRESS-Science and Technology Publications, 2023.
- [64] W. Wan, Y. Zhu, R. Shah, and Y. Zhu, "Lotus: Continual imitation learning for robot manipulation through unsupervised skill discovery," in *2024 IEEE International Conference on Robotics and Automation (ICRA)*, 2024, pp. 537–544.
- [65] Y. Wang, Y. Zhang, M. Huo, T. Tian, X. Zhang, Y. Xie, C. Xu, P. Ji, W. Zhan, M. Ding *et al.*, "Sparse diffusion policy: A sparse, reusable, and flexible policy for robot learning," in *8th Annual Conference on Robot Learning*, 2024.
- [66] H. Ma, M. Shi, B. Gao, and D. Huang, "Generalizing 6-dof grasp detection via domain prior knowledge," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024, pp. 18102–18111.
- [67] W. Huang, C. Wang, Y. Li, R. Zhang, and L. Fei-Fei, "Rekep: Spatio-temporal reasoning of relational keypoint constraints for robotic manipulation," in *2nd CoRL Workshop on Learning Effective Abstractions for Planning*, 2024.
- [68] P. Dhariwal and A. Nichol, "Diffusion models beat gans on image synthesis," *Advances in neural information processing systems*, vol. 34, pp. 8780–8794, 2021.
- [69] H. Chung, J. Kim, M. T. Mccann, M. L. Klasky, and J. C. Ye, "Diffusion controlled sampling for general noisy inverse problems," in *The Eleventh International Conference on Learning Representations*, 2023.
- [70] L. Yang, S. Ding, Y. Cai, J. Yu, J. Wang, and Y. Shi, "Guidance with spherical gaussian constraint for conditional diffusion," in *International Conference on Machine Learning*. PMLR, 2024, pp. 56071–56095.
- [71] Q.-Y. Zhou, J. Park, and V. Koltun, "Fast global registration," in *Computer Vision—ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part II 14*. Springer, 2016, pp. 766–782.
- [72] P. J. Besl and N. D. McKay, "Method for registration of 3-d shapes," in *Sensor fusion IV: control paradigms and data structures*, vol. 1611. Spie, 1992, pp. 586–606.
- [73] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark *et al.*, "Learning transferable visual models from natural language supervision," in *International conference on machine learning*. PMLR, 2021, pp. 8748–8763.
- [74] S. James, Z. Ma, D. R. Arrojo, and A. J. Davison, "Rlbench: The robot learning benchmark & learning environment," *IEEE Robotics and Automation Letters*, vol. 5, no. 2, pp. 3019–3026, 2020.
- [75] O. Mees, L. Hermann, E. Rosete-Beas, and W. Burgard, "Calvin: A benchmark for language-conditioned policy learning for long-horizon robot manipulation tasks," *IEEE Robotics and Automation Letters*, vol. 7, no. 3, pp. 7327–7334, 2022.
- [76] S. James, K. Wada, T. Laidlow, and A. J. Davison, "Coarse-to-fine q-attention: Efficient learning for visual robotic manipulation via discretisation," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022, pp. 13739–13748.
- [77] M. Shridhar, L. Manuelli, and D. Fox, "Perceiver-actor: A multi-task transformer for robotic manipulation," in *Conference on Robot Learning*, 2023.
- [78] P.-L. Guhur, S. Chen, R. G. Pinel, M. Tapaswi, I. Laptev, and C. Schmid, "Instruction-driven history-aware policies for robotic manipulations," in *Conference on Robot Learning*. PMLR, 2023, pp. 175–187.
- [79] S. Chen, R. G. Pinel, C. Schmid, and I. Laptev, "Polarnet: 3d point clouds for language-guided robotic manipulation," in *Conference on Robot Learning*. PMLR, 2023, pp. 1761–1781.
- [80] A. Goyal, J. Xu, Y. Guo, V. Blukis, Y.-W. Chao, and D. Fox, "Rvt: Robotic view transformer for 3d object manipulation," in *Conference on Robot Learning*. PMLR, 2023, pp. 694–710.
- [81] T. Gervet, Z. Xian, N. Gkanatsios, and K. Fragkiadaki, "Act3d: Infinite resolution action detection transformer for robotic manipulation," *arXiv preprint arXiv:2306.17817*, 2023.
- [82] O. Mees, L. Hermann, and W. Burgard, "What matters in language conditioned robotic imitation learning over unstructured data," *IEEE Robotics and Automation Letters (RA-L)*, vol. 7, no. 4, pp. 11205–11212, 2022.
- [83] K. Black, M. Nakamoto, P. Atreya, H. R. Walke, C. Finn, A. Kumar, and S. Levine, "Zero-shot robotic manipulation with pre-trained image-editing diffusion models," in *The Twelfth International Conference on Learning Representations*, 2024.
- [84] H. Wu, Y. Jing, C. Cheang, G. Chen, J. Xu, X. Li, M. Liu, H. Li, and T. Kong, "Unleashing large-scale video generative pre-training for visual robot manipulation," in *The Twelfth International Conference on Learning Representations*, 2024.
- [85] J. J. Kuffner and S. M. LaValle, "Rrt-connect: An efficient approach to single-query path planning," in *Proceedings 2000 ICRA. Millennium Conference. IEEE International Conference on Robotics and Automation.*, vol. 2. IEEE, 2000, pp. 995–1001.
- [86] E. Coumans and Y. Bai, "Pybullet, a python module for physics simulation for games, robotics and machine learning," 2016.
- [87] O. Mees, J. Borja-Diaz, and W. Burgard, "Grounding language with visual affordances over unstructured data," in *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*, London, UK, 2023.
- [88] J. Urain, N. Funk, J. Peters, and G. Chalvatzaki, "Se(3)-diffusionfields: Learning smooth cost functions for joint grasp and motion optimization through diffusion," in *2023 IEEE International Conference on Robotics and Automation (ICRA)*, 2023, pp. 5923–5930.
- [89] C. Eppner, A. Mousavian, and D. Fox, "Acronym: A large-scale grasp dataset based on simulation," in *2021 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2021, pp. 6222–6227.

- [90] A. X. Chang, T. Funkhouser, L. Guibas, P. Hanrahan, Q. Huang, Z. Li, S. Savarese, M. Savva, S. Song, H. Su, J. Xiao, L. Yi, and F. Yu, "Shapenet: An information-rich 3d model repository," 2015. [Online]. Available: <https://arxiv.org/abs/1512.03012>
- [91] V. Makoviychuk, L. Wawrzyniak, Y. Guo, M. Lu, K. Storey, M. Macklin, D. Hoeller, N. Rudin, A. Allshire, A. Handa *et al.*, "Isaac gym: High performance gpu based physics simulation for robot learning," in *Thirty-fifth Conference on Neural Information Processing Systems Datasets and Benchmarks Track*, 2021.



Liming Chen was awarded his B.Sc. degree in joint mathematics-computer science from the University of Nantes, France, in 1984, and his M.S. and Ph.D. degrees from the University of Paris 6, France, in 1986 and 1989. He first served as an Associate Professor with the Université de Technologie de Compiègne, before joining the Ecole Centrale de Lyon as a Professor in 1998, where he leads an Advanced Research Team in multimedia computing and pattern recognition. His current research interests include computer vision and multimedia, and in particular face analysis, image and video categorization, affective computing, and robotic manipulation. He is a Senior Member of the IEEE.



Zezeng Li received a B.S. degree from Beijing University of Technology (BJUT) in 2015 and a Ph.D. degree from Dalian University of Technology (DUT) in 2024. He is currently a postdoctoral fellow at the Ecole Centrale de Lyon (ECL). His research interests include generative models and robotic manipulation.



Rui Yang received a B.S. degree from Wuhan University in 2017 and an Engineering degree from École Centrale de Lyon (ECL) in 2020. He is currently pursuing a Ph.D. degree at LIRIS, École Centrale de Lyon. His research interests include continual learning and robotic manipulation.



Ruochen Chen received an Engineering degree in Computer Science and Engineering (GI) and a Master's degree in Machine Learning and Optimization of Complex Systems (AOS) from Université de Technologie de Compiègne (UTC) in 2022. He is currently pursuing a Ph.D. at LIRIS, École Centrale de Lyon, France. His research interests include deformable-object modeling and neural cloth and garment simulation.



Zhongxuan Luo received the B.S. degree from Jilin University in 1985 and the Ph.D. degree from Dalian University of Technology (DUT) in 1991. He has been a full professor with DUT since 1997, where he also serves as a president assistant. He is the director of the Liaoning Provincial Key Laboratory of Ubiquitous Network and Service Software. He is a member of the Software Engineering Professional Guidance Committee of the Ministry of Education of China. His research interests include computational geometry, computer vision and graphic imaging, and underwater agile robotics.

underwater agile robotics.