

任意车辆至任意地点：学习面向敏捷与自适应移动的通用动力学模型

Wenli Xiao*, Haoru Xue*, Tony Tao, Dvij Kalaria, John M. Dolan, and Guanya Shi

摘要——机器人学习领域近期的工作已成功引入能够控制多种机器人形态并完成导航、运动等多种任务的通用模型。然而，实现敏捷控制以突破机器人性能极限，仍依赖于需要大量参数调优的专用模型。为在保持通用模型适应性与灵活性的同时达到专用模型的敏捷性，本文提出 AnyCar，一种基于变换器的通用动力学模型，旨在实现多种轮式机器人的敏捷控制。为收集训练数据，本文统一多个仿真器并利用不同物理后端，模拟不同地形上具有不同尺寸、规模与物理特性的车辆。通过稳健训练与真实世界微调，该模型能够精确适应不同车辆，即使在野外环境及较大状态估计误差下亦然。在真实世界实验中，AnyCar 在多种车辆与环境展现出少样本与零样本泛化能力，结合基于采样的模型预测控制，其性能超越专用模型最高达 54%。这些结果标志着构建敏捷轮式机器人控制基础模型的关键一步。本文还将开源该框架以支持进一步研究。

I. 引言

变换器 (Transformer) [5] 架构在当代机器人学习中的应用无处不在，涵盖感知 [6, 7]、规划 [8] 与控制 [9] 任务。采用变换器的强化学习，如 [10] 和 [11]，被广泛应用于双臂操作 [12]、导航 [13]、人形机器人运动 [14] 以及全身遥操作 [15, 16] 等下游应用。视觉-语言-动作 (VLA) 模型，如 OpenVLA[17]、RT-1[18] 和 RT-2[19]，展示了在机器人领域采用变换器的可扩展性。这些基于互联网规模数据训练的模型能够将知识与技能泛化到不同的复杂任务中。机器人学习的最新进展还引入了更多“专家”系统，能够执行高度敏捷的运动任务 [20–23]。特别是在轮式机器人上，先前的工作已实现在赛道 [24]、草地 [25]、松散沙地 [26, 27] 以及越野地形 [28, 29] 上的高速自主驾驶。然而，这些工作 [28, 29] 大多针对特定车型和环境进行优化，需要大量的系统辨识与模型训练 [25, 26]，微调成本高昂且难以迁移到其他轮式平台。另一方面，面向安全关键应用的敏捷轮式控制需要精确的动力学建模，当运行时




图 1: AnyCar 与基线方法在状态估计误差下的野外性能。上图：设置 10 厘米容差走廊作为检查点。下图：每一行代表一种方法的真实轨迹，每一列对应 1/16 比例小车的特定设置：高速（2 米/秒）、拖拽箱子、以及将左前轮胎更换为塑料轮。所有设置均显著改变车辆动力学。

高速行驶时，小误差可能导致灾难性故障，例如碰撞 [25, 30]。已有工作尝试通过应用神经网络辨识 [9, 30, 31] 来缓解这一问题，使模型适应不同的环境因素，如轮胎退化、地面缺陷 [31] 和拖拽物体 [30]。然而，这些方法仍需要对特定车辆设置（例如，车辆的尺寸和轴距）做出假设。一个关键问题是：我们能否训练一个通用的轮式机器人动力学模型，使其在每个设置下都能达到专用模型的性能？在本文中，我们提出了 AnyCar（如图 2 所示），这是训练车辆动力学变换器 (Transformer) 的初步尝试，该变换器能够通过上下文适应预测各种车辆在各种设置下的轨迹。我们的贡献有三方面：

* 这些作者对本文贡献相同。作者来自美国卡内基梅隆大学机器人研究所。
 { wxiao2, haorux, longtao, dkalaria, jdolan, guanyas } @andrew.cmu.edu。论文网站：<https://lecar-lab.github.io/anycar/>




图 2: AnyCar 系统流程。阶段 1: 我们在 4 种不同的仿真中收集 1 亿条数据用于预训练, 并收集 2 万条少样本真实世界数据用于微调模型。阶段 2: 我们使用仿真数据集预训练模型, 并通过掩码、添加噪声和攻击输入来增强预测鲁棒性。我们还使用微调数据集进行微调。阶段 3: 我们在状态估计误差 (使用 SLAM [1–3] 和 VIO [4]) 下将 AnyCar 部署到实际环境中, 以控制不同车辆 (1/10 比例、1/16 比例), 在不同地形上采用不同设置 (拖曳物体、3D 打印车轮)。

- 我们构建了一个通用合成数据生成器, 使用不同保真度的物理引擎 (例如 DBM、MuJoCo、Isaac Sim、Assetto Corsa Gym) 收集跨多种车辆和环境的数据。
- 我们提出了一种两阶段鲁棒车辆动力学变换器训练方法, 利用仿真预训练和真实世界微调来处理仿真到现实的差距和状态估计误差。
- 我们将动力学变换器与基于采样的模型预测控制 (MPC) 集成, 并在不同车辆平台和不同环境 (室内和室外) 中展示了真实世界性能, 与基线方法相比, 性能提升高达 54%。

II. 相关工作

A. 神经动力学模型与自适应控制

神经网络, 尤其是变换器, 可用于学习任意系统的动力学 [32], 或在标称模型之上学习残差, 该标称模型以传统状态空间方程表示 [9, 33]。数据驱动技术可以帮助机器人适应时变动力学。在

特别是, 基于师生训练的开环自适应 (如快速运动自适应 (Rapid Motor Adaptation, RMA)) 能够有效弥合强化学习中的仿真到现实差距 [34]。当现实世界的真实数据可用时, 可以更监督的方式学习自适应。安全深度策略自适应 (Safe Deep Policy Adaptation, SafeDPA) [30] 执行自监督的现实世界微调。神经飞行 (Neural-Fly) [33] 训练残差动力学模型, 利用少量现实世界数据学习环境扰动的良好表示。学习模型预测控制 (Learning Model Predictive Control, LMPC) [24, 35] 基于现实世界中收集的最近历史状态的邻域, 直接回归状态空间动力学的局部线性近似。然而, 大规模自适应仍然是一个开放的挑战, 特别是当动力学差异显著时, 例如机器人参数或形态不同的情况。

B. 跨具身

近期研究表明, 大规模训练的深度学习模型能够利用同一策略控制多种机器人 [36, 37]。跨形态变换器 (CrossFormer) [36] 强调, 在六种形态 (轮式机器人、四足机器人、机械臂等) 的任务上训练单一变换器, 即使没有

对齐这些实体的动作空间。开放 X-实体数据集 [38, 39] 专注于跨不同实体的机器人操作。然而，现有的通才模型均未实现敏捷控制。为兼顾通才的适应性与专才的敏捷性，AnyCar 针对同一形态实体（如轮式机器人）的泛化问题，这相较于跨实体泛化缩小了范围。

C. 用于底层控制的变换器

变换器（Transformer）在低层控制中已展现出潜力，轨迹变换器（Trajectory Transformer）中的注意力模式能够有效捕捉马尔可夫决策过程（Markov Decision Process, MDP）的特性 [10]。这引出一个问题：变换器凭借其对序列元素间成对注意力的归纳偏置，能否在低层控制中实现马尔可夫动态的高效训练与表示。近期工作已开始探索这一领域。[16] 将变换器用于人形机器人全身控制，但未涉及跨具身泛化。[9] 将变换器应用于车辆机器人的在线系统辨识，利用历史状态为神经动力学模型生成上下文向量。尽管取得了这些进展，现有文献仍缺乏变换器在专门任务（如敏捷运动或灵巧操作）和跨不同机器人或任务泛化方面均表现优异的实例。

三、概述

符号说明。 x_t, a_t 是时间步 t 处的状态和动作。我们用 $x_{1:t}$ 表示序列 $\{x_1, \dots, x_t\}$ 。 $\hat{x}$ 表示对 x 的估计（例如来自视觉惯性里程计（VIO））， $\hat{a}$ 是带噪声的 a 。为展示所提方法的实际应用，我们聚焦于多种车辆在非结构化环境中的轨迹跟踪，该问题可形式化如下：

$$\begin{aligned} & \underset{a_{0:T}}{\text{maximize}} && \sum_{t=0}^T R(x_t, a_t) \\ & \text{subject to} && x_{t+1} = f(x_t, a_t, c_t), \quad \forall t = 0, 1, \dots, T \end{aligned}$$

其中 $R(x_t, a_t)$ 为奖励函数， $x_{t+1} = f(x_t, a_t, c_t)$ 表示系统动力学， c_t 代表与车辆动力学及环境条件（如地形、载荷等）相关的所有物理特性。状态由 $x_t \triangleq [p_t^x, p_t^y, \psi_t, \dot{p}_t^x, \dot{p}_t^y, \omega]$ 定义，包含位置

(p_t^x, p_t^y) 、航向角 ψ_t 、线速度和角速度 $(\dot{p}_t^x, \dot{p}_t^y, \omega)$ 。

作 $a_t \triangleq [\tau, \delta]$ 包含油门 τ 和转向角 δ 。我们的模型是一个序列到序列（seq2seq）模型，能够从不完美的状态与动作历史序列以及未来动作序列中预测未来状态序列：

$$x_{t+1:t+H} \approx f_{\theta}^{\text{AnyCar}}(\underbrace{\hat{x}_{t-K:t}, \hat{a}_{t-K:t-1}}_{\text{history}}, \underbrace{a_{t:t+H-1}}_{\text{future actions}}), \quad (1)$$

带噪声的状态与动作历史，其中 K 表示历史长度， H 表示预测时域（如图 2 第二阶段所示）。我们训练一个变换器，通过其上下文自适应能力来逼近方程（1），以适应各种车辆和地形。我们的模型不仅能学习自适应动力学，还能充当滤波器，处理带噪声的状态估计 $\hat{x}$ 和动作 $\hat{a}$ 。相比之下

与先前假设单一特定车型且可调参数有限的工作 [9, 24, 26, 30, 31] 相比，AnyCar 能够适应多种类型的车辆，无论是否对环境做出假设。为学习 θ ，我们设计了两阶段训练流程。第一阶段（第四节）中，我们利用不同的物理仿真生成包含不同地形下多种车辆轨迹的大规模数据集；随后在第四节 B 部分预训练 AnyCar 变换器 $f_{\theta_{\text{sim}}}^{\text{AnyCar}}$ （图 2 阶段 2）。第二阶段中，我们收集少量真实世界数据并在第四节 C 部分微调变换器 $f_{\theta_{\text{fine-tune}}}^{\text{AnyCar}}$ 。经过这两个阶段，模型 $f_{\theta_{\text{fine-tune}}}^{\text{AnyCar}}$ 即使在状态估计误差下也能准确预测不同车辆的未来轨迹。借助精确的动力学模型，我们应用模型预测路径积分（MPPI）执行轨迹跟踪。MPPI 是一种基于采样的模型预测控制方法，通过最小化采样轨迹的代价来加权多个候选轨迹，并根据其性能选择最优控制。我们选择 MPPI 是因为其能够利用并行计算且无需训练，同时不需要降阶模型。在第五节 A 部分，我们描述了使用 AnyCar 变换器与 MPPI 实现真实世界中 50Hz 控制的详细系统设计。最后，在第六节中，我们展示了 AnyCar 在各种真实场景中的部署，证明了其在不同车辆和环境中的多功能性与鲁棒性。

第四节 模型与数据

本节描述 AnyCar 的数据集收集与模型训练策略。如图 2 阶段 1 和阶段 2 所示，我们强调在大规模仿真和少量真实世界数据中的数据收集，以及稳健的训练和微调流程。

A. 大规模仿真数据预训练

场景生成。为收集多样化数据集，我们利用仿真的低成本特性生成大量仿真数据。我们的数据生成具有三个多样性来源：1) 动力学，2) 场景，3) 控制器。如图 2 阶段 1 所示，我们通过四种不同的仿真器合成各种车辆和地形的轨迹：基于动态自行车模型 [31]（DBM）的数值仿真、MuJoCo、IsaacSim 和 Assetto Corsa Gym [40]。¹

课程模型训练。为确保数据分布覆盖，本文通过两阶段课程学习方法在策略内与策略外数据之间进行多样化。第一阶段，收集大量策略外数据作为预热，构建混合控制器，其中使用纯追踪控制器进行转向 δ ，使用比例微分控制器进行油门 τ ，以跟踪随机合成的参考轨迹。在收集到 2 亿个可用于训练最敏捷任务（目标速度小于物理极限）通用模型的时间步后，切换至第二阶段，部署策略内神经网络模型预测路径积分控制器（详见第 V-A 节），以

¹The settings are summarized in <https://lecar-lab.github.io/anycar/>

跟踪敏捷轨迹，并利用收集到的策略内轨迹定期更新网络。

B. 鲁棒的上下文自适应动力学模型

模型结构。如图 2 第二阶段所示，方程 (1) 中的历史状态通过编码器层线性投影至 64 维潜空间。历史动作经过另一个类似

$$P_{\text{state}}(x) : \mathbb{R}^6 \rightarrow \mathbb{R}^{64} \text{ 规模的编码器} \\ P_{\text{act}}(a) : \mathbb{R}^2 \rightarrow \mathbb{R}^{64}。$$

随后将其交错堆叠，构成完整的历史令牌序列 $S^{2K-1 \times 64}$ ，作为上下文提供给变换器。未来动作通过 $P_{\text{act}}(a)$ 进行令牌化，并堆叠为序列 $A^{H \times 64}$ 。两个序列 S 与 A 随后与两个可学习的位置编码器相加。将上下文 S 与输入 A 传入变换器解码器后，得到 $S'^{H \times 64}$ ，再通过

$DP_{\text{state}}(x) : \mathbb{R}^{64} \rightarrow \mathbb{R}^6$ ，下投影至状态空间，成为最终的状态序列预测。

鲁棒训练。为学习在各种扰动下对公式 (1) 具有鲁棒性的模型 f_θ ，本文提出在预训练中加入三种技术：掩码、加噪与攻击（图 2）。掩码通过对变换器施加随机交叉注意力掩码实现，随后添加噪声 $\epsilon \sim \mathcal{N}(0, \epsilon^{\max})$ 。同时加入攻击：对历史中的随机维度施加不合理的大值或小值，以模拟真实世界中的状态估计误差。如第 IV 节所述，这些技术协同提升鲁棒性，确保真实世界部署的成功。

C. 基于状态估计误差降低的微调 在预训练 $f_{\theta_{\text{sim}}}^{\text{AnyCar}}$ 之后，我们使用 10 分钟的真实世界数据（0.02M）对模型进行微调，以缩小仿真到现实的差距并减轻状态估计误差。为了收集真实世界数据，我们通过操纵杆控制车辆在运动捕捉场中沿几条随机曲线轨迹行驶，并同时收集来自车载状态估计器的状态以及由 Vicon 系统提供的地面真值状态，如图 2 第一阶段所示。然后，我们在 $\|\theta_{\text{fine-tune}} - \theta_{\text{sim}}\|_2 \leq \epsilon_{\text{tune}}$ 的约束下对收集到的数据进行微调 $f_{\theta_{\text{sim}}}^{\text{AnyCar}}$ ，以防止灾难性遗忘。在实践中，我们还应用数据排线来辅助。微调后的模型 $f_{\theta_{\text{fine-tune}}}^{\text{AnyCar}}$ 即可零样本部署。

五、系统设计

在本节中，我们描述利用 AnyCar 执行各种轨迹跟踪任务的系统。

A. MPPI 控制器

如第三节所述，我们选择使用 MPPI 而非强化学习和模型预测控制来评估我们的方法，因为强化学习需要优化额外的策略和值函数参数，这超出了本工作的范围。同样，神经模型预测控制 [41] 会导致我们的神经动力学模型降阶近似，这对于公平评估是不利的。我们采用一种称为协方差最优模型预测控制（CoVO-MPC）[42] 的 MPPI 变体，它改进了原始 MPPI




图 3：不同模型结构和数据规模的比较。报告的测试误差使用评估数据集的均值和标准差进行归一化。

通过自适应采样协方差在代价函数上实现最优收敛速率。1) 轨迹采样：设 x_t, a_t 为时刻 t 的状态和动作。对于给定的控制时域 H ，我们在正态分布中随机采样 N 条动作序列 $\{a_{t:t+H-1}^i\}_i^N$ ，其均值和协方差由 [42] 计算得出。我们使用 AnyCar 模型展开每条动作序列并计算其累积奖励。为了生成平滑的动作序列，我们用一组由 $\theta_{0:k}$ [43] 表示的时间索引节点重新参数化控制序列 $a_{0:T}$ 。给定查询点 τ ，控制量可以通过 $a_\tau = \text{样条}(\tau; (\tau_{0:k}, \theta_{0:k}))$ 进行评估。2) 奖励函数：为了激励跟踪参考航点，我们使用 [28] 中的单步奖励函数，其表达式为

$$r(x, a, \hat{x}) = w_1 \|p - \hat{p}\|^2 + w_2 \|\psi - \hat{\psi}\| + w_3 \|v_x - \hat{v}_x\| + w_4 \|\delta a\|,$$

其中 p 表示位置， ψ 为航向角， v_x 为纵向速度， δa 为动作增量。3) 计算：我们在 JAX[44] 中实现 MPPI，并在 TransformerEngine 中实现变换器模型。我们在模型上并行评估 600 个动作序列样本，在 RTX 4090 GPU 上实现 20 毫秒（50 赫兹）的实时性能。我们注意到，进一步的优化，如 KV 缓存、在样本间共享历史令牌注意力以及 TensorRT 转换，可以支持边缘部署。

B. 状态估计

在使用地面真值数据的实验中，我们使用运动捕捉系统直接观测车辆的位置和速度。在野外实验中，我们通过使用扩展卡尔曼滤波器融合电机里程计和惯性测量单元数据来估计车辆的线速度和角速度

（EKF）[45]。然后，我们使用二维激光雷达同步定位与建图 [1–3] 或带视觉惯性里程计（VIO）的三维同步定位与建图来校正里程计漂移。我们将在第六节中展示 AnyCar 的微调流程能够适应状态估计误差。

C. 低级控制器

在接收到油门（加速度）和转向（角度）命令后，低级模块通过简单的线性映射将油门映射到电机电流，并将转向角度映射到舵机角度。适应这些粗略映射中的差异以及执行器响应中的延迟也是我们微调流程的目标。




图 4: AnyCar 变换器注意力在三种真实世界设置中的可视化: (a) 低速 0.5 米/秒, (b) 高速 2 米/秒, (c) 以 2 米/秒牵引物体, 均跟踪相同的参考轨迹。AnyCar 的变换器在所有设置中始终关注最近的 50 步, 并自适应地关注赛道的不同部分。例如, 在设置 (b) 中关注第一个弯道, 在设置 (c) 中关注第二个弯道。

表 I: 使用地面真值状态估计 (运动捕捉) 的室内结果

Setting	Method	$E^{\text{Prediction}} \downarrow$	$E^{\text{Tracking}} \downarrow$
Few-shot performance in fine-tuned scenarios			
1/10 Scale Car + Tow Box	PP	-	0.45 ± 0.02
	AnyCar (Ours)	0.27 ± 0.24	0.35 ± 0.04
	AnyCar w/o FT	0.54 ± 0.55	0.47 ± 0.23
	Specialist	0.14 ± 0.09	0.43 ± 0.05
1/10 Scale Car + Payloads	PP	-	0.54 ± 0.03
	AnyCar (Ours)	0.11 ± 0.08	0.41 ± 0.03
	AnyCar w/o FT	0.21 ± 0.11	0.47 ± 0.17
	Specialist	0.26 ± 0.11	0.51 ± 0.03
Zero-shot generalization in unseen scenarios			
1/10 Scale Car + Plastic wheels (All 4 wheels)	PP	-	0.79 ± 0.62
	AnyCar (Ours)	0.26 ± 0.32	0.335 ± 0.03
	AnyCar w/o FT	0.32 ± 0.21	0.45 ± 0.15
	Specialist	0.35 ± 0.15	0.334 ± 0.06
1/10 Scale Car + Plastic wheels (Front 2 wheels)	PP	-	0.52 ± 0.05
	AnyCar (Ours)	0.12 ± 0.08	0.39 ± 0.05
	AnyCar w/o FT	0.20 ± 0.11	0.49 ± 0.09
	Specialist	0.27 ± 0.11	0.41 ± 0.04
1/10 Scale Car + Plastic wheels + Tow box	PP	-	0.57 ± 0.03
	AnyCar (Ours)	0.09 ± 0.06	0.49 ± 0.09
	AnyCar w/o FT	0.18 ± 0.11	0.52 ± 0.09
	Specialist	0.14 ± 0.05	0.60 ± 0.04
1/16 Scale Car + Plastic wheels	PP	-	0.37 ± 0.16
	AnyCar (Ours)	0.17 ± 0.08	0.31 ± 0.06
	AnyCar w/o FT	0.25 ± 0.14	0.44 ± 0.08
	Specialist	0.26 ± 0.11	0.55 ± 0.07

六、实验

在本节中, 我们旨在通过回答以下问题来展示所提出的任意车辆模型 (AnyCar) 的能力: • **Q1:** 我们的模型能否泛化到各种车辆和地形, 并超越专用模型? • **Q2:** 即使状态估计不完美, 我们的模型能否保持其适应能力?

- **Q3:** 为什么所提出的鲁棒车辆动力学变换器优于其他基线模型?

基线. 我们将任意车辆模型 (AnyCar) 与三种基线方法进行比较: 1) 无微调的任意车辆模型 (AnyCar w/o FT): 没有真实世界微调阶段的任意车辆模型, 2) *PP*: 用于转向的纯追踪控制器和用于速度跟踪的比例积分微分 (PID) 控制器, 以及 3) 专用模型: 带有系统辨识的基于深度学习的模型 (DBM)。我们还考虑两种状态估计器设置: 1) 运动捕捉 (室内),

可视为地面真值, 以及 2) 同步定位与建图 (SLAM) [1–3] (室内或室外), 其精度低于运动捕捉, 且容易产生漂移问题。度量。我们使用模型预测误差 $E^{\text{Prediction}} \triangleq \|x_{t+1:t+H}^{\text{pred}} - x_{t+1:t+H}^{\text{gt}}\|_2$ 来评估预测准确率。我们, 其中 w_2 和 w_3 是 also define $E^{\text{Tracking}} \triangleq w_2 \|p_t - \hat{p}_t\|_2 + w_3 \|v_t - \hat{v}_t\|_2$ 第五-A 节中为位置和速度跟踪奖励定义的不同权重, 表示横向误差和速度跟踪误差的加权和, 用于评估轨迹跟踪性能。

A. 评估模型上下文适应能力

为回答问题一, 本文隔离估计误差, 并利用动作捕捉为真实世界中的状态估计提供真值。采用一辆十分之一比例的小车牵引物体并承载载荷, 以构建由人类遥操作采集的微调数据集。随后利用该数据集对动力学模型进行微调。模型在两类场景下进行评估: 少样本性能 (例如牵引物体和变化载荷, 均存在于微调数据集中) 与零样本泛化 (例如更换三维打印车轮、使用改装车轮牵引物体, 以及使用更换车轮的较小车型)。本文采用轨迹优化方法 [24] 在赛道线上计算一条临界参考轨迹。随后部署本文方法及其他基线 (未微调的任意车辆、纯追踪、专家模型) 跟踪该轨迹。评估同时考虑模型预测误差与完整控制器下的闭环跟踪误差。表一结果显示, 在少样本与零样本场景下, 任意车辆在预测误差和跟踪误差方面均达到并超越基线。本文观察到与 RT-X[38] 中相同的“涌现技能”: 使用一台机器人 (十分之一比例

车) 执行特定任务 (低速跟踪弯道) 的数据微调模型后, 另一台不同机器人 (十六分之一比例车) 在执行不同任务 (敏捷赛道线跟踪) 时也获得性能提升。

B. 评估模型在真实环境中的能力

为回答问题二, 本文在一辆十六分之一比例的小车上搭建了基于二维激光雷达的同步定位与建图系统。通过遥操作使小车低速沿 S 形路径行驶, 同时采集同步定位与建图系统和动作捕捉的里程计数据, 构建了一个包含 24000 个时间步的小规模数据集。随后对模型进行




图 5: 与基线在真实环境中的比较。

表二: 状态估计误差下的室内结果

Setting	Method	$E^{\text{Prediction}} \downarrow$	$E^{\text{Tracking}} \downarrow$
Few-shot performance in fine-tuned scenarios			
1/16 Scale Car	AnyCar (Ours)	0.30 ± 0.06	0.35 ± 0.02
+ Low Speed	AnyCar w/o FT	0.32 ± 0.07	0.48 ± 0.06
	Specialist	0.33 ± 0.05	0.42 ± 0.01
Zero-shot generalization in unseen scenarios			
1/16 Scale Car	AnyCar (Ours)	0.44 ± 0.11	0.57 ± 0.03
+ High Speed	AnyCar w/o FT	0.52 ± 0.15	1.30 ± 0.11
	Specialist	0.48 ± 0.10	1.26 ± 0.89
1/16 Scale Car	AnyCar (Ours)	0.34 ± 0.10	0.57 ± 0.02
+ Tow 2 Box	AnyCar w/o FT	0.41 ± 0.14	1.41 ± 0.09
	Specialist	0.39 ± 0.09	0.93 ± 0.62

使用第四节 C 部分的方法进行微调。利用微调后的模型（任意车辆），我们首先在室内环境中评估了该方法在不同条件（低速、高速、拖拽两个箱子）下与同步定位与建图（SLAM）结合的性能，并使用地面真值数据计算度量指标。表二中的结果表明，任意车辆优于基线方法，峰值提升达 54%。基于表一和表二，我们证明了微调的必要性，即对齐动力学模型以处理状态估计误差。随后，系统被移至室外环境，未做进一步修改。为验证任意车辆对状态估计能力的鲁棒性，我们在参考轨迹旁设置了一条狭窄走廊，允许车辆以 10 厘米的容差通过（如图 1 所示）。跟踪性能不佳将导致车辆与墙壁碰撞。我们通过计算每种方法成功通过所有检查点且无碰撞的百分比（成功率），将我们的方法与无微调的任意车辆和专用模型进行了比较。表二中的结果表明，任意车辆在所有设置中均取得最高成功率，而专用模型由于状态估计误差持续失败。我们还在图 4 中可视化了不同设置下的变换器注意力，展示了任意车辆在各种设置中的上下文自适应能力。除了基于 SLAM 的状态估计器，我们还在网站上展示了使用 ZED-VIO[4] 的部署。

C. 解释任意车辆的表达能力和鲁棒性

为解释任意车辆的成功，我们认为规模化和鲁棒训练是该方法不可或缺的部分。我们在不同规模的数据集上进行了实验，涵盖不同车辆在不同地形上运行的轨迹，时间步从 100 万（1M）到




图 6: 任意车辆鲁棒训练方法的比较。(a) 评估真实世界轨迹中的预测误差。(b) 展示不同方法的预测轨迹。

1 亿（100M）。评估了多种模型架构，包括变换器（Transformer）、长短期记忆网络（LSTM）、门控循环单元（GRU）、卷积神经网络（CNN）和多层感知机（MLP），并计算了每种模型的归一化预测误差。为确保模型能够与模型预测路径积分控制（MPPI）配合用于 50Hz 控制，我们将每个模型的最大参数数量限制在 20 万以内。我们创建了一个包含 100 万个数据点的测试数据集，这些数据点独立于训练数据集，从仿真中独立同分布采样得到，并在同一测试数据集上评估所有训练好的模型。图 3 所示的结果表明，随着训练数据集规模从 1000 万增加到 1 亿个时间步，预测误差显著下降，其中变换器模型在 1 亿规模下表现最佳。这凸显了与基线模型相比，变换器结构在建模多样化车辆动力学和环境方面最为有效。然而，仅靠扩展数据和采用合适的模型结构是不够的。在最优数据规模和模型配置下，我们发现应用所提出的鲁棒训练方法（包括攻击、噪声和掩码策略）至关重要，如第 IV-B 节所述。我们系统地评估了这些组件的所有组合，共得到 8 个预训练模型。每个模型使用相同的数据集进行微调，并在真实轨迹上进行评估。图 6(a) 所示的结果表明，只有当所有鲁棒训练组件都被激活时，模型才能达到最高的预测准确率和稳定性。例如，图 6(b) 显示，如果没有完整的鲁棒训练，变换器的预测容易受到噪声状态估计的影响，从而导致显著误差。模型选择、大规模数据和鲁棒训练的结合解释了为什么 AnyCar 比基线模型表现更好。

七、局限性与未来工作

本文提出了 AnyCar，这是迈向敏捷轮式控制基础模型（Foundation Model）的第一步。未来有三个有趣的研究方向。其一是在变换器中使用键值缓存（KV Caching）以实现完全的车载计算。其二是优化 MPPI 控制，使其能够感知模型不确定性和安全性。其三是与现有的视觉导航基础模型 [13] 集成，以在野外实现完全的敏捷自主。

致谢 我们感谢 Wennie Tabib、Jiaoyang Li、Jessica Hodgins 和 Justin Macey 在实验设置方面提供的帮助。同时感谢 Chaoyi Pan 和 Zeji Yi 富有洞见的讨论。

参考文献

- [1] S. Macenski and I. Jambrecic, “SLAM Toolbox: SLAM for the dynamic world,” en, *Journal of Open Source Software*, vol. 6, no. 61, p. 2783, May 2021.
- [2] S. Macenski, F. Martín, R. White, and J. G. Clavero, “The Marathon 2: A Navigation System,” en, in *2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, arXiv:2003.00368 [cs], Oct. 2020, pp. 2718–2725.
- [3] D. Fox, “KLD-Sampling: Adaptive Particle Filters,” in *Advances in Neural Information Processing Systems*, vol. 14, MIT Press, 2001.
- [4] {Stereolabs}, *Stereolabs/zed-ros2-wrapper*, original-date: 2019-04-12T14:23:46Z, Sep. 2024.
- [5] A. Vaswani *et al.*, “Attention is All you Need,” in *Advances in Neural Information Processing Systems*, vol. 30, Curran Associates, Inc., 2017.
- [6] A. Dosovitskiy *et al.*, “An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale,” en, Oct. 2020.
- [7] H. Liu, C. Li, Q. Wu, and Y. J. Lee, “Visual Instruction Tuning,” en, Nov. 2023.
- [8] L. Lehnert *et al.*, “Beyond A*: Better Planning with Transformers via Search Dynamics Bootstrapping,” en, Aug. 2024.
- [9] S. J. Wang, H. Zhu, and A. M. Johnson, *Pay Attention to How You Drive: Safe and Adaptive Model-Based Reinforcement Learning for Off-Road Driving*, en, arXiv:2310.08674 [cs], Oct. 2023.
- [10] M. Janner, Q. Li, and S. Levine, “Offline Reinforcement Learning as One Big Sequence Modeling Problem,” in *Advances in Neural Information Processing Systems*, vol. 34, Curran Associates, Inc., 2021, pp. 1273–1286.
- [11] L. Chen *et al.*, “Decision transformer: Reinforcement learning via sequence modeling,” in *Proceedings of the 35th International Conference on Neural Information Processing Systems*, ser. NIPS ’21, Red Hook, NY, USA: Curran Associates Inc., Jun. 2024, pp. 15 084–15 097.
- [12] T. Zhao, V. Kumar, S. Levine, and C. Finn, “Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware,” en, in *Robotics: Science and Systems XIX*, Robotics: Science and Systems Foundation, Jul. 2023.
- [13] D. Shah *et al.*, *ViNT: A Foundation Model for Visual Navigation*, en, Jun. 2023.
- [14] I. Radosavovic *et al.*, *Humanoid Locomotion as Next Token Prediction*, arXiv:2402.19469 [cs], Feb. 2024.
- [15] X. Cheng, J. Li, S. Yang, G. Yang, and X. Wang, *Open-TeleVision: Teleoperation with Immersive Active Visual Feedback*, arXiv:2407.01512 [cs], Jul. 2024.
- [16] Z. Fu, Q. Zhao, Q. Wu, G. Wetzstein, and C. Finn, “HumanPlus: Humanoid Shadowing and Imitation from Humans,” en,
- [17] M. J. Kim *et al.*, *OpenVLA: An Open-Source Vision-Language-Action Model*, en, arXiv:2406.09246 [cs], Jun. 2024.
- [18] A. Brohan *et al.*, “RT-1: Robotics Transformer for Real-World Control at Scale,” en, in *Robotics: Science and Systems XIX*, Robotics: Science and Systems Foundation, Jul. 2023.
- [19] B. Zitkovich *et al.*, “RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control,” en, in *Proceedings of The 7th Conference on Robot Learning*, ISSN: 2640-3498, PMLR, Dec. 2023, pp. 2165–2183.
- [20] T. He, C. Zhang, W. Xiao, G. He, C. Liu, and G. Shi, “Agile But Safe: Learning Collision-Free High-Speed Legged Locomotion,” en,
- [21] C. Zhang, W. Xiao, T. He, and G. Shi, “WoCoCo: Learning Whole-Body Humanoid Control with Sequential Contacts,” en,
- [22] T. He *et al.*, “OmniH2O: Universal and Dexterous Human-to-Humanoid Whole-Body Teleoperation and Learning,” en,
- [23] T. He *et al.*, *Learning Human-to-Humanoid Real-Time Whole-Body Teleoperation*, en, arXiv:2403.04436 [cs, eess], Mar. 2024.
- [24] H. Xue, E. L. Zhu, J. M. Dolan, and F. Borrelli, “Learning Model Predictive Control with Error Dynamics Regression for Autonomous Racing,” in *2024 IEEE International Conference on Robotics and Automation (ICRA)*, May 2024, pp. 13 250–13 256.
- [25] K. Stachowicz and S. Levine, *RACER: Epistemic Risk-Sensitive RL Enables Fast Driving with Fewer Crashes*, en, arXiv:2405.04714 [cs], May 2024.
- [26] G. Williams, P. Drews, B. Goldfain, J. M. Rehg, and E. A. Theodorou, “Aggressive driving with model predictive path integral control,” in *2016 IEEE International Conference on Robotics and Automation (ICRA)*, May 2016, pp. 1433–1440.
- [27] G. Williams *et al.*, “Information theoretic MPC for model-based reinforcement learning,” in *2017 IEEE International Conference on Robotics and Automation (ICRA)*, May 2017, pp. 1714–1721.
- [28] T. Han, A. Liu, A. Li, A. Spitzer, G. Shi, and B. Boots, “Model Predictive Control for Aggressive Driving Over Uneven Terrain,” en,
- [29] M. Sivaprakasam *et al.*, *TartanDrive 2.0: More Modalities and Better Infrastructure to Further Self-Supervised Learning Research in Off-Road Driving Tasks*, en, Feb. 2024.
- [30] W. Xiao, T. He, J. Dolan, and G. Shi, “Safe Deep Policy Adaptation,” in *2024 IEEE International Conference on Robotics and Automation (ICRA)*, May 2024, pp. 17 286–17 292.
- [31] D. Kalaria, Q. Lin, and J. M. Dolan, “Adaptive Planning and Control with Time-Varying Tire Models for Autonomous Racing Using Extreme Learning Machine,” in *2024 IEEE International Conference on Robotics and Automation (ICRA)*, May 2024, pp. 10 443–10 449.
- [32] N. Geneva and N. Zabarbas, “Transformers for modeling physical systems,” *Neural Networks*, vol. 146, pp. 272–289, Feb. 2022.
- [33] M. O’Connell *et al.*, “Neural-Fly enables rapid learning for agile flight in strong winds,” *Science Robotics*, vol. 7, no. 66, eabm6597, May 2022, Publisher: American Association for the Advancement of Science.
- [34] A. Kumar, Z. Fu, D. Pathak, and J. Malik, *RMA: Rapid Motor Adaptation for Legged Robots*, arXiv:2107.04034 [cs], Jul. 2021.
- [35] U. Rosolia and F. Borrelli, “Learning Model Predictive Control for Iterative Tasks. A Data-Driven Control Framework,” *IEEE Transactions on Automatic Control*, vol. 63, no. 7, pp. 1883–1896, Jul. 2018, Conference Name: IEEE Transactions on Automatic Control.
- [36] R. Doshi, H. Walke, O. Mees, S. Dasari, and S. Levine, *Scaling Cross-Embodied Learning: One Policy for Manipulation, Navigation, Locomotion and Aviation*, arXiv:2408.11812 [cs], Aug. 2024.
- [37] J. Yang *et al.*, *Pushing the Limits of Cross-Embodiment Learning for Manipulation and Navigation*, arXiv:2402.19432 [cs], Feb. 2024.
- [38] A. O’Neill *et al.*, “Open X-Embodiment: Robotic Learning Datasets and RT-X Models : Open X-Embodiment Collaboration0,” in *2024 IEEE International Conference on Robotics and Automation (ICRA)*, May 2024, pp. 6892–6903.
- [39] O. M. Team *et al.*, *Octo: An Open-Source Generalist Robot Policy*, arXiv:2405.12213 [cs], May 2024.
- [40] A. Remonda *et al.*, *A Simulation Benchmark for Autonomous Racing with Large-Scale Human Data*, arXiv:2407.16680 [cs], Jul. 2024.
- [41] T. Salzmann, E. Kaufmann, J. Arrizabalaga, M. Pavone, D. Scaramuzza, and M. Ryll, “Real-Time Neural MPC: Deep Learning Model Predictive Control for Quadrotors and Agile Robotic Platforms,” *IEEE Robotics and Automation Letters*, vol. 8, no. 4, pp. 2397–2404, Apr. 2023, Conference Name: IEEE Robotics and Automation Letters.
- [42] Z. Yi, C. Pan, G. He, G. Qu, and G. Shi, *CoVO-MPC: Theoretical Analysis of Sampling-based MPC and Optimal Covariance Design*, arXiv:2401.07369 [cs], Jan. 2024.
- [43] T. Howell, N. Gileadi, S. Tunyasuvunakool, K. Zakka, T. Erez, and Y. Tassa, *Predictive Sampling: Real-time Behaviour Synthesis with MuJoCo*, en, arXiv:2212.00541 [cs, eess], Dec. 2022.
- [44] J. Bradbury *et al.*, *GoogleJax*, original-date: 2018-10-25T21:25:02Z, Sep. 2024.
- [45] T. Moore and D. Stouch, “A Generalized Extended Kalman Filter Implementation for the Robot Operating System,” en, in *Intelligent Autonomous Systems 13*, E. Menegatti, N. Michael, K. Berns, and H. Yamaguchi, Eds., Cham: Springer International Publishing, 2016, pp. 335–348.