

AR-TTA: 一种用于现实世界持续测试时自适应的简单方法

达米安·索伊卡 1,2

damian.sojka@doctorate.put.poznan.pl

巴托米耶·特瓦尔多夫斯基 1,3

btwardowski@cvc.uab.es 托马什·特日

钦斯基 1,4,5 tomasz.trzcinski@pw.edu.pl

塞巴斯蒂安·西格特 1,6

sebcyg@multimed.org

¹ IDEAS-NCBR, 波兰华沙

² Institute of Robotics and Machine Intelligence

Poznan University of Technology
Poznań, Poland

³ Computer Vision Center
Universitat Autònoma de Barcelona
Barcelona, Spain

⁴ Warsaw University of Technology
波兰华沙

⁵ Tooplox, 波兰弗罗茨瓦夫

⁶ Gdańsk University of Technology
波兰格但斯克

摘要

测试时自适应是一个有前景的研究方向,它允许源模型在没有任何监督的情况下适应数据分布的变化。然而,当前的方法通常在仅简化了现实世界场景的基准上进行评估。因此,我们提出使用最近发布的自动驾驶数据集(即 CLAD-C 和 SHIFT)来验证测试时自适应方法。我们观察到,当前的测试时自适应方法难以有效处理不同程度的领域偏移,往往导致性能下降,甚至低于源模型。我们注意到,问题的根源在于无法保留源模型的知识并适应动态变化、时间相关的数据流。因此,我们通过引入一个小型记忆缓冲区来增强成熟的自我训练框架,以提高模型稳定性,同时根据领域偏移的强度执行动态自适应。所提出的方法名为 AR-TTA,在合成和更真实的基准上均优于现有方法,并在各种 TTA 场景中表现出鲁棒性。代码可在 <https://github.com/dmn-sjk/AR-TTA> 获取。

1 引言

深度神经网络已被证明在各种任务中能够取得显著的性能,然而,它们仅在测试时分布接近训练时分布时表现良好。这带来了重大挑战,因为在现实世界应用中,领域偏移可能在许多情况下发生,例如天气变化、一天中的时间变化或传感器

退化。因此，测试时自适应（Test-Time Adaptation，TTA）方法近年来得到了广泛发展 [30, 33]。这些方法旨在测试期间利用无标签的测试数据流，将源数据预训练模型即时适配到当前数据分布。有效的 TTA 方法应能在各种挑战下表现良好，包括突变和渐变的领域偏移。此外，模型在处理可能无限延长的长序列时，也应能保持稳定的性能。现有方法基于使用伪标签或熵正则化来更新模型参数 [33, 35]。进一步地，过滤可靠性较低的样本常被用来减少误差累积并提高计算效率 [1, 22, 23]。然而，由于上述困难，所有方法都可能变得不稳定，累积误差，使伪标签噪声更大，导致性能退化 [4]。在没有任何源数据的情况下，模型容易对先前获得的知识发生灾难性遗忘 [20]。

目前，方法大多在具有人工、不现实域偏移或相对较短序列的数据集上进行评估 [5, 33, 35]，因此这些方法在具有自然域偏移的真实场景中的表现尚不清楚。因此，我们将自动驾驶基准 CLAD[32] 适配到持续适应设置中。此外，我们使用 SHIFT 数据集 [29]，该数据集利用逼真的自动驾驶模拟器 CARLA[9] 生成生成，提供非常长的序列，并允许我们专门控制不同的域因素（时间、天气条件）。在所提出的评估设置中，我们发现当前方法缺乏所需的稳定性，因为与源模型相比，它们的性能显著下降（图 1）。此外，我们注意到它们在时间相关数据流和低批大小下难以正确估计批归一化统计量。在我们针对图像分类任务的 TTA 方法中，我们扩展了流行的自训练框架 [35]，加入了一个小型记忆缓冲区，在适应过程中用于防止知识遗忘，而不依赖于常用的基于启发式的策略或重置模型权重 [23, 35]。由于使用了混合数据增强 [36]，所需样本数量相对较少。此外，我们开发了一个动态批归一化统计量适应模块，该模块根据域偏移强度，对预训练模型计算的统计量与测试期间获得的统计量进行插值。我们将方法命名为 AR-TTA，因为我们通过使用动态批归一化统计量改进适应，并通过从记忆缓冲区重复样本结合混合数据增强来保持知识。因此，我们提出的 AR-TTA 方法简单、稳定，并且在使用小批量数据和非常长的序列时，在一系列具有不同偏移强度的数据集上表现良好。我们的主要贡献可总结如下：




图 1: 在人工（CIFAR10C、ImageNet-C[11]）和自然（CIFAR10.1[27]、SHIFT[29]、CLAD-C[32]）领域偏移上评估的持续测试时自适应方法。我们的方法是唯一一种能够持续优于使用（冻结的）源模型这一朴素策略的方法。

- 我们提出了基于自动驾驶场景的 TTA 新颖评估基准，揭示了现有 TTA 方法的显著局限性。

- 基于发现的漏洞，我们提出了一种 TTA 方法，该方法根据域偏移强度动态更新批归一化统计量，并使用小型记忆缓冲区结合混合数据增强。
- 大量评估表明，所提方法在包含人工失真和自然域偏移的基准上均达到了最先进的性能。

2 相关工作

测试时自适应 (Test Time Adaptation, TTA)。领域自适应方法可根据自适应期间假设可用的信息划分为不同类别 [34]。在某些场景中，目标分布的部分标签是可获取的，但最常见的场景是无监督领域自适应，即模型在自适应时能够访问带标签的源数据和无标签的目标数据。此外，在测试时自适应中，模型需要以在线方式实时适应测试时分布。在测试时训练 (TTT) 方法 [30] 中，模型对输入数据批次求解自监督任务以更新其参数。TENT[33] 仅更新批归一化权重以最小化预测熵。EATA[22] 通过仅使用多样且可靠的样本（预测熵低）进一步提升测试时自适应方法的效率。此外，它利用 EWC[14] 正则化防止对源域重要的参数发生剧烈变化。与 TENT 和 EATA 方法不同，CoTTA[35] 更新整个模型。为防止性能退化，它采用指数权重平均以及随机模型恢复，即随机选择的权重被重置为源模型。SAR[23] 通过移除具有大梯度的噪声测试样本并使用锐度感知最小化进一步改进。然而，它们也使用模型重置以防止遗忘。RMT[8] 提出了一种均值教师框架，并基于对比损失、自训练损失以及利用测试期间所有源训练数据的简单回放策略进行自适应。此外，它假设在自适应之前有一个额外的预热步骤。本文方法使用少量回放示例样本，且在 TTA 之前无需任何额外步骤。

测试时自适应 (TTA) 基准。测试时自适应最流行的设定是将 [11] 中提出的不同类别合成损坏应用于常用数据集，如 CIFAR10[15] 或 ImageNet，以人为获得域偏移。另一个用于持续测试时自适应的流行数据集是 DomainNet[24]，它包含不同域（如素描、信息图）中的图像。然而，现实世界部署中出现的分布偏移，例如在自动驾驶中，可能与同一物体的不同呈现方式非常不同。因此，最近引入了 CLAD 自动驾驶基准 [32]。它包含自然发生的分布偏移，如天气和光照条件、交通强度等的变化。该基准是为有监督持续学习场景开发的。在本工作中，我们将其用于测试时自适应，即不使用任何标签信息。在我们的工作中，我们还使用了 SHIFT 基准 [29]，这是一个为自动驾驶合成的数据集，捕捉了现实世界不断演变的特性。与我们类似，CoTTA[35] 包含现实的域偏移，但其测试规模非常小（1600 张图像）。总之，我们通过关注超长序列上的现实持续域偏移，扩展了先前的测试时自适应工作。




图 2：我们的方法 AR-TTA 利用重放策略和均值教师框架。每张图像与从记忆中采样的示例样本配对，图像对进行混合。类似地，来自教师模型的伪标签与采样示例样本的标签进行混合。学生模型基于其对增强样本的预测与增强伪标签之间的交叉熵损失进行更新。教师模型基于学生权重的指数移动平均进行自适应。每张图像的预测取自教师模型。

3 方法

持续测试时自适应旨在评估过程中即时地将预训练模型 f_{θ_0} （在有标签源数据 $(\mathcal{X}^S, \mathcal{Y}^S)$ 上训练）适配到不断变化的无标签测试数据批次流 $\mathbf{x}'$ 。我们提出的方法（图 2）可分为三个部分。我们首先在 3.1 节介绍模型更新过程。然后，在 3.2 节解释使用混合增强的经验重放。自适应批归一化统计量的过程在 3.3 节中呈现。

3.1 权重平均一致性

沿用先前工作 [8, 35]，本文采用自训练均值教师框架更新模型。该框架提升了伪标签的可靠性，并降低了误差累积的风险。本文初始化两个结构相同的人工神经网络模型，即学生模型 f_{θ} 与教师模型 $f_{\theta'}$ ，二者权重相等，均由源域数据训练获得。对于时间步 t 的每一批测试数据 $\mathbf{x}_t^T$ ，两个模型分别给出预测。教师模型的预测结果 $\hat{y}_{t,c}^T$ 被用作软伪标签。学生模型通过其预测与伪标签之间的交叉熵损失进行更新：

$$\mathcal{L}_{\theta_t}(\mathbf{x}_t^T) = - \sum_c \hat{y}_{t,c}^T \log \hat{y}_{t,c}^T \quad (1)$$

其中 $\hat{y}_{t,c}^T$ 表示学生模型预测类别 c 的概率。随后，教师模型的权重 θ' 通过学生模型权重 θ 的指数移动平均进行更新：

$$\theta'_{t+1} = \alpha \theta'_t + (1 - \alpha) \theta_{t+1} \quad (2)$$

其中 α 为平滑因子。采用权重平均的教师模型可确保伪标签噪声更低 [35]，提升泛化能力 [21]，且增加的惯性可防止基于噪声自训练反馈的权重快速更新。与许多其他测试时自适应方法 [22, 23, 33] 不同，本文不将权重更新仅限于批归一化层的仿射参数，而是对整个模型进行自适应。本文认为，仅调整批归一化层的权重不足以赋予模型

在不同域上成功运行的灵活性。本文在附录中通过实验证实了这一观点。

3.2 基于自适应的经验回放

在持续测试时自适应过程中, 自训练反馈无法保证准确, 频繁的模型更新不可避免地导致显著的误差累积、灾难性遗忘, 甚至模型崩溃 [23]。持续学习研究表明, 经验回放是缓解灾难性遗忘最有效的策略之一 [2, 3, 25, 32]。基于这一洞见, 本文提出在自适应过程中采用回放策略, 以提醒模型已学内容并强化其初始知识。在此基础上, 受 [16, 37] 等工作的启发, 本文整合混合数据增强 [36] 以提升模型鲁棒性。完成源模型预训练后, 从带标签的源数据中为每个类别存储等量且数量较少的随机示例样本至内存。在每次测试时自适应迭代中, 从内存随机采样示例样本 $\mathbf{x}_t^S$ 及其标签 $\mathbf{y}_t^S$ 。采样示例样本的数量等于批大小。混合后的样本批次 $\tilde{\mathbf{x}}_t$ 通过将测试数据样本与内存样本进行线性插值生成:

$$\tilde{\mathbf{x}}_t = \lambda \mathbf{x}_t^T + (1 - \lambda) \mathbf{x}_t^S \quad (3)$$

其中 $\lambda \sim \text{Beta}(\psi, \rho)$, 对于 $\psi, \rho \in (0, \infty)$ 。类似地, 用于交叉熵损失的标签是由教师模型基于当前未修改的测试批次 $\hat{\mathbf{y}}_t^T$ 生成的伪标签与内存中的标签 $\mathbf{y}_t^S$ 进行插值的结果, 使用相同的 λ :

$$\tilde{\mathbf{y}}_t = \lambda \hat{\mathbf{y}}_t^T + (1 - \lambda) \mathbf{y}_t^S \quad (4)$$

学生模型以增强批次 $\tilde{\mathbf{x}}_t$ 作为输入。其预测与插值标签 $\tilde{\mathbf{y}}_t$ 进行比较, 以计算如第 3.1 节所述的损失。将回放内存中的示例样本与待训练样本混合的类似方法已在 LUMP [16] 中成功使用, 但该方法用于持续表示学习任务。结合经验回放与混合增强有助于模型保留已获得的知识, 并降低伪标签噪声对自适应过程的影响。

3.3 动态批归一化统计量

批归一化 [13] (BN) 是利用初始训练数据的运行统计量对网络值进行归一化, 并在测试时应用。然而, 分布外数据可能干扰这一过程, 导致模型性能下降。测试时自适应方法 [22, 23, 33, 35] 通常对每个批次单独重新计算统计量。然而, 由于样本量小且数据存在时间相关性, 这种方法可能存在缺陷。在这些情况下, 使用源数据的 BN 统计量可能提供更准确的分布估计。为了进行稳健的统计量估计, 我们受 [12] 启发, 提出在测试时的时间步 t 通过线性插值计算 BN 统计量 $\phi_t = (\mu_t, \sigma_t)$, 插值对象为保存的源数据统计量 ϕ^S 与当前批次计算值 ϕ_t^T :

$$\phi_t = (1 - \beta_{ema}) \phi^S + \beta_{ema} \phi_t^T \quad (5)$$

其中 β_{ema} 是一个参数，用于权衡已保存统计量与当前计算统计量的影响。由于分布偏移的严重程度可能不同，我们需要适当调整 β_{ema} 的值。当分布偏移相对于源域较为严重时，该值应较大；当分布相似时，该值应较小。遵循 [12]，我们利用对称 KL 发散作为分布间距离的测度 $D(\phi_{t-1}, \phi_t^T)$ ：

$$D(\phi_{t-1}, \phi_t^T) = \frac{1}{C} \sum_{i=1}^C KL(\phi_{t-1,i} || \phi_{t,i}^T) + KL(\phi_{t,i}^T || \phi_{t-1,i}) \tag{6}$$

该距离用于计算时间步 t 的 β_t ：

$$\beta_t = 1 - e^{-\gamma D(\phi_{t-1}, \phi_t^T)} \tag{7}$$

其中 γ 是一个尺度超参数。为了弥补当前分布可能被错误估计的问题，并为自适应提供更多稳定性，我们考虑之前的 $\beta_{1:t-1}$ 值，并使用指数移动平均计算 β_{ema} ，系数为 α ：

$$\beta_{ema} = (1 - \alpha)\beta_{t-1} + \alpha\beta_t \tag{8}$$

本文方法区别于 MECTA[12]，保留原始归一化统计量而非使用指数移动平均。动机在于改变该值会导致不可避免的遗忘，并易受时间相关性影响。本文确保在与源数据相似的域上性能一致。同时，通过使用 β 参数的指数移动平均，允许统计量相对源数据有轻微漂移，为适应严重域偏移提供足够灵活性。

4 实验

数据集与基准。我们在多个具有领域偏移的图像分类数据集上评估了这些方法。我们使用 CIFAR10C 和 ImageNet-C 作为基准，它们包含人工的、基于损坏的偏移，被广泛用于评估测试时自适应方法 [8, 22, 23, 33, 35]。自然偏移的实验包括在 CIFAR10.1 [26] 和 SHIFT [29] 数据集上的测试，以及适应测试时自适应设置的 CLAD-C 持续学习基准 [32]。CIFAR10.1 的设计旨在最小化相对于原始 CIFAR10 数据集的分布偏移。这使我们能够测试 TTA 方法对非常细微的分布偏移的鲁棒性。CLAD-C 基准的目标是为持续学习引入一个更现实的测试平台。在不同地点和条件下拍摄的图像按时间顺序排列，导致标签和领域中的分布偏移。它由 6 个测试序列组成。我们在第一个训练序列上预训练源模型。TTA 在剩余的 5 个序列上持续测试，总共有 17092 张图像。在 SHIFT 数据集中，图像是在虚拟环境中模拟的多种现实领域类型中拍摄的，包括不同的天气和一天中的时间。我们将其视为自然领域偏移基准，因为它真实地表示了由真实条件而非图像损坏引起的分布偏移。我们在白天晴朗天气下拍摄的图像上训练源模型，并测试适应方法在各种天气组合和一天中的时间下的表现。我们最终得到 14 个不同的领域，总共有 380667 张图像。我们将我们原创的持续测试时自适应基准称为 SHIFT-C。更多细节可以在附录中找到。

方法论。我们考察了持续测试时自适应 (Continual Test-Time Adaptation) 的设置, 其中模型持续适应新领域, 除非作为被测试方法的一部分, 否则不会重置模型。为了模拟连续的数据流以及模型快速适应的需求, 我们使用了较小的批大小 10。这也是在线持续学习中常用的批大小 [17]。在嵌入式应用中, 有限的资源通常意味着较小的批大小, 这要求测试时自适应方法能够在样本较少的情况下有效工作。我们使用平均分类准确率和平均类平均准确率 (AMCA) 来评估方法。后者计算每个领域上所有类别的平均准确率, 使得在类别不平衡的数据集中每个类别都同等重要。基线。我们进行了涉及六种最先进方法的实验作为基线: TENT-continual [33]、EATA [22]、CoTTA [35]、SAR [23] 和 RMT [8]。此外, 我们展示了丢弃源数据的批归一化统计量并分别计算每个批次统计量 (BN-1) 的结果 [28]。我们还报告了冻结源模型 (Source) 的性能。为了提供公平的比较, 我们展示了 RMT 和我们的方法 (AR-TTA) 在不使用重放策略时的结果。

实现细节。遵循其他最先进的测试时自适应工作, 我们使用来自 RobustBench [6] 模型库的预训练 WideResnet28/ResNet50 模型, 用于 CIFAR10C 和 CIFAR10.1/ImageNet-C 数据集。在其余基准上, 我们利用 ResNet50 架构, 其权重在 ImageNet 上预训练, 从 torchvision 库 [18] 获得, 并针对特定基准的源数据进行微调。我们的方法使用默认的重放记忆大小为 2000 个样本, 这在持续学习设置中常用 [19], 并且只增加了很小的存储需求。RMT 方法遵循原始工作, 使用所有源训练数据。实验技术方面的其余细节可在附录中找到。

4.1 结果

所有测试基准的结果如表 1 所示。我们的方法能够达到最佳平均准确率 75.5%, 表明了我们方法的鲁棒性。此外, 即使没有重放方法, 它也表现出稳定的性能。

人工领域偏移。人工域偏移对源模型构成重大挑战, 在 CIFAR10C/ImageNet-C 上仅达到 56.5%/17.1% 的平均准确率。对每个批次分别计算批归一化统计量, 已经将损坏图像上的结果显著提升至 75.0%/26.9% 的准确率。所比较的最先进的测试时自适应方法均采用 BN-1 技术, 因此其性能较之有所提升, 但准确率值的增加并不显著。RMT 在 CIFAR10C 上优于本文方法, 但在其他基准上性能不足, 且利用整个源训练数据集进行回放, 使得 AR-TTA 对于不同类型的数据集更为可靠。

自然域偏移。BN-1 方法使冻结的源模型在自然偏移上的性能显著下降约 8-10 个百分点的准确率。类似地, 最先进的测试时自适应方法取得的平均准确率显著低于源模型, 使其对自然域偏移无效。这表明在人工域偏移 (以损坏形式) 上对这些方法进行基准测试, 并不能可靠地估计测试时自适应方法在实际应用中的性能。本文方法在自适应过程中使用预计算统计量和源数据示例样本, 优于最先进的方法, 并取得了高于源模型的准确率。这表明了其有效性和自适应能力。保持预计算统计量不变可能

8 SÓJKA 等: AR-TTA: 一种用于真实世界持续测试时自适应的简单方法

表 1: 所有测试的在线持续测试时自适应任务的分类准确率 (%)。使用示例样本的方法位于右侧部分。红色表示准确率低于源模型。

Method	CIFAR10C	ImageNet-C	CIFAR10.1	CLAD-C	SHIFT-C	Average
Source	56.5	18.1	88.3	81.3	93.5	67.5
BN-1	75.0	26.9	81.3	71.1	85.1	67.9
TENT 	76.7	29.2	82.3	71.5	82.7	68.5
EATA 	78.2	31.5	82.9	71.1	85.1	69.8
CoTTA 	75.7	15.5	82.3	72.6	77.4	64.7
SAR 	75.2	30.8	81.3	71.1	85.1	68.7
RMT w/o replay 	77.6	21.7	80.6	75.1	92.2	69.4
RMT 	83.1	30.5	83.3	75.3	95.9	73.6
AR-TTA (Ours) w/o replay	77.3±0.07	30.0±0.45	88.2±0.10	83.9±0.30	92.4±0.25	74.4
AR-TTA (Ours)	78.8±0.13	32.0±0.07	88.3±0.05	83.7±0.64	94.8±0.03	75.5

有时更为有益，尤其是在源模型表现相对较好的域偏移上。

准确率随时间变化。图 3 中的结果显示最先进方法的准确率如何降至源模型性能以下。可以看出，AR-TTA 在前两个源模型表现良好的域上保持了源模型的准确率，然后在源模型性能恶化时（在域 T3 处）对其进行了改进。

表 2: CLAD-C 持续测试时自适应任务的分类准确率与平均类准确率 (AMCA) (%)

Method	$t \longrightarrow$					Mean day	Mean night	Mean	AMCA
	T1	T2	T3	T4	T5				
Source	75.6	85.9	73.3	87.5	66.2	86.6	71.2	81.3	57.6
BN-1	73.2	69.9	75.0	75.5	59.7	72.2	69.1	71.1	48.3
TENT 	73.4	69.8	76.5	76.1	59.7	72.4	69.8	71.5	47.6
EATA 	73.3	69.9	75.0	75.6	59.7	72.2	69.1	71.1	48.4
CoTTA 	75.2	69.3	80.2	77.0	62.7	72.4	72.9	72.6	44.8
SAR 	73.2	69.9	75.0	75.5	59.7	72.2	69.1	71.1	48.3
RMT w/o replay 	87.1	70.9	86.6	76.9	64.3	73.9	79.3	75.1	48.4
RMT 	83.8	71.3	85.0	77.6	66.4	74.5	78.4	75.3	48.8
AR-TTA (Ours) w/o replay	76.9	86.7	81.4	87.9	73.5	87.2	77.1	83.9±0.30	59.6±2.92
AR-TTA (Ours)	77.2	86.7	80.0	89.6	70.7	87.8	75.7	83.7±0.64	63.1±3.32

表 3: SHIFT-C 持续测试时自适应任务的分类准确率与平均类准确率 (AMCA) (%)

Method	$t \longrightarrow$														Mean	AMCA
	daytime				dawn/dusk				night							
	cloudy	overcast	rainy	foggy	clear	cloudy	overcast	rainy	foggy	clear	cloudy	overcast	rainy	foggy		
Source	97.9	98.2	97.5	92.5	93.6	94.1	94.0	93.5	91.5	89.1	89.3	90.6	89.1	90.7	93.5	89.5
BN-1	89.1	88.9	88.0	86.2	85.3	84.8	87.3	83.5	84.8	81.3	81.2	80.3	79.6	83.5	85.1	69.9
TENT 	89.6	88.8	87.5	84.6	83.3	81.2	85.0	80.7	80.2	78.0	77.0	76.1	75.7	77.6	82.7	57.6
EATA 	89.1	88.9	88.0	86.2	85.3	84.8	87.4	83.6	84.9	81.4	81.4	80.3	79.7	83.7	85.1	70.5
CoTTA 	88.2	87.1	84.1	80.5	78.7	76.2	80.5	74.0	74.9	71.5	70.3	67.3	64.9	66.2	77.4	47.2
SAR 	89.1	88.9	88.0	86.2	85.3	84.8	87.3	83.5	84.8	81.3	81.2	80.3	79.6	83.6	85.1	69.9
RMT w/o replay 	93.0	94.2	93.6	91.7	91.0	91.3	93.0	92.2	90.8	90.7	90.9	91.7	90.5	91.7	92.0	80.3
RMT 	95.9	97.2	97.0	95.4	95.4	95.9	96.5	96.3	95.0	94.9	95.1	96.3	95.5	95.6	95.9	91.1
AR-TTA (Ours) w/o replay	96.4	96.5	95.3	93.2	92.2	91.9	93.2	91.4	91.8	88.7	88.7	88.6	87.5	91.2	92.4 ± 0.25	83.5 ± 0.96
AR-TTA (Ours)	97.7	98.0	97.4	94.3	94.2	95.5	94.8	95.2	93.1	92.3	92.7	93.0	91.4	92.6	94.8 ± 0.03	90.2 ± 0.24

表 4: 所提方法不同配置下 CIFAR10C 和 CLAD-C 任务的分类准确率 (%)

Method	CIFAR10C	CLAD-C
A: Weight-avg. teacher	75.7 $\pm$ 0.07	71.1 $\pm$ 0.53
B: A + Replay memory	77.3 $\pm$ 0.16	69.0 $\pm$ 0.66
C: B + Mixup	78.5 $\pm$ 0.13	72.2 $\pm$ 0.31
D: A + Dynamic BN stats	77.3 $\pm$ 0.07	83.8 $\pm$ 0.82
E: D + Replay memory	79.8 $\pm$ 0.03	82.8 $\pm$ 1.09
AR-TTA (Ours): E + Mixup	78.8 $\pm$ 0.13	83.7 $\pm$ 0.64

表 5: 加入简单回放方法后最先进方法的分类准确率与平均类准确率 (AMCA) (%) 结果

Method	CIFAR10C	CLAD-C	
	Mean	Mean	AMCA
Source	56.5	81.3	57.6
TENT 	77.3	70.3	49.2
EATA 	78.6	71.1	48.4
CoTTA 	79.9	72.6	51.0
SAR 	75.3	71.1	48.3
AR-TTA (Ours)	78.8	83.7	63.1




图 3: CLAD-C 基准上所选方法持续适应数据序列的批级分类准确率 (%), 以 400 批为窗口取平均, x 轴主刻度表示不同域的开始, 次刻度表示图像编号。建议彩色查看。

4.2 详细分析

示例样本的影响。表 2 和表 3 展示了在 CLAD-C 和 SHIFT-C 基准上的 AMCA 结果。结果表明, 在使用重放方法时, 平均每类准确率有显著提升。这表明在类别不平衡的测试时自适应设置中, 使用重放记忆可能对保持每个类别的高性能很重要。此外, 当所有方法都使用示例样本时, 我们的方法平均而言仍优于竞争对手, 并且是唯一持续优于冻结模型的方法。

组件分析。表 4 展示了所提方法中各个组件的贡献。在初始设置 **A** 中, 我们使用权重平均教师模型生成伪标签, 并使用交叉熵损失来适应模型, 其中源数据的批归一化统计量被丢弃。通过以 1:1 的比例将随机增强的示例样本从记忆注入批次, 添加简单的重放方法 (**B**, **E**), 并未在每个数据集上提升性能。可以看出, 混合数据增强可以提升简单重放方法 (**C**) 的性能。此外, 动态批归一化统计量显著有助于准确率提升 (**D**, **E**, **AR-TTA**), 尤其是在 **CLAD-C** 基准上。

具有简单重放记忆的基线。为了确保公平比较并检查最先进方法在使用重放策略时的性能, 我们为每种方法添加了简单的重放方法。从类别平衡的重放记忆中, 在每个批次上采样恒定数量的重放示例样本, 数量等于批次

大小。从示例样本计算的交叉熵损失值被添加到每种方法的原始损失中。结果见表 5。虽然所提方法在 CIFAR10C 上略逊于 CoTTA，但在自然域偏移数据集上表现显著更好。最重要的是，我们的方法是唯一持续优于源模型的方法。

计算效率评估 表 6 展示了基线方法和本文方法在来自 CIFAR10C 基准的 10,000 张图像上的墙钟时间和内存使用情况的比较。虽然本文方法并非计算效率最高的，但它在计算需求和性能之间取得了平衡。值得注意的是，尽管引入了示例样本，本文仍保持了稳定的计算预算。这是因为额外的样本被用于混合增强中，训练批大小保持不变。这种方法与 RMT 方法形成对比，后者使用重放技术会显著增加计算复杂度。

表 6：在单个 RTX 4080 GPU 上处理 CIFAR10C 的 10,000 张图像所测得的墙钟时间（秒）和内存使用量（MB）。

Method	Time [s]	Memory [MB]
Source	8.0	304
BN-I	8.3	304
TENT [8]	16.3	506
EATA [9]	24.3	505
CoTTA [6]	319.4	1532
SAR [10]	30.8	506
RMT [8] w/o replay	55.5	1576
RMT [8]	163.7	3039
AR-TTA (Ours) w/o replay	66.2	1098
AR-TTA (Ours)	66.6	1098

5 结论

本文通过提出两个新的评估基准，即 SHIFT-C 和 CLAD-C，使用更真实的数据评估了现有持续测试时自适应（TTA）方法在现实场景中的表现。研究结果表明，当前最先进的方法在此类场景下并不充分，其准确率未能超过冻结的源模型。这引发了人们对某些 TTA 方法在现实世界中适用性的担忧，并揭示了某些方法中频繁重置模型的现象。为解决这些局限性，本文提出了一种新颖且直接的方法，称为 AR-TTA，该方法基于自训练框架。AR-TTA 利用一个小的源数据内存缓冲区，结合混合数据增强，并根据域偏移的强度动态更新批归一化统计量。通过实验研究，本文证明了 AR-TTA 方法在各种基准上达到了最先进的性能。这些基准包括小批大小、长测试序列、不同域偏移程度的现实评估，以及诸如损坏的 CIFAR10-C 等人工场景。值得注意的是，AR-TTA 始终优于源模型，而源模型是可行的 TTA 方法的最终基线。本文对多种不同数据集的 TTA 进行了更现实的评估，从而更好地理解它们的潜在优势和不足。

局限性。本文方法的主要局限性在于使用了源数据的内存缓冲区，这在资源受限的场景下或存在隐私顾虑时可能成为问题。

致谢

本研究部分由国家科学中心（波兰）资助，项目编号：2020/39/B/ST6/01511、2022/45/B/ST6/02817 和 2023/51/D/ST6/02846。Bartłomiej Twardowski 感谢 RYC2021-032765-I 资助。我们衷心感谢波兰高性能计算基础设施 PLGrid（HPC 中心：ACK Cyfronet AGH）在计算资助编号 PLG/2023/016613 下提供的计算机设施和支持。本文得到了地平线欧洲计划（HORIZON-CL4-2022-HUMAN-02）在“ELIAS：欧洲人工智能可持续发展灯塔”项目下的支持，项目编号 101120237。

参考文献

- [1] Motasem Alfarrar, Hani Itani, Alejandro Pardo, Shyma Alhuwaider, Merey Ramazanov, Juan C Pérez, Zhipeng Cai, Matthias Müller, and Bernard Ghanem. Re-visiting test time adaptation under online evaluation. *arXiv preprint arXiv:2304.04795*, 2023.
- [2] M. Boschini, L. Bonicelli, P. Buzzega, A. Porrello, and S. Calderara. Class-incremental continual learning into the extended der-verse. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 45(05):5497–5512, may 2023. ISSN 1939-3539.
- [3] Arslan Chaudhry, Albert Gordo, Puneet Kumar Dokania, Philip H. S. Torr, and David Lopez-Paz. Using hindsight to anchor past knowledge in continual learning. In *AAAI Conference on Artificial Intelligence*, 2019.
- [4] Chaoqi Chen, Weiping Xie, Wenbing Huang, Yu Rong, Xinghao Ding, Yue Huang, Tingyang Xu, and Junzhou Huang. Progressive feature alignment for unsupervised domain adaptation. In *IEEE Conference on Computer Vision and Pattern Recognition, CVPR 2019, Long Beach, CA, USA, June 16-20, 2019*, pages 627–636. Computer Vision Foundation / IEEE, 2019.
- [5] Dian Chen, Dequan Wang, Trevor Darrell, and Sayna Ebrahimi. Contrastive test-time adaptation. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition, CVPR 2022, New Orleans, LA, USA, June 18-24, 2022*, pages 295–305. IEEE, 2022.
- [6] Francesco Croce, Maksym Andriushchenko, Vikash Sehwal, Edoardo Debenedetti, Nicolas Flammarion, Mung Chiang, Prateek Mittal, and Matthias Hein. Robustbench: a standardized adversarial robustness benchmark. *arXiv preprint arXiv:2010.09670*, 2020.
- [7] Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. Imagenet: A large-scale hierarchical image database. In *2009 IEEE conference on computer vision and pattern recognition*, pages 248–255. Ieee, 2009.
- [8] Mario Döbler, Robert A. Marsden, and Bin Yang. Robust mean teacher for continual and gradual test-time adaptation. *CoRR*, abs/2211.13081, 2022.
- [9] Alexey Dosovitskiy, German Ros, Felipe Codevilla, Antonio Lopez, and Vladlen Koltun. CARLA: An open urban driving simulator. In *Proceedings of the 1st Annual Conference on Robot Learning*, pages 1–16, 2017.

- [10] Jianhua Han, Xiwen Liang, Hang Xu, Kai Chen, Lanqing Hong, Jiageng Mao, Chaoqiang Ye, Wei Zhang, Zhenguo Li, Xiaodan Liang, and Chunjing Xu. Soda10m: A large-scale 2d self/semi-supervised object detection dataset for autonomous driving, 2021.
- [11] Dan Hendrycks and Thomas Dietterich. Benchmarking neural network robustness to common corruptions and perturbations. *Proceedings of the International Conference on Learning Representations*, 2019.
- [12] Junyuan Hong, Lingjuan Lyu, Jiayu Zhou, and Michael Spranger. Mecta: Memory-economic continual test-time adaptation. In *ICLR*, 2023.
- [13] Sergey Ioffe and Christian Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *Proceedings of the 32nd International Conference on Machine Learning - Volume 37, ICML'15*, page 448–456. JMLR.org, 2015.
- [14] James Kirkpatrick, Razvan Pascanu, Neil Rabinowitz, Joel Veness, Guillaume Desjardins, Andrei A Rusu, Kieran Milan, John Quan, Tiago Ramalho, Agnieszka Grabska-Barwinska, et al. Overcoming catastrophic forgetting in neural networks. *Proceedings of the national academy of sciences*, 114(13):3521–3526, 2017.
- [15] Alex Krizhevsky. Learning multiple layers of features from tiny images. pages 32–33, 2009.
- [16] Divyam Madaan, Jaehong Yoon, Yuanchun Li, Yunxin Liu, and Sung Ju Hwang. Representational continuity for unsupervised continual learning. In *International Conference on Learning Representations*, 2022.
- [17] Zheda Mai, Ruiwen Li, Jihwan Jeong, David Quispe, Hyunwoo Kim, and Scott Sanner. Online continual learning in image classification: An empirical survey. *Neurocomput.*, 469(C):28–51, jan 2022. ISSN 0925-2312. doi: 10.1016/j.neucom.2021.10.021. URL <https://doi.org/10.1016/j.neucom.2021.10.021>.
- [18] TorchVision maintainers and contributors. Torchvision: Pytorch’s computer vision library. <https://github.com/pytorch/vision>, 2016.
- [19] Marc Masana, Xialei Liu, Bartłomiej Twardowski, Mikel Menta, Andrew D Bagdanov, and Joost van de Weijer. Class-incremental learning: survey and performance evaluation on image classification. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2022.
- [20] Michael McCloskey and Neal J Cohen. Catastrophic interference in connectionist networks: The sequential learning problem. In *Psychology of learning and motivation*, volume 24, pages 109–165. Elsevier, 1989.
- [21] Daniel Morales-Brotons, Thijs Vogels, and Hadrien Hendrikx. Exponential moving average of weights in deep learning: Dynamics and benefits. *Transactions on Machine Learning Research*, 2024. ISSN 2835-8856.

- [22] Shuaicheng Niu, Jiaxiang Wu, Yifan Zhang, Yaofo Chen, Shijian Zheng, Peilin Zhao, and Mingkui Tan. Efficient test-time model adaptation without forgetting. In *International Conference on Machine Learning, ICML 2022, 17-23 July 2022, Baltimore, Maryland, USA*, volume 162 of *Proceedings of Machine Learning Research*, pages 16888–16905. PMLR, 2022.
- [23] Shuaicheng Niu, Jiaxiang Wu, Yifan Zhang, Zhiquan Wen, Yaofo Chen, Peilin Zhao, and Mingkui Tan. Towards stable test-time adaptation in dynamic wild world. In *International Conference on Learning Representations*, 2023.
- [24] Xingchao Peng, Qinxun Bai, Xide Xia, Zijun Huang, Kate Saenko, and Bo Wang. Moment matching for multi-source domain adaptation. In *Proceedings of the IEEE International Conference on Computer Vision*, pages 1406–1415, 2019.
- [25] Sylvestre-Alvise Rebuffi, Alexander Kolesnikov, Georg Sperl, and Christoph H. Lampert. icarl: Incremental classifier and representation learning. In *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 5533–5542, 2017.
- [26] Benjamin Recht, Rebecca Roelofs, Ludwig Schmidt, and Vaishal Shankar. Do cifar-10 classifiers generalize to cifar-10?, 06 2018.
- [27] Benjamin Recht, Rebecca Roelofs, Ludwig Schmidt, and Vaishal Shankar. Do cifar-10 classifiers generalize to cifar-10? 2018. <https://arxiv.org/abs/1806.00451>.
- [28] Steffen Schneider, Evgenia Rusak, Luisa Eck, Oliver Bringmann, Wieland Brendel, and Matthias Bethge. Improving robustness against common corruptions by covariate shift adaptation. *Advances in Neural Information Processing Systems*, 33:11539–11551, 2020.
- [29] Tao Sun, Mattia Segu, Janis Postels, Yuxuan Wang, Luc Van Gool, Bernt Schiele, Federico Tombari, and Fisher Yu. SHIFT: a synthetic driving dataset for continuous multi-task domain adaptation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 21371–21382, June 2022.
- [30] Yu Sun, Xiaolong Wang, Zhuang Liu, John Miller, Alexei A. Efros, and Moritz Hardt. Test-time training with self-supervision for generalization under distribution shifts. In *Proceedings of the 37th International Conference on Machine Learning, ICML 2020, 13-18 July 2020, Virtual Event*, volume 119 of *Proceedings of Machine Learning Research*, pages 9229–9248. PMLR, 2020.
- [31] Antonio Torralba, Rob Fergus, and William T. Freeman. 80 million tiny images: A large data set for nonparametric object and scene recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 30(11):1958–1970, 2008. doi: 10.1109/TPAMI.2008.128.
- [32] Eli Verwimp, Kuo Yang, Sarah Parisot, Lanqing Hong, Steven McDonagh, Eduardo Pérez-Pellitero, Matthias De Lange, and Tinne Tuytelaars. Clad: A realistic continual learning benchmark for autonomous driving. *Neural Networks*, 161:659–669, 2023.

- [33] Dequan Wang, Evan Shelhamer, Shaoteng Liu, Bruno A. Olshausen, and Trevor Darrell. Tent: Fully test-time adaptation by entropy minimization. In *9th International Conference on Learning Representations, ICLR 2021, Virtual Event, Austria, May 3-7, 2021*. OpenReview.net, 2021.
- [34] Mei Wang and Weihong Deng. Deep visual domain adaptation: A survey. *Neurocomputing*, 312:135–153, 2018.
- [35] Qin Wang, Olga Fink, Luc Van Gool, and Dengxin Dai. Continual test-time domain adaptation. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition, CVPR 2022, New Orleans, LA, USA, June 18-24, 2022*, pages 7191–7201. IEEE, 2022.
- [36] Hongyi Zhang, Moustapha Cisse, Yann N. Dauphin, and David Lopez-Paz. mixup: Beyond empirical risk minimization. *International Conference on Learning Representations*, 2018.
- [37] Fei Zhu, Zhen Cheng, Xu-yao Zhang, and Cheng-lin Liu. Class-incremental learning via dual augmentation. In M. Ranzato, A. Beygelzimer, Y. Dauphin, P.S. Liang, and J. Wortman Vaughan, editors, *Advances in Neural Information Processing Systems*, volume 34, pages 14306–14318. Curran Associates, Inc., 2021.

A Appendix

第 A.1 节对我们的方法进行了详细分析：记忆回放的效果、不同模型层的适配以及超参数分析。第 A.4 节提供了主论文实验的详细结果。第 A.2 节描述了所有方法的实现细节，包括超参数搜索。第 A.3 节描述了本文使用的基准，包括新引入的 SHIFT-C 和 CLAD-C。

A.1 AR-TTA 详细分析

A.1.1 回放记忆大小的影响

在内存受限的环境中，必须在内存中保留一组源数据样本可能存在问题。我们验证了最小化回放记忆大小的可能性，并评估了我们的方法在不同存储样本数量下的表现。图 A.1 中的结果表明，我们的方法对回放记忆大小具有鲁棒性。在 CIFAR10C 和 CLAD-C 基准上，记忆大小为 500 和 10000 时准确率没有显著差异。对于 CIFAR10C，仅使用 100 个示例样本时性能略有下降。CLAD-C 中较轻微的域偏移允许在不降低性能的情况下更显著地减小记忆大小。




图 A.1：回放记忆大小对 CIFAR10C 和 CLAD-C 基准上最终准确率的 影响。

A.1.2 适配权重

表 A.1 展示了使用本文所提方法时，不同适配权重配置下的性能表现。我们检验了适配最后两层、前两层以及仅适配批归一化统计量等多种配置。最佳结果通过适配整个模型获得。

Table A.1: Classification accuracy (%) for different configurations of adapted weights with our proposed method AR-TTA.

CIFAR10C (WideResNet28)		CLAD-C (ResNet50)	
Adapted weights	Mean	Adapted weights	Mean
block 1 (BN affine only)	61.4	layer 1 (BN affine only)	81.7
block 1, 2 (BN affine only)	26.3	layer 1, 2 (BN affine only)	81.5
block 2, 3 (BN affine only)	73.8	layer 3, 4 (BN affine only)	81.9
block 3 (BN affine only)	72.8	layer 4 (BN affine only)	82.1
block 1	17.4	layer 1	80.4
block 1, 2	13.9	layer 1, 2	81.6
block 2, 3	78.4	layer 3, 4	83.3
block 3	77.2	layer 4	82.8
BN affine only	75.1	BN affine only	81.8
Whole model (Ours)	78.8	Whole model (Ours)	83.7

A.1.3 混合增强中贝塔分布形状的影响

混合增强中的贝塔分布用于采样示例样本之间的插值参数。在本文方法中，它控制测试数据样本与回放记忆库中示例样本之间的插值。通过调整该分布的形状，我们可以控制增强样本中回放数据与测试数据的比例。结果如表 A.2 所示。分布形状对结果没有显著影响。混合增强中常见的对称分布形状给出了最佳结果。

表 A.2: 在混合数据增强所需的插值参数 $\lambda \sim \text{Beta}(\psi, \rho)$ 采样中，不同贝塔分布参数 ψ 和 ρ 配置下 CIFAR10C 和 CLAD-C 任务的分类准确率 (%)。

ψ	ρ	CIFAR10C	CLAD-C
5.0	5.0	78.6	83.7
1.0	5.0	78.6	81.8
5.0	1.0	78.2	83.0
2.0	8.0	74.8	82.0
8.0	2.0	77.5	83.8
Ours			
0.4	0.4	78.8	83.7

A.1.4 附加组件分析

表 A.3 展示了本文方法不同组件配置的结果。其中包括不使用权重平均教师模型的实验。我们利用自适应模型自身的伪标签（配置 **A**）。此外，我们还展示了当为回放记忆选择的示例样本不进行类别平衡时，本文方法的性能表现。

表 A.3: 本文方法不同配置下 CIFAR10C 和 CLAD-C 任务的分类准确率 (%)。

Method	CIFAR10C	CLAD-C
A: Pseudo-labels	75.5 $\pm$ 0.07	71.3 $\pm$ 0.54
B: A + Weight-avg. teacher	75.7 $\pm$ 0.07	71.1 $\pm$ 0.53
C: B + Replay memory	77.3 $\pm$ 0.16	69.0 $\pm$ 0.66
D: C + Mixup	78.5 $\pm$ 0.13	72.2 $\pm$ 0.31
E: B + Dynamic BN stats	77.3 $\pm$ 0.07	83.8 $\pm$ 0.82
F: E + Replay memory	79.8 $\pm$ 0.03	82.8 $\pm$ 1.09
AR-TTA (Ours) with random memory selection	77.1 $\pm$ 0.36	83.7 $\pm$ 0.81
AR-TTA (Ours)	78.8 $\pm$ 0.13	83.7 $\pm$ 0.64

A.1.5 动态批归一化统计分析

γ 是分布间距离 $D(\phi^S, \phi_t^T)$ 的尺度参数。它决定了 β 计算值的大小，该值用于在保存的源批归一化 (BN) 统计量 ϕ^S 与当前批次计算的 BN 统计量 ϕ_t^T 之间进行线性插值。 γ 的值越高， β 的值往往越高。同时， β 值越高，当前批次的 BN 统计量对插值及最终使用的 BN 统计量计算的影响越大。在图 A.2 中我们展示了




图 A.2: CIFAR10C 与 CLAD-C 基准上平均分类准确率 (%) 与参数 γ 值之间的关系。

γ 参数值与我们的 AR-TTA 方法在 CIFAR10-to-CIFAR10C 和 CLAD-C 基准上的平均准确率之间的关系。我们可以看到两个基准之间呈现相反的趋势。这表明源域与每个测试数据批次估计分布之间的数据分布差异在 CIFAR10C 中比在 CLAD-C 中更为显著。这与 BN-1 [28] 基线方法的结果一致。BN-1 丢弃了源数据的 BN 统计量。与固定源模型相比, 其在 CIFAR10C 上的性能显著更好, 而在 CLAD-C 上更差。

A.2 实现细节

结果在 3 个随机种子之间取平均。来自 CIFAR10C 和 ImageNet-C 的样本被随机打乱。考虑到 CLAD-C 和 SHIFT-C 基准(视频序列)中数据的顺序性, 我们不想打乱图像。相反, 我们用 3 个不同的种子训练了 3 个源模型, 并在使用不同模型的实验之间对结果取平均。我们在每个基准上以持续的方式测试该方法, 这意味着这些方法持续地适应模型, 而不会在域之间重置到源状态。所比较方法的实现取自其官方代码库。我们使用论文中建议或在代码中找到的所有超参数和优化器。我们遵循 TTA 实验中使用的标准模型架构, 对 CIFAR10C 和 CIFAR10.1 使用 WideResnet28, 对 ImageNet-C、CLAD-C 和 SHIFT-C 使用 ResNet50。此外, 由于我们使用了较小的批大小(BS) 10 以及之前未在 TTA 中使用过的基准, 我们为每种方法搜索最优学习率(LR)。考虑到批大小减小, 我们专注于降低 LR。此外, 我们搜索 EATA 的 ϵ 超参数以正确拒绝用于适应的样本。参数搜索的结果可以在表 A.4 中找到。每种方法使用的细节和参数描述如下。

TENT [83] 我们对 CIFAR10.1 使用 Adam 优化器, LR 为 $= 0.00025$, 对其他所有测试数据集使用 LR 为 $= 0.00003125$ 。在原始论文中, TENT 对所有数据集(除 ImageNet 外)使用 LR 为 $= 0.001$, 但在我们的设置中, 使用该值表现更差。

CoTTA [35] 我们对每个测试基准使用 Adam 优化器, LR 为 $= 0.00025$, 但 ImageNet-C 除外, 其 LR 等于 0.00003125 。原始实现将 LR 设置为 0.001 , 但使用调整后的值取得了更好的结果。我们遵循作者给出的其他超参数值的建议。恢复概率 p 设置为 0.01 , 教师权重指数移动平均的平滑因子 α 等于 0.999 , 应用增强的置信度阈值 p_{th} 设置为 0.92 。

EATA [22] 对于 CIFAR10C、ImageNet-C 和 CLAD-C, 我们使用动量为 0.9 、学习率为 0.00025 的 SGD 优化器。SHIFT-C 的学习率为 0.00003125 , CIFAR10.1 的学习率为 0.001 。原始 EATA 论文中 CIFAR10C/ImageNet-C 使用的学习率为 $0.005/0.00025$, 但他们使用的批量大小 $= 64$ 。在搜索用于过滤冗余样本的最优 ϵ 参数值后, 我们将其设置为 CLAD-C/SHIFT 的 $0.05/0.6$ 。CIFAR10C 和 CIFAR10.1/ImageNet-C 的 ϵ 值等于 $0.4/0.05$, 与原始论文一致。熵常数 E_0 设置为标准值 $0.4 \times \ln C$, 其中 C 为

类别数，遵循原始论文和 [23]。权衡参数 β 等于 1，并且使用 2000 个样本来计算模型权重的 Fisher 重要性，与原始论文中 CIFAR10 数据集的做法相同。

SAR [28] 对于 CIFAR10C 和 CIFAR10.1，使用动量为 0.9、学习率 = 为 0.001 的 SGD 优化器；对于 ImageNet-C、CLAD-C 和 SHIFT-C，学习率 = 为 0.00025。这与作者的选择基本一致，因为在原始实验中，他们为 ResNet/Vit 模型使用的学习率为 0.00025/0.001。参数 E_0 设置为 $0.4 \times \ln C$ ，与论文中一致，类似于 EATA。我们遵循作者的选择，将恒定重置阈值 e_0 设为 0.2，移动平均因子设为 0.9。半径参数 ρ 设置为默认值 0.05。

RMT [8] 对于 CIFAR10C、CLAD-C 和 SHIFT-C，使用学习率 = 为 0.00025 的 Adam 优化器。CIFAR10.1 和 ImageNet-C 的学习率为 0.00003125，均遵循网格搜索。遵循原始实现，我们将对比损失的温度 τ 设为 0.1，用于更新均值教师的动量参数 α 设为 0.999。

AR-TTA（本文方法） 我们使用动量为 0.9 的 SGD 优化器。对于 ImageNet-C 和 CIFAR10.1，学习率设为 0.00025；其余基准设为 0.001。尺度超参数 γ 对于 CIFAR10.1、CLAD-C 和 SHIFT-C 设为 0.1，对于 ImageNet-C 和 CIFAR10C 设为 10。用于加权 β_{ema} 的 α 值等于 0.2。我们将初始 β_{ema} 值设为 0.1。用于贝塔分布采样 λ 以进行混合的 ψ 和 ρ 参数等于标准值 0.4。我们从源数据中存储 2000 个示例样本用于记忆回放。

表 A.4: 在 CIFAR10C、ImageNet-C、CIFAR10.1、CLAD-C 和 SHIFT-C 持续测试时自适应任务中，不同学习率及 EATA 的 ε 参数下，对比最先进方法的平均分类准确率（%）。

Method	learning rate	ε	CIFAR10C	CIFAR10.1	CLAD-C	SHIFT-C	ImageNet-C
CoTTA [14]	0.001	-	49.3	79.3	71.5	74.3	3.8
	0.00025	-	75.7	82.3	71.8	78.6	10.6
	0.00003125	-	74.5	81.8	71.8	76.2	15.3
TENT [6]	0.001	-	24.3	81.2	64.4	63.4	0.6
	0.00025	-	72.3	82.3	71.0	75.3	3.1
	0.00003125	-	76.7	81.4	71.1	82.7	29.3
SAR [28]	0.001	-	75.2	81.3	70.6	86.0	11.3
	0.00025	-	75.1	81.3	70.6	86.0	31.5
	0.00003125	-	75.0	81.3	70.6	86.0	28.8
RMT [8]	0.001	-	83.0	81.1	76.0	93.1	30.2
	0.00025	-	83.1	81.9	75.3	95.9	28.6
	0.00003125	-	81.5	83.3	74.5	93.1	30.5
EATA [10]	0.001	0.60	-	82.6	70.1	80.4	-
	0.001	0.40	76.3	82.9	70.6	80.4	-
	0.001	0.10	-	82.4	70.6	86.0	-
	0.001	0.05	-	82.4	70.6	86.0	27.3
	0.00025	0.60	-	82.4	70.5	85.6	-
	0.00025	0.40	78.2	82.6	70.6	86.1	-
	0.00025	0.10	-	82.4	70.6	86.0	-
	0.00025	0.05	-	82.4	70.7	86.0	31.7
	0.00003125	0.60	-	82.4	70.6	86.1	-
	0.00003125	0.40	76.5	82.4	70.6	86.0	-
	0.00003125	0.10	-	82.4	70.6	86.0	-
	0.00003125	0.05	-	82.4	70.6	86.0	31.6

A.3 基准

A.3.1 CIFAR10C 与 ImageNet-C 基准详情

CIFAR10C 和 ImageNet-C 是测试时自适应中广泛使用的数据集。它们涉及在干净的 CIFAR10/ImageNet 数据集 [7, 15] 的训练划分上训练源模型，并在 CIFAR10C/ImageNet-C 上进行测试时自适应。CIFAR10C 和 ImageNet-C 由来自干净数据集的图像组成，这些图像经过 15 种类型的损坏和 5 个严重程度级别 [11] 的修改。它们最初用于评估神经网络模型的鲁棒性，现在被广泛用于测试测试时自适应方法的适应能力。我们在最高损坏严重程度级别 5 的标准序列上测试自适应，该序列被先前的方法 [8, 22, 35] 频繁使用。对于 ImageNet-C，我们基于 RobustBench 库 [6]，遵循 [35]，为每种损坏利用 5000 个样本的子集。

A.3.2 CIFAR10.1 基准详情

CIFAR10.1 [2]旨在最小化相对于原始 CIFAR10 数据集 [15] 的分布偏移。它包含大约 2000 张测试图像。CIFAR10.1 中的图像是 TinyImages 数据集 [31] 的子集。用于在该基准上测试的源模型是在原始 CIFAR10 数据集上预训练的。

A.3.3 CLAD-C 基准详情

CLAD-C [3]是一个面向自动驾驶的在线分类基准，旨在为持续学习引入更贴近现实的测试环境。该基准利用 SODA10M 数据集 [10] 的数据，构建了自然、时间相关且连续的分布偏移。图像按时间顺序排列，拍摄于不同地点、时段和天气条件下，从而在标签和域层面引入分布偏移。分类任务通过裁剪六类目标的标注二维边界框，并将其作为独立图像用于分类而构建。像素数少于 1024 的边界框被丢弃。图像按最短边进行填充（将宽高比调整为 1:1），并缩放至 32×32 。对于 ResNet50 模型，我们进一步将其缩放至 224×224 。由于该基准专为测试持续学习设置而设计，且模型原本应在训练序列上顺序训练，我们对设置稍作修改，在第一个训练序列上预训练源模型。TTA 在其余 5 个序列上持续测试，图像总数为 17092 张。

A.3.4 SHIFT-C 基准详情

SHIFT-C 基准基于 SHIFT 数据集 [29] 构建。它包含来自 CARLA 模拟器 [9] 的多种自动驾驶数据类型。我们使用车辆前视 RGB 图像，具有离散域偏移和边界框标注。具体而言，我们使用 SHIFT 网站 <https://www.vis.xyz/shift/> 提供的脚本下载所需数据，命令如下：

```
python 下载 . py --view " 前端
--group det_2d]" \ " \ " [ 图像 ,
--split "[ train ,验证]" \ " 图像" \
--framerate
--shift "discrete" TARGET_DIR
```

为加载实验数据，我们使用了 shift-dev 仓库：https://github.com/SysCV/shift-dev。我们按照 CLAD-C[32] 基准的步骤创建图像分类任务数据。数据集中的边界框分为六类，生成的图像也相应分为六类。示例图像如图 A.3 所示。类别分布如图 A.4 所示。我们根据时段和天气的标注来区分域。源模型在训练集上训练，图像拍摄于白天晴朗天气。TTA 同样在训练集数据上测试，但来自不同天气条件和时段。各域大小的详细信息见表 A.5。



图 A.3: 来自 SHIFT-C 基准中各个领域的示例图像。

表 A.5: SHIFT-C 基准中每个领域的样本数量

Domain nr	Time of day	Weather	Number of images
Source data		clean	57039
1	daytime	cloudy	41253
2		overcast	20497
3		rainy	59457
4		foggy	38590
5	dawn/dusk	clear	29543
6		cloudy	19985
7		overcast	9901
8		rainy	26677
9		foggy	20258
10	night	clear	28639
11		cloudy	18068
12		overcast	9471
13		rainy	32864
14		foggy	25464
Sum			437706




Figure A.4: SHIFT-C benchmark class distribution.

A.4 附加结果

我们分别在 CIFAR10C、ImageNet-C、CIFAR10.1 和 SHIFT-C 基准上展示了批量准确率图，如图 A.5、A.6、A.7、A.8 所示。此外，CIFAR10C 上的完整结果见表 A.6。




图 A.5：在 CIFAR10C 基准上，所选方法持续适应数据序列时，以 400 个批次为窗口平均的批量分类准确率（%）。x 轴上的主刻度表示下一个序列的开始，同时也表示不同的领域。x 轴上的次刻度（数字）表示图像编号。建议彩色查看。




图 A.6: 在 ImageNet-C 基准上, 所选方法持续适应数据序列时, 以 400 个批次为窗口平均的批量分类准确率 (%)。x 轴上的主刻度表示下一个序列的开始, 同时也表示不同的领域。x 轴上的次刻度 (数字) 表示图像编号。建议彩色查看。




图 A.7: 在 CIFAR10.1 基准上, 所选方法持续适应数据序列时, 以 400 批次为窗口平均的逐批次分类准确率 (%)。建议彩色查看。




图 A.8: 在 SHIFT-C 基准上, 所选方法持续适应数据序列时, 以 500 批次为窗口平均的逐批次分类准确率 (%)。x 轴上的主刻度表示下一个序列的开始, 同时也表示不同的域。x 轴上的次刻度 (数字) 表示图像编号。建议彩色查看。

表 A.6: 标准 CIFAR10C 在线持续测试时自适应任务的分类准确率 (%)。

Method	$t \rightarrow$															Mean
	Gaussian	shot	impulse	defocus	glass	motion	zoom	snow	frost	fog	brightness	contrast	elastic_trans	pixelate	jpeg	
Source	27.7	34.3	27.1	53.1	45.7	65.2	58.0	74.9	58.7	74.0	90.7	53.3	73.4	41.6	69.7	56.5
BN-1	67.3	69.4	59.7	82.7	60.4	81.4	83.0	78.1	77.7	80.6	87.3	83.4	71.4	75.3	67.9	75.0
TENT 	67.9	71.4	62.5	83.2	62.9	82.1	83.8	79.5	79.7	81.4	87.8	84.3	73.5	78.2	71.6	76.7
EATA 	70.3	74.9	67.1	83.0	65.6	82.3	84.0	80.3	81.4	82.2	88.0	85.1	74.7	80.1	73.8	78.2
CoTTA 	72.5	76.4	70.5	80.6	66.6	78.3	80.1	75.8	77.0	77.1	83.8	77.3	72.0	75.5	72.2	75.7
SAR 	67.4	69.6	60.8	82.6	61.4	81.5	82.8	78.1	77.7	80.5	87.4	83.4	71.5	75.2	68.2	75.2
RMT w/o replay 	73.2	77.5	72.1	79.6	69.8	78.2	79.7	76.9	78.0	79.9	83.0	81.6	76.5	80.4	77.3	77.6
RMT 	74.8	78.6	74.8	85.5	73.1	84.7	86.1	84.2	85.4	87.2	90.1	89.1	82.2	87.1	83.2	83.1
AR-TTA (Ours) w/o replay	69.5	73.6	63.3	83.5	63.0	82.5	84.5	80.2	80.4	81.9	88.4	83.8	74.2	76.9	74.5	77.3 ± 0.07
AR-TTA (Ours)	69.2	74.8	66.4	84.5	67.8	83.7	85.2	81.4	82.7	83.4	88.0	84.7	73.9	78.6	77.0	78.8 ± 0.13