

Atlas：在测试时学习最优记忆上下文

Ali Behrouz, Zeman Li, Praneeth Kacham, Majid Daliri, Yuan Deng, Peilin Zhong,

迈萨姆·拉扎维雅因 (Meisam Razaviyayn), 瓦哈布·米尔罗克尼 (Vahab Mirrokni)

Google Research

摘要

变换器 (Transformer) 已成为序列建模中最主流的骨干架构, 主要归功于其在上下文检索任务中的有效性以及大规模学习的能力。然而, 其二次方的内存和时间复杂度限制了其在更长序列上的适用性, 这促使研究者探索有效的替代架构, 例如现代循环神经网络 (又称长期循环记忆模块)。尽管这些模型近期在多种下游任务中取得了成功, 但在需要长上下文理解和向更长序列外推的任务中仍表现不佳。我们观察到, 这些不足源于其设计中的三个独立方面: (1) 记忆容量有限, 受限于记忆架构和输入特征映射; (2) 更新的在线特性, 即仅根据最后一个输入优化记忆; (3) 对固定大小记忆的管理表达能力不足。为了增强这三个方面, 我们提出了 Atlas, 一种高容量的长期记忆模块, 它通过基于当前和过去词元优化记忆来学习记忆上下文, 从而克服了长期记忆模型的在线特性。基于这一洞见, 我们提出了一类新的类变换器架构, 称为 DeepTransformers, 它们是原始变换器架构的严格推广。我们在语言建模、常识推理、召回密集型 and 长上下文理解任务上的实验结果表明, Atlas 超越了变换器和近期线性循环模型的性能。Atlas 进一步提升了 Titans 的长上下文性能, 在 BABILong 基准的 1000 万上下文长度上实现了 +80% 的准确率提升。

1 引言

注意力模块 (Attention Module) (Bahdanau 等人, 2014) 是现代深度学习架构中的关键构建块 (Achiam 等人, 2023; Behrouz, Zhong 等人, 2024; Kamath 等人, 2025; Vaswani 等人, 2017), 因其在上下文检索任务中的可扩展性和性能而表现出色。原则上, 注意力作为一种联想记忆, 计算直接的成对标记依赖关系以存储键值映射, 并通过查询-键相似性进行检索。然而, 计算这种成对依赖关系虽然准确, 却会导致二次方的空间和时间复杂度, 限制了它们在长上下文理解、记忆或建模中的应用 (Dalal 等人, 2025; Li, Huang 等人, 2024; Liu, Lin 等人, 2024)。

最近的研究工作旨在通过设计更高效且有效的循环神经网络 (Recurrent Neural Network) 来克服变换器 (Transformer) ——即纯注意力架构——在长上下文建模中的局限性 (Behrouz, Zhong 等人, 2024; Peng, Zhang 等人, 2025; Schlag 等人, 2021)。这些现代循环架构可以统一为联想记忆模块, 优化一个称为“注意力偏差” (attentional bias) 的内部目标 (Behrouz, Razaviyayn 等人, 2025)。与变换器不断增长的键值缓存不同, 这些模型使用固定大小的记忆, 因此需要改进记忆管理。因此, 人们越来越关注通过更有效的方式增强循环神经网络的记忆管理: (i) 学习规则, 从加法学习 (Katharopoulos 等人, 2020) 到 DeltaNet 的 Delta 规则 (Schlag 等人, 2021); (ii) 遗忘 (保留) 门, 从 RetNet 的输入无关门控 (Sun, Dong 等人, 2023) 到 Titans (Behrouz, Zhong 等人, 2024) 和 RWKV-7 (Peng, Zhang 等人, 2025) 中的自适应门控; 以及 (iii) 记忆架构, 从向量值记忆 (Peng, Alcaide 等人, 2023; Sun, Dong 等人, 2023) 到神经深度记忆模块 (Behrouz, Zhong 等人, 2024; Sun, Li 等人, 2024)。

尽管这些改进模型在各种下游基准测试中取得了成功, 但它们通常在长上下文理解、上下文检索以及外推到更长序列方面存在困难 (Arora, Eyuboglu, Zhang 等人, 2024;

*{alibehrouz, zemanli, pkacham, dengyuan, peilinz, razaviyayn, mirrokni}@google.com, 以及 majiddl.2099@gmail.com

表 1: 近期现代循环神经网络综述。我们基于五个特征对这些架构进行比较: (1) 动态衰减; (2) 深度神经记忆; (3) 非线性记忆容量; (4) 局部最优: 通过 (近似) 关于词元的二阶信息来管理记忆; (5) 灵活上下文: 灵活记忆上下文的能力. $\phi(\cdot)$ 和 $\phi^*(\cdot)$ 表示多项式与无限维特征映射 (见方程 22)。

Model	Attentional Bias $\ell(\cdot; \cdot)$	Optimizer	Dynamic Decay	Deep Memory	Non-linear Capacity [†]	Locally Optimal	Flexible Context	Memory Write Operation
Attention	$\sum_{t=1}^L a_t \ \mathcal{M}\mathbf{k}_t - \mathbf{v}_t\ _2^2$	NP [‡]	✗	✗	✓	✓	✗	$\mathcal{M}_t = \mathcal{M}_{t-1} \cup \{(\mathbf{k}_t, \mathbf{v}_t)\}$
SWA	$\sum_{t=c}^L a_t \ \mathcal{M}\mathbf{k}_t - \mathbf{v}_t\ _2^2$	NP	✗	✗	✓	✓	✓	$\mathcal{M}_t = (\mathcal{M}_{t-1} \setminus \{(\mathbf{k}_c, \mathbf{v}_c)\}) \cup \{(\mathbf{k}_t, \mathbf{v}_t)\}$
Linear Attention	$\langle \mathcal{M}_t \mathbf{k}_t, \mathbf{v}_t \rangle$	GD	✗	✗	✗	✗	✗	$\mathcal{M}_t = \mathcal{M}_{t-1} + \mathbf{v}_t \mathbf{k}_t^\top$
RetNet	$\langle \mathcal{M}_t \mathbf{k}_t, \mathbf{v}_t \rangle$	GD	✗	✗	✗	✗	✗	$\mathcal{M}_t = \alpha \mathcal{M}_{t-1} + \mathbf{v}_t \mathbf{k}_t^\top$
GLA	$\langle \mathcal{M}_t \mathbf{k}_t, \mathbf{v}_t \rangle$	GD	✓	✗	✗	✗	✗	$\mathcal{M}_t = \text{Diag}(\alpha_t) \mathcal{M}_{t-1} + \mathbf{v}_t \mathbf{k}_t^\top$
PolySketchFor.	$\langle \mathcal{M}_t \mathbf{k}_t^p, \mathbf{v}_t \rangle$	GD	✗	✗	✓	✗	✗	$\mathcal{M}_t = \mathcal{M}_{t-1} + \mathbf{v}_t (\mathbf{k}_t^\top)^p$
TTT	$\ \mathcal{M}_t(\mathbf{k}_t) - \mathbf{v}_t\ _2^2$	GD	✗	✓	✗	✗	✗	$\mathcal{M}_t = \mathcal{M}_{t-1} - \eta_t \nabla \ell(\mathcal{M}_{t-1}; \mathbf{k}_t, \mathbf{v}_t)$
DeltaNet	$\ \mathcal{M}_t \mathbf{k}_t - \mathbf{v}_t\ _2^2$	GD	✗	✗	✗	✗	✗	$\mathcal{M}_t = (1 - \beta_t \mathbf{k}_t \mathbf{k}_t^\top) \mathcal{M}_{t-1} + \beta_t \mathbf{v}_t \mathbf{k}_t^\top$
Longhorn	$\ \mathcal{M}_t \mathbf{k}_t - \mathbf{v}_t\ _2^2$	Implicit GD	✗	✗	✗	✗	✗	$\mathcal{M}_t = (1 - \delta_t \mathbf{k}_t \mathbf{k}_t^\top) \mathcal{M}_{t-1} + (\delta_t \odot \mathbf{v}_t) \mathbf{k}_t^\top$ §
Gated DeltaNet	$\ \mathcal{M}_t \mathbf{k}_t - \mathbf{v}_t\ _2^2$	GD	✓	✗	✗	✗	✗	$\mathcal{M}_t = \alpha_t (1 - \beta_t \mathbf{k}_t \mathbf{k}_t^\top) \mathcal{M}_{t-1} + \beta_t \mathbf{v}_t \mathbf{k}_t^\top$
RWKV-7	$\ \mathcal{M}_t \mathbf{k}_t - \mathbf{v}_t\ _2^2$	GD	✓	✗	✗	✗	✗	$\mathcal{M}_t = (\text{diag}(\alpha_t) - \beta_t \mathbf{k}_t \mathbf{k}_t^\top) \mathcal{M}_{t-1} + \beta_t \mathbf{v}_t \mathbf{k}_t^\top$
Titans	$\ \mathcal{M}_t(\mathbf{k}_t) - \mathbf{v}_t\ _2^2$	GD w/ M.*	✓	✓	✗	✗	✗	$\mathcal{M}_t = \alpha_t \mathcal{M}_{t-1} + S_t$ $S_t = \eta_t S_{t-1} - \theta_t \nabla \ell(\mathcal{M}_{t-1}; \mathbf{k}_t, \mathbf{v}_t)$
Titans-	$\ \mathcal{M}_t(\mathbf{k}_t) - \mathbf{v}_t\ _2^2$	GD	✓	✓	✗	✗	✗	$\mathcal{M}_t = \alpha_t \mathcal{M}_{t-1} - \eta_t \nabla \ell(\mathcal{M}_{t-1}; \mathbf{k}_t, \mathbf{v}_t)$
MONETA	$\ \mathcal{M}_t(\mathbf{k}_t) - \mathbf{v}_t\ _p^p$	GD	✓	✓	✓	✗	✗	$\mathcal{M}_t = \alpha_t \mathcal{M}_{t-1} - \eta_t \nabla \ell(\mathcal{M}_{t-1}; \mathbf{k}_t, \mathbf{v}_t)$
MEMORA	$\ \mathcal{M}_t(\mathbf{k}_t) - \mathbf{v}_t\ _2^2$	GD	✓	✓	✗	✗	✗	$\mathcal{M}_t = \sigma(\alpha_t \log(\mathcal{M}_{t-1}) - \eta_t \nabla \ell(\mathcal{M}_{t-1}; \mathbf{k}_t, \mathbf{v}_t))$
Our Models								
DLA	$\langle \mathcal{M}_t(\phi(\mathbf{k}_t)), \mathbf{v}_t \rangle$	GD	✓	✓	✗	✗	✗	$\mathcal{M}_t = \alpha_t \mathcal{M}_{t-1} - \eta_t \nabla \ell(\mathcal{M}_{t-1}; \mathbf{k}_t, \mathbf{v}_t)$
DeepTransformer*	$\langle \mathcal{M}_t(\phi^*(\mathbf{k}_t)), \mathbf{v}_t \rangle$	GD	✓	✓	✓	✗	✗	$\mathcal{M}_t = \alpha_t \mathcal{M}_{t-1} - \eta_t \nabla \ell(\mathcal{M}_{t-1}; \mathbf{k}_t, \mathbf{v}_t)$
SWDT	$\sum_{i=c}^L \langle \mathcal{M}_t(\phi^*(\mathbf{k}_i)), \mathbf{v}_i \rangle$	GD	✓	✓	✓	✗	✓	$\mathcal{M}_t = \alpha_t \mathcal{M}_{t-1} - \eta_t \nabla \ell(\mathcal{M}_{t-1}; \mathbf{k}_t, \mathbf{v}_t)$
OmegaNet	$\sum_{i=c}^L \gamma_i \ \mathcal{M}_t(\phi(\mathbf{k}_i)) - \mathbf{v}_i\ _2^2$	GD	✓	✓	✓	✗	✓	$\mathcal{M}_t = \alpha_t \mathcal{M}_{t-1} - \eta_t \nabla \ell(\mathcal{M}_{t-1}; \mathbf{k}_t, \mathbf{v}_t)$
DOT*	$\sum_{i=c}^L \gamma_i \ \mathcal{M}_t(\phi^*(\mathbf{k}_i)) - \mathbf{v}_i\ _2^2$	GD	✓	✓	✓	✗	✓	$\mathcal{M}_t = \alpha_t \mathcal{M}_{t-1} - \eta_t \nabla \ell(\mathcal{M}_{t-1}; \mathbf{k}_t, \mathbf{v}_t)$
ATLAS	$\sum_{i=c}^L \gamma_i \ \mathcal{M}_t(\phi(\mathbf{k}_i)) - \mathbf{v}_i\ _2^2$	Muon	✓	✓	✓	✓	✓	$\mathcal{M}_t = \alpha_t \mathcal{M}_{t-1} - \eta_t \text{NS-5}(S_t)$ $S_t = \theta_t S_{t-1} - \nabla \ell(\mathcal{M}_{t-1}; \mathbf{k}_t, \mathbf{v}_t)$ *

† 考虑矩阵值记忆版本。‡ NP: 非参数 § $\delta_t = \beta_t \frac{1}{1 + \beta_t \mathbf{k}_t^\top \mathbf{k}_t}$ · *Gradient 带动量下降。*Without 归一化。

Behrouz, Zhong 等人 2024; Wen 等人 2024; Yang, Kautz 等人 2024)。我们观察到这些不足源于三个设计方面: (1) 其记忆更新的在线特性, 即记忆基于当前词元进行优化, 同时保留过去的记忆状态, 导致记忆单个词元而不考虑更广泛的上下文;

(2) 记忆容量有限, 其中架构和键值特征映射限制了可完美映射的键值对数量; 以及 (3) 记忆管理的表达性 (即内部目标的优化器), 因为大多数近期模型使用依赖词元动态一阶信息的梯度下降, 导致记忆收敛到虚假的局部极小值, 并学习到效果较差的键值映射。

记忆视角

联想记忆——将不同实体或事件关联起来的能力——是人类学习中不可分割的组成部分 (Terry 2017), 因此推动了近期多项研究, 旨在通过这一视角理解最先进的深度学习架构 (Behrouz, Razaviyayn, et al. 2025; Behrouz, Zhong, et al. 2024; Ramsauer et al. 2021; Wang et al. 2025)。在这一视角下, 记忆被定义为由输入引起的神经更新; 输入越令人惊讶, 对记忆的影响就越大, 因而越容易被记住。因此, 寻找有效的“惊讶度量”是设计此类记忆模块的关键步骤。正如 Behrouz, Razaviyayn, et al. (2025) 和 Behrouz, Zhong, et al. (2024) 先前所讨论的, 几乎所有现有架构都使用一种基于当前输入更新记忆的惊讶度量。然而, 一个事件 (作为标记序列) 尽管令人难忘, 但在长时间内可能并不会持续令人惊讶。为克服这一问题, Behrouz, Zhong, et al. (2024) 建议将惊讶度量分解为“瞬时”和“过去”两部分, 在根据当前输入更新记忆时纳入过去输入的累积惊讶。然而, 这种设计可能因记忆单个标记而丢失上下文。为此, 本文提出一种长期神经记忆模块, 该模块度量局部 (或全局) 上下文窗口的惊讶程度, 意味着它学习如何在测试时记忆 (标记) 上下文。

本文通篇采用“测试时记忆” (Test Time Memorization) 这一术语, 因为该过程涉及存储与检索。

在全局上下文中严格形成，不更新模型核心学习参数（即外循环）或预训练的初始状态。通常，一旦记忆被清除，不会有持久学习或技能习得延续到新的独立全局上下文。因此，我们倾向于使用“测试时记忆”而非“测试时训练”。

贡献

本文旨在克服上述局限性，即（1）在线特性，（2）有限的内存容量，以及

（3）表达力较弱的内存管理——通过设计一种具有高容量且能记忆上下文（而非词元）的长期神经记忆模块。我们进一步基于这些洞见，提出了一系列严格更强大的变换器（Transformer）。具体而言：

深入理解记忆容量及其瓶颈。为改善有限的记忆容量，本文建议对输入令牌使用高阶特征映射（例如多项式特征核函数）。本文提供了理论依据，说明为何更深的记忆模块和/或高阶特征映射能够增强记忆容量——即记忆能够完美映射的线性无关键值关联的最大数量。

新颖的表达性学习规则。为克服近期循环模型的在线特性，本文提出一种滑动窗口更新规则，称为欧米伽规则，该规则基于给定上下文窗口内的所有历史令牌来优化和更新记忆，而不仅仅是最后一个令牌。这使得模型能够更好地管理其固定大小的记忆，并记忆局部上下文而非单个令牌。

变换器的严格泛化。接下来，本文展示欧米伽规则公式如何与全局和局部 Softmax 注意力（即滑动窗口注意力——SWA）相关联，并提出一类新的类变换器架构，称为深度变换器及其滑动窗口变体 SWDT，它们严格泛化了变换器（Vaswani 等人，2017）。本文进一步提出深度线性注意力的新颖基线，以展示深度记忆的作用。

具有更优记忆管理的新记忆模块。基于上述改进，本文提出欧米伽网络，一种在键和查询上使用多项式特征的新架构，同时基于欧米伽规则和梯度下降更新其记忆。为进一步增强记忆管理，本文引入阿特拉斯，它利用流行的 Muon 优化器（Jordan 等人，2024）来更新内部记忆。本文表明，欧米伽网络和阿特拉斯都能利用可并行化的训练算法，与在线版本（即上下文窗口 = 1）相比，训练速度快且无显著额外开销。据本文所知，阿特拉斯是首个利用二阶信息（近似）优化记忆（即具有局部最优记忆模块）的可并行化循环架构。

在多样化下游任务上的改进。大量实验验证了本文的模型设计与所提技术，包括对现代架构的消融研究。我们在语言建模、常识推理、召回密集型以及大海捞针任务等多个基准上评估了深度变换器（DeepTransformers）、欧米伽网络（OmegaNet）和阿特拉斯（Atlas），它们在上述任务中均优于现代线性循环神经网络、局部注意力（滑动窗口注意力，SWA）以及变换器（Transformers）。此外，我们研究了记忆架构、特征映射、记忆管理算法（内部优化器）以及欧米伽规则对长上下文理解任务中记忆模块容量与性能的影响。

证明、补充实验结果、相关工作讨论以及实验细节见附录。

2 预备知识

本节首先介绍全文使用的符号表示，然后回顾背景概念与相关工作。相关研究的补充讨论见附录 A。

符号表示。设 $x \in \mathbb{R}^{N \times d_{\text{in}}}$ 为输入， M_t 为时刻 t 时记忆 M 的状态， K 为键矩阵， V 为值矩阵， Q 为查询矩阵。使用带下标 t 的粗体小写字母表示对应于时刻 t 的向量（i.e., k_t, v_t ，以及 q_t ）。遵循 Behrouz、Razaviyayn 等人（2025）的记号，使用 $\ell(M_t; k_t, v_t)$ 表示注意力偏置（即内部记忆目标）。全文使用具有 $\mathcal{L}_M \geq 1$ 层及残差连接的简单多层感知机（MLP）作为记忆模块 $M(\cdot)$ 的架构。值得注意的是，尽管采用此选择，本文所有模型公式均可简单适配其他记忆架构选择；例如，线性矩阵值记忆（ $\mathcal{L}_M = 1$ ）。在需要时，我们

用 $\theta_M := \{W_1, \dots, W_{L_M}, \dots\}$ 参数化记忆模块，其中至少包含多层感知机中线性层的参数。

2.1 背景

注意力。注意力是变换器（Transformer）的关键组成部分，充当其联想记忆（Behrouz, Razaviyayn, et al. 2025; Bietti et al. 2023; Sun, Li, et al. 2024）。给定输入 $x \in \mathbb{R}^{N \times d_{in}}$ ，因果注意力基于输入相关的键、值和查询矩阵 $Q = xW_Q$, $K = xW_K$, 和 $V = xW_V$ 计算输出 $y \in \mathbb{R}^{N \times d_{in}}$ ，如下所示：

$$y_i = \sum_{j=1}^i \frac{\exp(q_i^\top k_j / \sqrt{d_{in}}) v_j}{\sum_{\ell=1}^i \exp(q_i^\top k_\ell / \sqrt{d_{in}})} = \frac{1}{Z_i} \sum_{j=1}^i \exp(q_i^\top k_j / \sqrt{d_{in}}) v_j, \quad (1)$$

其中 W_Q, W_K 和 $W_V \in \mathbb{R}^{d_{in} \times d_{in}}$ 是可学习参数， $Z_i = \sum_{\ell=1}^i \exp(q_i^\top k_\ell / \sqrt{d_{in}})$ 是归一化项。尽管变换器具有简单的可并行化训练和在召回密集型任务中的有效性（Arora, Eyuboglu, Zhang, et al. 2024），但其生成过程和长上下文扩展是显著缺点，因为注意力每个标记至少需要 $N \times d$ 次操作来计算输出（见方程 1）。因此，近年来，设计替代架构的研究工作十分广泛。我们将这些研究分为两组进行回顾：（1）线性浅层记忆循环模型，（2）深层记忆模块：

（线性）循环模型。线性循环神经网络（RNN）最近作为高效的变换器替代方案受到关注，因为它们具有可并行化、线性时间的训练和可比的性能（Peng, Alcaide, et al. 2023; Sun, Dong, et al. 2023）。早期的现代 RNN 变体通常基于赫布（Hebb 2005）或德尔塔（Widrow et al. 1988）学习规则，将数据压缩为向量值或矩阵值记忆（Kacham et al. 2024b; Katharopoulos et al. 2020; Lim et al. 2024; Liu, Wang, et al. 2024; Schlag et al. 2021; Sun, Dong, et al. 2023）。设 $M_t \in \mathbb{R}^{d \times n}$ 为记忆（其中 $n = 1$ 产生向量值记忆）， $k, v \in \mathbb{R}^d$ 为键和值（输入 $x_t \in \mathbb{R}^d$ 的投影）。此类线性 RNN 的一个简单通用公式为：

$$M_t = A_t * M_{t-1} + v_t k_t^\top, \quad (2)$$

其中 $*$ 是任意结合算子， A_t 是数据（不）相关的对角矩阵或低秩加单位矩阵（Yang, Wang, Zhang, et al. 2024）。尽管这些模型具有高效的线性循环特性，但其记忆可能溢出，尤其是在上下文长度增加时。虽然遗忘门最近显著改善了这些架构中的记忆管理（Peng, Zhang, et al. 2025; Sun, Dong, et al. 2023），但其记忆的表达能力仍受限于线性结构。

深层记忆模块。为了克服记忆的有限表达能力并增强循环模型的有效上下文长度，近期研究聚焦于一类具有深度记忆模块的新架构（Behrouz, Razaviyayn, et al. 2025; Behrouz, Zhong, et al. 2024; Irie et al. 2021; Sun, Li, et al. 2024）。这些架构建立在元学习视角之上，其中记忆是一个通过梯度下降（带动量）更新的深度多层感知机架构。最近，Behrouz, Razaviyayn, et al. (2025) 提出了一个框架，将流行的序列模型准确地统一为测试时记忆的实例。也就是说，序列模型是联想记忆模块，旨在通过优化内部记忆目标（称为注意力偏差）来学习给定键和值之间的底层映射。这种优化基于迭代优化算法，如梯度下降。更正式地，联想记忆定义为：

定义 1（Behrouz, Razaviyayn, et al. (2025)）。给定一组键 $K \subseteq \mathbb{R}^{d_k}$ 和值 $V \subseteq \mathbb{R}^{d_v}$ ，联想记忆是一个映射 $M: K \rightarrow V$ 。学习联想记忆基于一个目标 L ，称为注意力偏差，它决定了记忆的类型及其优先级：

$$M^* = \arg \min_M \mathcal{L}(M(K); V). \quad (3)$$

使用迭代算法（例如梯度下降）优化该目标会得到记忆更新规则。因此，序列模型是一个具有两个优化层次的元上下文学习器：




图 1: 学习记忆 (左) 单个标记与 (右) 上下文的比较。

1. 内循环: 优化记忆模块的参数 (即 $\theta_M = \{W_1, W_2, \dots, W_{L_M}, \dots\}$)。在内层优化循环中, 模型的所有其他参数被视为超参数, 固定且不进行优化。
2. 外循环: 优化模型的所有其他参数, 例如线性投影、多层感知机层、卷积等。

我们的术语建立在此框架之上。因此, 我们不再使用完整的循环公式, 而是通过以下方式描述模型:

(1) 记忆架构, (2) 内部目标 (即注意力偏差), 以及 (3) 记忆学习算法 (优化器)。在大多数情况下, 模型使用矩阵值记忆并采用在线梯度下降; 为简洁起见, 在此类情形中, 我们仅通过其内部记忆目标来指代架构。更多讨论与示例见附录 B。

3 在测试时学习记忆上下文

长期联想记忆对人类学习至关重要 (Terry 2017), 启发了众多人工神经架构 (Behrouz, Razaviyayn, et al. 2025; Behrouz, Zhong, et al. 2024; He et al. 2024; Hopfield 1982; Krotov and Hopfield 2016; Ramsauer et al. 2021; Schmidhuber and Hochreiter 1997)。虽然许多此类模型使用矩阵或向量值记忆来压缩过去数据 (Schlag et al. 2021; Von Oswald et al. 2023; Yang, Kautz, et al. 2024), 但近期研究提倡使用深度非线性神经记忆, 将过去的抽象编码到其参数中 (Behrouz, Razaviyayn, et al. 2025; Behrouz, Zhong, et al. 2024; Dalal et al. 2025; Sun, Li, et al. 2024)。然而, 对于长上下文推理/理解, 这些长期神经记忆模块仍需满足: (1) 高容量——可存储在参数中的最大 (键, 值) 对数量 (见 § 3.1); (2) 强大的内部记忆目标 (即注意力偏差), 以学习键与值之间的复杂映射 (见 § 3.2); (3) 强大的记忆管理, 以实现更好的固定大小记忆管理 (见 § 3.2); (4) 高效的并行训练过程, 以便在现代加速器上进行大规模训练 (见 § 3.3)。

本节进一步讨论这些挑战, 并提出欧米茄规则: 一种具有表达力的记忆更新规则, 可直接访问局部上下文窗口中的标记, 从而记忆上下文而非单个标记。

3.1 具有超线性容量的联想记忆

如前所述, 有效的长期记忆模块应在其参数中存储过去数据的抽象。然而, 在记忆参数数量固定的情况下, 一个关键问题仍未得到解答: “模型最多能存储多少个不相关的 (键, 值) 对?” 为回答此问题, 我们从最简单的情形开始: 矩阵记忆, 以 ℓ_2 回归损失作为注意力偏差 (即 $\ell(\mathcal{M}_t; \mathbf{k}_t, \mathbf{v}_t) = \|\mathcal{M}_t \mathbf{k}_t - \mathbf{v}_t\|_2^2$), 并通过梯度下降进行优化:

命题 1 (ℓ_2 注意力偏差的容量)。设 $\mathcal{M}$ 为具有 $d_v \times d_k$ 个参数的矩阵值记忆, 其通过梯度下降优化内部目标 $\ell(\mathcal{M}_t; \mathbf{k}_t, \mathbf{v}_t) = \|\mathcal{M}_t \mathbf{k}_t - \mathbf{v}_t\|_2^2$ 。 $\mathcal{M}$ 最多可存储 $O(d_k)$ 对具有线性无关的 $(\mathbf{k}_i, \mathbf{v}_i)$ 的映射。

上述命题表明, 采用增量更新规则的矩阵值记忆相对于其参数数量具有次线性容量。这意味着对于某个 $c \in \mathbb{R}^+$, 在大小为 M 的固定大小记忆中可存储的独立模式数量严格小于 $c \times M$ 。近期循环模型建议使用深度记忆模块来

将过去的抽象存储到深度神经网络（Deep Neural Network）的参数中（Behrouz, Razaviyayn, et al. 2025; Behrouz, Zhong, et al. 2024; Irie et al. 2021; Sun, Li, et al. 2024）。虽然这些深度记忆架构在直观上可以增强对键与值之间复杂底层映射模式的表达能力，但它们是否提升了记忆容量仍不清楚。

定理 1（深度记忆的效果）。 设 $M(\cdot)$ 为具有 $\mathcal{L}_M \geq 2$ 层、 d_k 输入维度和 d_h 隐藏维度的多层感知机（MLP）。则 $M(\cdot)$ 至少可存储 $O(d_k d_o)$ 个、至多 $O\left(d_k d_o \sum_{i=1}^{\mathcal{L}_M} \min\{d_h^{(j)}\}_{j \geq i} d_h^{(j+1)}\right)$ 具有线性无关键的 $(\mathbf{k}_i, \mathbf{v}_i)$ 的映射。

该定理表明，深度记忆不仅提升了表示能力，还进一步增强了网络容量，且优势随深度增长。然而，上界在键和值维度上仍为次二次，这引出一个问题：长期记忆模块能否实现超线性容量。

如前所述， d_k 的维度对于提升记忆容量至关重要。然而，单纯增加所有键和值的维度会显著增加参数数量（每个额外维度增加 $O(d_{in})$ ）和内存占用，尤其是在长上下文场景下。为解决这一问题，基于 Kacham 等人（2024a）以及 Krotov 和 Hopfield（2016）的方法，本文建议对键和查询使用可分离核函数 $\sigma(\mathbf{x}, \mathbf{u}) = \phi(\mathbf{x})^\top \phi(\mathbf{u})$ 。作为此类核函数的一个实例，本文聚焦于次数至多为 p 的多项式核函数，以提升输入维度，从而增强网络容量。给定 $p \in \mathbb{N}$ ，令 $\phi_p(\mathbf{x}) = [x^\beta]_{|\beta| \leq p}$ 为 $\mathbf{x}$ 的次数至多为 p 的多项式映射。本文通过将定义 1 中 $\mathcal{L}(M(\mathcal{K}); \mathcal{V})$ 的内部目标替换为 $\mathcal{L}(M(\phi(\mathcal{K})); \mathcal{V})$ ，重新定义了联想记忆模块。该多项式映射通过在不增加输入投影参数开销的情况下提升键的有效维度，增强了表示能力。接下来，本文讨论它们对记忆容量的影响，即使仅使用单个矩阵值记忆：

命题 2（多项式映射下的记忆容量）。 令 $\phi_p(\cdot)$ 为次数至多为 p 的多项式映射， M 为通过梯度下降优化 $\ell(M_t; \phi_p(\mathbf{k}_t), \mathbf{v}_t) = \|\mathbf{M}_t \phi_p(\mathbf{k}_t) - \mathbf{v}_t\|_2^2$ 内部目标的矩阵值记忆。 M 最多能够存储 $O(d_k^p)$ 对具有线性无关键的 $(\mathbf{k}_i, \mathbf{v}_i)$ 映射，其中 d_k 为键 $\mathbf{k}_i$ 的维度。

除上述直觉外，多项式核函数还受到两个视角的进一步推动：（1）利用泰勒级数近似 Softmax 函数；（2）输入特征门控。为清晰起见，本文继续使用线性记忆和两种常见的

注意力偏差，即 $\ell^{(1)}(M_t; \mathbf{k}_t, \mathbf{v}_t) = \langle M_t \mathbf{k}_t, \mathbf{v}_t \rangle$ 和 $\ell^{(2)}(M_t; \mathbf{k}_t, \mathbf{v}_t) = \|\mathbf{M}_t \phi(\mathbf{k}_t) - \mathbf{v}_t\|_2^2$

。相同的过程可应用于其他注意力目标和深度记忆模块。在内循环中使用梯度下降优化这些目标，可得到以下循环公式：

$$\ell^{(1)}(M_t; \mathbf{k}_t, \mathbf{v}_t) : \mathbf{M}_t = \mathbf{M}_{t-1} + \eta_t \mathbf{v}_t \phi(\mathbf{k}_t)^\top, \quad (\text{Hebbian Rule})$$

$$\ell^{(2)}(M_t; \mathbf{k}_t, \mathbf{v}_t) : \mathbf{M}_t = (\mathbf{I} - \eta_t \phi(\mathbf{k}_t) \phi(\mathbf{k}_t)^\top) \mathbf{M}_{t-1} + \eta_t \mathbf{v}_t \phi(\mathbf{k}_t)^\top. \quad (\text{Delta Rule})$$

赫布规则特例的核注意力视角。（赫布规则）的公式等价于核线性注意力（Arora, Eyuboglu, Zhang, et al. 2024; Hua et al. 2022; Kacham et al. 2024b; Kasai et al. 2021; Katharopoulos et al. 2020; Wang et al. 2025）。在此视角下， $\phi(\cdot)$ 的作用是近似 Softmax 函数，或更准确地说是指数核函数。由于带归一化的指数核函数（即 Softmax 函数）不可分离，导致变换器（Transformer）的二次时间和内存复杂度。然而，变换器的指数特征映射核函数（ $\exp(\mathbf{q}_i^\top \mathbf{k}_j)$ ）可通过其泰勒级数近似为：

$$\exp(\mathbf{q}_i^\top \mathbf{k}_j) \approx 1 + \mathbf{q}_i^\top \mathbf{k}_j + \frac{(\mathbf{q}_i^\top \mathbf{k}_j)^2}{2!} + \frac{(\mathbf{q}_i^\top \mathbf{k}_j)^3}{3!} + \dots \quad (4)$$

我们的多项式特征映射将此近似推广到更一般的情形：

$$\exp(\mathbf{q}_i^\top \mathbf{k}_j) \approx \phi_p(\mathbf{q}) \phi(\mathbf{k})^\top = a_0 + a_1 \mathbf{q}_i^\top \mathbf{k}_j + a_2 (\mathbf{q}_i^\top \mathbf{k}_j)^2 + a_3 (\mathbf{q}_i^\top \mathbf{k}_j)^3 + \dots + a_p (\mathbf{q}_i^\top \mathbf{k}_j)^p, \quad (5)$$

具有可学习参数 $a_i \in \mathbb{R}$ ，初始化为 $a_i = \frac{1}{i!}$ ，多项式核函数可视为 Softmax 注意力的表达性近似器。这为使用多项式核函数提供了理论动机，尤其是在记忆容量受限时；即具有（i）线性记忆和（ii）赫布学习规则。然而，这一直觉进一步推广到使用深度记忆模块和更复杂注意力偏差（即 Delta 规则方程）的更具表达力的情形。也就是说， $\exp(\cdot)$ 特征映射具有无限维度，并提供键与查询之间更强大的相似性测度（即 $\mathbf{q}_i^\top \mathbf{k}_j$ ）；

然而，其归一化计算会给模型带来额外的记忆和时间复杂度。在具有深度记忆和复杂注意力偏差的架构中使用多项式核函数，可以通过近似键-查询相似性的更强大表示来进一步提升性能（即 $\mathbf{q}^\top$ ）。更多 $\mathbf{k}_j$ 讨论见第 4 节关于指数核函数与变换器的讨论。

输入门控解释。另一个促使使用多项式特征的视角是，与 $\phi(x) = x$ 的简单情形相比，它们在建模复杂函数时具有更强的表示能力。也就是说， a_i 的系数可视为输入特征门控，其中 $a_i \rightarrow 0$ 表示排除 $[x^i]_{|i|=i}$ 的特征映射， $a_i \rightarrow 1$ 表示保留相应特征。这类似于循环神经网络的门控机制，但作用于输入而非记忆。这种门控机制显然提供了更强的表示能力，因为模型可以学习对所有 $i \neq 1$ 设置 $a_i \rightarrow 0$ ，并设置 $a_1 \rightarrow 1$ ，从而得到 $\phi(x) = x$ 的简单情形。

3.2 具有上下文记忆的长期记忆

如前所述，大多数现有循环模型的一个关键缺陷是其在线特性，即它们仅针对当前输入优化内部目标（注意力偏差），同时保留记忆的先前状态（Behrouz, Razaviyayn, et al. 2025; Liu, Wang, et al. 2024），即

$$\min_{\mathcal{M}} \ell(\mathcal{M}; \mathbf{k}_t, \mathbf{v}_t) + \text{Ret}_t(\mathcal{M}, \mathcal{M}_{t-1}), \quad (6)$$

其中 $\text{Ret}(\cdot, \cdot)$ 为保留门。这种在线特性虽然使记忆的优化更简单、更快速，但由于记忆贪婪地记忆单个标记，可能导致对上下文的次优记忆。然而，在更一般的情况下，可以在每个时间戳针对整个上下文（输入序列）优化记忆，即：

$$\min_{\mathcal{M}} \sum_{i=1}^t \ell(\mathcal{M}; \mathbf{k}_i; \mathbf{v}_i). \quad (7)$$

这种严格的全局公式通常存在两个关键局限性：（1）效率：循环架构的重要优势之一是在训练和推理中对较长上下文的高效性。然而，针对所有过去标记（整个上下文）优化记忆，（i）在每个记忆更新步骤中引入额外的优化约束，导致在极长序列上效率低下；（ii）在测试时需要缓存过去的键和值，增加内存消耗；（2）上下文剪枝：在大上下文任务中，针对所有过去标记进行优化可能导致次优性能，主要原因是输入序列中间的上下文变化（或无关上下文）。这一观察结果促使设计了带有保留（遗忘）门的架构，使模型能够在不再需要过去上下文时擦除记忆（Behrouz, Razaviyayn, et al. 2025; Behrouz, Zhong, et al. 2024; Peng, Zhang, et al. 2025; Sun, Dong, et al. 2023; Yang, Wang, Shen, et al. 2024）。

为了解决这些局限性，本文提出一种滑动窗口循环模型，该模型针对过去标记的窗口优化其注意力偏差。对于记忆模块 $\mathcal{M}(\cdot)$ 和窗口长度 $c \geq 1$ ，我们将记忆内部目标优化为：

$$\min_{\mathcal{M}} \sum_{i=t-c+1}^t \gamma_i^{(t)} \ell(\mathcal{M}; \mathbf{k}_i, \mathbf{v}_i), \quad (8)$$

其中 $\ell(\mathcal{M}; \mathbf{k}_i, \mathbf{v}_i)$ 衡量 $(\mathbf{k}_i, \mathbf{v}_i)$ 对的预测映射， $\gamma_i^{(t)}$ 是第 i 个标记在优化过程中影响的衰减项。基于此公式，本文提出 Omega 规则，该规则严格强于流行的 Delta 学习规则（Schlag et al. 2021; Widrow et al. 1988）：

Omega 规则： 设 $\mathbf{k}_i \in \mathbb{R}^{d_k}$ 和 $\mathbf{v}_i \in \mathbb{R}^{d_v}$ 为输入键和值， $\mathcal{M}(\cdot)$ 为充当记忆模块的神经架构。给定局部上下文长度 $c \in \mathbb{N}_{\geq 1}$ ，使用 Omega 学习规则更新记忆模块 $\mathcal{M}$ 定义为通过梯度下降优化以下损失函数：

$$\min_{\mathcal{M}} \sum_{i=t-c+1}^t \gamma_i^{(t)} \|\mathcal{M}(\mathbf{k}_i) - \mathbf{v}_i\|_2^2 \quad (9)$$




图 2: 不同上下文长度下 SWA 与 Atlas 或 OmegaNet 中标记依赖关系的示意图。

遵循 Behrouz、Razaviyayn 等人 2025 年的工作，该更新规则可通过将 $\ell_2(\cdot)$ 替换为 $\ell_q(\cdot)$ 扩展为 q -Omega 规则（或其他变体）。在极端情形下：(1) $c = 1$ 时，更新规则变为在线形式（Delta 规则）；(2) $c = \infty$ 或上下文长度时，更新变为针对所有历史词元的全局优化。在此公式中，参数 $\gamma_i^{(t)} \in [0, 1]$ 充当历史词元的硬（直接）门控。即 $\gamma_i^{(t)} \rightarrow 0$ 表示模型直接剪枝局部上下文中第 i 个词元的优化，而 $\gamma_i^{(t)} \rightarrow 1$ 表示完全纳入局部上下文中第 i 个词元的记忆优化。在我们的设计中，对 $\gamma_i^{(t)}$ 使用输入依赖参数，从而提供上下文内剪枝能力。注意，滑动窗口循环的设计允许这种灵活性，因为每个词元需要恒定数量的门控；i.e., $\{\gamma_i^{(t)}\}_{i=1}^c$ 。然而，对全局优化（方程 7）使用输入依赖门控会导致参数数量和内存使用显著增加，削弱循环模型的优势。

OmegaNet。 我们现在提出 **OmegaNet**，一种利用 Omega 规则更新记忆的新型序列模型。为增强 **OmegaNet** 的记忆容量，我们对 $\mathbf{k}_s$ 和 $\mathbf{q}_s$ 使用多项式核函数。相应地，优化方程 9 中的目标函数，得到 **OmegaNet** 的更新规则如下：

$$\mathcal{M}_t = \alpha_t \mathcal{M}_{t-1} - \underbrace{\nabla \sum_{i=t-c+1}^t \gamma_i^{(t)} \|\mathcal{M}(\phi(\mathbf{k}_i)) - \mathbf{v}_i\|_2^2}_{\text{上下文的意外性}}, \quad (10)$$

或在线性记忆的特殊情形下：

$$\mathcal{M}_t = \left(\text{diag}(\alpha_t) - \sum_{i=t-c+1}^t \gamma_i^{(t)} \phi(\mathbf{k}_i) \phi(\mathbf{k}_i)^\top \right) \mathcal{M}_{t-1} - \sum_{i=t-c+1}^t \gamma_i^{(t)} \mathbf{v}_i \phi(\mathbf{k}_i)^\top. \quad (11)$$

从记忆角度看，Omega 规则（OmegaNet）度量的不是单个词元的意外性，而是基于上下文中各词元上下文感知组合的局部上下文意外性。

超越梯度下降。 Omega 规则和“测试时上下文记忆”的概念可以简单地扩展到使用任意优化器优化方程 9 中的目标函数，甚至超越简单的梯度下降。我们以 c 的两个极端情形作为示例。在第一种情形中，令 $c = 1, \gamma_i^{(t)} = 1$ ，并使用带动量的梯度下降作为优化器，得到如下更新规则：

$$\mathcal{M}_t = \alpha_t \mathcal{M}_{t-1} + \mathcal{S}_t \quad (12)$$

$$\mathcal{S}_t = \theta_t \mathcal{S}_{t-1} - \eta_t \nabla \ell(\mathcal{M}_{t-1}; \mathbf{k}_t, \mathbf{v}_t). \quad (13)$$

该更新规则等价于泰坦（Titans）中的长期神经记忆（Behrouz, Zhong 等, 2024）。在第二种情况下，使用线性记忆 $\mathcal{M}$ ，令 $\gamma_i^{(t)} = 1$ ，且 c 等于上下文长度，则记忆更新过程等价于优化（正则化）最小二乘问题：

$$\mathcal{M}_t = \min_{\mathcal{M}} \sum_{i=1}^t \|\mathcal{M} \mathbf{k}_i - \mathbf{v}_i\|_2^2. \quad (14)$$

Von Oswald 等 (2023) 建议直接优化上述目标, 并利用谢尔曼-莫里森公式 (Sherman 等, 1950) 递归计算最优解中的逆项。尽管记忆具有最优性, 此类直接解法的代价是训练不可并行化, 且仅限于线性矩阵值记忆设置。此外, 如前所述, 缺乏直接硬门控项 (即 $v_i^{(t)}$ s) 的全局特性可能迫使模型无法剪枝上下文, 从而损害较长序列上的性能。

3.3 并行化欧米伽规则

虽然欧米伽规则为记忆模块的设计提供了比赫布或德尔塔学习规则更通用、更具表达力的公式化描述, 但其在大规模模型中的适用性依赖于训练效率。为此, 我们讨论一种快速可并行化的训练算法, 该算法不会给在线对应版本 (即 $c = 1$) 带来显著的计算开销。朴素实现需要具体化 c 个梯度 $\nabla \ell \in \mathbb{R}^{d_{\text{in}} \times d_{\text{in}}}$, 当 d_{in} 较大时, 这可能导致显著更高的内存占用和输入输出成本。此外, 为充分利用 TPU 和 GPU 等硬件加速器, 将计算张量化并最大化矩阵乘法运算的使用至关重要。受近期工作 (Behrouz, Zhong 等, 2024; Sun, Li 等, 2024) 的启发, 我们提出一种简单的滑动窗口掩码策略, 该策略支持高效的并行训练, 同时避免大量内存开销。具体而言, 我们将长度为 L 的输入序列划分为大小为 $b \geq 1$ 的块, 每个块由 $S_i = \{\mathbf{x}_{(i-1)b+1}, \dots, \mathbf{x}_{ib}\}$ 表示。然后, 对于每个块, 我们计算相对于前一个块最后状态的梯度。为清晰起见, 我们首先假设序列中所有位置的 $v_i^{(t)} = n_t$ 。当块大小为 $b = 1$ 时, 更新规则为:

$$\mathcal{M}_t = \alpha_t \mathcal{M}_{t-1} - \eta_t \sum_{i=t-c+1}^t \nabla \ell(\mathcal{M}_{t-1}; \mathbf{k}_i, \mathbf{v}_i), \quad (15)$$

其中 $\mathcal{M}_t$ 是第 t, α_t 步的模型状态, η_t 分别是权重衰减和学习率参数, $(\mathbf{k}_i, \mathbf{v}_i)$ 表示位置 i 处的输入对。在实践中, 我们通过将序列划分为较小的块, 在完全循环形式和完全并行形式之间取得平衡。在每个块内 (块内), 我们应用并行计算, 而在块之间 (块间), 我们采用循环计算方案。现在定义 $t' = t - \text{mod}(t, b)$ 。即, 对于满足 $t' \leq t < t' + b$ 的时间步 t , 每个块内的更新规则变为:

$$\mathcal{M}_t = \alpha_t \dots \alpha_{t'} \mathcal{M}_{t'} - \sum_{n=t'}^t \underbrace{\frac{\alpha_t \dots \alpha_{t'}}{\alpha_n \dots \alpha_{t'}}}_{G_t} \eta_n \sum_{i=n-c+1}^n \nabla \ell(\mathcal{M}_{t'}; \mathbf{k}_i, \mathbf{v}_i) \quad (16)$$

在我们的实现中, 对于 G_t , 我们遵循与 Titans (Behrouz, Zhong, et al. 2024) 中描述的相同梯度计算方法, 但在广播操作 (例如使用 einsum) 期间额外应用滑动窗口掩码 M_s 。当 $c = 1$ 时, 滑动窗口掩码 M_s 退化为单位矩阵。对于 $c > 1$, M_s 它是一个单位矩阵, 除了每个对角线条目之前的 $c - 1$ 个位置也被设置为 1。这允许来自大小为 c 的窗口的梯度贡献, 从而无需在块内具体化所有梯度即可实现高效计算。

4 深度变换器: 具有深度记忆的变换器

最近的研究通过联想记忆的视角广泛讨论了变换器架构 (Behrouz, Razaviyayn, et al. 2025; Sun, Li, et al. 2024; Wang et al. 2025)。因此, 很自然地会问, 我们关于记忆容量以及欧米伽规则的讨论如何影响变换器。在本节中, 我们讨论欧米伽规则的表述如何与变换器及其滑动窗口对应物 (即 SWA) 相关联。然后, 我们进一步提供变换器的两个扩展, 每个扩展都是变换器的严格泛化。

4.1 记忆的在线和局部上下文优化

与滑动窗口注意力的联系。 Softmax 注意力块也可以重新表述为使用 Nadaraya-Watson 估计器对 $\ell_2(\cdot)$ 回归的非参数解 (Fan 2018; Zhang et al. 2022) :

$$\mathcal{M}^* = \arg \min_{\mathcal{M}} \sum_{i=1}^L \|\mathbf{s}(\mathbf{k}_i, \mathbf{q})\| \mathbf{v}_i - \mathcal{M}\|_2^2 = \sum_{i=1}^L \frac{\mathbf{s}(\mathbf{k}_i, \mathbf{q})}{\sum_{j=1}^L \mathbf{s}(\mathbf{k}_j, \mathbf{q})} \mathbf{v}_i, \quad (17)$$

其中 L 是序列长度。虽然这种表述针对整个序列长度优化记忆 M ，但可以将优化过程限制在过去的 c 个标记上，从而得到：

$$\mathcal{M}^* = \arg \min_{\mathcal{M}} \sum_{i=t-c+1}^t \mathbf{s}(\mathbf{k}_i, \mathbf{q}_i) \|\mathbf{v}_i - \mathcal{M}\|_2^2 = \sum_{i=t-c+1}^t \frac{\mathbf{s}(\mathbf{k}_i, \mathbf{q})}{\sum_{j=t-c+1}^t \mathbf{s}(\mathbf{k}_j, \mathbf{q})} \mathbf{v}_i, \quad (18)$$

这等价于滑动窗口注意力 (Sliding Window Attention, SWA)。这一联系为注意力机制与循环模型之间的差异提供了重要洞见：注意力不仅是一种非参数化解决方案（与循环模型参数化特性相反），而且它全局优化其内部目标（注意力偏差），而大多数现代循环模型则是在线学习器 (Behrouz, Razaviyayn, et al. 2025; Peng, Zhang, et al. 2025; Sun, Li, et al. 2024; Yang, Kautz, et al.

2024)¹ 本文提出的滑动窗口循环神经网络 (RNN) 和欧米伽规则填补了这一空白，通过基于参数化方法针对过去标记的上下文窗口优化记忆，从而有效地记忆上下文而非单个标记。

深度线性注意力。作为一种新颖的基线，本文提出深度（门控）线性注意力 (Deep (Gated) Linear Attention, DLA)，用深度神经网络 (e.g., k 层多层感知机 (MLP) 替换（门控）线性注意力 (Katharopoulos et al. 2020; Yang, Wang, Shen, et al. 2024) 中的矩阵值记忆。如前文 (Hebbian Rule) 所述，使用点积相似度作为内部注意力偏差会导致线性注意力。因此，利用最近的深度记忆模块 (Behrouz, Razaviyayn, et al. 2025; Behrouz, Zhong, et al. 2024; Sun, Li, et al. 2024)，本文使用点积注意力偏差通过梯度下降优化记忆：

$$\mathcal{M}_t = \alpha_t \mathcal{M}_{t-1} - \eta_t \nabla \ell(\mathcal{M}_{t-1}; \phi(\mathbf{k}_t), \mathbf{v}_t), \quad (19)$$

其中 $\ell(\mathcal{M}_{t-1}; \phi(\mathbf{k}_t), \mathbf{v}_t) = \langle \mathcal{M}_{t-1}(\phi(\mathbf{k}_t)), \mathbf{v}_t \rangle$ 且 $\phi(\cdot)$ 是一个多项式核函数。DLA 的训练可以简单地通过线性和非线性分块训练的混合方式进行并行化，与 Behrouz, Zhong, et al. (2024) 和 Sun, Li, et al. (2024) 以及本文第 3.3 节的讨论相同。

滑动窗口线性注意力。基于上述直觉以及本文公式与 SWA 的联系，本文提出滑动窗口线性注意力 (Sliding Window Linear Attention, SWLA) 模块。遵循线性注意力在联想记忆视角下的公式 (Behrouz, Razaviyayn, et al. 2025)，本文使用点积相似度（即 $\ell(\mathcal{M}_t; \mathbf{k}_i, \mathbf{v}_i) = \langle \mathcal{M}_t(\mathbf{k}_i), \mathbf{v}_i \rangle$ ）作为注意力偏差，并通过梯度下降优化损失函数。为清晰起见，本文在此使用线性记忆来推导闭式解：

$$\mathcal{M}_t = \alpha_t \mathcal{M}_{t-1} - \eta_t \nabla \sum_{i=t-c+1}^t \ell(\mathcal{M}_{t-1}; \phi(\mathbf{k}_i), \mathbf{v}_i) = \mathcal{M}_{t-1} + \sum_{i=t-c+1}^t \gamma_i^{(t)} \mathbf{v}_i \phi(\mathbf{k}_i)^\top \quad (20)$$

在在线情况下 ($c = 1$) 且 $\phi(\cdot) = (\cdot)$ ，该递推与线性注意力相同 (Katharopoulos et al. 2020)。

4.2 记忆容量与指数核函数

本文首先回顾变换器 (Transformer) 中 Softmax 注意力的公式（即方程 1）：

$$\mathbf{y}_i = \frac{1}{\sum_{l=1}^i \exp(\mathbf{q}_i^\top \mathbf{k}_l / \sqrt{d_{\text{in}}})} \sum_{j=1}^i \exp(\mathbf{q}_i^\top \mathbf{k}_j / \sqrt{d_{\text{in}}}) \mathbf{v}_j, \quad (21)$$

其指数 ($\exp(\cdot)$) 核函数不可分离，因此无法写成递推形式。根据 Kacham 等人 (2024b) 的讨论，可以将指数核函数（与多项式核函数 $\phi_p(\cdot)$ 相比）视为一种特征映射，将输入映射到

¹ 其中两个例外是 Titans (Behrouz, Zhong 等人, 2024) 和 Mesa-layer (Von Oswald 等人, 2023)。Mesa-layer 针对所有历史令牌优化记忆（代价是训练速度慢），而 Titans 针对所有历史令牌优化记忆，但对每个历史令牌引入隐式衰减项（即动量的结果），从而保持可并行性。

无限维度。即，本文定义：

$$\phi^*(x) = \begin{pmatrix} 1 \\ \frac{x}{\sqrt{1}} \\ \frac{x^{\otimes 2}}{\sqrt{2!}} \\ \frac{x^{\otimes 3}}{\sqrt{3!}} \\ \vdots \end{pmatrix}, \quad \phi_P(x) = x^{\otimes P}, \quad (22)$$

其中 $x^{\otimes p} = x \otimes x^{\otimes (p-1)}$ 是使用克罗内克积（Kronecker product）的“自张量”算子（Kacham 等人，2024b），因此：

$$\exp(\mathbf{q}_t^\top \mathbf{k}_t) = \phi^*(\mathbf{q}_t)^\top \phi^*(\mathbf{k}_t). \quad (23)$$

基于上述核函数，本文将注意力（见方程 21）重新表述为：（为简化起见，移除 $1 / \sqrt{d_{\text{in}}}$ 项）

$$\mathbf{y}_i = \frac{1}{\sum_{t=1}^i \exp(\mathbf{q}_i^\top \mathbf{k}_t / \sqrt{d_{\text{in}}})} \sum_{j=1}^i \mathbf{v}_j \phi^*(\mathbf{k}_j)^\top \phi^*(\mathbf{q}_i) = \frac{1}{\sum_{t=1}^i \exp(\mathbf{q}_i^\top \mathbf{k}_t / \sqrt{d_{\text{in}}})} \left(\sum_{j=1}^i \phi^*(\mathbf{v}_j \mathbf{k}_j)^\top \right) \phi^*(\mathbf{q}_i) = \mathcal{M}_i \phi^*(\mathbf{q}_i), \quad (24)$$

该表述为注意力与（核）循环模型之间的差异提供了另一重要洞见：作为联想记忆的 Softmax 注意力具有无界记忆容量，因此能更好地将较大上下文记忆到其参数中。基于此洞见，本文提出深度变换器（DeepTransformers），在深度线性注意力公式（方程 19）中用 $\phi^*(\cdot)$ 核函数替换多项式核函数，得到未归一化的表述：

$$\mathcal{M}_t = \mathcal{M}_{t-1} - \nabla \langle \mathcal{M}_{t-1}(\phi^*(\mathbf{k}_t)), \mathbf{v}_t \rangle. \quad (25)$$

在线性记忆的特殊情况下，我们可以推导出上述公式的闭式解：

$$\mathcal{M}_t = \mathcal{M}_{t-1} - \nabla \langle \mathcal{M}_{t-1} \phi^*(\mathbf{k}_t), \mathbf{v}_t \rangle = \mathcal{M}_{t-1} + \mathbf{v}_t \phi^*(\mathbf{k}_t)^\top = \sum_{i=1}^t \mathbf{v}_i \phi^*(\mathbf{k}_i)^\top \Rightarrow \mathbf{y}_t = \mathcal{M}_t \phi^*(\mathbf{q}_t) = \sum_{i=1}^t \mathbf{v}_i \exp(\mathbf{q}_i^\top \mathbf{k}_i), \quad (26)$$

这与未归一化的变换器（Transformers）输出一致。因此，深度变换器（DeepTransformers）是采用 Softmax 函数注意力的变换器（Vaswani 等人，2017）的严格泛化。

4.3 深度欧米茄变换器（点积）：采用欧米茄学习规则的变换器

我们上述的深度变换器公式基于赫布规则（Hebbian Rule），该规则同样用于原始变换器。然而，如前所述，在联想记忆模块中使用更强大的记忆管理和学习规则可以进一步提升其性能。为此，我们通过用欧米茄学习规则替换赫布规则来扩展上述公式，得到深度欧米茄变换器（Dot）的未归一化公式：

$$\mathcal{M}_t = \mathcal{M}_{t-1} - \nabla \sum_{i=t-c+1}^t \gamma_i^{(t)} \|\mathcal{M}(\phi^*(\mathbf{k}_i)) - \mathbf{v}_i\|_2^2. \quad (27)$$

我们现在讨论深度欧米茄变换器的特例，以进一步理解其广义公式的直觉。

线性记忆。这种设置产生以下未归一化公式：

$$\mathcal{M}_t = \left(\mathbf{I} - \sum_{i=t-c+1}^t \gamma_i^{(t)} \phi^*(\mathbf{k}_i) \phi^*(\mathbf{k}_i)^\top \right) \mathcal{M}_{t-1} - \sum_{i=t-c+1}^t \gamma_i^{(t)} \mathbf{v}_i \phi^*(\mathbf{k}_i)^\top \quad (28)$$

$$\Rightarrow \mathbf{y}_t = \mathcal{M}_t \phi^*(\mathbf{q}_t) = \left(\mathbf{I} - \sum_{i=t-c+1}^t \gamma_i^{(t)} \phi^*(\mathbf{k}_i) \phi^*(\mathbf{k}_i)^\top \right) \mathcal{M}_{t-1} \phi^*(\mathbf{q}_t) - \sum_{i=t-c+1}^t \gamma_i^{(t)} \mathbf{v}_i \exp(\mathbf{q}_i^\top \mathbf{k}_i). \quad (29)$$

在线情况，其中 $c = 1$ ，我们现在令 $c = 1$ ：

$$\mathcal{M}_t = (\mathbf{I} - \eta_t \phi^*(\mathbf{k}_t) \phi^*(\mathbf{k}_t)^\top) \mathcal{M}_{t-1} - \eta_t \mathbf{v}_t \phi^*(\mathbf{k}_t)^\top \quad (30)$$

$$\Rightarrow \mathbf{y}_t = \mathcal{M}_t \phi^*(\mathbf{q}_t) = (\mathbf{I} - \eta_t \phi^*(\mathbf{k}_t) \exp(\mathbf{q}_t^\top \mathbf{k}_t)) \mathcal{M}_{t-1} - \eta_t \mathbf{v}_t \exp(\mathbf{q}_t^\top \mathbf{k}_t). \quad (31)$$

上述（未归一化的）表述可视为带增量规则的变换器（Transformers with Delta Rule）的泛化。因此，由于内存无界，点积（Dot）不仅追加新的键和值（类似于原始变换器），还会用前一状态预测的值替换新值。

5 Atlas：一种具有高容量的局部最优内存

尽管欧米伽规则（Omega rule）的设计使模型能够记忆上下文而非单个词元，并且使用多项式（或指数）特征映射提高了内存容量，但内存管理（即键与值之间映射的优化）仍局限于简单的梯度下降。这种优化器的选择可能导致模型陷入局部最优的低质量解，损害模型在更长上下文中的性能。为克服这一问题，我们建议使用带权重衰减的 Muon 优化器（Jordan 等人，2024），它不仅近似二阶信息，而且主要利用矩阵乘法，可跨序列并行化。因此，使用 Muon 优化方程 9 中的内部目标，得到以下更新规则：

$$\mathcal{M}_t = \alpha_t \mathcal{M}_{t-1} - \eta_t \text{NewtonSchulz-}k(\mathcal{S}_t), \quad (32)$$

$$\mathcal{S}_t = \theta_t \mathcal{S}_{t-1} + \nabla \sum_{i=t-c+1}^t \gamma_i^{(t)} \|\mathcal{M}(\phi^*(\mathbf{k}_i)) - \mathbf{v}_i\|_2^2, \quad (33)$$

其中 c 是局部上下文长度， k 是牛顿-舒尔茨（Newton-Schulz）操作的步数。关于该算法和此操作的更多讨论，我们建议读者参考 Jordan 等人（2024）。根据 Muon 优化器的文献，我们知道当 $k \rightarrow \infty$ 时，牛顿-舒尔茨- $k(\mathcal{S}_t)$ 收敛到动量项 $\mathcal{S}_t$ 的最近半正交矩阵，从而以更低的误差近似二阶信息。因此，有趣的是，参数 k 可视为 Atlas 中的内部测试时计算参数，使用更多步数可能带来更好的记忆效果。

5.1 并行训练

在本节中，我们讨论了 Atlas 训练过程的并行化方法。为清晰起见，我们假设 $c = 1$ 。将过程推广到任意 c 值遵循第 3.3 节中的步骤。我们采用与第 3.3 节相同的流程，将序列分块，并相对于前一块的最后状态计算所有梯度。因此，使用带动量但不带权重衰减的 Atlas 递推，我们有：

$$\mathcal{M}_t = \alpha_t \mathcal{M}_{t-1} + \mathcal{S}_t \quad (34)$$

$$\mathcal{S}_t = \theta_t \mathcal{S}_{t-1} - \eta_t \nabla \ell(\mathcal{M}_{t'}; \mathbf{k}_t, \mathbf{v}_t). \quad (35)$$

由于 t' 是前一块的最后状态，我们可以预先计算所有梯度，因此令 $u_t = \nabla \ell(\mathcal{M}_{t'}; \mathbf{k}_t, \mathbf{v}_t)$ 。于是，我们有：

$$\mathcal{M}_t = \alpha_t \mathcal{M}_{t-1} + \mathcal{S}_t \quad (36)$$

$$\mathcal{S}_t = \theta_t \mathcal{S}_{t-1} - \eta_t u_t. \quad (37)$$

现在展开第二个递推，我们有：

$$\begin{aligned} \mathcal{S}_t &= \theta_t \mathcal{S}_{t-1} - \underbrace{\eta_t \nabla \ell(\mathcal{M}_{t'}; \mathbf{k}_t, \mathbf{v}_t)}_{u_t} \\ \Rightarrow \mathcal{S}_t &= \underbrace{\theta_t \dots \theta_1}_{\beta_t} \mathcal{S}_0 - \sum_{i=1}^t \frac{\theta_t \dots \theta_1}{\theta_i \dots \theta_1} \eta_i u_i = \beta_t \mathcal{S}_0 - \Theta \odot E \odot G, \end{aligned} \quad (38)$$

$$\Rightarrow \mathcal{S}_t = \underbrace{\theta_t \dots \theta_1}_{\beta_t} \mathcal{S}_0 - \sum_{i=1}^t \frac{\theta_t \dots \theta_1}{\theta_i \dots \theta_1} \eta_i u_i = \beta_t \mathcal{S}_0 - \Theta \odot E \odot G, \quad (39)$$




图 3: Atlas（及本文其他变体）架构及其与 SWA 混合的对应架构可视化。

其中 G 为梯度矩阵， E 和 Θ 为对角矩阵，其值分别为 θ 和 n ， $\odot$ 为广播操作。

上述公式（分块递归）的主要优势在于动量的递归与记忆状态无关。也就是说，我们可以在块开始时利用上述公式计算所有动量项。在 Muon 情形下，我们对动量项使用 Newton-Schulz 算法，得到：

$$S'_t \leftarrow \text{Newton-Schulz5}(S_t), \quad (40)$$

$$M_t = M_{t-1} + S'_t. \quad (41)$$

由于所有 S_t 的计算可以并行完成，Newton-Schulz5($\cdot$) 的计算也可以并行完成。

架构骨干。关于架构骨干，我们遵循近期现代循环模型（Allen-Zhu 2025；Arora、Eyuboglu、Zhang 等 2024；Behrouz、Zhong 等 2024；Yang、Wang、Zhang 等 2024），使用线性层投影键、值和查询，随后使用尺寸为 4 的短卷积层。我们对键和查询应用归一化以稳定训练。我们还遵循 Behrouz、Zhong 等（2024），为我们的 Atlas 模型使用 MAL 和 MAG 的两种混合变体。架构如图 3 所示。对于具有深度记忆架构的模型，我们使用带残差连接的 2 层多层感知机：

$$M(\cdot) = (\cdot) + W_1 \sigma(W_2(\cdot)). \quad (42)$$

我们进一步将这种近期研究中常用的记忆架构（Behrouz, Razaviyayn, et al. 2025；Behrouz, Zhong, et al. 2024；Irie et al. 2021）扩展为门控 MLP 层：

$$M(\cdot) = (\cdot) + W_1 (\sigma(W_2(\cdot)) \otimes W_3(\cdot)), \quad (43)$$

其中 W_1, W_2, W_3 为线性可学习矩阵。我们将采用上述记忆架构的 Atlas 称为 Atlas++。

6 实验

接下来，我们评估 Atlas、OmegaNet、DeepTransformers 和 Dot 在语言建模、常识推理、大海捞针以及上下文召回任务中的性能。尽管我们还讨论了其他几种变体，如 SWLA，但在实验中我们重点关注上述模型，因此除了与最先进的模型进行比较外，我们还回答了以下问题：

1. 深度记忆对 Softmax 注意力是否有效？（见表 2——Transformer++ 与 DeepTransformers 的比较）

2. 使用 Omega 是否能提升 Softmax 注意力的性能？（见表 2——Transformer++、DeepTransformers 与 Dot 的比较）
3. Omega 规则是否提供了更具表达力的记忆更新？（见表 2 和表 6——OmegaNet 与 Atlas 的性能）
4. 局部最优记忆更新是否有效？（见表 2 和表 6——OmegaNet 与 Atlas 的比较）
5. 非线性特征映射是否有效？（见表 6）
6. 所提出的改进能否在上下文召回任务中缩小与 Transformer 的差距？（见表 5）
7. 内部优化器对内存有何影响？（见图 6）

设置。我们使用 FineWeb 数据集（Penedo 等人，2024）以 4K 大小的训练上下文窗口训练模型。我们使用 340M、400M、790M 和 1.3B 参数的模型规模，并在从数据集中采样的 15B、15B、30B 和 100B 个标记上训练它们。基线结果由 Behrouz、Razaviyayn 等人（2025）、Behrouz、Zhong 等人（2024）和 Yang、Kautz 等人（2024）报告。困惑度在留下的验证数据上测量。至于下游任务，我们在 Wikitext（Merity 等人，2017）、LMB（Paperno 等人，2016）、PIQA（Bisk 等人，2020）、HellaSwag（Zellers 等人，2019）、WinoGrande（Sakaguchi 等人，2021）、ARC-easy（ARC-e）和 ARC-challenge（ARC-c）（Clark、Cowhey 等人，2018）、SIQA（Sap 等人，2019）和 BoolQ（Clark、Lee 等人，2019）上评估训练后的模型。关于实验设置和其他使用数据集的更多细节见附录 E。

6.1 语言建模与常识推理

Atlas 和 OmegaNet 以及它们对应的基线 SWDT、DLA、DeepTransformers 和 Dot 在 760M 和 1.3B 规模下的结果报告在表 2 中。（小规模结果见附录 F）。在非混合模型中，包括 Transformer++，我们的 Atlas 和 OmegaNet 在困惑度和准确率指标上都达到了最佳性能。我们将这种性能归因于它们记忆上下文而非单个标记的能力。将 OmegaNet 与 Titans 进行比较，后者也使用相同的瞬时目标（即 ℓ_2 损失），但上下文窗口为 1，我们可以观察到采用非在线学习规则的有效性。另一方面，我们的模型，仅凭自身而没有任何注意力，就能超越混合模型，而它们的混合变体 MAG 进一步提升了性能。这种性能提升也与使用多项式核函数有关，这些核函数增强了模型的记忆容量。参见

表 6，其中对各个组件的影响进行了更受控的研究。

将 Transformer++ 与我们更通用的 Transformer（即 DeepTransformers 和 Dot）进行比较，我们观察到一致的性能提升。我们将这种性能归因于它们的深层记忆，这使得它们在建模标记依赖关系方面更强大。将 Dot 与 DeepTransformers 进行比较，我们可以看到 Omega 规则的优势，它帮助模型更好地管理其记忆。




图 4: Atlas 与基线模型在 BABILong 基准上的性能。Atlas 超越了 Titans 的性能，并在该任务中有效扩展到 1000 万上下文长度。




图 5: 局部上下文长度（即 c ）对不同全局上下文长度下 OmegaNet 性能的影响。

表 2: Atlas 与基线模型在语言建模和常识推理任务上的性能。混合模型以 * 标记。最佳结果已高亮显示。

Model	Wiki. ppl ↓	LMB. ppl ↓	LMB. acc ↑	PIQA acc ↑	Hella. acc_n ↑	Wino. acc ↑	ARC-e acc ↑	ARC-c acc_n ↑	SIQA acc ↑	BoolQ acc ↑	Avg. ↑
760M params / 30B tokens											
Transformer++	25.21	27.64	35.8	66.9	42.2	51.9	60.4	32.5	39.5	60.4	48.69
DEEPTTRANSFORMERS (ours)	20.32	20.67	36.9	68.4	49.8	52.8	65.7	34.9	40.2	61.8	51.31
DOT (ours)	19.96	20.15	39.0	69.1	50.7	53.1	66.2	37.0	40.3	63.7	52.39
RetNet	26.08	24.45	34.5	67.2	41.6	52.1	63.2	32.8	38.4	57.9	48.46
DeltaNet	24.37	24.60	37.1	66.9	42.0	50.7	64.9	31.4	39.9	59.0	48.97
TTT	24.17	23.51	34.7	67.3	43.9	51.0	64.5	33.8	40.2	59.6	47.32
Gated DeltaNet	21.18	22.09	35.5	68.0	44.9	50.7	66.9	33.1	39.2	59.1	49.69
Samba*	20.63	22.71	39.7	69.2	47.4	52.0	66.9	33.2	39.0	61.2	51.08
Gated DeltaNet-H2*	19.88	20.83	39.2	69.0	48.2	52.6	67.0	35.5	39.4	61.1	51.49
Titans (LMM)	20.04	21.96	37.4	69.3	48.5	52.3	66.3	35.8	40.1	62.8	51.56
MEMORA	22.28	22.31	38.2	67.8	49.3	53.3	63.6	36.1	40.9	63.0	51.52
SWDT (ours)	19.89	21.52	36.2	68.3	45.2	53.0	65.4	34.2	39.5	59.5	50.1
DLA (ours)	23.12	22.09	36.1	68.0	47.9	52.7	65.8	34.6	39.1	59.6	50.46
OMEGANET (ours)	19.16	20.14	38.7	69.8	50.0	53.3	67.8	36.8	39.6	64.4	52.56
ATLAS (ours)	18.92	21.01	39.1	69.7	50.2	53.5	67.5	37.1	40.7	64.3	52.77
ATLAS++ (ours)	19.04	20.03	39.7	69.7	51.1	53.2	68.2	37.4	40.9	64.4	53.09
ATLAS (MAG)	18.62	21.18	40.0	70.3	50.5	53.0	68.1	36.5	41.2	65.0	53.08
ATLAS (MAL)	19.07	21.46	38.8	69.2	50.5	53.6	67.3	36.1	41.0	64.5	52.63
1.3B params / 100B tokens											
Transformer++	18.53	18.32	42.6	70.0	50.2	53.5	68.8	35.1	40.7	57.1	52.25
DEEPTTRANSFORMERS (ours)	15.67	12.63	49.4	72.6	57.0	58.8	71.1	37.5	41.6	61.5	56.19
DOT (ours)	15.28	11.96	50.1	73.3	57.5	60.4	72.2	41.2	42.7	61.4	57.35
RetNet	19.08	17.27	40.5	70.1	49.2	54.1	67.3	33.8	40.8	60.4	52.02
Mamba2	16.56	12.56	45.7	71.9	55.7	55.2	72.5	37.9	40.2	60.1	54.89
DeltaNet	17.71	16.88	42.5	70.7	50.9	53.3	68.5	35.7	40.2	55.3	52.14
Gated DeltaNet	16.42	12.17	46.6	72.2	55.8	57.4	71.2	38.4	40.6	60.2	55.32
Samba*	16.13	13.29	44.9	70.9	53.4	55.6	68.8	36.2	40.0	62.1	54.00
Gated DeltaNet-H2*	15.91	12.55	48.8	72.2	56.9	57.8	71.4	39.1	41.2	61.6	56.18
Titans (LMM)	15.60	11.41	49.1	73.1	56.3	59.8	72.4	40.8	42.1	61.0	56.82
MEMORA	15.90	12.04	48.7	73.1	56.0	57.4	71.5	37.9	40.2	61.3	55.87
OMEGANET (ours)	14.91	11.26	49.7	73.4	57.6	59.7	72.6	40.3	42.4	62.1	57.23
ATLAS (ours)	14.97	10.98	50.1	73.9	57.3	60.2	72.8	41.0	42.9	62.8	57.62
ATLAS++ (ours)	14.40	10.72	50.8	73.5	59.4	61.1	71.3	43.7	42.5	61.9	58.03

6.2 长上下文：大海捞针

设计 Atlas 的主要动机之一是提升长上下文任务中长期神经记忆模块的性能。因此，为评估我们设计在提升有效上下文长度和记忆容量方面的有效性，我们在 RULER (Hsieh 等人, 2024) 基准的大海捞针任务上进行了实验。Atlas 及其混合变体，以及我们的类 Transformer 架构和基线模型的性能报告于表 3。Atlas 相较于循环基线模型表现出非常优异的性能，超越了 Titans 和 DeltaNet 等现代循环神经网络。其混合变体进一步提升了有效上下文长度，能够有效外推至训练上下文长度 $\times 4$ 倍的序列。我们将此性能归因于所提出的记忆容量增强方法。我们进一步进行了消融研究以验证这一论断。此外，我们的类 Transformer 架构在更长上下文中超越了基线模型，甚至超越了 Atlas 的混合变体。这表明了指数特征映射在更长序列中的重要性。

6.3 长上下文：BABILong 基准

为比较 Atlas 与 Titans (Behrouz, Zhong 等人, 2024) 在超长序列上的有效性，我们进一步在 BABILong 基准 (Kuratov 等人, 2024) 上评估了 Atlas 的性能。本实验中，我们遵循 Behrouz,

表 3: Atlas 与基线模型在 RULER 基准 S-NIAH 任务上的性能。简单模型和混合模型中的最佳结果已高亮显示。

Model	S-NIAH-PK				S-NIAH-N				S-NIAH-W		
	2K	4K	8K	16K	2K	4K	8K	16K	2K	4K	8K
TTT	98.4	98.8	98.0	88.4	60.2	36.6	10.2	4.4	78.8	28.0	4.4
DeltaNet	96.8	98.8	98.6	71.4	47.2	15.4	12.8	5.4	46.2	20.0	1.6
Titans (LMM)	99.8	98.4	98.2	96.2	100.0	99.8	93.4	80.2	90.4	89.4	85.8
ATLAS	100	99.2	98.0	97.0	100.0	100.0	93.0	84.0	93.2	90.6	86.2
Samba	98.8	98.0	97.4	97.2	98.8	98.6	96.2	95.6	96.8	90.0	84.0
Gated DeltaNet-H2*	99.2	97.8	97.4	98.4	98.0	97.8	96.2	95.8	97.4	96.8	88.4
ATLAS (MAG)	100	100	99.4	98.6	100	99.2	97.4	97.0	99.4	98.2	92.4
ATLAS (MAL)	99.8	99.6	98.4	96.8	99.8	98.0	97.2	96.8	98.0	98.4	92.6
DEEPTransformers	100	100	98.2	97.8	100	98.8	97.8	94.0	95.8	92.2	88.4
DOT	100	100	99.6	98.6	100	100	97.8	96.8	99.0	98.4	93.2

Zhong 等人 (2024) 采用了 MAC 架构, 但没有使用持久记忆令牌。我们还遵循基准测试中的原始设置, 并对模型进行了微调。结果如图 4 所示。虽然 Atlas 在 1M 上下文长度内表现出与 Titans 相当的性能, 但 Titans 在 10M 上下文长度下性能下降。然而, Atlas 保持了其性能, 并在 10M 上下文长度下达到了 +80% 的准确率。我们将此归因于更强大的记忆能力; 具体而言,

(1) 记忆管理 (即使用 Muon), (2) 由于多项式核函数而具有更好的记忆容量, 以及 (3) 其本质是记忆上下文, 而不是单个令牌。

在前面的章节中, 我们展示了类似 Transformer 的架构 (即 DeepTransformers 和 Dot) 在语言建模和长上下文大海捞针任务中的有效性。从现在开始, 我们专注于循环架构 (即 Atlas 和 OmegaNet), 以展示所提出改进的重要性。

6.4 可学习性实验

我们还进行了一些小规模实验, 以在线方式分析小型 MLP 的函数学习能力。在此设置中, 我们有一个元组序列 $(i_1, o_1), \dots, (i_t, o_t)$, 其中对于所有 j , $i_j, o_j \in \mathbb{R}^d$ 。我们以在线方式训练 MLP M , 以最小化损失 $J = \frac{1}{2} \|i_j - o_j\|_2^2$ ——具体来说, 我们在时间步 j 计算梯度为 $\nabla_{M.params} \text{loss}_j$, 并使用标准优化器 (如 Adam、Rmsprop 和 SGD) 更新参数。此类实验有助于我们理解用于表示记忆的模型的表示能力, 以及优化算法快速学习底层序列映射的能力。


我们研究了五种不同的序列到序列函数: 1. 低秩映射: 我们采样一个随机低秩矩阵 $W = XY$, 其中 $X \in \mathbb{R}^{d \times k}$ 且 $Y \in \mathbb{R}^{k \times d}$ 。然后我们从高斯分布中随机采样 $i_1, \dots, i_t$, 并对于所有 $j \in [t]$, 设置 $o_j = W^T \cdot i_j$ 。

2. MLP 映射: 我们采样一个具有 1 个输入层、1 个隐藏层和 1 个输出层并使用 GELU 非线性的 MLP M 。我们将隐藏维度设置为 d , 以便没有扩展。然后我们从高斯分布中随机采样 $i_1, \dots, i_t$, 并对于所有 $j \in [t]$, 设置 $o_j = M(i_j)$ 。


3. 注意力+MLP 映射: 我们从高斯分布中采样 $(i_1, \dots, i_t)$, 并采样一个如上所述的 MLP M 。我们还采样三个 $d \times d$ 矩阵 W_Q, W_K 和 W_V , 并对于所有 $j \in [t]$, 计算 $a_j = W_Q^T \cdot i_j, k_j = W_K^T \cdot i_j$ 和 $v_j = W_V^T \cdot i_j$ 。然后我们计算 $o'_1, \dots, o'_t$ 作为应用于 $\{a_j\}_j \in [t], \{k_j\}_j \in [t], \{v_j\}_j \in [t]$ 的因果掩码注意力机制的输出, 最后计算 $o_j = M(o'_j)$ 。

4. 注意力输出作为输入: 除输出 o' 作为输入序列、 o_j 作为输出序列外, 其余操作与上述相同。


5. 滑动窗口注意力 + 多层感知机映射: 除使用滑动窗口注意力代替全注意力外, 其余操作与注意力 + 多层感知机映射设置相同。实验中滑动窗口大小设为 512。




(a) $\mathcal{M}$ with 2 hidden layers and no expansion.



(b) $\mathcal{M}$ with 3 hidden layers and no expansion.



(c) $\mathcal{M}$ with 2 hidden layers and 4x expansion.



(d) $\mathcal{M}$ with 3 hidden layers and 4x expansion.

图 6: 不同设置及各种超参数下的损失曲线

表 4: Atlas、OmegaNet 及基线模型在 MAD 合成基准上的性能 (Poli 等, 2024)。Atlas 超越所有基线模型, 包括变换器。

	Compression	(Noisy) ICR	Fuzzy ICR	Selective Copying	Memorization	Average
Transformers	49.4	100	48.2	95.9	83.8	75.46
Gated DeltaNet	44.8	100	32.5	96.2	81.7	71.04
Titans	49.6	100	49.7	99.4	83.5	76.44
OMEGANET (ours)	50.9	100	54.2	99.6	90.2	78.98
ATLAS (ours)	51.6	100	54.9	99.6	91.4	79.50

注意, 设置 3 和 5 的学习难度显著更高, 因为它们需要 (部分) 记忆先前的输入和输出, 才能学习将 i_j 映射到 o_j 的函数; 而设置 1、2 和 4 无需记忆先前的输入-输出对, 只需学习底层低秩矩阵或将输入映射到输出的多层感知机。

设置 4 与设置 2 略有不同, 因为输入在每个时间步并非独立, 而是通过用于计算输入的注意力机制相互关联。因此, 强大的学习算法或许能够利用这些潜在相关性, 在设置 4 中比设置 2 更快地学习映射。

表 5: 本文模型 (Atlas 和 OmegaNet) 与基线模型的性能对比。尽管变换器在上下文召回任务中仍取得最佳结果, 但本文设计的上下文记忆与多项式特征映射能够缩小与变换器的差距。

	SWDE	NQ	DROP	FDA	SQUAD	TQA	Average
Transformers	84.9	23.0	28.4	72.5	48.1	64.4	53.55
Gated DeltaNet	63.2	19.1	26.7	33.4	39.6	59.7	40.28
Titans	65.1	20.7	27.2	37.3	42.6	61.0	42.31
OMEGANET (ours)	67.4	21.1	27.2	39.0	43.2	60.9	43.13
ATLAS (ours)	66.8	21.9	27.4	40.7	44.1	61.3	43.70

表 6: Atlas 的消融实验。Atlas 的所有组件均对其性能有积极贡献。

Model	Language Modeling ppl ↓	C.S. Reasoning acc ↑
ATLAS	19.97	52.77
+Gated MLP Memory	19.53	53.09
+Attn (MAG)	19.90	53.08
+Attn (MAL)	20.26	52.63
Linear Memory	21.03	49.74
w/o Muon	19.65	52.56
$c = 1$	21.98	49.26
w/o Polynomial Mapping	22.14	50.57

We set $d = 256$ and show the loss curves vs sequence position for all the five settings with function learning MLP $\mathcal{M}$ being defined and trained with different settings in Figure 6. We can see that in all the settings, the model learns non-trivial mappings from inputs to outputs with the $loss_j = \|i_j - o_j\|_2^2 / \|o_j\|_2^2$ being smaller than 1 eventually. Most notably, the correlations in inputs in setting 4 induced by the attention mechanism makes the model quickly learn the mapping compared to in setting 2 and the models usually learn the best in setting 1 which is the least complex function.

The models do the worst in settings 3 and 5 which require the models to (partially) memorize the inputs and outputs to learn the attention mechanism outputs. Surprisingly, the models learn to do better in setting 3 vs setting 5, when we would expect that capacity requirement for setting 3 to be higher than setting 5. We hypothesize that the learning algorithm is unable to make the model ‘forget’ old inputs which makes the loss worse in sliding window setting when compared to global attention setting. A caveat of our analysis is that, the attention computation is done on randomly initialized vectors and hence the attention matrix is usually not spiky, unlike in the attention matrix for trained set of query, key and value vectors in LLMs. This leads to attention outputs being close to the mean of value vectors in the context.

6.5 附加实验：上下文召回率、MAD 合成基准与关联召回率

在本节中, 我们首先在 MAD 基准上评估我们模型的性能, 该基准是一个合成基准, 用于评估模型在召回、记忆、压缩和复制任务中的性能 (Poli 等人, 2024)。结果报告在表 4 中。Atlas 在各个方面都取得了最佳结果, 特别是在记忆方面, 这表明其组件对于增强记忆容量的重要性。

上下文回忆任务是对循环神经网络最具挑战性的基准之一。在本节中，我们遵循 Arora、Eyuboglu、Zhang 等人 (2024) 的方法，在 SWDE (Lockard 等人, 2019)、NQ (Kwiatkowski 等人, 2019)、DROP (Dua 等人, 2019)、FDA (Arora、Yang 等人, 2023)、SQUAD (Rajpurkar 等人, 2016) 和 TQA (Kembhavi 等人, 2017) 上进行实验，以评估和比较 Atlas 与基线及变换器的性能。结果报告于表 5。虽然变换器在上下文回忆任务中仍取得最佳结果，但 Atlas 和 OmegaNet 表现出具有竞争力的性能，并且优于最先进的循环模型。我们再次将这一性能归因于更好的记忆管理和容量。




图 7：联想记忆召回的结果。





图 8：图集 (Atlas) 与欧米茄网络 (OmegaNet) 的扩展模式，分别关于 (左) 训练上下文长度和 (右) 浮点运算次数 (FLOPs)。



最后，遵循 Yang、Wang、Zhang 等人 (2024) 以及 Arora、Eyuboglu、Timalsina 等人 (2023) 的做法，本文在多查询联想回忆 (Multi-Query Associative Recall, MQAR) 任务中评估了 Atlas 与 Dot 的性能 (Arora、Eyuboglu、Timalsina 等人, 2023)。结果如图 7 所示。与基线相比，两种模型均表现出良好的性能，且 Atlas 在每种记忆规模下均达到最佳性能，优于 DeltaNet (Yang、Wang、Zhang 等人, 2024) 等最先进的模型。

6.6 消融实验与规模规律

在本节中，我们对 Atlas 的不同组件进行了消融实验，并评估了其随参数数量和训练上下文长度的扩展模式。消融实验结果见表 6。结果表明：(1) 更强大的记忆架构 (如门控 MLP) 可以进一步提升 Atlas 的性能；(2) 混合变体进一步提升了性能，其中 MAG 相比 MAL 架构表现出更好的改进；(3) 当我们使用上下文记忆 (即 Omega 规则) 时，多项式映射和深度记忆尤为重要。图 5 还展示了局部上下文长度 (即 c) 对模型性能的影响。随着 c 的增加，我们可以获得更好的性能，这主要归因于 γ 的门控参数，它可以在需要时修剪上下文。

模型规模。图 8 展示了 Atlas 和 OmegaNet 相对于参数数量的扩展模式，并与基线进行了比较。随着模型规模的增大，两种模型都实现了良好的扩展模式，在所有规模下都取得了比基线更低的困惑度。

上下文长度。图 8 展示了 Atlas 和 OmegaNet 相对于上下文长度的扩展模式，并与基线进行了比较。由于具有高记忆容量，两种模型在增加上下文长度时都能很好地扩展。

7 结论

我们介绍了 Atlas，一种新的长期记忆模块，旨在解决现代循环模型在长上下文理解中的核心局限性：记忆容量有限、仅在线更新以及记忆管理薄弱。我们提出的滑动窗口学习规则、高阶特征映射和先进的记忆优化器为克服这些挑战提供了一种有原则且可扩展的方法。在经验上，我们的模型——OmegaNet、Atlas、DeepTransformers 和 Dot——在多种基准测试中均取得了优于 Transformer 和近期 RNN 变体的一致改进。在理论上，我们深入探讨了记忆容量和优化动态，为先前工作中观察到的上下文长度限制提供了见解。

参考文献

- [1] Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altenschmidt, Sam Altman, Shyamal Anadkat, et al. “Gpt-4 technical report”. In: *arXiv preprint arXiv:2303.08774* (2023).
- [2] Zeyuan Allen-Zhu. “Physics of Language Models: Part 4.1, Architecture Design and the Magic of Canon Layers”. In: *SSRN Electronic Journal* (May 2025). <https://ssrn.com/abstract=5240330>.
- [3] Simran Arora, Sabri Eyuboglu, Aman Timalsina, Isys Johnson, Michael Poli, James Zou, Atri Rudra, and Christopher Ré. “Zoology: Measuring and improving recall in efficient language models”. In: *arXiv preprint arXiv:2312.04927* (2023).
- [4] Simran Arora, Sabri Eyuboglu, Michael Zhang, Aman Timalsina, Silas Alberti, James Zou, Atri Rudra, and Christopher Re. “Simple linear attention language models balance the recall-throughput tradeoff”. In: *Forty-first International Conference on Machine Learning*. 2024. URL: <https://openreview.net/forum?id=e93ffDcpH3>.
- [5] Simran Arora, Brandon Yang, Sabri Eyuboglu, Avanika Narayan, Andrew Hojel, Immanuel Trummer, and Christopher Ré. “Language models enable simple systems for generating structured views of heterogeneous data lakes”. In: *arXiv preprint arXiv:2304.09433* (2023).
- [6] Dzmitry Bahdanau, Kyunghyun Cho, and Yoshua Bengio. “Neural machine translation by jointly learning to align and translate”. In: *arXiv preprint arXiv:1409.0473* (2014).
- [7] Eric B Baum. “On the capabilities of multilayer perceptrons”. In: *Journal of Complexity* 4.3 (1988), pp. 193–215. ISSN: 0885-064X. DOI: [https://doi.org/10.1016/0885-064X\(88\)90020-9](https://doi.org/10.1016/0885-064X(88)90020-9). URL: <https://www.sciencedirect.com/science/article/pii/0885064X88900209>.
- [8] Ali Behrouz, Meisam Razaviyayn, Peilin Zhong, and Vahab Mirrokni. “It’s All Connected: A Journey Through Test-Time Memorization, Attentional Bias, Retention, and Online Optimization”. In: *arXiv preprint arXiv:2504.13173* (2025).
- [9] Ali Behrouz, Peilin Zhong, and Vahab Mirrokni. “Titans: Learning to memorize at test time”. In: *arXiv preprint arXiv:2501.00663* (2024).
- [10] Srinadh Bhojanapalli, Chulhee Yun, Ankit Singh Rawat, Sashank Reddi, and Sanjiv Kumar. “Low-rank bottleneck in multi-head attention models”. In: *International conference on machine learning*. PMLR. 2020, pp. 864–873.
- [11] Alberto Bietti, Vivien Cabannes, Diane Bouchacourt, Herve Jegou, and Leon Bottou. “Birth of a transformer: A memory viewpoint”. In: *Advances in Neural Information Processing Systems* 36 (2023), pp. 1560–1588.
- [12] Yonatan Bisk, Rowan Zellers, Jianfeng Gao, Yejin Choi, et al. “Piqa: Reasoning about physical commonsense in natural language”. In: *Proceedings of the AAAI conference on artificial intelligence*. Vol. 34. 2020, pp. 7432–7439.
- [13] Christopher Clark, Kenton Lee, Ming-Wei Chang, Tom Kwiatkowski, Michael Collins, and Kristina Toutanova. “BoolQ: Exploring the Surprising Difficulty of Natural Yes/No Questions”. In: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*. Ed. by Jill Burstein, Christy Doran, and Thamar Solorio. Minneapolis, Minnesota: Association for Computational Linguistics, June 2019, pp. 2924–2936. DOI: 10.18653/v1/N19-1300. URL: <https://aclanthology.org/N19-1300/>.
- [14] Peter Clark, Isaac Cowhey, Oren Etzioni, Tushar Khot, Ashish Sabharwal, Carissa Schoenick, and Oyvind Tafjord. “Think you have solved question answering? try arc, the ai2 reasoning challenge”. In: *arXiv preprint arXiv:1803.05457* (2018).
- [15] Thomas M. Cover. “Geometrical and Statistical Properties of Systems of Linear Inequalities with Applications in Pattern Recognition”. In: *IEEE Transactions on Electronic Computers* EC-14.3 (1965), pp. 326–334. DOI: 10.1109/PGEC.1965.264137.
- [16] Róbert Csordás, Christopher Potts, Christopher D Manning, and Atticus Geiger. “Recurrent Neural Networks Learn to Store and Generate Sequences using Non-Linear Representations”. In: *Proceedings of the 7th BlackboxNLP Workshop: Analyzing and Interpreting Neural Networks for NLP*. 2024, pp. 248–262.
- [17] Karan Dalal, Daniel Kocaja, Gashon Hussein, Jiarui Xu, Yue Zhao, Youjin Song, Shihao Han, Ka Chun Cheung, Jan Kautz, Carlos Guestrin, et al. “One-Minute Video Generation with Test-Time Training”. In: *arXiv preprint arXiv:2504.05298* (2025).
- [18] Dheeru Dua, Yizhong Wang, Pradeep Dasigi, Gabriel Stanovsky, Sameer Singh, and Matt Gardner. “DROP: A reading comprehension benchmark requiring discrete reasoning over paragraphs”. In: *arXiv preprint arXiv:1903.00161* (2019).
- [19] Jianqing Fan. *Local polynomial modelling and its applications: monographs on statistics and applied probability* 66. Routledge, 2018.

- [20] Xavier Gonzalez, Andrew Warrington, Jimmy Smith, and Scott Linderman. “Towards scalable and stable parallelization of nonlinear rnns”. In: *Advances in Neural Information Processing Systems* 37 (2024), pp. 5817–5849.
- [21] Ramin Hasani, Mathias Lechner, Tsun-Hsuan Wang, Makram Chahine, Alexander Amini, and Daniela Rus. “Liquid Structural State-Space Models”. In: *The Eleventh International Conference on Learning Representations*. 2023. URL: <https://openreview.net/forum?id=g40TKRKfS7R>.
- [22] Zexue He, Leonid Karlinsky, Donghyun Kim, Julian McAuley, Dmitry Krotov, and Rogerio Feris. “CAMELoT: Towards Large Language Models with Training-Free Consolidated Associative Memory”. In: *arXiv preprint arXiv:2402.13449* (2024).
- [23] Donald Olding Hebb. *The organization of behavior: A neuropsychological theory*. Psychology press, 2005.
- [24] Dan Hendrycks and Kevin Gimpel. “Gaussian error linear units (gelus)”. In: *arXiv preprint arXiv:1606.08415* (2016).
- [25] John J Hopfield. “Neural networks and physical systems with emergent collective computational abilities.” In: *Proceedings of the national academy of sciences* 79.8 (1982), pp. 2554–2558.
- [26] Cheng-Ping Hsieh, Simeng Sun, Samuel Krman, Shantanu Acharya, Dima Rekes, Fei Jia, and Boris Ginsburg. “RULER: What’s the Real Context Size of Your Long-Context Language Models?” In: *First Conference on Language Modeling*. 2024. URL: <https://openreview.net/forum?id=kIoBbc76Sy>.
- [27] Jerry Yao-Chieh Hu, Dennis Wu, and Han Liu. “Provably optimal memory capacity for modern hopfield models: Transformer-compatible dense associative memories as spherical codes”. In: *arXiv preprint arXiv:2410.23126* (2024).
- [28] Weizhe Hua, Zihang Dai, Hanxiao Liu, and Quoc Le. “Transformer quality in linear time”. In: *International conference on machine learning*. PMLR. 2022, pp. 9099–9117.
- [29] Guang-Bin Huang. “Learning capability and storage capacity of two-hidden-layer feedforward networks”. In: *IEEE Transactions on Neural Networks* 14.2 (2003), pp. 274–281. doi: 10.1109/TNN.2003.809401.
- [30] Kazuki Irie, Imanol Schlag, Robert Csordas, and Jurgen Schmidhuber. “Going beyond linear transformers with recurrent fast weight programmers”. In: *Advances in neural information processing systems* 34 (2021), pp. 7703–7717.
- [31] Keller Jordan, Yuchen Jin, Vlado Boza, Jiacheng You, Franz Cesista, Laker Newhouse, and Jeremy Bernstein. *Muon: An optimizer for hidden layers in neural networks*. 2024. URL: <https://kellerjordan.github.io/posts/muon/>.
- [32] Praneeth Kacham, Vahab Mirrokni, and Peilin Zhong. “PolySketchFormer: Fast Transformers via Sketching Polynomial Kernels”. In: *Forty-first International Conference on Machine Learning*. 2024. URL: <https://openreview.net/forum?id=ghYrfdJfjK>.
- [33] Praneeth Kacham, Vahab Mirrokni, and Peilin Zhong. “PolySketchFormer: Fast Transformers via Sketching Polynomial Kernels”. In: *Proceedings of the 41st International Conference on Machine Learning*. Ed. by Ruslan Salakhutdinov, Zico Kolter, Katherine Heller, Adrian Weller, Nuria Oliver, Jonathan Scarlett, and Felix Berkenkamp. Vol. 235. Proceedings of Machine Learning Research. PMLR, July 2024, pp. 22748–22770. URL: <https://proceedings.mlr.press/v235/kacham24a.html>.
- [34] Aishwarya Kamath, Johan Ferret, Shreya Pathak, Nino Vieillard, Ramona Merhej, Sarah Perrin, Tatiana Matejovicova, Alexandre Ramé, Morgane Riviére, et al. “Gemma 3 technical report”. In: *arXiv preprint arXiv:2503.19786* (2025).
- [35] M. Karami and V. Mirrokni. *Lattice: Learning to Efficiently Compress the Memory*. 2025.
- [36] Jungo Kasai, Hao Peng, Yizhe Zhang, Dani Yogatama, Gabriel Ilharco, Nikolaos Pappas, Yi Mao, Weizhu Chen, and Noah A. Smith. “Finetuning Pretrained Transformers into RNNs”. In: *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Ed. by Marie-Francine Moens, Xuanjing Huang, Lucia Specia, and Scott Wen-tau Yih. Online and Punta Cana, Dominican Republic: Association for Computational Linguistics, Nov. 2021, pp. 10630–10643. doi: 10.18653/v1/2021.emnlp-main.830. URL: <https://aclanthology.org/2021.emnlp-main.830/>.
- [37] Angelos Katharopoulos, Apoorv Vyas, Nikolaos Pappas, and François Fleuret. “Transformers are rnns: Fast autoregressive transformers with linear attention”. In: *International conference on machine learning*. PMLR. 2020, pp. 5156–5165.
- [38] Aniruddha Kembhavi, Minjoon Seo, Dustin Schwenk, Jonghyun Choi, Ali Farhadi, and Hannaneh Hajishirzi. “Are you smarter than a sixth grader? textbook question answering for multimodal machine comprehension”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern recognition*. 2017, pp. 4999–5007.
- [39] Dmitry Krotov. “Hierarchical associative memory”. In: *arXiv preprint arXiv:2107.06446* (2021).
- [40] Dmitry Krotov and John J Hopfield. “Dense associative memory for pattern recognition”. In: *Advances in neural information processing systems* 29 (2016).
- [41] Yuri Kuratov, Aydar Bulatov, Petr Anokhin, Ivan Rodkin, Dmitry Igorevich Sorokin, Artyom Sorokin, and Mikhail Burtsev. “BABILong: Testing the Limits of LLMs with Long Context Reasoning-in-a-Haystack”. In: *The Thirty-*

- eight Conference on Neural Information Processing Systems Datasets and Benchmarks Track. 2024. URL: <https://openreview.net/forum?id=u7m2CG84BQ>.
- [42] Tom Kwiatkowski, Jennimaria Palomaki, Olivia Redfield, Michael Collins, Ankur Parikh, Chris Alberti, Danielle Epstein, Illia Polosukhin, Jacob Devlin, Kenton Lee, et al. “Natural questions: a benchmark for question answering research”. In: *Transactions of the Association for Computational Linguistics* 7 (2019), pp. 453–466.
 - [43] Chengxuan Li, Di Huang, Zeyu Lu, Yang Xiao, Qingqi Pei, and Lei Bai. “A survey on long video generation: Challenges, methods, and prospects”. In: *arXiv preprint arXiv:2403.16407* (2024).
 - [44] Xiaoyu Li, Yuanpeng Li, Yingyu Liang, Zhenmei Shi, and Zhao Song. “On the expressive power of modern hopfield networks”. In: *arXiv preprint arXiv:2412.05562* (2024).
 - [45] Yi Heng Lim, Qi Zhu, Joshua Selfridge, and Muhammad Firmansyah Kasim. “Parallelizing non-linear sequential models over the sequence length”. In: *The Twelfth International Conference on Learning Representations*. 2024. URL: <https://openreview.net/forum?id=E34AlVLN0v>.
 - [46] Bo Liu, Rui Wang, Lemeng Wu, Yihao Feng, Peter Stone, and Qiang Liu. “Longhorn: State space models are amortized online learners”. In: *arXiv preprint arXiv:2407.14207* (2024).
 - [47] Nelson F Liu, Kevin Lin, John Hewitt, Ashwin Paranjape, Michele Bevilacqua, Fabio Petroni, and Percy Liang. “Lost in the middle: How language models use long contexts”. In: *Transactions of the Association for Computational Linguistics* 12 (2024), pp. 157–173.
 - [48] Colin Lockard, Prashant Shiralkar, and Xin Luna Dong. “Openceres: When open information extraction meets the semi-structured web”. In: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*. 2019, pp. 3047–3056.
 - [49] Carlo Lucibello and Marc Mézard. “Exponential capacity of dense associative memories”. In: *Physical Review Letters* 132.7 (2024), p. 077301.
 - [50] Stephen Merity, Caiming Xiong, James Bradbury, and Richard Socher. “Pointer Sentinel Mixture Models”. In: *International Conference on Learning Representations*. 2017. URL: <https://openreview.net/forum?id=Byj72udxe>.
 - [51] William Merrill, Jackson Petty, and Ashish Sabharwal. “The Illusion of State in State-Space Models”. In: *Forty-first International Conference on Machine Learning*. 2024. URL: <https://openreview.net/forum?id=QZgo9JZpLq>.
 - [52] Guido Montufar, Razvan Pascanu, Kyunghyun Cho, and Yoshua Bengio. “On the number of linear regions of deep neural networks”. In: *Proceedings of the 28th International Conference on Neural Information Processing Systems - Volume 2. NIPS’14*. Montreal, Canada: MIT Press, 2014, pp. 2924–2932.
 - [53] Tsendsuren Munkhdalai, Alessandro Sordani, Tong Wang, and Adam Trischler. “Metalearned neural memory”. In: *Advances in Neural Information Processing Systems* 32 (2019).
 - [54] Tsendsuren Munkhdalai and Hong Yu. “Neural semantic encoders”. In: *Proceedings of the conference. Association for Computational Linguistics. Meeting*. Vol. 1. NIH Public Access. 2017, p. 397.
 - [55] Denis Paperno, German Kruszewski, Angeliki Lazaridou, Ngoc Quan Pham, Raffaella Bernardi, Sandro Pezzelle, Marco Baroni, Gemma Boleda, and Raquel Fernandez. “The LAMBADA dataset: Word prediction requiring a broad discourse context”. In: *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Ed. by Katrin Erk and Noah A. Smith. Berlin, Germany: Association for Computational Linguistics, Aug. 2016, pp. 1525–1534. DOI: 10.18653/v1/P16-1144. URL: <https://aclanthology.org/P16-1144/>.
 - [56] Razvan Pascanu, Guido Montufar, and Yoshua Bengio. *On the number of response regions of deep feed forward networks with piece-wise linear activations*. 2014. arXiv: 1312.6098 [cs.LG]. URL: <https://arxiv.org/abs/1312.6098>.
 - [57] Guilherme Penedo, Hynek Kydlicek, Anton Lozhkov, Margaret Mitchell, Colin A Raffel, Leandro Von Werra, Thomas Wolf, et al. “The fineweb datasets: Decanting the web for the finest text data at scale”. In: *Advances in Neural Information Processing Systems* 37 (2024), pp. 30811–30849.
 - [58] Bo Peng, Eric Alcaide, Quentin Gregory Anthony, Alon Albalak, Samuel Arcadinho, Stella Biderman, Huanqi Cao, Xin Cheng, Michael Nguyen Chung, Leon Derczynski, Xingjian Du, Matteo Grella, Kranthi Kiran GV, Xuzheng He, Haowen Hou, Przemyslaw Kazienko, Jan Kocon, Jiaming Kong, Bartłomiej Koptyra, Hayden Lau, Jiaju Lin, Krishna Sri Ipsit Mantri, Ferdinand Mom, Atsushi Saito, Guangyu Song, Xiangru Tang, Johan S. Wind, Stanisław Wozniak, Zhenyuan Zhang, Qinghua Zhou, Jian Zhu, and Rui-Jie Zhu. “RWKV: Reinventing RNNs for the Transformer Era”. In: *The 2023 Conference on Empirical Methods in Natural Language Processing*. 2023. URL: <https://openreview.net/forum?id=7SaXczaBpG>.
 - [59] Bo Peng, Daniel Goldstein, Quentin Anthony, Alon Albalak, Eric Alcaide, Stella Biderman, Eugene Cheah, Xingjian Du, Teddy Ferdinan, Haowen Hou, et al. “Eagle and finch: Rwkv with matrix-valued states and dynamic recurrence”. In: *arXiv preprint arXiv:2404.05892* (2024).

- [60] Bo Peng, Ruichong Zhang, Daniel Goldstein, Eric Alcaide, Haowen Hou, Janna Lu, William Merrill, Guangyu Song, Kaifeng Tan, Saiteja Utpala, et al. “Rwkv-7” goose” with expressive dynamic state evolution”. In: *arXiv preprint arXiv:2503.14456* (2025).
- [61] Michael Poli, Armin W Thomas, Eric Nguyen, Pragaash Ponnusamy, Bjorn Deiseroth, Kristian Kersting, Taiji Suzuki, Brian Hie, Stefano Ermon, Christopher Re, et al. “Mechanistic design and scaling of hybrid architectures”. In: *arXiv preprint arXiv:2403.17844* (2024).
- [62] DL Prados and SC Kak. “Neural network capacity using delta rule”. In: *Electronics Letters* 25.3 (1989), pp. 197–199.
- [63] Pranav Rajpurkar, Jian Zhang, Konstantin Lopyrev, and Percy Liang. “Squad: 100,000+ questions for machine comprehension of text”. In: *arXiv preprint arXiv:1606.05250* (2016).
- [64] Hubert Ramsauer, Bernhard Schögl, Johannes Lehner, Philipp Seidl, Michael Widrich, Lukas Gruber, Markus Holzleitner, Thomas Adler, David Kreil, Michael K Kopp, Günter Klambauer, Johannes Brandstetter, and Sepp Hochreiter. “Hopfield Networks is All You Need”. In: *International Conference on Learning Representations*. 2021. URL: <https://openreview.net/forum?id=tL89RnzIiCd>.
- [65] Liliang Ren, Yang Liu, Yadong Lu, Yelong Shen, Chen Liang, and Weizhu Chen. “Samba: Simple Hybrid State Space Models for Efficient Unlimited Context Language Modeling”. In: *arXiv preprint arXiv:2406.07522* (2024).
- [66] Keisuke Sakaguchi, Ronan Le Bras, Chandra Bhagavatula, and Yejin Choi. “Winogrande: An adversarial winograd schema challenge at scale”. In: *Communications of the ACM* 64.9 (2021), pp. 99–106.
- [67] Maarten Sap, Hannah Rashkin, Derek Chen, Ronan Le Bras, and Yejin Choi. “Social IQa: Commonsense Reasoning about Social Interactions”. In: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*. Ed. by Kentaro Inui, Jing Jiang, Vincent Ng, and Xiaojun Wan. Hong Kong, China: Association for Computational Linguistics, Nov. 2019, pp. 4463–4473. DOI: 10.18653/v1/D19-1454. URL: <https://aclanthology.org/D19-1454/>.
- [68] Siddhartha Satpathi and Rayadurgam Srikant. “The dynamics of gradient descent for overparametrized neural networks”. In: *Learning for Dynamics and Control*. PMLR. 2021, pp. 373–384.
- [69] Imanol Schlag, Kazuki Irie, and Jürgen Schmidhuber. “Linear transformers are secretly fast weight programmers”. In: *International Conference on Machine Learning*. PMLR. 2021, pp. 9355–9366.
- [70] JH Schmidhuber. “Learning to control fast-weight memories: An alternative to recurrent nets. Accepted for publication in”. In: *Neural Computation* (1992).
- [71] Jürgen Schmidhuber. “Reducing the ratio between learning complexity and number of time varying variables in fully recurrent nets”. In: *ICANN’93: Proceedings of the International Conference on Artificial Neural Networks Amsterdam, The Netherlands 13–16 September 1993* 3. Springer. 1993, pp. 460–463.
- [72] Jürgen Schmidhuber and Sepp Hochreiter. “Long Short-term Memory”. In: *Neural Computation MIT-Press* (1997).
- [73] Mark Schöne, Babak Rahmani, Heiner Kremer, Fabian Falck, Hitesh Ballani, and Jannes Gladrow. “Implicit Language Models are RNNs: Balancing Parallelization and Expressivity”. In: *arXiv preprint arXiv:2502.07827* (2025).
- [74] Jack Sherman and Winifred J Morrison. “Adjustment of an inverse matrix corresponding to a change in one element of a given matrix”. In: *The Annals of Mathematical Statistics* 21.1 (1950), pp. 124–127.
- [75] Julien Siems, Timur Carstensen, Arber Zela, Frank Hutter, Massimiliano Pontil, and Riccardo Grazi. “DeltaProduct: Increasing the Expressivity of DeltaNet Through Products of Householders”. In: *arXiv preprint arXiv:2502.10297* (2025).
- [76] Jimmy T.H. Smith, Andrew Warrington, and Scott Linderman. “Simplified State Space Layers for Sequence Modeling”. In: *The Eleventh International Conference on Learning Representations*. 2023. URL: <https://openreview.net/forum?id=Ai8Hw3AXqks>.
- [77] Yu Sun, Xinhao Li, Karan Dalal, Jiarui Xu, Arjun Vikram, Genghan Zhang, Yann Dubois, Xinlei Chen, Xiaolong Wang, Sanmi Koyejo, et al. “Learning to (learn at test time): Rnns with expressive hidden states”. In: *arXiv preprint arXiv:2407.04620* (2024).
- [78] Yutao Sun, Li Dong, Shaohan Huang, Shuming Ma, Yuqing Xia, Jilong Xue, Jianyong Wang, and Furu Wei. “Retentive network: A successor to transformer for large language models”. In: *arXiv preprint arXiv:2307.08621* (2023).
- [79] W Scott Terry. *Learning and memory: Basic principles, processes, and procedures*. Routledge, 2017.
- [80] Matteo Tiezzi, Michele Casoni, Alessandro Betti, Tommaso Guidi, Marco Gori, and Stefano Melacci. “On the resurgence of recurrent models for long sequences: Survey and research opportunities in the transformer era”. In: *arXiv preprint arXiv:2402.08132* (2024).
- [81] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. “Attention is All you Need”. In: *Advances in Neural Information Processing Systems*. Ed. by I. Guyon, U. Von Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett. Vol. 30. Curran Associates, Inc., 2017. URL:

https://proceedings.neurips.cc/paper_files/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf.

- [82] Johannes Von Oswald, Maximilian Schlegel, Alexander Meulemans, Seijin Kobayashi, Eyvind Niklasson, Nicolas Zucchet, Nino Scherrer, Nolan Miller, Mark Sandler, Max Vladymyrov, et al. “Uncovering mesa-optimization algorithms in transformers”. In: *arXiv preprint arXiv:2309.05858* (2023).
- [83] Ke Alexander Wang, Jiaxin Shi, and Emily B Fox. “Test-time regression: a unifying framework for designing sequence models with associative memory”. In: *arXiv preprint arXiv:2501.12352* (2025).
- [84] Kaiyue Wen, Xingyu Dang, and Kaifeng Lyu. “Rnns are not transformers (yet): The key bottleneck on in-context retrieval”. In: *arXiv preprint arXiv:2402.18510* (2024).
- [85] Bernard Widrow and Marcian E Hoff. *Adaptive switching circuits*. 1988.
- [86] David J Willshaw, O Peter Buneman, and Hugh Christopher Longuet-Higgins. “Non-holographic associative memory”. In: *Nature* 222.5197 (1969), pp. 960–962.
- [87] Songlin Yang, Jan Kautz, and Ali Hatamizadeh. “Gated Delta Networks: Improving Mamba2 with Delta Rule”. In: *arXiv preprint arXiv:2412.06464* (2024).
- [88] Songlin Yang, Bailin Wang, Yikang Shen, Rameswar Panda, and Yoon Kim. “Gated Linear Attention Transformers with Hardware-Efficient Training”. In: *Forty-first International Conference on Machine Learning*. 2024. URL: <https://openreview.net/forum?id=ia5XvxFUJT>.
- [89] Songlin Yang, Bailin Wang, Yu Zhang, Yikang Shen, and Yoon Kim. “Parallelizing linear transformers with the delta rule over sequence length”. In: *Advances in Neural Information Processing Systems* 37 (2024), pp. 115491–115522.
- [90] Rowan Zellers, Ari Holtzman, Yonatan Bisk, Ali Farhadi, and Yejin Choi. “HellaSwag: Can a Machine Really Finish Your Sentence?” In: *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*. Ed. by Anna Korhonen, David Traum, and Lluís Marquez. Florence, Italy: Association for Computational Linguistics, July 2019, pp. 4791–4800. DOI: 10.18653/v1/P19-1472. URL: <https://aclanthology.org/P19-1472/>.
- [91] Yufeng Zhang, Boyi Liu, Qi Cai, Lingxiao Wang, and Zhaoran Wang. “An analysis of attention via the lens of exchangeability and latent variable models”. In: *arXiv preprint arXiv:2212.14852* (2022).

A 补充相关工作

现代线性循环神经网络²。近期研究致力于缓解变换器（Transformer）模型在处理长上下文序列时的二次计算复杂度及其固有局限性。这推动了高效循环替代方案的发展，其主要动机在于其快速的推理和训练能力（Tiezzi 等，2024）。该领域的早期进展，以 RetNet（Sun, Dong 等，2023）、RWKV（Peng, Alcaide 等，2023）和 S5（Smith 等，2023）等模型为代表，采用了数据无关的转移矩阵与类赫布（Hebbian）更新机制相结合。随后，第二代模型出现，在这些线性架构中引入了输入相关参数（例如，线性循环神经网络（Hasani 等，2023；Smith 等，2023）、RWKV6（Peng, Goldstein 等，2024））。这些模型还探索了更具表达力的记忆更新规则，尤其是基于增量规则（delta rule）的更新（Liu, Wang 等，2024；Peng, Zhang 等，2025；Schlag 等，2021；Yang, Kautz 等，2024；Yang, Wang, Zhang 等，2024）。该研究方向的进一步演进将这些记忆架构扩展至更深层模型，同时利用类增量规则的更新机制（Sun, Li 等，2024）或基于数据相关动量且带遗忘门控的更新规则（Behrouz, Zhong 等，2024）。最近，为提升基于增量规则的序列模型的性能，Siems 等（2025）提出对每个词元应用多次梯度下降更新，从而产生更具表达力的序列模型，尤其在状态跟踪任务中。除上述快速线性循环序列模型外，若干研究聚焦于具有非线性循环的循环神经网络（Behrouz, Razaviyayn 等，2025；Csordás 等，2024；Gonzalez 等，2024；Karami 等，2025；Lim 等，2024；Merrill 等，2024；Schöne 等，2025；Von Oswald 等，2023），以及如何加速其训练（Gonzalez 等，2024；Lim 等，2024；Schöne 等，2025）。

快速权重程序。将线性层概念化为键值联想记忆系统可追溯至霍普菲尔德网络（Hopfield Networks）（Hopfield 1982）。该概念随后在快速权重编程器的背景下得到发展，其中动态快速程序被集成到循环神经网络中，作为可写的记忆存储（Schlag et al. 2021; Schmidhuber 1992; Schmidhuber 1993）。在此类系统的学习范式中，赫布学习（Hebbian Learning）（Hebb 2005）和增量规则（Delta Rule）（Prados et al. 1989）最为突出。这两种学习规则在现有文献中均得到了广泛研究（Irie et al. 2021; Munkhdalai, Sordoni, et al. 2019; Munkhdalai and Yu 2017; Schlag et al. 2021; Schmidhuber 1992; Yang, Kautz, et al. 2024; Yang, Wang, Zhang, et al. 2024）。

霍普菲尔德网络。本文的公式在架构上基于联想记忆的广义概念，其主要目标是学习键与值之间的底层映射。Hopfield（1982）关于霍普菲尔德网络的开创性工作引入了最早明确基于联想记忆的神经架构之一，通过最小化能量函数来存储键值对。尽管传统霍普菲尔德网络近年来适用性有所下降，主要由于向量值记忆容量的限制及其能量函数的性质，但若干当代研究致力于通过各种方法增强其容量。这些包括 Krotov（2021）、Li, Li, et al.（2024）以及 Krotov and Hopfield（2016）的工作。值得注意的是，对这些模型能量函数的扩展，通常引入指数核函数，已被探索（Krotov and Hopfield 2016; Lucibello et al. 2024）。此外，这些现代化霍普菲尔德网络与变换器（Transformer）架构之间的关系已成为近期研究的主题（Hu et al. 2024; Ramsauer et al. 2021）。

B Miras 框架

如前所述，Behrouz, Razaviyayn, et al.（2025）将联想记忆的概念形式化为：

定义 2（Behrouz, Razaviyayn, et al.（2025））。给定一组键 $K \subseteq \mathbb{R}^{d_k}$ 和值 $V \subseteq \mathbb{R}^{d_v}$ ，联想记忆是一个映射 $M: K \rightarrow V$ 。学习联想记忆基于一个目标 L ，称为注意力偏差，它决定了记忆的类型及其优先级：

$$M^* = \arg \min_M \mathcal{L}(M(K); V). \quad (44)$$

² 注意，此处术语“线性”指的是其快速的训练和推理过程。这并非指其循环公式，因为某些模型如 Titans（Behrouz, Zhong, et al. 2024）、Yaad、Moneta、Memora（Behrouz, Razaviyayn, et al. 2025）和 TTT（Sun, Li, et al. 2024）基于非线性循环，但在训练和推理上速度很快。

使用迭代算法（如梯度下降）优化该目标可得到记忆更新规则。因此，该序列模型是一个具有两个优化层次的元上下文学习器：1. 内层循环：优化记忆模块的参数（即 $\theta_M = \{W_1, W_2, \dots, W_{\mathcal{L}_M, \dots}\}$ ）。在内层优化循环中，模型的所有其他参数被视为超参数，固定且不参与优化。

2. 外循环：优化模型的所有其他参数，例如线性投影、多层感知机层、卷积等。

B.1 示例

例如，可以将线性注意力定义为使用梯度下降优化点积相似度：即 $\tilde{\ell}_t := \langle M_{t-1} \mathbf{k}_t, \mathbf{v}_t \rangle$ 。也就是说，

$$\mathcal{M}_t = \mathcal{M}_{t-1} - \eta_t \nabla \tilde{\ell}_t(\mathcal{M}_{t-1}; \mathbf{k}_t, \mathbf{v}_t) = \mathcal{M}_{t-1} - \eta_t \nabla \langle \mathcal{M}_{t-1} \mathbf{k}_t, \mathbf{v}_t \rangle \quad (45)$$

$$= \mathcal{M}_{t-1} + \eta_t \mathbf{v}_t \mathbf{k}_t^\top. \quad (46)$$

另一个例子是，如果使用回归损失而非点积相似度，则可得到 DeltaNet (Schlag 等人, 2021)：

$$\mathcal{M}_t = \mathcal{M}_{t-1} - \eta_t \nabla \|\mathcal{M}_t \mathbf{k}_t - \mathbf{v}_t\|_2^2 = \mathbf{I} - \eta_t \mathbf{k}_t \mathbf{k}_t^\top \mathcal{M}_{t-1} + \mathbf{v}_t \mathbf{k}_t^\top. \quad (47)$$

C 支撑性证明

命题 1 (ℓ_2 注意力偏差的容量)。设 M 为具有 $d_v \times d_k$ 个参数的矩阵值记忆，其通过梯度下降优化内部目标 $\ell(M_t; \mathbf{k}_t, \mathbf{v}_t) = \|\mathcal{M}_t \mathbf{k}_t - \mathbf{v}_t\|_2^2$ 。 M 最多可存储 $O(d_k)$ 对具有线性无关键的 $(\mathbf{k}_i, \mathbf{v}_i)$ 的映射。

证明。设 $K = [\mathbf{k}_1 \ \dots \ \mathbf{k}_m] \in \mathbb{R}^{d_k \times m}$ 且 $V = [\mathbf{v}_1 \ \dots \ \mathbf{v}_m] \in \mathbb{R}^{d_v \times m}$ 。优化问题变为最小化 Frobenius 范数 $\|MK - V\|_F^2$ 。精确记忆需要求解线性方程组 $MK = V$ 。

将表达式向量化得到方程组 $(K^\top \otimes I_{d_v}) \text{vec}(M) = \text{vec}(V)$ ，该方程组有 md_v 个标量方程和 $d_k d_v$ 个未知数。当键线性无关时， $\text{rank}(K) = m$ ，因此系统矩阵具有满行秩 md_v 。因此可解性要求 $md_v \leq d_k d_v$ ，或等价地 $m \leq d_k$ 。这与线性联想存储器（如 Willshaw 模型和 Hopfield 网络）的存储容量经典结果一致，其中容量与输入嵌入的秩相关 (Hopfield 1982; Willshaw 等人, 1969)。

当 $m \leq d_k$ 且 K 具有满列秩时，可以通过 Moore-Penrose 伪逆构造精确插值解： $M^* = VK^\top$ 。则 $M^*K = VK^\top K = V$ ，实现零训练误差。因此上界是紧的。

此外，在该目标上以步长 $0 < \eta < 2/\lambda_{\max}(KK^\top)$ 进行全批量梯度下降，可得到迭代 $M_{t+1} = M_t - \eta(M_t K - V)K^\top$ ，当 $m \leq d_k$ 时，其收敛到最小范数插值解 $M^\dagger = VK^\top$ 。这是过参数化线性模型中梯度下降的一个众所周知的隐式偏置 (Satpathi 等人, 2021)。

最后，同样的基于秩的约束支配着线性或多头注意力模块的容量。在此类架构中，输出上下文矩阵的秩至多为 $\text{rank}(K) \leq d_k$ ，这直接限制了它们的表达能力。近期分析将这种“低秩瓶颈”视为变换器 (Transformer) 中的容量限制效应 (Bhojanapalli 等人, 2020)。□

定理 1 (深度记忆的效果)。设 $M(\cdot)$ 为具有 $\mathcal{L}_M \geq 2$ 层、 d_k 输入维度和 d_h 隐藏维度的多层感知机 (MLP)。则 $M(\cdot)$ 至少可存储 $O(d_k d_v)$ 个、至多 $O\left(d_k d_v \sum_{i=1}^{\mathcal{L}_M} \min\{d_h^{(j)}\}_{j \geq i} d_h^{(j+1)}\right)$ 具有线性无关键的 $(\mathbf{k}_i, \mathbf{v}_i)$ 的映射。

早期理论工作已确立，即使是简单的网络架构也能记忆大量的输入输出映射，其容量通常与网络参数（例如权重和偏差）的数量及输入维度相关 (Baum, 1988; Cover, 1965; Huang, 2003)。例如，Baum (1988) 证明， $\frac{N}{d}$ 个神经元足以使具有阈值单元的单隐层网络从 $\mathbb{R}^d$ 中记忆 N 个输入-标签对。

采用修正线性单元（ReLU）的网络表现出分段仿射行为。输入空间被划分为众多线性区域，在每个区域内，网络计算不同的仿射变换（Montufar 等人，2014；Pascanu 等人，2014）。这种结构对于分析其表达能力和存储容量至关重要。深度、宽度、线性区域数量与最终存储特定键值关联（尤其是在键线性独立等约束下）的能力之间的精确关系，仍是一个活跃的研究领域。

证明。设 m 表示 M 精确记忆的 $(\mathbf{k}_i, \mathbf{v}_i)$ 对的数量，并假设键 $\{\mathbf{k}_i\}_{i=1}^m \subset \mathbb{R}^{d_k}$ 线性独立。设 $d_h^{(0)} := d_k, d_h^{(\mathcal{L}_M)} := d_v$ ，对于每一层 $1 \leq \ell \leq \mathcal{L}_M$ ，定义 $W^{(\ell)} \in \mathbb{R}^{d_h^{(\ell)} \times d_h^{(\ell-1)}}$ 。为简单起见，省略偏差。

由于 $\sigma(x) = \max(0, x)$ 是分段线性的，线性映射与 ReLU 激活的复合产生分段仿射函数。对于任何固定的激活模式（即预激活符号固定），多层感知机（MLP）的作用为：

$$\mathcal{M}(\cdot) = A \cdot + B, \quad \text{其中 } A = W^{(\mathcal{L}_M)} D^{(\mathcal{L}_M-1)} W^{(\mathcal{L}_M-1)} \dots D^{(1)} W^{(1)},$$

且每个 $D^{(\ell)}$ 是一个对角 $\{0, 1\}$ 矩阵，用于选择活跃单元。因此，当所有键落入同一线性区域时（在小扰动后通常会发生）， M 是一个单一的仿射变换。并且

$$\text{Let } \mathbf{K} := [\mathbf{k}_1 \dots \mathbf{k}_m] \in \mathbb{R}^{d_k \times m} \quad \mathbf{V} := [\mathbf{v}_1 \dots \mathbf{v}_m] \in \mathbb{R}^{d_v \times m} \text{ 精确记忆意味着 } \quad \mathbf{AK} = \mathbf{V}, \text{ so:}$$

$$\text{rank}(\mathbf{V}) \leq \text{rank}(\mathbf{A}), \quad m = \text{rank}(\mathbf{K}) \leq \min\{\text{rank}(\mathbf{A}), d_k\}.$$

现在观察到：

$$A = W^{(\mathcal{L}_M)} \underbrace{D^{(\mathcal{L}_M-1)} W^{(\mathcal{L}_M-1)} \dots D^{(1)} W^{(1)}}_{R_{\mathcal{L}_M-1}},$$

因此， A 的秩受每条路径上遇到的最小宽度乘以直接输入维度的限制：

$$\text{rank}(A) \leq \sum_{i=1}^{\mathcal{L}_M} \left(\min_{j \geq i} d_h^{(j)} \right) d_h^{(i)} = O \left(d_k d_v \sum_{i=1}^{\mathcal{L}_M} \min_{j \geq i} d_h^{(j)} d_h^{(i+1)} \right).$$

因此，

$$m \leq O \left(d_k d_v \sum_{i=1}^{\mathcal{L}_M} \min_{j \geq i} d_h^{(j)} d_h^{(i+1)} \right)$$

□

命题 2（多项式映射下的记忆容量）。 令 $\phi_p(\cdot)$ 为次数至多为 p 的多项式映射， M 为通过梯度下降优化 $\ell(\mathcal{M}_t; \phi_p(\mathbf{k}_t), \mathbf{v}_t) = \|\mathbf{M}_t \phi_p(\mathbf{k}_t) - \mathbf{v}_t\|_2^2$ 内部目标的矩阵值记忆。 M 最多能够存储 $O(d_k^p)$ 对具有线性无关键的 $(\mathbf{k}_i, \mathbf{v}_i)$ 映射，其中 d_k 为键 $\mathbf{k}_i$ 的维度。

证明。首先分析由 ϕ_p 诱导的提升特征空间的维度。一个总次数恰好为 ℓ 的 d_k 元单项式具有形式 $\mathbf{k}^\alpha = \prod_{j=1}^{d_k} k_j^{\alpha_j}$ ，其中 $\alpha \in \mathbb{N}^{d_k}$ 且 $|\alpha| := \sum_{j=1}^{d_k} \alpha_j = \ell$ 。此类单项式的数量由经典的星条公式给出，该公式计算 $\alpha_1 + \dots + \alpha_{d_k} = \ell$ 的整数解个数，得到 $d_k + \ell - 1$

$$\binom{d_k + \ell - 1}{\ell}.$$

对所有次数 $\ell =$ 从 0 到 p 求和, 得到单项式总数 (即 ϕ_p), 的输出维度)

$$D = \sum_{\ell=0}^p \binom{d_k + \ell - 1}{\ell} = \binom{d_k + p}{p},$$

其中最后一个恒等式由组合数学中的曲棍球棒恒等式得出。

为了刻画记忆容量, 我们用矩阵符号重新表述损失。设 $\Phi := [\phi_p(\mathbf{k}_1) \ \cdots \ \phi_p(\mathbf{k}_m)] \in \mathbb{R}^{D \times m}$ 且 $V := [\mathbf{v}_1 \ \cdots \ \mathbf{v}_m] \in \mathbb{R}^{d_o \times m}$ 。则目标变为

$$L(\mathcal{M}) = \frac{1}{2} \|\mathcal{M}\Phi - V\|_2^2.$$

精确记忆等价于存在矩阵 $\mathcal{M}$ 使得 $\mathcal{M}\Phi = V$ 。这是一个线性系统, 其中 $\mathcal{M}$ 作用于 Φ 的列, 因此 Φ 的秩必然限制了能够被精确拟合的独立目标 $\mathbf{v}_i$ 的数量。

根据秩的次可乘性, 对于任意矩阵 A 和 B , 有

$$\text{rank}(AB) \leq \min\{\text{rank}(A), \text{rank}(B)\}.$$

将其应用于 $\mathcal{M}\Phi$ 可得

$$\text{rank}(\mathcal{M}\Phi) \leq \text{rank}(\Phi) \leq D.$$

现在考虑目标 $\mathbf{v}_1, \dots, \mathbf{v}_m$ 线性无关的情形; 例如, 取 $V = [e_1, \dots, e_m]$, 即前 m 个标准基向量。则 $\text{rank}(V) = m$ 。若 $m > D$, 则对任意 $\mathcal{M}$ 的选择都必然有 $\text{rank}(\mathcal{M}\Phi) < \text{rank}(V)$, 这意味着系统 $\mathcal{M}\Phi = V$ 无解。因此, 损失保持严格正, 精确记忆不可能实现。

这表明, 在次数为 $\leq p$ 的多项式提升下, 无论采用何种优化方法, 都无法记忆超过 $D = \binom{d_k+p}{p}$ 个独立的输入-输出对。由于对于固定的 p 有 $\binom{d_k+p}{p} = \Theta(d_k^p)$, 结论成立: 记忆容量上界为 $O(d_k^p)$. $\square$

D 所有架构的详细公式

本节为清晰起见, 讨论全文涉及的所有架构的细节:

D.1 深度线性注意力 (Deep Linear Attention, DLA)

我们设计了深度线性注意力 (Deep Linear Attention, DLA) ——一种使用深度多层感知机作为记忆 (键值缓存) 的线性注意力模块——作为本研究的基线之一。给定输入 $\mathbf{x} \in \mathbb{R}^{N \times d_{in}}$, 我们将输入投影为键、值和查询矩阵:

$$\mathbf{Q} = \begin{pmatrix} \mathbf{q}_1 \\ \vdots \\ \mathbf{q}_N \end{pmatrix} = \mathbf{x}\mathbf{W}_Q, \quad \mathbf{K} = \begin{pmatrix} \mathbf{k}_1 \\ \vdots \\ \mathbf{k}_N \end{pmatrix} = \mathbf{x}\mathbf{W}_K, \quad \mathbf{V} = \begin{pmatrix} \mathbf{v}_1 \\ \vdots \\ \mathbf{v}_N \end{pmatrix} = \mathbf{x}\mathbf{W}_V, \quad (48)$$

其中 $\mathbf{W}_Q, \mathbf{W}_K$, 和 $\mathbf{W}_V$ 是可学习的线性层。然后, 我们将记忆定义为一个学习模块, 该模块使用梯度下降优化内积相似度: 即,

$$\min_{\mathcal{M}} \underbrace{\langle \mathcal{M}(\mathbf{k}_t), \mathbf{v}_t \rangle}_{\ell(\mathcal{M}_{t-1}; \mathbf{k}_t, \mathbf{v}_t)}. \quad (49)$$

上述使用梯度下降的优化得到以下递推式 (我们还添加了带有输入依赖参数 α_t 的权重衰减

$$\mathcal{M}_t = \alpha_t \mathcal{M}_{t-1} - \eta_t \nabla \ell(\mathcal{M}_{t-1}; \mathbf{k}_t, \mathbf{v}_t) \quad (50)$$

在线性记忆的情况下 (即 $\mathcal{M}_t = W_t \in \mathbb{R}^{d \times d}$), 它变为:

$$W_t = \alpha_t W_{t-1} + \mathbf{v}_t \mathbf{k}_t^\top, \quad (51)$$

这就是门控线性注意力的公式。我们使用与其他模型相同的训练过程 (见第 3.3 节)。

D.2 滑动窗口线性注意力 (SWLA)

SWLA 的设计与 DLA 的设计相同，但使用了滑动窗口目标。即，给定键、值和查询：

$$\mathbf{Q} = \begin{pmatrix} \mathbf{q}_1 \\ \vdots \\ \mathbf{q}_N \end{pmatrix} = \mathbf{x}\mathbf{W}_Q, \quad \mathbf{K} = \begin{pmatrix} \mathbf{k}_1 \\ \vdots \\ \mathbf{k}_N \end{pmatrix} = \mathbf{x}\mathbf{W}_K, \quad \mathbf{V} = \begin{pmatrix} \mathbf{v}_1 \\ \vdots \\ \mathbf{v}_N \end{pmatrix} = \mathbf{x}\mathbf{W}_V, \quad (52)$$

我们优化以下内部目标：

$$\underbrace{\sum_{i=t-c+1}^t \langle \mathcal{M}_{t-1}(\mathbf{k}_i), \mathbf{v}_i \rangle}_{\ell(\mathcal{M}_{t-1}; \mathbf{k}_t, \mathbf{v}_t)}. \quad (53)$$

最小化 M

上述公式可推导出：

$$\mathcal{M}_t = \alpha_t \mathcal{M}_{t-1} - \nabla \ell(\mathcal{M}_{t-1}; \mathbf{k}_t, \mathbf{v}_t) = \alpha_t \mathcal{M}_{t-1} - \sum_{i=t-c+1}^t \eta_i^{(t)} \nabla \langle \mathcal{M}_{t-1}(\mathbf{k}_i), \mathbf{v}_i \rangle, \quad (54)$$

在线性记忆的情况下（即 $\mathcal{M}_t = \mathbf{W}_t \in \mathbb{R}^{d \times d}$ ），它变为：

$$\mathcal{M}_t = \alpha_t \mathcal{M}_{t-1} - \sum_{i=t-c+1}^t \eta_i^{(t)} \mathbf{v}_i \mathbf{k}_i^\top. \quad (55)$$

D.3 OmegaNet

在 OmegaNet 的设计中，我们将点积相似度目标替换为 $\ell(\mathcal{M}_{t-1}; \mathbf{k}_t, \mathbf{v}_t) = \sum_{i=t-c+1}^t \|\mathcal{M}_{t-1}(\phi(\mathbf{k}_i)) - \mathbf{v}_i\|_2^2$ ，从而得到如下递推关系：

$$\mathcal{M}_t = \alpha_t \mathcal{M}_{t-1} - \nabla \ell(\mathcal{M}_{t-1}; \mathbf{k}_t, \mathbf{v}_t) = \alpha_t \mathcal{M}_{t-1} - \sum_{i=t-c+1}^t \eta_i^{(t)} \nabla \|\mathcal{M}_{t-1}(\phi(\mathbf{k}_i)) - \mathbf{v}_i\|_2^2. \quad (56)$$

在上述公式中， $\phi(\cdot)$ 是多项式特征映射函数。

D.4 Atlas

在 Atlas 中，我们采用与 OmegaNet 相同的内部目标，但使用 Muon 优化器（Jordan 等人，2024）并加入权重衰减进行优化。即，

$$\mathcal{M}_t = \alpha_t \mathcal{M}_{t-1} + \text{Newton-schulz5}(\mathcal{S}_t) \quad (57)$$

$$\mathcal{S}_t = \theta_t \mathcal{S}_{t-1} - \sum_{i=t-c+1}^t \eta_i^{(t)} \nabla \|\mathcal{M}_{t-1}(\phi(\mathbf{k}_i)) - \mathbf{v}_i\|_2^2. \quad (58)$$

E 实验细节

在实验设置中，我们遵循近期关于线性循环模型的研究（Behrouz, Razaviyayn 等人，2025；Behrouz, Zhong 等人，2024；Yang, Kautz 等人，2024），使用 Wikitext（Merity 等人，2017）、LMB（Paperno 等人，2016）、PIQA（Bisk 等人，2020）、HellaSwag（Zellers 等人，2019）、WinoGrande（Sakaguchi 等人，2021）、ARC-easy（ARC-e）和 ARC-challenge（ARC-c）（Clark, Cowhey 等人，2018）、SIQA（Sap 等人，2019）以及 BoolQ（Clark, Lee 等人，2019）。此外，基线结果来自 Behrouz, Razaviyayn 等人（2025）和 Behrouz, Zhong 等人（2024）。在训练中，我们使用 T5 分词器，词汇量为 32K，训练长度为 4K 个标记（SWA 为 2K）。我们采用 AdamW 优化器，学习率为 4×10^{-4} ，使用余弦退火调度，批大小为 0.5M 个标记，权重衰减为 0.1。架构

表 7: 架构细节。

Model	Block	Dim	Head	Peak LR	Token
170M	12	768	16	3e-3	15B
340M	24	1024	16	1.5e-3	15B
760M	24	1536	16	1.25e-3	30B
1.3B	18	2048	8	7e-4	100B

细节同样见表 7。1.3B 的基线结果来自 Yang, Kautz 等人 (2024) , 760M 的基线结果来自 Behrouz, Razaviyayn 等人 (2025) 以及 Behrouz, Zhong 等人 (2024) 。

对于记忆架构, 除非另有说明, 我们使用一个具有 2 层、扩展因子为 4、采用 GELU 激活函数 (Hendrycks 等人, 2016) 的多层感知机。我们还在每个块末尾使用残差连接和层归一化:
 $\mathcal{M}(x) = x + W_1 \sigma(W_2 x)$.

F 附加实验结果

在本节中, 我们提供附加实验结果, 以支持模型设计、理解不同组件的影响, 并评估它们在长上下文、上下文召回和 MAD 任务中的性能。

F.1 语言建模与常识推理 (小规模)

在第 6 节中, 我们展示了语言建模和常识推理任务的部分结果。在本节中, 我们进一步报告所有规模模型的结果。结果见表 8。

最先进的结果。考察阿特拉斯 (Atlas) 与欧米茄网络 (OmegaNet) 的性能, 两种架构相较于现代线性循环模型和变换器 (Transformer) 均表现优异, 在困惑度上更低, 下游任务准确率更高。即便是这些模型的全循环版本, 也优于桑巴 (Samba, Ren 等人, 2024) 和门控德尔塔网络-H2 (Gated DeltaNet-H2, Yang, Kautz 等人, 2024) 等混合模型。采用 MAG 与 MAL 的混合变体进一步提升了阿特拉斯的性能, 这表明循环长期记忆与注意力具有互补作用。

设计的影响。比较阿特拉斯、欧米茄网络以及基线 SWLA 和 DLA 的性能, 可以看出 ℓ_2 回归损失作为注意力偏差的作用。此外, SWLA 相较于 GLA 和 RetNet 的更好性能表明, 记忆上下文而非记忆单个词元的重要性。

表 8: 阿特拉斯及基线在语言建模和常识推理任务上的性能。最佳结果以高亮显示。

Model	Wiki. ppl ↓	LMB. ppl ↓	LMB. acc ↑	PIQA acc ↑	Hella. acc_n ↑	Wino. acc ↑	ARC-e acc ↑	ARC-c acc_n ↑	SIQA acc ↑	BoolQ acc ↑	Avg. ↑
340M params / 15B tokens											
Transformer++	31.52	41.08	30.76	62.98	34.76	50.53	45.21	24.05	36.81	58.24	42.92
RetNet	32.50	49.73	28.24	62.61	34.15	50.91	44.27	23.62	36.79	59.72	42.54
GLA	28.51	43.02	28.73	64.05	35.96	50.00	54.19	24.29	37.13	58.39	44.09
Mamba	30.83	40.21	29.94	63.79	35.88	49.82	49.24	24.56	35.41	60.07	43.59
DeltaNet	28.65	47.30	28.43	63.52	35.95	49.63	52.68	25.37	37.96	58.79	44.04
TTT	27.44	34.19	30.06	63.97	35.71	50.08	53.01	26.11	37.32	59.83	44.51
Gated DeltaNet	27.01	30.94	34.11	63.08	38.12	51.60	55.28	26.77	34.89	59.54	45.42
MONETA	26.19	29.31	35.70	63.99	39.23	52.04	55.96	27.15	37.29	60.22	46.44
YAAD	26.61	29.11	34.09	64.93	39.86	51.12	54.75	28.64	33.82	60.29	45.93
MEMORA	27.16	30.44	33.68	65.21	39.17	51.23	53.40	27.99	34.1	59.29	45.51
DLA (ours)	27.93	35.09	30.8	62.9	36.2	50.4	53.5	26.7	37.1	59.7	44.76
SWDT (ours)	26.98	33.95	32.4	63.1	38.2	50.9	54.9	25.9	37.5	59.6	45.31
OMEGANET (ours)	26.03	28.76	35.6	65.3	39.7	52.0	56.1	28.6	37.7	60.4	46.93
ATLAS (ours)	25.88	28.54	36.1	64.9	40.1	52.7	56.4	28.8	38.1	61.2	47.28