

首先，学习你所未知的：面向操控极限驾驶的主动信息收集

Alexander Davydov^{1,2}, Franck Djeumou^{2,3}, Marcus Greiff²,
Makoto Suminaka², Michael Thompson², John Subosits², and Thomas Lew²

摘要——将在线自适应数据驱动模型与模型预测控制（MPC）相结合，已实现对非线性系统的有效控制。然而，当部署于不稳定系统时，在线自适应可能不够迅速，难以确保学习与控制同时可靠进行。例如，执行高动态机动（如漂移避障）的车辆控制器可能将轮胎推至摩擦极限，导致车辆失稳，使建模误差迅速累积并引发失控。为应对这一挑战，本文提出一种主动信息收集框架，旨在尽可能快速地辨识车辆动力学。本文提出一种表达力强的车辆动力学模型，利用贝叶斯最后一层元学习实现快速在线自适应。该模型的不确定性估计用于指导信息性数据收集，并在部署前快速改进模型。在丰田 Supra 上进行的动态漂移实验表明：(i) 该框架能够在稳定性边缘实现车辆的可靠控制；(ii) 仅靠在线自适应可能不足以实现零样本控制，并可能导致不良的瞬态误差或失控旋转；(iii) 主动数据收集有助于实现可靠性能。

I. 引言

控制不稳定的非线性系统仍然具有挑战性 [1]。例如，驾驶车辆进行动态且不稳定的漂移操作是一项困难的任务，其中轻微的决策失误可能导致失控旋转或碰撞。近年来，先进的控制方法已被开发出来，赋予自动驾驶汽车利用其全部操控极限的能力 [2] – [6]，并可能应用于未来高级驾驶辅助系统和自动驾驶安全系统的设计。在此背景下，数据驱动模型预测控制（MPC）方法因其高性能、使用表达性学习模型的能力以及考虑执行器极限和避障等约束的能力而广受欢迎 [7]。特别是，利用在线数据自适应调整的数据驱动模型可以减少部署时的模型误差和仿真到现实的差异 [8] – [11]。然而，同时控制和学习不稳定系统是出了名的困难。例如（见第五节），成功执行漂移操作需要足够精确的初始模型来精确启动漂移，仅靠在线自适应可能不足以执行该操作。




图 1：我们提出了一种主动信息收集框架，该框架引导数据收集，以便在受控（即安全）环境中快速学习模型。基于这些信息丰富的数据进行自适应，能够在动态漂移轨迹中实现可靠控制。相比之下，在部署前直接使用模型而不进行自适应可能导致不可靠的控制性能，例如失控旋转。

自动驾驶在极限工况下对具有在线自适应的数据驱动 MPC 提出了挑战，因为其快节奏特性和所执行操作的固有稳定性不足。这些困难引发了以下问题：我们如何有效识别不确定的非线性动力学，以确保后续控制可靠？如何高效且安全地收集信息丰富的数据，以最小化耗时且可能昂贵的硬件测试？

贡献：我们提出了一种主动信息收集框架，用于快速识别非线性动力学，以便后续在模型预测控制（MPC）中可靠部署。具体而言：• 我们提出了一种数据驱动的动力学模型，专为在操控极限下驾驶而定制。该模型将先验物理知识与学习到的表达性神经网络特征相结合。通过仅调整最后一层，该数据驱动模型能够实现快速在线自适应，在控制不稳定系统时显著优于非自适应模型，因为在这些系统中，小的初始误差会迅速放大。• 为了在 MPC 框架中可靠部署学习到的模型，我们提出了一种部署前的主动学习方法，以尽可能快地识别出准确的模型，同时在数据收集过程中满足约束条件。• 我们在丰田 Supra 上对两种不同的动态漂移机动进行了广泛验证。特别是，结果表明，仅对元训练模型进行在线自适应可能不足以可靠地启动漂移，并可能导致跟踪误差出现大幅瞬态。

*A. Davydov 的工作在丰田研究所完成。¹ 莱斯大学机械工程系，休斯顿，德克萨斯州，美国 ² 丰田研究所，洛斯阿尔托斯，加利福尼亚州，美国 ³ 机械、航空航天与核工程系，伦斯勒理工学院，特洛伊，纽约州，美国

另一方面，所提出的主动信息收集方法能够快速识别系统动力学，并提高跟踪性能。从车辆控制的角度来看，我们的结果表明，通过在信息丰富的非漂移轨迹上自适应模型，可以执行漂移机动。具体而言，信息丰富的轨迹不一定涉及漂移，而在这些数据上进行自适应可以显著改善具有挑战性的漂移机动的执行。

II. 相关工作

数据驱动模型在控制领域日益流行，因其能够利用表达性强的模型，并根据系统测量数据在线调整模型，参见 [7] 和 [12] 的近期综述。例如，利用神经网络模型的模型预测控制（MPC）方法近年来在操控极限下的动态驾驶中得到了广泛应用 [4], [9] – [11]。这些方法在线调整模型时隐含假设模型在控制任务中能足够快地适应，从而获得令人满意的性能，但对于初始误差迅速放大的系统，这可能难以实现。主动寻求信息数据以改进模型的在线学习与控制算法 [13] – [20]，相比在执行任务时被动调整模型，通常能提升控制性能，并允许在数据收集过程中施加安全约束 [15], [20]。将此类主动学习方法用于控制不稳定非线性系统仍具挑战性。事实上，寻求信息数据（探索）与执行任务（利用）之间的权衡众所周知；不稳定系统尤其难以同时学习和控制 [21], [22]。这些权衡促使设计一个框架，在部署前于受控环境中进行主动学习，以最少的实验学习用于控制的模型。操控极限下的自动驾驶体现了这些权衡。在该应用中，车辆可能在接近道路边界的饱和轮胎力下运行，因此希望在部署前尽可能准确地辨识车辆动力学。以往操控极限下的驾驶方法利用基于物理 [5], [6] 和基于神经网络 [4], [9], [11] 的动力学模型进行 MPC。最近，[10] 引入了一种用于 MPC 的神经随机微分方程（SDE）动力学模型，其中 SDE 的参数从以在线观测为条件的扩散模型中采样，从而在任务执行期间实现被动在线适应。我们提出的主动学习框架补充了这些工作，能够在基于模型的控制部署前尽可能快地辨识不确定动力学。非线性系统辨识的主动学习方法包括最大化信息增益的方法 [16], [20], [23], [24]。我们的方法基于类似的信息论思想，以尽快辨识不确定动力学。我们利用贝叶斯建模方法 [25] 进行最后一元学习 [25] – [29]，这有利于信息收集 [20]。与操控极限下的驾驶相比




图 2：车辆的曲线坐标系，引自 [11]。

在操控方面，[16]、[20]、[24] 中的实验涉及模拟或慢速机器人系统，这些系统不面临控制和学习不稳定动力学的相同挑战。[23] 也研究了越野驾驶的主动探索，但使用了概率集成神经网络，与最后一元训练的神经网络模型相比计算成本更高，并且惩罚车辆侧滑，从而阻止执行漂移机动。此外，正如我们在第五节中所示，仅在线自适应可能不足以可靠地执行漂移机动，即使使用能够快速适应的元学习模型。

III. 贝叶斯车辆动力学模型

我们方法的核心是一个表达力强、能捕捉不确定性并支持快速在线自适应的车辆动力学模型。为此，我们将基于物理的标称自行车模型与贝叶斯最后一元学习模型相结合。前者编码了关于车辆的先前知识，而后者捕捉模型失配，并能在表达性神经网络特征上实现快速自适应。车辆状态在曲线坐标系中表示 [5], [11]，参见

图 2。与 [5]、[11] 一样，本文不使用制动输入。车辆的状态和控制输入为

$$x = (r, v, \beta, \omega_r, e, \Delta\varphi) \in \mathbb{R}^n, \quad u = (\delta, \tau) \in \mathbb{R}^m, \quad (1)$$

其中 $(n, m) = (6, 2)$ 是状态和控制维度， r 是横摆角速度， v 是总平面速度， β 是侧滑角， ω_r 是后轮速度， e 和 $\Delta\varphi$ 分别是相对于参考轨迹的横向偏差和角度偏差， δ 是转向角， τ 是发动机扭矩。车辆用离散时间动力学建模为

$$x_{k+1} = f_\xi(x_k, \tilde{u}_k) + \epsilon_k, \quad (2)$$

其中 $k \in \mathbb{N}$ 和 $\epsilon_k \sim \mathcal{N}(0, \text{diag}(\sigma_1^2, \dots, \sigma_n^2))$ 是高斯分布的扰动，在时间 k 和状态维度上相互独立。 ξ 表示动力学的未知参数（例如，对应于未建模现象）， $\tilde{u}_k = (u_k, \dot{u}_k)$ 包括在时间 k 的控制输入速率 $\dot{u}_k = (\dot{\delta}_k, \dot{\tau}_k)$ 。将 $\dot{u}_k$ 包含在 $\tilde{u}_k$ 和 (2) 中，是因为 MPC 计划 $(u_0, u_1, \dots, u_N)$ 由低级控制器通过控制时域上的线性插值执行。即， $u(k\Delta t + \tau) = u_k + \tau\dot{u}_k$ ，时间步长为 Δt ，且 $\dot{u}_k = (u_{k+1} - u_k)/\Delta t$ 对于 $\tau \in [0, \Delta t)$ 。我们使用模型近似动力学 (2)

$$x_{k+1} = h(x_k, u_k) + g(z_k) + \epsilon_k, \quad (3)$$

其中 h 是标准自行车模型的 Δt 时间步欧拉积分（详见附录 I）。式 (3) 中的残差 g 由 $g(z) = (g_1, \dots, g_n)(z)$ 建模，输入为

$$z_k = ((r_k, v_k, \beta_k, \omega_{r,k}), u_k, u_{k+1}),$$

且每个维度 i 在 $g(\cdot)$ 中对于某些参数 $\theta_i \in \mathbb{R}^d$ 是学习特征 $\phi_i(z) \in \mathbb{R}^d$ 的线性函数，即

$$g_i(z_k) := \theta_i^\top \phi_i(z_k), \quad i \in \{1, \dots, n\}. \quad (4)$$

我们省略变量 e 和 $\Delta \varphi$ ，因为它们不影响其他状态变量的动态，参见 [5]。也就是说，给定 (1) 中的状态，我们令 $(g_5, g_6)(z) = 0$ 对所有 z 成立。特征 $\phi_i(\cdot)$ 是神经网络，通过最后一层贝叶斯元学习 [20]、[25]、[30] 与参数 θ_i 联合学习，从而得到一个具有表达能力且能快速适应并给出不确定性估计的模型。具体而言，将 $g_i(z_k)$ 视为神经网络，最后一层参数 θ_i 用高斯分布参数化

$$\theta_i \sim \mathcal{N}(\bar{\theta}_i, \sigma_i^2 \Lambda_i^{-1}), \quad i \in \{1, \dots, n\}, \quad (5)$$

具有均值参数 $\bar{\theta}_i$ 和正定精度矩阵 Λ_i / σ_i^2 。遵循 [20]，我们对每个 θ_i 建模独立的高斯分布，使得最后一层参数 $(\theta_1, \dots, \theta_n)$ 的联合分布为高斯分布。计算后验： $g_i(z)$ 的线性结构使得能够通过贝叶斯线性回归计算最后一层参数 θ_i 。具体而言，给定先验分布 $\mathcal{N}(\bar{\theta}_{i,0}, \sigma_i^2 \Lambda_{i,0}^{-1})$ 对于 θ_i ，以及状态-控制轨迹 $\mathcal{D}_T = \{(z_k, x_{k+1})\}_{k=0}^T$ ，后验 $\theta_{i,T} | \mathcal{D}_T$ 是高斯分布，并且可以从 $Q_{i,0} = \Lambda_{i,0} \theta_{i,0}$ 递归计算

$$\Lambda_{i,k+1}^{-1} = \Lambda_{i,k}^{-1} - \frac{(\Lambda_{i,k}^{-1} \phi_i(z_k))(\Lambda_{i,k}^{-1} \phi_i(z_k))^\top}{1 + \phi_i(z_k)^\top \Lambda_{i,k}^{-1} \phi_i(z_k)}, \quad (6a)$$

$$Q_{i,k+1} = Q_{i,k} + (x_{i,k+1} - h_i(x_k, u_k)) \phi_i(z_k), \quad (6b)$$

$$\bar{\theta}_{i,k+1} = \Lambda_{i,k+1}^{-1} Q_{i,k+1}. \quad (6c)$$

此外，一步预测是高斯分布的，即 $x_{i,k+1} | x_{0:k}, \tilde{u}_{0:k} \sim \mathcal{N}(\mu_{i,k+1}, \Sigma_{i,k+1})$ ，其中

$$\mu_{i,k+1} = h_i(x_k, u_k) + \bar{\theta}_{i,k}^\top \phi_i(z_k), \quad (7a)$$

$$\Sigma_{i,k+1} = \sigma_i^2 (1 + \phi_i(z_k)^\top \Lambda_{i,k}^{-1} \phi_i(z_k)). \quad (7b)$$

利用所提出的模型，真实动态 f 与标称模型 h 之间通过 g 的不匹配被学习，使得一步预测按设计为高斯分布，从而便于元学习和信息收集。离线贝叶斯元训练：先验参数 $(\bar{\theta}_{i,0}, \Lambda_{i,0}^{-1})$ 、特征 ϕ_i 和噪声协方差缩放 σ_i^2 ，被离线预训练，以获得一个可通过更新规则 (6) 在线适应的表达模型。具体而言，给定对应于真实系统 (2) 不同参数 ξ 的 J 条轨迹数据集和元训练时域 T ，我们最小化负后验对数似然目标

$$\mathcal{L}_{\text{nil}}(\bar{\theta}, \Lambda, \phi, \sigma) = \sum_{j=1}^J \sum_{k=1}^T \|x_k^j - \mu_k^j\|_{(\Sigma_k^j)^{-1}}^2 + \log(\det(\Sigma_k^j)),$$




图 3：所提出的主动信息收集框架。

其中 $\|y\|_A^2 = y^\top A y$ 和 (μ_k^j, Σ_k^j) 表示在数据集 j 中时刻 $k-1$ 由式 (6) 计算的一步超前预测。后验参数通过更新规则获得这一事实，是学习有利于模型快速在线适应的表达性特征 ϕ 的关键。关于贝叶斯元学习的更多细节，参见 [20]、[25]、[30]。实现细节：我们以 10Hz 处理车辆状态数据，因此定义离散时间动力学 (2) 和模型 (3)，其中 $\Delta t = 0.1s$ 。我们发现自行车模型对轮速动力学的估计较差，因此通过设置 $h_4(x_k, u_k) = 0$ 来学习完整的轮速动力学。我们使用 [30] 中的代码训练模型。作为数据集，我们在成功和失败的手动与自主漂移数据混合集上训练，总计约 19 分钟驾驶数据。该数据对应 35 条不同轨迹，即 f_ξ 的实现，共包含 11382 个数据点。遵循 [11]，我们通过取横摆角速度、侧偏角和转向角的符号相反来模拟反向转弯，从而用镜像数据集扩充数据。这使数据集规模翻倍。对于架构，我们对每个 ϕ_i 使用双曲正切函数前馈神经网络，具有两个宽度为 128 的隐藏层，每个 θ_i 的维度为 16。遵循 [20]，我们在每个 ϕ_i 之间共享权重和偏差，除了最后一层的权重和偏差

$(W_{\text{out}}^i, b_{\text{out}}^i) \in \mathbb{R}^{16 \times 128} \times \mathbb{R}^{16}$ 。总共有 27012 个可训练参数，包括神经网络、先验参数、 $(\bar{\theta}_{i,0}, \Lambda_{i,0}^{-1})$ 和噪声协方差缩放 σ_i^2 。我们使用元训练时域 $T = 10$ ，并用 Adam 训练模型，初始学习率为 10^{-3} ，在 1000 个训练轮次内指数衰减率为 0.9975。

IV. 信息采集模型预测控制框架

我们提出了一种主动信息收集框架，如图 3 所示，旨在尽可能快速地识别非线性动力学，以便后续在模型预测控制 (MPC) 中可靠部署。首先，我们利用车辆轨迹数据集离线元训练贝叶斯车辆模型（第三节）。其次，我们利用模型丰富的特征空间 ϕ 以及由 $(\bar{\theta}, \Lambda^{-1})$ 编码的不确定性表示，安全地收集信息数据并优化模型。经过这种信息引导的自适应后，我们在 MPC 框架内利用优化后的车辆模型，在漂移等具有挑战性的驾驶场景中控制车辆。接下来，我们构建用于 MPC 和信息收集的最优控制问题。我们定义了一种 MPC 公式，能够跟踪动态轨迹，例如参数化的漂移机动。

通过参考轨迹 x_{ref} 。为获得平滑的控制输入，本文对控制输入的快速变化进行惩罚，并定义

$$\ell_k(x, u, w) = \|x - x_{\text{ref},k}\|_Q^2 + \|u - w\|_R^2,$$

其中 (Q, R) 为半正定对角矩阵。本文施加约束以确保车辆保持在赛道上，并保证执行器在硬件约束范围内运行。为从初始状态 x_{init} 在时域 N 上进行规划，本文构建了一个最优控制问题 (OCP)

$$\min_{x,u} \sum_{k=0}^{N-1} \ell_k(x_k, u_k, u_{k+1}) \quad \boxed{\text{OCP}} \quad (8a)$$

$$\text{s.t. } x_{k+1} = f_{\bar{\theta}}(x_k, u_k, u_{k+1}), \quad k \in \{0, \dots, N-1\}, \quad (8b)$$

$$x_0 = x_{\text{init}}, \quad (8c)$$

$$u_{\min} \leq u_k \leq u_{\max}, \quad k \in \{1, \dots, N\}, \quad (8d)$$

$$e_{\min,k} \leq e_k \leq e_{\max,k}, \quad k \in \{1, \dots, N\}. \quad (8e)$$

最优控制问题 (OCP) 解的质量取决于由末层参数 $\bar{\theta}$ 参数化的模型 $f_{\bar{\theta}}$ 的准确率：

$$f_{\bar{\theta}}(x_k, u_k, u_{k+1}) = h(x_k, u_k) + g(z_k; \bar{\theta}),$$

其中 $g_i(z_k; \bar{\theta}) = \bar{\theta}_i^\top \phi_i(z_k)$ 对于每个 $i = 1, \dots, n$ 。在离线元训练之后，直接部署一个使用先前模型参数 $\bar{\theta}_{i,0}$ 递归求解最优控制问题的模型预测控制器，即使任务期间在线调整模型，也可能在实际中表现不佳，参见第五节。这些观察结果促使我们采用主动数据收集方法，在具有挑战性的应用中部署前对模型进行细化。由于在车辆上收集数据可能耗时且昂贵，这就引出一个问题：我们应该收集哪些数据才能最好地识别未知动力学？回答这一问题的关键洞见在于，尽可能快地学习模型等同于最大化未来观测的信息增益，即最大化观测与真实系统之间的互信息（参见 [31, 第 2 章] 和 [32, 第 8 章]）。两个随机变量之间的互信息刻画了它们的相互依赖性，并为选择最能有效识别真实动力学 (2) 的数据提供了定量测度。因此，为了引导系统朝向状态-输入空间中模型不确定性较高的区域，我们定义了信息收集目标

$$\ell_{\text{info}}(x, u) := \frac{1}{2} \sum_{k=0}^{N-1} \sum_{i=1}^n \log(1 + \phi_{i,k}^\top \Lambda_{i,0}^{-1} \phi_{i,k}), \quad (9)$$

其中 $\phi_{i,k} := \phi_i(x_k, u_k, u_{k+1})$ 。利用 ℓ_{info} ，我们定义了信息收集最优控制问题

$$\min_{x,u} -\alpha \ell_{\text{info}}(x, u) + \sum_{k=0}^{N-1} \ell_k(x_k, u_k, u_{k+1}) \quad \boxed{\text{Info-OCP}} \quad (10)$$

s.t. (8b) - (8e),

其中 $\alpha > 0$ 权衡了信息增益与标称模型预测控制目标。标称代价 ℓ_k 鼓励平滑的控制输入，约束 (8b) - (8e) 确保车辆在数据收集期间保持在赛道上。

信息收集目标 (9) 在 [20] 中通过利用模型最后一层的不确定性表示 g 推导得出，该表示给出了观测与动力学之间单步互信息的闭式表达式。类似的目标在 [16]、[33]、[34] 中用于主动学习。如 [20] 所讨论， ℓ_{info} 是对轨迹上真实总信息增益的近似，而真实总信息增益并不完全等于每个时间步期望信息增益之和。我们发现，将线性回归更新 (6) 纳入目标（通过定义代价 $\tilde{\ell}_{\text{info}} = \frac{1}{2} \sum_{k=0}^{N-1} \sum_{i=1}^n \log(1 + \phi_{i,k}^\top \Lambda_{i,k}^{-1} \phi_{i,k})$ ）并不会对计算出的轨迹产生实质性差异，反而会使所得信息收集问题的数值求解更具挑战性。信息收集目标 (9) 引导数据采集朝向能够实现快速适应的特征空间区域。如图 3 所示，生成信息收集轨迹并在其上适应模型的过程可以根据需要迭代多次，以降低不确定性估计。在我们的实验中，我们发现仅在一两条信息收集轨迹上进行适应就足以执行可靠的漂移操作，如下一节所示。

五、结果

我们在丰田 Supra 上验证了所提出的主动信息收集框架。状态由 OxTS 惯性导航系统 [35] 以 100Hz 的频率估计，MPC 问题在配备 3.30GHz Intel Xeon E-2278GE CPU 的车载计算机上以约 100Hz 的频率求解，使用标准线搜索序列二次规划方法 [36, 第 18 章]，其中二次规划子问题由 OSQP 求解器 [37] 求解。漂移参考轨迹由 [38] 中的方法生成。我们实验的所有视频可在 <https://tinyurl.com/d4pmb8kc> 获取。

A. 信息丰富的轨迹是什么样的？

我们将 OCP 的解与 **Info-OCP** 的解进行比较。我们定义问题，其中 $x_{\text{init}} = (0, 7.5, 0, 7.5, 0, 0)$ ，a 直线参考轨迹 x_{ref} 从 x_{init} 到 $x_{\text{ref},N} = (0, 20, 0, 20, 0, 0)$ ，规划时域 $N = 45$ ，对应于 4.5 秒长的轨迹。OCP 和

信息最优控制问题 的解通过低级跟踪控制器在车辆上执行。我们记录轨迹，并使用它们通过 (6) 适应贝叶斯车辆模型。我们称之为

(一) 在标称轨迹上根据最优控制问题 (OCP) 适配的后验模型称为一次最优控制问题模型 (Once-OCP-Model)，(二) 在信息收集轨迹上根据信息最优控制问题 (**Info-OCP**) 适配的后验模型称为一次信息模型 (**Once-Info-Model**)。随后，我们利用一次信息模型，使用适配后的模型参数再次求解信息最优控制问题，以生成第二条信息收集轨迹。我们将基于第一条和第二条信息收集轨迹共同适配的后验模型称为二次信息模型 (**Twice-Info-Model**)。

车辆轨迹如图 4 所示。表 1 $\| \Lambda \|_2$ 展示了适配前以及各轨迹适配后的模型协方差值 $\| \Lambda \|_2^{-1}$ 。




图 4：标称轨迹与信息收集轨迹。（上）车辆执行轨迹的俯视图，（下）对应的横摆角速度、速度和控制输入。所有执行轨迹的持续时间为 4.5 秒。

适配情况，图 5 展示了模型对状态空间相关区域的预测。在图 4 中，我们看到尽管模型仅在漂移数据上进行元训练，信息最优控制问题的解并非精确的漂移轨迹。最优控制问题的解大致遵循直线参考轨迹，而信息最优控制问题的解

信息最优控制问题 施加更大的发动机扭矩并在各个方向转向，以激励动力学并提供信息量丰富的数据：表 1 显示，遵循信息最优控制问题的解比直线行驶能更快地辨识动力学。最后，在第一条信息轨迹上适配后，信息最优控制问题的解施加更大的发动机扭矩并在各个方向转向，以达到更大的横摆角速度（见图 4）。这有助于降低横摆角速度和侧滑动力学的不确定性（见表 1）。直观上，达到更高的横摆角速度可能有助于使轮胎力饱和并辨识不确定的轮胎特性。尽管信息最优控制问题的解与任务无关，但辨识轮胎动力学可能是后续部署到动态漂移任务的关键。

表 1：先验模型、一次最优控制问题模型（1-OCP-Model）、一次信息模型（1-Info-Model）和二次信息模型（2-Info-Model）的协方差范数 $\|\Lambda_i^{-1}\|_2$ 。

$\ \Lambda_i^{-1}\ _2$	Prior	1-OCP-Model	1-Info-Model	2-Info-Model
r	3.05	1.43	0.81	0.49
v	27.47	1.36	1.56	0.52
β	1.89	0.56	0.44	0.31
ω_r	1.57	0.43	0.47	0.39
Total	33.98	3.79	3.24	1.71




图 5：模型在信息收集轨迹上自适应前后的预测（见图 4）。不同转向角 $\delta_k = \delta_{k+1}$ 在 $(r_{k+1} - r_k) / \Delta t$ 处的均值预测 ± 3 标准差， $(r_k, v_k, \beta_k, \omega_{r,k}, \tau_k, \tau_{k+1}) = (0.9, 14.5, -0.45, 21, 200, 200)$ 。 Δr 其他状态变量同理。

B. 信息收集实现可靠漂移

接下来，我们考虑沿 8 字形轨迹漂移的任务，见图 1。该操作具有挑战性，因为轨迹圆弧段之间的过渡（图 6 中灰色部分）存在快速且不稳定的瞬态。我们评估三种模型用于模型预测控制（MPC）的性能：单次最优控制问题模型（Once-OCP-Model）、单次信息模型（Once-Info-Model）和两次信息模型（Twice-Info-Model）。为单独评估所提信息收集过程的价值，本实验不进行在线自适应。每个模型有三次尝试沿 8 字形漂移的机会，图 6 展示了各模型跟踪性能的中位数（补充统计量见附录 II）。跟踪性能以沿参考轨迹的横向误差均方根衡量。我们观察到，单次最优控制问题模型无法完成漂移，在第一次过渡后偏离参考轨迹过远。这种不理想的大偏差是由于车辆在第一次过渡后从滑动转为抓地，随后无法重新启动漂移。相比之下，单次信息模型成功完成第一次过渡，但在第二次过渡后打转，而两次信息模型能够完成整个 8 字形操作，每次均成功。




图 6: 先验模型在标称轨迹和信息性轨迹上自适应后的 8 字形漂移性能中位数 (图 4)。所有模型均禁用在线自适应。过渡段以灰色高亮。仅两次信息模型成功完成整个操作, 其俯视图见图 1。

在部署前至少进行一轮信息收集有助于完成第一次过渡。我们假设这是因为在信息最优控制问题 (Info-OCP) 轨迹上自适应能比在标称 OCP 轨迹上自适应获得更好的横摆角速度动力学估计。实际上, 图 4 显示信息最优控制问题轨迹比 OCP 轨迹更显著地激发横摆角速度动力学。此外, 表 I 显示在

信息最优控制问题 轨迹导致更小的横摆角速度协方差范数, 相较于在标称最优控制问题轨迹上自适应, 表明在信息最优控制问题轨迹上自适应后横摆角速度动力学估计更准确。

C. 在线自适应可能不足以实现可靠控制 在确立了通过信息最优控制问题生成轨迹的信息收集与离线自适应的效用后, 我们现在评估通过 (6) 中最后一层更新规则对模型进行在线自适应的效果, 该评估在图 7 所示的环形机动上进行。该机动具有挑战性, 因为漂移由模型预测控制器发起, 与八字形机动中手刹发起的方式形成对比。因此, 要成功发起漂移, 模型必须精确描述抓地与滑动之间具有挑战性的初始过渡。我们将在线自适应的先验模型与在第五-A 节中两条信息收集轨迹上预先自适应的模型进行性能比较。我们对每个模型进行两次测试, 并报告各自的最佳性能。





图 7: 先验模型在线自适应与在信息丰富轨迹上自适应模型在环形机动中的最佳性能。(上) 俯视图和 (下) 关键信号的时间序列数据。在两次信息模型中在线自适应被禁用。

模型如图 7 所示。图 7 显示, 具有在线自适应的模型能够准确跟踪这一具有挑战性的轨迹。然而, 尽管它成功完成了机动并最终实现了准确跟踪, 仅使用在线自适应的模型预测控制会导致较大的初始误差, 需要超过 150 米才能正确发起漂移。这种较差的瞬态性能可能对极限驾驶控制器的安全关键应用造成问题, 例如紧急避障 [39]。相比之下, 使用在信息收集轨迹上离线自适应的模型能够在所有过渡中无缝漂移, 如图 7 中位置、横摆角速度和侧偏角跟踪误差图所示。我们推测, 先验模型未能足够准确地捕捉抓地与滑动之间的过渡。

适当地启动漂移。尽管模型经过元训练，能够利用少量数据进行快速适应，但结果表明，仅从先验模型进行在线适应不足以无缝启动漂移，并会导致较大的瞬态响应。在部署前收集信息丰富的数据，显然有助于可靠地执行这一困难操作，同时最小化瞬态响应。

六、结论

本文提出一种信息收集框架，用于主动且高效地识别非线性动力学，以便后续在模型预测控制（MPC）中可靠部署。该方法的核心在于一个表达力强的车辆动力学模型，该模型利用元学习特征和贝叶斯最后一层权重更新实现快速适应。结果表明，首先收集信息丰富的数据，能够在 MPC 框架内实现可靠的少样本部署，我们预期这些发现可推广至其他具有挑战性的任务，这些任务涉及控制不稳定系统，其中微小的模型误差可能导致较大的跟踪误差。该方法在被动在线适应可能不够快、无法纠正初始模型失配以成功完成任务的应用中尤其有价值，这正是不稳定系统难以同时学习和控制的原因。在未来的工作中，贝叶斯模型中编码的不确定性估计可用于 MPC 公式中，以在探索和任务部署期间增强约束的鲁棒性 [20]。这些不确定性估计还可用于识别何时收集了足够的数据，或检测分布外行为 [40]。最后，尽管所提出的方法具有任务无关性，并且已经在具有挑战性的漂移任务中展示了可靠的性能，但利用面向控制的辨识工具 [14]、[28]、[41]、[42] 可能会进一步提升该方法的性能，并进一步降低信息收集的数据需求。

附录一 单轨自行车动力学 (3) 中的标称动力学模型由单轨自行车模型组成（参见例如 [5]、[11]），其表达式为

$$\begin{bmatrix} \dot{r} \\ \dot{v} \\ \dot{\beta} \\ \dot{\omega}_r \\ \dot{e} \\ \Delta\dot{\varphi} \end{bmatrix} = \begin{bmatrix} (aF_{yf} \cos(\delta) + aF_{xf} \sin(\delta) - bF_{yr})/I_z \\ (-F_{yf} \sin(\delta - \beta) + F_{xf} \cos(\delta - \beta) + F_{yr} \sin(\beta) + F_{xr} \cos(\beta))/m \\ -r + (F_{yf} \cos(\delta - \beta) + F_{xf} \sin(\delta - \beta) + F_{yr} \cos(\beta) - F_{xr} \sin(\beta))/(mv) \\ (G\tau - F_{xr}R_w)/I_w \\ v \sin(\Delta\varphi) \\ \dot{\beta} + r - \kappa_{\text{ref}}v \cos(\Delta\varphi)/(1 - \kappa_{\text{ref}}e) \end{bmatrix},$$

其中 (a, b) 分别为重心到前轴和后轴的距离， (I_z, m) 分别为车辆惯量和质量， (R_w, I_w) 分别为车轮半径和后轴惯量， G 为发动机到后轴的传动比， κ_{ref} 为参考轨迹的曲率， $(F_{yf}, F_{xf}, F_{yr}, F_{xr})$ 表示轮胎力，并采用各向同性耦合滑移刷毛模型 [43] 进行建模。参照 [5]，由于我们在后轮驱动车辆上进行测试，故设定 $F_{xf} = 0$ 。

表二： Once-OCP-Model、Once-Info-Model 和 Twice-Info-Model 在三次尝试漂移 8 字形轨迹时的横向偏差均方根值。单位为米。

RMS(e)	Once-OCP-Model	Once-Info-Model	Twice-Info-Model
Best	2.31	1.18	0.61
Median	3.19	1.31	0.83
Worst	7.35	3.64	1.29

表三： Once-OCP-Model、Once-Info-Model 和 Twice-Info-Model 在三次尝试漂移 8 字形轨迹时的侧偏角误差均方根值 $e_\beta = \beta - \beta_{\text{ref}}$ 。单位为弧度。

RMS(e_β)	Once-OCP-Model	Once-Info-Model	Twice-Info-Model
Best	0.137	0.105	0.068
Median	0.261	0.348	0.070
Worst	0.384	0.526	0.084

附录二 8 字形轨迹的附加统计量 本文报告附加统计量，以比较 Once-OCP-Model、Once-Info-Model 和 Twice-Info-Model 在第五节 B 部分所述 8 字形轨迹漂移任务中的性能。表二给出了三种模型在三次试验中的横向偏差均方根值 e 。表三给出了侧偏角误差均方根值 $e_\beta = \beta - \beta_{\text{ref}}$ 。由于 Once-OCP-Model 和 Once-Info-Model 均未能完整完成 8 字形轨迹，因此对于这些模型，均方根值计算在发生失控旋转或人工接管之前截断。Twice-Info-Model 始终取得最低的均方根误差，并且是唯一能够完整完成 8 字形轨迹且从未发生失控旋转的模型。

致谢

感谢 Phung Nguyen、Steven Goldine 和 William Kettle 在测试平台和实验方面提供的支持。

参考文献

- [1] G. Stein, “Respect the unstable,” *IEEE Control Systems Magazine*, vol. 23, no. 4, pp. 12–25, 2003.
- [2] E. Velenis, D. Katzourakis, E. Frazzoli, P. Tsiotras, and R. Happee, “Steady-state drifting stabilization of RWD vehicles,” *Control Engineering Practice*, vol. 19, no. 11, pp. 1363–1376, 2011.
- [3] M. Cutler and J. P. How, “Autonomous drifting using simulation-aided reinforcement learning,” in *Proc. IEEE Conf. on Robotics and Automation*, pp. 5442–5448, 2016.
- [4] F. Djeumou, J. Y. M. Goh, U. Topcu, and A. Balachandran, “Autonomous drifting with 3 minutes of data via learned tire models,” in *Proc. IEEE Conf. on Robotics and Automation*, pp. 968–974, 2023.
- [5] J. Y. M. Goh, M. Thompson, J. Dallas, and A. Balachandran, “Beyond the stable handling limits: Nonlinear model predictive control for highly transient autonomous drifting,” *Vehicle System Dynamics*, pp. 1–24, 2024.
- [6] T. P. Weber and J. C. Gerdes, “Modeling and control for dynamic drifting trajectories,” *IEEE Transactions on Intelligent Vehicles*, vol. 9, no. 2, pp. 3731–3741, 2024.
- [7] L. Hewing, K. P. Wabersich, M. Menner, and M. N. Zeilinger, “Learning-based model predictive control: Toward safe learning in control,” *Annual Review of Control, Robotics, and Autonomous Systems*, vol. 3, no. 1, pp. 269–296, 2020.

- [8] J. Kabzan, L. Hewing, A. Liniger, and M. N. Zeilinger, "Learning-based model predictive control for autonomous racing," *IEEE Robotics and Automation Letters*, vol. 4, no. 4, pp. 3363–3370, 2019.
- [9] N. A. Spielberg, M. Brown, and J. C. Gerdes, "Neural network model predictive motion control applied to automated driving with unknown friction," *IEEE Transactions on Control Systems Technology*, vol. 30, no. 5, pp. 1934–1945, 2021.
- [10] F. Djeumou, T. Lew, N. Ding, M. Thompson, M. Suminaka, M. Greiff, and J. Subosits, "One model to drift them all: Physics-informed conditional diffusion model for driving at the limits," in *Conf. on Robot Learning*, 2024.
- [11] N. Ding, M. Thompson, J. Dallas, J. Y. M. Goh, and J. Subosits, "Drifting with unknown tires: Learning vehicle models online with neural networks and model predictive control," in *IEEE Intelligent Vehicles Symposium*, pp. 2545–2552, 2024.
- [12] L. Brunke, M. Greeff, A. W. Hall, Z. Yuan, S. Zhou, J. Panerati, and A. P. Schoellig, "Safe learning in robotics: From learning-based control to safe reinforcement learning," *Annual Review of Control, Robotics, and Autonomous Systems*, vol. 5, no. 1, pp. 411–444, 2022.
- [13] Y. Abbasi-Yadkori, D. Pal, and C. Szepesvári, "Improved algorithms for linear stochastic bandits," in *Conf. on Neural Information Processing Systems*, 2011.
- [14] A. Wagenmaker, G. Shi, and K. G. Jamieson, "Optimal exploration for model-based RL in nonlinear systems," *Conf. on Neural Information Processing Systems*, 2024.
- [15] T. Koller, M. T. F. Berkenkamp, and A. Krause, "Learning-based model predictive control for safe exploration," in *Proc. IEEE Conf. on Decision and Control*, pp. 6059–6066, 2018.
- [16] M. Buisson-Fenet, F. Solowjow, and S. Trimpe, "Actively learning Gaussian process dynamics," in *Conf. on Learning for Dynamics and Control*, pp. 5–15, 2020.
- [17] H. Mania, M. I. Jordan, and B. Recht, "Active learning for nonlinear system identification with guarantees," *Journal of Machine Learning Research*, vol. 23, no. 32, pp. 1–30, 2022.
- [18] A. Saviolo, J. Frey, A. Rathod, M. Diehl, and G. Loianno, "Active learning of discrete-time dynamics for uncertainty-aware model predictive control," *IEEE Transactions on Robotics*, vol. 40, pp. 1273–1291, 2024.
- [19] W. Zhang, M. Tognon, L. Ott, R. Siegwart, and J. Nieto, "Active model learning using informative trajectories for improved closed-loop control on real robots," in *Proc. IEEE Conf. on Robotics and Automation*, pp. 4467–4473, 2021.
- [20] T. Lew, A. Sharma, J. Harrison, A. Bylard, and M. Pavone, "Safe active dynamics learning and control: A sequential exploration–exploitation framework," *IEEE Transactions on Robotics*, vol. 38, no. 5, pp. 2888–2907, 2022.
- [21] S. Dean, H. Mania, N. Matni, B. Recht, and S. Tu, "On the sample complexity of the linear quadratic regulator," *Foundations of Computational Mathematics*, vol. 20, no. 4, pp. 633–679, 2019.
- [22] H. Mania, S. Tu, and B. Recht, "Certainty equivalence is efficient for linear quadratic control," in *Conf. on Neural Information Processing Systems*, 2019.
- [23] T. Kim, J. Mun, J. Seo, B. Kim, and S. Hong, "Bridging active exploration and uncertainty-aware deployment using probabilistic ensemble neural network dynamics," in *Robotics: Science and Systems*, 2023.
- [24] B. Sukhija, L. Treven, C. Sancaktar, S. Blaes, S. Coros, and A. Krause, "Optimistic active exploration of dynamical systems," *Advances in Neural Information Processing Systems*, pp. 38122–38153, 2024.
- [25] J. Harrison, A. Sharma, and M. Pavone, "Meta-learning priors for efficient online Bayesian regression," in *Algorithmic Foundations of Robotics XIII: Proceedings of the 13th Workshop on the Algorithmic Foundations of Robotics*, pp. 318–337, 2020.
- [26] K. Lee, S. Maji, A. Ravichandran, and S. Soatto, "Meta-learning with differentiable convex optimization," in *IEEE/CVF Conf. on Computer Vision and Pattern Recognition*, pp. 10657–10665, 2019.
- [27] L. Bertinetto, J. F. Henriques, P. H. S. Torr, and A. A. Vedaldi, "Meta-learning with differentiable closed-form solvers," in *International Conference on Learning Representations*, 2019.
- [28] S. M. Richards, N. Azizan, J.-J. Slotine, and M. Pavone, "Control-oriented meta-learning," *Int. Journal of Robotics Research*, vol. 42, no. 10, pp. 777–797, 2023.
- [29] M. O'Connell, G. Shi, X. Shi, K. Azizzadenesheli, A. Anandkumar, Y. Yue, and S.-J. Chung, "Neural-fly enables rapid learning for agile flight in strong winds," *Science Robotics*, vol. 7, no. 66, pp. 1–15, 2022.
- [30] S. Banerjee, J. Harrison, P. M. Furlong, and M. Pavone, "Adaptive meta-learning for identification of rover-terrain dynamics," in *Int. Symp. on Artificial Intelligence, Robotics and Automation in Space*, 2020.
- [31] T. M. Cover, *Elements of Information Theory*. John Wiley & Sons, 1999.
- [32] D. J. C. MacKay, *Information Theory, Inference, and Learning Algorithms*. Cambridge University Press, 2003.
- [33] A. Krause and C. Guestrin, "Nonmyopic active learning of Gaussian processes," in *Int. Conf. on Machine Learning*, 2007.
- [34] C. Zimmer, M. Meister, and D. Nguyen-Tuong, "Safe active learning for time-series modeling with Gaussian processes," in *Conf. on Neural Information Processing Systems*, 2018.
- [35] OxTS, "User manual: NCOM data format for the efficient communication of navigation measurements," 2022.
- [36] J. Nocedal and S. J. Wright, *Numerical Optimization*. Springer, 1999.
- [37] B. Stellato, G. Banjac, P. Goulart, A. Bemporad, and S. Boyd, "OSQP: An operator splitting solver for quadratic programs," *Mathematical Programming Computation*, vol. 12, no. 4, pp. 637–672, 2020.
- [38] J. Y. Goh and J. C. Gerdes, "Simultaneous stabilization and tracking of basic automobile drifting trajectories," in *IEEE Intelligent Vehicles Symposium*, pp. 597–602, 2016.
- [39] T. Zhao, E. Yurtsever, and G. Rizzoni, "Justifying emergency drift control for automated vehicles," in *IFAC Symposium on Advances in Automotive Control*, vol. 55, pp. 141–148, 2022.
- [40] R. Sinha, A. Sharma, S. Banerjee, T. Lew, R. Luo, S. M. Richards, Y. Sun, E. Schmerling, and M. Pavone, "A system-level view on out-of-distribution data in robotics," *arXiv preprint arXiv:2212.14020*, 2022.
- [41] S. Anderson and J. P. Hespanha, "Control-oriented identification via stochastic optimization," *IEEE Control Systems Letters*, vol. 8, pp. 1865–1870, 2024.
- [42] B. D. Lee, I. Ziemann, G. J. Pappas, and N. Matni, "Active learning for control-oriented identification of nonlinear systems," *arXiv preprint arXiv:2404.09030*, 2024.
- [43] J. Svendenius, *Tire modeling and friction estimation*. PhD thesis, Lund University, 2007.