

Cal-QL: 面向高效在线微调的校准离线强化学习预训练

Mitsuhiko Nakamoto^{1*} Yuexiang Zhai^{1*} Anikait Singh¹ Max Sobol Mark²

Yi Ma¹ Chelsea Finn² Aviral Kumar¹ Sergey Levine¹

¹UC Berkeley ²Stanford University

摘要

离线强化学习 (RL) 的一个引人注目的应用场景是：从现有数据集中获得策略初始化，随后通过有限的交互进行快速在线微调。然而，现有的离线强化学习方法在微调过程中往往表现不佳。本文在保守离线强化学习方法的背景下研究微调问题，并设计了一种方法，从离线数据中学习有效的初始化，同时具备快速在线微调的能力。我们的方法——校准 Q 学习 (Cal-QL) ——通过以下方式实现这一目标：学习一个保守的价值函数初始化，该初始化从离线数据中低估所学策略的价值，同时确保所学 Q 值处于合理的尺度。我们将这一性质称为校准，并将其正式定义为：为所学策略的真实价值函数提供下界，并为某个其他（次优）参考策略（可以简单地是行为策略）的价值提供上界。我们证明，同时学习校准价值函数的保守离线强化学习算法能够实现有效的在线微调，从而在在线微调中充分利用离线初始化的优势。在实践中，Cal-QL 可以在保守 Q 学习 (CQL) [32] 的基础上实现，只需一行代码的改动。实验表明，Cal-QL 在本文研究的 9/11 微调基准任务上优于最先进的方法。代码和视频可在 <https://nakamotoo.github.io/Cal-QL> 获取。

1 引言

现代机器学习的成功遵循一个共同的配方：在通用、互联网规模的数据上预训练模型，然后针对感兴趣的任務，在有限的数据上微调预训练的初始化 [22, 7]。我们如何将这种配方转化为顺序决策问题？实例化这种范式的一种自然方法是利用离线强化学习 (RL) [37] 从静态数据集中初始化价值函数和策略，然后通过在线微调，以有限的主动交互来改进这种初始化。如果成功，这种配方可能实现高效的在线强化学习，所需的样本远少于当前从头学习的方法。许多离线强化学习算法已被应用于在线微调。这些工作中的实证结果表明了一个反直觉的趋势：从更有效的离线强化学习方法获得的策略初始化，往往表现出更差的在线微调性能，即使在同一任务中也是如此（参见 Kostrikov 等人 [31] 的表 2 和 Xiao 等人 [57] 的图 4）。另一方面，从头训练的在线强化学习方法（或从演示中进行强化学习 [53]，其中回放缓冲区用离线数据播种）似乎以显著更快的速度在线改进。然而，

* 同等贡献。通讯作者：Mitsuhiko Nakamoto、Yuexiang Zhai 和 Aviral Kumar
({nakamoto, simonzhai}@berkeley.edu, aviralku@andrew.cmu.edu)

这些在线方法需要通过从头展开策略来主动收集数据，这在数据收集昂贵或危险的问题中继承了朴素在线强化学习方法的类似局限性。总体而言，这些结果表明，设计一种既能从先前数据中获得良好初始化，又能实现高效微调的离线强化学习算法具有挑战性。

我们如何设计一种方法来学习有效的策略初始化，并使其在微调过程中也能持续改进？先前的工作 [32, 6] 表明，可以通过针对从离线数据集获得的保守价值函数优化策略，来学习良好的离线初始化。但正如我们在第 4.1 节中所示，仅靠保守性不足以实现高效的在线微调。保守方法往往倾向于“遗忘”从离线数据中学到的策略初始化，并浪费通过在线交互收集的样本来恢复这一初始化。我们发现，“遗忘”现象是由于保守方法产生的价值估计可能显著低于任何有效策略的真实回报。价值估计与有效策略的回报不在同一尺度上是有问题的。因为一旦开始微调，在环境中为探索而执行的动作，如果其真实回报值大于学到的保守价值估计，即使这些动作实际上比从离线数据中学到的策略更差，也可能错误地显得更好。因此，后续的策略优化会降低策略性能，直到方法恢复。如果我们能确保使用离线数据学到的保守价值估计是校准的，即这些估计与真实回报值处于相似尺度，那么我们就可以避免由保守方法引起的遗忘现象（见 4.1 节中的正式定义）。当然，我们无法完美地强制执行这样的条件，因为这需要消除价值函数中的所有误差。相反，我们设计了一种方法，确保学到的价值是某个参考策略（例如行为策略）真实价值的上界，同时仍然是所学策略价值的下界。虽然这并不能完美保证学到的价值是正确的，但我们表明它仍然能实现样本高效的在线微调。因此，我们的实用方法——校准 Q 学习（Cal-QL）——通过对现有保守方法进行简单修改，学习相对于行为策略“校准”的保守价值函数。本文的主要贡献是 Cal-QL，一种获取有助于在线微调的离线初始化的方法。Cal-QL 旨在学习相对于参考策略（例如行为策略）校准的保守价值函数。我们对 Cal-QL 的分析表明，Cal-QL 在微调期间对累积遗憾获得了更强的保证。在实践中，Cal-QL 可以在保守 Q 学习 [32]（一种先前的离线强化学习方法）之上实现，无需任何额外的超参数。我们在来自 [10]、[51] 和 [44] 的一系列基准任务上评估了 Cal-QL，包括机器人操作和导航。我们表明，Cal-QL 在所有任务上匹配或优于最佳方法，在某些情况下高出 30-40%。

2 相关工作

多项先前研究表明，在线强化学习方法通常需要大量样本 [50, 54, 61, 26, 64, 18, 38] 才能从头学习。我们可以利用离线数据来加速在线强化学习算法。先前的工作通过多种方式实现这一点：将离线数据纳入在线强化学习的回放缓冲区 [48, 53, 23, 52]，利用辅助行为克隆损失与策略梯度 [46, 27, 67, 66]，或提取高层技能空间用于下游在线强化学习 [17, 1]。尽管这些方法提高了从头在线强化学习的样本效率，但正如我们将在结果中展示的，它们并未消除主动执行较差策略以收集数据的需要。为解决这一问题，另一类工作首先运行离线强化学习，从离线数据中学习良好的策略和值初始化，随后进行在线微调 [45, 30, 41, 3, 56, 36, 42]。这些




图 1：我们研究离线强化学习预训练后进行在线强化学习微调。一些先前的离线强化学习方法在这种设置下往往表现出缓慢的性能改进（黄色），导致较差的渐近性能。其他方法在在线微调开始后遭受初始性能下降（红色），导致较高的累积遗憾。我们开发了一种方法，通过“校准”学习到的价值函数，以较小的遗憾实现快速改进（蓝色）。

现有方法通常采用基于策略约束或悲观主义的离线强化学习算法（offline RL）处理离线数据 [12, 49, 16, 15, 30, 51, 36]，随后在微调开始时，将同一方法应用于离线与在线数据的组合继续训练 [43, 28, 62, 32, 4]。尽管悲观主义对离线强化学习至关重要 [25, 6]，但在微调中使用悲观主义或约束 [45, 30, 41] 会减慢微调速度或导致初始遗忘，我们将在第 4.1 节展示这一点。实际上，这些先前方法要么无法像在线强化学习那样快速提升，要么丢失了离线强化学习的初始化。本文旨在通过理解离线初始化上实现快速微调的某些条件来解决这一局限性。我们的工作与那些在离线训练中使用悲观强化学习算法但在微调中引入探索的方法最为相关 [36, 42, 56]。与这些工作相比，本文方法旨在学习更好的离线初始化，从而支持标准的在线微调。本文方法在微调时直接进行朴素微调，不使用集成 [36] 或探索 [42]，并且如实验所示，仅此一点就足以超越在数据收集过程中采用显式乐观主义的方法。

3 预备知识与背景

强化学习的目标是为马尔可夫决策过程学习最优策略 $\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, r, \rho, \gamma)$ 。 $\mathcal{S}, \mathcal{A}$ 表示状态空间和动作空间。 $P(s'|s, a)$ 和 $r(s, a)$ 是动态函数和奖励函数。 $\rho(s)$ 表示初始状态分布。 $\gamma \in (0, 1)$ 表示折扣因子。形式上，目标是学习一个策略 $\pi : \mathcal{S} \mapsto \mathcal{A}$ ，使其最大化累积折扣值函数，记为 $V^\pi(s) = \mathbb{E}_{s_0=s} [\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t) | s_0 = s, a_0 = \pi(s_0)]$ 。给定策略 π 的 Q 函数定义为 $Q^\pi(s, a) = \mathbb{E}_{s' \sim P(\cdot|s, a)} [r(s, a) + \gamma V^\pi(s')]$ ，我们使用 Q_θ^π 来表示通过参数为 θ 的神经网络获得的策略 π 的 Q 函数估计。给定使用行为策略 π_β 收集的离线数据集 $\mathcal{D} = \{(s, a, r, s')\}$ ，我们的目标是首先仅使用离线数据集 $\mathcal{D}$ 训练一个好的策略和值函数，然后进入利用 $\mathcal{M}$ 中在线交互的在线阶段。微调期间的目标是以最少的在线样本数量获得最优策略。

这可以表示为最小化在线交互轮次上的累积遗憾： $\text{Reg}(K) := \mathbb{E}_{s \sim \rho} \sum_{k=1}^K [V^*(s) - V^{\pi^k}(s)]$ 。正如我们在第 7 节中展示的，现有方法在此设置下面临挑战。我们的方法将建立在保守 Q 学习（CQL）[32] 算法之上。CQL 施加了一个额外的正则化器，该正则化器对分布外动作上的学习 Q 函数进行惩罚，同时对训练数据集中出现的动作补偿这种悲观性。假设值函数由函数 Q_θ 表示，CQL 的训练目标为

$$\min_{\theta} \underbrace{\alpha (\mathbb{E}_{s \sim \mathcal{D}, a \sim \pi} [Q_\theta(s, a)] - \mathbb{E}_{s, a \sim \mathcal{D}} [Q_\theta(s, a)])}_{\text{Conservative regularizer } \mathcal{R}(\theta)} + \frac{1}{2} \mathbb{E}_{s, a, s' \sim \mathcal{D}} [(Q_\theta(s, a) - \mathcal{B}^\pi Q(s, a))^2], \quad (3.1)$$

其中 $\mathcal{B}^\pi Q(s, a)$ 是应用于延迟目标 Q 网络的备份算子， $\mathcal{B}^\pi Q(s, a) := r(s, a) + \gamma \mathbb{E}_{s' \sim P(\cdot|s, a)} [Q(s', a)]$ 。第二项是标准 TD 误差 [40, 13, 20]。第一项 $\mathcal{R}(\theta)$ （蓝色部分）是一个保守正则化器，旨在通过最小化策略 $\pi(a|s)$ 下的 Q 值来防止分布外动作的 Q 值高估，并通过最大化数据集中遵循行为策略 π_β 的动作的 Q 值来平衡。

4 离线强化学习初始化何时能实现快速在线微调？

离线预训练和在线微调的一个起点是简单地用现有离线强化学习方法产生的值函数进行初始化，然后执行微调。然而，我们通过实验发现，许多离线强化学习算法学习到的初始化在微调期间可能表现不佳。我们将研究保守方法子集表现不佳的原因，以激励和开发我们的在线微调方法——校准 Q 学习。

4.1 实证分析

离线强化学习后进行在线微调通常给多种方法带来不小的挑战。虽然先前工作 [45] 中的分析指出了部分离线强化学习方法面临的挑战，但在图 2 中，我们评估了多种先前离线强化学习方法（保守 Q 学习（CQL）[32]、隐式 Q 学习（IQL）[30]、TD3+BC [11]、优势加权行为克隆（AWAC）[45]）在一个特定诊断实例上的微调性能，该实例是一个带有干扰物和稀疏二元奖励的视觉拾取放置任务 [51]，并发现所有方法都难以快速达到最佳性能。关于此任务的更多细节见附录 B。




图 3: CQL 在离线预训练和在线微调过程中平均 Q 值和成功率的变化。微调从 50K 步开始。红色部分表示性能恢复期, 该时期与 Q 值调整期重合。

虽然所有方法获得的离线 Q 函数初始化都达到了约 0.5 的相似 (归一化) 回报, 但它们在微调过程中遇到了困难: TD3+BC、IQL、AWAC 的渐近性能提升缓慢, 而 CQL 会遗忘离线初始化, 随后需要大量在线交互才能恢复离线性能, 之后才能进一步改进。这种初始遗忘现象出现在多个任务中, 如附录 F 所示。本文重点研究在保守方法 (如 CQL) 基础上开发有效的微调策略。为此, 我们接下来旨在理解 CQL 初始遗忘背后的潜在原因。CQL 为何会初始遗忘? 为了理解 CQL 初始遗忘的原因, 我们检查了图 3 中数据集上学习的 Q 值平均值。观察到 CQL 在离线阶段学习的 Q 值远小于其真实值 (符合预期), 但在微调开始时这些 Q 值会急剧跳跃并调整尺度。事实上, 我们观察到性能恢复 (图 3 中的红色段) 与 Q 值范围变化以匹配真实范围的时期相吻合。这是符合预期的: 当保守的 Q 函数遇到新的在线数据时, 在 rollout 状态上比离线策略差得多的动作, 相对于被严重低估的离线 Q 函数, 似乎能获得更高的奖励, 从而欺骗策略优化器遗忘初始策略。我们在图 4 中直观地展示了这一思想。一旦 Q 函数调整完毕且 Q 值范围与真实范围紧密匹配, 微调就可以在性能下降之后正常进行。总之, 我们的实证分析表明, 现有的微调方法存在初始遗忘或渐近性能差等困难。特别是, 我们观察到保守方法可以获得良好的渐近性能, 但会“浪费”样本本来修正学习到的 Q 函数。因此, 本文尝试在现有保守离线强化学习方法 CQL 的基础上开发一种良好的微调方法, 旨在“校准”Q 函数, 从而避免初始性能下降。




图 2: 多种先前离线强化学习算法在微调过程中遇到困难, 包括渐近性能差和初始遗忘。

4.2 实现快速微调的离线初始化条件

我们从之前的讨论中得出的观察结果, 为快速微调的离线 Q 初始化提供了两个结论: (a) 学习保守 Q 函数的方法能够获得良好的渐近性能; (b) 如果学习到的 Q 值与任务上真实 Q 值的范围紧密匹配, 那么在线微调就不需要消耗样本去遗忘并恢复离线初始化。将这种 Q 值处于与真实 Q 函数相似尺度的直觉形式化的一种方法, 是要求保守离线强化学习方法学习到的保守 Q 值必须以下界为约束, 即不低于某个次优参考策略的真实 Q 值。这将防止保守性学习到过小的 Q 值。我们将这一性质称为相对于参考策略的“校准”。

定义 4.1 (校准)。 对于给定策略 π 的估计 Q 函数 Q_θ^π , 如果满足 $\mathbb{E}_{a \sim \pi} [Q^\pi]$, 则称其相对于参考策略 μ 是校准的。

$$Q_\theta^\pi(s, a) \geq \mathbb{E}_{a \sim \mu} [Q^\mu(s, a)] := V^\mu(s), \forall s \in D.$$

如果学习到的 Q 函数 Q_θ^π 相对于一个比 π 更差的策略 μ 是校准的, 那么它将防止我们在 CQL 案例中观察到的微调过程中的遗忘现象。这是因为

策略优化器在观察到新的在线数据时，不会为了一个比参考策略 μ 更差的策略而遗忘 π ，因为 π 的期望值被约束为大于 V^μ ： $\mathbb{E}_{a \sim \pi} [Q_\theta^\pi(s, a)] \geq V^\mu(s)$ 。我们的实用方法 Cal-QL 将相对于策略 μ 强制执行校准，该策略的真实值 $V^\mu(s)$ 可以在没有自举误差的情况下可靠地估计（例如，由数据集诱导的行为策略）。这是我们方法背后的关键思想（我们将在接下来讨论），并在图 4 中进行了直观展示。

5 Cal-QL: 校准 Q 学习

我们的方法，校准 Q 学习 (Cal-QL)，旨在从离线数据集中学习保守且校准的价值函数初始化。为此，Cal-QL 建立在 CQL [32] 之上，然后根据定义 4.1 约束学习到的 Q 函数，使其产生的 Q 值大于参考策略 μ 的 Q 值。原则上，我们的方法可以利用多种不同的参考策略选择，但为了开发实用的方法，我们简单地利用行为策略作为参考策略。校准 CQL。我们可以通过对公式 3.1 中所示的 CQL 训练目标进行简单修改，约束学习到的 Q 函数 Q_θ^π 大于 V^μ ：如果 Q 函数未校准，即如果 $\mathbb{E}_{a \sim \pi} [Q^\pi]$ ，则在 CQL 中屏蔽对分布外 (OOD) 动作的学习 Q 值的下推。。Cal-QL 以这种方式 $(s, a)] \leq V^\mu(s)$ 修改 CQL 正则化器 $\mathcal{R}(\theta)$ ：

$$\mathbb{E}_{s \sim \mathcal{D}, a \sim \pi} [\max(Q_\theta(s, a), V^\mu(s))] - \mathbb{E}_{s, a \sim \mathcal{D}} [Q_\theta(s, a)], \quad (5.1)$$

其中与标准 CQL 的不同之处以红色标出。只要 α （在公式 3.1 中）足够大，对于学习到的 Q 值小于 Q^μ 的任何状态-动作对，公式 5.1 中的 Q 函数将在表格设置中上界 Q^μ 。当然，与任何实用的强化学习方法一样，使用函数逼近器和基于梯度的优化器，我们无法保证对每个状态-动作对都能强制执行此条件，但在我们的实验中，我们发现公式 5.1 足以在数据集中的状态上以期望的方式强制执行校准。

伪代码和实现细节。 我们的 Cal-QL 实现直接建立在 Geng [14] 的 CQL 实现之上。我们在附录 A 中给出了 Cal-QL 的伪代码。此外，我们在附录 C 中列出了 CQL 算法和每个任务套件的基线的超参数 α 。遵循先前工作 [30, 52] 中的协议，Cal-QL 的实际实现微调期间以一定比例加权训练离线数据和新在线数据的混合。为了获得 $V^\mu(s)$ ，我们可以通过回归拟合一个函数逼近器 Q_θ^μ 或 V_θ^μ 到回报值，但我们观察到，对于以终止状态结束的任务，简单地利用回报值估计就足以满足我们的用例。我们在第 7 节中展示了，对目标进行这一简单的单行修改如何显著改善了先前的微调结果。




图 4：基于 CQL 的策略遗忘背后的直觉以及 Cal-QL 背后的思想。 该图可视化了对给定状态下学习到的 Q 函数和真实值的一个切片。当使用在线数据更新 CQL Q 函数时，次优动作（x 轴）上会出现错误的峰值。这反过来可能导致策略偏离数据集中覆盖的高奖励动作，转而偏向错误的新动作，从而导致预训练策略的性能下降。相比之下，Cal-QL 通过使用参考值函数来校正学习到的 Q 值的尺度，使得 Q 值比参考值函数更差的动作在微调过程中不会错误地显得最优。

6 Cal-QL 的理论分析

我们现在分析当值函数使用 Cal-QL 预训练时，在线微调过程中获得的累积遗憾，并证明强制校准（定义 4.1）会在在线阶段带来有利的遗憾界。我们的分析利用了 Song 等人 [52] 的工具，但研究了校准对微调的影响。我们还指出，我们简化了对某些方面的处理（例如，如何纳入悲观主义），因为这使我们能够清晰地展示校准的好处。

符号与术语。 在我们的分析中，为简单起见，我们将考虑 Cal-QL 的理想化版本。具体来说，遵循先前工作 [52] 在双线性模型 [9] 下的做法，我们将在有限时域设置中操作，时域为 H 。我们将每个学习迭代 k 中给定 (s, a) 对和时间步 h 的学习到的 Q 函数表示为 Q^k 。对于任何给定的策略 π ，令 $C_\pi \geq 1$

表示集中系数，使得 $C_\pi := \max_{f \in \mathcal{C}} \frac{\sum_{h=0}^{H-1} \mathbb{E}_{s,a \sim d_h^\pi} [Tf_{h+1}(s,a) - f_h(s,a)]}{\sqrt{\sum_{h=0}^{H-1} \mathbb{E}_{s,a \sim \nu_h} (Tf_{h+1}(s,a) - f_h(s,a))^2}}$ ，即一个量化策略 π 与数据集 $\mathcal{D}$ 之间分布偏移的系数，以在 π 和数据集 $\mathcal{D}$ 下平均的贝尔曼误差之比来表示。注意 $\mathcal{C}$ 表示 Q 函数类，我们假设 $\mathcal{C}$ 具有贝尔曼双线性秩 [9] 为 d 。我们还使用 C_π^μ 来表示相对于参考策略的校准 Q 函数子集上的集中系数

$$\mu: C_\pi^\mu := \max_{f \in \mathcal{C}, f(s,a) \geq Q^\mu(s,a)} \frac{\sum_{h=0}^{H-1} \mathbb{E}_{s,a \sim d_h^\pi} [Tf_{h+1}(s,a) - f_h(s,a)]}{\sqrt{\sum_{h=0}^{H-1} \mathbb{E}_{s,a \sim \nu_h} (Tf_{h+1}(s,a) - f_h(s,a))^2}}, \text{ which provides } C_\pi^\mu \leq C_\pi.$$

类似于 $\mathcal{C}$ ，令 d_μ 表示 $\mathcal{C}_\mu$ 的贝尔曼双线性秩——即相对于参考策略 μ 的校准 Q 函数类。直观上，我们有 $\mathcal{C}_\mu \subset \mathcal{C}$ ，这意味着 $d_\mu \leq d$ 。正式定义见附录 H.2。我们将使用 π^k 来表示由 Q^k 诱导的 arg-max 策略 θ^k 。我们直观地讨论校准和保守性如何使 Cal-QL 相比不施加校准获得更小的遗憾。我们的目标是界定在线微调的累积遗憾。我们可以将该表达式分解为两项：

$$\begin{aligned} \sum_k \mathbb{E}_{s_0 \sim \rho} [V^{\pi^k}(s_0) - V^{\pi^*}(s_0)] \\ \text{Reg}(K) = \underbrace{\sum_{k=1}^K \mathbb{E}_{s_0 \sim \rho} [V^*(s_0) - \max_a Q_{\theta^k}^k(s_0, a)]}_{(i) := \text{miscalibration}} + \underbrace{\sum_{k=1}^K \mathbb{E}_{s_0 \sim \rho} [\max_a Q_{\theta^k}^k(s_0, a) - V^{\pi^k}(s_0)]}_{(ii) := \text{overestimation}}. \end{aligned} \quad (6.1)$$

将遗憾分解为项 (i) 和项 (ii) 具有启发性。项 (ii) 对应于学习值函数中的过高估计量，如果使用保守的强化学习算法进行训练，该项预期较小。项 (i) 是最优策略的真实值与学习 Q 函数之间的差异，如果学习 Q 函数针对最优策略进行了校准（根据定义 4.1），则该项为负。当然，这并不总是可能的，因为我们事先不知道 V^* 。但请注意，当 Cal-QL 利用具有高值 V^μ 、接近 V^* 的参考策略 μ 时，根据条件 4.1，学习 Q 函数 Q_θ 相对于 Q^μ 进行了校准，项 (i) 仍然可以得到控制。因此，控制这一遗憾需要在学习校准（项 (i)）和保守（项 (ii)）的 Q 函数之间取得平衡。我们现在将这一直觉形式化，并将详细证明推迟到附录 H.6。

定理 6.1（Cal-QL 的非正式遗憾界）。以高概率，Cal-QL 在在线微调期间累积的总遗憾获得以下界：

$$\text{Reg}(K) = \tilde{O}\left(\min\left\{C_{\pi^*}^\mu H \sqrt{dK \log(|\mathcal{F}|)}, K \mathbb{E}_\rho[V^*(s_0) - V^\mu(s_0)] + H \sqrt{d_\mu K \log(|\mathcal{F}|)}\right\}\right),$$

其中 $\mathcal{F}$ 是 Q 函数的函数类。

与 Song 等人 [52] 的比较。 宋等人 [52] 分析了一种在线强化学习算法，该算法利用离线数据而不施加保守性或校准。我们现在将定理 6.1 与宋等人 [52] 的定理 1 进行比较，以理解这些条件对最终遗憾保证的影响。宋等人 [52] 的定理 1 给出了一个遗憾界： $\text{Reg}(K) = O(C_{\pi^*}^\mu H \sqrt{dK \log(|\mathcal{F}|)})$ ，我们注意到我们的保证中有一些改进，这些改进也在第 7.3 节的实验中得到了验证：(a) 对于参考策略 μ 包含近最优行为的情形——即 $V^* - V^\mu \lesssim O(H \sqrt{d \log(|\mathcal{F}|)/K})$ ，与宋等人 [52] 相比，Cal-QL 能够实现更紧的遗憾保证；

(b) 如附录 H.3 所示，出现在我们保证中的集中系数 $C_{\pi^*}^\mu$ 不大于宋等人 [52] 定理 1 中出现的系数，这提供了另一个改进来源；(c) 最后，在参考策略具有广泛覆盖且高度次优的情况下，Cal-QL 回退到 [52] 的保证，这意味着 Cal-QL 改进了这一先前工作。




图 6: 基准任务上离线初始化后的在线微调。图中展示了每种方法预训练后的在线微调阶段（基于 SAC 的方法除外，它们未进行预训练）。观察到 Cal-QL 始终匹配或超过最佳先前方法的速度和最终性能，并且是唯一在所有任务上都做到这一点的算法。（6 个种子）

7 实验评估

我们的实验评估目标是研究 Cal-QL 在多大程度上能够促进样本高效的在线微调。为此，我们在来自 D4RL[10]、Singh 等人 [51] 和 Nair 等人 [45] 的各种离线强化学习基准任务上，将 Cal-QL 与其他几种最先进的微调方法进行比较，评估微调前后的性能。我们还研究了 Cal-QL 在更高维任务上的有效性，在这些任务中，策略和价值函数必须处理原始图像观测。最后，我们进行了实证研究，以理解 Cal-QL 在不同数据集组成下的有效性以及参考价值函数估计误差的影响。

离线强化学习任务和数据集。我们在先前工作

[30, 45] 用于评估微调性能的多个基准任务和数据集上评估了 Cal-QL: (1) 来自 D4RL[10]

的 **AntMaze** 任务，要求控制蚂蚁四足机器人从起点导航到迷宫中期望的目标位置。如果智能体到达目标周围预先指定的小半径内，则奖励为 +1，否则为 0。(2) 来自 D4RL 的

FrankaKitchen 任务，要求控制 9 自由度 Franka 机器人达到厨房的期望配置。为了成功，策略必须在单次运行中完成厨房中的四个子

任务，并且每完成一个子任务获得+1/0 的奖励。(3) 三个 **Adroit** 灵巧操作任务 [47, 30, 45]，要求学习 28 自由度五指手的复杂操作技能，以 (a) 在手中将笔操作到期望配置 (**pen-binary**)，(b) 通过解锁手柄打开门 (**door-binary**)，以及

(c) 将球重新定位到期望位置 (**relocate-binary**)。如果智能体成功解决任务，则获得稀疏的 +1/0 奖励。这些任务中的每一个仅提供狭窄的离线数据集，包括通过人类遥操作收集的 25 个演示和由 BC 策略收集的额外轨迹。最后，为了评估 Cal-QL 在从原始视觉观察中学习的任务上的有效性，我们研究了 (4) 来自先前工作 [51, 34] 的拾取放置任务，该任务要求学习在存在干扰物的情况下拾取球并将其放入碗中。此外，我们在附录 D 中比较了 Cal-QL 在 D4RL 运动任务 (**halfcheetah**, **hopper**, **walker**) 上的表现。




图 5: 任务：我们在多样化的基准问题上评估 Cal-QL: 来自 [10] 的 AntMaze 和 Franka 厨房领域，来自 [45] 的 Adroit 任务，以及来自 [34] 的基于视觉的机器人操作任务。

比较、先前方法和评估协议。我们将 Cal-QL 与从头开始运行在线 SAC [21] 以及利用离线数据的先前方法进行比较。这包括对离线强化学习方法（如 CQL [32] 和 IQL [30]）进行朴素微调，以及使用 AWAC [45]、O3F [42] 和在线决策 Transformer（ODT）[65] 进行微调，这些方法是专门为离线强化学习后接在线微调而设计的。此外，我们还与一个基线进行比较，该基线使用在线数据和离线数据训练 SAC [21]（记为“SAC + 离线数据”），它模仿 DDPGfD [53] 但使用 SAC 而非 DDPG。我们还与混合强化学习 [52] 进行比较，这是一种最近提出的方法，可提高“SAC + 离线数据”方法的样本效率，以及与“CQL+SAC”进行比较，后者先用 CQL 预训练，然后在离线与在线数据的混合上运行 SAC 微调，且无保守性。每种方法的更多细节见附录 C。我们展示了在线微调的学习曲线，并定量评估每种方法改进离线数据所学初始化的能力，衡量指标为（i）每个领域预定义步数后的最终性能，以及（ii）在线微调过程中的累积遗憾。在第 7.2 节中，我们以更高的更新数据比（UTD）运行 Cal-QL，并将其与 RLPD [2] 进行比较，后者是“SAC + 离线数据”的更具样本效率的版本。

7.1 实证结果

我们首先在表 1 中比较 Cal-QL 在微调前后的归一化性能，并在表 2 中比较固定在线步数内的累积遗憾。遵循 [10] 的协议，我们将每个领域的平均回报值相对于最高可能回报进行归一化（FrankaKitchen 中为 +4；其他任务中为 +1；更多细节见附录 C.1）。

Cal-QL 显著改进了离线初始化。观察表 1 和图 6，虽然 Cal-QL 获得的离线初始化性能与 CQL 和 IQL 等其他方法相当，但 Cal-QL 能够在其离线初始化基础上改进最多，总体提升 **106.9%**，并在 11 个任务中的 9 个上取得最佳微调性能。

Cal-QL 实现快速微调。观察表 2 可知，Cal-QL 在 11 项任务中的 **8** 项上取得了最小遗憾值，平均遗憾值为 0.22，比次优方法（IQL）提升了 **42%**。直观上，这意味着 Cal-QL 无需运行高度次优的策略。在 relocate-binary 等任务中，Cal-QL 享有与将离线数据纳入回放缓冲区的朴素在线强化学习方法（SAC+离线数据和 Cal-QL 是仅有的两种在该任务上达到 $\geq 90\%$ 得分的方法）相关的快速在线学习优势，这与先前的离线强化学习方法不同。如图 6 所示，在 kitchen 和 antmaze 领域中，Cal-QL 将快速在线学习的优势与良好的离线初始化相结合，显著改善了遗憾度量。最后，观察到在第 4.1 节中保守方法在微调初期出现的初始遗忘现象在所有任务中都得到了极大缓解（详见附录 F）。

Task	CQL	IQL	AWAC	O3F	ODT	CQL+SAC	Hybrid SRL	SAC+od	SAC	Cal-QL (Ours)
	34 → 76	41 → 51	00 → 00	68 → 01	00 → 00	21 → 00	→ 00	→ 00	→ 00	33 → 95
	62 → 98	72 → 94	00 → 00	89 → 99	00 → 05	67 → 98	→ 00	→ 00	→ 00	26 → 90
	71 → 75	40 → 60	01 → 13	11 → 22	-	71 → 00	→ 02	→ 68	→ 00	75 → 98
	65 → 98	70 → 92	01 → 08	01 → 08	00 → 00	65 → 98	→ 25	→ 96	→ 00	54 → 97
大型多样	25 → 87	50 → 59	00 → 00	42 → 10	06 → 36	33 → 00	→ 00	→ 07	→ 03	67 → 79
65 → 98	70 → 92	01 → 08	01 → 08	01 → 08	00 → 00	65 → 98	→ 01	→ 00	→ 02	38 → 80
	55 → 13	88 → 92	88 → 92	91 → 89	-	48 → 10	→ 00	→ 05	→ 06	22 → 68
新定位 操作 平均改进	22 → 88	41 → 88	29 → 13	04 → 08	-	29 → 66	→ 54	→ 17	→ 11	79 → 99
	06 → 69	06 → 45	06 → 08	03 → 35	-	01 → 00	→ 88	→ 39	→ 17	35 → 92
	50 → 97	49 → 81	50 → 73	-	-	42 → 41	→ 99	→ 16	→ 00	03 → 98
	42 → 71	50 → 69	16 → 20	44 → 45	00 → 02	42 → 29	→ 00	→ 01	→ 01	49 → 99
	+ 71.0%	+ 37.7%	+ 23.7%	+ 3.0%	N/A	- 30.3%	→ 24	→ 23	→ 04	44 → 90
					a		N/A	N/A	N/A	+ 106.9%

表 1：在线微调前后的归一化得分。观察可知，Cal-QL 优于先前最佳的微调方法，并在在线微调过程中取得了更大的性能提升。数字表示按照 [10] 中的惯例归一化到 100 分的得分。

7.2 具有高更新数据比（UTD）的 Cal-QL

我们可以通过增加算法在每个环境步骤中执行的梯度步数来进一步提升 Cal-QL 的在线样本效率。每个环境步骤的更新次数通常称为更新数据比（UTD）。在标准在线强化学习中，以高 UTD 值（例如 20，而典型值为 1）运行离策略 Q 学习通常会导致与过拟合相关的挑战 [39, 5, 2, 8]。正如预期的那样，我们注意到以高 UTD 值运行 Cal-QL 也会导致这些过拟合挑战。为了解决高 UTD 设置下的这些挑战，我们将 Cal-QL 与近期工作 RLPD[2] 中的 Q 函数架构相结合（即我们在 Q 函数中使用了层归一化，并采用了类似于 Chen 等人 [5] 的集成方法），以尝试解决

Task	CQL	IQL	AWAC	O3F	ODT	CQL+SAC	Hybrid RL	SAC+od	SAC	Cal-QL (Ours)
large-diverse	0.35	0.46	1.00	0.62	0.98	0.99	1.00	1.00	1.00	0.20
large-play	0.32	0.52	1.00	0.91	1.00	0.99	1.00	1.00	1.00	0.28
medium-diverse	0.06	0.08	0.99	0.03	0.95	0.06	0.98	0.77	1.00	0.05
medium-play	0.09	0.10	0.99	0.04	0.96	0.06	0.90	0.47	1.00	0.07
partial	0.31	0.49	0.89	0.78	-	0.97	0.98	0.98	0.92	0.27
mixed	0.55	0.60	0.88	0.72	-	0.97	0.99	1.00	0.91	0.27
complete	0.70	0.53	0.97	0.66	-	0.99	0.99	0.96	0.91	0.44
pen	0.86	0.11	0.12	0.13	-	0.90	0.56	0.75	0.87	0.11
door	0.36	0.25	0.81	0.82	-	0.23	0.35	0.60	0.94	0.23
relocate	0.71	0.74	0.95	0.71	-	0.86	0.30	0.89	1.00	0.43
manipulation	0.15	0.32	0.38	-	-	0.61	1.00	1.00	0.99	0.11
average	0.41	0.38	0.82	0.54	0.97	0.69	0.82	0.86	0.96	0.22

表 2: 微调步骤中平均的累积遗憾值。越小越好, 1.00 为最差。Cal-QL 取得了最小的总体遗憾值, 在 11 项任务中的 8 项上实现了最佳性能。




图 7: Cal-QL 与 UTD=20. 结合 RLPD 的设计选择使 Cal-QL 能够实现样本高效的微调, 并 UTD=20. 具体而言, Cal-QL 通常达到与 RLPD 相似或更高的渐近性能, 同时表现出更小的累积遗憾。(3 个种子) 过拟合挑战。注意, Cal-QL 仍首先使用方程 5.1 在离线数据集上进行预训练, 然后进行在线微调, 而 RLPD 从一开始就运行在线强化学习。在图 7 中, 我们将 Cal-QL (UTD = 20) 与 RLPD[2] (UTD = 20) 以及 Cal-QL (UTD = 1) as a 基线) 进行比较。观察到 Cal-QL (UTD = 20) 优于 Cal-QL (UTD = 1) 和从头训练 (RLPD)。

7.3 理解 Cal-QL 的行为

在本节中, 我们旨在通过修改数据集组成的受控实验, 并研究各种度量来理解 Cal-QL 的行为, 以了解在哪些场景下利用 Cal-QL 对在线微调尤为重要。

数据组成的影响。为了解 Cal-QL 在不同数据组成下的有效性, 我们在中等规模 AntMaze 域上运行了一个新构建的微调任务, 该任务使用低覆盖率的离线数据集, 该数据集由脚本控制器生成, 从固定初始位置出发并将蚂蚁导航到固定目标位置。在图 8 中, 我们绘制了 Cal-QL 和基线 CQL (用于比较) 在该任务上的性能, 以及离线预训练过程中 (虚线左侧, 250 个训练轮次之前) 和在线微调过程中 (虚线右侧, 250 个训练轮次之后) 平均 Q 值的趋势, 以及边界率 (即数据缓冲区中 Cal-QL 约束主动用参考值下界学习到的 Q 函数的转移比例) 的趋势。为了比较, 我们还在图 8 中绘制了高覆盖率多样化数据集的这些量 (我们使用 Fu 等人 [10] 的 antmaze-medium-diverse 作为代表性多样化数据集)。观察到对于多样化数据集, 朴素 CQL 和 Cal-QL 表现相似, 并且实际上, 这两种方法学习到的 Q 值行为相似。在这种情况下, 在线学习在微调开始时不会花费样本去修正 Q 函数, 导致边界率很低, 几乎总是接近 0。相反, 对于狭窄数据集, 我们观察到学习到的 Q 值




图 8: 不同数据组合下校准 Q 学习 (Cal-QL) 的性能表现。校准 Q 学习在窄数据集上最为有效, 此时 Q 值需要在微调初期进行校正。

朴素保守 Q 学习 (naïve CQL) 的 Q 值要小得多, 并在微调开始时得到修正。这种修正与性能下降同时发生 (左侧蓝色实线), 且朴素保守 Q 学习无法从这一下降中恢复。校准 Q 学习 (Cal-QL) 对数据集中更多样本的 Q 函数尺度进行校准, 能够稳定过渡到在线微调, 且不会发生遗忘 (左侧红色实线)。这表明, 在数据集较窄的设置中 (例如上述实验以及图 6 中的灵巧操作和视觉操作领域), 由于函数逼近误差, 朴素保守方法学习到的 Q 值更可能小于行为策略的真实 Q 函数。因此, 利用校准 Q 学习针对行为策略校准 Q 函数可能带来显著帮助。另一方面, 在覆盖率显著较高的数据集中, 尤其是行为策略本身随机且次优的问题中, 朴素方法学习到的 Q 值可能已经相对于行为策略的 Q 值得到了校准。因此, 可能不需要显式校准 (事实上, 如图 8 所示, 界限率往往非常接近 0)。在这种情况下, 校准 Q 学习将退回到标准保守 Q 学习, 正如我们在上述多样化数据集案例中观察到的那样。这一直觉也反映在定理 6.1 中: 当参考策略 μ 接近一个狭窄的专家策略时, 我们预期校准 Q 学习在控制在线微调效率方面会特别有效。

参考值函数中的估计误差不会影响

性能显著提升。 在实验中, 本文采用蒙特卡洛回报估计来计算参考值函数。然而, 并非所有任务都能获得此类估计。当参考值函数必须利用离线数据集本身进行估计时, Cal-QL 的表现如何? 为回答这一问题, 本文在厨房领域开展了一项实验: 不再使用基于蒙特卡洛回报的 Q^μ 估计, 而是训练一个神经网络函数逼近器 Q_θ^μ 。

应用于

通过监督回归逼近 Q^μ 蒙特卡洛回报, 随后由 Cal-QL 利用。观察图 9 可知, Cal-QL 的性能基本保持不变。这意味着只要能够获得合理的函数逼近器来估计参考策略 (此处为行为策略) 的 Q 函数, 参考 Q 函数的误差就不会显著影响 Cal-QL 的性能。




图 9: 采用神经网络逼近器估计参考值函数, 其性能与使用蒙特卡洛回报相当。这表明参考 Q 函数中的误差不会对性能产生负面影响。

8 讨论、未来方向与局限性

本文提出了 Cal-QL 方法, 用于获取保守的离线初始化, 从而促进快速在线微调。Cal-QL 学习保守的价值函数, 这些函数被约束为大于参考策略的价值函数。这种校准形式使我们能够在采用保守方法进行微调时避免初始遗忘, 同时保留这些方法所展现的有效渐近性能。我们的理论与实验结果凸显了 Cal-QL 在实现快速在线微调方面的优势。尽管 Cal-QL 优于先前的方法, 但我们相信通过更精细地调整校准与保守性, 可以开发出更有效的方法。本文的一个局限性在于未考虑预训练与微调任务不同的场景, 但这是未来工作一个有趣的方向。

致谢

本研究部分得到了海军研究办公室 N00014-21-1-2838、N00014-22-1-2102、ARO W911NF-21-1-0097、西蒙斯基金会-NSF DMS 联合基金 #2031899、AFOSR FA9550-22-1-0273 以及清华-伯克利深圳研究所 (TBSI) 研究基金的支持, 同时获得了英特尔和 C3.ai 的支持、伯克利研究计算项目提供的 Savio 计算集群资源以及谷歌的计算支持。我们感谢 Philip J. Ball、Laura Smith 和 Ilya Kostrikov 分享 RLPD 的实验结果。AK 受苹果 AI/ML 博士奖学金支持。MN 部分受中岛基金会奖学金支持。YZ 部分受西门子 CITRIS 和 TBSI 研究基金支持。YZ 感谢宋梅教授对定理 6.1 表述提出的深刻建议。

参考文献

- [1] A. Ajay, A. Kumar, P. Agrawal, S. Levine, and O. Nachum. Opal: Offline primitive discovery for accelerating offline reinforcement learning. *arXiv preprint arXiv:2010.13611*, 2020.
- [2] P. J. Ball, L. Smith, I. Kostrikov, and S. Levine. Efficient online reinforcement learning with offline data. *arXiv preprint arXiv:2302.02948*, 2023.
- [3] A. Beeson and G. Montana. Improving td3-bc: Relaxed policy constraint for offline learning and stable online fine-tuning. *arXiv preprint arXiv:2211.11802*, 2022.
- [4] J. Buckman, C. Gelada, and M. G. Bellemare. The importance of pessimism in fixed-dataset policy optimization. *arXiv preprint arXiv:2009.06799*, 2020.
- [5] X. Chen, C. Wang, Z. Zhou, and K. W. Ross. Randomized ensembled double q-learning: Learning fast without a model. In *International Conference on Learning Representations*, 2021. URL <https://openreview.net/forum?id=AY8zfZm0tDd>.
- [6] C.-A. Cheng, T. Xie, N. Jiang, and A. Agarwal. Adversarially trained actor critic for offline reinforcement learning. *arXiv preprint arXiv:2202.02446*, 2022.
- [7] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*, 2018.
- [8] P. D’Oro, M. Schwarzer, E. Nikishin, P.-L. Bacon, M. G. Bellemare, and A. Courville. Sample-efficient reinforcement learning by breaking the replay ratio barrier. In *The Eleventh International Conference on Learning Representations*, 2023. URL <https://openreview.net/forum?id=OpC-9aBBVJe>.
- [9] S. Du, S. Kakade, J. Lee, S. Lovett, G. Mahajan, W. Sun, and R. Wang. Bilinear classes: A structural framework for provable generalization in rl. In *International Conference on Machine Learning*, pages 2826–2836. PMLR, 2021.
- [10] J. Fu, A. Kumar, O. Nachum, G. Tucker, and S. Levine. D4rl: Datasets for deep data-driven reinforcement learning. *arXiv preprint arXiv:2004.07219*, 2020.
- [11] S. Fujimoto and S. S. Gu. A minimalist approach to offline reinforcement learning. *arXiv preprint arXiv:2106.06860*, 2021.
- [12] S. Fujimoto, D. Meger, and D. Precup. Off-policy deep reinforcement learning without exploration. *arXiv preprint arXiv:1812.02900*, 2018.
- [13] S. Fujimoto, H. van Hoof, and D. Meger. Addressing function approximation error in actor-critic methods. In *International Conference on Machine Learning (ICML)*, pages 1587–1596, 2018.
- [14] X. Geng. Jaxcql: a simple implementation of sac and cql in jax. 2022. URL <https://github.com/young-geng/JaxCQL>.
- [15] S. K. S. Ghasemipour, D. Schuurmans, and S. S. Gu. Emaq: Expected-max q-learning operator for simple yet effective offline and online rl. In *International Conference on Machine Learning*, pages 3682–3691. PMLR, 2021.

- [16] Y. Guo, S. Feng, N. Le Roux, E. Chi, H. Lee, and M. Chen. Batch reinforcement learning through continuation method. In *International Conference on Learning Representations*, 2020.
- [17] A. Gupta, V. Kumar, C. Lynch, S. Levine, and K. Hausman. Relay policy learning: Solving long-horizon tasks via imitation and reinforcement learning. *arXiv preprint arXiv:1910.11956*, 2019.
- [18] A. Gupta, A. Pacchiano, Y. Zhai, S. M. Kakade, and S. Levine. Unpacking reward shaping: Understanding the benefits of reward engineering on sample complexity. *arXiv preprint arXiv:2210.09579*, 2022.
- [19] T. Haarnoja, A. Zhou, P. Abbeel, and S. Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *arXiv*, 2018. URL <https://arxiv.org/pdf/1801.01290.pdf>.
- [20] T. Haarnoja, A. Zhou, K. Hartikainen, G. Tucker, S. Ha, J. Tan, V. Kumar, H. Zhu, A. Gupta, P. Abbeel, and S. Levine. Soft actor-critic algorithms and applications. Technical report, 2018.
- [21] T. Haarnoja, A. Zhou, K. Hartikainen, G. Tucker, S. Ha, J. Tan, V. Kumar, H. Zhu, A. Gupta, P. Abbeel, et al. Soft actor-critic algorithms and applications. *arXiv preprint arXiv:1812.05905*, 2018.
- [22] K. He, X. Chen, S. Xie, Y. Li, P. Dollár, and R. Girshick. Masked autoencoders are scalable vision learners. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 16000–16009, 2022.
- [23] T. Hester, M. Vecerik, O. Pietquin, M. Lanctot, T. Schaul, B. Piot, D. Horgan, J. Quan, A. Sendonaris, I. Osband, et al. Deep q-learning from demonstrations. In *Thirty-Second AAAI Conference on Artificial Intelligence*, 2018.
- [24] C. Jin, Q. Liu, and S. Miryoosefi. Bellman eluder dimension: New rich classes of rl problems, and sample-efficient algorithms. *Advances in neural information processing systems*, 34: 13406–13418, 2021.
- [25] Y. Jin, Z. Yang, and Z. Wang. Is pessimism provably efficient for offline rl? In *International Conference on Machine Learning*, pages 5084–5096. PMLR, 2021.
- [26] S. Kakade and J. Langford. Approximately optimal approximate reinforcement learning. In *International Conference on Machine Learning (ICML)*, volume 2, 2002.
- [27] B. Kang, Z. Jie, and J. Feng. Policy optimization with demonstrations. In *International conference on machine learning*, pages 2469–2478. PMLR, 2018.
- [28] R. Kidambi, A. Rajeswaran, P. Netrapalli, and T. Joachims. Morel: Model-based offline reinforcement learning. *arXiv preprint arXiv:2005.05951*, 2020.
- [29] I. Kostrikov. JAXRL: Implementations of Reinforcement Learning algorithms in JAX, 10 2021. URL <https://github.com/ikostrikov/jaxrl>.
- [30] I. Kostrikov, A. Nair, and S. Levine. Offline reinforcement learning with implicit q-learning. *arXiv preprint arXiv:2110.06169*, 2021.
- [31] I. Kostrikov, J. Tompson, R. Fergus, and O. Nachum. Offline reinforcement learning with fisher divergence critic regularization. *arXiv preprint arXiv:2103.08050*, 2021.
- [32] A. Kumar, A. Zhou, G. Tucker, and S. Levine. Conservative q-learning for offline reinforcement learning. *arXiv preprint arXiv:2006.04779*, 2020.
- [33] A. Kumar, A. Singh, F. Ebert, Y. Yang, C. Finn, and S. Levine. Pre-Training for Robots: Offline RL Enables Learning New Tasks from a Handful of Trials. *arXiv e-prints*, art. arXiv:2210.05178, Oct. 2022. doi: 10.48550/arXiv.2210.05178.
- [34] A. Kumar, A. Singh, F. Ebert, Y. Yang, C. Finn, and S. Levine. Pre-training for robots: Offline rl enables learning new tasks from a handful of trials. *arXiv preprint arXiv:2210.05178*, 2022.

- [35] T. Lattimore and C. Szepesvári. *Bandit algorithms*. Cambridge University Press, 2020.
- [36] S. Lee, Y. Seo, K. Lee, P. Abbeel, and J. Shin. Offline-to-online reinforcement learning via balanced replay and pessimistic q-ensemble. In *Conference on Robot Learning*, pages 1702–1712. PMLR, 2022.
- [37] S. Levine, A. Kumar, G. Tucker, and J. Fu. Offline reinforcement learning: Tutorial, review, and perspectives on open problems. *arXiv preprint arXiv:2005.01643*, 2020.
- [38] Q. Li, Y. Zhai, Y. Ma, and S. Levine. Understanding the complexity gains of single-task rl with a curriculum. *arXiv preprint arXiv:2212.12809*, 2022.
- [39] Q. Li, A. Kumar, I. Kostrikov, and S. Levine. Efficient deep reinforcement learning requires regulating overfitting. In *The Eleventh International Conference on Learning Representations*, 2023. URL <https://openreview.net/forum?id=14-kr46GvP->.
- [40] T. P. Lillicrap, J. J. Hunt, A. Pritzel, N. Heess, T. Erez, Y. Tassa, D. Silver, and D. Wierstra. Continuous control with deep reinforcement learning. *arXiv preprint arXiv:1509.02971*, 2015.
- [41] J. Lyu, X. Ma, X. Li, and Z. Lu. Mildly conservative q-learning for offline reinforcement learning. *arXiv preprint arXiv:2206.04745*, 2022.
- [42] M. S. Mark, A. Ghadirzadeh, X. Chen, and C. Finn. Fine-tuning offline policies with optimistic action selection. In *Deep Reinforcement Learning Workshop NeurIPS 2022*, 2022.
- [43] O. Nachum, B. Dai, I. Kostrikov, Y. Chow, L. Li, and D. Schuurmans. Algaedice: Policy gradient from arbitrary experience. *arXiv preprint arXiv:1912.02074*, 2019.
- [44] A. Nair, M. Dalal, A. Gupta, and S. Levine. Accelerating online reinforcement learning with offline datasets. *CoRR*, abs/2006.09359, 2020. URL <https://arxiv.org/abs/2006.09359>.
- [45] A. Nair, M. Dalal, A. Gupta, and S. Levine. Accelerating online reinforcement learning with offline datasets. *arXiv preprint arXiv:2006.09359*, 2020.
- [46] A. Rajeswaran, V. Kumar, A. Gupta, G. Vezzani, J. Schulman, E. Todorov, and S. Levine. Learning complex dexterous manipulation with deep reinforcement learning and demonstrations. *arXiv preprint arXiv:1709.10087*, 2017.
- [47] A. Rajeswaran, V. Kumar, A. Gupta, G. Vezzani, J. Schulman, E. Todorov, and S. Levine. Learning complex dexterous manipulation with deep reinforcement learning and demonstrations. In *Robotics: Science and Systems*, 2018.
- [48] S. Schaal. Learning from demonstration. *Advances in neural information processing systems*, 9, 1996.
- [49] N. Y. Siegel, J. T. Springenberg, F. Berkenkamp, A. Abdolmaleki, M. Neunert, T. Lampe, R. Hafner, and M. Riedmiller. Keep doing what worked: Behavioral modelling priors for offline reinforcement learning. *arXiv preprint arXiv:2002.08396*, 2020.
- [50] D. Silver, A. Huang, C. J. Maddison, A. Guez, L. Sifre, G. Van Den Driessche, J. Schrittwieser, I. Antonoglou, V. Panneershelvam, M. Lanctot, et al. Mastering the game of go with deep neural networks and tree search. *nature*, 529(7587):484–489, 2016.
- [51] A. Singh, A. Yu, J. Yang, J. Zhang, A. Kumar, and S. Levine. Cog: Connecting new skills to past experience with offline reinforcement learning. *arXiv preprint arXiv:2010.14500*, 2020.
- [52] Y. Song, Y. Zhou, A. Sekhari, D. Bagnell, A. Krishnamurthy, and W. Sun. Hybrid RL: Using both offline and online data can make RL efficient. In *The Eleventh International Conference on Learning Representations*, 2023. URL <https://openreview.net/forum?id=yyBis80iUuU>.
- [53] M. Vecerik, T. Hester, J. Scholz, F. Wang, O. Pietquin, B. Piot, N. Heess, T. Rothörl, T. Lampe, and M. Riedmiller. Leveraging demonstrations for deep reinforcement learning on robotics problems with sparse rewards. *arXiv preprint arXiv:1707.08817*, 2017.

- [54] O. Vinyals, I. Babuschkin, W. M. Czarnecki, M. Mathieu, A. Dudzik, J. Chung, D. H. Choi, R. Powell, T. Ewalds, P. Georgiev, et al. Grandmaster level in starcraft ii using multi-agent reinforcement learning. *Nature*, 575(7782):350–354, 2019.
- [55] A. Wagenmaker and A. Pacchiano. Leveraging offline data in online reinforcement learning. *arXiv preprint arXiv:2211.04974*, 2022.
- [56] J. Wu, H. Wu, Z. Qiu, J. Wang, and M. Long. Supported policy optimization for offline reinforcement learning. *arXiv preprint arXiv:2202.06239*, 2022.
- [57] C. Xiao, H. Wang, Y. Pan, A. White, and M. White. The in-sample softmax for offline reinforcement learning. In *International Conference on Learning Representations*, 2023. URL <https://openreview.net/forum?id=u-RuvyDYqCM>.
- [58] T. Xie and N. Jiang. Q^* approximation schemes for batch reinforcement learning: A theoretical comparison. In *Conference on Uncertainty in Artificial Intelligence*, pages 550–559. PMLR, 2020.
- [59] T. Xie, C.-A. Cheng, N. Jiang, P. Mineiro, and A. Agarwal. Bellman-consistent pessimism for offline reinforcement learning. *Advances in neural information processing systems*, 34, 2021.
- [60] T. Xie, N. Jiang, H. Wang, C. Xiong, and Y. Bai. Policy finetuning: Bridging sample-efficient offline and online reinforcement learning. *Advances in neural information processing systems*, 34:27395–27407, 2021.
- [61] D. Ye, G. Chen, W. Zhang, S. Chen, B. Yuan, B. Liu, J. Chen, Z. Liu, F. Qiu, H. Yu, Y. Yin, B. Shi, L. Wang, T. Shi, Q. Fu, W. Yang, L. Huang, and W. Liu. Towards playing full moba games with deep reinforcement learning. In H. Larochelle, M. Ranzato, R. Hadsell, M. F. Balcan, and H. Lin, editors, *Advances in Neural Information Processing Systems*, volume 33, pages 621–632. Curran Associates, Inc., 2020. URL <https://proceedings.neurips.cc/paper/2020/file/06d5ae105ea1bea4d800bc96491876e9-Paper.pdf>.
- [62] T. Yu, G. Thomas, L. Yu, S. Ermon, J. Zou, S. Levine, C. Finn, and T. Ma. Mopo: Model-based offline policy optimization. *arXiv preprint arXiv:2005.13239*, 2020.
- [63] A. Zanette, M. J. Wainwright, and E. Brunskill. Provable benefits of actor-critic methods for offline reinforcement learning. *Advances in neural information processing systems*, 34: 13626–13640, 2021.
- [64] Y. Zhai, C. Baek, Z. Zhou, J. Jiao, and Y. Ma. Computational benefits of intermediate rewards for goal-reaching policy learning. *Journal of Artificial Intelligence Research*, 73:847–896, 2022.
- [65] Q. Zheng, A. Zhang, and A. Grover. Online decision transformer. In *International Conference on Machine Learning*, pages 27042–27059. PMLR, 2022.
- [66] H. Zhu, A. Gupta, A. Rajeswaran, S. Levine, and V. Kumar. Dexterous manipulation with deep reinforcement learning: Efficient, general, and low-cost. In *2019 International Conference on Robotics and Automation (ICRA)*, pages 3651–3657. IEEE, 2019.
- [67] Y. Zhu, Z. Wang, J. Merel, A. Rusu, T. Erez, S. Cabi, S. Tunyasuvunakool, J. Kramár, R. Hadsell, N. de Freitas, et al. Reinforcement and imitation learning for diverse visuomotor skills. *arXiv preprint arXiv:1802.09564*, 2018.

附录

A Cal-QL 的实现细节

我们的算法 Cal-QL 在算法 1 中进行了说明。Python 风格的实现见附录 A.2。官方代码和实验日志可在 <https://github.com/nakamotoo/Cal-QL> 获取。

A.1 Cal-QL 算法

我们使用 $J_Q(\theta)$ 来表示 Q 网络更新的校准保守正则化器：

$$J_Q(\theta) := \underbrace{\alpha (\mathbb{E}_{s \sim \mathcal{D}, a \sim \pi} [\max(Q_\theta(s, a), Q^\mu(s, a))] - \mathbb{E}_{s, a \sim \mathcal{D}} [Q_\theta(s, a)])}_{\text{Calibrated conservative regularizer } \mathcal{R}(\theta)} \quad (\text{A.1})$$

$$+ \frac{1}{2} \mathbb{E}_{s, a, s' \sim \mathcal{D}} \left[(Q_\theta(s, a) - \mathcal{B}^\pi \bar{Q}(s, a))^2 \right]. \quad (\text{A.2})$$

Algorithm 1 Cal-QL pseudo-code

- 1: Initialize Q-function, Q_θ , a policy, π_ϕ
- 2: **for** step t in $\{1, \dots, N\}$ **do**
- 3: Train the Q-function using the conservative regularizer in Eq. A.1:

$$\theta_t := \theta_{t-1} - \eta_Q \nabla_\theta J_Q(\theta) \quad (\text{A.3})$$

- 4: Improve policy π_ϕ with SAC-style update:

$$\phi_t := \phi_{t-1} + \eta_\pi \mathbb{E}_{s \sim \mathcal{D}, a \sim \pi_\phi(\cdot|s)} [Q_\theta(s, a) - \log \pi_\phi(a|s)] \quad (\text{A.4})$$

- 5: **end for**
-

A.2 Python 实现

清单 1: 给定一批数据训练 Q 网络

```
q_data = 评论家 (批次 ['观测值'], 批次 ['动作'])

next_dist = actor(batch['next_observations'])
next_pi_actions, next_log_pis = next_dist.sample()

target_qval = target_critic (批次 ['观测值'], next_pi_actions) target_qval = 批次 ['奖励'] + 自身·伽马 * (1 - 批次 ['完成']) *
target_qval

td_loss = mse_loss(q_data, target_qval)

num_samples = 4 random_actions = 均匀分布 ((num_samples, batch_size, action_dim), min=-1, max=1)
random_pi = 0.5 ** 批次 ['动作'].形状 [-1]

pi_actions, log_pis = 演员 (批量数据 ['观测值'])

q_rand_is = 评论家 (批量数据 ['观测值'], random_actions) - random_pi q_pi_is = 评论家 (批量数据 ['观测值'],
pi_actions) - log_pis

# Cal-QL 的修改 mc_return = batch['mc_return'].重复 (num_samples)
q_pi_is = max(q_pi_is, mc_return)

cat_q = 连接 ([q_rand_is, q_pi_is], new_axis=True) cat_q = logsumexp(cat_q, 轴 =0) # 对
num_samples 求和 critic_loss = td_loss + ((cat_q - q_data).均值 () * cq1.alpha)

critic_optimizer.zero_grad () critic_loss.反向
传播 () critic_optimizer.步进 ()
```

清单 2: 给定一批数据训练策略（或演员）

```
# 返回动作分布 pi_actions, log_pis = 演员 (批量数据 ['观测值'])

# 计算演员动作的 q 值 qpi = 评论家 (批量数据 ['观测值'], 动作) qpi
= qpi.最小值 (轴=0)

# 与 CQL (kumar 等人) 相同的目标 actor_loss = (log_pis * self.alpha - qpi).
mean ()

# 优化损失 actor_optimizer.zero_grad ()
actor_loss.backward () actor_optimizer.step
()
```

B 环境细节

B.1 Antmaze

Antmaze 导航任务旨在控制一个 8 自由度蚂蚁四足机器人从起点移动到迷宫中的目标点。智能体将根据是否到达目标获得稀疏的+1/0 奖励。我们在“中等”和“困难”（如图 5 所示）迷宫中研究每种方法，这些迷宫难以解决，使用 D4RL 中的以下数据集 [10]：large-diverse、large-play、medium-diverse 和 medium-play。“diverse”和“play”数据集的区别在于它们所包含轨迹的最优性。“diverse”数据集包含从随机起点到随机目标的轨迹，而“play”数据集包含到特定位置（不一定是目标）的轨迹。每个任务使用 1000 步的回合长度。对于 Cal-QL、CQL 和 IQL，我们使用离线数据集预训练智能体 100 万步。然后对每种方法进行 100 万环境步的在线微调。

B.2 Franka Kitchen

Franka Kitchen 领域要求控制一个 9 自由度 Franka 机器人将厨房环境布置成所需配置。该配置分解为 4 个子任务，智能体将根据已解决的子任务数量获得 0, +1, +2, +3 或 +4 的奖励。要解决整个任务并达到所需配置，不仅需要学习如何解决每个子任务，还需要找出正确的解决顺序。我们使用三种不同最优性的数据集研究该领域：kitchen-complete、kitchen-partial 和 kitchen-mixed。“complete”数据集包含机器人完整执行整个任务的轨迹。“partial”数据集部分包含一些完整演示，而其他则是解决子任务的不完整演示。“mixed”数据集仅包含不完整数据，没有任何完整演示，这很困难，需要最高程度的拼接和泛化能力。每个任务使用 1000 步的回合长度。对于 Cal-QL、CQL 和 IQL，我们使用离线数据集预训练智能体 50 万步。然后对每种方法进行 125 万环境步的在线微调。

B.3 Adroit

阿德罗伊特领域涉及控制一个 24 自由度的影子手机机器人。我们在该领域中考虑 3 个任务：笔-二值、搬移-二值、搬移-二值。这些任务包含一组有限的狭窄人类专家数据分布（ ~ 25 ），并辅自由行为克隆策略收集的额外轨迹。我们截断每条轨迹，并使用正片段（在发现正奖励信号时终止）用于所有方法。该领域的数据集分布非常狭窄，且动作空间很大。此外，由于奖励稀疏，该领域的学习十分困难，这带来了探索挑战。我们采用了先前工作 [44] 中使用的数据集变体，以便与考虑该领域的最先进离线微调实验进行标准比较。在离线学习阶段，我们对智能体进行了 20K 步的预训练。随后，我们对笔-二值任务进行了 300K 环境步的在线微调，对门-二值和搬移-二值任务进行了 1M 环境步的在线微调。笔-二值、门-二值和搬移-二值的回合长度分别为 100、200 和 200。

B.4 视觉操作领域

视觉操作领域包含一个拾取-放置任务。该任务是在机器人预训练 (PTR) [33] 工作中探索的多任务形式。这里每个任务被定义为将一个物体放入一个箱子中。场景中存在一个干扰物体作为对抗性物体，智能体必须避免拾取它。共有 10 个独特物体，任务物体与干扰/分心物体之间没有重叠。回合长度为 40。在离线阶段，我们使用离线数据对策略进行了 50K 步的预训练。随后，我们对每种方法进行了 100K 环境步的在线微调，每个环境步执行 5 次梯度更新。

C 实验细节

C.1 归一化分数

视觉操作、灵巧操作和蚁穴领域均为目标导向的稀疏奖励任务。在这些领域中，我们将归一化度量直接计算为各方法的目标达成率。例如，在视觉操作环境中，若物体被成功放入箱中，则给予智能体 +1 奖励，任务即告完成。类似地，对于灵巧操作任务中的开门二值任务，我们考虑开门成功率。对于厨房任务，任务要求以迭代方式依次解决 4 个子任务。归一化得分直接计算为 $\frac{\text{\#tasks solved}}{\text{总任务数}}$ 。

C.2 混合比例超参数

本文探讨了在线微调阶段使用的混合比例参数 m 。该混合比例取值为 $[0, 1]$ 区间内的值或 -1。若混合比例在 $[0, 1]$ 内，则表示微调时每个批次中离线数据与在线数据的占比。例如，若混合比例为 $m = 0.25$ ，则每个批次中 25% 来自离线数据，75% 来自在线数据。若混合比例为 -1，则两个缓冲区相互拼接并均匀采样。附录 G 中给出了混合比例的消融实验。

C.3 CQL 与 Cal-QL 的细节与超参数

表 3 列出了 CQL 与 Cal-QL 的超参数。我们采用了一种贝尔曼备份变体，通过对下一状态策略采样得到的 k 个动作所计算的目标值取最大值来计算目标值，其中在视觉抓取与放置领域使用 $k = 4$ ，其他领域使用 $k = 10$ 。在蚁穴领域，我们使用了对偶版本的 CQL[32]，并对 CQL 正则化器阈值 $\mathcal{R}(\theta)$ (目标动作间隙) 而非 α 进行了消融。在原始论文未涉及的视觉操作领域，我们对 $\alpha = 0.5, 1, 5, 10$ 的 α 值进行了扫描，并在最终结果中为离线 ($\alpha = 5$) 和在线 ($\alpha = 0.5$) 阶段分别采用了不同的 α 值。我们的代码基于 <https://github.com/young-geng/JaxCQL>[14] 的 CQL 实现构建。每个实验使用单个 NVIDIA TITAN RTX 芯片运行。

C.4 IQL 的细节与超参数

我们在表 4 中列出了 IQL 的超参数。为了进行实验，我们使用了作者提供的 IQL 官方实现 [30]，并主要遵循了他们推荐并在先前工作中经过消融研究的参数。在原始论文未涉及的视觉操作领域，我们对期望值 $\tau = 0.5, 0.6, 0.7, 0.8, 0.9, 0.95, 0.99$ 和温度 $\beta = 1, 3, 5, 10, 25, 50$ 进行了参数扫描，并为最终结果选择了性能最佳的 $\tau = 0.7$ 和 $\beta = 10$ 值。此外，作为视觉操作领域性能第二好的方法，我们还尝试为 IQL 使用单独的 β 值，以便与 CQL 和 Cal-QL 进行公平比较。然而，我们发现其效果微乎其微，如图 10 所示。

C.5 AWAC 和 ODT 的细节与超参数

我们使用了来自 <https://github.com/ikostrikov/jaxrl>[29] 的 AWAC 的 JAX 实现。我们主要遵循了作者推荐的参数，其中在 Antmaze 和 Franka Kitchen 领域使用了拉格朗日乘子

$\lambda = 1.0$ ，在 Adroit 领域使用了 $\lambda = 0.3$ 。在视觉操作领域，我们对 $\lambda = 0.1, 0.3, 1, 3, 10$ 进行了参数扫描，并为最终结果选择了性能最佳的 $\lambda = 1$ 值。对于 ODT，我们使用了作者在 <https://github.com/facebookresearch/online-dt> 中提供的官方实现，并采用了他们在 Antmaze 领域中使用的推荐参数。此外，为了支持我们关于 AWAC 和 ODT 的结果（如表 1 所示），决策 Transformer 和 AWAC 在 Antmaze 领域表现不佳的情况也可以在 IQL 论文 [30] 的表 1 和表 2 中观察到。

C.6 SAC、SAC + 离线数据、混合强化学习和 CQL + SAC 的细节与超参数

我们使用了从 [19] 中的原始实现推导出的 SAC 标准超参数。其他超参数与 CQL 和 Cal-QL 相同。我们对策略和评论家熵项使用了自动熵调节，目标熵为负动作维度。对于 SAC，智能体仅使用在线探索数据进行训练。对于 SAC + 离线数据，离线数据和在线探索数据被合并在一起并均匀采样。对于混合强化学习，我们使用了与表 3 中 CQL 和 Cal-QL 相同的混合比例。对于 CQL + SAC，我们首先使用 CQL 进行预训练，然后使用离线和在线数据进行在线微调，同样使用表 3 中给出的混合比例。

表 3: CQL、Cal-QL 超参数

Hyperparameters	Adroit	Kitchen	Antmaze	Manipulation
α	1	5	-	5 (online: 0.5)
target action gap	-	-	0.8	-
mixing ratio	-1, 0.25, 0.5	-1, 0.25 , 0.5	0.5	0.2, 0.5 , 0.7, 0.9

表 4: IQL 超参数

超参数	Adroit	厨房	Antmaze	操作
expectile τ	0.8	0.7	0.9	0.7
temperature β	3	0.5	10	10
mixing ratio	-1, 0.2 , 0.5	-1, 0.25 , 0.5	0.5	0.2, 0.5 , 0.7, 0.9

D D4RL 运动基准

本节进一步将 Cal-QL 与先前方法在 D4RL 运动基准上进行比较。由于这些任务的数据集不以终止状态结束，我们通过将 SARSA Q 函数拟合到离线数据集，使用神经网络估计参考值函数。表 5 展示了微调前后的归一化分数，表 6 展示了累积遗憾。总体而言，我们观察到 Cal-QL 优于最先进的方法如 IQL 和 AWAC，以及不使用预训练的快速在线强化学习方法（混合强化学习），性能与 CQL 相当。

Task	CQL	IQL	AWAC	Hybrid RL	Cal-QL (Ours)
halfcheetah-expert-v2	0.79 $\rightarrow$ 1.02	0.95 $\rightarrow$ 0.54	0.69 $\rightarrow$ 0.65	N/A $\rightarrow$ 0.84	0.85 $\rightarrow$ 1.00
halfcheetah-medium-expert-v2	0.59 $\rightarrow$ 1.00	0.86 $\rightarrow$ 0.57	0.72 $\rightarrow$ 0.77	N/A $\rightarrow$ 0.86	0.54 $\rightarrow$ 0.99
halfcheetah-medium-replay-v2	0.51 $\rightarrow$ 0.95	0.43 $\rightarrow$ 0.36	0.43 $\rightarrow$ 0.47	N/A $\rightarrow$ 0.89	0.51 $\rightarrow$ 0.93
halfcheetah-medium-v2	0.53 $\rightarrow$ 0.97	0.47 $\rightarrow$ 0.43	0.49 $\rightarrow$ 0.57	N/A $\rightarrow$ 0.88	0.52 $\rightarrow$ 0.93
halfcheetah-random-v2	0.36 $\rightarrow$ 1.01	0.11 $\rightarrow$ 0.54	0.14 $\rightarrow$ 0.37	N/A $\rightarrow$ 0.80	0.33 $\rightarrow$ 1.04
hopper-expert-v2	1.00 $\rightarrow$ 0.73	1.02 $\rightarrow$ 0.52	1.12 $\rightarrow$ 1.11	N/A $\rightarrow$ 0.54	0.58 $\rightarrow$ 0.75
hopper-medium-expert-v2	0.86 $\rightarrow$ 0.92	0.07 $\rightarrow$ 0.81	0.30 $\rightarrow$ 1.03	N/A $\rightarrow$ 1.00	0.69 $\rightarrow$ 0.76
hopper-medium-replay-v2	0.69 $\rightarrow$ 1.11	0.76 $\rightarrow$ 0.86	0.70 $\rightarrow$ 1.08	N/A $\rightarrow$ 0.77	0.76 $\rightarrow$ 1.10
hopper-medium-v2	0.78 $\rightarrow$ 0.99	0.57 $\rightarrow$ 0.26	0.58 $\rightarrow$ 0.90	N/A $\rightarrow$ 1.06	0.89 $\rightarrow$ 0.98
hopper-random-v2	0.09 $\rightarrow$ 1.08	0.08 $\rightarrow$ 0.64	0.09 $\rightarrow$ 0.43	N/A $\rightarrow$ 0.80	0.10 $\rightarrow$ 0.79
walker2d-expert-v2	1.08 $\rightarrow$ 1.12	1.09 $\rightarrow$ 1.02	1.11 $\rightarrow$ 1.24	N/A $\rightarrow$ 1.12	0.92 $\rightarrow$ 1.00
walker2d-medium-expert-v2	1.00 $\rightarrow$ 0.56	1.09 $\rightarrow$ 1.06	0.86 $\rightarrow$ 1.16	N/A $\rightarrow$ 0.95	0.96 $\rightarrow$ 0.77
walker2d-medium-replay-v2	0.76 $\rightarrow$ 0.92	0.63 $\rightarrow$ 0.95	0.60 $\rightarrow$ 0.94	N/A $\rightarrow$ 1.03	0.52 $\rightarrow$ 0.99
walker2d-medium-v2	0.80 $\rightarrow$ 1.11	0.81 $\rightarrow$ 1.04	0.75 $\rightarrow$ 0.98	N/A $\rightarrow$ 0.86	0.75 $\rightarrow$ 1.03
walker2d-random-v2	0.05 $\rightarrow$ 0.85	0.06 $\rightarrow$ 0.09	0.04 $\rightarrow$ 0.04	N/A $\rightarrow$ 0.90	0.04 $\rightarrow$ 0.49
average	0.66 $\rightarrow$ 0.96	0.60 $\rightarrow$ 0.65	0.57 $\rightarrow$ 0.78	N/A $\rightarrow$ 0.89	0.60 $\rightarrow$ 0.90

表 5: D4RL 运动任务在线微调前后的归一化分数。

Task	CQL	IQL	AWAC	Hybrid RL	Cal-QL (Ours)
halfcheetah-expert-v2	0.03	0.47	0.28	0.49	0.08
halfcheetah-medium-expert-v2	0.05	0.42	0.24	0.49	0.07
halfcheetah-medium-replay-v2	0.14	0.65	0.56	0.29	0.16
halfcheetah-medium-v2	0.15	0.61	0.48	0.31	0.17
halfcheetah-random-v2	0.11	0.54	0.67	0.33	0.10
hopper-expert-v2	0.17	0.58	-0.07	0.37	0.22
hopper-medium-expert-v2	0.09	0.32	-0.02	0.32	0.17
hopper-medium-replay-v2	0.09	0.09	0.05	0.27	0.12
hopper-medium-v2	0.04	0.73	0.08	0.26	0.05
hopper-random-v2	0.17	0.54	0.74	0.37	0.27
walker2d-expert-v2	-0.02	0.15	-0.18	0.11	0.15
walker2d-medium-expert-v2	0.03	0.02	-0.14	0.17	0.10
walker2d-medium-replay-v2	0.06	0.10	0.19	0.30	0.13
walker2d-medium-v2	0.11	0.12	0.07	0.29	0.22
walker2d-random-v2	0.53	0.92	0.96	0.56	0.49
average	0.12	0.42	0.26	0.33	0.17

表 6: D4RL 运动任务上的累积遗憾。越小越好, 1.00 为最差。

E 现有微调方法局限性的扩展讨论

本节旨在强调第 4.1 节实证分析实验中其他方法改进缓慢的潜在原因, 具体以 IQL 为分析对象。我们首先扫描了 IQL 在线微调阶段使用的温度 β 值, 该值控制学习策略与行为策略匹配程度的约束。如图 10 所示, 温度 β 的变化对样本效率几乎没有影响。另一个自然的假设是 IQL 改进缓慢是因为每单位环境收集的数据更新次数不足。为探究这一点, 我们运行了 IQL, 设置 **(a)** 每步数据收集五倍的梯度步数 ($UTD = 5$), 以及 **(b)** 更激进的策略更新。从图 11 中观察到, **(a)** 并未提高 IQL 的渐近性能, 尽管它确实提高了 CQL, 表明通过更多梯度更新在该任务上仍有改进空间。从图 11 中观察到, **(b)** 经常导致策略遗忘, 类似于 CQL 中的失败模式。这两项观察共同表明, 策略约束方法会渐近地减慢学习速度, 而无法通过更激进的更新来提高速度, 因为这会导致策略找到错误乐观的分布外动作, 并遗忘从离线数据中学到的策略。




图 10: IQL 在线温度值的消融实验: 在线微调阶段所用温度 β 的变化对样本效率几乎没有影响。




图 11: IQL 与 CQL: x 轴上的第 0 步表示离线预训练后的性能。可以观察到, CQL 在初始策略遗忘中受损, 而 IQL 在整个微调过程中提升较慢。

F CQL 在多任务上的初始遗忘




图 12: 虽然 CQL 经历了初始遗忘, 但 Cal-QL 有效缓解了该问题并迅速恢复性能。

在本节中, 我们展示了图 6 中 CQL 和 Cal-QL 的学习曲线, 并放大 x 轴以更清晰地展示 CQL 在 Franka Kitchen、Adroit 和视觉操作领域的初始遗忘。如图 12 所示, 在所有任务中都可以明显看出, 虽然 CQL 经历了初始遗忘, 但 Cal-QL 能够有效缓解该问题并迅速恢复性能。关于 Antmaze 领域, 正如我们在第 7.3 节中讨论的, 由于默认数据集具有较高的数据覆盖率, CQL 并未表现出初始遗忘。然而, 如果缩小数据集分布 (如图 8 所示), 我们可以观察到类似现象。

G 混合比例超参数的消融实验

这里我们展示了在 adroit door-binary 任务上, Cal-QL (左) 和 IQL (右) 关于混合比例的消融实验。可能正如直觉所预期的那样, 我们通常观察到这样的趋势: 较大的混合比例 (即更多的离线数据) 在在线微调过程中表现出较慢的性能提升。




图 13: 在 adroit door-binary 任务上, Cal-QL (左) 和 IQL (右) 关于混合比例的消融实验。

H Cal-QL 的遗憾分析

我们在算法 2 中提供了 Cal-QL 的理论版本。策略微调已在不同设定下得到研究 [60, 52, 55]。我们的分析主要采用 Song 等人 [52] 中的设定和结果, 并在假设 H.1、假设 H.3 和定义 H.4 中做了额外修改。注意, 本证明的目标是展示悲观函数类 (假设 H.1) 允许高效利用离线数据, 而非为遗憾分析提供新的分析技术。

参见第 H.3 节与第 I.1 节的比较。注意，为符号简洁，我们在正文中使用 f 而非 Q_θ 来表示估计的 Q 函数。

Algorithm 2 Theoretical version of Cal-QL

- 1: **Input:** Value function class $\mathcal{F}$, # total iterations K , offline dataset $\mathcal{D}_h^\nu$ of size m_{off} for $h \in [H-1]$.
- 2: Initialize $f_h^1(s, a) = 0, \forall (s, a)$.
- 3: **for** $k = 1, \dots, K$ **do**
- 4: Let π^k be the greedy policy w.r.t. f^k $\triangleright$ I.e., $\pi_h^k(s) = \arg \max_a f_h^k(s, a)$.
- 5: For each h , collect m_{on} online tuples $\mathcal{D}_h^k \sim d_h^{\pi^k}$ $\triangleright$ online data collection
- 6: Set $f_H^{k+1}(s, a) = 0, \forall (s, a)$.
- 7: **for** $h = H-1, \dots, 0$ **do** $\triangleright$ FQI with offline and online data
- 8: Estimate f_h^{k+1} using **conservative** least squares on the aggregated data: $\triangleright$ I.e., **CQL**
regularized class $\mathcal{C}_h$
- $$f_h^{k+1} \leftarrow \arg \min_{f \in \mathcal{C}_h} \left\{ \widehat{\mathbb{E}}_{\mathcal{D}_h^\nu} \left[f(s, a) - r - \max_{a'} f_{h+1}^{k+1}(s', a') \right]^2 + \sum_{\tau=1}^K \widehat{\mathbb{E}}_{\mathcal{D}_h^\tau} \left[f(s, a) - r - \max_{a'} f_{h+1}^{k+1}(s', a') \right]^2 \right\}$$
(H.1)
- 9: $f_h^{k+1} = \max\{f_h^{k+1}, Q_h^{\text{ref}}\}$ $\triangleright$ Set a reference policy for calibration (Definition 4.1)
- 10: **end for**
- 11: **end for**
- 12: **Output:** π^K

H.1 预备知识

在本小节中，我们沿用 Song 等人 [52] 中的大部分符号和定义。特别地，我们考虑有限时域情形，其中价值函数和 Q 函数定义为：

$$V_h^\pi(s) = \mathbb{E} \left[\sum_{\tau=h}^{H-1} r_\tau \mid \pi, s_h = s \right] \quad (\text{H.2})$$

$$Q_h^\pi(s, a) = \mathbb{E} \left[\sum_{\tau=h}^{H-1} r_\tau | \pi, s_h = s, a_h = a \right]. \quad (\text{H.3})$$

我们还定义贝尔曼算子 $\mathcal{T}$ ，使得 $\forall f: \mathcal{S} \times \mathcal{A}$:

$$\mathcal{T}f(s, a) = \mathbb{E}_{s,a}[R(s, a)] + \mathbb{E}_{s' \sim P(s, a)} \max_{a'} f(s', a'), \quad \forall (s, a) \in \mathcal{S} \times \mathcal{A}, \quad (\text{H.4}), \quad \text{其中 } R(s, a) \in \Delta[0, 1]$$

表示随机奖励函数。

H.2 符号

- 特征协方差矩阵 $\Sigma_{k;h}$:

$$\Sigma_{k;h} = \sum_{\tau=1}^k X_h(f^\tau)(X_h(f^\tau))^\top + \lambda \mathbf{I} \quad (\text{H.5})$$

- 矩阵范数 (Matrix Norm) Zanette 等人 [63]: 对于矩阵 Σ , 矩阵范数 $\|u\|_{\Sigma}$ 定义为:

$$\|u\|_{\Sigma} = \sqrt{u \Sigma u^{\top}} \quad (\text{H.6})$$

- 加权 ℓ^2 范数: 对于给定分布 $\beta \in \Delta(\mathcal{S} \times \mathcal{A})$ 和函数 $f: \mathcal{S} \times \mathcal{A} \mapsto \mathbb{R}$, 我们将加权 ℓ^2 范数表示为:

$$\|f\|_{2,\beta}^2 := \sqrt{\mathbb{E}_{(s,a) \sim \beta} f^2(s,a)} \quad (\text{H.7})$$

- 随机奖励函数 $R(s, a) \in \Delta([0, 1])$ • 对于每个离线数据分布 $\nu = \{\nu_0, \dots, \nu_{H-1}\}$ ，时间步 h 处的离线数据集包含数据样本 $(\nu_h, (s, a, r))$ ，其中 $(s, a, r) \in R(s, a), s' \sim P(s, a)$.

表示由 π 在步骤 h 处引起的状态-动作占用。
 给定一个策略 $\pi := \{\pi_0, \dots, \pi_{H-1}\}$, 其中 $\pi_h : \mathcal{S} \mapsto \Delta(\mathcal{A})$, $d_h^\pi \in \Delta(s, a)$
 upancy induced b

- 我们考虑基于价值的函数逼近设置, 其中给定一个函数
 class $\mathcal{C} = \mathcal{C}_0 \times \dots \mathcal{C}_{H-1}$ with $\mathcal{C}_h \subset \mathcal{S} \times \mathcal{A} \mapsto [0, V_{\max}]$.
- 策略 π^f 被定义为关于 $f: \pi^f$ 的贪婪策略 $h(s) = \arg \max_a f_h(s, a)$ 。具体来说, 在第 k 次迭代中, 我们使用 π^k 来表示关于 f^k 的贪婪策略。

H.3 假设与定义

假设 H.1 (悲观可实现性与完整性)。对于任意策略 π^e , 若对于任意 h , 有 $Q_h^{\pi^e} \in \mathcal{C}_h$, 且对于任意 $f_{h+1} \in \mathcal{C}_{h+1}$, 有 $\mathcal{T}f_{h+1} \in \mathcal{C}_h$ 和 $f_h(s, a) \leq Q_h^{\pi^e}(s, a), \forall (s, a) \in \mathcal{S} \times \mathcal{A}$, 则称 $\mathcal{C}_h$ 是关于 π^e 的悲观函数类。

定义 H.2 (双线性模型 Du 等人 [9])。我们称马尔可夫决策过程与函数类 $\mathcal{F}$ 构成秩为 d 的双线性模型, 若对任意 $h \in [H-1]$, 存在两个 (已知的) 映射 $X_h, W_h : \mathcal{F} \mapsto \mathbb{R}^d$, 满足 $\max_f \|X_h(f)\|_2 \leq B_X$ 且 $\max_f \|W_h(f)\|_2 \leq B_W$, 使得

$$\forall f, g \in \mathcal{F} : \left| \mathbb{E}_{s, a \sim d_h^{\pi^f}} [g_h(s, a) - \mathcal{T}g_{h+1}(s, a)] \right| = |\langle X_h(f), W_h(g) \rangle|. \quad (\text{H.8})$$

假设 H.3 (参考策略的双线性秩)。假设 $Q^{\text{ref}} \in \mathcal{C}_{\text{ref}} \subset \mathcal{C}$, 其中 $\mathcal{C}_{\text{ref}}$ 是参考策略的函数类, 我们假设 $\mathcal{C}_{\text{ref}}$ 的双线性秩为 d_{ref} 和 $d_{\text{ref}} \leq d$ 。

定义 H.4 (校准贝尔曼误差传递系数)。对于任意策略 π , 我们定义相对于参考策略 π 的校准传递系数为

$$C_\pi^{\text{ref}} := \max_{f \in \mathcal{C}, f(s, a) \geq Q^{\text{ref}}(s, a)} \frac{\sum_{h=0}^{H-1} \mathbb{E}_{s, a \sim d_h^\pi} [\mathcal{T}f_{h+1}(s, a) - f_h(s, a)]}{\sqrt{\sum_{h=0}^{H-1} \mathbb{E}_{s, a \sim \nu_h} (\mathcal{T}f_{h+1}(s, a) - f_h(s, a))^2}}, \quad (\text{H.9})$$

其中 $Q^{\text{ref}} = Q^{\pi^{\text{ref}}}$.

H.4 关于假设的讨论

悲观可实现性与完备性假设 (假设 H.1) 受到一些关于带正则化项的悲观离线方法 [59, 6] 的理论研究的启发:

$$\min_{\theta} \underbrace{\alpha (\mathbb{E}_{s \sim \mathcal{D}, a \sim \pi} [Q_\theta(s, a)] - \mathbb{E}_{s, a \sim \mathcal{D}} [Q_\theta(s, a)])}_{\text{Conservative regularizer } \mathcal{R}(\theta)} + \frac{1}{2} \mathbb{E}_{s, a, s' \sim \mathcal{D}} \left[(Q_\theta(s, a) - \mathcal{B}^\pi \bar{Q}(s, a))^2 \right]. \quad (\text{H.10})$$

由于保守正则化项 $\mathcal{R}(\theta)$ 的目标本质上希望强制 $Q_\theta(s, \pi(s)) \leq Q_\theta(s, \pi^e(s))$, (H.11), 其中 π 是

训练策略, π^e 是参考 (行为) 策 $Q_\theta(s, \pi(s)) \leq Q_\theta(s, \pi^e(s))$,
 略。可以将 (H.10) 视为以下原始

优化问题的拉格朗日对偶形式:

$$\min_{\theta} \mathbb{E}_{s, a, s' \sim \mathcal{D}} \left[(Q_\theta(s, a) - \mathcal{B}^\pi \bar{Q}(s, a))^2 \right], \quad \mathbb{E}_{s \sim \mathcal{D}, a \sim \pi} [Q_\theta(s, a)] \leq \mathbb{E}_{s \sim \mathcal{D}, a \sim \pi^e} [Q_\theta(s, a)],$$

约束条件为 (H.12), 其中约束集等价于假设 H.1。尽管假设 H.1 直接刻画了 (H.10) 原始形式的约束集, 但悲观可实现性与正则化贝尔曼一致性方程之间的确切理论联系超出了本文的范围, 我们将其留待未来研究。假设 H.1 允许我们将感兴趣的函数类限制为更小的保守函数类 $\mathcal{C} \subset \mathcal{F}$, 这导致参考策略 ($d_{\text{ref}} \leq d$) 的贝尔曼秩更小 (如假设 H.3 所建议), 以及定义 H.4 和 L.2 中定义的更小的集中系数 ($C_\pi^{\text{ref}} \leq C_\pi$)。假设 H.3 和定义 L.2 给出了感兴趣的悲观函数类 $\mathcal{C}$ 的贝尔曼双线性秩和贝尔曼误差传递系数。

H.5 证明结构概述

我们在下面概述证明结构及其对不同假设的依赖关系：

- 定理 H.5：总遗憾被分解为离线遗憾和在线遗憾。
 - 界定离线遗憾，需要定义 H.4 和以下引理：* 相对于比较策略的性能差异引理（引理 I.5）。* 最小二乘泛化界（引理 I.4），需要假设 H.1。
 - 界定在线遗憾，需要定义 H.2 * 在线误差的性能差异引理（引理 I.6）。* 最小二乘泛化界（引理 I.4），需要假设 H.1。* 使用双线性模型假设的上界（引理 I.7）。* 应用椭圆势引理 [35]，结合贝尔曼秩 d 和 d_{ref} （引理 I.8），需要假设 H.3）。

H.6 我们的结果

定理 H.5（定理 6.1 的正式结果）。固定 $\delta \in (0, 1)$, $m_{\text{off}} = K$, $m_{\text{on}} = 1$ ，假设函数类 $\mathcal{C}$ 满足假设 H.1 w.r.t. π^e 。假设底层 MDP 在函数类 $\mathcal{C}$ 上具有双线性秩 d ，在 $\mathcal{C}_{\text{ref}}$ 上具有 d_{ref} ，则以至少 $1 - \delta$ 的概率，算法 2 相对于任何比较策略 π^e 获得以下累积次优性界：

$$\sum_{t=1}^K V^{\pi^e} - V^{\pi^k} = \tilde{O} \left(\min \left\{ C_{\pi^e}^{\text{ref}} H \sqrt{dK \log(|\mathcal{F}|/\delta)}, K \left(V^{\pi^e} - V^{\text{ref}} \right) + H \sqrt{d_{\text{ref}} K \log(|\mathcal{F}|/\delta)} \right\} \right). \quad (\text{H.13})$$

注意，定理 H.5 为任何比较策略 π^e 提供了保证，可直接应用于我们非正式结果（定理 6.1）中描述的 π^* 。为了证明中的符号一致性，我们还将参考策略的符号从定理 6.1 中的 μ 改为 π^{ref} （类似地， $d_{\text{ref}}, V^{\text{ref}}, C_{\pi^e}^{\text{ref}}$ 对应于定理 6.1 中的 $d_\mu, V^\mu, C_{\pi^e}^\mu$ ）。我们对定理 H.5 的证明主要遵循 [52] 的定理 1 的证明，主要变化源于假设 H.1、假设 H.3 和定义 H.4。

证明。设 $\mathcal{E}_k$ 表示事件 $\{f_0^k(s, a) \leq Q^{\text{ref}}(s, a)\}$ ， $\bar{\mathcal{E}}_k$ 表示事件 $\{f_0^k(s, a) > Q^{\text{ref}}(s, a)\}$ 。设 $V^{\text{ref}}(s) = \max_a Q^{\text{ref}}(s, a)$ ，我们首先注意到

$$\begin{aligned} \sum_{k=1}^K V^{\pi^e} - V^{\pi^{f^k}} &= \sum_{k=1}^K \mathbb{E}_{s \sim \rho} \left[V_0^{\pi^e}(s) - V_0^{\pi^{f^k}}(s) \right] \\ &= \underbrace{\sum_{k=1}^K \mathbb{E}_{s \sim \rho} \left[\mathbb{1}\{\bar{\mathcal{E}}_k\} \left(V_0^{\pi^e}(s) - V^{\text{ref}}(s) \right) \right]}_{\Gamma_0} + \underbrace{\sum_{k=1}^K \mathbb{E}_{s \sim \rho} \left[\mathbb{1}\{\bar{\mathcal{E}}_k\} \left(V^{\text{ref}}(s) - \max_a f_0^k(s, a) \right) \right]}_{=0, \text{ by the definition of } \bar{\mathcal{E}}_k \text{ and line 9 of Algorithm 2}} \\ &\quad + \underbrace{\sum_{t=1}^K \mathbb{E}_{s \sim \rho} \left[\mathbb{1}\{\bar{\mathcal{E}}_k\} \left(\max_a f_0^k(s, a) - V_0^{\pi^{f^k}}(s) \right) \right]}_{\Gamma_1} + \underbrace{\sum_{k=1}^K \mathbb{E}_{s \sim \rho} \left[\mathbb{1}\{\mathcal{E}_k\} \left(V_0^{\pi^e}(s) - \max_a f_0^k(s, a) \right) \right]}_{\Gamma_2} \\ &\quad + \underbrace{\sum_{t=1}^T \mathbb{E}_{s \sim \rho} \left[\mathbb{1}\{\mathcal{E}_k\} \left(\max_a f_0^k(s, a) - V_0^{\pi^{f^k}}(s) \right) \right]}_{\Gamma_3}. \end{aligned} \quad (\text{H.14})$$

Let $K_1 = \sum_{k=1}^K \mathbb{1}\{f_0^k(s, a) > Q^{\text{ref}}(s, a)\}$ and $K_2 = \sum_{k=1}^K \mathbb{1}\{f_0^k(s, a) \leq Q^{\text{ref}}(s, a)\}$ (or equivalently $K_1 = \sum_{k=1}^K \mathbb{1}\{\bar{\mathcal{E}}_k\}$, $K_2 = \sum_{k=1}^K \mathbb{1}\{\mathcal{E}_k\}$)。对于 Γ_0 ，我们有

$$\Gamma_0 = K_2 \mathbb{E}_{s \sim \rho} \left(V^{\pi^e}(s) - V^{\text{ref}}(s) \right). \quad (\text{H.15})$$

对于 Γ_2 ，我们有

$$\begin{aligned}
\Gamma_2 &= \sum_{k=1}^K \mathbb{E}_{s \sim \rho} \left[\mathbb{1} \{ \mathcal{E}_k \} \left(V_0^{\pi^e}(s) - \max_a f_0^k(s, a) \right) \right] \\
&\stackrel{(i)}{\leq} \sum_{k=1}^K \mathbb{1} \{ \mathcal{E}_k \} \sum_{h=0}^{H-1} \mathbb{E}_{s, a \sim d_h^{\pi^e}} [\mathcal{T} f_{h+1}^k(s, a) - f_h^k(s, a)] \\
&\stackrel{(ii)}{\leq} \sum_{k=1}^K \left[C_{\pi^e}^{\text{ref}} \cdot \mathbb{1} \{ \mathcal{E}_k \} \sqrt{\sum_{h=0}^{H-1} \mathbb{E}_{s, a \sim \nu_h} \left[(f_h^k(s, a) - \mathcal{T} f_{h+1}^k(s, a))^2 \right]} \right] \\
&\stackrel{(iii)}{\leq} K_1 C_{\pi^e}^{\text{ref}} \sqrt{H \cdot \Delta_{\text{off}}},
\end{aligned} \tag{H.16}$$

其中 Δ_{off} 的定义与 Song 等人 [52] 类似（见引理 I.4 的 (I.3)）。不等式 (i) 成立是因为引理 I.5，不等式 (ii) 成立是根据 $C_{\pi^e}^{\text{ref}}$ 的定义（定义 H.4），不等式 (iii) 成立是通过满足假设 H.1 和定义 H.4 的函数类应用引理 I.4。注意上述方程中的望远镜分解技术也出现在 [58, 24, 9] 中。接下来，我们将界定 $\Gamma_1 + \Gamma_3$ ：

$$\begin{aligned}
\Gamma_1 + \Gamma_3 &= \sum_{k=1}^K (\mathbb{1} \{ \mathcal{E}_k \} + \mathbb{1} \{ \bar{\mathcal{E}}_k \}) \mathbb{E}_{s \sim d_0} \left[\max_a f_0^k(s, a) - V_0^{\pi^{f^k}}(s) \right] \\
&\stackrel{(i)}{\leq} \sum_{k=1}^K (\mathbb{1} \{ \mathcal{E}_k \} + \mathbb{1} \{ \bar{\mathcal{E}}_k \}) \sum_{h=0}^{H-1} \left| \mathbb{E}_{s, a \sim d_h^{\pi^{f^k}}} [f_h^k(s, a) - \mathcal{T} f_{h+1}^k(s, a)] \right| \\
&\stackrel{(ii)}{=} \sum_{k=1}^K \left[(\mathbb{1} \{ \mathcal{E}_k \} + \mathbb{1} \{ \bar{\mathcal{E}}_k \}) \sum_{h=0}^{H-1} |\langle X_h(f^k), W_h(f^k) \rangle| \right] \\
&\stackrel{(iii)}{\leq} \sum_{k=1}^K \left[(\mathbb{1} \{ \mathcal{E}_k \} + \mathbb{1} \{ \bar{\mathcal{E}}_k \}) \sum_{h=0}^{H-1} \|X_h(f^k)\|_{\Sigma_{k-1;h}^{-1}} \sqrt{\Delta_{\text{on}} + \lambda B_W^2} \right],
\end{aligned} \tag{H.17}$$

其中 Δ_{on} 的定义与 Song 等人 [52] 类似（见引理 I.4 的 (I.4)）。不等式 (i) 成立是根据引理 I.6，方程 (ii) 成立是根据双线性模型的定义（定义 H.2 中的 (H.8)），不等式 (iii) 成立是根据引理 I.7 和对满足假设 H.1 的函数类应用引理 I.4。利用引理 I.8，我们有 $\Gamma_1 + \Gamma_3$

$$\begin{aligned}
&\leq \sum_{k=1}^K \left[(\mathbb{1} \{ \mathcal{E}_k \} + \mathbb{1} \{ \bar{\mathcal{E}}_k \}) \sum_{h=0}^{H-1} \|X_h(f^k)\|_{\Sigma_{k-1;h}^{-1}} \sqrt{\Delta_{\text{on}} + \lambda B_W^2} \right] \\
&\stackrel{(i)}{\leq} H \sqrt{2d \log \left(1 + \frac{K_1 B_X^2}{\lambda d} \right) \cdot (\Delta_{\text{on}} + \lambda B_W^2) \cdot K_1} + H \sqrt{2d_{\text{ref}} \log \left(1 + \frac{K_2 B_X^2}{\lambda d_{\text{ref}}} \right) \cdot (\Delta_{\text{on}} + \lambda B_W^2) \cdot K_2} \\
&\stackrel{(ii)}{\leq} H \left(\sqrt{2d \log \left(1 + \frac{K_1}{d} \right) \cdot (\Delta_{\text{on}} + B_X^2 B_W^2) \cdot K_1} + \sqrt{2d_{\text{ref}} \log \left(1 + \frac{K_2}{d_{\text{ref}}} \right) \cdot (\Delta_{\text{on}} + B_X^2 B_W^2) \cdot K_2} \right),
\end{aligned} \tag{H.18}$$

其中不等式 (i) 的第一部分成立是因为当 $\bar{\mathcal{E}}_k$ 发生时，底层 MDP 具有贝尔曼秩 d （定义 H.2），不等式 (i) 的第二部分成立是因为 $\mathcal{C}_{\text{ref}}$ 具有双线性秩 d_{ref} （假设 H.3） $\mathcal{C}_{\text{ref}}$ 在 $\mathcal{E}_k$ 发生时具有贝尔曼秩 d_{ref} 。不等式 (ii) 成立是通过代入 $\lambda = B_X^2$ 。将 (H.15)、不等式 H.16 和不等式 (H.18) 代入 (H.14)，我们有

$$\begin{aligned}
\sum_{t=1}^K V^{\pi^e} - V^{\pi^{f^k}} &\leq \Gamma_0 + \Gamma_2 + \Gamma_1 + \Gamma_3 \leq K_2 \left(V^{\pi^e}(s) - V^{\text{ref}}(s) \right) + K_1 C_{\pi^e}^{\text{ref}} \sqrt{H \cdot \Delta_{\text{off}}} \\
&+ H \left(\sqrt{2d \log \left(1 + \frac{K_1}{d} \right) \cdot (\Delta_{\text{on}} + B_X^2 B_W^2) \cdot K_1} + \sqrt{2d_{\text{ref}} \log \left(1 + \frac{K_2}{d_{\text{ref}}} \right) \cdot (\Delta_{\text{on}} + B_X^2 B_W^2) \cdot K_2} \right)
\end{aligned} \tag{H.19}$$

将 (I.3) 和 (I.4) 中 $\Delta_{\text{on}}, \Delta_{\text{off}}$ 的值代入, 并利用平方根函数的次可加性, 我们有

$$\begin{aligned}
& \sum_{k=1}^K V^{\pi^e} - V^{\pi^{f^k}} \\
& \leq K_2 \left(V^{\pi^e}(s) - V^{\text{ref}}(s) \right) + 16V_{\max} C_{\pi^e}^{\text{ref}} K_1 \sqrt{\frac{H}{m_{\text{off}}} \log \left(\frac{2HK_1|\mathcal{F}|}{\delta} \right)} \\
& \quad + \left(16V_{\max} \sqrt{\frac{1}{m_{\text{on}}} \log \left(\frac{2HK_1|\mathcal{F}|}{\delta} \right)} + B_X B_W \right) \cdot H \sqrt{2dK_1 \log \left(1 + \frac{K_1}{d} \right)} \\
& \quad + \left(16V_{\max} \sqrt{\frac{1}{m_{\text{on}}} \log \left(\frac{2HK_2|\mathcal{F}|}{\delta} \right)} + B_X B_W \right) \cdot H \sqrt{2d_{\text{ref}} K_2 \log \left(1 + \frac{K_2}{d_{\text{ref}}} \right)}.
\end{aligned} \tag{H.20}$$

在上述方程中令 $m_{\text{off}} = K, m_{\text{on}} = 1$ 即完成证明, 我们有

$$\begin{aligned}
& \sum_{k=1}^K V^{\pi^e} - V^{\pi^k} \\
& \leq \tilde{O} \left(C_{\pi^e}^{\text{ref}} \sqrt{HK_1 \log(|\mathcal{F}|/\delta)} \right) + \tilde{O} \left(H \sqrt{dK_1 \log(|\mathcal{F}|/\delta)} \right) \\
& \quad + K_2 \left(V^{\pi^e}(s) - V^{\text{ref}}(s) \right) + \tilde{O} \left(H \sqrt{d_{\text{ref}} K_2 \log(|\mathcal{F}|/\delta)} \right) \\
& \leq \begin{cases} \tilde{O} \left(C_{\pi^e}^{\text{ref}} H \sqrt{dK_1 \log(|\mathcal{F}|/\delta)} \right) & \text{if } K_1 \gg K_2, \\ \tilde{O} \left(K_2 (V^{\pi^e} - V^{\text{ref}}) + H \sqrt{d_{\text{ref}} K_2 \log(|\mathcal{F}|/\delta)} \right) & \text{otherwise.} \end{cases} \\
& \leq \tilde{O} \left(\min \left\{ C_{\pi^e}^{\text{ref}} H \sqrt{dK \log(|\mathcal{F}|/\delta)}, K (V^{\pi^e} - V^{\text{ref}}) + H \sqrt{d_{\text{ref}} K \log(|\mathcal{F}|/\delta)} \right\} \right),
\end{aligned} \tag{H.21}$$

其中最后一个不等式成立是因为 $K_1, K_2 \leq K$, 从而完成了证明。 $\square$

I Hy-Q 的关键结果 [52]

在本节中, 为了完整性, 我们重述 Hy-Q 的主要理论结果 [52]。

I.1 假设

假设 I.1 (可实现性与贝尔曼完备性)。对于任意 h , 我们有 $Q_h^* \in \mathcal{F}_h$, 并且此外, 对于任意 $f_{h+1} \in \mathcal{F}_{h+1}$, 我们有 $\mathcal{T}f_{h+1} \in \mathcal{F}_h$ 。定义 I.2 (贝尔曼误差传递系数)。对于任意策略 π , 我们将传递系数定义为

$$C_{\pi} := \max \left\{ 0, \max_{f \in \mathcal{F}} \frac{\sum_{h=0}^{H-1} \mathbb{E}_{s,a \sim d_h^{\pi}} [\mathcal{T}f_{h+1}(s,a) - f_h(s,a)]}{\sqrt{\sum_{h=0}^{H-1} \mathbb{E}_{s,a \sim \nu_h} (\mathcal{T}f_{h+1}(s,a) - f_h(s,a))^2}} \right\}. \tag{I.1}$$

I.2 Hy-Q 的主要定理

定理 I.3 (宋等人 [52] 的定理 1)。固定 $\delta \in (0, 1), m_{\text{off}} = K, m_{\text{on}} = 1$, 并假设底层马尔可夫决策过程 (MDP) 具有双线性秩 d (定义 H.2), 且函数类 $\mathcal{F}$ 满足假设 I.1。则以至少 $1 - \delta$ 的概率, HyQ 对任意比较策略 π^e 获得如下累积次优性界:

$$\text{Reg}(K) = \tilde{O} \left(\max\{C_{\pi^e}, 1\} V_{\max} B_X B_W \sqrt{dH^2 K \cdot \log(|\mathcal{F}|/\delta)} \right). \tag{I.2}$$

I.3 关键引理

I.3.1 最小二乘泛化及其应用

引理 I.4 (宋等人 [52] 的引理 7, FQI 的在线与离线贝尔曼误差界)。设 $\delta \in (0, 1)$ 和 $\forall h \in [H-1], k \in [K]$, 令 f_h^{k+1} 为时间步 h 的估计值函数

computed via least square regression using samples in the dataset $\{\mathcal{D}_h^0, \mathcal{D}_h^1, \dots, \mathcal{D}_h^T\}$ in (H.1) in the iteration t of Algorithm 2. Then with probability at least $1 - \delta$, for any $h \in [H - 1]$ and $k \in [K]$, we have

$$\|f_h^{k+1} - \mathcal{T}f_{h+1}^{k+1}\|_{2, \nu_h}^2 \leq \frac{1}{m_{\text{off}}} 256V_{\max}^2 \log(2HK|\mathcal{F}|/\delta) =: \Delta_{\text{off}} \quad (\text{I.3})$$

且

$$\sum_{\tau=1}^k \|f_h^{k+1} - \mathcal{T}f_{h+1}^{k+1}\|_{2, \mu_h^\tau}^2 \leq \frac{1}{m_{\text{on}}} 256V_{\max}^2 \log(2HK|\mathcal{F}|/\delta) =: \Delta_{\text{on}}, \quad (\text{I.4})$$

其中 ν_h 表示时间 h 的离线数据分布，分布 $\mu_h^\tau \in \Delta(s, a)$ 定义为使得 $s, a \sim d_h^{\pi^\tau}$ 。

I.3.2 通过性能差异引理界定离线次优性

引理 I.5 (Song 等人 [52] 的引理 5, 关于 π^e 的性能差异引理) 设 $\pi^e = (\pi_0^e, \dots, \pi_{H-1}^e)$ 为比较策略，并考虑任意值函数 $f = (f_0, \dots, f_{H-1})$ ，其中 $f_h : \mathcal{S} \times \mathcal{A} \mapsto \mathbb{R}$ 。则有

$$\mathbb{E}_{s \sim d_0} \left[V_0^{\pi^e}(s) - \max_a f_0(s, a) \right] \leq \sum_{i=1}^{H-1} \mathbb{E}_{s, a \sim d_i^{\pi^e}} [\mathcal{T}f_{i+1}(s, a) - f_i(s, a)], \quad (\text{I.5})$$

其中我们定义 $f_H(s, a) = 0, \forall (s, a)$ 。

I.3.3 通过性能差异引理界定在线次优性

引理 I.6 (Song 等人 [52] 的引理 4, 性能差异引理)。对于任意满足 $f = (f_0, \dots, f_{H-1})$ $f_h : \mathcal{S} \times \mathcal{A} \mapsto \mathbb{R}$ 和 $h \in [H - 1]$ 的函数，我们有

$$\mathbb{E}_{s \sim d_0} \left[\max_a f_0(s, a) - V_0^{\pi^f}(s) \right] \leq \sum_{h=0}^{H-1} \left| \mathbb{E}_{s, a \sim d_h^{\pi^f}} [f_h(s, a) - \mathcal{T}f_{h+1}(s, a)] \right|, \quad (\text{I.6})$$

其中我们定义 $f_H(s, a) = 0, \forall s, a$ 。

引理 I.7 (Song 等人 [52] 的命题 4.5) 的 Spoke 双线性类上界)。对于任意 $k \geq 2$ 和 $h \in [H - 1]$ ，我们有

$$|\langle W_h(f^k), X_h(f^k) \rangle| \leq \|X_h(f^k)\|_{\Sigma_{k-1;h}^{-1}} \sqrt{\sum_{i=1}^{k-1} \mathbb{E}_{s, a \sim d_h^{f^i}} [(f_h^k - \mathcal{T}f_{h+1}^k)^2]} + \lambda B_W^2, \quad (\text{I.7})$$

某表示 $k-1$ 的逆协方差范数 (Song 等人 [52] 的引理 6, 界定逆协方差范数)。设 $X_h(f^1), \dots, X_h(f^K) \in \mathbb{R}^d$ 为一向量序列，满足 $\|X_h(f^k)\|_2 \leq B_X < \infty, \forall k \leq K$ ，则有 $\sum_{k=1}^K$

$$\|X_h(f^k)\|_{\Sigma_{k-1;h}^{-1}} \leq \sqrt{2dK \log \left(1 + \frac{KB_X^2}{\lambda d} \right)}, \quad (\text{I.8})$$

where we define $\Sigma_{k;h} := \sum_{\tau=1}^k X_h(f^\tau)X_h(f^\tau)^T + \lambda \mathbf{I}$ 并且我们假设 $\lambda \geq B_X^2$ holds $\forall k \in [K]$ 。