

Centaur: Robust End-to-End Autonomous Driving with Test-Time Training

Chonghao Sima^{1,2*}Kashyap Chitta^{3,4*}Zhiding Yu²Shiyi Lan²Ping Luo¹Andreas Geiger^{3,4}Hongyang Li¹Jose M. Alvarez²¹ The University of Hong Kong² NVIDIA³ University of Tübingen⁴ Tübingen AI Center

Abstract

在部署过程中，我们如何信赖端到端自动驾驶车辆复杂的决策系统？一种常见的解决方案是设置一个“后备层”，该层检查规划轨迹是否存在规则违反，并在必要时用预定义的安全动作替换它。另一种方法涉及调整规划器的决策，以最小化预定义的“代价函数”，利用额外的系统预测，如道路布局和检测到的障碍物。然而，这些预编程的规则或代价函数无法通过新的训练数据学习和改进，往往导致过于保守的行为。在这项工作中，我们提出了 **Centaur**（基于不确定性的测试时训练聚类熵），它通过测试时训练更新规划器的行为，而不依赖手工设计的规则或代价函数。相反，我们测量并最小化规划器决策中的不确定性。为此，我们开发了一种新颖的不确定性度量，称为聚类熵，它简单、可解释，并且与最先进的规划算法兼容。利用在先前测试时时间步收集的数据，我们使用最小化聚类熵的梯度对模型参数进行更新。仅在推理前进行这一次梯度更新，**Centaur** 就表现出显著的改进，在 **navtest** 排行榜上排名第一，在安全关键指标（如碰撞时间）上取得了显著提升。为了在逐场景基础上提供详细的洞见，我们还引入了 **navsafe**，这是一个具有挑战性的新基准，它揭示了驾驶模型以前未被发现的失败模式。




图 1. 在测试时训练 (TTT) 中，当不确定时降低熵。端到端规划器 Hydra-MDP[33]，在 navtest[10] 上是最先进的，为固定集合中的每条轨迹预测一个分数。在散点图中，我们根据轨迹的横向终点位置绘制轨迹分数，将其聚类为五类（上方可视化中的彩色箭头）。Hydra-MDP 选择预测分数最高的轨迹（*）作为其输出。左图：在这个环岛中，它选择了“轻微左转”聚类中的一个高分异常值，而该聚类的平均分数较低，表明不确定性很高。右图：这种不确定性通过我们提出的聚类熵来衡量，我们在 Centaur 中通过梯度下降 (TTT) 将其最小化。这导致了一个更自信的规划器（熵更小），在该场景中更倾向于“轻微右转”，从而避免了碰撞。

1. Introduction

随着自动驾驶车辆越来越多地与人类驾驶车辆共享公共街道，在不可预见的安全交互和鲁棒性的需求变得至关重要 [38, 47]。特别是，人们对以下方面的兴趣日益增长：

*Equal contribution.

Primary contact: chonghaosima@connect.hku.hk

部署用于自动驾驶汽车 (AV) 的端到端规划器 [7, 22, 33, 59]，因为它们具有挑战性场景中的可扩展性和强大的经验性能 [4, 31]。然而，在实践中，端到端规划器通常应用回退层用于实际部署，这些回退层使用预定义的

安全动作以确保关键情况下的安全性 [7, 54, 58]。虽然有用，但后备层需要大量的领域专业知识和手工工程设计，无法从数据驱动的改进中受益，并且限制了所学算法的性能潜力。另一种提高安全性的方法涉及使用专家设计的代价函数在测试时优化规划的输出轨迹 [21, 22]。该方法依赖于显式表示，如可行行驶区域地图或车辆运动预测，并针对这些显式表示定义不安全规划行为的数值代价，例如驶离道路或发生碰撞。不幸的是，该方法所需的表示标注成本高昂，并且阻碍了充分利用端到端学习固有的可扩展性，而端到端学习通常只需要易于获取的标注，如车辆轨迹或驾驶动作 [45, 60]。因此，端到端规划器通常不适合使用专家设计的代价函数进行测试时优化。为了安全地部署和改进端到端驾驶策略，我们寻求一种数据驱动的方法，在不依赖后备层或显式表示的情况下增强安全性，并且能够有效扩展。在这项工作中，我们提出了这样一种方法，Centaur，它通过测试时训练（Test-Time Training, TTT）来增强安全性 [35, 51]。这涉及计算网络权重的梯度，以最小化使用部署期间收集的小型数据集定义的目标函数 [13, 36, 56]。与利用显式表示和专家设计的代价函数的测试时轨迹优化相比，我们的测试时训练目标优化网络权重以减少规划不确定性，这种不确定性可以以无监督的方式进行估计。此外，尽管我们执行测试时训练，Centaur 异步并行地执行梯度计算和推理，从而在运行时延迟方面产生最小的开销。鉴于端到端驾驶中历史上主流的轨迹回归范式 [7, 22, 34, 59]，其中规划器直接从传感器输入回归期望轨迹，定义规划不确定性度量以实现测试时训练并非易事。这是因为现有的测试时训练工作侧重于分类 [13, 55]，通常使用的训练目标是预测的熵，而在回归设置中不易计算。然而，近期端到端驾驶文献中基于轨迹评分 [3, 33, 46] 的一类新兴方法为多个候选轨迹分配数值分数，类似于分类器。针对这类方法，我们引入了一种新颖的端到端驾驶不确定性度量，即聚类熵（Cluster Entropy）。它根据驾驶方向将规划器的候选轨迹分数聚合到聚类中，并计算这个简单且可解释的分布的熵。我们的方法以轨迹评分规划器 Hydra-MDP [33] 为例，如图 1 所示。在复杂场景中

描绘了进入环岛的场景，高评分轨迹的分布在测试时训练（TTT）后更加集中于更安全的右转行为，帮助规划器避免非法左转进入迎面车流。除了对测试时训练的有效性之外，我们的实验还表明，聚类熵能够识别模型将失败的场景，表明其作为提醒人类驾驶员介入的机制的潜力。Centaur 在导航测试基准上达到了新的最先进水平（92.6%），显著优于保守的备用层策略（65.3%），并接近人类性能的上限（94.8%）。为了推动安全自动驾驶的进展，我们构建了 navsafe，这是一个包含各种边缘情况和具有挑战性的驾驶场景的新基准。为此，我们设计了一个半自动化的数据策展流程，涉及人工标注和验证，以采样安全关键场景。我们评估了包括 Centaur 在内的最先进规划器在 navsafe 上的泛化能力，揭示了它们在优势和劣势方面的一些新洞见，以及在这一具有挑战性的环境中实现人类水平性能的巨大差距。

贡献。（1）我们的工作首次证明了测试时训练在显著提升端到端自动驾驶性能方面的潜力。（2）我们提出了聚类熵，这是一种简单、可解释且有效的端到端规划不确定性度量方法，并通过全面的实验得到了验证。（3）我们发布了 navsafe 基准，这是一个包含环岛、恶劣天气条件和不保护转弯等安全关键场景的集合。随着我们的方法在现有基准上接近人类水平性能，这为未来工作提供了一个具有挑战性的新测试平台。

2. Centaur

在本节中，我们介绍 **Centaur** 的流程：利用不确定性进行测试时训练的聚类熵。我们的工作重点是部署一个训练好的规划器，如图 2 所示。

预备知识。 端到端自动驾驶方法旨在学习一个策略，记为 π ，该策略根据传感器输入 $\mathbf{x}$ 和导航指令 $\mathbf{c}$ 直接输出驾驶决策，例如期望轨迹 $\mathbf{t}$ 。轨迹形式为 $\tilde{\mathbf{t}} = (\mathbf{p}_0, \mathbf{p}_1, \dots, \mathbf{p}_N)$ ，即一系列航点。这些航点是车辆在 N 个等间隔时间步上的鸟瞰图（Bird’s Eye View, BEV）位置。该策略根据当前时间步（索引为 0）捕获的传感器输入 $\mathbf{x}_0$ （如相机图像）和离散导航指令 $\mathbf{c}_0$ （在模糊场景中指示驾驶员意图，例如左转/右转/直行）来估计轨迹。在现有的端到端驾驶范式中，利用人类驾驶演示数据集直接回归轨迹的简单方法可被称为




图 2. 半人马系统中的测试时训练。顶部：一个训练好的端到端规划器为测试期间观察到的帧从规划词汇表中对轨迹进行评分。我们采样这些轨迹的一个子集，并根据其驾驶方向进行聚类。在聚合各聚类的预测分数后，计算聚类熵以反映不确定性。随后，我们通过反向传播获得用于最小化聚类熵的梯度。底部：我们累积来自历史帧的梯度，并更新规划器以实现性能提升。

作为轨迹回归。尽管本文方法兼容轨迹回归，但下文主要探讨其在近期文献中性能更优的新兴范式——轨迹评分（Trajectory Scoring）中的应用（例如 Hydra-MDP [33]、VADv2 [5] 和 RAD [12]）。关于将本文方法应用于 UniAD [22] 和 TransFuser [7] 等轨迹回归方法的方法论与结果，详见补充材料。

轨迹评分。在该表述中，规划器为“规划”输出一组标量“评分特征” $\{s_j\}_{j=1}^k$ 不同轨迹的词汇表 k 。评分特征在数值上捕捉了期望驾驶行为的不同方面，例如避免碰撞和取得进展。这些特征随后可通过聚合函数 ϕ 汇总为单一最终评分。在推理过程中，选择预测最终评分最大的轨迹：

$$\{s_j\}_{j=1}^k = \{\pi_\theta(\mathbf{t}_j, \mathbf{x}_0, \mathbf{c}_0)\}_{j=1}^k, \quad (1)$$

$$\hat{\mathbf{t}}_0 = \arg \max_{\mathbf{t}_j} \{\phi(s_j)\}_{j=1}^k. \quad (2)$$

由于这种设计，规划器本质上是多模态的，规划词汇表上的分数分布提供了一种表示规划不确定性的方式。对于这类规划器，学习策略的参数 θ 可以表述为：

$$\arg \min_{\theta} \mathbb{E}_{(\mathbf{t}, \mathbf{x}, \mathbf{c}) \sim D_{kd}} [\mathcal{L}_{kd}(e(\mathbf{t}, \mathbf{x}, \mathbf{c}), \pi_\theta(\mathbf{t}, \mathbf{x}, \mathbf{c}))], \quad (3)$$

其中 e 是一种专家算法，能够为任意采样轨迹提供真实分数特征，且 $D_{kd} =$

$\{(\mathbf{t}, \mathbf{x}, \mathbf{c}), \dots\}$ 是一个知识蒸馏数据集，通过在不同输入上采样该专家算法生成，通常在驾驶模拟器 [2, 11] 或世界模型 [14, 61] 中。实践中，分数特征被归一化到 $(0, 1)$ 范围，且 $\mathcal{L}_{kd}$ 实现为交叉熵损失。

2.1. 聚类熵

本质上，公式 (1) 和公式 (2) 中的评分过程充当了规划词汇表中 k 个类别的分类器。我们提出一种新的不确定性测度——聚类熵，将这一直觉转化为端到端规划的无监督训练目标，无需像公式 (3) 那样依赖专家算法。我们的关键挑战在于规划词汇表 k 通常非常庞大，往往包含数千条可能的轨迹。因此，即使在简单的驾驶场景中，词汇表中若干相邻轨迹也会产生几乎相同的分数。简单地最小化分数分布的熵会导致目标鼓励模型避开词汇表中拥有更多近邻的轨迹，例如直线行驶。因此，这种朴素的熵不适合此场景下的不确定性估计。

轨迹候选。为解决这一问题，我们首先从规划词汇表中采样一组 M 个轨迹候选 $\{\mathbf{t}_m\}_{m=1}^M$ ，其中 $M \ll k$ 。我们采用加权采样过程，优先选择根据专家算法 e 在测试集上具有高平均分数的候选。有关该过程的更多细节见补充材料。虽然这个缩减后的 M 个分数集合上的熵已经是一个有意义的 uncertainty 测度，正如我们的实验所证明的，我们现在旨在进一步提升其有效性和可解释性。

测度，正如我们的实验所证明的，我们现在旨在进一步提升其有效性和可解释性。

基于方向的采样。接下来，我们使用领域特定标准从 M 个轨迹候选中选择轨迹锚点。遵循 [50]，我们选择 5 个锚点（急左转、缓左转、直行、缓右转、急右转）。急左转/急右转，即横向偏移最大的候选轨迹，首先被选中。缓左转/缓右转是横向偏移最接近急左转/急右转一半的候选轨迹，直行是横向偏移最小的轨迹。

分数聚合。如图 2（顶部）所示，我们旨在构建一个 5 路分类分布，以捕捉预测分数在 5 个驾驶方向上的分布。为此，我们通过为每个 M 个候选轨迹在 L_2 距离上识别最近的锚点来构建 5 个簇。在每个结果簇中，我们将所有轨迹的预测分数相加，得到锚点分数 $score_a$ 。我们通过归一化（ $\frac{score_a}{\sum_{a=1}^5 score_a}$ ）计算概率分布，并将簇熵（表示为 H ）定义为该分布的香农熵。

2.2. 测试时训练（TTT）

借助我们的无监督训练目标，我们的目标是最小化测试时不确定性，这是文献中 TTT 方法的关键思想。我们遵循标准做法，执行单步梯度下降来更新网络参数 θ [13]。我们使用簇熵 $H(\mathbf{x})$ 作为要优化的目标函数。具体来说，给定通过 π_θ 前向传播计算得到的 $H(\mathbf{x})$ ，我们通过反向传播获得梯度 $\frac{\partial H}{\partial \theta}$ 。然而，我们不是直接用计算出的梯度更新 θ ，而是将 $\frac{\partial H}{\partial \theta}$ 存储在一个长度为 4 的缓冲区中，如图 2（底部）所示。在时间步 i ，我们使用所有梯度的平均值 $F = \frac{1}{4} \sum_{t=i-3}^i \frac{\partial H}{\partial \theta}$ 来更新网络，其中 η 是学习率。直观上，这抑制了模型在多个簇中分配高分的能力。我们当前在缓冲区中，获得 $\hat{\theta}_i = \theta - \eta \left\{ \frac{\partial H}{\partial \theta} \right\}_{avg}$ ，显著不同的异常预测的分数。

部署。注意，在时间步 i 处计算的梯度仅使用缓冲区中已存在的历史时间步的梯度。因此，除了梯度平均带来的平滑性之外，我们使用缓冲区还支持异步和并行执行。在部署期间，梯度计算过程可以在独立的计算硬件上执行，从而使更关键的推理过程在延迟方面保持最小的开销。

3. navsafe: 安全关键场景集

在下文中，我们讨论 navsafe 的构建和亮点，这是一个具有挑战性的新基准，由

端到端规划的边缘案例组成。我们基准中使用的数据采样自 NAVSIM [10]，而 NAVSIM 又基于 OpenScene [8] 和 nuPlan [2] 的数据构建。

NAVSIM。我们构建 navsafe 所基于的框架主要旨在捕捉驾驶行为发生显著变化的场景，在这些场景中，自车的历史轨迹无法准确外推未来计划。它分为两部分：navtrain 和 navtest，分别包含 1,192 个日志（103,288 帧）和 136 个日志（12,146 帧）。在 NAVSIM 中，驾驶智能体需要规划一条轨迹，作为未来位置的序列，跨越 4 秒的预测范围。智能体的输入包括来自车载摄像头和激光雷达传感器的 1.5 秒过去历史（产生 4 帧数据），以及车辆当前速度、加速度和导航命令的数据，统称为自车状态。我们保留这些默认的 NAVSIM 设置，用于在 navsafe 基准上进行评估。

构建标准。图 3 展示了导航安全（navsafe）数据集的构建流程。美国国家公路交通安全管理局（NHTSA）每年收集全国报告的事故数据，并通过碰撞前场景类型学公开共享，用于避撞研究 [41]。该类型学涵盖多种碰撞前场景类型，从常见的“前车停止”到罕见的“动物碰撞伴随前车机动”。基于碰撞前场景类型的汇总统计 [41, 52]，导航安全数据集旨在突出这些安全关键场景，这些场景中现代端到端规划器可能出现失败案例。因此，我们按照以下步骤构建导航安全数据集：0. 根据最先进规划器 [33] 的平均性能对导航测试（navtest）划分中的视频片段进行排序。1. 检查视频片段，并尝试由人工标注者将帧分配到导航安全数据集中新的或现有的类别。2. 用新示例填充场景类型。3. 从 NHTSA 文件中检索场景类型标签，以定义导航安全数据集中尚未包含的场景类型。4. 重新排序导航测试划分，并开始新一轮工作流程。

亮点 navsafe。对于我们的基准，我们从 navtest 的 12,146 帧中选取了 229 帧，涵盖 10 个类别：“环岛”、“黄灯，冲还是等？”、“出口匝道”、“无保护左转”、“入口匝道”、“不常见交通标志”、“变道超车”、“无车道区域（如停车场）”、“恶劣天气”和“让行（如对行人）”。通过为每种场景类型提供独立评分，我们实现了对特定规划能力的细粒度评估，这与现有基准（如 navtest）提供的整体聚合性能不同。我们基于 CLIP 的聚类结果表明，navsafe 代表了远离原始 navtest 划分分布中心的数据点。在我们的实验

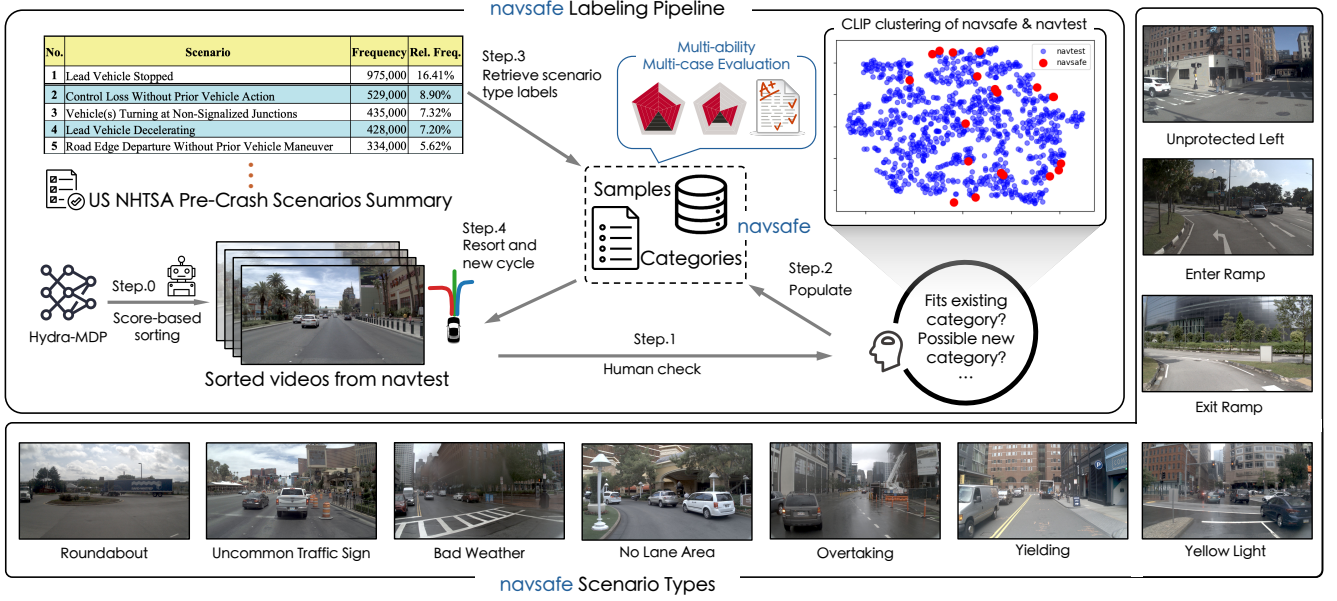


图 3. navsafe. 本文利用美国国家公路交通安全管理局 (NHTSA) 材料 [41] 中安全关键案例的定义, 并在 navtest 中搜索匹配这些定义的帧。经过人工检查后, 构建了 **navsafe**。基于 CLIP 的聚类 [23] 将我们的数据与 navtest 结合分析, 结果表明 **navsafe** 由分布边缘区域的帧组成。

在实验中, 我们以人类智能体性能 (来自导航模拟器的真实轨迹) 以及最先进的端到端规划器为基准, 以展示这一新基准所带来的难度提升。

4. 实验

在本节中, 我们展示了 Centaur 在 NAVSIM 框架 [10] 上的性能, 包括官方排行榜 (navtest) 和我们提出的 navsafe 安全关键场景, 详见第 3 节。

度量。 我们的实验采用 NAVSIM 的主要度量 PDM 分数 (PDMS) 来评估端到端规划模型的性能:

$$\text{PDMS} = \text{NC} \times \text{DAC} \times \left(\frac{5\text{TTC} + 2\text{C} + 5\text{EP}}{12} \right), \quad (4)$$

其中子分数 **NC** (无责任碰撞)、**DAC** (可行驶区域合规性)、**EP** (自车进度)、**C** (舒适性) 和 **TTC** (碰撞时间) 均以百分比表示, 并组合成一个单分数。每个子分数的详细定义见 [10]。由于与安全性相关, 在若干实验中我们特别讨论了 **TTC**, 它用于识别规划器输出的轨迹是否会导致近碰撞, 即沿轨迹任意点以恒定速度向前投影会在 1 秒内发生碰撞。

4.1. 基线

在我们的实验中, 我们考虑了几种基线方法来分析各种设计选择的影响。

基础模型。 专为 NAVSIM 设计的基础模型 Hydra-MDP [33] 输入激光雷达点, 这些点被投影到鸟瞰图平面上并通过 ResNet34 [18] 编码。这些特征与使用 V2-99 [43] 主干网络提取的基于图像的特征通过 Trans-Fuser [7] 传感器融合模块进行融合。然后解码器为 $k = 8192$ 条轨迹的规划词汇表预测分数。解码器输出的分数函数是 NAVSIM 评估期间考虑的五个子分数 (NC、DAC、EP、C、TTC)。使用更轻量的 TransFuser [7] 基线的额外实验在补充材料中提供, 该基线执行简单的轨迹回归, 而不是像 Hydra-MDP 那样进行评估。

部署策略。 作为更安全部署的基线, 我们按照 [54] 的描述实现了一个回退层策略。我们首先计算 Hydra-MDP 规划词汇表中每条轨迹的平均 PDMS, 并选择其中前 20 条作为回退轨迹。在推理过程中, 我们测量预测轨迹与 20 条回退轨迹之间的 L_2 距离。当基于高于阈值的置信度值检测到失败时, 选择这 20 条回退轨迹中最近的一条作为安全动作来替换预测轨迹。我们选择的阈值将在表 3 中讨论。

表 1. TTT 对 navtest 的影响。引入回退层 [54] 会导致极其保守的行为，从而降低 PDMS。另一方面，TTT 带来了显著的改进，特别是使用我们提出的聚类熵置信度测度时。

Model	Deployment	Uncertainty	NC $\uparrow$	DAC $\uparrow$	EP $\uparrow$	C $\uparrow$	TTC $\uparrow$	PDMS $\uparrow$
Hydra-MDP [33]	-	-	98.4	97.8	86.5	100.0	93.9	90.3
	Fallback Layer [54]	KL Divergence	99.1	99.2	9.6	100.0	96.7	63.1
		Full Entropy	99.6	99.4	13.2	100.0	99.1	65.9
		Semantic Entropy	99.7	99.5	10.4	100.0	98.9	65.3
		Cluster Entropy	99.7	99.5	8.2	100.0	99.3	64.2
	TTT	KL Divergence	98.9	98.1	86.0	100.0	94.4	91.5
		Full Entropy	99.3	98.5	85.7	100.0	97.1	91.8
Hydra-SE	TTT	Semantic Entropy	99.2	98.5	85.7	100.0	97.1	91.8
Centaur (Ours)	TTT	Cluster Entropy	99.5	98.9	85.9	100.0	98.0	92.6
Human Trajectory	-	-	100.0	100.0	87.5	99.9	100.0	94.8

表 2. navtest 排行榜。我们报告了 3 次独立训练运行的平均值和标准差，符合排行榜规则的建议。*Hydra-MDP 条目是 2024 年 NAVSIM 挑战赛的获胜者，它是 3 模型集成的单次评估，与其他所有行不同。

Model	NC $\uparrow$	DAC $\uparrow$	EP $\uparrow$	C $\uparrow$	TTC $\uparrow$	PDMS $\uparrow$
Centaur (Ours)	99.23 $\pm$ 0.35	98.72 $\pm$ 0.22	85.96 $\pm$ 0.77	99.97 $\pm$ 0.03	97.17 $\pm$ 1.06	92.10 $\pm$ 0.33
Hydra-SE	99.32 $\pm$ 0.05	98.58 $\pm$ 0.12	85.42 $\pm$ 0.07	99.96 $\pm$ 0.01	97.30 $\pm$ 0.23	91.87 $\pm$ 0.19
Hydra-MDP* [33]	99.07	98.29	85.20	100.0	96.56	91.26
TransFuser [7]	97.78 $\pm$ 0.10	92.63 $\pm$ 0.48	78.88 $\pm$ 0.25	99.98 $\pm$ 0.01	92.89 $\pm$ 0.21	83.88 $\pm$ 0.45
LTF [7]	97.68 $\pm$ 0.11	92.29 $\pm$ 0.45	78.33 $\pm$ 0.53	99.99 $\pm$ 0.01	93.10 $\pm$ 0.19	83.52 $\pm$ 0.55
Ego Status MLP [10]	93.09 $\pm$ 0.12	78.26 $\pm$ 0.98	63.20 $\pm$ 0.53	99.97 $\pm$ 0.02	84.02 $\pm$ 0.61	66.40 $\pm$ 0.94

置信度测度。我们将聚类熵与三个基线进行比较。对于 KL 散度，我们获得每个评分函数（NC、DAC、EP、C、TTC）在规划词汇表 ($k = 8192$ 个类别上的预测分类分布。然后计算每对分布之间的 KL 散度，并对所有对求和。对于全熵 [48]，我们的计算与聚类熵类似。然而，我们跳过了将 $M = 100$ 个候选聚类为 5 个簇的步骤，而是直接计算 100 路候选评分分布上的熵。语义熵是我们对 [29] 在自动驾驶领域的改编。同样，计算与聚类熵类似，但我们使用特征空间对候选进行聚类，其中每条轨迹由其预测评分 s_j 表示。更多细节见补充材料。为简洁起见，我们将使用语义熵的 Hydra-MDP 的 TTT 方法称为 **Hydra-SE**，这是我们的实验中最常用的基线。

实现。除表 2 外，我们采用 NAVSIM v1.0 进行所有训练和本地评估，并采用 NAVSIM v1.1 进行官方排行榜提交，两者之间的细微差异源于度量定义的微小变化。我们使用 8 个 GPU 在 navtrain 划分上训练基础端到端模型 Hydra-MDP[33]20 个训练轮次

NVIDIA A100 图形处理器，总批大小为 256。AdamW[39] 的学习率设为 10^{-4} ，并禁用权重衰减。对于聚类熵计算和测试时训练，我们使用 $M = 100$ 条候选轨迹，并在包含 $F = 4$ 帧历史数据的数据集上执行 1 步梯度下降，学习率 η 为 10^{-4} 。在测试时训练期间，我们仅更新评分解码器，保持感知主干网络冻结。

4.2. 结果

我们的主要结果如表 1 所示，考察了两个关键方面：部署策略和不确定性度量。

部署策略。无论采用何种不确定性度量，回退层都会显著降低 PDM 评分。这一下降主要归因于自车进度的大幅减少，从 86.5 降至 15 以下。不幸的是，模型识别的失败案例越多，由于保守的回退轨迹，回退层的 PDMS 就越差。尽管与安全相关的子评分（NC、DAC 和 TTC）有所改善，但这种方法很可能导致对人类干预的过度依赖，在实践中不可行。相比之下，测试时训练在保持高进度的同时改善了与安全相关的子评分。最显著的提升出现在 TTC 上，凸显了其在提高安全性方面的潜力。




图 4. 定性结果。对于每个场景，我们展示了 Hydra-MDP（测试时训练前）和 Centaur（测试时训练后）的 PDMS 以及选定的子评分，最高预测评分用 ★ 标记。每个图中的 x 轴是候选轨迹的横向终点位置。上图：测试时训练帮助 Centaur 在“直行”和“轻微左转”之间不确定时，倾向于选择聚类成员平均评分更高的方向，从而提高安全性。下图：一个失败案例，测试时训练无法抑制一个自信的原始预测。

表 3. 失败识别。我们提出的聚类熵不确定性与 Hydra-MDP 相结合，在识别模型在导航测试集上失败的帧方面取得了有前景的结果。

Uncertainty	Threshold	TPR ↑	Acc. ↑
KL Divergence	1500	41.3	68.3
Full Entropy	0.8	61.7	70.4
Semantic Entropy	0.8	62.5	72.2
Cluster Entropy (Ours)	0.8	62.8	73.6
Select All	-	100.0	15.6
Select None	-	0.0	84.4

置信度测度。在使用 TTT 与聚类熵时，Centaur 相较于先前最先进的 Hydra-MDP 提升了 2.3 PDMS，相较于基于语义熵的方法 Hydra-SE 基线提升了 0.6 PDMS，这些改进是显著的。这是因为 navtest 上的分数已经非常接近人类 PDMS 的上限 94.8。除了定量增益外，为了展示聚类熵如何通过其直观的聚类机制促进可解释性，我们在图 4 中可视化了两个场景。在顶行中，未使用 TTT 的基础 Hydra-MDP 模型表现出对轻微左转轨迹的偏好，这未能保持较大的碰撞时间余量。使用 TTT 后，Centaur 遵循了继续直行的更安全行为。在底行中，TTT 提高了两个“急左转”候选的可行驶区域合规分数，但这不足以使它们的分数超过原始预测。因此，该帧在 TTT 后模型的预测没有变化。

失败识别。在本实验中，我们使用不同的不确定性估计对潜在失败案例进行二分类。该任务对于

部署了部分自主能力的车辆在具有挑战性的情况下依赖人类干预。我们将模型获得 PDMS 为 0 的场景定义为失败，并在表 3 中报告识别此类失败的真阳性率（TPR）和准确率。我们将高于阈值的置信度视为可能的失败。从结果中可以看出，聚类熵（Cluster Entropy）最具潜力，优于所有其他基于置信度的失败分类器，TPR 达到 62.8%。此处我们选择阈值为 $0.8 = 0.5 \ln 5$ ，即 5 类均匀分布熵值的一半。基于这些发现，我们在后续实验中重点关注两种最佳的置信度测度（语义熵和聚类熵）。有趣的是，当使用 TTT 时，我们观察到 PDMS 是置信度测量质量的可靠指标，但在使用回退层时并非如此。例如，表 3 中最有效的失败案例识别器（即聚类熵）在表 1 中使用 TTT 时也获得了最佳 PDMS，但最常触发回退机制，导致使用回退层时的 PDMS 低于语义熵。导航测试排行榜。遵循排行榜提交的官方说明，我们使用 3 个随机初始化训练模型，并将 Centaur 以及 Hydra-SE 提交至使用 NAVSIM v1.1 的导航测试排行榜 [10]。与使用 NAVSIM v1.0 的其他基线的比较见补充材料。表 2 显示了排行榜上所有使用 3 个种子提交、设置与我们相同的条目的度量均值和标准差。Centaur 排名第一，平均 PDMS 为 92.1%。我们无需在 Hydra-MDP 默认值之外进行任何训练超参数调整即可达到此结果，并且不需要像之前基于 2024 年 NAVSIM 挑战赛获胜作品的 Hydra-MDP 结果那样进行模型集成 [33]。

表 4. 导航安全 PDM 分数。现有规划器未达到人类水平性能。RDBT: “环岛”。YLLT: “黄灯, 抢行还是等待? ”。EXR: “出口匝道”。UNPL: “无保护左转”。ENR: “入口匝道”。UNTS: “不常见交通标志”。OTLC: “变道超车”。NLA: “无车道区域 (如停车场) ”。BWTH: “恶劣天气”。YLD: “让行 (如对行人) ”。

	RDBT	YLLT	EXR	UNPL	ENR	UNTS	OTLC	NLA	BWTH	YLD	Overall
Num. Scenarios	7	23	45	28	51	12	8	5	39	11	229
Constant Velocity [10]	0.0	3.8	3.6	0.0	2.9	7.4	0.0	6.4	6.3	3.8	3.41
Ego Status MLP [10]	28.9	22.7	26.0	8.9	37.7	28.0	35.0	8.8	33.4	22.1	24.10
LTF [7]	42.8	70.2	43.8	59.4	70.6	55.3	55.8	31.5	62.8	47.5	53.74
TransFuser [7]	47.3	55.1	35.6	55.7	66.3	51.7	56.2	42.7	55.2	61.6	51.87
Hydra-MDP [33]	32.6	34.3	37.7	64.9	65.5	59.6	43.3	38.1	35.7	71.6	56.47
Hydra-SE	62.2	53.9	50.5	57.8	72.0	65.6	74.0	57.6	64.4	84.6	62.84
Centaur (Ours)	76.5	65.0	61.4	73.6	75.0	85.2	83.6	79.8	60.2	59.3	74.14
<i>Human Trajectory</i>	<i>96.4</i>	<i>97.6</i>	<i>95.2</i>	<i>94.3</i>	<i>97.2</i>	<i>95.8</i>	<i>94.1</i>	<i>93.7</i>	<i>90.7</i>	<i>91.5</i>	<i>94.65</i>

导航安全。最后, 我们在提出的导航安全基准上对不同规划器进行了场景级评估。如表 4 所示, 我们的新测试集捕捉到了多个规划器的常见失败, 例如在 EXR 和 NLA 场景中, 所有未进行测试时训练的现有方法得分均低于 50。我们的评估协议还提供了关于某些规划器独特缺陷和优势的洞见。例如, 在 RDBT 和 OTLC 场景中, Hydra-MDP 的得分与简单的自我状态多层感知机基线相似。另一方面, 仅使用摄像头的 LTF 模型在 YLLT 和 ENR 场景中表现惊人地好, 即使与 TransFuser 等更强大的传感器融合模型相比也是如此。我们提出的方法 Centaur 在这些具有挑战性的场景中显著优于 Hydra-MDP 和 Hydra-SE, 展示了聚类熵在测试时训练中的有效性。此外, 与导航测试不同, Centaur 与人类水平性能之间仍存在较大差距, 这鼓励在该基准上进一步努力。

5. 相关工作

端到端自动驾驶。

端到端自动驾驶代表了自动驾驶汽车技术的范式转变 [4]。这些方法的目标是利用神经网络直接将原始传感器输入映射到车辆控制输出, 绕过传统的模块化组件, 如分离的感知、规划与控制系统 [5, 6, 19, 22, 24 – 26, 28, 33, 37, 45, 53, 57, 63]。

端到端规划器部署。考虑到端到端系统的“黑箱”特性, 在部署期间获得可信的输出具有挑战性。基于规则的规划器或回退层是保护规划输出的常见方法。例如, UniAD[22] 使用测试时优化来细化规划输出, TransFuser[7] 在激光雷达传感器遇到障碍物时采用强制制动。SafetyNet[54] 采用回退层, 通过对碰撞和物理可行性的合理性检查来确保规划安全。

然而, 与 Centaur 不同, 这些工作要么在训练期间需要大量标注, 要么导致过于保守的动作。

测试时计算与训练。利用测试时计算最近已成为增强推理能力的重要途径 [42]。此外, 测试时自适应与训练技术 [35] 在计算机视觉 [15, 40, 51]、多模态学习 [49, 62]、视觉语言导航 [13]、轨迹预测 [44]、机器人操作 [17] 以及长上下文大语言模型 [51] 中展现出可观的潜力。这些方法的核心思想是在测试时最小化熵或相关代理指标。Centaur 在精神上与这些方法一致, 据我们所知, 它是首个通过不确定性度量探索测试时训练在车辆运动规划任务中潜力的工作。

6. 结论

本文首次尝试将测试时训练 (Test-Time Training, TTT) 应用于端到端自动驾驶, 并发现其在官方 navtest 排行榜上显著提升了最先进方法的性能。我们提出的聚类熵度量能够有效量化不确定性, 优于多个基线方法。最后, 为了对挑战性场景下的性能进行整体评估, 我们发布了 navsafe 测试集, 为端到端驾驶算法的关键改进领域提供了新的洞见。局限性。作为一项开创性尝试, Centaur 展现出有前景的性能。然而, 仍存在一些局限性。我们的方法目前仅在开环方案下进行评估, 尽管采用了基于仿真的原则性度量。将我们的工作扩展到具有可承受推理预算的闭环设置是一个有前景的探索方向。此外, 自动驾驶对效率敏感, 测试时计算资源相当有限。

值得探索统一测试时训练与模型推理的方法，以最小化计算开销。关于 Centaur 延迟的讨论见补充材料。

致谢

我们衷心感谢李天宇、李振新、尼基塔·杜拉索夫、卜庆文、崔智雄和陈力在写作过程中给予的深入讨论与支持。本工作由香港大学上海智能计算研究院支持，并部分受 EXC（编号 2064/1 – 项目编号：390727645）资助。我们感谢国际马克斯·普朗克智能系统研究学院（IMPRS-IS）对卡什亚普·奇塔的支持。

参考文献

- [1] Alexander Amini, Wilko Schwarting, Ava Soleimany, and Daniela Rus. Deep evidential regression. In *NeurIPS*, 2020. 1, 2, 3
- [2] Holger Caesar, Juraj Kabzan, Kok Seang Tan, Whye Kit Fong, Eric M. Wolff, Alex H. Lang, Luke Fletcher, Oscar Beijbom, and Sammy Omari. nuPlan: A closed-loop ml-based planning benchmark for autonomous vehicles. In *CVPR Workshops*, 2021. 3, 4
- [3] Sergio Casas, Abbas Sadat, and Raquel Urtasun. MP3: A unified model to map, perceive, predict and plan. In *CVPR*, 2021. 2
- [4] Li Chen, Penghao Wu, Kashyap Chitta, Bernhard Jaeger, Andreas Geiger, and Hongyang Li. End-to-end autonomous driving: Challenges and frontiers. *IEEE TPAMI*, 2024. 1, 8
- [5] Shaoyu Chen, Bo Jiang, Hao Gao, Bencheng Liao, Qing Xu, Qian Zhang, Chang Huang, Wenyu Liu, and Xinggang Wang. VADv2: End-to-end vectorized autonomous driving via probabilistic planning. *arXiv preprint arXiv:2402.13243*, 2024. 3, 8, 2
- [6] Kashyap Chitta, Aditya Prakash, and Andreas Geiger. Neat: Neural attention fields for end-to-end autonomous driving. In *International Conference on Computer Vision (ICCV)*, 2021. 8
- [7] Kashyap Chitta, Aditya Prakash, Bernhard Jaeger, Zehao Yu, Katrin Renz, and Andreas Geiger. TransFuser: Imitation with transformer-based sensor fusion for autonomous driving. *IEEE TPAMI*, 2023. 1, 2, 3, 5, 6, 8, 4
- [8] OpenScene Contributors. OpenScene: The largest up-to-date 3d occupancy prediction benchmark in autonomous driving. <https://github.com/OpenDriveLab/OpenScene>, 2023. 4
- [9] Daniel Dauner, Marcel Hallgarten, Andreas Geiger, and Kashyap Chitta. Parting with misconceptions about learning-based vehicle motion planning. In *CoRL*, 2023. 1
- [10] Daniel Dauner, Marcel Hallgarten, Tianyu Li, Xinshuo Weng, Zhiyu Huang, Zetong Yang, Hongyang Li, Igor Gilitschenski, Boris Ivanovic, Marco Pavone, Andreas Geiger, and Kashyap Chitta. NAVSIM: Data-driven non-reactive autonomous vehicle simulation and benchmarking. In *NeurIPS*, 2024. 1, 4, 5, 6, 7, 8
- [11] Alexey Dosovitskiy, German Ros, Felipe Codevilla, Antonio Lopez, and Vladlen Koltun. CARLA: An open urban driving simulator. In *CoRL*, 2017. 3
- [12] Hao Gao, Shaoyu Chen, Bo Jiang, Bencheng Liao, Yang Shi, Xiaoyang Guo, Yuechuan Pu, Haoran Yin, Xiangyu Li, Xinbang Zhang, Ying Zhang, Wenyu Liu, Qian Zhang, and Xinggang Wang. Rad: Training an end-to-end driving policy via large-scale 3dgs-based reinforcement learning. *arXiv preprint arXiv:2502.13144*, 2025. 3
- [13] Junyu Gao, Xuan Yao, and Changsheng Xu. Fast-slow test-time adaptation for online vision-and-language navigation. In *ICML*, 2024. 2, 4, 8
- [14] Shenyuan Gao, Jiazhi Yang, Li Chen, Kashyap Chitta, Yihang Qiu, Andreas Geiger, Jun Zhang, and Hongyang Li. Vista: A generalizable driving world model with high fidelity and versatile controllability. 2024. 3
- [15] Gustavo A Vargas Hakim, David Osowiechi, Mehrdad Noori, Milad Cheraghalikhani, Ali Bahri, Ismail Ben Ayed, and Christian Desrosiers. Clust3: Information invariant test-time training. In *ICCV*, 2023. 8
- [16] Marcel Hallgarten, Julian Zapata, Martin Stoll, Katrin Renz, and Andreas Zell. Can vehicle motion planning generalize to realistic long-tail scenarios?, 2024. 1
- [17] Nicklas Hansen, Rishabh Jangir, Yu Sun, Guillem Alenyà, Pieter Abbeel, Alexei A Efros, Lerrel Pinto, and Xiaolong Wang. Self-supervised policy adaptation during deployment. In *ICLR*, 2021. 8
- [18] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *CVPR*, 2016. 5
- [19] Anthony Hu, Gianluca Corrado, Nicolas Griffiths, Zachary Murez, Corina Gurau, Hudson Yeo, Alex Kendall, Roberto Cipolla, and Jamie Shotton. Model-based imitation learning for urban driving. In *NeurIPS*, 2022. 8
- [20] Anthony Hu, Lloyd Russell, Hudson Yeo, Zak Murez, George Fedoseev, Alex Kendall, Jamie Shotton, and Gianluca Corrado. GAIA-1: A generative world model for autonomous driving. *arXiv preprint arXiv:2309.17080*, 2023. 1
- [21] Yihan Hu, Kun Li, Pingyuan Liang, Jingyu Qian, Zhening Yang, Haichao Zhang, Wenxin Shao, Zhuangzhuang Ding, Wei Xu, and Qiang Liu. Imitation with spatial-temporal heatmap: 2nd place solution for nuplan challenge. *arXiv preprint arXiv:2306.15700*, 2023. 2
- [22] Yihan Hu, Jiazhi Yang, Li Chen, Keyu Li, Chonghao Sima, Xizhou Zhu, Siqi Chai, Senyao Du, Tianwei Lin, et al. Planning-oriented autonomous driving. In *CVPR*, 2023. 1, 2, 3, 8
- [23] Gabriel Ilharco, Mitchell Wortsman, Ross Wightman, Cade Gordon, Nicholas Carlini, Rohan Taori, Achal Dave, Vaishaal Shankar, Hongseok Namkoong, John Miller, Hananeh Hajishirzi, Ali Farhadi, and Ludwig Schmidt. OpenCLIP, 2021. 5
- [24] Bernhard Jaeger, Kashyap Chitta, and Andreas Geiger. Hidden biases of end-to-end driving models. In *ICCV*, 2023. 8
- [25] Xiaosong Jia, Yulu Gao, Li Chen, Junchi Yan, Patrick Langechuan Liu, and Hongyang Li. DriveAdapter:

- Breaking the coupling barrier of perception and planning in end-to-end autonomous driving. In *ICCV*, 2023.
- [26] Xiaosong Jia, Penghao Wu, Li Chen, Jiangwei Xie, Conghui He, Junchi Yan, and Hongyang Li. Think twice before driving: Towards scalable decoders for end-to-end autonomous driving. In *CVPR*, 2023. 8
- [27] Xiaosong Jia, Zhenjie Yang, Qifeng Li, Zhiyuan Zhang, and Junchi Yan. Bench2drive: Towards multi-ability benchmarking of closed-loop end-to-end autonomous driving. In *NeurIPS Datasets and Benchmarks Track*, 2024. 1
- [28] Bo Jiang, Shaoyu Chen, Qing Xu, Bencheng Liao, Jiajie Chen, Helong Zhou, Qian Zhang, Wenyu Liu, Chang Huang, and Xinggang Wang. VAD: Vectorized scene representation for efficient autonomous driving. In *ICCV*, 2023. 8, 1
- [29] Lorenz Kuhn, Yarin Gal, and Sebastian Farquhar. Semantic uncertainty: Linguistic invariances for uncertainty estimation in natural language generation. *arXiv preprint arXiv:2302.09664*, 2023. 6, 1
- [30] Balaji Lakshminarayanan, Alexander Pritzel, and Charles Blundell. Simple and scalable predictive uncertainty estimation using deep ensembles. *arXiv preprint arXiv:1612.01474*, 2016. 1
- [31] Hongyang Li, Yang Li, Huijie Wang, Jia Zeng, Huilin Xu, Pinlong Cai, Li Chen, Junchi Yan, Feng Xu, Lu Xiong, et al. Open-sourced data ecosystem in autonomous driving: the present and future. *arXiv preprint arXiv:2312.03408*, 2023. 1
- [32] Xiao Li, H. Eric Tseng, Anouck Girard, and Ilya Kolmanovsky. Autonomous driving with perception uncertainties: Deep-ensemble based adaptive cruise control. *arXiv preprint arXiv:2403.15577*, 2024. 1
- [33] Zhenxin Li, Kailin Li, Shihao Wang, Shiyi Lan, Zhiding Yu, Yishen Ji, Zhiqi Li, Ziyue Zhu, Jan Kautz, Zuxuan Wu, et al. Hydra-MDP: End-to-end multimodal planning with multi-target hydra-distillation. *arXiv preprint arXiv:2406.06978*, 2024. 1, 2, 3, 4, 5, 6, 7, 8
- [34] Zhiqi Li, Zhiding Yu, Shiyi Lan, Jiahao Li, Jan Kautz, Tong Lu, and Jose M Alvarez. Is ego status all you need for open-loop end-to-end autonomous driving? In *CVPR*, 2024. 2, 1
- [35] Jian Liang, Ran He, and Tien-Ping Tan. A comprehensive survey on test-time adaptation under distribution shifts. *arXiv preprint arXiv:2303.15361*, 2023. 2, 8
- [36] Jian Liang, Ran He, and Tieniu Tan. A comprehensive survey on test-time adaptation under distribution shifts. *IJCV*, 2024. 2
- [37] Bencheng Liao, Shaoyu Chen, Haoran Yin, Bo Jiang, Cheng Wang, Sixu Yan, Xinbang Zhang, Xiangyu Li, Ying Zhang, Qian Zhang, et al. Diffusiondrive: Truncated diffusion model for end-to-end autonomous driving. In *CVPR*, 2025. 8, 3
- [38] Henry X. Liu and Shuo Feng. Curse of rarity for autonomous vehicles. *Nature Communications*, 15, 2022. 1
- [39] I Loshchilov. Decoupled weight decay regularization. *arXiv preprint arXiv:1711.05101*, 2017. 6
- [40] Robert A Marsden, Mario Döbler, and Bin Yang. Universal test-time adaptation through weight ensembling, diversity weighting, and prior correction. 2024. 8
- [41] Wassim G Najm, John D Smith, Mikio Yanagisawa, et al. Pre-crash scenario typology for crash avoidance research. Technical report, United States. Department of Transportation. NHTSA, 2007. 4, 5
- [42] OpenAI. OpenAI o1 system card. <https://openai.com/index/openai-o1-system-card/>, 2024. 8
- [43] Dennis Park, Rares Ambrus, Vitor Guizilini, Jie Li, and Adrien Gaidon. Is pseudo-lidar needed for monocular 3d object detection? In *ICCV*, 2021. 5
- [44] Daehee Park, Jaeseok Jeong, Sung-Hoon Yoon, Jaewoo Jeong, and Kuk-Jin Yoon. T4p: Test-time training of trajectory prediction via masked autoencoder and actor-specific token memory. In *CVPR*, 2024. 8
- [45] Aditya Prakash, Kashyap Chitta, and Andreas Geiger. Multi-modal fusion transformer for end-to-end autonomous driving. In *CVPR*, 2021. 2, 8
- [46] Abbas Sadat, Sergio Casas, Mengye Ren, Xinyu Wu, Pranaab Dhawan, and Raquel Urtasun. Perceive, predict, and plan: Safe motion planning through interpretable semantic representations. In *ECCV*, 2020. 2
- [47] Shai Shalev-Shwartz, Shaked Shammah, and Amnon Shashua. On a formal model of safe and scalable self-driving cars. *arXiv preprint arXiv:1708.06374*, 2017. 1
- [48] Claude Elwood Shannon. A mathematical theory of communication. *The Bell System Technical Journal*, pages 379–423, 1948. 6
- [49] Manli Shu, Weili Nie, De-An Huang, Zhiding Yu, Tom Goldstein, Anima Anandkumar, and Chaowei Xiao. Test-time prompt tuning for zero-shot generalization in vision-language models. In *NeurIPS*, 2022. 8
- [50] Chonghao Sima, Katrin Renz, Kashyap Chitta, Li Chen, Hanxue Zhang, Chengen Xie, Ping Luo, Andreas Geiger, and Hongyang Li. DriveLM: Driving with graph visual question answering. In *ECCV*, 2024. 4, 2
- [51] Yu Sun, Xinhao Li, Karan Dalal, Jiarui Xu, Arjun Vikram, Genghan Zhang, Yann Dubois, Xinlei Chen, Xiaolong Wang, Sanmi Koyejo, et al. Learning to (learn at test time): Rnns with expressive hidden states. *arXiv preprint arXiv:2407.04620*, 2024. 2, 8
- [52] Eric Thorn, Shawn C Kimmel, Michelle Chaka, Booz Allen Hamilton, et al. A framework for automated driving system testable cases and scenarios. Technical report, United States. Department of Transportation. NHTSA, 2018. 4
- [53] Wenwen Tong, Chonghao Sima, Tai Wang, Li Chen, Silei Wu, Hanming Deng, Yi Gu, Lewei Lu, Ping Luo, Dahua Lin, and Hongyang Li. Scene as occupancy. In *ICCV*, 2023. 8
- [54] Matt Vitelli, Yan Chang, Yawei Ye, Ana Ferreira, Maciej Wołczyk, Błażej Osiński, Moritz Niendorf, Hugo Grimmer, Qiangui Huang, Ashesh Jain, and Peter Ondruska. SafetyNet: Safe planning for real-world self-driving vehicles using machine-learned policies. In *ICRA*, 2022. 2, 5, 6, 8
- [55] Dequan Wang, Evan Shelhamer, Shaoteng Liu, Bruno Olshausen, and Trevor Darrell. Tent: Fully test-time adaptation by entropy minimization. In *ICLR*, 2021. 2
- [56] Qin Wang, Olga Fink, Luc Van Gool, and Dengxin Dai. Continual test-time domain adaptation. In *CVPR*, 2022. 2

- [57] Xiaofeng Wang, Zheng Zhu, Guan Huang, Xinze Chen, Jiagang Zhu, and Jiwen Lu. DriveDreamer: Towards real-world-driven world models for autonomous driving. *arXiv preprint arXiv:2309.09777*, 2023. 8
- [58] Wayve. Wayve’s av2.0 approach: Pioneering the end-to-end ai driving model. <https://youtu.be/AEfq5nFi7s8>, 2024. 2
- [59] Xinshuo Weng, Boris Ivanovic, Yan Wang, Yue Wang, and Marco Pavone. PARA-Drive: Parallelized architecture for real-time autonomous driving. In *CVPR*, 2024. 1, 2, 3
- [60] Penghao Wu, Xiaosong Jia, Li Chen, Junchi Yan, Hongyang Li, and Yu Qiao. Trajectory-guided control prediction for end-to-end autonomous driving: A simple yet strong baseline. In *NeurIPS*, 2022. 2
- [61] Jiazhi Yang, Shenyuan Gao, Yihang Qiu, Li Chen, Tianyu Li, Bo Dai, Kashyap Chitta, Penghao Wu, Jia Zeng, Ping Luo, et al. Generalized predictive model for autonomous driving. In *CVPR*, 2024. 3
- [62] Hee Suk Yoon, Eunseop Yoon, Joshua Tian Jin Tee, Mark Hasegawa-Johnson, Yingzhen Li, and Chang D Yoo. C-tpt: Calibrated test-time prompt tuning for vision-language models via text feature dispersion. In *ICLR*, 2024. 8
- [63] Julian Zimmerlin, Jens Beißwenger, Bernhard Jaeger, Andreas Geiger, and Kashyap Chitta. Hidden biases of end-to-end driving datasets. *arXiv preprint arXiv:2412.09602*, 2024. 8

Centaur: Robust End-to-End Autonomous Driving with Test-Time Training

补充材料

在本补充文档中，我们呈现了额外的工作、方法细节、实验细节，以及更多的实验结果和可视化。

A. 额外相关工作

我们的工作扩展了 Hydra-MDP [33]，这是一种最先进的轨迹评分规划器。基于多模态感知架构 TransFuser [7]，Hydra-MDP 通过知识蒸馏框架从多个教师模型（包括基于规则的 PDM 规划器 [9]）中学习。除了某些集成技术 [30, 32] 之外，该领域中很少有工作探索增加更多测试时计算以提升性能的潜力。在我们的工作中，Centaur 通过测试时训练实现了精细化规划。

语义熵。我们的基线之一，语义熵，受到大语言模型中语义不确定性 [29] 的启发，其中通过利用聚类来减少具有语言不变性的冗余不确定性，从而改进语言模型中的不确定性估计，解决了传统熵测度的局限性。语义熵是基于聚类间的概率而非单个响应来计算的。这捕捉了真正不同含义之间的不确定性，而非表面措辞差异。在我们的案例中，我们采用类似的策略对预测轨迹进行聚类并构建熵。

安全关键场景。评估端到端自动驾驶模型面临重大挑战。虽然传统度量如平均位移误差

平均位移误差（ADE）和最终位移误差（FDE）已被广泛使用 [20, 22, 28]，但近期研究 [34] 指出它们在全面评估自动驾驶系统方面存在局限性。这促使采用更精细的基准，如 NAVSIM[10]，该基准从安全性、进展性和交通规则遵守等多个维度评估模型。Bench2Drive[27] 是一个新提出的基准，旨在闭环环境中评估端到端自动驾驶系统的多样化能力，测试驾驶模型处理 44 种不同单独场景的能力。InterPlan[16] 构建了分布外测试场景，例如处理道路中间的碰撞现场，并提出在测试时使用大语言模型调整不可微规划器的参数。在我们的工作中，navsafe 建立在 navtest 之上，深入探究最先进规划器可能失败的罕见案例，以详细展示性能差距。与 InterPlan 不同，我们专注于端到端驾驶。与 Bench2Drive 不同，navsafe 基于真实世界数据。

证据不确定性。Amini 等人 [1] 提出深度

Notation	Description
$\mathcal{L}_{im}$	Imitation loss
$\mathcal{L}_{kd}$	Knowledge distillation loss
$\mathbf{t}$	Trajectory
$\mathbf{p}$	Waypoint in trajectory
π	Policy for planning
$\mathbf{x}$	Sensor inputs
$\mathbf{c}$	Navigation command
θ	Model parameters
H	Cluster entropy
M	Number of trajectory candidates
$score_a$	Anchor score per cluster
k	Planning vocabulary size
γ, α, β, v	Evidential parameters
F	Number of history frames
η	Learning rate
τ	Clustering threshold

表 5. 本文使用的符号及其描述。

证据回归用于训练确定性神经网络，以同时估计连续目标及其相关不确定性。该方法使网络能够推断证据分布的超参数，从而在推理过程中无需采样或使用分布外（OOD）示例进行训练，即可捕获偶然（数据）不确定性和认知（模型）不确定性。通过对预测证据与实际输出之间的对齐施加正则化，该方法产生校准良好的不确定性估计。它可扩展且鲁棒，表现出对对抗性攻击和 OOD 样本的抵抗力，适用于不确定性估计至关重要的复杂任务。在本补充文档中，我们将证据回归损失适配到 TransFuser[7]，以评估其对 TTT 的适用性。

B. 额外方法细节

在本节中，我们提出语义熵的适配方案，以支持基于轨迹回归方法的 TTT。随后，我们提供关于轨迹评分损失函数的额外细节，以及针对轨迹评分和轨迹回归方法的语义熵建模。我们在表 5 中提供了所有符号的表格。

B.1. 轨迹回归规划器

为了在轨迹回归设置中实现不确定性估计，我们预测正态逆伽马（Normal Inverse Gamma, NIG）分布 α, β, γ 的‘证据参数’[1]，并且

对于输出的每个标量维度 y_i ，使用 π_θ 而不是标准点估计来预测 v 。我们可以从该分布中采样如下：

$$(y_1, \dots, y_N) \sim \mathcal{N}(\mu, \sigma^2),$$

$$\mu \sim \mathcal{N}(\gamma, \sigma^2 v^{-1}), \quad \sigma^2 \sim \Gamma^{-1}(\alpha, \beta), \quad (5)$$

其中 $\Gamma(\cdot)$ 是用于实现逆伽马先验的伽马函数， $\mathcal{N}(\cdot)$ 是高斯分布。模型在规划任务中的输出轨迹取 NIG 分布的均值 γ ，从而得到单一轨迹 $\hat{\mathbf{t}}_0 = \pi_\theta(\mathbf{x}_0) = (\gamma_0, \gamma_1, \dots, \gamma_N)$ 。在此设置下学习策略被称为模仿学习：

$$\arg \min_{\theta} \mathbb{E}_{(\mathbf{x}, \mathbf{t}, \mathbf{c}) \sim D_{im}} [\mathcal{L}_{im}(\mathbf{t}, \pi_\theta(\mathbf{x}, \mathbf{c}))], \quad (6)$$

其中 $D_{im} = \{(\mathbf{x}, \mathbf{t}, \mathbf{c}), \dots\}$ 是由专家驾驶员在与其他交通参与者交互时控制车辆所收集的数据集。我们使用 $\mathcal{L}_{im}$ ，的证据损失，这是证据参数 [1] 的最大似然目标。由于轨迹回归规划器所需的输出是一个向量，我们将其表示为 $\tilde{\mathbf{t}} = (\mathbf{p}_0, \mathbf{p}_1, \dots, \mathbf{p}_N)$ ，因此我们的‘证据参数’[1] 实际上采用向量化格式。我们使用策略 π_θ 来表示原始输出 $\tilde{\mathbf{t}}$ 的正态逆伽马 (NIG) 分布 $\tilde{\alpha}, \tilde{\beta}, \tilde{\gamma}$ 和 $\tilde{v}$ 的证据参数。我们可以从该分布中采样如下：

$$(\tilde{\mathbf{t}}_1, \dots, \tilde{\mathbf{t}}_N) \sim \mathcal{N}(\tilde{\mu}, \tilde{\sigma}^2),$$

$$\tilde{\mu} \sim \mathcal{N}(\tilde{\gamma}, \tilde{\sigma}^2 \tilde{v}^{-1}), \quad \tilde{\sigma}^2 \sim \Gamma^{-1}(\tilde{\alpha}, \tilde{\beta}), \quad (7)$$

其中 $\Gamma(\cdot)$ 是用于实现逆伽马先验的伽马函数， $\mathcal{N}(\cdot)$ 是高斯分布。模型在规划任务中的输出轨迹取 NIG 分布的均值 $\tilde{\gamma}$ ，从而得到单一轨迹 $\hat{\mathbf{t}}_0 = \pi_\theta(\mathbf{x}_0) = \tilde{\gamma}$ 。在此设置下学习策略被称为模仿学习：

$$\arg \min_{\theta} \mathbb{E}_{(\mathbf{x}, \tilde{\mathbf{t}}, \mathbf{c}) \sim D_{im}} [\mathcal{L}_{im}(\tilde{\mathbf{t}}, \pi_\theta(\mathbf{x}, \mathbf{c}))], \quad (8)$$

其中 $D_{im} = \{(\mathbf{x}, \tilde{\mathbf{t}}, \mathbf{c}), \dots\}$ 是由专家驾驶员在与其他交通参与者交互时控制车辆所收集的数据集。我们使用 $\mathcal{L}_{im}$ ，的证据损失，这是证据参数 [1] 的最大似然目标。

B.2. 轨迹评分规划器

在我们对 Hydra-MDP[33] 的实现中，除了式 (3) 中的交叉熵损失 $\mathcal{L}_{kd}$ 之外，我们还引入了一个模仿损失 $\mathcal{L}_{im}$ 来正则化轨迹分布，遵循 VADv2[5]。总体损失函数为：

$$\mathcal{L} = \sum_j \mathcal{L}_{im}(\tilde{\mathbf{t}}, \pi_\theta(\mathbf{t}_j, \mathbf{x}, \mathbf{c})) + \mathcal{L}_{kd}(e(\mathbf{t}, \mathbf{x}, \mathbf{c}), \pi_\theta(\mathbf{t}, \mathbf{x}, \mathbf{c})) \quad (9)$$

其中模仿损失 ($\mathcal{L}_{im}$) 实现为基于距离的交叉熵损失 [33]。每条轨迹的查询由该轨迹与日志回放中轨迹之间的 L2 距离所产生的模仿目标进行监督。Softmax 函数应用于该距离分布以产生概率分布。

B.3. 熵估计

锚点与候选轨迹的采样。 本文首先从规模为 8192 的规划词汇表中采样 $M = 100$ 条候选轨迹。采样过程为加权随机采样，权重为每条轨迹在导航训练划分上的平均真实预测驾驶模型分数 (PDMS)。值得注意的是，这与本文在回退层基线中使用的权重计算方式相似。随后，本文依据领域特定准则从候选轨迹中采样 5 个锚点，遵循驾驶语言模型 (DriveLM) [50] 的方法。与 k 均值等标准聚类算法不同，本文方法计算高效且可微分。此外，由于采用固定锚点，该方法确保了覆盖大量可行驶区域，且不受特征空间选择的影响。

语义熵。 直观地说，当策略预期许多轨迹会产生相似结果时，它比预期大多数轨迹产生多样结果时更“确定”。语义熵在特征空间中计算每个 M 轨迹候选到最近锚点的距离（以 L_2 距离衡量），而不是在轨迹的欧几里得空间中。虽然我们的方法所使用的特征空间选择是灵活的，但在这种适配中，我们优先考虑简单性。对于我们的轨迹评分规划器，我们直接使用其输出评分特征作为特征空间的选择。对于轨迹回归，我们考虑两个简单的评分特征 $\{L_\gamma, L_\mu\}$ ，基于证据参数 α, β, γ ，和 v 。我们首先通过 $\Gamma^{-1}(\alpha, \beta)$ 采样 N 个 σ 值，并通过 $\mathcal{N}(\gamma, \sigma^2 v^{-1})$ 采样相应的 μ 。随后，对于 M 个候选中的每条轨迹，我们计算其到 γ 的 L2 距离 L_γ ，以及到 N 个值中最近 μ 的 L2 距离 L_μ 。在所选特征空间中为所有 M 个候选确定最近锚点后，我们将聚类熵（记为 H ）定义为所得 5 类分类分布的香农熵。语义熵的聚类阈值。这里我们进一步详细说明语义熵中的聚类过程，其中我们使用 τ 作为阈值。将轨迹候选聚类到轨迹锚点需要一个距离函数 $D(\cdot, \cdot)$ ，以在评分特征方面诱导两条轨迹之间的等价性。我们采用 L_2 距离作为 D 的实现，因为它计算效率高且与两类规划器的评分特征兼容。聚类是固定中心的一步 k 均值。我们使用 D 来衡量两条轨迹（一条来自锚点，另一条来自候选）的评分特征，如果它低于某个阈值 τ ，则它们归入同一簇。

表 6. NAVSIM v1.0 与最先进方法的比较。与主论文表 2 中的官方排行榜不同，这里我们报告的是在用于 2024 年 NAVSIM 挑战赛的早期 NAVSIM 版本上，使用单一训练种子的模型结果。Transfuser-SE 表示将 Transfuser 与 TTT 和语义熵相结合。

Model	Deployment	NC $\uparrow$	DAC $\uparrow$	EP $\uparrow$	C $\uparrow$	TTC $\uparrow$	PDMS $\uparrow$
UniAD [22]	None	97.8	91.9	78.8	100.0	92.9	83.4
	Optimization	95.4	86.0	71.9	99.3	87.3	75.2
PARA-Drive [59] + Occupancy Head	None	97.9	92.4	79.3	99.8	93.0	84.0
	None	97.8	92.0	78.3	99.7	93.7	83.6
TransFuser [7] TransFuser-SE	None	97.1	91.9	79.3	100.0	91.9	83.4
	TTT	97.9	92.9	80.1	100.0	94.1	85.7
DiffusionDrive [37]	None	98.2	96.2	82.2	100.0	94.7	88.1
Hydra-MDP [33]	None	98.4	97.8	86.5	100.0	93.9	90.3
Hydra-SE	TTT	99.2	98.5	85.7	100.0	97.1	91.8
Centaur	TTT	99.5	98.9	85.9	100.0	98.0	92.6

终点。轨迹被分配给通过得分特征上的 D 度量的最近中心。在聚类中使用固定起始中心的原因是，无论得分特征如何，它们都能覆盖足够的可行驶区域。在实践中，我们将 τ 设置得足够大，以最小化落在阈值之外的轨迹数量。对于这些剩余的轨迹，我们根据轨迹空间中 L_2 距离的最近锚点分配一个默认聚类。

C. 实验细节

超参数。 对于所有采用 Hydra-MDP 的实验，我们遵循最先进的设置 [33]，将规划词汇表的大小设为 8192。对于所有采用 TransFuser 的实验，我们遵循证据深度学习 (Evidential Deep Learning) [1] 中的实现，为每个航点回归头配备证据回归损失。轨迹评分和轨迹回归规划器的输出均为 4 秒内、以 10 Hz 采样的 40 个航点轨迹，每个航点由其 x 、 y 和航向值定义。 $\tau = 0.06$ 用于 Hydra-SE， $\tau = 0.02$ 用于 TransFuser-SE。对于 TransFuser，我们使用 $1 \times$ 块 NVIDIA A100，批大小为 64，学习率为 $1e-4$ 。

C.1. 基线的动机

我们基于以下动机选择不确定性估计和部署策略中的基线：

- **KL 发散不确定性作为不确定性的基线** 在轨迹评分规划器中：这是通过可视化成功与失败案例中得分特征分布而得出的动机。我们发现不同度量下的得分分布存在不一致，尤其是 NC 与 DAC 的得分，如图 5 所示。因此，我们思考这种不一致是否可以作为潜在失败案例的指示器。

- **证据不确定性作为不确定性的基线，用于 轨迹回归规划器：**由于许多回归问题使用证据不确定性作为基线方法，我们遵循这一默认设置，将其作为 TTT 与 TransFuser 的基线。

- **回退层作为部署策略的基线，用于 端到端规划器：**我们采用回退层与测试时训练进行比较，因为这是工业界的常见做法，并且与测试时轨迹优化不同，它可以在无法访问显式表示的情况下实现。将回退层作为策略部署时使用的推理方案为：

- 使用基础端到端规划器推理所有帧。
- 对所有帧运行用于失败案例分类的不确定性估计，以选择可能的失败案例。分类设置的细节稍后在表 3 中讨论。
- 对于被选为可能失败的帧，运行回退层。

C.2. 附加消融研究

NAVSIM 1.0。为完整性起见，我们在表 6 中将 Centaur 与 NAVSIM 1.0 中的其他基线进行比较。我们优于所有其他方法。此处，我们还包含了 TransFuser-SE 的结果，这是我们用于将 TTT 应用于轨迹回归模型的基线。与 Centaur 类似，相对于未使用 TTT 的基础模型 TransFuser，它获得了 2.3 PDMS 的提升。有趣的是，UniAD [22] 使用专家设计的代价函数进行优化，在这一优化步骤中性能出现下降。这是由于自车进度 EP 的减少，与我们在表 1 中使用回退层的发现非常相似。此外，PARA-Drive [59] 的结果表明，从端到端模型中引入显式的 3D 占用表示会降低其规划性能。

表 7. navtest 上的消融实验。除主论文表 1 外，还有更多结果。TTT* 使用历史梯度的 SVD

来组合它们，而不是取平均。Hydra-SE r 指使用 r 个历史帧。Hydra-SE τ 表示仅在不确定性高于阈值（例如主论文 L383）的选定帧的推理上应用 TTT。我们报告 navtest 上的摊销延迟。

Model	Deployment	Uncertainty	NC $\uparrow$	DAC $\uparrow$	EP $\uparrow$	C $\uparrow$	TTC $\uparrow$	PDMS $\uparrow$	Latency (ms) $\downarrow$
TransFuser [7]	-	-	97.1	91.9	79.3	100.0	91.9	83.4	103.1
	Fallback Layer	Evidential	98.8	97.4	13.1	100.0	97.9	60.6	108.7
	Fallback Layer	Semantic Entropy	99.2	97.2	14.6	99.8	96.5	59.9	109.9
	TTT	Evidential	97.9	92.5	79.6	100.0	92.9	84.2	149.3
TransFuser-SE	TTT	Semantic Entropy	97.9	92.9	80.1	100.0	94.1	85.7	153.8
	TTT*		97.4	89.3	78.3	100.0	91.1	83.8	157.6
Hydra-MDP [33]	-	-	98.4	97.8	86.5	100.0	93.9	90.3	243.9
	Fallback Layer	KL Divergence	99.1	99.2	9.6	100.0	96.7	63.1	263.2
	Fallback Layer	Semantic Entropy	99.7	99.5	10.4	100.0	98.9	65.3	256.4
	TTT	KL Divergence	98.9	98.1	86.0	100.0	94.4	91.5	357.1
Hydra-MDP-ViT-L	-	-	98.4	97.7	85.0	100.0	94.5	89.9	237.2
	Fallback Layer	KL Divergence	99.7	99.2	10.4	100.0	98.9	67.4	259.5
	Fallback Layer	Semantic Entropy	99.6	97.5	11.8	100.0	94.1	61.0	255.7
	TTT	KL Divergence	99.1	98.2	89.6	100.0	96.7	90.9	354.1
Hydra-SE ⁴	TTT	Semantic Entropy	99.2	98.5	85.7	100.0	97.1	91.8	312.5
Hydra-SE ³			98.9	98.7	86.7	100.0	95.1	91.5	
Hydra-SE ²			98.8	98.6	86.5	100.0	95.0	91.3	
Hydra-SE ¹			98.9	98.6	86.7	100.0	95.1	91.4	
Hydra-SE ⁴	TTT	Semantic Entropy	98.6	98.1	86.3	100.0	94.9	91.3	279.6

这些结果表明，在部署过程中需要一种替代手段来确保安全，例如我们提出的 TTT。

延迟。我们以毫秒为单位统计前向传播时间，而对于带有不确定性估计及部署策略的规划器，我们先统计一次前向传播时间，再统计对应部署方法（测试时训练或回退层）的时间。对于测试时训练，我们计入梯度计算和模型更新的时间；对于回退层，我们计入通过 L2 距离选择与预测轨迹最近的安全轨迹的最近邻选择时间。本次推理测试的硬件详情如下：• GPU：1 $\times$ NVIDIA A100，驱动版本 535.54.03 • CPU：AMD EPYC 9124 16 核处理器 • RAM：500GB 如表 7 所示，在不集成我们提出的部署和不确定性增强的情况下，直接比较基础 TransFuser 和 Hydra-MDP 模型，可以发现 Hydra-MDP 在性能上具有显著优势。这可以归因于它们不同的骨干架构：TransFuser 使用高效的 ResNet-34 骨干，虽然牺牲了性能，但延迟显著更低，为 103.1 毫秒，而 Hydra-MDP 为 243.9 毫秒。相比之下，Hydra-MDP 计算开销更大的 V2-99 骨干使其在 PDMS 指标上性能高出约 7 个点。

我们重申，目前梯度计算时间已包含在 TTT 方法的延迟测量中。可以通过在我们的实现中并行化执行，或仅在不确定性超过阈值的选定帧上应用 TTT 来减少该时间（表 7，最后一行）。



带 SVD 的测试时训练 (TTT)。遵循 [13]，存在另一种测试时自适应的实现方式，它对历史梯度应用奇异值分解 (SVD)，以找出对模型更新最有用的梯度。如表 7 所示，在我们的案例中，TTT*（使用 SVD）在 TransFuser-SE 上的性能低于使用平均梯度实现的 TTT。

ViT-L 骨干。我们在表 7 中消融了不同骨干在 Hydra-MDP 上对不同不确定性及部署策略设置的影响。总体而言，Hydra-MDP 中实现的 V2-99 骨干比 ViT-L 骨干具有更好的性能。然而，在采用 KL 散度的回退层设置下，ViT-L 骨干在 PDMS 指标上超过 V2-99 约 4 个点。

缓冲区长度 F 。我们展示了在 navtest 上使用不同历史帧长度对 Hydra-SE 的影响

表 7。我们观察到，当增加历史帧的长度时，性能略有提升（ F 设为 2 时性能最低）。总体而言， F 的所有设置下性能表现一致，表明了我们方法的鲁棒性。

Group 1



Group 2





图 5。成功与失败案例之间的分数分布差异。我们展示了两组比较，每组内场景类型相似。我们观察到，与成功案例相比，失败案例（组内上排）在各组之间表现出更大的多样性。

表 8。失败识别。除主论文中的表 3 外，还提供了更多结果，包括其他规划器和不确定性阈值。

Uncertainty	Model	Thresh.	TPR $\uparrow$	Acc. $\uparrow$
Evidential	TransFuser [7]	0.1	47.2	34.9
		0.3	32.6	48.2
		0.5	26.9	59.5
		0.7	23.5	62.8
		0.9	7.4	71.2
KL Divergence	Hydra-MDP [33]	1500	41.3	68.3
Semantic Entropy	TransFuser [7]	0.8	35.3	63.1
	Hydra-MDP [33]	0.2	75.2	61.9
		0.5	73.3	62.4
		0.8	62.5	72.2
		1.1	41.7	73.2
		1.4	10.9	82.5
<i>Select All</i>	<i>TransFuser</i> [7]	-	<i>100.0</i>	<i>24.1</i>
<i>Select None</i>		-	<i>0.0</i>	<i>75.9</i>
<i>Select All</i>	<i>Hydra-MDP</i> [33]	-	<i>100.0</i>	<i>15.6</i>
<i>Select None</i>		-	<i>0.0</i>	<i>84.4</i>

失败识别阈值。我们研究了在可能失败案例识别中，不确定性识别采用不同阈值的效果。对于使用证据不确定性的 TransFuser 和使用语义熵的 Hydra-MDP，我们发现提高阈值会导致失败案例的真阳性率（TPR）下降，同时整体准确率上升。原因是在 navtest 上，我们面临长尾分布，失败案例仅占测试样本的一小部分，这使得在避免误判真正成功案例的同时，难以准确识别真正的失败案例。