

一致性策略

通过一致性蒸馏加速视觉运动策略

Aaditya Prasad¹, Kevin Lin¹, Jimmy Wu², Linqi Zhou¹, Jeannette Bohg¹

¹Stanford University ²Princeton University

<https://consistency-policy.github.io>

摘要——许多机器人系统，如移动机械臂或四旋翼飞行器，由于空间、重量和功率的限制，无法配备高端图形处理器（GPU）。这些限制使得这些系统无法利用视觉运动策略架构的最新发展，而这些架构需要高端 GPU 来实现快速的策略推理。本文提出一致性策略（Consistency Policy），这是一种比扩散策略（Diffusion Policy）更快且性能相当的替代方案，用于学习视觉运动机器人控制。凭借其快速的推理速度，一致性策略能够在资源受限的机器人设置中实现低延迟决策。一致性策略通过强制沿扩散策略学习轨迹的自治性，从预训练的扩散策略中蒸馏而来。我们在 6 个仿真任务以及三个真实世界任务中，将一致性策略与扩散策略及其他相关加速方法进行了比较，并在笔记本电脑 GPU 上演示了推理。在所有任务中，一致性策略的推理速度比最快的替代方法快一个数量级，并保持了具有竞争力的成功率。我们还表明，一致性策略的训练过程对预训练扩散策略的质量具有鲁棒性，这一有用结果有助于从业者避免对预训练模型进行大量测试。实现这一性能的关键设计决策包括一致性目标的选择、降低初始样本方差以及预设链式步骤的选择。




图 1：扩散策略与一致性策略（Consistency Policy）均通过采样随机动作并逐步去噪来生成动作预测。 x_t 表示在时刻 $t \in [0, T]$ 的当前动作分布，时刻越大对应噪声越大的动作。图中展示了在各自生成过程的不同阶段，预测动作序列的分布（由红到绿的点序列表示）。a) 扩散策略通过多个步骤对动作序列进行去噪，导致在机器人上部署策略时推理成本较高。b) 一致性策略在单步内生成动作序列，推理速度远快于扩散策略，同时保持具有竞争力的成功率。

一、引言

扩散模型（Diffusion Model）近期在机器人控制的模仿学习（Imitation Learning）中展现出令人瞩目的成果 [6, 19, 22, 33, 35]。特别是扩散策略（Diffusion Policy）[6] 在多种机器人任务上达到了最先进的模仿学习性能。扩散模型的一个关键缺陷在于生成动作所需的推理时间。扩散模型通过从初始噪声状态逐步去噪来产生输出。这一过程意味着它们需要多次前向评估才能预测一个动作，而减少评估次数会降低性能。扩散策略 [6] 采用名为去噪扩散概率模型（Denoising Diffusion Probabilistic Models, DDPM）[12] 的扩散框架，使用 100 个去噪步骤进行评估，在 NVIDIA T4 上每次动作生成大约需要一秒。如此缓慢的推理速度限制了扩散策略的应用场景，使其仅适用于能够容忍较长反应时间和较高计算成本的任务与环境。虽然准静态任务（如简单的拾取放置或零件装配）可以允许较慢的推理速度，但动态任务（如平衡物体或在动态环境中导航）通常需要更快的控制频率。此外，对于机载计算资源受限的机器人，扩散策略可能慢得不切实际。鉴于

基于这些观察，我们的目标是在大幅减少推理时间的同时，保持扩散策略的性能。在图像生成领域，蒸馏技术引起了广泛关注 [16, 24, 29, 31, 34]，这些技术利用预训练的扩散模型来教导新的学生模型如何采取更大的去噪步骤，从而减少生成所需的函数评估总次数。其中一组蒸馏技术 [14, 29, 31] 基于这样的洞见：训练好的扩散模型可以解释为求解常微分方程 [30]。这些方法利用这些常微分方程解的唯一性，并在始于同一常微分方程轨迹上不同位置的去噪步骤之间强制一致性。因此，蒸馏得到的学生网络被称为一致性模型。在图像生成中，蒸馏的一致性模型已被证明能够以单步或少数几步生成在样本质量上媲美传统扩散模型的结果。我们将这些一致性模型框架适配到机器人领域。我们首先将扩散策略所采用的扩散框架替换为 EDM[13]，这是一个类似的、更常用于一致性蒸馏的多步框架。我们训练

使用 EDM 框架的教师模型，然后通过一致性轨迹模型的改编版本进行蒸馏

金等人提出的 (CTM) 目标 [14]。关键设计决策包括一致性目标的具体选择、降低初始样本方差以及预设链式步骤的选择。本文还就随机失活 (dropout) 在 CTM 目标特定区域的作用提供了洞见，并分析了一致性策略对教师质量的鲁棒性。总体而言，本文证明所提方法的推理速度平均比最快的基线快约一个数量级（见表 I），并在多种任务上保持与所有基线相似或更高的成功率。

II. 相关工作

扩散模型已在图像、音频、视频和三维生成领域取得众多最先进的成果 [1, 14, 21, 23, 26, 28]。在机器人学背景下，扩散模型已被用作模仿学习的策略网络，并取得了显著效果 [6, 19, 33]。然而，扩散模型的原始变体，如去噪扩散概率模型 (DDPM) [12]，由于需要大量迭代采样步骤，推理时间较长。具体而言，DDPM[12] 可被解释为在时间上反向求解随机微分方程，因此其特征为随机去噪过程，在生成输出时积分少量布朗运动。DDPM 的固定步数通常超过 100 步，使其成为扩散策略 [6] 所使用的最慢框架。一类工作 [28] 通过减少预测所需的去噪步骤数来解决扩散模型推理时间长的的问题。与 DDPM 的随机求解器不同，去噪扩散隐式模型 (DDiM) [28] 可被解释为对确定性常微分方程 (ODE) [24] 进行积分。重要的是，DDiM 允许可变步数，这意味着基于 DDiM 的网络可以在训练时使用大量去噪步骤，而在推理时使用少得多的步骤进行评估。EDM[13] 遵循对确定性 ODE 积分的模式，也允许在测试时使用少量去噪步骤。EDM 与 DDiM 的不同之处在于对预处理和加权的修改。然而，即使采用 DDiM 和 EDM 等可变步长方案，在推理时减少去噪步骤数往往会降低样本质量。另一类工作由 Shih 等人 [27] 提出，旨在通过并行采样加速扩散模型。ParaDiGMS[27] 不是沿 ODE 顺序去噪，而是尝试通过这些点上的皮卡迭代，并行收敛扩散 ODE 轨迹上的滑动批次点。该方法具有大幅加速的潜力，因为点可以在顺序求解器到达之前很久就收敛，从而允许跳过所有先前的点。然而，ParaDiGMS 由于这种并行化而大幅增加了内存需求。在机器人场景中，处理硬件通常有限，可用计算资源受到需要与策略网络并行运行的其他进程的约束。实际用户可能会看到速度提升，

ParaDiGMS 在因显存可用性或其他约束而被迫减小批窗口大小时，性能会迅速下降。此外，该方法仍比单步预测慢，而一致性策略 (Consistency Policy) 能够实现单步预测。基于蒸馏的技术 [18, 24] 已被探索用于加速文本到图像领域中扩散模型的推理速度。许多此类蒸馏技术从一个预训练的教师模型开始，训练一个新的学生模型在教师已学会映射的常微分方程 (ODE) 轨迹上采取更大的步长 [14, 16, 24, 29, 31, 34]。通过采取更大的步长，学生模型能够以更少的总步数完成生成。在基于蒸馏的技术中，一致性模型 [14, 29, 31] 支持输出的单步和多步采样。一致性蒸馏技术利用 ODE 轨迹的自洽性 [31]，训练学生模型在给定同一 ODE 轨迹上两个不同点时预测相同的输出。该目标由 Song 等人 [31] 首次提出，他们选择一对相邻输入点，并教导学生模型将这些输入点映射到给定 ODE 轨迹上的同一起点，其中不同点借助预训练扩散模型进行采样。Kim 等人 [14] 通过训练任意步长和任意间隔的输入点对该方法进行了推广，在图像生成领域取得了最新技术成果。在本文中，我们研究如何将后者更通用的框架——一致性轨迹模型 (CTMs) [14]——适配到机器人领域。同时，[4, 8] 探索了将一致性模型用作基于状态的连续控制策略类别。Chen 等人 [4] 将一致性蒸馏模型目标 [31] 适配到基于状态的离线强化学习 (RL) 设置中。作者未使用 Kim 等人 [14] 的通用 CTM 框架，并且由于他们专注于 Q 学习而非行为克隆，也无法直接蒸馏教师模型。[8] 利用 [31] 中的一致性训练（而非蒸馏）目标进行基于状态的连续控制任务。一致性训练目标用蒙特卡洛估计器替代教师模型，从而实现无教师训练。虽然它在常见 RL 基准上对基于状态的策略可能取得良好结果，但我们证明，在相对更复杂的机器人任务上，对于维度高得多的基于图像的策略，该一致性训练目标无法达到足够的成功率。最后，已有大量工作使用非扩散模型架构作为视觉运动机器人策略。此类替代方案在相同任务上通常表现不如扩散策略，或需要许多机器人环境中可能不可用的外部计算资源。最初的扩散策略论文 [5] 在多个机器人仿真 [9, 17, 25] 和真实世界任务上与先前最先进的模仿学习 (IL) 算法进行了基准比较。由于扩散策略优于所有这些基线，我们选择仅与扩散策略和其他扩散策略推理加速方法进行基准比较。在这些较差的基线中，最值得注意的是行为

变换器 (Transformer) [25] 是扩散策略 (Diffusion Policy) 的一个重要替代方案：单步基于变换器的模型 [2, 3]。RT-1 [2] 是一个强大的单步基于变换器的基线，但它是为大规模预训练而设计的。与扩散策略 [5] 和我们自己的一致性策略 (Consistency Policy) 不同，像 Octo [19] 这样的扩散策略网络更容易与 RT-1 进行比较。事实上，Octo 将 RT-1 作为基线，并显示出相对于它以及另一个变换器基线的显著改进。由于我们在本文中引入的改进与具体的扩散策略公式是正交的，因此 Octo 策略也可以被蒸馏并制成单步或少步策略网络。这可能是未来工作的一个有趣方向。此外，我们决定不将 RT-2 [3] 和其他基于视觉或大语言模型 (Large Language Model) 的策略网络 [15, 36] 作为基线，因为它们利用了集成语言模型的大规模预训练和规模，并且必须在云端运行，而不是在机载计算机上运行（这是我们在本工作中考虑的场景）。

III. 一致性策略

我们将视觉运动机器人策略表述为一致性轨迹模型 (Consistency Trajectory Model) [14]，并将其称为一致性策略 (Consistency Policy)。在本节中，我们首先简要介绍扩散模型 (Diffusion Model)。然后描述如何训练一致性策略，这需要先训练一个教师扩散策略，再将该教师模型蒸馏为一致性策略。接着解释我们的推理过程，包括用于尽可能最快推理时间的单步过程，以及以牺牲一些推理速度换取更高准确率的多步过程。最后，我们介绍一些实现细节。

A. 预备知识

本节对我们所使用的扩散模型进行了简要介绍，因此我们重点关注这些模型的常微分方程 (ODE) 解释。进一步阅读请参见 [12, 13, 30]。在本文中，“轨迹”一词仅指由扩散步骤参数化的常微分方程轨迹，下文将对此进行解释。机器人运动（无论是预测的还是专家演示的）将被称为“动作”或“动作序列”，而非轨迹。我们的扩散模型学习将随机动作 $\mathbf{x}_T$ （从单位高斯分布 $\mathcal{N}(0, \mathbf{I})$ 中采样）映射到特定动作 $\mathbf{x}_0$ （从以当前观测为条件的专家动作分布中采样，我们将其记为 $p_0(\mathbf{x}|o)$ ）。下标 t 与 $0 \leq t \leq T$ 表示沿轨迹的时间，该轨迹将点从时间 T 处的简单高斯分布映射到时间 0 处的复杂数据分布。此过程通常被表述为概率流常微分方程 (PFODE) [30]，其中沿时间正向演化 PFODE 会使动作加噪，而沿时间反向演化则会使动作去噪。完全去噪的动作即为策略对专家动作的预测。该 PFODE 的一般形式为

$$d\mathbf{x}_t = \left[\boldsymbol{\mu}(\mathbf{x}_t, t) - \frac{1}{2}\sigma(t)^2 \nabla \log p_t(\mathbf{x}_t|o) \right] dt \quad (1)$$

其中 $\boldsymbol{\mu}(\cdot, \cdot)$ 为漂移系数， $\sigma(\cdot)$ 为扩散系数， $p_t(\mathbf{x}_t|o)$ 为某时间 $t \in [0, T]$ 处的加噪概率分布。为使 $p_T(\mathbf{x}_T|o)$ 在 T 足够大时趋近正态分布，Karras 等人 [13] 设定 $\boldsymbol{\mu}(\mathbf{x}_t, t) = 0$ 和 $\sigma(t) = \frac{1}{\sqrt{2t}}$ 。加噪概率分布的梯度 $\nabla \log p_t(\mathbf{x}_t|o)$ 被称为得分。该得分函数通常难以计算，因此我们用神经网络对其进行近似。因此，去噪步骤需要在当前位置 $\mathbf{x}_t$ 处评估得分函数近似器，然后使用数值积分技术对所得的 $d\mathbf{x}_t$ 进行积分。训练得分函数近似器可采用多种目标，但它们都需要首先对原始训练数据集中的样本执行前向扩散过程（加噪）。时间步 t 处的未归一化扰动分布 $p_t(\mathbf{x}_t|o)$ 等价于原始数据分布 $p_0(\mathbf{x}|o)$ 与 $\mathcal{N}(0, t^2 \mathbf{I})$ 的卷积。采样特定的 $\mathbf{x}_t \sim p_t(\mathbf{x}_t|o)$ 可通过采样随机噪声 $\epsilon \sim \mathcal{N}(0, \mathbf{I})$ 、将其乘以 t 、然后将其加到来自原始分布 $\mathbf{x} \sim p_0(\mathbf{x}|o)$ 的样本上来完成 $\mathbf{x}_t = \mathbf{x} + t * \epsilon$ 。在将该位置传入得分函数近似器之前，我们对其进行归一化以使其具有单位方差。

B. 训练

为了训练一个能够进行少步或单步生成的模型，我们首先训练一个教师模型，然后将其蒸馏为学生模型。教师模型和学生模型的公式描述如下。

1) 教师模型 (EDM) 教师模型，我们记为 s_ϕ ，按照 EDM 框架 [13] 进行训练。训练好的 EDM 模型以 PFODE 上的当前位置 $\mathbf{x}_t$ 、时间 t 以及条件 o 作为输入，用于估计 PFODE 轨迹的导数：

$$\frac{d\mathbf{x}_t}{dt} = -\frac{(\mathbf{x}_t - s_\phi(\mathbf{x}_t, t; o))}{t} \quad (2)$$

EDM 模型必须与数值积分方法结合使用，才能实际计算 PFODE 轨迹上的位置 $\mathbf{x}$ 。这种对 ODE 导数的重复估计及其后的数值积分，正是导致扩散模型推理速度缓慢的原因。按照 [13]，我们优化去噪分数匹配

(DSM) 损失来训练 EDM 模型：

$$\mathcal{L}_{\text{DSM}}(\boldsymbol{\theta}) = \mathbf{E}_{t, \mathbf{x}_0, \mathbf{x}_t | \mathbf{x}_0} [d(\mathbf{x}_0, s_\phi(\mathbf{x}_t, t; o))] \quad (3)$$

DSM 目标函数取 PFODE 上的一个采样点 $(\mathbf{x}_t, t)$ ，并教导 EDM 模型预测真实初始位置 $\mathbf{x}_0$ 。我们使用的度量 $d(\cdot, \cdot)$ 是伪胡贝尔损失：

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{\|\mathbf{x} - \mathbf{y}\|_2^2 + c^2} - c \quad (4)$$

其中 $c > 0$ 是一个小常数。我们遵循 Song [29] 的建议，对于维度数据设置 $\bar{D}$ 。该度量充当标准 l_1 与 $c = 0.00054 \sqrt{\bar{D}}$ 。

l_2 范数之间的桥梁，并且比 EDM 中最初使用的 l_2 损失更有效地处理离群值。按照 Karras 等人 [13] 的做法，我们使用 Heun 二阶求解器作为数值积分方案。在整个工作中，我们还保持了 EDM[13] 中描述的时间步离散化方案。

2) 学生模型（一致性策略）Kim 等人 [14] 提出了一种训练目标，将教师模型 $s_\phi(\mathbf{x}_t, t; o)$ 蒸馏为学生模型 $g_\theta(\mathbf{x}_t, t, s; o)$ ，并仅需一个或少量推理步骤即可在图像生成任务上达到最新技术水平。学生模型 $g_\theta(\mathbf{x}_t, t, s; o)$ 是一个神经网络，其输入为沿 PFODE 的位置 $\mathbf{x}_t$ 、时间 t 和观测 o 。学生模型学习输出 $\mathbf{x}_s$ 的估计值，其中 s 是沿 PFODE 的任意更早时间。学生模型使用两个目标的组合进行训练：DSM 损失（见公式 3）和 CTM 损失 [14]，下面将更详细地解释。直观上，CTM 目标可以理解为强制沿 PFODE 的自洽性，因为同一 PFODE 上的不同点 $(\mathbf{x}_t, t)$ 和 $(\mathbf{x}_u, u)$ 应在某个时间 s 重建为同一位置 $\mathbf{x}_s$ ，且 $0 \leq s < u < t \leq T$ 。更正式地，CTM 目标涉及在同一 PFODE 上采样两个位置 $\mathbf{x}_t, \mathbf{x}_u$ ，并将两个位置去噪回同一时间步 s 。在计算 $g_\theta(\mathbf{x}_t, t, s; o)$ 和 $g_\theta(\mathbf{x}_u, u, s; o)$ 之后，这两个样本（分别称为 $\mathbf{x}_s^{(t)}$ 和 $\mathbf{x}_s^{(u)}$ ）使用 $g_\theta(\mathbf{x}_s^{(t)}, s, 0; o)$ 和 $g_\theta(\mathbf{x}_s^{(u)}, s, 0; o)$ 被带回时间 0（见图 2）。这是在计算损失之前完成的，以确保损失度量始终在完全去噪的动作空间中计算，并取自 [14]。因此：

$$\mathcal{L}_{CTM} = d(g_\theta(\mathbf{x}_s^{(t)}, s, 0; o), g_\theta(\mathbf{x}_s^{(u)}, s, 0; o)) \quad (5)$$

where

$$\mathbf{x}_s^{(t)} = g_\theta(\mathbf{x}_t, t, s; o) \quad (6)$$

$$\mathbf{x}_s^{(u)} = g_\theta(\mathbf{x}_u, u, s; o) \quad (7)$$

且 s, u, t 均为离散时间网格上的点。前三个方程中唯一未置于 `stopgrad`¹ 下的操作是从 $t \rightarrow s$ 的生成，如公式 6 所述。我们从离散时间步上的均匀分布中采样训练时间 t 。在从 $\mathcal{N}(0, t^2 \mathbf{I})$ 采样 $\mathbf{x}_t$ 之后，使用教师 EDM 模型的 $t - u$ 步和所选数值积分器（根据公式 2）采样 $\mathbf{x}_u$ 。因此，蒸馏信号通过教师模型对给定 $\mathbf{x}_t$ 的 $\mathbf{x}_u$ 的预测提供。我们将此一致性项添加到公式 3 中的 DSM 损失中，以形成最终训练目标：

$$\mathcal{L}_{CP} = \alpha \mathcal{L}_{CTM} + \beta \mathcal{L}_{DSM} \quad (8)$$

¹`stopgrad` 是自动微分框架（如 Pytorch）中的函数，可防止操作被添加到计算图中。在图 2 中，损失的梯度仅针对来自 $t \rightarrow s$ （蓝色）的操作计算。对每个操作进行微分可能导致训练不稳定、收敛缓慢甚至失败。




图 2：一致性轨迹模型沿概率流常微分方程（黑色）施加自洽性，通过在时间上采样点 s, u, t 使得 $0 \leq s < u < t \leq T$ ，利用教师模型在停止梯度下从 $t \rightarrow u$ 去噪（绿色），利用学生模型从 $t \rightarrow s$ 去噪（蓝色），并利用学生模型在停止梯度下去噪 $u \rightarrow s$ （橙色）。随后，我们使用停止梯度的学生模型将时间 s 处的两个生成位置带回时间 0。这两个最终生成结果之间的差异即为计算得到的损失 $\mathcal{L}_{CTM}$ （红色）。在我们的实验中，我们发现 $u = t - 1$ 和 s 在 u 以下任意取值效果最佳。

具有可调超参数 α 和 β ，其中下标 CF 代表一致性策略。在实践中，调整 Song 等人 [31] 的标准采样方案，使得 t 和 u 为相邻时间步，似乎效果最佳。我们在表 V 中对此进行了更详细的探讨。跳跃连接和采样器等细节与 [14] 保持一致。

C. 推理

一致性策略的一个重要特性是，在推理时无需进一步训练模型即可在速度与准确率之间进行权衡。因此，我们描述两种过程：当速度至关重要时的单步推理，以及当需要更高准确率时的三步推理。这两种方法均比先前工作更快。我们训练好的一致性策略的单步推理过程如下：采样初始位置 $\mathbf{z} \sim \mathcal{N}(0, \mathbf{I})$ ，计算 $\mathbf{x} = g_\theta(\mathbf{z}, T, 0; o)$ ，其中 T 是训练期间使用的最大时间步， o 是当前观测，然后将 $\mathbf{x}$ 部署为我们的动作到环境中。注意，我们采样的是 $\mathbf{z} \sim \mathcal{N}(0, \mathbf{I})$ ，而非 $\mathbf{z} \sim \mathcal{N}(0, T^2 \mathbf{I})$ ，后者是标准的反归一化初始采样。这一改变使我们的初始点更接近正态分布的均值，并且经验上比标准采样方案表现更好，如表 VI 所示。对此的一种解释是，在均值附近采样可确保轨迹更符合分布内，并防止异常值。这可能与 Pearce 等人 [20] 的假设有关，即在模仿学习任务中，将输出推离位于专家数据中心的高似然无条件区域是有害的，即使这种力量在图像生成任务中（在作者的情况下，使用无分类器引导）是有用的。我们通过像一致性模型 [31] 那样将生成结果串联起来执行三步生成。给定串联时间步 $\{t_1, t_2\}$ ，我们照常从 $T \rightarrow 0$ 去噪，然后加噪至时间 t_1 ，再去噪回时间 0，并重复前述两步。

剩余链式时间步的步骤。这种往复过程可理解为对初始预测的细化。这些链式时间步是超参数。据我们所知，最初的一致性模型工作针对每个任务和数据集分别调整了这些步骤。在机器人领域，当需要通过真实世界试验来评估成功率时，这种调整可能变得复杂，实践者可能希望有一个开箱即用的强推荐。图像扩散领域的先前工作 [7, 11] 发现，不同的噪声水平在训练时对应不同的任务。最早的时间级别被发现调整的是难以察觉的、不重要的特征，而较大的时间级别则形成一般属性或仅插值到目标分布的中心 [13]。靠近区间早中期的时间步贡献了大部分重要特征和细节。因此，我们优先从这些早中期时间步进行链式。我们的离散化方案将连续时间扭曲，使时间区间起始处包含更多时间步。因此，我们使用离散化时间的细分作为时间步。也就是说，对于三步生成，我们在时间步 $\{t_{\frac{2N}{3}}, t_{\frac{N}{3}}\}$ 处进行链式，其中 N 是总步数。该策略实现了对早中期时间步的期望关注，并且与细分连续时间等其他简单策略表现不同。我们在第 IV-D 节中对该比较进行了定性验证。

D. 实现细节

我们沿用了 Chi 等人 [6] 中预测动作序列的设计选择，目的是将实验评估的重点放在训练后的网络上。为此，我们也保留了扩散策略（Diffusion Policy）中的一维卷积 UNet 架构作为教师模型。该架构通过 FiLM 块以观测和扩散时间步 t 为条件，并使用一维卷积块在动作域中进行扩散。对于学生模型，我们采用相同的架构，只是扩展了 FiLM 块以适应对停止时间步 s 的条件化。我们用训练好的教师模型对学生模型进行热启动，并将这些扩展的 FiLM 层零初始化，以防止它们延迟热启动参数的有效性，从而实现更快的收敛。扩散策略还给出了扩散 Transformer 而非一维卷积 UNet 的结果。我们选择使用 UNet，仅仅是因为扩散策略 [6] 提到 Transformer 通常比 UNet 需要更多的超参数调优：架构的选择与我们的方法正交，一致性策略（Consistency Policy）应当像扩散策略一样受益于经过适当调优的 Transformer 骨干网络。

四、实验

我们首先在多种常见机器人基线上展示一致性策略在准确率和推理速度方面的优势，这些基线包括基于图像和基于状态的控制，涵盖短时程和长时程任务。随后，我们在真实世界的垃圾清理任务中部署一致性策略，并



图 3: Robomimic 任务。我们在单机器人 Robomimic [17] 任务上评估我们的方法。从左到右，按难度递增的顺序，我们测试了 Lift、Can、Square 和 Tool Hang。

在计算资源受限的环境中将我们的方法与基线进行比较。最后，我们对核心设计选择进行消融实验，并探索模型的细节。

A. 基线

由于我们的目标是在减少推理时间的同时保持一致性策略（Consistency Policy）的性能，扩散策略（Diffusion Policy）的 DDPM 和 DDIM 变体是我们最重要的基线。此外，ParaDiGMS [27] 试图通过并行化去噪过程来提高扩散策略的生成速度。作者公布了扩散策略中使用的两种扩散调度器 DDPM 和 DDIM 的平均加速比，分别为 3.7 倍和 1.6 倍。ParaDiGMS 的实验表明，使用并行采样时性能没有下降，但他们假设有足够的计算资源。因此，我们通过假设这些加速可以在不降低标准顺序采样器性能的情况下实现，构建了一个乐观的强基线。如前所述，我们在所有实验和方法之间保持 UNet 架构和扩散策略基础设施（如图像编码器和归一化）。我们还在所有方法中使用扩散策略的输入和输出格式。具体来说，我们以两帧观测（包括腕部相机图像和第三人称视角相机图像，以及末端执行器姿态）作为输入，输出一系列末端执行器姿态。这样做使我们能够直接比较基线与我们方法的生成速度和成功率。

B. 仿真实验

任务：我们在三个基准 [9, 10, 17] 上的六个任务中评估一致性策略。Robomimic、Push-T 和 Kitchen 都是视觉运动策略和基于状态的策略学习的标准基准，并在原始的扩散策略 [6] 和 ParaDiGMS [27] 论文中进行了测试。

- 1) Robomimic: 从 robomimic [17] 基准套件中，我们在 Lift、Can、Square 和 Tool Hang 任务上评估我们的方法，这些任务涵盖了 Robomimic 中所有单机器人任务。对于每个任务，我们报告使用基于图像的观测和熟练人类演示数据集（每个任务包含 200 个演示）的策略的结果。
- 2) Push-T: 改编自 IBC [9]，Push-T 涉及使用圆形末端执行器将 T 形块推到固定目标。我们使用来自 [6] 的 200 个专家演示数据集，并报告使用基于状态的观测的策略的结果。




图 4：基于状态的仿真任务。本文还在两个基于状态的任务上评估了所提方法：Franka Kitchen [10]（左）和 Push-T [6, 9]（右）。Franka Kitchen 要求在多种可任意顺序完成的任务上具备长时程和多阶段性能，而 Push-T 则测试使用点力对 T 形块进行接触丰富操作的能力。

3) Franka Kitchen：该基于状态的任务由 [10] 提出，要求在厨房环境中以任意顺序完成四项任务。本文使用包含 566 条演示的人类演示数据集，并报告使用基于状态观测的策略的结果。该任务特别适用于测试长时程能力，因为它包含许多必须分别完成的子任务。

度量： 在 Robomimic 实验中报告的关键度量是特定策略网络在给定任务上获得的平均成功率，以及该度量的标准误。本文采用 ParaDiGMS [27] 的程序，使用最佳检查点在线设置中评估 200 次来计算平均值和标准误。Push-T 报告目标区域被覆盖的百分比，其余测量方式与前述任务相同。方法之间变化的另一个重要度量是生成时间，本文使用函数评估次数（NFE）来衡量。由于这些模型的推理成本主要由 NFE 决定，且网络架构保持不变，因此 NFE 提供了相对性能的良好估计，不受 GPU 不平衡的影响。对于 DDPM 和 DDiM，本文通过将所用 NFE 除以 ParaDiGMS [27] 报告的速度提升来考虑其加速效果。扩散策略 [6] 使用 100 步 DDPM 和 15 步 DDiM 评估其模型，因此本文分别报告 $\frac{100}{3.7} = 27$ 和 NFE，两种情况下均向下取整。

$$\frac{15}{1.6} = 9$$

结果： 表一展示了去噪扩散概率模型（DDPM）和去噪扩散隐式模型（DDiM）基线以及单步和多步一致性策略（Consistency Policy）的结果，后者是本文的贡献。对于 Push-T 任务上的 DDiM，我们采用了 ParaDiGMS 中报告的结果 [27]。所有其他度量均由我们计算。一致性策略（CP）在所有测试任务上展现出强大的单步和多步性能。单步 CP 在成功率方面通常介于 DDPM 和 DDiM 之间，尤其是在较难的任务如 Square 和 Tool Hang 上，但速度至少比两者快一个数量级。3 步 CP 优于单步 CP，在准确率上与 DDPM 相当，且速度分别是 DDiM 和 DDPM 的 3 倍和 9 倍。

策略 NFE Lift Can Square ToolHang Push-T							
DDPM	27	1.00	.97 ± .01	.93 ± .02	.79 ± .03	.87 ± .03	.87 ± .03
DDiM	9	1.00	.82 ± .03	.85 ± .03	.14 ± .02	.78 ± .03	.78 ± .03
CP (ours)	1	1.00	.98 ± .01	.92 ± .02	.70 ± .03	.82 ± .03	.82 ± .03
CP (ours)	3	1.00	.95 ± .02	.96 ± .01	.77 ± .03	.84 ± .03	.84 ± .03

表一：仿真基准结果——所呈现的结果为平均成功率（针对 Robomimic 任务）以及覆盖的目标区域（针对 Push-T），在 200 次 rollout 上取平均。每种方法都有一个相关的函数评估次数（NFE）度量，该度量主导其运行时间。注意，我们乐观地假设使用 ParaDiGMS[6] 加速基线 DDPM 和 DDiM 策略 [27] 不会导致成功率下降。我们通过将原始 NFE 100 除以 ParaDiGMS 中报告的速度提升倍数来报告 DDPM 和 DDiM 策略的 NFE。

在 Robomimic Can 任务上，单步 CP 实际上优于 3 步 CP，并相对于 DDPM 有轻微提升。这种差异可以通过简单任务上的随机性来解释：如果第一次 CP 生成已经获得 0.98 的成功率，后续的链式步骤可能没有太多改进输出的空间，反而可能使性能恶化。这解释了为什么 3 步 CP 在 Tool Hang 上大幅优于单步生成：由于任务更难，链式输出可以显著优于单步输出。

表二：Franka Kitchen 仿真结果——我们按照 Diffusion Policy[6] 中的方式在 Franka Kitchen 上测量结果，其中 p_x 表示与 x 个或更多物体交互的频率。Franka Kitchen 是一个基于状态的任务，测试多阶段和长时程性能。与表一相同，DDPM 和 DDiM 的 NFE 除以 ParaDiGMS 中报告的速度提升倍数 [27]。

Policy	NFE	p1	p2	p3	p4
DDPM	27	1.00	1.00	1.00	.98 ± .01
DDiM	9	1.00	.98 ± .01	.98 ± .01	.93 ± .02
CP (ours)	1	.99 ± .01	.96 ± .01	.95 ± .02	.93 ± .02
CP (ours)	3	.99 ± .01	.96 ± .01	.97 ± .01	.94 ± .02

Franka Kitchen 任务的结果 [10] 呈现在

表二：单步一致性策略在该任务的前两个阶段表现强劲，但在后续阶段则较为吃力。需要在长时程环境中进行更多探索，以理解一致性策略在这项更长任务中究竟难以学习什么。

表三展示了各策略在仿真中的墙钟时间，具体针对机械模仿方形任务。如预期所示，一致性策略的推理完成速度比扩散策略基线快数个数量级。

Policy	NFE	Inference Time (ms)
DDPM	100	110
DDiM	15	11
CP (ours)	1	1
CP (ours)	3	2

表三：仿真推理速度——仿真推理速度在英伟达 P5000 数据中心图形处理器上测量，并对 50 次运行取平均。基准测试使用原始扩散策略进行，因为本文将其作为基线。




图 5：垃圾清理。该任务包括：（1）拾取垃圾，（2）将垃圾放入垃圾桶，然后（3）盖上垃圾桶盖。

C. 真实世界实验

任务：本文在真实世界中评估一致性策略，涉及三项任务：垃圾清理、插头插入和微波炉操作。

1) 垃圾清理：机器人需捡起垃圾桶旁的垃圾，将其放入桶内，并盖上桶盖（见图 5）。2) 插头插入：机器人需拾取插头并将其插入插座。该任务通常接触丰富且要求精确（见图 6）。3) 微波炉：机器人（移动机械臂）需打开微波炉，导航至并取回一袋西兰花，将其放入微波炉，关闭炉门，并按下“蔬菜”按钮启动微波炉。该任务测试长时程性能以及对移动基座与标准机械臂的控制（见图 7）。对于前两项任务，我们使用一台配备单块 3070 Ti GPU（8GB 显存）的笔记本电脑进行推理。需注意，由于 ParaDiGMS 显存占用过高，我们无法在该配置上有效运行 ParaDiGMS。我们还注意到，在 3070 Ti GPU 上，扩散策略的 100 步 DDPM 变体每次前向传播的推理时间约为 1.5 秒。因此，我们选择更快且更贴近实际的扩散策略 DDIM 变体作为基线方法，该变体使用 15 步进行策略推理。除插头插入任务的观测尺寸外，我们保持与仿真实验设置相同的策略输入、输出和架构：对于该任务，我们使用 256x256 的图像尺寸。在给定时间步 t ，我们的策略接收：一个过肩视角图像、一个手眼相机图像、当前末端执行器位姿以及当前夹爪宽度。我们的策略输出长度为 16 的动作序列，其中每一步是一个 10 维向量，包含目标末端执行器位置（3 维）、目标末端执行器旋转（6 维）和目标夹爪位置（1 维）。对于移动操作微波炉任务，我们使用安装在完整约束移动基座上的 Kinova Gen3 七自由度机械臂。推理在同一台配备 3070 Ti GPU 的笔记本电脑上完成，并通过路由器连接传输至机器人。84x84 分辨率的图像观测来自腕部相机和基座安装相机。低维观测包括 3 维基座位姿、3 维机械臂位置、4 维



图 6：插头插入。该任务包括：（1）拾取电源适配器，（2）将其带到插头处并完全插入

机械臂旋转四元数，以及 1 维夹爪宽度。单个动作的维度为 13（基座位姿 3 维、机械臂位置 3 维、机械臂旋转 6 维、夹爪 1 维），并在时间上进行分块。

度量：对于每个训练好的策略，我们报告在一个策略检查点上的平均成功率（使用验证均方误差选择）。我们还报告在 3070 Ti 图形处理器上的推理时间。对于成功率，第一个和第三个任务我们平均进行 10 次试验，第二个任务平均进行 20 次试验。前两个任务的起始位置在试验之间随机化，第三个任务的起始位置固定。

结果：表 IV 显示，基线 DDIM 变体的扩散策略在垃圾清理和插头插入任务上取得了与我们方法相似的平均成功率。然而，我们的方法推理时间显著更低（~9 倍延迟）。我们的方法在微波任务中保持了推理速度优势，但表现略逊于 DDIM。关于移动任务的更多讨论见局限性部分（参见第五节）。

由于一致性策略所需的前向传递次数比 DDIM 少 15 倍，人们可能期望完整的推理加速也接近 15 倍而不是约 9 倍。这种差异是由于观测编码器开销成本造成的。我们在附录中进一步讨论推理速度。

D. 消融实验

我们进行了多项消融实验以验证和探索我们的设计选择。除非另有说明，我们使用与仿真实验相同的评估方法计算成功率（参见第 IV-B 节）。我们选择 Robomimic Square 和 Toolhang 进行这些实验，因为它们是



图 7: 微波任务。该任务包括: (1) 导航至微波炉并打开, (2) 导航至一袋西兰花并拾起, (3) 将袋子放入微波炉内, (4) 关闭微波炉门, (5) 启动微波炉。

	Trash Clean Up		Plug Insertion		Microwave
	Success Rate	Inference Time (ms)	Success Rate	Inference Time (ms)	Success Rate
DDiM	$0.8 \pm .13$	192	0.6 ± 0.11	198	0.5 ± 0.16
CP (ours)	$0.8 \pm .13$	21	0.7 ± 0.10	22	0.4 ± 0.15

表 IV: 多任务真实世界实验结果——展示了一致性策略和扩散策略的 DDiM 变体的结果。每个任务均给出成功率和标准误。前两个任务还给出了推理速度。

两个最难的基于图像的任务。

一致性目标: 回顾一致性轨迹模型 (CTM) 框架, 其部分通过优化式 5 中的一致性目标来学习函数 $g_\theta(\mathbf{x}_t, t, s)$ 。存在三种自然的一致性目标可供优化, 它们在起始点 t, u 的选择以及停止点 s 的选择上有所不同——均在图 2 中可视化展示。Song 等人 [31] 提出了一致性蒸馏目标, 该目标强制相邻点 t 与 u 之间在 $s = 0$ 条件下保持一致。Kim 等人 [14] 提出了非相邻 CTM 目标, 该目标强制任意点 t 与 u 在去噪至任意 $s < u < t$ 后保持一致。最后, 可以像一致性蒸馏 [31] (也称为 CTM[14] 中的“局部一致性”) 那样使用相邻 t 和 u , 以及任意 s 。在我们的实验中, 我们发现第三种目标效果最佳。在比较所有三种目标的消融实验 (见表 V) 中, 我们改变一致性目标, 但保持式 8 中的辅助去噪得分匹配 (DSM) 目标不变。

表 V: 方形任务上的一致性目标消融实验

Method	Success Rate
Consistency Distillation	$.88 \pm .02$
CTM	$.91 \pm .02$
CTM-local (ours)	$.92 \pm .02$

CTM 和 CTM-local 具有相似的成功率, 但两者均以微弱优势优于一致性蒸馏。然而, CTM 的训练计算开销远高于

CTM-local 和一致性蒸馏, 因为需要多次教师去噪步骤才能从 $t \rightarrow u$ 移动。即使有约束 $t - u \leq 10$, 我们发现 CTM 的训练速度比一致性蒸馏和 CTM-local 慢 40% 以上, 而后两者的训练速度相同。这些结果是在 NVIDIA RTX A5000 上测得的。

初始样本方差: 扩散需要从高斯分布中采样初始位置, 然后将其去噪为有效的动作预测。归一化的初始位置传统上从单位高斯分布中采样, $\mathcal{N}(0, 1)$ 。我们选择从低方差高斯分布中采样, $\mathcal{N}(0, \frac{1}{T^2})$, 以促使输出更符合数据分布。在表六中, 我们比较了在 Robomimic Square 任务上, 使用单步和三步一致性策略方法时, 从高方差 (原始) 与低方差 (本文) 初始位置采样的结果。

表六: Square 任务上的初始采样方差消融

Initial Variance	1-step	3-step
1	$.9 \pm .02$	$.91 \pm .02$
$\frac{1}{T^2}$	$.92 \pm .02$	$.96 \pm .01$

尽管低方差初始采样在两种方法下均表现更优, 但在多步情况下其影响似乎更大。这可能是因为步骤之间发生的加噪过程。较高初始方差的优势在于对复杂数据分布的表达能力和多模态性: 虽然第一步从某个 $\mathbf{x}_t \sim \mathcal{N}(0, 1)$ 开始, 因此会结束于某个更中心的终点, 但后续的加噪和去噪步骤可能会保 $\frac{1}{T^2}$ 留高方差位置的表达性。

预设链式步骤: 为了验证我们通过细分离散时间而非连续时间将链式聚焦于早中期时间步的决策, 我们在 Square 和 Tool Hang 上测试了这两种链式过程。两项实验均报告于表七, 并使用 3 个链式步骤以及对底层时间空间的均匀细分 (离散网格与连续时间区间)。

表七: Square 和 Tool Hang 上的链式步骤消融

NFE	Square	Tool Hang	离散	.96 $\pm$.01
.77 $\pm$.03	连续	.94 $\pm$.02	.72 $\pm$.03	

离散细分在 Tool Hang 上大幅优于连续细分, 而在 Square 上两种方法结果相近 (离散细分略好但不显著)。与其他消融实验一样, 我们认为这种选择的优势在更难的任务 (如 Tool Hang) 上最为明显, 因为那里有更大的改进空间。我们建议任何希望在困难任务上提升性能的用户, 首先尝试细分离散时间, 仅在仍有需要时才进一步调整超参数。

教师模型质量：由于一致性策略需要将预训练的教师模型蒸馏到学生网络中，因此了解教师模型的性能对学生模型最终达到的性能有多重要是相关的。我们使用三种不同质量的教师模型对正方形任务进行了蒸馏测试，并在表 VIII 中报告了结果。

表 VIII：正方形任务上对教师模型质量的鲁棒性

Teacher Success Rate	Student Success Rate
.92 $\pm$.02	.92 $\pm$.02
.88 $\pm$.03	.92 $\pm$.02
.84 $\pm$.03	.88 $\pm$.03

虽然观察到教师质量与学生成功率之间存在轻微相关性，一致性策略（Consistency Policy）在此教师质量范围内对教师成功率保持鲁棒性。虽然一致性目标 $\mathcal{L}_{CTM}$ (Eq. 5) 直接依赖于教师，但去噪得分匹配（DSM）目标 $\mathcal{L}_{DSM}$ (Eq. 3) 独立于教师，并且即使在教师变差时也可能维持学生性能。这对于在可能无法对教师模型进行广泛测试的现实世界任务中部署是个好兆头。随机失活在 CTM 目标中的作用：诸如随机失活 [32] 之类的正则化技术通常用于防止高表达模型在训练数据集上过拟合。然而，在我们的实验中，我们发现随机失活在 CTM 目标中扮演的角色远比预期重要。回想一下，在计算 $t \rightarrow s$ 和 $u \rightarrow s$ 之后，得到的预测在计算损失之前被带回时间 0（见公式 5 和图 2）。我们的假设是，当 g_θ 达到一定性能水平时，例如使用预训练教师模型的参数进行热启动时，损失 $\mathcal{L}_{CTM} = d(g_\theta(\mathbf{x}_s^{(t)}, s, 0; o), g_\theta(\mathbf{x}_s^{(u)}, s, 0; o))$ 消失，不提供训练信号。EDM 用于训练的 DSM 损失（公式 3）可以解释为教导扩散模型将使用任意噪声样本 ϵ 和某个时间步 s （我们有意选择此符号）加噪的原始样本 $\mathbf{x}$ 一步带回原始样本。直观上，向强大的图像空间扩散模型输入同一图像的两个加噪版本，即使这两个加噪版本不在同一轨迹上（意味着它们不是用相同的采样 ϵ 形成的），在两种情况下都应返回相似的图像。按照这种推理，如果 $\mathbf{x}_s^{(t)}$ 和 $\mathbf{x}_s^{(u)}$ 是使用任意 ϵ 将 $\mathbf{x}$ 加噪到时间 s 的良好近似，那么即使 $d(\mathbf{x}_s^{(t)}, \mathbf{x}_s^{(u)})$ 很大，我们也应期望输出 $g_\theta(\mathbf{x}_s^{(t)}, s, 0; o)$ 和 $g_\theta(\mathbf{x}_s^{(u)}, s, 0; o)$ 非常相似。事实上，经验上我们发现，在禁用随机失活的情况下， $d(\mathbf{x}_s^{(t)}, \mathbf{x}_s^{(u)})$ 至少比 $d(g_\theta(\mathbf{x}_s^{(t)}, s, 0; o), g_\theta(\mathbf{x}_s^{(u)}, s, 0; o))$ 大两个数量级。当启用随机失活时， $s \rightarrow 0$ 步骤不再以这种方式具有确定性。因为一致性网络不能再依赖这些后续步骤将点从

不同的轨迹彼此靠近时，会有更多信号直接作用于 $d(\mathbf{x}_s^{(t)}, \mathbf{x}_s^{(u)})$ 上的自洽性，而不是使 $\mathbf{x}_s^{(t)}$ 和 $\mathbf{x}_s^{(u)}$ 成为任意 $\mathbf{x}_s$ 的良好预测器。作为探索这一假设的初步步骤，我们在训练时仅从 $s \rightarrow 0$ 的两个生成中移除了随机失活，而在网络其余部分保留它。

表九：在方形任务上移除 $s \rightarrow 0$ 随机失活的效果

Dropout	Success Rate
Enabled	.92 $\pm$.02
Disabled	.86 $\pm$.03

如表九所示，仅在训练的这一部分移除随机失活导致成功率下降，如果随机失活确实负责一致性目标的大部分信号，这是可以预期的。对于这一点以及我们的其他结果，随机失活率设为 0.2。

一致性训练：[8] 是强化学习中的一项并行工作，它使用一致性训练 [29, 31] 学习了一个基于状态的策略，该方法将用于从 $\mathbf{x}_t$ 计算 $\mathbf{x}_u$ （对于 $u = t - 1$ ）的训练好的教师模型替换为得分函数的蒙特卡洛估计。我们实现了该系统（在表十中称为 CT 策略），并在 Robomimic 的 Lift 和 Square 任务上使用单步生成进行了测试。我们方法在 Lift 和 Square 上的结果也一并展示以供比较。

表十：Lift 和 Square 任务上的一致性训练消融

NFE	Lift	Square
CT Policy	.91 $\pm$.02	.55 $\pm$.04
CP (ours)	1.0	.92 $\pm$.02

五、局限性

虽然一致性策略在保持性能的同时，在原始速度上比扩散策略有显著提升，但蒸馏过程确实存在一些缺点。扩散策略的一些 [6] 优势包括其表示动作分布多模态性的能力以及稳定的训练。一致性策略在这两个属性上做出了权衡。扩散策略的多模态性可能来自 DDPM 对随机微分方程的积分，而 EDM 和 CTM 学习积分的是常微分方程——一致性目标要求对确定性轨迹进行蒸馏。事实上，我们发现教师 EDM 策略和一致性策略都丢失了扩散策略的一些多模态性，例如，在 Push-T 任务中偏向一侧而不是另一侧。然而，一致性策略在 Push-T 任务上仍然表现良好，这表明多模态性的缺乏并未损害我们在相关工作使用的标准评估任务上的表现。在未来的工作中，我们将探索如何通过更复杂的采样方案潜在地将多模态性重新引入一致性策略。

我们还注意到，一致性策略在训练过程中的稳定性略低于扩散策略，这可能是由于一致性目标的自指性质所致（见公式 5）。在我们的移动操作结果中，一致性策略在准确率上略逊于扩散策略，这展示了我们方法在不同方面的优势与不足。首先请注意，由于外部时间限制，我们未能在微波炉任务上训练一致性策略直至其不再提升。此外，一致性策略在经验上需要更多的训练时间才能达到与扩散策略相同的性能水平，尤其是考虑到训练教师策略所需的时间。这通常意味着需要更多的训练轮次以及每轮次更长的时间，因为一致性策略的训练步骤除了学生网络的多次前向传播外，还需要运行教师模型。训练时间的增加会因任务难度而加剧（微波炉任务的蒸馏时间远长于其他两个任务），并且这是直观的，因为一致性策略拟合的是一个更难的问题（在同一任务上拟合单步策略而非多步策略）。重要的是要考虑这些权衡如何与您的特定用例相互作用，而不是在真空中比较这些工具。

六、结论

我们提出了使用基于一致性的训练目标来训练高性能、低延迟的视觉运动机器人策略。在仿真和现实世界共 9 个任务的评估套件中，我们证明一致性策略在不牺牲成功率的前提下，相比之前的扩散策略方法大幅提升了推理速度。通过消融实验，我们还强调了导致视觉运动策略达到最高成功率的关键设计决策。这些包括：一致性目标的选择、降低初始样本方差、使用随机失活以及预设链式步骤的选择。在未来的工作中，我们希望探索某些实验结果背后的更深层解释，例如链式动力学和随机失活在 $s \rightarrow 0$ 生成过程中的作用，并将一致性策略移植到能够更好利用快速推理速度的机器人上，包括腿式、翼式和其他移动平台。

致谢： 丰田研究所提供了资金支持这项工作。

参考文献

- [1] Omer Bar-Tal, Hila Chefer, Omer Tov, Charles Herrmann, Roni Paiss, Shiran Zada, Ariel Ephrat, Junhwa Hur, Yuanzhen Li, Tomer Michaeli, et al. Lumiere: A space-time diffusion model for video generation. *arXiv preprint arXiv:2401.12945*, 2024.
- [2] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Joseph Dabis, Chelsea Finn, Keerthana Gopalakrishnan, Karol Hausman, Alex Herzog, Jasmine Hsu, et al. Rt-1: Robotics transformer for real-world control at scale. *arXiv preprint arXiv:2212.06817*, 2022.

- [3] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Xi Chen, Krzysztof Choromanski, Tianli Ding, Danny Driess, Avinava Dubey, Chelsea Finn, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control. *arXiv preprint arXiv:2307.15818*, 2023.
- [4] Yuhui Chen, Haoran Li, and Dongbin Zhao. Boosting continuous control with consistency policy. *arXiv preprint arXiv:2310.06343*, 2023.
- [5] Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin Burchfiel, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. *arXiv preprint arXiv:2303.04137*, 2023.
- [6] Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin CM Burchfiel, and Shuran Song. Diffusion Policy: Visuomotor Policy Learning via Action Diffusion. In *Proceedings of Robotics: Science and Systems*, Daegu, Republic of Korea, July 2023. doi: 10.15607/RSS.2023.XIX.026.
- [7] Jooyoung Choi, Jungbeom Lee, Chaehun Shin, Sungwon Kim, Hyunwoo Kim, and Sungroh Yoon. Perception prioritized training of diffusion models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 11472–11481, 2022.
- [8] Zihan Ding and Chi Jin. Consistency models as a rich and efficient policy class for reinforcement learning. In *The Twelfth International Conference on Learning Representations*, 2024. URL <https://openreview.net/forum?id=v8jdwkUNXb>.
- [9] Pete Florence, Corey Lynch, Andy Zeng, Oscar A Ramirez, Ayzaan Wahid, Laura Downs, Adrian Wong, Johnny Lee, Igor Mordatch, and Jonathan Tompson. Implicit behavioral cloning. In *5th Annual Conference on Robot Learning*, 2021.
- [10] Abhishek Gupta, Vikash Kumar, Corey Lynch, Sergey Levine, and Karol Hausman. Relay policy learning: Solving long-horizon tasks via imitation and reinforcement learning. In *Conference on Robot Learning*, pages 1025–1037. PMLR, 2020.
- [11] Tiankai Hang, Shuyang Gu, Chen Li, Jianmin Bao, Dong Chen, Han Hu, Xin Geng, and Baining Guo. Efficient diffusion training via min-snr weighting strategy. *arXiv preprint arXiv:2303.09556*, 2023.
- [12] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. *Advances in neural information processing systems*, 33:6840–6851, 2020.
- [13] Tero Karras, Miika Aittala, Timo Aila, and Samuli Laine. Elucidating the design space of diffusion-based generative models. In *Proc. NeurIPS*, 2022.
- [14] Dongjun Kim, Chieh-Hsin Lai, Wei-Hsiang Liao, Naoki Murata, Yuhta Takida, Toshimitsu Uesaka, Yutong He, Yuki Mitsufuji, and Stefano Ermon. Consistency trajectory models: Learning probability flow ode trajectory of diffusion, 2023.
- [15] Xinghang Li, Minghuan Liu, Hanbo Zhang, Cunjun Yu, Jie Xu, Hongtao Wu, Chilam Cheang, Ya Jing, Weinan

- Zhang, Huaping Liu, et al. Vision-language foundation models as effective robot imitators. In *The Twelfth International Conference on Learning Representations*, 2023.
- [16] Xingchao Liu, Xiwen Zhang, Jianzhu Ma, Jian Peng, and Qiang Liu. Instaflo: One step is enough for high-quality diffusion-based text-to-image generation. *arXiv preprint arXiv:2309.06380*, 2023.
- [17] Ajay Mandlekar, Danfei Xu, Josiah Wong, Soroush Nasiriany, Chen Wang, Rohun Kulkarni, Li Fei-Fei, Silvio Savarese, Yuke Zhu, and Roberto Martín-Martín. What matters in learning from offline human demonstrations for robot manipulation. In *5th Annual Conference on Robot Learning*, 2021.
- [18] Chenlin Meng, Robin Rombach, Ruiqi Gao, Diederik Kingma, Stefano Ermon, Jonathan Ho, and Tim Salimans. On distillation of guided diffusion models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 14297–14306, 2023.
- [19] Octo Model Team, Dibya Ghosh, Homer Walke, Karl Pertsch, Kevin Black, Oier Mees, Sudeep Dasari, Joey Hejna, Charles Xu, Jianlan Luo, Tobias Kreiman, You Liang Tan, Dorsa Sadigh, Chelsea Finn, and Sergey Levine. Octo: An open-source generalist robot policy. <https://octo-models.github.io>, 2023.
- [20] Tim Pearce, Tabish Rashid, Anssi Kanervisto, David Bignell, Mingfei Sun, Raluca Georgescu, Sergio Valcarcel Macua, Shan Zheng Tan, Ida Momennejad, Katja Hofmann, et al. Imitating human behaviour with diffusion models. In *Deep Reinforcement Learning Workshop NeurIPS 2022*, 2022.
- [21] Ben Poole, Ajay Jain, Jonathan T. Barron, and Ben Mildenhall. Dreamfusion: Text-to-3d using 2d diffusion. In *The Eleventh International Conference on Learning Representations*, 2023. URL <https://openreview.net/forum?id=FjNys5c7VyY>.
- [22] Moritz Reuss, Maximilian Li, Xiaogang Jia, and Rudolf Lioutikov. Goal conditioned imitation learning using score-based diffusion policies. In *Robotics: Science and Systems*, 2023.
- [23] Ludan Ruan, Yiyang Ma, Huan Yang, Huiguo He, Bei Liu, Jianlong Fu, Nicholas Jing Yuan, Qin Jin, and Baining Guo. Mm-diffusion: Learning multi-modal diffusion models for joint audio and video generation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 10219–10228, 2023.
- [24] Tim Salimans and Jonathan Ho. Progressive distillation for fast sampling of diffusion models. In *International Conference on Learning Representations*, 2022. URL <https://openreview.net/forum?id=TIIdIXIpzhoI>.
- [25] Nur Muhammad Mahi Shafiullah, Zichen Jeff Cui, Ariuntuya Altanzaya, and Lerrel Pinto. Behavior transformers: Cloning k modes with one stone. In *Thirty-Sixth Conference on Neural Information Processing Systems*, 2022. URL <https://openreview.net/forum?id=agTr-vRQsa>.
- [26] Shelly Sheynin, Adam Polyak, Uriel Singer, Yuval Kirstain, Amit Zohar, Oron Ashual, Devi Parikh, and Yaniv Taigman. Emu edit: Precise image editing via recognition and generation tasks. *arXiv preprint arXiv:2311.10089*, 2023.
- [27] Andy Shih, Suneel Belkhale, Stefano Ermon, Dorsa Sadigh, and Nima Anari. Parallel sampling of diffusion models, 2023.
- [28] Jiaming Song, Chenlin Meng, and Stefano Ermon. Denoising diffusion implicit models. In *International Conference on Learning Representations*, 2021. URL <https://openreview.net/forum?id=St1giarCHLP>.
- [29] Yang Song and Prafulla Dhariwal. Improved techniques for training consistency models. *arXiv preprint arXiv:2310.14189*, 2023.
- [30] Yang Song, Jascha Sohl-dickstein, Diederik P. Kingma, Abhishek Kumar, Stefano Ermon, and Ben Poole. Score-based generative modeling through stochastic differential equations. 2021. URL <https://openreview.net/forum?id=PxTIG12RRHS>.
- [31] Yang Song, Prafulla Dhariwal, Mark Chen, and Ilya Sutskever. Consistency models. *arXiv preprint arXiv:2303.01469*, 2023.
- [32] Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov. Dropout: a simple way to prevent neural networks from overfitting. *The journal of machine learning research*, 15(1):1929–1958, 2014.
- [33] Hsiang-Chun Wang, Shang-Fu Chen, Ming-Hao Hsu, Chun-Mao Lai, and Shao-Hua Sun. Diffusion model-augmented behavioral cloning, 2023.
- [34] Tianwei Yin, Michaël Gharbi, Richard Zhang, Eli Shechtman, Fredo Durand, William T Freeman, and Tae-sung Park. One-step diffusion with distribution matching distillation. *arXiv preprint arXiv:2311.18828*, 2023.
- [35] Yanjie Ze, Gu Zhang, Kangning Zhang, Chenyuan Hu, Muhan Wang, and Huazhe Xu. 3d diffusion policy. *arXiv preprint arXiv:2403.03954*, 2024.
- [36] Fanlong Zenga, Wensheng Gana, Yongheng Wanga, Ning Liua, and Philip S Yub. Large language models for robotics: A survey.

OVERVIEW

The appendix offers additional details with respect to the inference speed benefits of Consistency Policy (Appx. A), the low variance initial sampler (Appx. B), and the real world experiment (Appx. C).

附录 A 推理速度

Policy	Image Encoder Time (ms)	Network Time (ms)	Total Inference Time (ms)
DDiM	6	179	192
CP (ours)	6	13.5	21

表十一：所有时间测量均以毫秒为单位。 图像编码器时间是指在图像观测被传递到策略网络之前对其进行编码所花费的时间。网络时间是指策略网络前向传播所花费的时间。推理时间是指从图像观测输入到动作部署之间的总时间。这包括前两项测量以及任何额外的时间成本，例如数据搬运的时间。

在我们的真实世界实验中（第 IV-C 节），我们指出 15 步 DDiM 的推理时间为 192 毫秒，而一致性策略的推理时间为 21 毫秒（见表十一）。我们使用推理时间来指代从策略网络（无论是扩散策略还是一致性策略）接收图像观测到预测动作部署到机器人控制器的整个过程。虽然这段时间的大部分用于策略网络的前向传播，但其中一部分也用于编码图像观测和搬运内存。因此，我们还测量了仅用于策略网络前向传播的时间和用于编码图像观测的时间。这些值报告在表十一中，并且全部在一台 NVIDIA 3070 Ti 上测量，这是一款性能较弱的笔记本电脑 GPU。

虽然 DDiM 与一致性策略之间的推理时间相对加速为 9 倍，但网络时间的相对加速为 13.3 倍，更接近我们方法与 DDiM 之间 15 倍的步数减少。

我们报告了第 IV-C 节中的整体推理速度提升，以便与其他加速方法进行简单比较。然而，实践者实际实现的推理加速将取决于他们与策略网络一起运行的其他系统，例如他们自己的观测编码器或并行进程。随着策略网络在推理时相对于其他进程消耗的计算比例越来越大，我们的方法将变得更加有影响力。

附录 B 低方差初始样本

我们的一项消融实验（见第 IV-D 节）发现，与 EDM 和一致性模型标准的较高方差初始采样器相比，较低方差初始采样器提高了生成质量。

在无条件图像生成上测试 EDM 表明，这种低方差样本可能对机器人领域具有某些特定益处。图 8 和图 9 是同一 EDM 模型（在 CIFAR-10 上训练，一个 32x32 像素的图像数据集）分别使用低初始方差采样和高初始方差采样生成的图像。

这些只是启发式结果，因为 EDM 并未训练至收敛，但很明显，与高方差初始位置相比，低方差区域没有学习到的支持，这导致低方差生成在图 8 中产生灰色块。

这些领域之间低方差区域支持的差异可能源于各自扩散模型试图拟合的数据分布维度的不同。流形假设指出，现实世界数据集，如机器人动作或图像，包含在 R^n 的低维流形中。直观上（尽管不确定），对于给定任务和机器人，机器人动作所在的流形维度远低于所有 CIFAR-10 图像的空间，后者包含 10 个类别的 60000 张图像，并存在于 32x32x3 像素空间中。作为比较，我们的机器人动作数据维度为 $h \times 10$ ，其中 h 是动作水平长度，每个动作由一个 9 维姿态向量和一个 1 维夹爪动作表示。可能的情况是，分数模型仅在足够低维的数据流形上学习支持低方差初始位置，例如机器人动作的流形，而当分数模型在更高维空间上训练时，该区域则没有支持。




图 8：低初始方差生成。扩散模型显然未学习在该区域预测分数。



图 9：高初始方差生成。同一扩散模型已学习支持该较高方差区域。

模型在更高维空间上训练时。这种行为可能源于高维高斯分布将更多质量集中在边缘而非中心。如果扩散/一致性策略正在学习从 N 维高斯分布出发或到达该分布的映射，随着 N 增大，它对该高斯分布中心的支持可能越来越少。

附录 C 真实世界实验设置

我们使用 Franka Panda 机器人进行固定臂真实世界实验（垃圾拾取和插头插入）。我们在腕部安装一个 Zed Mini 相机，并在肩上安装一个 Zed Mini 相机，以在每个时间步获取两幅图像。我们使用 Meta Quest 2 虚拟现实装置为任务收集 180 个演示。Franka 机器人以 1kHz 的频率接受控制命令，并以 15 Hz 的频率从虚拟现实控制器或训练策略接收新命令。注意，一致性策略（Consistency Policy）在约 21ms 内生成末端执行器动作序列输出，我们以 15Hz 的频率向机器人提供每个路径点。当策略执行推理时，我们向机器人发送控制命令以维持其当前末端执行器位姿。