

使用元学习方法在线适应学习的车辆动力学模型

由希 土屋¹、托马斯·巴尔奇²、保罗·德鲁斯³和盖伊·罗斯 男人²

Abstract— 我们通过多层神经网络构建了接近操控极限的自动驾驶车辆动力学模型。为了应对看不见的环境，在线适应是可取的。然而，模型需要适应新的环境，同时又不能忘记以前遇到的环境。在本研究中，我们应用Continual-MAML来克服这个困难。它使模型能够通过从优化的初始参数开始更新来快速有效地适应以前遇到的环境。我们使用 TRIKart 平台评估在线模型自适应对推理性能的影响以及对模型预测路积分 (MPPI) 控制器控制性能的影响。使用在我们的测试环境中收集的驾驶数据对神经网络进行预训练，并在训练数据中未包含的多种不同路况上执行在线适应实验。实证结果表明，使用Continual-MAML的模型在测试集损失和MPPI在线跟踪性能方面优于固定模型和使用梯度下降的模型。

一、简介

自动驾驶汽车一直受到关注，因为它们的安全、缓解交通拥堵和减轻乘客晕车方面有可能超越人类。最近，一些公司已经开始在现实世界中部署自动驾驶汽车[1]、[2]。然而，它们的部署仅限于特定地区和条件。因此，需要扩大自动驾驶汽车的运行范围，以便它们能够在任何驾驶情况和条件下安全行驶。

为了提高紧急情况下的安全性和信心，例如出现意外障碍物，需要接近处理极限的高性能控制。自动赛车是自动驾驶车辆极限处理的一个很好的代理问题[3]-[8]。一些前沿研究甚至解决了漂移状态下的稳定控制问题，以最大限度地发挥车辆潜力[9]、[10]。

对于自动驾驶车辆的本地规划和控制，基于模型的方法是最常见的。为了实现高性能，需要具有快速推理时间的准确模型。许多基于模型的方法通过基于物理的模型来表示车辆动力学，因为它可以提供合理的车辆行为并且易于分析[3]、[7]、[9]。尽管基于物理的方法是一种强大且

经过验证的方法，它变得复杂或无法对接近处理极限的高度非线性行为进行建模。另一方面，诸如神经网络模型之类的学习模型有可能捕获非线性特征，而不会显著增加计算成本[10]-[12]。出于这些原因，我们采用神经网络作为学习动力学模型，以超越基于物理的模型的性能。

学习模型的性能很大程度上取决于训练数据集。换句话说，将固定模型应用于不包含在训练集中的环境可能会导致性能不佳。对于自动驾驶汽车来说，有很多因素会随着时间的推移而变化，例如乘客和负载重量、轮胎状况和道路状况。个人用户可以更换轮胎以应对冬季路况或用新轮胎更换旧轮胎。在[5]、[6]中，通过将历史数据集集成到模型输入中，针对两种不同的道路条件（高摩擦道路和低摩擦道路）开发了学习模型。然而，他们的训练集同时包含高摩擦和低摩擦道路数据，很难保证所有可能场景的性能。现实世界中存在不可测量的环境，提前从所有环境中推断出模型是不切实际的。因此，在线模型适应是适应训练集中未包含的可能环境的强大替代方案。

在实时行驶时，车辆会遇到如上所述的未见过的环境，以及过去遇到的环境。因此，在线适应算法不仅需要适应新的环境，还需要利用过去的信息快速重新适应以前遇到的环境。到目前为止，在利用学习模型对车辆动力学进行高效顺序学习方面，很少有方法能够脱颖而出，该领域的研究对于开发对现实世界不断变化具有鲁棒性的车辆控制非常重要。在本文中，我们解决了基于模型控制的学习车辆动力学模型中的在线自适应问题。我们将 Continual-MAML [13] 应用到我们学习的车辆动力学模型中，以便在条件恢复到之前的状态时实现高控制性能，同时保持适应不可预见条件的能力。Continual-MAML 是著名的元学习方法 MAML 的扩展，旨在解决新任务和先前任务出现的场景。它有助于在这种情况下进行有效的学习。当车辆遇到先前观察到的路况时，模型可以通过基于先前观察的最佳初始值开始参数更新来有效地适应。因此，基于模型的控制表现出更高的性能。

¹Yuki Tsuchiya was with Toyota Research Institute, Cambridge, MA, USA. He is now with Toyota Motor Corporation, Toyota City, Aichi, Japan yuki.tsuchiya_aa@mail.toyota.co.jp

²Thomas Balch and Guy Rosman are with Toyota Research Institute, Cambridge, MA, USA thomas.balch@tri.global, guy.rosman@tri.global

³Paul Drews was with Toyota Research Institute, Cambridge, MA, USA paul.drews@gmail.com

为了评估模型改进对基于模型的控制器的影响, 我们实现了模型预测路径积分 (MPPI) 控制器[14]-[18]。该控制器源自模型预测控制 (MPC), 并利用基于采样的方法进行优化。MPPI 是一种强大的控制算法, 因为它自然地考虑了系统的非线性。

我们使用十分之一比例的汽车进行实验[19]。比例汽车可以捕获难以在模拟中建模的几个现实元素, 并且与使用全尺寸汽车相比, 确保实验的安全性要简单得多。我们比较了三种模型的推理和控制性能, 即固定模型、梯度下降在线自适应模型和连续 MAML 在线自适应模型, 在两种不同路面依次出现的场景中。这些路面上的驾驶数据不包含在训练数据中, 以便查看模型的自适应性能, 并且每个模型都使用相同的神经网络结构。我们表明, 在推理和控制性能方面, Continual-MAML 的在线自适应优于固定模型和梯度下降自适应模型。我们关注路况的差异。然而, 我们的方法可以扩展到其他不可预见的场景, 例如可变负载。

总而言之, 我们的贡献包括: (1) 将Continual-MAML 算法应用于学习的车辆动力学模型并提供其应用的描述。(2) 与替代方法进行对比, 表明连续 MAML 在真实平台上基于模型的控制的推理和控制性能方面均优于固定模型和梯度下降自适应模型。

二.相关工作

我们的工作涉及用于规划和控制的车辆动力学建模、其在在线适应中的使用以及元学习方法。

A. Vehicle Dynamics Modeling

对于自动驾驶汽车领域基于模型的控制, 基于物理的方法是流行的选择, 因为它们易于分析, 并且简单的基于物理的模型通常对于普通驾驶情况来说是可行且足够准确的。文献[20]表明, 当横向加速度不大时, 自行车运动学模型与考虑滑移的动态模型一样准确。[21]提供了横向加速度的阈值, 使得用于运动规划的运动学自行车模型是可靠的。即使在避障或接近操控极限 (如漂移) 等紧急情况下, 也可以使用非线性模型预测控制 (NMPC) 结合自行车模型和刷胎模型来实现自动驾驶[9], [22]。

车辆动力学建模的另一种方法是基于学习的方法。最近, 车辆动力学学习模型引起了人们的关注, 因为它们有可能捕捉车辆的非线性方面

动力学, 而不会显著增加计算成本。在[5]、[6]中, 学习模型被用作车辆动力学模型, 用于高摩擦和低摩擦道路上的路径跟踪控制, 并且它们优于由自行车模型和刷胎模型组成的基于物理的模型的控制性能。学习模型的参数是从路面学习的, 并且基于物理的模型的参数针对每个路面进行调整。[11]使用简单的神经网络模型来估计滑移角并实现高性能, 而无需高计算成本和额外的传感器。[12]使用循环神经网络对转向系统动力学进行建模, 并将其与基于物理的车辆模型相结合以实现自动驾驶。[10]提出了一种学习轮胎模型, 该模型满足与自主漂移控制器一起使用的物理假设。他们的学习模型比 Fiala 刷子和 Magic Formula 轮胎模型具有更高的预测精度。

B. Online Adaptation

基于模型的控制器需要高保真模型。然而, 在现实世界中, 车辆可能会遇到模型设计时未考虑到的新环境。在线适配解决了这个缺点。

对于基于物理的模型的在线适应, 一些研究重点关注道路和轮胎之间的摩擦力的在线识别, 因为它是影响车辆行为的关键参数, 并且根据轮胎状态和道路条件而变化。[3] 使用无迹卡尔曼滤波器估计自动驾驶的摩擦参数。[7] 表明, 处于摩擦极限的自动驾驶车辆可以使用在线摩擦估计器跟踪圆形路径。另外, [4] 不仅仅关注摩擦参数。他们的方法利用高斯过程回归来估计状态方程中基于物理的模型的误差, 以增强 MPC 的自动驾驶性能。[23] 采用类似的方法, 用基于运动学的模型来表达标称模型, 并通过使用学习的轮胎模型来补偿它与动力学模型之间的差异。

对于学习模型的在线适应, 主要焦点是适应训练集中未包含的新环境。对于学习模型, 需要顺序学习才能做到这一点。[24]开发了一种使用动量梯度下降的在线参数更新算法。在学习的模型优于基于物理的模型之前, 该方法使用基于物理的模型, 然后, 当学习的模型实现更高的性能时, 模型切换到学习的模型。神经网络模型在线适应的一个主要问题是灾难性遗忘, 这是模型在适应新数据时忘记旧数据的现象。为了避免这种情况, [25]将局部加权投影回归纳入更新方案中。[26]结合了潜在向量的概念。它根据历史状态和动作、声谱图读数和 RGB 图像推断当地路面状况。使用潜在向量学习的动力学模型

与在不同表面条件下不使用潜在向量的模型相比，可提供更短的单圈时间和更安全的驾驶。

C. Meta-Learning

要使模型快速适应新环境，更新算法的效率是关键因素。元学习也称为学习学习，因为它改进了学习算法本身。它的目的是使代理能够快速适应新任务。模型无关元学习（MAML）是一种元学习方法，可以通过学习初始模型参数快速解决新任务[27]。通过从学习的初始值开始参数更新周期，模型可以快速适应它遇到的每个任务。MAML 假定任务作为批处理一起可用，并且无法摄取顺序任务。因此，人们越来越有兴趣将 MAML 应用于按顺序测量数据的在线方案。Follow The Meta Leader (FTML) [28] 将 MAML 应用于在线框架。即使顺序测量未见过的任务的数据集，FTML 也可以更新初始参数。然而 FTML 需要存储所有观察到的数据，这个特性对于实际问题来说并不理想。其他研究将元学习框架应用于数据增量到达而不将其分割成离散任务的情况[29]。然而，[29]在与预训练相似的数据上测试了其连续学习性能，并且不能保证新任务的性能。[13]重点关注称为在线快速适应和知识积累（OSAKA）的持续学习场景，其中出现新的和以前的任务。为了应对这种场景，即新任务的出现，同时在以前的任务再次出现时快速适应它们，Continual-MAML被开发为原始MAML算法的扩展，但具有在线运行的能力。

三. 我们的方法

A. Vehicle Dynamics Modeling

为了在不显著增加计算成本的情况下捕获接近操控极限的车辆动力学非线性特征，我们利用多层神经网络对车辆动力学进行建模。为了正确地对车辆动力学进行建模，我们采用了[18]中的神经网络模型框架。在[18]中，作者表明他们的多层神经网络显著优于从物理学角度导出的基函数。

我们将状态变量向量定义为：

$$\mathbf{x} = [\phi, v_x, v_y, r]^T \quad (1)$$

其中， ϕ 是滚动角， v_x 和 v_y 是局部坐标系中的 x 和 y 速度， r 是偏航率。那么，状态方程可写为：

$$\mathbf{x}(t+1) = \mathbf{x}(t) + \mathbf{f}(\mathbf{x}(t), \mathbf{v}(t))\Delta t \quad (2)$$

其中 Δt 是采样周期， $\mathbf{v}(t)$ 是系统输入向量：

$$\mathbf{v}(t) = \begin{bmatrix} u_1(t) + \epsilon_1 \\ u_2(t) + \epsilon_2 \end{bmatrix} \quad (3)$$

u_1 和 u_2 分别是转向和加速度输入，它们受到高斯噪声 ϵ 的随机扰动。在(2)中， $\mathbf{f}(\cdot)$ 是具有双曲正切激活函数的全连接多层神经网络模型。它有两个隐藏层，每个隐藏层有 32 个神经元。该模型使用 Adam 优化器进行训练。它最大限度地减少了 100 个时间步长的 MPPI 预测损失。在我们的环境中，训练数据被抽取为 20 (ms) 长度的采样周期。因此，模型经过训练以在 2 (s) 间隔内进行优化。损失是X位置X、Y位置Y、侧倾角 ϕ 和偏航角 ψ 的平方误差之和。X、Y和 ψ 可以从状态变量运动学上导出：

$$\psi(t+1) = \psi(t) + r(t)\Delta t \quad (4)$$

$$X(t+1) = X(t) + \{v_x(t) \cos \psi(t) - v_y(t) \sin \psi(t)\} \Delta t \quad (5)$$

$$Y(t+1) = Y(t) + \{v_x(t) \sin \psi(t) + v_y(t) \cos \psi(t)\} \Delta t \quad (6)$$

B. Online Adaptation

我们使用 Continual-MAML [13] 来帮助我们的代理适应新环境，而不会忘记过去的环境。持续 - MAML 有效地适应新环境，同时保持针对以前见过的环境优化启动参数的能力。在我们的实验中，我们将路况的变化也称为任务或环境的变化。

在Continual-MAML中，使用两种参数：元参数 θ ，用于调整优化初始参数；快速参数 $\tilde{\theta}$ ，用于适应固定本地任务。当车辆在静止任务中行驶时，模型通过快速更新参数来适应当前任务。当检测到任务边界时，使用积累的任务知识来调整元参数。之后，使用元参数重新初始化快速参数，并开始适应下一个固定任务。因此，Continual-MAML 允许模型在检测到任务边界后从优化的初始值开始更新，并且还可以很好地适应固定任务。这使得模型对环境变化的适应更加有效和鲁棒。

算法 1 表示我们的比例汽车环境中的连续 MAML 流程，该流程对原始算法稍作修改。首先，我们将描述原始的 Continual-MAML 算法，然后明确说明修改以将其应用到我们的应用程序中。

在原始算法中，我们需要初始化模型参数和缓冲区（Alg. 1, L1-L2）。初始参数是通过 MAML 学习的。在持续学习循环（Alg. 1, L3-L16）中，对用于模型自适应的数据进行采样。如果检测到任务变化（图 1, L5），则使用缓冲区中存储的最近状态测量来更新元参数（图 1, L6-L9）。此后，缓冲区被清除（图 1, L10），并且快速参数被重置为元参数，元参数是更普遍调整的初始参数集（图 1, L11）。然后更新过程再次开始。如果一个

Algorithm 1 Continual-MAML for scale-car experiment

Require: N_c : the number of time steps used for one step

Require: η, l_r : learning rate hyperparameter

```
1: Initialize meta and fast parameters,  $\theta$  and  $\tilde{\theta}$ 
2: Initialize buffer,  $\mathcal{B}$  for incoming data
3: while do
4:   Sample  $\mathbf{x}_t$  and  $\mathbf{y}_t$  which consist of the past  $N_c$  steps data
5:   if Task boundary is detected then
6:     Sample training data  $\mathbf{x}_{\text{train}}, \mathbf{y}_{\text{train}} \sim \mathcal{B}$ 
7:     Sample test data  $\mathbf{x}_{\text{test}}, \mathbf{y}_{\text{test}} \sim \mathcal{B}$ 
8:     Fast adaptation  $\theta' \leftarrow \theta - \eta \nabla_{\theta} \mathcal{L}(f_{\theta}(\mathbf{x}_{\text{train}}), \mathbf{y}_{\text{train}})$ 
9:     Meta-Update  $\theta \leftarrow \theta - l_r \nabla_{\theta} \mathcal{L}(f_{\theta'}(\mathbf{x}_{\text{test}}), \mathbf{y}_{\text{test}})$ 
10:    Reset buffer  $\mathcal{B}$ 
11:    Reset fast parameters  $\tilde{\theta}_t \leftarrow \theta - \eta \nabla_{\theta} \mathcal{L}(f_{\theta}(\mathbf{x}_t), \mathbf{y}_t)$ 
12:   else
13:     Add  $\mathbf{x}_t, \mathbf{y}_t$  to buffer  $\mathcal{B}$ 
14:     Fine-tuning  $\tilde{\theta}_t \leftarrow \tilde{\theta}_{t-1} - \eta \nabla_{\tilde{\theta}} \mathcal{L}(f_{\tilde{\theta}_{t-1}}(\mathbf{x}_t), \mathbf{y}_t)$ 
15:   end if
16: end while
```

如果未检测到任务更改，则测量结果将添加到缓冲区（算法 1, L13），并且快速参数将根据其先前值进行更新（算法 1, L14）。

接下来，我们关注与原始算法的差异。在我们的实验中，我们在预训练阶段没有使用 MAML，而是使用第 III-A 节中提到的方案，因为我们使用一种道路条件下的数据集进行预训练。对于连续循环，我们将模型更新的更新周期 T_{up} 定义为允许实时进行在线适应的值，并且在每个 T_{up} 周期提供用于模型适应的数据（算法 1, L4）。这些数据由过去 N_c 个时间步的 $\mathbf{x}$ 和 $\mathbf{y}$ 组成。虽然我们理想情况下会像预训练阶段那样覆盖 100 个步骤，但我们需要分配一个较小的值 N_c 以确保实时操作。原始算法假设任务边界未知，并引入了检测边界的机制。在我们的例子中，我们假设我们的智能体知道任务边界并正确检测它们（算法 1, L5），以便看到 Continual-MAML 的纯粹适应潜力。实际上，视觉信息对于检测变化是有效的，并且有研究利用视觉信息进行自动驾驶[26]、[30]、[31]。我们将任务检测算法纳入未来的工作中。如果检测到任务边界，则像原始算法一样更新元参数。当更新元参数时，原始算法使用一种机制来做出平滑的行为。然而，在我们的实验条件下，这种机制效果不大，所以我们此时不将其采用到我们的算法中。当未检测到任务边界时，采样数据被添加到缓冲区（算法 1, L13）。为了减少计算负担，训练和测试数据集的缓冲区大小均设置为 1。原始算法中，每次采样的数据都保存到缓冲区中，当检测到任务边界或缓冲区满时，将其清除。然而，当缓冲区大小为一时，

任一缓冲区中的数据将与另一个缓冲区中包含的数据重叠，因为每个数据点都包含多个时间步测量。为了避免训练集和测试集的重叠，在我们的实验中，我们引入了一个函数来随机决定是否替换缓冲区中的旧数据，如果替换，则替换哪个缓冲区的数据。在我们的算法中，元参数每 0.4 (s) 更新一次，而原始算法仅在检测到任务边界或缓冲区已满时才更新它们。然而，与检测任务边界时不同，快速参数不会使用元参数进行初始化。在我们的实验中，快速参数和元参数是使用一种路况下的数据集进行预训练的，然后在持续学习阶段将其暴露于其他路况。如果当车辆穿越路况转换时元参数相对于预训练值没有发生足够的变化，则元参数将被重新初始化为预训练值。为了解决这个问题，即使车辆没有跨越任务边界，我们也会定期更新元参数。通过这种方式，元参数将被更新以适应现有条件。我们分别使用 Adam [32] 和梯度下降进行元参数更新和快速参数更新，如原始 Continual-MAML 论文 [13] 中所执行的那样。

C. Control Method

我们选择 MPPI [14]-[18] 作为我们所有模型（固定、梯度下降和连续 MAML）的基线控制器。MPPI 是一种基于随机采样方法的强大非线性 MPC，能够在无需近似的情况下解决非平滑且不可微的成本函数。在[14]、[15]中，改进了路径积分控制框架，使得设计者可以调整采样分布的均值和方差，并且使得路径积分控制能够快速收敛。他们还将 MPPI 的性能与基于微分动态规划 (DDP) 的最强大的非线性 MPC 公式之一进行了比较，并展示了 MPPI 在仿真中的优越性。[16]-[18]将 MPPI 部署在五分之一比例的汽车上，并展示了 MPPI 在接近操控极限的可行性。[17]、[18]利用神经网络对车辆动力学进行建模。

随着图形处理单元 (GPU) 的不断发展，MPPI 将能够对更多样本进行计算，从而实现更快、更准确的优化。MPPI 是一种算法，已被证明能够在接近规模汽车的处理极限的情况下进行稳定的规划和控制，并且预计在未来通过更强大的 GPU 进一步提高性能。由于这些原因，我们选择[18]中描述的 MPPI 作为我们的控制器，以显示建模精度对整体控制性能的影响。

为了准确评估动态模型对控制器的影响，我们设计了一个简单的成本函数，以使用 MPPI 最小化，如下所示：

$$J = \alpha_1 \text{Track}(\mathbf{x}) + \alpha_2 \text{Speed}(\mathbf{x}) \quad (7)$$

其中 α_1 和 α_2 是轨道成本的系数，



图 1. TRIKart, 我们实验中使用的十分之一比例的汽车。在实验过程中, 电气设备被塑料体覆盖, 并且保险杠安装在周边。



图 2. 我们的测试车库, 天花板上安装了 12 个 OptiTrack Prime 13 摄像机。这个车库的水泥地板用于对学习模型进行预训练。

分别是速度成本。由于众所周知, 使用转向和制动对于避免碰撞是有效的[33], 因此在成本函数中评估跟踪和速度。另外, 成本函数设计得简单, 便于分析模型精度对控制的影响。轨道成本和速度成本的细节在第 IV-C 节中描述。

四. 实验装置

A. Experimental Environment

在实验中, 我们使用 TRIKart [19], 这是一个十分之一比例的汽车平台, 如图 1 所示。我们使用由 12 个 OptiTrack Prime 13 摄像头组成的 Optitrack 运动捕捉系统(如图 2 所示)来测量车辆的位置和航向。系统以 120 Hz 的频率发布这些测量结果。从这些值我们可以得出速度和加速度。我们使用 ROS 来传输信息并运行我们的算法。

B. Model Setup

为了评估Continual-MAML的性能贡献, 我们准备了三个模型, 一个固定模型, 一个使用梯度下降的自适应模型和一个使用梯度下降的自适应模型




图 3. 用于我们实验的椭圆形路线。颜色代表轨迹成本, 即白色区域的成本为0, 黑色区域的成本为1。灰色在0和1之间线性插值。




图4.在线适应的实验路况。右侧的黑色垫子由具有高摩擦力的橡胶制成。左边的灰色垫子是用泡沫制成的, 比橡胶垫的摩擦力小。

连续-MAML。对于梯度下降, 我们只需在 Alg 中执行更新即可。1、L14, 而对于 Continual-MAML, 更新过程如 Alg 所概述。1. 在实验中, 车辆在简单的椭圆形路线上行驶, 以降低问题的复杂性并提供更直接的分析(图 3)。

所有三个模型都根据第 III-A 节中概述的学习方案, 使用在水泥地板上行驶时收集的相同数据进行了预训练。此外, 预训练模型在水泥地板上沿着椭圆形路线以梯度下降进行了微调。我们这样做是为了消除预训练模型与椭圆形路线不匹配的可能性; 这样, 固定模型和自适应模型之间的性能差异很可能仅源于对路况的处理, 而不是源于对路线的适应。

图4显示了用于评估在线自适应模型在不包含在训练集中的路况上的性能的实验条件。一半的球场是在比水泥地板摩擦力更大的橡胶垫上进行的。道路的另一半位于橡胶垫的泡沫背面, 其摩擦力比橡胶垫小。我们使用橡胶垫的背面而不是不同的表面, 以便在道路条件之间实现平坦的过渡, 并避免道路高度的变化作为可能的实验条件。道路状况之间的过渡发生在椭圆形赛道直线部分的中心。[13]引入了一种检测任务边界的机制。然而, 在我们的实验中, 我们选择不

表1 在线适应参数

Item	
T_{up}	80 (ms)
N_c	14
η	0.1
l_r	1.0×10^{-4}
Buffer size	1 training buffer and 1 test buffer

使用该功能，而是向算法提供路况转换的位置。

表 I 概述了用于在线自适应算法的参数值。 T_{up} 是梯度下降和Continual-MAML的更新周期。虽然持续时间越短越好，但将其设置为 80 (ms) 以实现实时执行。 N_c 是一步损失计算的时间步数。理想情况下，该值应设置为 100，与训练期间相同。但考虑到计算量，设置为14。如果该值太小，系统容易受到噪声的影响，导致性能下降。 η 和 l_r 分别是快速参数和元参数的学习率。由于计算限制，训练和测试数据集的缓冲区大小均设置为第 III-B 节中提到的 1。

C. Control Setup

在这里，我们提供了测试环境中 (7) 的详细信息。轨道成本在成本图中定义，如图3所示。在图3中，白色区域的成本值为0，黑色区域的成本为1。白色和黑色区域之间的灰色区域沿着轨道法线在0和1之间线性插值。

速度成本定义如下：

$$\text{Speed}(\mathbf{x}) = (v_x - v_{\text{ref}})^2 \quad (8)$$

其中 v_{ref} 是参考速度，在我们的实验中保持恒定。 v_x 是车辆动力学模型预测的车辆纵向速度。MPPI 提供转向角和加速度命令序列，可优化 100 个预测步骤的成本函数之和。

对于实验，我们在(7)中设置 $\alpha_1 = 600$ 、 $\alpha_2 = 25$ 和 $v_{\text{ref}} = 3.2$ (m/s)。

五、结果

我们从两个主要角度探讨了学习动力学模型的性能。作为一个学习问题，我们首先证明我们的方法在使用推理结果学习正确的动态系数方面的有效性。然后，我们探讨所得模型与 MPPI 控制器结合时的性能。

A. Inference

我们使用推理性能来评估模型的准确性。为了比较推理性能，车辆在垫子上自动顺时针行驶（图 4），使用




图 5. 40 (s) 到 60 (s) 之间每个模型的推理损失的放大视图。每个以红色虚线椭圆为特征的峰值对应于橡胶垫上的转动。特别是在这个区域，每种方法之间的差异非常显著。梯度下降优于固定模型，显示了适应的有效性。Continual-MAML 的性能优于梯度下降，尤其是在打开橡胶垫时，这意味着当检测到道路变化时，Continual-MAML 通过从最佳初始参数开始更新来实现快速有效的适应。

表 II 超过 60 (S) 的累积均方推理

Test No.	Fixed model	Gradient descent	Continual-MAML
N_1	2.56×10^{-3}	2.10×10^{-3}	1.98×10^{-3}
N_2	2.63×10^{-3}	2.20×10^{-3}	2.16×10^{-3}
N_3	2.75×10^{-3}	2.29×10^{-3}	2.23×10^{-3}

记录车辆状态时固定的学习动态模型。之后，通过依次将测量的车辆状态作为固定模型、梯度下降自适应模型和Continual-MAML自适应模型这三个模型的输入来计算推理误差。我们使用 N_c 步骤的累积损失来评估性能，该损失在在线适应过程中被最小化。

图5是每个模型在40(s)到60(s)之间的推理损失的放大图。由于前 40 (s) 与图 5 具有几乎相同的性能差异，因此我们显示放大视图以便更容易看到差异。如图 5 所示，自适应模型在损失值方面显著优于固定模型。图 5 中的周期性损失峰值对应于橡胶垫上的转弯，连续 MAML 显示出比梯度下降更好的推理性能，特别是在这些操作期间。这意味着Continual-MAML可以通过从精心调整的初始参数开始其更新周期来有效地学习足够的参数。

表 II 显示了 60 (s) 内的累积均方误差损失。我们进行了 3 次迭代测试，从表 2 的结果可以看出，对于相同的驾驶数据，Continual-MAML 实现了最佳的推理性能。

B. Control

为了评估动态模型精度对控制性能的贡献，我们在 TR IKart 平台上使用三个动态模型中的每一个，部署具有 (7) 中描述的成本函数的 MPPI 算法。对于自适应模型，模型参数实时更新

表3 轨迹误差和速度误差的控制误差统计

计

Test No.	Fixed model	Gradient descent	Continual-MAML
N_1	58.44	49.70	46.68
N_2	61.20	53.67	44.18
N_3	61.76	46.34	44.47
N_4	60.69	51.06	45.90
N_5	55.57	50.70	46.02
N_6	57.62	51.49	42.72
N_7	59.87	47.03	46.12
N_8	59.16	46.64	40.96
N_9	56.44	44.66	42.85
N_{10}	59.18	44.41	41.21
Mean	58.99	48.57	44.11
Min.	55.57	44.41	40.96

分别使用梯度下降和连续 MAML。每个型号的车辆顺时针行驶几圈。

图 6 显示了每个模型的前十圈轨迹。图 6 顶部的绘图显示固定模型在拐角内侧偏离路线，尤其是在橡胶垫上。我们认为这是因为橡胶垫的摩擦力远高于水泥地板的摩擦力，在水泥地板上收集固定模型的训练数据，导致对转向输入的反应比预期更大。下面的两张图显示，这两个自适应模型通过实时学习垫子上更好的模型参数来改善其轨迹误差。此外，自适应模型的速度比固定模型的速度更接近目标值。使用梯度下降的自适应模型的速度在球场一侧有泡沫垫的弯角后半部分较慢。我们假设模型在橡胶路面上学习了可接受的速度，并且当进入泡沫路面时，模型开始从适应橡胶表面的模型参数中学习。因此，模型最初以适合橡胶表面的速度运行，但对于泡沫表面来说太快了。然后控制器必须放慢速度以避免偏离目标路径。或者，当车辆进入新的路况时，使用Continual-MAML的自适应模型开始从适应两个新表面的初始参数中学习。因此，Continual-MAML 能够在两个路面上保持较高的速度。

表 III 显示了作为跟踪误差和速度误差之和评估的控制误差的统计数据 (7)。每个模型进行了十次测试。每次测试包括 18 圈赛道。表 III 总结了每次测试的控制误差的平均值，并且在第二圈至第十八圈内评估平均误差。如表 I II 所示，采用连续 MAML 的 MPPI 比采用梯度下降的控制误差更低。

六. 结论

在本文中，我们将最先进的Continual-MAML算法应用于学习车辆动力学模型参数的在线设置。我们利用TRIK art比例车平台对其适配性能进行评估。我们利用神经网络来捕获车辆动态




图 6. 使用 MPPI 控制的 10 圈顺时针车辆轨迹，目标速度为 3.2 (m/s)。MPPI 基于 (a) 固定模型、(b) 梯度下降自适应模型和 (c) 连续 MAML 自适应模型进行优化。梯度下降和连续 MAML 轨迹显然比固定模型更好地遵循白色范围指示的目标路径。Continual-MAML 的速度曲线最接近目标速度。

行为及其权重和偏差是根据在水泥地板上行驶收集的数据进行预先训练的。我们从两个主要角度探讨在线动态学习。第一个是它的推理性能，第二个是它对基于模型的自主控制器的速度和跟踪性能的贡献。对于这两项评估，我们在椭圆形跑道上自动驾驶比例车，该跑道的表面一半由橡胶垫组成，另一半由泡沫垫组成，这些表面不在训练集中。我们使用 MPPI 作为基线控制器。

对于推理评估，我们测量了每个候选模型的损失。在线适应的目的是最小化推理损失，因此使用梯度下降的模型和使用Continual-MAML的模型都优于固定模型。然而，Continual-MAML 的表现优于固定模型和梯度下降，特别是在橡胶垫上转弯时，这

意味着Continual-MAML可以通过从优化良好的初始参数开始其更新周期来快速有效地学习足够的参数。

对于模型对基于模型控制的自动驾驶性能的贡献，我们评估了由轨迹和速度误差组成的最终成本值。使用Continual-MAML，与固定模型相比，平均成本值提高了25%，与使用梯度下降的模型相比，平均成本值提高了9%。此外，Continual-MAML使控制器能够将最小成本值与固定模型相比提高26%，与梯度下降模型相比提高8%。

未来的工作包括在自动驾驶场景中引入自动检测任务边界的算法，以及将我们的方法扩展到现实世界中可能实际发生的更具挑战性的环境，例如湿滑的道路。

参考

[1] L. D. Lillo, T. Gode, X. Zhou, M. Atzei, R. Chen 和 T. Victor, “自动驾驶和人类驾驶员的安全性能比较: waymo one 服务的真实案例研究”, arXiv 预印本 arXiv:2309.01206, 2023. [2] “Pony.ai”, <https://pony.ai/?lang=en>, 访问时间: 2024 年 1 月 15 日. [3] J. Dallas, M. Thompson, J. Y. M. Goh 和 A. Balachandran, “一种用于最大化自动驾驶车辆轮胎力使用的分层自适应非线性模型预测控制方法”, arXiv 预印本 arXiv:2304.12263, 2023. [4] J. Kabzan, L. Hewing, A. Liniger 和 M. N. Zeilinger, “基于学习的自动驾驶模型预测控制”赛车”, IEEE 机器人与自动化快报, 卷. 4, 没有. 4, 第 3363-3370 页, 2019 年. [5] N. A. Spielberg, M. Brown 和 J. C. Gerdes, “神经网络模型预测运动控制应用于未知摩擦力的自动驾驶”, IEEE 控制系统技术学报, 卷. 30, 没有. 5, 第 1934-1945 页, 2022 年. [6] N. A. Spielberg, M. Brown, N. R. Kapania, J. C. Kegelmann 和 J. C. Gerdes, “高性能自动驾驶的神经网络车辆模型”, 《科学机器人》, 卷. 4, 没有. 2 019 年 2 月 28 日. [7] V. A. Laurence, J. Y. M. Goh 和 J. C. Gerdes, “在摩擦极限下自动驾驶车辆的路径跟踪”, 2017 年美国控制会议 (ACC), 美国华盛顿州西雅图, 第 5586-5591 页, 2017 年. [8] J. Betz, M. C heng, A. Liniger, U. Rosolia, P. Karle, M. Behl, V. Krovi 和 R. Mangharam “边缘自动驾驶汽车: 自动驾驶汽车竞赛调查”, IEEE 智能交通系统开放杂志, 卷. 3, 第 458-488 页, 2022 年. [9] J. Y. M. Goh, M. Thompson, J. Dallas 和 A. Balachandran, “高瞬态自主漂移的非线性模型预测控制”, 第 15 届高级车辆控制国际研讨会, 2022 年. [10] F. Djeumou, J. Y. M. Goh, U. Topcu 和 A. Balachandran, “通过学习轮胎模型使用 3 分钟数据进行自主漂移”, arXiv 预印本 arXiv: 2306.06330, 2023. [11] D. Chindamo 和 M. Gadola, “使用人工神经网络估计车辆侧滑角”, MATEC 会议网络, 第 1 卷. 166, 2018. [12] G. Garimella, J. Funke, C. Wang, 和 M. Kobilarov, “自动驾驶车辆转向控制的神经网络建模”, 2017 年 IEEE/RSJ 国际智能机器人和系统会议 (IRIOS), 加拿大不列颠哥伦比亚省温哥华, 第 2609-2615 页, 2017 年. [13] M. Caccia, P. 166 Rodriguez, O. Ostapenko, F. Normandin, M. Lin, L. Caccia, I. Laradji, I. Rish, A. Lacoste, D. Vazquez 和 L. Charlin, “在线快速适应和知识积累 (大阪): 持续学习的新方法”, arXiv 预印本 arXiv: 2003.05856, 2020. [14] G. Williams, A. Aldrich 和 E. A. Theodorou, “使用协方差变量重要性采样的模型预测路径积分控制”, arXiv 预印本 arXiv:1509.01149, 2015. [15] G. Williams, A. Aldrich 和 E. A. Theodorou, “模型预测路径积分控制: 从理论到并行计算”, 《指导、控制和动力学杂志》, 卷. 40, 没有. 2, 第 344-357 页, 2017 年.

[16] G. Williams, P. Drews, B. Goldfain, J. M. Rehg 和 E. A. Theodorou, “采用模型预测路径积分控制的主动驾驶”, 2016 年 IEEE 国际机器人与自动化会议 (ICRA), 瑞典斯德哥尔摩, 第 1433-1440 页, 2016 年. [17] G. Williams, N. Wagener, B. Goldfain, P. Drews, J. M. Rehg, B. Boots 和 E. A. Theodorou, “基于模型的强化学习的信息理论 MPC”, 2017 年 IEEE 国际机器人与自动化会议 (ICRA), 新加坡, 第 1714-1721 页, 2017 年. [18] G. Williams, P. Drews, B. Goldfain, J. M. Rehg 和 E. A. Theodorou, “信息理论模型预测控制: 自动驾驶的理论和应用”, IEEE 机器人学报, 卷. 34, 没有. 6, 第 1603-1622 页, 2018 年. [19] “使用 TRIKart 进行快速迭代设计和测试”, <https://medium.com/toyota-research/rapid-iterative-design-and-testing-with-trikart-f5a3f59f2dd9>, 访问时间: 2024-01-16. [20] J. Kong, M. Pfeiffer, G. Schildbach 和 F. Borrelli, “自动驾驶控制设计的运动学和动态车辆模型”, 2015 年 IEEE 智能车辆研讨会 (IV), 韩国首尔 (韩国), 第 1094-1099 页, 2015 年. [21] P. Polack, F. Althé, B. d’Andréa-Novell 和 A. de La Fortelle, “运动学自行车模型: 规划自动驾驶车辆可行轨迹的一致模型?”, 2017 年 IEEE 智能车辆研讨会 (IV), 美国加利福尼亚州洛杉矶, 第 812-818 页, 2017 年. [22] M. Brown 和 J. C. Gerdes, “协调轮胎力以避免障碍物非线性模型预测控制”, IEEE 智能车辆汇刊, 卷. 5, 没有. 1, 第 21-31 页, 2020 年. [23] D. Kalaria, Q. Lin 和 J. M. Dolan, “使用极限学习机对自动赛车的时变轮胎模型进行自适应规划和控制”, arXiv 预印本 arXiv:2303.08235, 2023 年. [24] M. Rokonzaman, N. Mohajer, S. Nahavandi 和 S. Mohamed, “利用学习的车辆动力学进行模型预测控制, 用于自主车辆路径跟踪”, IEEE Access, 卷. 9, 第 128233-128249 页, 2021 年. [25] G. Williams, B. Goldfain, J. M. Rehg 和 E. A. Theodorou “车辆动力学在线学习的局部加权回归伪演练”, arXiv 预印本 arXiv:1905.05162, 2019. [26] J. Vertens, N. Dorika, T. Welschhold, M. Thompson 和 W. Burgard, “利用表面的多模态潜在映射改进自动驾驶汽车的深度动力学模型”, arXiv 预印本 arXiv:2303.11756, 2023. [27] C. Finn, P. Abbeel 和 S. Levine, “用于快速适应深度网络的模型不可知元学习”, 国际机器学习会议, PMLR, 第 1126-1135 页, 2017 年. [28] C. Finn, A. Rajeswaran, S. Kakade 和 S. Levine, “在线元学习”, 国际机器学习会议, PMLR, 第 1920-1930 页, 2019 年. [29] J. Harrison, A. Sharma, C. Finn 和 M. Pavone, “无任务的连续元学习”, 神经信息处理系统进展, 33, 第 17571-17581 页, 2020. [30] P. Drews, G. Williams, B. Goldfain, E. A. Theodorou 和 J. M. Rehg, “积极深度驾驶: 结合卷积神经网络和模型预测控制”, 机器学习会议, 第 133-142 页, 2017. [31] P. Drews, G. Williams, B. Goldfain, E. A. Theodorou 和 J. M. Rehg, “利用深度动态观察器进行基于视觉的高速驾驶”, IEEE 机器人与自动化快报, 第 1 卷. 4, 没有. 2, 第 1564-1571 页, 2019. [32] D. P. Kingma 和 J. L. Ba, “Adam: 一种随机优化方法”, arXiv 预印本 arXiv: 1412.6980, 2014. [33] J. Wurts, J. L. Stein 和 T. Ersal, “碰撞迫在眉睫使用非线性模型预测控制进行高速转向”, 《IEEE 车辆技术汇刊》, 卷. 69, 没有. 8, 第 8278-8289 页, 2020 年.