

基于元学习方法的车辆动力学模型在线自适应

Yuki Tsuchiya¹, Thomas Balch², Paul Drews³ and Guy Rosman²

摘要——本文通过多层神经网络表示用于极限操控工况下自动驾驶的车辆动力学模型。为应对未知环境，在线自适应是必要的。然而，模型需要在不遗忘先前环境的前提下适应新环境。本研究采用持续模型无关元学习（Continual-MAML）来克服这一难题。该方法通过从优化后的初始参数开始更新，使模型能够快速高效地适应先前遇到的环境。我们利用 TRIKart 平台评估了在线模型自适应对推理性能的影响，以及对模型预测路径积分（MPPI）控制器控制性能的影响。神经网络使用测试环境中采集的驾驶数据进行预训练，在线自适应实验在训练数据中未包含的多种不同路面条件下进行。实验结果表明，采用持续模型无关元学习的模型在测试集损失和 MPPI 在线跟踪性能方面均优于固定模型和采用梯度下降的模型。

1. 引言

自动驾驶汽车因在安全性、缓解交通拥堵以及减轻乘客晕动症方面具有超越人类的潜力而日益受到关注。近期，部分企业已开始现实世界中部署自动驾驶汽车 [1]、[2]。然而，其部署仅限于特定区域和条件。因此，有必要扩展自动驾驶汽车的运行包线，使其能够在任何驾驶情境和条件下安全行驶。为提升紧急场景（例如突发障碍物出现）下的安全性与信心，需要在操控极限附近实现高性能控制。自动驾驶赛车是自动驾驶汽车极限操控的一个良好代理问题 [3] – [8]。一些前沿研究甚至致力于在漂移状态下实现稳定控制，以最大化车辆潜力 [9]、[10]。在自动驾驶汽车的局部规划与控制中，基于模型的方法最为常见。为实现高性能，需要具备快速推理能力的精确模型。许多基于模型的方法通过基于物理的模型来表示车辆动力学，因为该模型能够提供合理的车辆行为且易于分析 [3]、[7]、[9]。尽管基于物理的方法功能强大且

经过验证的方法在操控极限附近会变得复杂或无法对高度非线性行为进行建模。另一方面，神经网络（Neural Network）等学习模型有潜力在不显著增加计算成本的情况下捕捉非线性特征 [10] – [12]。因此，我们采用神经网络作为学习动力学模型，以超越基于物理的模型的性能。学习模型的性能在很大程度上取决于训练集。换言之，将固定模型应用于训练集中未包含的环境可能导致性能不佳。对于自动驾驶汽车而言，许多因素会随时间变化，例如乘客和负载重量、轮胎状况以及道路状况。用户可能会更换轮胎以应对冬季路况或更换旧轮胎。在 [5]、[6] 中，通过将历史数据整合到模型输入中，针对高摩擦和低摩擦两种不同路况开发了学习模型。然而，其训练集同时包含高摩擦和低摩擦路况数据，难以保证在所有可能场景下的性能。现实世界中存在不可估量的环境，预先从所有环境中推断模型是不切实际的。因此，在线模型自适应是一种强有力的替代方案，可适应训练集中未包含的可能环境。实时驾驶时，车辆不仅会遇到上述未见过的环境，还会遇到过去经历过的环境。因此，在线自适应算法不仅需要适应新环境，还需利用过去的信息快速重新适应之前遇到的环境。迄今为止，在学习模型高效序贯学习车辆动力学方面，鲜有方法脱颖而出，该领域的研究对于开发对现实世界持续变化具有鲁棒性的车辆控制至关重要。本文针对基于模型的控制中的学习车辆动力学模型，解决在线自适应问题。我们将持续元学习（Continual-MAML）[13] 应用于学习车辆动力学模型，以在条件恢复到先前状态时实现高控制性能，同时保持适应未知条件的能力。持续元学习是著名的元学习方法模型无关元学习（MAML）的扩展，旨在应对新旧任务交替出现的场景，并促进此类情况下的高效学习。当车辆遇到之前观察到的路况时，模型可通过基于先前观测的最优初始值开始参数更新，从而实现高效自适应。因此，基于模型的控制展现出更高的性能。

¹ 土屋优纪曾就职于美国马萨诸塞州剑桥市的丰田研究所，现就职于日本爱知县丰田市的丰田汽车公司，邮箱：yuki.tsuchiya_aa@mail.toyota.co.jp。 ² 托马斯·巴尔奇和盖伊·罗斯曼就职于美国马萨诸塞州剑桥市的丰田研究所，邮箱：thomas.balch@tri.global, guy.rosman@tri.global。 ³ 保罗·德鲁斯曾就职于美国马萨诸塞州剑桥市的丰田研究所，邮箱：paul.drews@gmail.com

为评估模型改进对基于模型控制器的影响,本文实现了一种模型预测路径积分 (Model Predictive Path Integral, MPPI) 控制器 [14] – [18]。该控制器源自模型预测控制 (Model Predictive Control, MPC), 并采用基于采样的方法进行优化。MPPI 是一种强大的控制算法,因为它能自然地考虑系统非线性。本文使用十分之一比例的模型车 [19] 进行实验。该比例模型车能够捕捉若干在仿真中难以建模的现实因素,并且与全尺寸车辆相比,确保实验安全性要简单得多。本文比较了三种模型的推理与控制性能: 固定模型、采用梯度下降的在线自适应模型以及采用 Continual-MAML 的在线自适应模型,实验场景为两种不同路面交替出现。这些路面上的驾驶数据未包含在训练数据中,以观察模型的自适应性能,且每个模型使用相同的神经网络结构。结果表明,采用 Continual-MAML 的在线自适应在推理和控制性能上均优于固定模型和采用梯度下降的自适应模型。本文重点关注道路条件差异,但所提方法可扩展到其他未预见场景,如可变负载。综上所述,本文贡献包括: (1) 将 Continual-MAML 算法应用于学习型车辆动力学模型,并描述其应用方式; (2) 与替代方法进行对比,表明在真实平台上基于模型控制时,Continual-MAML 在推理和控制性能上均优于固定模型和采用梯度下降的自适应模型。

II. 相关工作

本文工作涉及用于规划与控制的车辆动力学建模、其在在线自适应中的应用以及元学习方法。

A. 车辆动力学建模

在自动驾驶汽车领域的基于模型的控制中,基于物理的方法是常见的选择,因为它们易于分析,并且一个简单的基于物理的模型通常对于普通驾驶情况是可行的且足够准确。在 [20] 中表明,当横向加速度不大时,运动学自行车模型与考虑滑移的动态模型一样准确。[21] 为横向加速度提供了一个阈值,使得用于运动规划的运动学自行车模型是可靠的。即使在紧急场景中,如避障或在操控极限附近驾驶(如漂移),使用非线性模型预测控制 (NMPC) 结合自行车模型和刷子轮胎模型已经实现了自动驾驶 [9], [22]。另一种建模车辆动力学的方法是基于学习的方法。最近,学习到的车辆动力学模型引起了关注,因为它们有潜力捕捉车辆的非线性方面

动力学,而不会显著增加计算成本。在 [5], [6] 中,学习到的模型被用作在高摩擦和低摩擦路面上进行路径跟踪控制的车辆动力学模型,并且它们的控制性能优于由自行车模型和刷子轮胎模型组成的基于物理的模型。学习模型的参数是从两种路面学习到的,而基于物理的模型的参数是针对每种路面调整的。[11] 使用一个简单的神经网络模型来估计侧偏角,并在没有高计算成本和额外传感器的情况下实现了高性能。[12] 使用循环神经网络来建模转向系统动力学,并将其与基于物理的车辆模型相结合用于自动驾驶。[10] 提出了一种学习到的轮胎模型,该模型满足物理假设,可用于自动漂移控制器。他们学习到的模型比 Fiala 刷子模型和魔术公式轮胎模型具有更高的预测准确率。

B. 在线自适应

基于模型的控制需要高保真模型。然而,在现实世界中,车辆可能遇到模型设计时未考虑的新环境。在线自适应解决了这一不足。对于基于物理模型的在线自适应,多项研究聚焦于路面与轮胎之间摩擦力的在线辨识,因为它是影响车辆行为的关键参数,且随轮胎状态和路况变化。[3] 使用无迹卡尔曼滤波器估计自动驾驶中的摩擦参数。[7] 证明处于摩擦极限的自动驾驶车辆能够通过在线摩擦估计器跟踪圆形路径。另外, [4] 不仅关注摩擦参数,其方法利用高斯过程回归估计状态方程中基于物理模型的误差,以提升使用模型预测控制的自动驾驶性能。[23] 采用类似方法,用基于运动学的模型表达标称模型,并通过学习到的轮胎模型补偿其与动力学模型之间的差异。对于学习模型的在线自适应,主要关注适应训练集中未包含的新环境。对于学习模型,需要顺序学习来实现这一点。[24] 开发了一种使用带动量的梯度下降的在线参数更新算法。在学习模型性能超过基于物理模型之前,该方法使用基于物理模型,当学习模型达到更高性能时,切换到学习模型。神经网络模型在线自适应的一个主要问题是灾难性遗忘,即模型在适应新数据时忘记旧数据的现象。为避免该问题, [25] 将局部加权投影回归纳入更新方案。[26] 引入潜在向量的思想,从历史状态和动作、声学频谱图读数 and RGB 图像推断局部路面状况。使用潜在向量的学习动力学模型

在不同表面条件下比不使用潜在向量的模型提供更短的圈速和更安全的驾驶。

C. 元学习

为使模型快速适应新环境，一个关键因素是更新算法的效率。元学习 (Meta-learning) 也被称为学会学习，因为它改进了学习算法本身。其目标是使智能体能够快速适应新任务。模型无关元学习 (Model-Agnostic Meta-Learning, MAML) 是一种元学习方法，通过学习初始模型参数 [27] 来快速解决新任务。通过学习到的初始值开始参数更新循环，模型能够快速适应遇到的每个任务。MAML 假设任务以批量形式同时可用，无法处理顺序到达的任务。因此，将 MAML 应用于数据按顺序测量的在线方案引起了越来越多的关注。跟随元领导者 (Follow The Meta Leader, FTML) [28] 将 MAML 应用于在线框架。即使未见任务的数据集按顺序测量，FTML 也能更新初始参数。然而，FTML 需要存储所有观测数据，这一特性对于实际问题并不理想。其他研究将元学习框架应用于数据增量到达且未分割为离散任务的情形 [29]。然而，[29] 在与预训练数据相似的数据上测试其持续学习性能，对新任务的性能无法保证。[13] 关注称为在线快速适应与知识积累 (OSAKA) 的持续学习场景，其中新任务和先前任务都会出现。为了应对这一场景，即新任务出现的同时，先前任务一旦重现便能快速适应，研究者开发了持续 MAML (Continual-MAML)，作为原始 MAML 算法的扩展，但具备在线运行的能力。

三、本文方法

A. 车辆动力学建模

为了在不显著增加计算成本的情况下捕捉车辆动力学在操控极限附近的非线性特性，我们利用多层神经网络对车辆动力学进行建模。为了正确建模车辆动力学，我们采用了 [18] 中的神经网络模型框架。在 [18] 中，作者表明其多层神经网络显著优于从物理角度推导的基函数。我们将状态变量向量定义为：

$$\mathbf{x} = [\phi, v_x, v_y, r]^T \quad (1)$$

其中 ϕ 为侧倾角， v_x 和 v_y 分别为局部坐标系下的 x 和 y 速度， r 为横摆角速度。则状态方程写为：

$$\mathbf{x}(t+1) = \mathbf{x}(t) + \mathbf{f}(\mathbf{x}(t), \mathbf{v}(t))\Delta t \quad (2)$$

其中 Δt 为采样周期， $\mathbf{v}(t)$ 为系统输入向量：

$$\mathbf{v}(t) = \begin{bmatrix} u_1(t) + \epsilon_1 \\ u_2(t) + \epsilon_2 \end{bmatrix} \quad (3)$$

u_1 和 u_2 分别是转向和加速度输入，它们被高斯噪声 ϵ 随机扰动。在式 (2) 中， $\mathbf{f}(\cdot)$ 是一个具有双曲正切激活函数的全连接多层神经网络模型。它有两个隐藏层，每层有 32 个神经元。该模型使用 Adam 优化器进行训练。它在 100 个时间步长上最小化 MPPI 的预测损失。在我们的环境中，训练数据被抽取以使采样周期为 20 (毫秒)。因此，模型被训练为在 2 (秒) 的区间上进行优化。损失是 X 位置 X 、 Y 位置 Y 、横滚角 ϕ 和偏航角 ψ 。 X, Y 的平方误差之和，并且 ψ 可以从状态变量运动学推导得出：

$$\psi(t+1) = \psi(t) + r(t)\Delta t \quad (4)$$

$$X(t+1) = X(t) + \{v_x(t) \cos \psi(t) - v_y(t) \sin \psi(t)\} \Delta t \quad (5)$$

$$Y(t+1) = Y(t) + \{v_x(t) \sin \psi(t) + v_y(t) \cos \psi(t)\} \Delta t \quad (6)$$

B. 在线自适应

我们使用持续模型无关元学习 (Continual-MAML) [13] 来帮助智能体适应新环境而不遗忘过去的环境。持续模型无关元学习能够高效地适应新环境，同时保持为先前见过的环境优化起始参数的能力。在我们的实验中，道路状况的变化也被称为任务或环境的变化。在持续模型无关元学习中，使用两类参数：元参数 θ ，其被调整为优化的初始参数；以及快速参数 $\tilde{\theta}$ ，其适应平稳的局部任务。当车辆在平稳任务中行驶时，模型通过更新快速参数来适应当前任务。当检测到任务边界时，利用累积的任务知识调整元参数。之后，使用元参数重新初始化快速参数，并开始适应下一个平稳任务。因此，持续模型无关元学习允许模型在检测到任务边界后从优化的初始值开始更新，同时也能很好地适应平稳任务。这使得模型适应更加高效，并且对环境变化具有鲁棒性。算法 1 描述了在我们的比例车环境中持续模型无关元学习的流程，该流程对原始算法进行了轻微修改。首先，我们将描述原始的持续模型无关元学习算法，然后明确说明为将其应用于我们的应用所做的修改。在原始算法中，我们需要初始化模型参数和一个缓冲区 (算法 1, 第 1-2 行)。初始参数通过模型无关元学习学习得到。在持续学习循环中 (算法 1, 第 3-16 行)，采样用于模型适应的数据。如果检测到任务变化 (算法 1, 第 5 行)，则使用存储在缓冲区中的近期状态测量值更新元参数 (算法 1, 第 6-9 行)。之后，清空缓冲区 (算法 1, 第 10 行)，并将快速参数重置为元参数，元参数是一组更通用的初始参数 (算法 1, 第 11 行)。然后更新过程重新开始。如果

Algorithm 1 Continual-MAML for scale-car experiment

Require: N_c : the number of time steps used for one step

Require: η, l_r : learning rate hyperparameter

```
1: Initialize meta and fast parameters,  $\theta$  and  $\tilde{\theta}$ 
2: Initialize buffer,  $\mathcal{B}$  for incoming data
3: while do
4:   Sample  $\mathbf{x}_t$  and  $\mathbf{y}_t$  which consist of the past  $N_c$  steps
     data
5:   if Task boundary is detected then
6:     Sample training data  $\mathbf{x}_{\text{train}}, \mathbf{y}_{\text{train}} \sim \mathcal{B}$ 
7:     Sample test data  $\mathbf{x}_{\text{test}}, \mathbf{y}_{\text{test}} \sim \mathcal{B}$ 
8:     Fast adaptation  $\theta' \leftarrow \theta - \eta \nabla_{\theta} \mathcal{L}(f_{\theta}(\mathbf{x}_{\text{train}}), \mathbf{y}_{\text{train}})$ 
9:     Meta-Update  $\theta \leftarrow \theta - l_r \nabla_{\theta} \mathcal{L}(f_{\theta'}(\mathbf{x}_{\text{test}}), \mathbf{y}_{\text{test}})$ 
10:    Reset buffer  $\mathcal{B}$ 
11:    Reset fast parameters  $\tilde{\theta}_t \leftarrow \theta - \eta \nabla_{\theta} \mathcal{L}(f_{\theta}(\mathbf{x}_t), \mathbf{y}_t)$ 
12:  else
13:    Add  $\mathbf{x}_t, \mathbf{y}_t$  to buffer  $\mathcal{B}$ 
14:    Fine-tuning  $\tilde{\theta}_t \leftarrow \tilde{\theta}_{t-1} - \eta \nabla_{\tilde{\theta}} \mathcal{L}(f_{\tilde{\theta}_{t-1}}(\mathbf{x}_t), \mathbf{y}_t)$ 
15:  end if
16: end while
```

未检测到任务变化时，测量值被加入缓冲区（算法 1，第 13 行），快速参数根据其先前值进行更新（算法 1，第 14 行）。接下来，我们重点讨论与原算法的差异。在我们的实验中，预训练阶段不使用 MAML，而是采用第 III-A 节中提到的方案，因为我们使用单一道路条件下的数据集进行预训练。对于持续循环，我们定义了一个更新周期 T_{up} 用于模型适应，其值允许在线适应实时进行，并且用于模型适应的数据在每个 T_{up} 周期提供（算法 1，第 4 行）。这些数据由过去 N_c 个时间步的 $\mathbf{x}$ 和 $\mathbf{y}$ 组成。尽管理想情况下我们会像预训练阶段那样覆盖 100 步，但我们需要分配一个较小的值 N_c 以确保实时运行。原算法假设任务边界未知，并引入了检测边界的机制。在我们的情况下，我们假设智能体知道任务边界并能正确检测它们（算法 1，第 5 行），以便观察持续 MAML 的纯粹适应潜力。实际上，视觉信息对于检测变化是有效的，并且有研究利用视觉信息进行自动驾驶 [26]、[30]、[31]。我们将任务检测算法的整合留作未来工作。如果检测到任务边界，则像原算法那样更新元参数。在更新元参数时，原算法使用一种机制来产生平滑行为。然而，在我们的实验条件下，这种机制效果甚微，因此我们目前不将其纳入我们的算法。当未检测到任务边界时，采样数据被加入缓冲区（算法 1，第 13 行）。为了减少计算负担，训练和测试数据集的缓冲区大小均设置为 1。在原算法中，采样数据每次都被保存到缓冲区，当检测到任务边界或缓冲区已满时，缓冲区被清空。然而，当缓冲区大小为 1 时，

由于每个数据点由多个时间步测量值组成，任一缓冲区中的数据都会与另一缓冲区中的数据重叠。为避免训练集和测试集出现这种重叠，在实验中，我们引入一个函数来随机决定是否替换缓冲区中的旧数据，以及替换哪个缓冲区的数据。在我们的算法中，元参数每 0.4 秒更新一次，而原始算法仅在检测到任务边界或缓冲区填满时才更新。然而，与检测到任务边界时不同，快速参数不会用元参数初始化。在实验中，快速参数和元参数先在一种道路条件下的数据集上进行预训练，然后在持续学习阶段暴露于其他道路条件。如果车辆跨越道路条件转换时，元参数相对于预训练值的变化不够充分，元参数将被重新初始化为预训练值。为解决这一问题，即使车辆尚未跨越任务边界，我们也定期更新元参数。通过这种方式，元参数被更新以对现有条件具有鲁棒性。与原始持续模型无关元学习论文 [13] 中的做法相同，我们分别使用 Adam[32] 和梯度下降来更新元参数和快速参数。

C. 控制方法

我们选择 MPPI [14] – [18] 作为所有模型（固定模型、梯度下降模型和 Continual-MAML 模型）的基线控制器。MPPI 是一种基于随机采样方法的强大非线性模型预测控制（MPC），能够在不进行近似的情况下处理非光滑和非可微的代价函数。在 [14]、[15] 中，路径积分控制框架得到了改进，使得设计者可以调节采样分布的均值和方差，从而使路径积分控制能够快速收敛。他们还比较了 MPPI 与基于微分动态规划（DDP）的最强大非线性 MPC 公式之一的性能，并在仿真中展示了 MPPI 的优越性。[16] – [18] 将 MPPI 部署在一辆五分之一比例的汽车上，并展示了 MPPI 在接近操控极限时的可行性。[17]、[18] 利用神经网络对车辆动力学进行建模。随着图形处理单元（GPU）的持续发展，MPPI 将能够对更多样本进行计算，从而实现更快、更精确的优化。MPPI 是一种已被证明能够在比例汽车上接近操控极限时进行稳定规划与控制的算法，并且随着 GPU 能力的增强，其性能有望在未来进一步提升。基于这些原因，我们选择 [18] 中描述的 MPPI 作为控制器，以展示建模精度对整体控制性能的影响。为了准确评估动力学模型对控制器的影响，我们设计了一个简单的代价函数，供 MPPI 最小化，如下所示：

$$J = \alpha_1 \text{Track}(\mathbf{x}) + \alpha_2 \text{Speed}(\mathbf{x}) \quad (7)$$

其中 α_1 和 α_2 分别是赛道代价和速度代价的系数。



图 1. TRIKart，一辆用于我们实验的十分之一比例汽车。在实验过程中，电子设备由塑料车身覆盖，并在周边安装了保险杠。



图 2. 我们的测试车库，天花板上安装了 12 台 OptiTrack Prime 13 相机。该车库的水泥地面用于学习模型的预训练。

由于已知使用转向和制动对于避免碰撞是有效的 [33]，因此在代价函数中对跟踪和速度进行评估。此外，代价函数设计得较为简单，以便于分析模型精度对控制的影响。赛道代价和速度代价的细节将在第 IV-C 节中描述。

IV. 实验设置

A. 实验环境

在实验中，我们采用 TRIKart [19]，这是一个十分之一比例的赛车平台，如图 1 所示。我们使用由 12 台 OptiTrack Prime 13 相机组成的 Optitrack 运动捕捉系统来测量车辆的位置和航向，如图 2 所示。该系统以 120 赫兹的频率发布这些测量值。基于这些数值，我们推导出速度和加速度。我们利用 ROS 来传输信息并运行我们的算法。

B. 模型设置

为了评估持续元学习 (Continual-MAML) 的性能贡献，我们准备了三种模型：固定模型、使用梯度下降的自适应模型以及带有




图 3. 用于实验的椭圆形赛道。颜色代表轨迹成本，即白色区域的成本为 0，黑色区域的成本为 1。灰色在 0 到 1 之间线性插值。




图 4. 用于在线适应的实验路面条件。右侧的黑色垫子由高摩擦力的橡胶制成。左侧的灰色垫子由摩擦力低于橡胶的泡沫制成。

持续模型无关元学习 (Continual-MAML)。对于梯度下降，我们仅执行算法 1 第 14 行的更新，而对于持续模型无关元学习，更新过程如算法 1 所述。在实验中，车辆在简单的椭圆形赛道上行驶，以降低问题复杂度并提供更直接的分析（图 3）。所有三个模型均使用在水泥地面上采集的相同数据进行预训练，训练方案如第 III-A 节所述。此外，预训练模型在水泥地面的椭圆形赛道上通过梯度下降进行了微调。我们这样做是为了消除预训练模型可能与椭圆形赛道不匹配的可能性；这样，固定模型与自适应模型之间的性能差异最可能仅源于对路面条件的处理，而非对赛道的适应。图 4 展示了用于评估在线自适应模型在训练集中未包含的路面条件下性能的实验条件。赛道的一半位于橡胶垫上，其摩擦力高于水泥地面。另一半路面位于橡胶垫的泡沫背面，其摩擦力低于橡胶垫。我们使用橡胶垫的背面而非其他表面，是为了在路面条件之间实现平坦过渡，并避免路面高度变化成为可能的实验条件。路面条件之间的过渡发生在椭圆形赛道直线部分的中央。[13] 引入了一种检测任务边界的机制。然而，在我们的实验中，我们选择不

表 I 在线自适应参数

Item	
T_{up}	80 (ms)
N_c	14
η	0.1
l_r	1.0×10^{-4}
Buffer size	1 training buffer and 1 test buffer

利用该特征，转而在向算法提供道路状况变化的位置。表 I 概述了在线自适应算法所使用的参数值。 T_{up} 是梯度下降和持续模型无关元学习（Continual-MAML）的更新周期。虽然更短的周期更可取，但为了能够实时执行，将其设置为 80 毫秒。 N_c 是单步损失计算的时间步数。理想情况下，该值应设为 100，与训练时相同。然而，考虑到计算负载，将其设为 14。如果该值过小，系统容易受到噪声影响，导致性能下降。 η 和 l_r 分别是快速参数和元参数的学习率。由于计算限制，训练和测试数据集的缓冲区大小均设为 1，如第 III-B 节所述。

C. 控制设置

在此，我们提供测试环境中公式 (7) 的详细信息。赛道代价在代价图中定义，如图 3 所示。在图 3 中，白色区域的代价值为 0，黑色区域的代价值为 1。白色与黑色区域之间的灰色区域沿赛道法线在 0 和 1 之间线性插值。速度代价定义如下：

$$\text{Speed}(\mathbf{x}) = (v_x - v_{\text{ref}})^2 \quad (8)$$

其中 v_{ref} 是参考速度，在我们的实验中保持恒定。 v_x 是车辆的纵向速度，由车辆动力学模型预测。模型预测路径积分控制（MPPI）提供转向角和加速度命令序列，在 100 个预测步长上优化代价函数之和。在实验中，我们设置 $\alpha_1 = 600$, $\alpha_2 = 25$ 和 $v_{\text{ref}} = 3.2$ (m/s) in (7)。

V. 结果

我们从两个主要角度考察所学动力学模型的性能。作为学习问题，我们首先利用推理结果证明所提方法在学习正确动力学系数方面的有效性。然后，我们考察所得模型与模型预测路径积分控制（MPPI）控制器结合时的性能。

A. 推理

我们使用推理性能评估模型准确率。为了比较推理性能，车辆在垫子上顺时针自主行驶（图 4），使用




图 5. 各模型在 40 秒至 60 秒区间内推理损失的放大视图。每个由红色虚线椭圆标出的峰值对应于开启橡胶垫的时刻。特别是在该区域，各方法之间的差异显著。梯度下降优于固定模型，显示了自适应的有效性。持续型模型无关元学习在开启橡胶垫时尤其优于梯度下降，这表明持续型模型无关元学习在检测到道路变化时，通过从最优初始参数开始更新，实现了快速有效的自适应。

表 II 60 秒内累计均方推理损失

Test No.	Fixed model	Gradient descent	Continual-MAML
N_1	2.56×10^{-3}	2.10×10^{-3}	1.98×10^{-3}
N_2	2.63×10^{-3}	2.20×10^{-3}	2.16×10^{-3}
N_3	2.75×10^{-3}	2.29×10^{-3}	2.23×10^{-3}

在记录车辆状态的同时，使用一个固定的已学习动力学模型。之后，通过将测得的车辆状态依次作为三种模型（即固定模型、采用梯度下降的自适应模型和采用持续型模型无关元学习的自适应模型）的输入来计算推理误差。我们使用

N_c 步的累计损失来评估性能，该损失在在线自适应过程中被最小化。图 5 是各模型在 40 秒至 60 秒区间内推理损失的放大视图。由于前 40 秒的性能差异与图 5 中几乎相同，我们展示放大视图以便更清晰地观察差异。如图 5 所示，自适应模型在损失值方面显著优于固定模型。图 5 中损失的周期性峰值对应于在橡胶垫上的转弯，持续型模型无关元学习在这些机动过程中尤其表现出比梯度下降更好的推理性能。这意味着持续型模型无关元学习通过从良好调整的初始参数开始其更新周期，能够高效地学习合适的参数。表 II 显示了 60 秒内的累计均方误差损失。我们进行了 3 次测试迭代，从表 II 的结果可以看出，对于相同的驾驶数据，持续型模型无关元学习取得了最佳的推理性能。

B. 控制

为了评估动力学模型精度对控制性能的贡献，我们在 TRIKart 平台上部署了带有 (7) 中所述代价函数的模型预测路径积分控制算法，分别使用三种动力学模型。对于自适应模型，模型参数实时更新

表 III 控制误差统计，包括轨迹误差和速度误差

Test No.	Fixed model	Gradient descent	Continual-MAML
N_1	58.44	49.70	46.68
N_2	61.20	53.67	44.18
N_3	61.76	46.34	44.47
N_4	60.69	51.06	45.90
N_5	55.57	50.70	46.02
N_6	57.62	51.49	42.72
N_7	59.87	47.03	46.12
N_8	59.16	46.64	40.96
N_9	56.44	44.66	42.85
N_{10}	59.18	44.41	41.21
Mean	58.99	48.57	44.11
Min.	55.57	44.41	40.96

分别采用梯度下降和持续模型无关元学习（Continual-MAML）。车辆对每个模型顺时针行驶数圈。图 6 展示了每个模型前十圈的轨迹。在图 6 顶部，固定模型在弯道内侧偏离了赛道，尤其是在橡胶垫上。本文推测这是因为橡胶垫的摩擦力远高于水泥地面，而固定模型的训练数据是在水泥地面上采集的，导致转向输入的反应比预期更大。下方两幅图显示，两个自适应模型通过在垫子上实时学习更好的模型参数，改善了轨迹误差。此外，自适应模型的速度比固定模型更接近目标值。使用梯度下降的自适应模型在弯道后半段、赛道铺有泡沫垫的一侧速度较慢。本文假设模型在橡胶路面上学到了可接受的速度，当进入泡沫路面时，模型开始从已适应橡胶表面的模型参数进行学习。因此，模型最初以适合橡胶表面的速度行驶，但对泡沫表面而言过快。控制器随后不得不减速以避免偏离目标路径。相比之下，采用持续模型无关元学习的自适应模型在车辆进入新路况时，从已适应两种新表面的初始参数开始学习。因此，持续模型无关元学习能够在两种路面上保持更高的速度。表 III 展示了控制误差的统计数据，该误差为跟踪误差与速度误差之和（7）。每个模型执行了十次测试。每次测试包含 18 圈赛道。表 III 总结了每次测试控制误差的平均值，平均误差是在第二圈到第十八圈上评估的。如表 III 所示，采用持续模型无关元学习的模型预测路径积分控制（MPPI）比采用梯度下降的控制误差更低。

六、结论

本文采用最新技术中的持续模型无关元学习（Continual-MAML）算法，将其应用于已学习车辆动力学模型参数的在线设定。利用 TRIKart 比例车平台评估其自适应性能。本文利用神经网络捕捉车辆动力学特性。




图 6. 使用带目标速度 3.2（米/秒）的 MPPI 控制的 10 圈顺时针车辆轨迹。MPPI 基于（a）固定模型，（b）带梯度下降的自适应模型和（c）带持续 MAML 的自适应模型进行优化。梯度下降和持续 MAML 的轨迹明显比固定模型更好地遵循白色范围指示的目标路径。持续 MAML 的速度曲线最接近目标速度。

行为及其权重与偏差是在水泥地面上行驶所收集的数据上预训练的。我们从两个主要角度探究在线动力学学习。其一是其推理性能，其二是其对基于模型的自主控制器速度与跟踪性能的贡献。对于这两项评估，我们在椭圆形赛道上自动驾驶比例车，赛道表面一半由橡胶垫构成，另一半由泡沫垫构成，这些表面均不在训练集中。我们采用 MPPI 作为基线控制器。对于推理评估，我们测量了每个候选模型的损失。在线自适应旨在最小化推理损失，因此使用梯度下降的模型和使用持续 MAML 的模型均优于固定模型。然而，持续 MAML 优于固定模型和梯度下降，尤其是在橡胶垫上转弯时以及这一

这意味着持续模型无关元学习 (Continual-MAML) 能够通过从优化良好的初始参数开始其更新循环, 快速且高效地学习到合适的参数。对于模型在基于模型控制的自动驾驶性能中的贡献, 我们评估了由轨迹误差和速度误差组成的结果代价值。采用持续模型无关元学习后, 平均代价值相比固定模型提升了 25%, 相比使用梯度下降的模型提升了 9%。此外, 持续模型无关元学习使控制器的最小代价值相比固定模型提升了 26%, 相比梯度下降提升了 8%。未来工作包括在自动驾驶场景中引入任务边界的自动检测算法, 以及将我们的方法扩展到现实世界中可能实际出现的更具挑战性的环境, 例如湿滑路面。

参考文献

- [1] L. D. Lillo, T. Gode, X. Zhou, M. Atzei, R. Chen, and T. Victor, "Comparative safety performance of autonomous- and human drivers: A real-world case study of the waymo one service," arXiv preprint arXiv:2309.01206, 2023.
- [2] "Pony.ai," <https://pony.ai/?lang=en>, accessed: 2024-01-15.
- [3] J. Dallas, M. Thompson, J. Y. M. Goh, and A. Balachandran, "A hierarchical adaptive nonlinear model predictive control approach for maximizing tire force usage in autonomous vehicles," arXiv preprint arXiv:2304.12263, 2023.
- [4] J. Kabzan, L. Hewing, A. Liniger, and M. N. Zeilinger, "Learning-based model predictive control for autonomous racing," IEEE Robotics and Automation Letters, vol. 4, no. 4, pp. 3363-3370, 2019.
- [5] N. A. Spielberg, M. Brown, and J. C. Gerdes, "Neural network model predictive motion control applied to automated driving with unknown friction," IEEE Transactions on Control Systems Technology, vol. 30, no. 5, pp. 1934-1945, 2022.
- [6] N. A. Spielberg, M. Brown, N. R. Kapania, J. C. Kegelmann, and J. C. Gerdes, "Neural network vehicle models for high-performance automated driving," Science robotics, vol. 4, no. 28, 2019.
- [7] V. A. Laurence, J. Y. Goh, and J. C. Gerdes, "Path-tracking for autonomous vehicles at the limit of friction," 2017 American Control Conference (ACC), Seattle, WA, USA, pp. 5586-5591, 2017.
- [8] J. Betz, H. Zheng, A. Liniger, U. Rosolia, P. Karle, M. Behl, V. Krovi, and R. Mangharam, "Autonomous vehicles on the edge: A survey on autonomous vehicle racing," IEEE Open Journal of Intelligent Transportation Systems, vol. 3, pp. 458-488, 2022.
- [9] J. Y. M. Goh, M. Thompson, J. Dallas, and A. Balachandran, "Nonlinear model predictive control for highly transient autonomous drifting," 15th International Symposium on Advanced Vehicle Control, 2022.
- [10] F. Djeumou, J. Y. M. Goh, U. Topcu, and A. Balachandran, "Autonomous drifting with 3 minutes of data via learned tire models," arXiv preprint arXiv:2306.06330, 2023.
- [11] D. Chindamo and M. Gadola, "Estimation of vehicle side-slip angle using an artificial neural network," MATEC web of conferences, vol. 166, 2018.
- [12] G. Garimella, J. Funke, C. Wang, and M. Kobilarov, "Neural network modeling for steering control of an autonomous vehicle," 2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), Vancouver, BC, Canada, pp. 2609-2615, 2017.
- [13] M. Caccia, P. Rodríguez, O. Ostapenko, F. Normandin, M. Lin, L. Caccia, I. Laradji, I. Rish, A. Lacoste, D. Vazquez, and L. Charlin, "Online fast adaptation and knowledge accumulation (OSAKA): a new approach to continual learning," arXiv preprint arXiv:2003.05856, 2020.
- [14] G. Williams, A. Aldrich, and E. A. Theodorou, "Model predictive path integral control using covariance variable importance sampling," arXiv preprint arXiv:1509.01149, 2015.
- [15] G. Williams, A. Aldrich, and E. A. Theodorou, "Model predictive path integral control: From theory to parallel computation," Journal of Guidance, Control, and Dynamics, vol. 40, no. 2, pp. 344-357, 2017.
- [16] G. Williams, P. Drews, B. Goldfain, J. M. Rehg, and E. A. Theodorou, "Aggressive driving with model predictive path integral control," 2016 IEEE International Conference on Robotics and Automation (ICRA), Stockholm, Sweden, pp. 1433-1440, 2016.
- [17] G. Williams, N. Wagener, B. Goldfain, P. Drews, J. M. Rehg, B. Boots, and E. A. Theodorou, "Information theoretic MPC for model-based reinforcement learning," 2017 IEEE International Conference on Robotics and Automation (ICRA), Singapore, pp. 1714-1721, 2017.
- [18] G. Williams, P. Drews, B. Goldfain, J. M. Rehg, and E. A. Theodorou, "Information-theoretic model predictive control: Theory and applications to autonomous driving," IEEE Transactions on Robotics, vol. 34, no. 6, pp. 1603-1622, 2018.
- [19] "Rapid Iterative Design and Testing with TRIKart," <https://medium.com/toyota-research/rapid-iterative-design-and-testing-with-trikart-f5a3f59f2dd9>, accessed: 2024-01-16.
- [20] J. Kong, M. Pfeiffer, G. Schildbach, and F. Borrelli, "Kinematic and dynamic vehicle models for autonomous driving control design," 2015 IEEE Intelligent Vehicles Symposium (IV), Seoul, Korea (South), pp. 1094-1099, 2015.
- [21] P. Polack, F. Althé, B. d'Andréa-Novet, and A. de La Fortelle, "The kinematic bicycle model: A consistent model for planning feasible trajectories for autonomous vehicles?," 2017 IEEE Intelligent Vehicles Symposium (IV), Los Angeles, CA, USA, pp. 812-818, 2017.
- [22] M. Brown and J. C. Gerdes, "Coordinating tire forces to avoid obstacles using nonlinear model predictive control," IEEE Transactions on Intelligent Vehicles, vol. 5, no. 1, pp. 21-31, 2020.
- [23] D. Kalaria, Q. Lin, and J. M. Dolan, "Adaptive planning and control with time-varying tire models for autonomous racing using extreme learning machine," arXiv preprint arXiv:2303.08235, 2023.
- [24] M. Rokonzaman, N. Mohajer, S. Nahavandi, and S. Mohamed, "Model predictive control with learned vehicle dynamics for autonomous vehicle path tracking," IEEE Access, vol. 9, pp. 128233-128249, 2021.
- [25] G. Williams, B. Goldfain, J. M. Rehg, and E. A. Theodorou, "Locally weighted regression pseudo-rehearsal for online learning of vehicle dynamics," arXiv preprint arXiv:1905.05162, 2019.
- [26] J. Vertens, N. Dorka, T. Welschhold, M. Thompson, and W. Burgard, "Improving deep dynamics models for autonomous vehicles with multimodal latent mapping of surfaces," arXiv preprint arXiv:2303.11756, 2023.
- [27] C. Finn, P. Abbeel, and S. Levine, "Model-agnostic meta-learning for fast adaptation of deep networks," International conference on machine learning, PMLR, pp. 1126-1135, 2017.
- [28] C. Finn, A. Rajeswaran, S. Kakade, and S. Levine, "Online meta-learning," International Conference on Machine Learning, PMLR, pp. 1920-1930, 2019.
- [29] J. Harrison, A. Sharma, C. Finn, and M. Pavone, "Continuous meta-learning without tasks," Advances in neural information processing systems, 33, pp. 17571-17581, 2020.
- [30] P. Drews, G. Williams, B. Goldfain, E. A. Theodorou, and J. M. Rehg, "Aggressive deep driving: combining convolutional neural networks and model predictive control," Conference on Robot Learning, pp. 133-142, 2017.
- [31] P. Drews, G. Williams, B. Goldfain, E. A. Theodorou, and J. M. Rehg, "Vision-based high-speed driving with a deep dynamic observer," IEEE Robotics and Automation Letters, vol. 4, no. 2, pp. 1564-1571, 2019.
- [32] D. P. Kingma and J. L. Ba, "Adam: A method for stochastic optimization," arXiv preprint arXiv:1412.6980, 2014.
- [33] J. Wurts, J. L. Stein, and T. Eral, "Collision imminent steering at high speed using nonlinear model predictive control," IEEE Transactions on Vehicular Technology, vol. 69, no. 8, pp. 8278-8289, 2020.