

持续测试时领域自适应

Qin Wang¹ Olga Fink^{1,3*} Luc Van Gool^{1,4} Dengxin Dai²

¹ETH Zurich, Switzerland ²MPI for Informatics, Germany ³EPFL, Switzerland ⁴KU Lueven, Belgium
{qin.wang, vangool, dai}@vision.ee.ethz.ch olga.fink@epfl.ch

摘要

测试时领域自适应旨在在不使用任何源数据的情况下，将源预训练模型适配到目标域。现有工作主要考虑目标域是静态的情况。然而，现实世界的机器感知系统运行在非平稳且持续变化的环境中，目标域分布可能随时间变化。现有方法大多基于自训练和熵正则化，可能在这些非平稳环境中表现不佳。由于目标域分布随时间偏移，伪标签变得不可靠。噪声伪标签进一步可能导致错误累积和灾难性遗忘。为解决这些问题，我们提出了一种持续测试时自适应方法（CoTTA），包含两部分。首先，我们提出通过使用权重平均和增强平均的预测来减少错误累积，这些预测通常更准确。另一方面，为避免灾难性遗忘，我们提出在每次迭代中随机将一小部分神经元恢复到源预训练权重，以帮助长期保留源知识。所提方法使网络中所有参数能够长期自适应。CoTTA 易于实现，可轻松集成到现成的预训练模型中。我们在四个分类任务和一个分割任务上验证了所提方法在持续测试时自适应中的有效性，在这些任务上我们优于现有方法。我们的代码可在 <https://qin.ee/cotta> 获取。




图 1. 本文考虑在线持续测试时自适应场景。目标数据以序列形式提供，且来自持续变化的环境。现成的源预训练网络用于初始化目标网络。模型基于当前目标数据在线更新，并以在线方式给出预测。目标网络的自适应不依赖任何源数据。现有方法常受误差累积和遗忘困扰，导致性能随时间退化。本文方法能够在持续变化的环境下实现长期测试时自适应。

1. 引言

测试时领域自适应旨在通过在推理时从未标记的测试（目标）数据中学习来适配源预训练模型。由于源训练数据与目标测试数据之间存在域偏移，必须进行自适应才能获得良好性能。例如，一个在数据上训练的语义分割模型

晴朗天气条件下训练的模型在雪夜条件下测试时可能出现显著的性能退化 [50]。类似地，预训练图像分类模型在传感器退化导致的损坏图像上测试时也会出现这一现象。由于隐私顾虑或法律约束，在该设定下推理阶段通常认为源数据不可用，这使得该问题比无监督领域自适应更具挑战性，但也更贴近实际。在许多场景中，自适应还需要以在线方式进行。因此，测试时自适应对于领域偏移下真实世界机器感知应用的成功至关重要。现有测试时自适应工作通常通过伪标签或熵正则化更新模型参数，以应对源域与固定目标域之间的分布偏移 [43,61]。这些自训练方法

*The corresponding author

当测试数据来自同一静态域时，这些方法已被证明是有效的。然而，当目标测试数据来自持续变化的环境时，它们可能不稳定 [48]。这有两个方面的原因：首先，在持续变化的环境下，由于分布偏移，伪标签变得更嘈杂且校准不良 [13]。因此，早期的预测错误更可能导致误差累积 [4]。其次，由于模型长时间持续适应新分布，源域的知识更难保留，导致灾难性遗忘 [11,41,45]。为了解决持续变化环境下的这些问题，本文聚焦于在线持续测试时自适应这一实际问题。如图 1 所示，目标是从现成的源预训练模型开始，持续将其适应当前测试数据。在此设置下，我们假设目标测试数据从持续变化的环境中流式传输。预测和更新在线进行，这意味着模型只能访问当前数据流，而无法访问完整测试数据或任何源数据。所提出的设置与真实世界的机器感知系统高度相关。例如，自动驾驶系统的周围环境持续变化（例如天气从晴到多云再到下雨）。它们甚至可能突然变化（例如当汽车驶出隧道时，摄像头突然过曝）。感知模型需要在这些非平稳域偏移下在线自适应并做出决策。为了有效地将预训练源模型适应到持续变化的测试数据，我们提出了一种持续测试时自适应方法（CoTTA），该方法解决了现有方法的两个主要局限性。所提出方法的第一个组成部分旨在减轻误差累积。我们提出在自训练框架下通过两种不同方式提高伪标签质量。一方面，受均值教师预测通常比标准模型质量更高这一事实的启发 [55]，我们使用权重平均的教师模型来提供更准确的预测。另一方面，对于遭受较大域差距的测试数据，我们使用增强平均预测来进一步提升伪标签质量。所提出方法的第二个组成部分旨在帮助保留源知识并避免遗忘。我们提出随机将网络中一小部分神经元恢复到预训练源模型的状态。通过减少误差累积和保留知识，CoTTA 实现了在持续变化环境中的长期自适应，并使训练网络的所有参数成为可能。相比之下，先前的方法 [43,61] 只能训练批归一化参数。值得指出的是，我们的方法可以轻松

已实现。权重与增强平均策略以及随机恢复可以轻松地整合到任何现成的预训练模型中，无需在源数据上重新训练。我们在四个分类任务和一个分割任务上验证了所提方法在持续测试时自适应中的有效性，在这些任务上，我们显著提升了现有方法的性能。我们的贡献总结如下：

- 我们提出了一种持续测试时自适应方法，能够有效地将现成的源预训练模型适配到持续变化的目标数据上。
- 具体而言，我们通过使用更准确的权重平均和增强平均伪标签来减少误差累积。
- 通过显式保留源模型的知识，缓解了长期遗忘效应。
- 所提方法在分类和分割基准上显著提升了持续测试时自适应的性能。

2. 相关工作

2.1. 领域自适应

无监督领域自适应（Unsupervised Domain Adaptation）[44,46] 旨在带标签的源域与无标签的目标域之间存在域偏移的情况下，提升目标模型的性能。在训练过程中，无监督领域自适应方法通常使用差异损失 [39] 或对抗训练 [12, 58] 来对齐两个域之间的特征分布。此外，对齐也可以在输入空间中进行 [18,67]。近年来，自训练通过迭代地使用逐渐改进的目标伪标签来训练网络，也展现出了有前景的结果 [19,36,62,75]。

2.2. 测试时自适应

测试时自适应在某些文献中也被称为无源领域自适应 [28,66]。与需要同时访问源域和目标域数据进行自适应的领域自适应不同，测试时自适应方法在自适应过程中不需要源域的任何数据。一些现有工作 [29,33,68] 利用生成模型在缺少源数据的情况下支持特征对齐。另一个流行的方向是在不显式进行领域对齐的情况下微调源模型。测试熵最小化（TENT）[61] 采用预训练模型，通过熵最小化更新批归一化层中的可训练参数来适应测试数据。源假设迁移（SHOT）[37] 同时利用熵最小化和多样性正则化进行自适应。SHOT 需要使用源数据通过标签平滑技术训练一个专门的源模型

表 1. 本文提出的持续测试时自适应与相关自适应设置之间的差异。

Setting	Data		Learning	
	Source	Target	Train stage	Test stage
standard domain adaptation	Yes	stationary	Yes	No
standard test-time training [54]	Yes	stationary	Yes (aux task)	Yes
fully test-time adaptation [61]	No	stationary	No (pre-trained)	Yes
continual test-time adaptation	No	continually changing	No (pre-trained)	Yes

使用权重归一化层。因此，它无法支持使用任意预训练模型。[43] 提出应用多样性正则化结合输入变换模块以进一步提升性能。[23] 使用一个单独的归一化卷积网络来归一化来自新域的测试图像。[22] 在推理阶段仅使用伪原型更新最后的分类层。[74] 从贝叶斯角度分析该问题，并提出一种正则化熵最小化过程用于测试时自适应，这需要在训练期间近似密度。使用目标数据更新批归一化层中的统计量是另一条路径，也显示出有前景的结果 [21, 34, 70]。虽然大多数现有工作聚焦于图像分类，[20,27,38] 将测试时自适应扩展到语义分割。标准测试时自适应考虑离线场景，即提供完整测试数据集用于训练。这对于在线机器感知应用通常是不现实的。大多数现有工作（除 TENT 变体 [60] 外）还需要重新训练源模型以支持测试时自适应。因此，它们无法直接使用来自源域的现成预训练模型。

2.3. 连续领域自适应

与假设特定目标域的标准领域自适应不同，连续领域自适应考虑的是目标数据持续变化的适应问题。连续流形自适应 (Continuous Manifold Adaptation, CMA) [17] 是考虑适应演化域的早期工作。增量对抗领域自适应 (Incremental Adversarial Domain Adaptation, IADA) [63] 通过对抗性地对齐源特征和目标特征来适应持续变化的域。[59] 旨在持续适应未见过的视觉域，同时在不保留源训练数据的情况下缓解对已见域的遗忘。[3] 旨在利用逐渐变化域之间的连续性假设来适应逐渐变化的域。现有的连续领域自适应方法需要访问源域和目标域的数据以对齐分布。本文的主要关注点是持续测试时自适应，它额外考虑了在测试时进行适应且不访问源数据的情况。虽然这是现实世界中机器感知系统的一种现实场景，但适用于此类场景的方法非常有限。理论上，在线版本

TENT 的扩展版本 [61] 可以通过使用熵损失持续更新批归一化参数来适应这种设置。然而，由于预测校准不当，它可能会遭受误差累积。测试时训练 (TTT) [54] 也可以利用旋转预测辅助任务的监督持续更新特征提取器。然而，它需要使用源数据重新训练源模型以学习辅助任务。因此，它不能被视为全流程无源，并且不支持现成的源预训练模型。

2.4. 持续学习

持续学习 (Continual Learning) [10] 与终身学习 (Lifelong Learning) [45] 作为灾难性遗忘的潜在解决方案，与连续自适应问题密切相关。持续学习方法通常可分为基于回放 [49] 和基于正则化 [53, 72] 两类。后者进一步分为数据聚焦方法，如无遗忘学习 (LwF) [35]，以及先验聚焦方法，如弹性权重巩固 (EWC) [24]。持续学习的思想被采纳用于连续领域自适应方法 [3,30]。

2.5. 领域泛化

这项工作在广义上也与领域泛化 [42] 相关，因为其共同目标是提升在可能变化的目标领域上的性能。许多工作还表明，训练期间 [14, 16, 32, 69] 和测试期间 [1, 40, 73] 的数据增强 [52] 可以提高模型的鲁棒性和泛化能力。领域随机化是最流行的方法之一，它通过从仿真环境的不同综合参数中学习来提高模型的泛化能力 [56,57]。与主要旨在从源领域训练出更具泛化能力的神经网络的领域泛化方法不同，这项工作专注于在测试时利用来自持续变化的目标领域的无标签在线数据来提升现有预训练神经网络的性能。

3. 持续测试时领域自适应

3.1. 问题定义

给定一个在源数据 $(\mathcal{X}^S, \mathcal{Y}^S)$ 上训练好的现有预训练模型 $f_{\theta_0}(x)$ ，其参数为 θ ，我们的目标是在推理过程中提升该现有模型的性能。




图 2. 所提出的持续测试时自适应 (CoTTA) 方法概览。CoTTA 从一个现成的源预训练网络进行自适应。通过使用教师模型提供权重平均的伪标签, 并使用多种增强来平均预测, 从而减轻误差累积。通过随机恢复可训练权重中的少量元素来保留源数据的知识。

在无法访问任何源数据的情况下, 以在线方式对持续变化的目标域进行推理。未标记的目标域数据 $\mathcal{X}^T$ 按顺序提供, 模型只能访问当前时间步的数据。在时间步 t , 目标数据 x_t^T 作为输入提供, 模型 f_{θ_t} 需要做出预测 $f_{\theta_t}(x_t^T)$, 并据此为未来的输入 $\theta_t \rightarrow \theta_{t+1}$ 进行自适应。 x_t^T 的数据分布持续变化。模型基于在线预测进行评估。这种设置主要受持续变化环境中机器感知应用需求的驱动。例如, 自动驾驶汽车周围的环境因位置、天气和时间而持续变化。感知决策需要在线做出, 模型也需要进行自适应。我们在表 1 中列出了我们的在线持续测试时自适应设置与现有自适应设置之间的主要差异。与之前专注于固定目标域的设置相比, 我们考虑在持续变化的目标环境中进行长期自适应。

3.2. 方法论

本文提出一种面向在线持续测试时自适应场景的自适应方法。该方法采用现成的源预训练模型, 并以在线方式使其适应持续变化的目标数据。鉴于误差累积是自训练框架中的关键瓶颈之一, 本文提出利用权重与增强平均的伪标签来

减少误差累积。此外, 为帮助减少持续适应中的遗忘, 本文提出显式保留源模型的信息。所提方法的概览如图 2 所示。

源模型 现有的测试时自适应方法通常需要在源模型的训练过程中进行特殊处理, 以提高领域泛化能力并促进自适应。例如, 在源训练期间, TTT [54] 增加了一个辅助的旋转预测分支, 用于训练以促进目标自适应监督。这需要对源数据进行重新训练, 并且无法重用现有的预训练模型。在我们提出的测试时自适应方法中, 我们消除了这一负担, 不需要修改架构或额外的源训练过程。因此, 任何现有的预训练模型都可以直接使用, 无需在源数据上重新训练。我们将在实验中证明, 我们的方法可以适用于广泛的预训练网络, 包括 ResNet 变体和基于 Transformer 的架构。

权重平均伪标签 给定目标数据 x_t^T 和模型 f_{θ_t} , 自训练框架下常见的测试时目标是最小化预测 $\hat{y}_t^T = f_{\theta_t}(x_t^T)$ 与伪标签之间的交叉熵一致性。例如, 直接使用模型预测本身作为伪标签, 就得到了 TENT [61] 的训练目标 (即熵最小化)。虽然这对于静态目标域有效, 但对于持续变化的目标数据, 由于分布偏移, 伪标签的质量会显著下降。受以下观察的启发: 在训练步骤上权重平均的模型通常比最终模型 [47, 55] 更准确, 我们使用权重平均的教师模型 $f_{\theta'}$ 来生成伪标签。在时间步 $t = 0$, 教师网络被初始化为与源预训练网络相同。在时间步 t , 首先由教师生成伪标签 $\hat{y}_t'^T = f_{\theta'}(x_t^T)$ 。然后学生 f_{θ_t} 通过学生和教师预测之间的交叉熵损失进行更新:

$$\mathcal{L}_{\theta_t}(x_t^T) = - \sum_c \hat{y}_{tc}'^T \log \hat{y}_{tc}^T, \quad (1)$$

其中 $\hat{y}_{tc}'^T$ 是教师模型软伪标签预测中类别 c 的概率, $\hat{y}_{tc}^T$ 是学生模型 (学生) 的预测。该损失强制教师和学生预测之间的一致性。在使用方程 1 更新学生模型 $\theta_t \rightarrow \theta_{t+1}$ 之后, 我们使用学生权重通过指数移动平均更新教师模型的权重:

$$\theta'_{t+1} = \alpha \theta'_t + (1 - \alpha) \theta_{t+1}, \quad (2)$$

其中 α 为平滑因子。本文对输入数据 x_t^T 的最终预测为 $\hat{y}_t^T$ ，中概率最高的类别。权重平均一致性的优势体现在两个方面。一方面，通过使用通常更准确的 [47] 权重平均预测作为伪标签目标，模型在持续适应过程中受误差累积的影响更小。另一方面，均值教师预测 $\hat{y}_t^T$ 编码了过去迭代中模型的信息，因此在长期持续适应中更不易遭受灾难性遗忘，并提升了对新未见领域的泛化能力。这一思想源于 [55] 在半监督学习中提出的均值教师方法。

增强平均伪标签 训练时的数据增强 [52] 已被广泛应用于提升模型性能。不同的增强策略通常针对不同数据集进行人工设计 [26] 或搜索 [9]。虽然测试时增强也被证明能够提升鲁棒性 [5, 54]，但增强策略通常针对特定数据集确定并固定，未考虑推理时分布的变化。在持续变化的环境中，测试分布可能发生剧烈变化，从而使增强策略失效。本文考虑测试时领域偏移，并通过预测置信度近似领域差异。仅当领域差异较大时应用增强，以减少误差累积。

$$\tilde{y}_t^T = \frac{1}{N} \sum_{i=0}^{N-1} f_{\theta'_i}(x_t^T), \quad (3)$$

$$y_t^T = \begin{cases} \hat{y}_t^T, & \text{if } \text{conf}(f_{\theta_0}(x_t^T)) \geq p_{th} \\ \tilde{y}_t^T, & \text{otherwise,} \end{cases} \quad (4)$$

其中 $\tilde{y}_t^T$ 为教师模型的增强平均预测， $\hat{y}_t^T$ 为教师模型的直接预测， $\text{conf}(f_{\theta_0}(x_t^T))$ 为源预训练模型对当前输入 x_t^T 的预测置信度， p_{th} 为置信度阈值。通过使用预训练模型 f_{θ_0} 在方程 4 中计算当前输入 x_t^T 的预测置信度，本文尝试近似源领域与当前领域之间的差异。本文假设较低的置信度表示较大的领域差距，而相对较高的置信度表示较小的领域差距。因此，当置信度较高且大于阈值时，直接使用 $\hat{y}_t^T$ 作为伪标签，不进行任何增强。当置信度较低时，额外应用 N 次随机增强以进一步提升伪标签质量。该过滤至关重要，因为本文观察到随机增强

Algorithm 1 The proposed continual test-time adaptation

Initialization: A source pre-trained model $f_{\theta_0}(x)$, teacher model $f_{\theta'_0}(x)$ initialized from $f_{\theta_0}(x)$.

Input: For each time step t , current stream of data x_t .

- 1: 增强 x_t ，并根据方程 4. 从教师模型 $f_{\theta'_t}$ 获取权重和增强平均的伪标签。
- 2: 通过方程 5 中的一致性损失更新学生模型 f_{θ_t} 。
- 3: Update teacher $f_{\theta'_t}$ by moving average in Equation 2.
- 4: Stochastically restore student f_{θ_t} by Equation 8.

Output: Prediction $f_{\theta'_t}(x_t)$; Updated student model $f_{\theta_{t+1}}(x)$; Updated teacher model $f_{\theta'_{t+1}}(x)$.

在具有较小域差距的置信样本上应用增强有时会降低模型性能。我们在补充材料中对此观察进行了详细讨论。总之，我们使用置信度来近似域差异，并决定何时应用增强。学生模型通过精炼的伪标签进行更新：

$$\mathcal{L}_{\theta_t}(x_t^T) = - \sum_c y_{tc}^T \log \hat{y}_{tc}^T, \quad (5)$$

随机恢复 虽然更准确的伪标签可以缓解误差累积，但长时间通过自训练进行持续适应不可避免地会引入误差并导致遗忘。当数据序列中存在强烈的域偏移时，这一问题尤为突出，因为强烈的分布偏移会导致校准错误甚至错误的预测。在这种情况下，自训练可能只会强化错误的预测。更糟糕的是，在遇到困难样本后，由于持续适应，即使新数据没有严重偏移，模型也可能无法恢复。为了解决灾难性遗忘问题，我们提出了一种随机恢复方法，该方法显式地从源预训练模型中恢复知识。考虑学生模型 f_{θ} 在时间步 t 基于方程 1 进行梯度更新后的卷积层：

$$x_{l+1} = W_{t+1} * x_l, \quad (6)$$

其中 $*$ 表示卷积运算， x_l 和 x_{l+1} 表示该层的输入和输出， W_{t+1} 表示可训练的卷积滤波器。所提出的随机恢复方法还通过以下方式更新权重 W ：

$$M \sim \text{Bernoulli}(p), \quad (7)$$

$$W_{t+1} = M \odot W_0 + (1 - M) \odot W_{t+1}, \quad (8)$$

其中 $\odot$ 表示逐元素乘法， p 是较小的恢复概率， M 是与 W_{t+1} 形状相同的掩码张量。该掩码张量决定 W_{t+1} 中的哪些元素恢复为源权重 W_0 。

随机恢复也可视为随机失活（Dropout）的一种特殊形式。通过随机地将可训练权重中的少量张量元素恢复至初始权重，网络避免了偏离初始源模型过远，从而避免了灾难性遗忘。此外，通过保留源模型的信息，我们能够训练所有可训练参数而不会遭受模型崩溃。这为自适应带来了更大的容量，也是与仅训练批量归一化（BN）参数进行测试时自适应的熵最小化方法 [43, 61] 的另一主要区别。如算法 1 所示，将精炼伪标签与随机恢复相结合，形成了我们的在线持续测试时自适应（CoTTA）方法。

4. 实验

我们在五个持续测试时自适应基准任务上评估了所提出的方法：用于图像分类的 CIFAR10 到 CIFAR10C（标准和渐进式）、CIFAR100 到 CIFAR100C、ImageNet 到 ImageNet-C，以及用于语义分割的 Cityscapes 到 ACDC。

4.1. 数据集与任务

CIFAR10C、CIFAR100C 和 ImageNet-C 最初是为了基准测试分类网络的鲁棒性而创建的 [15]。每个数据集包含 15 种损坏类型，每种类型有 5 个严重程度级别。这些损坏被应用于干净的 CIFAR10 或 CIFAR100 数据集测试集的图像上 [25]。对于 CIFAR10C 和 CIFAR100C 数据集，每种损坏类型都有 10,000 张图像。对于我们的在线持续测试时自适应任务，使用在 CIFAR10 或 CIFAR100 数据集的干净训练集上预训练的网络。在测试期间，损坏的图像以在线方式提供给网络。与之前的方法不同，之前的方法评估从干净图像预训练模型到每种损坏类型的测试时自适应性，我们持续地将源预训练模型顺序地适应到每种损坏类型。我们在最大的损坏严重程度级别 5 下评估所有模型。评估基于遇到数据后立即的在线预测结果。CIFAR10 和 CIFAR100 实验都遵循这种在线持续测试时自适应方案。对于 CIFAR10 到 CIFAR10C，我们遵循 TENT[61] 的官方公开实现进行 CIFAR10 实验。采用相同的预训练模型，即来自 RobustBench 基准 [8] 的 WideResNet-28[71] 模型。我们在每次迭代时更新模型一步（即每个测试点一个梯度步骤）。我们使用与官方实现相同的 Adam 优化器，学习率为 $1e-3$ 。遵循 [5]，我们使用相同的随机增强组合，包括颜色抖动、随机仿射、高斯模糊、随机水平翻转和高斯噪声。

我们使用 32 种增强进行实验。我们在补充材料中讨论了增强阈值 p_{th} 的选择。与仅更新 BN 尺度和偏移权重的 TENT 模型不同，我们在实验中更新所有可训练参数。我们在所有实验中使用恢复概率 $p = 0.01$ 。对于 CIFAR100 到 CIFAR100C 实验，我们采用来自 [16] 的预训练 ResNeXt-29[65] 模型，该模型被用作 RobustBench 基准 [8] 中 CIFAR100 的默认架构之一。使用与 CIFAR10 实验相同的超参数。ImageNet 到 ImageNet-C[15] 实验使用 RobustBench[8] 中标准的预训练 resnet50 模型。ImageNet-C 实验在十种不同的损坏顺序下进行评估。

Cityscapes 到 ACDC 是一项我们设计的连续语义分割任务，旨在模拟现实世界中的连续分布偏移。源模型是一个现成的预训练分割模型，在 Cityscapes 数据集上训练 [7]。目标域包含来自不利条件数据集（ACDC）[50] 中各种场景的图像。ACDC 数据集与 Cityscapes 共享相同的语义类别，并在四种不同的不利视觉条件下采集：雾、夜、雨和雪。我们按照相同的默认顺序评估连续测试时自适应。我们使用每种不利条件下的 400 张无标签图像进行自适应。为了模拟现实生活中相似环境可能被再次访问的场景，并评估我们方法的遗忘效应，我们将相同的序列组（四种条件）重复 10 次（即总共 40 次：雾 → 夜 → 雨 → 雪 → 雾...）。这也提供了对长期自适应性能的评估。在实现细节方面，我们采用基于 Transformer 的架构 Segformer[64] 进行 Cityscapes 到 ACDC 的实验。我们使用公开可用的在 Cityscapes 上预训练的 Segformer-B5 作为现成的源模型。对于基线比较方法，TENT 优化归一化层中的参数。对于提出的 CoTTA 模型，所有可训练层都被更新，无需选择特定层。ACDC 中的图像分辨率为 1920x1080。我们使用下采样到 960x540 的分辨率作为网络输入，并在原始分辨率下评估预测结果。使用 Adam 优化器，学习率比 Segformer 的默认值小 8 倍，因为我们在在线连续测试时自适应实验中使用批大小 1 而不是 8（源训练的默认值）。我们使用多尺度输入和翻转作为所提出方法的增强方法，以生成增强加权伪标签（如方程 3 所示）。遵循 MMSeg[6] 中为 Cityscapes 设计的默认做法，我们使用尺度因子 [0.5, 0.75, 1.0, 1.25, 1.5, 1.75, 2.0]。

表 2. 标准 CIFAR10 到 CIFAR10C 在线连续测试时自适应任务的分类错误率 (%)。结果在 WideResNet-28 上以最大损坏严重级别 5 进行评估。

*表示需要额外的域信息。				$t \longrightarrow$																
Method	Weight- avg.	Aug- avg.	Stochastic Restore	Gaussian	shot	impulse	defocus	glass	motion	zoom	snow	frost	fog	brightness	contrast	elastic	trans	pixelate	jpeg	Mean
Source				72.3	65.7	72.9	46.9	54.3	34.8	42.0	25.1	41.3	26.0	9.3	46.7	26.6	58.5	30.3		43.5
BN Stats Adapt				28.1	26.1	36.3	12.8	35.3	14.2	12.1	17.3	17.4	15.3	8.4	12.6	23.8	19.7	27.3		20.4
Pseudo-label				26.7	22.1	32.0	13.8	32.2	15.3	12.7	17.3	17.3	16.5	10.1	13.4	22.4	18.9	25.9		19.8
TENT-online* [61]				24.8	23.5	33.0	12.0	31.8	13.7	10.8	15.9	16.2	13.7	7.9	12.1	22.0	17.3	24.2		18.6
TENT-continual [61]				24.8	20.6	28.6	14.4	31.1	16.5	14.1	19.1	18.6	18.6	12.2	20.3	25.7	20.8	24.9		20.7
CoTTA (Ours)	✓			27.2	22.8	30.8	12.1	30.1	13.9	11.9	17.2	16.0	14.3	9.4	13.1	19.9	15.4	19.9		18.3
CoTTA (Ours)	✓	✓		24.5	21.0	26.0	12.3	27.9	13.9	12.0	16.6	15.9	14.7	9.4	13.6	19.8	14.7	18.7		17.4
CoTTA (Ours)	✓	✓	✓	24.3	21.3	26.6	11.6	27.6	12.2	10.3	14.8	14.1	12.4	7.5	10.6	18.3	13.4	17.3		16.2 (0.1)

表 3. 逐渐变化的 CIFAR10 到 CIFAR10C 结果。严重程度在最低和最高之间逐渐变化。当严重程度最低时，损坏类型发生变化。结果是十种不同损坏类型序列的平均值。

Avg. Error (%)	Source	BN Adapt	TENT-continual [61]	CoTTA
CIFAR10C	24.8	13.7	30.7	10.4 ± 0.2

4.2. CIFAR10 到 CIFAR10C 的实验

我们首先在 CIFAR10 到 CIFAR10C 任务上评估所提模型的有效性。我们将本文方法与仅源域基线和四种流行方法进行比较。如表 2 所示，直接使用预训练模型而不进行自适应，平均错误率高达 43.5%，表明自适应是必要的。批归一化统计自适应方法保持网络权重不变，并使用当前迭代输入数据的批归一化统计量进行预测 [34, 51]。该方法简单且完全在线，显著优于仅源域基线。使用硬伪标签 [31] 更新批归一化可训练参数可将错误率降至 19.8%。如果 TENT 在线 [61] 方法能够获取额外的域信息，并在遇到新域时重置为初始预训练模型，性能可进一步提升至 18.6%。然而，此类信息在实际应用中通常不可用。在无法获取这些额外信息的情况下，TENT 持续方法相比批归一化统计自适应方法没有任何改进。值得一提的是，在自适应的早期阶段，TENT 持续方法优于批归一化统计自适应。然而，在观察到三种损坏类型后，模型迅速恶化。这表明基于 TENT 的方法在长期持续自适应下可能因误差累积而不稳定。本文所提方法通过使用权重和增强平均一致性，能够持续优于上述所有方法，错误率显著降低至 16.2%。此外，由于本文的随机恢复方法，该方法不会遭受长期性能恶化。消融实验：各个组件 本文所提方法的主要贡献在于减少误差累积。

通过使用平均伪标签和随机恢复进行累积。为验证本文动机，我们对所提方法的每个组成部分进行了消融实验。如表 2 所列，通过使用来自教师模型的权重平均伪标签，错误率从 20.7% 降至 18.3%。这表明权重平均预测确实比直接预测更准确。通过使用多种增强进一步细化权重平均预测，我们能够将性能进一步提升至 17.4%。然而，性能仍随时间恶化（例如与 TENT-online* 对比），这表明即使伪标签更准确，由于不可避免的错误预测，误差仍会累积。最后，通过使用随机恢复显式保留源知识，长期预测得到大幅改善，错误率降至 16.2%。括号内数字为 5 个随机种子下的标准差。

$$\underbrace{\dots \rightarrow 2 \rightarrow 1}_{t-1 \text{ and before}} \xrightarrow[\text{type}]{\text{change}} \underbrace{1 \rightarrow 2 \rightarrow 3 \rightarrow 4 \rightarrow 5 \rightarrow 4 \rightarrow 3 \rightarrow 2 \rightarrow 1}_{\text{corruption type } t, \text{ gradually changing severity}} \xrightarrow[\text{type}]{\text{change}} \underbrace{1 \rightarrow 2 \dots}_{t+1 \text{ and on}},$$

当损坏类型改变时，严重程度级别最低（1），因此类型变化是渐进的。每种类型内的分布偏移也是渐进的。我们为损坏类型创建 10 个随机打乱顺序 t ，然后使用这十个不同序列上的平均错误率评估方法。表 3 显示，所提方法优于竞争方法，错误率为 10.4%，而 TENT 为 30.7%。

4.3. CIFAR100 到 CIFAR100C 实验

为进一步证明所提方法的有效性，我们在更困难的 CIFAR100 到 CIFAR100C 任务上进行了评估。实验结果总结于表 4。我们将本文方法与仅源域基线、批归一化统计自适应、伪标签以及 TENT-continual 方法进行了比较。我们观察到

表 4. 标准 CIFAR100 到 CIFAR100C 在线持续测试时自适应任务的分类错误率（%）。所有结果均在 ResNeXt-29 架构上以最大损坏严重程度级别 5 进行评估。

Time	$t \longrightarrow$															
Method	<i>Gaussian</i>	<i>shot</i>	<i>impulse</i>	<i>defocus</i>	<i>glass</i>	<i>motion</i>	<i>zoom</i>	<i>snow</i>	<i>frost</i>	<i>fog</i>	<i>brightness</i>	<i>contrast</i>	<i>elastic.trans</i>	<i>pixelate</i>	<i>jpeg</i>	Mean
Source	73.0	68.0	39.4	29.3	54.1	30.8	28.8	39.5	45.8	50.3	29.5	55.1	37.2	74.7	41.2	46.4
BN Stats Adapt	42.1	40.7	42.7	27.6	41.9	29.7	27.9	34.9	35.0	41.5	26.5	30.3	35.7	32.9	41.2	35.4
Pseudo-label	38.1	36.1	40.7	33.2	45.9	38.3	36.4	44.0	45.6	52.8	45.2	53.5	60.1	58.1	64.5	46.2
TENT-continual [61]	37.2	35.8	41.7	37.9	51.2	48.3	48.5	58.4	63.7	71.1	70.4	82.3	88.0	88.5	90.4	60.9
CoTTA (Proposed)	40.1	37.7	39.7	26.9	38.0	27.9	26.4	32.8	31.8	40.3	24.7	26.9	32.5	28.3	33.5	32.5

表 5. 在 Cityscapes 到 ACDC 在线持续测试时自适应任务上的语义分割结果（mIoU 以 % 计）。我们连续十次评估四种测试条件，以评估长期自适应性能。为节省篇幅，我们仅展示第一轮、第四轮、第七轮和最后一轮的持续自适应结果。完整结果见补充材料。所有结果均基于 Segformer-B5 架构评估。

Time	$t \longrightarrow$																
Round	1				4				7				10				All
Condition	Fog	Night	rain	snow	Fog	Night	rain	snow	Fog	Night	rain	snow	Fog	Night	rain	snow	Mean
Source	69.1	40.3	59.7	57.8	69.1	40.3	59.7	57.8	69.1	40.3	59.7	57.8	69.1	40.3	59.7	57.8	56.7
BN Stats Adapt	62.3	38.0	54.6	53.0	62.3	38.0	54.6	53.0	62.3	38.0	54.6	53.0	62.3	38.0	54.6	53.0	52.0
TENT-continual [61]	69.0	40.2	60.1	57.3	66.5	36.3	58.7	54.0	64.2	32.8	55.3	50.9	61.8	29.8	51.9	47.8	52.3
CoTTA (Proposed)	70.9	41.2	62.4	59.7	70.9	41.0	62.7	59.7	70.9	41.0	62.8	59.7	70.8	41.0	62.8	59.7	58.6

表 6. 在 10 种不同损坏序列（严重程度 5 级）上的标准 ImageNet 到 ImageNet-C 实验的平均误差。

Avg. Error (%)	Source	BN Adapt	Test Aug [5]	TENT [58]	CoTTA
ImageNet-C	82.4	72.1	71.4	66.5	63.0 ± 1.8 (0.1)

TENT 持续模型在后续损坏类型上随时间迅速退化，原因是误差累积和遗忘。我们的方法相比 BN 统计自适应实现了 2.9% 的绝对误差率改进，达到 32.5%。更重要的是，改进随时间增大，这表明所提方法能够从过去流的无标签测试图像中学习，以进一步提升当前测试数据的性能。

4.4. ImageNet 到 ImageNet-C 实验

为了对所提方法进行更全面的评估，我们在严重程度 5 级的十种不同损坏类型序列上进行了 ImageNet 到 ImageNet-C 实验。如表 6 所示，CoTTA 能够持续优于 TENT 和其他竞争方法。± 后的数字是 10 种不同损坏类型序列上的标准差。

4.5. Cityscapes 到 ACDC 实验

我们还在更复杂的持续测试时语义分割 Cityscapes 到 ACDC 任务上评估了我们的方法。实验结果总结如下

表 5. 结果表明，我们的方法对语义分割任务同样有效，并且对不同架构选择具有鲁棒性。我们提出的方法相比基线实现了 1.9% 的绝对 mIoU 改进，达到 58.6% mIoU。值得提及的是

这表明批归一化统计自适应和测试熵最小化在此任务中表现不佳，且性能随时间显著下降。部分原因在于两者均专为具有批归一化层的网络设计，而分割变换器中仅有一个批归一化层，变换器模型中的大多数归一化层基于层归一化 [2]。然而，本文方法不依赖特定层，在截然不同的架构上仍能有效应对这一更复杂的任务。在相对长期的持续自适应后，改进的性能也基本得以保持。

5. 结论

本文聚焦于非平稳环境下的持续测试时自适应，其中目标域分布随时间不断变化。为解决该设置下的误差累积与灾难性遗忘问题，本文提出了一种新颖的方法——持续测试时自适应，包含两部分。首先，通过权重平均和增强平均的预测来减少误差累积，这些预测通常更为准确。其次，为保留源模型的知识，本文随机将一小部分权重恢复为源预训练权重。所提方法可集成到现成的预训练模型中，无需访问源数据。持续测试时自适应的有效性在四个分类任务和一个分割任务上得到了验证。致谢 王琴和奥尔加·芬克的贡献由瑞士国家科学基金会资助，项目编号 PP00P2 176878。本工作还由丰田汽车欧洲公司通过 TRACE-苏黎世项目资助。

参考文献

- [1] Arsenii Ashukha, Alexander Lyzhov, Dmitry Molchanov, and Dmitry Vetrov. Pitfalls of in-domain uncertainty estimation and ensembling in deep learning. *ICLR*, 2020. 3
- [2] Jimmy Lei Ba, Jamie Ryan Kiros, and Geoffrey E Hinton. Layer normalization. *arXiv preprint arXiv:1607.06450*, 2016. 8
- [3] Andreea Bobu, Eric Tzeng, Judy Hoffman, and Trevor Darrell. Adapting to continuously shifting domains. In *ICLR Workshops*, 2018. 3
- [4] Chaoqi Chen, Weiping Xie, Wenbing Huang, Yu Rong, Xinghao Ding, Yue Huang, Tingyang Xu, and Junzhou Huang. Progressive feature alignment for unsupervised domain adaptation. In *CVPR*, pages 627–636, 2019. 2
- [5] Gilad Cohen and Raja Giryes. Katana: Simple post-training robustness using test time augmentations. *arXiv preprint arXiv:2109.08191*, 2021. 5, 6
- [6] MMSegmentation Contributors. MMSegmentation: Openmmlab semantic segmentation toolbox and benchmark. <https://github.com/open-mmlab/mms Segmentation>, 2020. 6
- [7] Marius Cordts, Mohamed Omran, Sebastian Ramos, Timo Rehfeld, Markus Enzweiler, Rodrigo Benenson, Uwe Franke, Stefan Roth, and Bernt Schiele. The cityscapes dataset for semantic urban scene understanding. In *CVPR*, 2016. 6
- [8] Francesco Croce, Maksym Andriushchenko, Vikash Sehwag, Edoardo Debenedetti, Nicolas Flammarion, Mung Chiang, Prateek Mittal, and Matthias Hein. Robustbench: a standardized adversarial robustness benchmark. In *NeuIPS Datasets and Benchmarks Track*, 2021. 6
- [9] Ekin D Cubuk, Barret Zoph, Dandelion Mane, Vijay Vasudevan, and Quoc V Le. Autoaugment: Learning augmentation strategies from data. In *CVPR*, pages 113–123, 2019. 5
- [10] Matthias Delange, Rahaf Aljundi, Marc Masana, Sarah Parisot, Xu Jia, Ales Leonardis, Greg Slabaugh, and Tinne Tuytelaars. A continual learning survey: Defying forgetting in classification tasks. *T-PAMI*, 2021. 3
- [11] Sayna Ebrahimi, Franziska Meier, Roberto Calandra, Trevor Darrell, and Marcus Rohrbach. Adversarial continual learning. In *ECCV*. Springer, 2020. 2
- [12] Yaroslav Ganin and Victor Lempitsky. Unsupervised domain adaptation by backpropagation. In *ICML*, pages 1180–1189, 2015. 2
- [13] Chuan Guo, Geoff Pleiss, Yu Sun, and Kilian Q Weinberger. On calibration of modern neural networks. In *ICML*, pages 1321–1330. PMLR, 2017. 2
- [14] Dan Hendrycks, Steven Basart, Norman Mu, Saurav Kadavath, Frank Wang, Evan Dorundo, Rahul Desai, Tyler Zhu, Samyak Parajuli, Mike Guo, et al. The many faces of robustness: A critical analysis of out-of-distribution generalization. In *ICCV*, pages 8340–8349, 2021. 3
- [15] Dan Hendrycks and Thomas Dietterich. Benchmarking neural network robustness to common corruptions and perturbations. *ICLR*, 2019. 6
- [16] Dan Hendrycks, Norman Mu, Ekin D. Cubuk, Barret Zoph, Justin Gilmer, and Balaji Lakshminarayanan. AugMix: A simple data processing method to improve robustness and uncertainty. *ICLR*, 2020. 3, 6
- [17] Judy Hoffman, Trevor Darrell, and Kate Saenko. Continuous manifold based adaptation for evolving visual domains. In *CVPR*, pages 867–874, 2014. 3
- [18] Judy Hoffman, Eric Tzeng, Taesung Park, Jun-Yan Zhu, Phillip Isola, Kate Saenko, Alexei Efros, and Trevor Darrell. Cycada: Cycle-consistent adversarial domain adaptation. In *ICML*, pages 1989–1998. PMLR, 2018. 2
- [19] Lukas Hoyer, Dengxin Dai, and Luc Van Gool. Daformer: Improving network architectures and training strategies for domain-adaptive semantic segmentation. *arXiv preprint arXiv:2111.14887*, 2021. 2
- [20] Minhao Hu, Tao Song, Yujun Gu, Xiangde Luo, Jieneng Chen, Yinan Chen, Ya Zhang, and Shaoting Zhang. Fully test-time adaptation for image segmentation. In *International Conference on Medical Image Computing and Computer-Assisted Intervention*, pages 251–260. Springer, 2021. 3
- [21] Xuefeng Hu, Gokhan Uzunbas, Sirius Chen, Rui Wang, Ashish Shah, Ram Nevatia, and Ser-Nam Lim. Mixnorm: Test-time adaptation through online normalization estimation. *arXiv preprint arXiv:2110.11478*, 2021. 3
- [22] Yusuke Iwasawa and Yutaka Matsuo. Test-time classifier adjustment module for model-agnostic domain generalization. In *NeuIPS*, 2021. 3
- [23] Neerav Karani, Ertunc Erdil, Krishna Chaitanya, and Ender Konukoglu. Test-time adaptable neural networks for robust medical image segmentation. *Medical Image Analysis*, 68:101907, 2021. 3
- [24] James Kirkpatrick, Razvan Pascanu, Neil Rabinowitz, Joel Veness, Guillaume Desjardins, Andrei A Rusu, Kieran Milan, John Quan, Tiago Ramalho, Agnieszka Grabska-Barwinska, et al. Overcoming catastrophic forgetting in neural networks. *Proceedings of the national academy of sciences*, 114(13):3521–3526, 2017. 3
- [25] Alex Krizhevsky and Geoffrey Hinton. Learning multiple layers of features from tiny images. Technical report, Cite-seer, 2009. 6
- [26] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E Hinton. Imagenet classification with deep convolutional neural networks. In *NeuIPS*, pages 1097–1105, 2012. 5
- [27] Jogendra Nath Kundu, Akshay Kulkarni, Amit Singh, Varun Jampani, and R Venkatesh Babu. Generalize then adapt: Source-free domain adaptive semantic segmentation. In *ICCV*, pages 7046–7056, 2021. 3
- [28] Jogendra Nath Kundu, Naveen Venkat, R Venkatesh Babu, et al. Universal source-free domain adaptation. In *CVPR*, pages 4544–4553, 2020. 2
- [29] Vinod K Kurmi, Venkatesh K Subramanian, and Vinay P Namboodiri. Domain impression: A source data free domain adaptation method. In *WACV*, pages 615–625, 2021. 2
- [30] Qicheng Lao, Xiang Jiang, Mohammad Havaei, and Yoshua Bengio. Continuous domain adaptation with variational domain-agnostic feature replay. *arXiv preprint arXiv:2003.04382*, 2020. 3

- [31] Dong-Hyun Lee. Pseudo-label: The simple and efficient semi-supervised learning method for deep neural networks. In *Workshop on Challenges in Representation Learning, ICML*, volume 3, page 2, 2013. 7
- [32] Boyi Li, Felix Wu, Ser-Nam Lim, Serge Belongie, and Kilian Q Weinberger. On feature normalization and data augmentation. In *CVPR*, pages 12383–12392, 2021. 3
- [33] Rui Li, Qianfen Jiao, Wenming Cao, Hau-San Wong, and Si Wu. Model adaptation: Unsupervised domain adaptation without source data. In *CVPR*, pages 9641–9650, 2020. 2
- [34] Yanghao Li, Naiyan Wang, Jianping Shi, Jiaying Liu, and Xiaodi Hou. Revisiting batch normalization for practical domain adaptation. *arXiv preprint arXiv:1603.04779*, 2016. 3, 7
- [35] Zhizhong Li and Derek Hoiem. Learning without forgetting. *T-PAMI*, 40(12):2935–2947, 2017. 3
- [36] Qing Lian, Fengmao Lv, Lixin Duan, and Boqing Gong. Constructing self-motivated pyramid curriculums for cross-domain semantic segmentation: A non-adversarial approach. In *ICCV*, October 2019. 2
- [37] Jian Liang, Dapeng Hu, and Jiashi Feng. Do we really need to access the source data? source hypothesis transfer for unsupervised domain adaptation. In *ICLR*, pages 6028–6039. PMLR, 2020. 2
- [38] Yuang Liu, Wei Zhang, and Jun Wang. Source-free domain adaptation for semantic segmentation. In *CVPR*, pages 1215–1224, 2021. 3
- [39] Mingsheng Long, Yue Cao, Jianmin Wang, and Michael Jordan. Learning transferable features with deep adaptation networks. In *ICML*, pages 97–105, 2015. 2
- [40] Alexander Lyzhov, Yuliya Molchanova, Arsenii Ashukha, Dmitry Molchanov, and Dmitry Vetrov. Greedy policy search: A simple baseline for learnable test-time augmentation. In Jonas Peters and David Sontag, editors, *Conference on Uncertainty in Artificial Intelligence (UAI)*, volume 124 of *Proceedings of Machine Learning Research*, pages 1308–1317. PMLR, 03–06 Aug 2020. 3
- [41] Michael McCloskey and Neal J Cohen. Catastrophic interference in connectionist networks: The sequential learning problem. In *Psychology of learning and motivation*, volume 24, pages 109–165. Elsevier, 1989. 2
- [42] Krikamol Muandet, David Balduzzi, and Bernhard Schölkopf. Domain generalization via invariant feature representation. In *ICML*, pages 10–18. PMLR, 2013. 3
- [43] Chaithanya Kumar Mummadi, Robin Hutmacher, Kilian Rambach, Evgeny Levinkov, Thomas Brox, and Jan Hendrik Metzen. Test-time adaptation to distribution shift by confidence maximization and input transformation. *arXiv preprint arXiv:2106.14999*, 2021. 1, 2, 3, 6
- [44] Sinno Jialin Pan, Ivor W Tsang, James T Kwok, and Qiang Yang. Domain adaptation via transfer component analysis. *IEEE Transactions on Neural Networks*, 22(2):199–210, 2011. 2
- [45] German I Parisi, Ronald Kemker, Jose L Part, Christopher Kanan, and Stefan Wermter. Continual lifelong learning with neural networks: A review. *Neural Networks*, 113:54–71, 2019. 2, 3
- [46] Vishal M Patel, Raghuraman Gopalan, Ruonan Li, and Rama Chellappa. Visual domain adaptation: A survey of recent advances. *IEEE signal processing magazine*, 32(3):53–69, 2015. 2
- [47] Boris T Polyak and Anatoli B Juditsky. Acceleration of stochastic approximation by averaging. *SIAM journal on control and optimization*, 30(4):838–855, 1992. 4, 5
- [48] Viraj Prabhu, Shivam Khare, Deeksha Kartik, and Judy Hoffman. Sentry: Selective entropy optimization via committee consistency for unsupervised domain adaptation. In *ICCV*, pages 8558–8567, 2021. 2
- [49] Sylvestre-Alvise Rebuffi, Alexander Kolesnikov, Georg Sperl, and Christoph H Lampert. icarl: Incremental classifier and representation learning. In *CVPR*, pages 2001–2010, 2017. 3
- [50] Christos Sakaridis, Dengxin Dai, and Luc Van Gool. ACDC: The adverse conditions dataset with correspondences for semantic driving scene understanding. In *ICCV*, October 2021. 1, 6
- [51] Steffen Schneider, Evgenia Rusak, Luisa Eck, Oliver Bringmann, Wieland Brendel, and Matthias Bethge. Improving robustness against common corruptions by covariate shift adaptation. *NeurIPS*, 33, 2020. 7
- [52] Connor Shorten and Taghi M Khoshgohfar. A survey on image data augmentation for deep learning. *Journal of Big Data*, 6(1):1–48, 2019. 3, 5
- [53] Daniel L Silver and Robert E Mercer. The task rehearsal method of life-long learning: Overcoming impoverished data. In *Conference of the Canadian Society for Computational Studies of Intelligence*, pages 90–101. Springer, 2002. 3
- [54] Yu Sun, Xiaolong Wang, Zhuang Liu, John Miller, Alexei Efros, and Moritz Hardt. Test-time training with self-supervision for generalization under distribution shifts. In *ICML*, pages 9229–9248. PMLR, 2020. 3, 4, 5
- [55] Antti Tarvainen and Harri Valpola. Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results. In *NeurIPS*, pages 1195–1204, 2017. 2, 4, 5
- [56] Josh Tobin, Rachel Fong, Alex Ray, Jonas Schneider, Wojciech Zaremba, and Pieter Abbeel. Domain randomization for transferring deep neural networks from simulation to the real world. In *IROS*, pages 23–30. IEEE, 2017. 3
- [57] Jonathan Tremblay, Aayush Prakash, David Acuna, Mark Brophy, Varun Jampani, Cem Anil, Thang To, Eric Cameracci, Shaad Boochoon, and Stan Birchfield. Training deep networks with synthetic data: Bridging the reality gap by domain randomization. In *CVPR Workshops*, pages 969–977, 2018. 3
- [58] Y.-H. Tsai, W.-C. Hung, S. Schulter, K. Sohn, M.-H. Yang, and M. Chandraker. Learning to adapt structured output space for semantic segmentation. In *CVPR*, 2018. 2
- [59] Riccardo Volpi, Diane Larlus, and Grégory Rogez. Continual adaptation of visual representations via domain randomization and meta-learning. In *CVPR*, pages 4443–4453, 2021. 3

- [60] Dequan Wang, Shaoteng Liu, Sayna Ebrahimi, Evan Shelhamer, and Trevor Darrell. On-target adaptation. *arXiv preprint arXiv:2109.01087*, 2021. 3
- [61] Dequan Wang, Evan Shelhamer, Shaoteng Liu, Bruno Olshausen, and Trevor Darrell. Tent: Fully test-time adaptation by entropy minimization. In *ICLR*, 2021. 1, 2, 3, 4, 6, 7, 8
- [62] Qin Wang, Dengxin Dai, Lukas Hoyer, Luc Van Gool, and Olga Fink. Domain adaptive semantic segmentation with self-supervised depth estimation. In *ICCV*, pages 8515–8525, 2021. 2
- [63] Markus Wulfmeier, Alex Bewley, and Ingmar Posner. Incremental adversarial domain adaptation for continually changing environments. In *ICRA*, pages 4489–4495. IEEE, 2018. 3
- [64] Enze Xie, Wenhai Wang, Zhiding Yu, Anima Anandkumar, Jose M. Alvarez, and Ping Luo. Segformer: Simple and efficient design for semantic segmentation with transformers. In *NeurIPS*, 2021. 6
- [65] Saining Xie, Ross Girshick, Piotr Dollár, Zhuowen Tu, and Kaiming He. Aggregated residual transformations for deep neural networks. In *CVPR*, pages 1492–1500, 2017. 6
- [66] Shiqi Yang, Yaxing Wang, Joost van de Weijer, Luis Herranz, and Shangling Jui. Generalized source-free domain adaptation. In *ICCV*, pages 8978–8987, 2021. 2
- [67] Yanchao Yang and Stefano Soatto. Fda: Fourier domain adaptation for semantic segmentation. In *CVPR*, pages 4085–4095, 2020. 2
- [68] Hao-Wei Yeh, Baoyao Yang, Pong C Yuen, and Tatsuya Harada. Sofa: Source-data-free feature alignment for unsupervised domain adaptation. In *WACV*, pages 474–483, 2021. 2
- [69] Dong Yin, Raphael Gontijo Lopes, Jonathon Shlens, Ekin D Cubuk, and Justin Gilmer. A fourier perspective on model robustness in computer vision. *NeurIPS*, 2019. 3
- [70] Fuming You, Jingjing Li, and Zhou Zhao. Test-time batch statistics calibration for covariate shift. *arXiv preprint arXiv:2110.04065*, 2021. 3
- [71] Sergey Zagoruyko and Nikos Komodakis. Wide residual networks. *BMVC*, 2016. 6
- [72] Friedemann Zenke, Ben Poole, and Surya Ganguli. Continual learning through synaptic intelligence. In *International Conference on Machine Learning*, pages 3987–3995. PMLR, 2017. 3
- [73] Marvin Zhang, Sergey Levine, and Chelsea Finn. Memo: Test time robustness via adaptation and augmentation. *arXiv preprint arXiv:2110.09506*, 2021. 3
- [74] Aurick Zhou and Sergey Levine. Training on test data with bayesian adaptation for covariate shift. *arXiv preprint arXiv:2109.12746*, 2021. 3
- [75] Yang Zou, Zhiding Yu, BVK Vijaya Kumar, and Jinsong Wang. Unsupervised domain adaptation for semantic segmentation via class-balanced self-training. In *ECCV*, pages 289–305, 2018. 2