

可控交通仿真的引导式条件扩散

Ziyuan Zhong, Davis Rempe, Danfei Xu, Yuxiao Chen,
Sushant Veer, Tong Che, Baishakhi Ray, and Marco Pavone

摘要——可控且逼真的交通仿真对于开发和验证自动驾驶汽车至关重要。典型的基于启发式的交通模型提供了灵活的控制，使车辆遵循特定轨迹和交通规则。另一方面，数据驱动的方法生成逼真且类人的行为，从而改善从仿真到真实世界交通的迁移。然而，据我们所知，尚无交通模型同时具备可控性和逼真性。在这项工作中，我们开发了一种用于可控交通生成（CTG）的条件扩散模型，允许用户在测试时控制轨迹的期望属性（例如，到达目标或遵循速度限制），同时通过强制动力学保持逼真性和物理可行性。关键的技术思想是利用扩散建模和可微逻辑的最新进展，引导生成的轨迹满足使用信号时序逻辑（STL）定义的规则。我们进一步将引导扩展到多智能体设置，并启用基于交互的规则，如避免碰撞。CTG 在 nuScenes 数据集上针对多样和复合规则进行了广泛评估，展示了在可控性-逼真性权衡方面相对于强基线的改进。

1. 引言

仿真对于全面评估现代自动驾驶汽车（AV）至关重要。由于进行大规模真实世界测试的困难和危险 [1]，自动驾驶开发者依赖在仿真中进行广泛测试以产生可靠的系统 [2]。为了发挥最大效用，仿真器必须同时具备逼真性和可控性，尤其是对于交通模型。逼真的交通使得在仿真中取得的进展能够忠实地迁移到现实世界，而可控性则能够构建细粒度的交通场景以分析特定的自动驾驶行为。然而，开发逼真的交通模型仍然是一个开放的挑战 [3]，[4]，并且很少有人关注使此类模型易于控制。现有的驾驶仿真器通常通过回放记录的驾驶日志或使用基于启发式的控制器来合成智能体行为 [5]–[7]。此类行为通常可以通过用户友好的高级编程进行控制




图 1：概述。可控交通生成（CTG）利用两个关键阶段实现可控仿真。（左）训练条件扩散模型以生成逼真轨迹。（右）引导模型采样使用信号时序逻辑规则以满足期望目标。应用程序编程接口 [5]、[6] 或场景编辑器用户界面 [7]。然而，这些方法缺乏逼真性，因为它们要么无法对其他交通参与者做出反应，要么表达能力不足以呈现类人行为。为解决这些问题，近期研究提出从大规模驾驶数据集中学习交通行为的生成模型 [3]、[4]。尽管这些模型生成的行为看似合理，但它们仅反映训练数据的分布：缺乏控制生成交通流的机制，使得这些方法在实际应用中价值有限。例如，为测试自动驾驶车辆对相邻车道切入的响应，用户需要一个接口来引导车辆执行该操作。遗憾的是，神经网络模型的不透明性使当前方法难以实现这一点。本文旨在通过研究可控交通行为生成问题，弥合逼真性与可控性之间的差距。本文寻求一种模型，能够在推理时根据用户指定的期望目标生成轨迹，这些目标可能不同于训练时使用的目标。这不同于旨在学习最大似然行为的交通模型，因此无法灵活适应新目标。此外，可控生成对基于学习的方法尤为困难，这类方法通常难以生成训练分布之外的样本。为实现这种灵活生成，本文利用扩散建模的最新进展，该技术已在图像 [8]、[9]、音频 [10]–[12] 和行人轨迹 [13] 等多个领域取得最先进的性能。重要的是，扩散模型通过所谓的引导机制在生成时提供控制能力，这已惠及条件图像生成 [9]、语言生成 [14] 和离线强化学习 [15] 等多项任务。受这些工作启发，本文提出一种条件智能体中心扩散模型（图 1），能够灵活地

Ziyuan Zhong 现就职于哥伦比亚大学，本工作完成于其在英伟达（NVIDIA）期间，邮箱：ziyuan.zhong@columbia.com。Davis Rempe 现就职于斯坦福大学，本工作完成于其在英伟达期间，邮箱：drempe@stanford.edu。Danfei Xu 现就职于佐治亚理工学院，同时隶属于英伟达研究院，邮箱：danfei@gatech.edu, danfeix@nvidia.com。Yuxiao Chen、Sushant Veer、Tong Che 现就职于英伟达研究院，邮箱：yuxiaoc, sveer, tongche@nvidia.com。Baishakhi Ray 现就职于哥伦比亚大学，邮箱：rayb@cs.columbia.edu。Marco Pavone 现就职于斯坦福大学，同时隶属于英伟达研究院，邮箱：pavone@stanford.edu, mpavone@nvidia.com。

交通行为生成。与先前用于轨迹的扩散模型 [13]、[15] 不同，本文模型以车辆周围的整体环境为条件，包括局部道路地图和邻近智能体。由于交通具有固有的真实转移函数，我们还在扩散模型状态空间的设计中强制加入真实的车辆动力学，以保证生成的轨迹在物理上可行。为实现可控生成，**Diffuser**[15] 通过用某些可微目标的梯度扰动网络输出，引导扩散模型去噪过程的每一步，以鼓励期望的性质。然而，对于交通仿真，由于时空和多智能体特性，推导和实现诸如避撞、到达目标和道路规则等目标十分复杂。我们提出利用信号时序逻辑（Signal Temporal Logic, STL）[16] 的既有语法。作为一种为指定时空约束而设计的形式语言，STL 允许轻松且可扩展地定义驾驶规则；它还包含鲁棒性概念，用于衡量规则满足程度。具体而言，我们利用可微框架 [17]、[18] 使 STL 与引导兼容，将该规则满足度量作为引导扩散模型的目标函数（图 1 右）。由于我们的扩散模型为场景中每个智能体独立生成轨迹，我们进一步提出针对涉及多智能体交互规则（如无碰撞）的联合引导过程，该过程同时去噪场景中所有智能体，以减轻交互规则违反。我们在 **nuScenes**[19] 驾驶数据集上评估可控交通生成（Controllable Traffic Generation, CTG），展示了在保持真实轨迹生成的同时满足用户约束的能力。总之，本文贡献包括：（1）可控交通生成的问题表述；（2）一种基于条件扩散的方法，用于生成满足物理可行性和用户指定 STL 规则的真实交通；以及

（3）将条件表格生成（CTG）与多个强基线进行广泛评估，证明了其在可控性与真实性权衡方面的优越性。演示可在 <https://aiasd.github.io/ctg.github.io> 找到。

II. 相关工作与背景

A. 交通仿真

交通仿真方法可分为基于规则和基于学习两类。基于规则的方法依赖解析模型，如元胞自动机和智能驾驶员模型 [20]。这些方法通常为车辆设定固定路线，并将智能体的纵向与横向运动分离，因此对行为仿真的表达能力有限。基于学习的方法则基于轨迹数据集模仿真实驾驶行为 [21]–[23]。例如，TrafficSim[3] 使用轨迹预测模型进行场景级交通仿真。BITS[4] 将问题解耦为高层潜变量推断和低层驾驶行为模仿。然而，这些方法均不允许用户在推理时指定生成交通行为的自定义属性。

近期在对抗性或安全关键场景生成方面的工作可视为可控交通仿真的一个实例，即生成使自动驾驶车辆以某种方式出现异常行为的轨迹 [24]。STRIVE[25] 通过在测试时优化已训练轨迹预测模型的潜空间来生成近碰撞场景。Abeyirigoonawardena 等人 [26] 和 Chen 等人 [27] 分别使用贝叶斯优化和强化学习，为特定场景（如交叉路口通行或车道变换）中的车辆生成对抗性轨迹。这些工作专注于对抗性目标，而本文方法具有通用性，可生成满足多种不同目标的轨迹。

B. 扩散建模

可控扩散模型已通过分类器 [9]、无分类器 [28] 和重建 [29] 引导在图像和视频生成中得到探索。Li 等人 [14] 使用带有不同预训练分类器的扩散模型，在不同自然语言任务上引导语言生成。Diffuser[15] 使用扩散模型规划机器人行为（状态-动作轨迹）。Gu 等人 [13] 对行人轨迹进行建模以用于预测。与这些不使用或仅使用有限上下文的工作不同，我们将条件扩散适配为以决策相关信息（如地图和附近智能体的状态）为条件。此外，我们利用已知的车辆动力学模型来确保生成轨迹的物理可行性。Diffuser[15] 还引入了测试时引导，以生成优化给定奖励函数的轨迹。我们基于此公式生成可控交通轨迹，但不同于学习奖励函数，我们使用基于 STL 规则的解析损失函数，这些规则对于驾驶应用而言简单且可扩展。

C. 信号时序逻辑（STL）

STL[16] 公式在信号上进行解释， $\tau = s_t, \dots, s_{t+T}$ ，即状态的有序有限序列 $s_i \in \mathbb{R}^n$ 。信号表示系统输出的实值离散时间序列。STL 公式基于以下上下文无关文法递归定义：

$$\phi ::= \top \mid \mu_c \mid \neg\phi \mid \phi \wedge \psi \mid \phi \mathcal{U}_{[a,b]} \psi. \quad (1)$$

该文法定义了一系列表达式，每个表达式由竖线（|）分隔，可用于构造 STL 公式。特别地，公式 ϕ 通过递归选择表达式生成。我们在此简要总结式 (1)，但建议读者参考 Leung 等人 [17]（第 2.2 节）获取 STL 的教学性介绍。STL 公式的核心是形如 $\mu(z) > c$ 的谓词 μ_c ，其中 $c \in \mathbb{R}$ 且 $\mu: \mathbb{R}^n \rightarrow \mathbb{R}$ 为可微函数。这些定义了信号期望的性质/约束。此外， $\top$ 表示真， ϕ 和 ψ 是 STL 公式， $[a, b] \subseteq \mathbb{R}_{\geq 0}$ is a 为时间区间（若省略则假定为 $[0, \infty)$ ）。符号 $\neg$ 表示否定，而其他符号描述如何组合多个公式： $\wedge$ （合取/与）和 $\mathcal{U}$ （直到），后者是一个时序算子。其他常见逻辑连接词

($\vee$ 析取/或, $\Rightarrow$ 蕴含), 以及时序算子 ($\Diamond$ 最终, $\Box$ 总是) 均可由式 (1) 推导得出。重要的是, 信号时序逻辑包含形式化的鲁棒性概念, 用于度量信号满足或违反公式 [16] 的程度。本文将鲁棒性公式作为所提出的条件扩散模型的引导函数。与 Leung 和 Pavone[30] 专注于单一控制器设定及训练时固定规则不同, 本文考虑一种更灵活的多智能体推理时引导。

三、可控交通生成

接下来, 本文详细介绍所提出的可控交通生成方法。第三节 A 部分对可控交通生成问题进行形式化描述。随后描述该方法的两个阶段。离线阶段训练一个动力学强化的条件扩散模型, 以捕捉真实世界驾驶数据中的多样化行为 (第三节 B 部分)。在线推理阶段, 该方法通过一种新颖的迭代联合信号时序逻辑引导过程对模型进行采样, 生成符合规则的行为 (第三节 C 部分)。条件扩散模型与基于信号时序逻辑的引导相结合, 实现了交通轨迹的真实且可控生成。

A. 问题形式化

对于某个我们希望模拟的目标车辆 (tgt), 令时间步 t 处的状态为 $s_t^{\text{tgt}} = (x_t^{\text{tgt}}, y_t^{\text{tgt}}, v_t^{\text{tgt}}, \theta_t^{\text{tgt}})$, 包括二维位置、速度和航向角。类似地, 令动作 (即控制量) 为 $a_t^{\text{tgt}} = (\ddot{v}_t^{\text{tgt}}, \dot{\theta}_t^{\text{tgt}})$, 包含加速度和横摆角速度。我们将 $\mathbf{c} = (I, S)$ 记为目标智能体的决策相关上下文。该上下文由局部 (以智能体为中心) 语义地图 I 以及目标智能体及其 M 个邻居的 H 个先前状态 $S_{t-H:t} = \{s_{t-H:t}^{\text{tgt}}, s_{t-H:t}^1, \dots, s_{t-H:t}^M\}$ 组成。为获得车辆 m 在时间 $t+1$ 的状态 s_{t+1}^m , 我们假设存在一个转移函数 f , 在给定先前状态 s_t^m 和控制量 a_t^m 的情况下计算 $s_{t+1}^m = f(s_t^m, a_t^m)$ 。我们对 f 采用单轮动力学模型。我们的目标是在给定 (1) 决策上下文 $\mathbf{c}$ 和 (2) 用于衡量状态与动作轨迹规则满足度的函数 $r: \mathbb{R}^{4T} \times \mathbb{R}^{2T} \rightarrow \mathbb{R}$ 的情况下, 为目标智能体生成真实且满足规则的交通行为。模型应在未来 T 个时间步内为目标智能体生成未来轨迹 $s_{t:t+T}^{\text{tgt}}$ 。理想情况下, 该轨迹最大化满足度 $r(s_{t:t+T}^{\text{tgt}}, a_{t:t+T}^{\text{tgt}})$ 以避免违反给定规则。然而, 在许多情况下, 规则满足度与轨迹真实性之间存在固有的权衡: 例如, 若用户希望模拟车辆的速度远低于/高于限速, 这在城市街道背景下自然是不真实的。因此, 我们必须在满足用户指定约束与保持真实行为之间取得平衡。如下文所述, 我们的方法通过首先在真实世界数据上训练一个与规则无关的交通生成模型来捕捉真实性, 然后仅在推理阶段对其进行规则特定合规性引导。

B. 用于交通建模的条件扩散

扩散模型 [8], [31] 将数据生成视为迭代去噪过程, 通过学习逆转前向扩散过程来实现。如图 2 所示, 我们的扩散模型

主要作用于状态和动作的 (未来) 轨迹 [15], 但它是条件化的, 因为在去噪的每一步都接收上下文作为输入。从高斯噪声开始, 扩散模型被迭代应用以预测干净、去噪的状态和动作轨迹。

轨迹表示。在本节中, 我们将模型所作用的 (未来) 轨迹表示为:

$$\tau := \begin{bmatrix} \tau_a \\ \tau_s \end{bmatrix}, \quad \tau_a := [a_0 \dots a_{T-1}], \quad \tau_s := [s_1 \dots s_T].$$

与 [15] 直接联合预测状态和动作不同, 本文模型仅预测动作 τ_a , 并利用已知动力学 f 通过从初始状态 s_0 (包含在历史上下文中) 开始的推演来推断状态 τ_s 。换言之, 在以下表述中, τ_s 始终指由动作产生的状态轨迹, 或更正式地表示为: $\tau_s = f(s_0, \tau_a)$ 。这确保了整个去噪过程中状态轨迹的物理可行性。表述。设 τ_a^k 为第 k th 个扩散步骤处的动作轨迹, 其中 $k=0$ 位于原始干净轨迹处。作用于 τ_a^0 的前向扩散过程定义为:

$$q(\tau_a^{1:K} | \tau_a^0) := \prod_{k=1}^K q(\tau_a^k | \tau_a^{k-1}) \quad (2)$$

$$q(\tau_a^k | \tau_a^{k-1}) := \mathcal{N}(\tau_a^k; \sqrt{1 - \beta_k} \tau_a^{k-1}, \beta_k \mathbf{I}),$$

其中 $\beta_1, \beta_2, \dots, \beta_K$ 是一个固定的方差调度, 用于控制每个扩散步骤注入噪声的尺度。随着噪声逐渐添加, 信号被破坏为各向同性高斯分布。对于轨迹生成, 本文旨在利用学习到的条件去噪模型 (图 2) 逆转该扩散过程, 该模型从采样噪声开始迭代应用。给定上下文信息 $\mathbf{c}$, 逆向扩散过程为:

$$p_\theta(\tau_a^{0:K} | \mathbf{c}) := p(\tau_a^K) \prod_{k=1}^K p_\theta(\tau_a^{k-1} | \tau_a^k, \mathbf{c})$$

$$p_\theta(\tau_a^{k-1} | \tau_a^k, \mathbf{c}) := \mathcal{N}(\tau_a^{k-1}; \mu_\theta(\tau_a^k, k, \mathbf{c}), \Sigma_\theta(\tau_a^k, k, \mathbf{c})), \quad (3)$$

其中 $p(\tau_a^K) = \mathcal{N}(\mathbf{0}, \mathbf{I})$ 且 θ 表示扩散模型的参数。注意, 在每一步中, 模型同时接收动作 τ_a^k 和结果状态 $\tau_s^k = f(s_0, \tau_a^k)$ 作为输入。遵循 [8]、[13], 高斯转移的方差项固定为 $\Sigma^k = \Sigma_\theta(\tau_a^k, k, \mathbf{c}) = \sigma^2 \mathbf{I}$ 。训练。在每次训练迭代中, 从真实世界驾驶数据 $\mathbf{I} = \beta_k \mathbf{I}$ 集中采样上下文 $\mathbf{c}$ 和真实干净轨迹 τ^0 , 并从 $\{1, \dots, K\}$ 中均匀采样去噪步骤 k 。本文通过首先用 β_l

破坏动作轨迹 τ_a^k 为 $\sqrt{\bar{\alpha}_k} \tau_a^0 + \sqrt{1 - \bar{\alpha}_k} \epsilon$, $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ $\bar{\alpha}_k = \prod_{l=1}^k \alpha_l$, 然后计算相应状态 $\tau_s^k = f(s_0, \tau_a^k)$ $\hat{\tau}^0 = [\hat{\tau}_a^0; \hat{\tau}_s^0]$, 从 τ^0 计算噪声输入 $f(s_0, \tau_a^k)$ 。扩散模型通过预测 $1 - \alpha_k$ 未破坏轨迹 $f(s_0, \hat{\tau}_a^0)$ 来间接参数化式 (3) 中的 μ_θ $\hat{\tau}^0 = [\hat{\tau}_a^0; \hat{\tau}_s^0]$, 其中 $\hat{\tau}_a^0(\tau_a^k, k, \mathbf{c})$ 是直接网络输出 (见 [14]、[15]、[32])。最后, 本文使用简化的损失函数来训练模型:

$$L(\theta) = \mathbb{E}_{\epsilon, k, \tau^0, \mathbf{c}} [\|\tau^0 - \hat{\tau}^0\|^2]. \quad (4)$$




图 2: 单次测试时去噪步骤。给定当前含噪动作和状态以及编码后的上下文, 扩散模型预测下一步分布的均值, 然后根据期望的引导函数进行扰动。

注意, 动作和状态轨迹均受此损失监督, 因为本文发现额外的状态轨迹信息能提升生成质量。

实现细节。 包含以智能体为中心的地图信息和历史轨迹的输入上下文 $\mathbf{c}$ 以栅格化格式表示。该上下文在传入扩散模型之前, 先由 ResNet [33] 编码器 $\mathcal{F}_\theta$ 处理。与 Diffuser [15] 类似, 我们采用类似 U-Net 的扩散模型架构, 其中包含对输入轨迹进行时间一维卷积的多个块。我们通过首先与扩散步输入 k 拼接, 然后将该条件特征添加到 U-Net 每个块的卷积特征中, 来融入条件信息。所有实验的扩散过程均采用余弦方差调度 [15]、[32] 和 $K = 100$ 个扩散步骤。

C. 基于信号时序逻辑 (STL) 的引导生成

为了对训练好的扩散模型生成的逼真样本施加期望的规则约束, 我们引入一种迭代引导算法, 其规则以 STL 公式指定。

条件引导公式。 Diffuser [15] 引入了引导的概念, 用于从无条件扩散模型中采样轨迹以满足某些预定义目标。我们可以通过定义一个二元随机变量 $\mathcal{O}$ 来对条件扩散模型做同样的事情, 该变量指示轨迹是否最优, 其中

$p(\mathcal{O} = 1) = \exp(r(\tau_s, \tau_a))$ 基于规则满足“奖励” r 。为了近似地从最优轨迹分布中采样, 去噪过程的步骤可以修改为 [15]、[31]:

$$p_\theta(\tau_a^{k-1} | \tau^k, \mathbf{c}, \mathcal{O}) \approx \mathcal{N}(\tau_a^{k-1}; \mu + \Sigma g, \Sigma), \quad (5)$$

其中 $\mu = \mu_\theta$, $\Sigma = \Sigma_\theta$ 如公式 (3) 所示, 添加的梯度由基于满足度的引导器 $\mathcal{J}$ 计算得出:

$$g = \nabla \mathcal{J}(\mu) = \nabla_\mu r(f(s_0, \mu), \mu). \quad (6)$$

利用指定目标的梯度来扰动扩散模型预测均值的过程

Algorithm 1 Guided Sampling

```

1: Require encoder  $\mathcal{F}_\theta$ , conditional diffusion model  $\mu_\theta$ , transition function  $f$ , guide  $\mathcal{J}$ , scale  $\alpha$ , covariances  $\Sigma^k$ , diffusion steps  $K$ , inner gradient descent steps  $M$ , number of actions to take before re-planning  $l$ .
2: while not done do
3:   Observe state  $s_0$  and context  $\mathbf{c}$ 
4:   Initialize trajectory  $\tau_a^K \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ ;  $\tau_s^K = f(s_0, \tau_a^K)$ ;  $\tau^K = [\tau_a^K; \tau_s^K]$ 

5:   for  $k = K, \dots, 1$  do
6:      $\mu = \mu_\theta(\tau^k, k, \mathcal{F}_\theta(\mathbf{c}))$ 
7:      $\mu^{(0)} = \mu$ 
8:     for  $j = 1, \dots, M$  do
9:        $\mu^{(j)} = \mu^{(j-1)} + \alpha \nabla \mathcal{J}(\mu^{(j-1)})$ 
10:       $\Delta\mu = |\mu^{(j)} - \mu^{(0)}|$ ;  $\Delta\mu \leftarrow \text{clip}(\Delta\mu, -\beta_k, \beta_k)$ 
11:       $\mu^{(j)} \leftarrow \mu^{(0)} + \Delta\mu$ 
12:       $\tau^{k-1} \sim \mathcal{N}(\mu^{(M)}, \Sigma^k)$ ;  $\tau_s^{k-1} = f(s_0, \tau_a^{k-1})$ ;
13:       $\tau^{k-1} = [\tau_a^{k-1}; \tau_s^{k-1}]$ 
13:   Execute first  $l$  actions of trajectory  $\tau_a^0$ 

```

总结在算法 1 中。与 Diffuser [15] 不同, 本文采用带裁剪的迭代内部梯度下降, 并使用 Adam 优化器, 而非单步梯度更新。这为通过调整学习率和优化步数来权衡规则符合性与真实性提供了灵活性。在实际生成未来轨迹时, 我们从扩散模型中引导多个样本, 并在去噪结束时根据 $\mathcal{J}$ 选择规则满足度最佳的样本。我们将此称为过滤。

STL 作为引导。 与先前工作 [14]、[15] 中为 $\mathcal{J}$ 训练分类器或奖励函数不同, 本文的引导函数基于 STL 解析实现。对于希望通过引导施加的每条规则, 使用式 (1) 中的语法生成相应的 STL 公式, 描述轨迹应如何被约束。表 I 展示了所使用的各种 STL 规则示例; 注意, 尽管这些公式描述的行为复杂, 但公式本身相对简单。根据构造, 每个 STL 公式都对应一个鲁棒性公式, 用于度量规则满足程度, 该鲁棒性公式被用作引导 $\mathcal{J}$ 。由于需要通过该函数计算梯度, STL 公式使用可微框架 [17]、[18] 实现。

多智能体引导。 一个特别的挑战是应用涉及多个智能体的场景级规则 (例如, 无碰撞)。为此, 引导采样以批处理方式对同一场景中的所有智能体同时进行。这样可以在所有轨迹上计算引导, 并将相应的梯度收集起来, 根据需要传播回各个智能体。

交通仿真。 为了对包含多个智能体的场景进行闭环交通仿真, 在标准控制循环中对每个智能体使用相同的模型: 在仿真的每一步, 从模型生成一个引导样本, 并在规定的频率下重新规划之前执行前几个动作。在所有实验 (第 IV 节) 中, 每个场景从真实驾驶日志开始推演 20 秒, 重规划频率为 2 Hz, 与 [4] 一致。

IV. 实验

本文进行实验以验证: (1) CTG 能够生成满足用户指定规则的可控交通行为; (2) 与强基线相比, CTG 在保持真实性的同时实现了更好的规则满足度。

表一：规则定义。对于每条规则，展示了信号时序逻辑公式及用于评估的相应度量。

Rule	STL Formula	Evaluation Metric
speed limit	$\phi_{\text{speedlimit}} := \bigwedge_i \Box (v_{i,t} - v_{\text{limit}_i}) < \epsilon$	$h_{\text{speedlimit}} := \sum_i \sum_t \max(0, v_{i,t} - v_{\text{limit}_i})$
target speed	$\phi_{\text{targetspeed}} := \bigwedge_{i,t} v_{i,t} - v_{\text{target}_{i,t}} < \epsilon$	$h_{\text{targetspeed}} := \sum_i \sum_t v_{i,t} - v_{\text{target}_{i,t}} $
no collision	$\phi_{\text{collision}} := \Box \bigwedge_{i \neq j} (x_{i,t}, y_{i,t}) - (x_{j,t}, y_{j,t}) > \epsilon$	$h_{\text{collision}} := \sum_{i \neq j} \mathbb{I}[(x_{i,t}, y_{i,t}) - (x_{j,t}, y_{j,t}) \leq \epsilon]$
no off-road	$\phi_{\text{offroad}} := \bigwedge_{i,w} \Box (x_{i,t}, y_{i,t}) - (x_{\text{off-road}_w}, y_{\text{off-road}_w}) > \epsilon$	$h_{\text{offroad}} := \sum_i \mathbb{I}[\min_w (x_{i,t}, y_{i,t}) - (x_{\text{off-road}_w}, y_{\text{off-road}_w}) \leq \epsilon]$
goal waypoint	$\phi_{\text{waypoint}} := \bigwedge_i \Diamond (x_{i,t}, y_{i,t}) - (x_{\text{goal}_i}, y_{\text{goal}_i}) < \epsilon$	$h_{\text{waypoint}} := \sum_i \min_t (x_{i,t}, y_{i,t}) - (x_{\text{goal}_i}, y_{\text{goal}_i}) $
stop sign	$\phi_{\text{stopsign}} := \bigwedge_i \Box (\phi_i \text{ in stop region} \Rightarrow \Diamond_{[0,m]} (\phi_i \text{ in stop region} \wedge \phi_{\text{stop}}))$	$h_{\text{stopsign}} := \sum_i \min_{i \text{ in stop region}} v_{i,t} $
stop sign + no off-road	$\phi_{\text{stopsign}} \wedge \phi_{\text{offroad}}$	$h_{\text{stopsign}}, h_{\text{offroad}}$
goal waypoint + target speed	$\phi_{\text{waypoint}} \wedge \phi_{\text{targetspeed}}$	$h_{\text{waypoint}}, h_{\text{targetspeed}}$

表二：定量结果（单规则）。每个度量下表现最好的两种方法被突出显示。

	speed limit			target speed			no collision			no off-road			goal waypoint		
	rule	real	fail	rule	real	fail	rule	real	fail	rule	real	fail	rule	real	fail
SimNet	0.739	0.898	0.353	1.989	0.898	0.353	0.137	0.898	0.353	0.453	0.900	0.353	7.543	0.900	0.353
SimNet+opt	0.038	0.770	0.470	0.630	1.234	0.593	0.045	1.149	0.398	0.427	1.242	0.416	1.947	1.162	0.467
TrafficSim	0.737	1.362	0.443	1.922	1.346	0.440	0.140	1.542	0.416	0.485	1.564	0.401	7.733	1.574	0.458
TrafficSim+opt	0.042	1.444	0.325	0.610	1.634	0.404	0.075	1.063	0.265	0.423	1.836	0.413	2.414	1.766	0.532
BITS	0.188	1.068	0.256	1.054	0.968	0.246	0.038	1.220	0.314	0.432	1.131	0.296	4.493	1.152	0.332
BITS+opt	0.033	1.190	0.487	0.681	1.434	0.542	0.028	1.617	0.354	0.435	1.261	0.343	1.533	1.280	0.442
CTG (w/o f+g)	1.380	0.396	0.301	2.662	0.396	0.301	0.172	0.396	0.301	0.369	0.396	0.301	7.052	0.396	0.301
CTG	0.019	0.359	0.165	0.150	0.855	0.179	0.040	0.569	0.271	0.341	0.501	0.455	1.943	0.564	0.387

表三：定量结果（多规则）。

	stop sign + no off-road				goal waypoint + target speed			
	rule1	rule2	real	fail	rule1	rule2	real	fail
SimNet	2.282	0.454	0.898	0.353	3.803	1.610	0.898	0.353
SimNet+opt	1.527	0.480	0.796	0.443	3.238	0.980	1.189	0.659
TrafficSim	2.670	0.484	1.605	0.409	1.583	4.544	1.369	0.450
TrafficSim+opt	0.849	0.405	1.577	0.281	2.817	0.995	1.398	0.529
BITS	2.023	0.434	1.032	0.254	2.677	1.077	0.919	0.286
BITS+opt	1.299	0.471	1.083	0.399	3.171	1.019	1.455	0.601
CTG (w/o f+g)	2.573	0.369	0.396	0.301	3.868	2.202	0.396	0.301
CTG	0.528	0.338	0.288	0.326	1.205	0.231	0.738	0.329

如第三节-A 部分所述，真实性与规则合规性之间通常存在权衡；理想的方法应取得合理的平衡，并在两方面都表现良好。在描述实验设计（第四节-A 部分）之后，我们在单规则（第四节-B 部分）和多规则（第四节-C 部分）设置下与基线方法进行定量和定性比较，最后进行消融实验（第四节-D 部分）。

A. 实验设置

数据集。nuScenes [19] 是一个大规模真实世界驾驶数据集，包含两个城市中 5.5 小时的高精度轨迹，场景多样且交通密集。我们在训练集场景上训练所有模型，并在从验证集随机抽取的 100 个场景上进行评估。在当前工作中，我们仅关注车辆仿真，将其他类型（如行人、骑行者）留待未来工作。

度量。我们的评估侧重于可控性、真实感和稳定性（即避免碰撞和偏离道路）。我们考虑规则特定的违规度量（规则），详见表一，以评估可控性。度量针对每个场景计算（ i 表示场景中的每辆车），然后在所有测试场景上取平均。为评估真实感，我们遵循 [4] 并比较生成的交通仿真与数据集中真实轨迹之间的数据统计。该比较通过仿真轨迹与记录轨迹的驾驶特征归一化直方图之间的 Wasserstein 距离计算。我们定义一个聚合度量——真实感偏差（真实）——作为来自 [4] 的三个属性的真实感均值：纵向

加速度幅值、横向加速度幅值和急动度。我们进一步提供失败率（失败）来评估生成轨迹的稳定性。该指标衡量场景中经历严重失败（即碰撞或偏离道路）的智能体平均比例。

基线。由于没有关于规则合规交通生成的同类工作，我们通过添加测试时优化来增强最先进的交通仿真模型，以满足指定规则。为了公平比较，该优化使用与 CTG 中引导相同的损失函数。**SimNet** [34] 是一个确定性行为克隆模型。我们对其输出动作轨迹应用优化（**SimNet+opt**）。**TrafficSim** [3] 是一种基于 CVAE 的轨迹生成方法。我们考虑一个使用我们损失函数的带过滤变体（**TrafficSim**），以及另一个同时具有过滤和潜空间优化的变体（**TrafficSim+opt**）。BITS [4] 是一个双层模仿学习模型，我们调整其采样排序函数以使用我们的损失函数（BITS）。我们还使用一个对输出动作轨迹进行优化的变体（**BITS+opt**）。最后，我们与没有过滤和引导的 CTG（CTG w/o f+g）进行比较，即扩散模型的随机样本。

B. 单规则评估

我们首先评估各方法满足单一指定规则的能力，这对于交通场景编辑等应用至关重要。我们应用表 I 中制定的五条 STL 规则：速度限制、目标速度、目标航点、无碰撞和禁止驶离道路。对于需要设置特定参数的规则（例如目标航点位置），我们根据数据集中的真实日志选择合理值，以避免设置分布外值（例如偏离道路的航点）。

速度极限。车辆不应超过速度极限阈值。由于数据集中未提供每条道路的速度极限，本文将每个场景的极限设定为该场景中所有移动车辆速度的 75% 分位数。

目标速度。车辆应在每个时间步遵循指定速度。对于每辆车，速度设定为




图 3：目标速度 (a) - (c) 与目标航点 (d) - (f) 规则结果。规则违反情况在括号中（分别为 m/s 和 m ）。

其速度与地面真实场景中的情况相似，类似于交通拥堵。

目标航点。车辆应在未来任意时刻到达指定航点。本文将航点设定为每辆车沿真实数据轨迹 15 秒处的位置。由于采样轨迹常与数据集存在较大偏差，因此命中真实数据中的航点并非易事。

无碰撞。车辆之间不应发生碰撞。

不驶离道路。车辆不应离开可行驶区域。定量结果见表二。总体而言，CTG 在规则违反、真实度偏差和失败率方面均低于基线方法。在全部五种设置中，CTG 在其中三种设置下规则违反最低，其余设置下也具有竞争力。在真实度偏差和失败率方面，CTG 通常位列前二。图 3 展示了目标速度和航点规则的定性结果。与目标速度方面最强的基线 TrafficSim+opt 和 BC+opt 相比，CTG 使用更真实的轨迹实现了最低的规则违反。对于航点示例，尽管 BC+opt 在规则满足方面优于 CTG，但 BC+opt 和 BITS+opt 均预测出弯曲且不真实的轨迹，导致多次碰撞。

C. 多规则评估

停车标志与不驶离道路。车辆在进入停车标志区域时应停车，且不得驶离道路。该规则的表达式（表一）相对复杂，使用了“蕴含”和“最终”算子，使其成为检验本文基于 STL 方法的良好测试。停车区域为 20×20 米的方框，其中心设定在真实数据轨迹 5 秒处。

目标航点与目标速度。车辆应按照指定的目标速度到达其目标。航点沿真实轨迹每 10 秒设置一次，每个时间步的目标速度与真实场景相同。该设置类似于自动驾驶测试中的“反应式回放”用例，用户利用交通模型重建驾驶日志，使智能体能够对自动驾驶行为或环境的任何后续变化做出真实反应。结果见表 III。对于两种设置，CTG

表四：CTG 特征的消融实验：dyn（动力学强制）、f（过滤）、g（引导）、a（优化后的动作轨迹）以及 op（内部优化步数）。

dyn	Features				Loss action only?	Metrics		
	f	g	a	op		rule	real	fail
✓	✓	✓		1		0.0189	0.3588	0.1647
✓				1		1.3802	0.3964	0.3011
✓		✓		1		0.0387	0.4336	0.2227
✓	✓			1		1.3268	0.3869	0.2942
✓		✓	✓	1		0.019	0.447	0.1879
✓	✓	✓	✓	1		0.0132	0.4431	0.1845
✓	✓		✓	1		0.0329	0.4591	0.1881
✓			✓	1		0.0819	0.4339	0.2117
✓	✓	✓		3		0.0158	0.4591	0.2017
✓	✓	✓		5		0.0156	0.456	0.1966
✓	✓	✓		1	✓	0.018	0.2057	0.2824
	✓	✓		1		0.0525	3.4204	0.612
		✓		1		1.2797	3.3251	0.7523

变体达到了最低的两项规则违反率和真实感偏差，仅失败率略高。

D. 消融实验

为分析设计选择，我们在速度限制规则设置下进行了消融实验。结果展示于

表 IV 中，首行为本文提出的 CTG 版本。第一部分比较了引导 (g) 与筛选 (f) 的不同组合。无引导时，规则违反显著增加。筛选与引导结合使用时比单独使用更有效，因为它能从多个已引导的样本中挑选出最佳者，这些样本对规则的满足程度可能各不相同。在表的下一部分，评估了采用额外输出动作优化 (a) 的变体。用优化替代引导在所有度量上表现更差，而将引导与优化结合则降低了规则违反，但代价是更高的真实感偏差和失败率。接着，在引导中使用了更多的内部优化步数 (op)，改善了规则违反，但真实感和失败率变差。最后，在底部部分，我们评估了一个仅监督动作轨迹的变体，以及未强制单轮车动力学 (dyn) 的变体。仅监督动作（而非状态和动作）能产生更忠实的加速度，从而降低真实感偏差，但缺少状态监督的正则化时失败更频繁。此外，我们发现使用单轮车模型强制动力学至关重要：没有它，所有度量都会恶化。

五、结论

本文提出了可控交通生成 (Controllable Traffic Generation, CTG)，一种用于可控交通仿真任务的条件扩散模型，开辟了若干令人振奋的未来研究方向。目前，本文仅将可控交通生成用于车辆建模，但骑行者和行人同样是自动驾驶交互仿真中需要模拟的重要智能体。此外，利用碰撞与越界引导实现超长时程、鲁棒的交通仿真是一项重要应用。在自动驾驶之外，所提出的引导框架有望惠及众多任务，这些任务中处于回路内的学习模型必须具有反应性并能在线遵循新颖目标。

致谢。作者感谢奥尔·利塔尼 (Or Litany)、桑娅·菲德勒 (Sanja Fidler) 和卡伦·梁 (Karen Leung) 提出的宝贵讨论与反馈。

参考文献

- [1] N. Kalra and S. M. Paddock, *Driving to Safety: How Many Miles of Driving Would It Take to Demonstrate Autonomous Vehicle Reliability?* RAND Corporation, 2016. [Online]. Available: <http://www.jstor.org/stable/10.7249/j.ctt1btc0xw>
- [2] Waymo, “Waymo safety report,” <https://storage.googleapis.com/waymo-uploads/files/documents/safety/2021-03-waymo-safety-report.pdf>, February 2021.
- [3] S. Suo, S. Regalado, S. Casas, and R. Urtasun, “TrafficSim: Learning to simulate realistic multi-agent behaviors,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2021, pp. 10 400–10 409.
- [4] D. Xu, Y. Chen, B. Ivanovic, and M. Pavone, “Bits: Bi-level imitation for traffic simulation,” 2022.
- [5] P. A. Lopez, M. Behrisch, L. Bieker-Walz, J. Erdmann, Y.-P. Flötteröd, R. Hilbrich, L. Lücken, J. Rummel, P. Wagner, and E. Wiessner, “Microscopic traffic simulation using sumo,” in *2018 21st International Conference on Intelligent Transportation Systems (ITSC)*, 2018, pp. 2575–2582.
- [6] A. Dosovitskiy, G. Ros, F. Codevilla, A. Lopez, and V. Koltun, “CARLA: An open urban driving simulator,” ser. Proceedings of Machine Learning Research, S. Levine, V. Vanhoucke, and K. Goldberg, Eds., vol. 78, 13–15 Nov 2017, pp. 1–16. [Online]. Available: <http://proceedings.mlr.press/v78/dosovitskiy17a.html>
- [7] LG Electronics, “SVL Simulator: An Autonomous Vehicle Simulator, A ROS/ROS2 Multi-robot Simulator for Autonomous Vehicles,” <https://github.com/lgsvl/simulator>, 2021.
- [8] J. Ho, A. Jain, and P. Abbeel, “Denoising diffusion probabilistic models,” in *Advances in Neural Information Processing Systems*, H. Larochelle, M. Ranzato, R. Hadsell, M. Balcan, and H. Lin, Eds., vol. 33. Curran Associates, Inc., 2020, pp. 6840–6851.
- [9] P. Dhariwal and A. Nichol, “Diffusion models beat gans on image synthesis,” *Advances in Neural Information Processing Systems*, vol. 34, pp. 8780–8794, 2021.
- [10] N. Chen, Y. Zhang, H. Zen, R. J. Weiss, M. Norouzi, and W. Chan, “Wavegrad: Estimating gradients for waveform generation,” in *International Conference on Learning Representations*, 2021.
- [11] Z. Kong, W. Ping, J. Huang, K. Zhao, and B. Catanzaro, “Diffwave: A versatile diffusion model for audio synthesis,” in *International Conference on Learning Representations*, 2021.
- [12] V. Popov, I. Vovk, V. Gogoryan, T. Sadekova, and M. Kudinov, “GradTTS: A diffusion probabilistic model for text-to-speech,” in *Proceedings of the 38th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 139. PMLR, 18–24 Jul 2021, pp. 8599–8608.
- [13] T. Gu, G. Chen, J. Li, C. Lin, Y. Rao, J. Zhou, and J. Lu, “Stochastic trajectory prediction via motion indeterminacy diffusion,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2022, pp. 17 113–17 122.
- [14] X. L. Li, J. Thickstun, I. Gulrajani, P. Liang, and T. B. Hashimoto, “Diffusion-lm improves controllable text generation,” 2022.
- [15] M. Janner, Y. Du, J. B. Tenenbaum, and S. Levine, “Planning with diffusion for flexible behavior synthesis,” in *International Conference on Machine Learning*, 2022.
- [16] O. Maler and D. Nickovic, “Monitoring temporal properties of continuous signals,” in *Formal Techniques, Modelling and Analysis of Timed and Fault-Tolerant Systems*, Y. Lakhnech and S. Yovine, Eds. Berlin, Heidelberg: Springer Berlin Heidelberg, 2004, pp. 152–166.
- [17] K. Leung, N. Aréchiga, and M. Pavone, “Backpropagation through signal temporal logic specifications: Infusing logical structure into gradient-based methods,” *The International Journal of Robotics Research*.
- [18] A. Paszke et. al, “Pytorch: An imperative style, high-performance deep learning library,” in *Advances in Neural Information Processing Systems* 32, 2019, pp. 8024–8035.
- [19] H. Caesar, V. Bankiti, A. H. Lang, S. Vora, V. E. Liong, Q. Xu, A. Krishnan, Y. Pan, G. Baldan, and O. Beijbom, “nuscenes: A multimodal dataset for autonomous driving,” in *CVPR*, 2020.
- [20] E. Brockfeld, R. D. Kühne, A. Skabardonis, and P. Wagner, “Toward benchmarking of microscopic traffic flow models,” *Transportation Research Record*, vol. 1852, no. 1, pp. 124–129, 2003.
- [22] Y. Chen, B. Ivanovic, and M. Pavone, “Scept: Scene-consistent, policy-based trajectory predictions for planning,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2022, pp. 17 103–17 112.
- [23] T. Salzmann, B. Ivanovic, P. Chakravarty, and M. Pavone, “Trajectory++: Dynamically-feasible trajectory forecasting with heterogeneous data,” in *Computer Vision—ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XVIII* 16. Springer, 2020, pp. 683–700.
- [24] J. Wang, A. Pun, J. Tu, S. Manivasagam, A. Sadat, S. Casas, M. Ren, and R. Urtasun, “AdvSim: Generating safety-critical scenarios for self-driving vehicles,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2021, pp. 9909–9918.
- [25] D. Rempe, J. Pailion, L. J. Guibas, S. Fidler, and O. Litany, “Generating useful accident-prone driving scenarios via a learned traffic prior,” in *Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022.
- [26] Y. Abeyirigoonawardena, F. Shkurti, and G. Dudek, “Generating adversarial driving scenarios in high-fidelity simulators,” in *2019 International Conference on Robotics and Automation (ICRA)*, 2019, pp. 8271–8277.
- [27] B. Chen, X. Chen, Q. Wu, and L. Li, “Adversarial evaluation of autonomous vehicles in lane-change scenarios,” *IEEE Transactions on Intelligent Transportation Systems*, pp. 1–10, 2021.
- [28] J. Ho and T. Salimans, “Classifier-free diffusion guidance,” *arXiv preprint arXiv:2207.12598*, 2022.
- [29] J. Ho, T. Salimans, A. Gritsenko, W. Chan, M. Norouzi, and D. J. Fleet, “Video diffusion models,” *arXiv preprint arXiv:2204.03458*, 2022.
- [30] K. Leung and M. Pavone, “Semi-supervised trajectory-feedback controller synthesis for signal temporal logic specifications,” 2022.
- [31] J. Sohl-Dickstein, E. Weiss, N. Maheswaranathan, and S. Ganguli, “Deep unsupervised learning using nonequilibrium thermodynamics,” in *Proceedings of the 32nd International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, F. Bach and D. Blei, Eds., vol. 37. Lille, France: PMLR, 07–09 Jul 2015, pp. 2256–2265.
- [32] A. Q. Nichol and P. Dhariwal, “Improved denoising diffusion probabilistic models,” in *International Conference on Machine Learning*. PMLR, 2021, pp. 8162–8171.
- [33] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 770–778.
- [34] L. Bergamini, Y. Ye, O. Scheel, L. Chen, C. Hu, L. Del Pero, B. Osinski, H. Grimmet, and P. Ondruska, “Simnet: Learning reactive self-driving simulations from real-world observations,” in *2021 IEEE International Conference on Robotics and Automation (ICRA)*, 2021.