

DayDreamer: 面向物理机器人学习的世界模型


Philipp Wu* Alejandro Escontrela* Danijar Hafner*

Ken Goldberg Pieter Abbeel

University of California, Berkeley

*Equal contribution

摘要：为了在复杂环境中解决任务，机器人需要从经验中学习。深度强化学习是机器人学习的常用方法，但需要大量的试错才能学会，这限制了其在物理世界中的部署。因此，机器人学习的许多进展依赖于模拟器。另一方面，在模拟器中学习无法捕捉真实世界的复杂性，容易受到模拟器不准确性的影响，并且产生的行为无法适应世界的变化。Dreamer 算法最近展示了通过在学习的世界模型内进行规划，从少量交互中学习的巨大潜力，在视频游戏中超越了纯强化学习。学习一个世界模型来预测潜在动作的结果，使得能够在想象中进行规划，从而减少在真实环境中所需的试错次数。然而，Dreamer 是否能够促进物理机器人更快地学习尚不清楚。在本文中，我们将 Dreamer 应用于 4 个机器人，直接在真实世界中在线学习，不使用任何模拟器。Dreamer 训练一个四足机器人从零开始、无需重置地在仅 1 小时内学会翻身、站立和行走。随后我们推动机器人，发现 Dreamer 在 10 分钟内适应扰动或快速翻身并重新站立。在两个不同的机械臂上，Dreamer 直接从相机图像和稀疏奖励中学会拾取和放置多个物体，接近人类表现。在一个轮式机器人上，Dreamer 纯粹从相机图像中学会导航到目标位置，自动解决机器人朝向的歧义。在所有实验中使用相同的超参数，我们发现 Dreamer 能够在真实世界中进行在线学习，这建立了一个强大的基线。我们发布了基础设施，以供未来将世界模型应用于机器人学习。视频可在项目网站上获取：
<https://danijar.com/daydreamer>



(a) A1 Quadruped Walking (b) UR5 Visual Pick Place (c) XArm Visual Pick Place (d) Sphero Navigation

图 1：为研究“梦想家”（Dreamer）在样本高效机器人学习中的适用性，本文将算法应用于 4 台真实机器人，在无仿真器条件下从零开始学习机器人运动、操作和导航任务。这些任务评估了多种挑战，包括连续与离散动作、稠密与稀疏奖励、本体感觉与相机输入，以及多输入模态的传感器融合。所有实验使用相同超参数均成功学习，“梦想家”为真实世界机器人学习建立了强大的基线。

1 引言

教机器人在真实世界中解决复杂任务是机器人研究的基础问题。深度强化学习 (RL) 提供了一种流行的机器人学习方法, 使机器人能够通过试错随时间改进其行为。然而, 当前算法需要与环境进行过多交互才能学习到成功行为, 这使得它们在许多真实世界任务中不切实际。近年来, 现代世界模型在模拟领域和视频游戏中展现出数据高效学习的巨大潜力 (哈夫纳等人, 2019; 2020)。从过去经验中学习世界模型使机器人能够想象潜在动作的未来结果, 从而减少在真实环境中学习成功行为所需的试错次数。

尽管学习精确的世界模型 (World Model) 具有挑战性, 但它们为机器人学习提供了引人注目的特性。通过预测未来结果, 世界模型允许仅基于少量真实世界交互进行规划与行为学习 (Gal 等, 2016; Ebert 等, 2018)。此外, 世界模型总结了关于环境的一般动力学知识, 一旦习得, 便可复用于广泛的下游任务 (Sekar 等, 2020)。世界模型还学习融合多种传感器模态并将其整合到潜状态中的表示, 从而消除了手动状态估计的需要。最后, 世界模型能够从可用的离线数据中良好泛化 (Yu 等, 2021), 这可以进一步加速真实世界中的学习。

尽管世界模型前景广阔, 但为真实世界学习精确的世界模型仍是一个重大的开放挑战。本文利用 Dreamer 世界模型的最新进展, 在最直接且基础的问题设定中训练多种机器人: 真实世界中的在线强化学习, 不使用模拟器或演示。如图 2 所示, Dreamer 从过去经验的回放缓冲区中学习世界模型, 从世界模型潜空间中想象的轨迹中学习行为, 并持续与环境交互以探索和改进其行为。我们的目标是直接推动真实世界中机器人学习的极限, 并提供一个稳健的平台, 以支持未来工作开发世界模型对机器人学习的益处。本文的关键贡献总结如下:

- **机器人上的 Dreamer** 我们将 Dreamer 应用于 4 个机器人, 展示了无需引入新算法即可在现实世界中直接成功学习。这些任务涵盖了一系列挑战, 包括不同的动作空间、感官模态和奖励结构。
- **1 小时内学会行走** 我们在现实世界中从零开始教一只四足机器人翻身、站立和行走, 仅用 1 小时。之后, 我们发现机器人在 10 分钟内适应了被推动的情况, 学会了承受推力或快速翻身并重新站起来。
- **视觉抓取与放置** 我们训练机械臂从稀疏奖励中学习抓取和放置物体, 这需要从像素中定位物体并将图像与本体感觉输入融合。学习到的行为优于无模型智能体, 并接近人类表现。
- **开源** 我们公开了所有实验的软件基础设施, 支持不同的动作空间和感官模态, 为未来在现实世界中进行机器人学习的世界模型研究提供了一个灵活的平台。




图 2: “梦想家”遵循一条简单的流程, 在无仿真器的机器人硬件上进行在线学习。当前学习到的策略在机器人上收集经验。这些经验被添加到回放缓冲区中。世界模型通过监督学习在回放的离线策略序列上进行训练。演员-评论家算法从世界模型潜空间中的想象轨迹优化神经网络策略。本文将数据收集与神经网络学习并行化, 使学习步骤在机器人移动时也能持续进行, 并实现低延迟动作计算。




图 3：神经网络训练 我们利用 Dreamer 算法 (Hafner 等人, 2019; 2020) 在现实世界中实现快速机器人学习。Dreamer 由两个神经网络组件组成。左：世界模型遵循深度卡尔曼滤波器的结构，在从回放缓冲区中抽取的子序列上进行训练。编码器将所有感官模态融合为离散编码。解码器从编码中重建输入，提供丰富的学习信号，并支持人工检查模型预测。循环状态空间模型 (RSSM) 被训练为在给定动作的情况下预测未来编码，而无需观察中间输入。右：世界模型通过在紧凑的潜空间中使用大批量进行想象 rollout，实现了大规模并行的策略优化，而无需重建感官输入。Dreamer 从想象 rollout 和学习的奖励函数中训练策略网络和价值网络。

2 方法

我们利用梦想家算法 (Dreamer Algorithm, Hafner 等人, 2019; 2020) 在物理机器人上进行在线学习，无需模拟器。本节概述了通用算法，以及机器人实验所需的训练架构和传感器融合细节。图 2 展示了该方法的概览。梦想家算法从过去经验的回放缓冲区中学习世界模型，使用演员-评论家算法从学习模型预测的轨迹中学习行为，并在环境中部署其行为以持续扩充回放缓冲区。我们将学习更新与数据收集解耦，以满足延迟要求，并实现快速训练而无需等待环境。在我们的实现中，一个学习线程持续训练世界模型和演员-评论家行为，而一个演员线程并行计算用于环境交互的动作。

世界模型学习 世界模型是一个深度神经网络，学习预测环境动态，如图 3 (左) 所示。由于感官输入可能是大图像，我们预测未来表示而非未来输入。这减少了累积误差，并支持使用大批量进行大规模并行训练。因此，世界模型可以被视为环境的一个快速模拟器，机器人从空白状态开始自主学习，并在探索真实世界的过程中不断改进其模型。世界模型基于循环状态空间模型 (Recurrent State-Space Model, RSSM; Hafner 等人, 2018)，由四个组件组成：

$$\begin{aligned}
 \text{Encoder Network:} \quad & \text{enc}_{\theta}(s_t \mid s_{t-1}, a_{t-1}, x_t) & \text{Decoder Network:} \quad & \text{dec}_{\theta}(s_t) \approx x_t \\
 \text{Dynamics Network:} \quad & \text{dyn}_{\theta}(s_t \mid s_{t-1}, a_{t-1}) & \text{Reward Network:} \quad & \text{rew}_{\theta}(s_{t+1}) \approx r_t
 \end{aligned} \tag{1}$$

物理机器人通常配备多种不同模态的传感器，例如本体感受关节读数、力传感器以及高维输入（如 RGB 和深度相机图像）。编码器网络将所有感官输入 x_t 融合为随机表示 z_t 。动力学模型利用其循环状态 h_t 学习预测随机表示序列。解码器重建感官输入，为学习表示提供丰富信号，并支持人类检查模型预测，但在从潜在推演中学习行为时并不需要。在我们的实验中，机器人必须通过与真实世界交互来发现任务奖励，奖励网络学习预测这些奖励。也可以使用基于解码感官输入的手动指定奖励函数。我们通过随机反向传播 (Kingma 和 Welling, 2013; Rezende 等, 2014) 联合优化世界模型的所有组件。

演员-评论家学习 虽然世界模型表示与任务无关的动力学知识，但演员-评论家算法学习的是针对当前任务的行为。如图所示

图 3（右），本文在世界模型的潜空间中预测的轨迹上学习行为，无需解码观测。这使得在单个图形处理器（GPU）上以典型批大小 16K 进行大规模并行行为学习成为可能，类似于专门的现代模拟器（Makoviychuk 等人，2021 年）。演员-评论家算法由两个神经网络组成：

$$\text{Actor Network: } \pi(a_t | s_t) \quad \text{Critic Network: } v(s_t) \quad (2)$$

演员网络的作用是为每个潜在模型状态 s_t 学习一个成功动作的分布 a_t ，以最大化未来预测任务奖励的总和。评论家网络通过时序差分学习（Sutton and Barto, 2018）来学习预测未来任务奖励的总和。这一点很重要，因为它允许算法考虑超出 $H = 16$ 步规划时域的奖励，从而学习长期策略。给定一条预测的模型状态轨迹，评论家被训练来回归该轨迹的回报。一个简单的选择是将回报计算为 N 个中间奖励加上评论家自身对下一状态的预测之和。为了避免为 N 选择任意值，我们改为计算 λ -回报，它对所有 $N \in [1, H - 1]$ 取平均，并按如下方式计算：

$$V_t^\lambda \doteq r_t + \gamma \left((1 - \lambda)v(s_{t+1}) + \lambda V_{t+1}^\lambda \right), \quad V_H^\lambda \doteq v(s_H). \quad (3)$$

评论家网络被训练以回归 λ 回报，而演员网络被训练以最大化这些回报。不同的梯度估计器可用于计算优化演员的策略梯度，例如强化算法（Reinforce）（Williams, 1992）和重参数化技巧（Kingma and Welling, 2013; Rezende et al., 2014），后者通过可微动力学网络直接反向传播回报梯度（Henaff et al., 2019）。遵循 Hafner 等人（2020）的做法，我们为连续控制任务选择重参数化梯度，为具有离散动作的任务选择强化梯度。除了最大化回报外，演员还被激励保持高熵，以防止退化为确定性策略，并在整个训练过程中保持一定程度的探索：

$$\mathcal{L}(\pi) \doteq -\mathbb{E} \left[\sum_{t=1}^H \ln \pi(a_t | s_t) \text{sg}(V_t^\lambda - v(s_t)) + \eta H [\pi(a_t | s_t)] \right] \quad (4)$$

我们使用 Adam 优化器（Kingma and Ba, 2014）优化演员和评论家。为了计算 λ 回报，我们使用评论家网络的缓慢更新副本，这在文献中很常见（Mnih et al., 2015; Lillicrap et al., 2015）。演员和评论家的梯度不会影响世界模型，因为这会导致不正确且过于乐观的模型预测。超参数列于附录 D 中。与 Hafner 等人（2020）相比，没有训练频率超参数，因为解耦学习器在数据收集的同时并行优化神经网络，没有速率限制。

3 实验

我们在 4 个机器人上评估 Dreamer，每个机器人执行不同的任务，并将其性能与适当的算法基线和人类基线进行比较。这些实验代表了常见的机器人任务，如运动、操作和导航。这些任务带来了各种各样的挑战，包括连续和离散动作、密集和稀疏奖励、本体感觉和图像观测以及传感器融合。学习到的世界模型具有多种特性，使其非常适合机器人学习。实验的目标是评估学习到的世界模型的最新成功是否能够在现实世界中直接实现样本高效的机器人学习。具体来说，我们旨在回答以下研究问题：

- Dreamer 是否能够在没有模拟器的情况下直接在现实世界中实现机器人学习？
- Dreamer 是否能够在各种机器人平台、感官模态和动作空间中取得成功？
- Dreamer 的数据效率与之前的强化学习算法相比如何？




图 4: A1 四足机器人从仰卧、四脚朝天的状态开始行走。Dreamer 在 1 小时的真实世界训练时间内学会了翻身、站立和行走, 无需模拟器或重置。相比之下, SAC 只学会了翻身, 既不能站立也不能行走。对于 SAC, 我们还需要在训练期间帮助机器人摆脱死锁的腿部构型。右侧展示了 SAC 和 Dreamer 的训练曲线。最大奖励为 14。实心圆表示机器人仰面摔倒的时刻, 这需要学习一种稳健的翻身策略。训练 1 小时后, 我们开始推机器人, 发现它在 10 分钟内调整了行为, 能够承受轻微推动, 并在强力推动下迅速翻身站起。图中展示了一次训练运行, 阴影区域表示每个时间区间内的一个标准差。

实现 我们基于 DreamerV2 (Hafner 等人, 2020) 的官方实现进行构建, 该实现处理多种感官模式。我们开发了一种异步执行器与学习器设置, 这对于控制频率较高的环境 (如四足机器人) 至关重要, 同时也能加速较慢环境 (如机械臂) 的学习。我们在所有实验中使用了相同的超参数, 从而能够现成地部署到不同的机器人形态上。

基线 我们在每个实验设置中都与一个强大的学习算法进行了比较。A1 四足机器人使用连续动作和低维输入, 这使我们能够与 SAC (Haarnoja 等人, 2018a; b) 进行比较, SAC 是一种流行的数据高效连续控制算法。对于 XArm 和 UR5 机器人上的视觉抓取与放置实验, 输入是图像和本体感觉读数, 动作是离散的, 这提示使用 DQN (Mnih 等人, 2015) 系列算法作为基线。我们选择 Rainbow (Hessel 等人, 2018) 作为该类别的强大代表, 该算法结合了 DQN 的许多改进。为了输入本体感觉读数, 我们将它们作为广播平面拼接到图像的 RGB 通道中, 这是文献中的常见做法 (Schrittwieser 等人, 2019)。对于 UR5, 我们还与 PPO (Schulman 等人, 2017) 进行了比较, 并进行了类似的修改以融合图像和本体感觉读数。此外, 我们还与通过机器人控制接口操控机械臂的人类操作员进行了比较, 这为机器人性能提供了一个近似上限。对于 Sphero 导航任务, 输入是图像, 动作是连续的。该类别中最先进的基线是 DrQv2 (Yarats 等人, 2021), 它使用图像增强来提高样本效率。

3.1 A1 四足行走

这项高维连续控制任务要求训练四足机器人从背部翻身、站立并以固定目标速度向前行走。以往的四足运动工作要么需要在领域随机化下进行大量仿真训练, 使用恢复控制器避免不安全状态, 要么将动作空间定义为参数化轨迹生成器以限制运动空间。相比之下, 本文直接在机器人上进行端到端强化学习训练, 无需仿真器或重置。本文使用宇树 A1 机器人, 该机器人由 12 个直驱电机组成。电机以 20 赫兹的频率通过连续动作进行控制, 这些动作表示由硬件上的比例微分控制器实现的电机角度。输入包括电机角度、姿态和角速度。为保护电机, 本文通过巴特沃斯滤波器滤除高频电机指令。由于空间限制, 当机器人到达可用训练区域末端时, 本文进行人工干预, 但不改变机器人所处的关节构型或姿态。



图 8: 在扰动学习到的行走行为后 10 分钟内, 机器人适应了承受推力或快速翻滚并重新站立。




图 5: UR5 多物体视觉抓取与放置。该任务要求从第三人称相机图像中定位三个球体, 抓取它们并将其移动到另一个箱子中。机械臂可在箱子内部和上方自由移动, 抓取球体和将其放入对面箱子时给予稀疏奖励。该环境要求世界模型学习真实世界中的多物体动力学, 稀疏奖励结构对策略优化构成挑战。Dreamer 克服了该任务中视觉定位和稀疏奖励的挑战, 在数小时的自主操作内学会了成功的策略。

奖励函数是五项之和。直立奖励由基座坐标系的上方向量 $\hat{z}^T$ 计算得出, 匹配站立姿态的项由髋、肩、膝关节角度计算得出, 前进速度项由投影前进速度 $\mathcal{B}_{v_x}$ 和总速度 $\mathcal{B}_v$ 计算得出。五项中的每一项在其前序项满足至少 0.7 时激活, 否则置为 0:

$$\begin{aligned} r^{\text{upr}} &\doteq (\hat{z}^T[0, 0, 1] - 1)/2 & r^{\text{hip}} &\doteq 1 - \frac{1}{4} \|q^{\text{hip}} + 0.2\|_1 & r^{\text{shoulder}} &\doteq 1 - \frac{1}{4} \|q^{\text{shoulder}} + 0.2\|_1 \\ r^{\text{knee}} &\doteq 1 - \frac{1}{4} \|q^{\text{knee}} - 1.0\|_1 & r^{\text{velocity}} &\doteq 5(\max(0, \mathcal{B}_{v_x})/\|\mathcal{B}_v\|_2 \cdot \text{clip}(\mathcal{B}_{v_x}/0.3, -1, 1) + 1) \end{aligned} \quad (5)$$

如图 4 所示, 经过一小时的训练, Dreamer 学会了持续地将机器人从背部翻转过来、站立并向前行走。在训练的前 5 分钟内, 机器人成功地从背部翻滚并双脚着地。20 分钟后, 它学会了如何站立。训练约 1 小时后, 机器人学会了以蹦跳步态向前行走, 达到期望速度。成功完成该任务后, 我们通过用一根大杆反复将机器人击倒来测试算法的鲁棒性, 如图 8 所示。在额外在线学习的 10 分钟内, 机器人适应了推挤, 能够承受推力或迅速翻滚回站立姿态。相比之下, SAC 很快学会了从背部翻滚, 但在小数据预算下未能学会站立或行走。

3.2 UR5 多物体视觉抓取与放置

抓取与放置任务常见于仓库和物流环境, 要求机器人操作臂将物品从一个箱子搬运到另一个箱子。图 5 展示了该任务的一个成功抓取与放置循环。该任务具有挑战性, 原因在于奖励稀疏、需要从像素推断物体位置以及多个运动物体的复杂动力学。感官输入包括本体感受读数 (关节角度、夹爪位置、末端执行器笛卡尔位置) 和场景的第三人称 RGB 图像。成功抓取 3 个物体之一 (通过夹爪部分闭合检测) 会获得 +1 奖励, 将物体释放在同一箱子中会获得 -1 奖励, 将物体放置在对面箱子中会获得 +10 奖励。我们以 2 赫兹的频率控制 Universal Robotics 的高性能 UR5 机器人。动作是离散的, 用于沿 X、Y 和 Z 轴增量移动末端执行器以及切换夹爪状态。仅在持有物体时启用 Z 轴移动, 并且夹爪在到达正确箱子上方后自动打开。我们通过记录 3 名演示者使用操纵杆控制 UR5 各 20 分钟来估计人类表现。

Dreamer 在 8 小时内达到平均每分钟拾取 2.5 个物体的速度。机器人最初因奖励信号非常稀疏而难以学习, 但在训练 2 小时后开始逐步改进。机器人首先学会定位物体, 并在靠近物体时切换夹爪。随着时间推移, 抓取变得精确, 机器人学会将物体推出角落。图 5 展示了 Dreamer 与 Rainbow DQN、PPO 以及人类基线的学习曲线。Rainbow DQN 和 PPO 仅学会了短视行为, 即抓取后立即将物体丢入同一个箱子。相比之下, Dreamer 在 8 小时后接近人类水平性能。我们推测 Rainbow DQN 和 PPO 失败的原因是它们需要大量经验, 而在现实世界中收集这些经验对我们来说不可行。




图 6: XArm 视觉拾取与放置。XArm 是一款价格实惠的机器人手臂，运行速度比 UR5 慢。为了展示在该机器人上的成功学习，我们使用带有 RGB 和深度模态的第三人称 RealSense 相机，以及机器人手臂的本体感知输入，这要求世界模型学习传感器融合。拾取与放置任务使用软物体。虽然软物体在模拟器中难以精确建模，但 Dreamer 通过直接在真实机器人上学习而无需模拟器，避免了这一问题。Rainbow 收敛到在同一箱子中抓取和松开物体的局部最优，而 Dreamer 在 10 小时内从稀疏奖励中学习到成功的拾取与放置策略。

3.3 XArm 视觉拾取与放置

UR5 机器人是一款高性能工业机器人，而 XArm 是一款易于获取的低成本 7 自由度机械臂，我们以约 0.5 Hz 的频率控制它。与第 3.2 节类似，该任务要求定位并抓取一个软物体，并将其从一个箱子移动到另一个箱子再移回，如图 6 所示。由于箱子没有倾斜，我们用绳子将物体连接到夹爪上。这降低了物体卡在角落的可能性，但代价是动力学更加复杂。稀疏奖励、离散动作空间和观测空间与 UR5 设置相同，只是增加了深度图像观测。

Dreamer 学习了一种策略，使 XArm 在 10 小时内达到平均每分钟拾取 3.1 个物体的速度，这与人类在该任务上的表现相当。图 6 显示，Dreamer 在 10 小时内学会了解决该任务，而 Rainbow 算法（一种用于像素级离散控制的顶级无模型算法）未能学会。有趣的是，我们观察到 Dreamer 学会了有时利用绳子将物体从角落拉出后再抓取，展示了多模态行为。此外，我们观察到当光照条件发生剧烈变化时（如日出时的强烈阴影），性能最初会下降，但 Dreamer 随后适应了变化的条件，并在额外训练几小时后超过了之前的性能，详见附录 A。

3.4 Sphero 导航

我们在一个视觉导航任务上评估 Dreamer，该任务要求仅根据 RGB 图像输入操控轮式机器人到达固定目标位置。我们使用 Sphero Ollie 机器人，这是一种带有两个可控电机的圆柱形机器人，我们通过 2 赫兹的连续扭矩命令进行控制。由于机器人是对称的，并且只能获取图像观测，它必须从观测历史中推断航向方向。机器人获得密集奖励，等于负 L2 距离。由于目标是固定的，在 100 个环境步骤后，我们结束回合，并通过一系列高功率随机电机动作随机化机器人的位置。

在 2 小时内，Dreamer 学会了快速且一致地导航到目标，并在回合剩余时间内停留在目标附近。如图 7 所示，Dreamer 实现了到目标的平均距离为 0.15，以区域大小的单位衡量，并在时间步上取平均。我们发现 DrQv2（一种专门为像素级连续控制设计的无模型算法）实现了类似的性能。这一结果与 Yarats 等人（2021）的模拟实验一致，该实验表明两种算法在图像连续控制任务上表现相似。

4 相关工作

现有的机器人学习工作通常利用大量模拟经验，在领域和动力学随机化下进行训练，然后部署到现实世界（Rusu 等人，2016；Peng 等人，2018；OpenAI 等人，2018；Lee 等人，2020；Irpan 等人，2020；Rudin 等人，2021；Kumar 等人，2021；Siekman 等人，2021；Smith 等人，2021；Escontrela 等人，2022；Miki 等人，2022），利用




图 7: Sphero 导航 该任务要求 Sphero Ollie 机器人通过连续动作导航到固定目标位置，仅以俯视 RGB 图像作为唯一感官输入。任务要求机器人仅从像素中定位自身，没有本体感觉输入，从过去图像序列推断其方向，因为单张图像存在歧义，并通过需要随时间积累动量的欠驱动电机控制机器人。Dreamer 在不到 2 小时内学会了该任务的成功策略。

机器人编队收集经验数据集 (Kalashnikov 等人, 2018; Levine 等人, 2018; Dasari 等人, 2019; Kalashnikov 等人, 2021; Ebert 等人, 2021)，或依赖外部信息，如人类专家演示或任务先验，以实现样本高效学习 (Xie 等人, 2019; Schoettler 等人, 2019; James 等人, 2021; Shah 和 Levine, 2022; Bohez 等人, 2022; Sivakumar 等人, 2022)。然而，设计模拟任务和收集专家演示非常耗时。此外，许多这些方法需要专门的算法来利用离线经验、演示或模拟器不准确性。相比之下，我们的实验表明，通过世界模型从物理世界的奖励中进行端到端学习对于各种任务是可行的。

相对较少的工作展示了在物理世界中从零开始的端到端学习。视觉预见 (Visual Foresight) (Finn 等, 2016; Finn 和 Levine, 2017; Ebert 等, 2018) 学习视频预测模型，通过在线规划解决现实世界任务，但仅限于短视界任务，并且需要在规划过程中生成图像，计算成本高昂。相比之下，本文学习潜动力学，能够在紧凑的潜空间中以大批量进行高效的策略优化。Yang 等 (2019; 2022) 通过基于模型的方法学习四足运动，预测落脚点并利用特定领域的控制器来实现这些落脚点。SOLAR (Zhang 等, 2019) 从图像中学习潜动力学模型，并展示了机械臂的到达和推动任务。Nagabandi 等 (2019) 通过从状态观测中学习动力学模型进行规划，学习灵巧操作策略。相比之下，本文的实验在 4 个具有挑战性的机器人任务上展示了成功的学习，这些任务涵盖了广泛的挑战和感官模态，且使用单一学习算法和超参数设置。

5 讨论

本文将 Dreamer 应用于物理机器人学习，发现现代世界模型能够实现样本高效的机器人学习，适用于一系列任务，从现实世界中从零开始，无需仿真器。本文还发现该方法具有普遍适用性，能够在不改变超参数的情况下解决机器人运动、操作和导航任务。Dreamer 教会四足机器人在 1 小时内从零开始翻身、站立和行走，而此前这需要在仿真中进行大量训练，然后迁移到现实世界，或者使用参数化轨迹生成器和给定的重置策略。本文还展示了在两个机械臂上从像素和稀疏奖励中学习拾取和放置任务，耗时 8–10 小时。

局限性 虽然 Dreamer 展示了有前景的结果，但在硬件上长时间学习会造成机器人磨损，可能需要人工干预或维修。此外，还需要更多工作来通过更长时间的训练探索 Dreamer 和基线的极限。最后，本文将解决更具挑战性的任务视为有影响力的未来研究方向，可能通过结合快速现实世界学习与仿真器的优势来实现。

致谢 本文感谢斯蒂芬·詹姆斯 (Stephen James) 和贾斯汀·克尔 (Justin Kerr) 提出的宝贵建议，以及他们在四足机器人保护外壳打印方面提供的帮助。感谢阿德米·阿德尼吉 (Ademi Adeniji) 在搭建 XArm 机器人过程中给予的帮助，以及雷文·黄 (Raven Huang) 在搭建 UR5 机器人过程中给予的帮助。本研究部分得到了美国国家科学基金会奖学金 (NSF Fellowship)、美国国家科学基金会国家机器人计划项目 (NSF NRI #2024675) 以及加拿大瓦尼尔研究生奖学金 (Vanier Canada Graduate Scholarship) 的资助。

参考文献

- D. Hafner, T. Lillicrap, J. Ba, and M. Norouzi. Dream to control: Learning behaviors by latent imagination. *arXiv preprint arXiv:1912.01603*, 2019.
- D. Hafner, T. Lillicrap, M. Norouzi, and J. Ba. Mastering atari with discrete world models. *arXiv preprint arXiv:2010.02193*, 2020.
- Y. Gal, R. McAllister, and C. E. Rasmussen. Improving pilco with bayesian neural network dynamics models. In *Data-Efficient Machine Learning workshop, ICML*, 2016.
- F. Ebert, C. Finn, S. Dasari, A. Xie, A. Lee, and S. Levine. Visual foresight: Model-based deep reinforcement learning for vision-based robotic control. *arXiv preprint arXiv:1812.00568*, 2018.
- R. Sekar, O. Rybkin, K. Daniilidis, P. Abbeel, D. Hafner, and D. Pathak. Planning to explore via self-supervised world models. In *International Conference on Machine Learning*, pages 8583–8592. PMLR, 2020.
- T. Yu, A. Kumar, R. Rafailov, A. Rajeswaran, S. Levine, and C. Finn. Combo: Conservative offline model-based policy optimization. *Advances in neural information processing systems*, 34: 28954–28967, 2021.
- D. Hafner, T. Lillicrap, I. Fischer, R. Villegas, D. Ha, H. Lee, and J. Davidson. Learning latent dynamics for planning from pixels. *arXiv preprint arXiv:1811.04551*, 2018.
- D. P. Kingma and M. Welling. Auto-encoding variational bayes. *arXiv preprint arXiv:1312.6114*, 2013.
- D. J. Rezende, S. Mohamed, and D. Wierstra. Stochastic backpropagation and approximate inference in deep generative models. *arXiv preprint arXiv:1401.4082*, 2014.
- V. Makoviychuk, L. Wawrzyniak, Y. Guo, M. Lu, K. Storey, M. Macklin, D. Hoeller, N. Rudin, A. Allshire, A. Handa, et al. Isaac gym: High performance gpu-based physics simulation for robot learning. *arXiv preprint arXiv:2108.10470*, 2021.
- R. S. Sutton and A. G. Barto. *Reinforcement learning: An introduction*. MIT press, 2018.
- R. J. Williams. Simple statistical gradient-following algorithms for connectionist reinforcement learning. *Machine learning*, 8(3-4):229–256, 1992.
- M. Henaff, A. Canziani, and Y. LeCun. Model-predictive policy learning with uncertainty regularization for driving in dense traffic. *arXiv preprint arXiv:1901.02705*, 2019.
- D. P. Kingma and J. Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.
- V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski, et al. Human-level control through deep reinforcement learning. *Nature*, 518(7540):529, 2015.
- T. P. Lillicrap, J. J. Hunt, A. Pritzel, N. Heess, T. Erez, Y. Tassa, D. Silver, and D. Wierstra. Continuous control with deep reinforcement learning. *arXiv preprint arXiv:1509.02971*, 2015.
- T. Haarnoja, A. Zhou, P. Abbeel, and S. Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. *arXiv preprint arXiv:1801.01290*, 2018a.
- T. Haarnoja, A. Zhou, K. Hartikainen, G. Tucker, S. Ha, J. Tan, V. Kumar, H. Zhu, A. Gupta, P. Abbeel, et al. Soft actor-critic algorithms and applications. *arXiv preprint arXiv:1812.05905*, 2018b.

- M. Hessel, J. Modayil, H. Van Hasselt, T. Schaul, G. Ostrovski, W. Dabney, D. Horgan, B. Piot, M. Azar, and D. Silver. Rainbow: Combining improvements in deep reinforcement learning. In *Thirty-Second AAAI Conference on Artificial Intelligence*, 2018.
- J. Schrittwieser, I. Antonoglou, T. Hubert, K. Simonyan, L. Sifre, S. Schmitt, A. Guez, E. Lockhart, D. Hassabis, T. Graepel, et al. Mastering atari, go, chess and shogi by planning with a learned model. *arXiv preprint arXiv:1911.08265*, 2019.
- J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
- D. Yarats, R. Fergus, A. Lazaric, and L. Pinto. Mastering visual continuous control: Improved data-augmented reinforcement learning. *arXiv preprint arXiv:2107.09645*, 2021.
- A. A. Rusu, M. Vecerik, T. Rothörl, N. Heess, R. Pascanu, and R. Hadsell. Sim-to-real robot learning from pixels with progressive nets, 2016.
- X. B. Peng, M. Andrychowicz, W. Zaremba, and P. Abbeel. Sim-to-real transfer of robotic control with dynamics randomization. In *2018 IEEE International Conference on Robotics and Automation (ICRA)*, pages 1–8, May 2018. doi:10.1109/ICRA.2018.8460528.
- OpenAI, M. Andrychowicz, B. Baker, M. Chociej, R. Jozefowicz, B. McGrew, J. Pachocki, A. Petron, M. Plappert, G. Powell, A. Ray, J. Schneider, S. Sidor, J. Tobin, P. Welinder, L. Weng, and W. Zaremba. Learning dexterous in-hand manipulation, 2018.
- J. Lee, J. Hwangbo, L. Wellhausen, V. Koltun, and M. Hutter. Learning quadrupedal locomotion over challenging terrain. *Science Robotics*, 5(47), oct 2020. doi:10.1126/scirobotics.abc5986. URL <https://doi.org/10.1126%2Fscirobotics.abc5986>.
- A. Irpan, C. Harris, J. Ibarz, K. Rao, M. Khansari, and S. Levine. Rl-cyclelegan: Improving deep-rl robotics with simulation-to-real. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR 2020)*, 2020.
- N. Rudin, D. Hoeller, P. Reist, and M. Hutter. Learning to walk in minutes using massively parallel deep reinforcement learning, 2021.
- A. Kumar, Z. Fu, D. Pathak, and J. Malik. Rma: Rapid motor adaptation for legged robots, 2021.
- J. Siekmann, K. Green, J. Warila, A. Fern, and J. Hurst. Blind bipedal stair traversal via sim-to-real reinforcement learning, 2021.
- L. Smith, J. C. Kew, X. B. Peng, S. Ha, J. Tan, and S. Levine. Legged robots that keep on learning: Fine-tuning locomotion policies in the real world, 2021.
- A. Escontrela, X. B. Peng, W. Yu, T. Zhang, A. Iscen, K. Goldberg, and P. Abbeel. Adversarial motion priors make good substitutes for complex reward functions, 2022.
- T. Miki, J. Lee, J. Hwangbo, L. Wellhausen, V. Koltun, and M. Hutter. Learning robust perceptive locomotion for quadrupedal robots in the wild. *Science Robotics*, 7(62), jan 2022. doi:10.1126/scirobotics.abk2822.
- D. Kalashnikov, A. Irpan, P. Pastor, J. Ibarz, A. Herzog, E. Jang, D. Quillen, E. Holly, M. Kalakrishnan, V. Vanhoucke, and S. Levine. Qt-opt: Scalable deep reinforcement learning for vision-based robotic manipulation, 2018.
- S. Levine, P. Pastor, A. Krizhevsky, J. Ibarz, and D. Quillen. Learning hand-eye coordination for robotic grasping with deep learning and large-scale data collection. *The International Journal of Robotics Research*, 37(4-5):421–436, 2018.
- S. Dasari, F. Ebert, S. Tian, S. Nair, B. Bucher, K. Schmeckpeper, S. Singh, S. Levine, and C. Finn. Robonet: Large-scale multi-robot learning, 2019.

- D. Kalashnikov, J. Varley, Y. Chebotar, B. Swanson, R. Jonschkowski, C. Finn, S. Levine, and K. Hausman. Mt-opt: Continuous multi-task robotic reinforcement learning at scale, 2021.
- F. Ebert, Y. Yang, K. Schmeckpeper, B. Bucher, G. Georgakis, K. Daniilidis, C. Finn, and S. Levine. Bridge data: Boosting generalization of robotic skills with cross-domain datasets, 2021.
- A. Xie, F. Ebert, S. Levine, and C. Finn. Improvisation through physical understanding: Using novel objects as tools with visual foresight. *arXiv preprint arXiv:1904.05538*, 2019.
- G. Schoettler, A. Nair, J. Luo, S. Bahl, J. A. Ojea, E. Solowjow, and S. Levine. Deep reinforcement learning for industrial insertion tasks with visual inputs and natural rewards, 2019.
- S. James, K. Wada, T. Laidlow, and A. J. Davison. Coarse-to-fine q-attention: Efficient learning for visual robotic manipulation via discretisation, 2021.
- D. Shah and S. Levine. Viking: Vision-based kilometer-scale navigation with geographic hints, 2022.
- S. Bohez, S. Tunyasuvunakool, P. Brakel, F. Sadeghi, L. Hasenclever, Y. Tassa, E. Parisotto, J. Humplik, T. Haarnoja, R. Hafner, M. Wulfmeier, M. Neunert, B. Moran, N. Siegel, A. Huber, F. Romano, N. Batchelor, F. Casarini, J. Merel, R. Hadsell, and N. Heess. Imitate and repurpose: Learning reusable robot movement skills from human and animal behaviors, 2022.
- A. Sivakumar, K. Shaw, and D. Pathak. Robotic telekinesis: Learning a robotic hand imitator by watching humans on youtube, 2022.
- C. Finn, I. Goodfellow, and S. Levine. Unsupervised learning for physical interaction through video prediction. In *Advances in neural information processing systems*, pages 64–72, 2016.
- C. Finn and S. Levine. Deep visual foresight for planning robot motion. In *Robotics and Automation (ICRA), 2017 IEEE International Conference on*, pages 2786–2793. IEEE, 2017.
- Y. Yang, K. Caluwaerts, A. Iscen, T. Zhang, J. Tan, and V. Sindhwani. Data efficient reinforcement learning for legged robots, 2019.
- Y. Yang, T. Zhang, E. Coumans, J. Tan, and B. Boots. Fast and efficient locomotion via learned gait transitions. In *Conference on Robot Learning*, pages 773–783. PMLR, 2022.
- M. Zhang, S. Vikram, L. Smith, P. Abbeel, M. Johnson, and S. Levine. Solar: deep structured representations for model-based reinforcement learning. In *International Conference on Machine Learning*, 2019.
- A. Nagabandi, K. Konoglie, S. Levine, and V. Kumar. Deep dynamics models for learning dexterous manipulation, 2019.
- G. I. Parisi, R. Kemker, J. L. Part, C. Kanan, and S. Wermter. Continual lifelong learning with neural networks: A review. *Neural Networks*, 113:54–71, 2019. ISSN 0893-6080.
- T.-Y. Yang, T. Zhang, L. Luu, S. Ha, J. Tan, and W. Yu. Safe reinforcement learning for legged locomotion, 2022. URL <https://arxiv.org/abs/2203.02638>.
- L. Pinto and A. Gupta. Supersizing self-supervision: Learning to grasp from 50k tries and 700 robot hours, 2015.
- H. Ha and S. Song. Flingbot: The unreasonable effectiveness of dynamic manipulation for cloth unfolding. *Conference on Robot Learning*, 2021.
- S. James and A. J. Davison. Q-attention: Enabling efficient learning for vision-based robotic manipulation, 2021.
- E. Tzeng, C. Devin, J. Hoffman, C. Finn, P. Abbeel, S. Levine, K. Saenko, and T. Darrell. Adapting deep visuomotor representations with weak pairwise constraints, 2015.

- I. Akkaya, M. Andrychowicz, M. Chociej, M. Litwin, B. McGrew, A. Petron, A. Paino, M. Plappert, G. Powell, R. Ribas, et al. Solving rubik’s cube with a robot hand. *arXiv preprint arXiv:1910.07113*, 2019.
- M. P. Deisenroth, G. Neumann, J. Peters, et al. A survey on policy search for robotics. *Foundations and Trends in Robotics*, 2(1–2):1–142, 2013.
- K. Chua, R. Calandra, R. McAllister, and S. Levine. Deep reinforcement learning in a handful of trials using probabilistic dynamics models. In *Advances in Neural Information Processing Systems*, pages 4754–4765, 2018.
- A. Nagabandi, G. Yang, T. Asmar, R. Pandya, G. Kahn, S. Levine, and R. S. Fearing. Learning image-conditioned dynamics models for control of under-actuated legged millirobots, 2017.
- F. Deng, I. Jang, and S. Ahn. Dreamerpro: Reconstruction-free model-based reinforcement learning with prototypical representations. *arXiv preprint arXiv:2110.14565*, 2021.
- M. Okada and T. Taniguchi. Dreaming: Model-based reinforcement learning by latent imagination without reconstruction. In *2021 IEEE International Conference on Robotics and Automation (ICRA)*, pages 4209–4215. IEEE, 2021.
- H. Bharadhwaj, M. Babaeizadeh, D. Erhan, and S. Levine. Information prioritization through empowerment in visual model-based rl. *arXiv preprint arXiv:2204.08585*, 2022.
- K. Paster, L. E. McKinney, S. A. McIlraith, and J. Ba. Blast: Latent dynamics models from bootstrapping. In *Deep RL Workshop NeurIPS 2021*, 2021.

A 适应

真实世界机器人学习面临实际挑战，如环境条件变化和时变动态。我们发现 Dreamer 能够在不改变学习算法的情况下适应当前环境条件。这显示了在持续学习环境中使用 Dreamer 的前景（Parisi 等人，2019）。四足机器人对外部扰动的适应在第 3.1 节和图 8 中报告。

XArm 位于大窗户附近，能够在光照条件变化的情况下适应并保持性能。XArm 实验在日落后进行，以保持整个训练过程中光照条件恒定。图 A.1 显示了 XArm 的学习曲线。正如预期，XArm 的性能在日出时下降。然而，XArm 能够在大约 5 小时内适应光照条件的变化并恢复原始性能，这比从头开始训练要快。对这些时刻图像观测的仔细检查（如图 A.1 所示）表明，机器人接收到的观测包含覆盖场景的强烈光线，这与原始训练观测有很大不同。




图 A.1：左侧两幅图像是 Dreamer 消耗的原始观测。最左侧图像是 XArm 在夜间训练时看到的图像观测。下一幅图像显示日出时的观测。尽管像素空间差异巨大，XArm 仍能恢复，并在大约 5 小时内超越原始性能。

B 想象



图 B.1：为了内省策略，我们可以在 Dreamer 的潜空间中展开轨迹，然后解码图像以可视化演员网络的意图。每一行是一个想象的轨迹，显示每第 2 帧。顶部：UR5 环境中的潜空间展开。多个物体引入了网络必须建模的更多视觉复杂性。注意第二条轨迹，它显示一个静态的橙色球变成了绿色球。底部：XArm 环境中的潜空间展开。

C 详细相关工作

用于运动的强化学习 一种常见的方法是在领域和动力学随机化条件下，利用大量仿真数据训练强化学习智能体（Peng 等，2018；Lee 等，2020；Rudin 等，2021；Siekman 等，2021；Escontrela 等，2022；Miki 等，2022；Kumar 等，2021；Rusu 等，2016；Bohez 等，2022），然后冻结所学策略并将其部署到现实世界。Smith 等（2021）探索了在仿真中预训练策略并用现实世界数据微调的方法。Yang 等（2019）研究了使用多步损失学习动力学模型，并利用模型预测控制完成指定任务。Yang 等（2022）在现实世界中训练运动策略，但需要仿真中训练的恢复控制器以避免不安全状态。相比之下，本文不使用仿真器或重置策略，直接在物理机器人上进行训练。

用于操作的强化学习 学习有望使机器人操作器在开放的现实世界环境中解决接触丰富的任务。一类方法试图通过机器人集群扩大经验收集规模（Kalashnikov 等，2018；2021；Ebert 等，2021；Dasari 等，2019；Levine 等，2018）。相比之下，本文仅利用一台机器人，但通过使用学习到的世界模型并行化智能体的经验。另一种常见方法是利用专家演示或其他任务先验（Pinto 和 Gupta，2015；Ha 和 Song，2021；Xie 等，2019；Schoettler 等，2019；Sivakumar 等，2022）。James 和 Davison（2021）；James 等（2021）利用少量演示，通过让学习器关注场景的重要方面来提高 Q 学习的样本效率。其他方法，如运动领域，首先利用仿真器，然后迁移到现实世界（Tzeng 等，2015；Akkaya 等，2019；OpenAI 等，2018；Irpan 等，2020）。

基于模型的强化学习 由于相比无模型方法具有更高的样本效率，基于模型的强化学习（Model-based RL）是一种在真实世界机器人上学习的有前景的方法（Deisenroth 等，2013）。基于模型的方法首先学习一个动力学模型，然后可以利用该模型来规划动作（Nagabandi 等，2019；Hafner 等，2018；Chua 等，2018；Nagabandi 等，2017），或者像 Dreamer 那样将其用作模拟器来学习策略网络（Hafner 等，2019；2020）。应对世界高度视觉复杂性的一种方法是学习一个以动作为条件的视频预测模型（Finn 和 Levine，2017；Ebert 等，2018；Finn 等，2016）。这种方法的一个缺点是需要直接预测高维观测，这可能在计算上效率低下且容易产生漂移。Dreamer 在潜空间（Latent Space）中学习动力学模型，从而实现更高效的推演，并避免策略对高质量视觉重建的依赖。另一类工作提出无需重建输入即可学习潜动力学模型（Deng 等，2021；Okada 和 Taniguchi，2021；Bharadhwaj 等，2022；Paster 等，2021），我们认为这是在杂乱环境中支持移动视点的一种有前景的方法。

D 超参数

名称	符号	值
通用		
Replay capacity (FIFO)	—	10^6
Start learning	—	10^4
Batch size	B	32
Batch length	T	32
MLP size	—	4×512
Activation	—	LayerNorm + ELU
World Model		
RSSM size	—	512
Number of latents	—	32
Classes per latent	—	32
KL balancing	—	0.8
Actor Critic		
Imagination horizon	H	15
Discount	γ	0.95
Return lambda	λ	0.95
Target update interval	—	100
All Optimizers		
Gradient clipping	—	100
Learning rate	—	10^{-4}
Adam epsilon	ϵ	10^{-6}