

# 具有动态校正的闭环动作块用于免训练扩散策略


Pengyuan Wu<sup>1,2\*</sup>, Pingrui Zhang<sup>2,3\*</sup>, Zhigang Wang<sup>2</sup>, Dong Wang<sup>2</sup>, Bin Zhao<sup>2,4✉</sup>, Xuelong Li<sup>5</sup>, *Fellow,IEEE*

**摘要**——基于扩散的策略在机器人操作中取得了显著成果，但在动态场景中往往难以快速适应，导致响应延迟或任务失败。本文提出 DCDP，一种动态闭环扩散策略框架，将基于块的动作生成与实时校正相结合。DCDP 集成了自监督动态特征编码器、交叉注意力融合和非对称动作编码器-解码器，在动作执行前注入环境动态，实现实时闭环动作校正，增强系统在动态场景中的适应性。在动态 PushT 仿真中，DCDP 无需重新训练即可将适应性提高 19%，同时仅需 5% 的额外计算量。其模块化设计支持即插即用集成，在动态机器人场景（包括真实世界操作任务）中同时实现时间连贯性和实时响应性。项目页面位于：

<https://github.com/wupengyuan/dcdp>

## I. 引言

近年来，扩散策略在机器人操作任务中取得了显著成果 [1], [2], [3]。这些方法通常对动作块进行推理，以捕捉非马尔可夫依赖关系，减少顺序预测中的复合误差，并实现连贯的长期动作生成 [4], [5]。然而，在动态环境中实现高效的机器人操作不仅需要长期规划，策略还必须能够及时响应快速的环境变化。这种双重需求对现有方法构成了重大挑战：策略必须在较长时间范围内生成连贯的动作序列，同时在执行过程中感知并适应外部干扰或目标运动。缺乏这种响应能力，开环执行往往会导致延迟或任务失败。在典型场景中，例如抓取移动物体，反应能力不足会显著降低成功率。总体而言，现有方法的局限性可归纳如下：（1）开环动作生成。动作块在执行前完全生成，缺乏根据最新观测动态调整后续动作的能力。这严重限制了动态环境中的响应性。（2）时间建模不足。推理过程通常依赖于单帧



**图 1. 开环扩散策略、闭环扩散策略与本文提出的带动态校正的闭环扩散策略之比较。**橙色线表示开环扩散策略长度为  $H$  的动作分块预测。绿色线表示闭环扩散策略，其采用单步推理实现闭环控制。然而，该方法延迟较高且需频繁重新规划。相比之下，本文的动态校正闭环扩散策略（如红线所示）利用长度为  $M$  的历史库信息，在每个推理步骤执行轻量级快速校正，从而实现闭环控制。

或少量静态观测，未能充分利用连续时间信息，从而限制了其对环境变化的适应性。为解决上述问题，以往研究探索了两条主要改进途径。第一条途径通过缩短预测时域或减少去噪步骤来提高推理频率，以增强系统响应性 [6]、[1]、[4]。然而，这些方法通常会降低动作生成质量，且过于频繁的更新可能破坏动作序列的连续性，从而削弱任务执行的稳定性。第二条途径采用时间集成或双向解码，通过整合多步推理的动作序列来实现闭环执行 [7]、[8]。然而，这些方法面临两个主要局限：要么受限于历史推理信息，阻碍了真正的实时闭环执行；要么需要在单个推理步骤内采样多个动作序列以进行解码和

<sup>1</sup> 浙江大学。 <sup>2</sup> 上海人工智能实验室。 <sup>3</sup> 复旦大学。 <sup>4</sup> 西北工业大学。 <sup>5</sup> 中国电信人工智能研究院。 邮箱： { pengyuanwu0810, zprzpr121 } @gmail.com

\* 同等贡献。 ✉ 通讯作者。

选择，这带来了巨大的计算开销。面对这些挑战，本文提出了一种闭环动作分块策略框架，将长期规划与实时动态校正相结合。该框架利用扩散策略在长时程规划中的优势，同时引入一个轻量级动态特征模块，将高频环境信息注入动作生成过程。通过这种方式，在每个时间步实现闭环执行和动态响应。具体而言，我们首先设计了一个自监督动态特征编码器，用于提取环境变化信息。该编码器在滑动窗口内收集近期观测图像，并对其差分特征应用自监督对比学习，从而捕获高频动态。为了进一步增强时间感知能力，我们引入了交叉注意力和时间注意力模块，以加强动态场景中的特征建模。此外，我们开发了一种非对称动作编码器，将原始动作序列压缩为潜在表示，并利用动态特征信息进行重构。通过施加重构损失和 KL 散度约束，迫使解码器依赖近期动态观测，从而提高动作生成的适应性。总体而言，所提方法的训练和推理阶段可描述如下：阶段 1（训练）：利用标注数据，端到端地训练非对称动作编码器和自监督动态特征编码器。采用重构损失和 KL 散度引导解码器关注动态特征。阶段 2（推理）：预训练的扩散策略生成完整的动作块，以确保长期动作一致性。同时，动态特征模块通过滑动窗口持续提取环境变化信息，并与动作潜在表示联合解码，实现每个时间步的动作实时校正。由于该模块的更新频率与动作执行频率相同，因此能在保持整体动作连贯性的同时，显著增强对动态环境的适应性。值得强调的是，该方法无需对原始扩散策略进行任何重新训练。只需在推理阶段插入动态校正模块，该框架即可大幅提升动态场景下的响应能力和鲁棒性。此外，该框架具有高度模块化和兼容性，能够与各种基于动作分块的策略无缝集成，为平衡长期规划与实时闭环控制提供即插即用的解决方案。我们在动态 PushT 仿真任务和两个真实世界任务上评估了 DCDP 方法。结果表明，DCDP 能够有效缓解扩散策略在动态场景中的适应性局限，且无需重新训练。与原始推理方法相比，其成功率提高了 19%，而额外计算开销仅为 5%。此外，在

在静态场景中，其高效的闭环特性进一步提升了任务成功率。

**综上所述，本文的贡献如下：**

- **框架闭环**：长期规划与实时校正相结合，在保持扩散策略一致性的同时，能够对环境变化做出快速响应。
- **动态特征提取与动作校正**：轻量级时序注意力模块学习环境动态并将其与潜在动作融合，从而能够灵活适应扰动和移动目标。
- **免训练与模块化设计**：无需重新训练扩散策略即可增强动态适应性；模块化设计支持与各种动作块策略即插即用集成，用于长期规划和实时控制。

## II. 相关工作

### A. 行为克隆

近期在模拟与真实环境中数据收集和基准开发方面的进展 [9]、[10]、[11]、[12]，显著推动了机器人技术的进步。模仿学习，尤其是通过专家示范，已成为提升机器人能力的关键驱动力 [13]、[14]、[15]、[16]、[17]、[18]、[19]、[20]。在模仿学习的众多技术中，生成式行为克隆因其能有效建模专家示范分布而备受关注。该方法不仅简化了学习过程，还在实际应用中展现出强大的经验性成功 [21]、[22]、[23]。近期，一种结合动作分块的行为克隆方法被提出 [1]、[24]、[8]。该技术通过预测连续动作序列来有效管理时间依赖性。然而，动作分块的推理过程往往依赖于单帧或有限数量的帧观测，未能充分利用数据中存在的连续时间信息。相比之下，本文方法利用了观测中此前未被充分利用的时间线索，并整合一个快速策略，将这些信号注入较慢的扩散策略中，从而实现在线策略校正。

### B. 闭环动作分块

扩散策略通过从高斯噪声迭代精炼生成高质量动作，显著提升了机器人操作性能 [1]、[2]、[5]。然而，扩散策略的重新规划频率有限，动作分块过程的执行仍为开环。扩散策略在快速变化环境中表现不佳，也归因于动作分块的开环特性，使其无法及时接收反馈并动态响应。为解决此问题，一些方法 [25]、[26]、[27] 旨在引入高频策略，在动作分块执行期间注入额外信息以实现闭环控制。本文同样采用闭环

方案，通过充分利用闭环动作分块内的记忆和差分动态信息，增强扩散策略的动态能力。

### C. 动态操作

在机器人-物体交互中，物体往往处于运动状态，例如在工业传送带上处理物品，或在体育活动中与足球 [28]、羽毛球 [29]、乒乓球 [30] 等动态物体交互。然而，目前尚无专门设计的真实或模拟数据集，用于训练机器人适应此类动态场景。为应对动态挑战，一些方法 [31]、[32] 集成模型预测控制 (Model Predictive Control, MPC) [33] 以实现实时性能。尽管这些方法在结构化环境中有效，但当被操作物体的运动序列变得更加不确定时，其泛化能力往往较差。此外，一些方法 [34]、[35]、[36] 结合强化学习来探索动态能力。然而，这些方法并未充分利用来自模仿学习的动作专家数据，如第 II-A 节所述。相比之下，本文方法在第二阶段动态场景评估期间，以无需训练的方式将动态校正信息注入已通过模仿学习训练好的扩散策略中。该方法无需对动作模型进行额外训练，并增强了模型在动态环境中有效运行的能力。

## III. 方法

### A. 预备知识

**带动作分块的扩散策略。**令  $\mathbf{A}_{t:t+H-1} :=$

$[\mathbf{a}_t, \mathbf{a}_{t+1}, \dots, \mathbf{a}_{t+H-1}]$  表示以当前观测  $\mathbf{o}_t$  为条件的长度为  $H$  的动作分块。本文将慢速策略实例化为条件扩散模型  $\pi_s(\mathbf{A}_{t:t+H-1} | \mathbf{o}_t)$ ，该模型通过以观测为条件的去噪器  $\epsilon_{\theta_s}$  将高斯噪声转换为  $\mathbf{A}_{t:t+H-1}$ 。在动态评估期间，本文保持参数  $\theta_s$  固定（无需训练），复用从静态数据集学习到的权重。虽然  $\pi_s$  促进了分块内的时间一致性，但它在分块内以开环方式运行，因此无法在快速变化的场景中对物体运动做出及时反应（见图 2 第二阶段）。

**动态感知策略。**本文维护一个包含最近  $M$  次观测的历史缓冲区（图 2 阶段 1）， $\mathbf{O}_{t-M+1:t} := [\mathbf{O}_{t-M+1}, \dots, \mathbf{O}_t]$ 。快速策略从该历史中提取动态感知的记忆特征， $\mathbf{F}_M =$

$\pi_f(\mathbf{O}_{t-M+1:t})$ 。

**用于动态评估的联合策略。**在动态评估阶段，我们通过一个联合模块融合慢速与快速通路

policy  $\pi_c(\mathbf{A}'_{t:t+H-1} | \mathbf{o}_t, \mathbf{F}_M)$ ，其中  $\mathbf{A}'_{t:t+H-1}$

是经过在线动态校正后的动作块，由当前观测  $\mathbf{o}_t$  与特征  $\mathbf{F}_M$  联合预测得到。下文第 III-B 节详述快速动态感知策略  $\pi_f$  的训练过程，第 III-C 节解释其特征如何条件化扩散策略，以在动态环境中生成校正后的动作块。

### B. 阶段一：快速动态感知策略训练

本节详述快速动态感知策略 (Fast Dynamic-Aware Policy) 的阶段一训练流程，如图 2（左）所示。我们使用历史库存储大小为  $M$  的观测滑动窗口，记为  $\mathbf{O}_{t-M+1:t}$ 。随后，历史库与计算得到的差分特征共同用于交叉注意力，以捕获动态信息，同时利用逐帧时间注意力学习序列历史（见第 III-B.1 节）。此外，我们利用差分特征为快速动态感知策略的输出计算自监督损失，并据此训练模型（见第 III-B.5 节）。为确保快速动态感知策略训练充分利用专家数据，我们采用轻量级变分自编码器在 pushT 数据上进行动作预测训练。此时，快速动态感知策略的输出与  $\mathbf{o}_t$  联合用于预测动作并计算反向传播损失（见第 III-B.6 节）。1) 历史库记忆学习：我们提出一种动态特征提取器，旨在同时捕获环境中的时间依赖与动态变化。系统依赖历史库中存储的最近观测滑动窗口，通过卷积层与注意力机制的组合提取动态特征。历史库包含最近  $M$  个观测。这些观测被输入特征提取器以捕获空间与时间依赖。首先，输入  $\mathbf{O}_{t-M+1:t}$  经过预训练的 ResNet18 骨干网络处理以提取空间特征。记提取的特征图为：

$$\text{Let } \mathbf{O}_{t-M+1:t} := [\mathbf{O}_{t-M+1}, \mathbf{O}_{t-M+2}, \dots, \mathbf{O}_t]$$

$$\mathbf{X}_{\text{spatial}} = \text{ResNet}(\mathbf{O}_{t-M+1:t}), \quad (1)$$

其中  $\mathbf{X}_{\text{spatial}} \in \mathbb{R}^{M \times C \times H_f \times W_f}$ ；此处  $M$  为帧数， $C, H_f, W_f$  分别表示特征图的通道数、高度与宽度。

**2) 差分特征计算：**为捕获连续帧之间的动态变化，我们计算差分特征  $\Delta \mathbf{X}_t$  如下：

$$\Delta \mathbf{X}_t = \mathbf{X}_{t+1} - \mathbf{X}_t, \quad (2)$$

其中  $\mathbf{X}_t$  表示第  $t$  帧提取的特征图。本文通过可学习参数  $\alpha$  对差分进行缩放：

$$\mathbf{D}_t = \alpha \cdot (\mathbf{X}_{t+1} - \mathbf{X}_t), \quad (3)$$

其中  $\mathbf{D}_t \in \mathbb{R}^{(M-1) \times C' \times H_f \times W_f}$  表示滑动窗口的差分特征。该操作使模型能够捕捉相邻帧之间的时序动态。

**3) 时间注意力：**时间注意力机制旨在捕捉帧序列中跨时间维度的依赖关系。它使模型能够学习帧之间的时间关联，从而聚焦于最相关的时间步并捕捉长程时间依赖。

给定帧特征  $\mathbf{X}_{\text{spatial}} \in \mathbb{R}^{M \times C' \times H_f \times W_f}$ ，模型在每个时间步  $t$  计算查询 ( $\mathbf{Q}_t$ )、键 ( $\mathbf{K}_t$ )，step  $t$ , the quer




图 2. DCDP 概览。本文方法采用两阶段框架。在第一阶段（图左半部分），训练快速动态感知策略与变分自编码器（VAE）。在第二阶段（图右半部分），利用前述快速动态感知策略进行免训练的逐步动作校正；校正后的动作随后由变分自编码器解码器解码。

以及值  $(V_{t'})$ ，通过学习的线性投影从  $X_{\text{spatial}}$  获得。注意力分数通过计算时间步  $t$  的查询与时间步  $t'$  的键之间的点积得到，注意力分数  $\text{Attn}_{t,t'}$  由下式给出：

$$\text{Attn}_{t,t'} = \text{SoftMax}\left(\frac{Q_t \cdot K_{t'}^T}{\sqrt{D}}\right), \quad (4)$$

其中  $D$  表示查询向量和键向量的维度；该分数量化了时间步  $t$  与  $t'$  之间的时间相似性，并通过  $1/\sqrt{D}$  进行缩放，以在训练期间稳定梯度。然后使用 **Softmax** 函数对注意力分数进行归一化，将其转换为概率分布。最后，将注意力分数应用于值  $V_{t'}$ ，生成时间步  $t$  的注意力输出。该输出是所有时间步值的加权和，使模型能够聚焦于最重要的帧。时间步  $t$  的注意力特征计算如下：

$$X_{\text{attended},t} = \sum_{t'} \text{Attn}_{t,t'} \cdot V_{t'}. \quad (5)$$

最终的注意力特征随后通过线性投影生成输出张量  $X_{\text{temporal}}$ 。时间注意力机制通过聚焦于相关时间步，有效地学习长期时间依赖关系，使其特别适用于建模动态环境，其中过去帧与未来帧之间的关系对于准确预测至关重要。

**4) 融合交叉注意力：** 为了将动态特征与观测历史相关联，我们应用交叉注意力将差分特征  $D_t$  与历史库  $X_{\text{temporal}}$  中的时间上下文进行融合。给定来自  $X_{\text{temporal}}$  的查询  $Q_t$

以及来自  $D_t$  的键/值  $K_t, V_t$ ，注意力输出为

$$\text{Attn}(Q_t, K_t, V_t) = \text{softmax}\left(\frac{Q_t K_t^T}{\sqrt{d_k}}\right) V_t, \quad (6)$$

其中  $d_k$  是键的维度。这种交叉注意力将时间上下文与差分线索对齐，使模型能够关注随时间变化的动态。令  $F_M$  表示融合表示，它综合了历史记忆和动态变化。

**5) 基于差分的自监督：** 在本节中，我们提出了一种用于动态特征提取器的自监督学习方案，该方案利用帧间差分来建模时间变化，从而无需人工标签。

在训练过程中，在第  $M$  步，提取器生成预测的动态特征  $F_M$ ，而历史库提供差分目标  $D_{M-1}$ （第 III-B.1 节）。模型以先前帧为条件， $D_{M-1}$  作为监督信号。为使预测与观测到的变化对齐，本文最小化归一化特征之间的 KL 散度：

$$\mathcal{L}_{\text{diff}} = \sum_{t=1}^T \text{KL}\left(\text{softmax}(F_M^{(t)}) \parallel \text{softmax}(D_{M-1}^{(t)})\right). \quad (7)$$

该目标促使表示在无需人工标注的情况下捕捉时间动态。

**6) 变分自编码器：** 本文采用一种改进的变分自编码器（Variational Autoencoder, VAE）来预测未来动作。该模型由编码器和解码器组成，编码器处理动作序列，解码器以动态时间特征为条件生成预测的未来动作。这种架构使模型能够学习紧凑的潜表示，捕捉当前动作与未来动作之间的关键时间动态。编码器与潜空间表示。编码器网络以动作序列  $A_t$  作为输入，并

输出均值 ( $\mu$  和对数方差 ( $\log(\sigma^2)$ ) of  $\mathbf{a}$  的高斯分布, 该分布参数化了隐变量  $\mathbf{z}$  上的近似后验分布  $q(\mathbf{z} | \mathbf{A}_t)$  :

$$q(\mathbf{z} | \mathbf{A}_t) = \mathcal{N}(\mu, \sigma^2). \quad (8)$$

该分布用于捕捉动作序列中潜在的变化因素。随后, 利用重参数化技巧从该分布中采样隐向量  $\mathbf{z}$ , 以便在随机采样过程中进行反向传播:

$$\mathbf{z} = \mu + \sigma \cdot \varepsilon, \quad (9)$$

其中  $\varepsilon \sim \mathcal{N}(0, I)$  为随机噪声,  $\sigma = \exp(\frac{1}{2} \log(\sigma^2))$  为由对方数方差导出的标准差。

**解码器与动作预测。** 解码器基于潜在向量  $\mathbf{z}$  和动作序列的动态特征  $\mathbf{F}_M$  生成预测的未来动作  $\hat{\mathbf{A}}_t$ 。这些动态特征  $\mathbf{F}_M$  捕捉了环境的时间依赖性, 并作为动作预测的额外上下文。解码器使用循环神经网络 (RNN) 重建动作序列, 该网络接收潜在向量和时间上下文, 输出预测的动作序列:

$$p(\mathbf{A}_t | \mathbf{z}, \mathbf{F}_M) = \mathcal{N}(\hat{\mathbf{A}}_t, \sigma_{\text{decoder}}^2). \quad (10)$$

此处,  $\hat{\mathbf{A}}_t$  为预测动作,  $\sigma_{\text{decoder}}$  为预测分布的标准差。

**7) 损失: 变分自编码器 (VAE) 的训练目标是重建损失与 KL 发散正则化的组合。** 重建损失计算如下:

$$\mathcal{L}_{\text{recon}} = \text{MSELoss}(\hat{\mathbf{A}}_t, \mathbf{A}_t). \quad (11)$$

KL 发散计算如下:

$$\mathcal{L}_{\text{KL}} = -\frac{1}{2} \sum_{i=1}^d (1 + \log(\sigma_i^2) - \mu_i^2 - \sigma_i^2), \quad (12)$$

其中  $\mu_i$  和  $\sigma_i$  分别为第  $i$  个潜在维度的后验均值和标准差。差分损失  $\mathcal{L}_{\text{diff}}$  利用上述 KL 发散计算。因此, 总损失函数为重建损失、KL 发散和差分损失的加权和:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{recon}} + \lambda_{\text{KL}} \mathcal{L}_{\text{KL}} + \lambda_{\text{diff}} \mathcal{L}_{\text{diff}}, \quad (13)$$

其中  $\lambda_{\text{KL}}$  和  $\lambda_{\text{diff}}$  为控制各项相对重要性的超参数。前向传播涉及动作序列  $\mathbf{A}_t$  和时间条件特征  $\mathbf{F}_M$ , VAE 模型输出重建动作  $\hat{\mathbf{A}}_t$ , 以及编码器的均值  $\mu$  和对数方差  $\log(\sigma^2)$ 。总损失随后反向传播以更新模型参数。

### C. 阶段 2: 免训练扩散的动态注入

策略 在动态评估期间, 我们维护一个长度为  $M$  的滑动窗口

在观测数据上,  $\mathbf{O}_{t-M+1:t} =$

$[\mathbf{o}_{t-M+1}, \dots, \mathbf{o}_t]$  随后, 我们利用第一阶段快速动态感知提取器在线计算动态感知特征  $\pi_f$  :

$$\mathbf{F}_t = \pi_f(\mathbf{O}_{t-M+1:t}) \in \mathbb{R}^{d_f}. \quad (14)$$

冻结的慢速扩散策略基于当前观测生成一个长度为  $H$  的开环动作块,

$$\mathbf{A}_{t:t+H-1} \sim \pi_s(\cdot | \mathbf{o}_t), \quad \mathbf{A}_{t:t+H-1} = [\mathbf{a}_t, \dots, \mathbf{a}_{t+H-1}]. \quad (15)$$

对于特征注入, 我们首先利用已知边界进行逐元素归一化  $\mathbf{a}_{\min}, \mathbf{a}_{\max}$  :

$$\tilde{\mathbf{A}}_{t:t+H-1} = 2 \frac{\mathbf{A}_{t:t+H-1} - \mathbf{a}_{\min}}{\mathbf{a}_{\max} - \mathbf{a}_{\min}} - \mathbf{1}, \quad (16)$$

其中所有操作均为逐元素执行,  $\mathbf{1}$  表示与  $\mathbf{A}_{t:t+H-1}$  形状相同的全一张量。随后, 我们利用第一阶段训练好的冻结变分自编码器编码器  $E$  将该块编码为潜在向量:

$$\mathbf{z}_t = E(\tilde{\mathbf{A}}_{t:t+H-1}) \in \mathbb{R}^{d_z}. \quad (17)$$

在每个块内, 执行以闭环方式进行。对于每一步  $s \in \{0, \dots, H-1\}$ , 我们刷新历史窗口并重新计算特征:

$$\mathbf{F}_{t+s} = \pi_f(\mathbf{O}_{t+s-M+1:t+s}). \quad (18)$$

随后, 我们利用第一阶段训练好的冻结变分自编码器解码器  $D$ , 以步骤嵌入  $\mathbf{e}_s$  为条件, 解码出动态校正后的动作:

$$\hat{\mathbf{a}}_{t+s} = D(\mathbf{z}_t, \mathbf{F}_{t+s}, \mathbf{e}_s). \quad (19)$$

对所有步骤进行聚合, 得到闭环动作块:

$$\hat{\mathbf{A}}'_{t:t+H-1} = [D(\mathbf{z}_t, \mathbf{F}_t, \mathbf{e}_0), \dots, D(\mathbf{z}_t, \mathbf{F}_{t+H-1}, \mathbf{e}_{H-1})]. \quad (20)$$

Equivalently, this induces a deterministic joint closed-loop policy

$$\pi_c(\hat{\mathbf{a}}_{t+s} | \mathbf{o}_t, \mathbf{O}_{t+s-M+1:t+s}) = \delta(\hat{\mathbf{a}}_{t+s} - D(E(\text{norm}(\pi_s(\mathbf{o}_t))), \pi_f(\mathbf{O}_{t+s-M+1:t+s}), \mathbf{e}_s)) \quad (21)$$

其中范数  $(\cdot)$  表示上述线性归一化,  $\delta(\cdot)$  为指示确定性映射的狄拉克  $\delta$  函数。在  $s = H-1$  之后, 我们通过对  $\pi_s$  中利用最新观测重新采样新块来进行重规划 (滚动时域), 同时保持所有模块冻结; 因此, 整个第二阶段过程无需训练。持续注入  $\mathbf{F}_{t+s}$  为开环扩散块提供细粒度在线校正, 提升快速变化场景中的响应性与鲁棒性。

## 四、实验

本节在动态场景下的 PushT 任务上评估所提算法。首先, 在静态设置下, 评估该方法对任务成功率的影响, 并与标准扩散策略推理策略进行比较。然后, 在动态场景中, 进一步考察算法的鲁棒性与泛化能力, 并进行消融研究以验证各设计模块的有效性。最后, 测量算法的推理延迟,



证明其轻量特性，并表明其能够支持高频闭环控制与实时部署。

### A. 实验设置

对于 PushT 任务，我们采用由人类演示训练得到的扩散策略作为基本控制策略。推理过程中，将批大小设为  $N = 50$ ，即在仿真环境中随机生成 50 个初始位姿并在整个实验中保持不变。对于每个初始条件，我们在环境中进行推演，并以任务成功率和推理延迟为指标评估各方法的性能。仿真在达到最大步数  $T_{\max} = 300$  时终止，或当物体与目标位置的重叠率  $\sigma$  超过 95% 时提前终止。仿真环境以 10 Hz 运行。模型在单次推理中预测接下来的 16 个动作，并以开环方式执行前 8 个动作。

**基线方法：**我们考虑三种具有代表性的现有推理方法作为比较基线：• 原始 Open-loop( $H=8$ ): 在每个推理步骤执行整个动作块。• 原始 Closed-loop( $H=1$ ): 在每个推理步骤仅执行最近的一个动作。• 时间集成 [23]( $H=1$ ): 在每个重叠步骤，将新预测  $\alpha$  与先前预测  $\hat{\alpha}$  进行平均，以产生更平滑的动作块：

$$\alpha_t = \lambda \alpha_t + (1 - \lambda) \hat{\alpha}_t, \text{ 其中 } \lambda \text{ 设为 } 0.5.$$

$H$  表示扩散策略模型每  $H$  个时间步推断一次。

**扰动：**为系统评估所提方法在动态条件下的鲁棒性与泛化能力，本文在仿真中引入两类扰动：• 恒定方向扰动：在每个执行步中，对物体施加固定大小和方向的偏移，以模拟持续的外力。

• 随机方向扰动：在每个执行步中，施加固定大小但方向随机变化的偏移，方向每隔

$N = 50$  steps.




图 3. 考虑了不同类型的扰动，其中随机扰动在特定时间步更新其方向。

### Dataset

本研究采用一个公开的人类演示数据集，该数据集包含 200 条轨迹，其中积木不受外部扰动影响。

**模型训练：**本文方法在单块 NVIDIA A800 80GB 图形处理器上从零开始训练。作为比较，

基线扩散策略采用默认参数训练 500 个训练轮次以确保收敛。

**推理延迟测度：**为确保推理效率的公平评估，本文在相同的硬件和软件配置下，于单块 NVIDIA RTX 4090 24GB 图形处理器上测度所有推理延迟。

### B. 定量分析

表 1 展示了所提方法与若干基线在静态场景和不同扰动下的动态场景中的任务成功率比较。

表一 三种扰动强度下的成功率表明，所提出的 DCDP 方法优于所有基线方法。

| Methods           | Static      | Constant Perturbations | Random Perturbations |
|-------------------|-------------|------------------------|----------------------|
| Open-Loop         | 88.4        | 58.2                   | 52.8                 |
| Close-Loop        | 84.6        | 76.1                   | 61.6                 |
| Temporal Ensemble | 81.0        | 65.8                   | 57.3                 |
| <b>DCDP</b>       | <b>92.5</b> | <b>77.6</b>            | <b>71.9</b>          |

表二展示了每种方法的平均单步延迟，突出了本文方法在实时性和计算效率方面的改进。

表二 每步推理延迟的比较。DCDP 在闭环执行中仅增加 5% 的开销，显著低于其他闭环方法。

| Methods    | OL( $H=8$ ) | CL( $H=1$ ) | TE( $H=1$ ) | DCDP( $H=8$ ) |
|------------|-------------|-------------|-------------|---------------|
| Delay (ms) | 7.05        | 53.60       | 53.74       | <b>7.39</b>   |

我们观察到，在动态场景下，原始闭环策略在任务成功率方面优于开环策略，而在静态场景下则表现出明显的性能下降。我们推测这是因为作为扩散模型，扩散策略在每次推理步骤中重新规划整个动作序列，导致连续动作之间的不连续性。这可能削弱其再现人类演示中长期协调的能力，从而降低任务成功率。相比之下，DCDP 以较低的重新规划频率运行，利用扩散策略的长期规划能力，同时整合近期观测以实现快速闭环控制，从而在静态和动态任务中均取得显著改进。此外，推理延迟数据表明，本文的轻量级模型在实时性能方面具有明显优势，延迟低于直接闭环策略，并支持高频闭环控制。




图 4. 不同推理策略对扰动响应的可视化。

### C. 消融实验


为评估所提出架构中每个模块的必要性和有效性，我们进行了消融实验，分析它们对模型性能的相对贡献。具体而言，我们对自监督动态特征提取模块进行了消融实验。依次移除关键组件，并在每次移除后重新训练第一阶段。训练参数和评估指标与原始实验保持一致。

表三 消融单个模块后的任务成功率，表明 DCDP 中的每个模块都是有效的。

| TA | SSD | DCA | SRstatic | SRdynamic |              |              |
|----|-----|-----|----------|-----------|--------------|--------------|
|    |     |     |          |           | 88.40        | 58.20        |
|    |     | ✓   |          | ✓         | 92.05        | 73.59        |
| ✓  |     |     |          | ✓         | 92.31        | 73.50        |
| ✓  |     | ✓   |          |           | 93.36        | 68.23        |
| ✓  |     | ✓   |          | ✓         | <b>92.50</b> | <b>77.60</b> |

表 III 展示了消融实验的结果。**TA** 表示时间注意力，**SSD** 表示自监督差异损失，**DCA** 表示差异交叉注意力，**SRstatic**、**SRdynamic** 表示成功率 (%)。我们选取静态场景和恒定方向扰动作为评估度量。结果表明，所有提出的模块均对系统性能有积极贡献。

### Pick and place a moving cup



### Pour liquid into a moving cup




图 5. 两个任务包含两种扰动类型：恒定方向和随机方向。这些扰动仅施加于图中高亮显示的组件上。

### D. 实际应用

为验证所提算法在实际场景中的有效性，我们选取两个代表性操作任务进行评估：• 移动杯子的抓取与放置，对应恒定方向扰动场景，考察算法在持续扰动下的鲁棒性；

• 向移动杯子中倾倒液体，对应随机方向扰动场景，评估算法对不确定扰动的适应性。我们采用 UMI [22] 夹爪执行任务，并利用公开的 FastUMI 数据集，复现其场景以构建实际评估平台。在实际任务测试中，我们采用 PushT 动态任务评估设计，并施加恒定和随机扰动。恒定方向扰动应用于“抓取并放置移动杯子”任务，其中杯子在抓取前沿单一方向移动。随机扰动应用于“向移动杯子中倾倒液体”任务，其中杯子的移动方向随机，要求机械臂准确地将液体倒入其中。结果表明，与原始推理方法相比，DCDP 在动态环境中表现出显著增强的适应性，能够处理多种动态场景。

### V. 结论

本文提出 DCDP，一种免训练闭环动作块框架，将高频动态特征注入预训练扩散策略以实现实时校正。关键要素包括自监督动态特征

编码器、用于时序感知的交叉/时序注意力，以及一个非对称的动作编码器/解码器，该解码器利用更新后的上下文解码冻结的扩散块。由于校正发生在推理阶段且无需重新训练，DCDP 在长时程规划与响应式控制之间实现了轻量级、即插即用的平衡。目前的局限包括仅在单一模拟任务和小规模数据集上进行评估；未来工作应测试多样化任务、真实硬件以及具有多模态动态的自适应调度。

致谢 本研究得到上海人工智能实验室、国家重点研发计划（2024YFC3015503）、国家自然科学基金（62376222）以及陕西省自然科学基金基础研究计划（2025JC-TBZC-07）的资助。

## 参考文献

- [1] C. Chi, S. Feng, Y. Du, Z. Xu, E. Cousineau, B. Burchfiel, and S. Song, "Diffusion Policy: Visuomotor Policy Learning via Action Diffusion," in *Robotics: Science and Systems XIX*. Robotics: Science and Systems Foundation, July 2023.
- [2] M. Reuss, M. Li, X. Jia, and R. Lioutikov, "Goal-conditioned imitation learning using score-based diffusion policies," *arXiv preprint arXiv:2304.02532*, 2023.
- [3] Y. Liu, W. C. Shin, Y. Han, Z. Chen, H. Ravichandar, and D. Xu, "Imimic: Cross-domain imitation from human videos via mapping and interpolation," 2025.
- [4] M. Janner, Y. Du, J. B. Tenenbaum, and S. Levine, "Planning with diffusion for flexible behavior synthesis," *arXiv preprint arXiv:2205.09991*, 2022.
- [5] T. Pearce, T. Rashid, A. Kanervisto, D. Bignell, M. Sun, R. Georgescu, S. V. Macua, S. Z. Tan, I. Momennejad, K. Hofmann, et al., "Imitating human behaviour with diffusion models," *arXiv preprint arXiv:2301.10677*, 2023.
- [6] A. Prasad, K. Lin, J. Wu, L. Zhou, and J. Bohg, "Consistency policy: Accelerated visuomotor policies via consistency distillation," *arXiv preprint arXiv:2405.07503*, 2024.
- [7] Y. Liu, J. I. Hamid, A. Xie, Y. Lee, M. Du, and C. Finn, "Bidirectional decoding: Improving action chunking via closed-loop resampling," *International Conference on Learning Representations (ICLR)*, 2025.
- [8] A. George and A. B. Farimani, "One act play: Single demonstration behavior cloning with action chunking transformers," *arXiv preprint arXiv:2309.10175*, 2023.
- [9] Q. Vuong, S. Levine, H. R. Walke, K. Pertsch, A. Singh, R. Doshi, C. Xu, J. Luo, L. Tan, D. Shah, et al., "Open x-embodiment: Robotic learning datasets and rt-x models," in *Towards Generalist Robots: Learning Paradigms for Scalable Skill Acquisition@ CoRL2023*, 2023.
- [10] A. Khazatsky, K. Pertsch, S. Nair, A. Balakrishna, S. Dasari, S. Karamcheti, S. Nasiriany, M. K. Srirama, L. Y. Chen, K. Ellis, et al., "Droid: A large-scale in-the-wild robot manipulation dataset," *arXiv preprint arXiv:2403.12945*, 2024.
- [11] H. R. Walke, K. Black, T. Z. Zhao, Q. Vuong, C. Zheng, P. Hansen-Estruch, A. W. He, V. Myers, M. J. Kim, M. Du, et al., "Bridgedata v2: A dataset for robot learning at scale," in *Conference on Robot Learning*. PMLR, 2023, pp. 1723–1736.
- [12] P. Zhang, X. Gao, Y. Wu, K. Liu, D. Wang, Z. Wang, B. Zhao, Y. Ding, and X. Li, "Moma-kitchen: A 100k+ benchmark for affordance-grounded last-mile navigation in mobile manipulation," in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, October 2025, pp. 6315–6326.
- [13] F. Torabi, G. Warnell, and P. Stone, "Behavioral cloning from observation," *arXiv preprint arXiv:1805.01954*, 2018.
- [14] M. J. Kim, K. Pertsch, S. Karamcheti, T. Xiao, A. Balakrishna, S. Nair, R. Rafailov, E. Foster, G. Lam, P. Sanketi, et al., "Openvla: An open-source vision-language-action model," *arXiv preprint arXiv:2406.09246*, 2024.
- [15] S. Liu, L. Wu, B. Li, H. Tan, H. Chen, Z. Wang, K. Xu, H. Su, and J. Zhu, "Rdt-1b: a diffusion foundation model for bimanual manipulation," *arXiv preprint arXiv:2410.07864*, 2024.
- [16] K. Black, N. Brown, D. Driess, A. Esmail, M. Equi, C. Finn, N. Fusai, L. Groom, K. Hausman, B. Ichter, et al., " $\pi_0$ : A vision-language-action flow model for general robot control," *arXiv preprint arXiv:2410.24164*, 2024.
- [17] H. Liang, X. Chen, B. Wang, M. Chen, Y. Liu, Y. Zhang, Z. Chen, T. Yang, Y. Chen, J. Pang, et al., "Mm-act: Learn from multimodal parallel generation to act," *arXiv preprint arXiv:2512.00975*, 2025.
- [18] S. Yang, H. Li, Y. Chen, B. Wang, Y. Tian, T. Wang, H. Wang, F. Zhao, Y. Liao, and J. Pang, "Instructvla: Vision-language-action instruction tuning from understanding to manipulation," *arXiv preprint arXiv:2507.17520*, 2025.
- [19] X. Chen, Y. Chen, Y. Fu, N. Gao, J. Jia, W. Jin, H. Li, Y. Mu, J. Pang, Y. Qiao, et al., "Internvla-m1: A spatially guided vision-language-action framework for generalist robot policy," *arXiv preprint arXiv:2510.13778*, 2025.
- [20] P. Zhang, Y. Su, P. Wu, D. An, L. Zhang, Z. Wang, D. Wang, Y. Ding, B. Zhao, and X. Li, "Cross from left to right brain: Adaptive text dreamer for vision-and-language navigation," 2025.
- [21] A. Brohan, N. Brown, J. Carbajal, Y. Chebotar, J. Dabis, C. Finn, K. Gopalakrishnan, K. Hausman, A. Herzog, J. Hsu, et al., "Rt-1: Robotics transformer for real-world control at scale," *arXiv preprint arXiv:2212.06817*, 2022.
- [22] C. Chi, Z. Xu, C. Pan, E. Cousineau, B. Burchfiel, S. Feng, R. Tedrake, and S. Song, "Universal manipulation interface: In-the-wild robot teaching without in-the-wild robots," *arXiv preprint arXiv:2402.10329*, 2024.
- [23] T. Z. Zhao, V. Kumar, S. Levine, and C. Finn, "Learning fine-grained bimanual manipulation with low-cost hardware," *arXiv preprint arXiv:2304.13705*, 2023.
- [24] G. Swamy, S. Choudhury, D. Bagnell, and S. Wu, "Causal imitation learning under temporally correlated noise," in *International Conference on Machine Learning*. PMLR, 2022, pp. 20 877–20 890.
- [25] H. Xue, J. Ren, W. Chen, G. Zhang, Y. Fang, G. Gu, H. Xu, and C. Lu, "Reactive diffusion policy: Slow-fast visual-tactile policy learning for contact-rich manipulation," *arXiv preprint arXiv:2503.02881*, 2025.
- [26] X. Ye, R. H. Yang, J. Jin, Y. Li, and A. Rasouli, "Ra-dp: Rapid adaptive diffusion policy for training-free high-frequency robotics replanning," *arXiv preprint arXiv:2503.04051*, 2025.
- [27] L. X. Shi, Z. Hu, T. Z. Zhao, A. Sharma, K. Pertsch, J. Luo, S. Levine, and C. Finn, "Yell at your robot: Improving on-the-fly from language corrections," *arXiv preprint arXiv:2403.12910*, 2024.
- [28] A. Labiosa, Z. Wang, S. Agarwal, W. Cong, G. Hemkumar, A. N. Harish, B. Hong, J. Kelle, C. Li, Y. Li, et al., "Reinforcement learning within the classical robotics stack: A case study in robot soccer," in *2025 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2025, pp. 14 999–15 006.
- [29] Z. Shi, X. Zhang, C. Zhu, H. Wang, J. Yan, F. Yang, and D. Xuan, "Mv-bmr: A real-time motion and vision sensing integration based agile badminton robot," *Information Fusion*, p. 103337, 2025.
- [30] Z. Su, B. Zhang, N. Rahmanian, Y. Gao, Q. Liao, C. Regan, K. Sreenath, and S. S. Sastry, "Hitter: A humanoid table tennis robot via hierarchical planning and learning," *arXiv preprint arXiv:2508.21043*, 2025.
- [31] N. Hansen, X. Wang, and H. Su, "Temporal difference learning for model predictive control," *arXiv preprint arXiv:2203.04955*, 2022.
- [32] T. Salzmann, E. Kaufmann, J. Arrizabalaga, M. Pavone, D. Scaramuzza, and M. Ryll, "Real-time neural mpc: Deep learning model predictive control for quadrotors and agile robotic platforms," *IEEE Robotics and Automation Letters*, vol. 8, no. 4, pp. 2397–2404, 2023.
- [33] J. B. Rawlings, D. Q. Mayne, M. Diehl, et al., *Model predictive control: theory, computation, and design*. Nob Hill Publishing Madison, WI, 2020, vol. 2.
- [34] Y. Zhang, T. Liang, Z. Chen, Y. Ze, and H. Xu, "Catch it! learning to catch in flight with mobile dexterous hands," in *2025 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2025, pp. 14 385–14 391.
- [35] H. Zhang, S. Christen, Z. Fan, O. Hilliges, and J. Song, "Graspplx: Generating grasping motions for diverse objects at scale," in *European Conference on Computer Vision*. Springer, 2024, pp. 386–403.
- [36] Y. Zhang, M. Xu, X. Bai, K. Chen, P. Zhang, Y. Xiang, and M. Zhang, "Instruction anchors: Dissecting the causal dynamics of modality arbitration," *arXiv preprint arXiv:2602.03677*, 2026.