

揭示测试时自适应的对抗性风险

Tong Wu[†] Feiran Jia[‡] Xiangyu Qi[†] Jiachen T. Wang[†]
Vikash Sehwal[†] Saeed Mahloujifar[†] Prateek Mittal[†]

[†]Princeton University, [‡]Penn State University

摘要

近期，测试时自适应（**Test-Time Adaptation, TTA**）被提出作为解决分布偏移问题的一种有前景的方案。它允许基础模型在推理过程中利用（未标记的）测试数据批次中的信息，适应未预见的分布。然而，我们基于一个洞见揭示了 **TTA** 的一个新颖安全漏洞：良性样本的预测可能受到同一批次中恶意样本的影响。为利用这一漏洞，我们提出了分布入侵攻击（**Distribution Invading Attack, DIA**），该攻击向测试批次中注入少量恶意数据。**DIA** 导致使用 **TTA** 的模型对良性且未扰动的测试数据产生错误分类，为对手提供了一种在传统机器学习流程中无法实现的全新能力。通过全面评估，我们证明了该攻击在多个基准上对六种 **TTA** 方法具有高效性。作为回应，我们研究了两种对策，以强化现有不安全的 **TTA** 实现，遵循“设计即安全”的原则。总之，我们希望我们的发现能让社区意识到部署 **TTA** 时效用与安全之间的权衡，并为开发鲁棒的 **TTA** 方法提供有价值的洞见。

1. 引言

测试时自适应（**Test-Time Adaptation, TTA**）（Wang 等, 2021b; Schneider 等, 2020; Goyal 等, 2022）是一种前沿的机器学习（**Machine Learning, ML**）方法，用于解决测试数据中的分布偏移问题（Hendrycks & Dietterich, 2019）。与依赖固定基础模型的传统机器学习方法不同，**TTA** 生成批次特定的模型来处理不同的测试数据分布。具体而言，当测试数据按批次处理时（bat, 2021），**TTA** 首先利用




图 1. 传统机器学习与测试时自适应的概览。测试时自适应适应测试批次，但在测试时容易受到恶意数据的影响（与传统机器学习形成对比）。

它们用于更新基础模型，随后利用更新后的模型进行最终预测。在方法论上，测试时自适应（**TTA**）不同于传统的机器学习（归纳学习），属于直推式学习范式（Vapnik, 1998）。在分布偏移下，**TTA** 通常优于传统机器学习，原因在于：1) 它从测试批次中获取分布知识；2) 它能够自适应地调整模型。经验表明，**TTA** 在一系列任务中表现出有效性，包括图像分类（Wang et al., 2021b）、目标检测（Sinha et al., 2023）以及视觉文档理解（Ebrahimi et al., 2022）。

然而，在本工作中，我们揭示了测试时自适应过程中一个潜在的安全漏洞——攻击者可以通过在测试批次中构造样本来向模型注入恶意行为。我们的核心洞见是：**TTA** 基于整个测试批次生成最终的预测模型，而非像传统机器学习流程那样对每个数据独立预测。因此，批次中一个条目的预测会受到同一批次中其他条目的影响。结果，攻击者可能在测试时提交恶意数据以干扰最终预测模型的生成，从而破坏良性用户提交的其他未扰动数据的预测。这凸显了在部署 **TTA** 时考虑效用与安全权衡的必要性。

本文贡献。为利用这一漏洞，我们提出了一种新颖的攻击方法，称为分布入侵攻击（**DIA**），它通过引入恶意数据来利用 **TTA**（第 4 节）。具体而言，**DIA** 构造（或上传）少量恶意样本（例如批次的 5%）到测试批次中，旨在诱导良性样本的误预测。我们将 **DIA** 形式化为一个双层优化问题，外层优化用于构造恶意数据，内层优化用于 **TTA** 更新。接着，我们通过近似模型参数将其转化为单层优化，该问题可通过投影梯度下降机制求解。**DIA** 是一个通用框架，能够实现多种对抗目标，包括：1) 将关键样本的预测翻转为选定标签（定向攻击）；2) 降低所有良性数据的性能（无差别攻击）。

首先利用 < tongwu@princeton.edu > 的通信信息。

恶意样本（例如批次的 5%）到测试批次中，旨在诱导良性样本的误预测。我们将 DIA 形式化为一个双层优化问题，外层优化用于构造恶意数据，内层优化用于 TTA 更新。接着，我们通过近似模型参数将其转化为单层优化，该问题可通过投影梯度下降机制求解。DIA 是一个通用框架，能够实现多种对抗目标，包括：1) 将关键样本的预测翻转为选定标签（定向攻击）；2) 降低所有良性数据的性能（无差别攻击）。

在第 5 节中，我们通过实验证明，动态输入攻击（DIA）在多个基准数据集上对多种测试时自适应（TTA）方法均取得了较高的攻击成功率（ASR），这些基准包括 CIFAR-10-C、CIFAR-100-C 和 ImageNet-C (Hendrycks & Dietterich, 2019)，而受攻击的方法包括 TeBN (Nado et al., 2020)、TENT (Wang et al., 2021b) 和 Hard PL (Lee et al., 2013)。值得注意的是，我们展示了在测试批次中使用 5% 的恶意样本进行定向攻击，即可在 ImageNet-C 上实现超过 92% 的攻击成功率。我们的评估还表明，DIA 在多种模型架构和数据增强条件下均表现良好。此外，即使要求恶意输入必须经过伪装以绕过人工检查，该攻击仍然有效。

为此，我们探索了通过融入“设计即安全”原则来增强现有 TTA 方法的对策（第 6 节）。鉴于经过对抗训练的模型 (Madry et al., 2018) 对扰动更具抵抗力，我们研究了使用它们作为基础模型来防御 DIA 的可能性。此外，由于 TTA 的脆弱性主要源于批量归一化 (BN) 的不安全计算，我们探索了两种稳健估计 BN 的方法。首先，我们利用训练期间计算的 BN 作为最终 BN 统计量的先验，该先验对 DIA 具有鲁棒性。其次，我们观察到 DIA 对后续层 BN 统计量的影响大于其他层，并据此开发了一种调整 BN 统计量的方法。我们的评估表明，结合对抗模型和稳健 BN 估计对防御 DIA 是有效的，这为未来提高 TTA 鲁棒性的工作提供了指导。

总体而言，我们的工作表明，在努力提升效用的过程中，使用测试时自适应（转导学习范式）无意中放大了安全风险。这种效用与安全之间的权衡在归纳学习中已被深入探讨 (Chakraborty et al., 2018)，我们敦促社区在利用转导学习提升效用时，借鉴归纳学习的先前工作，充分考虑这些安全风险。

2. 背景与相关工作

在本节中，我们介绍测试时自适应，然后回顾对抗机器学习中的相关工作。更多细节可参见附录 A。

2.1. 符号表示与测试时自适应

设 $\mathcal{D}^s := \{(\mathbf{x}_i^s, y_i^s)\}_{i=1}^{N_s}$ 为来自源域的训练数据集， $\mathbf{X}^t := \{\mathbf{x}_i^t\}_{i=1}^{N_t}$ 为来自目标域的无标签测试数据集，其中 N_s 和 N_t 分别表示 $\mathcal{D}^s$ 和 $\mathbf{X}^t$ 中的样本数量。目标是学习一个由 θ 参数化的预测规则 $f(\cdot; \theta)$ ，能够正确预测每个 $\mathbf{x}_i^t \in \mathbf{X}^t$ 的标签 y_i^t 。在传统机器学习（归纳学习）设置中，我们通过在源数据集 $\mathcal{D}^s$ 上训练来找到最佳模型参数 θ^s 。然而，在实践中，训练和测试数据分布可能发生偏移，固定的模型 $f(\cdot; \theta^s)$ 将导致性能不佳 (Hendrycks & Dietterich, 2019)。为了解决这个问题，在直推学习设置下提出了测试时自适应 (TTA) (Wang et al., 2021b)。具体来说，TTA 首先获得一个从源训练集 $\mathcal{D}^s$ 学习或从在线来源下载的 $f(\cdot; \theta^s)$ ，然后在推理过程中适应测试数据 $\mathbf{X}^t$ 。在这种情况下，TTA 可以刻画 $\mathbf{X}^t$ 的分布，从而提升性能。

2.2. 在 TTA 中利用测试批次 TTA 技术通常用于测试数据以在线方式逐批处理的情况。¹ 设 $\mathbf{X}_B^t = \{\mathbf{x}_i^t\}_{i=1}^{N_{Bt}} \subseteq \mathbf{X}^t$ 为大小为 N_{Bt} 的测试数据子集（即批次）， $f(\cdot; \theta^{\text{pre}})$ 为即将立即执行自适应的预适应模型。初始时，我们设置 $\theta^{\text{pre}} = \theta^s$ 。在每次迭代中，新的测试数据批次 $\mathbf{X}_B^t$ 可用；模型参数的部分内容相应更新，最终预测基于更新后的模型。这里我们介绍两种主流技术：

测试时批归一化 (TeBN)。 批归一化 (BN) (Ioffe & Szegedy, 2015) 通过批次均值和方差对输入特征进行归一化，减少神经网络中的内部协变量偏移。Nado et al. (2020) 将训练集上的归一化统计量 $\{\mu, \sigma^2\}$ 替换为测试批

$$\mathbf{X}_B^t \quad \theta_B(\mathbf{X}_B^t) := \{\mu(\mathbf{X}_B^t), \sigma^2(\mathbf{X}_B^t)\},$$

次的统计量，记为其中 θ_B 是 BN 统计量。这有助于模型更好地泛化到未见过的偏移数据分布。

自学习 (Self Learning (SL))。 SL 通过损失函数 $\mathcal{L}_{\text{TTA}}$ 的梯度更新模型参数 θ_A 的一部分。一些方法如 TENT (Wang et al., 2021b) 最小化一批测试样本上预测分布的熵，其中损失为。然后我们将剩余参数记为 $\theta_{\mathcal{F}} := \theta^s \setminus (\theta_A \cup \theta_B)$ ，它们保持固定。在其他方法中

¹ 我们排除了单样本测试时自适应方法（例如，Zhang 等人 (2021a)），这类方法通常比批量版本表现更差。此外，它们对每个测试数据独立预测，避免了本文讨论的风险。

类似于伪标签 (PL)，损失可以表示为 $\mathcal{L}_{\text{TTA}}(\mathbf{X}_B^t, \tilde{\mathbf{y}})$ ，其中 $\tilde{\mathbf{y}} = \{\tilde{y}_i\}_{i=1}^{N_{Bt}}$ 表示伪标签。在标准 PL 方法中，伪标签 $\tilde{\mathbf{y}}$ 可以直接由教师模型预测，称为硬伪标签 (Lee 等人, 2013)，或通过预测类别概率，称为软伪标签 (Lee 等人, 2013)。后来，Rusak 等人 (2022) 提出的鲁棒伪标签和 Goyal 等人 (2022) 提出的共轭伪标签通过更先进的测试时自适应损失进一步改进了伪标签。值得注意的是，所有自学习 (SL) 方法通常在 θ_A 等于批量归一化层的仿射变换时达到最佳性能 (Rusak 等人, 2022)。

2.3 相关工作

以往关于传统机器学习风险的研究主要集中在对抗攻击上，例如逃避攻击 (Biggio 等人, 2013; Goodfellow 等人, 2015; Carlini 和 Wagner, 2017)，这些攻击通过扰动测试数据使模型在推理时产生错误预测。然而，我们对测试时自适应的攻击不同之处在于，我们构造的恶意样本可以针对良性且未受扰动的数据。另一种机器学习风险是数据投毒 (Biggio 等人, 2012; Koh 和 Liang, 2017; Gu 等人, 2017)，它涉及将恶意数据注入训练样本，导致基于这些数据训练的模型做出错误预测。我们的攻击不同之处在于，我们仅假设能够访问未标记的测试数据，因此更容易在现实环境中部署。

据我们所知，这是首次揭示测试时自适应方法对抗风险的工作。我们在附录 A.5 中讨论了更多相关工作。

3 威胁模型

由于此前没有文献研究测试时自适应的脆弱性，我们首先讨论攻击者的目标、能力和知识。我们考虑一个场景：受害者获得一个源模型，该模型要么在源数据上训练，要么在线获取，并试图通过对一批测试数据进行测试时自适应来提升其性能。

对手的目标。分布的目标

分布入侵攻击 (Distribution Invading Attack, DIA) 是为了以下列方式之一干扰后适应模型的性能：(1)

定向攻击：将关键目标样本误分类为特定标签，(2) **无差别攻击**：提高同一批次中良性数据的整体错误率，或 (3)

隐蔽式定向攻击：在保持其他良性样本准确率的同时实现定向攻击。

对手的能力与额外约束。攻击者可以在推理阶段构造并上传有限数量的恶意样本到测试批次中。由于 DIA 不对目标样本进行任何扰动，在我们的主要评估中，只要恶意数据是有效图像，就不要求对其施加约束。然而，有时绕过人工检查是

值得关注的是，对手也可能构造伪装的恶意样本。具体而言，本文考虑对攻击样本施加两种约束：(1) ℓ_∞ 攻击 (Goodfellow 等人, 2015)，这是文献中最常见的做法；(2) 对抗性生成的扰动 (例如雪花) (Kang 等人, 2019)，用于模拟目标分布。

对手的知识。本文考虑一种白盒设定，其中域内自适应 (DIA) 攻击者已知预适应模型参数 θ^{pre} ，并对测试批次中的良性样本具有只读访问权限 (例如，涉及恶意内部人员)。然而，攻击者无法访问训练数据或训练过程。此外，本文的主要攻击方法 (在大多数实验中使用) 不要求知晓受害者将部署何种测试时自适应 (TTA) 方法。

4. 分布入侵攻击

在本节中，我们首先识别详细的漏洞 (第 4.1 节)，然后将分布入侵攻击 (Distribution Invading Attack) 形式化为一个通用的双层优化问题 (第 4.2 节)，最后讨论构造恶意样本 (第 4.3 节)。

4.1. 识别测试时增强的脆弱性

测试时自适应 (TTA) 的风险源于其转导学习范式，在该范式下，测试样本上的预测不再相互独立。本节将详细阐述 TTA 中采用的具体方法如何暴露安全漏洞。

重新估计批归一化统计量。大多数现有的测试时自适应方法 (Nado 等人, 2020; Wang 等人, 2021b; Rusak 等人, 2022) 采用测试时批归一化 (TeBN) 作为缓解分布偏移的基本方法，当源模型是带有 BN 层的 CNN 时。我们将 l th BN 层的输入记为 $\mathbf{z}_l$ ，每个 BN 层的测试时 BN 统计量可以通过前向路径依次计算

$\{\mu \leftarrow \mathbb{E}[\mathbf{z}_l], \sigma^2 \leftarrow \mathbb{E}[(\mu - \mathbf{z}_l)^2]\}$ ，其中期望 (即平均值) $\mathbb{E}$ 在输入上按通道应用。当在一批测试数据上计算 BN 统计量 θ_B 时，对批中某些样本的扰动会逐层影响统计量 μ, σ^2 ，并可能改变批中其他样本的输出 (即 $\mathbf{z}_l^{\text{out}} := (\mathbf{z}_l - \mu)/\sigma$)。因此，攻击者可以利用这一特性设计分布入侵攻击。

参数更新。为了进一步使模型适应目标分布，现有方法通常通过最小化在测试样本上定义的无监督目标来更新部分模型参数 θ_A (Wang 等人, 2021b; Rusak 等人, 2022; Goyal 等人, 2022)。更新后的参数可以通过以下方式计算： $\theta_A^* = \arg \min_{\theta_A} \mathcal{L}_{\text{TTA}}(\mathbf{X}_B^t; \theta_A)$ 因此， $\mathbf{X}_B^t$ 内部的恶意样本可能会扰动模型

参数 θ_A^* ，导致后续预测错误。

4.2. 将 DIA 形式化为双层优化

Problem

我们将动态输入攻击 (DIA) 表述为一个优化问题, 以利用上述两种漏洞。直观上, 我们希望构造一些恶意样本 $\mathbf{X}_{mal}^t := \{\mathbf{x}_{mal,i}^t\}_{i=1}^{N_m}$ 来实现攻击目标 (例如, 使目标样本被错误分类)。然后, 测试批次 $\mathbf{X}_B^t$ 由 $\mathbf{X}^t$ 和其他良性样本 $\mathbf{X}^t$ 组成。预适应模型参数 θ^{pre} 将由更新的参数 θ_A 、批归一化统计量 θ_B 和其他固定参数 θ_F (i.e., $\theta^{\text{pre}} := \theta_A \cup \theta_B \cup \theta_F$)。这里, 我们使用 $\mathbb{L}(f(\cdot; \theta^*(\mathbf{X}_B^t)))$ 来表示通用对抗损失, 攻击者的问题可以表述为以下双层优化:

$$\min_{\mathbf{X}_{mal}^t} \mathbb{L}(f(\cdot; \theta^*(\mathbf{X}_B^t))) \quad (1)$$

$$\begin{aligned} \text{s.t. } \mathbf{X}_B^t &= \mathbf{X}_{mal}^t \cup \mathbf{X}_{B \setminus mal}^t; \quad \theta'_B = \{\mu(\mathbf{X}_B^t), \sigma^2(\mathbf{X}_B^t)\}; \\ \theta_A^* &= \arg \min_{\theta_A} \mathcal{L}_{\text{TTA}}(\mathbf{X}_B^t; \theta_A, \theta'_B, \theta_F); \\ \theta^*(\mathbf{X}_B^t) &= \theta_A^* \cup \theta'_B \cup \theta_F; \end{aligned} \quad (2)$$

其中 θ'_B 是给定测试批次数据更新后的批归一化统计量, θ_A^* 是在测试时自适应损失上优化的参数, $\theta^*(\mathbf{X}_B^t)$ 是包含 θ_A^* , θ'_B 和其他固定参数 θ_F 的优化模型参数。在大多数情况下, 测试时自适应方法执行单步梯度下降更新 (Wang 等人, 2021b), 测试时自适应的内层优化简化为 $\theta_A^* = \theta'_A = \theta_A - \partial \mathcal{L}_{\text{TTA}}(\mathbf{X}_B^t) / \partial \theta_A$ 。现在, 我们讨论如何设计特定的对抗损失 $\mathbb{L}(f(\cdot; \theta^*(\mathbf{X}_B^t)))$ 以实现各种目标。

定向攻击。我们的目标是使模型对目标样本预测一个特定的错误目标标签 $\hat{y}_{tgt}$ 。因此, 目标可以表述 $\mathbf{x}_{tgt}^t \in \mathbf{X}_{B \setminus mal}^t$ 为:

$$\hat{\mathbf{X}}_{mal}^t := \arg \min_{\mathbf{X}_{mal}^t} \mathcal{L}(f(\mathbf{x}_{tgt}^t; \theta^*(\mathbf{X}_B^t)), \hat{y}_{tgt}) \quad (3)$$

其中 $\mathcal{L}$ 是交叉熵损失。

无差别攻击。目标转变为尽可能降低所有良性样本的性能。给定良性样本的正确标签 $\mathbf{y}_{B \setminus mal}^t$, 本文将无差别攻击的目标定义如下:

$$\hat{\mathbf{X}}_{mal}^t := \arg \min_{\mathbf{X}_{mal}^t} -\mathcal{L}(f(\mathbf{X}_{B \setminus mal}^t; \theta^*(\mathbf{X}_B^t)), \mathbf{y}_{B \setminus mal}^t). \quad (4)$$

隐蔽式定向攻击。在某些情况下, 执行定向攻击时, 其他良性样本 $\mathbf{X}_{B \setminus (tgt \cup mal)}^t$ (即整个测试批次中排除恶意和定向数据后的部分) 的性能可能会下降。一种解决方案是同时进行定向攻击并保持其他良性数据的准确率, 即:

$$\begin{aligned} \hat{\mathbf{X}}_{mal}^t &:= \arg \min_{\mathbf{X}_{mal}^t} \mathcal{L}(f(\mathbf{x}_{tgt}^t; \theta^*(\mathbf{X}_B^t)), \hat{y}_{tgt}) + \\ &\quad \omega * \mathcal{L}(f(\mathbf{X}_{B \setminus (tgt \cup mal)}^t; \theta^*(\mathbf{X}_B^t)), \mathbf{y}_{B \setminus (tgt \cup mal)}^t). \end{aligned} \quad (5)$$

Algorithm 1 for constructing Distribution Invading Attack

```

1: Input: Pre-adapted model parameters  $\theta^{\text{pre}} = \theta_A \cup \theta_B \cup \theta_F$ , test batch  $(\mathbf{X}_B^t; \mathbf{y}_B^t)$  which contains malicious samples  $\mathbf{X}_{mal}^t$  and benign samples  $\mathbf{X}_{B \setminus mal}^t$ , targeted samples  $\mathbf{x}_{tgt}^t$  and incorrect targeted label  $\hat{y}_{tgt}$ , attack learning rates  $\alpha$ , constraint  $\epsilon$ , number of steps  $N$ , TTA update rate:  $\eta$ , perturbation  $\delta_m = 0$ 
2: Output: Perturbed malicious input  $\mathbf{X}_{mal}^t + \delta_m$ 
3: for step = 1, 2, ...,  $N$  do:
4:    $\mathbf{X}_B^t \leftarrow (\mathbf{X}_{mal}^t + \delta_m) \cup \mathbf{X}_{B \setminus mal}^t$ 
5:    $\theta'_B \leftarrow \{\mu(\mathbf{X}_B^t), \sigma^2(\mathbf{X}_B^t)\}$ 
6:   (Optional)  $\theta'_A \leftarrow \theta_A - \eta \cdot \partial \mathcal{L}_{\text{TTA}}(\mathbf{X}_B^t) / \partial \theta_A$ 
   #  $\theta'_A \approx \theta_A$  in the single-level version.
7:    $\theta^* \leftarrow \theta'_A \cup \theta'_B \cup \theta_F$ 
8:    $\delta_m \leftarrow \Pi_{\epsilon}(\delta_m - \alpha \cdot \text{sign}(\nabla_{\delta_m} \mathbb{L}(f(\cdot; \theta^*(\mathbf{X}_B^t))))$ 
   #  $\mathbb{L}$  is chosen from Eq. (3), Eq. (4), or Eq. (5)
9: end for
10: return  $\hat{\mathbf{X}}_{mal}^t = \mathbf{X}_{mal}^t + \delta_m$ 

```

本文引入一个新的权重项 ω 以捕捉这两个目标之间的权衡。

4.3. 通过投影构造恶意输入 梯度下降

本文通过迭代投影梯度下降法求解上一节定义的双层优化问题, 算法流程总结于算法 1。该解法可推广至三种对抗目标, 其中 $\mathbb{L}(f(\cdot; \theta^*(\mathbf{X}_B^t)))$ 可分别替换为式 (3)、式 (4) 或式 (5)。我们遵循通用的投影梯度下降方法, 但引入了测试时自适应 (TTA) 方法。具体而言, 第 4 行更新测试批次, 第 5 行计算测试时批归一化。随后, 第 6 行和第 7 行执行参数更新。在第 8 行中, 我们计算朝向目标 (即前述三种攻击) 的梯度, 并以 α 学习率更新扰动 δ_m 。由于在大多数情况下我们不考虑恶意图像的约束, 投影 Π_{ϵ} 用于确保图像在 $[0, 1]$ 范围内有效。对于 ℓ_{∞} 约束的 DIA 攻击, 我们还将利用带有约束 ϵ (e.g., $\epsilon = 8/255$) 的 Π_{ϵ} to clip δ_m 。最终, 我们得到最优恶意输出样本 $\mathbf{X}_{mal}^t = \mathbf{X}_{mal}^t + \delta_m$ 。

实现。虽然算法 1 直观易懂, 但由于双层优化, 梯度计算可能不一致且计算成本高昂。此外, 我们注意到测试时自适应方法在每次迭代中仅对 θ_A 参数进行短暂的一步更新 (第 6 行)。因此, 在大多数实验中我们近似 $\theta'_A \approx \theta_A$, 这使得内部测试时自适应梯度更新 (第 6 行) 成为可选项。² 由于重新估计的第 6 行对于没有批归一化层的模型是必要的。

θ'_B 不涉及任何内部梯度计算, 我们

然后将该问题解读为单层优化。我们的实证评估表明了该方法的有效性, 达到了可比甚至更高的结果 (见附录 C.2)。我们方法的另一个优势是不再需要知道受害者将选择哪种测试时自适应方法。我们还在附录 B.1 中提供了一些理论分析。

5. 分布入侵攻击的评估攻击

在本节中, 我们报告分布入侵攻击的结果。我们在第 5.1 节介绍实验设置, 在第 5.2 节讨论定向攻击的主要结果, 在第 5.3 节展示无差别和隐蔽定向攻击的结果, 并在第 5.4 节考虑额外约束。更多结果见附录 D。

5.1. 实验设置

数据集与架构。我们在常见的分布偏移基准上评估攻击: CIFAR-10 到 CIFAR-10-C、CIFAR-100 到 CIFAR-100-C, 以及 ImageNet 到 ImageNet-C (Hendrycks 和 Dietterich, 2019), 严重程度为中等 (级别 3)。对于 CIFAR-C³, 我们主要使用 ResNet-26 (He 等人, 2016); 对于 ImageNet-C, 使用 ResNet-50。

测试时自适应方法。我们选取六种测试时自适应方法: TeBN (Nado 等人, 2020)、TENT (Wang 等人, 2021b)、硬伪标签 (Hard PL) (Lee 等人, 2013)、软伪标签 (Soft PL) (Lee 等人, 2013)、鲁棒伪标签 (Robust PL) (Rusak 等人, 2022) 和共轭伪标签 (Conjugate PL) (Goyal 等人, 2022)。我们遵循其实验设置, 批大小为 **200**, 所有其他超参数均为默认值。结果表明, 所有测试时自适应方法都显著提升了损坏准确率 (即在良性损坏测试数据如 ImageNet-C 上的准确率), 详见附录 C.3。

攻击设置 (定向攻击)。我们将每个测试批次视为一次独立的攻击试验, 随机选取一个带有目标标签的目标样本。

⁴ 攻击者可以在该批次内注入少量恶意数据, 只要像素值有效即可, 无其他限制。CIFAR-C 共进行 750 次试验, ImageNet-C 共进行 375 次试验。我们通过所有试验的平均攻击成功率 (ASR) 来评估攻击有效性。注意, 除 TeBN 外, 每次试验中测试时自适应方法使用当前批次更新 θ_A , 并将其传递给下一次试验。因此, θ^{pre} 在不同试验中是不同的。更多实验设置细节见附录 D.1。

³CIFAR-C 表示 CIFAR-10-C 和 CIFAR-100-C。⁴ 除非另有说明, 本文大多数实验均采用定向攻击。




图 2. 我们提出的攻击在恶意样本数量从 1 到 128 (0.5% 到 64%) 时的成功率。[测试时自适应: TeBN]

5.2. 定向攻击的主要结果

分布入侵攻击实现了较高的攻击成功率 成功率 (ASR) 在基准和 TTA 方法上的表现 (表 1)。我们从 CIFAR-C 的 200 个数据批次中选取 $N_m = \{10, 20, 40\}$ 个恶意样本, 从 ImageNet-C 中选取 $N_m = \{5, 10, 20\}$ 个。通过在 CIFAR-10-C 和 CIFAR-100-C 上构造 40 个恶意样本, 本文提出的攻击能够在超过 82.93% 的试验中将受害者样本的预测转移到随机目标标签。对于 ImageNet-C, 仅需 10 个恶意样本就足以攻击所有 TTA 方法, 攻击成功率超过 92.80%。TeBN 的 ASR 高于其他 TTA 方法, 因为这里的攻击仅利用了重新估计批归一化统计量的漏洞。本文证明其他 TTA 方法的进一步参数更新无法显著降低攻击有效性。例如, 对于具有 10 个恶意样本的 ImageNet-C, ASR 的下降小于 6.7%。

DIA 达到接近 100% 的攻击成功率, 其中 CIFAR-10-C、CIFAR-100-C 和

分别为 ImageNet-C (图 2)。随后, 本文通过更全面的实验评估攻击在不同恶意样本数量下的表现。具体而言, 考虑了 1 至 128 个恶意样本, 占批大小的 0.5% 至 64%。选择 TeBN 作为示例的测试时适应方法 (附录 D.2 展示了更多方法)。总体而言, 当攻击者能控制更多样本时, 攻击成功率上升。对于 CIFAR-10-C, 我们观察到攻击者必须操纵 ~ 64 (占批大小的 32%) 个样本, 才能确保受害者数据以接近 100% 的概率被预测为目标标签。尽管与传统投毒攻击相比, 32% 似乎是一个相对较强的假设, 但值得注意的是, DIA 仅需扰动测试数据, 而这些数据可能并未被主动监控。

DIA 同样适用于不同模型架构与数据

增强方法 (表 2)。除了残差网络 26 层 (ResNet-26), 本文还考虑了两种更常见的架构: 在 CIFAR-C 数据集上具有 19 层的视觉几何组网络 (VGG) (西蒙扬和齐瑟曼, 2015 年), 以及深度为 28、宽度为 10 的宽残差网络 (WRN-28) (扎戈鲁伊科和科莫达基斯, 2016 年)。尽管针对 VGG-19 的攻击成功率有所下降 ($< 20\%$), 本文提出的攻击在不同架构上仍然有效。本文假设具有更多批归一化层的模型更可能被攻击者利用, 其中 ResNet-26,

表 1. 分布入侵攻击（定向攻击）在不同基准和测试时自适应方法上的攻击成功率。 N_m 表示恶意数据的数量，其中批大小为 200。

Dataset	N_m	TeBN(%)	TENT(%)	Hard PL(%)	Soft PL(%)	Robust PL(%)	Conjugate PL(%)
CIFAR-10-C (ResNet26)	10 (5%)	25.87	23.20	25.33	23.20	24.80	23.60
	20 (10%)	55.47	45.73	48.13	47.47	49.47	45.73
	40 (20%)	92.80	83.87	84.27	82.93	86.93	85.47
CIFAR-100-C (ResNet26)	10 (5%)	46.80	26.40	31.20	27.60	32.13	26.13
	20 (10%)	93.73	72.80	87.33	78.53	82.93	71.60
	40 (20%)	100.00	100.00	99.87	100.00	99.87	100.00
ImageNet-C (ResNet50)	5 (2.5%)	80.80	75.73	69.87	62.67	66.40	57.87
	10 (5%)	99.47	98.67	96.53	94.13	96.00	92.80
	20 (10%)	100.00	100.00	100.00	100.00	100.00	100.00

表 2. 分布入侵攻击在不同模型架构和数据增强下的有效性。
[CIFAR-C: $N_m=40$; ImageNet-C: $N_m=10$]。表 6 呈现完整结果。

Dataset	Architectures	TeBN(%)	TENT(%)	Hard PL(%)
CIFAR-10-C	ResNet-26	92.80	83.87	84.27
	VGG-19	79.07	65.33	67.47
	WRN-28	93.73	89.60	90.80
CIFAR-100-C	ResNet-26	100.00	100.00	99.87
	VGG-19	88.00	82.93	86.53
	WRN-28	97.47	83.60	87.07
Dataset	Augmentations	TeBN(%)	TENT(%)	Hard PL(%)
ImageNet-C	Standard	99.47	98.67	96.53
	AugMix	98.40	96.00	93.60
	DeepAugment	96.00	94.67	91.20

VGG-19, and WRN-28 contain 28, 16, and 25 BN layers, respectively. We further refine the statement through more experiments in Appendix D.3. In addition, we also select two more data augmentation methods, AugMix (Hendrycks et al., 2020) and DeepAugment (Hendrycks et al., 2021), on top of ResNet-50, which is known to improve the model generalization on the corrupted dataset. Strong data augmentation techniques provide mild mitigations against our attacks (with 10 malicious samples) but still mistakenly predict the targeted data in more than 91% of trials.

5.3. 交替攻击目标

本文之前的分布入侵攻击评估聚焦于定向攻击。然而，如第 4.2 节所讨论的，恶意行为者也可以通过略微修改损失函数来利用本文的攻击框架实现其他目标。

5.3.1. 无差别攻击


第一个替代目标是降低所有良性样本的性能，这通过利用公式 (4) 实现。本文采用良性损坏数据集上的损坏错误率作为攻击评估度量。

通过注入少量恶意样本，误差

率增长（表 3）。除攻击有效性外，本文报告了 0 个恶意样本（即无攻击）时的错误率作为标准基线。本文的攻击导致良性样本的错误率从 $\sim 11\%$ 上升至 $\sim 28\%$ ，以及从 $\sim 34\%$ 上升至 $\sim 56\%$ ，分别针对 CIFAR-10-C 和

表 3. 部署 DIA 无差别攻击时，TTA 的平均良性损坏错误率。完整结果见表 7。

Dataset	N_m	TeBN(%)	TENT(%)	Hard PL(%)
CIFAR-10-C (ResNet-26)	0 (0%)	10.73	10.47	11.05
	40 (20%)	28.02	27.01	27.91
CIFAR-100-C (ResNet-26)	0 (0%)	34.52	33.31	34.66
	40 (20%)	58.41	54.44	56.59
ImageNet-C (ResNet-50)	0 (0%)	47.79	45.45	43.42
	20 (10%)	79.03	75.01	70.26

图 3. 调整权重 ω 可获得较高的攻击成功率（折线）和较高的良性损坏准确率（柱状）。[基准：CIFAR-10-C, $N_m=40$, TTA 方法：TeBN]

CIFAR-100-C 基准上分别达到。此外，仅 20 个恶意样本（10%）就使 ImageNet-C 的错误率提升至 70% 以上。由于所有良性样本均未受扰动，错误率的上升表明 TTA 方法相比传统机器学习带来了额外风险。

5.3.2. 隐蔽定向攻击

在表 1 中， ~ 40 个样本对于 CIFAR-C 数据集达到高攻击性能是必需的。因此，恶意影响也可能影响其他良性样本的预测，导致攻击隐蔽性丧失。本文采用公式 (5) 同时实现定向攻击并保持腐蚀准确率。此处，本文利用良性样本上的腐蚀准确率下降来衡量隐蔽性。

当 $\omega = 0.1$ 时，隐蔽的脏标签攻击既能实现高攻击成功率，又能保持污染准确率

（图 3）。我们选择包含 40 个恶意数据的 CIFAR-10-C 数据集和 TeBN 方法，其中 $\omega = \{0, 0.1, 0.2\}$ 。我们观察到，如果 $\omega = 0.1$ ，污染准确率下降幅度降至 $\sim 2\%$ 。同时，攻击成功率仍保持在 75% 以上。附录 D.5 包含更多关于 CIFAR-100-C 的结果。



图 4. (a) 来自 ImageNet-C 的高斯噪声测试数据。(b) 对测试数据施加 L_∞ 约束的脏标签攻击 ($\epsilon=8/255$)。(c) 来自 ImageNet 验证集的一张干净数据。(d) 对于干净数据实施雪攻击。




图 5. 不同 ϵ 的 L_∞ 约束 [$N_m = 5$] (左) 和不同恶意样本数量 (右) [$\epsilon = 8/255$] 下的攻击成功率示意图。[定向攻击]

5.4. 对恶意图像的额外约束

我们进一步考虑恶意样本的隐蔽性以避免引起怀疑。模型可能会拒绝异常测试样本并拒绝基于它们进行自适应。

5.4.1. ℓ_p BOUND 与对抗机器学习领域的许多其他文献一样，我们采用 ℓ_p 约束作为不可感知性度量来扰动恶意样本。具体而言，我们通过改变 5 个恶意数据样本的 ℓ_∞ 界限，在 ImageNet-C 上进行定向攻击实验。图 5 报告了在不同 ℓ_∞ 约束下的攻击有效性趋势，其中带有 $\epsilon = 32/255$ 的脏标签攻击达到了与无约束攻击相似的性能。此外，我们特别选择 $\epsilon = 8/255$ 来对恶意样本数量进行额外实验，因为生成的图像几乎与原始图像不可区分（如图 4(b) 和图 26 所示）。结果表明，脏标签攻击在 ImageNet-C 上使用 32 个 ($\epsilon = 8/255$) 恶意样本即可实现接近 100% 的攻击成功率。

5.4.2. 模拟损坏

由于我们的分布外基准由常见损坏组成，另一种思路是利用这些固有属性自适应地生成“不可感知”的对抗样本。例如，我们可以将对抗优化的雪损坏应用于干净图像，并将其插入雪分布中的测试数据。然后，这些注入的恶意图像（如图 4(d) 所示）很难与良性损坏数据区分开来。在实现上，我们再次计算式 (3) 中损失函数的梯度，并采用与 Kang 等人 (2019) 相同的方法。

对抗优化的模拟损坏是另一种有效且输入隐蔽的分布入侵攻击向量（表 4）。我们将雪攻击应用于 ImageNet-C，

表 4. 对抗优化的雪损坏和雾损坏的平均攻击成功率。[$N_m = 20$; 定向攻击]

Dataset	Corruption/Attack	TeBN(%)	TENT(%)	Hard PL(%)
ImageNet-C (ResNet50)	Snow/Snow Attack	64.00	68.00	68.00
	Fog/Fog Attack	84.00	76.00	72.00




图 6. (左) 分布入侵攻击对鲁棒模型的攻击成功率，包括 Salman 等人 (2020) 和 Engstrom 等人 (2019)，随恶意样本数量的变化。作为参考，128 是包含 200 个样本的整个批次的 64%。(右) 鲁棒模型的损坏准确率。[测试时适应方法: TeBN]

雪损坏，与雾类似。通过插入 20 个恶意样本，雪和雾的攻击成功率分别至少达到 60% 和 72%。我们的发现表明，攻击者可以利用测试分布知识来开发更好的威胁模型。更多细节见附录 D.6。

6. 缓解分布入侵攻击

接下来，我们将注意力转向开发缓解方法。我们的目标有两个：保持测试时适应方法的优势并缓解分布入侵攻击。注意，我们在附录 E 中提供了额外结果，包括所有 CIFAR-C 实验。

6.1. 利用鲁棒模型缓解数据注入攻击

我们的第一个想法是用鲁棒模型（即对抗训练模型 (Madry 等人, 2018)）替换源模型。我们的直觉是，在训练过程中生成对抗样本会导致批归一化统计量的偏移。使用此类样本进行（对抗）训练将使模型对批归一化扰动具有鲁棒性。我们针对 Salman 等人 (2020) 和 Engstrom 等人 (2019) 训练的鲁棒 ResNet-50 评估了目标 DIA，这些是 RobustBench (Crocce 等人, 2020) 中最好的 ResNet-50 模型。由于我们的单层攻击仅利用重新估计批归一化统计量的漏洞，因此在更新参数的测试时自适应上评估防御可能会产生虚假的鲁棒性。因此，大多数对策实验主要集中在 TeBN 方法上。

经过对抗训练的模型提升了对鲁棒性的防御能力 DIA 并保持污染准确率 (图 6)。本文报告了两个鲁棒模型的 ASR 曲线，并观察到它们显著缓解了来自测试批次的漏洞。例如，在 8 个恶意样本的情况下，鲁棒模型在 ImageNet-C 上将 ASR 降低了 $\sim 80\%$ 。




图 7. 控制 $\tau = 0.6$ 会降低攻击成功率（折线），同时保持较高的破坏准确率（柱状）。[$N_m=20$]

同时，TeBN 方法显著提升了鲁棒模型的损坏准确率，甚至达到了更高的结果。然而，DIA 在 32 个恶意样本（占整个批次的 16%）的情况下，仍然实现了超过 70% 的成功率。

6.2. 批归一化统计量的稳健估计

随后，本文通过增强批归一化（Batch Norm）统计量重新估计的鲁棒性来缓解这些脆弱性。

通过训练时批归一化统计量进行平滑处理。由于训练时批归一化无法被动态输入攻击（DIA）扰动，因此可以将训练时与测试时的批归一化统计量相结合。该方法在（Schneider 等人，2020；You 等人，2021）中也有提及；然而，他们的动机是在批大小较小（例如， < 32 ）时稳定批归一化估计，并提高对损坏数据的准确率。其公式可表示为 $\bar{\mu} = \tau\mu_s + (1-\tau)\mu_t$ ，其中 $\bar{\mu}$ 代表最终的批归一化统计量， (μ_s, σ_s^2) 为训练时批归一化统计量， (μ_t, σ_t^2) 为测试时批归一化统计量。本文将训练时批归一化统计量视为最终估计的鲁棒先验，并采用平滑因子 τ 来平衡权重。

利用 训练时批归一化统计量能够缓解标准模型和对抗模型的脆弱性（图 7）。本文特别选取 $N_m = 20$ 并设置 $\tau = \{0.0, 0.2, 0.4, 0.6, 0.8, 1.0\}$ ，其中 $\tau = 0.0$ 忽略测试时批归一化， $\tau = 1.0$ 忽略训练时批归一化。结果表明，提高 τ 通常会导致 ImageNet-C 上的攻击成功率（ASR）和损坏准确率同时下降。然而，损坏准确率的下降仅发生在 $\tau > 0.6$ 时。因此，设置 $\tau = 0.6$ 是一个合适的选择，对于鲁棒模型，可将 20 个恶意样本的 ASR 降低至 $\sim 20\%$ 。

自适应选择逐层批归一化统计量。本文还在附录 E.4 中通过可视化各层批归一化来探索和理解动态输入攻击。其中批量归一化（BN）在应用 DIA 时，后层统计量发生偏移，我们可以有策略地为不同层选择训练时或测试时的 BN 统计量。因此，我们利用最后几层的训练时 BN 来限制恶意影响。

自适应逐层 BN 进一步限制了 DIA 的恶意影响（图 8）。给定 $\tau = 0.6$ 是对所有 BN 层的合适选择，我们进一步对最后 $N_{tr} = \{0, 1, 2, 4\}$ 层使用完整的训练时 BN（ $\tau = 1.0$ ）。




图 8. 平衡逐层 BN 可以降低攻击成功率（ASR，折线），同时保持较高的损坏准确率（柱状）。[$N_m=20, \tau=0.6$]

8, 16} 个 BN 层。结果表明，增加训练时 BN 层数（从 $N_{tr} = 0$ 到 $N_{tr} = 16$ ）会导致损坏准确率仅有微小下降（ $\sim 2\%$ ），并且通常有助于提高对 DIA 的鲁棒性。例如，如果我们设置 $N_{tr} = 8$ ，对于具有 $N_m = 20$ 的标准模型，ASR 下降 $\sim 40\%$ 。

总之，通过应用这两种方法，我们的最佳结果在 ImageNet-C 上实现了可忽略的损坏准确率下降，并将标准模型的 ASR 降低了 $\sim 50\%$ ，将鲁棒模型的 ASR 降低了 $\sim 40\%$ 。然而，我们的缓解措施尚未完全解决问题，增加恶意数据样本的数量仍可能以高概率实现成功的 DIA 攻击。我们鼓励未来的研究者在开发测试时自适应（TTA）技术时考虑潜在的对抗风险。

7. 讨论与未来工作

尽管本文提出的攻击在有效性方面具有前景，但仍存在若干局限性。近期已有许多测试时自适应（Test-Time Adaptation）方法被提出，它们采用了不同的自适应技术（例如（Niu 等人，2022））。其中大多数方法仍受到我们在第 4 节中识别的两个漏洞的影响，并且可以直接被分布入侵攻击（DIA）攻击（见附录 D.10）。然而，如果测试时自适应技术发生显著变化（例如，既不使用测试时批量归一化也不使用自学习的方法），则应考虑自适应攻击设计。此外，在一般直推学习设置下的方法（即预测受测试批次影响）也涉及类似风险，我们鼓励社区在未来的研究中探索这些风险。

另一个方向是放宽对手的知识假设。在我们的白盒威胁模型中，我们假设对手完全了解测试批次，包括目标样本和良性样本。然而，在现实场景中获取这些信息可能很困难（例如，一些用户对上传的图像保密（Deng 等人，2021））。放宽这一假设的一种潜在方法是利用外部信息（例如在线图像）来替代良性图像，并像期望变换（EOT）（Athalye 等人，2017）那样优化期望损失。此外，当模型架构和参数未暴露给对手时（黑盒威胁模型），发起分布入侵攻击可能更具挑战性。未来的工作应考虑使用模型集成（Geiping 等人，2020）或

多样化输入 (Xie 等人, 2018) 来提升分布入侵攻击恶意数据的可迁移性。

8. 结论

本文研究了测试时自适应 (Test-Time Adaptation) 的对抗风险。首先, 我们提出了一种新颖的框架, 称为分布入侵攻击 (Distribution Invading Attack), 可用于实现新的恶意目标。重要的是, 我们证明了在采用测试时自适应的情况下, 操纵少量测试样本可以影响其他良性输入的预测, 这在以往文献中从未被研究过。随后, 我们探索了缓解策略, 例如利用对抗训练的模型作为源模型以及稳健地估计批量归一化统计量。总体而言, 我们的发现揭示了测试时自适应的风险, 并启发未来工作构建稳健且有效的测试时自适应技术。

9. 致谢

我们感谢艾哈迈德·哈立德 (Ahmed Khaled)、向崇 (Chong Xiang)、阿什维尼·潘达 (Ashwinee Panda)、谢廷豪 (Tinghao Xie)、杨威廉 (William Yang)、韩贝宁 (Beining Han)、童亮 (Liang Tong) 以及奥尔加·鲁萨科夫斯基 (Olga Russakovsky) 教授为本项目提供的慷慨帮助和深刻反馈。本研究部分由国家自然科学基金会 (National Science Foundation) 资助 (项目号 CNS-2131859)、陆军人工智能创新研究所 (ARL's Army Artificial Intelligence Innovation Institute, A2I2)、施密特数据科学奖 (Schmidt DataX award)、普林斯顿电子联盟奖 (Princeton E-filiates Award) 以及普林斯顿戈登 (Princeton Gordon)

Y. S. 吴奖学金 (Y. S. Wu Fellowship)。

参考文献

Online versus batch prediction. <https://cloud.google.com/ai-platform/prediction/docs/online-vs-batch-prediction>, 2021.

Athalye, A., Engstrom, L., Ilyas, A., and Kwok, K. Synthesizing robust adversarial examples. In *International Conference on Machine Learning*, 2017.

Bartler, A., Bühler, A., Wiewel, F., Döbler, M., and Yang, B. Mt3: Meta test-time training for self-supervised test-time adaption. In Camps-Valls, G., Ruiz, F. J. R., and Valera, I. (eds.), *Proceedings of The 25th International Conference on Artificial Intelligence and Statistics*, volume 151 of *Proceedings of Machine Learning Research*, pp. 3080–3090. PMLR, 28–30 Mar 2022. URL <https://proceedings.mlr.press/v151/bartler22a.html>.

Biggio, B., Nelson, B., and Laskov, P. Poisoning attacks against support vector machines. *arXiv preprint arXiv:1206.6389*, 2012.

Biggio, B., Corona, I., Maiorca, D., Nelson, B., Srndic, N., Laskov, P., Giacinto, G., and Roli, F. Evasion attacks

against machine learning at test time. In *ECML/PKDD*, 2013.

Carlini, N. Poisoning the unlabeled dataset of semi-supervised learning. *ArXiv*, abs/2105.01622, 2021.

Carlini, N. and Terzis, A. Poisoning and backdooring contrastive learning. *ArXiv*, abs/2106.09667, 2021.

Carlini, N. and Wagner, D. A. Towards evaluating the robustness of neural networks. *2017 IEEE Symposium on Security and Privacy (SP)*, pp. 39–57, 2017.

Chakraborty, A., Alam, M., Dey, V., Chattopadhyay, A., and Mukhopadhyay, D. Adversarial attacks and defences: A survey. *ArXiv*, abs/1810.00069, 2018.

Chen, J., Wu, X., Guo, Y., Liang, Y., and Jha, S. Towards evaluating the robustness of neural networks learned by transduction. *CoRR*, abs/2110.14735, 2021. URL <https://arxiv.org/abs/2110.14735>.

Chen, J., Cheng, Y., Gan, Z., Gu, Q., and Liu, J. Efficient robust training via backward smoothing. In *AAAI Conference on Artificial Intelligence*, 2022.

Croce, F., Andriushchenko, M., Sehwag, V., Debenedetti, E., Flammarion, N., Chiang, M., Mittal, P., and Hein, M. Robustbench: a standardized adversarial robustness benchmark. *arXiv preprint arXiv:2010.09670*, 2020.

Croce, F., Goyal, S., Brunner, T., Shelhamer, E., Hein, M., and Cemgil, A. T. Evaluating the adversarial robustness of adaptive test-time defenses. *ArXiv*, abs/2202.13711, 2022.

Dai, S., Mahloutjifar, S., and Mittal, P. Parameterizing activation functions for adversarial robustness. *2022 IEEE Security and Privacy Workshops (SPW)*, pp. 80–87, 2022.

Damodaran, B. B., Kellenberger, B., Flamary, R., Tuia, D., and Courty, N. Deepjdot: Deep joint distribution optimal transport for unsupervised domain adaptation. In *Proceedings of the European Conference on Computer Vision (ECCV)*, pp. 447–463, 2018.

Deng, S., Garg, S., Jha, S., Mahloutjifar, S., Mahmoody, M., and Guha Thakurta, A. A separation result between data-oblivious and data-aware poisoning attacks. *Advances in Neural Information Processing Systems*, 34:10862–10875, 2021.

Di, J. Z., Douglas, J., Acharya, J., Kamath, G., and Sekhari, A. Hidden poison: Machine unlearning enables camouflaged poisoning attacks. *ArXiv*, abs/2212.10717, 2022.

- Döbler, M., Marsden, R. A., and Yang, B. Robust mean teacher for continual and gradual test-time adaptation. *ArXiv*, abs/2211.13081, 2022.
- Ebrahimi, S., Arik, S. O., and Pfister, T. Test-time adaptation for visual document understanding, 2022. URL <https://arxiv.org/abs/2206.07240>.
- Engstrom, L., Ilyas, A., Salman, H., Santurkar, S., and Tsipras, D. Robustness (python library), 2019. URL <https://github.com/MadryLab/robustness>.
- Fournier, A., Fussell, D. S., and Carpenter, L. C. Computer rendering of stochastic models. *Commun. ACM*, 25:371–384, 1982.
- Galstyan, A. G. and Cohen, P. R. Empirical comparison of “hard” and “soft” label propagation for relational classification. In *ILP*, 2007.
- Gandelsman, Y., Sun, Y., Chen, X., and Efros, A. A. Test-time training with masked autoencoders. *ArXiv*, abs/2209.07522, 2022.
- Ganin, Y., Ustinova, E., Ajakan, H., Germain, P., Larochelle, H., Laviolette, F., Marchand, M., and Lempitsky, V. Domain-adversarial training of neural networks. *The journal of machine learning research*, 17(1):2096–2030, 2016.
- Gao, J., Zhang, J., Liu, X., Darrell, T., Shelhamer, E., and Wang, D. Back to the source: Diffusion-driven test-time adaptation. *arXiv preprint arXiv:2207.03442*, 2022a.
- Gao, Y., Shi, X., Zhu, Y., Wang, H., Tang, Z., Zhou, X., Li, M., and Metaxas, D. N. Visual prompt tuning for test-time domain adaptation. *ArXiv*, abs/2210.04831, 2022b.
- Geiping, J., Fowl, L., Huang, W. R., Czaja, W., Taylor, G., Moeller, M., and Goldstein, T. Witches’ brew: Industrial scale data poisoning via gradient matching. *ArXiv*, abs/2009.02276, 2020.
- Geiping, J., Fowl, L., Somepalli, G., Goldblum, M., Moeller, M., and Goldstein, T. What doesn’t kill you makes you robust (er): Adversarial training against poisons and backdoors. *arXiv preprint arXiv:2102.13624*, 2021.
- Goldwasser, S., Kalai, A. T., Kalai, Y., and Montasser, O. Beyond perturbations: Learning guarantees with arbitrary adversarial test examples. *Advances in Neural Information Processing Systems*, 33:15859–15870, 2020.
- Gong, T., Jeong, J., Kim, T., Kim, Y., Shin, J., and Lee, S.-J. NOTE: Robust continual test-time adaptation against temporal correlation. In Oh, A. H., Agarwal, A., Belgrave, D., and Cho, K. (eds.), *Advances in Neural Information Processing Systems*, 2022. URL <https://openreview.net/forum?id=E9HNxrCFZPV>.
- Goodfellow, I. J., Shlens, J., and Szegedy, C. Explaining and harnessing adversarial examples. *CoRR*, abs/1412.6572, 2015.
- Gowal, S., Rebuffi, S.-A., Wiles, O., Stimberg, F., Calian, D. A., and Mann, T. Improving robustness using generated data. In *Neural Information Processing Systems*, 2021.
- Goyal, S., Sun, M., Raghunathan, A., and Kolter, Z. Test-time adaptation via conjugate pseudo-labels. *ArXiv*, abs/2207.09640, 2022.
- Gu, T., Dolan-Gavitt, B., and Garg, S. Badnets: Identifying vulnerabilities in the machine learning model supply chain. *Arxiv*, 2017.
- He, K., Zhang, X., Ren, S., and Sun, J. Deep residual learning for image recognition. *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 770–778, 2016.
- Hendrycks, D. and Dietterich, T. G. Benchmarking neural network robustness to common corruptions and perturbations. *ArXiv*, abs/1903.12261, 2019.
- Hendrycks, D., Mu, N., Cubuk, E. D., Zoph, B., Gilmer, J., and Lakshminarayanan, B. Augmix: A simple data processing method to improve robustness and uncertainty. *ArXiv*, abs/1912.02781, 2020.
- Hendrycks, D., Basart, S., Mu, N., Kadavath, S., Wang, F., Dorundo, E., Desai, R., Zhu, T. L., Parajuli, S., Guo, M., Song, D. X., Steinhardt, J., and Gilmer, J. The many faces of robustness: A critical analysis of out-of-distribution generalization. *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 8320–8329, 2021.
- Hu, X., Uzunbas, M. G., Chen, S., Wang, R., Shah, A., Nevatia, R., and Lim, S.-N. Mixnorm: Test-time adaptation through online normalization estimation. *ArXiv*, abs/2110.11478, 2021.
- Huang, H., Gu, X., Wang, H., Xiao, C., Liu, H., and Wang, Y. Extrapolative continuous-time bayesian neural network for fast training-free test-time adaptation. In Oh, A. H., Agarwal, A., Belgrave, D., and Cho, K. (eds.), *Advances in Neural Information Processing Systems*, 2022. URL <https://openreview.net/forum?id=wiHzQWwg3l>.
- Ioffe, S. and Szegedy, C. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *International conference on machine learning*, pp. 448–456. PMLR, 2015.

- Iwasawa, Y. and Matsuo, Y. Test-time classifier adjustment module for model-agnostic domain generalization. In *Neural Information Processing Systems*, 2021.
- Jia, X., Zhang, Y., Wu, B., Ma, K., Wang, J., and Cao, X. Las-at: Adversarial training with learnable attack strategy. *2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 13388–13398, 2022.
- Kang, D., Sun, Y., Hendrycks, D., Brown, T. B., and Steinhardt, J. Testing robustness against unforeseen adversaries. *ArXiv*, abs/1908.08016, 2019.
- Kantorovich, L. V. On the translocation of masses. In *Dokl. Akad. Nauk. USSR (NS)*, volume 37, pp. 199–201, 1942.
- Koh, P. W. and Liang, P. Understanding black-box predictions via influence functions. *ArXiv*, abs/1703.04730, 2017.
- Kojima, T., Matsuo, Y., and Iwasawa, Y. Robustifying vision transformer without retraining from scratch by test-time class-conditional feature alignment. *ArXiv*, abs/2206.13951, 2022.
- Kundu, J. N., Venkat, N., RahulM., V., and Babu, R. V. Universal source-free domain adaptation. *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 4543–4552, 2020.
- Lee, D.-H. et al. Pseudo-label: The simple and efficient semi-supervised learning method for deep neural networks. In *Workshop on challenges in representation learning, ICML*, volume 3, pp. 896, 2013.
- Li, R., Jiao, Q., Cao, W., Wong, H.-S., and Wu, S. Model adaptation: Unsupervised domain adaptation without source data. *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 9638–9647, 2020.
- Li, Y., Wang, N., Shi, J., Liu, J., and Hou, X. Revisiting batch normalization for practical domain adaptation. *arXiv preprint arXiv:1603.04779*, 2016.
- Liang, J., Hu, D., and Feng, J. Do we really need to access the source data? Source hypothesis transfer for unsupervised domain adaptation. In III, H. D. and Singh, A. (eds.), *Proceedings of the 37th International Conference on Machine Learning*, volume 119 of *Proceedings of Machine Learning Research*, pp. 6028–6039. PMLR, 13–18 Jul 2020.
- Liu, Y., Kothari, P., van Delft, B., Bellot-Gurlet, B., Mordan, T., and Alahi, A. Ttt++: When does self-supervised test-time training fail or thrive? In *Neural Information Processing Systems*, 2021.
- Long, M., Cao, Z., Wang, J., and Jordan, M. I. Conditional adversarial domain adaptation. *Advances in neural information processing systems*, 31, 2018.
- Loshchilov, I. and Hutter, F. Sgdr: Stochastic gradient descent with warm restarts. *arXiv: Learning*, 2016.
- Madry, A., Makelov, A., Schmidt, L., Tsipras, D., and Vladu, A. Towards deep learning models resistant to adversarial attacks. *arXiv preprint arXiv:1706.06083*, 2017.
- Madry, A., Makelov, A., Schmidt, L., Tsipras, D., and Vladu, A. Towards deep learning models resistant to adversarial attacks. *ArXiv*, abs/1706.06083, 2018.
- Marchant, N. G., Rubinstein, B. I. P., and Alfeld, S. Hard to forget: Poisoning attacks on certified machine unlearning. In *AAAI Conference on Artificial Intelligence*, 2021.
- Mehra, A., Kailkhura, B., Chen, P.-Y., and Hamm, J. Understanding the limits of unsupervised domain adaptation via data poisoning. In Ranzato, M., Beygelzimer, A., Dauphin, Y., Liang, P., and Vaughan, J. W. (eds.), *Advances in Neural Information Processing Systems*, volume 34, pp. 17347–17359. Curran Associates, Inc., 2021. URL <https://proceedings.neurips.cc/paper/2021/file/90cc440b1b8caa520c562ac4e4bbcb51-Paper.pdf>.
- Mirza, M. J., Micorek, J., Possegger, H., and Bischof, H. The norm must go on: Dynamic unsupervised domain adaptation by normalization. *2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 14745–14755, 2021.
- Nado, Z., Padhy, S., Sculley, D., D’Amour, A., Lakshminarayanan, B., and Snoek, J. Evaluating prediction-time batch normalization for robustness under covariate shift. *ArXiv*, abs/2006.10963, 2020.
- Nelson, B., Barreno, M., Chi, F. J., Joseph, A. D., Rubinstein, B. I. P., Saini, U., Sutton, C., Tygar, J. D., and Xia, K. Exploiting machine learning to subvert your spam filter. In *USENIX Workshop on Large-Scale Exploits and Emergent Threats*, 2008.
- Niu, S., Wu, J., Zhang, Y., Chen, Y., Zheng, S., Zhao, P., and Tan, M. Efficient test-time model adaptation without forgetting. In *The International Conference on Machine Learning*, 2022.
- Pang, T., Lin, M., Yang, X., Zhu, J., and Yan, S. Robustness and accuracy could be reconcilable by (proper) definition. In *International Conference on Machine Learning*, 2022.

- Rebuffi, S.-A., Gowal, S., Calian, D. A., Stimberg, F., Wiles, O., and Mann, T. A. Fixing data augmentation to improve adversarial robustness. *ArXiv*, abs/2103.01946, 2021.
- Rusak, E., Schneider, S., Pachitariu, G., Eck, L., Gehler, P. V., Bringmann, O., Brendel, W., and Bethge, M. If your data distribution shifts, use self-learning, 2022. URL <https://openreview.net/forum?id=loEvY1a67c1>.
- Saito, K., Watanabe, K., Ushiku, Y., and Harada, T. Maximum classifier discrepancy for unsupervised domain adaptation. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 3723–3732, 2018.
- Salman, H., Ilyas, A., Engstrom, L., Kapoor, A., and Madry, A. Do adversarially robust imagenet models transfer better? *ArXiv*, abs/2007.08489, 2020.
- Schneider, S., Rusak, E., Eck, L., Bringmann, O., Brendel, W., and Bethge, M. Improving robustness against common corruptions by covariate shift adaptation. *ArXiv*, abs/2006.16971, 2020.
- Sehwag, V., Mahlouljifar, S., Handina, T., Dai, S., Xiang, C., Chiang, M., and Mittal, P. Robust learning meets generative models: Can proxy distributions improve adversarial robustness? In *International Conference on Learning Representations*, 2022.
- Shafahi, A., Najibi, M., Ghiasi, M. A., Xu, Z., Dickerson, J., Studer, C., Davis, L. S., Taylor, G., and Goldstein, T. Adversarial training for free! *Advances in Neural Information Processing Systems*, 32, 2019.
- Simonyan, K. and Zisserman, A. Very deep convolutional networks for large-scale image recognition. *CoRR*, abs/1409.1556, 2015.
- Singh, S. and Shrivastava, A. Evalnorm: Estimating batch normalization statistics for evaluation. *2019 IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 3632–3640, 2019.
- Sinha, S., Gehler, P., Locatello, F., and Schiele, B. Test: Test-time self-training under distribution shift. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, pp. 2759–2769, January 2023.
- Sun, Y., Wang, X., Liu, Z., Miller, J., Efros, A. A., and Hardt, M. Test-time training with self-supervision for generalization under distribution shifts. In *ICML*, 2020.
- Tramèr, F., Shokri, R., Joaquin, A. S., Le, H. M., Jagielski, M., Hong, S., and Carlini, N. Truth serum: Poisoning machine learning models to reveal their secrets. *Proceedings of the 2022 ACM SIGSAC Conference on Computer and Communications Security*, 2022.
- Vapnik, V. *Statistical learning theory*. John Wiley & Sons, 1998.
- Vorobeychik, Y. and Kantarcioglu, M. *Adversarial Machine Learning*. Morgan Claypool, 2018.
- Wang, D., Ju, A., Shelhamer, E., Wagner, D. A., and Darrell, T. Fighting gradients with gradients: Dynamic defenses against adversarial attacks. *ArXiv*, abs/2105.08714, 2021a.
- Wang, D., Shelhamer, E., Liu, S., Olshausen, B. A., and Darrell, T. Tent: Fully test-time adaptation by entropy minimization. In *ICLR*, 2021b.
- Wang, H., Zhang, A., Zheng, S., Shi, X., Li, M., and Wang, Z. Removing batch normalization boosts adversarial training. In *ICML*, 2022a.
- Wang, J.-K. and Wibisono, A. Towards understanding gd with hard and conjugate pseudo-labels for test-time adaptation. *ArXiv*, abs/2210.10019, 2022.
- Wang, Q., Fink, O., Van Gool, L., and Dai, D. Continual test-time domain adaptation. In *Proceedings of Conference on Computer Vision and Pattern Recognition*, 2022b.
- Wang, X., Jin, Y., Long, M., Wang, J., and Jordan, M. I. Transferable normalization: Towards improving transferability of deep neural networks. *Advances in neural information processing systems*, 32, 2019.
- Wong, E., Rice, L., and Kolter, J. Z. Fast is better than free: Revisiting adversarial training. In *International Conference on Learning Representations*, 2019.
- Wu, D., Xia, S., and Wang, Y. Adversarial weight perturbation helps robust generalization. *arXiv: Learning*, 2020a.
- Wu, J. and He, J. Indirect invisible poisoning attacks on domain adaptation. In *Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, KDD '21, pp. 1852–1862, New York, NY, USA, 2021. Association for Computing Machinery. ISBN 9781450383325. doi: 10.1145/3447548.3467214. URL <https://doi.org/10.1145/3447548.3467214>.
- Wu, Y.-H., Yuan, C.-H., and Wu, S.-H. Adversarial robustness via runtime masking and cleansing. In III, H. D. and Singh, A. (eds.), *Proceedings of the 37th International Conference on Machine Learning*, volume 119 of *Proceedings of Machine Learning Research*, pp. 10399–10409. PMLR, 13–18 Jul 2020b. URL <https://proceedings.mlr.press/v119/wu20f.html>.

- Xie, C., Zhang, Z., Wang, J., Zhou, Y., Ren, Z., and Yuille, A. L. Improving transferability of adversarial examples with input diversity. *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 2725–2734, 2018.
- Xie, C., Wu, Y., van der Maaten, L., Yuille, A. L., and He, K. Feature denoising for improving adversarial robustness. *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 501–509, 2019.
- Xie, C., Tan, M., Gong, B., Wang, J., Yuille, A. L., and Le, Q. V. Adversarial examples improve image recognition. *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 816–825, 2020.
- You, F., Li, J., and Zhao, Z. Test-time batch statistics calibration for covariate shift. *ArXiv*, abs/2110.04065, 2021.
- Zagoruyko, S. and Komodakis, N. Wide residual networks. *ArXiv*, abs/1605.07146, 2016.
- Zhang, M., Levine, S., and Finn, C. Memo: Test time robustness via adaptation and augmentation. *ArXiv*, abs/2110.09506, 2021a.
- Zhang, M., Marklund, H., Dhawan, N., Gupta, A., Levine, S., and Finn, C. Adaptive risk minimization: Learning to adapt to domain shift. In *NeurIPS*, 2021b.
- Zhang, X., Gu, S. S., Matsuo, Y., and Iwasawa, Y. Domain prompt learning for efficiently adapting clip to unseen domains, 2021c. URL <https://arxiv.org/abs/2111.12853>.
- Zhou, A. and Levine, S. Bayesian adaptation for covariate shift. *Advances in Neural Information Processing Systems*, 34:914–927, 2021.

A. 背景与相关工作补充细节

在本附录中，我们补充了批归一化（附录 A.1）和自学习（附录 A.2）的更多细节，并在附录 A.3 中介绍了测试时自适应算法。随后，我们在附录 A.4 中讨论了包括对抗样本和数据投毒在内的传统机器学习脆弱性。此外，我们在附录 A.5 中提供了现有文献的全面综述。

A.1. 批归一化

在批归一化中，我们通过计算预激活值 $\mathbf{z}_l$: $\mu \leftarrow \mathbb{E}[\mathbf{z}_l], \sigma^2 \leftarrow \mathbb{E}[(\mathbf{z}_l - \mu)^2]$ 的均值 μ 和方差 σ^2 ，为每个批归一化层 l 计算批归一化统计量。期望 $\mathbb{E}$ 在输入上按通道计算。然后，我们通过减去均值并除以标准差来归一化预激活值： $\bar{\mathbf{z}}_l = (\mathbf{z}_l - \mu)/\sigma$ 。最后，我们通过可学习的仿射参数 $\{\gamma_l, \beta_l\}$ 对标准化后的预激活值 $\bar{\mathbf{z}}_l$ 进行缩放和平移，得到 $\mathbf{z}'_l = \gamma_l^T \bar{\mathbf{z}}_l + \beta_l$ 。在我们的实验中，测试时自适应过程中更新的参数为 $\theta_A = \{\gamma_l, \beta_l\}_{l=1}^L$ ，其中 L 是批归一化层的数量。源数据的统计量被替换为测试批次的统计量。

A.2. 自学习目标

我们提供了自学习方法中使用的测试时自适应损失函数的详细公式。设 $h(\cdot; \theta)$ 为由 θ 参数化的假设函数，我们将其视为逻辑输出（不失一般性）。样本 $\mathbf{x}$ 属于类别 j 的概率记为 $p(j|\mathbf{x}) = \sigma(h(\mathbf{x}; \theta))$ ，其中 $\sigma(\cdot)$ 是 **Softmax** 函数。这里，为简单起见，我们用 θ 表示 θ^{pre} 。

TENT (Wang 等人, 2021b)。该方法最小化模型预测的熵。

$$\mathcal{L}_{\text{TTA}}(\mathbf{X}_B^t) := -\frac{1}{N_{Bt}} \sum_{i=1}^{N_{Bt}} \sum_j p(j|\mathbf{x}_i^t) \log p(j|\mathbf{x}_i^t) \quad (6)$$

硬伪标签 (Hard PL) (Galstyan 与 Cohen, 2007; Lee 等人, 2013)。由预适应模型预测的最可能类别被计算为未标注测试数据的伪标签。

$$\mathcal{L}_{\text{TTA}}(\mathbf{X}_B^t, \tilde{\mathbf{y}}(\theta)) := -\frac{1}{N_{Bt}} \sum_{i=1}^{N_{Bt}} \log p(\tilde{y}_i(\theta)|\mathbf{x}_i^t), \quad (7)$$

其中 $\tilde{y}_i(\theta) = \underset{j}{\operatorname{argmax}} p(j|\mathbf{x}_i^t), \forall \mathbf{x}_i^t \in \mathbf{X}_B^t$

软伪标签 (Soft PL) (Galstyan 与 Cohen, 2007; Lee 等人, 2013)。不使用预测类别，而是直接将 Softmax 函数应用于预测结果以生成伪标签。

$$\mathcal{L}_{\text{TTA}}(\mathbf{X}_B^t, \tilde{\mathbf{y}}(\theta)) := -\frac{1}{N_{Bt}} \sum_{i=1}^{N_{Bt}} \sum_j \tilde{y}_i(\theta) \log p(j|\mathbf{x}_i^t), \quad (8)$$

其中 $\tilde{y}_i(\theta) = p(j|\mathbf{x}_i^t), \forall \mathbf{x}_i^t \in \mathbf{X}_B^t$

鲁棒伪标签 (Robust PL) (Rusak 等人, 2022)。已有研究表明交叉熵损失对标签噪声敏感。为减轻其对训练稳定性和超参数敏感性的副作用，鲁棒伪标签将硬伪标签的交叉熵（CE）损失替换为广义交叉熵（GCE）。

$$\mathcal{L}_{\text{TTA}}(\mathbf{X}_B^t, \tilde{\mathbf{y}}(\theta)) := -\frac{1}{N_{Bt}} \sum_{i=1}^{N_{Bt}} q^{-1} (1 - p(\tilde{y}_i(\theta)|\mathbf{x}_i^t))^q, \quad (9)$$

其中 $\tilde{y}_i(\theta) = \underset{j}{\operatorname{argmax}} p(j|\mathbf{x}), \forall \mathbf{x}_i^t \in \mathbf{X}_B^t$

其中 $q \in (0, 1]$ 调整损失函数的形状。当 $q \rightarrow 1$ 时，GCE 损失趋近于平均绝对误差（MAE）损失；而当 $q \rightarrow 0$ 时，它退化为交叉熵损失。

共轭伪标签 (Conjugate PL) (Goyal 等人, 2022)。考虑源损失函数, 其可表示为 $g(h(\mathbf{x}; \theta)) - y^T h(\mathbf{x}; \theta)$ $\mathcal{L}(h(\mathbf{x}; \theta), y) =$, 其中 g 为函数, y 为独热编码的类别标签。采用共轭伪标签进行自适应的测试时自适应损失可写为:

$$\mathcal{L}_{\text{TTA}}(\mathbf{X}_B^t, \tilde{\mathbf{y}}(\theta)) := -\frac{1}{N_{Bt}} \sum_{i=1}^{N_{Bt}} \mathcal{L}(h(\mathbf{x}_i^t; \theta)/T, \tilde{y}_i(\theta)), \quad (10)$$

其中 $\tilde{y}_i(\theta) = \nabla g(h(\mathbf{x}_i^t)/T; \theta), \forall \mathbf{x}_i^t \in \mathbf{X}_B^t$

温度 T 用于缩放预测器。

A.3. 测试时自适应算法详述

本小节给出测试时自适应的详细算法 (算法 2)。在本文设定中, 模型在测试数据批次到达时在线自适应, 随后立即进行预测。

Algorithm 2 Test-Time Adaptation

- 1: **Input:** Source model parameters θ^s , number of steps N , TTA update rate: η
 - 2: **Initialization:** $\theta = \theta^s$
 - 3: **for** step = 1, 2, ..., N **do**
 - 4: Obtain a new test batch $\mathbf{X}_B^t$ from the test domain.
 - 5: $\theta_B \leftarrow \{\mu(\mathbf{X}_B^t), \sigma^2(\mathbf{X}_B^t)\}$
 - 6: $\theta_A \leftarrow \theta_A - \eta \cdot \partial \mathcal{L}_{\text{TTA}}(\mathbf{X}_B^t) / \partial \theta_A$
 - 7: $\theta \leftarrow \theta_A \cup \theta_B \cup \theta_{\mathcal{F}}$
 - 8: Make the prediction $\hat{\mathbf{y}}_B^t = f(\mathbf{X}_B^t; \theta)$
 - 9: **end for**
-

A.4. 传统机器学习脆弱性

以下小节补充介绍机器学习脆弱性及其与动态输入攻击 (DIA) 的关联。随后强调所提攻击的独特性, 使其区别于其他已知的对抗样本与数据投毒攻击。

对抗样本。绝大多数研究深度神经网络脆弱性的工作都集中在寻找难以察觉的对抗样本上。这些样本已被成功用于在测试时欺骗模型 (Goodfellow 等人, 2015; Carlini 和 Wagner, 2017; Vorobeychik 和 Kantarcioglu, 2018)。通常, 生成对抗样本 $\hat{\mathbf{x}}^t = \mathbf{x}^t + \hat{\delta}$ 可以表述如下:

$$\hat{\delta} = \arg \max_{\delta} \mathcal{L}(f(\mathbf{x}^t + \delta; \theta^s), y^t) \quad s.t. \|\delta\|_p \leq \varepsilon, \quad (11)$$

其中 $\mathcal{L}$ 是损失函数 (例如, 交叉熵损失), $\mathbf{x}^t, y^t$ 表示一个测试数据, $\|\delta\|_p \leq \varepsilon$ 是扰动 δ 的 ℓ_p 约束。目标是优化 δ 以最大化预测损失 $\mathcal{L}$ 。对于 ℓ_∞ 约束, 该问题可以通过投影梯度下降 (Madry 等人, 2018) 求解为

$$\delta \leftarrow \Pi_\varepsilon(\delta + \alpha \text{sign}(\nabla_{\delta} \mathcal{L}(f(\mathbf{x}^t + \delta; \theta^s), y^t))). \quad (12)$$

这里, Π_ε 表示将更新后的扰动投影回约束, α 是攻击步长。通过式 (12) 迭代更新, 攻击者很可能导致模型误预测。我们 DIA 攻击的单层变体采用了类似于投影梯度下降的算法。

机器学习流程中对抗样本的一个特点是扰动必须施加在目标数据上。因此, 只要用户安全地保存测试数据 (不被扭曲), 机器学习模型总能做出良性预测。我们针对 TTA 的攻击与对抗样本不同, 我们的恶意样本可以

插入到测试批次中，并攻击良性且未受扰动的数据。因此，如果部署 TTA，安全风险会不断增加。

数据投毒攻击。在不直接修改数据的情况下攻击良性样本，另一种有害的攻击变体——数据投毒，可以实现这一目标。具体而言，攻击者将投毒样本注入训练集，旨在使训练后的模型对良性样本产生错误预测。投毒攻击主要有两个目标：定向投毒和无差别投毒。对于定向投毒攻击（Koh & Liang, 2017; Carlini & Terzis, 2021; Carlini, 2021; Geiping et al., 2020），攻击者的目标是攻击一个特定的样本，并预先选定错误的目标标签，其形式可写为：

$$\min_{\delta} \mathcal{L}(f(\mathbf{x}_{tgt}^t, \theta^*(\delta)), y_{tgt}^t) \quad s.t. \theta^*(\delta) = \arg \min_{\theta} \frac{1}{N_s} \sum_{i=1}^{N_s} \mathcal{L}(f(\mathbf{x}_i^s + \delta_i, \theta), y_i^s) \quad (13)$$

其中 $\mathbf{x}_{tgt}^t$ 是目标样本， y_{tgt}^t 是对应的错误目标标签。 $\mathbf{x}_i^s$ 是训练数据， y_i^s 是对应的真实标签。我们用 δ_i 表示对训练数据 $\mathbf{x}_i^s$ 的扰动，由于有 N_m 个投毒样本，部分 δ_i 保持为零以表示干净样本。

对于无差别攻击（Nelson et al., 2008; Biggio et al., 2012），攻击者试图降低所有测试数据的准确率，其形式可表示为：

$$\min_{\delta} -\frac{1}{N_t} \sum_{j=1}^{N_t} \mathcal{L}(f(\mathbf{x}_j^t, \theta^*(\delta)), y_j^t) \quad s.t. \theta^*(\delta) \in \arg \min_{\theta} \frac{1}{N_s} \sum_{i=1}^{N_s} \mathcal{L}(f(\mathbf{x}_i^s + \delta_i, \theta), y_i^s) \quad (14)$$

其中 $\mathbf{x}_j^t$ 是测试数据， y_j^t 是其真实标签。这些目标也指导了我们攻击者目标的设计。

然而，针对机器学习模型的数据投毒的关键特征是假设攻击者能够访问训练数据。因此，如果模型开发者从可靠来源获取训练数据并确保数据库安全，那么任何投毒攻击都无法生效。我们针对测试时自适应的攻击与数据投毒不同，动态输入攻击仅需要访问测试数据。这使得我们的攻击更容易实施，因为野外环境中的数据（测试数据）不太可能被监控。

A.5. 扩展相关工作

我们在本小节中介绍更多与本文相关的工作。

无监督领域自适应。无监督领域自适应（Unsupervised Domain Adaptation, UDA）解决的是利用带标签的源域数据和无标签的目标域数据，使在源域上训练的模型在目标域上表现良好的问题。一种常见方法（Ganin 等，2016; Long 等，2018）是使用源域和目标域共享权重的神经网络，并引入额外的损失项以促使网络学习领域不变特征。其他方法包括显式地（Saito 等，2018; Damodaran 等，2018）或隐式地（Li 等，2016; Wang 等，2019）对齐源域和目标域的分布。与我们的设置相关的一类方法是无源领域自适应（Liang 等，2020; Kundu 等，2020; Li 等，2020），其中假设给定源模型和整个测试集。例如，SHOT（Liang 等，2020）在推理阶段利用信息最大化和伪标签来对齐源域和目标域。

测试时自适应。测试时自适应（Test-time Adaptation, TTA）获取在源域上训练的模型，并在目标域上执行自适应。一些方法（Sun 等，2020; Liu 等，2021; Gandelsman 等，2022）通过添加自监督代理任务来修改训练目标，以促进测试时训练。然而，在许多情况下，无法访问训练过程。因此，一些测试时自适应方法仅修正批量归一化（Batch Norm, BN）统计量（Singh & Shrivastava, 2019; Nado 等，2020; Schneider 等，2020; You 等，2021; Hu 等，2021）。后来，TENT（Wang 等，2021b）、BACS（Zhou & Levine, 2021）和 MEMO（Zhang 等，2021a）被提出，通过在测试时最小化熵来提升性能。其他方法（Galstyan & Cohen, 2007; Lee 等，2013; Rusak 等，2022; Goyal 等，2022; Wang & Wibisono, 2022）使用源模型（或其他模型）生成的伪标签来自训练一个自适应模型。作为一个活跃的研究领域，近期工作致力于在各个方向进一步改进 TTA 方法。例如，Niu 等（2022）试图解决 TTA 的遗忘问题。Wang 等（2022b）；Gong 等（2022）；Huang 等（2022）提出了方法来

解决持续的领域偏移问题。Iwasawa 和 Matsuo (2021) 通过使用伪原型表示改进了伪标签。Zhang 等人 (2021c)、Kojima 等人 (2022)、Gao 等人 (2022b) 利用最近的视觉变换器模型架构来改进测试时自适应。

大多数测试时自适应方法假设一批测试样本可用，而一些论文考虑测试样本逐个到达 (Zhang 等人, 2021a; Gao 等人, 2022a; Bartler 等人, 2022; Mirza 等人, 2021; Döbler 等人, 2022)。例如，MEMO (Zhang 等人, 2021b) 利用单个测试输入上的多种增强，然后调整模型参数。Gao 等人 (2022a) 提出使用扩散将分布外样本转换回源域。这种“单样本”自适应范式对每个数据进行独立预测，避免了测试时自适应的风险 (即 DIA)。然而，批量测试样本提供了更多关于分布的信息，通常能获得更好的性能。

对抗样本与防御。大量工作探索了难以察觉的对抗样本 (Goodfellow 等人, 2015; Carlini 和 Wagner, 2017; Vorobeychik 和 Kantarcioglu, 2018)，这些样本在测试时欺骗模型并引发安全问题。作为回应，对抗训练 (Madry 等人, 2017) (使用对抗样本进行训练) 已被提出作为防御对抗样本的有效技术。后来，出现了许多增强方法，涉及鲁棒性 (Wu 等人, 2020a; Schwag 等人, 2022; Dai 等人, 2022; Gowal 等人, 2021)、时间效率 (Shafahi 等人, 2019; Wong 等人, 2019) 以及效用-鲁棒性权衡 (Pang 等人, 2022; Wang 等人, 2022a)。

通过转导学习的对抗防御。安全社区也探索了使用转导学习来增强机器学习鲁棒性的方法 (Goldwasser 等人, 2020; Wu 等人, 2020b; Wang 等人, 2021a)。然而，Chen 等人 (2021) 和 Croce 等人 (2022) 的后续工作表明，这些通过转导学习的防御在鲁棒性上只有很小的改进。本文关注另一个视角，即转导学习在良性和未扰动数据中引入了新的脆弱性。

数据投毒攻击与防御。数据投毒攻击是指向训练集中注入被投毒的样本，从而使模型预测错误。该攻击已被应用于不同的机器学习算法，包括基于贝叶斯的方法 (Nelson 等, 2008)、支持向量机 (Biggio 等, 2012) 以及神经网络 (Koh 和 Liang, 2017)。后来，Carlini (2021) 尝试对半监督学习的无标签训练集进行投毒，而 Carlini 和 Terzis (2021) 则针对对比学习，使用极少数量的投毒样本。最近，研究者利用投毒攻击来实现其他目标 (例如，增强成员推断攻击 (Tramèr 等, 2022) 和破坏机器遗忘 (Marchant 等, 2021; Di 等, 2022))。在防御方面，Geiping 等 (2021) 表明对抗训练也能有效防御数据投毒攻击。

领域自适应中的对抗风险。只有少数论文讨论了领域自适应设置下的对抗风险。一个例子是 (Mehra 等, 2021)，该工作提出了几种利用源域和目标域信息向源域数据添加投毒数据的方法。另一个例子是 (Wu 和 He, 2021)，该工作引入了 I2Attack，这是一种间接的、不可见的投毒攻击，仅操纵源样本，但能使领域自适应算法在目标测试样本上做出错误预测。然而，这两种方法都假设攻击者可以访问源数据，因此无法应用于无源 (测试时自适应) 设置。

B. 分布入侵攻击的理论分析

在本附录中，我们提供了计算第 4 节所述 DIA 梯度的技术细节。然后，我们分析了为何通过训练时批归一化进行平滑可以缓解我们的攻击。为简单起见，我们考虑单层情况，梯度计算可以通过反向传播推广到多层情况。

B.1. 理解重新估计批归一化统计量的脆弱性

回顾设置，其中 $\mathbf{x}_{tgt}^t \in \mathbb{R}^d$, $\mathbf{X}_B^t = (x_{i,j})_{i=1\dots n, j=1\dots d} \in \mathbb{R}^{n \times d}$, $\vec{w} \in \mathbb{R}^d$ 且 $b \in \mathbb{R}$ 。带有批归一化⁵的线性层在单个维度上的输出可以写为

$$f(\mathbf{x}_{tgt}^t) = \frac{\mathbf{x}_{tgt}^t - \mu(\mathbf{X}_B^t)}{\sqrt{\sigma^2(\mathbf{X}_B^t)}} \vec{w} + b \quad (15)$$

其中 μ 和 $\sigma^2: \mathbb{R}^{n \times d} \rightarrow \mathbb{R}^d$ 表示逐坐标的均值与方差。此外，平方根 $\sqrt{\cdot}$ 同样逐坐标应用。假设我们可以在 $\mathbf{X}_B^t$ 中扰动 x_i ，这对应于 $\mathbf{X}_{mal}^t$ 中的一个恶意数据点。为了找到导致 $f(\mathbf{x}_{tgt}^t)$ 预测最大偏差的最优扰动方向，我们计算如下导数：

$$\begin{aligned} \frac{\partial f(\mathbf{x}_{tgt}^t)}{\partial x_{i,j^*}} &= \frac{(-\frac{1}{n})(\sigma(\mathbf{X}_B^t))_j - [(\mathbf{x}_{tgt}^t)_j - \mu(\mathbf{X}_B^t)_j] \frac{\partial(\sigma(\mathbf{X}_B^t))_j}{\partial x_{i,j}}}{(\sigma(\mathbf{X}_B^t))_j^2} w_j \\ &= \frac{(-\frac{1}{n}) \{ (\sigma(\mathbf{X}_B^t))_j - [(\mathbf{x}_{tgt}^t)_j - \mu(\mathbf{X}_B^t)_j] (\sigma(\mathbf{X}_B^t))_j^{-1} (x_{i,j^*} - \mu(\mathbf{X}_B^t)_j) \}}{(\sigma(\mathbf{X}_B^t))_j^2} w_j \end{aligned}$$

$$\text{其中 } (\mu(\mathbf{X}_B^t))_j = \frac{1}{n} \sum_{i=1}^n x_{i,j}$$

$$(\sigma(\mathbf{X}_B^t))_j = \sqrt{\frac{1}{n} \sum_{i=1}^n x_{i,j}^2 - \left(\frac{1}{n} \sum_{i=1}^n x_{i,j} \right)^2}$$

然后，我们可以利用上述公式来搜索最优的恶意数据。

B.2. 基于训练时批归一化统计量的平滑分析

我们通过 $\bar{\mu} = \tau \vec{\mu}_s + (1-\tau) \vec{\mu}_t$, $\bar{\sigma}^2 = \tau \vec{\sigma}_s^2 + (1-\tau) \vec{\sigma}_t^2$ 稳健地估计最终的批归一化统计量，其中 $(\vec{\mu}_s, \vec{\sigma}_s^2)$ 是训练时批归一化统计量， $(\vec{\mu}_t = \mu(\mathbf{X}_B^t), \vec{\sigma}_t^2 = \sigma^2(\mathbf{X}_B^t))$ 是测试时批归一化统计量（见第 6.2 节）。因此，带有平滑批归一化的线性层在单个维度上的输出可以重写为

$$f(\mathbf{x}_{tgt}^t) = \frac{\mathbf{x}_{tgt}^t - ((1-\tau)\mu(\mathbf{X}_B^t) + \tau\vec{\mu}_s)}{\sqrt{(1-\tau)\sigma^2(\mathbf{X}_B^t) + \tau\vec{\sigma}_s^2}} \vec{w} + b \quad (16)$$

新的梯度可以通过以下方式计算：

⁵ 为便于分析，我们将尺度参数设为 1，平移参数设为 0。这一假设并不限制我们结果的普适性。

$$\begin{aligned}\frac{\partial f(\mathbf{x}_{tgt}^t)}{\partial x_{i,j^*}} &= \frac{(-\frac{1-\tau}{n})\tilde{\sigma}_j - [(\mathbf{x}_{tgt}^t)_j - (1-\tau)\mu(\mathbf{X}_B^t)_j - \tau(\vec{\mu}_s)_j]\frac{1}{2}(\tilde{\sigma}_j)^{-1}(1-\tau)\frac{\partial(\sigma(\mathbf{X}_B^t))_j}{\partial x_{i,j}}}{(1-\tau)(\sigma(\mathbf{X}_B^t))_j^2 + \tau(\vec{\sigma}_s^2)_j} w_j \\ &= \frac{(-\frac{1-\tau}{n})\{(\sigma(\mathbf{X}_B^t))_j^2 - [(\mathbf{x}_{tgt}^t)_j - (1-\tau)(\mu(\mathbf{X}_B^t))_j - \tau(\vec{\mu}_s)_j](\tilde{\sigma}_j)^{-1}(x_{i,j^*} - (\mu(\mathbf{X}_B^t))_j)\}}{(1-\tau)(\sigma(\mathbf{X}_B^t))_j^2 + \tau(\vec{\sigma}_s^2)_j} w_j\end{aligned}$$

$$\text{其中 } (\mu(\mathbf{X}_B^t))_j = \frac{1}{n} \sum_{i=1}^n x_{i,j},$$

$$(\sigma(\mathbf{X}_B^t))_j = \sqrt{\frac{1}{n} \sum_{i=1}^n x_{i,j}^2 - (\frac{1}{n} \sum_{i=1}^n x_{i,j})^2}$$

$$\tilde{\sigma}_j := \sqrt{(1-\tau)(\sigma(\mathbf{X}_B^t))_j^2 + \tau(\vec{\sigma}_s^2)_j}.$$

这里，每当 $\mu(\mathbf{X}_B^t) \approx \vec{\mu}_s$ 且 $\sigma^2(\mathbf{X}_B^t) \approx \vec{\sigma}_s^2$ 时，梯度范数 $\|\frac{\partial f(\mathbf{x}_{tgt}^t)}{\partial x_{i,j^*}}\|$ 将随着 τ 的增大而减小。具体地，当 $\tau = 1$ 时， $\|\frac{\partial f(\mathbf{x}_{tgt}^t)}{\partial x_{i,j^*}}\| = 0$ ，这意味着批归一化统计量仅基于训练时批归一化，不涉及任何对抗风险。

C. 初步结果

C.1. 利用训练时批归一化统计量进行测试时自适应的合理性检验

本实验中，我们使用 ResNet 架构（He 等人，2016）在 CIFAR-10-C、CIFAR-100-C 和 ImageNet-C 上评估了采用训练时批归一化统计量的测试时自适应性能。注意，我们未包含 TeBN 方法的结果，因为它与 **Source** 方法（直接使用源模型而不采用任何测试时自适应方法）完全相同。对于其他测试时自适应方法，仅更新批归一化层内的仿射变换参数（即缩放 γ_l 和偏移 β_l ）。所有其他超参数与 Goyal 等人（2022）的实验保持一致，包括批大小 200 和测试时自适应学习率 $\eta = 0.001$ 。




图 9. 使用训练时批归一化统计量时，测试时自适应在损坏数据集上表现出明显的性能下降。[严重程度：3]

采用训练时批归一化完全破坏了测试时自适应的性能增益（图 9）。我们观察到所有测试时自适应方法在各基准上均表现出显著下降（从 $\sim 15\%$ 到 $\sim 50\%$ ）。可以推断，测试时批归一化统计量的利用对所有已实现的测试时自适应方法至关重要。

C.2. 双层优化的初步结果

本文研究利用双层优化（Bilevel Optimization）寻找恶意数据 $\mathbf{X}_{mal}^t$ 的有效性。

表 5. 分布入侵攻击在有无双层优化下的攻击成功率。（我们省略 TeBN，因为两种方法相同）

Dataset	N_m	Bilevel	TENT(%)	Hard PL(%)	Soft PL(%)	Robust PL(%)	Conjugate PL(%)
CIFAR-10-C (ResNet26)	10 (5%)	✗	23.20	25.33	23.20	24.80	23.60
	10 (5%)	✓	22.93	23.73	22.80	24.00	23.73
	20 (10%)	✗	45.73	48.13	47.47	49.47	45.73
	20 (10%)	✓	44.40	47.33	46.40	47.60	45.20
	40 (10%)	✗	83.87	84.27	82.93	86.93	85.47
	40 (10%)	✓	82.80	84.53	82.40	84.53	84.67
CIFAR-100-C (ResNet26)	10 (5%)	✗	26.40	31.20	27.60	32.13	26.13
	10 (5%)	✓	26.93	31.87	28.80	32.93	26.40
	20 (10%)	✗	72.80	87.33	78.53	82.93	71.60
	20 (10%)	✓	72.27	85.87	78.13	85.47	72.13
	40 (10%)	✗	100.00	99.87	100.00	99.87	100.00
	40 (10%)	✓	100.00	99.73	100.00	100.00	100.00
ImageNet-C (ResNet50)	5 (2.5%)	✗	75.73	69.87	62.67	66.40	57.87
	5 (2.5%)	✓	74.93	70.13	62.13	67.47	59.43
	10 (5%)	✗	98.67	96.53	94.13	96.00	92.80
	10 (5%)	✓	98.40	97.07	94.40	96.27	93.43
	20 (10%)	✗	100.00	100.00	100.00	100.00	100.00
	20 (10%)	✓	100.00	100.00	100.00	99.73	100.00

本文提出的单层解决方案达到了与双层优化方法相当的有效性（表 5）。我们评估了带和不带双层优化（内循环）步骤的 DIA 方法，结果表明在大多数情况下，两者之间的差异通常小于 1%。此外，我们观察到使用双层优化会导致计算时间大幅增加（增加约 ~ 10 倍）。

C.3. 测试时自适应在损坏数据集上的有效性

我们展示了应用测试时自适应（TTA）方法提升损坏准确率的有效性。我们用 **Source** 表示未使用 TTA 的源模型性能。




图 10. 测试时自适应持续提升严重程度为 3 的损坏数据集上的准确率。

所有 TTA 方法都显著提升了分布偏移基准上的准确率（图 10）。我们观察到 TTA 在损坏输入上的绝对性能增益为：CIFAR-10-C 上 $>5\%$ ，CIFAR-100-C 上 $>10\%$ ，ImageNet-C 上 $>12\%$ 。这些有前景的结果激励了在测试数据发生分布偏移的各种应用中使用 TTA 方法。

D. 分布入侵攻击的补充实验细节与结果

在本附录中，我们展示第 5 节的一些补充实验细节与结果。首先在附录 D.1 中概述实验设置。随后在附录 D.2 中通过改变恶意样本数量研究分布入侵攻击（DIA）的有效性，并在附录 D.3 中使用各种模型和数据增强进行研究。接着，我们深入探讨不同类型的攻击目标和约束，包括（1）无差别攻击（附录 D.4），（2）隐蔽定向攻击（附录 D.5），以及（3）通过模拟损坏进行的分布入侵攻击（附录 D.6）。此外，我们考察了各种测试时自适应（TTA）设计选择，例如更大的学习率（附录 D.8）和增加的优化步数（附录 D.9）。我们还在附录 D.6 中通过调整损坏严重程度考虑了各种损坏选择下的分布入侵攻击，并在附录 D.11 中展示了所有类型损坏的详细结果。附录 D.10 中应用了其他新的基线方法。

D.1. 实验设置的补充细节

数据集。我们的攻击在 CIFAR-10 到 CIFAR-10-C、CIFAR-100 到 CIFAR-100-C 以及 ImageNet 到 ImageNet-C (Hendrycks & Dietterich, 2019) 上进行评估，这些数据集包含测试数据上的 15 种损坏类型。我们选择所有损坏类型，并在大多数实验中将损坏严重程度设置为 3。⁶ 因此，我们的 CIFAR-10-C 和 CIFAR-100-C 评估集分别包含来自 10 个和 100 个类别的 $10,000 \times 15 = 150,000$ 张图像，分辨率为 32×32 。对于 ImageNet-C，有来自 1000 个标签的 $5,000 \times 15 = 75,000$ 张高分辨率（ 224×224 ）图像用于评估我们的攻击。

源模型细节。我们遵循分布偏移基准（distribution shift benchmarks）上的常见做法（Hendrycks & Dietterich, 2019），并在 CIFAR-10、CIFAR-100 和 ImageNet 上训练模型。对于在 CIFAR 数据集上训练模型，我们使用 SGD 优化器，学习率为 0.1，动量为 0.9，权重衰减为 0.0005。我们以批大小 256 训练模型 200 个训练轮次。我们还使用余弦退火调度调整学习率（Loshchilov & Hutter, 2016）。这与 Goyal et al. (2022) 的配置相同。如前所述，架构包括 26 层的 ResNet (He et al., 2016)、19 层的 VGG (Simonyan & Zisserman, 2015)、28 层的 Wide ResNet (Zagoruyko & Komodakis, 2016)。对于 ImageNet 基准，我们直接使用从 RobustBench (Croce et al., 2020) 下载的模型 (<https://robustbench.github.io/>)，包括标准训练的 ResNet-50 (He et al., 2016)、AugMix (Hendrycks et al., 2020)、DeepAugment (Hendrycks et al., 2021)、来自 Salman et al. (2020) 和 Engstrom et al. (2019) 的鲁棒模型。我们想强调，测试时自适应不一定需要从头训练模型，从外部下载是可以接受的，有时甚至是可取的。

测试时自适应方法。选择了六种测试时自适应方法，包括 TeBN (Schneider et al., 2020)、TENT (Wang et al., 2021b)、硬伪标签 (Hard PL) (Lee et al., 2013; Galstyan & Cohen, 2007)、软伪标签 (Soft PL) (Lee et al., 2013; Galstyan & Cohen, 2007)、鲁棒伪标签 (Robust PL) (Rusak et al., 2022) 和共轭伪标签 (Conjugate PL) (Goyal et al., 2022)，它们在数据分布偏移时都获得了明显的性能提升。我们使用与 Wang et al. (2021b) 和 Goyal et al. (2022) 相同的默认超参数，代码可在 github.com/DequanWang/tent 和 github.com/locuslab/tta-conjugate 获取。除了将批大小设置为 200 外，我们使用 Adam 作为 TTA 优化器， $\eta = 0.001$ 作为 TTA 学习率，温度设为 1。每个测试批次执行 1 步 TTA。

攻击设置。每个测试批次是一次独立的攻击试验，包含 200 个样本。因此，CIFAR-C 共有 $150,000/200=750$ 次试验，ImageNet-C 共有 $75,000/200=375$ 次试验。我们所有的实验结果均对所有试验取平均。对于定向攻击，我们使用攻击成功率 (ASR) 作为攻击有效性的评估度量，即 DIA 能将目标样本翻转到预选标签的比例。对于非定向攻击，我们使用损坏错误率（即在良性损坏数据上的错误率）来衡量有效性。对于隐蔽定向攻击，我们再次使用攻击成功率 (ASR) 作为攻击有效性度量。此外，由于我们希望保持损坏准确率，我们利用损坏准确率下降（即良性损坏数据与“无攻击”相比的准确率下降）作为度量。

对于其他超参数，我们设置攻击步数 $N = 500$ 和攻击优化率 $\alpha = 1/255$ 。此外，如果像 Madry 等人 (2018) 那样应用更多迭代或多次随机初始化，攻击有效性可以进一步提高。我们将更多增强 DIA 技术留作未来方向。

⁶ 损坏的严重程度从 1 到 5，其中 3 可视为中等损坏程度。

D.2. 不同恶意样本数量下 DIA 的更多实验

图 11 描绘了 DIA 成功率与恶意样本数量之间的关系。我们选择了 TeBN、TENT 和 Hard PL 作为演示的 TTA 方法，并观察到它们表现相似。我们的结论“DIA 使用 64 个恶意样本对 CIFAR-10-C、32 个对 CIFAR-100-C、16 个对 ImageNet-C 即可获得接近 100% 的 ASR”仍然成立。




图 11. 我们提出的攻击在恶意样本数量从 1 到 128 (0.5% 到 64%) 下的成功率。[TTA: TeBN、TENT 和 Hard PL] (图 2 的扩展版本)

D.3. DIA 在不同模型架构和数据增强下的有效性

随后，本文针对数据无关投毒攻击 (DIA) 开展了更为全面的实验，涵盖不同模型架构、数据增强策略以及恶意样本数量。在表 6 (表 2 的完整版本) 中，本文观察到，与宽残差网络 (Wide ResNet) 架构相比，VGG 架构的攻击成功率受恶意样本数量的影响较小。例如，在 CIFAR-10-C 数据集上采用 TeBN 方法时，当 N_m 从 10 增加到 40，VGG 的攻击成功率从 $\sim 42\%$ 提升至 $\sim 79\%$ ，而宽残差网络则从 $\sim 16\%$ 提升至 $\sim 94\%$ 。因此，本文之前的假设应修正为“在恶意数据数量充足的情况下，更多的批归一化层会暴露更多漏洞”。对于 ImageNet-C 数据集，本文仍观察到强数据增强带来的轻微缓解效果。

D.4. 无差别攻击的有效性

我们进一步展示了更多测试时自适应 (TTA) 方法和恶意样本数量选项下无差别攻击的详细结果。由于不同恶意数据数量下的良性损坏错误率不同，我们在括号中用红色标注了损坏错误率的改善情况。

表 7. 部署无差别攻击时测试时自适应的平均损坏错误率。括号内的红色数字为损坏错误率改善值。(表 3 的扩展版本)

Dataset	N_m	TeBN(%)	TENT(%)	Hard PL(%)	Soft PL(%)	Robust PL(%)	Conjugate PL(%)
CIFAR-10-C (ResNet26)	10 (5%)	15.66 (+4.96)	15.16 (+4.74)	15.86 (+4.84)	15.56 (+4.86)	16.60 (+5.04)	14.32 (+4.51)
	20 (10%)	20.09 (+9.37)	19.43 (+9.00)	20.14 (+9.10)	19.77 (+9.06)	21.04 (+9.46)	18.51 (+8.70)
	40 (20%)	28.02 (+17.29)	27.01 (+16.54)	27.91 (+16.86)	27.47 (+16.69)	28.81 (+17.20)	26.09 (+16.26)
CIFAR-100-C (ResNet26)	10 (5%)	43.84 (+7.22)	42.90 (+7.32)	44.65 (+7.92)	43.45 (+7.56)	45.34 (+8.02)	42.01 (+7.53)
	20 (10%)	51.99 (+13.44)	50.33 (+12.60)	52.00 (+13.33)	50.80 (+12.82)	52.52 (+13.21)	49.39 (+12.71)
	40 (20%)	58.41 (+23.89)	54.44 (+21.13)	56.59 (+21.93)	54.93 (+21.22)	56.97 (+21.72)	53.33 (+21.06)
ImageNet-C (ResNet50)	5 (2.5%)	57.42 (+9.45)	54.53 (+8.90)	52.32 (+8.70)	50.53 (+8.50)	51.52 (+8.43)	50.18 (+8.52)
	10 (5%)	67.18 (+19.21)	62.39 (+16.76)	58.70 (+15.09)	55.90 (+13.88)	57.08 (+13.97)	55.60 (+13.94)
	20 (10%)	79.03 (+31.24)	75.01 (+29.57)	70.26 (+26.84)	65.67 (+23.81)	67.53 (+24.60)	65.30 (+23.80)

无差别的分布入侵攻击 (DIA) 导致良性样本的错误率大幅上升 (表 7)。我们观察到恶意数据比例与错误率改善之间的比率在 CIFAR-10-C 上约为 $0.9 \times$ ，在 CIFAR-100-C 上约为 $1.2 \times$ 。例如，在 CIFAR-100-C 上使用 20 个 (10%) 恶意数据时，错误率增加了 $\sim 12\%$ 。值得注意的是，在 ImageNet-C 上，20 个 (10%) 恶意数据导致错误率改善了 $\sim 25\%$ 。此外，与其他测试时自适应方法相比，TeBN 仍然是对分布入侵攻击最脆弱的方法。

表 6. 分布入侵攻击在不同模型架构、数据增强和恶意数据数量下的有效性。（表 2 的完整版本）

Dataset	N_m	Architectures	TeBN(%)	TENT(%)	Hard PL(%)	Soft PL(%)	Robust PL(%)	Conjugate PL(%)
CIFAR-10-C	10 (5%)	ResNet-26	25.87	23.20	25.33	23.20	24.80	23.60
		VGG-19	41.73	30.27	30.13	28.00	33.07	29.07
		WRN-28	16.27	14.40	14.67	14.53	15.73	13.87
	20 (10%)	ResNet-26	55.47	45.73	48.13	47.47	49.47	45.73
		VGG-19	60.13	44.80	46.67	44.13	46.67	44.67
		WRN-28	46.00	41.47	43.33	41.60	44.00	40.53
	40 (20%)	ResNet-26	92.80	83.87	84.27	82.93	86.93	85.47
		VGG-19	79.07	65.33	67.47	64.13	67.47	64.13
		WRN-28	93.73	89.60	90.80	90.13	91.20	89.33
CIFAR-100-C	10 (5%)	ResNet-26	46.80	26.40	31.20	27.60	32.13	26.13
		VGG-19	42.13	32.00	41.33	33.60	33.87	37.33
		WRN-28	29.60	14.67	16.53	15.47	18.13	14.53
	20 (10%)	ResNet-26	93.73	72.80	87.33	78.53	82.93	71.60
		VGG-19	71.60	57.33	71.60	61.87	63.60	66.13
		WRN-28	64.80	38.67	44.13	40.93	46.40	39.87
	40 (20%)	ResNet-26	100.00	100.00	99.87	100.00	99.87	100.00
		VGG-19	88.00	82.93	86.53	85.73	87.33	85.47
		WRN-28	97.47	83.60	87.07	86.67	90.13	79.73
Dataset	N_m	Augmentations	TeBN(%)	TENT(%)	Hard PL(%)	Soft PL(%)	Robust PL(%)	Conjugate PL(%)
ImageNet-C	5 (2.5%)	Standard	80.80	75.73	69.87	62.67	66.40	57.87
		AugMix	72.53	65.60	59.47	53.60	56.27	49.07
		DeepAugment	67.20	63.73	58.67	53.87	57.33	53.33
	10 (5%)	Standard	99.47	98.67	96.53	94.13	96.00	92.80
		AugMix	98.40	96.00	93.60	88.27	92.00	87.20
		DeepAugment	96.00	94.67	91.20	87.47	89.60	86.67
	20 (10%)	Standard	100.00	100.00	100.00	100.00	100.00	100.00
		AugMix	100.00	100.00	100.00	100.00	100.00	100.00
		DeepAugment	100.00	100.00	100.00	100.00	100.00	100.00

D.5. 隐蔽定向攻击的有效性

接下来，我们在图 12 中展示针对 CIFAR-C 数据集的隐蔽定向攻击的更多结果。我们使用 40 个恶意数据和 TeBN 方法，其中 $\omega = \{0, 0.1, 0.2\}$ 。具体而言，我们选择了三种架构，包括 ResNet-26、VGG-19 和 WRN-28。由于不同架构会导致不同的损坏准确率，我们使用损坏准确率下降来衡量隐蔽性，其中最佳攻击应具有 0% 的下降。我们观察到，当 $\omega = 0.1$ 时，通过牺牲约 10% 的攻击成功率，可以获得 $< 2\%$ 的下降。此外，我们发现 Wide ResNet-28 的攻击成功率下降幅度远大于其他模型架构。




图 12. 调整权重 ω 可实现高攻击成功率（折线）和最小的良性损坏准确率下降（柱状）。[$N_m=40$, TTA 方法: Norm] (图 3 的扩展版本)

D.6. 通过模拟损坏进行分布入侵攻击

本小节介绍生成模拟损坏的细节，并展示其有效性。

构建模拟损坏。我们直接利用 Kang 等人（2019）的方法来构建对抗性雪和雾效果，这些方法可在 github.com/ddkang/advex-uar 获取。具体而言，我们在随机选择的位置使用许多微小的遮挡图像区域来表示雪花。然后，这些“雪片”的强度和方向被对抗性优化。此外，对抗性雾是通过对抗性优化菱形-方形算法（Fournier 等人，1982）生成的，该算法是一种常用于创建随机、随机雾效果的技术。我们在图 27 中展示了一些雪和雾攻击的示例。

模拟损坏可用作一种输入隐蔽的分布入侵攻击（Distribution Invading Attack, DIA）方法（表 8）。在评估中，我们使用雪攻击干净图像，并将其插入雪损坏的验证集。类似地，我们对雾损坏数据集使用雾攻击。我们观察到，无论是对抗性雪还是雾，都能有效攻击所有测试时自适应方法，攻击成功率至少为 60%。

表 8. 对抗性优化的雪损坏和雾损坏的平均攻击成功率。[$N_m=20$; 目标攻击]（表 4 的扩展版本）

Dataset	Corruption	TeBN(%)	TENT(%)	Hard PL(%)	Soft PL(%)	Robust PL(%)	Conjugate PL(%)
ImageNet-C (ResNet-50)	Snow	64.00	68.00	68.00	60.00	68.00	60.00
	Fog	84.00	76.00	72.00	76.00	76.00	76.00

D.7. 分布入侵攻击在不同损坏严重程度下的有效性




图 13. 损坏严重程度如何影响我们在 ImageNet-C 数据集上的攻击的损坏准确率和攻击成功率的说明。（折线图：攻击成功率；柱状图：损坏准确率）[$N_m=5$; 目标攻击]




图 14. 损坏严重程度如何影响我们在 CIFAR-C 数据集上的攻击的损坏准确率和攻击成功率的说明。（折线图：攻击成功率；柱状图：损坏准确率）[$N_m=20$; 目标攻击]

较大的损坏严重程度往往更容易受到分布入侵攻击（图 13 和图 14）。我们之前的评估仅集中于中等严重程度（级别 3）的损坏；现在，我们分析损坏严重程度的影响。首先，当损坏更严重时，准确率显著下降，例如，在 ImageNet-C 上从级别 1 到级别 5 的平均退化接近 30%。因此，正如预期的那样，随着模型（由测试时自适应方法更新）倾向于对其预测不自信，分布入侵攻击的攻击成功率变得更高。在 CIFAR-C 数据集上也观察到类似行为。

D.8. 较大测试时自适应学习率下分布入侵攻击的有效性

我们对测试时自适应学习率 η （此前实验设为 0.001）进行了消融研究（见表 9）。具体而言，我们将 η 增大至 0.005 并评估分布入侵攻击。当测试时自适应学习率增大时，本文的单层优化方法出现一定性能下降，但在 20 个（10%）恶意数据下仍能达到接近 100% 的攻击成功率。此外，我们还观察到当 $\eta = 0.005$ 时，损坏准确率平均下降 $\sim 4\%$ 。

表 9. 在 ImageNet-C 数据集上采用较大测试时自适应学习率 (η) 的分布入侵攻击有效性。

N_m	η	TeBN(%)	TENT(%)	Hard PL(%)	Soft PL(%)	Robust PL(%)	Conjugate PL(%)
5 (2.5%)	0.001	80.80	75.73	69.87	62.67	66.40	57.87
	0.005	80.80	52.00	46.93	35.73	45.33	32.00
10 (5%)	0.001	99.47	98.67	96.53	94.13	96.00	92.80
	0.005	99.47	87.73	83.73	74.67	82.13	71.47
20 (5%)	0.001	100.00	100.00	100.00	100.00	100.00	100.00
	0.005	100.00	100.00	99.73	98.13	100.00	98.67

D.9. 更多测试时自适应优化步数下分布入侵攻击的有效性

在本小节中，我们进行了消融研究（见表 10），其中测试时自适应优化步数不再是 1 步而是 5 步。我们观察到，若测试时自适应以 5 步优化无监督损失，分布入侵攻击性能出现下降（0% 至 25%）。然而，在 20 个恶意数据下，攻击成功率仍接近 100%。

表 10. 在 ImageNet-C 数据集上采用更多测试时自适应优化步数的分布入侵攻击有效性。

N_m	Steps	TeBN(%)	TENT(%)	Hard PL(%)	Soft PL(%)	Robust PL(%)	Conjugate PL(%)
5 (2.5%)	1	80.80	75.73	69.87	62.67	66.40	57.87
	5	80.80	58.13	53.07	39.73	49.87	36.00
10 (5%)	1	99.47	98.67	96.53	94.13	96.00	92.80
	5	99.47	93.60	88.53	79.73	87.20	77.87
20 (5%)	1	100.00	100.00	100.00	100.00	100.00	100.00
	5	100.00	100.00	100.00	99.73	100.00	99.47

D.10. 针对额外基线方法的分布入侵攻击有效性

在本小节中，我们展示本文的分布入侵攻击同样能够攻击测试时熵最小化（TENT）的先进方法，如高效测试时自适应（ETA）（Niu 等，2022）。总体而言，高效测试时自适应引入了一种技术，通过主动选择可靠样本来更新基础模型，从而提升测试时熵最小化的效率。然而，它们仍然受到重新估计批归一化统计量这一漏洞的影响。因此，我们可以直接应用分布入侵攻击，且结果表明，在 CIFAR-C 数据集上，高效测试时自适应比测试时熵最小化更加脆弱（表 11）。此外，在 ImageNet-C 基准上，20 个恶意数据仍能达到接近 100% 的攻击成功率。

表 11. 分布入侵攻击（定向攻击）在不同基准和测试时自适应方法上的攻击成功率。

Dataset	N_m	TeBN(%)	TENT(%)	ETA(%)
CIFAR-10-C (ResNet26)	10 (5%)	25.87	23.20	24.53
	20 (10%)	55.47	45.73	53.07
	40 (20%)	92.80	83.87	89.87
CIFAR-100-C (ResNet26)	10 (5%)	46.80	26.40	33.60
	20 (10%)	93.73	72.80	86.67
	40 (20%)	100.00	100.00	100.00
ImageNet-C (ResNet50)	5 (2.5%)	80.80	75.73	41.33
	10 (5%)	99.47	98.67	81.60
	20 (10%)	100.00	100.00	99.47

D.1.1. 分布入侵攻击在不同损坏类型上的有效性

随后，我们在表 12 中报告了分布入侵攻击在所有 15 种损坏类型上的结果。对于 CIFAR-10-C 和 CIFAR-100-C，我们选择 $N_m = 20$ ；对于 ImageNet-C，我们选择 $N_m = 5$ 。我们观察到，在亮度损坏下的预测最难攻击。这是预期结果，因为亮度损坏的良性准确率最高（Schneider 等人，2020）。

表 12. 分布入侵攻击在不同损坏类型上的有效性。（CIFAR- C: $N_m=20$; ImageNet- C: $N_m=5$ ）

Dataset	Corruption Type	TeBN(%)	TENT(%)	Hard PL(%)	Soft PL(%)	Robust PL(%)	Conjugate PL(%)
CIFAR-10-C (ResNet-26) ($N_m=20$ (10%))	Gaussian Noise	68.0	48.0	52.0	50.0	56.0	50.0
	Shot Noise	70.0	54.0	56.0	62.0	62.0	54.0
	Impulse Noise	76.0	48.0	58.0	54.0	62.0	50.0
	Defocus Blur	44.0	38.0	38.0	40.0	40.0	40.0
	Glass Blur	50.0	44.0	52.0	44.0	48.0	42.0
	Motion Blur	54.0	48.0	46.0	50.0	52.0	46.0
	Zoom Blur	44.0	46.0	44.0	46.0	44.0	44.0
	Snow	58.0	44.0	42.0	44.0	50.0	44.0
	Frost	48.0	46.0	48.0	50.0	48.0	48.0
	Fog	60.0	40.0	46.0	44.0	48.0	40.0
	Brightness	38.0	38.0	40.0	38.0	38.0	40.0
	Contrast	62.0	48.0	48.0	48.0	50.0	50.0
	Elastic Transform	56.0	56.0	58.0	50.0	54.0	52.0
	Pixelate	44.0	46.0	46.0	44.0	40.0	44.0
	JPEG Compression	60.0	42.0	48.0	48.0	50.0	42.0
All		55.47	45.73	48.13	47.47	49.47	45.73
CIFAR-100-C (ResNet-26) ($N_m=20$ (10%))	Gaussian Noise	100.0	80.0	92.0	86.0	94.0	74.0
	Shot Noise	100.0	80.0	98.0	82.0	86.0	82.0
	Impulse Noise	96.0	82.0	92.0	90.0	90.0	74.0
	Defocus Blur	86.0	64.0	82.0	72.0	82.0	68.0
	Glass Blur	96.0	78.0	80.0	78.0	78.0	66.0
	Motion Blur	94.0	74.0	82.0	80.0	82.0	74.0
	Zoom Blur	90.0	60.0	80.0	62.0	70.0	60.0
	Snow	92.0	72.0	80.0	74.0	72.0	66.0
	Frost	94.0	72.0	94.0	74.0	82.0	78.0
	Fog	94.0	76.0	92.0	86.0	92.0	76.0
	Brightness	86.0	64.0	84.0	72.0	72.0	68.0
	Contrast	96.0	80.0	94.0	88.0	94.0	78.0
	Elastic Transform	100.0	74.0	90.0	80.0	84.0	70.0
	Pixelate	90.0	64.0	84.0	80.0	78.0	72.0
	JPEG Compression	92.0	72.0	86.0	74.0	88.0	68.0
All		93.73	72.80	87.33	78.53	82.93	71.60
ImageNet-C (ResNet-50) ($N_m=5$ (2.5%))	Gaussian Noise	92.0	92.0	72.0	56.0	64.0	52.0
	Shot Noise	88.0	76.0	68.0	56.0	60.0	48.0
	Impulse Noise	92.0	84.0	80.0	68.0	80.0	60.0
	Defocus Blur	100.0	96.0	88.0	84.0	84.0	80.0
	Glass Blur	92.0	84.0	84.0	68.0	72.0	64.0
	Motion Blur	88.0	88.0	84.0	68.0	76.0	68.0
	Zoom Blur	84.0	76.0	76.0	72.0	76.0	68.0
	Snow	72.0	64.0	56.0	56.0	56.0	56.0
	Frost	88.0	72.0	72.0	64.0	68.0	52.0
	Fog	88.0	84.0	80.0	76.0	80.0	68.0
	Brightness	48.0	48.0	44.0	40.0	40.0	40.0
	Contrast	96.0	96.0	88.0	84.0	88.0	80.0
	Elastic Transform	56.0	60.0	52.0	48.0	48.0	40.0
	Pixelate	56.0	52.0	52.0	44.0	48.0	36.0
	JPEG Compression	72.0	64.0	52.0	56.0	56.0	56.0
All		80.80	75.73	69.87	62.67	66.40	57.87

E. 关于鲁棒模型和缓解方法的额外实验

在本附录中，我们展示一些额外的发现和缓解方法的结果，作为第 6 节的补充。

本节路线图如下。首先从两个方面研究鲁棒模型的作用。在附录 E.1 中，将测试时适应（TTA）应用于对抗训练模型，并意外观察到干净准确率的提升。随后在附录 E.2 中评估鲁棒模型面对损坏准确率时的性能，并在附录 E.3 中分析其抵抗 DIA 攻击的有效性。此外，广泛研究了鲁棒批归一化（BN）估计。在附录 E.4 中，可视化逐层 BN 的行为。然后在附录 E.5 中提供鲁棒 BN 估计在 CIFAR-C 上的额外结果，在附录 E.6 中提供 ImageNet-C 上的结果。最后，在附录 E.7 中对鲁棒 BN 估计进行参数搜索。

E.1. 对抗模型与测试时适应在干净数据上的额外发现

Dataset	Models	Source(%)	TeBN(%)	TENT(%)	Hard PL(%)	Soft PL(%)	Robust PL(%)	Conjugate PL(%)
CIFAR-10	(Dai et al., 2022) WRN-28	87.02	87.00	91.74	90.83	91.62	90.93	91.68
	(Wu et al., 2020a) WRN-28	88.25	86.35	92.81	91.35	93.07	93.02	91.59
	(Gowal et al., 2021) WRN-28	87.49	87.42	88.39	88.22	88.44	88.21	88.44
	(Sehwag et al., 2022) RN-18	84.59	84.38	87.24	87.25	87.63	87.05	86.73
CIFAR-100	(Sehwag et al., 2022) WRN-34	65.93	67.37	73.96	70.63	74.06	73.93	72.81
	(Wu et al., 2020a) WRN-34	60.38	55.37	62.01	59.43	62.19	61.89	61.87
	(Chen et al., 2022) WRN-34	64.07	61.94	67.58	61.29	68.11	69.09	65.02
	(Jia et al., 2022) WRN-34-20	67.31	64.17	69.72	68.60	70.21	69.97	69.71

表 13. 在 CIFAR-10 和 CIFAR-100 上，对经过对抗训练的模型进行测试时自适应可以提升干净样本准确率。作为参考，标准 28 层宽残差网络（WRN-28）在 CIFAR-10 上的准确率为 94.78%，在 CIFAR-100 上为 78.78%。（RN-18 为 ResNet-18，WRN-34 为宽残差网络 34）

对抗训练的一个显著弱点是在干净测试数据上性能明显下降（Madry 等人，2018；Xie 等人，2019），这是由于对抗输入与干净输入在批归一化（Batch Normalization, BN）上的分布不一致所致。因此，Xie 等人（2020）提出使用不同的 BN 层来处理来自两种分布的数据，而 Wang 等人（2022a）则利用无归一化器网络（移除 BN 层）来提高干净准确率。正如我们所讨论的，测试时自适应（TTA）方法在缓解分布偏移方面表现出有前景的改进。因此，我们考虑当训练数据来自对抗数据分布时，它们是否能够提高干净输入的准确率。

TTA 方法在 CIFAR-10 上为对抗训练模型带来了显著的干净准确率提升，并且

CIFAR-100（表 13）。我们选取了一系列对抗训练方法（Dai et al., 2022; Wu et al., 2020a; Gowal et al., 2021; Sehwag et al., 2022; Chen et al., 2022; Jia et al., 2022）作为源模型，并在干净输入上使用测试时自适应方法。所有模型均从 RobustBench（Crocce et al., 2020）下载。如图所示，软伪标签显著提升了平均准确率 $\sim 3.35\%$ （CIFAR-10）和 $\sim 4.22\%$ （CIFAR-100）。最显著的提升甚至比不使用测试时自适应方法高出 8.13%。这一结果从另一个角度加深了对测试时自适应的理解，我们希望未来工作能对此进行更多探索。我们还观察到，在 ImageNet 上简单替换批归一化统计量的效果不如使用对抗模型。

E.2. 鲁棒模型的损坏准确率

我们评估了损坏准确率，其中 CIFAR-10-C 选用 Gowal et al. (2021) 和 Wu et al. (2020a) 训练的 28 层宽残差网络，CIFAR-100-C 选用 Pang et al. (2022) 和 Rebuffi et al. (2021) 开发的 28 层宽残差网络。注意所有对抗模型均从 RobustBench（Crocce et al., 2020）下载。

在 CIFAR-10-C 上，使用测试时自适应的鲁棒模型性能优于标准模型，但在 CIFAR-100-C 上表现较差

（图 15 和图 16）。对于 CIFAR-10-C，我们观察到使用鲁棒模型带来了性能提升。例如，Wu et al. (2020a) 比标准模型提高了 $\sim 5\%$ 。对于 CIFAR-100-C，鲁棒模型无法达到与标准模型相当的性能。然而，结合对抗模型和测试时自适应仍能超过未使用测试时自适应的标准模型。由于它们可能使用不同的训练配置（例如训练批大小、数据增强、内部优化步数），我们将“为测试时自适应训练最佳对抗源模型”的问题留作未来工作。

如果部署了测试时自适应（TTA），鲁棒模型在 ImageNet-C 上可以达到与标准模型相当的性能（图 17）。随后，我们评估了鲁棒模型在 ImageNet-C 数据集上的损坏准确率。具体而言，我们选择了由 Salman 等人（2020）和 Engstrom 等人（2019）提出的对抗训练 ResNet 50 模型。我们观察到，对抗模型的平均损坏准确率可以显著受益于测试时自适应方法。例如，鲁棒模型的平均损坏准确率比标准模型低 $\sim 10\%$ ，但在部署 TTA 时达到相似性能。此外，鲁棒模型在更高严重程度下通常比标准模型获得更高的准确率（e.g., $\sim$ 在严重程度 5 下使用 TTA 提高 10% ）。




图 15. 标准模型和鲁棒模型（Gowal 等人（2021）和 Wu 等人（2020a））在 CIFAR-10-C 上不同严重程度下的损坏准确率。




图 16. 标准模型和鲁棒模型（Pang 等人（2022）和 Rebuffi 等人（2021））在 CIFAR-100-C 上不同严重程度下的损坏准确率。




图 17. 标准模型和鲁棒模型（Salman 等人（2020）和 Engstrom 等人（2019））在 ImageNet-C 上不同严重程度下的损坏准确率。

E.3. 通过鲁棒模型缓解 CIFAR-C 基准上的分布入侵攻击




图 18. 我们提出的攻击针对鲁棒模型在不同恶意样本数量下的攻击成功率。作为参考，128 个样本占包含 200 个样本的整个批次的 64%。CIFAR-10-C 的鲁棒模型为 Gowal 等人（2021）和 Wu 等人（2020a）；CIFAR-100-C 的鲁棒模型为 Pang 等人（2022）和 Rebuffi 等人（2021）。[TTA 方法：TeBN]

在图 18 中，我们报告了标准模型和两个鲁棒模型在 CIFAR-C 数据集上不同恶意样本数量下的攻击成功率（ASR）。对抗模型减轻了对 DIA 的脆弱性，但无法完全消除。例如，使用 32 个恶意样本时，鲁棒模型在 CIFAR-10-C 和 CIFAR-100-C 上的 ASR 分别降低了 $\sim 60\%$ 和 $\sim 70\%$ 。然而，增加恶意样本仍然会破坏鲁棒源模型。

E.4. 理解逐层批归一化行为

为了进一步设计更鲁棒的方法，我们试图理解在部署分布入侵攻击时批归一化统计量会发生什么变化。因此，我们在图 28 和图 29 中可视化了所有 53 层的批归一化均值直方图和批归一化方差直方图，包括有攻击和无攻击的情况。我们使用带有 ℓ_1 范数的沃瑟斯坦距离来衡量两个直方图之间的差异。具体来说，给定 $\mathbb{R}$ 上的两个概率测度 μ_w, μ_v ，康托罗维奇形式（Kantorovich Formulation）下的沃瑟斯坦距离定义为

$$D_W(\mu_w, \mu_v) := \min_{\pi \in \Pi(\mu_w, \mu_v)} \int_{\mathbb{R} \times \mathbb{R}} |z - z'| d\pi(z, z') \quad (17)$$

$\Pi(\mu_w, \mu_v) := \{ \pi \in \mathcal{P}(\mathbb{R} \times \mathbb{R}) \mid \int_{\mathbb{R}} \pi(z, z') dz = \mu_w, \int_{\mathbb{R}} \pi(z, z') dz' = \mu_v \}$ 其中表示两个分布 μ_w 和 μ_v 之间的耦合集合。这里，我们将每个直方图自然地视为离散概率分布。注意，不同层的直方图可能具有不同的总体尺度；因此，为了公平比较，我们将 ℓ_1 距离 $|z - z'|$ 按良性样本直方图的范围进行归一化。

图 19(a) 展示了每一层的沃瑟斯坦距离，有趣的是，我们观察到 D_w 在大多数层上保持较低，但在最后几层上跃升，尤其是批归一化层 52。然后，我们在图 19(b) 中可视化了第 52 层的直方图，这似乎是一个明显的分布偏移。




图 19. (a) 恶意与良性批归一化统计量之间的沃瑟斯坦距离在批归一化层 52 处意外升高。(b) 批归一化层 52 的批均值和方差直方图。（更多图见图 28 和图 29）。

E.5. 鲁棒批归一化估计在 CIFAR-C 上的有效性

我们报告了两种鲁棒估计方法在 CIFAR-C 上的有效性：通过训练时批归一化统计量进行平滑和自适应选择逐层批归一化统计量。具体来说，我们使用 $N_m = 40$ ，这对防御来说非常具有挑战性（攻击成功率接近 100%）。同样，我们选择 $\tau = \{0.0, 0.2, 0.4, 0.6, 0.8, 1.0\}$ 来平衡训练时和测试时的批归一化。对于自适应选择逐层批归一化统计量，我们对最后 $N_{tr} = \{0, 1, 2, 4, 8, 16\}$ 个批归一化层利用完整的训练时批归一化（ $\tau = 1.0$ ）。




图 20. 控制 $\tau = 0.6$ 可以降低攻击成功率（折线），同时保持较高的损坏准确率（柱状）。[$N_m=40$]




图 21. 控制逐层批归一化可以降低攻击成功率（折线），同时保持较高的损坏准确率（柱状）。[$N_m=40$; $\tau=0.6$]

稳健地估计最终批归一化统计量显著增强了对分布入侵攻击（Distribution Invading Attack, DIA）的性能。图 20 展示了使用训练时批归一化进行平滑的有效性，如果选择 $\tau = 0.6$ ，标准模型的攻击成功率 $\sim$ 会降低 30%。然后，我们保持 $\tau = 0.6$ 并应用逐层批归一化。结果，攻击成功率进一步降低约 15%，而不会

牺牲损坏准确率（如图 21 所示）。总之，应用我们的两种稳健估计方法可以使标准模型的攻击成功率总共降低 $\sim 45\%$ ，对抗模型的攻击成功率降低 $\sim 30\%$ 。

我们的方法在测试时自适应性能和针对分布入侵攻击的鲁棒性之间存在权衡。在利用测试批次信息时，它并不能从根本上消除脆弱性。此外，在没有分布外信息的情况下选择合适的超参数（即 τ 和 N_{tr} ）是另一个具有挑战性的问题。

E.6. 在 ImageNet-C 上稳健批归一化估计的额外实验




图 22. 稳健估计最终批归一化统计量可以降低攻击成功率（折线），同时在 ImageNet-C 上保持较高的损坏准确率（柱状）。[$N_m=40$] 这是图 7 和图 8 在更多恶意样本下的补充评估。

图 22 展示了第 6.2 节在更强攻击设置（ $N_m = 40$ ）下的额外实验。我们观察到结论保持一致：选择合适的 τ 和 N_{tr} (i.e., $\tau = 0.6$, $N_{tr} = 16$) 可以分别将稳健模型和标准模型的攻击成功率降低 $\sim 70\%$ 和 $\sim 20\%$ ，同时保持损坏准确率。

E.7. 稳健估计批归一化时损坏准确率的更多评估

在本小节中，我们对平滑因子 τ 和训练时批归一化层数 N_{tr} 进行了更全面的参数搜索，以理解它们对损坏准确率的影响。具体而言，我们在 CIFAR-C 和 ImageNet-C 基准上分析了标准模型和稳健模型。

如图 23、图 24 和图 25 所示，我们观察到当 $\tau = 0.5$ 和 $N_{tr} = 0$ 时，损坏准确率通常达到最佳。与 TeBN ($\tau = 0$ 和 $N_{tr} = 0$) 相比，改进有限（ $\sim 2\%$ ），除了 CIFAR-100-C 上的稳健模型。当 $\tau > 0.7$ 时，损坏准确率急剧下降。此外，增加 N_{tr} 也会降低损坏数据的准确率。






图 23. 在 CIFAR-10-C 上平衡训练时批归一化在 τ 和训练时批归一化层数下的损坏准确率。

图 24. 在 CIFAR-100-C 上，平衡训练时批归一化 (BN) 跨 τ 与训练时 BN 层数的损坏准确率。图 25. 在 ImageNet-C 上，平衡训练时批归一化 (BN) 跨 τ 与训练时 BN 层数的损坏准确率。

F. 约束攻击的可视化

F.1. 损坏图像及其对应示例 恶意图像


 L_∞ 

图 26. 来自 ImageNet-C 基准的 15 种损坏良性图像（上）与带有 $\epsilon = 8/255$ 的恶意图像（下）的演示。大多数恶意图像与其原始图像相比在视觉上难以察觉。[严重程度：3 级]

F.2. 损坏图像与对抗性损坏图像示例




图 27. 展示来自 ImageNet-C 的雪和雾损坏数据集（严重程度 3 级）以及对抗性损坏图像（DIA）。我们观察到，人工区分恶意样本和良性样本是困难的。

G. 批归一化统计量可视化




图 28. 有无 DIA 攻击时批归一化均值直方图的逐层完整可视化。最后几层的分布存在差异。




图 29. 有无 DIA 攻击时批归一化方差直方图的逐层完整可视化。最后几层的分布存在差异。