

基于扩散的规划用于灵活行为综合

Michael Janner^{*1} Yilun Du^{*2} 约书亚·B·特南鲍姆² Sergey Levine¹

摘要

基于模型的强化学习方法通常仅将学习用于估计近似动力学模型，而将剩余的决策工作交由经典轨迹优化器处理。尽管这一组合在概念上简单，但在实践中存在诸多不足，表明学习得到的模型可能并不适合标准轨迹优化。本文探讨了将轨迹优化流程尽可能融入建模问题中的可能性，使得从模型中采样与利用模型进行规划几乎一致。我们技术方法的核心在于一种扩散概率模型，该模型通过迭代去噪轨迹来进行规划。我们展示了分类器引导采样和图像修复如何被重新解释为连贯的规划策略，探索了基于扩散的规划方法所具有的独特且有用的性质，并在强调长时程决策和测试时灵活性的控制场景中验证了框架的有效性。




图 1. Diffuser 是一种扩散概率模型，通过迭代细化轨迹来进行规划。

然而，这种组合很少能如描述般奏效。由于强大的轨迹优化器会利用学习到的模型，该过程生成的计划往往更像对抗样本而非最优轨迹（Talvitie, 2014; Ke et al., 2018）。因此，当代基于模型的强化学习算法往往更多继承自无模型方法，如价值函数和策略梯度（Wang et al., 2019），而非轨迹优化工具箱。那些确实依赖在线规划的方法倾向于使用简单的无梯度轨迹优化例程，如随机射击（Nagabandi et al., 2018）或交叉熵方法（Botev et al., 2013; Chua et al., 2018），以避免上述问题。

1 引言

利用学习模型进行规划是强化学习和数据驱动决策中一个概念上简单的框架。其吸引力在于仅在最为成熟和有效的环节使用学习技术：即在本质上属于监督学习问题的未知环境动力学近似中。之后，学习得到的模型可以接入经典的轨迹优化例程（Tassa 等, 2012; Posa 等, 2014; Kelly, 2017），这些例程在其原始背景下同样得到了充分理解。

本文提出一种数据驱动轨迹优化的替代方法。核心思想是训练一个直接适用于轨迹优化的模型，使得从模型中采样与利用模型规划几乎一致。这一目标要求模型设计方式的转变。由于学习到的动力学模型通常旨在作为环境动力学的代理，改进往往通过根据底层因果过程构建模型来实现（Bapst et al., 2019）。相反，本文考虑如何根据模型将用于的规划问题来设计模型。例如，由于模型最终将用于规划，动作分布与状态动力学同样重要，长时程准确率比单步误差更重要。另一方面，模型应保持对奖励函数的不可知性，以便可用于

^{*} 同等贡献 1 加州大学伯克利分校 2 麻省理工学院。通讯作者：janner@berkeley.edu, yilundu@mit.edu。




图 2. Diffuser 通过迭代去噪由可变数量状态-动作对组成的二维数组来采样计划。较小的感受野约束模型在单个去噪步骤中仅强制局部一致性。通过组合多个去噪步骤，局部一致性可以驱动采样计划的全局连贯性。可选的引导函数 J 可用于使计划偏向于优化测试时目标或满足一组约束的计划。

在多个任务中，包括训练期间未见过的任务。最后，模型的设计应使其规划（而不仅仅是预测）能够随着经验的积累而改进，并且能够抵抗标准基于射击的规划算法中常见的短视失败模式。

我们将这一思想实例化为一个轨迹级扩散概率模型（Diffusion Probabilistic Model），称为扩散规划器（Diffuser），如图 2 所示。标准的基于模型的规划技术以自回归方式在时间上向前预测，而扩散规划器则同时预测计划的所有时间步。扩散模型的迭代采样过程带来了灵活的调节能力，允许辅助引导修改采样过程，以恢复具有高回报或满足一组约束的轨迹。这种数据驱动轨迹优化的表述具有几个吸引人的特性：

长时域可扩展性 扩散规划器的训练目标是其生成轨迹的准确性，而非单步误差，因此它不会遭受单步动力学模型的复合滚动误差，并且相对于长规划时域能够更优雅地扩展。

任务组合性 奖励函数在采样计划时提供辅助梯度，通过将多个奖励的梯度相加，可以同时组合多个奖励，从而实现直接的规划方式。

时间组合性 扩散规划器通过迭代改进局部一致性来生成全局连贯的轨迹，使其能够通过拼接分布内的子序列来泛化到新颖的轨迹。

有效的非贪心规划 通过模糊模型与规划器之间的界限，改进模型预测的训练过程同时也提升了其规划能力。这种设计产生了一个学习型规划器，能够解决许多传统规划方法难以应对的长时域、稀疏奖励问题。

本工作的核心贡献是一个针对轨迹数据设计的去噪扩散模型，以及一个用于行为综合的相关概率框架。尽管与深度基于模型的强化学习中常用的模型类型相比显得非常规，我们证明了扩散规划器具有许多有用的特性，并且在需要长时域推理和测试时灵活性的离线控制环境中特别有效。

2 背景

我们的规划方法是过去使用轨迹优化进行行为综合工作的基于学习的类比（Witkin & Kass, 1988; Tassa et al., 2012）。在本节中，我们简要介绍轨迹优化所考虑的问题设置以及我们为该方法采用的生成模型类别。

2.1 问题设置

考虑一个由离散时间动力学 $s_{t+1} = f(s_t, a_t)$ 在状态 s_t 给定动作 a_t 下支配的系统。轨迹优化指的是找到一系列动作 $a_{0:T}^*$ ，以最大化（或最小化）一个目标 J ，该目标按每个时间步的奖励（或成本） $r(s_t, a_t)$ 分解：

$$a_{0:T}^* = \arg \max_{a_{0:T}} J(s_0, a_{0:T}) = \arg \max_{a_{0:T}} \sum_{t=0}^T r(s_t, a_t)$$

其中 T 是规划时域。我们使用缩写

$\tau = (s_0, a_0, s_1, a_1, \dots, s_T, a_T)$ 来指代状态和动作交错的轨迹，并使用 $J(\tau)$ 来表示该轨迹的目标值。

2.2 扩散概率模型

扩散概率模型（Diffusion Probabilistic Models）（Sohl-Dickstein 等, 2015; Ho 等, 2020）将数据生成过程视为一种迭代去噪程序 $p_\theta(\tau^{i-1} | \tau^i)$ 。该去噪过程是正向扩散过程 $q(\tau^i | \tau^{i-1})$ 的逆过程，正向扩散通过添加噪声缓慢破坏数据结构。模型所诱导的数据分布由下式给出：

$$p_\theta(\tau^0) = \int p(\tau^N) \prod_{i=1}^N p_\theta(\tau^{i-1} | \tau^i) d\tau^{1:N}$$

其中 $p(\tau^N)$ 为标准高斯先验， τ^0 表示（无噪声）数据。参数 θ 通过最小化以下目标进行优化

负对数似然的变分下界

逆向过程: $\theta^* = \arg \min_{\theta} -\mathbb{E}_{\tau^0} [\log p_{\theta}(\tau^0)]$. The 逆向过程通常被参数化为具有固定时间步相关协方差的高斯分布:

$$p_{\theta}(\tau^{i-1} | \tau^i) = \mathcal{N}(\tau^{i-1} | \mu_{\theta}(\tau^i, i), \Sigma^i).$$

正向过程 $q(\tau^i | \tau^{i-1})$ 通常是预先指定的。

符号说明。本文涉及两种“时间”：扩散过程的时间与规划问题的时间。我们使用上标（未指定时为 i ）表示扩散时间步，使用下标（未指定时为 t ）表示规划时间步。例如， s_t^0 指无噪声轨迹中的第 t^{th} 个状态。当上下文无歧义时，无噪声量的上标可省略： $\tau = \tau^0$ 。我们略微重载符号，将轨迹 τ 中的第 t^{th} 个状态（或动作）记为 τ_{s_t} （或 τ_{a_t} ）。

3 基于扩散的规划

使用轨迹优化技术的一个主要障碍是它们需要环境动力学的知识。大多数基于学习的方法试图通过训练一个近似动力学模型并将其嵌入传统规划流程来克服这一障碍。然而，学习得到的模型往往不适合那些为真实模型设计的规划算法，导致规划器利用学习模型来

寻找对抗样本。

我们提出建模与规划之间更紧密的耦合。不同于在经典规划器中使用学习模型，我们尽可能将规划过程纳入生成式建模框架，使规划几乎等同于采样。我们通过轨迹的扩散模型 $p_{\theta}(\tau)$ 来实现这一点。扩散模型的迭代去噪过程天然支持灵活的条件化，通过从如下形式的扰动分布中采样：

$$\tilde{p}_{\theta}(\tau) \propto p_{\theta}(\tau)h(\tau). \quad (1)$$

函数 $h(\tau)$ 可以包含先验证据（如观测历史）、期望结果（如要到达的目标）或需要优化的一般函数（如奖励或代价）的信息。在该扰动分布中进行推理可视作第 2.1 节所提轨迹优化问题的概率类比，因为它需要找到既在 $p_{\theta}(\tau)$ 下物理真实又在 $h(\tau)$ 下高奖励（或满足约束）的轨迹。由于动力学信息与扰动分布 $h(\tau)$ 分离，同一个扩散模型 $p_{\theta}(\tau)$ 可在同一环境中复用于多个任务。

本节描述 Diffuser，一个为学习轨迹优化而设计的扩散模型。然后讨论 Diffuser 规划的两种具体实例，分别实现为分类器引导采样和图像修复的强化学习对应方法。

3.1 一种用于轨迹规划的生成模型

时间顺序。模糊从轨迹模型中采样与利用其进行规划之间的界限，产生了一个不寻常的约束：我们不能再按时间顺序自回归地预测状态。考虑目标条件推理 $p(s_1 | s_0, s_T)$ ；下一个状态 s_1 同时依赖于未来状态和先前状态。这个例子是一个更一般原则的实例：虽然动力学预测是因果的，即现在由过去决定，但决策和控制可以是反因果的，即现在的决策以未来为条件。¹ 由于我们无法使用时间自回归顺序，我们设计 Diffuser 来同时预测计划的所有时间步。

时间局部性。尽管不是自回归或马尔可夫的，Diffuser 具有一种宽松的时间局部性形式。在图 2 中，我们描绘了一个由单个时间卷积组成的扩散模型的依赖图。给定预测的感受野仅由附近的时间步组成，包括过去和未来。因此，去噪过程的每一步只能基于轨迹的局部一致性进行预测。然而，通过组合许多这样的去噪步骤，局部一致性可以驱动全局连贯性。

轨迹表示。

Diffuser 是一个为规划而设计的轨迹模型，这意味着从模型导出的控制器的有效性与状态预测的质量同样重要。因此，轨迹中的状态和动作被联合预测；就预测而言，动作只是状态的额外维度。具体来说，我们将 Diffuser 的输入（和输出）表示为一个二维数组：

$$\tau = \begin{bmatrix} s_0 & s_1 & \cdots & s_T \\ a_0 & a_1 & \cdots & a_T \end{bmatrix}. \quad (2)$$

规划时域的每个时间步对应一列。

架构。我们现在已具备指定扩散器（Diffuser）架构所需的要素：（1）整条轨迹应以非自回归方式预测，（2）去噪过程的每一步应在时间上局部化，¹ 在一般强化学习语境中，对未来进行条件化源于为编写动态规划递归而假设未来最优性。具体而言，这表现为动作分布 $\log p(a_t | s_t, \mathcal{O}_{t:T})$ 中的未来最优性变量 $\mathcal{O}_{t:T}$ （Levine, 2018）。

Algorithm 1 Guided Diffusion Planning

```

1: Require Diffuser  $\mu_\theta$ , guide  $\mathcal{J}$ , scale  $\alpha$ , covariances  $\Sigma^i$ 
2: while not done do
3:   Observe state  $\mathbf{s}$ ; initialize plan  $\tau^N \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 
4:   for  $i = N, \dots, 1$  do
5:     // parameters of reverse transition
6:      $\mu \leftarrow \mu_\theta(\tau^i)$ 
7:     // guide using gradients of return
8:      $\tau^{i-1} \sim \mathcal{N}(\mu + \alpha \Sigma \nabla \mathcal{J}(\mu), \Sigma^i)$ 
9:     // constrain first state of plan
10:     $\tau_{s_0}^{i-1} \leftarrow \mathbf{s}$ 
11:   Execute first action of plan  $\tau_{\mathbf{a}_0}^0$ 
    
```

以及 (3) 轨迹表示应允许沿一个维度（规划时域）具有等变性，而沿另一个维度（状态和动作特征）不具有等变性。我们通过一个由重复的（时间）卷积残差块组成的模型来满足这些标准。整体架构类似于在基于图像的扩散模型中取得成功的 U 型网络（U-Net）类型，但将二维空间卷积替换为一维时间卷积（图 A1）。由于模型是全卷积的，预测的时域长度不由模型架构决定，而由输入维度决定；如果需要，它可以在规划过程中动态变化。

训练。我们使用扩散器来参数化轨迹去噪过程的学习梯度 $\epsilon_\theta(\tau^i, i)$ ，从中可以闭式求解均值 μ_θ （Ho et al., 2020）。我们使用简化目标来训练 ϵ 模型，其表达式为：

$$\mathcal{L}(\theta) = \mathbb{E}_{i, \epsilon, \tau^0} [\|\epsilon - \epsilon_\theta(\tau^i, i)\|^2],$$

其中 $i \sim \mathcal{U}\{1, 2, \dots, N\}$ 是扩散时间步， $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 是噪声目标， τ^i 是被噪声 ϵ 破坏的轨迹 τ^0 。反向过程的协方差 Σ^i 遵循 Nichol & Dhariwal (2021) 的余弦调度。

3.2 强化学习作为引导采样

为了用扩散器解决强化学习问题，我们必须引入奖励的概念。为此，我们借助控制即推理（control-as-inference）图模型（Levine, 2018）。设 $\mathcal{O}_t$ 为一个二元随机变量，表示轨迹第 t 个时间步的最优性，且

$p(\mathcal{O}_t = 1) = \exp(r(\mathbf{s}_t, \mathbf{a}_t))$ 。我们可以通过在方程 1 中设置 $h(\tau) = p(\mathcal{O}_{1:T} | \tau)$ 来从最优轨迹集合中采样：

$$\tilde{p}_\theta(\tau) = p(\tau | \mathcal{O}_{1:T} = 1) \propto p(\tau) p(\mathcal{O}_{1:T} = 1 | \tau).$$

我们已将强化学习问题转化为条件采样问题。值得庆幸的是，目前已有

已有大量关于扩散模型条件采样的前期工作。虽然从该分布中精确采样难以实现，但当 $p(\mathcal{O}_{1:T} | \tau^i)$ 足够平滑时，逆向扩散过程的转移可近似为高斯分布（Sohl-Dickstein 等, 2015）：

$$p_\theta(\tau^{i-1} | \tau^i, \mathcal{O}_{1:T}) \approx \mathcal{N}(\tau^{i-1}; \mu + \Sigma g, \Sigma) \quad (3)$$

where μ, Σ are the parameters of the original reverse process transition $p_\theta(\tau^{i-1} | \tau^i)$ and

$$\begin{aligned} g &= \nabla_\tau \log p(\mathcal{O}_{1:T} | \tau)|_{\tau=\mu} \\ &= \sum_{t=0}^T \nabla_{\mathbf{s}_t, \mathbf{a}_t} r(\mathbf{s}_t, \mathbf{a}_t)|_{(\mathbf{s}_t, \mathbf{a}_t)=\mu_t} = \nabla \mathcal{J}(\mu). \end{aligned}$$

该关系提供了分类器引导采样（用于生成类别条件图像（Dhariwal & Nichol, 2021））与强化学习问题设定之间的直接转换。本文首先在所有可用轨迹数据的状态和动作上训练一个扩散模型 $p_\theta(\tau)$ 。随后训练一个单独的模型 $\mathcal{J}_\phi$ 来预测轨迹样本 τ^i 的累积奖励。 $\mathcal{J}_\phi$ 的梯度被用于通过根据方程 3 修改反向过程的均值 μ 来引导轨迹采样过程。采样轨迹 $\tau \sim p(\tau | \mathcal{O}_{1:T} = 1)$ 的第一个动作可在环境中执行，之后规划过程在标准的滚动时域控制循环中重新开始。引导规划方法的伪代码见算法 1。

3.3 目标条件强化学习作为图像修复

某些规划问题更自然地表述为约束满足而非奖励最大化。在这些设定中，目标是生成满足一组约束的任何可行轨迹，例如终止于目标位置。借助方程 2 所描述的轨迹二维数组表示，该设定可转化为修复问题，其中状态和动作约束的作用类似于图像中的观测像素（Sohl-Dickstein 等人, 2015）。数组中所有未观测位置必须由扩散模型以与观测约束一致的方式填充。

该任务所需的扰动函数为观测值处的狄拉克 δ 函数，其余位置为常数。具体而言，若 $\mathbf{c}_t$ 为时间步 t 处的状态约束，则

$$h(\tau) = \delta_{\mathbf{c}_t}(\mathbf{s}_0, \mathbf{a}_0, \dots, \mathbf{s}_T, \mathbf{a}_T) = \begin{cases} +\infty & \text{if } \mathbf{c}_t = \mathbf{s}_t \\ 0 & \text{otherwise} \end{cases}$$

动作约束的定义完全相同。在实践中，这可以通过从以下分布中采样来实现




图 3. (扩散规划器的特性) (a) 学习到的长时域规划: 扩散器 (Diffuser) 学习到的规划过程不会受到射击算法常见的短视失效模式的影响, 并且能够在稀疏奖励下进行长时域规划。 (b) 时间组合性: 尽管该模型不是马尔可夫模型, 但它通过迭代细化局部一致性来生成轨迹。因此, 它表现出通常与马尔可夫模型相关的泛化类型, 能够将训练数据中的轨迹片段拼接在一起以生成新颖的计划。 (c) 可变长度计划: 尽管是轨迹级模型, 扩散器的规划时域并不由其架构决定。可以在训练后通过改变输入噪声的维度来更新时域。 (d) 任务组合性: 扩散器可以与新的奖励函数组合, 为训练期间未见过的任务进行规划。在所有子图中, 表示起始状态, 表示目标状态。



未扰动的逆向过程

$$\tau^{i-1} \sim p_{\theta}(\tau^{i-1} | \tau^i)$$

并在所有扩散时间步 $i \in \{0, 1, \dots, N\}$ 之后用条件值 c_t 替换采样值。

即使是奖励最大化问题也需要通过修复进行条件化, 因为所有采样的轨迹都应从当前状态开始。这种条件化在算法 1 的第 10 行中描述。

算法 1 中的第 10 行。

4 扩散规划器的特性

我们讨论扩散器的若干重要特性, 重点关注那些要么与标准动力学模型不同, 要么对于非自回归轨迹预测而言不寻常的特性。

学习到的长时域规划。 单步模型通常被用作真实环境动态的代理 f , 因此并不与任何特定的规划算法绑定。相比之下, 算法 1 中的规划流程与扩散模型的特定能力紧密相关。由于我们的规划方法与采样几乎相同 (唯一区别在于通过扰动函数进行引导 $h(\tau)$), 扩散模型作为长时域预测器的有效性直接转化为有效的长时域规划。我们在图 3a 中展示了在目标达成设定下学习规划的优势, 表明扩散模型能够在射击法已知难以处理的稀疏奖励环境中生成可行的轨迹。

我们在第 5.1 节中对该问题设定进行了更定量的探索。

时序组合性。 单步模型通常利用马尔可夫性质进行推导, 使其能够组合分布内的转移以泛化到分布外的轨迹。由于扩散模型通过迭代改进局部一致性来生成全局连贯的轨迹 (第 3.1 节), 它也能够以新颖的方式拼接熟悉的子序列。在图 3b 中, 我们在仅沿直线行进的轨迹上训练扩散模型, 并展示其能够通过组合轨迹来泛化到 V 形轨迹。

变长规划。

由于我们的模型在预测的时域维度上完全卷积, 其规划时域不由架构选择决定。相反, 它由初始化去噪过程的输入噪声大小 $\tau^N \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 决定, 从而允许变长规划 (图 3c)。

任务组合性。

虽然扩散模型包含关于环境动态和行为的信息, 但它独立于奖励函数。由于模型充当可能未来的先验, 规划可以由相对轻量的扰动函数 $h(\tau)$ (甚至多个扰动的组合) 引导, 这些扰动对应不同的奖励。我们通过为扩散模型训练期间未见的新奖励函数进行规划来展示这一点 (图 3d)。

Environment		MPPI	CQL	IQL	Diffuser
Maze2D	U-Maze	33.2	5.7	47.4	113.9 ± 3.1
Maze2D	Medium	10.2	5.0	34.9	121.5 ± 2.7
Maze2D	Large	5.1	12.5	58.6	123.0 ± 6.4
Single-task Average		16.2	7.7	47.0	119.5
Multi2D	U-Maze	41.2	-	24.8	128.9 ± 1.8
Multi2D	Medium	15.4	-	12.1	127.2 ± 3.4
Multi2D	Large	8.0	-	13.9	132.1 ± 5.8
Multi-task Average		21.5	-	16.9	129.4

表 1.（长时程规划）扩散器（Diffuser）与先前无模型算法在迷宫二维（Maze2D）环境中的性能对比，该环境因其稀疏奖励结构而用于测试长时程规划能力。多任务二维（Multi2D）设置指在每个回合开始时重新采样目标位置的多任务变体。扩散器在两种设置下均显著优于先前方法。附录 A 详细说明了基线算法得分的来源。

5 实验评估

本文实验的重点是评估扩散器在数据驱动规划器所需能力上的表现。具体而言，本文评估：（1）在无人工奖励塑形的情况下进行长时程规划的能力；（2）泛化到训练期间未见的新目标配置的能力；（3）从质量参差不齐的异构数据中恢复有效控制器的能力。最后，本文研究基于扩散的规划在实际运行时的考量，包括在性能损失最小的情况下加速规划过程的最有效方法。

5.1 长时程多任务规划

本文在迷宫二维环境（Fu 等人，2020）中评估长时程规划，该环境要求智能体到达目标位置并获得 1 的奖励。其他任何位置均不提供奖励塑形。由于到达目标位置可能需要数百步，即使是最优秀的无模型算法也难以充分进行信用分配并可靠地到达目标（表 1）。

本文使用扩散器通过修复（inpainting）策略进行规划，以起始位置和目标位置为条件。（目标位置同样提供给无模型方法；可通过数据集中唯一具有非零奖励的状态来识别。）随后，本文将采样得到的轨迹用作开环计划。扩散器在所有迷宫尺寸下均获得超过 100 的得分，表明其优于参考专家策略。图 4 展示了生成扩散器计划的反向扩散过程。

虽然迷宫二维中的训练数据是无向的——由控制器往返于随机选择的位置组成




图 4.（规划即修复）在迷宫二维环境中，通过采样与指定起始和目标条件一致的轨迹来生成计划。其余状态由去噪过程“修复”。

位置——评估是单任务的，因为目标始终相同。为了测试多任务灵活性，我们修改环境，在每个回合开始时随机化目标位置。该设置在表 1 中记为 Multi2D。扩散器（Diffuser）天然是多任务规划器；我们无需从单任务实验中重新训练模型，只需更改条件目标。因此，扩散器在多任务设置中的表现与单任务设置中一样好。相比之下，单任务设置中最佳的无模型算法（IQL；Kostrikov 等，2022）在适应多任务设置时性能显著下降。我们采用事后经验重标记（Andrychowicz 等，2017）的多任务 IQL 的细节见附录 A。MPPI 使用真实动态；与扩散器学习到的规划算法相比，其较差的表现凸显了即使没有预测误差，长时程规划也面临困难。

5.2 测试时灵活性

为了评估对新测试时目标的泛化能力，我们构建了一套积木堆叠任务，包含三种设置：（1）无条件堆叠，任务是搭建尽可能高的积木塔；（2）有条件堆叠，任务是按指定顺序搭建积木塔；（3）重排，任务是将一组参考积木的位置匹配到新的排列中。我们在由 PDDLStream（Garrett 等，2020）生成的演示中的 10000 条轨迹上训练所有方法；成功放置积木时奖励为 1，否则为 0。这些积木堆叠任务是对测试时灵活性的挑战性诊断。

Environment	BCQ	CQL	Diffuser
Unconditional Stacking	0.0	24.4	58.7 ± 2.5
Conditional Stacking	0.0	0.0	45.6 ± 3.1
Rearrangement	0.0	0.0	58.9 ± 3.4
Average	0.0	8.1	54.4

表 3. (测试时灵活性) BCQ、CQL 和扩散器在积木堆叠任务上的性能。得分 100 对应完美执行的堆叠；0 对应随机策略。

时间灵活性；在执行随机目标的部分堆叠过程中，控制器会进入训练配置中未包含的新状态。

所有方块堆叠任务均使用同一个经过训练的扩散器 (Diffuser)，仅在不同设置之间修改扰动函数 $h(\tau)$ 。在无条件堆叠任务中，我们直接从无扰动的去噪过程 $p_\theta(\tau)$ 中采样，以模拟 PDDLStream 控制器。在条件堆叠和重排任务中，我们组合两个扰动函数 $h(\tau)$ 来偏置采样轨迹：第一个最大化轨迹最终状态与目标构型匹配的似然，第二个在堆叠运动期间强制末端执行器与方块之间的接触约束。（详见附录 B。）我们与两种先前的无模型离线强化学习算法进行比较：BCQ (Fujimoto 等人, 2019) 和 CQL (Kumar 等人, 2020)，为无条件堆叠训练标准变体，为条件堆叠和重排训练目标条件变体。（基线细节见附录 A。）定量结果见表 3，其中 100 分对应任务的完美执行。扩散器显著优于两种先前方法，条件设置需要灵活的行为生成，对无模型算法尤其困难。扩散器执行的可视化描述见图 5。




图 5. (方块堆叠) 扩散器执行的方块堆叠序列。该任务最好通过 diffusion-planning.github.io 上的视频来展示。

5.3 离线强化学习

最后，我们评估使用 D4RL 离线运动套件 (Fu 等人, 2020) 从质量各异的数据中恢复有效单任务控制器的能力。我们使用第 3.2 节描述的采样过程将扩散器生成的轨迹引导到高奖励区域，并使用第 3.3 节描述的修复过程以当前状态为条件。奖励预测器 $\mathcal{J}_\phi$ 在与扩散模型相同的轨迹上进行训练。

我们将所提方法与多种先前算法进行比较，这些算法涵盖了数据驱动控制的其他方法，包括无模型强化学习算法 CQL (Kumar 等人, 2020) 和 IQL (Kostrikov 等人, 2022)；回报条件方法，如决策 Transformer (DT; Chen 等人, 2021b)；以及基于模型的强化学习方法，包括轨迹 Transformer (TT; Janner 等人, 2021)、MOPO (Yu 等人, 2020)、MOREL (Kidambi 等人, 2020) 和 MBOP (Argenson 与 Dulac-Arnold, 2021)。在单任务设置中，Diffuser 的性能与先前算法相当：优于基于模型的 MOREL 和 MBOP 以及回报条件 DT，但劣于

Dataset	Environment	BC	CQL	IQL	DT	TT	MOPO	MOREL	MBOP	Diffuser
Medium-Expert	HalfCheetah	55.2	91.6	86.7	86.8	95.0	63.3	53.3	105.9	88.9 ± 0.3
Medium-Expert	Hopper	52.5	105.4	91.5	107.6	110.0	23.7	108.7	55.1	103.3 ± 1.3
Medium-Expert	Walker2d	107.5	108.8	109.6	108.1	101.9	44.6	95.6	70.2	106.9 ± 0.2
Medium	HalfCheetah	42.6	44.0	47.4	42.6	46.9	42.3	42.1	44.6	42.8 ± 0.3
Medium	Hopper	52.9	58.5	66.3	67.6	61.1	28.0	95.4	48.8	74.3 ± 1.4
Medium	Walker2d	75.3	72.5	78.3	74.0	79.0	17.8	77.8	41.0	79.6 ± 0.55
Medium-Replay	HalfCheetah	36.6	45.5	44.2	36.6	41.9	53.1	40.2	42.3	37.7 ± 0.5
Medium-Replay	Hopper	18.1	95.0	94.7	82.7	91.5	67.5	93.6	12.4	93.6 ± 0.4
Medium-Replay	Walker2d	26.0	77.2	73.9	66.6	82.6	39.0	49.8	9.7	70.6 ± 1.6
Average		51.9	77.6	77.0	74.7	78.9	42.1	72.9	47.8	77.5

表 2. (离线强化学习) Diffuser 及多种先前算法在 D4RL 运动基准 (Fu 等人, 2020) 上的性能。Diffuser 的结果对应 150 个规划种子的均值和标准误。先前方法性能的来源详见附录 A.3。遵循 Kostrikov 等人 (2022) 的做法，我们以粗体强调每个任务中在最大值 5% 以内的分数 ($\geq 0.95 \cdot \max$)。




图 6. (引导采样) Diffuser 通过去噪过程同时生成计划的所有时间步，而非自回归地生成。

针对单任务性能专门设计的最佳离线技术。我们还研究了一种变体，将 Diffuser 用作传统轨迹优化器（如 MPPI（Williams 等人，2015））中的动力学模型，但发现这种组合的性能并不优于随机方法，这表明 Diffuser 的有效性源于耦合的建模与规划，而非改进的开环预测准确率。

5.4 热启动扩散以实现更快的规划

Diffuser 的一个局限性是单个计划的生成速度较慢（由于迭代生成）。简单地在开环执行计划时，每一步执行都需要重新生成新计划。为了提高 Diffuser 的执行速度，我们可以进一步重用先前生成的计划来热启动后续计划的生成。

为了热启动规划，我们可以从先前生成的计划运行有限数量的前向扩散步骤，然后从这个部分加噪的轨迹运行相应数量的去噪步骤，以重新生成更新后的计划。在图 7 中，我们展示了在将用于重新生成每个新计划的底层去噪步骤数量从 2 变化到 100 时，性能与运行时间预算之间的权衡。我们发现，可以显著减少我们方法的规划预算，而性能仅略有下降。

6 相关工作

深度生成建模的最新进展已开始进入基于模型的强化学习领域，多条工作线探索了参数化为卷积 U 型网络（Kaiser 等人，2020 年）、随机循环网络（Ke 等人，2018 年；




图 7. (快速规划) Diffuser 在 Walker2d Medium-Expert 任务上的性能，当改变扩散步骤数以热启动规划时。只要计划从上一时间步的计划初始化，即使使用十分之一的扩散步骤数，性能也仅受到极小影响。

Hafner 等人，2021a；Ha & Schmidhuber，2018 年）、向量量化自编码器（Hafner 等人，2021b；Ozair 等人，2021 年）、神经微分方程（Du 等人，2020a）、归一化流（Rhinehart 等人，2020 年；Janner 等人，2020 年）、生成对抗网络（Eysenbach 等人，2021 年）、基于能量的模型（EBMs；Du 等人，2019 年）、图神经网络（Sanchez-Gonzalez 等人，2018 年）、神经辐射场（Li 等人，2021 年）以及变换器（Janner 等人，2021 年；Chen 等人，2021a）。此外，Lambert 等人（2020 年）研究了用于长时程预测的非自回归轨迹级动力学模型。这些研究通常假设模型与规划器之间存在抽象屏障。具体而言，学习的作用被降级为近似环境动力学；一旦学习完成，模型可以被插入到各种规划（Botev 等人，2013 年；Williams 等人，2015 年）或策略优化（Sutton，1990 年；Wang 等人，2019 年）算法中，因为规划器的形式并不强烈依赖于模型的形式。我们的目标是打破这一抽象屏障，设计一个与规划算法一同训练的模型，从而得到一个非自回归轨迹级模型，其采样与规划几乎相同。

多项并行研究从不同角度探索了如何打破模型学习与规划之间的抽象壁垒。相关方法包括：训练自回归潜空间模型以进行奖励预测（Tamar 等，2016；Oh 等，2017；Schrittwieser 等，2019）；根据状态价值对模型训练目标进行加权（Farahmand 等，2017）；以及将配置方法应用于学习到的单步能量（Du 等，2019；Rybkin 等，2021）。相比之下，本文方法通过同时建模并生成轨迹的所有时间步来进行规划，而非采用自回归方式，并利用辅助引导函数对采样轨迹进行条件约束。

同时地，而非自回归地，并利用辅助引导函数对采样轨迹进行条件约束。

扩散模型 (Diffusion Model) 已成为一类有前景的生成模型，其将数据生成过程表述为迭代去噪过程 (Sohl-Dickstein 等, 2015; Ho 等, 2020)。去噪过程可视为对数据分布梯度的参数化 (Song 和 Ermon, 2019)，从而将扩散模型与分数匹配 (Hyvärinen, 2005) 及基于能量的模型 (LeCun 等, 2006; Du 和 Mordatch, 2019; Nijkamp 等, 2019; Grathwohl 等, 2020) 联系起来。基于梯度的迭代采样方法天然支持灵活的条件生成 (Dhariwal 和 Nichol, 2021) 与组合性 (Du 等, 2020b)，本文利用这些特性从异构数据集中恢复有效行为，并为训练期间未见过的奖励函数进行规划。尽管扩散模型已被用于图像 (Song 等, 2021)、波形 (Chen 等, 2021c)、三维形状 (Zhou 等, 2021) 和文本 (Austin 等, 2021) 的生成，但据我们所知，此前尚未在强化学习或决策领域得到应用。

7 结论

本文提出了 Diffuser，一种用于轨迹数据的去噪扩散模型。使用 Diffuser 进行规划的过程几乎等同于从其采样，唯一区别在于加入了辅助扰动函数以引导采样。所学习的基于扩散的规划方法具有多项实用特性，包括对稀疏奖励的优雅处理、无需重新训练即可为新奖励进行规划的能力，以及时间组合性，使其能够通过拼接分布内子序列来生成分布外轨迹。本文结果为深度基于模型的强化学习开辟了一类新的基于扩散的规划方法。

代码参考

本工作使用了以下开源库：NumPy (Harris 等人, 2020)、PyTorch (Paszke 等人, 2019) 以及 PyTorch 中的扩散模型 (Wang, 2020)。

致谢

我们感谢 Ajay Jain 对早期草稿的反馈，以及 Leslie Kaelbling、Tomás Lozano-Pérez、Jascha Sohl-Dickstein、Ben Eysenbach、Amy Zhang、Colin Li 和 Toru Lin 的有益讨论。本工作部分得到了微软计算资源捐赠的支持。M.J. 受美国国家科学基金会和开放慈善项目奖学金资助。Y.D. 受美国国家科学基金会奖学金资助。

参考文献

- Andrychowicz, M., Wolski, F., Ray, A., Schneider, J., Fong, R., Welinder, P., McGrew, B., Tobin, J., Abbeel, P., and Zaremba, W. Hindsight experience replay. In *Advances in Neural Information Processing Systems*. 2017.
- Argenson, A. and Dulac-Arnold, G. Model-based offline planning. In *International Conference on Learning Representations*, 2021.
- Austin, J., Johnson, D. D., Ho, J., Tarlow, D., and van den Berg, R. Structured denoising diffusion models in discrete state-spaces. In *Advances in Neural Information Processing Systems*, 2021.
- Bapst, V., Sanchez-Gonzalez, A., Doersch, C., Stachenfeld, K. L., Kohli, P., Battaglia, P. W., and Hamrick, J. B. Structured agents for physical construction. In *International Conference on Machine Learning*, 2019.
- Botev, Z. I., Kroese, D. P., Rubinstein, R. Y., and L’Ecuyer, P. The cross-entropy method for optimization. In *Handbook of Statistics*, volume 31, chapter 3. 2013.
- Chen, C., Yoon, J., Wu, Y.-F., and Ahn, S. TransDreamer: Reinforcement learning with transformer world models, 2021a.
- Chen, L., Lu, K., Rajeswaran, A., Lee, K., Grover, A., Laskin, M., Abbeel, P., Srinivas, A., and Mordatch, I. Decision transformer: Reinforcement learning via sequence modeling. In *Advances in Neural Information Processing Systems*, 2021b.
- Chen, N., Zhang, Y., Zen, H., Weiss, R. J., Norouzi, M., and Chan, W. Wavegrad: Estimating gradients for waveform generation. In *International Conference on Learning Representations*, 2021c.
- Chua, K., Calandra, R., McAllister, R., and Levine, S. Deep reinforcement learning in a handful of trials using probabilistic dynamics models. In *Advances in Neural Information Processing Systems*. 2018.
- Dhariwal, P. and Nichol, A. Q. Diffusion models beat GANs on image synthesis. In *Advances in Neural Information Processing Systems*, 2021.
- Du, J., Futoma, J., and Doshi-Velez, F. Model-based reinforcement learning for semi-markov decision processes with neural odes. In *Advances in Neural Information Processing Systems*, 2020a.
- Du, Y. and Mordatch, I. Implicit generation and generalization in energy-based models. In *Advances in Neural Information Processing Systems*, 2019.

- Du, Y., Lin, T., and Mordatch, I. Model based planning with energy based models. In *Conference on Robot Learning*, 2019.
- Du, Y., Li, S., and Mordatch, I. Compositional visual generation with energy based models. In *Advances in Neural Information Processing Systems*, 2020b.
- Eysenbach, B., Khazatsky, A., Levine, S., and Salakhutdinov, R. Mismatched no more: Joint model-policy optimization for model-based rl. *arXiv preprint arXiv:2110.02758*, 2021.
- Farahmand, A.-M., Barreto, A., and Nikovski, D. Value-aware loss function for model-based reinforcement learning. In *International Conference on Artificial Intelligence and Statistics*, 2017.
- Fu, J., Kumar, A., Nachum, O., Tucker, G., and Levine, S. D4RL: Datasets for deep data-driven reinforcement learning. *arXiv preprint arXiv:2004.07219*, 2020.
- Fujimoto, S., Meger, D., and Precup, D. Off-policy deep reinforcement learning without exploration. In *International Conference on Machine Learning*, 2019.
- Garrett, C. R., Lozano-Pérez, T., and Kaelbling, L. P. Pddlstream: Integrating symbolic planners and blackbox samplers via optimistic adaptive planning. In *International Conference on Automated Planning and Scheduling*, 2020.
- Grathwohl, W., Wang, K.-C., Jacobsen, J.-H., Duvenaud, D., and Zemel, R. Learning the stein discrepancy for training and evaluating energy-based models without sampling. In *International Conference on Machine Learning*, 2020.
- Ha, D. and Schmidhuber, J. Recurrent world models facilitate policy evolution. In *Advances in Neural Information Processing Systems*, 2018.
- Hafner, D., Lillicrap, T., Fischer, I., Villegas, R., Ha, D., Lee, H., and Davidson, J. Learning latent dynamics for planning from pixels. In *International Conference on Machine Learning*, 2021a.
- Hafner, D., Lillicrap, T. P., Norouzi, M., and Ba, J. Mastering atari with discrete world models. In *International Conference on Learning Representations*, 2021b.
- Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., Wieser, E., Taylor, J., Berg, S., Smith, N. J., Kern, R., Picus, M., Hoyer, S., van Kerkwijk, M. H., Brett, M., Haldane, A., del Río, J. F., Wiebe, M., Peterson, P., Gérard-Marchant, P., Sheppard, K., Reddy, T., Weckesser, W., Abbasi, H., Gohlke, C., and Oliphant, T. E. Array programming with NumPy. *Nature*, 585(7825):357–362, 2020.
- Ho, J., Jain, A., and Abbeel, P. Denoising diffusion probabilistic models. In *Advances in Neural Information Processing Systems*, 2020.
- Hyvärinen, A. Estimation of non-normalized statistical models by score matching. *Journal of Machine Learning Research*, 2005.
- Janner, M., Mordatch, I., and Levine, S. γ -models: Generative temporal difference learning for infinite-horizon prediction. In *Advances in Neural Information Processing Systems*, 2020.
- Janner, M., Li, Q., and Levine, S. Offline reinforcement learning as one big sequence modeling problem. In *Advances in Neural Information Processing Systems*, 2021.
- Kaiser, L., Babaeizadeh, M., Miłos, P., Osiniski, B., Campbell, R. H., Czechowski, K., Erhan, D., Finn, C., Kozakowski, P., Levine, S., Mohiuddin, A., Sepassi, R., Tucker, G., and Michalewski, H. Model based reinforcement learning for atari. In *International Conference on Learning Representations*, 2020.
- Ke, N. R., Singh, A., Touati, A., Goyal, A., Bengio, Y., Parikh, D., and Batra, D. Modeling the long term future in model-based reinforcement learning. In *International Conference on Learning Representations*, 2018.
- Kelly, M. An introduction to trajectory optimization: How to do your own direct collocation. *SIAM Review*, 59(4): 849–904, 2017.
- Kidambi, R., Rajeswaran, A., Netrapalli, P., and Joachims, T. MOREL: Model-based offline reinforcement learning. In *Advances in Neural Information Processing Systems*, 2020.
- Kingma, D. P. and Ba, J. Adam: A method for stochastic optimization. In *International Conference on Learning Representations*, 2015.
- Kostrikov, I., Nair, A., and Levine, S. Offline reinforcement learning with implicit Q-learning. In *International Conference on Learning Representations*, 2022.
- Kumar, A., Zhou, A., Tucker, G., and Levine, S. Conservative Q-learning for offline reinforcement learning. In *Advances in Neural Information Processing Systems*, 2020.
- Lambert, N. O., Wilcox, A., Zhang, H., Pister, K. S., and Calandra, R. Learning accurate long-term dynamics for model-based reinforcement learning. *arXiv preprint arXiv:2012.09156*, 2020.

- LeCun, Y., Chopra, S., Hadsell, R., Huang, F. J., and et al. A tutorial on energy-based learning. In *Predicting Structured Data*. MIT Press, 2006.
- Levine, S. Reinforcement learning and control as probabilistic inference: Tutorial and review. *arXiv preprint arXiv:1805.00909*, 2018.
- Li, Y., Li, S., Sitzmann, V., Agrawal, P., and Torralba, A. 3d neural scene representations for visuomotor control. In *Conference on Robot Learning*, 2021.
- Misra, D. Mish: A self regularized non-monotonic neural activation function. In *British Machine Vision Conference*, 2019.
- Nagabandi, A., Kahn, G., S. Fearing, R., and Levine, S. Neural network dynamics for model-based deep reinforcement learning with model-free fine-tuning. In *International Conference on Robotics and Automation*, 2018.
- Nichol, A. Q. and Dhariwal, P. Improved denoising diffusion probabilistic models. In *International Conference on Machine Learning*, 2021.
- Nijkamp, E., Hill, M., Zhu, S.-C., and Wu, Y. N. Learning non-convergent non-persistent short-run MCMC toward energy-based model. In *Advances in Neural Information Processing Systems*, 2019.
- Oh, J., Singh, S., and Lee, H. Value prediction network. In *Advances in Neural Information Processing Systems*, 2017.
- Ozair, S., Li, Y., Razavi, A., Antonoglou, I., Van Den Oord, A., and Vinyals, O. Vector quantized models for planning. In *International Conference on Machine Learning*, 2021.
- Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., Gimelshein, N., Antiga, L., Desmaison, A., Kopf, A., Yang, E., DeVito, Z., Raison, M., Tejani, A., Chilamkurthy, S., Steiner, B., Fang, L., Bai, J., and Chintala, S. Pytorch: An imperative style, high-performance deep learning library. In *Advances in Neural Information Processing Systems*. 2019.
- Posa, M., Cantu, C., and Tedrake, R. A direct method for trajectory optimization of rigid bodies through contact. *The International Journal of Robotics Research*, 2014.
- Rhinehart, N., McAllister, R., and Levine, S. Deep imitative models for flexible inference, planning, and control. In *International Conference on Learning Representations*, 2020.
- Rybkin, O., Zhu, C., Nagabandi, A., Daniilidis, K., Mordatch, I., and Levine, S. Model-based reinforcement learning via latent-space collocation. In *International Conference on Machine Learning*, pp. 9190–9201. PMLR, 2021.
- Sanchez-Gonzalez, A., Heess, N., Springenberg, J. T., Merel, J., Riedmiller, M., Hadsell, R., and Battaglia, P. Graph networks as learnable physics engines for inference and control. In *International Conference on Machine Learning*, 2018.
- Schrittwieser, J., Antonoglou, I., Hubert, T., Simonyan, K., Sifre, L., Schmitt, S., Guez, A., Lockhart, E., Hassabis, D., Graepel, T., Lillicrap, T., and Silver, D. Mastering atari, go, chess and shogi by planning with a learned model. *arXiv preprint arXiv:1911.08265*, 2019.
- Sohl-Dickstein, J., Weiss, E., Maheswaranathan, N., and Ganguli, S. Deep unsupervised learning using nonequilibrium thermodynamics. In *International Conference on Machine Learning*, 2015.
- Song, J., Meng, C., and Ermon, S. Denoising diffusion implicit models. In *International Conference on Learning Representations*, 2021.
- Song, Y. and Ermon, S. Generative modeling by estimating gradients of the data distribution. In *Advances in Neural Information Processing Systems*, 2019.
- Sutton, R. S. Integrated architectures for learning, planning, and reacting based on approximating dynamic programming. In *International Conference on Machine Learning*, 1990.
- Talvitie, E. Model regularization for stable sample rollouts. In *Conference on Uncertainty in Artificial Intelligence*, 2014.
- Tamar, A., Wu, Y., Thomas, G., Levine, S., and Abbeel, P. Value iteration networks. In *Advances in Neural Information Processing Systems*. 2016.
- Tassa, Y., Erez, T., and Todorov, E. Synthesis and stabilization of complex behaviors through online trajectory optimization. In *International Conference on Intelligent Robots and Systems*, 2012.
- Wang, P. Implementation of denoising diffusion probabilistic models in pytorch, 2020. URL <https://github.com/lucidrains/denoising-diffusion-pytorch>.
- Wang, T., Bao, X., Clavera, I., Hoang, J., Wen, Y., Langlois, E., Zhang, S., Zhang, G., Abbeel, P., and Ba, J. Benchmarking model-based reinforcement learning. *arXiv preprint arXiv:1907.02057*, 2019.

- Williams, G., Aldrich, A., and Theodorou, E. Model predictive path integral control using covariance variable importance sampling. *arXiv preprint arXiv:1509.01149*, 2015.
- Witkin, A. and Kass, M. Spacetime constraints. *ACM Siggraph Computer Graphics*, 1988.
- Wu, Y. and He, K. Group normalization. In *European Conference on Computer Vision*, 2018.
- Yu, T., Thomas, G., Yu, L., Ermon, S., Zou, J., Levine, S., Finn, C., and Ma, T. MOPO: Model-based offline policy optimization. In *Advances in Neural Information Processing Systems*, 2020.
- Zhou, L., Du, Y., and Wu, J. 3D shape generation and completion through point-voxel diffusion. In *International Conference on Computer Vision*, 2021.

附录 A 基线细节与来源

在本节中，我们提供了自行运行的基线的详细信息。对于之前在标准化任务上评估过的基线分数，我们提供了所列分数的来源。

A.1 Maze2D 实验

单任务。CQL 和 IQL 在标准 Maze2D 环境上的性能已在 D4RL 白皮书 (Fu 等人, 2020) 的表 2 中报告。

我们使用作者提供的官方实现运行了 IQL:

github.com/ikostrikov/implicit-q-learning.

我们调整了两个超参数:

1. 温度 $\in [3, 10]$
2. 期望分位数 $\in [0.65, 0.95]$

多任务。我们仅在 Multi2D 环境中评估了 IQL，因为它在单任务 Maze2D 环境中以显著优势成为最强基线。为了使 IQL 适应多任务设置，我们将 Q 函数、价值函数和策略修改为以目标为条件。在训练期间选择目标时，我们采用了基于后见经验回放的策略，即从轨迹未来遇到的状态中采样一个目标。对于训练备份 (s_t, a_t, s_{t+1}) ，我们根据未来状态的几何分布采样目标。

$$\Delta \sim \text{Geom}(1 - \gamma) \quad g = s_{t+\Delta},$$

基于采样目标重新计算奖励，并在更新过程中将所有相关模型以目标为条件。在测试阶段，我们以真实目标为条件来约束策略。

我们调整了与单任务设置中相同的 IQL 参数。

A.2 积木堆叠实验

单任务。我们使用以下实现运行 CQL

<https://github.com/young-geng/cql>.

并采用代码中的默认超参数。我们使用作者原始实现运行 BCQ

<https://github.com/sfujim/BCQ>.

对于 BCQ，我们调整了两个超参数:

1. discount factor $\in [0.9, 0.999]$
2. tau $\in [0.001, 0.01]$




图 A1. Diffuser 采用 U-Net 架构，其残差块由时间卷积、组归一化和 Mish 非线性组成。

多任务。为了在多任务设置中评估 BCQ 和 CQL，我们将 Q 函数、价值函数和策略修改为以目标为条件。我们采用与 Multi2D 环境中相同的目标重标记方法进行训练。我们调整了与单任务积木堆叠实验中所述相同的超参数。

A.3 离线运动

BC、CQL、IQL 和 AWAC 的得分来自 Kostrikov 等人 (2022) 的表 1。DT 的得分来自

Chen 等人 (2021b) 的表 2。TT 的得分来自 Janner 等人 (2021) 的表 1。MOREL 的得分来自 Kidambi 等人 (2020) 的表 2。MBOP 的得分来自 Argenson 和 Dulac-Arnold (2021) 的表 1。

附录 B 测试时灵活性 为了引导扩散模型按指定配置堆叠积木，我们使用了两个独立的扰动函数 $h(\tau)$ 来指定积木 A 堆叠在积木 B 上的给定堆叠，具体如下所述。

最终状态匹配 为了强制最终状态由积木 A 堆叠在积木 B 上组成，我们训练了一个扰动函数 $h_{\text{match}}(\tau)$ 作为每个时间步的分类器，判断状态 s 是否表现出积木 A 堆叠在积木 B 上的堆叠。我们在演示数据上训练该分类器，与扩散模型相同。

接触约束 积木 A 堆叠在积木 B 上，我们构造一个扰动函数 $h_{\text{contact}}(\tau) = \sum_{i=1}^{64} -1 * \|\tau_{c_i} - 1\|^2$, where τ_{c_i}

对应于状态 τ_{s_i} 中指定库卡机械臂与方块 A 之间是否存在接触的底层维度。我们在轨迹的前 64 个时间步对库卡机械臂与方块 A 施加接触约束，对应于规划中与方块 A 的初始接触。

附录 C 实现细节

本节描述架构并记录超参数。

1. 扩散器 (Diffuser) 的架构 (图 A1) 由具有 6 个重复残差块的 U-Net 结构组成。每个块包含两个时间卷积, 每个卷积后接组归一化 (Group Norm) (Wu & He, 2018), 以及最终的 Mish 非线性 (Misra, 2019)。时间步嵌入由单个全连接层产生, 并加到每个块内第一个时间卷积的激活上。
2. 我们使用 Adam 优化器 (Kingma & Ba, 2015) 训练模型, 学习率为 $4e-05$, 批大小为 32。模型训练 50 万步。
3. 回报预测器 $\mathcal{J}$ 具有扩散模型所用 U-Net 前半部分的结构, 最后接一个线性层以产生标量输出。
4. 我们在所有运动任务中使用规划时域 T 为 32, 方块堆叠为 128, 迷宫 2D/多 2D U 型迷宫为 128, 迷宫 2D/多 2D 中型为 265, 迷宫 2D/多 2D 大型为 384。
5. 我们发现对于许多任务可以减小规划时域, 但需要降低引导尺度 (例如, 在半猎豹任务中时域为 4 时降至 0.001) 以适应。开源代码中的配置文件演示了如何以修改后的尺度和时域运行。
6. 本文在运动任务中使用 $N = 20$ 个扩散步骤, 在方块堆叠任务中使用 $N = 100$ 个。
7. 除跳跃者-中等-专家 (hopper-medium-expert) 任务外, 本文对所有任务使用 $\alpha = 0.1$ 的引导尺度, 在该任务中使用较小的 0.0001 尺度。
8. 本文对回报预测 $\mathcal{J}_\phi$ 使用 0.997 的折扣因子, 但发现当规划步数超过 $\gamma = 0.99$ 时, 对折扣因子的变化相当不敏感。
9. 本文发现, 选择用扩散模型预测噪声 ϵ 还是未损坏数据 τ^0 , 对控制性能没有显著影响。