

DREAM-Chunk: 基于潜在世界模型的反应式动作分块

Wenxi Chen¹ Kaidi Zhang^{1,†} * Chi Lin^{1,†} Zhiyuan Zhang¹ Yu She¹
Yuejiang Liu² Raymond A. Yeh¹ Shaoshuai Mou¹ Yan Gu¹
¹Purdue University ²Stanford University

摘要

动作分块已成为视觉-语言-动作（VLA）模型的常用接口，使低频策略推理能够驱动高频机器人执行。然而，一旦分块被提交，其开环执行在随机动力学、硬件执行误差和部分可观测状态下可能变得脆弱。我们提出 DREAM-Chunk，一种测试时扩展方法，通过轻量级潜在世界模型增强基于分块的策略，无需额外的策略微调。在测试时，DREAM-Chunk 采样多个候选动作分块，推演其预测的潜在未来，并从“梦境”状态与观测推演最匹配的分块中选择动作。通过这种方式，DREAM-Chunk 利用额外的测试时计算覆盖多种可能的随机推演，并在长时程分块执行期间提高反应性。在 Kinetix 基准上，DREAM-Chunk 在动作噪声增加的情况下提高了鲁棒性，并受益于更大的候选样本量，尤其是当演示包含纠正行为时。我们在两个机器人平台和两种 VLA 策略上对四个操作任务进行了多种随机性来源的实证验证。在仿真和硬件实验中，DREAM-Chunk 在随机动力学下改进了动作分块策略。项目页面：<https://wenxichen2746.github.io/DREAM-Chunk/>。

1 引言

视觉-语言-动作（VLA）模型旨在通过从大规模机器人演示数据中学习语言条件的视觉运动策略，将基础模型能力引入物理控制 [42, 9, 4]。与此同时，世界模型通过从轨迹数据中学习预测结构，为具身智能提供了一条互补路径，使模型能够推理在动作下未来状态如何演变。最近的 VLA 研究开始连接这两个方向，例如，通过引入视频预测或世界-动作建模目标来改进时空理解 [39, 6, 24]。Physical Intelligence 最近的 $\pi_{0.7}$ 系统 [28] 也反映了这一趋势，使用视频生成世界模型为 VLA 推理提供上下文。这些发展表明了一条模块化路径




图 1: 分块切换以处理外部扰动和随机动力学的示意图。

* Kaidi Zhang 和 Chi Lin 对实验工作做出了同等贡献。

为了实现可实际部署的具身智能 [14]，整合了机器人研究互补领域的进展，包括视觉-语言-动作模型与世界模型研究 [12]。

在从演示中学习的方法中，一种广泛使用的技术是动作分块 [41]，即策略预测未来动作的短序列而非单步动作。通过对时间上连贯的动作片段进行建模，动作分块在模仿学习和生成式视觉运动策略学习中已被证明有效 [7, 26]。近期视觉-语言-动作模型越来越多地采用这种分块动作接口，部分原因在于它允许低频策略推理驱动高频机器人执行。代表性视觉-语言-动作模型要么使用生成式“动作专家”直接采样动作块，如 $\pi_{0.5}$ [4, 29]、Octo [25] 和 SmolVLA [32]，要么预测动作标记并将其解码为短动作块，如 RT-2 [42]、OpenVLA [15] 和 FAST [27, 29, 28]。

这种分块接口使大型视觉-语言-动作模型在实时部署中更具实用性。该接口已被证明有助于通过异步执行处理推理延迟 [32, 34]，同时在从多样化演示中学习时保持模式一致性 [7, 41]。然而，这些优势伴随着一个重要局限：一旦动作块被提交，机器人便在很大程度上开环执行，导致执行过程中误差累积 [17]。Liu 等人 [20] 分析指出，当策略的隐式内部模型能正确预测未观测的未来状态时，长时程执行可提供信息优势，但在随机动态下这种优势可能被大幅削弱。

近期为提升视觉-语言-动作模型反应能力所做的努力包括：在条件于未来状态的同时反复重新规划新动作块 [34]、训练轻量级视觉-语言-动作模型以加快推理 [37]、自适应调整执行时程 [33, 19]，以及训练残差模块以修正生成的动作块 [38, 31]。然而，现有方法仍面临重要局限。频繁重新规划可能计算开销大，且可能浪费策略已预测的长时程计划；而通过轻量级架构修改提升反应能力则可能限制向更大模型和更广泛训练任务扩展的潜力。

受视觉-语言-动作策略与世界模型之间新兴联系的启发，本文探讨轻量级预测能否在不修改基础策略的情况下，提升测试时长时间跨度动作块执行的性能。本文提出梦境状态反应式动作匹配动作分块方法（DREAM-Chunk），该方法保持基础策略固定，采样多个候选动作块，并利用轻量级世界模型预测其潜在未来状态。在执行过程中，DREAM-Chunk 将观测状态与相位对齐的预测轨迹进行匹配，并从最一致的候选动作块中选择动作，从而在随机动态使机器人偏离标称轨迹时实现反应式切换。图 1 展示了这一过程：黄色虚线表示候选轨迹，绿色箭头表示随机效应，如外部扰动或物体速度变化。为清晰起见，动作块时间跨度和模式差异被夸大。

本文的主要贡献有三方面：（一）本文提出 DREAM-Chunk，一种策略无关的测试时扩展框架，在不修改或微调基础视觉-语言-动作策略的情况下，提升动作分块策略在随机动态下的反应能力。

（二）在受控的 Kinetix 仿真中 [22]，DREAM-Chunk 在高随机性条件下优于代表性的测试时分块基线，本文的分析研究了来自 R2-Dreamer[23]、LeWorldModel[21] 和 EB-JEPA[35] 的纠正性专家演示和潜在表征的影响。（三）本文在 SO-101 和 Franka Panda 上使用 SmolVLA 和 $\pi_{0.5}$ ，在四个真实世界操作任务中验证了 DREAM-Chunk，涵盖硬件执行误差、部分可观测性和外部扰动；在这些设置中，DREAM-Chunk 提高了成功率，包括在外部扰动下的精确插入任务中，将开环 $\pi_{0.5}$ 从 10% 提高到 65%。

2 相关工作

动作分块的测试时扩展。我们广泛使用测试时扩展这一术语，指在推理阶段分配额外计算或修改采样过程以改进动作分块策略的方法。双向解码（Bidirectional Decoding, BID）[20] 采样多个候选块，并选择与先前轨迹一致且避免与较差策略相似动作的块。实时动作分块（Real-Time Action Chunking, RTC）[5] 通过修复引导新动作块的采样，使新块与先前执行的块对齐，这需要在测试时进行反向传播。自引导（Self-Guidance）[33] 在动作采样期间应用无分类器风格的引导，利用当前和先前观测的两次前向传播将动作推开




图 2: 朴素的开环动作块执行在下一个推理步骤之前无法纠正动作。DREAM-Chunk 从 VLA 采样批量动作块, 并利用世界模型预测在它们之间切换。潜在世界模型比 VLA 轻量得多, 它从当前观测预测未来轨迹: 每个新观测由编码器编码, 并与潜在动力学模型的预测进行比较。执行的动作 (由红色虚线箭头指示) 从梦想状态最匹配真实世界轨迹的块中选择。这使得采样块能够提供替代轨迹, 在随机性下保持动作有效。

来自先前观测诱导的分布。他们还提出自适应分块以平衡反应性和一致性, 该方法反复推断新块, 并在新动作与当前块差异足够大时切换执行。近期方法利用批量块样本间的不确定性来调整执行: Liang 等人 [19] 根据动作熵调整执行范围, 而 HiPolicy [40] 在多个频率上采样由粗到细的块, 并使用熵确定执行频率。除了块特定机制外, RoboMonkey [16] 使用测试时动作采样和微调的 VLM 验证器在候选动作中进行选择。相比之下, DREAM-Chunk 将块执行本身视为测试时决策问题: 它一次性采样多个块, 并在执行过程中利用新观测在它们的相位对齐动作之间进行选择。

世界模型 已成为通往通用智能的另一条主要路径, 涵盖从视频生成 [1] 到基于模型的强化学习 [10] 的多种工作。其中一类工作旨在学习基础规模模型, 预测未来观测与动作, 视觉重建为时空理解提供辅助训练信号, 并支持从大规模视频数据扩展 [39, 6, 24]。另一类工作则学习潜在动力学模型, 无需视觉解码器, 利用学到的潜在转移结构进行策略学习 [10, 23] 或在线动作规划 [21, 35]。已有工作尝试利用潜在世界模型提升视觉-语言-动作 (VLA) 模型的性能。例如, FOREWARN [36] 使用潜在世界模型预测候选动作结果, 并让潜在对齐的视觉-语言模型 (VLM) 根据高层用户意图和语义约束选择最佳动作计划。

3 预备知识

我们简要回顾必要背景, 以建立统一符号。

动作分块策略。 我们考虑一个动作分块策略, 其参数化为生成模型 $\pi(A_t | o_t)$, 以观测 o_t 作为输入, 其中每个动作块 $A_t = \{a_t, a_{t+1}, \dots, a_{t+L-1}\}$ 是长度为 L 的动作序列。该策略通过离线专家演示数据集 $\{(o_t, a_t)\}$ 训练, 最小化生成动作块与从演示轨迹切分的动作片段之间的差异。测试时, 策略通常只执行每个预测块的一部分, 然后重新规划。我们将实际执行的动作数记为执行时域 H 。

反应式长时域控制。 由于整个块由推理时可用观测生成, 后续动作基于越来越过时的状态信息执行。为

形式化这一不匹配，令 $A_t = \{a_t, \dots, a_{t+H-1}\} \sim \pi(\cdot | o_t)$ 表示在时间 t 采样的动作块，令 $A_t[\tau]$ 为其第 τ 个动作。理想情况下，在阶段 τ 执行的动作应与同一策略在基于已实现观测 $o_{t+\tau}$ 重新推断时做出的决策保持一致。对于已执行动作 $a_{t+\tau}$ ，我们将这种一致性定义为

$$\text{Align}(a_{t+\tau}, o_{t+\tau}) = \mathbb{E}_{\hat{A}_{t+\tau} \sim \pi(\cdot | o_{t+\tau})} \left[\exp \left(- \left\| a_{t+\tau} - \hat{A}_{t+\tau}[0] \right\|_2^2 \right) \right], \quad (1)$$

其中 $\hat{A}_{t+\tau}[0]$ 是从当前观测 $o_{t+\tau}$ 推断出的一个块中的第一个动作。

目标。 本文使用期望对齐作为块执行策略的反应性测度 η ，该策略在展开过程中从可用动作块中选择执行动作 $a_{t+\tau}^\eta$ 。此处， $P_\eta(o_{t+1:t+H} | o_t)$ 表示由随机动力学 $o_{t+\tau+1} \sim P(\cdot | o_{t+\tau}, a_{t+\tau}^\eta)$ 诱导的展开分布。本文定义反应性目标为

$$J_{\text{react}}(\eta) = \mathbb{E}_{o_{t+1:t+H} \sim P_\eta(\cdot | o_t)} \left[\sum_{\tau=0}^{H-1} \text{Align}(a_{t+\tau}^\eta, o_{t+\tau}) \right]. \quad (2)$$

更具反应性的执行策略通过保持执行动作与策略在已实现观测下所选择的动作对齐，从而获得更大的 $J_{\text{react}}(\eta)$ 。随机动力学可能使展开偏离原始块的名义轨迹，导致后续开环动作与当前策略决策失配。本文将这种每步偏离的概率记为 p_{dyn} 。直接评估 $J_{\text{react}}(\eta)$ 需要在每个已实现观测处反复重新推断 VLA；DREAM-Chunk 则使用潜在匹配作为轻量级替代，选择其梦想潜在状态与已实现展开最匹配的候选块。

4 方法

DREAM-Chunk 通过辅助世界模型增强基于分块的 VLA 策略，并在从固定策略 π 采样的候选块上定义执行策略。如图 2 所示，该方法维护一组候选动作块，利用世界模型展开其潜在后果，并根据潜在状态兼容性反应式地选择要遵循的块。

辅助世界模型。 DREAM-Chunk 使用由编码器和潜在动力学模型组成的辅助世界模型。编码器将高维观测（如图像和机器人关节测量）映射到潜在状态空间， $s_t = e(o_t)$ 。潜在动力学模型随后根据当前潜在状态和动作预测下一个潜在状态， $\tilde{s}_{t+1} = f(s_t, a_t)$ 。由于世界模型在与动作分块策略相同的离线专家演示上训练，本文期望其捕获的潜在转移结构与策略的隐式内部模型 [20] 大致对齐。

直觉。 DREAM-Chunk 从当前观测中采样多个合理的短时域计划，并利用辅助世界模型预测其潜在展开。在执行过程中，它选择预测潜在状态与观测状态最匹配的块，从而使机器人能够切换离开在随机动态下已变得不一致的展开。因此，DREAM-Chunk 在测试时并不发明新的恢复行为；相反，它暴露并选择策略采样动作分布中已存在的纠正行为。我们进一步在附录 A1.3 中分析 DREAM-Chunk 何时能优于高频短时域控制。

4.1 批量动作块推理与并行潜在展开

在每个重规划步骤 t ，DREAM-Chunk 从块策略中采样 N 个候选动作块，

$$\mathcal{A} = \{A^{(j)}\}_{j=1}^N \leftarrow \pi(o_t), \quad A^{(j)} = a_{t:t+H-1}^{(j)}. \quad (3)$$

当前观测 o_t 被编码为 $s_t = e(o_t)$ ，该潜在状态沿候选维度复制以初始化批量潜在张量，

$$\tilde{S}_t = \text{Repeat}(s_t, N), \quad \tilde{S}_t \in \mathbb{R}^{N \times d_z}. \quad (4)$$

从 $\tilde{S}_t$ 开始，DREAM-Chunk 并行展开所有候选块的潜在后果。在每个阶段 $\tau = 0, \dots, H-1$ ，批量潜在在动态模型更新

$$\tilde{S}_{t+\tau+1} = f\left(\tilde{S}_{t+\tau}, \{A_\tau^{(j)}\}_{j=1}^N\right), \quad (5)$$

Algorithm 1 DREAM-Chunk Execution under Asynchronous Inference

Require: chunking policy π , encoder e , latent dynamics model f

Require: execution horizon H , overlap step d , number of candidate chunks N

```
1:  $\mathcal{A} = \{A^{(j)}\}_{j=1}^N \leftarrow \pi(o_t)$ 
2:  $s_t \leftarrow e(o_t)$ 
3:  $\tilde{S}_t \leftarrow \text{Repeat}(s_t, N)$   $\triangleright \tilde{S}_t \in \mathbb{R}^{N \times d_z}$  for batched rollout
4: while not terminated do
5:   for  $\tau = 0, \dots, H - 1$  do
6:      $s_{t+\tau} \leftarrow e(o_{t+\tau})$ 
7:      $i \leftarrow \arg \min_{j \in \{1, \dots, N\}} \|s_{t+\tau} - \tilde{S}_{t+\tau}[j]\|_2$ 
8:      $a_{t+\tau} \leftarrow A_\tau^{(i)}$ ; execute  $a_{t+\tau}$ 
9:     if  $\tau = H - 1 - d$  then
10:       $S \leftarrow \{s_{t+\tau}\}_{j=1}^N$ ;  $\mathcal{A}^{\text{next}} \leftarrow \pi(o_{t+\tau})$  asynchronously
11:    end if
12:     $\tilde{S}_{t+\tau+1} \leftarrow f(\tilde{S}_{t+\tau}, \{A_\tau^{(j)}\}_{j=1}^N)$ 
13:  end for
14:   $\mathcal{A} \leftarrow \mathcal{A}^{\text{next}}$ ;  $\tilde{S} \leftarrow S$ ;  $i \leftarrow 1$ 
15: end while
```

其中 $\tilde{S}_{t+\tau}[j]$ 表示候选块 j 在执行阶段 τ 的梦想潜在状态， $A_\tau^{(i)}$ 是候选块 $A^{(j)}$ 中的第 τ 个动作。这为每个候选块产生相位对齐的潜在展开。重要的是，梦想状态在展开过程中不会使用未来观测进行重置；它们代表每个采样动作块所诱导的预期潜在演化。

该过程充当一种测试时扩展形式：利用额外的推理时间计算来采样更多候选块并预测更多可能的潜在未来。DREAM-Chunk 不是承诺单一的开环块，而是维护一组批量想象的展开，可以在新观测到达时在线查询。

4.2 基于反应式潜在匹配的执行

在执行过程中，机器人在每个阶段 $\tau \in \{0, \dots, H - 1\}$ 接收到新的观测 $o_{t+\tau}$ ，并将其编码为 $s_{t+\tau} = e(o_{t+\tau})$ 。DREAM-Chunk 将该观测到的潜在状态与批量推演中相位对齐的梦想状态进行比较，并选择预测最匹配实际状态的候选块：

$$i^* = \arg \min_{j \in \{1, \dots, N\}} \|s_{t+\tau} - \tilde{S}_{t+\tau}[j]\|_2. \quad (6)$$

然后，机器人从所选块中执行相位对齐的动作 $A_\tau^{(i^*)}$ 。

该规则允许 DREAM-Chunk 在观测轨迹偏离当前所遵循块的预测推演时，在候选块之间进行切换。由于与观测潜在状态的匹配仅针对同一执行阶段的梦想状态进行，因此切换在时间上与动作序列保持对齐，而不会跳转到另一推演的更早或更晚阶段。DREAM-Chunk 还可以结合异步推理，通过在策略推理时存储真实潜在状态来实现，如算法 1 所述。

4.3 辅助世界模型公式化

潜在状态表示可以是确定性的，遵循 JEPA [18, 21] 的工作路线；也可以是随机的（ $s = (h, z)$ ，其中 h 是确定性的， z 是随机的），如 Dreamer 系列 [11, 23] 所采用的循环状态空间模型（RSSM）中所公式化的那样。我们的实验将表明，DREAM-Chunk 方法可以适应这两种公式化，如图 5 中的消融实验所示。此外，我们想强调，这种潜在动力学模型比 VLA 模型轻得多，不会引入显著的计算开销。例如，一个 JEPA 世界模型可以只有 1500 万个参数，而像 SmolVLA 这样的小规模 VLA 大约有




图 3: Kinetix 仿真在性能和潜在相似度上的结果。报告值为 12 个环境的平均值。

4.5 亿个参数，而像 $\pi_{0.5}$ 这样更大的模型可以有超过 20 亿个参数。在我们的硬件实验中，VLA 推理耗时超过 100 毫秒，而世界模型编码和预测耗时不到 10 毫秒，如表 A2 所列。

5 实验

我们在受控仿真和真实硬件环境中评估 DREAM-Chunk。在第 5.1 节中，我们使用 Kinetix 基准来研究 DREAM-Chunk 在受控动作噪声下的行为，包括样本数量的影响、演示中的纠正行为以及潜在世界模型设计。在第 5.2 节中，我们将 DREAM-Chunk 部署到真实机器人操作任务上，以测试相同机制是否能在硬件执行不完美、部分可观测性和外部扰动等现实随机性下提高鲁棒性。

5.1 Kinetix 仿真

我们的仿真实验旨在回答三个问题：（1）增加采样块的数量是否能在随机动态下提高 DREAM-Chunk 的性能？（2）DREAM-Chunk 测试时扩展有效的必要条件是什么？

（3）辅助世界模型学习到的潜在表示如何影响性能？

Kinetix [22] 是一个二维智能体仿真基准，涵盖运动、操作和类 Atari 控制任务。遵循 RTC 评估设置 [5]，我们通过模仿学习从不同随机种子收集的强化学习专家演示中训练一个流匹配动作分块策略。我们通过向执行动作添加高斯噪声来引入环境随机性， $a_{\text{exec}} = a + \epsilon$ ，其中 $\epsilon \sim \mathcal{N}(0, \sigma^2 I)$ 和 σ 控制噪声水平。




图 4: 该图报告了 DreamChunk 在动作噪声 0.3 下不同样本大小 N 的解决率，其中行为克隆策略是在由不同动作噪声水平训练的专家演示上训练的。

实现细节。我们将 DREAM-Chunk 与朴素异步执行 [32, 34]、RTC [5]、BID [20] 和自适应分块 (AC) [33] 进行比较。对于 BID 和 RTC，我们遵循 [5] 中提供的设置。BID 使用 10 个采样的动作块，并使用早期检查点作为弱策略。我们仅展示原始论文所推崇的具有软掩码的 RTC 变体的性能。我们按照 [33] 实现 AC，使用余弦相似度作为切换度量，阈值为 0.97。除非另有说明，所报告的 DREAM-Chunk 性能使用基于 RSSM 的世界模型，该模型采用一步预测损失和 Barlow Twins 正则化进行训练 [23]。

随机性下的性能。如图 3a 所示，随着采样块数量的增加，DREAM-Chunk 获得了更大的改进。这一比较突显了提高块内反应性的好处。相比之下，BID 和 RTC 主要针对跨块一致性，通过改进独立推断块之间的过渡。在低随机性下，两个方向相对于朴素异步执行提供了相似的增益。然而，随着动作噪声方差的增加，DREAM-Chunk 实现了更大的优势，这表明当实际轨迹偏离标称开展开时，块内反应性变得更加重要。

AC 也旨在通过自适应改变执行范围来提高反应性，但其在动态任务上的性能通常接近朴素的一步重规划基线，这表明它倾向于频繁重规划，而不是保持更长的块执行。我们在附录图 A1 中提供了跨执行范围的额外结果，其中 DREAM-Chunk 在中长期执行下表现出特别的优势。

为了测试更多候选块是否提供更接近随机执行下实际达到状态的预测未来，我们测量了执行期间达到的编码潜在状态与候选块预测的梦想潜在状态之间的平均最近邻距离。如图 3b 所示，增加采样块的数量会减小这一距离，表明对实际展开的覆盖更好。更高的环境随机性导致更大的距离，反映了在更强执行噪声下预测未来状态的难度增加。

演示中的纠正行为。接下来，我们研究 DREAM-Chunk 在何种情况下最为有效。由于 DREAM-Chunk 是在策略已采样的动作块中进行选择，其收益取决于策略分布是否包含有用的纠正行为，以及辅助世界模型是否提供了一个潜空间，能够可靠地区分这些候选块的后果。也就是说，DREAM-Chunk 要求动作分块策略在随机动力学下生成有用的恢复选项。Kinetix 环境允许我们通过收集演示之前以不同水平的动作噪声训练强化学习专家来控制这一因素。如图 4 所示，当模仿策略是在来自暴露于更高动作噪声的专家的演示上训练时，DREAM-Chunk 在相同采样块数量下扩展更有效。相比之下，当策略仅在来自低动作噪声训练的专家的演示上训练时，例如， $\sigma = 0.1$ ，增加采样数量带来的增益较小。这表明，当演示数据已经包含学习策略在推理时可以采样的纠正行为时，测试时扩展最为有用。

潜表示至关重要。

DREAM-Chunk。我们评估了几种无解码器的潜动力学模型，包括从 R2-Dreamer [23] 改编的 RSSM 变体、LeWorldModel (LEWM) [21] 以及基于能量的 JEPA (EB-JEPA) [35]。对于 R2-Dreamer，我们移除了奖励和延续预测器，仅使用 Barlow Twins、动力学和表示损失进行训练。对于 LEWM 和 EB-JEPA，我们使用带潜正则化的单步预测：LEWM 使用 SigReg，EB-JEPA 使用 VICReg [3]。我们还测试了一种变体，该变体冻结动作分块策略编码器，仅训练单步潜动力学预测器。作为参考，我们纳入了朴素开环执行和随机切换基线，后者采样批量块但在执行过程中随机切换。

We now study how the choice of auxiliary world model affects




图 5: 不同世界模型架构的消融。所有方法均在动作噪声 $\sigma = 0.2$, $N = 20$ 下针对 DREAM-Chunk 进行评估。

图 5 表明，潜在表征对 DREAM-Chunk 的性能影响显著。EB-JEPA 在较长执行时域下性能下降，这可能是由于累积的展开误差使得潜在匹配不可靠。其性能仍高于随机切换，说明其预测保留了部分有用结构，但不足以支持可靠的长时间域匹配。相比之下，冻结策略编码器变体退化至随机切换水平，表明这些特征在经过单层多层感知机投影后，无法提供足够的预测信息来识别策略预期的未来状态。LEWM 表现具有竞争力，甚至能超越 RSSM 变体，说明 DREAM-Chunk 并不需要显式随机的世界模型。其核心需求是一个潜在表征和动力学模型，能够在候选块之间实现可靠的相位对齐匹配。

5.2 硬件部署

我们在真实机器人硬件上评估 DREAM-Chunk，以研究其在物理操作中随机动态下是否能改进动作分块策略。我们重点关注硬件部署中常见的三类不确定性来源：(i) 由于硬件限制导致的执行噪声（我们




图 6: 我们在 SO-101 机械臂和 Franka Emika Panda 机器人上设计了四个硬件实验。随机性主要来源于 SO-101 上不精确的硬件执行。在移动物体抓取任务中, 额外的不确定性来自滚动物体速度的不确定性。在最后的拾取与插入罐体测试中, 我们在插入前手动扰动目标盒。该图展示了由动态随机性引起的典型失败模式。

在附录 A1.2 中进一步讨论伺服精度, (ii) 任务状态的部分可观测性, 以及 (iii) 执行过程中改变环境的外部扰动。我们在 SO-101 和 Franka 机械臂上设计了四个操作任务, 代表性失败模式如图 6 所示。(1) 拔插 USB (SO-101): 机器人从右侧端口拔出 USB 连接器, 并将其插入左侧端口。有限的电机精度可能导致连接器卡住或错过目标端口。(2) 接住并放置移动物体 (SO-101): 机器人接住一个滚动的物体并将其放入篮子中。变化的物体速度和单帧观测使得动力学部分可观测, 导致接球失败或放置不准确。(3) 拾取并插入物体 (SO-101): 机器人拾取一个玩具积木并将其插入正确位置。末端执行器振荡可能导致抓取失败或放置不准确。(4) 在扰动下插入罐子 (Franka): 机器人拾取一个罐子并将其插入目标槽中, 同时容器受到人为扰动。未能及时反应可能导致插入失败, 而不精确的抓取可能导致罐子掉落。

实现细节。我们通过遥操作收集每个任务约 50 到 100 个专家演示片段。一个关键观察与我们的仿真结果一致: 当演示包含可在轨迹偏离时作为恢复选项采样的纠正行为时, DREAM-Chunk 最为有效。我们对 SO-101 实验微调 SmolVLA [32], 对 Franka 实验微调 $\pi_{0.5}$ [4]。所有硬件实验均使用 R2-Dreamer 潜在世界模型公式, 在与策略训练相同的离线演示数据集上进行训练。在评估期间, 我们将 SO-101 的控制频率设置为 30 Hz, Franka 设置为 10 Hz, 与演示收集期间使用的帧率一致。对于四个任务, 我们分别使用 30、20、30 和 10 步的执行视野。选择这些视野是为了足够长以避免演示中频繁的空闲转换, 同时足够短以支持动态任务中的及时推理。

计算硬件。我们报告了两种硬件设置下测试时扩展的开销。SO-101/SmolVLA 的延迟是在配备 NVIDIA RTX 5090 GPU 和 Intel Core Ultra 9 CPU 的工作站上测量的。Franka/ $\pi_{0.5}$ 的延迟是在分布式设置中测量的, 机器人控制

在配备英特尔 i7-11700KF 中央处理器和 RTX 3080 图形处理器的本地个人计算机上进行推理，并在配备 AMD Threadripper PRO 5995WX 中央处理器和 RTX A6000 图形处理器的远程工作站上通过 WebSocket 通信进行推理。所有报告数值均为一次测试会话的平均值。

硬件结果。表 1 报告了在 SO-101 平台上使用 SmolVLA 执行硬件任务的成功率，其中 DREAM-Chunk 使用 $N = 10$ 个候选块。DREAM-Chunk 在所有任务上均提升了性能，表明反应式块选择有助于缓解硬件不精确性、部分观测到的物体运动以及外部扰动带来的不确定性。

表 2 进一步报告了在 Franka 机械臂上 $\pi_{0.5}$ 的性能和延迟。在本地推理下，使用 $N = 5$ 的 DREAM-Chunk 相比开环执行显著提高了成功率，尽管该设置采用顺序推理而非并行批量采样，因此在执行过程中会出现可见的停顿，如补充视频所示。

表 1: 使用 SmolVLA 在三个 SO-101 测试上进行 20 次推出的成功率。

Task	Open-loop	Ours
USB unplug/insert	75%	95%
Pick moving object	60%	80%
Pick and insert toy	35%	45%

接下来，我们还评估了远程推理，以支持更大候选池的并行采样。尽管增加了通信延迟（1 秒），远程 DREAM-Chunk 仍然优于本地开环基线。然而，进一步增加 N 并未提升性能，可能是因为增加的推理延迟抵消了块内反应性的优势。我们在补充材料中提供了实验视频，并在表 A1 中总结了观察到的失败模式。

表 2: 在 Franka 机械臂上使用 $\pi_{0.5}$ 执行罐插入任务的性能和推理延迟。

Method	N	Inference Time	Performance
Naive open loop (local)	1	194.68 ms	10%
DREAM-Chunk (local)	5	634.77 ms	65%
DREAM-Chunk (remote)	10	697.93 ms	40%
DREAM-Chunk (remote)	15	1001.27 ms	30%
DREAM-Chunk (remote)	20	1303.82 ms	35%

表 3: DREAM-Chunk 世界模型组件的延迟分解。

N	Encoder	Predictor	Latent Matching
5	1.41 ms	1.83 ms	0.16 ms
10	1.40 ms	2.74 ms	0.17 ms
20	1.56 ms	3.09 ms	0.18 ms

推理延迟。表 2 还报告了 $\pi_{0.5}$ 在不同样本量和硬件设置下的推理延迟。随着采样块数量的增加，策略推理变慢，但测得的延迟并未随 N 线性增长。相比之下，表 3 显示与世界模型相关的计算保持在毫秒级：将批量潜在展开从 $N = 5$ 增加到 $N = 20$ 仅增加约 1.2 毫秒的延迟。我们还在表 A2 中报告了 SmolVLA 的推理延迟。

纠正行为的性质。尽管我们最初预期 DREAM-Chunk 会产生更明显的块内反应性，例如切换到显著不同的行为模式以捕捉错过的移动物体（如图 1 所示），但观察到的纠正大多是当前动作模式周围的局部变化。这与 Pan 等人 [26] 的分析一致，该分析表明生成式策略的优势往往不在于分布学习，而在于围绕可能动作的迭代细化。在我们的硬件实验中，采样的动作块很少表现出明显的高层模式。相反，它们主要在不完美的标称行为周围提供小的纠正变化。因此，在 DREAM-Chunk 中增加样本数量主要通过暴露更多这些局部纠正选项来帮助，而不是发现性质不同的策略。

6 结论

我们提出了 DREAM-Chunk，一种在随机动力学下提高动作分块策略反应性的测试时缩放方法。DREAM-Chunk 采样多个候选块，利用轻量级世界模型展开其潜在后果，并在每一步通过潜在匹配选择动作，实现在线纠正。在 Kinetix 中，我们方法的收益随随机性和样本数量的增加而增加，并依赖于演示数据中的纠正行为和可靠的潜在动力学。在实际硬件上，DREAM-Chunk 在四个涉及执行噪声、部分可观测性和外部扰动的操作任务中提高了性能。这些结果表明，轻量级预测模型可以作为实用的反应模块，用于鲁棒的长时程 VLA 控制。

参考文献

- [1] Eloi Alonso, Adam Jelley, Vincent Micheli, Anssi Kanervisto, Amos Storkey, Tim Pearce, and François Fleuret. Diffusion for world modeling: Visual details matter in atari. In *Proc. NeurIPS*, 2024. 3
- [2] Juan Alvarez-Padilla, John Z Zhang, Sofia Kwok, John M Dolan, and Zachary Manchester. Real-time whole-body control of legged robots with model-predictive path integral control. In *Proc. ICRA*, 2025. 16
- [3] Adrien Bardes, Jean Ponce, and Yann LeCun. VICReg: Variance-invariance-covariance regularization for self-supervised learning. In *Proc. ICLR*, 2022. 7
- [4] Kevin Black, Noah Brown, James Darpinian, Karan Dhabalia, Danny Driess, Adnan Esmail, Michael Robert Equi, Chelsea Finn, Niccolo Fusai, Manuel Y. Galliker, Dibya Ghosh, Lachy Groom, Karol Hausman, Brian Ichter, Szymon Jakubczak, Tim Jones, Liyiming Ke, Devin LeBlanc, Sergey Levine, Adrian Li-Bell, Mohith Mothukuri, Suraj Nair, Karl Pertsch, Allen Z. Ren, Lucy Xiaoyang Shi, Laura Smith, Jost Tobias Springenberg, Kyle Stachowicz, James Tanner, Quan Vuong, Homer Walke, Anna Walling, Haohuan Wang, Lili Yu, and Ury Zhilinsky. $\pi_{0.5}$: A vision-language-action model with open-world generalization. In *Proc. CoRL*, 2025. 1, 2, 8
- [5] Kevin Black, Manuel Y. Galliker, and Sergey Levine. Real-time execution of action chunking flow policies. In *Proc. NeurIPS*, 2026. 2, 6
- [6] Jun Cen, Chaohui Yu, Hangjie Yuan, Yuming Jiang, Siteng Huang, Jiayan Guo, Xin Li, Yibing Song, Hao Luo, Fan Wang, et al. WorldVLA: Towards autoregressive action world model. *arXiv preprint arXiv:2506.21539*, 2025. 1, 3
- [7] Cheng Chi, Zhenjia Xu, Siyuan Feng, Eric Cousineau, Yilun Du, Benjamin Burchfiel, Russ Tedrake, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. *IJRR*, 2025. 2
- [8] Franka Emika GmbH. Panda Technical Data. <https://www.generationrobots.com/media/panda-franka-emika-datasheet.pdf>, 2018. Datasheet, accessed 2026-05-04. 14
- [9] Gemini Robotics Team, Saminda Abeyruwan, Joshua Ainslie, Jean-Baptiste Alayrac, Montserrat Gonzalez Arenas, Travis Armstrong, Ashwin Balakrishna, Robert Baruch, Maria Bauza, Michiel Blokzijl, et al. Gemini robotics: Bringing AI into the physical world. *arXiv preprint arXiv:2503.20020*, 2025. 1
- [10] Danijar Hafner, Timothy Lillicrap, Jimmy Ba, and Mohammad Norouzi. Dream to control: Learning behaviors by latent imagination. *arXiv preprint arXiv:1912.01603*, 2019. 3
- [11] Danijar Hafner, Jurgis Pasukonis, Jimmy Ba, and Timothy Lillicrap. Mastering diverse domains through world models. *arXiv preprint arXiv:2301.04104*, 2023. 5
- [12] Bohan Hou, Gen Li, Jindou Jia, Tuo An, Xinying Guo, Sicong Leng, Haoran Geng, Yanjie Ze, Tatsuya Harada, Philip Torr, et al. World model for robot learning: A comprehensive survey. *arXiv preprint arXiv:2605.00080*, 2026. 2
- [13] Hugging Face LeRobot. SO-101. <https://huggingface.co/docs/lerobot/so101>, 2026. LeRobot documentation, accessed 2026-05-04. 14
- [14] Joonkyung Kim, Wenxi Chen, Davood Soleymanzadeh, Yi Ding, Xiangbo Gao, Zhengzhong Tu, Ruqi Zhang, Fan Fei, Sushant Veer, Yiwei Lyu, et al. Modular safety guardrails are necessary for foundation-model-enabled robots in the real world. *arXiv preprint arXiv:2602.04056*, 2026. 2
- [15] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan Foster, Grace Lam, Pannag Sanketi, et al. OpenVLA: An open-source vision-language-action model. *arXiv preprint arXiv:2406.09246*, 2024. 2

- [16] Jacky Kwok, Christopher Agia, Rohan Sinha, Matt Foutter, Shulu Li, Ion Stoica, Azalia Mirhoseini, and Marco Pavone. Robomony: Scaling test-time sampling and verification for vision-language-action models. *arXiv preprint arXiv:2506.17811*, 2025. 3
- [17] Michael Laskey, Jonathan Lee, Roy Fox, Anca Dragan, and Ken Goldberg. Dart: Noise injection for robust imitation learning. In *Proc. CoRL*, 2017. 2
- [18] Yann LeCun et al. A path towards autonomous machine intelligence version 0.9.2, 2022-06-27. *OpenReview*, 2022. 5
- [19] Yuanchang Liang, Xiaobo Wang, Kai Wang, Shuo Wang, Xiaojiang Peng, Haoyu Chen, David Kim Huat Chua, and Prahlad Vadakkepat. Adaptive action chunking at inference-time for vision-language-action models. *arXiv preprint arXiv:2604.04161*, 2026. 2, 3, 16
- [20] Yuejiang Liu, Jubayer Ibn Hamid, Annie Xie, Yoonho Lee, Max Du, and Chelsea Finn. Bidirectional decoding: Improving action chunking via guided test-time sampling. In *Proc. ICLR*, 2025. 2, 4, 6, 16
- [21] Lucas Maes, Quentin Le Lidec, Damien Scieur, Yann LeCun, and Randall Balestriero. LeWorld-Model: Stable end-to-end joint-embedding predictive architecture from pixels. *arXiv preprint arXiv:2603.19312*, 2026. 2, 3, 5, 7, 14
- [22] Michael Matthews, Michael Beukman, Chris Lu, and Jakob Nicolaus Foerster. Kinetix: Investigating the training of general agents through open-ended physics-based control tasks. In *Proc. ICLR*, 2025. 2, 6
- [23] Naoki Morihira, Amal Nahar, Kartik Bharadwaj, Yasuhiro Kato, Akinobu Hayashi, and Tatsuya Harada. R2-Dreamer: Redundancy-reduced world models without decoders or augmentation. In *Proc. ICLR*, 2026. 2, 3, 5, 6, 7
- [24] Chaojun Ni, Cheng Chen, Xiaofeng Wang, Zheng Zhu, Wenzhao Zheng, Boyuan Wang, Tianrun Chen, Guosheng Zhao, Haoyun Li, Zhehao Dong, et al. SwiftVLA: Unlocking spatiotemporal dynamics for lightweight VLA models at minimal overhead. *arXiv preprint arXiv:2512.00903*, 2025. 1, 3
- [25] Octo Model Team, Dibya Ghosh, Homer Walke, Karl Pertsch, Kevin Black, Oier Mees, Sudeep Dasari, Joey Hejna, Tobias Kreiman, Charles Xu, et al. Octo: An open-source generalist robot policy. *arXiv preprint arXiv:2405.12213*, 2024. 2
- [26] Chaoyi Pan, Giri Anantharaman, Nai-Chieh Huang, Claire Jin, Daniel Pfrommer, Chenyang Yuan, Frank Permenter, Guannan Qu, Nicholas Boffi, Guanya Shi, et al. Much ado about noising: Dispelling the myths of generative robotic control. *arXiv preprint arXiv:2512.01809*, 2025. 2, 9
- [27] Karl Pertsch, Kyle Stachowicz, Brian Ichter, Danny Driess, Suraj Nair, Quan Vuong, Oier Mees, Chelsea Finn, and Sergey Levine. FAST: Efficient action tokenization for vision-language-action models. *arXiv preprint arXiv:2501.09747*, 2025. 2
- [28] Physical Intelligence. π 0.7: A steerable model with emergent capabilities. <https://www.physicalintelligence.com/blog/pi07>, 2026. Blog post, accessed April 20, 2026. 1, 2
- [29] Physical Intelligence, Ali Amin, Raichelle Aniceto, Ashwin Balakrishna, Kevin Black, Ken Conley, Grace Connors, James Darpinian, Karan Dhabalia, Jared DiCarlo, et al. $\pi_{0.6}^*$: a VLA that learns from experience. *arXiv preprint arXiv:2511.14759*, 2025. 2
- [30] Robo9. Testing of feetech sts3215 servomotor: Backlash, repeatability, and torque. <https://robonine.com/testing-of-feetech-sts3215-servomotor-backlash-repeatability-and-torque/>, 2025. Accessed: 2026-05-04. 14
- [31] Kohei Sendai, Maxime Alvarez, Tatsuya Matsushima, Yutaka Matsuo, and Yusuke Iwasawa. Leave no observation behind: Real-time correction for VLA action chunks. *arXiv preprint arXiv:2509.23224*, 2025. 2

- [32] Mustafa Shukor, Dana Aubakirova, Francesco Capuano, Pepijn Kooijmans, Steven Palma, Adil Zouitine, Michel Aractingi, Caroline Pascal, Martino Russi, Andres Marafioti, et al. SmolVLA: A vision-language-action model for affordable and efficient robotics. *arXiv preprint arXiv:2506.01844*, 2025. 2, 6, 8
- [33] Junhyuk So, Chiwoong Lee, Shinyoung Lee, Jungseul Ok, and Eunhyeok Park. Improving generative behavior cloning via self-guidance and adaptive chunking. In *Proc. NeurIPS*, 2025. 2, 6
- [34] Jiaming Tang, Yufei Sun, Yilong Zhao, Shang Yang, Yujun Lin, Zhuoyang Zhang, James Hou, Yao Lu, Zhijian Liu, and Song Han. Vlash: Real-time vlas via future-state-aware asynchronous inference. *arXiv preprint arXiv:2512.01031*, 2025. 2, 6
- [35] Basile Terver, Randall Balestriero, Megi Dervishi, David Fan, Quentin Garrido, Tushar Nagarajan, Koustuv Sinha, Wancong Zhang, Mike Rabbat, Yann LeCun, et al. A lightweight library for energy-based joint-embedding predictive architectures. *arXiv preprint arXiv:2602.03604*, 2026. 2, 3, 7, 14
- [36] Yilin Wu, Ran Tian, Gokul Swamy, and Andrea Bajcsy. From foresight to forethought: VLM-in-the-loop policy steering via latent alignment. *arXiv preprint arXiv:2502.01828*, 2025. 3
- [37] Haozhe Xie, Beichen Wen, Jiarui Zheng, Zhaoxi Chen, Fangzhou Hong, Haiwen Diao, and Ziwei Liu. DynamicVLA: A vision-language-action model for dynamic object manipulation. *arXiv preprint arXiv:2601.22153*, 2026. 2
- [38] Charles Xu, Jost Tobias Springenberg, Michael Equi, Ali Amin, Adnan Esmail, Sergey Levine, and Liyiming Ke. Precise manipulation with efficient online RL. <https://www.pi.website/research/rlt>, 2026. Research blog post, accessed April 20, 2026. 2
- [39] Angen Ye, Boyuan Wang, Chaojun Ni, Guan Huang, Guosheng Zhao, Hao Li, Hengtao Li, Jie Li, Jindi Lv, Jingyu Liu, et al. GigaWorld-Policy: An efficient action-centered world–action model. *arXiv preprint arXiv:2603.17240*, 2026. 1, 3
- [40] Jiyao Zhang, Zimu Han, Junhan Wang, Xionghao Wu, Shihong Lin, Jinzhou Li, Hongwei Fan, Ruihai Wu, Dongjiang Li, and Hao Dong. HiPolicy: Hierarchical multi-frequency action chunking for policy learning. *arXiv preprint arXiv:2604.06067*, 2026. 3
- [41] Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. In *Proc. RSS*, 2023. 2
- [42] Brianna Zitkovich, Tianhe Yu, Sichun Xu, Peng Xu, Ted Xiao, Fei Xia, Jialin Wu, Paul Wohlhart, Stefan Welker, Ayzaan Wahid, et al. RT-2: Vision-language-action models transfer web knowledge to robotic control. In *Proc. CoRL*, 2023. 1, 2

A1 技术附录和补充材料

A1.1 附加实验结果




Figure A1: Solve rates across 12 environments in Kinetix with action noise $\sigma = 0.2$. Adaptive chunking method is considered not to have a fixed execution horizon, and we report its performance as a horizontal line.

Table A1: Failure modes observed in hardware experiments.

Task	Failure mode	DreamChunk	Open-loop
Toy stacking	Inaccurate placement	3	5
	Missed grasp	5	8
	Stuck in placement	3	0
Grasp moving object	Failed to intercept	4	6
	Inaccurate placement	0	2
USB unplug and insert	Stuck at unplugging	0	3
	Incorrect-angle insertion	1	2
Can insertion (local $N = 5$)	Failed to pick up	0	9
	Missed insertion	7	9

本节提供补充实验结果。图 A1 展示了在 12 个 Kinetix 环境中，不同执行时域下，包含推理延迟 $\sigma = 0.2$, $d = 1$ 与动作噪声的性能表现。

如表 A2 所示，增加采样块的数量会使 SmolVLA 的动作推理延迟从基线的 129.25 毫秒分别提升至 303.70 毫秒、326.72 毫秒和 358.51 毫秒

DREAM-Chunk 与 $N = 5, 10$, 以及 15。相比之下, 额外的世界模型计算是轻量级的: 编码、潜在预测和潜在匹配分别仅需 4.64 毫秒、2.36 毫秒和 0.20 毫秒。

A1.2 实现细节

仿真中的世界模型架构。对于 R2-Dreamer 世界模型, 我们使用 MLP 模块以及类似 GRU 的循环转移来处理来自 Kinetix 环境的向量观测。由于观测向量长度约为 700, 观测编码器是一个两层 MLP, 维度为 $\text{obs_dim} \rightarrow 512 \rightarrow 256$ 。先验和后验 RSSM 头使用隐藏大小 512, 默认情况下先验有两个隐藏层, 后验有一个隐藏层。确定性动态通过分块 GRU 更新实现, 使用确定性宽度 256、大小为 32×16 的随机状态展平为 512 维、转移隐藏大小 512、一个转移隐藏层和 8 个块。对于确定性的 JEPA 风格世界模型 (包括 EB-JEPA 和 LEWM), 我们使用完全基于 MLP 的架构, 没有循环动态。该模型包括一个观测编码器 $\text{obs_dim} \rightarrow 512 \rightarrow 256$ 、一个动作编码器 $\text{action_dim} \rightarrow 256 \rightarrow 256$ 、一个预测器, 该预测器具有一个隐藏阶段, 将拼接的观测-动作表示从 $256 + 256$ 维映射到 512 维隐藏层, 然后通过残差连接和 LayerNorm 映射到 256 维输出, 以及一个投影器 $256 \rightarrow 512 \rightarrow 256$ 。LEWM 和 EB-JEPA 仅在其潜在正则化目标上有所不同: LEWM 使用 SIGReg [21], 而 EB-JEPA 使用方差-协方差正则化 [35]。

Component	Latency (ms)
Baseline inference	129.25
Action inference, $N = 5$	303.70
Action inference, $N = 10$	326.72
Action inference, $N = 15$	358.51
WM encoder	4.64
WM predictor	2.36
WM latent matching	0.20

硬件引起的执行不确定性。我们进一步阐明实验任务设计中由不精确的硬件执行所引入的不确定性。低成本 SO-101 机械臂采用 Feetech STS3215 总线舵机, 其制造商规格标称编码器分辨率为 $\pm 0.088^\circ$, 齿轮箱回差极限为 0.5° [13]。一项针对同型号舵机的独立在线测试报告称, 实际回差可能超过该标称极限, 并在 86 mm 单连杆装置上导致毫米级末端执行器位移 [30]。与该观察一致, 我们发现 SO-101 末端执行器位置受到多个舵机关节累积误差的影响, 即使在遥操作过程中也难以实现精确操控。作为对比, 工业级 Franka Emika Panda 提供显著更高的定位精度: 其官方数据表表明这是一款 7 自由度机械臂, 工作半径 855 mm, 负载 3 kg, 末端执行器重复定位精度为 ± 0.1 mm [8]。这一对比凸显出我们的 SO-101 实验是在具有不可忽略驱动不确定性的低成本硬件平台上进行的。

A1.3 反应性分析

反应性失效。我们提供一个简化分析, 将 DREAM-Chunk 与式 (2) 中的反应性目标联系起来。回顾 $J_{\text{react}}(\eta)$ 衡量的是执行策略 η 所选择的动作是否与同一策略在根据实际观测重新推断时会做出的决策保持一致。我们称在阶段 τ 发生反应性失效, 当执行的动作与当前策略决策的对齐度较低时, 即 $\text{Align}(a_{t+\tau}^\eta, o_{t+\tau}) < \epsilon_{\text{align}}$, (A7) 其中 ϵ_{align} 为对齐阈值。该定义抓住了开环分块执行的核心问题: 随机动力学、部分可观测性或执行噪声可能使系统到达某个实际观测状态, 在该状态下, 最初采样的分块中剩余动作不再与策略在再次查询时会选择的动作相匹配。

开环失配。令 p_{dyn} 表示每一步中此类随机偏差导致原始分块中的开环动作与基于实际观测条件的策略决策失配的概率。对于标准开环执行策略 η_{open} , 其在时间范围 H 内执行原始分块, 在执行窗口内不发生此类失配的概率为

执行窗口

$$P_{\text{align}}^{\text{open}}(H) = (1 - p_{\text{dyn}})^H. \quad (\text{A8})$$

因此，开环执行遇到至少一个导致性能下降阶段的概率为

$J_{\text{react}}(\eta_{\text{open}})$ is

$$P_{\text{misalign}}^{\text{open}}(H) = 1 - (1 - p_{\text{dyn}})^H. \quad (\text{A9})$$

该表达式体现了缩短执行视野的优势：较小的 H 降低了策略在下次推理步骤前继续执行过时动作的概率。

候选覆盖。DREAM-Chunk 采用了不同的方法。它不缩短执行视野，而是保持较长的视野，但采样多个候选块，并利用世界模型维护一个相位对齐的梦想未来状态池。设 p_δ 表示一个采样块在执行相位 δ 时，包含一个动作的概率，该动作的梦想潜状态与实现的观测兼容，因此该动作与在该观测处重新推断的策略决策对齐。该概率由策略分布诱导，并取决于学习到的策略能否在扰动轨迹周围采样纠正性动作。对于 N 个独立采样的块，至少有一个候选在相位 δ 提供对齐的纠正动作的概率为 $P_{\text{cover}}(N, \delta) = 1 - (1 - p_\delta)^N$ 。 (A10)。这与通过最近梦想状态距离实证测量的覆盖效应相同：增加 N 使得梦想状态池更可能包含接近实现轨迹的候选，这作为在 $J_{\text{react}}(\eta)$ 下更高对齐的替代指标。

世界模型可靠性。然而，仅靠覆盖是不够的。DREAM-Chunk 还需要辅助世界模型提供一个潜空间，在该空间中，相位对齐匹配能够识别出动作与实现的观测最兼容的候选。因此，我们引入一个可靠性项 $r_{\text{wm}} \in [0, 1]$ ，它表示当候选池中存在对齐的纠正块时，潜匹配选择该块的概率。随机偏差可被纠正的有效概率近似为

$$P_{\text{corr}}(N, \delta) = r_{\text{wm}} P_{\text{cover}}(N, \delta) = r_{\text{wm}} [1 - (1 - p_\delta)^N]. \quad (\text{A11})$$

相应地，每一步发生错位且未被恢复的概率为

$$p_{\text{unrec}} = p_{\text{dyn}} (1 - P_{\text{corr}}(N, \delta)). \quad (\text{A12})$$

对于具有较长执行视野 H_L 的 DREAM-Chunk，遇到至少一次未恢复错位的概率可近似为

$$P_{\text{fail}}^{\text{DC}}(H_L, N) = 1 - (1 - p_{\text{dyn}} (1 - r_{\text{wm}} [1 - (1 - p_\delta)^N]))^{H_L}. \quad (\text{A13})$$

与较短执行视野的比较。现在考虑一个执行视野为 $H_S < H_L$ 的较短视野基线。由于它不维护用于视野内校正的候选池，其遇到至少一次失准的概率为

$$P_{\text{fail}}^{\text{short}}(H_S) = 1 - (1 - p_{\text{dyn}})^{H_S}. \quad (\text{A14})$$

当 DREAM-Chunk 具有更小的未恢复失准概率时，预期其反应性高于该较短视野基线：

$$P_{\text{fail}}^{\text{DC}}(H_L, N) < P_{\text{fail}}^{\text{short}}(H_S). \quad (\text{A15})$$

代入两个失败概率得到

$$1 - (1 - p_{\text{dyn}} (1 - r_{\text{wm}} [1 - (1 - p_\delta)^N]))^{H_L} < 1 - (1 - p_{\text{dyn}})^{H_S}. \quad (\text{A16})$$

等价地，

$$(1 - p_{\text{dyn}} (1 - r_{\text{wm}} [1 - (1 - p_\delta)^N]))^{H_L} > (1 - p_{\text{dyn}})^{H_S}. \quad (\text{A17})$$

对于较小的 p_{dyn} ，利用一阶近似 $(1 - x)^H \approx 1 - Hx$ ，该条件变为

$$H_L p_{\text{dyn}} (1 - r_{\text{wm}} [1 - (1 - p_\delta)^N]) < H_S p_{\text{dyn}}. \quad (\text{A18})$$

当 $p_{\text{dyn}} > 0$ 时, 可以约去 p_{dyn} 得到

$$r_{\text{wm}} [1 - (1 - p_{\delta})^N] > 1 - \frac{H_S}{H_L}. \quad (\text{A19})$$

该不等式给出了权衡的简单解释。较长视野的 DREAM-Chunk 策略能够弥补其对随机偏差的更大暴露, 前提是其候选池足够可能包含对齐的纠正动作, 并且世界模型能够可靠地识别该候选。换言之, 缩短执行视野降低了陈旧动作变为失准的概率, 而 DREAM-Chunk 提高了失准发生时对齐纠正可用的概率。

启示。该分析还阐明了 DREAM-Chunk 何时应当有效。覆盖项 $P_{\text{cover}}(N, \delta)$ 取决于采样动作块的多样性, 以及演示数据是否包含学习策略可以采样的纠正行为。如果策略分布仅在标称轨迹周围产生微小变化, 且演示中不包含恢复行为, 则 p_{δ} 保持较小, 增加 N 带来的收益有限。相比之下, 当演示包含对随机动态的响应时, 增加 N 可以暴露更多局部纠正选项, 并提高维持高 $J_{\text{react}}(\eta)$ 的机会。世界模型可靠性项 r_{wm} 同样重要: 即使候选池中包含对齐的纠正动作, DREAM-Chunk 只有在学习到的潜在动态和匹配度量能够正确识别出理想状态与实现观测兼容的候选时才能使用它。同时, p_{dyn} 由环境和硬件决定: 更强的动作噪声、部分可观测性、外部扰动或低精度执行都会增加开环动作与实现观测失准的概率。因此, DREAM-Chunk 在中间状态最有用: 随机偏差发生得足够频繁, 使得开环执行变得脆弱, 但学习到的策略和世界模型仍提供足够的纠正覆盖和匹配可靠性, 使潜在匹配能够恢复。

A1.4 讨论

局限性。所提出的方法在测试时需要额外的计算资源来采样批量动作块, 这可以通过在个人电脑上进行远程推理来部署, 但在边缘设备上样本量将受到更大限制。我们还讨论了纠正行为的性质在很大程度上受生成策略表达能力的限制, 我们的实验表明采样的动作块没有明显不同的模式, 限制了 DREAM-Chunk 在块内执行期间展示显著策略变化的能力。此外, 所提出方法的有效性取决于专家演示是否包含对随机动态的响应, 这对数据收集提出了要求。

扩展。本文旨在让所提方法创新世界模型在视觉-语言-动作研究中的应用, 灵感来源于成熟的基于模型的机器人学研究, 如模型预测控制、鲁棒控制和模型预测路径积分 [2]。由于 DREAM-Chunk 方法在测试时采样多个动作块, 它也可以与其他测试时扩展算法集成。例如, 将 BID [20] 中的后向损失加入块选择可以改善跨块一致性, 应用跨块熵 [19], 并提供自适应改变执行时长的测度。为了减少批量动作采样的开销, 未来的实现可以通过一次计算视觉-语言嵌入并在候选块中复用来摊销视觉-语言模型骨干推理, 同时在动作专家中采样不同的噪声输入以生成多样化的动作。

社会影响。本文通过提高机器人策略在随机动力学、硬件不确定性和部分可观测性下的鲁棒性, 为具身智能和机器人学习做出贡献。这些能力可以惠及辅助机器人、制造业和物流业, 在这些领域更安全、更具适应性的机器人行为具有价值。然而, 更鲁棒的机器人策略也可能增加有害或监管不善应用中的风险, 包括武器化自动化、不安全的自主系统。机器人自动化更广泛的进步也可能影响某些行业的劳动力需求。这些风险并非 DREAM-Chunk 所独有, 但促使在高风险领域设置任务特定的安全约束、人类监督、滥用监控和部署限制。