

DriveCritic: 面向自动驾驶的上下文感知、人类对齐评估框架，基于视觉语言模型

Jingyu Song^{*1} Zhenxin Li^{2,3} Shiyi Lan² Xinglong Sun² Nadine Chang²
Maying Shen² Joshua Chen² Katherine A. Skinner¹ Jose M. Alvarez²

¹University of Michigan ²NVIDIA ³Fudan University

摘要——自动驾驶规划器的基准测试需与人类判断对齐，这仍是一项关键挑战，因为最先进的度量指标（如扩展预测驾驶员模型评分，EPDMS）在细微场景中缺乏上下文感知能力。为此，本文提出 DriveCritic，一个新颖的框架，包含两项核心贡献：DriveCritic 数据集，一个精心构建的挑战性场景集合，其中上下文对正确判断至关重要，并标注了成对人类偏好；以及 DriveCritic 模型，一个基于视觉语言模型（VLM）的评估器。通过两阶段监督学习和强化学习流程进行微调，DriveCritic 模型学习通过整合视觉和符号上下文来裁决轨迹对。实验表明，DriveCritic 在匹配人类偏好方面显著优于现有度量和基线，并展现出强大的上下文感知能力。总体而言，本文工作为评估自动驾驶系统提供了更可靠、与人类对齐的基础。DriveCritic 项目页面：<https://song-jingyu.github.io/DriveCritic>。

一、引言

规划是实现自动驾驶的核心组成部分之一，因为它需要为自动驾驶车辆预测安全且高效的未来轨迹以供其遵循 [1]、[2]。近年来，以规划为导向目标进行训练的端到端（E2E）驾驶系统发展迅速，并在大规模基准测试中展现出卓越的性能 [3]–[7]。然而，以准确反映安全性和人类期望的方式对规划器进行基准测试仍然具有挑战性 [8]、[9]。若缺乏这一特性，驾驶规划器可能在标准定量度量上达到最先进的（SOTA）性能，但在真实驾驶场景中的细微场景上仍与人类实际偏好不一致。驾驶策略的评估通常分为两种主要方法：闭环仿真，由 CARLA 等平台采用 [10]，提供高保真、交互式测试，其中智能体的行为会影响环境的后续状态。尽管闭环仿真被视为评估真实世界性能的黄金标准，但它计算成本高昂，存在仿真与现实的差距，并且难以扩展以在不同场景中进行全面测试 [1]、[8]。相比之下，开环评估回放来自真实世界驾驶场景的记录传感器数据，并在不影响其他智能体行为的情况下评估规划器的预测轨迹。这种方法具有高度可扩展性，




图 1: 来自 NAVSIM[8] 的示例，说明了自动驾驶中需要上下文感知评估。在这个成对比较任务中，轨迹 A 短暂向左微调以保持安全的横向缓冲——这一动作在上下文中是合适的，并非真正的车道偏离。我们的 DriveCritic 模型不仅偏好 A，还生成了类似的推理，展示了其上下文理解能力。相比之下，最先进的基于规则的度量 EPDMS[13] 给 A 分配了较低的分值，而偏好 B，仅仅因为 B 保持在固定的车道保持阈值内，尽管其前进程度不必要地低。关键鸟瞰图图例：自车——位于中心（0 米，0 米）朝上的红色矩形；轨迹航点——绿色虚线带圆点（4 秒视野内 8 个航点，间隔 0.5 秒），起始于自车后轴中心。建议放大并以彩色查看。

数据驱动，并允许在大量真实世界数据集上进行直接比较，使其成为大规模基准测试的首选方法 [3]、[7]、[11]、[12]。虽然闭环测试比开环仿真更能反映人类驾驶偏好 [1]，但我们的工作采取了不同的路径：不是首先将开环评估与闭环性能对齐，而是提出一种解决方案，直接将开环评估与专家人类对齐连接起来。为了理解所提方法的必要性，首先必须审视开环范式下先前方法的局限性。早期评估方法主要依赖于简单的位移误差，如平均位移误差（ADE）和最终位移误差（FDE）[7]、[9]。然而，这些度量不足以应对驾驶的多模态和安全关键特性 [8]、[9]，因为它们通过将正确性概念限制在单一参考轨迹上，往往惩罚有效的替代驾驶行为，并且未能捕捉碰撞避免或乘客舒适度等关键方面。

^{*} 本工作于 NVIDIA 实习期间完成。通讯作者：
jingyuso@umich.edu

一项较新的提议，评分者反馈分数（Rater Feedback Score, RFS）[14] 试图通过依赖专家标注者提供三条具有不同分数的参考轨迹来克服这些局限性；随后，每条候选轨迹根据其与其与评分者指定轨迹中最接近的一条进行评分。虽然 RFS 比 ADE/FDE 更能适应多模态性，但由于昂贵的人工标注，其可扩展性有限，并且由于缺乏公开的评分细则，其分数的可解释性不足（例如，7 分与 8 分的含义仍不明确）。为了解决依赖位移误差的模仿式度量的缺陷，最先进的基准引入了更全面的基于规则的度量。一个突出的例子是预测驾驶员模型分数（Predictive Driver Model Score, PDMS）及其扩展版本 EPDMS，它们随 NAVSIM 基准 [8] 一同提出。EPDMS 是一种基于规则的评估器，考虑了安全性、舒适性和行进效率等关键因素，已被广泛用于评估现代驾驶策略 [13]、[15] – [17]。尽管 PDMS/EPDMS 等最先进的基于规则的度量被广泛采用，我们观察并认为它们仍存在一个根本性局限：缺乏上下文感知和人类对齐（图 1）。我们将人类对齐定义为以反映经验丰富的人类驾驶员在复杂交通情境中如何平衡安全性、行进效率和社会规范的方式来评估驾驶计划的能力。具体而言，这些度量基于一组预定义的固定规则和阈值，难以在这些情境中捕捉此类人判断。例如，为创造安全横向缓冲空间而发生的轻微车道偏离可能会受到严厉惩罚，而忽视停车标志的过于激进的轨迹却可能获得有利评分。我们通过分析专家人类轨迹在具有挑战性场景中的 EPDMS 分数，并整理一个集中于此类模糊区域的成对偏好数据集，揭示了这一缺陷，在这些区域中 EPDMS 常常与人类偏好相悖。为弥合这一关键差距，我们提出 DriveCritic，一个面向自动驾驶规划器人类对齐评估的新颖框架。我们首先介绍 DriveCritic 数据集，这是一个试点收集的具有挑战性和模糊性的驾驶场景集合，现有度量在这些场景中经常失效，并附有成对人类偏好标注。其次，我们介绍 DriveCritic 模型，作为一个“与专家人类对齐”的评判者，它利用视觉语言模型（Vision-Language Models, VLMs）[18] – [22] 强大的上下文推理和常识知识。通过可验证奖励强化学习（RLVR）范式 [23] – [25] 对 VLM 进行微调，DriveCritic 实现了与专家人类偏好的最先进对齐，为开发面向自动驾驶的上下文感知、人类对齐评估奠定了可靠基础。我们的主要贡献可总结如下：

- 我们识别并证明了 EPDMS 等最先进的基于规则的度量的局限性，表明它们在细微驾驶场景中缺乏上下文感知以及与专家人类判断的对齐。
- 我们介绍 DriveCritic 数据集，这是一个从 NAVSIM [8] 中采样、用于评估驾驶评估方法的精选数据集，包含具有挑战性的场景标注

与成对人类专家偏好配对。

- 我们提出 DriveCritic 模型，这是一种新颖的基于视觉语言模型（VLM）的模型，通过 RLVR 流程微调以评估驾驶轨迹，并表明其在符合人类专家偏好方面显著优于现有度量，在所提出的 DriveCritic 数据集上达到 76% 的准确率。

II. 相关工作

A. 自动驾驶基准测试

评估自动驾驶系统的性能是一项复杂且多方面的挑战。当前方法主要分为两种范式：闭环仿真和开环评估。闭环仿真 [3], [10], [26] 将自主智能体置于交互式仿真环境中，其行为直接影响未来状态。尽管由于其交互性常被视为自动驾驶基准测试的黄金标准，但该方法计算密集，难以扩展到真实世界场景的多样性，并且可能面临持续的仿真到现实领域差距 [8], [13]。另一方面，开环评估 [7], [27] 利用真实世界日志回放和人类轨迹进行基准测试，提供可扩展性和可解释性 [1]。早期开环评估方法（例如 ADE 和 FDE）主要依赖于比较与人类轨迹的位移误差。这些方法计算简单，但通常无法捕捉驾驶的多模态特性或惩罚不安全行为 [8], [9], [26], [28]。为解决这些不足，近期基准提出了基于规则的评分系统，明确评估安全合规性、进展和舒适性，而非仅关注位移误差，从而在确保安全的同时鼓励驾驶的多模态特性 [3], [8]。NAVSIM [8] 及其后继者伪仿真 [13] 通过在对象和地图的符号空间中仿真轨迹并使用 EPDMS 度量（一套全面的基于规则的套件）进行评分，推进了这一范式。尽管 EPDMS 已成为可扩展开环评估的最先进技术，但其逻辑仍是硬编码的，且仅限于符号表示，这使其本质上“上下文盲”，因为它缺乏人类驾驶员在导航社会复杂或模糊情境时所使用的丰富视觉和语义线索 [16], [29]。我们的工作通过提出一种基于 VLM 的评估器直接弥补这一差距，该评估器能够以上下文感知和类人推理补充这些基于规则的度量。

B. 自动驾驶中的视觉语言模型

大语言模型（Large Language Models）和视觉语言模型（VLMs）[18]、[21] 的最新进展推动了将其应用于自动驾驶领域广泛任务的研究浪潮 [30] – [35]。尽管这些方法展示了视觉语言模型在驾驶场景理解和决策制定方面的强大潜力，但我们注意到利用视觉语言模型进行驾驶评估的研究仍较少。受其他领域使用大语言模型/视觉语言模型作为评判者的进展 [36] – [38] 的启发，[39] 中的研究者

表 I: 人类专家轨迹在 NAVSIM [8] 的 navtrain 和 navtest 划分上的 EPDMS 及子分数。缩写见第 III-A 节。

Split	NC	DAC	DDC	TLC	EP	TTC	LK	HC	EC	EPDMS
navtrain	1.00	1.00	1.00	0.98	0.88	1.00	0.90	0.98	0.91	0.92
navtest	1.00	1.00	1.00	0.97	0.87	1.00	0.87	0.98	0.90	0.90

[40] 已开始探索使用视觉语言模型作为驾驶行为的评估器。此外, HE-Drive [41] 提出引入视觉语言模型引导的评分器, 以在确保舒适性的同时帮助调整驾驶风格。与此同时, 一项密切相关的工作 StyleDrive [16] 利用微调后的视觉语言模型挖掘不同驾驶风格的场景, 并根据标注的驾驶风格调整 EPDMS [13] 中的关键子度量, 从而开发出一种风格感知的度量。我们的工作 DriveCritic 与 StyleDrive [16] 在提升 EPDMS 的上下文感知能力方面具有相同的动机, 但在视觉语言模型的使用和任务表述上做出了独特的贡献。我们对 EPDMS 与专家人类偏好之间的错位进行了系统性研究, 并将基于视觉语言模型的模型定位为一种上下文感知的评估器, 能够在模糊场景上生成与人类对齐的成对判断。值得注意的是, DriveCritic 可以无缝集成到 TrajHF [42] 等框架中, 通过在其基于人类反馈的强化学习流程中提供可扩展的、与人类对齐的偏好信号来指导轨迹生成。此外, DriveCritic 模型采用 RLVR 范式 [23] – [25] 进行微调, 这遵循了自动驾驶领域开创性工作 [17]、[34]、[35] 的成功经验。

III. 预备知识

本文聚焦于解决基于规则的评估方法 EPDMS [13] 中上下文感知的不足, 这基于其作为最先进的开环度量的地位, 该地位已在第 II-A 节中讨论。我们首先基于 NAVSIM 基准 [8]、[13] 回顾 EPDMS 的技术细节, 然后讨论其局限性, 这些局限性构成了我们工作的动机。

A. EPDMS

EPDMS 是一项基于规则的综合性子度量, 随 NAVSIM 基准 [13] 提出, 重点关注 OpenScene 数据集 [43] 中的挑战性场景, 该数据集是 nuPlan [3] 的轻量级再分配版本。它利用真实感知 (如目标边界框、鸟瞰图) 评估固定时域轨迹 (通常为 4 秒), 采用一组可解释的基于规则的子度量, 涵盖安全合规性、进展和舒适性。在实践中, 它将安全规则违规的乘法惩罚与轨迹质量子分数的加权平均相结合:

$$\text{EPDMS} = \left(\prod_{m \in \mathcal{M}_{\text{pen}}} s_m \right) \cdot \frac{\sum_{m \in \mathcal{M}_{\text{avg}}} w_m s_m}{\sum_{m \in \mathcal{M}_{\text{avg}}} w_m},$$

其中 $\mathcal{M}_{\text{pen}} =$ 无责任碰撞 (NC)、可行驶区域合规性 (DAC)、行驶方向合规性 (DDC)、交通信号灯合规性 (TLC) 以及 $\mathcal{M}_{\text{avg}} =$ 碰撞时间 (TTC)、自车进展 (EP)、车道保持 (LK)、历史舒适性 (HC)、扩展舒适性 (EC)。此处, $s_m \in [0, 1]$ 表示度量 m 的子分数: 值为 1

表示完全合规, 0 表示严重违规, 分数值 (例如 0.7 对于 EP) 根据规则捕获部分合规性。项 w_m 表示分配给每个平均子度量的相对权重, 反映它们在 EPDMS 中的重要性。EPDMS 的完整规范见 [13]。

B. 上下文差距

如 [3]、[8] 所述, NAVSIM 中的人类驾驶员轨迹可视为由训练有素的操作员驾驶的专家演示。这引发了一个自然的一致性检验: 如果 EPDMS 真正与专家人类偏好对齐, 那么人类轨迹预期应获得满分。然而, 如表 I 所示, 情况并非如此。虽然安全关键子分数 (如 NC、DAC、DDC、TLC 和 TTC) 在人类驾驶中接近 1.0 饱和, 但有两个子分数始终落后: 自车进展 (EP) 和车道保持 (LK)。虽然扩展舒适性 (EC) 也低于聚合的 EPDMS, 但我们不对其进一步分析, 因为舒适性体验本质上是主观的, 难以通过视觉检查可靠评估。为清晰起见, 我们现在详细说明 LK 和 EP 的计算, 因为这些子分数在我们的分析中起着核心作用。LK 检查自车是否在车道内且无长时间偏离。在每个仿真步骤中测量与车道中心的横向偏移; 仅当 $d > 0.5$ 米持续超过 2 秒时才发生违规。最终分数为二值 (若无持续违规则为 1, 否则为 0)。EP 衡量相对于来自预测驾驶员模型 (PDM) -Closed 规划器的上下文无关上界 d_{ref} 的路线推进。[8]:

$$\text{EP} = \min \left(1, \frac{d_{\text{ego}}}{d_{\text{ref}}} \right),$$

分数被截断至 $[0, 1]$ 区间。若 $d_{\text{ref}} < 5$ m, 该比值被舍弃以避免不稳定的情况。

对低分场景的审计显示, 人类专家常会做出符合情境的车道微调或降低行进进度以配合保守线索 (示例见图 1 和图 3)。由于 EPDMS 会惩罚这些合理行为, 我们利用车道保持 (LK) 与自车进度 (EP) 作为探针来挖掘此类细微案例, 并构建评估数据集。

四、技术方法

本节介绍驾驶评论家 (DriveCritic) 框架, 涵盖驾驶评论家数据集的构建与驾驶评论家模型的设计。

A. 驾驶评论家数据集

驾驶评论家数据集从导航模拟器 (NAVSIM) [8] 中采样并构建, 包含 5,730 个轨迹对, 作为一项试点基准, 旨在凸显情境感知评估的必要性。构建过程详述如下。

1) 数据集构建策略: 如第 III-B 节所述, 我们扩展了对人类轨迹 EPDMS 的审计, 并通过车道保持 (LK) 与自车进度 (EP) 分数从导航模拟器 [8] 中挖掘模糊场景 (图 2)。然而, 定量地降低人类偏好




图 2: 驾驶评论家框架概览。驾驶评论家数据集是一项聚焦于情境感知评估的试点基准。驾驶评论家模型融合丰富的多模态输入，并通过两阶段训练流程进行微调，使其能够在具有挑战性的驾驶场景中生成与人类对齐的评估决策。

表二：两个重点案例研究的轨迹采样模式。每个采样的轨迹对由人类轨迹和与子分数模式匹配的词汇表轨迹组成。采样轨迹的其他子分数均为满分。

Case	Human (H)	Vocabulary (V)
1	$LK_H = 0, EP_H \geq \tau_{EP_1}$ $LK_H = 1, EP_H \leq \tau_{EP_2}$	$LK_V = 1, EP_V \leq EP_H - \Delta_{EP}$ $LK_V = 0, EP_V \geq EP_H + \Delta_{EP}$
2	$EP_H \leq \tau_{EP_2}$	$EP_V \geq EP_H + \Delta_{EP}$

Hyperparameters: $\tau_{EP_1} = 0.88, \tau_{EP_2} = 0.75, \Delta_{EP} = 0.2$.

表三：按划分和数据来源统计的轨迹对数量。案例一：车道保持与进度权衡；案例二：仅进度对比。

Split	Data Source	Case 1	Case 2	Total
Train	navtrain	2626	1938	4564
Test	navtest	663	503	1166
Total	—	3289	2441	5730

将轨迹归结为单一数值分数具有挑战性，因为对于细微权衡（例如轻微偏离车道以绕过停靠车辆）尚无广泛接受的评分标准。因此，本文将数据集任务构建为成对判定问题 [38]、[44]，并利用大型静态词汇表 [6]、[15] 中的样本扩充人类轨迹，同时配对其原始 EPDMS 子分数。在检查人类轨迹获得低 LK 或 EP 分数的场景过程中，本文观察到 EPDMS 通常会误判两类典型场景。第一类，在人类驾驶员获得 $LK = 0$ 的场景中，人类驾驶员可能为了保持进度而短暂牺牲车道保持，例如轻微偏离以绕过停靠车辆。然而，严格保持在车道内 ($LK = 1$) 的词汇表轨迹，即使进度明显较低，也往往被 EPDMS 评为更优。第二类，在人类驾驶员获得低于典型 EP 分数的场景中，人类驾驶行为常常反映出合理的保守驾驶，此时降低进度在情境上是恰当的，而 EP 明显更高的词汇表轨迹并不总是更可取，因为过度激进的进度可能与安全或礼貌驾驶相冲突。

驾驶。因此，本文构建了两个诊断性案例研究，其构建规则见表二：

案例一（车道保持与进度权衡）

：本文首先采样人类轨迹具有 $LK = 0$ 且 EP 较高、词汇表替代轨迹具有 $LK = 1$ 且 EP 较低的轨迹对（表二第一行）；在实践中，本文发现标注后大多数此类轨迹对对人类轨迹更受偏好。为防止评估器学习到退化规则（“总是选择 $LK = 0$ ”），本文额外加入了镜像轨迹对（表二第二行）。对于镜像轨迹对，本文采样具有 $LK = 0$ 且 EP 较高的词汇表候选轨迹，而人类轨迹具有 $LK = 1$ 且 EP 较低。这迫使模型基于情境进行推理，而非仅仅依赖 LK。

案例二（仅进度对比）： 在这种情况下，我们采样人类轨迹，其 EP 低于预定义阈值，而其配对的词汇表轨迹获得显著更高的 EP，同时两条轨迹的其他子分数均为完美（表 II 第三行）。这些配对聚焦于驾驶进度的上下文感知评估。我们在表 II 中列出了所使用的超参数，其中 EP 阈值 τ_{EP_1} 和 τ_{EP_2} 是根据 NAVSIM 统计经验设定的，进度裕度 Δ_{EP} 确保 EP 在视觉上清晰分离。这些精心构建的案例共同构成了 DriveCritic 数据集的基础，提供了受控且多样的场景，在这些场景中，基于规则的 EPDMS 评分与人类驾驶偏好常常出现分歧。

2) 人类偏好标注：采样后，每个轨迹对随机分配为 A 或 B 进行人类偏好标注。表 III 报告了最终的数据集规模。我们创建了训练/测试划分，测试集上使用经过验证的标签，训练集上使用可扩展的自动标签（详见下文）。

我们招募主要作者标注整个测试划分，以确保标注标准一致。标注者可视领域专家，拥有超过五年的自动驾驶研究经验，从而提供可靠的真实偏好。在标注过程中

过程，指南被迭代细化，随后进行了验证过程以确保所有标签都符合该指南。我们还丢弃了过于模糊而无法判断的样本，确保每个保留的配对都展现出清晰且可辨别的偏好。在测试集上，我们观察到在车道-进度权衡（案例 1）中偏好高度倾斜：人类轨迹在 608/663 个配对中被选择（91.7%），而在仅进度对比（案例 2）中偏好更为均衡，人类在 304/503 个配对中被选择（60.4%）。这表明案例 1 相对明确：人类几乎总是被偏好，无论他们是短暂偏离车道以保持进度，还是保持更保守以维持车道保持。相比之下，案例 2 反映了真正的模糊性，其中保守的进度有时被青睐，有时被惩罚。为了扩展训练集的标注，我们因此对案例 1 使用伪标签（人类偏好），并采用 GPT-5[19] 来标注案例 2。当使用从案例 2 的标注指南中提炼出的具体指令进行提示时，GPT-5 在验证测试集上达到了高准确率（82%）。确切的提示将在我们的项目网站上提供。

B. DriveCritic 模型

1) 模型设计：驾驶评判（DriveCritic）模型的目标是在具有挑战性的驾驶场景中裁决候选轨迹对，产生与人类偏好一致的成对判断。受视觉语言模型（VLM）在感知、推理和规划等自动驾驶任务中集成与微调取得显著成功的启发 [17]、[30]、[34]、[35]，本文同样采用开源视觉语言模型 [22] 作为驾驶评判模型的骨干网络。具体而言，本文选用通义千问 2.5 视觉语言（Qwen2.5-VL）模型家族中的 70 亿参数版本 [22]，因为它在训练效率与推理能力之间提供了良好的平衡。如图 2 所示，驾驶评判模型以四项输入为条件：其一，拼接的三摄像头视图（左前、前、右前），遵循 [32]、[35]；其二，包含场景上下文（如可行驶区域、车道、人行横道、附近智能体）的鸟瞰图（BEV），其中两条候选轨迹分别叠加以避免重叠；其三，自车状态（即当前加速度、速度、驾驶指令）；其四，扩展规划与决策度量系统（EPDMS）子分数中的自我进展（EP）与车道保持（LK）。本文尝试了其他配置，例如在文本提示中提供原始航点坐标、纳入额外的扩展规划与决策度量系统子分数，或将候选轨迹投影到摄像头视图上，但经验表明所选配置具有最可靠的性能。

视觉语言模型被提示为一名驾驶评估专家，其任务是在甲与乙（即驾驶评判数据集中每个场景的两条候选轨迹）之间选择更合理的轨迹。提示中明确了角色、输入和评估范围（在当前情境下强调自我进展与车道保持），并遵循 [23]、[24] 以强制实施结构化推理过程，随后给出单一偏好决策。该设计引导模型交叉检查视觉与符号线索，理解并推理车道保持与自我进展子分数的适当性，

并产生与人类一致的成对判断。

2) 两阶段训练流程：本文最初仅使用强化学习（RL）的尝试被证明不稳定，模型需要长时间预热才能显示出有意义的改进。为解决这一问题，本文采用监督微调（SFT）后接强化学习微调的两阶段流程：监督

微调：我们首先从驾驶评论家（DriveCritic）数据集训练划分中随机采样的 1,100 对子集上微调基础 Qwen2.5-VL-7B 模型。对于每一对，我们采用 GPT-5 [19] 作为“教师”模型。对于每个轨迹对，教师模型被提示使用真实人类偏好标签，并负责生成相应的思维链推理轨迹。该阶段有助于在强化学习之前预热模型遵循所需响应格式的能力，并使其判断基于逐步推理。强化学习

微调：在第二阶段，我们使用强化学习与可验证奖励（RLVR）范式对来自监督微调（SFT）阶段的模型进行精炼。具体而言，我们采用解耦裁剪与动态采样策略优化（DAPO）算法 [24]，这是基于群体相对策略优化（GRPO）[23] 的最新进展，可提高训练效率和稳定性。与 GRPO 类似，DAPO 通过在一组样本内计算相对优势来避免显式价值函数，同时进一步引入稳定更新和加速收敛的机制。我们使用与 [23] 相同的奖励设计，鼓励格式遵循（例如正确使用 <think> 标记）和准确率，因为发现 DAPO 中的原始奖励设计在我们的设置中会引入训练不稳定性。由于篇幅限制，我们在此不包含完整的算法细节，而是建议读者参阅原始 GRPO 和 DAPO 论文以获取全面描述 [23]、[24]。

五、实验与结果


A. 实现细节

我们总结了 DriveCritic 模型的关键实现细节。如第 IV-B.2 节所述，训练分两个阶段进行。在第一阶段，对 1,100 个带注释的轨迹对进行监督微调（SFT），参考推理轨迹由 GPT-5 生成 [19]。我们使用 LLaMA-Factory[45] 中实现的 LoRA（低秩适配）方法进行 5 个训练轮次的微调，每设备批大小为 1，学习率为 1×10^{-4} 。在第二阶段，在 RLVR 范式下使用 DriveCritic 数据集的训练集进行强化学习微调。我们采用基于 verl 框架 [47] 构建的 EasyR1 库 [46]，在 16 块 NVIDIA A100 GPU 上使用 bfloat16 数据类型训练 4 个训练轮次，全局批大小为 256，展开次数为 8，学习率为 1×10^{-6} 。展开温度设为 1.0 以鼓励探索，验证时温度设为 0.1 以保证评估稳定。消融研究（第 V-D 节）中报告的所有模型变体均使用相同的训练配置。

B. 总体比较

我们首先在 DriveCritic 数据集上评估所有方法，使用第 IV-A.2 节所述的验证测试集。


Velocity: 7.466 m/s | Acceleration: 0.456 m/s² | Command: forward



EPDMS_A < EPDMS_B A > B

Selected reasoning: Trajectory A: it maintains a safe buffer from the parked cars on the right seen in the cameras and the BEV. Trajectory B: the waypoints are shorter and more clustered, indicating earlier braking and reduced forward reach (about 20 m), with no clear reason to slow given the open lane.

Velocity: 2.515 m/s | Acceleration: -0.219 m/s² | Command: forward



EPDMS_A < EPDMS_B A > B

Selected reasoning: Given the red light and the visible queue, the conservative creep in A preserves safe following distance and respects the signal, while B's extra forward push is not meaningful and risks unnecessary late braking. Therefore, A better matches the context and is the more reasonable plan.

图 3: 展示 DriveCritic 上下文理解与评估能力的定性示例。由于篇幅限制, 仅展示代表性推理步骤。关键鸟瞰图图例: 自车——位于中心 (0 米, 0 米) 朝上的红色矩形; 轨迹航点——绿色虚线带圆点 (4 秒视野内 8 个航点, 间隔 0.5 秒), 起始于自车后轴中心。建议放大并以彩色查看。

表 IV: DriveCritic 测试集上的总体准确率。“微调”表示模型是否在原始预训练之外基于 DriveCritic 数据进行了微调。

Method	Fine-tuning	Accuracy
EPDMS [13]		0.414
OpenAI-o3 (zero-shot) [20]		0.533
GPT-5 (zero-shot) [19]		0.552
Qwen2.5-VL-7B (zero-shot)		0.480
Supervised Pairwise Classifier		0.648
DriveCritic (ours)		0.760

主要评估指标是准确率, 定义为模型判断与人类偏好轨迹一致的成对比较所占比例。

1) 基线: 我们将 DriveCritic 与涵盖基于规则的度量、通用大语言模型和受控监督模型的广泛基线进行比较:

基于规则: EPDMS [13] 作为最先进的基于规则的基准。由于 EPDMS 为每条轨迹输出一个标量分数, 我们选择得分较高的轨迹作为其偏好。

通用视觉语言模型: 我们在与 DriveCritic 相同的评估提示下, 评估了最先进的闭源 (OpenAI-o3 [20] 和 GPT-5 [19]) 和开源 (Qwen2.5-VL-7B [22]) 视觉语言模型。该基线捕捉了前沿视觉语言模型在未进行领域特定微调情况下的开箱即用推理能力。

监督式成对分类器: 我们实现了一个监督式成对分类器, 作为不依赖视觉语言模型的数据驱动基线。该模型采用 ResNet-101 [48] 编码器处理拼接的相机图像和带有候选轨迹叠加的鸟瞰图, 并通过基于多层感知机的融合层与自车状态和 EPDMS 子分数的特征编码进行拼接。分类器在 DriveCritic 数据集的训练划分上使用交叉熵损失训练 20 个训练轮次, 结果报告自最佳检查点。该基线提供了一种基于学习的替代方案, 突显了 DriveCritic 中视觉语言模型骨干的优势。

表 V: DriveCritic 训练方案的消融实验。勾选标记 (✓) 表示启用的组件。奖励下的“准确率”表示基于准确率的奖励。最后一列报告 DriveCritic 测试集上的准确率。

ID	SFT	RL		Rewards		Accuracy
		GRPO	DAPO	Format	Acc.	
A						0.480
B						0.464
C						0.645
D						0.739
E						0.750
F						0.760

ID legend

A = 基础 Qwen2.5-VL-7B (零样本); B = 仅 GRPO (格式 + 准确率奖励); C = 仅 SFT; D = SFT + GRPO (准确率奖励); E = SFT + GRPO (格式 + 准确率奖励); F = SFT + DAPO (格式 + 准确率奖励)。

2) 结果: 表 IV 报告了所有基线和 DriveCritic 在 DriveCritic 测试集上的总体准确率。基于规则的 EPDMS 度量表现最弱, 反映了改进基于规则的驾驶度量中上下文感知的迫切需求。通用视觉语言模型 (GPT-5、OpenAI-o3、Qwen2.5-VL-7B) 表现出更强的上下文感知能力, 但仍不如所提出的方法可靠。监督式成对分类器比零样本视觉语言模型取得了更高的准确率, 表明微调有助于使模型对齐人类偏好。DriveCritic 以显著优势超越所有基线, 达到 76.0% 的准确率, 验证了 DriveCritic 模型和所提出的训练范式的有效性。

C. 定性结果

在图 3 中, 我们展示了两个定性示例, 其中正确的上下文理解使得在 DriveCritic 数据集上能够对齐到真实标签。这些示例表明, 仅靠固定阈值 (例如车道偏移、进度) 在细微场景中可能会错误排序轨迹, 而上下文感知推理模型 (DriveCritic) 可用于在这些具有挑战性的场景中补充基于规则的评估方法。我们

表 VI: 在 DriveCritic 测试集上进行轨迹位置翻转的鲁棒性。“无翻转准确率”和“翻转准确率”分别是交换轨迹顺序前后的标准准确率。RR 表示如上定义的鲁棒率。

Model	No-flip acc.	Flip acc.	RR (%)
Supervised Pairwise Classifier	0.648	0.613	55.8
Qwen2.5-VL-7B (base)	0.480	0.487	74.9
Qwen2.5-VL-7B + SFT	0.645	0.649	78.0
DriveCritic (ours)	0.760	0.765	81.8

在补充视频中包含了更多定性结果。

D. 消融实验

我们进一步进行了消融实验，以分解 DriveCritic 模型中各组件的贡献。我们注意到，仅应用强化学习微调 (B) 可能会降低准确率，这凸显了监督微调训练 (C) 预热模型能力的必要性。在监督微调的基础上，所有强化学习变体 (D–F) 都带来了明显的提升，其中完整的 DriveCritic 方案 (F，监督微调 + DAPO [24] + 格式和准确率奖励) 在 DriveCritic 数据集上取得了最佳的测试准确率。

E. 鲁棒性分析

对于基于学习的驾驶评估器，一个重要的要求是无论输入顺序或格式如何，都能产生一致的判断，这也是近期关于大语言模型/视觉语言模型评判器的研究中提出的关注点 [36], [37]。为了量化鲁棒性，我们进行了位置翻转测试：对于每个测试对，我们在提示中交换轨迹 A 和轨迹 B 的顺序，并重新评估模型。设 y^i 为原始预测， $\hat{y}^i$ 为翻转后的预测。我们遵循 [36] 计算鲁棒率 (RR): $RR = \frac{1}{|D|} \sum_{i=1}^{|D|} \mathbb{I}[y^i = \hat{y}^i]$ ，其中 $|D|$ 是 DriveCritic 测试集与 $\mathbb{I}[\cdot]$ 为指示函数。我们还报告了交换前 (无翻转) 和交换后 (翻转) 的标准准确率。如表 VI 所示，DriveCritic 达到了最高的鲁棒率 (81.8%)，持续优于其他模型。我们观察到，通过两阶段训练流程，鲁棒性稳步提升，表明监督微调 (SFT) 和强化学习 (RL) 微调都有助于增强对轨迹顺序扰动的不变性。此外，所有基于视觉语言模型 (VLM) 的模型在翻转后均保持准确率，而监督分类器则出现显著下降，凸显了 VLM 骨干在此评估任务中的优势。

VI. 局限性与展望

尽管 DriveCritic 改善了对人类偏好的对齐，但仍存在若干局限性。首先，由于依赖视觉语言模型 (VLM)，它继承了常见弱点，如对提示设计敏感、领域偏移，以及在分布外场景中偶尔出现幻觉或不一致的判断。随着更强大、更可靠的 VLM 出现，这些问题有望减少，DriveCritic 无需架构改动即可直接受益于这些进展。其次，精心构建的偏好数据集在规模和多样性上仍然有限，且我们的标注目前仅依赖一位专家标注者。我们未测量评分者间一致性，因此标签偏差和有限的泛化性仍是问题。第三，DriveCritic 目前未利用时间信息，这可能导致在动态场景（如交通灯变化）中出现错误。最后，基于 VLM 的选择性裁决引入了

不可忽视的计算和环境成本。尽管批处理和缓存有所帮助，但在大规模部署时开销仍可能相当大，带来实用性和环境方面的挑战。尽管存在这些局限性，我们看到了未来工作的若干有前景的方向。跨领域、评估模式和驾驶风格扩展 DriveCritic 数据集 [16] 将增强其实用性。此外，我们认为将 DriveCritic 模型整合以创建可扩展的人类对齐轨迹数据库，并结合基于强化学习的规划器 [42]，是一个有趣的未来方向，以展示偏好对齐的评判器可以指导端到端规划器的强化学习微调。进一步探索更轻量模型或从大型 VLM 到较小学生评判器的知识蒸馏，可能降低计算成本并提高基于 VLM 的驾驶评估解决方案的可部署性。

VII. 结论

本文针对现有基于规则的最先进度量（如 EPDMS）缺乏上下文感知的问题展开研究，这类度量在复杂驾驶场景中常与专家人工判断不一致。为此，本文提出了一种新颖的框架 DriveCritic，该框架包含一个视觉语言模型评估器，以及一个由成对人工偏好标注的模糊场景新数据集。通过采用两阶段监督学习和强化学习流程对视觉语言模型进行微调，模型能够学习做出与人类判断一致的评估。实验结果验证了该方法的有效性，表明 DriveCritic 在与人类偏好对齐方面达到了 76.0% 的准确率，显著优于所有基线方法。该模型还对输入排列表现出较高的鲁棒性，证实了本文训练策略的有效性。总体而言，DriveCritic 标志着在开发更可靠、以人为中心的自动驾驶评估工具方面迈出了重要一步。

生成式人工智能声明：生成式人工智能工具仅用于语言编辑。

参考文献

- [1] L. Chen, P. Wu, K. Chitta, B. Jaeger, A. Geiger, and H. Li, “End-to-end autonomous driving: Challenges and frontiers,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2024.
- [2] C. Cui, Y. Ma, X. Cao, W. Ye, Y. Zhou, K. Liang, J. Chen, J. Lu, Z. Yang, K.-D. Liao, T. Gao, E. Li, K. Tang, Z. Cao, T. Zhou, A. Liu, X. Yan, S. Mei, J. Cao, Z. Wang, and C. Zheng, “A survey on multimodal large language models for autonomous driving,” in *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV) Workshops*, January 2024, pp. 958–979.
- [3] H. Caesar, J. Kabzan, K. S. Tan, W. K. Fong, E. Wolff, A. Lang, L. Fletcher, O. Beijbom, and S. Omari, “nuplan: A closed-loop ml-based planning benchmark for autonomous vehicles,” *arXiv preprint arXiv:2106.11810*, 2021.
- [4] Z. Li, K. Li, S. Wang, S. Lan, Z. Yu, Y. Ji, Z. Li, Z. Zhu, J. Kautz, Z. Wu *et al.*, “Hydra-mdp: End-to-end multimodal planning with multi-target hydra-distillation,” *arXiv preprint arXiv:2406.06978*, 2024.
- [5] Z. Li, S. Wang, S. Lan, Z. Yu, Z. Wu, and J. M. Alvarez, “Hydra-next: Robust closed-loop driving with open-loop training,” *arXiv preprint arXiv:2503.12030*, 2025.
- [6] S. Chen, B. Jiang, H. Gao, B. Liao, Q. Xu, Q. Zhang, C. Huang, W. Liu, and X. Wang, “Vadv2: End-to-end vectorized autonomous driving via probabilistic planning,” *arXiv preprint arXiv:2402.13243*, 2024.

- [7] H. Caesar, V. Bankiti, A. H. Lang, S. Vora, V. E. Liong, Q. Xu, A. Krishnan, Y. Pan, G. Baldan, and O. Beijbom, "nuscenes: A multimodal dataset for autonomous driving," in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2020, pp. 11 621–11 631.
- [8] D. Dauner, M. Hallgarten, T. Li, X. Weng, Z. Huang, Z. Yang, H. Li, I. Gilitschenski, B. Ivanovic, M. Pavone, A. Geiger, and K. Chitta, "Navsim: Data-driven non-reactive autonomous vehicle simulation and benchmarking," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2024.
- [9] J.-T. Zhai, Z. Feng, J. Du, Y. Mao, J.-J. Liu, Z. Tan, Y. Zhang, X. Ye, and J. Wang, "Rethinking the open-loop evaluation of end-to-end autonomous driving in nuscenes," *arXiv preprint arXiv:2305.10430*, 2023.
- [10] A. Dosovitskiy, G. Ros, F. Codevilla, A. Lopez, and V. Koltun, "Carla: An open urban driving simulator," in *CoRL*. PMLR, 2017, pp. 1–16.
- [11] S. Ettinger, S. Cheng, B. Caine, C. Liu, H. Zhao, S. Pradhan, Y. Chai, B. Sapp, C. Qi, Y. Zhou *et al.*, "Large scale interactive motion forecasting for autonomous driving: The waymo open motion dataset," in *ICCV*, 2021.
- [12] P. Sun, H. Kretzschmar, X. Dotiwalla, A. Chouard, V. Patnaik, P. Tsui, J. Guo, Y. Zhou, Y. Chai, B. Caine *et al.*, "Scalability in perception for autonomous driving: Waymo open dataset," in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2020, pp. 2446–2454.
- [13] W. Cao, M. Hallgarten, T. Li, D. Dauner, X. Gu, C. Wang, Y. Miron, M. Aiello, H. Li, I. Gilitschenski, B. Ivanovic, M. Pavone, A. Geiger, and K. Chitta, "Pseudo-simulation for autonomous driving," in *CoRL*, 2025.
- [14] "2025 vision-based end-to-end driving challenge," <https://waymo.com/open/challenges/2025/e2e-driving/>, 2025.
- [15] Z. Li, W. Yao, Z. Wang, X. Sun, J. Chen, N. Chang, M. Shen, Z. Wu, S. Lan, and J. M. Alvarez, "Generalized trajectory scoring for end-to-end multimodal planning," *arXiv preprint arXiv:2506.06664*, 2025.
- [16] R. Hao, B. Jing, H. Yu, and Z. Nie, "Styledrive: Towards driving-style aware benchmarking of end-to-end autonomous driving," *arXiv preprint arXiv:2506.23982*, 2025.
- [17] Y. Li, K. Xiong, X. Guo, F. Li, S. Yan, G. Xu, L. Zhou, L. Chen, H. Sun, B. Wang *et al.*, "Recogdrive: A reinforced cognitive framework for end-to-end autonomous driving," *arXiv preprint arXiv:2506.08052*, 2025.
- [18] J. Achiam, S. Adler, S. Agarwal, L. Ahmad, I. Akkaya, F. L. Aleman, D. Almeida, J. Altenschmidt, S. Altman, S. Anadkat *et al.*, "Gpt-4 technical report," *arXiv preprint arXiv:2303.08774*, 2023.
- [19] OpenAI, "Gpt-5," <https://openai.com/gpt-5/>, 2025.
- [20] OpenAI, "Introducing openai o3 and o4-mini," <https://openai.com/index/introducing-o3-and-o4-mini/>, 2025.
- [21] G. Team, R. Anil, S. Borgeaud, J.-B. Alayrac, J. Yu, R. Soricut, J. Schalkwyk, A. M. Dai, A. Hauth, K. Millican *et al.*, "Gemini: a family of highly capable multimodal models," *arXiv preprint arXiv:2312.11805*, 2023.
- [22] S. Bai, K. Chen, X. Liu, J. Wang, W. Ge, S. Song, K. Dang, P. Wang, S. Wang, J. Tang, H. Zhong, Y. Zhu, M. Yang, Z. Li, J. Wan, P. Wang, W. Ding, Z. Fu, Y. Xu, J. Ye, X. Zhang, T. Xie, Z. Cheng, H. Zhang, Z. Yang, H. Xu, and J. Lin, "Qwen2.5-vl technical report," *arXiv preprint arXiv:2502.13923*, 2025.
- [23] Z. Shao, P. Wang, Q. Zhu, R. Xu, J. Song, X. Bi, H. Zhang, M. Zhang, Y. Li, Y. Wu *et al.*, "Deepseekmath: Pushing the limits of mathematical reasoning in open language models," *arXiv preprint arXiv:2402.03300*, 2024.
- [24] Q. Yu, Z. Zhang, R. Zhu, Y. Yuan, X. Zuo, Y. Yue, W. Dai, T. Fan, G. Liu, L. Liu *et al.*, "Dapo: An open-source llm reinforcement learning system at scale," *arXiv preprint arXiv:2503.14476*, 2025.
- [25] Y. Yue, Z. Chen, R. Lu, A. Zhao, Z. Wang, S. Song, and G. Huang, "Does reinforcement learning really incentivize reasoning capacity in llms beyond the base model?" *arXiv preprint arXiv:2504.13837*, 2025.
- [26] X. Jia, Z. Yang, Q. Li, Z. Zhang, and J. Yan, "Bench2drive: Towards multi-ability benchmarking of closed-loop end-to-end autonomous driving," *NeurIPS*, vol. 37, pp. 819–844, 2024.
- [27] Y. Hu, J. Yang, L. Chen, K. Li, C. Sima, X. Zhu, S. Chai, S. Du, T. Lin, W. Wang *et al.*, "Planning-oriented autonomous driving," in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2023, pp. 17 853–17 862.
- [28] Z. Li, Z. Yu, S. Lan, J. Li, J. Kautz, T. Lu, and J. M. Alvarez, "Is ego status all you need for open-loop end-to-end autonomous driving?" in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2024, pp. 14 864–14 873.
- [29] N. Mu, J. Ji, Z. Yang, N. Harada, H. Tang, K. Chen, C. R. Qi, R. Ge, K. Goel, Z. Yang *et al.*, "Most: Multi-modality scene tokenization for motion prediction," in *CVPR*, 2024, pp. 14 988–14 999.
- [30] X. Tian, J. Gu, B. Li, Y. Liu, Y. Wang, Z. Zhao, K. Zhan, P. Jia, X. Lang, and H. Zhao, "DriveVlm: The convergence of autonomous driving and large vision-language models," in *8th Annual Conference on Robot Learning*.
- [31] C. Sima, K. Renz, K. Chitta, L. Chen, H. Zhang, C. Xie, J. Beißwenger, P. Luo, A. Geiger, and H. Li, "DriveVlm: Driving with graph visual question answering," in *European conference on computer vision*. Springer, 2024, pp. 256–274.
- [32] S. Wang, Z. Yu, X. Jiang, S. Lan, M. Shi, N. Chang, J. Kautz, Y. Li, and J. M. Alvarez, "Omnidrive: A holistic vision-language dataset for autonomous driving with counterfactual reasoning," in *Proceedings of the Computer Vision and Pattern Recognition Conference*, 2025, pp. 22 442–22 452.
- [33] B. Jiang, S. Chen, B. Liao, X. Zhang, W. Yin, Q. Zhang, C. Huang, W. Liu, and X. Wang, "Senna: Bridging large vision-language models and end-to-end autonomous driving," *arXiv preprint arXiv:2410.22313*, 2024.
- [34] B. Jiang, S. Chen, Q. Zhang, W. Liu, and X. Wang, "Alphadrive: Unleashing the power of vlms in autonomous driving via reinforcement learning and reasoning," *arXiv preprint arXiv:2503.07608*, 2025.
- [35] K. Qian, S. Jiang, Y. Zhong, Z. Luo, Z. Huang, T. Zhu, K. Jiang, M. Yang, Z. Fu, J. Miao *et al.*, "Agentthink: A unified framework for tool-augmented chain-of-thought reasoning in vision-language models for autonomous driving," *arXiv preprint arXiv:2505.15298*, 2025.
- [36] J. Ye, Y. Wang, Y. Huang, D. Chen, Q. Zhang, N. Moniz, T. Gao, W. Geyer, C. Huang, P.-Y. Chen *et al.*, "Justice or prejudice? quantifying biases in llm-as-a-judge," *arXiv preprint arXiv:2410.02736*, 2024.
- [37] D. Li, B. Jiang, L. Huang, A. Beigi, C. Zhao, Z. Tan, A. Bhattacharjee, Y. Jiang, C. Chen, T. Wu *et al.*, "From generation to judgment: Opportunities and challenges of llm-as-a-judge, 2025," URL <https://arxiv.org/abs/2411.16594>, 2025.
- [38] Y. Liu, H. Zhou, Z. Guo, E. Shareghi, I. Vulić, A. Korhonen, and N. Collier, "Aligning with human judgement: The role of pairwise preference in large language model evaluators," in *First Conference on Language Modeling*.
- [39] S. You, X. Luo, X. Liang, J. Yu, C. Zheng, and J. Gong, "A comprehensive llm-powered framework for driving intelligence evaluation," *arXiv preprint arXiv:2503.05164*, 2025.
- [40] S. Xie, L. Kong, Y. Dong, C. Sima, W. Zhang, Q. A. Chen, Z. Liu, and L. Pan, "Are vlms ready for autonomous driving? an empirical study from the reliability, data, and metric perspectives," *arXiv preprint arXiv:2501.04003*, 2025.
- [41] J. Wang, X. Zhang, Z. Xing, S. Gu, X. Guo, Y. Hu, Z. Song, Q. Zhang, X. Long, and W. Yin, "He-drive: Human-like end-to-end driving with vision language models," *arXiv preprint arXiv:2410.05051*, 2024.
- [42] D. Li, J. Ren, Y. Wang, X. Wen, P. Li, L. Xu, K. Zhan, Z. Xia, P. Jia, X. Lang, N. Xu, and H. Zhao, "Finetuning generative trajectory model with reinforcement learning from human feedback," *arXiv preprint arXiv:2503.10434*, 2025.
- [43] O. Contributors, "Openscene: The largest up-to-date 3d occupancy prediction benchmark in autonomous driving," in *Proceedings of the Conference on Computer Vision and Pattern Recognition, Vancouver, Canada*, 2023, pp. 18–22.
- [44] Z. Qin, R. Jagerman, K. Hui, H. Zhuang, J. Wu, L. Yan, J. Shen, T. Liu, J. Liu, D. Metzler *et al.*, "Large language models are effective text rankers with pairwise ranking prompting," in *Findings of the Association for Computational Linguistics: NAACL 2024*, 2024, pp. 1504–1518.
- [45] Y. Zheng, R. Zhang, J. Zhang, Y. Ye, Z. Luo, Z. Feng, and Y. Ma, "Llamafactory: Unified efficient fine-tuning of 100+ language models," in *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 3: System Demonstrations)*. Bangkok, Thailand: Association for Computational Linguistics, 2024. [Online]. Available: <http://arxiv.org/abs/2403.13372>
- [46] Y. Zheng, J. Lu, S. Wang, Z. Feng, D. Kuang, and Y. Xiong, "Easyrl: An efficient, scalable, multi-modality rl training framework," <https://github.com/hyouga/EasyRL>, 2025.
- [47] G. Sheng, C. Zhang, Z. Ye, X. Wu, W. Zhang, R. Zhang, Y. Peng, H. Lin, and C. Wu, "Hybridflow: A flexible and efficient rlhf framework," *arXiv preprint arXiv: 2409.19256*, 2024.
- [48] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 770–778.