

DynaGuide: 利用主动动态引导操控扩散策略

Maximilian Du
Stanford University
maxjdu@stanford.edu

Shuran Song
Stanford University
shuran@stanford.edu

dynaguide.github.io

摘要

在现实世界中部署大型复杂策略，需要能够根据具体情境需求对其进行操控。最常见的操控方法（如目标条件化）要求在训练机器人策略时预先考虑测试时目标的分布。为克服这一局限，本文提出 DynaGuide，一种在扩散去噪过程中利用外部动力学模型提供引导的扩散策略操控方法。DynaGuide 将动力学模型与基础策略分离，从而具备多重优势：能够朝向多个目标操控、增强基础策略中表现不足的行为，并在低质量目标下保持鲁棒性。独立的引导信号还使 DynaGuide 能够直接用于现成的预训练扩散策略。本文通过一系列仿真与真实实验，将 DynaGuide 的性能与特性同其他操控方法进行对比，在一组关节式 CALVIN 任务上平均操控成功率达 70%，在低质量目标操控下性能超越目标条件化方法 5.4 倍。此外，本文还成功操控现成的真实机器人策略，使其表达对特定物体的偏好，甚至产生全新行为。视频及其他可视化内容见项目网站：<https://dynaguide.github.io>

1 引言

大规模数据集与高表达力策略的兴起，使机器人得以掌握复杂技能，如叠衣服 [3, 56]、制作三明治 [45] 和洗碗 [7]。当这些大型策略部署于动态变化的现实世界时，面临的挑战是如何将其操控至符合特定场景需求。这意味着需要找出策略行为中适用于该场景的子集 [49]。由于策略本身具有高度复杂性，理想情况下应在无需重新训练策略、无需过度采样、也无需在策略训练阶段预先考虑所有可能操控方式的前提下完成操控。

然而，现有大多数策略引导工作至少依赖于上述假设之一。即便是语言或目标条件策略，也是在特定集合上训练得到的




图 1: DynaGuide 通过将动力学模型的引导加入动作去噪过程来操控预训练扩散策略。这种基于动力学的引导可以将多样化的基础策略操控为单一行为（左）、多种行为（中），甚至移除某种行为（右）——全程无需微调。

目标分布，这需要对满足所有未来引导需求的目标分布具有预见性 [46]。在本文工作中，我们摒弃了这些假设。我们提出将引导力与基础行为策略分离，并将引导模型的影响与基础策略的强动作先验相结合，以生成满足推理时目标的引导行为，同时利用基础策略已有的技能。

引导机器人行为需要理解当前动作如何影响未来结果，这一任务非常适合动力学模型 [40, 16]。为使动力学模型适用于策略引导，本文构建了一个潜视觉动力学模型，该模型根据当前观测和动作预测轨迹的最终或远期观测，从而能够理解长时程依赖关系。该动力学模型从非结构化环境交互数据中学习，并作用于投影到表达力强的 DinoV2 潜空间 [38] 中的视觉观测，该潜空间此前已被证明对机器人规划有用 [57]。在此潜空间中，我们可以计算预测的未来观测与其他期望或不期望结果的观测之间的距离，从而创建一个包含引导目标的可微度量。

以往利用外部度量来引导策略的方法会从策略中采样动作，并选择最满足该度量的动作 [40, 35]。相比之下，本文方法利用了基于扩散策略的去噪随机过程。受分类器引导 [9] 以及其他应用中动力学扩散引导 [54] 的启发，本文通过动力学模型计算度量的梯度，并利用该动力学梯度直接修正动作去噪过程。

该独立动力学模型与主动扩散引导共同构成了动态引导（DYNAGUIDE），这是一种将预训练扩散策略导向复杂目标的新方法。相较于现有引导方法，该设计具备若干关键优势：

- **灵活转向结构。**目标条件化公式具有固定的输入结构，在推理过程中无法修改——且大多数策略仅接受单一目标条件。DynaGuide 接受一组引导条件，涵盖任意数量的正目标和/或负目标（§ 4.3）。
- **增强的转向鲁棒性。**目标条件化方法要求输入条件与策略一同训练，当推理过程中引入新的或质量较低的目标时，会导致分布外（OOD）失败。DynaGuide 中的 DinoV2 嵌入器以及引导与策略的分离意味着在相同情况下系统的任何部分都不会出现分布外问题，并且引导度量的平均效应（公式 2）意味着 DynaGuide 仍能提取出有意义的引导信号（§ 4.2）。动力学模型中额外的经验还使得能够引导产生新颖行为（§ 4.5）。
- **即插即用的模块化。**与微调方法不同，DynaGuide 仅修改扩散策略的推理过程，允许在不改变基础策略的情况下更换不同的动力学模型。这种模块化还使得现成的策略无需进一步修改即可被引导（§ 4.5）。
- **增强代表性不足的行为。**基于采样的引导方法 [40, 35] 从基础策略提出的一组动作中选择最佳动作。这不仅需要每一步对策略进行多次推理，而且这些采样方法在表达基础策略中代表性不足的行为时也存在困难（§ 4.4）。相比之下，我们的动力学引导直接影响去噪过程。通过一次去噪序列，我们将动作引导至指定目标，即使该行为在基础策略中较少出现（§ 4.4）。

为了验证这些主张，我们使用模拟的 CALVIN 环境任务 [31] 进行了五项实验，并在真实机器人手臂上进行了三项实验。我们表明 DynaGuide 在 70% 的情况下成功引导基础策略（§ 4.1），并且在低质量目标上比目标条件化高出 5.4 倍（§ 4.2）。它成功地增强了代表性不足的行为，优于采样方法（§ 4.4），并适应多个正目标和负目标（§ 4.3）。DynaGuide 在现有的真实机器人策略上也取得了成功，实现了高达 80% 的引导成功率，甚至创造了新颖行为（§ 4.5）。我们将公开代码和收集的数据。视频和可视化结果可在我们的网站上找到，<https://dynaguide.github.io>

2 相关工作

基于目标表征的条件策略。一种影响机器人行为的常见方法是目标条件化，即策略接收期望结果的表征。常见的表征是自然语言 [5, 58, 23, 37]，它也可用作人在回路执行的引导机制 [46, 8]。语言条件策略需要特殊数据和/或监督来获取和使用语言标签，且仅通过语言可能难以精确指定引导需求。其他假设较少的方法可以通过在学习的潜在嵌入上条件化 [21, 29] 或直接使用未来观测作为目标 [42, 4, 39, 10, 2]，从轨迹中学习目标条件策略。与 DynaGuide 类似，这些条件策略学习实现目标观测所代表的结果。然而，与 DynaGuide 不同，这些方法需要训练一个能够将目标条件作为输入的策略。DynaGuide 的外部动力学模型意味着它可以应用于任何扩散策略之上。它还支持多个期望和不期望的结果，而基于观测的目标条件化通常仅支持一个期望结果。在我们的实验中，我们比较了 DynaGuide 与观测目标条件策略的性能。

利用动力学模型改进机器人策略。模型可通过接收观测潜变量、动作并输出预测的未来潜状态来训练预测未来状态，即潜动力学 [43, 32, 16, 14, 15, 57, 25]。这些潜动力学常用于通过动力学模型模拟轨迹来训练强化学习智能体 [16, 14, 15, 41, 24]，并已在真实机器人上取得成功 [52]。它们还可用于模型预测控制（MPC）直接生成轨迹 [57, 44, 17, 13, 12, 48]，以及结合强化学习与规划的方法 [18, 19]。与 DynaGuide 尤其相关的是利用动力学模型根据预测价值 [35]、视觉语言模型反馈 [53] 或工程化奖励 [40] 来筛选策略样本的方法。与部分先前工作尤其是 Dino-WM [57] 类似，DynaGuide 使用基于变换器的动力学模型来引导动作生成。然而，DynaGuide 并非从基础策略采样、运行强化学习或 MPC，而是通过动作扩散过程直接引导已训练的基础策略。

	Ours	PG	GC	GPC
Untrained Goals (§4.2)	✓	✓	✗	✓
Movable Objects (§4.1)	✓	✗	✓	✓
Multiple Conditions (§4.3)	✓	✓	✗	✓
Enhance Rare Behavior (§4.4)	✓	✓	✓	✗

表 1：方法能力比较。目标条件化（GC）和采样方法（GPC）[40] 可以引导策略行为，但 GC 未针对未训练目标做好准备，且稀有行为对 GPC 具有挑战性。外部引导方法解决了这些不足，与位置引导（PG）[51] 不同，DynaGuide（本文方法）无需精确坐标输入即可引导实现复杂目标。

推理时引导 策略训练完成后，其行为仍可在不修改权重或要求目标条件的情况下改变 [49]。安全价值函数可在预测到异常行为时介入，采用恢复策略或请求人类协助 [36, 27, 11]。扩散策略可通过偏置初始噪声分布 [50]、采样 [28, 40] 或应用无分类器引导 [20] 来引导，从而影响动作扩散过程 [42] 或逆动力学规划过程 [1]。虽然无分类器引导对引导有效，但仍需在提供的条件上训练策略，类似于目标条件。另一种引导方法是分类器引导，它利用外部分类器影响扩散生成过程 [9]。扩散策略中的分类器引导类似于寻找由分类器定义的最优轨迹 [22]。应用于机器人策略时，分类器引导可施加事后约束 [33] 或寻找人类提供的关键点附近的物体 [51]。DynaGuide 是一种分类器引导方法，但它利用训练好的动力学模型作为分类器，以更复杂的目标引导策略。基于动力学的扩散引导已在硬件生成等其他应用中取得成功 [54]，DynaGuide 将其引入机器人策略。

3 DynaGuide 方法

如图 2 所示，我们考虑在扩散策略 $\pi_\theta(\mathbf{a}|o)$ 的推理过程中对其进行引导的问题。给定一组引导条件 $\mathcal{G} = \mathbf{g}^+ \cup \mathbf{g}^-$ ，它们表示为包含部分状态信息的图像观测。其中一些引导条件展示了期望的结果 $\mathbf{g}^+ = \{g_1^+, \dots, g_i^+\}$ ，另一些则是不期望的结果 $\mathbf{g}^- = \{g_1^-, \dots, g_i^-\}$ 。利用 $\mathcal{G}$ ，我们希望创建一个 $\pi'_\theta(\mathbf{a}|o)$ ，使得对于每个 $\mathbf{a} \sim \pi'_\theta(\cdot|o_t)$ ，概率 $p(\mathbf{g}^+|o_t, \mathbf{a})$ 尽可能高，而概率 $p(\mathbf{g}^-|o_t, \mathbf{a})$ 尽可能低。为此，我们训练一个




图 2: 实现动力学引导。(A): DynaGuide 将来自预训练策略的动作去噪梯度 ϵ_p 与引导梯度 $\nabla_{a_t^k} \mathbf{d}$ 相结合, 以提高完成一组引导条件 $\mathcal{G}$ (B) 的可能性: 在引导模块内部, 动力学模型预测未来结果 $\hat{z}_{t+H}$ 并将其与引导条件 $\mathcal{G}$ (期望/不期望的结果) 进行比较。我们使用潜在距离 d 来定义引导度量 $\mathbf{d}$ (方程 2), 并取梯度以获得 DynaGuide 使用的引导信号 $\nabla_{a_t^k} \mathbf{d}$ 。(C): 一个去噪步骤的示例。预训练策略在数据中寻找行为模式, 而引导梯度选择特定的模式。

动力学模型, 并使用该模型来近似这些概率 (§ 3.1), 然后利用该动力学模型的梯度, 通过修改其动作去噪过程来创建 π' (§ 3.2)。

3.1 具备引导能力的动力学模型

创建一个模型来近似 $p(\mathbf{g}^+|o_t, \mathbf{a})$ 和 $p(\mathbf{g}^-|o_t, \mathbf{a})$ 需要满足两个要求: 1) 模型需要从当前观测 o_t 和动作序列 $\mathbf{a}$ 预测未来结果 $\hat{o}_{t+H}$; 2) 我们需要将 o_{t+H} 与引导条件进行比较。这里, H 可以是一个较大的值, 或者 $t+H$ 可以是轨迹的终点。

以往针对规划与强化学习中的未来观测预测工作, 已采用潜动力学模型来满足这两项要求。这些动力学模型 $h_\theta(\phi(o_t), \mathbf{a})$ 在习得的潜空间 $z_t = \phi(o_t)$ 中运行。近期 Dino-WM[57] 的工作证明了预训练 DinoV2 图像嵌入 [38] 中的潜距离对规划的有效性。受 Dino-WM 启发, 我们利用相同的 DinoV2 图像潜空间进行观测比较。具体而言, 我们使用 DinoV2 的块嵌入作为 $z_t = \phi(o_t)$, 并训练一个变换器 $h_\theta(\mathbf{a}, z_t)$ 来预测潜结果表示 $\hat{z}_{t+H}$ 。由于 ϕ 是冻结的, 且训练期间可获取完整轨迹数据, 因此仅需通过回归目标 (式 1) 训练 h_θ 即可。更多细节参见附录 B。

$$\mathcal{L}(o_t, o_{t+H}, \mathbf{a}) = \|\phi(o_{t+H}) - h_\theta(\phi(o_t), \mathbf{a})\|_2^2 \quad (1)$$

在训练好该动力学模型后, 我们定义一种引导度量, 用于比较预测结果与引导条件。给定一个引导条件 g_i^+ , 我们希望近似 $p(g_i^+|o_t, \mathbf{a})$, 这可以通过将预测结果 $\hat{z}_{t+H}$ 与 g_i^+ 进行比较来实现。条件 g_i^+ 是一个视觉观测, 因此我们将其投影到相同的潜空间 $z_i^+ = \phi(g_i^+)$ 。这使我们能够直接比较 z_i^+ 与 $\hat{z}_{t+H}$ 。若粗略假设潜空间具有高斯结构, 则 $\log p(g_i^+|o_t, \mathbf{a})$ 的一个合理近似与 $-\|\hat{z}_{t+H} - z_i^+\|_2^2$ 成正比, 该度量在潜强化学习 [55, 34] 和规划 [57] 中以类似形式出现。

Algorithm 1 DynaGuide (Inference-Time)

```

1: Input: Guidance Conditions  $\mathbf{g}^+, \mathbf{g}^-$ , Dynamics model  $h_\theta$ 
2: Input: Action denoiser  $\epsilon_\phi(a, o)$ , current obs  $o_t$ 
3:  $\mathbf{a}^K \leftarrow \text{Sample from } \mathcal{N}(0, I)$ 
4: for  $k$  in  $K$  to 1 do ▷ Action Denoising
5:   for  $i$  in 1 to  $M$  do ▷ Stochastic Sampling
6:      $\epsilon \leftarrow \epsilon_\phi(\mathbf{a}^k, o_t)$ 
7:      $\mathbf{d} \leftarrow \text{Eq. 2}$ 
8:      $\hat{\epsilon}(\mathbf{a}^k, o_t) \leftarrow \epsilon - s\sqrt{1 - \bar{\alpha}_k} \nabla_{\mathbf{a}^k} \mathbf{d}$ 
9:     if  $i < M$  then
10:       $\mathbf{a}^k \leftarrow \text{Denoise } \mathbf{a}^k \text{ using } \hat{\epsilon}$ 
11:     else
12:       $\mathbf{a}^{k-1} \leftarrow \text{Denoise } \mathbf{a}^k \text{ using } \hat{\epsilon}$ 
13:     end if
14:   end for
15: end for

```

当我们试图在引导条件集合 $\mathbf{g}^+$ 上最大化 $\log p(\mathbf{g}^+|o_t, \mathbf{a})$ 时，可以尝试最大化实现每个结果的联合概率 $\log \sum_i p(g_i^+|o_t, \mathbf{a})$ 。对于不希望出现的结果，情况则相反。我们利用 $\log p(g_i^+|o_t, \mathbf{a})$ 的近似以及方差超参数 σ 得到引导度量 $\mathbf{d}(\mathbf{g}^+, \mathbf{g}^-, o_t, \mathbf{a})$ (Eq. 2)。对数求和指数函数充当软最大值，这一特性对于多样化目标 (§ 4.3) 和较低质量的引导条件 (§ 4.2) 十分有用。关于 $\mathbf{d}$ 的更详细推导及设计选择说明，参见附录 B.3。

$$\mathbf{d} = \log \left[\sum_i \exp \frac{-\|\phi(g_i^+) - h_\theta(\phi(o_t), \mathbf{a})\|_2^2}{\sigma} \right] - \log \left[\sum_j \exp \frac{-\|\phi(g_j^-) - h_\theta(\phi(o_t), \mathbf{a})\|_2^2}{\sigma} \right] \quad (2)$$

我们利用多样化的机器人交互数据训练动力学模型。对于第 4.1 至 4.4 节的 Calvin 实验，我们使用基准中已有的人类采集的演示数据。对于第 4.5 节的真实世界实验，我们使用在 UMI 接口上采集的开源数据 [6]。由于在引导过程中我们会用带噪声的动作查询动力学模型，因此我们在训练时对动作添加高斯噪声进行增强，使用与推理时相同的噪声调度器，噪声步从几何分布中选取。更多实现细节见附录 B。

3.2 引导动作扩散过程

为了从扩散策略 $\pi(\cdot|o_t)$ 中采样动作，策略预测一系列去噪步骤 $\epsilon(\mathbf{a}^k, o_t)$ ，将初始噪声样本 $\mathbf{a}^K \sim \mathcal{N}$ 逐步转化为去噪后的动作序列 $\mathbf{a}^0$ 。扩散模型可以通过分类器 $p(y|a)$ 进行引导，使其偏向于最大化 $p(y|a)$ [9] 的特定样本集合。引导信号来自分类器的梯度 $\nabla_a \log p(y|a)$ ，并在去噪过程中与 $\epsilon(\mathbf{a}^k, o_t)$ 结合。

在我们的场景中， y 是引导条件， $\log p(y|a)$ 是我们在公式 2 中推导出的度量 $\mathbf{d}$ 。与以往工作 [54, 42] 类似，我们采用去噪扩散隐式模型 (DDIM) [47] 作为采样方法。在 DDIM 下，去噪与引导信号的结合形式为

$$\hat{\epsilon}(\mathbf{a}^k, o_t) = \epsilon(\mathbf{a}^k, o_t) - s\sqrt{1 - \bar{\alpha}_k} \nabla_{\mathbf{a}^k} \mathbf{d}(\mathbf{g}^+, \mathbf{g}^-, o_t, \mathbf{a}^k) \quad (3)$$

其中 $\bar{\alpha}_k = \prod_{l=k}^K \alpha_l$ ， α_l 是噪声调度器， s 是引导缩放参数 [9]。 s 越大，遵循引导要求的信号越强。然而，以往工作发现，较高的 s 也会导致轨迹不够平滑甚至不连贯 [51]，从而在轨迹有效性与遵循引导条件之间形成微妙的平衡。这一现象的原因是 $\nabla_a d$ 可能将 ϵ 拉出分布，导致错误的噪声预测，并随着去噪过程的进行不断累积。为解决这一问题，Wang 等人 [51] 提出了随机采样方案，即对每个去噪步骤 k 运行多次 (M 次)，通过 MCMC 采样稳定引导信号对动作去噪过程的影响。经验表明，这一技巧允许将 s 调得更高，从而在不牺牲轨迹有效性的前提下提高引导成功率。DynaGuide 的总体流程见算法 1。我们在附录 A.4 中研究了这些超参数。

4 实验

为理解动态引导 (DynaGuide) 的特性、优势与局限性，本文在卡尔文 (Calvin) 环境中开展了五组实验 (图 3，第 4.1 至 4.4 节)。为验证其在真实机器人上的实用可行性，本文利用动态引导操控一个公开可用的机器人策略完成真实任务 (第 4.5 节)。此外，本文还在一个二维导航玩具环境中进行了实验，详见附录 A.1。在相关之处，本文将动态引导与一组代表性基线方法进行了比较。

- **基础策略。**这是扩散策略 [7]，我们利用动态引导 (DynaGuide) 对其进行引导。该策略在有效行为上提供了相当均匀的分布。

- **DynaGuide-Sampling (GPC) [40]。**与扩散引导不同，本文从基础策略中多次采样，并选取最满足度量 $\mathbf{d}$ (式 2) 的动作序列，这一思想在 GPC-Rank 中通过工程化奖励函数得以展示 [40]。本文利用动力学模型重新实现该思想，并将此基线用于显式检验扩散引导的益处。



图 3：实验设置。在 CALVIN 模拟器 [31] 中，本文提出了四种实验设置，旨在展示 DynaGuide 及其相较于其他引导方法的优势。首先，本文测试以高质量结果观测作为引导条件时的性能（完全指定目标）。其次，通过随机化机器人状态及与目标物体无关的其他状态来降低引导条件的质量（欠指定目标）。最后，本文考察如何以复杂方式引导基础策略，包括实现多种行为和避免某些行为（多目标）。

- **目标条件化。**我们训练一个策略，将额外的视觉观测作为目标。过去在视觉目标条件方面的工作使用未来观测作为目标 [2, 37, 42]。在我们的基线中，我们采用常见方法，将每条轨迹的最后一个观测作为目标。我们将该模型与 DynaGuide 进行比较，在推理时从 g^+ 采样作为目标。我们还在附录 A.2 中测试了一个中间目标条件基线。

- **位置引导 (ITPS) [51]。**过去的工作已经实现了扩散策略引导，将机器人引导到人类提供的 3D 空间中的特定位置。对于不移动的物体，我们通过找到机器人完成期望行为后的平均位置，并在该位置上使用位置引导来复现这种引导。

4.1 实验 1 和 2：在复杂 3D 环境中的引导

我们的前两个实验考察了 DynaGuide 如何在 CALVIN 环境 [31] 中将机器人引导到特定行为。CALVIN 设置允许机器人与带有抽屉、开关、按钮和柜子的桌子进行交互（图 3）。它可以操作这些物体，还可以重新排列随机放置在桌子上的三个彩色立方体。对于这两个实验，我们关注表示期望结果的引导条件 g^+ ，这些条件取自展示目标行为的演示轨迹的最后一个观测。我们通过为每次展开采样 $g_i^+ \in g^+$ 作为目标，将这些相同的观测用于目标条件基线。

在这组实验中，我们关注 DynaGuide 将基础策略引导向与可操作桌面元素（ArticulatedParts）和随机立方体物体（MovableObjects）交互的行为的能力。总体而言，对于两个实验中的每个目标行为，DynaGuide 都显著提高了目标行为出现的频率，超过了基础策略的频率（图 4，顶部，左下）。

在关节部件（ArticulatedParts）任务上，DynaGuide 将基础策略的行为提升了 8.7 倍，并实现了平均 70% 的目标行为成功率。由于关节部件中的物体保持原位，我们可以运行 ITPS 基线 [51]。使用位置引导相比基础策略提升了目标行为，但动力学模型的推理能力使 DynaGuide 在所有任务中均优于它（图 4，顶部）。关节部件的位置一致性还意味着，如果执行了期望行为， g^+ 的结果与当前环境的真实结果高度吻合。因此，目标条件基线处于分布内，表现近乎完美。这是预期的，因为目标条件模型正是为此设置训练的。

可移动物体（MovableObjects）实验提出了一系列新的挑战。立方体物体不再固定位置，而是体积小且在每次环境重置时随机排列。在可移动物体任务中，所有引导性能均有所下降，但出现了两个显著差异。首先，GPC 基线性能降至基础策略水平。像 GPC 这样的采样方法依赖于从基础策略中抽取的动作。如果这些动作具有高方差，那么所选动作也可能具有高方差。与 DynaGuide 的稳定引导相比，方差增大导致动作更加不稳定，并影响精确任务的性能。第二个差异是目标条件性能的急剧下降。与关节部件不同，随机化的立方体意味着 g^+ 中的某些结果在当前设置下无法实现。例如， g^+ 中的某些结果与桌子左侧的蓝色立方体交互，而测试时的设置可能将蓝色立方体放在右侧。这




图 4: Calvin 环境中 DynaGuide 的引导能力与鲁棒性 DynaGuide 在所有实验中显著增强了目标行为（横轴）（第 4.1 节）。目标条件基线在干净的固定关节设置上表现非常好，但在目标质量降低时急剧下降，而 DynaGuide 保持更强的鲁棒性（第 4.2 节）。对于具有可移动立方体物体的更精确任务，DynaGuide 中的主动引导优于使用相同动力学模型的基于采样的方法（第 4.1 节）

不匹配意味着目标条件策略处于分布外，且受到的影响比动态引导（DynaGuide）更大。我们在下一个实验中探索这一现象。

4.2 实验 3: 对低质量引导条件的鲁棒性

可移动物体（MovableObjects）中的立方体随机化造成了期望结果观测与当前环境中可实现结果之间的不匹配，这一挑战对目标条件化的影响不成比例地大于对动态引导的影响。虽然可移动物体存在不可避免的不匹配，但我们在本实验中探索一种刻意的不匹配，以模拟推理时引导的更实用用例。前两个实验使用了从机器人实现期望行为的轨迹中抽取的 g^+ 。对于每个引导条件，机器人位置与目标物体位置的组合完全指示了期望行为。对于实际部署，更容易的做法是拍摄期望场景的照片，而无需收集轨迹演示或将机器人放置在正确位置。我们在欠指定目标（UnderspecifiedObjectives）中模拟了这一需求，将目标关节桌部件设置为期望姿态，并随机化所有其他物体，包括机器人。我们使用此设置中的图像作为

$$g^+.$$

正如预期，低质量的引导条件将目标条件策略推至分布外，导致平均成功率低于 10%（图 4，右下）。相比之下，动力学模型引导方法（动态引导和动态引导采样）仍能相对于基础策略率提高目标行为，并平均优于目标条件策略 5.4 倍。动态引导的表现也比其采样对应方法更一致，进一步说明了主动引导的重要性。我们尝试在附录 A.2 中通过增加训练数据和实现中间目标条件算法来强化目标条件基线，但这些方法均未能本文测试的目标条件基线上产生一致的改进（附录 A.2）。

这些欠明确的目标展示了将策略与引导分离的优势。尽管 DynaGuide 的引导条件仍然不匹配，但输入 (g^+, o_t, a) 各自都处于参数化编码器、基础策略和动力学模型的分布内。因此，不匹配发生在一个大型视觉编码器的潜空间中。由于没有分布外的情况，我们面临一个更简单的挑战：从这些潜空间距离中提取有意义的信号。幸运的是，DynaGuide 还利用了潜空间中所有条件来计算引导度量（公式 2）。虽然每个潜空间距离 d_i 可能充满噪声且不准确，但组合度量会抵消部分噪声，从而产生有意义的引导。




图 5：多目标与代表性不足的行为。DynaGuide 能够引导基础策略实现多种行为，同时最小化其他行为和失败（左）。DynaGuide 还能通过成功执行其他行为来避免不期望的行为（中）。在这些复杂目标和低数据量情况下（右），DynaGuide 的表现优于采样方法。

4.3 实验 4：多目标引导

将引导与策略分离提高了 DynaGuide 对低质量引导条件的鲁棒性，还允许引导信号被组合，从而将策略引导至一组多模态的期望结果，甚至远离一组负面结果。这种能力对于未修改的、以单个观测为目标的、目标条件策略来说是不可能的。

在 **MultiObjectives** 中，我们将多个目标行为添加到 g^+ 中，并用不期望的行为填充 g^- 。良好的引导将允许 g^+ 中所有被表示的行为得以执行，同时最小化 g^- 中的行为以及整体行为失败率（例如，什么都不做）。实际上，DynaGuide 将策略引导至多个目标行为，并公平地表示每种行为（图 5，左），平均成功率高达 80%，且几乎没有完全行为失败。当需要避免 g^- 中的行为时，DynaGuide 在避免不期望行为方面几乎达到完美成功，同时执行各种其他行为（图 5，中）。关于与无分类器引导（Classifier-Free Guidance, CFG）[20] 的额外比较，请参阅附录 A.5。

由于动态引导（DynaGuide）与引导策略对比（GPC）均采用相同的动力学模型进行引导，二者均可引导至多个目标。然而，GPC 的采样方法在期望行为的整体成功率上较低，且允许更多非期望行为的执行，尤其是在尝试避免 g^- 中的结果时（图 5，中）。在避免 g^- 时，GPC 还产生了更多行为失败的情况，即在轨迹时域内未执行任何动作。类似 GPC 的采样方法依赖于基础策略能够轻易产生满足目标的动作。然而，尤其是当机器人靠近物体时，基础策略可能仅采样到单一行为的动作，使得该行为无法被避免。相比之下，扩散过程中的主动引导能够寻找动作分布中的稀有模式，从而更有可能完成本实验中这类复杂目标。

4.4 实验 5：增强代表性不足的行为

在多目标（**MultiObjectives**）实验中，我们观察到 GPC 采样方法难以满足复杂目标，因为它依赖于基础策略提供足够的样本。在代表性不足行为（**UnderrepresentedBehaviors**）实验中，我们明确测试了这一特性。训练后的机器人策略会根据其在训练数据中的代表性提供行为。然而，当我们引导策略时，也希望将其引导至训练数据中代表性不足的行为模式。

为模拟数据代表性不足的情况，我们减少了基础策略训练集中开关（Switch-On）行为的出现频率。正如预期，随着包含更多数据，基础策略提供了更多的开关行为（图 5，右）。GPC 也随着数据代表性的增加而提升，因为它可以通过选择正确的动作来增强该行为。最重要的是，动态引导（DynaGuide）在这些低数据区间始终优于其采样对应方法，在训练基础策略中仅包含 1% 原始开关行为的情况下，实现了 40% 的成功率（图 5，右）。通过直接影响




图 6：真实世界实验 在杯子摆放任务（左、中）中，我们展示了 DynaGuide 能够引导预训练机器人策略表达对杯子颜色的偏好。使用同一策略，我们还展示了通过利用训练好的动力学模型中的额外知识，可以创造新颖的抓取鼠标行为（右）。在动作扩散过程中，DynaGuide 可以利用动力学模型的知识，在动作分布中寻找满足目标的区域，即使这些区域代表性不足。

4.5 实验 6：用真实机器人引导现成策略

在模拟的 Calvin 环境中，我们使用现有数据训练基础策略和动力学模型。DynaGuide 适用于这种设置，但它也应该适用于任何预训练的扩散策略，并且也应该适用于真实机器人。为了验证这两个说法，我们设置了一个真实机器人实验，利用公开可用的预训练策略 [6]，该策略可以拿起杯子并将其放在碟子上。我们使用来自 UMI 采集接口 [6] 的开源数据以及在实验设置上收集的一组演示来训练动力学模型。有关设置的更多细节，请参阅附录 B.5。

我们在这个真实世界设置上进行了三个实验。前两个实验 **CupPreference** 和 **HiddenCup** 向机器人展示了两个不同颜色的杯子，它们与机器人起始夹爪的距离相等。基础策略会随机选择一个杯子并将其放在碟子上。在 **CupPreference** 中应用 DynaGuide 会产生对杯子颜色的偏好（图 6 左），平均目标行为成功率达到 72.5%。在 **HiddenCup** 中，红色杯子隐藏在灰色杯子后面。基础策略通常会选择更近的灰色杯子，但 DynaGuide 中的主动引导使机器人能够在 80% 的时间内找到红色杯子（图 6 中）。

受 DynaGuide 在数据表示仅为 1% 时的性能启发（§ 4.4），我们测试了 DynaGuide 将预训练策略引导至新颖行为的能力：触摸电脑鼠标。在 **NovelBehavior** 中，动力学模型在各种物体操作上进行了训练，包括来自其他开源数据集 [26] 的杯子和电脑鼠标。我们使用了相同的现成基础策略，该策略仅训练用于摆放杯子。尽管被引导的策略仍然表现出对杯子的偏好，但 DynaGuide 能够将与新颖物体的交互次数翻倍。

5 结论与讨论

本文提出了一种新颖的方法，通过使用单独训练的潜在动力学模型来引导预训练的扩散策略。我们展示了 DynaGuide 在模拟和真实实验中增强目标行为性能的能力，在某些或所有设置中优于位置引导和目标条件化等基线。最后，我们证明了 DynaGuide 可以被引导以实现多种行为、避免不良行为，并增强在基础机器人策略训练中代表性不足的行为。真实世界的机器人部署要求机器人在技能上具有高度的可引导性，而 DynaGuide 展示了实现这一能力的一个潜在途径。

5.1 局限性与未来工作

DynaGuide 能够成功引导预训练策略朝向特定目标，但目前难以指定实现该方法。这一局限性源于当前的形式

将引导条件视为表示期望或非期望结果的观测。还存在其他更复杂的引导模式，包括语言和动觉示范。未来工作包括支持多模态引导条件，有望实现对轨迹所有部分的非常精细的引导。未来，我们还希望为基础策略增加记忆过往引导、整合知识并自动应用于新任务的能力。

5.2 致谢

马克西米利安·杜 (Maximilian Du) 受奈特-亨尼西奖学金 (Knight-Hennessy Fellowship) 和美国国家科学基金会研究生研究奖学金计划 (NSF Graduate Research Fellowships Program, GRFP) 资助。本工作部分得到美国国家科学基金会奖项 #2143601、#2037101 和 #2132519 以及丰田研究所 (Toyota Research Institute) 的支持。我们感谢 ARX 公司提供机器人硬件，感谢高翌淮协助在 ARX 机械臂上部署策略。感谢孙展毅就分类器引导进行的讨论，以及斯坦福大学 REAL 实验室全体成员对论文草稿和实验方向提出的详细反馈。本文所表达的观点和结论仅代表作者本人，不应被解读为必然反映资助方的官方政策，无论明示或暗示。

卡尔文实验 (第 4.1 至 4.4 节) 得以实现，得益于卡尔文基准代码库 [31]。扩散策略改编自机器人模仿仓库 [30]。动力学模型受恐龙世界模型实现 [57] 启发，并利用恐龙视觉第二版 [38] 的表征。

参考文献

- [1] Anurag Ajay, Yilun Du, Abhi Gupta, Joshua Tenenbaum, Tommi Jaakkola, and Pulkit Agrawal. Is conditional generative modeling all you need for decision-making? URL <http://arxiv.org/abs/2211.15657>.
- [2] Marcin Andrychowicz, Filip Wolski, Alex Ray, Jonas Schneider, Rachel Fong, Peter Welinder, Bob McGrew, Josh Tobin, OpenAI Pieter Abbeel, and Wojciech Zaremba. Hindsight experience replay. In *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc. URL https://proceedings.neurips.cc/paper_files/paper/2017/hash/453fadbd8a1a3af50a9df4df899537b5-Abstract.html.
- [3] Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, Szymon Jakubczak, Tim Jones, Liyiming Ke, Sergey Levine, Adrian Li-Bell, Mohith Mothukuri, Suraj Nair, Karl Pertsch, Lucy Xiaoyang Shi, James Tanner, Quan Vuong, Anna Walling, Haohuan Wang, and Ury Zhilinsky. Pi-0: A vision-language-action flow model for general robot control, . URL <http://arxiv.org/abs/2410.24164>.
- [4] Kevin Black, Mitsuhiko Nakamoto, Pranav Atreya, Homer Walke, Chelsea Finn, Aviral Kumar, and Sergey Levine. Zero-shot robotic manipulation with pretrained image-editing diffusion models, . URL <http://arxiv.org/abs/2310.10639>.
- [5] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Joseph Dabis, Chelsea Finn, Keerthana Gopalakrishnan, Karol Hausman, Alexander Herzog, Jasmine Hsu, Julian Ibarz, Brian Ichter, Alex Irpan, Tomas Jackson, Sally Jesmonth, Nikhil Joshi, Ryan Julian, Dmitry Kalashnikov, Yuheng Kuang, Isabel Leal, Kuang-Huei Lee, Sergey Levine, Yao Lu, Utsav Malla, Deeksha Manjunath, Igor Mordatch, Ofir Nachum, Carolina Parada, Jodilyn Peralta, Emily Perez, Karl Pertsch, Jornell Quiambao, Kanishka Rao, Michael Ryoo, Grecia Salazar, Pannag Sanketi, Kevin Sayed, Jaspiar Singh, Sumedh Sontakke, Austin Stone, Clayton Tan, Huong Tran, Vincent Vanhoucke, Steve Vega, Quan Vuong, Fei Xia, Ted Xiao, Peng Xu, Sichun Xu, Tianhe Yu, and Brianna Zitkovich. RT-1: Robotics transformer for real-world control at scale. In *Robotics: Science and Systems XIX*. Robotics: Science and Systems Foundation. ISBN 978-0-9923747-9-2. doi: 10.15607/RSS.2023.XIX.025. URL <http://www.roboticsproceedings.org/rss19/p025.pdf>.
- [6] Cheng Chi, Zhenjia Xu, Chuer Pan, Eric Cousineau, Benjamin Burchfiel, Siyuan Feng, Russ Tedrake, and Shuran Song. Universal manipulation interface: In-the-wild robot teaching without in-the-wild robots. In *Robotics: Science and Systems XX*. Robotics: Science and Systems Foundation. ISBN 979-8-9902848-0-7. doi: 10.15607/RSS.2024.XX.045. URL <http://www.roboticsproceedings.org/rss20/p045.pdf>.

- [7] Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin CM Burchfiel, and Shuran Song. Diffusion Policy: Visuomotor Policy Learning via Action Diffusion. In *Proceedings of Robotics: Science and Systems*, Daegu, Republic of Korea, July 2023. doi: 10.15607/RSS.2023.XIX.026.
- [8] Yuchen Cui, Siddharth Karamcheti, Raj Palleti, Nidhya Shivakumar, Percy Liang, and Dorsa Sadigh. No, to the right: Online language corrections for robotic manipulation via shared autonomy. In *Proceedings of the 2023 ACM/IEEE International Conference on Human-Robot Interaction*, HRI '23, pages 93–101. Association for Computing Machinery. ISBN 978-1-4503-9964-7. doi: 10.1145/3568162.3578623. URL <https://dl.acm.org/doi/10.1145/3568162.3578623>.
- [9] Prafulla Dhariwal and Alexander Nichol. Diffusion models beat GANs on image synthesis. In *Advances in Neural Information Processing Systems*, volume 34, pages 8780–8794. Curran Associates, Inc. URL <https://proceedings.nips.cc/paper/2021/hash/49ad23d1ec9fa4bd8d77d02681df5cfa-Abstract.html>.
- [10] Yiming Ding, Carlos Florensa, Pieter Abbeel, and Mariano Phielipp. Goal-conditioned imitation learning. In *Advances in Neural Information Processing Systems*, volume 32. Curran Associates, Inc. URL https://proceedings.neurips.cc/paper_files/paper/2019/hash/c8d3a760ebab631565f8509d84b3b3f1-Abstract.html.
- [11] Maximilian Du, Alexander Khazatsky, Tobias Gerstenberg, and Chelsea Finn. To err is robotic: Rapid value-based trial-and-error during deployment. URL <http://arxiv.org/abs/2406.15917>.
- [12] Frederik Ebert, Chelsea Finn, Sudeep Dasari, Annie Xie, Alex Lee, and Sergey Levine. Visual foresight: Model-based deep reinforcement learning for vision-based robotic control. URL <http://arxiv.org/abs/1812.00568>.
- [13] Chelsea Finn and Sergey Levine. Deep visual foresight for planning robot motion. In *2017 IEEE International Conference on Robotics and Automation (ICRA)*, pages 2786–2793. doi: 10.1109/ICRA.2017.7989324. URL <https://ieeexplore.ieee.org/document/7989324/>.
- [14] Danijar Hafner, Timothy Lillicrap, Jimmy Ba, and Mohammad Norouzi. Dream to control: Learning behaviors by latent imagination. . URL <http://arxiv.org/abs/1912.01603>.
- [15] Danijar Hafner, Timothy Lillicrap, Mohammad Norouzi, and Jimmy Ba. Mastering atari with discrete world models, . URL <http://arxiv.org/abs/2010.02193>.
- [16] Danijar Hafner, Jurgis Pasukonis, Jimmy Ba, and Timothy Lillicrap. Mastering diverse control tasks through world models. 640(8059):647–653, . ISSN 1476-4687. doi: 10.1038/s41586-025-08744-2. URL <https://www.nature.com/articles/s41586-025-08744-2>. Publisher: Nature Publishing Group.
- [17] Danijar Hafner, Timothy Lillicrap, Ian Fischer, Ruben Villegas, David Ha, Honglak Lee, and James Davidson. Learning latent dynamics for planning from pixels. *arXiv preprint arXiv:1811.04551*, 2018.
- [18] Nicklas Hansen, Xiaolong Wang, and Hao Su. Temporal difference learning for model predictive control. In *ICML*, 2022.
- [19] Nicklas Hansen, Hao Su, and Xiaolong Wang. Td-mpc2: Scalable, robust world models for continuous control, 2024.
- [20] Jonathan Ho and Tim Salimans. Classifier-free diffusion guidance. URL <http://arxiv.org/abs/2207.12598>.
- [21] Eric Jang, Alex Irpan, Mohi Khansari, Daniel Kappler, Frederik Ebert, Corey Lynch, Sergey Levine, and Chelsea Finn. BC-z: Zero-shot task generalization with robotic imitation learning. In *Proceedings of the 5th Conference on Robot Learning*, pages 991–1002. PMLR. URL <https://proceedings.mlr.press/v164/jang22a.html>. ISSN: 2640-3498.

- [22] Michael Janner, Yilun Du, Joshua Tenenbaum, and Sergey Levine. Planning with diffusion for flexible behavior synthesis. In *International Conference on Machine Learning*, 2022.
- [23] Gi-Cheon Kang, Junghyun Kim, Kyuhwan Shim, Jun Ki Lee, and Byoung-Tak Zhang. CLIP-RT: Learning language-conditioned robotic policies from natural language supervision. URL <http://arxiv.org/abs/2411.00508>.
- [24] Alex X. Lee, Anusha Nagabandi, Pieter Abbeel, and Sergey Levine. Stochastic latent actor-critic: Deep reinforcement learning with a latent variable model. In *Advances in Neural Information Processing Systems*, volume 33, pages 741–752. Curran Associates, Inc. URL <https://proceedings.neurips.cc/paper/2020/hash/08058bf500242562c0d031ff830ad094-Abstract.html>.
- [25] Shuang Li, Yihuai Gao, Dorsa Sadigh, and Shuran Song. Unified video action model. URL <http://arxiv.org/abs/2503.00200>.
- [26] Fanqi Lin, Yingdong Hu, Pingyue Sheng, Chuan Wen, Jiacheng You, and Yang Gao. Data scaling laws in imitation learning for robotic manipulation. *arXiv preprint arXiv:2410.18647*, 2024.
- [27] Huihan Liu, Yu Zhang, Vaarij Betala, Evan Zhang, James Liu, Crystal Ding, and Yuke Zhu. Multi-task interactive robot fleet learning with visual world models. In *8th Annual Conference on Robot Learning (CoRL)*, 2024.
- [28] Yuejiang Liu, Jubayer Ibn Hamid, Annie Xie, Yoonho Lee, Maximilian Du, and Chelsea Finn. Bidirectional decoding: Improving action chunking via guided test-time sampling, 2025. URL <https://arxiv.org/abs/2408.17355>.
- [29] Corey Lynch, Mohi Khansari, Ted Xiao, Vikash Kumar, Jonathan Tompson, Sergey Levine, and Pierre Sermanet. Learning latent plans from play. In *Proceedings of the Conference on Robot Learning*, pages 1113–1132. PMLR. URL <https://proceedings.mlr.press/v100/lynch20a.html>. ISSN: 2640-3498.
- [30] Ajay Mandlekar, Danfei Xu, Josiah Wong, Soroush Nasiriany, Chen Wang, Rohun Kulkarni, Li Fei-Fei, Silvio Savarese, Yuke Zhu, and Roberto Martín-Martín. What matters in learning from offline human demonstrations for robot manipulation. In *arXiv preprint arXiv:2108.03298*, 2021.
- [31] Oier Mees, Lukas Hermann, Erick Rosete-Beas, and Wolfram Burgard. CALVIN: A benchmark for language-conditioned policy learning for long-horizon robot manipulation tasks. URL <http://arxiv.org/abs/2112.03227>.
- [32] Vincent Micheli, Eloi Alonso, and François Fleuret. Transformers are sample-efficient world models. In *The Eleventh International Conference on Learning Representations*, 2023. URL <https://openreview.net/forum?id=vhFu1AcB0xb>.
- [33] Utkarsh Aashu Mishra, Shangjie Xue, Yongxin Chen, and Danfei Xu. Generative skill chaining: Long-horizon skill planning with diffusion models. In *Proceedings of The 7th Conference on Robot Learning*, pages 2905–2925. PMLR. URL <https://proceedings.mlr.press/v229/mishra23a.html>. ISSN: 2640-3498.
- [34] Ashvin Nair, Vitchyr Pong, Murtaza Dalal, Shikhar Bahl, Steven Lin, and Sergey Levine. Visual reinforcement learning with imagined goals. URL <http://arxiv.org/abs/1807.04742>.
- [35] Mitsuhiko Nakamoto, Oier Mees, Aviral Kumar, and Sergey Levine. Steering your generalists: Improving robotic foundation models via value guidance. *Conference on Robot Learning (CoRL)*, 2024.
- [36] Kensuke Nakamura, Lasse Peters, and Andrea Bajcsy. Generalizing safety beyond collision-avoidance via latent-space reachability analysis. 2025.

- [37] Iman Nematollahi, Branton DeMoss, Akshay L Chandra, Nick Hawes, Wolfram Burgard, and Ingmar Posner. Lumos: Language-conditioned imitation learning with world models. In *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*, Atlanta, USA, 2025. URL <http://ais.informatik.uni-freiburg.de/publications/papers/nematollahi25icra.pdf>.
- [38] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, Mahmoud Assran, Nicolas Ballas, Wojciech Galuba, Russell Howes, Po-Yao Huang, Shang-Wen Li, Ishan Misra, Michael Rabbat, Vasu Sharma, Gabriel Synnaeve, Hu Xu, Hervé Jegou, Julien Mairal, Patrick Labatut, Armand Joulin, and Piotr Bojanowski. DINOv2: Learning robust visual features without supervision. URL <http://arxiv.org/abs/2304.07193>.
- [39] Deepak Pathak, Parsa Mahmoudieh, Guanghao Luo, Pulkit Agrawal, Dian Chen, Yide Shentu, Evan Shelhamer, Jitendra Malik, Alexei A. Efros, and Trevor Darrell. Zero-shot visual imitation. In *ICLR*, 2018.
- [40] Han Qi, Haocheng Yin, Yilun Du, and Heng Yang. Strengthening generative robot policies through predictive world modeling. URL <http://arxiv.org/abs/2502.00622>.
- [41] Rafael Rafailov, Tianhe Yu, Aravind Rajeswaran, and Chelsea Finn. Offline reinforcement learning from images with latent space models. In *Proceedings of the 3rd Conference on Learning for Dynamics and Control*, pages 1154–1168. PMLR. URL <https://proceedings.mlr.press/v144/rafailov21a.html>. ISSN: 2640-3498.
- [42] Moritz Reuss, Maximilian Li, Xiaogang Jia, and Rudolf Lioutikov. Goal conditioned imitation learning using score-based diffusion policies. In *Robotics: Science and Systems*, 2023.
- [43] Jan Robine, Marc Höftmann, Tobias Uelwer, and Stefan Harmeling. Transformer-based world models are happy with 100k interactions. In *The Eleventh International Conference on Learning Representations*, 2023. URL <https://openreview.net/forum?id=TdBaDGCpjly>.
- [44] Julian Schrittwieser, Ioannis Antonoglou, Thomas Hubert, Karen Simonyan, Laurent Sifre, Simon Schmitt, Arthur Guez, Edward Lockhart, Demis Hassabis, Thore Graepel, Timothy Lillicrap, and David Silver. Mastering atari, go, chess and shogi by planning with a learned model. 588(7839):604–609. ISSN 1476-4687. doi: 10.1038/s41586-020-03051-4. URL <https://www.nature.com/articles/s41586-020-03051-4>. Publisher: Nature Publishing Group.
- [45] Lucy Xiaoyang Shi, Brian Ichter, Michael Equi, Liyiming Ke, Karl Pertsch, Quan Vuong, James Tanner, Anna Walling, Haohuan Wang, Niccolo Fusai, Adrian Li-Bell, Danny Driess, Lachy Groom, Sergey Levine, and Chelsea Finn. Hi robot: Open-ended instruction following with hierarchical vision-language-action models. URL <http://arxiv.org/abs/2502.19417>.
- [46] Lucy Xiaoyang Shi, Zheyuan Hu, Tony Z. Zhao, Archit Sharma, Karl Pertsch, Jianlan Luo, Sergey Levine, and Chelsea Finn. Yell at your robot: Improving on-the-fly from language corrections. *arXiv preprint arXiv: 2403.12910*, 2024.
- [47] Jiaming Song, Chenlin Meng, and Stefano Ermon. Denoising diffusion implicit models. URL <http://arxiv.org/abs/2010.02502>.
- [48] E. Todorov and Weiwei Li. A generalized iterative LQG method for locally-optimal feedback control of constrained nonlinear stochastic systems. In *Proceedings of the 2005, American Control Conference, 2005.*, pages 300–306 vol. 1. doi: 10.1109/ACC.2005.1469949. URL <https://ieeexplore.ieee.org/document/1469949>. ISSN: 2378-5861.
- [49] Masatoshi Uehara, Yulai Zhao, Chenyu Wang, Xiner Li, Aviv Regev, Sergey Levine, and Tommaso Biancalani. Inference-time alignment in diffusion models with reward-guided generation: Tutorial and review. URL <http://arxiv.org/abs/2501.09685>.
- [50] Andrew Wagenmaker, Mitsuhiko Nakamoto, Yunchu Zhang, Seohong Park, Waleed Yagoub, Anusha Nagabandi, Abhishek Gupta, and Sergey Levine. Steering your diffusion policy with latent space reinforcement learning, 2025. URL <https://arxiv.org/abs/2506.15799>.

- [51] Yanwei Wang, Lirui Wang, Yilun Du, Balakumar Sundaralingam, Xuning Yang, Yu-Wei Chao, Claudia Perez-D'Arpino, Dieter Fox, and Julie Shah. Inference-time policy steering through human interactions. URL <http://arxiv.org/abs/2411.16627>.
- [52] Philipp Wu, Alejandro Escontrela, Danijar Hafner, Ken Goldberg, and Pieter Abbeel. Day-dreamer: World models for physical robot learning. *Conference on Robot Learning*, 2022.
- [53] Yilin Wu, Ran Tian, Gokul Swamy, and Andrea Bajcsy. From foresight to forethought: Vlm-in-the-loop policy steering via latent alignment, 2025. URL <https://arxiv.org/abs/2502.01828>.
- [54] Xiaomeng Xu, Huy Ha, and Shuran Song. Dynamics-guided diffusion model for sensor-less robot manipulator design. In *8th Annual Conference on Robot Learning*.
- [55] Ruihan Zhao, Ufuk Topcu, Sandeep Chinchali, and Mariano Phielipp. Learning sparse control tasks from pixels by latent nearest-neighbor-guided explorations, . URL <http://arxiv.org/abs/2302.14242>.
- [56] Tony Z. Zhao, Jonathan Tompson, Danny Driess, Pete Florence, Seyed Kamyar Seyed Ghasemipour, Chelsea Finn, and Ayzaan Wahid. ALOHA unleashed: A simple recipe for robot dexterity. In *Proceedings of The 8th Conference on Robot Learning*, pages 1910–1924. PMLR, . URL <https://proceedings.mlr.press/v270/zhao25b.html>. ISSN: 2640-3498.
- [57] Gaoyue Zhou, Hengkai Pan, Yann LeCun, and Lerrel Pinto. DINO-WM: World models on pre-trained visual features enable zero-shot planning. URL <http://arxiv.org/abs/2411.04983>.
- [58] Brianna Zitkovich, Tianhe Yu, Sichun Xu, Peng Xu, Ted Xiao, Fei Xia, Jialin Wu, Paul Wohlhart, Stefan Welker, Ayzaan Wahid, Quan Vuong, Vincent Vanhoucke, Huong Tran, Radu Soricut, Anikait Singh, Jaspiar Singh, Pierre Sermanet, Pannag R. Sanketi, Grecia Salazar, Michael S. Ryoo, Krista Reymann, Kanishka Rao, Karl Pertsch, Igor Mordatch, Henryk Michalewski, Yao Lu, Sergey Levine, Lisa Lee, Tsang-Wei Edward Lee, Isabel Leal, Yuheng Kuang, Dmitry Kalashnikov, Ryan Julian, Nikhil J. Joshi, Alex Irpan, Brian Ichter, Jasmine Hsu, Alexander Herzog, Karol Hausman, Keerthana Gopalakrishnan, Chuyuan Fu, Pete Florence, Chelsea Finn, Kumar Avinava Dubey, Danny Driess, Tianli Ding, Krzysztof Marcin Choromanski, Xi Chen, Yevgen Chebotar, Justice Carbajal, Noah Brown, Anthony Brohan, Montserrat Gonzalez Arenas, and Kehang Han. RT-2: Vision-language-action models transfer web knowledge to robotic control. In *Proceedings of The 7th Conference on Robot Learning*, pages 2165–2183. PMLR. URL <https://proceedings.mlr.press/v229/zitkovich23a.html>. ISSN: 2640-3498.

神经信息处理系统大会论文清单

1. 声明

问题：摘要和引言中提出的主要声明是否准确反映了论文的贡献与范围？

回答：[是] 理由：关节式任务的平均转向成功率： § 4.1。目标条件改进： § 4.2。引言中的其他所有结果均已指向论文结果部分： § 4.1-4.5。

指南：

- 回答不适用（NA）表示摘要和引言未包含论文中提出的声明。
- 摘要和/或引言应清晰陈述所提出的声明，包括论文的贡献以及重要假设和局限性。对此问题回答“否”或“不适用”将不会得到审稿人的良好评价。
- 所提出的声明应与理论和实验结果相匹配，并反映这些结果在多大程度上可推广至其他场景。

- 将理想化目标作为动机是可以接受的，只要明确说明这些目标并未在本文中实现。

2. 局限性

问题：论文是否讨论了作者所做工作的局限性？回答：[是] 理由：局限性在 § 5 中明确讨论，并在论文其他部分（包括结果 § 4.1-4.5）中提及。指南：

• 答案 NA 表示论文没有局限性，而答案 No 表示论文有局限性但未在论文中讨论。• 鼓励作者在论文中单独设立“局限性”一节。• 论文应指出任何强假设，以及结果对这些假设违反的稳健性（例如，独立性假设、无噪声设置、模型设定正确、渐近近似仅在局部成立）。作者应反思这些假设在实践中可能如何被违反，以及其影响是什么。• 作者应反思所提出主张的范围，例如，该方法是否仅在少数数据集或少数运行上进行了测试。一般来说，实证结果往往依赖于隐含假设，这些假设应予以明确阐述。• 作者应反思影响方法性能的因素。例如，人脸识别算法在图像分辨率低或光线不足时可能表现不佳。或者，语音转文本系统可能无法可靠地用于为在线讲座提供闭路字幕，因为它无法处理技术术语。• 作者应讨论所提算法的计算效率以及它们如何随数据集规模扩展。• 如果适用，作者应讨论其方法在解决隐私和公平性问题时可能存在的局限性。• 虽然作者可能担心对局限性的完全诚实会被审稿人用作拒稿理由，但更糟糕的结果可能是审稿人发现论文中未承认的局限性。作者应运用自己的最佳判断，并认识到支持透明度的个人行为在制定维护社区诚信的规范中发挥着重要作用。审稿人将被明确指示不要因对局限性的诚实而给予惩罚。3. 理论假设与证明

问题：对于每一项理论结果，论文是否提供了完整的假设集以及完整（且正确）的证明？
答案：[不适用] 理由：尽管第 3.1 节给出了简要的数学推导，并在第 B.3 节中完整展开，但这些仅旨在展示指导度量（公式 2）背后的推理过程。本文并未贡献理论结果。指南：

- 答案“不适用”表示论文不包含理论结果。• 论文中所有的定理、公式和证明都应编号并交叉引用。
- 所有假设都应在任何定理的陈述中明确说明或引用。
- 证明可以出现在正文或补充材料中，但如果出现在补充材料中，鼓励作者提供简短的证明草图以提供直观理解。
- 反之，论文核心部分提供的任何非正式证明都应辅以附录或补充材料中的正式证明。
- 证明所依赖的定理和引理应当适当引用。

4. 实验结果可复现性

问题：论文是否充分披露了复现其主要实验结果所需的所有信息，以至于影响论文的主要主张和/或结论（无论代码和数据是否提供）？答案：[是] 理由：实验设置在正文第 4 节中描述，并在第 B 节中详细说明。对于模拟结果，数据是公开可用的，并将提供使用说明。代码在补充材料中提供，清理后的版本将在不久的将来发布。指南：

• 答案“不适用”表示论文未包含实验。• 若论文包含实验，对此问题回答“否”将不会被审稿人看好：无论是否提供代码和数据，使论文可复现都至关重要。• 若贡献为数据集和/或模型，作者应描述为使结果可复现或可验证所采取的步骤。• 根据贡献的不同，可复现性可通过多种方式实现。例如，若贡献为新颖的架构，完整描述该架构可能已足够；若贡献为特定模型及实证评估，则可能需要使他人能够使用相同数据集复现该模型，或提供模型访问权限。一般而言，发布代码和数据通常是实现此目标的一种良好方式，但可复现性也可通过详细说明如何复现结果、提供托管模型访问权限（例如大语言模型的情况）、发布模型检查点或其他适合所开展研究的方式来实现。• 虽然神经信息处理系统大会（NeurIPS）不要求发布代码，但会议确实要求所有投稿提供某种合理的可复现途径，具体可能取决于贡献的性质。例如：(a) 若贡献主要为新算法，论文应明确说明如何复现该算法。(b) 若贡献主要为新模型架构，论文应清晰完整地描述该架构。(c) 若贡献为新模型（例如大语言模型），则应有途径访问该模型以复现结果，或有途径复现该模型（例如使用开源数据集或说明如何构建数据集）。(d) 我们认识到在某些情况下可复现性可能较为棘手，此时欢迎作者描述其提供的特定可复现方式。对于闭源模型，模型访问可能受到某种限制（例如仅限注册用户），但其他研究人员应有可能通过某种途径复现或验证结果。5. 数据和代码的开放获取

问题：论文是否提供了数据和代码的开放获取，并附有足够的说明以忠实复现主要实验结果，如补充材料中所述？答案：[是] 理由：模拟 CALVIN 环境中的数据取自公开数据集 [31]。在真实世界设置中，预训练策略以及数据 [6] 均公开可用。在实验环境中额外收集了一个数据集，该数据集将在不久的将来公开发布。代码库的工作副本将包含在补充材料中，清理后的代码库实现将在不久的将来提供。指南：

- 答案 NA 表示论文不包含需要代码的实验。
- 请参阅 NeurIPS 代码和数据提交指南 (<https://nips.cc/public/guides/CodeSubmissionPolicy>) 了解更多详情。

- 虽然我们鼓励发布代码和数据，但我们理解这可能无法实现，因此“否”是一个可接受的答案。论文不能仅仅因为未包含代码而被拒绝，除非这对贡献至关重要（例如，对于一个新的开源基准）。
- 说明应包含运行以复现结果所需的确切命令和环境。请参阅 NeurIPS 代码和数据提交指南 (<https://nips.cc/public/guides/CodeSubmissionPolicy>) 了解更多详情。
- 作者应提供数据访问和准备的说明，包括如何访问原始数据、预处理数据、中间数据和生成数据等。
- 作者应提供脚本以复现新提出方法和基线的所有实验结果。如果只有部分实验可复现，应说明哪些实验从脚本中省略及其原因。
- 在提交时，为保持匿名性，作者应发布匿名化版本（如适用）。
- 建议在补充材料（附于论文后）中提供尽可能多的信息，但允许包含数据和代码的 URL。

6. 实验设置/细节

问题：论文是否详细说明了所有训练和测试细节（例如数据划分、超参数及其选择方式、优化器类型等），以便理解结果？答案：[是] 理由：实验设置在正文第 4 节中概述，并在附录 B 中详细说明。详细的训练、测试和模型超参数在 B.1 节中描述。代码说明中将包含其他实用细节。指南：

- 答案“不适用”表示论文未包含实验。
- 实验设置应在论文核心部分呈现，其详细程度应足以理解结果并对其做出合理解释。
- 完整细节可随代码、附录或补充材料提供。

7. 实验统计显著性

问题：论文是否适当地报告了误差线并正确定义，或提供了关于实验统计显著性的其他适当信息？答案：[是] 理由：所有仿真条形图和图表均包含置信区间，关于这些区间的详细信息见 § B.4。如 B.4 所述，真实机器人实验结果资源密集，因此没有区间。这在真实机器人实验中非常常见。指南：

- 答案“不适用”表示论文未包含实验。
- 如果结果附有误差线、置信区间或统计显著性检验，至少对于支持论文主要主张的实验，作者应回答“是”。
- 应清楚说明误差线所反映的变异因素（例如训练/测试划分、初始化、某些参数的随机抽取，或在给定实验条件下的整体运行）。
- 应解释计算误差线的方法（闭式公式、调用库函数、自助法等）。
- 应给出所做的假设（例如误差服从正态分布）。
- 应明确误差线是标准差还是均值的标准误。
- 报告 1σ 误差线是可以的，但应说明。如果误差正态性假设未经验证，作者最好报告 2σ 误差线并说明其对应 96% 置信区间。

- 对于非对称分布，作者应注意不要在表格或图中显示对称误差线，以免产生超出范围的结果（例如负错误率）。
- 若表格或图中报告了误差线，作者应在正文中说明其计算方法，并引用相应的图或表。

8. 实验计算资源 问题：对于每项实验，论文是否提供了复现实验所需的计算机资源（计算工作者类型、内存、执行时间）的充分信息？ 回答：[是] 理由：计算细节见附录 B.1。指南：

- 答案“不适用”表示论文未包含实验。
- 论文应指明计算工作者类型（CPU 或 GPU、内部集群或云提供商），包括相关内存和存储。
- 论文应提供每个单独实验运行所需的计算量，并估算总计算量。
- 论文应披露整个研究项目所需的计算量是否多于论文中报告的实验（例如，未纳入论文的初步或失败实验）。

9. 伦理准则

问题：论文中开展的研究是否在各方面均符合神经信息处理系统大会伦理准则 <https://neurips.cc/public/EthicsGuidelines>？ 回答：[是] 理由：我们确认论文中开展的研究在各方面均符合神经信息处理系统大会伦理准则。指南：

- 回答“不适用”表示作者未审阅神经信息处理系统大会伦理准则。
- 如果作者回答“否”，则应解释需要偏离伦理准则的特殊情况。
- 作者应确保匿名性（例如，若因所在司法辖区的法律或法规而有特殊考虑）。

10. 更广泛影响

问题：论文是否讨论了所开展工作的潜在积极社会影响和消极社会影响？ 回答：[是] 理由：我们在 § C 指南中讨论了更广泛影响：

- 回答“不适用”意味着所开展的工作没有社会影响。
- 如果作者回答“不适用”或“否”，则应解释为何其工作没有社会影响，或为何论文未涉及社会影响。
- 消极社会影响的示例包括潜在的恶意或非预期用途（例如虚假信息、生成虚假个人资料、监控）、公平性考量（例如部署可能做出不公平影响特定群体决策的技术）、隐私考量以及安全考量。
- 会议预期许多论文属于基础研究，不涉及特定应用，更不用说部署。然而，如果存在通往任何负面应用的直接路径，作者应予以指出。例如，指出生成模型质量的提升可能被用于生成虚假信息深度伪造是合理的。另一方面，无需指出用于优化神经网络的通用算法可能使人们更快地训练出生成深度伪造的模型。

- 作者应考虑技术按预期使用且功能正常时可能产生的危害、技术按预期使用但给出错误结果时可能产生的危害，以及技术被（有意或无意）滥用后产生的危害。
- 若存在负面社会影响，作者亦可讨论可能的缓解策略（例如，模型的分级发布、在提供攻击手段的同时提供防御措施、建立监控滥用的机制、建立监控系统如何随时间从反馈中学习的机制、提升机器学习（ML）的效率与可及性）。

11. 安全防护措施

问题：论文是否描述了为高风险滥用（例如，预训练语言模型、图像生成器或爬取的数据集）的数据或模型进行负责任发布而设置的安全防护措施？回答：[不适用] 理由：本文使用公开可用的数据集和公开可用的真实机器人训练策略。动力学模型预测机器人环境中的未来状态，不存在易于滥用或双重用途的途径。指南：

- 回答“不适用”表示论文不存在此类风险。
 - 具有高滥用或双重用途风险的已发布模型，应配备必要的安全防护措施，以允许对模型进行受控使用，例如要求用户遵守使用指南或访问限制，或实施安全过滤器。
 - 从互联网爬取的数据集可能带来安全风险。作者应说明如何避免发布不安全图像。
 - 我们认识到提供有效的安全防护措施具有挑战性，且许多论文并不要求如此，但我们鼓励作者考虑这一点并尽最大努力。
12. 现有资产的许可证 问题：论文中使用的资产（例如，代码、数据、模型）的创建者或原始所有者是否得到了适当的署名，并且许可证和使用条款是否被明确提及并得到适当尊重？回答：[是] 理由：数据集和代码库的署名在全文适当引用，并在附录 D 中详细说明。指南：

- 回答“不适用”表示论文未使用现有资产。
- 作者应引用产生代码包或数据集的原始论文。
- 作者应说明所使用的资产版本，并在可能的情况下提供 URL。
- 每个资产应包含许可证名称（例如 CC-BY 4.0）。
- 对于从特定来源（例如网站）抓取的数据，应提供该来源的版权和服务条款。
- 如果发布资产，应在包中提供许可证、版权信息和使用条款。对于流行的数据集，paperswithcode.com/datasets 已为部分数据集整理了许可证。其许可指南有助于确定数据集的许可证。
- 对于重新打包的现有数据集，应同时提供原始许可证和衍生资产的许可证（如果已更改）。
- 如果这些信息无法在线获取，鼓励作者联系资产创建者。

13. 新资产

问题：论文中引入的新资产是否记录完善，且文档是否随资产一同提供？

答案: [是] 理由: 补充材料中提供了代码的预发布版本及文档, 该文档将在近期进一步完善。指南:

- 答案“不适用”表示论文未发布新资产。
 - 研究人员应通过结构化模板, 在提交材料中说明数据集、代码或模型的详细信息, 包括训练细节、许可证、局限性等。
 - 论文应讨论是否以及如何获得资产所有者的同意。
 - 提交时, 请记得对资产进行匿名化处理(如适用)。您可以创建匿名链接或包含匿名压缩文件。
14. 众包与人类受试者研究

问题: 对于众包实验和人类受试者研究, 论文是否包含提供给参与者的完整说明文本和截图(如适用), 以及补偿细节(如有)? 答案: [不适用] 理由: 本项目未使用众包。指南:

- 答案“不适用”表示论文不涉及众包或人类受试者研究。
 - 在补充材料中包含这些信息是可以的, 但如果论文的主要贡献涉及人类受试者, 则应在正文中尽可能详细地说明。
 - 根据 NeurIPS 伦理准则, 参与数据收集、整理或其他劳动的工作人员应获得不低于数据收集国最低工资的报酬。
15. 机构审查委员会 (IRB) 批准或人类受试者研究的等效批准 问题: 论文是否描述了研究参与者可能面临的风险, 是否向受试者披露了这些风险, 以及是否获得了机构审查委员会 (IRB) 的批准 (或根据所在国家或机构要求进行的等效批准/审查)? 答案: [不适用] 理由: 未使用研究参与者, 因此无需 IRB。指南:

- 答案“不适用”表示论文不涉及众包或人类受试者研究。
- 根据研究开展所在国家的情况, 任何人类受试者研究都可能需要 IRB 批准 (或等效批准)。如果获得了 IRB 批准, 应在论文中明确说明。
- 我们认识到不同机构和地区的相关程序可能存在显著差异, 期望作者遵守 NeurIPS 伦理准则及其所在机构的指南。
- 对于初次提交, 请勿包含任何可能破坏匿名性的信息 (如适用), 例如进行评审的机构。

16. 大语言模型使用声明

问题: 如果大语言模型是本研究中核心方法的重要、原创或非标准组成部分, 论文是否描述了其使用情况? 请注意, 如果大语言模型仅用于写作、编辑或格式调整, 且不影响核心方法论、科学严谨性或原创性, 则无需声明。答案: [不适用]

理由：除协助可视化代码和语法检查外，本项目未使用大语言模型。指南：

- 答案“不适用”意味着本研究的核心方法开发不涉及大语言模型作为任何重要、原创或非标准组成部分。
- 请参阅我们的大语言模型政策 (<https://neurips.cc/Conferences/2025/LLM>)，了解应描述或不应描述的内容。

A 附加实验、可视化与消融研究

A.1 简单二维方块任务中的引导




图 7：方块触碰环境。该二维环境要求智能体（黑色圆圈）导航至彩色目标（方块）。基础策略任意选择一个目标，而动态引导将其引导至特定颜色（A）。这种引导能够表达方块颜色偏好（B）。动力学模型还使基础策略能够完成未在基础策略上显式训练的新任务，包括从紧密排列的方块群中挑选目标（C），以及绕过三个近距离立方体到达远处目标（D）。在可视化图 B 至 D 中，方块的分布由阴影区域表示。方块的平均位置由实心方块表示。

作为理解动态引导中引导机制如何运作的另一种方式，我们考察一个玩具方块触碰环境。在方块触碰环境中，智能体在二维环境中导航并触碰彩色方块。我们在合成数据上训练基于视觉的基础策略和动力学模型，这些数据展示了向任意位置、任意颜色的方块导航的过程。随后，在测试阶段，我们利用动力学模型引导策略朝向特定颜色的立方体。在图 7A 中，我们可视化了在动力学引导下动作块（Action Chunk）的生成过程。在初始噪声较大的步骤中，引导信号与去噪策略信号在动作方向上相互竞争。在该示例中，智能体几乎触碰到黄色方块，因此基础策略希望将动作去噪至黄色方块方向。引导信号则希望将智能体移向蓝色方块。这两个力的矢量和将动作推向蓝色方块。在去噪的后期阶段，引导信号与策略信号开始协同工作，以生成指向蓝色方块的最终动作序列。这种引导在早期决策对命中正确颜色至关重要的情形下有效（图 7B），也在后期决策至关重要的情形下有效（图 7C）。

尽管动力学模型和基础策略都是在随机导航行为上训练的，我们仍可利用动力学模型完成基础策略中未明确包含的新任务。延迟决策设置（图 7C）中的方块间距比训练数据更近，要求较高的导航精度。前往最远方块设置（图 7D）将目标放置在比三个方块远得多的地方，需要刻意绕过较近的方块进行导航。基础策略会前往较近的方块，但动力学模型能够可靠地引导策略在方块之间穿行并到达目标。注意，B-D 中的可视化展示了方块分布，轨迹黄色末端的黑点表示环境中第一次也是唯一一次与方块的接触。

	Red	Grey
DynaGuide	75%	25%
DynaGuide-Sampling	60%	40%
Base Policy	55%	45%

表 2：杯子偏好附加结果。我们在杯子偏好任务的引导红色条件（第 4.5 节）中增加了一个基线。虽然动态引导采样相比基线有所改进，但动态引导实现了最佳引导效果。

A.2 额外的目标条件基线

在实验 1-3 中，我们使用简单的目标条件基线，将最后轨迹状态作为目标表示。为保持与基础策略的公平性，我们还在 Calvin 中仅使用测试环境的数据训练目标条件模型。然而，我们注意到 DynaGuide 中的动力学模型是使用多环境数据训练的。

为保持方法各部分所接触的总数据量的公平性，我们在相同的多环境数据上训练了另一个目标条件策略。在未充分指定目标（**UnderspecifiedObjectives**）上评估时，这些额外数据在某些转向目标上提升了性能，尽管 DynaGuide 仍然优于这个增强的目标条件基线（GC w/ All Data，表 3）。

最后，我们尝试通过实现后见经验回放（Hindsight Experience Replay）[2] 对目标条件基线进行算法改进。在训练期间，我们不仅以最终状态为条件，还采样中间未来状态以扩大目标分布。我们发现这在某些任务上提高了转向成功率，但在其他任务上没有（GC w/ HER，表 3）。总体而言，我们发现目标条件可以通过额外数据或算法改进在特定任务上得到提升，但这些增强并未将该基线的性能提升到 DynaGuide 的水平。

	button_on	button_off	switch_on	switch_off	drawer_open	drawer_close	door_left	door_right
DynaGuide	0.33±0.031	0.36±0.032	0.24±0.017	0.26±0.024	0.26±0.015	0.27±0.017	0.25±0.018	0.19±0.015
Original GC	0.023±0.0080	0.053±0.015	0.073±0.018	0.047±0.0067	0.00±0.00	0.0033±0.0033	0.12±0.012	0.080±0.016
GC w/ All Data	0.054±0.017	0.10±0.012	0.064±0.015	0.047±0.015	0.00±0.00	0.00±0.00	0.095±0.026	0.075±0.021
GC w/ HER	0.0067±0.0042	0.087±0.030	0.027±0.011	0.020±0.0073	0.00±0.00	0.00±0.00	0.21±0.023	0.13±0.021

表 3：更强的目标条件方法。通过额外数据或后见回放 [2] 增强目标条件基线，在转向能力上显示出一定改进，但在未充分指定目标（实验 3）上测试时，它们仍然比 DynaGuide 表现更差。

A.3 额外的真实机器人基线

真实机器人实验（第 4.5 节）证明了 DynaGuide 能够引导预训练策略。为了进一步展示 DynaGuide 在真实机器人上的性能，我们为一个真实机器人任务添加了 DynaGuide-Sampling 基线。如表 2 所示，利用扩散模型影响动作采样相比基线提高了目标任务的成功率，但 DynaGuide 的分类器引导仍然获得了更高的目标任务成功率。

A.4 消融与超参数研究

为了理解 DynaGuide 的各种超参数和组件如何影响最终成功率，我们在 **ArticulatedParts** 实验中的 Switch-On 任务上进行了一组实验。总体而言，我们观察到两个主要超参数 σ (Eq. 2 和 s (Eq. 3 对合理变化具有鲁棒性，这意味着 DynaGuide 并不难调。在 s 值非常低时，成功率较低，因为引导不足。成功率随着强度增加而提高，直到强度过高导致不稳定。非常低的 σ 值会使引导条件距离过远而无法提供有意义的信号，从而降低引导成功率。增加随机采样步数 M 通常会提高引导性能，但会增加计算开销。令人惊讶的是，DynaGuide 对引导条件数量 G 非常鲁棒，即使只有一个引导条件也能达到相当的引导效果。

在实践中，我们为每个实验使用从网格搜索中选择的引导强度和 σ 。这些参数在同一环境中的不同任务之间通常非常相似（表 4），这意味着切换目标任务不需要进行大量的超参数搜索。我们在实验中使用随机采样 $M = 4$ ，以平衡稳定性和计算效率。我们为每个任务使用 20 个引导条件，这对于 Switch-On 来说已经绰绰有余，但对于欠指定目标（§ 4.2）和更困难的目标来说更为重要。

关键的是，我们发现使用加噪动作预训练动力学模型对性能至关重要（图 9）。这是合理的，因为否则噪声将超出分布范围。

在实验 1 至 5 中，我们利用在四个不同卡尔文（Calvin）环境中收集的更多样化数据集来训练动力学模型。这一数据规模提升了训练稳定性并减少了过拟合。然而，由于我们仅在单一卡尔文环境中进行测试，我们进行了

Task	Scale	σ
switch_on	1.5	30
switch_off	1.5	30
drawer_open	1.0	40
drawer_close	1.0	40
button_on	1.0	30
button_off	1.0	30
door_left	1.5	30
door_right	2.0	15

表 4：各任务的采样超参数。在每个环境中，不同任务的最优参数非常相似。

数据消融，并仅使用该环境的数据训练动力学模型。如表 5 所示，减少动力学训练数据也会降低转向成功率，尽管性能仍高于基线（实验 4.1）。该消融表明，DynaGuide 能够从相关环境迁移信息，以帮助在目标环境中引导策略，从而降低在新环境中训练动力学模型的数据需求。

	button_on	button_off	switch_on	switch_off	drawer_open	drawer_close	door_left	door_right
All Environments	0.70±0.031	0.70±0.038	0.74±0.027	0.76±0.037	0.60±0.015	0.66±0.029	0.74±0.025	0.68±0.026
Target Environment Only	0.66±0.023	0.69±0.038	0.54±0.043	0.58±0.031	0.51±0.022	0.53±0.024	0.65±0.019	0.57±0.036

表 5：减少动力学模型训练数据。来自关节部件（ArticulatedParts，第 4.1 节）的消融结果，使用仅在卡尔文 D 划分上训练的动力学模型的 DynaGuide。

A.5 无分类器引导基线

另一个相关基线是无分类器引导（Classifier Free Guidance，CFG）[20]，它利用扩散策略自身的版本来引导扩散过程。我们实现并运行 CFG 作为多目标（MultiObjectives）的基线。CFG 能够引导多个目标，这是目标条件基线无法实现的。表 6 展示了 CFG 基线的额外结果，应与图 5 中 DynaGuide 和 DynaGuide-Sampling 的结果进行比较。正如预期，CFG 能够成功地将策略引导至多个目标，包括实现多种行为并避免其他行为。然而，正向引导（表 6 前三行）的总成功率低于 DynaGuide（图 5）。

CFG 也能够引导策略远离某些行为，如表 6 最后三行所示

表 6。CFG 与 DynaGuide 的非期望行为成功率均在一个标准差以内。然而，DynaGuide 几乎总能提供有效的替代行为（图 5），而 CFG 基线在三种测试条件下（无行为，表 6）有超过 10% 的时间无法执行任何行为。这一结果符合预期，因为 DynaGuide 的对数求和指数潜在选择方法使引导能够找到合适的行为，并最小化其他矛盾行为的影响。相比之下，CFG 实现对所有引导信号赋予相同权重。缺乏潜在距离使得难以选择最相关的引导。矛盾的引导信号可能对扩散过程产生负面影响，导致动作形成不良和行为失败。

	按钮开关 抽屉门 挡块 无行为					
Button or Switch	0.18±0.01	0.37±0.02	0.05±0.02	0.05±0.00	0.29±0.02	0.05±0.01
Button or Door	0.37±0.01	0.09±0.01	0.01±0.00	0.28±0.03	0.23±0.02	0.02±0.01
Switch or Button or Door	0.17±0.02	0.29±0.04	0.03±0.00	0.23±0.02	0.25±0.01	0.03±0.01
NO Drawer	0.16±0.03	0.23±0.02	0.01±0.00	0.09±0.00	0.35±0.02	0.17±0.02
NO Door	0.23±0.03	0.15±0.02	0.12±0.04	0.01±0.00	0.38±0.04	0.11±0.02
NO Drawer NO Door	0.19±0.02	0.25±0.03	0.02±0.01	0.00±0.00	0.42±0.05	0.12±0.00

表 6：附加无分类器引导（CFG）基线。多目标实验中 CFG 基线的行为分布表明，CFG 能够引导至多个目标，但在不增加总体失败率的情况下难以避免特定行为（下方三行）。

B 实现细节

B.1 DynaGuide 实现细节

基础扩散策略 扩散策略经过训练，接收视觉观测和机器人本体感知的 2 步历史堆栈，并预测 16 个动作的块。它使用 Resnet-18 图像编码器，该编码器条件化一个具有 4 个编码层和 4 个解码层的 U-Net。该 U-Net 在训练期间使用标准扩散策略目标 [7] 预测噪声。在推理期间，我们使用带有 DDIM 噪声调度器的噪声预测器来生成动作块。扩散策略总共约有 1800 万个参数。我们使用 Adam 优化器，学习率为 $1e-4$ 。我们以批大小 16 训练模型 200k 个梯度步骤。扩散策略的所有部分均被训练

结合专家数据共同使用。在执行过程中，14 个动作在环境中开环执行，之后再次查询策略。




图 8：超参数扫描与消融实验。我们考察推理时超参数及噪声预训练对最终性能的影响。对于引导强度，我们固定 $\sigma = 40, M = 4$ ，其中 M 为随机采样步数。对于 σ 参数，我们固定 $s = 1.5, M = 4$ ，其中 s 为引导强度。对于随机采样，我们固定 $s = 3, \sigma = 40$ 。我们采用更高的 s 以展示随机采样对稳定性的影响。对于引导条件，我们使用 $s = 1.5, \sigma = 40, M = 4$ 。

动力学模型。我们使用 DinoV2 块嵌入作为潜空间，其提供 256 个大小为 384 的嵌入块。尽管该嵌入尺寸较大（ 256×384 ），以往工作已证明该嵌入在机器人规划中的有效性 [57]。在以往工作及我们的开发过程中，经验表明 DinoV2 中的 CLS 标记（ 1×384 ）所携带的空间信息不足以进行有意义的潜空间引导。对于潜动力学模型，我们采用 6 层、8 头的变换器编码器，输入为 256 个块、一个机器人本体感知标记和一个动作标记。该动作标记通过将每个动作嵌入 $\mathbf{a}^k$ （使用相同的多层感知机）并将嵌入拼接成标记而创建。我们使用学习的位置嵌入。变换器的前 256 个输出作为预测的未来状态。我们将这些块回归到轨迹最后（或后续）观测的 DinoV2 嵌入。对于 CALVIN 实验，我们回归到轨迹的最终潜变量。对于真实世界实验，我们回归到在环境中执行所提出的动作块之后的观测潜变量。我们使用 Adam 优化器，学习率为 $1e-4$ 。由于 DinoV2 嵌入被冻结，变换器可以使用回归目标进行端到端训练。该变换器约有 1600 万个参数。我们以批大小 16 训练模型 600k 梯度步，此时模型已收敛。在开发过程中，我们表明验证性能强烈依赖于动作的存在，这表明动力学模型已学会关注动作。

为了在引导过程中考虑噪声动作，我们向用于训练动力学模型的动作添加噪声。输入的动作中 50% 为无噪声，50% 基于推理时使用的同一 DDIM 调度器添加噪声。我们使用几何随机变量选择加噪步骤，期望噪声步骤为 20。调度器从步骤 100 开始，此时为纯高斯噪声，因此在步骤 20 时，动作虽有噪声但仍具有意义，可供动力学模型使用。

推理时引导 在推理之前，我们获取引导条件并预先计算其嵌入。随后，在推理过程中，我们计算公式 (2) 的目标。经验表明，欧氏距离相较于公式 (2) 中的平方距离能产生更稳定的结果。我们通过动力学模型反向传播该度量，并将相对于输入动作的梯度用作引导信号。与基础策略相同，我们使用 DDIM 采样器将推理时间计算从 100 步减少到 10 步。为实现随机采样，我们在去噪循环内多次重复相同的去噪步骤。

计算硬件 所有策略和动力学模型均在单块 RTX 3090 GPU（24GB 显存）上训练，收敛耗时 24 至 48 小时。动力学模型具有 ≈ 1500 万个可训练参数，训练和推理期间占用 ≈ 4 GB 的 GPU 内存。

所有实验均在单块 RTX 3090 GPU 上进行，每个种子每个任务耗时 10 至 20 分钟。方法开发和实验同样在 RTX 3090 GPU 上进行，开发总计算时数估计为论文所示结果的 10 至 20 倍。大部分计算用于开发动力学模型。

B.2 基线实现

目标条件化 我们使用 Robomimic 中提供的状态条件化实现 [30]，并以轨迹中的最终观测作为额外输入来条件化扩散策略。我们使用与基础扩散策略相同的超参数训练该策略。

位置引导 (ITPS) [51]。ITPS 算法擅长将策略引导至由人类指定的三维目标点。为了将 ITPS 与无需人工指定的方法进行比较，我们手动计算了 20 条展示期望行为的轨迹中机器人的平均最终位置，并将该位置作为 ITPS 的目标点。

采样 (GBC) [40]。先前提出 GBC-Rank 的工作使用目标函数对策略的动作样本进行排序，以选择最佳样本。我们借鉴该思想，将其应用于我们的引导度量（公式 2）。每次推理时，我们对基础策略采样 5 次，并根据该度量选择最佳动作执行。

无分类器引导 [20]。我们采用与目标条件基线相同的目标条件架构。然而，在训练过程中，我们随机将目标条件置零，以表示无分类器引导所需的非条件输入。在推理过程中，我们使用与目标条件策略基线相同的条件来计算无分类器引导的噪声估计。




图 9：消融噪声预训练。移除动力学模型对含噪动作的接触会大幅降低其引导动作扩散过程的能力。

B.3 距离度量：推导与设计选择

在本节中，我们将对公式 2 所示的度量进行更详细的推导。虽然其他工作 [57] 简单地假设该度量为欧几里得距离，但我们采用概率动机来理解对数求和指数（log-sum-exp），我们通过实验发现这对 DynaGuide 的性能至关重要。在本推导的第一部分，我们仅讨论期望结果 $\mathbf{z}^+$ ，非期望结果可通过取反得到。

我们从一个非常粗略的近似开始：潜空间是高斯分布且具有对角方差 Σ 。这是使用平方潜距离的方法已经隐含做出的近似。此处，概率 $p(z_i^+ | \hat{z}_{t+H}) = \mathcal{N}(z_i^+, \mu = \hat{z}_{t+H}, \Sigma = \sigma I)$ 。对数概率可计算如下：

$$\begin{aligned}
 \log p(z_i^+ | \hat{z}_{t+H}) &= \log \frac{1}{(2\pi)^{n/2} \sqrt{|\Sigma|}} \exp \left(-\frac{1}{2} (z_i^+ - \hat{z}_{t+H})^T \Sigma^{-1} (z_i^+ - \hat{z}_{t+H}) \right) \\
 &= -\frac{1}{2} (z_i^+ - \hat{z}_{t+H})^T \Sigma^{-1} (z_i^+ - \hat{z}_{t+H}) + \underbrace{\log \frac{1}{(2\pi)^{n/2} \sqrt{|\Sigma|}}}_{\text{Constant}} \\
 &= -\frac{1}{2\sigma} (z_i^+ - \hat{z}_{t+H})^T (z_i^+ - \hat{z}_{t+H}) + C \\
 &= -\frac{1}{2\sigma} \|z_i^+ - \hat{z}_{t+H}\|_2^2 + C
 \end{aligned}$$

在 z^+ 中组合多个 $\mathbf{z}^+$ 的影响有多种方式。一种在经验上无效的方式是将对数概率相加：

$$d = \sum -\frac{1}{2\sigma} \|z_i^+ - \hat{z}_{t+H}\|_2^2$$

这并不令人意外，因为将对数概率相加等价于将概率相乘。如前所述，并非所有 z_i^+ 都是可实现的，有些可能相互排斥。例如，在多目标设置（§ 4.3）中，某些 z^+ 可能对应于按下按钮和

其他人打开抽屉。由于乘积运算，任何单个 z_i^+ 的影响在此设置中都过于强大。

相比之下，将概率相加更为合理。这样，总体上提高 z_i^+ 可能性的变化会增大该度量，即使它降低了其他竞争 z_i^+ 的可能性。为了将概率相加，我们可以执行以下操作：

$$\begin{aligned}\log p(\mathbf{z}^+ | \hat{z}_{t+H}) &= \log \sum_i p(z_i^+ | \hat{z}_{t+H}) \\ &= \log \sum_i \exp \left(-\frac{1}{2\sigma} \|z_i^+ - \hat{z}_{t+H}\|_2^2 + C \right) \\ &= \log \sum_i \exp(C) \exp \left(-\frac{1}{2\sigma} \|z_i^+ - \hat{z}_{t+H}\|_2^2 \right) \\ &= C + \log \sum_i \exp \left(-\frac{1}{2\sigma} \|z_i^+ - \hat{z}_{t+H}\|_2^2 \right)\end{aligned}$$

这产生了一个直观的结果，因为对数求和指数是一个软最大值。该度量聚焦于更接近期望结果的距离。 σ 的值调节软最大值的锐度。我们为 $\mathbf{z}^-$ 计算相同的度量。因为我们希望 $\mathbf{z}^-$ 中的结果与 $\mathbf{z}^+$ 互斥，所以我们希望将概率相除：

$$d = \frac{p(\mathbf{z}^+)}{p(\mathbf{z}^-)}$$

直观上，这意味着存在强烈的梯度激励，促使 $p(\mathbf{z}^-)$ 尽可能小，而如果我们使用 $p(\mathbf{z}^+) - p(\mathbf{z}^-)$ ，这种激励则不那么强。我们通过实验观察到这种相除的好处。此设置相当于从期望结果度量中减去不期望结果度量。为了创建最终的 $\mathbf{d}$ ，我们将常数 2 吸收到 σ 中，并丢弃常数 C 。这给出了公式 2 中的表达式：

$$\mathbf{d} = \log \left[\sum_i \exp \frac{-\|\phi(g_i^+) - h_\theta(\phi(o_t), \mathbf{a})\|_2^2}{\sigma} \right] - \log \left[\sum_j \exp \frac{-\|\phi(g_j^-) - h_\theta(\phi(o_t), \mathbf{a})\|_2^2}{\sigma} \right]$$

通过实验，我们发现公式 2 在使用欧氏距离替代平方 L2 距离时效果最佳。这种与理论结果的偏差最好归因于 DinoV2 的高斯潜在假设并不完全符合真实的嵌入空间。

在实践中， $\mathbf{g}^+$ 可以是未来状态 ($t+H$) 或最终状态 (T)。使用未来状态 $t+H$ 更容易训练动力学模型，但在推理时引导中更难找到正确的 $\mathbf{g}^+$ ，因为它必须是当前时间步起 H 步内可达的状态。或者，预测最终状态 T 意味着演示轨迹中的最终状态可以用作 $\mathbf{g}^+$ ，从而使推理时引导示例的选择变得直接。然而，对于长时程任务，训练动力学模型预测最终状态可能很困难。我们发现 Calvin 环境支持终态预测 (T)，但真实世界机器人环境需要将 $H=48$ 设置为未来步数。我们将整个轨迹作为 $\mathbf{g}^+$ 输入，并依靠对数求和指数潜在选择来动态挑选最相关的引导点。 $\mathbf{g}^+$ 的选择是一个重要的设计决策，它取决于环境和数据。

B.4 实验设置：仿真

CALVIN 环境：数据 尽管 CALVIN 被用于基准测试，本文仅利用 CALVIN 任务的数据进行自有实验。CALVIN 数据以连续转移序列的形式提供。

本文利用特权状态信息将这些转移序列分割为轨迹，每条轨迹展示一种行为：开启开关、关闭开关、打开抽屉、关闭抽屉、左转门、右转门、按下按钮、松开按钮、触碰红色物体、移动红色物体、触碰蓝色物体、移动蓝色物体、触碰粉色物体、移动粉色物体。本文自行进行分割，以与评估标准保持一致（见后续段落）。分割对于提取目标条件基线的最终观测值以及训练动力学模型也至关重要。

CALVIN 环境：基础策略 本文使用 CALVIN-D 数据集训练基础策略。基础扩散策略采用第三人称观测、腕部相机观测以及完整的机器人本体感知信息。由于演示展示了大量多样化的行为，训练得到的基础策略也提供了广泛的行为能力。

CALVIN 环境：动力学模型 由于动力学模型可以接受更广泛的数据，本文在 CALVIN-ABCD 数据集上训练动力学模型，该数据集是基准提供的完整数据划分。本文发现，加入非相关环境能够改善收敛性并减少过拟合。本文使用第三人称观测和完整的机器人本体感知信息作为动力学模型的输入。CALVIN 任务的短时程特性意味着，训练动力学模型预测单任务轨迹的最终状态观测是有利的。本文利用轨迹分割在训练期间获取最终观测目标。

CALVIN 环境：评估 我们将提供的验证卡尔文（CALVIN）数据集进行分割，并为每个期望行为随机选择 20 条轨迹，利用最后的状态观测提取 g^+ , g^- （未指定目标实验除外）。每次评估执行 50 次试验，时间范围为 400 步。我们使用特权状态信息监测物体交互，当物体被充分铰接或移动时停止回放。若 400 步后没有物体被充分移动或铰接，则将该试验计为失败（无行为）。对于每个目标行为（图 4 横轴），通过计算显示目标行为的试验频率来得到成功率。我们通过验证集轨迹中采样起始位姿来随机重置机器人。仿真结果（图 4、图 5）中的所有误差条均为 1 西格玛误差条。标准误通过评估在卡尔文数据集上分别独立训练-验证分割的六个策略上的 DynaGuide 来计算。由于六个成功率中的每一个已经是 100 次试验的平均值，因此使用均值的标准误作为西格玛。我们假设误差服从正态分布，因此标准误使用标准 $\sigma/\sqrt{n}$ 公式计算，其中 σ 通过 Numpy 函数计算。对于折线图（图 5 右），阴影区域计算为六个成功率的均值的标准误——与条形图相同。

铰接部件实验 要计为充分铰接，我们要求按钮和开关被完全按下/拨动，使得指示灯改变状态。对于抽屉和门，它们必须从起始位置到终点位置铰接超过一半的距离。

可移动物体实验 在本任务中，我们关注将策略引导至彩色立方体的能力。要取得成功，我们要求机器人接触立方体并将其移动一小段距离，这可以通过提起立方体或轻推它来实现。

未指定目标实验 在本任务中，我们采用了关节部件实验，但为所有引导方法提供了较低质量的引导条件。我们没有从验证轨迹的最终状态中获取观测，而是手动将目标物体设置到期望姿态（例如抽屉打开，或门向左）。我们为所有其他物体采样状态，并通过将机器人设置为从验证轨迹中采样的起始姿态来随机化机器人。这些 g^+ 与其他实验中使用的 g^+ 之间的关键区别在于，机器人不再被展示为直接与目标物体交互。尽管机器人位置是随机的，但仍然可以推断出目标行为，因为它是唯一在不同条件间保持不变的物体状态。

多目标实验。 本任务中，我们从验证轨迹中提取了代表多种行为类型的引导条件。我们不关心行为的链式执行，而是希望得到一个引导策略，能够以可比的频率提供多种期望行为，同时避免不期望的行为。在评估期间，我们仍然在单个行为后终止回放，并以与之前所有实验相同的方式计算成功率。然而，我们不再报告每个任务的单一成功率，而是报告整个任务分布（图 5，左）。

欠表示行为实验。本任务需要使用修改后的训练数据重新训练基础策略。利用特权状态信息获取轨迹行为标签，我们有意从基础扩散策略的训练集中移除了“开启”行为，以创建保留原始“开启”数据 1%、2%、5%、10%、20%、40%、60% 和 80% 的数据集。

方块触碰实验 我们通过创建一条具有 0 至 2 个中间点的贝塞尔曲线，收集智能体导航至随机选定方格的合成数据。该贝塞尔曲线使得动力学模型无法仅凭当前行进方向以完美准确率推断最终目的地。我们不直接使用度量 d ，而是训练动力学模型将输出方格颜色分类为 4 维向量类别分布。在推理阶段，我们使用该分布与表示期望方格颜色的独热向量之间的交叉熵度量。在训练及所有数据收集过程中，我们随机化方格位置。在测试阶段，我们引入特定方格排列以测试引导的性质。在早期决策测试中，我们仍随机化方格，但确保立方体停留在各自区域内，迫使智能体做出早期方向决策。在晚期决策测试中，我们使方格彼此靠近；在前往最远立方体测试中，我们始终将蓝色方格置于环境中与智能体起始位置相对的一侧。该智能体必须越过其他三个方格才能找到蓝色方格。一旦任何方格被触碰，环境即终止。

B.5 实验设置：真实机器人

基础策略 我们使用通用操作接口仓库 (github 链接) 提供的公开训练扩散策略。该策略在 $\approx 2k$ 条抓取杯子、重新定向 (将把手移至左侧) 以及放置于碟子上的轨迹上训练。该策略接收来自配备 Max Lens 模组的 GoPro 相机图像，每次生成输出 16 个动作。这些相对动作表示机器人相对于其当前位置 [6] 的变化。该策略在环境中主要见过单个杯子和碟子，但当提供多个杯子时，它会随机选择一个杯子。为在现有策略上演示 DynaGuide，我们不对该策略进行修改。尽管该策略提供随机选择，但它对环境左侧存在偏差。为消除此偏差，我们在杯子偏好测试中随机化期望杯子的位置。我们还在新颖行为测试中将电脑鼠标置于与该偏差相反的区域，以确保所有改进均源于引导而非基础策略偏差。

数据。我们在通用操作接口 (Universal Manipulation Interface) 仓库提供的开源杯子重排数据上训练动力学模型 (数据链接)。由于我们希望引导策略朝向两个杯子中的一个，因此需要在这些决策上训练动力学模型。利用通用操作接口硬件，我们采集了 500 条演示，实验场景中展示两个杯子和一个杯碟。我们拾取一个杯子并将其放置在杯碟上。我们使用不同的杯子和杯碟，杯子对与杯碟之间不存在相关性。我们将这些数据与现有的杯子排列数据结合用于动力学模型。对于新颖行为 (NovelBehavior) 实验，我们额外在 3648 条公开可用的电脑鼠标重排轨迹 [26] 上训练动力学模型，这为其提供了将基础策略引导至电脑鼠标所需的经验。

设置。我们使用配备软鳍条 (Fin Ray) 手指的 ARX5 机械臂，以及带有 Max Lens 模组的 GoPro 相机，以模拟采集基础策略训练数据时所用的设置。我们使用通用操作接口针对 ARX5 机械臂适配所提供的硬件控制器栈 (Github 链接)，并配备具有过流保护功能的电源以确保部署安全。

评估。我们对每个基础/引导策略进行 20 次试验。真实世界评估资源消耗极大，因此我们未创建置信区间。这在真实机器人结果中非常常见，即使对于大型项目也是如此 [5, 58]。

杯子偏好实验。我们将红色和灰色杯子摆放为机器人到任一杯子的起始距离大致相等。我们通过有时将两个杯子放得近、有时放得远来随机化该距离。我们将杯碟随机放置在环境中。在 50% 的试验中，红色杯子位于左侧，另外 50% 的试验中红色杯子位于右侧。我们将成功定义为拾取一个杯子并将其放置在杯碟上。

隐藏杯子实验。我们将红色杯子摆放在灰色杯子前方，使得灰色杯子始终比红色杯子更靠近机器人。我们随机化红色与灰色杯子之间的距离，以及两个杯子整体相对于机器人的位置。我们在环境中随机放置一个杯碟，但我们将抓取杯子视为成功，无需该杯碟。我们

发现该配置下的双杯设置分布外程度足以使基础策略加剧杯子放置错误。由于本实验旨在引导杯子颜色偏好，抓取杯子的动作已足够。前序实验测试的是完整行为成功率。

新颖行为实验 与杯子颜色偏好实验类似，我们将红色杯子和黑色电脑鼠标等距放置在机器人起始位置两侧。如前所述，我们将鼠标置于其侧向偏差的相反区域，以确保观察到的效果归因于引导而非基础策略偏差。与隐藏杯子实验相同，我们将对电脑鼠标的抓取尝试计为成功。这是因为电脑鼠标对于该基础策略而言分布外程度极高，无法成功抓取。本实验的关键在于能否通过动力学引导使机器人伸手抓取新颖物体。

C 更广泛影响

动态引导通过提升预训练策略在无需重新训练情况下被引导的能力，为机器人学领域做出贡献，有望减少重新训练所需的能耗。在预训练策略上增加引导还可能提升那些原本无法重新训练大型策略的实验室的可及性。该引导方法也可作为在训练过程之后消除已训练机器人策略中不期望或有问题偏差的有效手段。动力学模型基于公开可用或易于收集的数据进行训练，数据中不包含任何隐私或敏感信息。

由于动态引导允许对现有策略进行引导，存在不良行为者引导现成策略执行危险或恶意行为的风险，这一风险同样存在于其他生成模型中。为降低这些风险，基础策略的训练者可以确保恶意行为完全不被表示。了解动态引导的机制后，或许还可以训练基础策略在被要求执行恶意行为时对引导信号采取对抗性行动，从而使引导难度等同于从头重新训练策略。

D 代码、资产与许可证

我们所有模型均在公开可用数据上训练，并使用了以下许可证下的代码库和资产：

- CALVIN 环境与数据（MIT 许可证）[31]
- Robomimic 代码库（MIT 许可证）[30]
- DinoV2 模型（Apache 许可证）[38]
- 通用操作接口代码库、预训练模型与数据（MIT 许可证）[6, 26]

我们的代码将在近期以 MIT 许可证公开发布。补充材料中提供了代码的简化版本。