

E-TTS: 一种面向机器人操作的新型具身测试时扩展框架

Wen Ye^{1,2*}, Peiyan Li^{1,2*}, Tingyu Yuan^{2,3}, Yuan Xu^{1,2},
Xiangnan Wu^{1,2}, Chaoyang Zhao³, Jing Liu⁴, Nianfeng Liu⁴,
Yan Huang^{1,2,4†}, and Liang Wang^{1,2†}

¹ New Laboratory of Pattern Recognition (NLPR), Institute of Automation,
Chinese Academy of Sciences, Beijing, China

² School of Artificial Intelligence,

University of Chinese Academy of Sciences, Beijing, China

³ Foundation Model Research Center, Insti

中国科学院, 中国北京

4 FiveAges, 中国北京

yewen2025@ia.ac.cn, 李培燕@cripac.ia.ac.cn

{黄岩, 王亮}@nlpr.ia.ac.cn

摘要。近期, 少数工作已对具身任务的测试时扩展进行了初步探索。然而, 两大核心挑战仍未解决: (1) 推理能够有效提升策略性能, 但其扩展机制鲜有研究; (2) 历史信息至关重要, 因为具身任务本质上是长程且序列化的, 仅依赖当前观测进行动作扩展因缺乏历史上下文利用而不足。为应对这些挑战, 本文提出 E-TTS, 一种模块化、即插即用的具身测试时扩展框架, 通过基于视觉-语言验证器的历史感知迭代精化, 统一机器人操作中的推理与动作扩展。为支持联合推理-动作扩展, E-TTS 以成对方式执行推理-动作联合采样与评分。为更好地利用历史信息, E-TTS 采用历史缓冲区存储历史上下文, 随后由推理与动作验证器用于评估采样候选。与传统的开环测试时扩展方法不同, E-TTS 在采样过程中引入反馈生成, 形成闭环迭代精化机制, 同时提升推理效率与环境适应性。每个组件均作为独立且可组合的模块运行, 可根据任务需求灵活自适应配置。为评估框架优势, 本文在 4 个不同基准、6 种环境、3 类具身形态及 4 个基础视觉-语言-动作模型上开展实验。实验结果表明, 无需额外专家数据收集或重训练, E-TTS 持续提升性能, 仿真中最高提升 33.14%, 真实场景中最高提升 26.62%。项目主页为 <https://27yw.github.io/E-TTS-Web/>。

关键词: 视觉-语言-动作模型 · 测试时扩展 · 机器人操作 * 同等贡献。† 通讯作者。

1 引言




图 1：概览。 E-TTS 是一种具身测试时扩展框架，通过历史感知的闭环交互与视觉语言验证器，将推理扩展与动作扩展相结合，用于机器人操作。与标准视觉语言动作模型结合时，E-TTS 持续提升性能，在仿真中最高提升 33.14%，在真实场景中最高提升 26.62%。

测试时扩展 (Test-Time Scaling, TTS) 在计算机视觉和自然语言处理等领域已获得显著关注，因为它无需额外数据或重新训练即可提升模型性能。这一优势在具身领域更具吸引力，因为采集真实世界机器人数据的成本远高于获取互联网视觉语言数据。本质上，TTS 以额外的推理时间计算换取更高的输出质量。在具身领域，存在大量对延迟不敏感的任务（例如物体重排），这些任务优先考虑任务成功率而非毫秒级延迟。对于这些场景，TTS 为实现稳健执行提供了一条有前景的路径。因此，一个关键问题随之而来：如何在具身领域中应用测试时扩展，以实现计算与性能之间的最优平衡？近期工作 [11,15,17] 探索了具身系统的测试时扩展（见图 1），如图 1 上半部分所示，但它们忽视了机器人操作的两个内在挑战。首先，在动作预测之前引入推理组件已变得流行 [14,19,29,47,48]。然而，现有 TTS 方法仅专注于扩展动作，导致高层规划与执行之间不一致，从而造成操作性能欠佳。与传统的视觉语言任务不同，操作是一个序贯决策过程。历史轨迹上下文对于候选评估至关重要，而迭代反馈对于优化推理和动作必不可少。当前的 TTS 方法缺乏整合这些历史的机制，限制了它们在复杂具身场景中的有效性。为有效应对这两个挑战，本文提出一个统一的具身测试时扩展框架（E-TTS），该框架联合扩展推理与动作

通过历史感知的闭环交互与视觉-语言验证器（Vision-Language Verifier）的迭代优化（图 1）。具体而言，针对第一个挑战，E-TTS 执行联合推理-动作采样，其中推理过程与底层动作生成基于从两个维度联合建模的统一评分进行采样与选择。在推理选择方面，本文提示视觉语言模型（VLM）对每个推理候选进行零样本评分。在动作选择方面，本文构建动作偏好数据集，并基于该数据集训练一个独立的视觉语言模型作为验证器，对候选动作进行评分。针对第二个挑战，本文采用历史缓冲区存储历史信息，并将其纳入输入上下文，以增强验证器对时序依赖的建模能力。此外，本文框架在采样步骤集成反馈生成。生成的反馈随后被纳入后续采样轮次，形成迭代优化过程，从而提升效率与适应性。E-TTS 具有高度灵活的架构，每个组件均为可选、可独立配置，并可与其他组件组合，提供了一个适应性强的框架，无需额外训练即可适应广泛任务与不同视觉-语言-动作（VLA）模型。

为验证其有效性，本文将所提出的 E-TTS 与四种代表性视觉-语言-动作模型集成，这些模型均以视觉-语言输入并输出动作，但中间推理类型各异。评估实验在六个环境中进行：SIMPLER WidowX、SIMPLER Google Robot、LIBERO、LIBERO-Plus、VLAbench 及真实世界。平均成功率得到提升，最大增益为 33.14%，平均增益为 13.52%。此外，本文对关键组件进行了广泛的消融研究，以确定改进来源，并探索推理扩展与动作扩展之间的权衡，发现两者对具身测试时扩展均至关重要。

综上所述，本文的主要贡献有三方面：

- 本文提出一种新颖的即插即用具身测试时扩展框架，可与多种不同的视觉-语言-动作模型无缝集成，无需额外专家数据收集或重新训练即可提升其成功率。
- 我们通过历史感知的迭代优化与视觉-语言验证器，联合扩展推理与行动，应对具身领域的独特挑战，相较于传统测试时扩展方法，性能显著提升。
- 我们在模拟与真实环境中进行了大量实验，以验证框架的有效性。结果一致表明，我们的方法在多种环境和具身形态下显著提升了任务成功率。

2 相关工作

2.1 视觉-语言-动作模型

随着具身领域 [5,7 – 9,22,23,32,33,40,41,45] 的快速发展，视觉-语言-动作（VLA）模型 [14,16,21] 近年来成为热门研究方向，旨在单一框架内统一视觉感知、语言理解与决策。然而，简单耦合视觉、语言和运动信号不足以应对复杂具身环境中的推理需求。因此，近期研究强调将推理嵌入为显式动作令牌，能够在生成具体动作前外化内部认知过程 [50]。一些基于推理的 VLA，如 E-CoT[47] 和 RAD[10]，通过合成大规模推理-动作数据集，将多模态结构化思维链（CoT）表示融入策略学习。另一些工作，如 ThinkAct[13]、 $\pi_{0.5}$ [14] 和 Embodied-R1[46]，通过强化学习和规划生成文本推理，利用多模态潜在规划 [13]、异构数据协同训练 [14] 和具身指向表示 [46] 来提升长程泛化和空间推理能力。最近，EMMA-X[34] 和 MolmoAct[19] 将这种推理增强范式扩展到空间锚定的多模态动作推理，模型在视觉上下文中预测子任务、场景描述和细粒度运动轨迹，在真实机器人操作中展现出强大的泛化能力。尽管进展显著，大多数 VLA 在训练阶段依赖扩展数据集和模型规模来提升最终性能，这限制了它们在数据和模型规模受限环境中的适应性。

2.2 测试时扩展

近期大语言模型的进展已将研究重心转向测试时扩展，即通过三种主要策略在推理阶段分配更多计算资源：并行扩展 [4,18,20,30] 通过生成多个候选方案并借助选择机制进行聚合，从而提升可靠性。顺序扩展 [6,28,39,44,51] 支持迭代优化，使模型能够逐步构建并修正中间推理过程。混合扩展 [2,38,43] 统一了上述优势，以思维树和思维图为代表，提供结构化、自适应的探索与深思熟虑。受这些以语言为中心的工作启发，本文探索了具身领域的测试时扩展。本文框架联合扩展推理空间与动作空间，同时利用历史感知的联合验证与选择机制，在执行过程中协调探索与优化。

2.3 具身测试时扩展

鲜有研究将测试时扩展的概念延伸至具身领域，旨在不重新训练底层策略的情况下提升推理时的性能。例如，Hume [31] 引入了一个双系统框架

该框架为视觉-语言-动作模型增加了一个价值头，用于重复采样和级联去噪，使模型能够在推理过程中重新评估并优化其动作提议。类似地，RoboMonkey [17] 探索了大规模奖励建模和合成数据生成，以支持动作候选的外部评估。RoVer [11] 为视觉-语言-动作系统设计了一个机器人过程奖励模型，使其能够在推理时对候选动作进行评分和优化。TACO [42] 设计了一个利用伪计数估计的测试时扩展框架。然而，这些方法主要在动作空间内进行扩展，忽视了推理与动作之间的紧密耦合。相比之下，本文提出的 E-TTS 联合扩展推理与动作，显著提高了成功率。此外，这些方法未能充分利用历史上下文和反馈，忽视了具身领域顺序决策的特性。相比之下，本文提出了一个历史感知的框架级闭环框架，有效应对了这些独特挑战。




图 2: 所提出的 E-TTS 框架概览。在时间步 t ，给定指令 I 和当前观测 O_t ，视觉-语言-动作模型联合采样多个推理-动作对 $J_t^i \wedge \{i, j\} = (c_t^i, a_t^{i,j})$ 。每个候选由历史感知验证模块基于历史缓冲区 H_t 、 O_t 和 I 进行评估，该模块应用推理验证器和动作验证器来评估一致性。通过自适应在线选择，执行最佳对；否则，触发反馈引导细化以重新采样改进的候选。

3 具身测试时扩展

3.1 框架概览

如图 2 所示，给定任务指令 I 和当前观测 t ，我们的方法首先执行推理-动作联合采样（第 3.2 节）。此步骤涉及采样一组多样化的候选对 $J_t^{i,j} = (C_t^i, a_t^{i,j})$ ，

其中 c_t^i 表示中间推理步骤， $a_t^{i,j}$ 是对应的动作。这些联合样本连同先前的观测一起存储在表示为 t 的历史缓冲区中。然后，该缓冲区被我们的历史感知

验证与选择（第 3.3 节）模块利用，该模块采用双验证器（推理（第 3.3 节）和动作（第 3.3 节））通过联合评分策略评估候选的语义和物理一致性。接下来，我们应用

自适应在线选择（第 3.3 节）以评估候选对的适宜性。若所选对的置信度超过预定义阈值，则执行相应动作。否则，若未找到满意的候选对，则触发反馈引导的迭代细化（第 3.4 节）机制，向视觉-语言-动作模型提供纠正性反馈。该反馈引导模型重新采样更准确且上下文对齐的对。E-TTS 被设计为即插即用框架，所有模块完全模块化且可配置：可根据任务复杂度独立启用、禁用或组合，使 E-TTS 在保持统一框架的同时适应不同任务和视觉-语言-动作架构。整个流程的伪代码见附录 A.2。

3.2 推理-动作联合采样

先前工作 [11, 15, 17] 主要关注扩展动作空间，往往忽视中间推理过程。然而，在复杂具身任务中，推理结果指导动作预测，进而影响最终动作结果。为此，E-TTS 引入推理-动作联合扩展策略，旨在识别最优〈推理，动作〉对，而非选择单一动作。具体而言，我们采用通用机器人策略 $\pi_\theta(c_t, a_t \mid O_t, I)$ ，其中 O_t 表示当前观测， I 表示任务指令， c_t 为推理结果， a_t 为执行动作。在每个时间步 t ，我们首先采样一个推理 c_t^i ($i \in [1, M]$)，基于此策略生成 N 个候选动作 $\{a_t^{i,j}\}_{j=1}^N$ 。我们将每个〈推理，动作〉对定义为一个联合单元，同一推理样本对应的所有对构成一个联合采样批次：

$$J_t^{i,j} = (c_t^i, a_t^{i,j}), \mathcal{B}_t^i = \{J_t^{i,j}\}_{j=1}^N \quad (1)$$

其中 M 为每个时间步的最大推理采样数， N 为每个推理的动作采样数。该联合采样范式为后续验证与选择模块生成结构化的推理-动作对搜索空间。此外，由于具身任务本质上是顺序决策过程，最终决策不仅取决于当前观测，还取决于历史上下文。为此，我们将选定的〈推理，动作〉对与过去观测一起存储在历史缓冲区中，为其他模块提供历史经验。具体而言，在时间步 t ，我们维护一个动态缓冲区：

$$\mathcal{H}_t = \{J_{t-K}, O_{t-K}, \dots, J_{t-1}, O_{t-1}\} \quad (2)$$

该缓冲区存储最近的 K 个推理-动作对。该历史缓冲区以总长度为 K 的滑动窗口方式运行：当新的联合对 J_{t+1} 生成并通过验证后，将其追加到 $\mathcal{H}_t$ 中，同时丢弃最旧的条目 J_{t+1-K} ，得到 $\mathcal{H}_{t+1}$ 。更多细节见附录 A.1。

3.3 历史感知的验证与选择

在联合采样策略和历史缓冲区的基础上，本文引入双验证器机制来评估联合样本。

推理验证器 (V_c) 本文采用视觉-语言基础模型 (Qwen2.5-VL-7B [1]) 作为零样本推理验证器，评估候选推理样本的有效性、连贯性和依据性。形式上，对于 $\mathcal{B}_t^i$ 中的每个 $J_t^{i,j}$ ，给定历史感知的推理序列 $\mathcal{H}_t$ 、当前观测 O_t 和任务指令 I ，推理验证器生成置信度分数：

$$S_c^{i,j} = V_c(\mathcal{H}_t, J_t^{i,j}, O_t, I) \quad (3)$$

其中 S_c 量化了该推理样本在当前具身情境下成功完成任务的似然性。为处理多样化的中间推理结果，本文将其分为三种互补类型，并设计专门的处理策略：

文本推理。此类推理涉及纯语言内容，例如子任务。Embodied-R1 [46] 是输出此类中间推理的代表性操作模型之一。我们的推理验证器通过上下文嵌入处理这些样本，以评估逻辑一致性、因果可靠性和任务相关性。

多模态推理。此类推理整合了视觉感知（例如目标检测与分割结果）和文本理解（例如场景描述与任务分解）。E-CoT [47] 生成此类推理。此类推理要求推理验证器评估跨模态一致性。在我们的框架中，我们将视觉感知直接渲染在图像上作为视觉提示，并与原始文本理解一同提供，以避免丢失关键的空间细节。

空间推理。空间推理通常涉及与空间关系相关的信息，例如 MolmoAct 的 [19] 轨迹关键点。在我们的框架中，我们将这些空间推理结果转换为视觉提示，并将其叠加在原始观测上。为了帮助验证器更好地理解空间上下文，我们构建了代表性示例，展示在当前环境中什么构成有效的推理预测。该方法使 V_c 能够学习区分有充分依据的空间推理与不一致的空间推理，从而确保对空间意图的稳健评估。关于推理及我们相应策略的更多细节见附录 A.5。

效率优化 引入推理扩展不可避免地带来额外计算。为降低推理延迟，我们采用了若干系统级优化。我们使用 vLLM 引擎部署验证器，并利用 PagedAttention 优化 GPU 内存利用率。为进一步加速处理，我们采用前缀共享策略，缓存静态指令的 KV 状态。值得注意的是，我们的最终方法仅增加极少额外时间，详细分析见第 4.3 节。

动作验证器 (Action Verifier) (V_a) 受 [17] 启发，本文的动作验证器评估候选动作的低层可行性与任务相关性。动作验证器 (LLaVA-7B [35]) 在 9 万条包含成功与失败策略执行的成对演示上训练。数据采集自 SimplerEnv 与 LIBERO，通过采样成对的好动作与坏动作获得。质量标签通过基于均方误差 (MSE) 的准则将采样动作与真值动作比较后分配。该验证器通过改进的布拉德利-特里 (Bradley-Terry) [3] 目标学习，该目标纳入动作对之间的分级偏好水平。具体而言，它最小化真值与预测偏好边际之间的差异，增强对不同动作质量的敏感性。遵循 RT-2 [52]，训练期间将机器人连续动作的每个维度离散为 256 个区间。推理时，对于联合采样批次中的动作对 $J_t^{i,j}$ ，验证器 V_a 预测一个标量分数：

$$S_a^{i,j} = V_a(J_t^{i,j}, O_t, I) \quad (4)$$

该分数反映当前具身情境下的动作可行性。更多细节见附录 A.6。

自适应在线联合选择 为评估 $\langle \text{推理}, \text{动作} \rangle$ 对 t ，本文结合两个验证器的归一化分数。每对 $(c_t^i, a_t^{i,j})$ 的最终联合分数计算如下：

$$S_t^{i,j} = S_c^{i,j} \times \hat{S}_a^{i,j} \quad (5)$$

其中 $S_c^{i,j}$ 表示推理轨迹 c_t^i 的分数， $\hat{S}_a^{i,j}$ 是推理 $a_t^{i,j}$ 的动作样本 c_t^i 的归一化分数。这确保只有 $\langle \text{推理}, \text{动作} \rangle$ 对同时具有连贯推理和可行动作时才能获得高联合分数。数学论证见附录 A.3。虽然该联合评分机制有效衡量推理与动作之间的一致性，但贪心搜索选择最高分数的对可能限制模型对解空间的探索，潜在地导致次优或局部最优解。为解决此问题，本文采用基于 ϵ -贪心策略的自适应在线选择策略，在推理期间平衡探索与利用。在每个时间步 t ，随机变量 $u \sim \text{均匀分布}(0, 1)$ 决定选择模式：以概率 ϵ 从当前批次 $\mathcal{B}_t^i$ 随机采样一个推理-动作对进行探索；否则，选择联合分数最高的对

分数被贪心地选择: $J_t^{\mathcal{B}_i}$ 其中 $= J_t^{i,j^*}$, $j^* = \arg \max_j S_t^{i,j}$

$S_t^{i,j}$ 表示对 $J_t^{i,j}$ 的联合分数。为

进一步避免低质量选择, 应用阈值 η :

$$J_t^{\mathcal{B}_i} = \begin{cases} \text{Random}(\mathcal{B}_t^i), & u \leq \epsilon \\ J_t^{i,j^*}, & u > \epsilon \text{ and } S_t^{i,j^*} > \eta \\ \text{next batch } \mathcal{B}_t^{i+1}, & u > \epsilon \text{ and } S_t^{i,j^*} \leq \eta \end{cases} \quad (6)$$

该自适应策略动态地将计算资源分配给有前景的候选方案, 同时保持模型探索解空间的能力。更多细节见附录 A.7。

3.4 反馈引导的迭代精化

为帮助模型更快找到解决方案并避免反复访问次优区域, 整个联合批次的拒绝会触发反馈引导的迭代精化机制。我们重新应用推理验证器来分析被拒绝样本的失败原因, 并生成结构化的文本反馈。具体来说, 模型被提示一组引导性问题, 旨在引出有针对性的批评。给定当前观测 O_t 、指令 I 和失败样本 $J_t^{i,j}$, 验证器生成文本建议

F_t^i , 描述推理缺陷并提供可操作的纠正。该反馈 F_t^i 随后被插入原始指令提示中, 形成修订后的上下文, 以条件化下一轮联合批次采样 $\mathcal{B}_t^{i+1}$:

$$I_t^{i+1} = \text{Concat}(I, F_t^i) \quad (7)$$

where I_t^{i+1} 表示条件化基础策略的精化指令。这种闭环精化使模型能够从自身错误中学习, 逐步提高推理连贯性和动作可行性, 直到获得高分解决方案或达到最大批次限制 M 。我们提供了更多细节, 包括提示 (A.4)、精化策略 (A.1)、迭代精化示例 (A.8) 和详细建议 (A.9)。

4 实验

我们进行了大量实验来评估 E-TTS 的有效性。我们的实验旨在回答以下研究问题:

Q1: E-TTS 是否足够通用, 能够提升依赖不同中间推理结果的各种操作方法的性能?

Q2: 针对具身场景的特定设计, 如联合扩展推理和动作以及纳入反馈和历史, 是否真正有益? **Q3:** E-TTS 的效率-性能权衡是什么, 能否在不产生过高延迟的情况下实现显著增益?

Q4: 在固定计算预算内, 推理和动作扩展之间的最优权衡是什么? **Q5:**

E-TTS 在真实世界环境中是否保持强劲性能?

表 1：在 Simpler widowx 机器人（视觉匹配）上三个具身操作任务的性能比较。所提方法（E-CoT + 本文方法）一致优于所有基线和消融变体。灰色行表示移除特定组件（如反馈、缩放或历史缓冲区）的消融设置。

Method	Spoon on Towel	Eggplant in Basket	Carrot on Plate	Average
E-CoT	20.00	0.00	0.00	6.67
E-CoT + naive TTS	41.67	4.17	25.00	23.61
E-CoT + Robomoney	33.33	8.33	37.50	26.38
w/o feedback	50.00	11.50	13.63	25.04
w/o reasoning scaling	50.00	4.17	25.00	26.39
w/o action scaling	45.83	16.67	29.17	30.56
w/o joint scoring	42.85	18.75	31.80	31.13
w/o history buffer	54.17	20.83	20.83	31.94
w/o ϵ -greedy	50.00	20.83	37.50	36.11
E-CoT + Ours	58.33	22.22	38.89	39.81

4.1 不同类型操作方法的实验

我们在四个代表性视觉-语言-动作模型上评估 E-TTS：E-CoT [47]、MolmoAct [19]、 $\pi_{0.5}$ [14] 和 Embodied-R1 [46]。虽然它们都将多模态输入映射到动作，但其中间推理过程不同。具体而言，E-CoT 生成包括目标边界框、夹爪位置、子任务和运动原语在内的推理输出；MolmoAct 产生深度预测和视觉轨迹； $\pi_{0.5}$ 和 Embodied-R1 生成任务计划。关于这三个模型的更多细节见附录 B.2。我们进一步与 RoboMonkey [17] 和一个朴素的测试时缩放基线进行比较。该朴素测试时基线同样缩放推理和动作，并通过与本文相同的视觉-语言基础模型进行验证。然而，它缺乏其他与具身相关的适配，如闭环反馈或基于历史的输入。为公平比较，RoboMonkey 也在 SimplerEnv WidowX 中与 E-CoT 集成。RoboMonkey 仅以与 E-TTS 相同的设置缩放动作。实验中评估间隔为 10 步。详细超参数设置见附录 B.1。

E-CoT 上的实验。我们将 E-TTS 集成到 E-CoT 中，并在 SimplerEnv 基准 [24] 上进行评估。SimplerEnv 是一套真实到仿真的环境套件，用于在仿真中评估机器人策略。它为基准测试为私有真实世界平台（如 Google Robot 和 WidowX）开发的机器人策略的成功率提供了标准化竞技场。本文在 WidowX 平台上评估 E-CoT，使用 BridgeData V2 [37]，其中包含从 24 个环境收集的 60,096 条轨迹。每种方法在三种任务类型上进行评估，每个任务 24 次试验。实验结果报告于表 1。我们观察到原始 E-CoT 基线表现不佳，经常无法准确接近目标物体。相比之下，当与我们的 E-TTS 流程集成时，E-CoT 产生更合适的推理输出，使平均任务成功率从 6.67% 大幅提升至 39.81%。与 Robomoney 相比，我们的方法在平均成功率上取得了显著 50.91% 的提升，

表 2：在 SimplerEnv 上跨任务的视觉和变体性能比较。 MolmoAct + Ours 显著优于 MolmoAct 和基线，在视觉（80.00%）和变体（77.77%）设置中均取得最高平均分。

Method	Visual				Variant			
	Pick Coke	Can Move	Near Open/Close	Drawer Average	Pick Coke	Can Move	Near Open/Close	Drawer Average
MolmoAct	74.50	75.45	63.25	71.05	66.95	52.55	77.75	65.68
MolmoAct + naive TTS	76.47	80.00	66.60	74.36	56.00	50.00	80.00	62.00
MolmoAct + Ours	83.00	85.00	72.00	80.00	80.00	70.00	83.30	77.77

同时保持极具竞争力的推理效率，执行时间仅增加 7.8%。更多结果见附录 B.5。

MolmoAct 实验。我们使用 MolmoAct 在 SimplerEnv（Google Robot）、LIBERO [26] 和 LIBERO-Plus [12] 上评估 E-TTS。对于 SimplerEnv，我们在两种设置下进行测试：(1) 视觉匹配，镜像训练设置，以及 (2) 变体聚合，具有随机化的视觉条件。我们将框架集成到官方零样本和微调的 MolmoAct 检查点中，总成功率为所有场景变体的平均值。如表 2 所示，E-TTS 在所有设置中持续提升成功率，显著优于朴素的测试时扩展基线。

表 3：在 LIBERO 基准和 LIBERO-Plus 基准上跨四个推理类别（空间、物体、目标、长时程）的性能比较。 MolmoAct + Ours 始终优于基线和朴素变体。

Setting	Spatial	Goal	Object	Long
MolMoAct	88.80	84.30	90.40	77.46
MolMoAct + Ours	91.20	85.04	91.36	80.99

(a) LIBERO-Plus Benchmark

Method	Spatial	Object	Goal	Long	Average
MolmoAct	87.00	92.67	87.60	75.00	85.57
MolmoAct + naive TTS	88.90	93.10	70.00	75.00	81.75
MolmoAct + Ours	93.60	97.50	92.00	80.00	90.78

(b) LIBERO Benchmark

在 LIBERO 基准测试中，模拟的 Franka Emika Panda 机械臂根据多模态演示执行操作任务，演示包括前置和腕部摄像头观测、自然语言指令以及末端执行器位姿动作增量。LIBERO 提供四个任务套件——空间、物体、目标和长程——每个套件包含十个不同的任务。评估时，每个任务执行 50 次回放。详细结果见表 3。与 E-TTS 集成后，MolmoAct 在所有四个任务套件上均达到最高性能，进一步证明了本文方法的有效性。更多结果见附录 B.7。本文进一步在 LIBERO-plus[12] 上评估泛化能力，该基准在七个扰动维度上引入了 10,030 个任务，包括视角变化、物体布局偏移、机器人初始化变化、指令改写、光照、背景纹理和传感器噪声。本文评估每个类别的前 200 个任务，共 800 个任务，如表 3 所示，本文方法在所有类别上均持续改进 MolMoAct。这些多样化扰动下的改进

证明了在标准 LIBERO 设置之外增强的鲁棒性和更强的泛化能力。

表 4: VLABench 基准测试中代表性任务的成功率 (SR)。

轨道	IF	SB	SCT	SPo	AC	SD	平均	轨道 1	0.18	
0.48	0.48	0.46	0.50	0.42	0.39	轨道 2	-	0.02	0.15	0.40
0.06	0.14	0.20	轨道 3	0.08	0.38	0.50	-	0.14	0.14	0.19
轨道 4	0.04	0.38	0.21	0.06	0.10	0.20	0.15	轨道 6		
0.06	0.45	0.29	0.22	0.46	0.30	0.25				

(a) $\pi_{0.5}$

轨道	IF	SB	SCT	SPo	AC	SD	平均	轨道 1	0.20	
0.53	0.53	0.63	0.54	0.48	0.42	轨道 2	-	0.02	0.16	0.48
0.02	0.16	0.48	0.08	0.14	0.24	轨道 3	0.10	0.36	0.54	-
0.18	0.16	0.21	轨道 4	0.06	0.48	0.24	0.08	0.16	0.22	0.16
轨道 6	0.04	0.48	0.31	0.28	0.31	0.34	0.26			

(b) $\pi_{0.5} + \text{Ours}$

实验 $\pi_{0.5}$. 我们进一步将框架与 $\pi_{0.5}$ 集成, 后者是一种基于流匹配的视觉-语言-动作模型, 具有中间子任务预测能力。该模型在 VLABench [49] 上进行评估, 该基准专为评估长程推理、世界知识迁移、语义指令理解和物理规律意识而设计。它包含需要多步规划和隐式意图理解的复合任务。如表 4 所示, 集成我们的方法在大多数赛道和代表性任务上一致提升了 $\pi_{0.5}$ [14] (详见附录 B.8), 所有报告赛道的平均成功率均有所提高。值得注意的是, 在 `select_poker(from` (0.46 至 0.63) 和 `add_condiment(from` (0.10 至 0.16) 等需要多步空间推理和语义接地的任务上, 提升更为显著。这些结果表明, 在复杂和组合式任务设置下, 该方法增强了跨步骤的决策一致性, 并通过 E-TTS 提高了长程成功率。平均值为全部 12 项任务的平均值, 完整结果见附录 B.8。此外, 我们使用 TACO [42] 对 E-TTS 进行了评估, 结果见附录 B.8。

Embodied-R1 (ER-1) 实验。 我们使用与 E-CoT 相同的评估协议, 在 `SimplerEnv WidowX` 环境中评估 ER-1。由于篇幅限制, 详细结果见附录 B.6。我们观察到, 集成 E-TTS 将原始模型的平均成功率从 39.8% 大幅提升至 44.9%。这些结果回答了 **Q1**, 表明无论中间推理过程类型如何, E-TTS 都能有效提升操作方法的性能。

4.2 消融研究

为验证模型设计的有效性并为社区提供洞见, 我们在 `SimplerEnv WidowX` 环境中以 E-CoT 为基础操作模型进行了五项消融研究。结果见表 1。无反馈消融从缩放步骤中移除了反馈, 导致性能显著下降, 证明了反馈在缩放过程中的重要性。

表 5: SimplerEnv 上的消融实验。R/A 表示推理/动作。

Method	R/A Samples	SR (%)	Avg Time (s)	K	SR (%)	η	SR(%)	ϵ	SR(%)
E-CoT	—	20.00	8.35	1	37.50	0.1	70.83	0.1	54.17
E-CoT + ours	10 / 20	37.50	14.57	3	33.33	0.2	45.83	0.2	50.00
E-CoT + ours	10 / 30	41.67	11.46	5	45.83	0.3	50.00	0.3	37.50
E-CoT + ours	10 / 50	50.00	12.23	10	58.33	0.4	37.50	0.5	37.50
E-CoT + ours	20 / 20	59.10	14.77	20	45.83	0.5	33.33	0.7	33.33
E-CoT + ours	50 / 100	50.00	15.65						
E-CoT + ours	100 / 100	62.50	20.22						

(a) 样本规模与效率的消融实验

(b) 超参数消融

无动作缩放 且无推理缩放仅应用一个缩放组件。单独使用任一组件都会显著降低性能，表明两者对于具身任务都是必需的。无联合评分分别评估推理和动作。我们首先选择得分最高的推理，然后在其条件下采样并评分动作。该策略表现不佳，因为高质量的推理并不能保证高质量的动作。有效的评估需要联合评分（第 3.2 节）。无历史缓冲区在评估时移除历史输入，降低了成功率，证明了轨迹信息的重要性。 $\mathbf{w/o} \epsilon$ -贪心禁用探索，导致性能降低，凸显了平衡探索与利用的必要性。

参数分析。 我们对历史长度 K 、阈值 η 和 ϵ 探索进行了消融（表 5 右侧部分）。性能表明，增加 K 可将成功率提升至 $K = 10$ ，但更长的历史会导致性能下降。适中的 η 和较小的 ϵ 在探索多样性与推理精度之间实现了最佳权衡，解决了采样规模与效率-性能权衡问题。总体而言，这些消融结果回答了问题 2，证实了我们的设计选择具有充分依据，并可能为未来研究提供有用的洞见。

4.3 性能与延迟之间的权衡

测试时缩放本质上以推理时间换取性能。然而，我们的实证结果表明这种权衡是有利的。如表 5 所示，最优缩放配置在延迟仅增加 46.6% 的情况下，成功率相对提升了 150%，反映了较高的采样效率。通过整合第 3.3 节的系统级优化，我们进一步降低了这一开销。与 Robomongokey 相比，我们的方法在平均成功率上实现了 51.5% 的相对提升，而执行时间仅边缘增加 7.8%。这些结果直接回答了问题 3，产生了极为有利的效率-性能权衡。此外，E-TTS 与模型无关，兼容各种视觉-语言-动作架构。其模块化设计允许可组合、选择性的部署，能够在推理和动作维度上灵活联合缩放以匹配任务复杂度，同时有效控制计算开销和推理延迟。

4.4 动作扩展与推理扩展之间的权衡

本文的主要贡献之一是提出同时扩展推理和动作。一个自然的问题是，在计算资源有限时如何分配。我们使用第 4.1 节的 E-CoT 设置，在 60 步采样限制下测试了五种分配比例。图 3 的结果表明，过度优先考虑任一组件都会导致次优性能。在约 1:1 比例（Q4）处达到峰值性能，这强调了推理和动作扩展对于有效的具身测试时扩展都是不可或缺的。




图 3：不同比例下的成功率。“1/1”比例在所有任务中达到峰值性能。

4.5 真实机器人实验

设置。为了验证我们的框架在真实环境中的有效性，我们还进行了真实机器人实验。我们的设置包括一个 Franka Research 3 机械臂，配备平行夹爪、一个静态 ZED 2i 深度相机用于全局视图，以及一个腕部安装的 Realsense D405 用于局部观察（图 4）。我们使用微调的 MolmoAct 在四个任务上评估 E-TTS，任务范围从简单的抓取放置到复杂的长时间序列（例如，通过打开/关闭抽屉将可乐放入抽屉）。这些任务涉及刚性和可变形物体（例如布袋）。我们通过 SpaceMouse 遥操作收集了每个任务 100 个遥操作专家演示。每个基线在每个任务上评估 40 次试验（总共 160 次试验），初始物体配置手动标准化以确保一致性。




图 4：真实机器人实验。真实世界机器人设置和评估结果概览。左：硬件配置，包括 ZED 2i 相机、Franka Research 3 机械臂和 RealSense D405。中：代表性操作任务。右：成功率比较，其中我们的方法（蓝色）显著优于 MolmoAct 微调基线，平均提升 26.62%。

结果。真实机器人结果（图 4）表明，E-TTS 将原始模型的平均成功率从 22.13% 提升至 48.75%，在所有任务上均取得优异性能，回答了问题 5。值得注意的是，我们观察到涌现的自我纠正行为：例如，在抓取失败后，机器人可能自主重新尝试该动作，这种能力在训练中并不存在。该过程的可视化见附录 C。我们推测这源于视觉-语言基础模型广泛的预训练知识，使其能够在分布外状态下进行有效推理。关于任务和结果的更多细节见附录 C。

5 结论与未来工作

本文提出一种具身测试时扩展框架，以应对具身任务的独特挑战。该框架可与多种操作策略集成，无需额外的专家遥操作数据即可提升性能。通过在不同环境和具身形态上的实验，我们验证了方法的有效性。尽管集成的效率优化缓解了延迟问题，未来研究将探索更多加速技术。

致谢

本工作得到国家自然科学基金（62322607、62236010 和 62276261）和北京市自然科学基金（L252033）的联合资助。

参考文献

1. Bai, S., Chen, K., Liu, X., Wang, J., Ge, W., Song, S., Dang, K., Wang, P., Wang, S., Tang, J., et al.: Qwen2. 5-vl technical report. arXiv preprint arXiv:2502.13923 (2025)
2. Besta, M., Blach, N., Kubicek, A., Gerstenberger, R., Podstawski, M., Giani-nazzi, L., Gajda, J., Lehmann, T., Niewiadomski, H., Nyczyk, P., et al.: Graph of thoughts: Solving elaborate problems with large language models. In: Proceedings of the AAAI conference on artificial intelligence. vol. 38, pp. 17682–17690 (2024)
3. Bradley, R.A., Terry, M.E.: Rank analysis of incomplete block designs: I. the method of paired comparisons. *Biometrika* **39**(3/4), 324–345 (1952)
4. Brown, B., Juravsky, J., Ehrlich, R., Clark, R., Le, Q.V., Ré, C., Mirhoseini, A.: Large language monkeys: Scaling inference compute with repeated sampling. arXiv preprint arXiv:2407.21787 (2024)
5. Cai, R., Guo, J., He, X., Jin, P., Li, J., Lin, B., Liu, F., Liu, W., Ma, F., Ma, K., et al.: Xiaomi-robotics-0: An open-sourced vision-language-action model with real-time execution. arXiv preprint arXiv:2602.12684 (2026)
6. Chen, X., Lin, M., Schärli, N., Zhou, D.: Teaching large language models to self-debug. arXiv preprint arXiv:2304.05128 (2023)

7. Chen, Y., Huang, Y., He, K., Li, P., Wang, L.: Verm: Leveraging foundation models to create a virtual eye for efficient 3d robotic manipulation. *IEEE Robotics and Automation Letters* **11**(3), 2482–2489 (2026)
8. Chen, Y., Li, P., Huang, Y., Yang, J., Chen, K., Wang, L.: Ec-flow: Enabling versatile robotic manipulation from action-unlabeled videos via embodiment-centric flow. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision*. pp. 11958–11968 (2025)
9. Chen, Y., Li, P., Yang, J., He, K., Wu, X., Xu, Y., Wang, K., Liu, J., Liu, N., Huang, Y., et al.: Bridgev2w: Bridging video generation models to embodied world models via embodiment masks. *arXiv preprint arXiv:2602.03793* (2026)
10. Clark, J., Mirchandani, S., Sadigh, D., Belkhale, S.: Action-free reasoning for policy generalization. *arXiv preprint arXiv:2502.03729* (2025)
11. Dai, M., Liu, L., Bai, Y., Liu, Y., Wang, Z., Su, R., Chen, C., Lin, L., Wu, X.: Rover: Robot reward model as test-time verifier for vision-language-action model. *arXiv preprint arXiv:2510.10975* (2025)
12. Fei, S., Wang, S., Shi, J., Dai, Z., Cai, J., Qian, P., Ji, L., He, X., Zhang, S., Fei, Z., et al.: Libero-plus: In-depth robustness analysis of vision-language-action models. *arXiv preprint arXiv:2510.13626* (2025)
13. Huang, C.P., Wu, Y.H., Chen, M.H., Wang, Y.C.F., Yang, F.E.: Thinkact: Vision-language-action reasoning via reinforced visual latent planning. *arXiv preprint arXiv:2507.16815* (2025)
14. Intelligence, P., Black, K., Brown, N., Darpinian, J., Dhabalia, K., Driess, D., Esmail, A., Equi, M., Finn, C., Fusai, N., et al.: $\pi 0. 5$: a vision-language-action model with open-world generalization, 2025. URL <https://arxiv.org/abs/2504.16054> **1**(2), 3
15. Jang, S., Kim, D., Kim, C., Kim, Y., Shin, J.: Verifier-free test-time sampling for vision language action models. *arXiv preprint arXiv:2510.05681* (2025)
16. Kim, M.J., Pertsch, K., Karamcheti, S., Xiao, T., Balakrishna, A., Nair, S., Rafailov, R., Foster, E., Lam, G., Sanketi, P., et al.: Openvla: An open-source vision-language-action model. *arXiv preprint arXiv:2406.09246* (2024)
17. Kwok, J., Agia, C., Sinha, R., Foutter, M., Li, S., Stoica, I., Mirhoseini, A., Pavone, M.: Robomongo: Scaling test-time sampling and verification for vision-language-action models. *arXiv preprint arXiv:2506.17811* (2025)
18. Lambert, N., Morrison, J., Pyatkin, V., Huang, S., Ivison, H., Brahman, F., Miranda, L.J.V., Liu, A., Dziri, N., Lyu, S., et al.: Tulu 3: Pushing frontiers in open language model post-training. *arXiv preprint arXiv:2411.15124* (2024)
19. Lee, J., Duan, J., Fang, H., Deng, Y., Liu, S., Li, B., Fang, B., Zhang, J., Wang, Y.R., Lee, S., et al.: Molmoact: Action reasoning models that can reason in space. *arXiv preprint arXiv:2508.07917* (2025)
20. Li, D., Cao, S., Cao, C., Li, X., Tan, S., Keutzer, K., Xing, J., Gonzalez, J.E., Stolica, I.: S*: Test time scaling for code generation. *arXiv preprint arXiv:2502.14382* (2025)
21. Li, P., Chen, Y., Wu, H., Ma, X., Wu, X., Huang, Y., Wang, L., Kong, T., Tan, T.: Bridgevla: Input-output alignment for efficient 3d manipulation learning with vision-language models. *arXiv preprint arXiv:2506.07961* (2025)
22. Li, P., Chen, Y., Xu, Y., Yang, J., Wu, X., Guo, J., Sun, N., Qian, L., Li, X., Xiao, X., et al.: Multi-view video diffusion policy: A 3d spatio-temporal-aware video action model. *arXiv preprint arXiv:2604.03181* (2026)
23. Li, P., Wu, H., Huang, Y., Cheang, C., Wang, L., Kong, T.: Gr-mg: Leveraging partially-annotated data via multi-modal goal-conditioned policy. *IEEE Robotics and Automation Letters* **10**(2), 1912–1919 (2025)

24. Li, X., Hsu, K., Gu, J., Pertsch, K., Mees, O., Walke, H.R., Fu, C., Lunawat, I., Sieh, I., Kirmani, S., Levine, S., Wu, J., Finn, C., Su, H., Vuong, Q., Xiao, T.: Evaluating real-world robot manipulation policies in simulation. *arXiv preprint arXiv:2405.05941* (2024)
25. Lightman, H., Kosaraju, V., Burda, Y., Edwards, H., Baker, B., Lee, T., Leike, J., Schulman, J., Sutskever, I., Cobbe, K.: Let’s verify step by step. In: *The Twelfth International Conference on Learning Representations* (2023)
26. Liu, B., Zhu, Y., Gao, C., Feng, Y., Liu, Q., Zhu, Y., Stone, P.: Libero: Benchmarking knowledge transfer for lifelong robot learning. *Advances in Neural Information Processing Systems* **36**, 44776–44791 (2023)
27. Liu, H., Li, C., Li, Y., Lee, Y.J.: Improved baselines with visual instruction tuning. In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. pp. 26296–26306 (2024)
28. Madaan, A., Tandon, N., Gupta, P., Hallinan, S., Gao, L., Wiegrefe, S., Alon, U., Dziri, N., Prabhume, S., Yang, Y., et al.: Self-refine: Iterative refinement with self-feedback. *Advances in Neural Information Processing Systems* **36**, 46534–46594 (2023)
29. Qu, D., Song, H., Chen, Q., Chen, Z., Gao, X., Ye, X., Lv, Q., Shi, M., Ren, G., Ruan, C., et al.: Eo-1: Interleaved vision-text-action pretraining for general robot control. *arXiv preprint arXiv:2508.21112* (2025)
30. Renze, M.: The effect of sampling temperature on problem solving in large language models. In: *Findings of the association for computational linguistics: EMNLP 2024*. pp. 7346–7356 (2024)
31. Song, H., Qu, D., Yao, Y., Chen, Q., Lv, Q., Tang, Y., Shi, M., Ren, G., Yao, M., Zhao, B., et al.: Hume: Introducing system-2 thinking in visual-language-action model. *arXiv preprint arXiv:2505.21432* (2025)
32. Sun, N., Li, Y., Wang, C., Li, H., Liu, H.: Collabvla: Self-reflective vision-language-action model dreaming together with human. *arXiv preprint arXiv:2509.14889* (2025)
33. Sun, N., Zhang, Y., Yang, Y., Zhao, W., Li, P., Guo, J., Song, W., Ding, P., Suo, R., Su, Y., et al.: Revisiting embodied chain-of-thought for generalizable robot manipulation. *arXiv preprint arXiv:2606.03784* (2026)
34. Sun, Q., Hong, P., Pala, T.D., Toh, V., Tan, U., Ghosal, D., Poria, S., et al.: Emma-x: An embodied multimodal action model with grounded chain of thought and look-ahead spatial reasoning. *arXiv preprint arXiv:2412.11974* (2024)
35. Sun, Z., Shen, S., Cao, S., Liu, H., Li, C., Shen, Y., Gan, C., Gui, L., Wang, Y.X., Yang, Y., et al.: Aligning large multimodal models with factually augmented rlhf. In: *Findings of the Association for Computational Linguistics: ACL 2024*. pp. 13088–13110 (2024)
36. Sundaralingam, B., Hari, S.K.S., Fishman, A., Garrett, C., Van Wyk, K., Blukis, V., Millane, A., Oleynikova, H., Handa, A., Ramos, F., et al.: curobo: Parallelized collision-free minimum-jerk robot motion generation. *arXiv preprint arXiv:2310.17274* (2023)
37. Walke, H., Black, K., Lee, A., Kim, M.J., Du, M., Zheng, C., Zhao, T., Hansen-Estruch, P., Vuong, Q., He, A., Myers, V., Fang, K., Finn, C., Levine, S.: Bridge-data v2: A dataset for robot learning at scale. In: *Conference on Robot Learning (CoRL)* (2023)
38. Wang, J., Wang, J., Athiwaratkun, B., Zhang, C., Zou, J.: Mixture-of-agents enhances large language model capabilities. *arXiv preprint arXiv:2406.04692* (2024)

39. Wei, J., Wang, X., Schuurmans, D., Bosma, M., Xia, F., Chi, E., Le, Q.V., Zhou, D., et al.: Chain-of-thought prompting elicits reasoning in large language models. *Advances in neural information processing systems* **35**, 24824–24837 (2022)
40. Xu, Y., Yang, J., Wang, X., Chen, Y., Zhu, Z., Fang, B., Huang, G., Chen, X., Ye, Y., Zhang, Q., et al.: Egodemogen: Novel egocentric demonstration generation enables viewpoint-robust manipulation. *arXiv preprint arXiv:2509.22578* (2025)
41. Yang, J., Chen, Y., Xu, Y., Li, P., Wu, X., Wen, Z., Fang, B., Yu, T., Zhang, Z., Li, Y., et al.: Uaor: Uncertainty-aware observation reinjection for vision-language-action models. *arXiv preprint arXiv:2602.18020* (2026)
42. Yang, S., Zhang, Y., He, H., Pan, L., Li, X., Bai, C., Li, X.: Steering vision-language-action models as anti-exploration: A test-time scaling approach. *arXiv preprint arXiv:2512.02834* (2025)
43. Yao, S., Yu, D., Zhao, J., Shafran, I., Griffiths, T., Cao, Y., Narasimhan, K.: Tree of thoughts: Deliberate problem solving with large language models. *Advances in neural information processing systems* **36**, 11809–11822 (2023)
44. Yu, P., Xu, J., Weston, J., Kulikov, I.: Distilling system 2 into system 1. *arXiv preprint arXiv:2407.06023* (2024)
45. Yuan, T., Guan, B., Ye, W., Tian, Z., Yang, Y., Zhou, W., Li, Z., Huang, Y., Wang, P., Zhao, C., et al.: Unibyd: A unified framework for learning robotic manipulation across embodiments beyond imitation of human demonstrations. *arXiv preprint arXiv:2512.11609* (2025)
46. Yuan, Y., Cui, H., Huang, Y., Chen, Y., Ni, F., Dong, Z., Li, P., Zheng, Y., Hao, J.: Embodied-r1: Reinforced embodied reasoning for general robotic manipulation. *arXiv preprint arXiv:2508.13998* (2025)
47. Zawalski, M., Chen, W., Pertsch, K., Mees, O., Finn, C., Levine, S.: Robotic control via embodied chain-of-thought reasoning. *arXiv preprint arXiv:2407.08693* (2024)
48. Zhai, A., Liu, B., Fang, B., Cai, C., Ma, E., Yin, E., Wang, H., Zhou, H., Wang, J., Shi, L., et al.: Igniting vlms toward the embodied space. *arXiv preprint arXiv:2509.11766* (2025)
49. Zhang, S., Xu, Z., Liu, P., Yu, X., Li, Y., Gao, Q., Fei, Z., Yin, Z., Wu, Z., Jiang, Y.G., et al.: Vlabench: A large-scale benchmark for language-conditioned robotics manipulation with long-horizon reasoning tasks. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision*. pp. 11142–11152 (2025)
50. Zhong, Y., Bai, F., Cai, S., Huang, X., Chen, Z., Zhang, X., Wang, Y., Guo, S., Guan, T., Lui, K.N., et al.: A survey on vision-language-action models: An action tokenization perspective. *arXiv preprint arXiv:2507.01925* (2025)
51. Zhou, D., Schärli, N., Hou, L., Wei, J., Scales, N., Wang, X., Schuurmans, D., Cui, C., Bousquet, O., Le, Q., et al.: Least-to-most prompting enables complex reasoning in large language models. *arXiv preprint arXiv:2205.10625* (2022)
52. Zitkovich, B., Yu, T., Xu, S., Xu, P., Xiao, T., Xia, F., Wu, J., Wohlhart, P., Welker, S., Wahid, A., et al.: Rt-2: Vision-language-action models transfer web knowledge to robotic control. In: *Conference on Robot Learning*. pp. 2165–2183. PMLR (2023)

A 方法细节

A.1 E-TTS 的更多细节

与先前工作（如 RoboMonkey [17]）仅沿动作维度扩展不同，本文提出的框架 E-TTS 在历史感知、反馈引导的推理循环中执行联合推理-动作扩展，从而实现深思熟虑与控制之间的协调配合。我们通过联合采样与验证策略实现这一目标。

联合采样 给定任务指令和当前观测，VLA 模型迭代生成推理轨迹，每条轨迹提供一个高层计划。对于每条推理轨迹，采样一系列候选动作以鼓励行为多样性，同时保持上下文相关性。

联合验证 推理-动作对的联合质量通过推理分数与动作分数相乘计算得出。对于第一批（一条推理轨迹及其候选动作），抽取一个随机变量（ $u \in [0, 1]$ ）。若（ $u < \epsilon$ ），则随机选择一个样本以鼓励探索；否则，得分最高的样本代表该批次。将该样本与阈值比较：若满足标准，则执行该动作，并将推理-动作对及观测更新至历史缓冲区。若不满足，则生成反馈，当前时间步保持不变，并在反馈和更新后的历史条件下采样并验证下一批次。由于具身任务具有顺序性，通常涉及长时程动作序列，我们设计了历史缓冲区和反馈引导的迭代细化机制。

历史缓冲区 历史缓冲区存储过去的推理-动作对和观测，为采样和验证提供条件，以确保长时程任务中的时序一致性。该缓冲区动态维护并在验证过程中被纳入，使模型能够参考过去的推理-动作对和观测，从而保证时序一致性并做出明智决策。

用于细化的反馈：若批次中没有任何候选推理-动作对达到预定义的置信度阈值，则触发反馈引导的细化过程。在此过程中，反馈顾问生成结构化反馈，为纠正偏差和调整后续采样分布提供明确指导。下一次迭代则基于更新后的反馈以及当前任务指令和观测来采样新批次，从而在推理质量和动作精确率两方面实现渐进式改进。通过这种联合采样、历史感知验证和反馈引导细化的闭环过程，本文方法能够持续适应任务上下文，保持时序一致性，并在长时程、序列化具身任务中实现稳健且高质量的性能。

A.2 E-TTS 算法

Algorithm 1 E-TTS Pseudocode

Input: policy π_θ , reasoning verifier V_c , action verifier V_a , feedback advisor f , instruction I , initial observation O , history length K , max reasoning samples M , max action samples N , selection parameter ϵ , acceptance threshold η , max timesteps T , evaluation steps Δ , the set of the best sample in each batch $\mathcal{A}$.

```

1: Initialize  $\mathcal{H}_0 = \emptyset$ ,  $t \leftarrow 0$ 
2: for  $t = \Delta$  to  $T$  step  $\Delta$  do
3:   Obtain observation  $O_t$  and initialize  $\mathcal{A} \leftarrow \emptyset$ 
4:   for  $i = 1$  to  $M$  do
5:     Sample reasoning  $c_t^i \sim p_\theta(c \mid O_t, I, F_t^{i-1})$ 
6:     Form joint pairs  $J_t^{i,j} = (c_t^i, a_t^{i,j})$  with  $a_t^{i,j} \sim p_\theta(a \mid c_t^i, O_t, I)$ ,  $j = 1 \dots N$ 
7:     Build joint batch  $\mathcal{B}_t^i = \{J_t^{i,j}\}_{j=1}^N$ 
8:     Build history buffer:  $\mathcal{H}_t = \{J_{t-K}, \dots, J_{t-1}\}$ 
9:     for each  $J_t^{i,j} \in \mathcal{B}_t^i$  do
10:       $S_c^{i,j} \leftarrow V_c(\mathcal{H}_t, J_t^{i,j}, O_t, I)$ 
11:       $S_a^{i,j} \leftarrow V_a(J_t^{i,j}, O_t, I)$ 
12:       $S_t^{i,j} \leftarrow S_c^{i,j} \times \hat{S}_a^{i,j}$ 
13:    end for
14:    Sample  $u \sim \text{Uniform}(0, 1)$ 
15:     $j^* \leftarrow \arg \max_j S_t^{i,j}$ 
16:    if  $u \leq \epsilon$  then
17:      Execute  $a_t$  from  $\text{Random}(\mathcal{B}_t^i)$ 
18:    else if  $S_t^{i,j^*} \leq \eta$  then
19:      Generate feedback  $F_t^i \leftarrow f(\mathcal{H}_t, J_t^{i,j^*}, O_t, I)$ 
20:      Update  $I \leftarrow \text{Concat}(I, F_t^i)$ 
21:      Update  $\mathcal{A} \leftarrow J_t^{i,j^*}$ 
22:    else
23:      Execute  $a_t = J_t^{i,j^*}$ 
24:    end if
25:  end for
26:  if no sample executed then
27:     $i^* \leftarrow \arg \max_i \mathcal{A}$ 
28:    Execute  $a_t = J_t^{i^*,j^*}$ 
29:  end if
30: end for

```

A.3 联合评分的数学依据

由于动作 a 是在给定推理轨迹 c 的条件下生成的，因此不能假设它们条件独立。为严格论证联合验证分数的乘法形式，本文从任务成功的精确概率分解出发。

设 $Y = 1$ 表示成功， c 表示推理轨迹， a 表示对应的动作序列。本文的目标是估计在给定推理和动作的条件下成功的后验概率：

$$P(Y = 1 \mid c, a) \quad (8)$$

根据概率链式法则和贝叶斯定理，可得

$$\begin{aligned} P(Y = 1 \mid c, a) &= \frac{P(c, a \mid Y = 1) P(Y = 1)}{P(c, a)} \\ &= \frac{P(c \mid Y = 1) P(a \mid c, Y = 1) P(Y = 1)}{P(c, a)} \end{aligned} \quad (9)$$

We further expand $P(Y = 1 \mid c)$ as

$$P(Y = 1 \mid c) = \frac{P(c \mid Y = 1) P(Y = 1)}{P(c)} \quad (10)$$

将其代入前式，得到如下精确恒等式：

$$\begin{aligned} P(Y = 1 \mid c, a) &= \frac{P(Y = 1 \mid c) P(c) P(a \mid c, Y = 1)}{P(c, a)} \\ &= P(Y = 1 \mid c) \frac{P(a \mid c, Y = 1)}{P(a \mid c)} \end{aligned} \quad (11)$$

方程 11 表明，成功的后验概率可以分解为两个可解释的项：

- $P(Y = 1 \mid c)$ ：推理 c 导致成功的概率（反映高层计划的质量）；
- $\frac{P(a \mid c, Y = 1)}{P(a \mid c)}$ ：一个似然比，衡量在成功执行下动作 a 的可能性相对于其在给定 c 下的一般可能性有多大。它衡量在给定推理下动作与成功的兼容性。

在实践中，在基于同一推理 c 条件的一批样本中，边际项 $P(a \mid c)$ 通常可以近似视为常数，即

$$P(a \mid c) \approx C_c \quad (12)$$

其中 C_c 是所有候选项共享的归一化常数。因此，我们得到比例关系

$$P(Y = 1 \mid c, a) \propto P(Y = 1 \mid c) P(a \mid c, Y = 1) \quad (13)$$

因此，

$$S_c \propto P(Y = 1 \mid c), \quad S_a \propto P(a \mid c, Y = 1) \quad (14)$$

那么联合验证分数可以表示为

$$S_t \propto S_c \times S_a \quad (15)$$

方程 13 对应于联合成功似然。直观上，较高的 S_c 确保推理连贯且目标导向，而较高的 S_a 确保所选动作与该推理下的成功结果一致。因此，它们的乘积同时反映了深思熟虑的可靠性和控制可靠性。

A.4 E-TTS 中使用的提示

带反馈的采样提示 我们说明反馈引导的细化在实际中如何应用。对于 E-CoT [47]，来自先前尝试的反馈被用于迭代调整推理轨迹和动作预测，从而改善计划对齐和动作精确率。以下提示展示了如何将反馈纳入 E-CoT 的下一推理-动作迭代：

任务指令： 机器人应采取什么动作来 {TASK}？你是一个机器人助手。根据观察执行以下任务。先前尝试：机器人的推理：{} 监督者反馈：{} 在规划下一个动作时考虑上述反馈。助手：任务：

以下提示展示了如何将反馈纳入 MolmoACT [19] 的下一推理-动作迭代：

任务是 {TASK}。机器人应采取什么动作？为了确定机器人应采取什么动作来 {TASK}，请考虑以下内容。以下是先前的推理和反馈：- 先前推理（思维轨迹）：{} - 监督者反馈：{} 请考虑上述监督者的反馈，以改进你的下一推理和动作决策。让我们逐步思考。首先，这张图像的深度图是什么？其次，末端执行器的轨迹是什么？基于图像的深度图和末端执行器的轨迹，机器人应采取什么动作？

以下提示展示了如何将反馈纳入 ER-1 [46] 的下一推理-动作迭代，任务为“选择抓取点”：

提供该句子描述的对象区域的一个或多个点坐标：{TASK}。结果以 `<point>[[x1,y1], [x2,y2], ...]` 格式呈现。先前尝试：机器人的推理：{} 监督者反馈：{} 你首先将推理过程作为内心独白进行思考，然后提供最终答案。推理过程和答案分别包含在 `<think></think>` 和 `<answer></answer>` 标签中。答案仅由几个坐标点组成，整体格式为：`<think>此处为推理过程</think><answer><point>[[x1, y1], [x2, y2], ...]`

反馈生成提示 以下提示用于生成反馈：

你是一位专业的机器人任务监督专家，负责提供建设性反馈。你的任务：分析图像中的当前情况以及机器人的推理和动作。提供具体、可操作的反馈：1. 当前方法可能存在什么问题？2. 机器人应关注或优先考虑什么？3. 哪个具体方面需要调整？4. 如何提高动作质量（奖励）？' 如果 reward_info 否则 " } 请用 2-3 句话给出简洁、可操作的反馈。要有建设性且具体。总体目标：{instruction} 机器人当前推理：{reasoning_text} 评估分数：{score:.2f}（低分表明当前计划可能存在问题）{reward_section}

A.5 推理验证器

在本文的实现中，我们采用 Qwen2.5-VL-7B [1] 作为推理验证器，因为它具备强大的多模态感知和推理能力。为了适应

具身决策中多样化的推理模态，我们将推理分为三种类型：

(1) 多模态推理。作为多模态推理的代表，E-CoT [47] 将视觉感知与文本任务理解相结合，生成能够有效连接高层任务目标和低层动作的推理轨迹。这种推理类型将任务指令中描述的空间和功能语义与当前观测 o_t 中的感知证据对齐，生成具有上下文基础的中间推理步骤。在本文的实现中，文本推理轨迹保持为文本，而视觉感知结果被渲染到图像上以构建结构化的视觉提示。这种设计使推理验证器 V_c 能够评估跨模态一致性和候选计划的合理性。E-CoT 中的每个推理轨迹都按层次组织，以捕捉完整的决策过程，包括总体任务、分解的计划、各个子任务及其对应的子任务推理，以及低层动作规范，如移动、移动推理、夹爪位置和可见物体。通过以结构化格式表示感知基础和动作相关推理，E-CoT 使 V_c 能够评估推理轨迹的连贯性、上下文对齐和任务可行性，构成我们历史感知、反馈引导的验证框架的基础。

(2) 文本推理。文本推理侧重于纯粹的语言推理形式，例如直接从任务指令中推导出的目标分解和时间计划序列。在这种推理范式中，高层计划以自然语言表示，捕捉子目标序列及其依赖关系，而不依赖于感知基础。推理验证器 V_c 通过上下文嵌入评估这些文本计划的逻辑连贯性和任务相关性，确保每个提议的步骤与总体任务目标一致。代表性工作如 ER-1[46] 生成 `<think>` 轨迹，例如 `<think>` 我应该先抓住把手并将其从底座上提起...`</think>`，而 thinkACT 则以自然语言生成逐步指令，例如“要将草莓放入抽屉，机器人需要：1. 拿起草莓...”。通过以这种结构化方式编码纯粹的语言推理， V_c 可以评估高层计划的可行性和一致性，构成我们面向顺序具身任务的历史感知、反馈引导验证框架中的关键组成部分。

这两类评估的提示如下：

你是一位专业的机器人任务监督员。你的职责是判断机器人的思考过程在当前情境下是否合理。你的任务：基于总体目标、从历史到当前观察的视觉进展、近期动作历史（如有提供）以及当前机器人的内部推理，评估：机器人的

当前计划是否逻辑连贯，并且是否代表实现目标的有前景的一步？考虑它是否建立在先前动作之上或与之矛盾。仅用单词“是”或“否”回答。总体目标：“{指令}”
 {image_description} {history_context} 当前机器人对其下一步动作的内部推理：—
 {ecot_reasoning_text} —

(3) 空间推理。空间推理聚焦于轨迹层面和基于关键点的推理，其中推理轨迹被转换为视觉提示，以捕捉机器人在场景中的预期空间配置。为引导推理验证器 V_c 评估空间合理性，我们构建了具有不同预测意图与场景几何对齐程度的代表性示例。高置信度示例对应于预测空间配置与可观测环境紧密匹配的推理轨迹，而低置信度实例则反映了错位或物理上不可行的空间基础。该设计使 V_c 能够有效区分基础良好与不一致的空间推理，确保在历史感知、反馈引导的框架内对空间意图进行稳健评估。

代表性工作如 MolmoACT[19] 通过结合深度感知令牌（例如<depth_95>）和指定轨迹关键点的视觉推理轨迹（例如 [[123,242],[245,163]]）来编码空间推理，提供了一种直接为验证器评分提供信息的结构化表示。具体而言，我们将关键点叠加在观测图像上，其中蓝色和红色端点分别表示轨迹的起点和终点，如图 5 所示。空间推理评估的提示为：

您是一位专业的机器人任务监督员。您的职责是判断机器人的推理对于给定任务是否正确。您的任务：我们用点和线在图像上绘制机器人的推理。轨迹可视化使用蓝到红的颜色梯度来表示时间序列：蓝色线和点表示机器人规划的起始位置和早期阶段，而红色线和点表示结束位置和后期阶段。梯度显示了机器人末端执行器路径随时间的时序进展。基于总体目标和当前图像，检查机器人的推理。是否正确




图 5：空间推理轨迹的可视化。每个示例显示了表示预测机器人轨迹的叠加关键点，其中蓝色和红色圆点分别表示起点和终点。对齐良好的轨迹对应于物理上合理的推理，而错位的轨迹则表示不一致或不可行的空间基础。

推理是否逻辑、连贯，并且是实现目标的有前景的一步？仅回答“是”或“否”。以下提供几个示例供参考：示例 1：指令：{指令 1} 观察：{图像示例 1} 回答：是 示例 2：指令：{指令 2} 观察：{图像示例 2} 回答：是 示例 3：指令：{指令 3} 观察：{图像示例 3} 回答：否 总体目标：“{指令}” 当前观察：{图像观察} 近期历史（可选）：对于每个历史观察和推理对：观察：{历史图像示例} 推理轨迹：{历史推理轨迹}

A.6 动作验证器

为了评估每个推理轨迹的候选动作，我们引入了一种受 [17] 启发的学习型动作验证器架构。该验证器以当前观察 o_t 、任务指令 I 和采样动作 a 作为输入，并输出一个置信度分数 S_a ，表示该动作在给定指令下成功的可能性。验证器在基于专家演示派生的动作比较的合成偏好数据集上进行训练。对于每个观察-指令对，从策略中采样多个候选动作，并计算相对于专家动作的真实误差度量。质量较高的动作被标记为更优。遵循 [17]，动作验证器采用 LLaVA-7B[27] 作为骨干网络，将其最后的解嵌入层替换为一个轻量级奖励头，输出标量置信度分数。动作验证器仅在基础 VLA 策略的同一数据集上进行预训练，严格排除所有评估环境和测试任务。在推理时，对于观察 o 、推理 c 和指令 I 下的每个候选动作 a ，验证器输出

$$S_a = V_a(o, I, a) \quad (16)$$

该分数被归一化到 $\hat{S}_a$ ，随后与推理轨迹分数结合以产生联合分数。

A.7 自适应在线联合选择

利用用于联合样本的双验证器，联合样本批次中的每个 $J_t^{i,j} = (c_t^i, a_t^{i,j})$ 被赋予一个分数 $S_t^{i,j}$ 。尽管联合评分提供了推理-动作一致性的稳健度量，但天真地评估所有批次可能在计算上昂贵，并可能导致冗余探索，尤其是在动作空间较大的长时程具身任务中。为了解决这个问题，我们提出了一种自适应在线选择策略，在推理过程中动态平衡探索与利用，该策略可以表示为：

$$J_t^{\mathcal{B}_i} = \begin{cases} \text{Random}(\mathcal{B}_t^i), & u \leq \epsilon \\ J_t^{i,j^*}, & u > \epsilon \text{ and } S_t^{i,j^*} > \eta \\ \text{next batch } \mathcal{B}_t^{i+1}, & u > \epsilon \text{ and } S_t^{i,j^*} \leq \eta \end{cases} \quad (17)$$

其中 $J_t^{\mathcal{B}_i}$ 是从批次 $\mathcal{B}_t^i$ 在时间步 t ， $u \sim$ 均匀分布 $(0,1)$ 中选出的推理-动作对，用于决定探索与利用， ϵ 是探索概率， J_t^{i,j^*} 是具有联合得分 S_t^{i,j^*} ， η 的最高得分对，是质量阈值， $\mathcal{B}_t^{i+1}$ 是下一个候选批次。该设计体现了若干原则性考量。首先，乘法联合得分明确要求推理质量和动作质量都高，这在具身任务中至关重要，因为仅计划良好而对应动作不可行是不够的。其次， ϵ -贪心策略鼓励系统探索替代的推理-动作假设，防止过早收敛到次优轨迹。最后，阈值 η 过滤掉低置信度候选，同时动态地将计算资源分配给最有前景的对。这些设计选择共同使框架能够在测试时扩展期间实现高效、鲁棒和自适应的推理-动作对选择，在保持高任务性能的同时最小化冗余评估。联合得分和选择过程的定性结果如图 6 所示。如图 6 所示，模型生成多个联合样本对，每个对关联一个联合得分。在第一个推理实例中，模型表现出显著的感知失败，未能识别场景中的透明塑料勺。因此，生成的移动推理缺乏具体目标，导致联合得分低并拒绝该动作。在第二次迭代中，尽管模型成功检测到勺子，但忽略了蓝色布（目标放置区域）。相比之下，第三次推理尝试通过正确感知所有关键环境实体（包括勺子和蓝色布及其各自的空间坐标）获得了最高的联合得分（0.7982）。该选定动作的成功执行表明，鲁棒的目标检测是逻辑一致的机器人操作的前提。



图 6: 选择过程示例。该图展示了三次迭代。前两次因目标检测不完整（分别遗漏勺子和布）而被拒绝，而第三次成功识别所有目标并获得最高联合得分以供执行。

A.8 反馈引导的迭代细化示例

表 6: 代表性批次，展示思维链得分、动作奖励、联合得分及两行反馈摘要。

Step-Batch	CoT Score	Max Action Reward	Joint Score	Supervisor Feedback
10-1	0.1754	0.4385	0.0769	Robot moved towards spoon but selected incorrect one; should distinguish correct spoon relative to towel.
10-2	0.0608	0.2494	0.0152	Robot moved forward without aligning gripper; feedback suggests adjusting gripper position to improve grasp.
10-3	0.1296	0.3972	0.0515	Robot still misaligned; feedback reinforces correct gripper alignment and positioning.
10-4	0.5883	0.3403	0.2002	-

我们在表 6 中通过一个具体任务实例来说明反馈引导的迭代优化过程，该任务要求机器人将勺子移动到毛巾上。该过程在单样本生成与经验证的联合推理-动作采样之间交替进行。最初，系统在步骤 0-9 中生成候选推理轨迹和动作，但未进行验证。从步骤 10 开始，我们引入剪枝与验证机制。对于每个批次，采样一条推理轨迹，并生成多个候选动作。每个动作使用联合推理-动作得分进行评分，该得分结合了轨迹合理性与预测的动作奖励。低于接受阈值的样本被剪枝，并生成针对性反馈以指导下一轮迭代。例如，早期迭代显示机器人在多个可见物体中错误识别目标勺子，导致联合得分较低（0.0769-0.0515），并触发纠正性反馈。到步骤 10 的第四次尝试时，系统开始接受联合得分较高（0.2002）的样本，并开始为下一时间步生成推理和动作。然而，我们也观察到在进行第二次采样时得分下降，这主要是因为反馈扰动了模型的即时策略

并推动其探索尚未优化的替代推理-动作轨迹。尽管存在这种短期退化，但此类反馈驱动的探索是有益的，因为它引导模型更准确地理解物体，并最终在后续迭代中产生更高质量的样本。该示例证明了带反馈的迭代优化的有效性：低质量动作被剪枝，提供纠正性指导，推理-动作一致性逐步提升，从而无需穷举搜索即可实现稳健的任务执行。

A.9 反馈引导的迭代优化示例

监督者反馈

我们展示了反馈引导的迭代优化过程中的一个关键迭代，任务为：将勺子放到毛巾上。机器人生成一个推理样本，评估多个候选动作，并剪枝低于联合得分阈值的样本。随后生成监督者反馈以指导后续批次。时间步 10 的示例如表 6 所示。

反馈示例：例如，在表 6 中的步骤 10-2 中，监督者反馈为：

“机器人似乎专注于向勺子移动，但尚未正确抓取。它应优先确保夹爪与勺子正确对齐，然后再尝试拾取。一个小的调整可以是优化抓取位置，使其更直接地对准勺子的放置位置。这应有助于通过使下一步动作更精确和有效来提升动作质量。”

该反馈被纳入下一次推理生成中，引导机器人调整其推理并改进后续动作。通过迭代地结合推理评估、动作验证和监督者反馈，机器人逐步实现更精确和有效的操作。

B 仿真中的评估细节

B.1 实现

所有实验使用相同的推理和验证流程，并采用少量任务级超参数以平衡计算量和样本多样性。实验重复三次以获得平均结果。对于主论文中报告的 E-CoT [47] (E-TTS) 配置，我们使用：每 10 步评估一次，探索概率 $\epsilon = 0.1$ ，以及阈值 $\eta = 0.4$ 。通过将随机种子固定为 42 来确保可重复性。为限制运行时间，对于每个批次，我们采样 20 个动作，最大批次数量为 20。验证器维护一个大小为 $k = 3$ 的短历史窗口（最近的推理-动作对），以在评分期间提供时间上下文。

我们评估了两个对比基线模型，对上述超参数进行了小幅受控修改。对于 MolmoAct [19]，我们保留 E-CoT 配置，但将最大批次数减少到 $m = 25$ 。对于 ER-1 [46]，我们设置了更保守的采样预算和阈值： $m = 20$ 和 $\eta = 0.3$ 。选择这些变体设置是为了尊重每个基线的计算特性，同时保持整体实验比较的公平性。在我们的实验中，朴素的测试时扩展（TTS）基线采用了 best-of-N 策略 [25]。具体来说，对于每个采样时间步，模型通过独立扩展推理和动作组件生成 N 个候选解。然后使用与本文方法相同的视觉-语言基础模型评估每个候选解，并选择验证得分最高的候选解作为最终输出。该策略旨在通过利用多次尝试来提升性能，而不引入本文方法中更复杂的推理或规划机制。形式上，对于时间步 t ，给定 N 个候选推理-动作对 $\{J_t^1, \dots, J_t^N\}$ 及其对应的验证得分 $\{S_1, S_2, \dots, S_N\}$ ，选出的对 J_t^* 为：

$$J_t^* = \arg \max_{i \in \{1, \dots, N\}} S_i.$$

这种简单方法作为一个强大的朴素基线用于比较。 N 被设置为本文采样迭代次数的平均值，对于 E-CoT 为 $N = 15$ ，对于 MolmoAct 为 $N = 5$ ，对于 ER-1 为 $N = 5$ 。对于 RoboMonkey，在每个时间步 t ，它首先从 VLA 模型生成一组 $\hat{N}$ 个候选动作 $\hat{A}$ ，并拟合一个多元高斯分布 $\mathcal{N}(\mu_t, \Sigma_t)$ 。然后从该拟合的提议分布中重新采样一组 $\hat{K}$ 个新动作 $\tilde{A}$ ，每个精炼动作由奖励模型 R 评估，并选择使奖励最大化的动作执行。这里 N 和 K 对于 E-CoT 分别为 2 和 10。

B.2 基线模型

E-CoT 在本文实验中，我们采用基线模型 **E-CoT** [47]，其中预训练的视觉-语言骨干网络经过微调，将图像观测和语言指令直接映射到机器人动作。我们将该架构用作比较评估的“基线模型”，不进行额外训练或微调。具体来说，基线模型以指令字符串 I 和当前图像观测 o_t 作为输入，以自回归范式生成推理 c_t 并预测动作 a_t 。**E-CoT** 的推理迹可归类为多模态推理，包含以下核心类型：

- **任务**：对原始指令的重述或细化。
- **计划**：为实现目标而设计的高层子任务序列。
- **子任务**：为当前决策步骤选定的具体子任务。
- **子任务推理**：根据场景和指令选择当前子任务的理由或依据。

- **动作**: 原始运动指令 (例如, “前进”、“左转”) 以推进至子任务目标。
- **运动推理**: 解释为何选择该特定运动, 基于观测或机器人状态。
- **夹爪位置**: 在抓取或操作时预测或参考的末端执行器位置 (图像或世界坐标)。
- **可见物体**: 场景中检测到的命名物体及其边界框或空间描述列表, 支持基于依据的推理。

这些推理类别使策略能够首先对任务进行推理, 然后通过物体边界框和夹爪位置理解场景, 最后预测低级动作, 从目标到计划再到详细运动。

ER-1 本文将具身 R1 (Embodied-R1, **ER-1**) [46] 作为基础模型之一。具身 R1 是一个 30 亿参数的视觉语言模型, 通过文本推理整合空间推理与顺序操作。**ER-1** 采用“指向”作为统一的、与具体形态无关的中间表示。这种以点为中心的方法充当桥梁, 将模型的高层感知理解转化为紧凑的空间信号, 从而引导底层动作执行。在架构上, 具身 R1 基于 Qwen2.5-VL 模型 [1] 构建, 并经过微调以掌握四种不同的指向能力: 用于目标定位的指代表达定位 (Referring Expression Grounding, REG)、用于指定放置位置的区域指代定位 (Region Referring Grounding, RRG)、用于识别可供性的目标功能定位 (Object Functional Grounding, OFG) 以及用于规划以物体为中心轨迹的视觉迹生成 (Visual Trace Generation, VTG)。一个关键设计选择是训练方法论。作者没有采用传统的监督微调 (Supervised Fine-Tuning, SFT), 而是采用两阶段强化微调 (Reinforced Fine-tuning, RFT) 课程。该范式由定制整理的具身点 20 万数据集和多任务奖励函数驱动, 专门用于克服指向任务中固有的“多解困境”, 即多个坐标都可能成为有效答案。生成的点最终由下游动作执行器消费, 从而实现模块化且可泛化的零样本控制。给定自然语言指令和场景观测, 模型首先生成如下格式的内部推理迹:

<think> 我应首先抓住把手并将其从底座上提起。抽屉位于桌面上, 位置更靠后, 更靠近墙壁。我需要避开障碍物, 小心地将摩卡壶从当前位置移动到抽屉右侧。</think>

该文本推理明确捕捉了空间关系和任务顺序, 形成了感知与控制之间可解释的中间步骤。最终动作预测同时以视觉输入和生成的推理迹为条件, 使底层运动控制与高层任务意图对齐。ER-1 首先生成文本推理, 然后使用 CuRobo 运动规划器 [36] 预测目标可供性点和目标区域点, 随后在 WidowX 机械臂上进行零样本部署, 用于 Simpler 评估。

MolmoAct 虽然许多现有的视觉-语言-动作 (VLA) 模型通常将感知和指令直接映射到动作, 但 **MolmoAct** [19] 引入了一种新颖的方法, 通过结构化的推理流程将感知、规划和控制整合在一起, 并明确地在空间中进行。这涉及生成深度感知令牌序列、视觉推理轨迹, 最后生成精确的动作令牌, 从而确保空间上具有依据且可解释的行为。具体而言, 该模型采用深度感知令牌来实现三维理解, 这对于需要空间感知的任务至关重要。此外, **MolmoAct** 生成二维视觉推理轨迹, 表示规划的末端执行器轨迹, 直接将视觉输入与控制输出对齐。这种方法与将复杂三维轨迹提炼为语言描述的方法形成对比, 后者可能导致信息丢失。通过将每个推理阶段以前一阶段的输出为条件, **MolmoAct** 确保最终动作在推断深度和规划运动的基础上具有鲁棒性。给定自然语言指令和场景观察, 模型首先生成以下格式的内部推理轨迹:

图像的 深度图 为: <DEPTH_START> <DEPTH_26> <DEPTH_56>
 <DEPTH_75> <DEPTH_101> <DEPTH_69> <DEPTH_55> <DEPTH_25>
 <DEPTH_69> <DEPTH_8> <DEPTH_32> <DEPTH_101> <DEPTH_125>
 <DEPTH_26> <DEPTH_75> <DEPTH_25> <DEPTH_55> <DEPTH_25>
 <DEPTH_9> <DEPTH_69> <DEPTH_32> <DEPTH_26> <DEPTH_74>
 <DEPTH_116> <DEPTH_84> <DEPTH_75> <DEPTH_74> <DEPTH_116>
 <DEPTH_116> <DEPTH_9> <DEPTH_69> <DEPTH_26> <DEPTH_116>
 <DEPTH_74> <DEPTH_9> <DEPTH_125> <DEPTH_74> <DEPTH_25>
 <DEPTH_116> <DEPTH_9> <DEPTH_69> <DEPTH_26> <DEPTH_84>
 <DEPTH_28> <DEPTH_25> <DEPTH_8> <DEPTH_25> <DEPTH_116>
 <DEPTH_25> <DEPTH_9> <DEPTH_8> <DEPTH_101> <DEPTH_55>
 <DEPTH_103> <DEPTH_25> <DEPTH_74> <DEPTH_56> <DEPTH_9>
 <DEPTH_116> <DEPTH_9> <DEPTH_32> <DEPTH_75> <DEPTH_116>
 <DEPTH_9> <DEPTH_74> <DEPTH_28> <DEPTH_32> <DEPTH_8>
 <DEPTH_69> <DEPTH_69> <DEPTH_69> <DEPTH_75> <DEPTH_26>
 <DEPTH_32> <DEPTH_55> <DEPTH_74> <DEPTH_8> <DEPTH_56>
 <DEPTH_8> <DEPTH_8> <DEPTH_8> <DEPTH_75> <DEPTH_26>
 <DEPTH_8> <DEPTH_74> <DEPTH_74> <DEPTH_9> <DEPTH_56>
 <DEPTH_101> <DEPTH_56> <DEPTH_56> <DEPTH_69> <DEPTH_8>
 <DEPTH_84> <DEPTH_76> <DEPTH_103> <DEPTH_30> <DEPTH_69>
 <DEPTH_55> <DEPTH_25> <DEPTH_116> <DEPTH_END>. 图像中末端
 执行器的轨迹为: [[108,59], [81,89], [76,111], [76,125], [78,71]]。

$\pi_{0.5}$ $\pi_{0.5}$ 是一个基于 π_0 的分层视觉-语言-动作 (VLA) 模型, 实现了机器人操作的开世界泛化。该模型从网络训练的视觉-语言模型 (VLM) 初始化, 首先在混合数据集上进行预训练, 使用 FAST 分词器进行离散动作表示, 然后进行后训练以用于

基于流匹配的动作专家进行移动操作以生成连续动作，并融入人类指令数据以优化高层子任务推理。该模型在单一变换器架构中统一了高层语义推理与低层动作预测，通过组合损失函数融合离散与连续动作表示，并利用多源知识迁移实现对未见家庭环境的泛化。在推理时， $\pi_{0.5}$ 首先通过其统一的变换器主干从全局语言提示、机器人视觉观测和本体感受状态中推断出高层语义子任务，然后以该预测子任务为条件，驱动专用动作专家生成细粒度的连续低层动作块，用于端到端的移动机械臂控制。给定自然语言指令和场景观测，模型首先生成如下格式的内部推理轨迹：

拿起枕头。

B.3 SimplierEnv 评估细节

我们在 SimplierEnv [24] 仿真套件中进行实验，这是一个开源的实到仿基准，旨在标准化和可复现的条件下评估通用操作策略 [24]。SimplierEnv 提供两种互补的评估机制：视觉匹配，使仿真场景与真实外观对齐；变体聚合，系统性地改变场景配置（光照、干扰物和纹理）以评估鲁棒性。使用 SimplierEnv 可以快速且一致地对具身推理-动作模型进行基准测试，同时保持与真实机器人行为的高度相关性。对于三项代表性工作，我们在 widowx 机器人设置下对 E-CoT [47] 和 Embodied-R1 [46] 在 SimplierEnv 仿真上进行了测试。对于 Molmoact [19]，我们在 google 机器人设置下对 E-TTS 在 SimplierEnv 仿真上进行了测试。为确保与其他方法的公平且可复现的比较，我们的评估遵循 Embodied-R1 和 Molmoact 的官方 SimplierEnv 设置。至于 E-CoT，鉴于论文中未报告其在 SimplierEnv 上的性能，我们仅将最大时间步设为 500 以充分评估其能力，其余设置保持默认。我们报告成功率作为主要评估指标，计算方式为每个任务下成功试验次数与总试验次数之比，并在视觉匹配和变体聚合两种设置下对所有任务取平均。

谷歌机器人。我们遵循标准评估套件，包含四个具有代表性的语言条件操作任务：（1）抓取可乐罐，机器人抓取并举起放置在桌面不同位置和方向的可乐罐，共 75 次试验。（2）将 {obj1} 移动到 {obj2} 附近，涉及 8 个家用物品和多种空间布局以测试关系推理，共 60 次试验。（3）打开/关闭（上、中、下）抽屉，评估机器人从不同姿态控制关节物体的能力，共 54 次试验。（4）打开顶部抽屉；将苹果放入顶部抽屉，这是一个长时程

组合任务，结合了顺序子目标，共 27 次试验。每种配置遵循官方的基于网格的初始机器人和物体姿态采样。

WidowX 机器人。对于 WidowX 机器人，我们评估四个桌面操作任务：（1）将勺子放在毛巾上，（2）将胡萝卜放在盘子上，（3）将茄子放入黄色篮子。每个任务评估 24 次试验。

B.4 LIBERO 评估细节

我们在 Franka Emika Panda 机械臂的 LIBERO 仿真基准上评估 MolmoAct [19]，这是一个全面的多任务基准，旨在评估机器人操作系统的能力。每个演示包括前视图和腕视图 RGB 图像、自然语言任务指令以及末端执行器位姿增量轨迹。我们遵循 [19]，在四个不同的任务上评估 E-TTS：LIBERO-Spatial、LIBERO-Object、LIBERO-Goal 和 LIBERO-Long，每个任务包含 10 个任务类别和 500 个专家演示。为了公平比较，我们将 MolmoAct 的动作块设置为固定窗口大小 8。

B.5 E-CoT 实验

表 7: Simpler 环境上的成功率 (%) 和推理延迟 (秒/步) 比较。本文方法以极小的计算开销实现了显著的性能提升。

Method	Spoon on Towel		Eggplant in Basket		Carrot on Plate		Average	
	SR↑	Time↓	SR↑	Time↓	SR↑	Time↓	SR↑	Time↓
E-CoT + Robomongokey	33.33	12.81	8.33	11.75	37.50	12.81	26.38	12.46
E-CoT + Ours	59.10	14.77	22.73	13.02	38.10	12.49	39.98	13.43

我们在三个具有代表性的操作任务上，对本文方法与基础模型 E-CoT [47] 进行了定性比较。如图 7 所示，E-CoT 经常出现抓取不准确或物体与目标表面之间错位的情况，即使在延长的时间步长后仍导致任务失败。相比之下，采用 E-TTS 后，它能够成功完成所有任务，并具有清晰的空间对齐和稳定的放置行为。性能提升主要源于我们增强的推理-动作耦合机制，该机制使模型能够更好地解释空间关系并动态调整运动轨迹。此外，采用 E-TTS 后，E-CoT 实现了更快的收敛（例如， $t = 21$ vs. $t = 499$ ），并且在不同的物体几何形状和环境中具有更一致的成功率，展示了在具身操作中优越的鲁棒性和泛化能力。




图 7: 在 SimplerEnv 上对 E-CoT 与 E-CoT+本文方法 (E-TTS) 在三个操作任务上的定性比较: “将勺子放在毛巾上”、“将茄子放入篮子中”和“将胡萝卜放在盘子上”。每一行显示时间执行帧。虽然 E-CoT 经常无法完成放置动作, 但本文方法实现了精确的物体操作, 完成时间更短, 成功率更高。




图 8: E-CoT + 本文方法在“将胡萝卜放在盘子上”任务中表现出的自我纠正行为可视化。每一行显示同一次 rollout 中的连续尝试。在第一次和第二次尝试未能将胡萝卜与盘子对齐后，模型通过闭环反馈重新评估其推理和动作候选，并在第三次尝试中成功完成任务。这证明了我们历史感知的联合推理-动作扩展在实现顺序操作中的自适应纠正方面的有效性。

表 8: 在 Simpler WidowX 基准上的定量比较。 E-TTS (ER-1+本文方法) 在所有任务上均实现了一致的性能提升。成功率以成功执行的百分比报告。

Method	Spoon on Towel	Eggplant in Basket	Carrot on Plate	Average
ER-1	62.50%	4.17%	52.78%	39.82%
ER-1 + naive TTS	63.88%	5.55%	51.38%	40.27%
ER-1 + Ours (E-TTS)	65.27%	8.33%	61.11%	44.90%

如表 7 所示, 本文方法在所有场景中均优于基线 Robomongokey。具体而言, 平均成功率相对提升 51.5% (从 26.38% 提升至 39.81%), 而平均延迟仅边际增加 7.8%。值得注意的是, 在特定任务如将胡萝卜放在盘子上 (记为“Carrot”) 中, E-TTS 甚至降低了平均推理时间 (12.49 秒对比 12.81 秒)。这种性能与效率的权衡凸显了 E-TTS 的有效性, 且无需承担通常沉重的计算开销负担。进一步发现, E-CoT + 本文方法在具身操作中具备自我纠正能力。如图 8 所示, 机器人最初因抓取或轨迹预测欠佳而未能将胡萝卜放在盘子上。然而, 模型并未终止回合, 而是利用缓冲区中存储的历史观测来优化推理, 并通过验证器的反馈重新采样改进的动作。这种迭代优化使模型能够从先前失败中恢复, 并最终在后续尝试中成功, 且无需任何外部监督。此类闭环适应性在传统测试时扩展方法中并不存在, 凸显了在具身任务中联合扩展推理与动作并利用历史感知反馈的优势。

B.6 Embodied-R1 实验

我们在 Simpler WidowX 基准上评估了所提出的 E-TTS 模块的有效性, 并将其与基线 ER-1 [46] 以及一种朴素的测试时扩展 (TTS) 变体进行了比较。如图 9 和图 8 所示, ER-1 在涉及精确空间推理和稳定物体放置的任务中表现困难, 常常导致部分完成或失败。朴素的 TTS 方法提升有限, 表明仅仅增加文本推理不足以实现稳健执行。相比之下, 我们的 E-TTS 方法显著提高了所有任务的操作成功率, 尤其是在“将茄子放入篮子”等场景中, 成功率相比 ER-1 翻倍。这一改进源于 E-TTS 能够通过推理引导的轨迹采样与验证动态细化动作表示, 使模型在执行过程中理解上下文线索并纠正运动误差。总体而言, E-TTS 不仅将任务完成准确率平均提高了 5% 以上, 还产生了更平滑、更接近人类的操作行为, 展示了其在具身环境中强大的泛化与控制能力。



图 9: ER-1 与 ER-1+本文方法 (E-TTS) 在 SimplerEnv 上三个操作任务的定性比较：“将胡萝卜放在盘子上”、“将茄子放入篮子”和“将勺子放在毛巾上”。ER-1 常因空间推理不准确而无法完成精细放置，而本文的 E-TTS 增强模型实现了更一致的物体对齐和成功的任务完成。

B.7 MolmoAct 实验

表 9: VLaBench 基准上的性能比较。我们报告了各任务的成功率 (SR)。

Method	Track	AC	IF	SB	SCT	SD	SF	SM	SNLP	SPa	SPo	ST	SUM	Avg.
$\pi_{0.5}$	Track 1	0.50	0.18	0.48	0.48	0.42	0.38	0.44	–	0.28	0.46	0.28	–	0.39
	Track 2	0.06	–	0.02	0.15	0.14	0.44	0.20	–	0.28	0.40	0.14	–	0.20
	Track 3	0.14	0.08	0.38	0.50	0.14	0.24	–	0.14	0.16	–	0.04	0.04	0.19
	Track 4	0.10	0.04	0.38	0.21	0.20	0.18	0.10	–	0.12	0.06	0.08	–	0.15
	Track 6	0.46	0.06	0.45	0.29	0.30	0.24	0.13	–	0.28	0.22	0.04	–	0.25
$\pi_{0.5} + \text{Ours}$	Track 1	0.54	0.20	0.53	0.53	0.48	0.40	0.33	–	0.30	0.63	0.32	–	0.42
	Track 2	0.08	–	0.02	0.16	0.14	0.38	0.33	–	0.30	0.48	0.22	–	0.24
	Track 3	0.18	0.10	0.36	0.54	0.16	0.24	–	0.16	0.26	–	0.06	0.09	0.21
	Track 4	0.16	0.06	0.48	0.24	0.22	0.14	0.14	–	0.10	0.08	0.06	–	0.16
	Track 6	0.43	0.04	0.48	0.31	0.34	0.26	0.11	–	0.32	0.28	0.03	–	0.26

注: 成功率 (SR): 成功率, 缩写: AC: add_condiment, IF: insert_flower, SB: select_book, SCT: select_chemistry_tube, 标准差: select_drink, 缩放因子: select_fruit, 空间映射: select_mahjong, 空间自然语言处理: select_nth_largest_poker, 空间解析: select_painting, 空间定位: select_poker, 空间变换: select_toy, 求和: select_unique_type_mahjong.

本文进行定性比较，以评估在 MolmoAct [19] 框架之上所提改进的有效性。如图 10 所示，MolmoAct 在需要精确空间推理的任务中常常遇到困难，例如正确抓取目标物体或将其与目标区域对齐。例如，在“打开中间抽屉”和“拿起奶油奶酪”任务中，基线由于运动规划不完整和可供性理解不准确而未能执行最后一步。相比之下，采用 E-TTS 后，能够以稳定的操作轨迹和一致的时间进度成功完成所有任务。这一改进源于本文的自适应推理-动作采样与验证模块，该模块基于多模态反馈动态细化空间表示并优化底层运动控制。这种增强不仅产生了更自然、可解释的行为，而且显著减少了所需的时间步数，突显了本文方法在复杂具身操作场景中优越的效率与鲁棒性。

B.8 在 $\pi_{0.5}$ 上的实验

如完整结果所示，将本文方法与基础 $\pi_{0.5}$ 模型集成，可在多样化的任务组合中取得一致的性能提升。具体而言，在赛道 1 中，本文方法的平均成功率从 0.39 显著提升至 0.42，在语义密集型任务（如 select_poker（空间定位））中提升尤为明显，成功率从 0.46 提高到 0.63。本文还将 E-TTS 与 TACO 进行了比较，TACO 是近期一种使用伪计数估计的测试时扩展框架。如表 12 所示，E-TTS 取得了更好的平均成功率，验证了其性能。





图 10: 在 LIBERO 上 MolmoAct 与 MolmoAct+本文方法在四个操作任务上的定性比较：“打开中间抽屉”、“将字母汤放入篮子”、“拿起拉梅金旁边的黑碗并将其放在盘子上”以及“拿起奶油奶酪并将其放入篮子”。MolmoAct 常常无法完成细粒度动作或误解空间关系，而本文方法能够以准确的抓取、正确的放置和更高的时间效率持续完成每项任务。

Task: Put the toy lion on the shelf



Task: Press the sanitizer



图 11：两个代表性任务的真实世界执行过程可视化：将玩具狮子放在架子上（上）和按压消毒液瓶（下）。每一行展示了机器人在执行过程中依次观察到的画面，其中绿色框表示成功的交互，红色框表示失败的尝试。结果突出表明，基础模型结合 E-TTS 能够从之前的失败中恢复，并通过自我纠正行为成功完成任务。

表 10：真实世界数据集的统计信息。

Task description	Episodes	Frames	Avg. length
Pick up the toy lion and place it on the shelf	100	4,577	45.8
Hang the bag on the shelf	100	2,917	29.2
Press the sanitizer	100	1,385	13.8
Put the Coke can on the upper drawer	100	8,899	89.0

C 真实世界实验

我们收集了一个包含 400 个操作片段的真实世界数据集。每条轨迹以 20 赫兹的频率记录，包含同步的第三人称和腕部 RGB 视频流（分辨率分别为 376×672 和 480×672 ），以及 7 自由度末端执行器动作、时间戳和任务标注。该语料库涵盖四种日常操作目标，每个任务有 100 次演示，共包含 17,778 个已标注帧，如表 10 所示。为了评估模型的性能，我们设计了四个不同的操作任务，涵盖非抓取放置任务、长时程任务和可变形物体操作。“狮子”指“将玩具狮子放在架子上”，“袋子”指“将袋子挂在架子上”，“消毒液”指“按压消毒液瓶”，“抽屉”指“将可乐罐放在上层抽屉”。每个任务捕捉了不同的接触动力学和工作空间布局，确保覆盖短时程按钮按压行为和长时程抓取放置操作。这种多样性，结合一致的传感器流和动作表示，使该数据集成为野外多任务策略学习的一个具有挑战性的基准。

表 11：符号列表。E-TTS 框架中使用的数学符号总结。

Notation	Description
I	Task instruction describing the embodied manipulation goal.
O_t	Observation (visual input) at timestep t .
c_t	Reasoning output (intermediate cognitive state) at timestep t .
c_t^i	i -th reasoning output (intermediate cognitive state) at timestep t .
a_t	Action predicted by the policy at timestep t .
$a_t^{i,j}$	j -th action predicted by the policy with c_t^i at timestep t .
$J_t^{i,j} = (c_t^i, a_t^{i,j})$	Joint reasoning-action pair sampled at timestep t .
$B_t^i = \{J_t^{i,j}\}_{j=1}^N$	Joint batch for the i -th joint reasoning-action pair.
$\pi_\theta(c_t, a_t O_t, I)$	Vision-Language-Action policy parameterized by θ .
M	Max Number of reasoning samples.
N	Number of action samples per reasoning trace.
$\mathcal{H}_t = \{J_{t-K}, O_{t-K}, \dots, J_{t-1}, O_{t-1}\}$	History buffer storing past reasoning-action pairs and observations.
K	Window size (length) of the history buffer.
V_c	Reasoning verifier evaluating reasoning quality and consistency.
V_a	Action verifier assessing action feasibility and relevance.
$S_c^{i,j}$	Confidence score from the reasoning verifier.
$S_a^{i,j}$	Confidence score from the action verifier.
$\hat{S}_a^{i,j}$	Normalized action score.
$S_t^{i,j} = S_c^{i,j} \times \hat{S}_a^{i,j}$	Final joint score combining reasoning and action.
ϵ	Exploration rate in the ϵ -greedy selection policy.
η	Confidence threshold for accepting joint samples.
$u \sim \text{Uniform}(0,1)$	Random variable controlling exploration vs. exploitation.
F_t^i	Feedback text describing reasoning flaws and corrective guidance.
$I_t^{i+1} = \text{Concat}(I, F_t^i)$	Refined instruction after feedback-guided update.

表 12: LIBERO-Long 任务上的成功率 (%) 。

Method	汤/ 薯 芝士/ 黄油 炉灶/ 摩卡 黑碗 马克杯/ 盘子 烤架/ 餐具架 马克杯/ 布丁 汤/ 芝士 摩卡/ 炉灶 马克杯/ 微波炉 平均										
$\pi_{0.5}$	98.0	100.0	98.0	98.0	98.0	100.0	96.0	94.0	68.0	98.0	94.8
$\pi_{0.5} + \text{TACO}$	96.0	98.0	100.0	98.0	96.0	100.0	96.0	100.0	76.0	98.0	95.8
$\pi_{0.5} + \text{Ours}$	96.0	98.0	100.0	100.0	98.0	100.0	96.0	98.0	80.0	96.0	96.2

我们进一步分析真实世界的执行过程，以更好地理解模型展现的自我纠正行为。如图 11 所示，机器人偶尔在早期步骤中未能抓取或对准目标物体，但随后会重新评估场景并重试以完成任务。尽管训练中未出现此类行为，它的出现表明我们的方法通过历史感知的验证与反馈机制，有助于提升时序一致性和任务持续性。这种涌现的鲁棒性使智能体能够从轻微动作错误中恢复，并在长时程场景中保持稳定的任务完成。

D 局限性

延迟限制了该方法在高度动态任务中的应用，因为我们的方法继承了测试时扩展的延迟限制，即利用更多推理计算来提升性能。随着更强大的硬件和异步推理的出现，延迟有望进一步降低。未来工作将探索轻量级解决方案以缓解该问题。

E 符号说明

我们在表 11 中总结了所提出的 **E-TTS** 框架中使用的关键符号。在每个时间步 t ，模型观察当前场景 O_t 并接收描述目标操作目标的指令 I 。基于这些输入，视觉-语言-动作策略 $\pi_\theta(c_t, a_t \mid O_t, I)$ 联合采样多个推理-动作对 $J_t^{i,j} = (c_t^i, a_t^{i,j})$ ，其中 c_t^i 表示中间推理迹， $a_t^{i,j}$ 表示相应的动作候选样本。历史缓冲区 $\mathcal{H}_t$ 存储最近的推理-动作对和观察结果，为后续决策提供时间上下文。为了评估采样的候选，采用了两个验证器：推理验证器 V_c ，对推理输出的语义和逻辑可靠性进行评分；动作验证器 V_a ，评估动作预测的物理可行性和任务相关性。它们的输出 $S_c^{i,j}$ 和 $S_a^{i,j}$ 被归一化并组合成联合得分 $S_t^{i,j} = S_c^{i,j} \times \hat{S}_a^{i,j}$ ，以识别最连贯且可执行的推理-动作对。在线推理过程中，采用 ϵ -贪心策略来平衡探索和利用。当所有候选都低于置信度阈值 η 时，触发反馈引导的细化过程：推理验证器生成结构化的文本反馈 F_t^i 解释失败原因，该反馈与原始指令 I 拼接形成更新后的提示 I_t^{i+1} 。这种闭环设计使 **E-TTS** 能够通过迭代细化逐步提高其推理对齐和动作精确率。