

高效的无遗忘测试时模型自适应

Shuaicheng Niu^{*1,2} Jiayang Wu^{*3} Yifan Zhang^{*4} Yaofu Chen¹
 郑世健¹ 赵培林³ Minghui Tan^{1,5}

摘要

测试时自适应 (TTA) 旨在通过针对任意测试样本调整给定模型，以应对训练与测试数据之间潜在分布偏移。当测试环境频繁变化时，该任务对深度模型尤为重要。尽管近期已有一些尝试处理此任务，我们仍面临两个实际挑战：1) 现有方法必须对每个测试样本执行反向计算，导致许多应用难以承受的预测成本；2) 虽然现有 TTA 方案能显著提升分布外数据的测试性能，但它们在 TTA 后往往在分布内数据上出现严重的性能退化（即灾难性遗忘）。本文指出，并非所有测试样本对模型自适应的贡献相同，高熵样本可能产生噪声梯度，从而干扰模型。受此启发，我们提出一种主动样本选择准则，以识别可靠且非冗余的样本，并在这些样本上更新模型以最小化测试时自适应的熵损失。此外，为缓解遗忘问题，我们引入 Fisher 正则化器来约束重要模型参数避免剧烈变化，其中 Fisher 重要性由带有生成伪标签的测试样本估计。在 CIFAR-10-C、ImageNet-C 和 ImageNet-R 上的大量实验验证了所提方法的有效性。代码可在 <https://github.com/mr-eggplant/EATA> 获取。

1. 引言

深度神经网络 (DNNs) 在许多具有挑战性的任务中取得了优异的性能，包括图像分类 (He et al., 2016; Tan & Le, 2019)、视频识别 (Wang et al., 2018; Chen et al., 2021) 以及许多其他领域 (Choi et al., 2018; Fan et al., 2020; Xu et al., 2021)。深度神经网络成功的一个前提是测试样本与训练数据来自相同的分布，然而在许多实际应用中这一前提常常被违背。在实践中，测试样本可能遭遇自然变化或损坏（也称为分布偏移），例如天气变化导致的光照变化以及传感器退化导致的意外噪声 (Hendrycks & Dietterich, 2019; Koh et al., 2021)。不幸的是，模型通常对这种分布偏移非常敏感，并遭受严重的性能下降。

最近，一些尝试 (Sun et al., 2020; Wang et al., 2021; Liu et al., 2021; Zhang et al., 2021b,c; Wang et al., 2022) 被提出通过在测试时在线调整模型（称为测试时自适应）来处理分布偏移。测试时训练 (TTT) (Sun et al., 2020) 首先提出了这一流程。给定一个测试样本，TTT 首先通过旋转分类 (Gidaris et al., 2018) 微调模型，然后使用更新后的模型进行预测。然而，TTT 仍然依赖于额外的训练修改（在模型中添加旋转头），因此获取原始训练数据也是必需的。如果训练数据因隐私/存储问题不可用或训练涉及意外的大量计算，这些要求可能不可行。为了避免这些问题，Tent (Wang et al., 2021) 和 MEMO (Zhang et al., 2021b) 提出了完全测试时自适应的方法，其中自适应仅涉及测试样本和已训练的模型。

* 同等贡献。本工作完成于牛帅程在腾讯 AI 实验室实习期间。¹ 华南理工大学软件学院，中国² 大数据与智能机器人教育部重点实验室，中国³ 腾讯 AI 实验室，中国⁴ 新加坡国立大学，新加坡⁵ 琶洲实验室，中国。通讯作者：谭明奎 <mingkuitan@scut.edu.cn>。

尽管最近的测试时自适应方法在处理测试偏移方面是有效的，但它们仍然存在以下局限性。首先，由于我们在测试时调整模型，自适应效率在许多延迟敏感的场景中非常重要。然而，先前的方法依赖于对每个测试样本执行反向计算（甚至对单个样本执行多次反向传播，如 TTT (Sun et al., 2020) 和 MEMO (Zhang et al., 2021b)）。由于执行过多的反向传播非常耗时，这些方法

表 1. 将训练好的模型适配到可能发生偏移的测试域的问题设置特征。“离线”适配假设可以访问整个源或目标数据集，而“在线”适配可以立即预测单个或一批传入的测试样本。

Setting	Source Data	Target Data	Training Loss	Testing Loss	Offline	Online	Source Acc.
Fine-tuning	$\times$	$\mathbf{x}^t, y^t$	$\mathcal{L}(\mathbf{x}^t, y^t)$	–	$\checkmark$	$\times$	Not Considered
Continual learning	$\times$	$\mathbf{x}^t, y^t$	$\mathcal{L}(\mathbf{x}^t, y^t)$	–	$\checkmark$	$\times$	Maintained
Unsupervised domain adaptation	$\mathbf{x}^s, y^s$	$\mathbf{x}^t$	$\mathcal{L}(\mathbf{x}^s, y^s) + \mathcal{L}(\mathbf{x}^s, \mathbf{x}^t)$	–	$\checkmark$	$\times$	Maintained
Test-time training	$\mathbf{x}^s, y^s$	$\mathbf{x}^t$	$\mathcal{L}(\mathbf{x}^s, y^s) + \mathcal{L}(\mathbf{x}^s)$	$\mathcal{L}(\mathbf{x}^t)$	$\times$	$\checkmark$	Not Considered
Fully test-time adaptation (FTTA)	$\times$	$\mathbf{x}^t$	$\times$	$\mathcal{L}(\mathbf{x}^t)$	$\times$	$\checkmark$	Not Considered
EATA (ours)	$\times$	$\mathbf{x}^t$	$\times$	$\mathcal{L}(\mathbf{x}^t)$	$\times$	$\checkmark$	Maintained

当延迟不可接受时，这些方法可能不可行。其次，这些方法侧重于提升训练模型在分布外（OOD）测试样本上的性能，却忽略了模型在测试时自适应后在分布内（ID）测试样本上遭受严重的性能下降（称为遗忘）（见图 3）。一个合格的测试时自适应方法应同时在 OOD 和 ID 测试样本上表现良好，因为实际测试样本往往同时来自 ID 和 OOD 域。

为了解决上述局限性，我们提出了一种高效的抗遗忘测试时自适应方法（即 EATA），该方法由样本高效优化策略和权重正则化器组成。具体来说，我们设计了一种样本自适应熵最小化损失，其中排除了两类样本的优化：i) 熵值高的样本，因为这些样本提供的梯度高度不可靠；ii) 非常相似的样本。在这种情况下，测试数据流的反向更新总数适当减少（提高效率），同时模型在 OOD 样本上的性能也得到改善。另一方面，我们设计了一种抗遗忘正则化器，以强制模型的重要权重在自适应过程中不发生大的变化。我们基于费舍尔信息（Kirkpatrick 等人，2017）通过一小部分测试样本计算权重重要性。通过这种正则化，模型可以持续自适应，而不会在 ID 测试样本上出现性能下降。

贡献：1) 我们提出了一种主动样本识别方案，以从模型自适应中过滤掉不可靠和冗余的测试数据；2) 我们将标签依赖的费舍尔正则化器扩展到带有伪标签生成的测试样本，以防止重要模型权重的剧烈变化；3) 我们证明了所提出的 EATA 提高了测试时自适应的效率，并缓解了长期被忽视的灾难性遗忘问题。

2. 相关工作

我们根据表 1 中总结的不同自适应设置来划分相关工作的讨论。

测试时自适应 测试时自适应（Test-Time Adaptation, TTA）旨在通过利用测试样本进行模型自适应，提升模型在分布外（OOD）测试数据上的准确率。现有的测试时训练方法，例如 TTT（Sun 等，2020）和 TTT++（Liu 等，2021），通过监督目标和自监督目标联合训练源模型，然后在测试时通过自监督目标对模型进行自适应。然而，这一流程对模型训练方式存在假设，在实际中可能并不总是可控。为解决这一问题，完全测试时自适应方法被提出，仅利用测试数据对模型进行自适应，包括批归一化统计量自适应（Nado 等，2020；Schneider 等，2020；Khurana 等，2021）、测试时熵最小化（Wang 等，2021；Fleuret 等，2021）、不同增强下预测一致性最大化（Zhang 等，2021b）以及分类器调整（Iwasawa 和 Matsuo，2021）。本文遵循完全测试时自适应设定，并致力于解决先前工作的两个关键局限性（即效率瓶颈和灾难性遗忘），以使测试时自适应在实际应用中更加实用。

持续学习 持续学习（CL）旨在帮助模型记住先前已学的基本概念，缓解在新任务上学习时的灾难性遗忘问题（Kirkpatrick et al., 2017; Li & Hoiem, 2017; Rolnick et al., 2019; Farajtabar et al., 2020; Niu et al., 2021; Mittal et al., 2021）。本文与持续学习动机一致，指出测试时自适应同样面临灾难性遗忘（即分布内测试样本上的性能下降），这使得测试时自适应方法部署不稳定。为解决此问题，本文提出一种简单而有效的方案，在仅使用测试数据的情况下维持模型在分布内测试样本上的性能，同时提升在分布外测试样本上的性能。

无监督领域自适应（Unsupervised Domain Adaptation, UDA）。传统的无监督域自适应（UDA）通过在带标签的源数据和未带标签的目标数据上联合优化源模型来应对分布偏移，例如设计域判别器以学习域不变特征（Pei et al., 2018; Saito et al., 2018; Zhang et al., 2020b;a）。为避免访问源数据，近期提出的无源无监督域自适应方法要么通过生成式




图 1. 所提出的 EATA 方法示意图。给定一个训练好的基础模型 f_{Θ^0} ，我们使用一个由 Θ^0 初始化的模型 f_{Θ} 进行测试时自适应。在自适应过程中，我们仅更新 f_{Θ} 中批归一化层的参数，并冻结其余参数。当一批测试样本 $\mathcal{X} = \{\mathbf{x}_b\}_{b=1}^B$ 到来时，我们为每个测试样本计算一个样本自适应权重 $S(\mathbf{x})$ ，以判断该样本是否适合进行自适应。我们仅对满足 $S(\mathbf{x}) \neq 0$ 的样本执行反向传播。此外，我们提出了一种抗遗忘正则化器，以防止模型参数 Θ 相对于 Θ^0 变化过大。

建模 (Li 等人, 2020; Kundu 等人, 2020; Qiu 等人, 2021) 或信息最大化 (Liang 等人, 2020)。然而，此类方法通过多个训练轮次和损失进行离线优化。相比之下，本文方法以在线方式进行自适应，并对给定的目标样本选择性地执行一次反向传播，在推理过程中更为高效。

3. 问题表述

不失一般性，令 $P(\mathbf{x})$ 为训练数据 $\{\mathbf{x}_i\}_{i=1}^N$ （即 $\mathbf{x}_i \sim P(\mathbf{x})$ ）的分布， $f_{\Theta^0}(\mathbf{x})$ 为在带标签训练数据 $\{(\mathbf{x}_i, y_i)\}_{i=1}^N$ 上训练得到的基础模型，其中 Θ^0 表示模型参数。由于训练过程，模型 $f_{\Theta^0}(\mathbf{x})$ 倾向于拟合（或过拟合）训练数据。在推理阶段，模型应在分布内测试数据上表现良好，即 $\mathbf{x} \sim P(\mathbf{x})$ 。然而，在实践中，由于训练数据与测试数据之间可能存在分布偏移，我们可能会遇到许多分布外测试样本，即 $\mathbf{x} \sim Q(\mathbf{x})$ ，其中 $Q(\mathbf{x}) \neq P(\mathbf{x})$ 。在这种情况下，预测将非常不可靠，性能也会很差。

测试时自适应 (TTA) (Wang 等人, 2021; Zhang 等人, 2021b) 旨在仅通过对测试数据进行模型自适应来提升分布外预测性能。具体而言，给定一组测试样本 $\{\mathbf{x}_j\}_{j=1}^M$ ，其中 $\mathbf{x}_j \sim Q(\mathbf{x})$ 且 $Q(\mathbf{x}) \neq P(\mathbf{x})$ ，需要在任何情况下对 $f_{\Theta}(\mathbf{x})$ 进行自适应，以利用测试数据提高预测性能。为实现这一目标，现有方法通常通过最小化定义在测试样本上的某些无监督目标来更新模型：

$$\min_{\tilde{\Theta}} \mathcal{L}(\mathbf{x}; \Theta), \mathbf{x} \sim Q(\mathbf{x}), \quad (1)$$

其中 $\tilde{\Theta} \subseteq \Theta$ 表示应被更新的自由模型参数。

一般而言，测试时学习目标 $\mathcal{L}(\cdot)$ 可以表述为熵最小化问题 (Wang 等人, 2021) 或数据增强上的预测一致性最大化问题 (Zhang 等人, 2021b)。

对于现有的测试时自适应方法，如测试时训练 (TTT) (Sun 等, 2020) 和边缘化熵最小化 (MEMO) (Zhang 等, 2021b)，在测试时自适应过程中，每个样本都需要进行一轮甚至多轮反向计算，这非常耗时，且不利于对延迟敏感的应用。此外，大多数方法假设所有测试样本均来自分布外数据。然而，在实际中，测试样本可能同时来自分布内和分布外。事实上，在许多应用中，测试集可能只包含少量测试样本。仅在分布外测试样本上优化模型可能导致分布内样本的性能严重下降。我们在图 3 中通过实验验证了这一问题的存在，其中更新后的模型在分布内测试样本上的准确率始终低于原始模型。

4. 提出的方法

本文提出了一种抗遗忘测试时自适应 (EATA) 方法，旨在提高测试时自适应的效率，并同时解决现有测试时自适应策略带来的灾难性遗忘问题。如图 1 所示，EATA 包含两种策略。

1) 样本高效熵最小化 (见第 4.1 节) 旨在通过主动样本选择策略进行高效自适应。其中，样本选择过程仅选择主动样本进行反向传播，从而提高整体测试时自适应效率（即减少梯度反向传播）。为此，我们设计了一个主动样本选择分数，记为 $S(\mathbf{x})$ ，用于检测

Algorithm 1 The pipeline of proposed EATA.

Input: Test samples $\mathcal{D}_{test}=\{\mathbf{x}_j\}_{j=1}^M$, the trained model $f_{\Theta}(\cdot)$, ID samples $\mathcal{D}_F=\{\mathbf{x}_q\}_{q=1}^Q$, batch size B .

- 1: **for** a batch $\mathcal{X}=\{\mathbf{x}_b\}_{b=1}^B$ in $\mathcal{D}_{test}$ **do**
- 2: Calculate predictions $\hat{y}$ for all $\mathbf{x} \in \mathcal{X}$ via $f_{\Theta}(\cdot)$.
- 3: Calculate sample selection score $S(\mathbf{x})$ via Eqn. (6).
- 4: Update model ($\tilde{\Theta} \subseteq \Theta$) with Eqn. (2) or Eqn. (8).
- 5: **end for**

Output: The predictions $\{\hat{y}\}_{j=1}^M$ for all $\mathbf{x} \in \mathcal{D}_{test}$.

测试集中可靠且非冗余的测试样本以进行测试时自适应。

2) 抗遗忘权重正则化 (见第 4.2 节) 通过强制对分布内域重要的参数在测试时自适应中不过度变化来缓解知识遗忘。这样, 灾难性遗忘问题可以得到显著缓解。EATA 的伪代码总结在算法 1 中。

4.1. 样本高效熵最小化

为了实现高效的测试时自适应, 本文提出了一种主动样本识别策略, 用于选择样本进行反向传播。具体而言, 本文为每个样本设计了一个主动样本选择分数, 记为 $S(\mathbf{x})$, 该分数基于两个准则: 1) 样本对于测试时自适应应当是可靠的; 2) 参与优化的样本应当是非冗余的。通过为非主动样本 (即不可靠和冗余的样本) 设置 $S(\mathbf{x})=0$, 本文可以在测试时自适应过程中减少不必要的反向计算, 从而提高预测效率。

基于样本分数 $S(\mathbf{x})$, 遵循 (Wang 等人, 2021; Zhang 等人, 2021b) 的方法, 本文使用熵损失进行模型自适应。然后, 样本高效的熵最小化旨在最小化以下目标:

$$\min_{\tilde{\Theta}} S(\mathbf{x}) E(\mathbf{x}; \Theta) = -S(\mathbf{x}) \sum_{y \in \mathcal{C}} f_{\Theta}(y|\mathbf{x}) \log f_{\Theta}(y|\mathbf{x}), \quad (2)$$

其中 $\mathcal{C}$ 是模型输出空间。此处, 熵损失 $E(\cdot)$ 每次在一个批次的样本上计算 (类似于 Tent (Wang 等人, 2021)), 以避免平凡解, 即把所有概率分配给最可能的类别。为了实现高效自适应, 本文更新 $\tilde{\Theta} \subseteq \Theta$ 以及所有批归一化层的仿射参数。

可靠样本识别。 本文的直觉是, 不同的测试样本在自适应过程中会产生不同的效果。为了验证这一点, 本文进行了一项初步研究, 其中选择不同比例的样本 (样本根据其熵值 $E(\mathbf{x})$ 预先排序; Θ) 用于自适应, 并在所有测试样本上评估所得模型。从图 2 中, 本文发现: 1) 在低熵样本上的自适应比在高熵样本上的自适应贡献更大; 2) 在具有非常高熵的测试样本上的自适应




图 2. 不同测试样本在测试时熵最小化中的效果 (Wang 等人, 2021)。本文在部分样本 (熵值最高或最低的前 $p\%$ 样本) 上自适应模型, 然后在所有测试样本上评估自适应后的模型。结果在 ImageNet-C (高斯噪声, 级别 3) 和 ResNet-50 (基础准确率为 27.6%) 上获得。在自适应过程中引入更多高熵样本会损害自适应性能。

高熵可能会损害性能。可能的原因是, 高熵样本的预测是不确定的, 因此它们由熵损失产生的梯度可能是有偏且不可靠的。据此, 本文将低熵样本称为可靠样本。

基于上述观察, 本文提出一种基于熵的加权方案, 用于识别可靠样本并强调其在适应过程中的贡献。形式上, 基于熵的权重定义为:

$$S^{ent}(\mathbf{x}) = \frac{1}{\exp[E(\mathbf{x}; \Theta) - E_0]} \cdot \mathbb{I}_{\{E(\mathbf{x}; \Theta) < E_0\}}(\mathbf{x}), \quad (3)$$

其中 $\mathbb{I}_{\{\cdot\}}(\cdot)$ 为指示函数, $E(\mathbf{x}; \Theta)$ 为样本 $\mathbf{x}$ 的熵, E_0 为预定义阈值。上述加权函数将高熵样本排除在适应过程之外, 并为预测不确定性较低的测试样本赋予更高权重, 使其对模型更新贡献更大。注意, 计算 $S^{ent}(\mathbf{x})$ 不涉及任何梯度反向传播。

非冗余样本识别。 尽管公式 (3) 有助于排除部分不可靠样本, 但剩余的测试样本仍可能存在冗余。例如, 给定两个彼此相似且预测熵均低于 E_0 的测试样本, 根据公式 (3) 仍需对每个样本执行梯度反向传播。然而, 这是不必要的, 因为这两个样本为模型适应产生相似的梯度。

为进一步提高效率, 本文提出利用能为模型适应产生不同梯度的样本。鉴于熵损失仅依赖于最终模型输出 (即分类逻辑值), 本文进一步筛选样本, 确保剩余样本具有多样化的模型输出。

为此，一种直接的方法是保存所有先前见过的样本的模型输出，然后计算新测试样本的输出与所有已保存模型输出之间的相似度以进行筛选。然而，该方法在测试时计算开销大，且随着测试样本增加而消耗大量内存。

为解决此问题，本文利用指数移动平均技术跟踪所有已用于模型适应的测试样本的平均模型输出。具体而言，给定一组测试样本的模型输出，移动平均向量按以下方式递归更新：

$$\mathbf{m}^t = \begin{cases} \bar{\mathbf{y}}^1, & \text{if } t = 1 \\ \alpha \bar{\mathbf{y}}^t + (1 - \alpha) \mathbf{m}^{t-1}, & \text{if } t > 1 \end{cases}, \quad (4)$$

where $\bar{\mathbf{y}}^t = \frac{1}{n} \sum_{k=1}^n \hat{\mathbf{y}}_k^t$ is the average model prediction of a mini-batch of n test samples at the iteration t , and $\alpha \in [0, 1]$. Following that, given a new test sample $\mathbf{x}$ received at iteration $t > 1$, we compute the cosine similarity between its prediction $f_{\Theta}(\mathbf{x})$ and the moving average $\mathbf{m}^{t-1}$ (i.e., $\cos(f_{\Theta}(\mathbf{x}), \mathbf{m}^{t-1})$), which is then used to determine the diversity-based weight:

$$S^{div}(\mathbf{x}) = \mathbb{I}_{\{\cos(f_{\Theta}(\mathbf{x}), \mathbf{m}^{t-1}) < \epsilon\}}(\mathbf{x}), \quad (5)$$

其中 ϵ 为余弦相似度的预定义阈值。整体样本自适应权重由下式给出：

$$S(\mathbf{x}) = S^{ent}(\mathbf{x}) \cdot S^{div}(\mathbf{x}), \quad (6)$$

该方法结合了基于熵的项（如公式 3 所示）和基于多样性的项（如公式 5 所示）。由于我们仅对满足 $S(\mathbf{x}) > 0$ 的测试样本执行梯度反向传播，算法效率得到进一步提升。

备注 1. Given M test samples $\mathcal{D}_{test} = \{\mathbf{x}_j\}_{j=1}^M$, the reduced backward computation by $\mathbb{E}_{\mathbf{x} \sim \mathcal{D}_{test}}[\mathbb{I}_{\{S(\mathbf{x})=0\}}(\mathbf{x})]$ is given, the value is determined by the test data distribution $\mathcal{D}_{test}$, entropy threshold E_0 and cosine similarity threshold ϵ jointly.

4.2. 基于费舍尔正则化的抗遗忘机制

本节提出一种新的加权费舍尔正则化器（称为抗遗忘正则化器），以缓解测试时自适应引起的灾难性遗忘问题，即测试时自适应模型的性能可能在分布内测试样本上显著下降。我们通过权重正则化实现这一目标，该正则化仅影响损失函数，不会为模型自适应带来任何额外计算开销。具体而言，我们应用重要性感知正则化器 $\mathcal{R}$ ，以防止对分布内域重要的模型参数在测试时自适应过程中发生过大变化（Kirkpatrick 等人，2017）：

$$\mathcal{R}(\tilde{\Theta}, \tilde{\Theta}^o) = \sum_{\theta_i \in \tilde{\Theta}} \omega(\theta_i) (\theta_i - \theta_i^o)^2, \quad (7)$$

其中 $\tilde{\Theta}$ 是用于模型更新的参数， $\tilde{\Theta}^o$ 是原始模型的对参数。 $\omega(\theta_i)$ 表示 θ_i 的重要性，我们通过弹性权重巩固中的对角费舍尔信息矩阵来度量该重要性（Kirkpatrick 等人，2017）。此处，费舍尔信息 $\omega(\theta_i)$ 的计算并非易事，因为我们无法访问任何带标签的训练数据。为便于表述，我们将计算 $\omega(\theta_i)$ 的细节留待下一小节。

引入抗遗忘正则化器后，我们方法的最终优化公式可表示为：

$$\min_{\tilde{\Theta}} S(\mathbf{x}) E(\mathbf{x}; \Theta) + \beta \mathcal{R}(\tilde{\Theta}, \tilde{\Theta}^o), \quad (8)$$

where β is a trade-off parameter, $S(\mathbf{x})$ and $E(\mathbf{x}; \Theta)$ are defined in Eqn. (2).

权重重要性的度量 $\omega(\theta_i)$. 费舍尔信息的计算通常涉及一组带标签的分布内训练样本。然而，在我们的问题设定中，无法访问训练数据，且测试样本仅有未标注数据，这使得衡量权重重要性并非易事。为解决这一问题，我们首先收集一小批未标注的分布内测试样本 $\{\mathbf{x}_q\}_{q=1}^Q$ ，然后使用原始训练模型 $f_{\Theta}(\cdot)$ 对所有样本进行预测，以获得相应的硬伪标签 $\hat{y}_q$ 。随后，我们构建一个带有伪标签的分布内测试集，并基于该测试集计算费舍尔模型权重的权重性，计算公式为：

$$\omega(\theta_i) = \frac{1}{Q} \sum_{\mathbf{x}_q \in \mathcal{D}_F} \left(\frac{\partial}{\partial \theta_i} \mathcal{L}_{CE}(f_{\Theta}(\mathbf{x}_q), \hat{y}_q) \right)^2, \quad (9)$$

其中 $\mathcal{L}_{CE}$ 为交叉熵损失。此处，我们仅需在执行测试时自适应之前计算一次 $\omega(\theta_i)$ 。一旦计算完成，我们保持 $\omega(\theta_i)$ 固定不变，并将其应用于任何类型的分布偏移。此外，未标注的分布内测试样本基于分布外检测技术（Liu et al., 2020; Berger et al., 2021）收集，这些技术易于实现。需要注意的是，计算 $\omega(\theta_i)$, e.g., 500 无需收集过多分布内测试样本，对于 ImageNet-C 数据集而言，样本数量已足够。更多相关实证研究可参见图 4(b)。

5. 实验

我们组织实验以回答以下问题：

- 1) EATA 在效率和准确率方面与先前方法相比如何？
- 2) EATA 能否缓解测试时自适应后发生的遗忘？
- 3) 不同组件如何影响 EATA 的性能？

数据集与模型。 我们在三个用于分布外泛化的基准数据集上进行实验，即 CIFAR-10-C、ImageNet-C（Hendrycks & Dietterich, 2019）（包含 15 种损坏类型，分属 4 个主要类别）

表 2. 在最高严重度等级 5 的 ImageNet-C 上关于损坏误差 (% , ↓). “GN”和“BN”分别表示组归一化和批归一化。“JT”表示模型通过监督交叉熵和旋转预测损失联合训练。粗体数字表示最佳结果，下划线数字表示次佳结果。

Method	Noise			Blur				Weather				Digital				Average	
	Gauss.	Shot	Impul.	Defoc.	Glass	Motion	Zoom	Snow	Frost	Fog	Brit.	Contr.	Elastic	Pixel	JPEG	#Forwards	#Backwards
R-50 (GN)+JT	94.9	95.1	94.2	88.9	91.7	86.7	81.6	82.5	81.8	80.6	49.2	87.4	76.9	79.2	68.5	50,000	0
• TTT	69.0	66.4	66.6	71.9	92.2	66.8	63.2	59.1	81.0	49.0	38.2	61.1	50.6	48.3	52.0	50,000×21	50,000×20
R-50 (BN)	97.8	97.1	98.2	82.1	90.2	85.2	77.5	83.1	76.7	75.6	41.1	94.6	83.1	79.4	68.4	50,000	0
• TTA	95.9	95.1	95.5	87.5	91.8	87.1	74.2	86.0	80.9	78.7	47.0	87.6	85.4	75.4	66.4	50,000×64	0
• BN adaptation	84.5	83.9	83.7	80.0	80.0	71.5	60.0	65.2	65.0	51.5	34.1	75.9	54.2	49.3	58.9	50,000	0
• MEMO	92.5	91.3	91.0	80.3	87.0	79.3	72.4	74.7	71.2	67.9	39.0	89.0	76.2	67.0	62.5	50,000×65	50,000×64
• Tent	71.6	69.8	69.9	71.8	72.7	58.6	50.5	52.9	58.7	42.5	32.6	74.9	45.2	41.5	47.7	50,000	50,000
• Tent (episodic)	85.4	84.8	84.9	85.5	85.4	74.6	62.2	66.4	67.8	53.2	35.7	83.9	57.1	52.4	61.5	50,000×2	50,000
• ETA (ours)	64.9	<u>62.1</u>	<u>63.4</u>	66.1	67.1	52.2	47.4	48.1	54.2	39.9	32.1	55.0	42.1	39.1	<u>45.1</u>	50,000	26,031
• EATA (ours)	<u>65.0</u>	63.1	64.3	66.3	<u>66.6</u>	52.9	<u>47.2</u>	<u>48.6</u>	<u>54.3</u>	<u>40.1</u>	32.0	<u>55.7</u>	<u>42.4</u>	<u>39.3</u>	45.0	50,000	25,150
• EATA (lifelong)	<u>65.0</u>	61.9	63.2	<u>66.2</u>	65.8	<u>52.7</u>	46.8	48.9	54.4	40.3	32.0	55.8	42.8	39.6	45.3	50,000	28,243

每种类型有 5 个严重度等级) 和 ImageNet-R (Hendrycks 等人, 2021) 上与最先进方法的比较。我们使用 ResNet-26 (R-26) /ResNet-50 (R-

50) (He 等人, 2016) 进行 CIFAR-10/ImageNet 实验。

模型在 CIFAR-10 或 ImageNet 训练集上训练，然后在干净或上述 OOD 测试集上测试。

比较方法。我们与以下最先进的方法进行比较。测试时训练 (TTT) (Sun 等人, 2020) 在测试时通过旋转预测来适应模型，但要求模型也通过旋转预测进行训练。测试时增强 (TTA) (Ashukha 等人, 2020) 通过样本不同增强的平均输出来预测样本。BN 适应 (Schneider 等人, 2020) 在测试样本上更新批归一化统计量。Tent (Wang 等人, 2021) 在测试期间最小化测试样本的熵。MEMO (Zhang 等人, 2021b) 最大化给定测试样本的不同增强副本的预测一致性。我们将公式 (7) 中没有权重正则化的 EATA 表示为高效测试时自适应 (ETA)。

对于 TTT、Tent、我们的 ETA 和 EATA，模型在给定测试数据集（例如，ImageNet-C 的高斯噪声等级 5）的整个评估过程中在线自适应。一旦在该数据集上的自适应完成，模型参数将被重置。对于 TTT（情景式）和 Tent（情景式），模型参数将在每个测试样本或批次的优化步骤后立即重置。对于 EATA（终身式）和 Tent（终身式），模型在线自适应且参数永不重置（如图 3（右）所示），这更具挑战性但更实用。

评估度量。1) 原始分布内 (ID) 测试样本上的干净准确率/错误率 (%), 例如 ImageNet 的原始测试图像。注意，我们通过 (重新) 自适应来衡量所有方法的干净准确率；2) 分布外

(OOD) 测试样本上的准确率/错误率 (%), 例如 ImageNet-C 上的损坏准确率；3) 整个测试时自适应过程中的前向和反向传播次数。注意，前向和反向次数越少表示计算量越少，从而效率更高。

表 3. 在 ImageNet-R 上的比较。基础模型是在原始 ImageNet 训练集上训练的 ResNet-50 (使用批归一化)。

Model	Error (%)	#Forwards	#Backwards
Base Model	63.8	30,000	0
• TTA (Ashukha et al., 2020)	61.3 _(-2.5)	30,000×64	0
• BN (Schneider et al., 2020)	59.7 _(-4.1)	30,000	0
• MEMO (Zhang et al., 2021b)	58.8 _(-5.0)	30,000×65	30,000×64
• Tent (Wang et al., 2021)	57.7 _(-6.1)	30,000	30,000
• Tent (episodic)	61.0 _(-2.9)	30,000	30,000
• ETA (ours)	54.5 _(-9.3)	30,000	14,847
• EATA (ours)	54.8 _(-9.0)	30,000	14,800

实现细节。对于测试时自适应，我们使用 SGD 作为更新规则，动量为 0.9，批大小为 64，CIFAR-10/ImageNet 的学习率为 0.005/0.00025（遵循 Tent 和 MEMO）。公式 (3) 中的熵常数 E_0 设为 $0.4 \times \ln C$ ，其中 C 是任务类别数。公式 (6) 中的 ϵ 对于 CIFAR-10/ImageNet 设为 0.4/0.05。公式 (8) 中的权衡参数 β 对于 CIFAR-10/ImageNet 设为 1/2,000，以使两个损失具有相似的量级。我们使用 2,000 个样本来计算公式 (9) 中的 $\omega(\theta_i)$ ，这需要 2,000 次额外的前向和反向传播。公式 (4) 中的移动平均因子 α 设为 0.1。更多细节见补充材料。

5.1. OOD 性能与效率的比较

ImageNet-C 上的结果。我们在表 2 中报告了最高严重级别 5 的 ImageNet-C 上的比较，并将其他严重级别 1-4 的更多结果放入补充材料中，因为页面限制。从结果来看，我们的 ETA 和 EATA 在所有 15 种损坏类型上关于分类错误率一致地优于所考虑的方法，表明我们的有效性。借助我们的样本自适应熵损失，ETA 相对于 Tent 在 (e.g., 71.6% $\rightarrow$ 65.0% 高斯噪声上取得了很大的性能提升，验证了移除具有不可靠梯度的样本并区别对待样本有利于测试时自适应。更关键的是，ETA 一致地优于 TTT (而 Tent




图 3. 在 ImageNet-C (严重程度 5 级) 上使用 ResNet-50 比较防止遗忘。我们记录每个损坏测试集上的分布外损坏准确率以及分布内干净准确率 (在分布外自适应之后)。左图中, Tent 和我们的 EATA 的模型参数在适应新的损坏类型之前都会重置。右图中, 模型进行终身自适应, 参数永不重置, 即 Tent (终身) 和我们的 EATA (终身)。EATA 实现了更高的分布外准确率, 同时保持了分布内干净准确率。

表 4. 在 CIFAR-10-C 上的比较。每个结果是在 15 种不同损坏类型和 5 个严重程度级别 (共 75 种) 上的平均值。

模型	平均错误率 (%)	平均前向次数	平均反向次数
ResNet-26 (GroupNorm)	22.5	10,000	0
• TTA (Ashukha et al., 2020)	19.9 _(-2.6)	10,000×32	0
• MEMO (Zhang et al., 2021b)	19.6 _(-2.9)	10,000×33	10,000×32
ResNet-26 (GroupNorm)+JT	22.8	10,000	0
• TTT (Sun et al., 2020)	15.6 _(-7.2)	10,000×33	10,000×32
• TTT (episodic)	21.5 _(-1.3)	10,000×33	10,000×32
ResNet-26 (BatchNorm)	28.4	10,000	0
• Tent (Wang et al., 2021)	20.2 _(-8.2)	10,000	10,000
• ETA (ours)	19.4 _(-9.0)	10,000	8,192
• EATA (ours)	19.7 _(-8.7)	10,000	8,153

未能实现这一点), 展示了完全测试时自适应方法的潜力, 即在不改变训练过程的情况下提升分布外泛化能力。与 ETA 相比, EATA 和 EATA (终身) 实现了可比的分布外性能 (但防止了对分布内样本的遗忘, 见图 3), 表明我们的防遗忘正则化不会限制自适应过程中的学习能力。

在效率方面, 我们的 ETA 所需的平均反向次数为 26,031, 远少于需要多次数据增强的方法 (即 TTT 和 MEMO 分别为 $50,000 \times 20$ 和 64)。与 Tent 相比, ETA 通过排除具有高预测熵的样本和测试时优化中相似的样本, 将平均反向次数从 50,000 减少到 26,031。从这个意义上说, 我们的方法只需要对部分样本进行自适应, 从而提高了效率。注意, 尽管无需优化的方法 (如 BN 自适应) 不需要反向更新, 但它们的分布外性能有限。



在 ImageNet-R 和 CIFAR-10-C 上的结果。从表 3 可以看出, 我们的 ETA 在 ImageNet-R 上实现了 54.5% 的分类错误率

(比最佳对照方法 Tent 低 3.2%), 且仅需 14,847 次反向传播 (远少于其他基于学习的测试时自适应方法, 如 MEMO 和 Tent)。CIFAR-10-C 上的结果见表 4。在相同基础模型 (带批归一化的 ResNet-26) 下, ETA 的平均误差低于 Tent (19.4% 对 20.2%), 且反向传播需求更少 (8,192 对 10,000)。此外, ETA 相对于基础模型的性能增益大于 TTT, 即平均误差 -9.0% 对 -7.2%。这些结果与 ImageNet-C 上的结果一致, 表明 ETA 实现了更高的性能并提升了效率, 进一步证明了本文方法的有效性和优越性。

5.2. 防止遗忘的演示

本节研究本文提出的 EATA 在测试时自适应过程中防止分布内遗忘的能力。实验在 ImageNet-C 上使用 ResNet-50 进行。通过比较自适应前后模型的干净准确率 (即在 ImageNet 原始验证数据上的准确率) 来衡量抗遗忘能力。为此, 首先在给定的分布外测试集上执行测试时自适应, 然后评估更新后模型的干净准确率。这里考虑两种自适应场景: 1) 在适应新的损坏测试集之前重置模型参数; 2) 模型参数永不重置 (即终身自适应), 这更具挑战性但更实用。图 3 报告了严重程度 5 的结果, 严重程度 1-4 的结果见补充材料。

从图 3 可以看出, 本文提出的 EATA 在分布外损坏准确率上始终优于 Tent, 同时在两种自适应场景下均保持了分布内数据的干净准确率, 证明了本文方法的有效性。值得注意的是, 终身自适应场景下的性能退化更为严重 (见图 3 右)。更多

(a) Effect of different entropy margins E_0 in Eqn. (3)

(b) Effect of #samples for calculating Fisher in Eqn. (9).

图 4. ImageNet-C 上的消融实验（高斯噪声，严重程度 level=5），使用 ResNet-50）。

关键的是，在终身适应中，Tent 在适应前三种损坏类型后，其干净准确率和损坏准确率都迅速下降（直至降至 0%），表明 Tent 在终身适应中不够稳定。相比之下，在整个终身适应过程中，我们的 EATA 取得了良好的损坏准确率，并且干净准确率也非常接近未进行任何 OOD 适应的模型的干净准确率（即原始干净准确率，使用 Tent 测试）。这些结果证明了 EATA 在克服 ID 数据遗忘方面的优越性。

5.3. 消融研究

组件的影响 $S(\mathbf{x})$ （公式 6）。本文提出的高效测试时自适应（EATA）通过将两类样本排除在优化之外来加速测试时自适应：1) 预测熵值较高的样本（公式 3）和 2) 相似的样本（公式 6）。表 5 中对这两类样本进行了消融实验。与基线 $S(\mathbf{x})=1$ （与 Tent 相同）相比，在公式 (3) 中引入 $S^{ent}(\mathbf{x})$ 可获得更低的误差和更少的反向传播次数（例如，在第 5 级上为 **65.7%**（26,694 次）对比 **71.6%**（50,000 次））。这验证了图 2 中的动机，即某些高熵样本可能因其梯度不可靠而损害性能。当进一步移除一些相似的冗余样本（公式 6）时，本文提出的 EATA 进一步减少了反向传播次数（第 5 级上为 *e.g.*, 26,694 $\rightarrow$ 19,121 次），并实现了可比的分布外误差（例如，**65.0%**）。

表 5. 在 ImageNet-C（高斯噪声）上使用 ResNet-50 的 EATA 中，样本自适应权重 $S(\mathbf{x})$ 各组件的有效性。

Method	Level 3		Level 5	
	Error (%)	#Backwards	Error (%)	#Backwards
Baseline ($S(\mathbf{x})=1$)	45.3	50,000	71.6	50,000
+ $S^{ent}(\mathbf{x})$ (Eqn. 3)	43.0	37,943	65.7	26,694
+ $S(\mathbf{x})$ (Eqn. 6)	42.6	29,051	65.0	19,121

相较于 65.7%)，证明了本文所提出的样本高效优化策略的有效性。

熵常数 在公式 E_0 (3)。我们评估了我们的高效抗测试时适应（EATA）方法，采用不同的 E_0 ，这些值选自 $\{0.20, 0.25, 0.30, 0.35, 0.40, 0.45, 0.50, 0.55\} \times \ln 10^3$ ，其中 10^3 是 ImageNet 的类别数。从图 4(a) 可以看出，当 E_0 属于 $[0.4, 0.5]$ 时，我们的 EATA 取得了优异的性能。无论是更小还是更大的 E_0 都会损害性能。原因主要如下。当 E_0 较小时，EATA 在适应过程中移除了过多的样本，因此无法从剩余样本中学习到足够的适应知识。当 E_0 过大时，一些高熵样本会参与适应，但贡献了不可靠且有害的梯度，导致性能下降。由于更大的 E_0 会导致更多的反向传播次数，我们将 E_0 设为 $0.4 \times \ln 10^3$ ，以在效率和性能之间取得平衡，并在所有其他实验中固定 0.4 的比例。

用于计算公式中费舍尔信息的样本数量 (9)。如第 4.2 节所述，费舍尔信息的计算涉及一小部分未标注的分布内样本，这些样本可通过现有的分布外检测技术收集（Berger 等，2021）。在此，我们研究从

$\{200, 300, 500, 700, 1000, \text{中选取的样本数量 } Q \text{ 的影 } 1500, 2000, 3000\}$ 响。从图 4(b) 可见，与 ETA 相比，我们的 EATA 在 $Q \geq 300$, *i.e.* 时实现了稳定的性能。（未使用正则化时），分布外性能相当，而干净准确率则高得多。这些结果表明，本文提出的高效抗测试时适应方法无需收集过多的域内样本，而这些样本在实际中易于获取。

5.4. 更多讨论

单样本自适应结果（批大小 $B = 1$ ）。在我们提出的方法中，每次对一批测试样本进行测试时学习。当批大小 B 等于 1 时，直接应用 Tent 和我们的 ETA 可能会失败（见表 6），但在实践中这并不是一个非常显著的问题。实际上，可以通过维护一个滑动窗口 $\{\mathbf{x}_i\}_{i=t-L}^t$ ，包含 L 之前的样本和当前测试样本 $\mathbf{x}_t$ ，或采用现有单样本 TTA 方法中的数据增强技术（(Zhang et al., 2021b; Khurana et al., 2021)）来解决。第一种方法实现简单，仅产生少量额外成本。从表 6 可以看出，带有滑动窗口的 ETA (ETA-wnd) 表现良好，并始终优于 Tent 对应方法。

表 6. 滑动窗口策略下 ETA 的有效性（不同窗口长度 L ）用于单样本自适应。本文报告在 ImageNet-C（高斯噪声，等级 5）上的损坏准确率（%）。

Base ResNet-50	Tent	ETA	Tent-wnd ($L=32$)	ETA-wnd ($L=32$)	Tent-wnd ($L=64$)	ETA-wnd ($L=64$)
2.2	0.1	0.1	28.1	30.8	29.5	32.4

表 7. 与 Tent（Wang 等人，2021 年）在 ImageNet-C 上混合 15 种损坏类型下的损坏准确率（%）比较。

Severity	Base (ResNet-50)	Tent	EATA (ours)
Level=3	39.8	41.5 _(+1.7)	52.6 _(+12.8)
Level=5	18.0	2.3 _(-15.7)	26.6 _(+8.6)

表 8. EATA 在不同骨干模型上的有效性。我们报告了在 ImageNet-C（高斯噪声，严重程度 5 级）上的损坏准确率（%）。

Base	ResNet-50 (2.2)	ResNet-101 (3.5)	ResNet-152 (3.6)
Tent	28.4 _(+26.2)	32.5 _(+29.0)	33.7 _(+30.1)
EATA	35.0 _(+32.8)	38.8 _(+35.3)	40.2 _(+36.6)

EATA 的墙钟时间加速。在当前 PyTorch 版本中，即使应用了实例级掩码，梯度计算仍是在完整的小批量上进行的。我们通过一次仅前向传播 B 个样本，以及一次对 ETA/EATA 选出的 B' 个样本进行前向和反向传播，实现了墙钟时间加速。对于在 ImageNet-C（高斯噪声，level=5, 50,000 张图像）上使用一块 Tesla V100 GPU 的 ResNet-50，实际运行时间为 Tent 113 秒（准确率 28.6%），EATA 102 秒（准确率 35.1%）。实际上，这更是一个工程问题，理想的实现（对 B 个样本进行前向传播，对 B' 个样本进行反向传播）应能进一步加速计算。

Fisher 正则化器带来的额外内存。由于我们仅对 BN 层的仿射参数进行正则化，EATA 所需的额外内存非常少。对于 ImageNet-C 上的 ResNet-50，运行时额外 GPU 内存仅为 9.8 MB，远低于批大小为 64 的 Tent（5,675 MB）。

混合与偏移分布下的 EATA。我们在混合的 ImageNet-C (level=3 或

5) 包含 15 种不同的损坏类型/分布偏移（共 75 万张图像）。表 7 中的结果展示了 EATA 在大规模复杂测试时自适应场景下的稳定性。

EATA 在大规模网络模型上的应用。在表 8 中，我们将 EATA 应用于具有不同计算复杂度的预训练模型。结果表明，即使对于倾向于过度自信的大型模型（ResNet-101 和 ResNet-152），我们的 EATA 仍然表现良好。

表 9. 在 ImageNet-C（高斯噪声，严重程度 5 级）上，使用更少（ N ）测试样本时，与 Tent（Wang 等人，2021）在损坏准确率（%）方面的比较。

Method	$N=256$	$N=512$	$N=1,024$	$N=2,048$	$N=4,096$	$N=10,000$
Tent	13.7	18.2	14.8	15.2	17.5	20.9
EATA	14.8	20.1	16.3	18.7	23.5	27.6

EATA 在不同测试样本数量下的表现。我们研究了 EATA 中测试样本总数（ N ）的影响，其中较少的样本是从整个测试集中采样得到的。从表 9 可以看出，无论测试样本数量如何，EATA 都表现良好，并始终优于 Tent 对应方法。同时，如果测试样本较多，EATA 将受益更多，即获得更大的准确率提升。

6. 结论

本文提出了一种高效的抗遗忘测试时自适应方法，以提升预训练模型在可能发生偏移的测试域上的性能。具体而言，我们设计了一种样本高效的熵最小化策略，该策略选择性地对可靠且非冗余的样本进行测试时优化。这提高了自适应效率，同时增强了分布外性能。此外，我们将基于费舍尔的抗遗忘正则化器引入测试时自适应。借助该损失，模型可以在分布内测试样本上持续自适应而不会出现性能下降，从而使测试时自适应在实际应用中更加实用。在多个基准数据集上的大量实验结果证明了所提方法的有效性。

7. 致谢

本工作部分得到科学技术部基金项目 2020AAA0106900、广州市重点领域研发计划 202007030007、国家自然科学基金（NSFC）62072190、广东省引进创新创业团队计划 2017ZT07X183 的资助。

参考文献

- Ashukha, A., Lyzhov, A., Molchanov, D., and Vetrov, D. P. Pitfalls of in-domain uncertainty estimation and ensembling in deep learning. In *International Conference on Learning Representations*, 2020.
- Berger, C., Paschali, M., Glocker, B., and Kamnitsas, K. Confidence-based out-of-distribution detection: A comparative study and analysis. In *Uncertainty for Safe Uti-*

- lization of Machine Learning in Medical Imaging, and Perinatal Imaging, Placental and Preterm Image Analysis, pp. 122–132. Springer, 2021.
- Chen, P., Huang, D., He, D., Long, X., Zeng, R., Wen, S., Tan, M., and Gan, C. Rspnet: Relative speed perception for unsupervised video representation learning. In *AAAI Conference on Artificial Intelligence*, volume 1, pp. 5, 2021.
- Choi, Y., Choi, M., Kim, M., Ha, J.-W., Kim, S., and Choo, J. Stargan: Unified generative adversarial networks for multi-domain image-to-image translation. In *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 8789–8797, 2018.
- Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., and Fei-Fei, L. Imagenet: A large-scale hierarchical image database. In *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 248–255, 2009.
- Fan, D.-P., Zhou, T., Ji, G.-P., Zhou, Y., Chen, G., Fu, H., Shen, J., and Shao, L. Inf-net: Automatic covid-19 lung infection segmentation from ct images. *IEEE Transactions on Medical Imaging*, 39(8):2626–2637, 2020.
- Farajtabar, M., Azizan, N., Mott, A., and Li, A. Orthogonal gradient descent for continual learning. In *International Conference on Artificial Intelligence and Statistics*, pp. 3762–3773, 2020.
- Fleuret, F. et al. Test time adaptation through perturbation robustness. In *Advances in Neural Information Processing Systems Workshop*, 2021.
- Gidaris, S., Singh, P., and Komodakis, N. Unsupervised representation learning by predicting image rotations. In *International Conference on Learning Representations*, 2018.
- Guo, Y., Stutz, D., and Schiele, B. Improving corruption and adversarial robustness by enhancing weak subnets. *arXiv preprint arXiv:2201.12765*, 2022.
- He, K., Zhang, X., Ren, S., and Sun, J. Deep residual learning for image recognition. In *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 770–778, 2016.
- Hendrycks, D. and Dietterich, T. Benchmarking neural network robustness to common corruptions and perturbations. In *International Conference on Learning Representations*, 2019.
- Hendrycks, D., Mu, N., Cubuk, E. D., Zoph, B., Gilmer, J., and Lakshminarayanan, B. Augmix: A simple data processing method to improve robustness and uncertainty. In *International Conference on Learning Representations*, 2020.
- Hendrycks, D., Basart, S., Mu, N., Kadavath, S., Wang, F., Dorundo, E., Desai, R., Zhu, T., Parajuli, S., Guo, M., et al. The many faces of robustness: A critical analysis of out-of-distribution generalization. In *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 8340–8349, 2021.
- Iwasawa, Y. and Matsuo, Y. Test-time classifier adjustment module for model-agnostic domain generalization. *Advances in Neural Information Processing Systems*, 34, 2021.
- Khurana, A., Paul, S., Rai, P., Biswas, S., and Aggarwal, G. Sita: Single image test-time adaptation. *arXiv preprint arXiv:2112.02355*, 2021.
- Kirkpatrick, J., Pascanu, R., Rabinowitz, N., Veness, J., Desjardins, G., Rusu, A. A., Milan, K., Quan, J., Ramalho, T., Grabska-Barwinska, A., et al. Overcoming catastrophic forgetting in neural networks. *Proceedings of the national academy of sciences*, 114(13):3521–3526, 2017.
- Koh, P. W., Sagawa, S., Marklund, H., Xie, S. M., Zhang, M., Balsubramani, A., Hu, W., Yasunaga, M., Phillips, R. L., Gao, I., et al. Wilds: A benchmark of in-the-wild distribution shifts. In *International Conference on Machine Learning*, pp. 5637–5664, 2021.
- Krizhevsky, A., Hinton, G., et al. Learning multiple layers of features from tiny images. 2009.
- Kundu, J. N., Venkat, N., Babu, R. V., et al. Universal source-free domain adaptation. In *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 4544–4553, 2020.
- Li, B., Wu, F., Lim, S.-N., Belongie, S., and Weinberger, K. Q. On feature normalization and data augmentation. In *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 12383–12392, 2021.
- Li, R., Jiao, Q., Cao, W., Wong, H.-S., and Wu, S. Model adaptation: Unsupervised domain adaptation without source data. In *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 9641–9650, 2020.
- Li, Z. and Hoiem, D. Learning without forgetting. *IEEE transactions on pattern analysis and machine intelligence*, 40(12):2935–2947, 2017.
- Liang, J., Hu, D., and Feng, J. Do we really need to access the source data? source hypothesis transfer for unsupervised domain adaptation. In *International Conference on Machine Learning*, pp. 6028–6039, 2020.

- Lim, S., Kim, I., Kim, T., Kim, C., and Kim, S. Fast autoaugment. *Advances in Neural Information Processing Systems*, 32:6665–6675, 2019.
- Liu, W., Wang, X., Owens, J., and Li, Y. Energy-based out-of-distribution detection. *Advances in Neural Information Processing Systems*, 33, 2020.
- Liu, Y., Kothari, P., van Delft, B., Bellot-Gurlet, B., Mordan, T., and Alahi, A. Ttt++: When does self-supervised test-time training fail or thrive? *Advances in Neural Information Processing Systems*, 34, 2021.
- Madaan, D., Shin, J., and Hwang, S. J. Learning to generate noise for multi-attack robustness. In *International Conference on Machine Learning*, pp. 7279–7289, 2021.
- Mittal, S., Galesso, S., and Brox, T. Essentials for class incremental learning. In *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 3513–3522, June 2021.
- Nado, Z., Padhy, S., Sculley, D., D’Amour, A., Lakshminarayanan, B., and Snoek, J. Evaluating prediction-time batch normalization for robustness under covariate shift. *arXiv preprint arXiv:2006.10963*, 2020.
- Niu, S., Wu, J., Zhang, Y., Guo, Y., Zhao, P., Huang, J., and Tan, M. Disturbance-immune weight sharing for neural architecture search. *Neural Networks*, 144:553–564, 2021.
- Pei, Z., Cao, Z., Long, M., and Wang, J. Multi-adversarial domain adaptation. In *AAAI Conference on Artificial Intelligence*, 2018.
- Qiu, Z., Zhang, Y., Lin, H., Niu, S., Liu, Y., Du, Q., and Tan, M. Source-free domain adaptation via avatar prototype generation and adaptation. In *IJCAI*, 2021.
- Rolnick, D., Ahuja, A., Schwarz, J., Lillicrap, T. P., and Wayne, G. Experience replay for continual learning. *Advances in Neural Information Processing Systems*, 2019.
- Rusak, E., Schott, L., Zimmermann, R. S., Bitterwolf, J., Bringmann, O., Bethge, M., and Brendel, W. A simple way to make neural networks robust against diverse image corruptions. In *European Conference on Computer Vision*, pp. 53–69, 2020.
- Saito, K., Watanabe, K., Ushiku, Y., and Harada, T. Maximum classifier discrepancy for unsupervised domain adaptation. In *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 3723–3732, 2018.
- Schneider, S., Rusak, E., Eck, L., Bringmann, O., Brendel, W., and Bethge, M. Improving robustness against common corruptions by covariate shift adaptation. In Larochelle, H., Ranzato, M., Hadsell, R., Balcan, M., and Lin, H. (eds.), *Advances in Neural Information Processing Systems*, 2020.
- Sun, Y., Wang, X., Liu, Z., Miller, J., Efros, A., and Hardt, M. Test-time training with self-supervision for generalization under distribution shifts. In *International Conference on Machine Learning*, pp. 9229–9248, 2020.
- Tan, M. and Le, Q. Efficientnet: Rethinking model scaling for convolutional neural networks. In *International Conference on Machine Learning*, pp. 6105–6114, 2019.
- Wang, D., Shelhamer, E., Liu, S., Olshausen, B., and Darrell, T. Tent: Fully test-time adaptation by entropy minimization. In *International Conference on Learning Representations*, 2021.
- Wang, Q., Fink, O., Van Gool, L., and Dai, D. Continual test-time domain adaptation. In *CVPR*, 2022.
- Wang, X., Girshick, R., Gupta, A., and He, K. Non-local neural networks. In *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 7794–7803, 2018.
- Wong, E., Rice, L., and Kolter, J. Z. Fast is better than free: Revisiting adversarial training. In *International Conference on Learning Representations*, 2020.
- Xu, G., Niu, S., Tan, M., Luo, Y., Du, Q., and Wu, Q. Towards accurate text-based image captioning with content diversity exploration. In *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 12637–12646, 2021.
- Yao, H., Wang, Y., Li, S., Zhang, L., Liang, W., Zou, J., and Finn, C. Improving out-of-distribution robustness via selective augmentation. In *International Conference on Machine Learning*, 2022.
- Zhang, D., Ahuja, K., Xu, Y., Wang, Y., and Courville, A. Can subnetwork structure be the key to out-of-distribution generalization? In *International Conference on Machine Learning*, pp. 12356–12367. PMLR, 2021a.
- Zhang, M. M., Levine, S., and Finn, C. Memo: Test time robustness via adaptation and augmentation. In *NeurIPS 2021 Workshop on Distribution Shifts: Connecting Methods and Applications*, 2021b.
- Zhang, Y., Niu, S., Qiu, Z., Wei, Y., Zhao, P., Yao, J., Huang, J., Wu, Q., and Tan, M. Covid-da: deep domain adaptation from typical pneumonia to covid-19. *arXiv preprint arXiv:2005.01577*, 2020a.
- Zhang, Y., Wei, Y., Wu, Q., Zhao, P., Niu, S., Huang, J., and Tan, M. Collaborative unsupervised domain adaptation for medical image diagnosis. *IEEE Transactions on Image Processing*, 29:7834–7844, 2020b.
- Zhang, Y., Hooi, B., Hong, L., and Feng, J. Test-agnostic long-tailed recognition by test-time aggregating diverse experts with self-supervision. *arXiv preprint arXiv:2107.09249*, 2021c.

Supplementary Materials for “Efficient Test-Time Model Adaptation without Forgetting”

In the supplementary, we provide more implementation details and more experimental results of our EATA. We organize our supplementary as follows.

- In Section A, we provide more experimental details of our proposed EATA.
- In Section B, we show more experimental results to compare the out-of-distribution performance and efficiency with state-of-the-art methods on ImageNet-C with different corruption types and severity levels.
- In Section C, we give more experimental results to demonstrate the anti-forgetting ability of our EATA.
- In Section D, we provide more discussions on related training-time robustification studies.

A. EATA 的更多实现细节

A.1. 数据集的更多细节

遵循 Tent (Wang 等, 2021) 和 MEMO (Zhang 等, 2021b) 的设置, 我们在三个用于分布外泛化的基准数据集上进行了实验, 即 CIFAR-10-C、ImageNet-C (Hendrycks & Dietterich, 2019) 和 ImageNet-R (Hendrycks 等, 2021)。

CIFAR-10-C 和 **ImageNet-C** 分别由 CIFAR-10 (Krizhevsky 等, 2009) 和 ImageNet (Deng 等, 2009) 的验证图像损坏版本组成。损坏包括 4 个主要类别 (即噪声、模糊、天气和数字) 的 15 种不同类型。每种损坏类型有 5 个不同的严重程度级别。

ImageNet-R 包含 30,000 张图像, 涵盖 200 个 ImageNet 类别的多种艺术表现形式, 这些图像主要收集自 Flickr, 并由 Amazon MTurk 标注员进行筛选。

A.2. 更多实验协议

我们的 EATA。 遵循 TTT (Sun 等人, 2020) 和 Tent (Wang 等人, 2021) 的做法, 我们分别使用 ResNet-26 和 ResNet-50 进行 CIFAR-10 和 ImageNet 实验。模型在原始 CIFAR-10 或 ImageNet 训练集上训练, 然后在干净或上述 OOD 测试集上进行测试。为了公平比较, ResNet-50 的参数直接取自 torchvision 1 库。ResNet-26 通过 TTT 的官方代码使用相同的超参数进行训练, 将组范数替换为批范数, 并移除旋转头。对于测试时自适应, 我们使用 SGD 作为更新规则, 动量为 0.9, 批大小为 64, 学习率对于 CIFAR-10/ImageNet 分别为 0.005/0.00025 (遵循 Tent 和 MEMO)。公式 (3) 中的熵常数 E_0 设置为 $0.4 \times \ln C$, 其中 C 是任务类别数。公式 (6) 中的 ϵ 对于 CIFAR-10/ImageNet 设置为 0.4/0.05。公式 (8) 中的权衡参数 β 对于 CIFAR-10/ImageNet 设置为 1/2,000, 以使两个损失具有相似的量级。我们使用 2,000 个样本来计算公式 (9) 中的 $\omega(\theta_i)$ 。

比较方法。 对于 TTA (Ashukha 等人, 2020)、BN 自适应 (Schneider 等人, 2020) 和 MEMO (Zhang 等人, 2021b), 超参数遵循其原始论文或 MEMO。具体来说, TTA (Ashukha 等人, 2020) 的增强大小对于 CIFAR-10 和 ImageNet 分别设置为 32 和 64。对于 BN 自适应 (Schneider 等人, 2020), 批大小 B 和先验强度 N 均设置为 256。MEMO (Zhang 等人, 2021b) 的超参数设置可在其原始论文中找到。对于 Tent (Wang 等人, 2021), 我们使用 SGD 作为更新规则, 动量为 0.9。批大小对于 ImageNet 和 CIFAR-10 实验均为 64。学习率对于 ImageNet 和 CIFAR-10 分别设置为 0.00025 和 0.005。请注意, Tent 的超参数与我们的 EATA 完全相同, 以确保公平比较。对于 TTT (Sun 等人, 2020), 我们严格遵循其原始设置, 除了测试时的增强大小 1 <https://github.com/pytorch/vision>

ImageNet 实验的时间开销。根据 TTT 的实现，增强尺寸设置为 64，然而这非常耗时（例如，在 ImageNet-C 上使用特定损坏类型和严重程度级别，单块 Tesla V100 GPU 上约需 12 个 GPU 小时）。在我们的实现中，我们将增强尺寸减小到 20，与增强尺寸 64 相比，性能差异很小。例如，使用 ResNet-18 时，TTT 在 ImageNet-C（高斯噪声，严重程度级别 5）上的性能为 26.2%（64）对比 26.0%（20）。我们建议读者参考上述方法的原始论文以获取更多实现细节。

B. 更多关于分布外性能与效率的结果

在表 12 中，我们提供了更多结果，将我们的 ETA 和 EATA 与 ImageNet-C 上严重程度级别 1-4 的最先进方法进行比较。我们的 ETA 和 EATA 在大多数图像损坏类型和各种严重程度级别上持续优于最先进的方法（例如，TTA、MEMO 和 Tent）。性能提升主要来自于移除高熵测试样本，因为这些样本在测试时自适应过程中可能贡献不可靠且有害的梯度。

在图 5 中，我们展示了我们的 ETA 在 ImageNet-C 上不同损坏类型和严重程度级别下的反向传播次数。在各种损坏类型中，我们的 ETA 在自适应效率方面表现出对现有方法的巨大优越性。与 MEMO ($50,000 \times 64$) 和 Tent (50,000) 相比，当严重程度级别设置为 3 时，我们的 ETA 仅需要 31,741 次反向传播（在 15 种损坏类型上取平均）。原因是我们将一些不可靠和冗余的测试样本排除在测试时优化之外。在这种情况下，我们只需要对剩余的测试样本执行反向计算，从而提高了效率。

使用不同学习率与 Tent 的比较。 在我们的样本自适应权重 $S(x)$ （公式 (6)）中，每个测试样本都有一个特定的权重 $S(x)$ ，且 $S(x)$ 的值始终大于 1。从这个意义上说，使用样本自适应权重 $S(x)$ 进行训练实际上与使用更大学习率进行训练具有相同的效果。因此，我们将我们的 EATA 与使用不同学习率的基线（Tent）进行比较。我们将学习率从 2.5×10^{-4} （Tent 的默认值）增加到 25.0×10^{-4} ，并在表 10 中报告结果。

随着学习率从 2.5×10^{-4} 增加到 10.0×10^{-4} ，Tent 的误差从 45.3% 降至 43.9%，表明在某些情况下较大的学习率可能提升性能。然而，当学习率进一步增大到 20.0×10^{-4} 时，Tent 的性能出现下降。更关键的是，我们的 EATA 方法在不同学习率下均优于 Tent。这些结果验证了单纯增大学习率无法达到与本文提出的样本自适应适应方法相竞争的性能，证明了我们的优越性。

表 10. 在 ImageNet-C（高斯噪声）上不同学习率（ $\times 10^{-4}$ ）下与 Tent 的误差（%）比较。

Severity	EATA (ours)		Tent (Wang et al., 2021)		
	$lr = 2.5$	$lr = 2.5$	$lr = 10.0$	$lr = 20.0$	$lr = 25.0$
Level 3	42.6	45.3	43.9	44.4	45.1
Level 5	65.0	71.6	72.2	83.6	87.1

不同随机顺序下的 EATA。 表 11 记录了 EATA 在随机打乱测试样本上的性能（均值与标准差），使用 10 个不同随机种子（从 2020 到 2029）。结果表明，EATA 在不同随机顺序下表现一致，显示了 EATA 的稳定性。

表 11. 在 ImageNet-C（级别 5）上使用 ResNet-50，EATA 在 10 种随机顺序下的损坏准确率（%）的均值与标准差。

高斯噪声	散粒噪声	脉冲噪声	散焦	玻璃模糊	运动模糊	缩放	平均。	
34.9 $\pm$ 0.2	36.9 $\pm$ 0.1	35.8 $\pm$ 0.2	33.6 $\pm$ 0.3	33.3 $\pm$ 0.2	47.2 $\pm$ 0.3	52.7 $\pm$ 0.1	35.8 $\pm$ 0.2	

C. 防止遗忘的更多结果

在本节中，我们提供更多结果以证明我们的 EATA 在防止遗忘方面的有效性。我们分别在图 6 和图 7 中报告了 EATA（终身）与 Tent（终身）以及 EATA 与 Tent 的比较结果。在终身适应场景中，Tent 遭受的 ID 性能下降比重置适应（即图 7）更严重，表明优化步骤越多，遗忘越严重。此外，随着严重程度的增加，

ID 干净准确率的退化程度随 Tent 的增强而相应增加。这一结果表明，分布偏移更严重的 OOD 适应会导致更严重的遗忘。相比之下，我们的方法在两种适应场景（重置和终身）中均实现了更高的 OOD 损坏准确率，同时保持了 ID 干净准确率（与任何 OOD 适应前测试的原始准确率相当）。这些结果与主论文中的结果一致，进一步证明了我们提出的抗遗忘权重正则化的有效性。

D. 关于训练时鲁棒化的更多讨论

为了防御分布偏移，许多先前的研究试图扩大训练数据分布，使其能够覆盖测试时可能遇到的偏移，例如对抗训练策略（Wong 等，2020；Rusak 等，2020；Madaan 等，2021）、各种数据增强技术（Lim 等，2019；Hendrycks 等，2020；Li 等，2021；Hendrycks 等，2021；Yao 等，2022）以及搜索/增强深度模型的子网络（Zhang 等，2021a；Guo 等，2022）。然而，在训练时很难预见所有可能的测试偏移。相比之下，我们试图通过直接从测试数据中学习来克服这种测试分布偏移。

表 12. 在 ImageNet-C 上严重程度 1-4 级下与最先进方法的误差 (%) 比较。“GN”和“BN”分别表示组归一化和批归一化。“JT”表示模型通过监督交叉熵损失和旋转预测损失联合训练。粗体数字表示最佳结果，下划线数字表示次佳结果。

	Noise			Blur				Weather				Digital				Average	
Severity level=1	Gauss.	Shot	Impul.	Defoc.	Glass	Motion	Zoom	Snow	Frost	Fog	Brit.	Contr.	Elastic	Pixel	JPEG	#Forwards	#Backwards
R-50 (GN)+JT	40.9	43.4	52.4	47.4	48.2	39.9	56.2	48.4	45.5	45.2	31.6	35.5	36.7	36.7	39.2	50,000	0
• TTT	37.5	37.4	39.4	41.8	39.7	37.2	43.9	41.7	40.5	36.3	31.0	32.9	35.0	33.8	36.2	50,000×21	50,000×20
R-50 (BN)	40.6	42.8	52.0	40.6	46.0	35.3	47.5	45.4	38.7	38.2	26.0	35.1	33.4	35.9	33.8	50,000	0
• TTA	40.6	42.6	52.5	44.4	46.6	38.0	45.6	48.0	42.0	40.6	28.8	35.6	33.9	37.7	36.8	50,000×64	0
• BN adaptation	34.6	36.1	41.2	35.7	35.2	30.8	37.6	38.2	35.2	31.3	25.4	28.5	30.8	28.7	30.5	50,000	0
• MEMO	36.9	39.5	46.3	38.2	41.1	32.8	42.7	40.4	36.8	35.3	25.8	31.3	31.2	32.4	32.9	50,000×65	50,000×64
• Tent	32.2	32.7	36.2	33.8	32.8	29.7	34.6	35.1	33.6	29.8	<u>25.6</u>	28.0	30.1	28.0	29.8	50,000	50,000
• Tent (episodic)	36.0	37.8	41.7	38.8	38.1	32.0	39.3	40.5	37.3	32.6	26.5	29.8	31.7	29.9	32.1	50,000×2	50,000
• ETA (ours)	31.7	<u>31.8</u>	<u>34.7</u>	32.9	32.2	29.6	34.1	33.6	33.3	29.5	26.0	28.2	30.3	28.1	29.9	50,000	35,379
• EATA (ours)	31.5	<u>31.8</u>	34.9	33.0	<u>32.1</u>	<u>29.2</u>	33.8	33.6	33.0	<u>29.4</u>	25.7	<u>27.7</u>	29.9	27.8	29.6	50,000	34,898
• EATA (lifelong)	31.5	31.7	34.6	32.9	32.0	29.1	33.8	33.6	33.0	29.3	25.8	27.6	29.9	27.8	29.6	50,000	36,675
Severity level=2	Gauss.	Shot	Impul.	Defoc.	Glass	Motion	Zoom	Snow	Frost	Fog	Brit.	Contr.	Elastic	Pixel	JPEG	#Forwards	#Backwards
R-50 (GN)+JT	50.1	55.0	60.0	55.8	61.6	49.9	65.5	68.9	63.1	52.0	33.5	38.6	58.0	39.4	42.8	50,000	0
• TTT	42.0	42.5	44.3	47.7	53.3	42.7	48.2	50.4	56.6	38.2	31.8	34.3	49.4	34.7	38.3	50,000×21	50,000×20
R-50 (BN)	53.8	57.9	64.2	48.0	59.6	45.7	57.4	68.1	55.9	44.1	27.6	41.6	55.2	35.9	37.5	50,000	0
• TTA	52.9	56.9	62.4	53.0	60.4	49.3	54.4	71.5	60.6	46.9	30.7	40.0	53.8	41.1	40.3	50,000×64	0
• BN adaptation	42.3	45.6	49.7	43.0	44.5	37.4	44.1	53.1	47.6	34.1	26.6	30.6	47.2	29.7	33.8	50,000	0
• MEMO	47.1	51.7	55.9	44.8	53.4	41.3	51.8	58.6	51.6	40.2	27.2	35.5	51.0	33.6	36.2	50,000×65	50,000×64
• Tent	37.2	38.5	41.8	39.5	39.4	34.0	39.2	44.8	43.6	31.6	26.6	29.7	44.1	29.0	32.1	50,000	50,000
• Tent (episodic)	44.0	47.2	50.5	48.0	49.3	39.2	46.4	55.0	50.7	35.5	27.6	32.3	49.1	32.2	36.1	50,000×2	50,000
• ETA (ours)	35.8	<u>36.5</u>	<u>39.5</u>	37.7	<u>37.8</u>	<u>33.1</u>	37.7	41.4	<u>41.7</u>	30.9	27.0	29.2	43.0	28.6	31.8	50,000	33,363
• EATA (ours)	<u>35.9</u>	<u>36.5</u>	39.6	37.9	<u>37.8</u>	<u>33.1</u>	<u>37.4</u>	41.7	<u>41.7</u>	30.7	26.7	29.1	42.6	28.4	31.4	50,000	32,754
• EATA (lifelong)	<u>35.9</u>	36.2	39.2	37.7	37.6	33.0	37.3	41.6	41.6	<u>30.8</u>	26.6	29.1	42.6	<u>28.5</u>	31.4	50,000	34,922
Severity level=3	Gauss.	Shot	Impul.	Defoc.	Glass	Motion	Zoom	Snow	Frost	Fog	Brit.	Contr.	Elastic	Pixel	JPEG	#Forwards	#Backwards
R-50 (GN)+JT	64.4	69.3	66.7	71.5	83.2	65.8	71.4	65.5	73.9	61.3	36.7	45.2	44.1	50.2	45.5	50,000	0
• TTT	48.5	48.9	48.3	57.7	67.1	50.7	50.7	51.2	70.3	41.0	33.3	37.6	36.3	38.4	39.9	50,000×21	50,000×20
R-50 (BN)	72.4	75.0	74.9	62.0	83.1	62.3	64.8	64.8	67.9	53.4	30.4	54.0	44.4	53.8	40.7	50,000	0
• TTA	70.4	72.7	70.0	68.7	83.7	66.2	62.0	67.9	72.7	56.3	33.8	47.7	47.8	51.8	43.4	50,000×64	0
• BN adaptation	54.7	57.2	56.6	57.8	63.6	48.9	48.8	52.2	57.5	38.2	28.3	35.4	33.1	36.0	36.6	50,000	0
• MEMO	62.5	65.7	63.3	58.8	76.7	55.9	58.9	55.6	62.6	47.9	29.5	44.0	41.3	45.0	39.2	50,000×65	50,000×64
• Tent	45.3	45.9	46.6	51.1	53.9	41.2	42.4	44.4	51.5	34.2	27.9	32.9	30.7	32.6	34.3	50,000	50,000
• Tent (episodic)	56.6	58.8	57.5	64.9	69.5	51.5	51.0	54.4	60.3	39.9	29.5	37.7	35.3	37.5	39.1	50,000×2	50,000
• ETA (ours)	42.4	42.4	<u>43.3</u>	<u>47.3</u>	49.6	38.9	40.5	41.2	48.5	33.1	28.1	32.0	30.5	31.7	33.6	50,000	31,741
• EATA (ours)	<u>42.6</u>	42.9	43.7	47.4	49.8	<u>38.8</u>	<u>40.4</u>	<u>41.6</u>	<u>48.7</u>	32.7	27.7	31.7	30.0	31.8	33.3	50,000	31,068
• EATA (lifelong)	<u>42.6</u>	42.4	43.2	47.2	49.6	38.7	40.2	<u>41.6</u>	48.8	<u>32.9</u>	<u>27.8</u>	31.7	<u>30.1</u>	31.7	<u>33.4</u>	50,000	33,469
Severity level=4	Gauss.	Shot	Impul.	Defoc.	Glass	Motion	Zoom	Snow	Frost	Fog	Brit.	Contr.	Elastic	Pixel	JPEG	#Forwards	#Backwards
R-50 (GN)+JT	81.4	87.6	82.2	81.8	87.8	80.2	77.2	76.8	75.9	66.9	41.8	64.2	54.8	68.0	54.7	50,000	0
• TTT	57.5	58.7	57.1	64.8	84.9	60.5	54.4	57.3	73.1	43.1	35.5	46.0	39.6	44.5	45.1	50,000×21	50,000×20
R-50 (BN)	89.0	92.1	91.8	73.5	87.2	78.1	71.6	75.9	70.1	59.6	34.9	79.5	57.8	71.1	52.5	50,000	0
• TTA	85.9	89.5	86.1	79.8	88.4	80.5	67.9	79.3	74.4	62.9	39.3	65.8	61.0	66.2	53.0	50,000×64	0
• BN adaptation	69.3	74.1	71.2	70.3	70.5	63.0	54.8	62.0	58.9	41.5	30.8	50.0	38.7	44.7	46.0	50,000	0
• MEMO	78.5	83.3	78.8	71.0	82.2	71.2	67.6	65.9	64.5	53.3	33.4	66.7	52.8	58.6	48.7	50,000×65	50,000×64
• Tent	56.0	59.4	57.3	61.7	60.6	50.9	46.5	51.4	53.1	36.5	30.0	43.3	34.0	37.9	39.6	50,000	50,000
• Tent (episodic)	70.7	75.5	72.0	77.3	76.5	66.3	57.2	64.1	61.8	43.1	32.0	56.4	41.4	46.5	48.9	50,000×2	50,000
• ETA (ours)	51.5	<u>53.4</u>	<u>52.5</u>	57.1	<u>55.4</u>	46.6	<u>43.7</u>	<u>46.9</u>	49.7	35.1	<u>29.8</u>	39.4	33.2	36.0	38.2	50,000	29,240
• EATA (ours)	<u>52.3</u>	54.2	53.0	<u>57.0</u>	55.5	46.6	<u>43.7</u>	46.8	49.9	34.7	29.7	<u>39.8</u>	33.1	<u>36.4</u>	<u>38.3</u>	50,000	28,423
• EATA (lifelong)	<u>52.3</u>	53.0	52.2	56.4	55.1	46.6	43.4	47.2	49.7	<u>34.8</u>	<u>29.8</u>	40.0	33.1	36.5	38.5	50,000	31,141




图 5. ETA 与 Tent 在 ImageNet-C 上不同损坏类型和严重程度级别下反向传播次数的比较。

高效的无遗忘测试时模型自适应




图 6. 使用 ResNet-50 在 ImageNet-C (严重程度 1-4 级) 上防止遗忘的比较。我们记录每个损坏测试集上的 OOD 损坏准确率以及相关的 ID 干净准确率 (OOD 适应后)。模型执行终身适应, 其中模型参数永远不会被重置。

高效的无遗忘测试时模型自适应




图 7. 在 ImageNet-C (严重程度 1-4) 上使用 ResNet-50 进行防遗忘比较。我们记录每个损坏测试集上的分布外损坏准确率以及相关的分布内干净准确率 (分布外适应后)。在适应新的损坏类型之前, Tent 和我们的 EATA 的模型参数均被重置。