

Can We Detect Failures Without Failure Data? Uncertainty-Aware Runtime Failure Detection for Imitation Learning Policies

Chen Xu¹, Tony Khuong Nguyen¹, Emma Dixon¹, Christopher Rodriguez¹, Patrick Miller¹, Robert Lee²,
Paarth Shah¹, Rares Ambrus¹, Haruki Nishimura¹, and Masha Itkina¹

¹Toyota Research Institute (TRI), ²Woven by Toyota (WbyT)
chen.xu@tri.global


摘要——近年来，得益于模仿学习与生成建模（如基于扩散和流的方法）的进展，机器人操作系统的性能令人瞩目。随着机器人策略性能的提升，可实现任务的复杂度和时间跨度也随之增加，从而引发难以事先预测的意外且多样的失败模式。为了在安全关键的人类环境中实现可信的策略部署，策略推理过程中的可靠运行时失败检测变得至关重要。然而，现有大多数失败检测方法依赖于对失败模式的先验知识，并且需要在训练阶段获取失败数据，这在实用性和可扩展性方面构成了重大挑战。针对这些局限性，本文提出 FAIL-Detect，一种用于基于模仿学习的机器人操作中失败检测的模块化两阶段方法。为了仅从成功训练数据中准确识别失败，我们将该问题建模为序列化分布外检测。首先，我们将策略输入和输出提炼为与策略失败相关并能捕捉认知不确定性的标量信号。随后，FAIL-Detect 采用保形预测作为具有统计保证的不确定性量化的通用框架。在实验上，我们在多种机器人操作任务中深入研究了学习型与事后型标量信号候选方案。实验结果表明，学习型信号大多持续有效，尤其是在使用我们新颖的基于流的密度估计时。此外，与最先进的失败检测基线相比，我们的方法能够更准确、更快速地检测失败。这些结果凸显了 FAIL-Detect 在基于模仿学习的机器人系统迈向实际部署过程中提升安全性与可靠性的潜力。FAIL-Detect 的视频可在我们的网站上查看：<https://cxu-tri.github.io/FAIL-Detect-Website/>。

一、引言


机器人操作在制造、物流和医疗保健等许多重要领域都有应用 [19]。近年来，模仿学习算法利用扩散 [12, 65] 和基于流的方法 [9, 45] 等随机生成建模，在从人类演示中学习复杂操作技能方面取得了巨大成功。然而，尽管结果出色，策略网络仍可能因动作分布的随机采样不佳而失败。模型还可能遇到分布外（OOD）条件，即输入观测偏离训练数据分布。在这种情况下，生成的动作可能不可靠甚至危险。

因此，必须快速检测这些失败，以确保机器人系统的安全性和可靠性。在机器人操作任务中检测失败面临若干挑战。首先，用于失败检测的输入数据（如环境观测）通常是高维的，且分布复杂。这使得识别区分成功与失败执行的判别特征变得困难，尤其是在未定义奖励函数的模仿学习环境中。其次，由于操作任务的复杂性和可能环境条件的广泛范围（见图 2），失败的机会数不胜数。因此，失败检测器必须对各种失败场景具有通用性和鲁棒性。在模仿学习中，训练数据自然由成功轨迹组成，使得失败轨迹成为分布外（OOD）数据。先前的工作通常通过分布内（ID）和分布外（OOD）条件的二元分类来处理失败检测 [33]。因此，许多这些方法 [24, 17, 18, 33] 需要分布外数据来训练失败分类器。这带来了重大挑战，因为收集和标注全面的失败示例集通常耗时、昂贵，在许多现实场景中甚至不可行。此外，在特定分布外数据集上训练的分类器可能无法很好地泛化到未见过的失败模式。为了解决这些局限性，我们开发了一种无需访问分布外数据的失败检测方法，克服了对失败示例的依赖，同时保持稳健的性能。我们提出 **FAIL-Detect**：模仿学习中的失败分析——无需失败数据检测失败。**FAIL-Detect** 是一种两阶段方法（见图 1），用于生成式模仿学习策略中的失败检测。在第一阶段，我们从策略输入和/或输出（例如，机器人状态、视觉特征、生成未来动作）中提取标量信号，这些信号在策略推理期间对成功和失败具有判别性。我们研究了学习型 and 事后型信号候选，发现学习型信号在失败检测中最为准确。我们方法的一个关键新颖性在于能够在没有失败数据的情况下学习失败检测信号。除了性能优异外，我们的方法比先前的工作 [1] 推理速度更快，后者需要在推理期间采样多个机器人动作。在第二阶段，

Stage 1: Score Learning



Stage 2: Threshold Calibration



Runtime Failure Detection




图 1: FAIL-Detect: 模仿学习中的失败分析——在无失败数据的情况下检测失败。 本文提出一种两阶段失败检测方法。（左——阶段一）多视角相机图像与机器人状态被提炼为失败检测标量分数。图像首先经过特征提取器，随后与机器人状态共同构成观测 O_t 。 O_t 与生成的未来机器人动作 A_t 均可作为分数网络 D_M 的输入。该网络输出标量分数 $D_M(A_t, O_t)$ ，以捕捉成功演示数据的特征。（中——阶段二）来自成功轨迹校准集的分数随后用于计算均值 μ_t 与带宽 h_t ，以构建时变共形预测阈值。（右——运行时失败检测）成功轨迹（底部）的分数始终保持在阈值以下。当失败发生时（顶部），例如未能折叠毛巾，分数会飙升至阈值以上，从而触发失败检测（红色框）。


本文采用共形预测（Conformal Prediction, CP）[52, 47] 构建时变阈值，以序贯方式判断分数何时指示失败，并对假阳性率提供统计保证。通过将自适应函数型共形预测 [14] 集成到本文流程中，所获得的阈值能够适应操作任务动态变化，不同于先前工作中使用的静态阈值 [1]。本文贡献如下。本文提出 FAIL-Detect，一种模块化的两阶段不确定性感知运行时失败检测框架，适用于基于生成式模仿学习的机器人操作。首先，构建代表任务成功的标量分数。其次，利用共形预测构建具有随机保证的时变阈值。FAIL-Detect 可灵活整合新的分数与阈值设计。本文全面测试了仅依赖成功演示的学习型与事后型分数候选方案。基于流式密度估计器的新型学习分数（logpZO）使 FAIL-Detect 优于其他方法。实验表明，FAIL-Detect 在多种机器人操作任务中（包括仿真与真实机器人硬件）能够准确且快速地识别失败，性能超越最先进的失败检测基线。

II. 相关工作

机器人操作中的模仿学习。 模仿学习已成为一种强大的范式，通过从专家演示中学习来教授机器人复杂技能。扩散策略（Diffusion Policy, DP）[12] 利用扩散模型 [22] 在该领域表现出极高的性能。扩散策略学习对从高斯分布采样的轨迹进行去噪，有效捕捉人类演示中常见的多模态动作分布 [63, 12]。扩散模型已被用于学习以观测为条件的策略 [12, 49]、通过语言条件整合语义信息 [63, 10, 44]，以及提升鲁棒性和泛化能力 [29, 54, 56]。与此同时，视觉-语言-动作模型如 Octo[40] 和 OpenVLA[28] 通过在不同数据集上进行大规模预训练，在通用机器人操作方面展现出潜力。最近，流匹配

（流匹配）生成模型已被提出作为模仿学习中扩散模型的替代方案 [4, 23, 6, 64]，提供更快的推理速度和更大的灵活性（即超越高斯先验 [9]），同时达到具有竞争力或更优的成功率。我们在扩散策略和流匹配模仿学习架构上测试了 FAIL-Detect。

分布外检测（OOD Detection）。 机器人故障检测任务可视为异常检测，属于更广泛的分布外检测框架 [61]。集成方法 [31] 通过组合多个模型的预测来提升鲁棒性并估计不确定性，长期以来被视为解决该问题的标准方法。然而，这类方法计算开销大，因为需要训练多个模型并分别进行推理。另一种流行的方法将分布外检测建模为分类问题 [34]。该形式通过训练二分类器 [53, 15] 学习分布内与分布外数据之间的决策边界，但训练时需要分布外数据。相比之下，基于密度的方法 [35, 16, 60]、基于随机网络的单类判别器 [13, 21] 以及控制理论方法 [7] 旨在仅利用分布内数据建模信息，训练时不依赖分布外数据。基于密度的方法试图捕捉分布内数据的分布，但优化难度较大。单类判别器在实践中表现出优于深度集成的性能，但对判别器模型的设计较为敏感。控制理论方法使用对比式基于能量的模型，但通常需要系统动力学的表示。此外，证据深度学习（Evidential Deep Learning）方法 [8, 5, 25] 学习二阶分布（如狄利克雷分布）的参数，以从偶然不确定性（数据固有随机性所致）中近似认知不确定性（模型知识有限或分布外输入所致）。最后，基于距离的方法 [3, 51, 27] 通过计算样本在输入空间或潜空间中与分布内样本的距离来识别分布外样本，无需训练，但性能相比其他方法有限。我们将上述多种模型变体作为 FAIL-Detect 中的评分候选。



(a) Slipped out early. (b) Slipped out late. (c) Tilted upward. (d) Tilted downward. (e) Tilted slightly. (f) Not picked up.

图 2: 在简单的抓放任务（将方块套在柱上）中，单一训练策略 g 表现出的多种故障类型。这些故障发生在多次推演的不同时间步，包括方块从夹爪滑落或放置位置不当（如倾斜套在柱上）。FAIL-Detect 能够处理测试时观察到的各种故障。

机器人故障检测。检测机器人系统中的故障对于确保安全性和可靠性至关重要，因为故障可能导致在人类环境中出现不良行为 [39, 42, 34]。已提出多种方法，例如基于大语言模型嵌入构建快速异常分类器 [48]，以及利用变分自编码器（VAE）的重构误差来检测移动操作中行为克隆（BC）策略的异常 [57]。另外，Ren 等人 [43] 从共形预测中为基于大语言模型的规划器生成的动作构建不确定性集合，当集合模糊时提示人类干预。这些工作未考虑生成式模仿学习策略下的故障检测。另一方面，Gokmen 等人 [18] 学习一个与 BC 策略联合训练的状态价值函数，可用于预测故障。Liu 等人 [33] 提出一种基于 LSTM 的故障分类器，用于 BC-RNN 策略，利用条件 VAE 的潜在嵌入。给定基于 Transformer 的策略和用于预测未来潜在嵌入的世界模型，Liu 等人 [34] 在嵌入上训练故障检测分类器。为处理未见过的状态，他们还提出一种最先进的分布外检测方法，我们将其适配为基线（见第 V 节 PCA-kmeans）。然而，与 FAIL-Detect 不同，这些方法需要预先收集失败轨迹来检测故障。同时，Wang 等人 [55] 使用自重置收集额外故障数据并训练分类器以识别故障模式。在他们的机器人实验中，必须使用自重置收集约 2000 条轨迹（约 2 小时），这使得可扩展性具有挑战性。对于基于扩散的策略，Sun 等人 [50] 通过为预测轨迹的奖励生成预测区间来降低模型不确定性。He 等人 [21] 提出使用随机网络蒸馏（RND）检测分布外轨迹并选择可靠轨迹。这些工作未直接考虑运行时故障检测。我们针对此问题的两阶段解决方案结合了两方法的优势。与 FAIL-Detect 最接近的最先进方法由 Agia 等人 [1] 提出，引入统计时间动作一致性（STAC）测度，结合视觉语言模型（VLM）在运行时检测展开过程中的故障。STAC 不需要故障数据，由一批预测动作事后计算的分数和常数时间的共形预测阈值组成以标记故障，并在扩散策略背景下进行评估。我们展示了改进的经验性能

通过将学习到的故障检测分数与时变共形预测带相结合，在 STAC 基础上提升性能。

三、问题表述

本文的核心工作是检测生成式模仿学习策略在执行过程中何时未能完成任务。定义如下符号。设 $g(A_t | O_t)$ 表示生成器，其中 O_t 表示时间 t 的环境观测（例如图像特征和机器人状态）， g 是未来 H 个时间步动作序列

$A_t = (A_{t|t}, A_{t+1|t}, \dots, A_{t+H-1|t})$ 的随机预测器。执行前 $H' < H$ 个动作 $A_{t:t+H'|t}$ 后，机器人在时间 $t+H'$ 重新规划，生成新的 H 个动作序列。近期工作已通过扩散策略 [12] 和流匹配 [9] 训练出有效的生成器 g 。给定初始条件 O_0 和生成器 g 输出下一步动作，我们得到一条轨迹

$\tau_t = (O_0, A_0, O_{H'}, A_{H'}, \dots, O_t, A_t)$ up to $t = kH'$ ($k \geq 1$) 执行时间步。因此，故障检测可表述为设计一个带参数 θ 的决策函数 $D(\cdot; \theta) : \tau_t \rightarrow \{0, 1\}$ ，该函数接收当前轨迹并做出决策。若决策 $D(\tau_t; \theta) = 1$ ，则在时间步 t 将该次执行标记为故障。例如，在抓取放置任务中，当机器人未能抓取物体或未达到目标位置时，即可检测到故障。

四、故障检测框架

Given action-observation data (A_t, O_t) , we propose a two-stage framework to design the decision function $D(\cdot; \theta)$:

- 1) Train a scalar score model $D_M(\cdot; \theta) : (A_t, O_t) \rightarrow \mathbb{R}$ (for score “method” M) on action and/or observation pairs from successful trajectories only.
- 2) 基于共形预测带校准时变阈值 η_t 。

最终决策为：若 $D(\tau_t; \theta) = \mathbb{1}(D_M(A_t, O_t; \theta) > \eta_t)$ raises 标量分数 $D_M(A_t, O_t; \theta)$ 在时间步 t 超过阈值 η_t ，则发出故障标志。该两阶段框架灵活，可在第一阶段纳入新分数或在第二阶段纳入新阈值。框架概览见图 1。

A. 标量分数的设计

为了构建能够指示失败的评分，本文提出了一种新颖的评分候选方案，并对若干现有方法进行了适配，这些方法最初是为其他应用而开发的。参见

表一，了解本文所评估的评分方法概览。

表一：本文评估的评分方法概览。输入的选择基于每种方法的结构和需求，或者在多种输入组合可行时，基于经验性能进行选择。除 STAC（其提出了不同的校准方法；见第五节）外，所有方法均使用第四节 B 部分描述的时变共形预测带。

Method	Type	Input	Category	Novelty	Original application
logpZO 学习型	O_t 密度估计	新颖的 lopO 学习型	O_t 密度估计	适配自 [60] 表格数	N/A 据的似然估计
NatPN 学习型	O_t 二阶	适配自 [8]	分类		
与回归的分布外检测	DER 学习型	(O_t, A_t) 二阶	适配自 [5]	人体姿态估计的分布外检测	RND 学习型
				(O_t, A_t) 单类判别器	适配自 [21]
强化学习 [21]; 分布外检测 [13]	CFM 学习型	O_t 单类判别器	适配自 [62]	流模型的高效采样	SPARC 后处理型
				A_t 平滑度测度	适配自 [2]
时间序列数据的平滑度分析	STAC 后处理型	A_t 统计发散	基线 [1]	生成式模仿学习策略的失败检测	PCA-kmeans 后处理型
				O_t 聚类	基线 [34]
机器人执行过程中的分布外检测					

在设计能够指示策略失败的标量评分时，本文考虑以下需求：

(1) 单类：方法在训练期间不应需要失败数据，因为失败数据可能过于多样而难以枚举（见图 2）。(2) 轻量

级：方法应支持快速推理，以实现实时机器人操作。(3) 判别性：方法应在成功和失败轨迹的评分上产生差距。为避免对历史数据过拟合，评分网络 D_M 仅将过去观测 O_t 中最近的 T_O 步（ $T_O = 2$ 跟随 [12]）以及未来动作 A_t 作为输入，而非不断增长的轨迹历史。为满足上述需求，本文选择并基于以下方法类别进行构建。

(a) 学习型数据密度：本文对观测数据拟合基于归一化流（Normalizing Flow）的密度估计器，其中远离成功轨迹观测分布的数据可能指示失败。本文所提方法 lopO [60] 对观测集合 $\{O_t\}_{t \geq 0}$ 拟合连续归一化流（Continuous Normalizing Flow, CNF） f_θ ，对于新观测 $O_{t'}$ ，低 $\log p(O_{t'})$ 意味着其不太可能出现，从而指示可能的失败。注意，计算 $\log p(O_{t'})$ 需要在常微分方程轨迹上对 f_θ 的发散进行积分，这在高维度下难以估计。

此外，本文提出新颖的对数概率零阶（logpZO）方法，该方法利用相同的连续归一化流（CNF） f_θ 来评估噪声估计 Z_{O_t} （以观测 O_t 为条件）的似然。利用前向常微分方程（ODE）过程，本文通过从初始条件 O_t 出发，在单位区间 $[0, 1]$ 上对 f_θ 进行积分来计算 Z_{O_t} 。当 O_t is ID, Z_{O_t} 近似 $p(Z_{O_t}) = C \exp(-0.5|Z_{O_t}|^2)$ 为高斯分布时，可 of $|Z_{O_t}|^2$ 得。因此，较高的值对应于噪声空间中较低的似然 $p(Z_{O_t})$ 。关于 logpZO 的更多细节见附录 A。lopO 与 logpZO 的关键区别在于其定义域：前者在原始观测空间中评估似然，而后者在潜在噪声空间中评估。本文预期后者更优，因为其计算不需要在 $[0, 1]$ 上对 f_θ 的散度进行积分，而该量在高维空间中难以估计。

(b) 二阶：这些方法学习二阶分布的参数，能够分离偶然不确定性与认知不确定性 [46]。NatPN[8] 在类别概率上施加狄利克雷先验，并通过以下方式优化模型参数

最小化贝叶斯损失。为使用 NatPN，我们利用 K 均值对观测值 O_t 进行离散化，并将 NatPN 应用于离散化版本。此外，我们还考虑了多元深度证据回归 DER [5]，该方法假设 $A_t|O_t$ 服从具有威沙特先验的多元高斯分布，并学习其参数。

(c) 单类判别器：本文考虑学习连续度量（metric）的方法，但不直接建模输入数据的分布。单类判别器随机网络蒸馏（Random Network Distillation, RND）[21] 初始化随机目标 $f_T(\cdot)$ 和随机预测器 $f(\cdot; \theta)$ 网络。目标网络被冻结，而预测器

经训练以最小化 $\mathbb{E}_{(A_t, O_t) \sim \text{ID 轨迹}} [D_M(A_t, O_t; \theta)]$
 $D_M(A_t, O_t; \theta) = \|f_T(A_t, O_t) - f(A_t, O_t; \theta)\|^2$

针对成功的演示数据。直观上，RND 学习从数据 (A_t, O_t) 到预设随机函数的映射。如果学习到的映射开始偏离预期的随机输出，则输入数据很可能是分布外（OOD）的。在此类别中，我们还考虑了流匹配一致性（CFM）[62]，它通过观测到噪声前向流的经验方差来度量轨迹曲率。其直觉是，在分布内（ID）数据上，前向流被训练为笔直且一致的。因此，高轨迹曲率表明输入数据是分布外的。

(d) 事后度量：我们研究无需学习即可解析计算标量分数的方法。我们使用 SPARC [2] 来度量预测动作的平滑度。我们期望 SPARC 对机器人抖动故障有用，这类故障在分布外场景中经验上很常见。最近在基于成功的故障检测中的最先进方法 STAC [1] 属于事后方法类别。然而，由于它自带统计评估程序，我们在第五节中将其描述为主要基线之一。此外，我们将 Liu 等人 [34] 提出的分布外检测方法称为 PCA-kmeans，它也属于此类别。我们在两阶段框架中将其改造为第五节中的另一个基线。

B. 基于共形预测的序列阈值设计

我们设计了一个时变阈值 η_t ， $D_M(A_t, O_t; \theta)$ exceeds η_t . To do so, we 使得当利用函数型共形预测（CP）[14] 时标记故障，该框架包裹任意标量分数 $D_M(A_t, O_t; \theta)$ 的时间序列（分数越高表示




图 3：机器人硬件实验场景。（顶行）带干扰的折叠红毛巾：在（b）中，人在策略执行期间将毛巾从（a）中的位置向底部拉动。我们注意到，这种恢复行为有时存在于训练数据中，因此任务可能如（c）中所示成功。失败案例如（d）所示。（中行）折叠红毛巾分布外：与分布内（e）相比，我们以一块皱巴巴的毛巾开始，毛巾右侧有一个蓝色铲子干扰物，如（f）所示。这两种情况在训练数据中均不存在，因此尽管任务可能如（g）中所示成功，但成功率较低，机器人通常如（h）中所示失败。（底行）清理溢出物分布外：与分布内（i）相比，我们以一块绿色毛巾开始，如（j）所示。训练数据仅包含白色和灰色毛巾，因此尽管任务可能如（k）中所示成功，但机器人通常如（l）中所示以较低成功率失败。

失败）并产生一个分布无关的预测带 C_α ，其显著性水平由用户指定 $\alpha \in (0, 1)$ 。在温和条件下 [52, 58, 59]， C_α 在整个展开期间以至少 $1 - \alpha$ 的概率包含任何分布内得分 $D_M(A_t, O_t; \theta)$ 。若 $D_M(A_t, O_t; \theta) \notin C_\alpha$ ，我们可以确信地拒绝 (A_t, O_t) is ID。

对于顺序故障检测，我们构建 C_α 作为单侧时变共形预测带。该带是单侧的，因为我们只关注标量得分 $D_M(A_t, O_t; \theta)$ 的高值，这表明轨迹是分布外（即故障）。给定 N 个成功展开作为校准数据，我们获得标量得分 $\mathcal{D}_{cal} = \{D_M(A_t^i, O_t^i; \theta) : t = 1, H', \dots, T\}$ 。共形预测带是一组区间 $\text{其中下界 } t = \min(\mathcal{D}_{cal})$ ，因

$C_\alpha = \{[\text{lower}_t, \text{upper}_t] : t = 1, H', \dots, T\}$ ，为该带是单侧的。为获得上界，我们遵循 [14]，计算时变均值 μ_t 和带宽 h_t ，使得上界 $t = \mu_t + h_t$ 。理论上，对于一次新的成功展开 $\tau_T = (O_0, A_0, \dots, O_T, A_T)$ ，至少以概率 $1 - \alpha$ ，得分 $D_M(A_t, O_t; \theta) \in [\text{下界}_t, \text{上界}_t]$ 对所有 $t = 1, H', \dots, T$ 成立。通过定义阈值 $\eta_t = \text{上界}_t$ 并将失败设为 1，决策规则 $\mathbb{1}(D_M(A_t, O_t; \theta) > \eta_t)$ 控制误差

（成功被标记为故障）在水平 α 。

五、实验

我们在仿真和机器人硬件上测试我们的两阶段故障检测框架。我们的实验跨越多个环境，每个环境在任务类型和分布偏移方面都带来独特的挑战。我们在 FAIL-Detect 框架内实证研究了一组广泛的已学习和事后标量得分（见表 I）（结果见第六节）。关于策略训练、共形预测带校准程序和已学习标量得分架构的更多细节，请参阅附录 C。a) 任务：在仿真中，我们考虑来自开源 Robomimic 基准¹ [38] 的 **Square**、**Transport**、**Can** 和 **Toolhang** 任务。在机器人硬件实验中，我们考虑双臂 Franka Emika Panda 机器人站上的两个任务，这些任务显著更具挑战性：**FoldRedTowel** 和 **CleanUpSpill**（见图 8）。我们为每个任务构建分布外设置。在仿真中，我们在 $t = 50$ 之后的第一个时间步将第三人称相机向上调整 10 厘米，以模拟展开中途的相机碰撞²。对于机器人上的

¹ 我们省略了 Lift 任务，因为 FM 和 DP 策略均达到 100% 成功率。² 我们对 Can 使用 $t = 15$ ，因为它的任务完成时间最短。




图 4: 仿真任务在快速移动策略上的定量故障检测结果 (最佳、次佳、第三); 含真阳率和真阴率的结果见图 11, 含差分隐私的结果见图 12。对于平衡准确率和加权准确率, 数值越高越好; 对于检测时间, 数值越低越好。每个任务的校准预测带仅使用分布内初始条件下的成功轨迹进行校准 (即分布内和分布外测试用例使用相同的预测带)。我们将事后方法 (STAC、PCA-kmeans、SPARC)、基于密度的方法 (logpO、logpZO)、二阶方法 (DER、NatPN) 和单类方法 (CFM、RND) 分组展示, 并绘制带标准差的条形图。检测时间图中的虚线表示该设置下平均成功轨迹时间及其标准差。总体而言, 学习型方法在故障检测方面优于事后方法。就综合准确率 (平衡准确率和加权准确率) 而言, logpZO 和 RND 是最佳的两个方法, 分别在 16 个案例中的 10 个和 5 个达到最佳性能。此外, logpZO 在 16 个案例中的 14 个达到前三性能, 而 RND 在 9 个案例中达到前三性能。相比之下, 基线方法 STAC 和 PCA-kmeans 分别在 16 个案例中的 3 个和 0 个达到最佳性能。值得注意的是, STAC 在 16 个案例中的 8 个达到前三性能, 而 PCA-kmeans 在 3 个案例中达到前三性能。学习型方法还实现了最快的检测时间, 除一个案例外, 学习型方法之一始终获得最佳总体检测时间。就最佳性能而言, logpZO 在 8 个案例中的 3 个是最快方法, RND 在 0 个案例中是最快方法, 而 PCA-kmeans 基线在 1 个案例中是最快方法。相比之下, STAC 在几乎所有案例中都是最慢的, 仅在平均成功轨迹时间之后才检测到故障, 使得检测不实用。

FoldRedTowel 任务中, 我们在第一次折叠后扰动任务 (具有挑战性的分布内场景), 并通过揉皱毛巾 (在不到 $\sim 15\%$ 的数据中出现) 和添加一个从未见过的干扰物 (蓝色铲子) 来创建一个分布外初始条件。对于清理溢出物任务, 我们通过将毛巾更换为一条新颖的绿色毛巾来创建分布外初始条件 (见图 3)。b) 基线: 我们将 FAIL-Detect 与 STAC[1] 和 PCA-kmeans[34] 作为基线进行比较, 它们是生成式模仿学习策略中基于成功的故障检测的最先进方法。STAC 在每个时间步生成预测动作的批次 (例如 256 个)。然后, 它计算两个连续预测的时间重叠区域之间的统计距离 (例如最大均值距离 (MMD)) , 其中 MMD 由批次元素近似。直观上, MMD 衡量了 rollout 过程中预测的“意外程度”, 随后 STAC 使用共形预测进行检测。请注意, STAC 不是为时间序列计算共形预测带, 而是基于累积发散的经验分位数计算单个阈值

在校准集中。我们复现了该方法, 并采用其 push-T 示例中使用的超参数, 其中我们在每个时间步生成 256 个动作预测的批次。我们没有采用 STAC 故障检测器的视觉语言模型组件, 以尽可能保持实时可行性。由于 STAC 推理时间较长 (即使并行化后) 以及由此产生的高系统延迟, 我们省略了其在两个机器人硬件任务上的比较。在我们的第二个基线中, Liu 等人 [34] 通过训练故障分类器来解决故障检测问题, 这需要收集故障训练数据。然而, 这种方法不适用于我们的设置, 因为我们假设只能访问成功的人类演示用于训练和成功的 rollout 用于校准。相反, 我们将他们提出的分布外检测方法作为后验标量分数纳入 FAIL-Detect 的第一阶段, 以构建一个公平的基线。我们使用性能良好的时变共形预测带在第二阶段获得阈值。该方法测量测试时间索引 t' 处的新观测 $O_{t'}$ 与训练数据 $\{O_t\}_{t \geq 0}$ 集合之间的距离, 这些训练数据包括




图 5：机器人硬件实验的定量结果，涵盖两项任务，策略分别使用流匹配（FM）和扩散策略（DP）训练。我们考虑两种计算一致性预测（CP）区间的方法：“设置依赖型”使用每个分布外/分布内环境的成功轨迹，“仅分布内型”仅使用分布内环境的轨迹。对于平衡准确率和加权准确率，数值越高越好；对于检测时间，数值越低越好。更多度量指标见图 13 和图 14。图布局与图 4 相同（最佳、次佳、第三佳），“NaN”检测时间表示没有测试轨迹被检测为失败。再次表明，学习型方法优于事后方法。注意，此处未展示 STAC，因为它在硬件上实时运行速度较慢。在小样本量情况下，logpZO 在综合准确率上保持稳健，在最多情况下（8/12）达到第一，在 11/12 情况下达到前三。RND 从未达到第一，但始终达到前三。相比之下，PCA-kmeans 基线在 4/12 情况下达到第一，在 10/12 情况下达到前三。在检测时间方面，事后 SPARC 方法在 4/6 情况下最快，但从未达到第一。PCA-kmeans 在速度上稳健，在 4/6 情况下达到前三。logpZO 仍然实用，其检测时间远低于平均成功轨迹完成时间。

视觉编码特征与策略在演示数据上联合训练。主成分分析-均值聚类方法首先利用主成分分析对训练特征进行嵌入，随后对嵌入后的数据应用 K 均值聚类以获得 $K = 64$ 个质心。使用相同的主成分对 O_t 进行嵌入后，该方法计算嵌入与 K 个质心之间的最小欧氏距离。该距离作为分布外度量（数值越大表示分布外程度越高）。由于随机网络蒸馏在先前工作中已展现出优于集成方法的性能 [13]，且集成方法的计算成本过高，本文省略了与集成方法 [31] 这一流行分布外检测技术的比较。c) 评估协议：为量化失败检测性能，本文将失败轨迹标记为一，成功轨迹标记为零。随后采用以下标准度量：(1) 真阳性率，(2) 真阴性率，(3) 平衡准确率 = (真阳性率 + 真阴性率) / 2，(4) 加权准确率 = $\beta \cdot$ 真阳性率 + $(1 - \beta) \cdot$ 真阴性率，其中 $\beta =$ 为成功轨迹数与总轨迹数之比，以及 (5) 检测时间，即测试轨迹中满足 η_t 的最小索引，用于计算从轨迹开始到失败检测的平均时间。平衡准确率度量在类别不平衡的数据集（例如分布外场景中成功轨迹较少）中平等地表示各类别。加权准确率 $s = \mathbb{E}_{(A_t, O_t) \sim t=1, H', \dots, T} \mathbb{1}(D_M(A_t, O_t; \theta) > \text{实成功/失败分布的程度})$ 。由于执行真实机器人轨迹的人工时间成本较高，本文在机器人硬件任务中评估失败检测及基线方法时使用的轨迹数量（即 50 条）显著少于仿真任务（即 2000 条）。

与仿真任务（即 2000 条轨迹）相比，机器人硬件任务中评估失败检测及基线方法所使用的轨迹数量显著减少（即 50 条轨迹）。

六、结果

本文呈现实验发现，以回答以下研究问题：A. 在没有失败数据的情况下，失败检测的性能如何？B. 学习得到的分数与事后分数对失败检测的影响是什么？C. 失败检测是否与人类直觉一致？

A. 在没有故障数据的情况下，故障检测的性能如何？我们考虑的一个关键问题是，在不枚举所有可能故障场景（这在实践中不可行）的情况下，故障检测是否可行且性能良好。我们进行了大量仿真和机器人硬件任务的实验来回答这个问题。我们评估平衡准确率、加权准确率和检测时间，以判断故障能否被可靠且快速地识别。FAIL-Detect 实现了高准确率和快速检测。我们的两阶段框架在准确率指标和检测速度方面均表现出强劲性能。例如，FAIL-Detect 的评分候选中平均最佳平衡准确率在仿真中为 $\sim 78\%$ （图 4），在机器人硬件任务中为 $\sim 72\%$ （图 5）。这一性能表明，无故障数据的故障检测方法能够在多种场景下稳健地识别故障。值得注意的是，FAIL-Detect 在各种评分下保持了可行的检测时间




图 6：故障检测评分与 CP 区间叠加的定性结果。曲线按轨迹的真实成功/失败状态着色（失败=为红色，成功=为蓝色）。我们展示了 Square ID 上 150 条测试轨迹，涵盖事后基线（STAC、PCA-kmeans）和学习的 FAIL-Detect 方法（logpZO、NatPN、RND）。我们按照 [1] 对 STAC 使用恒定的 CP 阈值。注意，事后基线方法由于故障/成功分离度差，将大多数轨迹标记为成功。相比之下，学习的度量具有紧密的 CP 区间和更高的故障/成功分离度。

设计，平均最佳检测时间快于成功轨迹完成时间。

B. 学习评分与事后评分对故障检测的影响是什么？

学习评分优于事后评分。纵观仿真与机器人硬件任务中的性能表现，我们发现学习得到的标量分数在故障检测方面优于事后分数。在仿真中（图 4），logpZO 与 RND 是最佳两种方法，分别在 16 例中的 10 例和 5 例达到最优性能。STAC 在事后类别中于 16 例中的 3 例取得最高准确率，而 PCAkmeans 从未成为最佳。总体而言，学习型方法与事后方法之间存在较大的性能差距，尤其是在最佳总体准确率方面。我们确实注意到，事后方法在分布外场景中的表现优于分布内场景。我们推测，这可能是由于成功的分布内轨迹与失败的分布外轨迹之间存在更清晰的区分，例如，对于 SPARC 而言，若分布外轨迹表现出显著抖动。在检测时间方面，logpZO 最为高效，在 8 例中的 3 例达到最快时间，而 PCA-kmeans 仅在 1 例中做到。值得注意的是，STAC 的检测时间始终超出实用极限，超过了平均成功轨迹时间。对于机器人硬件实验（图 5），由于校准所用的轨迹数据量远低于仿真（见表 III），且行为与观测的多样性更广，logpZO 依然稳健地成为最佳方法，在 12 个场景中的 8 个达到最高的平衡准确率与加权准确率。PCA-kmeans 基线以 4/12 的最优排名位居第二。RND 表现欠佳，从未达到最优性能，但始终位列前三最佳方法之中。此外，包括 logpZO 与 RND 在内的大多数方法，其检测时间均保持在远低于平均成功轨迹时间的实用范围内。SPARC 平均最快，在 6 例中的 4 例达到最优性能，但其准确率较差。

总体而言，在所有实验中，我们发现 FAIL-Detect 框架内新颖的学习型 logpZO 分数在性能上最为稳定。事后方法往往

处于性能的极端（要么表现良好，要么表现不佳），具体取决于特定设置。

定性分数趋势。检测分数的可视化（图 6 和图 9）证实，与事后方法相比，学习型方法更具判别力，成功与失败轨迹之间的分数分离更佳。STAC 还受限于单一的时间不变校准阈值。在附录 D 中，我们给出了全面的消融研究，考察性能对 CP 显著性水平 α 的敏感性（图 10）。

计算优势。一些事后方法需要反复从随机策略中采样，以获得有效的失败分数。例如，STAC 每个时间步需要生成 256 个动作预测。虽然减少预测数量可以提高计算效率，但这会损害其统计可靠性。另一方面，与 STAC 相比，我们的学习分数提供了显著更快的推理速度。例如，在 A6000 GPU 上使用 50 次回滚进行测试，logpZO 分数计算每个时间步耗时 0.04s（**Square**）和 0.033s（**Transport**），而 STAC 在两个任务上都需要 1.45s，相当于慢了 36-44 倍。

C. 失败检测是否与人类直觉一致？

FAIL-Detect 的警报与环境中的可观察失败指示表现出强相关性（图 7）。当分数超过决策阈值时，这些时刻通常与任务物理状态的有意义变化相一致。在仿真环境中，检测分数以高精度捕捉不同的失败模式。例如，对于 **Square** 任务，分数的突然增加与夹爪失去对正方形的抓握的时刻相吻合。类似地，在 **Transport** 任务中，分数尖峰识别出锤子双臂间转移时滑落的瞬间。真实世界应用展示了同样令人信服的结果：系统有效检测到导致第二次毛巾折叠不完整的人为干扰（**FoldRedTowel** ID + **Disturb**）以及导致第一次毛巾折叠不当的分布外初始条件（**FoldRedTowel** OOD）。分数尖峰与物理事件之间的这种对应关系令人鼓舞，表明 FAIL-Detect 有能力捕捉




图 7: logpZO 的物理解释, 这是最成功且最稳健的学习评分方法。失败轨迹得分以红色表示, 成功轨迹得分以蓝色表示。每幅图展示了故障检测时间及对应的相机视角。(仿真) 在图 7a 中, 当方块从夹爪滑落时标记故障。在图 7b 中, 当双臂掉落锤子时检测到故障。(机器人上) 在图 7c 中, 当第二次折叠尝试失败时发出故障警报。在图 7d 中, 当左机械臂未能完成第一次折叠时检测到故障。

任务相关的细微差别。该框架成功地将复杂的环境变化转化为可量化的度量, 分数变化作为故障事件的合理指标。此外, 这种相关性为潜在的政策改进提供了有价值的诊断能力。我们的方法无需事先穷举潜在的故障模式 (这本身是一项极具挑战性的工作), 而是能够对观察到的故障进行有针对性的分析。通过检查故障检测周围时间窗口内的执行情况, 可以高效地识别故障类型以供后续分析。依赖于环境的阈值有助于提升性能

环境与行为的变化。然而, 更先进的技术, 例如在推理过程中自适应调整共形预测的显著性水平, 可能会有所帮助。此外, 我们的候选分数未考虑长时间序列数据。尽管共形预测区间有时序感知能力, 但若能让学习到的分数从历史时间序列数据中提炼时序模式, 则可能实现更准确的失败预测。最后, 通过考虑多模态传感信息 (如声音或触觉), 及时检测失败的能力有望进一步提升。

八、结论

本文提出了一种模块化的两阶段不确定性感知运行时失败检测方法, 用于操作任务中的生成式模仿学习。该方法结合了学习到的标量分数与时变共形预测, 能够在提供统计保证的同时, 准确且高效地识别失败。通过在多样化任务上的大量实验, 我们证明了新颖的对数概率零阶 (logpZO) 分数在所考虑的候选方案中始终取得最高性能。关键在于, 我们证明了在无法获取失败数据的情况下, 仍能有效检测未见过的失败, 而收集覆盖所有可能失败场景的数据往往十分困难。我们的结果凸显了该方法在提升真实世界应用中机器人系统安全性与可靠性方面的潜力。

致谢 本工作主要在日本丰田研究所 (Toyota Research Institute, TRI) 实习期间完成。我们感谢 Vitor Guizilini、Benjamin Burchfiel 和 David Snyder 提供的有益讨论与反馈。我们感谢 TRI 总部的机器人教师团队, 特别是 Derick Seale 和 Donovan Jackson, 在数据收集方面给予的支持。

七、局限性

借助失败检测 (FAIL-Detect), 本文展示了在无法获取失败数据的情况下进行失败检测这一方法的广阔前景。所提出的两阶段方法确实存在若干局限性, 这些局限性为未来工作提供了可能的方向。我们观察到, 学习到的分数有时会侧重于较简单的机器人状态信息 (例如, 夹爪闭合或张开), 而非更高维度的视觉特征。寻找能够最大限度利用视觉信息的分数架构, 有望提升失败检测的性能。同时, 我们承认存在假阳性 (False Positive) 现象, 尤其是在轨迹性能下降的分布外 (OOD) 场景中。我们提出的依赖场景的共形预测 (CP) 区间, 正是为了应对这些

参考文献

- [1] Christopher Agia, Rohan Sinha, Jingyun Yang, Ziang Cao, Rika Antonova, Marco Pavone, and Jeannette Bohg. Unpacking Failure Modes of Generative Policies: Runtime Monitoring of Consistency and Progress. In *Conference on Robot Learning (CoRL)*, 2024.
- [2] Sivakumar Balasubramanian, Alejandro Melendez-Calderon, Agnes Roby-Brami, and Etienne Burdet. On the Analysis of Movement Smoothness. *Journal of Neuroengineering and Rehabilitation*, 12:1–11, 2015.
- [3] Steven Basart, Mazeika Mantas, Mostajabi Mohammadreza, Steinhardt Jacob, and Song Dawn. Scaling

- Out-of-Distribution Detection for Real-world Settings. In *International Conference on Machine Learning (ICML)*, 2022.
- [4] Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, et al. π_0 : A Vision-Language-Action Flow Model for General Robot Control. *arXiv preprint arXiv:2410.24164*, 2024.
- [5] Lennart Bramlage, Michelle Karg, and Cristóbal Curio. Plausible Uncertainties for Human Pose Regression. In *International Conference on Computer Vision (ICCV)*, pages 15087–15096. IEEE, 2023.
- [6] Max Braun, Noémie Jaquier, Leonel Rozo, and Tamim Asfour. Riemannian Flow Matching Policy for Robot Motion Learning. *arXiv preprint arXiv:2403.10672*, 2024.
- [7] Fernando Castañeda, Haruki Nishimura, Rowan McAllister, Koushil Sreenath, and Adrien Gaidon. In-Distribution Barrier Functions: Self-Supervised Policy Filters that Avoid Out-of-Distribution States. In *Learning for Dynamics & Control Conference (L4DC)*, volume 211, pages 286–299. PMLR, 2023.
- [8] Bertrand Charpentier, Oliver Borchert, Daniel Zügner, Simon Geisler, and Stephan Günnemann. Natural Posterior Network: Deep Bayesian Predictive Uncertainty for Exponential Family Distributions. In *International Conference on Learning Representations (ICLR)*, 2022.
- [9] Kaiqi Chen, Eugene Lim, Kelvin Lin, Yiyang Chen, and Harold Soh. Don’t Start from Scratch: Behavioral Refinement via Interpolant-based Policy Diffusion. In *Robotics: Science and Systems (RSS)*, 2024.
- [10] Lili Chen, Shikhar Bahl, and Deepak Pathak. PlayFusion: Skill Acquisition via Diffusion from Language-Annotated Play. In *Conference on Robot Learning (CoRL)*, 2023.
- [11] Ricky TQ Chen, Yulia Rubanova, Jesse Bettencourt, and David K Duvenaud. Neural Ordinary Differential Equations. *Advances in Neural Information Processing Systems (NeurIPS)*, 31, 2018.
- [12] Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin Burchfiel, and Shuran Song. Diffusion Policy: Visuomotor Policy Learning via Action Diffusion. In *Robotics: Science and Systems (RSS)*, 2023.
- [13] Kamil Ciosek, Vincent Fortuin, Ryota Tomioka, Katja Hofmann, and Richard Turner. Conservative Uncertainty Estimation By Fitting Prior Networks. In *International Conference on Learning Representations (ICLR)*, 2020.
- [14] Jacopo Diquigiovanni, Matteo Fontana, Simone Vantini, et al. The Importance of Being a Band: Finite-Sample Exact Distribution-Free Prediction Sets for Functional Data. *Statistica Sinica*, 1:1–41, 2024.
- [15] Andrija Djuricic, Nebojsa Bozanic, Arjun Ashok, and Rosanne Liu. Extremely Simple Activation Shaping for Out-of-Distribution Detection. In *International Conference on Learning Representations (ICLR)*, 2023.
- [16] Xuefeng Du, Zhaoning Wang, Mu Cai, and Sharon Li. Towards Unknown-aware Learning with Virtual Outlier Synthesis. In *International Conference on Learning Representations (ICLR)*, 2022.
- [17] Matt Foutter, Rohan Sinha, Somrita Banerjee, and Marco Pavone. Self-Supervised Model Generalization using Out-of-Distribution Detection. In *First Workshop on Out-of-Distribution Generalization in Robotics at CoRL 2023*, 2023.
- [18] Cem Gokmen, Daniel Ho, and Mohi Khansari. Asking for Help: Failure Prediction in Behavioral Cloning Through Value Approximation. In *International Conference on Robotics and Automation (ICRA)*, pages 5821–5828. IEEE, 2023.
- [19] Martin Hägele, Klas Nilsson, J Norberto Pires, and Rainer Bischoff. Industrial Robotics. *Springer Handbook of Robotics*, pages 1385–1422, 2016.
- [20] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep Residual Learning for Image Recognition. In *Computer Society Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778. IEEE, 2016.
- [21] Nantian He, Shaohui Li, Zhi Li, Yu Liu, and You He. ReDiffuser: Reliable Decision-Making Using a Diffuser with Confidence Estimation. In *International Conference on Machine Learning (ICML)*, volume 235, pages 17921–17933. PMLR, 21–27 Jul 2024.
- [22] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising Diffusion Probabilistic Models. *Advances in Neural Information Processing Systems (NeurIPS)*, 33:6840–6851, 2020.
- [23] Xixi Hu, qiang liu, Xingchao Liu, and Bo Liu. AdaFlow: Imitation Learning with Variance-Adaptive Flow-Based Policies. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2024.
- [24] Arda Inceoglu, Eren Erdal Aksoy, and Sanem Sariel. Multimodal Detection and Classification of Robot Manipulation Failures. *Robotics and Automation Letters*, 2023.
- [25] Masha Itkina and Mykel Kochenderfer. Interpretable Self-aware Neural Networks for Robust Trajectory Prediction. In *Conference on Robot Learning (CoRL)*, pages 606–617. PMLR, 2023.
- [26] Michael Janner, Yilun Du, Joshua Tenenbaum, and Sergey Levine. Planning with Diffusion for Flexible Behavior Synthesis. In *International Conference on Machine Learning (ICML)*, pages 9902–9915. PMLR, 2022.
- [27] Ramneet Kaur, Kaustubh Sridhar, Sangdon Park, Yahan Yang, Susmit Jha, Anirban Roy, Oleg Sokolsky, and Insup Lee. CODiT: Conformal Out-of-Distribution Detection in Time-Series Data for Cyber-Physical Systems. In *Proceedings of the ACM/IEEE 14th International Conference on Cyber-Physical Systems (with CPS-IoT Week 2023)*, ICCPS ’23, page 120–131, New York, NY, USA, 2023. Association for Computing Machinery. ISBN 9798400700361. doi: 10.1145/3576841.3585931.

- [28] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan Foster, Grace Lam, Pannag Sanketi, Quan Vuong, Thomas Kollar, Benjamin Burchfiel, Russ Tedrake, Dorsa Sadigh, Sergey Levine, Percy Liang, and Chelsea Finn. OpenVLA: An Open-Source Vision-Language-Action Model. *arXiv preprint arXiv:2406.09246*, 2024.
- [29] Woo Kyung Kim, Minjong Yoo, and Honguk Woo. Robust Policy Learning via Offline Skill Diffusion. In *AAAI Conference on Artificial Intelligence (AAAI)*, volume 38, pages 13177–13184, 2024.
- [30] Diederik P. Kingma and Jimmy Ba. Adam: A Method for Stochastic Optimization. In Yoshua Bengio and Yann LeCun, editors, *International Conference on Learning Representations (ICLR)*, 2015.
- [31] Balaji Lakshminarayanan, Alexander Pritzel, and Charles Blundell. Simple and Scalable Predictive Uncertainty Estimation using Deep Ensembles. *Advances in Neural Information Processing Systems (NeurIPS)*, 30, 2017.
- [32] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matthew Le. Flow Matching for Generative Modeling. In *International Conference on Learning Representations (ICLR)*, 2023.
- [33] Huihan Liu, Shivin Dass, Roberto Martín-Martín, and Yuke Zhu. Model-based Runtime Monitoring with Interactive Imitation Learning. In *International Conference on Robotics and Automation (ICRA)*, pages 4154–4161. IEEE, 2024.
- [34] Huihan Liu, Yu Zhang, Vaarij Betala, Evan Zhang, James Liu, Crystal Ding, and Yuke Zhu. Multi-Task Interactive Robot Fleet Learning with Visual World Models. In *Conference on Robot Learning (CoRL)*, 2024.
- [35] Weitang Liu, Xiaoyun Wang, John Owens, and Yixuan Li. Energy-based Out-of-Distribution Detection. *Advances in Neural Information Processing Systems (NeurIPS)*, 33:21464–21475, 2020.
- [36] Ilya Loshchilov and Frank Hutter. SGDR: Stochastic Gradient Descent with Warm Restarts. In *International Conference on Learning Representations (ICLR)*, 2017.
- [37] Ilya Loshchilov and Frank Hutter. Decoupled Weight Decay Regularization. In *International Conference on Learning Representations (ICLR)*, 2019.
- [38] Ajay Mandlekar, Danfei Xu, Josiah Wong, Soroush Nasiriany, Chen Wang, Rohun Kulkarni, Li Fei-Fei, Silvio Savarese, Yuke Zhu, and Roberto Martín-Martín. What Matters in Learning from Offline Human Demonstrations for Robot Manipulation. In *Conference on Robot Learning (CoRL)*, 2021.
- [39] Rajesh Natarajan, Santosh Reddy P, Subash Chandra Bose, H.L. Gururaj, Francesco Flammini, and Shanmugapriya Velmurugan. Fault Detection and State Estimation in Robotic Automatic Control using Machine Learning. *Array*, 19:100298, 2023. ISSN 2590-0056. doi: <https://doi.org/10.1016/j.array.2023.100298>.
- [40] Octo Model Team, Dibya Ghosh, Homer Walke, Karl Pertsch, Kevin Black, Oier Mees, Sudeep Dasari, Joey Hejna, Charles Xu, Jianlan Luo, Tobias Kreiman, You Liang Tan, Pannag Sanketi, Quan Vuong, Ted Xiao, Dorsa Sadigh, Chelsea Finn, and Sergey Levine. Octo: An Open-Source Generalist Robot Policy. In *Robotics: Science and Systems (RSS)*, Delft, Netherlands, 2024.
- [41] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. Learning Transferable Visual Models from Natural Language Supervision. In *International Conference on Machine Learning (ICML)*, pages 8748–8763. PMLR, 2021.
- [42] Quazi Marufur Rahman, Peter Corke, and Feras Dayoub. Run-Time Monitoring of Machine Learning for Robotic Perception: A Survey of Emerging Trends. *IEEE Access*, 9:20067–20075, 2021.
- [43] Allen Z. Ren, Anushri Dixit, Alexandra Bodrova, Sumeet Singh, Stephen Tu, Noah Brown, Peng Xu, Leila Takayama, Fei Xia, Jake Varley, Zhenjia Xu, Dorsa Sadigh, Andy Zeng, and Anirudha Majumdar. Robots That Ask For Help: Uncertainty Alignment for Large Language Model Planners. In *Conference on Robot Learning (CoRL)*, 2023.
- [44] Moritz Reuss and Rudolf Lioutikov. Multimodal Diffusion Transformer for Learning from Play. In *2nd Workshop on Language and Robot Learning: Language as Grounding*, 2023.
- [45] Quentin Rouxel, Andrea Ferrari, Serena Ivaldi, and Jean-Baptiste Mouret. Flow matching Imitation Learning for Multi-Support Manipulation. In *International Conference on Humanoid Robots (Humanoids)*, pages 528–535. IEEE, 2024.
- [46] Murat Sensoy, Lance Kaplan, and Melih Kandemir. Evidential Deep Learning to Quantify Classification Uncertainty. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2018.
- [47] Glenn Shafer and Vladimir Vovk. A Tutorial on Conformal Prediction. *Journal of Machine Learning Research*, 9(3), 2008.
- [48] Rohan Sinha, Amine Elhafsi, Christopher Agia, Matt Foutter, Edward Schmerling, and Marco Pavone. Real-Time Anomaly Detection and Reactive Planning with Large Language Models. In *Robotics: Science and Systems (RSS)*, 2024.
- [49] Ajay Sridhar, Dhruv Shah, Catherine Glossop, and Sergey Levine. Nomad: Goal Masked Diffusion Policies for Navigation and Exploration. In *International Conference on Robotics and Automation (ICRA)*, pages 63–70. IEEE, 2024.
- [50] Jiankai Sun, Yiqi Jiang, Jianing Qiu, Parth Talpur Nobel, Mykel Kochenderfer, and Mac Schwager. Conformal Prediction for Uncertainty-Aware Planning with Diffusion Dynamics Model. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.
- [51] Leitian Tao, Xuefeng Du, Jerry Zhu, and Yixuan Li. Non-parametric Outlier Synthesis. In *International Confer-*

- ence on Learning Representations (ICLR), 2023.
- [52] Vladimir Vovk, Alexander Gammernan, and Glenn Shafer. *Algorithmic Learning in a Random World*, volume 29. Springer, 2005.
 - [53] Apoorv Vyas, Nataraj Jammalamadaka, Xia Zhu, Dipankar Das, Bharat Kaul, and Theodore L Willke. Out-of-Distribution Detection Using an Ensemble of Self Supervised Leave-out Classifiers. In *European Conference on Computer Vision (ECCV)*, pages 550–564, 2018.
 - [54] Dian Wang, Stephen Hart, David Surovik, Tarik Kestemur, Haojie Huang, Haibo Zhao, Mark Yeatman, Jiuguang Wang, Robin Walters, and Robert Platt. Equivariant Diffusion Policy. In *Conference on Robot Learning (CoRL)*, 2024.
 - [55] Yanwei Wang, Tsun-Hsuan Wang, Jiayuan Mao, Michael Hagenow, and Julie Shah. Grounding Language Plans in Demonstrations Through Counterfactual Perturbations. In *International Conference on Learning Representations (ICLR)*, 2024.
 - [56] Yixuan Wang, Guang Yin, Binghao Huang, Tarik Kestemur, Jiuguang Wang, and Yunzhu Li. GenDP: 3D Semantic Fields for Category-Level Generalizable Diffusion Policy. In *Conference on Robot Learning (CoRL)*, 2024.
 - [57] Josiah Wong, Albert Tung, Andrey Kurenkov, Ajay Mandlekar, Li Fei-Fei, Silvio Savarese, and Roberto Martín-Martín. Error-Aware Imitation Learning from Teleoperation Data for Mobile Manipulation. In *Conference on Robot Learning (CoRL)*, pages 1367–1378. PMLR, 2022.
 - [58] Chen Xu and Yao Xie. Conformal Prediction for Time Series. *Transactions on Pattern Analysis and Machine Intelligence*, 45(10):11575–11587, 2023.
 - [59] Chen Xu and Yao Xie. Sequential Predictive Conformal Inference for Time Series. In *International Conference on Machine Learning (ICML)*, pages 38707–38727. PMLR, 2023.
 - [60] Chen Xu, Xiuyuan Cheng, and Yao Xie. Normalizing Flow Neural Networks by JKO Scheme. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.
 - [61] Jingkan Yang, Kaiyang Zhou, Yixuan Li, and Ziwei Liu. Generalized Out-of-Distribution Detection: A Survey. *International Journal of Computer Vision*, pages 1–28, 2024.
 - [62] Ling Yang, Zixiang Zhang, Zhilong Zhang, Xingchao Liu, Minkai Xu, Wentao Zhang, Chenlin Meng, Stefano Ermon, and Bin Cui. Consistency Flow Matching: Defining Straight Flows with Velocity Consistency. *arXiv preprint arXiv:2407.02398*, 2024.
 - [63] Tianhe Yu, Ted Xiao, Jonathan Tompson, Austin Stone, Su Wang, Anthony Brohan, Jaspiar Singh, Clayton Tan, Dee M, Jodilyn Peralta, Karol Hausman, Brian Ichter, and Fei Xia. Scaling Robot Learning with Semantically Imagined Experience. In *Robotics: Science and Systems (RSS)*, 2023.
 - [64] Qinglun Zhang, Zhen Liu, Haoqiang Fan, Guanghui Liu, Bing Zeng, and Shuaicheng Liu. FlowPolicy: Enabling Fast and Robust 3D Flow-based Policy via Consistency Flow Matching for Robot Manipulation. *arXiv preprint arXiv:2412.04987*, 2024.
 - [65] Tony Z. Zhao, Jonathan Tompson, Danny Driess, Pete Florence, Seyed Kamyar Seyed Ghasemipour, Chelsea Finn, and Ayzaan Wahid. ALOHA Unleashed: A Simple Recipe for Robot Dexterity. In *Conference on Robot Learning (CoRL)*, 2024.

附录

A. 提出的对数零阶优化分数网络 本文逐步解释所提出的新颖对数零阶优化 (logpZO) 的工作原理:

• Step 1

在观测值 $\{O_t\}$ (即图像嵌入与本体感知) 与潜在噪声 $\{Z\} \sim \mathcal{N}(0, I)$ 之间拟合一个流匹配模型 f_θ , 使得对于 $s \in [0, 1]$:

$$f_\theta(O_t[s], s) \approx Z - O_t,$$

$$O_t[s] = O_t + s(Z - O_t).$$

• Step 2 给定时间步 t' 处的新观测值 $O_{t'}$, 执行一步预测以获得潜在噪声估计:

$$Z_{O_{t'}} = O_{t'} + f_\theta(O_{t'}, 0).$$

当 $O_{t'}$ 属于分布内时, 根据流匹配公式, $Z_{O_{t'}}$ 接近于从 $\mathcal{N}(0, I)$ 中抽取的样本。

• 步骤 3: 使用平方范数计算潜在噪声的密度 (相差一个常数):

$$\log p(Z_{O_{t'}}) \propto -\|Z_{O_{t'}}\|_2^2$$

$\|Z_{O_{t'}}\|_2^2$ 的高范数值表明似然较低, 这由异常观测值 $O_{t'}$ 引起。因此, 本文使用 $\|Z_{O_{t'}}\|_2^2$ 作为对数零阶优化分数。

B. 共形预测带构建 遵循 [14], 本文将校准分数集合 $\mathcal{D}_{cal}$ 划分为两个不相交的部分 $\mathcal{D}_{cal_A}$ 和 $\mathcal{D}_{cal_B}$, 其大小分别为 N_1 和 N_2 。首先在 $\mathcal{D}_{cal_A}$ 上为 $t = 1, \dots, T$ 计算平均成功轨迹 $\mu_t = N_1^{-1} \sum_{i=1}^{N_1} D_M(A_t^i, O_t^i; \theta)$ 。然后, 对于 $j = 1, \dots, N_2$, 计算 $D_j = \max(\{(\mu_t - D_M(A_t^j, O_t^j; \theta))/s_{cal_A}(t)\}_{t=1}^T)$, 即从平均预测到标量分数在展开长度上的最大偏差。函数 $s_{cal_A}(t)$ 被称为“调制”函数, 它依赖于数据集 $\mathcal{D}_{cal_A}$ 。在本文的实验中, 考虑以下两种情形之一

$$s_{cal_A}(t) = 1/T \tag{1}$$

$$s_{cal_A}(t) = \max_{k \in \mathcal{H}} |D_M(A_t^k, O_t^k, \theta) - \mu_t|, \tag{2}$$

其中 $\mathcal{H} = [N_1]$, 若 $(N_1 + 1)(1 - \alpha) > N_1$, 否则 $\mathcal{H} = \{k \in [N_1] : \max_{t \in [T]} |D_M(A_t^k, O_t^k, \theta) - \mu_t| \leq \gamma\}$ 对于 $\gamma = (1 - \alpha)$ 分位数 $\{\max_{t \in [T]} |D_M(A_t^m, O_t^m, \theta) - \mu_t|\}_{m=1}^{N_1}$ 。直观上, 式 (2) 根据函数数据的非极端行为自适应调整预测带的宽度。其做法是, 通过最小化最大绝对残差位于所有最大值上 α 分位数内的离群点的影响。此外, 注意取最大值是因为共形预测带旨在反映整条轨迹。本文定义 $S = \{D_j, j = 1, \dots, N_2\}$ 为这些最大偏差的集合。带宽 h 最终计算为 S 的 $(1 - \alpha)$ 分位数, 上界为上 $t = \mu_t + h s_{cal_A}(t)$ 。在所有实验中, 本文选取 $\alpha = 0.05$ (即 95% 置信区间) (超参数选择见表 III)。

C. 实验细节

1) 任务描述:

- (仿真) 来自 Robomimic 基准 [38] 的任务如下。Square 任务要求机器人拾取一个方形螺母并将其放置在杆上, 这需要精确性。Transport 任务要求两个机械臂转移一把锤子

表 II: 流策略在每个任务-环境组合的测试数据上的成功率。这些测试数据也用于测试故障检测方法。在硬件实验中, 当测试回放中的故障数量不超过 5 时, 本文用 * 标记某些单元格。在这种情况下, 本文打乱回放索引, 并将所有故障样本纳入测试集, 以使故障检测度量具有更高的统计显著性。在全部 50 次回放中, FM 策略在 FoldRedTowel ID 上的真实成功率为 0.96, DP 在 CleanUpSpill ID 上的真实成功率为 0.82。(a) 仿真任务

	Square ID	Square OOD	Transport ID	Transport OOD	Can ID	Can OOD	Toolhang ID	Toolhang OOD
FM Policy	0.90 (1000 rollouts)	0.63 (2000 rollouts)	0.85 (1000 rollouts)	0.63 (2000 rollouts)	0.98 (1000 rollouts)	0.84 (2000 rollouts)	0.77 (1000 rollouts)	0.53 (2000 rollouts)
DP	0.93 (125 rollouts)	0.63 (250 rollouts)	0.84 (125 rollouts)	0.76 (250 rollouts)	0.98 (125 rollouts)	0.95 (250 rollouts)	0.82 (125 rollouts)	0.54 (250 rollouts)

(b) Robot hardware tasks

	FoldRedTowel ID via FM policy	FoldRedTowel ID + Disturb via FM policy	FoldRedTowel OOD via FM policy	CleanUpSpill ID via DP	CleanUpSpill OOD via DP	CleanUpSpill ID via FM policy	CleanUpSpill OOD via FM policy
Setting-dependent band	0.9* (20 rollouts)	0.75* (20 rollouts)	0.60 (20 rollouts)	0.70 (20 rollouts)	0.45 (20 rollouts)	0.90* (20 rollouts)	0.90* (20 rollouts)
ID-only band	0.9* (20 rollouts)	0.90 (50 rollouts)	0.58 (50 rollouts)	0.70 (20 rollouts)	0.52 (50 rollouts)	0.90* (20 rollouts)	0.76 (50 rollouts)




图 8：真实机器人实验设置。（上排）FoldRedTowel：从一块平铺的毛巾开始，两个机械臂需要先沿短边折叠毛巾，然后右臂需要沿长边进行第二次折叠。最后，毛巾需要被推到右下角才算成功。（下排）CleanUpSpill：从平台上杯子倒下造成的溢出开始，右臂必须先将杯子扶正，而左臂必须拿起毛巾擦拭溢出物。要达到成功，溢出物必须被完全清理干净，并且毛巾必须放回原位。

从一个架子上的封闭容器到另一个架子上的目标箱，涉及机器人之间的协调。罐装任务要求机器人将可乐罐从一个箱放入一个较小的目标箱，这需要比方块任务更高的精确率。工具悬挂任务要求机器人组装一个包含多个组件的框架，这在四个任务中需要最高的灵巧性和精确率。

• **（机器人硬件）在折叠红毛巾任务中，两个机器人手臂必须将一条红毛巾折叠两次，并将其推到桌角。**

在清理溢出物任务中，一个机器人手臂必须扶起一个倒下并导致溢出的杯子，而另一个机器人手臂必须拿起一条白毛巾并擦拭平台上的溢出物。这两个任务都是长时程的，需要精确率和协调性来操作可变形物体。

2) 策略骨干与 CP 带的校准：表 II 展示了各任务的成功率。同时，关于 • 动作维度 A_t 和每个任务的观测 O_t 的超参数，请参见表 III。• 策略骨干的架构细节 g 以及图像编码器的选择。• 训练细节 g （即优化器、学习率和调度器以及训练轮数）。• 用于校准 CP 带的成功回滚次数和测试回滚次数。注意，在仿真任务上，我们回滚 DP 的次数较少，因为它生成动作所需的时间比 FM 策略长得多（去噪步骤更多）。我们进一步解释策略网络的设计和训练 g 。底层策略网络 g 使用流匹配 [32] 和/或扩散模型 [22] 进行训练。我们遵循 [12] 中的设置，并使用相同的超参数来训练策略。当使用流匹配 [32] 训练策略时，唯一的区别是，我们不再使用扩散损失进行优化，而是将目标改为 $A_t|O_t$ 和 Z （标准高斯分布）之间的流匹配损失。图像特征使用 ResNet 或 CLIP 骨干提取，并与 g 联合训练。这些图像特征与机器人状态拼接后构成观测 O_t 。3) 标量故障检测分数：在使用 ResNet 编码器学习策略网络 g 后，我们首先使用与策略网络相同的训练演示数据为每个任务获得 $\{(A_t, O_t)\}$ 。对于事后方法 SPARC，它利用从轨迹获得的傅里叶幅度谱的弧长。为了学习和测试标量分数，我们采用以下设置：1) CFM：我们使用一个比策略网络小 4 倍、架构相同的网络。它是无条件的，以观测 O_t 作为输入。我们训练 200 个轮次，批大小为 128，使用 Adam 优化器 [30]，学习率恒定为 $1e-4$ 。

2) logpO 和 logpZO：我们让流网络（以 O_t 作为输入）具有与策略网络相同的架构。在




图 9: 在真实 FoldRedTowel OOD 任务上, 检测分数与 CP 带叠加的定性结果。布局与图 6 相同。我们注意到, 与事后 PCA-kmeans 和 SPARC 相比, 学习到的 logpZO 和 RND 在失败轨迹上计算出的分数尖峰更为明显。




图 10: 仿真和硬件实验中 TPR 和 TNR 与 CP 显著性水平的关系。

在仿真中, 我们令流网络比策略网络小 4 倍, 且两者架构相同; 在真实数据上, 我们保持两个模型大小一致。在仿真 (对应真实数据) 中, 我们训练 500 (对应 2000) 个训练轮次, 批大小为 128 (对应 512), 使用 Adam 优化器, 学习率恒为 $1e-4$ 。对于新观测 $O_{t'}$, 其密度 $\log p(O_{t'})$ 通过瞬时变量替换公式 [11] 获得。3) DER: 用于参数化正态-逆威沙特参数的神经网络与策略网络架构相同, 但小 4 倍。它以 O_t 作为输入。我们训练 200 个训练轮次, 批大小为 128, 使用 Adam 优化器, 学习率恒为 $1e-4$ 。4) NatPN: 我们首先使用 K 均值聚类, 设置 64 个簇, 为观测 $X = O_t$ 获得类别标签 Y 。然后我们考虑 Y 服从类别分布, 且分布参数具有狄利克雷先验的情况。为学习参数, 我们遵循 [8], 使用具有 16 个流层的表格编码器。我们将学习率设为 $1e-3$, 最多训练 1000 个训练轮次。5) RND: 在仿真中, 我们使用比策略网络小 4 倍且架构相同的网络, 该网络以 A_t 和 O_t 作为输入 (O_t 作为条件变量)。我们训练 200 个训练轮次, 批大小为 128, 使用 Adam 优化器, 学习率恒为 $1e-4$ 。在真实数据上, 我们使用与策略网络大小相同的网络以提升性能。我们训练 2000 个训练轮次, 批大小为 512, 使用 Adam 优化器, 学习率恒为 $1e-4$ 。在推理过程中, 较高的 $D_M(A_t, O_t; \hat{\theta})$ 表示预测器与目标输出之间存在较大不匹配, 我们假设这是由于 (A_t, O_t) 并非来自成功轨迹所致。

D. 消融

我们在不同共形预测显著性水平 α 下, 对方法行为进行消融研究。在图 10 中, 我们展示了使用 logpZO 时, $\alpha \in [0.01, 0.1]$ 的 10 个等间距取值下的真阳性率和真阴性率。如预期, 较高的 α 会提高真阳性率并降低真阴性率, 因为更多回放被标记为失败。这一趋势在仿真中更为明显; 在硬件实验中, 由于回放次数有限, 且对于较小的 α 校准分位数保持不变, 该效应被削弱。总体而言, $\alpha = 0.05$ 提供了稳健的权衡, 这也是我们在所有实验中采用的设置。

表三：评估协议中的超参数。我们在表三 a 中给出了策略网络的详细信息，在表三 b 中给出了仿真中用于共形预测（CP）带校准的超参数，在表三 c 和表三 d 中给出了机器人硬件实验中的超参数。对于仿真任务，训练在一块具有 48GB 显存的 NVIDIA RTX A6000 图形处理器（GPU）上完成。对于硬件实验，训练在八块具有 80GB 显存的 NVIDIA A100-SXM4-80GB 图形处理器（GPU）上完成。（a）策略网络

	Dimension of (A_t, O_t)	Architecture of (policy g , visual encoder for O_t)	Policy training specification (optimizer, lr, lr scheduler, batch size, number of epochs)
(Simulation) Square	(160, 274)	(UNet [26], ResNet [20])	(AdamW [37], 1e-4, cosine [36], 64, 800)
(Simulation) Can	(160, 274)	(UNet [26], ResNet [20])	(AdamW [37], 1e-4, cosine [36], 64, 800)
(Simulation) Toolhang	(160, 274)	(UNet [26], ResNet [20])	(AdamW [37], 1e-4, cosine [36], 64, 300)
(Simulation) Transport	(320, 548)	(UNet [26], ResNet [20])	(AdamW [37], 1e-4, cosine [36], 64, 300)
(Real) FoldRedTowel	(320, 4176)	(UNet [26], ResNet [20])	(AdamW [37], 1e-4, cosine [36], 96, 1000)
(Real) CleanUpSpill	(320, 6732)	(UNet [26], CLIP [41])	(AdamW [37], 1e-4, cosine [36], 36, 500)

(b) (Simulation) CP band calibration and testing

	Square ID	Square OOD	Can ID	Can OOD	Toolhang ID	Toolhang OOD	Transport ID	Transport OOD
CP band modulation	Eq. (2)	Eq. (2)	Eq. (2)	Eq. (2)	Eq. (2)	Eq. (2)	Eq. (2)	Eq. (2)
CP significance level	0.05	0.05	0.05	0.05	0.05	0.05	0.05	0.05
(FM policy) Num successes for CP band mean	269	269	296	296	224	224	253	253
(FM policy) Num successes for CP band width	629	629	693	693	523	523	591	591
(FM policy) Num test rollouts for evaluation	1000	2000	1000	2000	1000	2000	1000	2000
(DP) Num successes for CP band mean	31	31	34	34	27	27	27	27
(DP) Num successes for CP band width	82	82	90	90	70	70	71	71
(DP) Num test rollouts for evaluation	125	250	125	250	125	250	125	250

(c) (Hardware: FoldRedTowel) CP band calibration and testing

	ID Disturb (Setting-dependent)	ID Disturb (ID-only)	OOD (Setting-dependent)	OOD (ID-only)
CP band modulation	Eq. (1)	Eq. (1)	Eq. (1)	Eq. (1)
CP significance level	0.05	0.05	0.05	0.05
Num successes for CP band mean	7	7	4	7
Num successes for CP band width	23	23	13	23
Num test rollouts for evaluation	20	50	20	50

(d) (Hardware: CleanUpSpill) CP band calibration and testing

	OOD (DP) (Setting-dependent)	OOD (DP) (ID-only)	OOD (FM policy) (Setting-dependent)	OOD (FM policy) (ID-only)
CP band modulation	Eq. (2)	Eq. (2)	Eq. (1)	Eq. (1)
CP significance level	0.05	0.05	0.05	0.05
Num successes for CP band mean	6	5	6	9
Num successes for CP band width	14	12	14	18
Num test rollouts for evaluation	20	50	20	50




图 11: 由流匹配 (FM) 策略在仿真任务中得到的定量结果 (最佳、次佳、第三佳), 该图通过纳入所有定量度量对图 4 进行了扩充。结论与之前相似, 其中对数概率零阶 (logpZO) 和随机网络蒸馏 (RND) 是整体表现最好的两种方法。







图 12: 由扩散策略 (DP) 在仿真任务中得到的定量结果 (最佳、次佳、第三佳)。布局与图 4 完全相同。我们同样观察到, 学习型方法似乎比事后方法具有更强的故障检测能力, 其中对数概率零阶 (logpZO) 和随机网络蒸馏 (RND) 是表现最好的方法。




(a) FM policy: (Setting-dependent band) ID + Disturb



(b) FM policy: (ID-only band) ID + Disturb




(c) FM policy: (Setting-dependent band) OOD initial condition




(d) FM policy: (ID-only band) OOD initial condition


图 13: 在叠红毛巾机器人硬件任务上使用两种计算共形预测 (CP) 带的方法得到的定量结果 (最佳、次佳、第三佳)。对数概率零阶 (logpZO) 仍然是整体最稳健的方法。




(a) DP: (Setting-dependent band) OOD initial condition



(b) DP: (ID-only band) OOD initial condition



(c) FM policy: (Setting-dependent band) OOD initial condition



(d) FM policy: (ID-only band) OOD initial condition

图 14：在清理溢出物机器人硬件任务上使用两种计算共形预测（CP）带的方法得到的定量结果（最佳、次佳、第三佳）。对数概率零阶（logpZO）仍然是整体最稳健的方法。