

组合你的策略！通过测试时分布级 组合改进基于扩散或流的机器人策略

Jiahang Cao^{1,2,3*} Yize Huang^{1,4*} Hanzhong Guo¹ Rui Zhang¹ Mu Nan¹
Weijian Mai¹ Jiaxu Wang⁵ Hao Cheng⁵ Jingkai Sun^{1,2} Gang Han²
Wen Zhao² Qiang Zhang² Yijie Guo² Qihao Zheng³ Chunfeng Song³
Xiao Li⁴ Ping Luo¹ Andrew F. Luo^{1†}

¹The University of Hong Kong ²Beijing Innovation Center of Humanoid Robotics

³Shanghai AI Lab ⁴Shanghai Jiaotong University

⁵The Hong Kong University of Science and Technology

摘要

用于机器人控制的基于扩散的模型，包括视觉-语言-动作（VLA）和视觉-动作（VA）策略，已展现出显著的能力。然而，其发展受到获取大规模交互数据集的高昂成本制约。本文引入一种无需额外模型训练即可提升策略性能的替代范式。或许令人惊讶的是，我们证明组合后的策略可以超越任一父策略的性能。本文的贡献有三方面。首先，我们建立了一个理论基础，表明来自多个扩散模型的分布分数的凸组合可以产生优于任何单个分数的一步函数目标。然后使用格朗沃尔型界证明，这种单步改进会传播到整个生成轨迹，从而带来系统性的性能提升。其次，受这些结果的启发，我们提出了通用策略组合（GPC），这是一种免训练的方法，通过凸组合和测试时搜索来结合多个预训练策略的分布分数，从而提升性能。GPC 具有通用性，允许即插即用组合异构策略，包括 VA 和 VLA 模型，以及基于扩散或流匹配的模型，无论其输入视觉模态如何。第三，我们提供了广泛的实证验证。在 Robomimic、PushT 和 RoboTwin 基准上的实验，以及真实世界机器人评估，证实 GPC 在各种任务中持续提升性能和适应性。对替代组合算子和加权策略的进一步分析为 GPC 成功背后的机制提供了洞见。这些结果确立了 GPC 作为一种简单而有效的方法，通过利用现有策略来提升控制性能。我们的项目页面在 <https://sagecao1125.github.io/GPC-Site/>。

1 引言

扩散策略（Diffusion Policies, DPs）（Chi et al., 2023; Ho et al., 2020; Song et al., 2020a）已成为机器人学习中策略参数化的强大方法，能够表示复杂的多模态动作分布——这对于以视觉和语言等高维输入为条件的策略而言，在从操作（Ze et al., 2024b; Zhu et al., 2024; Liu et al., 2024a）到导航（Sridhar et al., 2024; Zhang et al., 2024a）等领域中是一项关键优势。尽管取得了这些进展，基于扩散和流的策略发展仍从根本上受到模型容量和数据可用性两方面扩展挑战的制约。性能可能因给定模型固有的表示极限而趋于平稳，然而扩大模型架构也需要

* 同等贡献 jiahang@connect.hku.hk † 通讯作者
aluo@hku.hk




图 1：通用策略组合示意图。 (a) 来自预训练的最先进的基于扩散或流的策略分布可以在无需额外训练的情况下进行组合，以构建更强的策略，并通过测试时对组合权重的搜索来选择最佳的父策略混合；得分组合对应于概率密度函数（PDF）的乘积，将采样引导至共识区域。(b) 通用策略组合（GPC）可以在多种任务上带来一致的提升。(c) 我们发现组合两个模型时的最优权重可能因任务而异。

收集昂贵的交互数据集以充分捕捉潜在的性能收益（Black et al., 2024）。传统的后训练策略提供的解决方案有限；监督微调需要昂贵的数据收集（Ouyang et al., 2022），而强化学习则引入了奖励工程和大量在线交互的复杂性（Hu et al., 2025）。

为克服这些局限性，本文引入一种替代范式：通过组合现有预训练模型来创建更强的策略。尽管先前工作已探索静态模型组合（Du & Kaelbling, 2024; Wang et al., 2024c），我们发现最优权重并非普适，而是高度依赖于任务，即使对于一组固定的父策略也是如此。受组合式生成建模的启发，我们首先建立理论基础，证明分布分数的凸组合能够为策略改进提供一个可证明更优的目标。这一原理支撑了我们提出的通用策略组合方法（GPC，图 1）。GPC 是一个免训练框架，在推理时通过凸组合和测试时搜索来组合多个预训练策略的分布分数。该方法灵活地整合异构模型——涵盖基于扩散和流的架构、视觉动作（VA）与视觉语言动作（VLA）模态以及多样化的感官输入——以形成能力更强的策略，且无需修改基础模型。关键的是，我们证明所得组合策略的性能可以超越其任何单个父策略。

我们通过在仿真和真实环境中的大量实验验证了 GPC，证明其相对于单策略基线具有一致的性能优势。我们的分析扩展到替代组合算子（例如逻辑与/或）和各种权重配置，为组合为何有效以及何时有效提供了更广泛的洞见。我们的贡献总结如下：(i) 我们为机器人策略组合建立了理论基础，证明分布分数的凸组合能够产生改进的函数目标，并且这一优势会传播到系统层面。(ii) 我们提出了通用策略组合（GPC），这是一个灵活的免训练框架，将跨不同模态和架构的预训练策略组合成更具表达力的策略。(iii) 我们在仿真和真实世界中进行了广泛评估，证明了 GPC 的一致性能提升，同时分析了关键设计选择，以指导未来策略组合的研究。

2 相关工作

可组合生成模型。可组合性是指将多个组件或分布组合成统一表示，同时保留各个元素属性的能力。(一) 视觉生成：基于能量的模型（Energy-Based Models, EBM）（Hinton, 2002; Du & Mordatch, 2019; Grathwohl 等, 2020）通过能量求和支持组合性，允许因子级组合。Du 等（2020）统一了视觉生成中组合性的视角。Liu 等（2021）通过分解关系结构进一步改进了用于场景生成的 EBM。Skreta 等（2024）通过使用 $\hat{o}$ 估计引入了扩散模型的叠加。(二) 语言




图 2: 我们提出的通用策略组合概览。通过组合来自预训练的基于扩散或基于流的策略在不同条件（*e.g.*，视觉模态和网络骨干）下的分布得分，GPC 能够通过凸得分组合生成富有表现力和适应性的动作轨迹，无需额外训练。

生成：Du 等（2023b）利用多智能体辩论组合输出，以实现稳健的语言生成。Lifshitz 等（2025）提出了测试时多智能体验证以改进性能。

机器人学习中的扩散模型。由于其灵活性和表示能力，扩散模型（Ho 等，2020；Song 等，2020a；Nichol & Dhariwal，2021）提供了一种新颖的策略表示方式。扩散策略（Diffusion Policy）的概念（Chi 等，2023）首次提出使用扩散来建模动作空间，显著增强了表达能力。此后，出现了许多进展：多模态 DP 如 MDT（Reuss 等，2024），轨迹提取方法如 AWE（Shi 等，2023）。DP3（Ze 等，2024b）利用点云表示达到最先进的性能，以及 VLA 模型，*e.g.*，Octo（Team 等，2024）， π_0 （Black 等，2024）和 RDT（Liu 等，2024a）。在这项工作中，我们的 GPC 可以应用于各种通用的基于扩散的（*e.g.*，DP、DP3、MDT 和 RDT）或基于流的策略（*e.g.*，流策略和 π_0 ），展示了极大的灵活性（详见附录 G）。

机器人学中的组合扩散模型。近期研究探索了组合扩散模型在机器人领域的应用。Janner 等人（2022）将组合性应用于基于扩散的规划。Yang 等人（2023b）解决了机器人规划中的连续约束满足问题，Luo 等人（2024）通过学习势场改进了运动规划。此外，策略组合（PoCo）（Wang 等人，2024c）实现了基于约束、基于任务和基于输入模态的组合；然而，它并未探索策略之间的权重。而且，它尚未在广泛采用的仿真环境中得到验证，并且对底层组合机制的分析有限。相比之下，本文提出的 GPC 框架通过支持视觉动作（VA）和视觉语言动作（VLA）模型的组合，无论输入视觉模态如何，提供了更广泛的通用性，并且本文还深入揭示了策略组合中任务相关权重搜索的机制。

3 预备知识

扩散模型（Sohl-Dickstein 等人，2015）基于一个生成过程，该过程迭代地对随机噪声分布进行去噪以生成样本。以下方程描述了基于朗之万动力学（Song 等人，2020b）的扩散过程更新规则：

$$\tau_{t-1} = \alpha_t \tau_t + \beta_t s_\theta(\tau_t, t) + \gamma_t \eta, \quad \eta \sim \mathcal{N}(\mathbf{0}, \sigma_t^2 \mathbf{I}), \quad (1)$$

其中 $s_\theta(\tau_t, t)$ 表示学习到的得分函数， $\alpha_t, \beta_t, \gamma_t$ 是由噪声调度器和求解器选择确定的系数。通过相应地指定这些系数，可以恢复不同的采样方法，例如 DDPM（Ho 等人，2020）、DDIM（Song 等人，2020a）或基于 ODE/SDE 的求解器（Song 等人，2020b）。

与扩散模型密切相关的是基于能量的模型（Hinton，2002；Du & Mordatch，2019），它们通过可学习的能量函数定义概率分布。这种联系源于能量模型中能量函数的梯度所起的作用类似于扩散模型中的得分函数。组合能量模型（Du 等人，2020）进一步取得了进展，其中多个能量函数可以通过对其贡献求和来组合。

4 凸得分组合的理论分析

我们首先为凸分数组合能够提升策略性能提供数学论证。分析表明：（一）在函数层面，来自预训练策略分数的凸组合可以降低分数误差；（二）在系统层面，采样误差通过采样动力学的稳定性受分数误差约束。这些结果确立了凸分数组合作为策略改进的原则性基础，直接启发了我们在第 5 节提出的通用策略组合框架。

4.1 函数层面的改进

我们首先探讨组合分数估计器能否更好地逼近真实分数 s^* 。以下结果表明，存在两个估计器的凸组合，其误差不大于较优单个估计器的误差，并且除非它们的误差完全一致，否则严格更小。

命题 4.1（通过凸组合实现单步改进）。设两个分数估计器为 $\varepsilon_1 = s^* + b_1 + \eta_1$ 和 $\varepsilon_2 = s^* + b_2 + \eta_2$ ，具有确定性偏差 b_i 和随机零均值噪声 η_i ，后者在时间反转随机动力学（例如，逆向时间常微分方程）中扮演扩散分量的角色。对于任意凸权重 $w \in [0, 1]$ ，定义 $\varepsilon(w) = w\varepsilon_1 + (1-w)\varepsilon_2$ 。则均方误差 $Q(w) = \mathbb{E} \|\varepsilon(w) - s^*\|^2$ 是关于 w 的凸二次函数。其极小值点 w^* 满足 $Q(w^*) \leq \min\{Q(0), Q(1)\}$ 。

with strict inequality in most non-trivial cases.

证明见附录 B。直观上，每个估计器以不同方式偏离真实分数。凸组合可以抵消这些误差，从而获得更好的分数估计器。除非两个模型产生完全相同的误差，否则真实分数 s^* 更接近某个内部点，确保加权平均能够实现更小的误差。这确立了凸分数组合能够在每一步降低估计误差。

4.2 系统层面的稳定性

虽然命题 4.1 展示了函数层面的改进，但仍需理解分数误差如何传播到轨迹采样中。以下命题建立了稳定性保证：终端误差受累积分数误差控制。

命题 4.2（分数到采样的稳定性）。设 $x^*(t)$ 表示由真实分数 s^* 导出的理想轨迹， $x_{\hat{s}}(t)$ 表示由估计器 $\hat{s}$ 导出的近似轨迹，两者从相同的初始条件出发。它们满足

$$\dot{x}^*(t) = F(t, x^*(t), s^*(t, x^*(t))), \quad \dot{x}_{\hat{s}}(t) = F(t, x_{\hat{s}}(t), \hat{s}(t, x_{\hat{s}}(t))),$$

其中 F 表示将评分映射为状态更新的底层动态。假设 F 关于 (x, s) 是利普希茨连续的，常数为 $L_x(t), L_s(t)$ ，且 $\hat{s}$ 关于 x 是利普希茨连续的，常数为 $\hat{\Lambda}(t)$ 。假设评分误差具有一致上界 $\kappa(t)$ (i.e., $\|\hat{s} - s^*\| \leq \kappa(t)$)。定义 $\tilde{L}(t) = L_x(t) + L_s(t)\hat{\Lambda}(t)$ 。则对所有 $T > 0$ ，

$$\mathbb{E} \|x_{\hat{s}}(T) - x^*(T)\| \leq \left(\int_0^T e^{2\int_t^T \tilde{L}(\tau) d\tau} L_s(t)^2 dt \right)^{1/2} \left(\int_0^T \kappa(t)^2 dt \right)^{1/2}.$$

证明见附录 C。该结果表明采样动态是稳定的：终端误差至多随利普希茨常数呈指数增长，并直接受积分评分误差的约束。因此，减少每一步的评分误差即可降低整体轨迹误差。

4.3 对策略组合的启示

结合命题 4.1 与命题 4.2，可得到关于组合策略的直接启示。

推论 4.1（凸评分组合收敛采样误差界）。设

$\mathcal{B}(\hat{s})$ 表示命

题 4.2（具体为式 21）中推导出的期望采样误差上界。若凸组合

$$s_{\text{comp}} = ws_1 + (1-w)s_2 \text{ 满足}$$

$$\int_0^T \mathbb{E} \|s_{\text{comp}} - s^*\|^2 dt < \min_i \int_0^T \mathbb{E} \|s_i - s^*\|^2 dt, \text{ 则相应的理论误差界}$$

严格减小:

$$\mathcal{B}(s_{\text{comp}}) < \min_i \mathcal{B}(s_i).$$

See proof in App. D. Once functional-level improvement is established by obtaining an optimal w^* （命题 4.1），稳定性确保该优势沿轨迹传播（命题 4.2），使得凸评分组合在理论上优于依赖单一评分。

该理论分析为凸评分组合提供了明确的依据：它能在每个功能步骤提高准确率，并通过稳定的采样动态传播这一优势，从而带来系统级增益。这些结果直接推动了 GPC 方法，该方法利用凸评分组合从预训练组件构建更强的策略。虽然理论保证了最优权重的存在，但解析求解难以实现；因此，在实践中我们采用测试时搜索来识别有效的加权策略，如第 6 节所述。

5 我们的方法：通用策略组合

在第 4 节数学基础之上，本文提出通用策略组合方法，如图 2 所示。其核心思想是利用凸分数组合将多个预训练策略融合为更强、更具表达力的策略。首先，在第 5.1 节回顾组合扩散模型的数学表述，为基于不同因素条件的策略组合奠定基础。随后，在第 5.2 节介绍本文方法，其中通用策略组合（GPC）对跨模态、架构或视觉动作/视觉语言动作（VA/VLA）设置的扩散或基于流的策略分数进行凸组合。最后，在第 5.3 节扩展该框架，纳入替代组合算子，从而提供超越凸平均的更广泛策略组合视角。

5.1 组合扩散模型

组合扩散模型（CDM）的核心思想是建模轨迹 τ 在多个概念 c_i 条件下的分布，类似于组合能量模型。在独立性假设下，数学上可将轨迹 τ 基于概念集合 $\{c_1, \dots, c_n\}$ 的联合概率表示为式 2，并通过参数化进一步改写条件项

$$p(c_i|\tau) \propto \left(\frac{p(\tau|c_i)}{p(\tau)} \right)^\alpha, \text{ as follows:}$$

$$p(\tau|c_1, \dots, c_n) \propto p(\tau, c_1, \dots, c_n) = p(\tau) \prod_{i=1}^n p(c_i|\tau), \quad (2)$$

$$\propto p(\tau) \prod_{i=1}^n \left(\frac{p(\tau|c_i)}{p(\tau)} \right)^\alpha, \text{ 其中 } p(c_i|\tau) \propto \left(\frac{p(\tau|c_i)}{p(\tau)} \right)^\alpha, \quad (3)$$

其中 $p(c_i|\tau)$ 可解释为隐式分类器（Ho & Salimans, 2022）， α 作为权重因子调节每个概念对整体轨迹分布的影响。

然后，组合分布的分数函数可直接由式 3 推导得出：

$$\nabla_\tau \log p(\tau|c_1, \dots, c_n) = \nabla_\tau \log p(\tau) + \sum_{i=1}^n \alpha (\nabla_\tau \log p(\tau|c_i) - \nabla_\tau \log p(\tau)). \quad (4)$$

利用分布分数函数与噪声之间的关系（Bao et al., 2022），i.e., $\epsilon_\theta(\tau_t, t) = -\sigma_\tau \nabla_\tau \log p(\tau)$ ，可表达 CDM 在 ϵ 参数化下的更新规则：

$$\hat{\epsilon}(\tau_t, t, \mathbf{c}) = \epsilon_\theta(\tau_t, t) + \sum_{i=1}^n w_i (\epsilon_\theta(\tau_t, t, c_i) - \epsilon_\theta(\tau_t, t)), \quad (5)$$




图 3：不同扩散策略及 GPC 组合策略的可视化结果。本文提出的 GPC 在扩散策略某一部分失效时仍能成功，且当两部分均正常工作时表现出更优性能。

Alg. 1: General Policy Composition Sampling

Input: Pre-trained policies π_1, π_2 , weights w_1, w_2 (i.e., $1 - w_1$), policies' conditions c_1, c_2
 1: **for** $w_1 = 0.0, 0.1, \dots, 0.9, 1.0$: // test-time searching
 2: Initialize noise trajectory $\tau_N \sim \mathcal{N}(0, I)$ per action
 3: **for** $t = N, \dots, 1$: // denoising steps
 4: $s_1 \leftarrow \pi_1(\tau_t, t, c_1)$
 5: $s_2 \leftarrow \pi_2(\tau_t, t, c_2)$ # score estimation
 6: $\hat{s}_{\text{comp}} \leftarrow w_1 * s_1 + w_2 * s_2$ # score composition
 7: $\tau_{t-1} \leftarrow \alpha_t \tau_t + \beta_t \hat{s}_{\text{comp}} + \gamma_t$
 8: **Return:** Action trajectory τ_0
 9: Evaluate SR and store in reward pools $R(w_1)$
Return: Optimal weights $w_1^* \leftarrow \arg \max_{w_1} R(w_1)$

Algorithm 1: **GPC Sampling**. Policies are combined via test-time score composition into a stronger policy.

其中 $\epsilon_\theta(\tau_t, t, c_i) / \epsilon_\theta(\tau_t, t)$ 表示在时间步 t 、轨迹 τ_t 上，以单个概念 c_i 为条件或无条件下的噪声估计。权重 w_i 调节每个概念对整体噪声估计的影响。该公式代表了生成模型中常用的无分类器引导 (CFG) (Ho & Salimans, 2022) 技术的推广。

5.2 通用策略组合

基于前述基础，我们现在可以将组合扩散模型 (CDM) 应用于机器人任务的扩散策略。以不同模式 c_i (e.g. (例如不同视觉模式输入或不同模型架构) 为条件的轨迹联合概率分布可表示如下：

$$p(\tau|c_1, \dots, c_n) \propto p(\tau|c_1)p(\tau|c_2) \cdots p(\tau|c_n). \quad (6)$$

虽然原则上可以如公式 5 那样应用无分类器引导采样，但我们在第 4 节的理论分析表明，分数的凸组合能够提供更好的函数目标，并通过采样动力学传播稳定性。受此结果启发，我们通过凸组合直接组合多个条件扩散策略的分数函数来构建组合策略。该公式不仅继承了理论中建立的稳定性保证，还实现了多样化条件信息的灵活集成。

形式上，令 $\hat{s}_{\text{comp}}(\tau_t, t, c)$ 表示组合分数，通用策略组合 (GPC) 的更新规则定义为：

$$\hat{s}_{\text{comp}}(\tau_t, t, c) = \sum_{i=1}^n w_i s_\theta(\tau_t, t, c_i), \quad \text{含} \quad \sum_{i=1}^n w_i = 1, \quad (7)$$

其中 $s_\theta(\tau_t, t, c_i)$ 表示以概念 c_i (e.g. (例如视觉模式或策略架构) 为条件的分数估计， w_i 表示分配给每个概念的凸组合权重，确保最终轨迹估计中所有源分布的均衡贡献。

这种凸组合确保复合分数保持在各个策略的可行凸包内，防止发散到极端或不稳定行为。直观上，GPC 公式平衡了来自不同条件的信息，产生更稳定和连贯的生成轨迹 (e.g., 例如图 3)。GPC 采样过程如算法 1 所示。

5.3 具有叠加的 GPC

除了使用分数凸组合外，我们的引导策略组合框架 (GPC) 自然地与叠加原理 (Skreta et al., 2024) 相联系，该原理包括：(i) 逻辑或对应于从分布混合中采样，通过在每次采样时使用 Softmax 函数加权来实现： $w_i^{1-t} = \text{softmax}(T \log p_t(\tau|c_i) + \ell)$ ，其中 w_i^{1-t} 决定了每个策略分数在采样时间 t, T 中的相对贡献， ℓ 为常数；(ii) 逻辑与强制策略间达成一致，对应于它们分布的交集。这通过求解线性系统来计算权重，使得 $d \log p_t(\tau|c_i) = d \log p_t(\tau|c_j)$ ，在采样过程中确保不同策略间的一致性。在本文中，我们利用这些公式，以逻辑或和逻辑与算子实例化引导策略组合框架，作为第 6.5 节中的应用。

表 1: Robomimic 和 PushT 上的实验结果。表中展示了成功率 $\uparrow$ 。与基础策略相比，我们的引导策略组合框架带来了显著的平均提升。

Method	Generative Mode	Model Type	Robomimic			PushT	Average
			Can	Lift	Square	PushT	
Base Policies							
Diffusion Policy (DP)	Diffusion	VA	34.50	98.50	2.00	21.75	39.19
Mamba Policy (MP)	Diffusion	VA	5.00	98.50	3.00	12.06	29.64
Flow Policy (FP)	Flow Matching	VA	95.00	13.00	77.50	54.25	59.94
Florence Policy-D	Diffusion	VLA	61.50	97.00	46.50	40.00	61.25
Florence Policy-F	Flow Matching	VLA	89.00	98.50	88.50	39.38	78.84
π_0	Flow Matching	VLA	96.50	99.00	92.50	57.69	86.42
Composed Policies via Convex Score Combination							
DP+MP	Diffusion	VA & VA	34.50	99.50	8.00	23.63	41.41 +2.22%
Florence-Policy-D+DP	Diffusion	VLA & VA	62.50	100.00	61.50	43.06	66.76 +5.51%
Florence-Policy-D+MP	Diffusion	VLA & VA	63.00	100.00	54.50	40.88	64.60 +3.35%
Florence-Policy-F+FP	Flow Matching	VLA & VA	98.50	98.50	92.50	56.06	86.39 +7.55%
π_0 +FP	Flow Matching	VLA & VA	99.50	100.00	94.00	62.25	88.94 +2.52%

表 2: RoboTwin 上 6 个多样化双臂操作任务的实验结果。引导策略组合框架取得了明显提升，成功率最高提高了 7%。

Method	Model Type	RoboTwin 2.0						
		Hanging Mug	Open Laptop	Place Burger Fries	Put Object Cabinet	Stack Bowls Three	Turn Switch	Average
Base Policies								
DP _{img}	VA	0.10	0.74	0.49	0.56	0.52	0.38	0.46
DP _{pcd}	VA	0.21	0.93	0.72	0.71	0.64	0.71	0.65
RDT	VLA	0.13	0.69	0.46	0.32	0.47	0.30	0.40
Composed Policies via Convex Score Combination								
DP _{img} + DP _{pcd}	VA & VA	0.23	0.93	0.78	0.82	0.71	0.71	0.70 +5%
RDT + DP _{img}	VLA & VA	0.18	0.80	0.57	0.59	0.66	0.38	0.53 +7%
RDT + DP _{pcd}	VLA & VA	0.36	0.94	0.83	0.78	0.73	0.71	0.72 +7%

6 实验

我们进行实验以探究三个关键问题：（i）引导策略组合框架在仿真和真实世界实验中的表现如何？（ii）不同的权重配置如何影响引导策略组合框架在不同场景下的性能？（iii）如何解释组合扩散策略的优势？

6.1 实验设置

环境设置。我们在 Robomimic (Mandlekar et al., 2022) 上进行评估，该平台包含三个操作任务（Can、Lift、Square），以及 PushT (Florence et al., 2021) 和 RoboTwin (Mu et al., 2025)，后者是一套双臂协作任务，我们从 1.0 和 2.0 版本 (Chen et al., 2025) 中选取了代表性任务。此外，我们还进行了四个真实世界实验：放置瓶子、挂杯子、关桌子和打孔，设置如图 6 所示。更多细节见附录 I。

基线。对于 Robomimic 和 PushT，我们与三种视觉动作模型进行比较：扩散策略（DP）（Chi 等，2023）、曼巴策略（MP）（Cao 等，2025b）、流策略（FP，即扩散策略的流匹配版本），以及三种视觉语言动作模型：基于 Florence 的掩码扩散变换器（MDT）（Reuss 等，2024）、基于 Florence 的流式掩码扩散变换器，以及一个基于 Florence 视觉语言模型（Xiao 等，2024）构建的修订版 π_0 （Black 等，2024）。对于 RoboTwin，我们采用两种视觉动作模型：扩散策略、DP3（Ze 等，2024b），以及一种视觉语言动作模型 RDT（Liu 等，2024a）。

训练与测试细节。由于 GPC 无需训练，我们直接使用基于其原始设置训练的预训练策略（更多细节见附录 I）。每个设置评估 200 次 rollout（RoboTwin 为 100 次），并报告平均成功率（SR）。对于组合，我们采用 GCP 并以 0.1 为步长在 0.0 到 1.0 之间搜索权重系数。

优化权重搜索（可选）。尽管 GPC 原则上允许任意凸权重，但我们的框架自然表明，得分更高的策略应获得更大的权重。这一直觉在第 6.3 节的实证发现中得到验证。因此，在实际使用中，一旦已知基础策略的相对优势，可以直接偏向较强策略使其权重为 >0.5 ，而不是穷举搜索整个区间 $[0.1, 0.9]$ 。这种简单的启发式方法既尊重了底层的得分组合原理，又显著减少了搜索时间。

表 3: 不同组合配置下我们方法的实验结果。这些结果凸显了 GPC 的多功能性以及跨策略权重调整的重要性。


Scenario	Task	DP _{img}	DP _{pcd}	Weight Scheduling in GPC										Δ
				0.1*	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9		
<i>Both Policies Perform Well</i>	Empty Cup Place	0.42	0.62	0.70	0.86	0.84	0.86	0.84	0.84	0.76	0.68	0.61	+24%	
	Dual Bottles Pick (Hard)	0.49	0.64	0.69	0.63	0.71	0.66	0.64	0.65	0.63	0.56	0.58	+7%	
	Shoe Place	0.37	0.36	0.47	0.52	0.56	0.59	0.60	0.59	0.59	0.53	0.41	+23%	
<i>Both Policies Perform Bad</i>	Dual Shoes Place	0.08	0.23	0.19	0.17	0.19	0.20	0.20	0.17	0.16	0.14	0.09	+0%	
	Pick Apple Messy	0.05	0.26	0.25	0.17	0.21	0.15	0.13	0.08	0.08	0.06	0.08	+0%	
<i>Policy A > Policy B</i>	Dual Bottles Pick (Easy)	0.77	0.36	0.52	0.64	0.70	0.75	0.82	0.81	0.80	0.85	0.80	+8%	
<i>Policy A < Policy B</i>	Block Hammer Beat	0.00	0.76	0.61	0.3	0.18	0.15	0.12	0.07	0.00	0.00	0.00	+0%	

*: The number set {0.1, ..., 0.9} denotes the weight of DP_{img} (i.e., w_1), corresponding to the noise estimation of GPC as $\hat{\epsilon}_{\mathcal{M}} = w_1 * \epsilon_{\text{DP}_{\text{img}}} + w_2 * \epsilon_{\text{DP}_{\text{pcd}}}$. When w_1 equals to 0.0 and 1.0, GPC degenerates into DP_{pcd} and DP_{img}, respectively.

Density

0.80.60.40.20.0

: The number set $\{0.1, \dots, 0.9\}$ denotes the weight of DP_{img} (i.e., w_1), corresponding to the noise estimation of GPC as $\epsilon_{M} = w_1 * \epsilon_{DP_{img}} + w_2 * \epsilon_{DP_{pcd}}$. When w_1 equals to 0.0 and 1.0, GPC degenerates into DP_{pcd} and DP_{img}, respectively.

**图 4: 不同组合下 GPC 的可视化分析。GPC 在 (a) 模态和 (b) 架构上均具有泛化性，适当的权重分配能产生准确的分布，且成功率优于单个策略。****图 5: 执行时间内的样本分布。GPC 产生的分布比基线更连贯。**

6.2 主要结果: GPC 跨架构与模态的适用性

仿真结果。我们的结果表明，GPC 广泛适用于基于扩散和基于流的策略，并在多种通用设置下有效：(i) 相同输入模态，不同架构。GPC 成功组合了在相同模态上训练但网络架构不同的策略。例如，在表 1 中，组合两个 VA 策略 (DP+MP) 相比基础策略平均提升+2.22%，而组合 VA 与 VLA 模型 (Florence-D+DP) 则实现了更大的+5.51% 提升。(ii) 不同模态，相似架构。GPC 也支持异构模态的集成。在表 2 中，组合基于 RGB 和基于点云的 DP (DP_{img}+DP_{pcd}) 将平均成功率从 0.46/0.65 提升至 0.70 (+5%)，证实凸分数组合即使在相同感知域内也能利用互补信息。(iii) 不同模态，不同架构。GPC 实现了跨模态和架构的灵活集成。例如，将 VLA 模型与 VA 策略组合 (RDT+DP_{pcd}) 产生了一致的改进，平均成功率相比 DP_{pcd} 提升至+7%，且令人惊讶地相比 RDT 本身提升+32%。

真实世界结果。在真实世界评估中 (表 5)，GPC 表现出比单策略基线更稳定且更强的性能。例如，在清洁桌面任务中，它实现了 14/20 次成功，超过了基础策略。同样，在放置瓶子任务中也取得了提升 (13/20 对比 7/20 和 11/20)。

总体而言，针对问题一，在多样化任务和基准上，GPC 持续提升性能，在 Robomimic 和 PushT 上平均提升高达+7.55%，在 RoboTwin 上提升+7%，在真实世界任务中提升+10%。这些结果验证了凸分数组合为策略组合提供了一个稳健且通用的原则，无论模型类型或输入模态如何。

6.3 权重配置对 GPC 性能的影响

为分析第二个问题，我们在表 3 中评估了不同权重配置下 GPC 在多个任务上的性能。总结出以下几点发现：发现 1: 当两种策略均具有中等准确率 (e.g., > 30%) 时，在适当的权重配置下，GPC 通常能获得比基础策略更高的准确率。对于

表 4: 采用叠加的 GPC 结果, 突出强组合算子带来的性能提升。

Method	Robomimic			PushT	Average
	Can	Lift	Square	PushT	
Base Policies					
Diffusion Policy (DP)	34.50	98.50	2.00	21.75	39.19
Mamba Policy (MP)	5.00	98.50	3.00	12.06	29.64
Florence Policy-D	61.50	97.00	46.50	40.00	61.25
Composed Policies via Logical AND Composition					
DP+MP	84.00	99.50	48.00	28.18	64.92 +25.73%
Florence-Policy-D+DP	90.50	100.00	90.00	36.31	79.20 +17.95%
Florence-Policy-D+MP	83.00	100.00	90.00	37.38	77.60 +16.35%
Composed Policies via Logical OR Composition					
DP+MP	82.50	99.50	44.00	29.13	63.78 +24.59%
Florence-Policy-D+DP	83.50	100.00	89.00	37.87	77.59 +16.34%
Florence-Policy-D+MP	86.50	100.00	86.50	38.44	77.86 +16.61%

表 6: 训练/微调时间与 GPC 权重搜索的比较。
 $T_{\text{eval}} = N_{\text{rollout}} \times T$ 每次展开。对于 RoboMimic, $T_{\text{eval}}^{\text{RoboMimic}} \approx 200 * 5s = 0.27$ 小时。对于真实世界, $T_{\text{eval}}^{\text{Real}} \approx 20 * 30s = 0.17$ hr.

Method	Setting	Time cost
Training from scratch	1M+ demos, N GPUs	14d (OpenVLA 7B), 30d (RDT 1B)
Finetuning	100 demos, 1 GPU	>5h (DP 200M+), >8h (RDT 1B)
GPC (full search)	9 weights ($w = 0.1:0.9$)	$9 T_{\text{eval}} (\sim 2.5\text{hrs})$
GPC (optimized)	4 weights ($w_{\text{strong}} \in [0.6, 0.9]$)	$4 T_{\text{eval}} (\sim 1\text{hr})$

在空杯放置任务中, DPimg 和 DPpcd 的姿态准确率分别为 0.42 和 0.62, 而 GPC 达到峰值 0.86 (+24%), $w_1=0.4$, 超越了两种单模态 DP。这一提升反映了扩散分数的组合能够捕捉更泛化的分布, 从而减少对特定条件的依赖, 这与组合模型的理论优势相一致。

发现 2: 当一个策略的准确率显著较低时, GPC 难以超越

性能更优的基础策略的最高准确率。例如, 在杂乱拾取苹果任务中, DPpcd 达到 0.26, 而 DPimg 仅达到 0.05。GPC 峰值为 0.25, 低于 DPpcd。这表明来自较弱模态的低准确率分数会显著影响联合分布, 从而降低组合策略的整体性能。

发现 3: 当性能更优的基础模型被使用时, GPC 的改进总是达到最大

策略在通用策略组合 (GPC) 中占有更大权重。例如, 在双瓶拾取 (简单) 任务中, DPimg 达到 0.77, 而 GPC 通过 $w_1=0.8$ 达到 0.85, 有效利用了更强的 DP。这凸显了为表现更优的分布分配更高权重的必要性, 以最大化 GPC 的有效性, 引导组合策略走向共识。

这些发现凸显了 GPC 在利用不同条件优势方面的灵活性, 以及适当调整权重以适应各策略性能的重要性。

6.4 GPC 的时间与计算效率

GPC 相较于使用单一基础策略引入了两个主要的额外成本来源: (i) 额外的权重搜索评估 (Snell 等人, 2024 年), 以及 (ii) 每个动作块推理成本的增加。

权重搜索即重复评估。在权重搜索过程中, 我们固定一个候选权重配置, 运行 N_{rollout} 次并计算评估成本。如表 6 所示, 从 0.1 到 0.9 会导致 $N_{\text{search}}=9$ 和约 2.5 小时。通过我们优化的搜索方法, 我们

$$T_{\text{search}} = N_{\text{search}} * T_{\text{eval}}, \quad T_{\text{eval}} = N_{\text{rollout}} * T_{\text{chunk}} \quad \text{每次回滚} \cdot w_{\text{strong}} [0.6, 0.9] \text{ 总搜索成本减少到 } w$$

$N_{\text{cfg}} = 4 (\sim 1 \text{ 小时})$ 。与从头训练数天或微调数小时相比, 这使得 GPC 成为一种高效的替代方案。

推理时开销。在回滚过程中, GPC 因每个动作块查询多个基础策略而产生额外计算。表 7 报告了在 RoboMimic 中测得的推理延迟: GPC 组合将延迟从 0.09 s to 0.13 秒每块增加, 这在实践中是适度的。这种开销纯粹是计算性的, 可以通过更强的硬件、优化的推理运行时或未来的工程改进 (e.g., 例如模型压缩 (Høeg 等人, 2024) 或蒸馏 (Liu 等人, 2026)) 进一步降低。

表 5: 真实世界实验结果, 证明了 GPC 的有效性。

Method	Place Bottles	Hang Mug	Clean Table	Punch Holes
DPimg	7/20	5/20	12/20	7/20
DPpcd	11/20	6/20	7/20	6/20
GPC (ours)	13/20	7/20	14/20	9/20



图 6: 真实世界设置与结果。

表 7: RoboMimic 中每个动作块的推理延迟。GPC 的开销适中且纯粹是计算性的。

Method	Time per chunk (s)
DP	0.09
Florence-Policy-D	0.06
GPC (DP + FP-D)	0.13

表 8: GPC 可应用于不同的动作块长度和推理时间步。结果在 Robomimic 中。

Method	Setting	Success Rate
DP	DDPM, chunk 8, 5 steps	0.50
Florence-Policy-D	DDIM, chunk 16, 10 steps	0.53
GPC (DP+FP-D)	DDIM, chunk 16, 10 steps	0.66

表 9: 在 RoboMimic 上使用三个基础策略的 GPC。

Method	Can	Lift	Square
Flow Policy	0.95	0.13	0.77
Florence-Policy-F	0.89	0.98	0.88
π_0	0.61	0.96	0.92
GPC (best 2-policy)	0.99	1.00	0.94
GPC (FP+FP-F+π_0)	1.00	1.00	0.94

6.5 通用策略组合有效性的综合分析

通过可视化分析通用策略组合 (GPC) 的优越性。针对第三个问题, 图 4 展示了 GPC 在不同设置下如何改善样本分布: (i) 不同模态下的 GPC。在图 4(a) 中, **DPimg** 和 **DPpcd** 学习到不同的分布。通过调整凸权重, GPC 在两者之间平滑适应。这表明 GPC 如何利用来自不同模态的知识形成更完整的分布。(ii) 不同架构下的 GPC。在图 4(b) 中, Florence 和 FlowP 学习到大致相似的分布, 但各自表现出局部偏差。通过凸组合, GPC 扩大了覆盖范围并提高了精确率。这表明即使基础模型学习到相似的表示, GPC 也能细化它们的对齐并取得更强的结果。总体而言, 这些可视化结果证实了 GPC 在不同模态和架构间具有泛化能力, 适当的权重能产生比单个策略更广泛、更准确的分布。

执行时间样本分布分析。图 5 展示了执行时间样本分布的演变。基线 **DPimg** 和 **DPpcd** 产生分散或嘈杂的模式, 尤其是在后期阶段, 表明不稳定性和较高的方差。相比之下, GPC 产生连贯且集中的分布, 确保更高的稳定性并减轻执行过程中的误差累积。

通用策略组合 (GPC) 与叠加的实验结果。我们进一步评估了叠加设置下的 GPC。如表 4 所示, 将 DP 和 MP 进行逻辑与组合将成功率提升至 64.92 (+25.73%), 而 Florence-D 与 DP 在逻辑或下达到 77.59 (+16.34%)。这些结果凸显了叠加通过更强的组合算子放大策略性能的潜力。然而, 叠加也有明显的局限性。它不能直接应用于基于流的模型, 并且每一步重新计算权重的需求增加了推理成本。

具有异构推理步长和块大小的 GPC。GPC 对不同推理步数和块大小也具有灵活性。对于扩散步数, 我们在测试时简单地选择一个统一的采样器和推理步数, 并在这一共同配置下运行所有策略, *e.g.*, 即 RoboTwin 中 DP+RDT 的结果。对于动作块不匹配 (假设 $H_A \geq H_B$), 我们采样一条长度为 H_A 的共享噪声轨迹, 仅在前 H_B 步应用策略 B, 并在重叠部分取分数的凸组合, 同时保留策略 A 的尾部。表 8 中的结果证实, 这种异构块组合也能带来明显的增益。

具有多个基础策略的通用策略组合 (GPC)。GPC 的分数组合规则通过分数的凸组合直接扩展到三个或更多基础策略。表 9 报告了在 RoboMimic 上使用三个策略的结果。三策略 GPC 要么匹配要么优于最佳的双策略配置, 并且始终优于单个基础策略。这表明 GPC 超越了成对组合, 能够有效利用多个预训练策略之间的多样性。

7 讨论

局限性。我们的 GPC 在广泛的实验中展示了明显的有效性。尽管有这一优势, 仍存在一些局限性。首先, 测试时权重搜索受限于固定的离散化, 可能错过最优值; 未来工作可以探索自适应或自动搜索策略。其次, 我们主要研究双/三策略组合, 而扩展到更多策略会增加计算量。解决这一问题可能需要特征共享或紧凑表示, 以实现高效的多策略集成。

结论。我们提出了通用策略组合 (GPC), 这是一种免训练的框架, 通过组合预训练策略的分布分数来改进机器人控制。我们的理论分析表明, 凸分数组合能带来逐步和轨迹级别的改进, 而在多样化基准和真实世界设置上的实验证实了一致的性能增益。GPC 简单、通用且广泛适用, 为未来将策略组合作为无需额外训练资源即可提升性能的手段的研究奠定了基础。

参考文献

- Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altenschmidt, Sam Altman, Shyamal Anadkat, et al. Gpt-4 technical report. *arXiv preprint arXiv:2303.08774*, 2023.
- Adilzhan Adilkhanov, Amir Yelenov, Assylkhan Seitzhanov, Ayan Mazhitov, Azamat Abdikarimov, Danissa Sandykbayeva, Daryn Kenzhebek, Dinmukhammed Mukashev, Ilyas Umurbekov, Jabrail Chumakov, et al. Survey on vision-language-action models. *arXiv preprint arXiv:2502.06851*, 2025.
- Anurag Ajay, Yilun Du, Abhi Gupta, Joshua Tenenbaum, Tommi Jaakkola, and Pulkit Agrawal. Is conditional generative modeling all you need for decision-making? *arXiv preprint arXiv:2211.15657*, 2022.
- Anurag Ajay, Seungwook Han, Yilun Du, Shuang Li, Abhi Gupta, Tommi Jaakkola, Josh Tenenbaum, Leslie Kaelbling, Akash Srivastava, and Pulkit Agrawal. Compositional foundation models for hierarchical planning. *Advances in Neural Information Processing Systems (NeurIPS)*, 36: 22304–22325, 2023.
- Shan An, Ziyu Meng, Chao Tang, Yuning Zhou, Tengyu Liu, Fangqiang Ding, Shufang Zhang, Yao Mu, Ran Song, Wei Zhang, et al. Dexterous manipulation through imitation learning: A survey. *arXiv preprint arXiv:2504.03515*, 2025.
- Fan Bao, Chongxuan Li, Jun Zhu, and Bo Zhang. Analytic-dpm: an analytic estimate of the optimal reverse variance in diffusion probabilistic models. In *International Conference on Learning Representations (ICLR)*, 2022.
- Jose Barreiros, Andrew Beaulieu, Aditya Bhat, Rick Cory, Eric Cousineau, Hongkai Dai, Ching-Hsin Fang, Kunimatsu Hashimoto, Muhammad Zubair Irshad, Masha Itkina, et al. A careful examination of large behavior models for multitask dexterous manipulation. *arXiv preprint arXiv:2507.05331*, 2025.
- Suneel Belkhale, Tianli Ding, Ted Xiao, Pierre Sermanet, Quon Vuong, Jonathan Tompson, Yevgen Chebotar, Debidatta Dwibedi, and Dorsa Sadigh. Rt-h: Action hierarchies using language. *arXiv preprint arXiv:2403.01823*, 2024.
- Richard Bellman. The stability of solutions of linear differential equations. *Duke Mathematical Journal*, 1943.
- Homanga Bharadhwaj, Jay Vakil, Mohit Sharma, Abhinav Gupta, Shubham Tulsiani, and Vikash Kumar. Roboagent: Generalization and efficiency in robot manipulation via semantic augmentations and action chunking. In *International Conference on Robotics and Automation (ICRA)*, pp. 4788–4795. IEEE, 2024.
- Johan Bjorck, Fernando Castañeda, Nikita Cherniadev, Xingye Da, Runyu Ding, Linxi Fan, Yu Fang, Dieter Fox, Fengyuan Hu, Spencer Huang, et al. Gr00t n1: An open foundation model for generalist humanoid robots. *arXiv preprint arXiv:2503.14734*, 2025.
- Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, et al. π_0 : A vision-language-action flow model for general robot control. *arXiv preprint arXiv:2410.24164*, 2024.
- Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Joseph Dabis, Chelsea Finn, Keerthana Gopalakrishnan, Karol Hausman, Alexander Herzog, Jasmine Hsu, et al. Rt-1: Robotics transformer for real-world control at scale. *Robotics: Science and Systems (RSS)*, 2023.
- Qingwen Bu, Hongyang Li, Li Chen, Jisong Cai, Jia Zeng, Heming Cui, Maoqing Yao, and Yu Qiao. Towards synergistic, generalized, and efficient dual-system for robotic manipulation. *arXiv preprint arXiv:2410.08001*, 2024.
- Qingwen Bu, Jisong Cai, Li Chen, Xiuqi Cui, Yan Ding, Siyuan Feng, Shenyuan Gao, Xindong He, Xuan Hu, Xu Huang, et al. Agibot world colosseum: A large-scale manipulation platform for scalable and intelligent embodied systems. *arXiv preprint arXiv:2503.06669*, 2025.

- Remi Cadene, Simon Alibert, Alexander Soare, Quentin Gallouedec, Adil Zouitine, Steven Palma, Pepijn Kooijmans, Michel Aractingi, Mustafa Shukor, Dana Aubakirova, Martino Russi, Francesco Capuano, Caroline Pascal, Jade Choghari, Jess Moss, and Thomas Wolf. Lerobot: State-of-the-art machine learning for real-world robotics in pytorch. <https://github.com/huggingface/lerobot>, 2024.
- Wenxiao Cai, Iaroslav Ponomarenko, Jianhao Yuan, Xiaoqi Li, Wankou Yang, Hao Dong, and Bo Zhao. Spatialbot: Precise spatial understanding with vision language models. In *International Conference on Robotics and Automation (ICRA)*, pp. 9490–9498. IEEE, 2025.
- Jiahang Cao, Qiang Zhang, Hanzhong Guo, Jiaxu Wang, Hao Cheng, and Renjing Xu. Modality-composable diffusion policy via inference-time distribution-level composition. *arXiv preprint arXiv:2503.12466*, 2025a.
- Jiahang Cao, Qiang Zhang, Jingkai Sun, Jiaxu Wang, Hao Cheng, Yulin Li, Jun Ma, Yecheng Shao, Wen Zhao, Gang Han, et al. Mamba policy: Towards efficient 3d diffusion policy with hybrid selective state models. *International Conference on Intelligent Robots and Systems (IROS)*, 2025b.
- Joao Carvalho, An T Le, Mark Baierl, Dorothea Koert, and Jan Peters. Motion planning diffusion: Learning and planning of robot motions with diffusion models. In *International Conference on Intelligent Robots and Systems (IROS)*, pp. 1916–1923. IEEE, 2023.
- Augustin-Louis Cauchy. Sur les formules qui résultent de l’emploi du signe et sur $\int$ ou $\int$, et sur les moyennes entre plusieurs quantités. *Cours d’Analyse, 1er Partie, Analyse Algebrique*, pp. 373–377, 1821.
- Chilam Cheang, Sijin Chen, Zhongren Cui, Yingdong Hu, Liqun Huang, Tao Kong, Hang Li, Yifeng Li, Yuxiao Liu, Xiao Ma, et al. Gr-3 technical report. *arXiv preprint arXiv:2507.15493*, 2025.
- Lili Chen, Shikhar Bahl, and Deepak Pathak. Playfusion: Skill acquisition via diffusion from language-annotated play. In *Conference on Robot Learning (CoRL)*, pp. 2012–2029. PMLR, 2023.
- Shang-Fu Chen, Hsiang-Chun Wang, Ming-Hao Hsu, Chun-Mao Lai, and Shao-Hua Sun. Diffusion model-augmented behavioral cloning. In *International Conference on Machine Learning (ICML)*, pp. 7486–7510. PMLR, 2024.
- Tianxing Chen, Zhanxin Chen, Baijun Chen, Zijian Cai, Yibin Liu, Qiwei Liang, Zixuan Li, Xi-anliang Lin, Yiheng Ge, Zhenyu Gu, et al. Robotwin 2.0: A scalable data generator and benchmark with strong domain randomization for robust bimanual robotic manipulation. *arXiv preprint arXiv:2506.18088*, 2025.
- An-Chieh Cheng, Yandong Ji, Zhaojing Yang, Zaitian Gongye, Xueyan Zou, Jan Kautz, Erdem Biyik, Hongxu Yin, Sifei Liu, and Xiaolong Wang. Navila: Legged robot vision-language-action model for navigation. *arXiv preprint arXiv:2412.04453*, 2024a.
- Xuxin Cheng, Kexin Shi, Ananye Agarwal, and Deepak Pathak. Extreme parkour with legged robots. In *International Conference on Robotics and Automation (ICRA)*, pp. 11443–11450. IEEE, 2024b.
- Cheng Chi, Zhenjia Xu, Siyuan Feng, Eric Cousineau, Yilun Du, Benjamin Burchfiel, Russ Tedrake, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. *The International Journal of Robotics Research (IJRR)*, pp. 02783649241273668, 2023.
- Hao-Tien Lewis Chiang, Zhuo Xu, Zipeng Fu, Mithun George Jacob, Tingnan Zhang, Tsang-Wei Edward Lee, Wenhao Yu, Connor Schenck, David Rendleman, Dhruv Shah, et al. Mobility vla: Multimodal instruction navigation with long-context vlms and topological graphs. *arXiv preprint arXiv:2407.07775*, 2024.
- Armand Comas, Yilun Du, Christian Fernandez Lopez, Sandesh Ghimire, Mario Sznaier, Joshua B Tenenbaum, and Octavia Camps. Inferring relational potentials in interacting systems. In *International Conference on Machine Learning (ICML)*, pp. 6364–6383. PMLR, 2023.

- Can Cui, Pengxiang Ding, Wenxuan Song, Shuanghao Bai, Xinyang Tong, Zirui Ge, Runze Suo, Wanqi Zhou, Yang Liu, Bofang Jia, et al. Openhelix: A short survey, empirical analysis, and open-source dual-system vla model for robotic manipulation. *arXiv preprint arXiv:2505.03912*, 2025.
- Tri Dao and Albert Gu. Transformers are ssms: Generalized models and efficient algorithms through structured state space duality. In *International Conference on Machine Learning (ICML)*, pp. 10041–10071. PMLR, 2024.
- Sudeep Dasari, Oier Mees, Sebastian Zhao, Mohan Kumar Srirama, and Sergey Levine. The ingredients for robotic diffusion transformers. In *International Conference on Robotics and Automation (ICRA)*, pp. 15617–15625. IEEE, 2025.
- Danny Driess, Jost Tobias Springenberg, Brian Ichter, Lili Yu, Adrian Li-Bell, Karl Pertsch, Allen Z Ren, Homer Walke, Quan Vuong, Lucy Xiaoyang Shi, et al. Knowledge insulating vision-language-action models: Train fast, run fast, generalize better. *arXiv preprint arXiv:2505.23705*, 2025.
- Maximilian Du and Shuran Song. Dynaguide: Steering diffusion polices with active dynamic guidance. *arXiv preprint arXiv:2506.13922*, 2025.
- Yilun Du and Leslie Kaelbling. Compositional generative modeling: A single model is not all you need. *arXiv preprint arXiv:2402.01103*, 2024.
- Yilun Du and Igor Mordatch. Implicit generation and modeling with energy based models. *Advances in Neural Information Processing Systems (NeurIPS)*, 32, 2019.
- Yilun Du, Shuang Li, and Igor Mordatch. Compositional visual generation with energy based models. *Advances in Neural Information Processing Systems (NeurIPS)*, 33:6637–6647, 2020.
- Yilun Du, Shuang Li, Yash Sharma, Josh Tenenbaum, and Igor Mordatch. Unsupervised learning of compositional energy concepts. *Advances in Neural Information Processing Systems (NeurIPS)*, 34:15608–15620, 2021.
- Yilun Du, Conor Durkan, Robin Strudel, Joshua B Tenenbaum, Sander Dieleman, Rob Fergus, Jascha Sohl-Dickstein, Arnaud Doucet, and Will Sussman Grathwohl. Reduce, reuse, recycle: Compositional generation with energy-based diffusion models and mcmc. In *International conference on Machine Learning (ICML)*, pp. 8489–8510. PMLR, 2023a.
- Yilun Du, Shuang Li, Antonio Torralba, Joshua B Tenenbaum, and Igor Mordatch. Improving factuality and reasoning in language models through multiagent debate. In *International Conference on Machine Learning (ICML)*, 2023b.
- Shichao Fan, Quantao Yang, Yajie Liu, Kun Wu, Zhengping Che, Qingjie Liu, and Min Wan. Diffusion trajectory-guided policy for long-horizon robot manipulation. *arXiv preprint arXiv:2502.10040*, 2025.
- AI Figure. Helix: A vision-language-action model for generalist humanoid control. *Figure AI News*, 2024.
- Roya Firoozi, Johnathan Tucker, Stephen Tian, Anirudha Majumdar, Jiankai Sun, Weiyu Liu, Yuke Zhu, Shuran Song, Ashish Kapoor, Karol Hausman, et al. Foundation models in robotics: Applications, challenges, and the future. *The International Journal of Robotics Research (IJRR)*, 44 (5):701–739, 2025.
- Pete Florence, Corey Lynch, Andy Zeng, Oscar Ramirez, Ayzaan Wahid, Laura Downs, Adrian Wong, Johnny Lee, Igor Mordatch, and Jonathan Tompson. Implicit behavioral cloning. *Conference on Robot Learning (CoRL)*, November 2021.
- Letian Fu, Huang Huang, Gaurav Datta, Lawrence Yunliang Chen, William Chung-Ho Panitch, Fangchen Liu, Hui Li, and Ken Goldberg. In-context imitation learning via next-token prediction. *arXiv preprint arXiv:2408.15980*, 2024.
- Guido Fubini. Sugli integrali multipli. *Rend. Acc. Naz. Lincei*, 16:608–614, 1907.

- Timur Garipov, Sebastiaan De Peuter, Ge Yang, Vikas Garg, Samuel Kaski, and Tommi Jaakkola. Compositional sculpting of iterative generative processes. *Advances in Neural Information Processing Systems (NeurIPS)*, 36:12665–12702, 2023.
- Koffivi Fidèle Gbagbe, Miguel Altamirano Cabrera, Ali Alabbas, Oussama Alyunes, Artem Lykov, and Dzmitry Tsetserukou. Bi-vla: Vision-language-action model-based system for bimanual robotic dexterous manipulations. In *International Conference on Systems, Man, and Cybernetics (SMC)*, pp. 2864–2869. IEEE, 2024.
- Theophile Gervet and Zhou Xiao. Act3d: 3d feature field transformers for multi-task robotic manipulation. In *Conference on Robot Learning (CoRL)*. Proceedings of Machine Learning Research, 2023.
- Will Grathwohl, Kuan-Chieh Wang, Jörn-Henrik Jacobsen, David Duvenaud, and Richard Zemel. Learning the stein discrepancy for training and evaluating energy-based models without sampling. In *International Conference on Machine Learning (ICML)*, pp. 3732–3747. PMLR, 2020.
- Will Grathwohl, Kevin Swersky, Milad Hashemi, David Duvenaud, and Chris Maddison. Oops i took a gradient: Scalable sampling for discrete distributions. In *International Conference on Machine Learning (ICML)*, pp. 3831–3841. PMLR, 2021.
- Thomas Hakon Gronwall. Note on the derivatives with respect to a parameter of the solutions of a system of differential equations. *Annals of Mathematics*, 20(4):292–296, 1919.
- Albert Gu and Tri Dao. Mamba: Linear-time sequence modeling with selective state spaces. In *Conference on Language Modeling (CoLM)*, 2024.
- Huy Ha, Pete Florence, and Shuran Song. Scaling up and distilling down: Language-guided robot skill acquisition. In *Conference on Robot Learning (CoRL)*, pp. 3766–3777. PMLR, 2023.
- Geoffrey E Hinton. Training products of experts by minimizing contrastive divergence. *Neural Computation*, 14(8):1771–1800, 2002.
- Jonathan Ho and Tim Salimans. Classifier-free diffusion guidance. *arXiv preprint arXiv:2207.12598*, 2022.
- Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. *Advances in Neural Information Processing Systems (NeurIPS)*, 33:6840–6851, 2020.
- Sigmund H Høeg, Yilun Du, and Olav Egeland. Streaming diffusion policy: Fast policy synthesis with variable noise diffusion models. *arXiv preprint arXiv:2406.04806*, 2024.
- Edward J Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yanzhi Li, Shean Wang, Lu Wang, Weizhu Chen, et al. Lora: Low-rank adaptation of large language models. *International Conference on Learning Representations (ICLR)*, 1(2):3, 2022.
- Jiaheng Hu, Rose Hendrix, Ali Farhadi, Aniruddha Kembhavi, Roberto Martín-Martín, Peter Stone, Kuo-Hao Zeng, and Kiana Ehsani. Flare: Achieving masterful and adaptive robot policies with large-scale reinforcement learning fine-tuning. In *International Conference on Robotics and Automation (ICRA)*, pp. 3617–3624. IEEE, 2025.
- Yucheng Hu, Yanjiang Guo, Pengchao Wang, Xiaoyu Chen, Yen-Jen Wang, Jianke Zhang, Koushil Sreenath, Chaochao Lu, and Jianyu Chen. Video prediction policy: A generalist robot policy with predictive visual representations, 2024. URL <https://arxiv.org/abs/2412.14803>.
- Haojie Huang, Karl Schmeckpeper, Dian Wang, Ondrej Biza, Yaoyao Qian, Haotian Liu, Mingxi Jia, Robert Platt, and Robin Walters. Imagination policy: Using generative point cloud models for learning manipulation policies. In *Conference on Robot Learning (CoRL)*, pp. 5150–5165. PMLR, 2025a.
- Jiangyong Huang, Silong Yong, Xiaojian Ma, Xiongkun Linghu, Puhao Li, Yan Wang, Qing Li, Song-Chun Zhu, Baoxiong Jia, and Siyuan Huang. An embodied generalist agent in 3d world. In *International Conference on Machine Learning (ICML)*, pp. 20413–20451, 2024.

- Siyan Huang, Liliang Chen, Pengfei Zhou, Shengcong Chen, Zhengkai Jiang, Yue Hu, Peng Gao, Hongsheng Li, Maoqing Yao, and Guanghui Ren. Enerverse: Envisioning embodied future space for robotics manipulation. *arXiv preprint arXiv:2501.01895*, 2025b.
- Wenlong Huang, Chen Wang, Ruohan Zhang, Yunzhu Li, Jiajun Wu, and Li Fei-Fei. Voxposer: Composable 3d value maps for robotic manipulation with language models. In *Conference on Robot Learning (CoRL)*, pp. 540–562. PMLR, 2023.
- Wenlong Huang, Chen Wang, Yunzhu Li, Ruohan Zhang, and Li Fei-Fei. Rekep: Spatio-temporal reasoning of relational keypoint constraints for robotic manipulation. In *Conference on Robot Learning (CoRL)*, pp. 4573–4602. PMLR, 2025c.
- Physical Intelligence, Kevin Black, Noah Brown, James Darpinian, Karan Dhabalia, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, et al. $\pi 0$. 5: a vision-language-action model with open-world generalization, 2025. URL <https://arxiv.org/abs/2504.16054>, 1(2): 3, 2025.
- Michael Janner, Yilun Du, Joshua Tenenbaum, and Sergey Levine. Planning with diffusion for flexible behavior synthesis. In *International Conference on Machine Learning (ICML)*, pp. 9902–9915. PMLR, 2022.
- Johan Ludwig William Valdemar Jensen. Sur les fonctions convexes et les inégalités entre les valeurs moyennes. *Acta mathematica*, 30(1):175–193, 1906.
- Yueru Jia, Jiaming Liu, Sixiang Chen, Chenyang Gu, Zhilue Wang, Longzan Luo, Lily Lee, Pengwei Wang, Zhongyuan Wang, Renrui Zhang, et al. Lift3d foundation policy: Lifting 2d large-scale pretrained models for robust 3d robotic manipulation. *arXiv preprint arXiv:2411.18623*, 2024.
- Albert Q Jiang, Alexandre Sablayrolles, Antoine Roux, Arthur Mensch, Blanche Savary, Chris Bamford, Devendra Singh Chaplot, Diego de las Casas, Emma Bou Hanna, Florian Bressand, et al. Mixtral of experts. *arXiv preprint arXiv:2401.04088*, 2024.
- Tao Jiang, Tianyuan Yuan, Yicheng Liu, Chenhao Lu, Jianning Cui, Xiao Liu, Shuiqi Cheng, Jiyang Gao, Huazhe Xu, and Hang Zhao. Galaxea open-world dataset and g0 dual-system vla model. *arXiv preprint arXiv:2509.00576*, 2025.
- Joshua Jones, Oier Mees, Carmelo Sferrazza, Kyle Stachowicz, Pieter Abbeel, and Sergey Levine. Beyond sight: Finetuning generalist robot policies with heterogeneous sensors via language grounding. *arXiv preprint arXiv:2501.04693*, 2025.
- Siddharth Karamcheti, Suraj Nair, Annie S Chen, Thomas Kollar, Chelsea Finn, Dorsa Sadigh, and Percy Liang. Language-driven representation learning for robotics. *arXiv preprint arXiv:2302.12766*, 2023.
- Tsung-Wei Ke, Nikolaos Gkanatsios, and Katerina Fragkiadaki. 3d diffuser actor: Policy diffusion with 3d scene representations. In *Conference on Robot Learning (CoRL)*, pp. 1949–1974. PMLR, 2025.
- Alexander Khazatsky, Karl Pertsch, Suraj Nair, Ashwin Balakrishna, Sudeep Dasari, Siddharth Karamcheti, Soroush Nasiriany, Mohan Kumar Srirama, Lawrence Yunliang Chen, Kirsty Ellis, et al. Droid: A large-scale in-the-wild robot manipulation dataset. In *Robotics: Science and Systems (RSS)*, 2024.
- Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan P Foster, Pannag R Sanketi, Quan Vuong, et al. Openvla: An open-source vision-language-action model. In *Conference on Robot Learning (CoRL)*, pp. 2679–2713. PMLR, 2025.
- Daphne Koller and Nir Friedman. *Probabilistic graphical models: principles and techniques*. MIT press, 2009.
- Sébastien Lachapelle, Divyat Mahajan, Ioannis Mitliagkas, and Simon Lacoste-Julien. Additive decoders for latent variables identification and cartesian-product extrapolation. *Advances in Neural Information Processing Systems (NeurIPS)*, 36:25112–25150, 2023.

- Qixiu Li, Yaobo Liang, Zeyu Wang, Lin Luo, Xi Chen, Mozheng Liao, Fangyun Wei, Yu Deng, Sicheng Xu, Yizhong Zhang, et al. Cogact: A foundational vision-language-action model for synergizing cognition and action in robotic manipulation. *arXiv preprint arXiv:2411.19650*, 2024a.
- Shuang Li, Yilun Du, Joshua B Tenenbaum, Antonio Torralba, and Igor Mordatch. Composing ensembles of pre-trained models via iterative consensus. *arXiv preprint arXiv:2210.11522*, 2022.
- Shuang Li, Yihuai Gao, Dorsa Sadigh, and Shuran Song. Unified video action model. *arXiv preprint arXiv:2503.00200*, 2025.
- Xiang Li, Varun Belagali, Jinghuan Shang, and Michael S Ryoo. Crossway diffusion: Improving diffusion-based visuomotor policy via self-supervised learning. In *International Conference on Robotics and Automation (ICRA)*, pp. 16841–16849. IEEE, 2024b.
- Xinghang Li, Peiyan Li, Minghuan Liu, Dong Wang, Jirong Liu, Bingyi Kang, Xiao Ma, Tao Kong, Hanbo Zhang, and Huaping Liu. Towards generalist robot policies: What matters in building vision-language-action models. *arXiv preprint arXiv:2412.14058*, 2024c.
- Shalev Lifshitz, Sheila A McIlraith, and Yilun Du. Multi-agent verification: Scaling test-time compute with multiple verifiers. *Conference on Language Modeling (CoLM)*, 2025.
- Fanqi Lin, Yingdong Hu, Pingyue Sheng, Chuan Wen, Jiacheng You, and Yang Gao. Data scaling laws in imitation learning for robotic manipulation. In *International Conference on Learning Representations (ICLR)*, 2024a.
- Ming-Yi Lin, Ou-Wen Lee, and Chih-Ying Lu. Embodied ai with large language models: A survey and new hri framework. In *International Conference on Advanced Robotics and Mechatronics (ICARM)*, pp. 978–983. IEEE, 2024b.
- Yaron Lipman, Ricky TQ Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow matching for generative modeling. In *International Conference on Learning Representations (ICLR)*, 2023.
- Jiaming Liu, Hao Chen, Pengju An, Zhuoyang Liu, Renrui Zhang, Chenyang Gu, Xiaoqi Li, Ziyu Guo, Sixiang Chen, Mengzhen Liu, et al. Hybridvla: Collaborative diffusion and autoregression in a unified vision-language-action model. *arXiv preprint arXiv:2503.10631*, 2025a.
- Nan Liu, Shuang Li, Yilun Du, Josh Tenenbaum, and Antonio Torralba. Learning to compose visual relations. *Advances in Neural Information Processing Systems (NeurIPS)*, 34:23166–23178, 2021.
- Nan Liu, Yilun Du, Shuang Li, Joshua B Tenenbaum, and Antonio Torralba. Unsupervised compositional concepts discovery with text-to-image generative models. In *International Conference on Computer Vision (ICCV)*, pp. 2085–2095, 2023.
- Qiang Liu. Rectified flow: A marginal preserving approach to optimal transport. *arXiv preprint arXiv:2209.14577*, 2022.
- Songming Liu, Lingxuan Wu, Bangguo Li, Hengkai Tan, Huayu Chen, Zhengyi Wang, Ke Xu, Hang Su, and Jun Zhu. Rdt-1b: a diffusion foundation model for bimanual manipulation. *arXiv preprint arXiv:2410.07864*, 2024a.
- Songming Liu, Bangguo Li, Kai Ma, Lingxuan Wu, Hengkai Tan, Xiao Ouyang, Hang Su, and Jun Zhu. Rdt2: Exploring the scaling limit of umi data towards zero-shot cross-embodiment generalization. *arXiv preprint arXiv:2602.03310*, 2026.
- WeiYu Liu, Tucker Hermans, Sonia Chernova, and Chris Paxton. Structdiffusion: Object-centric diffusion for semantic rearrangement of novel objects. In *CoRL Workshop on Language and Robotics*, 2022.
- Yang Liu, Weixing Chen, Yongjie Bai, Xiaodan Liang, Guanbin Li, Wen Gao, and Liang Lin. Aligning cyber space with physical world: A comprehensive survey on embodied ai. *IEEE/ASME Transactions on Mechatronics (TMECH)*, 2025b.

- Yijun Liu, Yuwei Liu, Yuan Meng, Jieheng Zhang, Yuwei Zhou, Ye Li, Jiacheng Jiang, Kangye Ji, Shijia Ge, Zhi Wang, et al. Spatial policy: Guiding visuomotor robotic manipulation with spatial-aware modeling and reasoning. *arXiv preprint arXiv:2508.15874*, 2025c.
- Yuejiang Liu, Jubayer Ibn Hamid, Annie Xie, Yoonho Lee, Maximilian Du, and Chelsea Finn. Bidirectional decoding: Improving action chunking via closed-loop resampling. *arXiv e-prints*, pp. arXiv-2408, 2024b.
- Yiyang Lu, Yufeng Tian, Zhecheng Yuan, Xianbang Wang, Pu Hua, Zhengrong Xue, and Huazhe Xu. H3dp: Triply-hierarchical diffusion policy for visuomotor learning. *arXiv preprint arXiv:2505.07819*, 2025.
- Yunhao Luo, Chen Sun, Joshua B Tenenbaum, and Yilun Du. Potential based diffusion motion planning. In *International Conference on Machine Learning (ICML)*, 2024.
- Xiao Ma, Sumit Patidar, Iain Haughton, and Stephen James. Hierarchical diffusion policy for kinematics-aware multi-task robotic manipulation. In *Computer Vision and Pattern Recognition (CVPR)*, pp. 18081–18090, 2024a.
- Yueen Ma, Zixing Song, Yuzheng Zhuang, Jianye Hao, and Irwin King. A survey on vision-language-action models for embodied ai. *arXiv preprint arXiv:2405.14093*, 2024b.
- Ajay Mandlekar, Danfei Xu, Josiah Wong, Soroush Nasiriany, Chen Wang, Rohun Kulkarni, Li Fei-Fei, Silvio Savarese, Yuke Zhu, and Roberto Martín-Martín. What matters in learning from offline human demonstrations for robot manipulation. In *Conference on Robot Learning (CoRL)*, pp. 1678–1690. PMLR, 2022.
- David McAllister, Songwei Ge, Brent Yi, Chung Min Kim, Ethan Weber, Hongsuk Choi, Haiwen Feng, and Angjoo Kanazawa. Flow matching policy gradients. *arXiv preprint arXiv:2507.21053*, 2025.
- Utkarsh Aashu Mishra, Shangjie Xue, Yongxin Chen, and Danfei Xu. Generative skill chaining: Long-horizon skill planning with diffusion models. In *Conference on Robot Learning (CoRL)*, pp. 2905–2925. PMLR, 2023.
- Eleonora Misino, Giuseppe Marra, and Emanuele Sansone. Vael: Bridging variational autoencoders and probabilistic logic programming. *Advances in Neural Information Processing Systems (NeurIPS)*, 35:4667–4679, 2022.
- Yao Mu, Tianxing Chen, Zanxin Chen, Shijia Peng, Zhiqian Lan, Zeyu Gao, Zhixuan Liang, Qiaojun Yu, Yude Zou, Mingkun Xu, et al. Robotwin: Dual-arm robot benchmark with generative digital twins. In *Computer Vision and Pattern Recognition Conference (CVPR)*, pp. 27649–27660, 2025.
- Kevin P Murphy. *Probabilistic machine learning: an introduction*. MIT press, 2022.
- Alexander Quinn Nichol and Prafulla Dhariwal. Improved denoising diffusion probabilistic models. In *International Conference on Machine Learning (ICML)*, pp. 8162–8171. PMLR, 2021.
- Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, et al. Training language models to follow instructions with human feedback. *Advances in Neural Information Processing Systems (NeurIPS)*, 35:27730–27744, 2022.
- Abby O’Neill, Abdul Rehman, Abhiram Maddukuri, Abhishek Gupta, Abhishek Padalkar, Abraham Lee, Acorn Pooley, Agrim Gupta, Ajay Mandlekar, Ajinkya Jain, et al. Open x-embodiment: Robotic learning datasets and rt-x models: Open x-embodiment collaboration 0. In *International Conference on Robotics and Automation (ICRA)*, pp. 6892–6903. IEEE, 2024.
- Daojie Peng, Jiahang Cao, Qiang Zhang, and Jun Ma. Lovon: Legged open-vocabulary object navigator. *arXiv preprint arXiv:2507.06747*, 2025.
- Karl Pertsch, Kyle Stachowicz, Brian Ichter, Danny Driess, Suraj Nair, Quan Vuong, Oier Mees, Chelsea Finn, and Sergey Levine. Fast: Efficient action tokenization for vision-language-action models. *arXiv preprint arXiv:2501.09747*, 2025.

- Aaditya Prasad, Kevin Lin, Jimmy Wu, Linqi Zhou, and Jeannette Bohg. Consistency policy: Accelerated visuomotor policies via consistency distillation. In *Robotics: Science and Systems (RSS)*, 2024.
- Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. Learning transferable visual models from natural language supervision. In *International Conference on Machine Learning (ICML)*, pp. 8748–8763. PmLR, 2021.
- Allen Z Ren, Justin Lidard, Lars L Ankile, Anthony Simeonov, Pulkit Agrawal, Anirudha Majumdar, Benjamin Burchfiel, Hongkai Dai, and Max Simchowitz. Diffusion policy policy optimization. *arXiv preprint arXiv:2409.00588*, 2024.
- Moritz Reuss, Ömer Erdinç Yağmurlu, Fabian Wenzel, and Rudolf Lioutikov. Multimodal diffusion transformer: Learning versatile behavior from multimodal goals. *Robotics: Science and Systems (RSS)*, 2024.
- Tim Salimans and Jonathan Ho. Progressive distillation for fast sampling of diffusion models. *arXiv preprint arXiv:2202.00512*, 2022.
- Ranjan Sapkota, Yang Cao, Konstantinos I Roumeliotis, and Manoj Karkee. Vision-language-action models: Concepts, progress, applications and challenges. *arXiv preprint arXiv:2505.04769*, 2025.
- Vaibhav Saxena, Yotto Koga, and Danfei Xu. Constrained-context conditional diffusion models for imitation learning. *arXiv preprint arXiv:2311.01419*, 2023.
- Atharva Sehgal, Arya Grayeli, Jennifer J Sun, and Swarat Chaudhuri. Neurosymbolic grounding for compositional world models. *arXiv preprint arXiv:2310.12690*, 2023.
- Rui Shao, Wei Li, Lingsen Zhang, Renshan Zhang, Zhiyang Liu, Ran Chen, and Liqiang Nie. Large vlm-based vision-language-action models for robotic manipulation: A survey. *arXiv preprint arXiv:2508.13073*, 2025.
- SP Sharan, Ruihan Zhao, Zhangyang Wang, Sandeep P Chinchali, et al. Plan diffuser: Grounding llm planners with diffusion models for robotic manipulation. In *Bridging the Gap between Cognitive Science and Robot Learning in the Real World: Progresses and New Directions*, 2024.
- Lucy Xiaoyang Shi, Archit Sharma, Tony Z Zhao, and Chelsea Finn. Waypoint-based imitation learning for robotic manipulation. In *Conference on Robot Learning (CoRL)*, pp. 2195–2209. PMLR, 2023.
- Marta Skreta, Lazar Atanackovic, Joey Bose, Alexander Tong, and Kirill Neklyudov. The superposition of diffusion models using the itô density estimator. In *International Conference on Learning Representations (ICLR)*, 2024.
- Charlie Snell, Jaehoon Lee, Kelvin Xu, and Aviral Kumar. Scaling llm test-time compute optimally can be more effective than scaling model parameters. *arXiv preprint arXiv:2408.03314*, 2024.
- Jascha Sohl-Dickstein, Eric Weiss, Niru Maheswaranathan, and Surya Ganguli. Deep unsupervised learning using nonequilibrium thermodynamics. In *International Conference on Machine Learning (ICML)*, pp. 2256–2265. pmlr, 2015.
- Houshang H Sohrab. *Basic real analysis*, volume 231. Springer, 2003.
- Jiaming Song, Chenlin Meng, and Stefano Ermon. Denoising diffusion implicit models. In *International Conference on Learning Representations (ICLR)*, 2020a.
- Mingchen Song, Xiang Deng, Zhiling Zhou, Jie Wei, Weili Guan, and Liqiang Nie. A survey on diffusion policy for robotic manipulation: Taxonomy, analysis, and future directions. *Authorea Preprints*, 2025.
- Yang Song and Stefano Ermon. Generative modeling by estimating gradients of the data distribution. *Advances in Neural Information Processing Systems (NeurIPS)*, 32, 2019.

- Yang Song, Jascha Sohl-Dickstein, Diederik P Kingma, Abhishek Kumar, Stefano Ermon, and Ben Poole. Score-based generative modeling through stochastic differential equations. *arXiv preprint arXiv:2011.13456*, 2020b.
- Ajay Sridhar, Dhruv Shah, Catherine Glossop, and Sergey Levine. Nomad: Goal masked diffusion policies for navigation and exploration. In *IEEE International Conference on Robotics and Automation (ICRA)*, pp. 63–70. IEEE, 2024.
- Jocelin Su, Nan Liu, Yanbo Wang, Joshua B Tenenbaum, and Yilun Du. Compositional image decomposition with diffusion models. In *International Conference on Machine Learning (ICML)*, pp. 46823–46842. PMLR, 2024.
- Zhanyi Sun and Shuran Song. Latent policy barrier: Learning robust visuomotor policies by staying in-distribution. *arXiv preprint arXiv:2508.05941*, 2025.
- Gemini Robotics Team, Saminda Abeyruwan, Joshua Ainslie, Jean-Baptiste Alayrac, Montserrat Gonzalez Arenas, Travis Armstrong, Ashwin Balakrishna, Robert Baruch, Maria Bauza, Michiel Blokzijl, et al. Gemini robotics: Bringing ai into the physical world. *arXiv preprint arXiv:2503.20020*, 2025.
- Octo Model Team, Dibya Ghosh, Homer Walke, Karl Pertsch, Kevin Black, Oier Mees, Sudeep Dasari, Joey Hejna, Tobias Kreiman, Charles Xu, et al. Octo: An open-source generalist robot policy. *arXiv preprint arXiv:2405.12213*, 2024.
- Brian S Thomson, Judith B Bruckner, and Andrew M Bruckner. *Elementary real analysis*, volume 1. ClassicalRealAnalysis. com, 2008.
- Leonida Tonelli. Sull’integrazione per parti. *Rend. Acc. Naz. Lincei*, 5(18):246–253, 1909.
- Julen Uraïn, Ajay Mandlekar, Yilun Du, Mahi Shafiullah, Danfei Xu, Katerina Fragkiadaki, Georgia Chalvatzaki, and Jan Peters. Deep generative models in robotics: A survey on learning from multimodal demonstrations. *arXiv preprint arXiv:2408.04380*, 2024.
- Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in Neural Information Processing Systems (NeurIPS)*, 30, 2017.
- Robert Verkuil, Ori Kabeli, Yilun Du, Basile IM Wicky, Lukas F Milles, Justas Dauparas, David Baker, Sergey Ovchinnikov, Tom Sercu, and Alexander Rives. Language models generalize beyond natural proteins. *BioRxiv*, pp. 2022–12, 2022.
- Vitalis Vosylius, Younggyo Seo, Jafar Uruç, and Stephen James. Render and diffuse: Aligning image and action spaces for diffusion-based behaviour cloning. *arXiv preprint arXiv:2405.18196*, 2024.
- Andrew Wagenmaker, Mitsuhiko Nakamoto, Yunchu Zhang, Seohong Park, Waleed Yagoub, Anusha Nagabandi, Abhishek Gupta, and Sergey Levine. Steering your diffusion policy with latent space reinforcement learning. *arXiv preprint arXiv:2506.15799*, 2025.
- Homer Rich Walke, Kevin Black, Tony Z Zhao, Quan Vuong, Chongyi Zheng, Philippe Hansen-Estruch, Andre Wang He, Vivek Myers, Moo Jin Kim, Max Du, et al. Bridgedata v2: A dataset for robot learning at scale. In *Conference on Robot Learning (CoRL)*, pp. 1723–1736. PMLR, 2023.
- Dian Wang, Stephen Hart, David Surovik, Tarik Kelestemur, Haojie Huang, Haibo Zhao, Mark Yeatman, Jiuguang Wang, Robin Walters, and Robert Platt. Equivariant diffusion policy. *arXiv preprint arXiv:2407.01812*, 2024a.
- Lirui Wang. *Robot Fleet Learning From Heterogeneous Data*. PhD thesis, Massachusetts Institute of Technology, 2025.
- Lirui Wang, Xinlei Chen, Jialiang Zhao, and Kaiming He. Scaling proprioceptive-visual learning with heterogeneous pre-trained transformers. *Advances in Neural Information Processing Systems (NeurIPS)*, 37:124420–124450, 2024b.

- Lirui Wang, Jialiang Zhao, Yilun Du, Edward H Adelson, and Russ Tedrake. Poco: Policy composition from and for heterogeneous robot learning. *Robotics: Science and Systems (RSS)*, 2024c.
- Qianhao Wang, Yinqian Sun, Enmeng Lu, Qian Zhang, and Yi Zeng. Mtdp: Modulated transformer diffusion policy model. *arXiv e-prints*, pp. arXiv-2502, 2025a.
- Shaoan Wang, Jiazhao Zhang, Minghan Li, Jiahang Liu, Anqi Li, Kui Wu, Fangwei Zhong, Junzhi Yu, Zhizheng Zhang, and He Wang. Trackvla: Embodied visual tracking in the wild. *arXiv preprint arXiv:2505.23189*, 2025b.
- Yanwei Wang, Lirui Wang, Yilun Du, Balakumar Sundaralingam, Xuning Yang, Yu-Wei Chao, Claudia Pérez-D’Arpino, Dieter Fox, and Julie Shah. Inference-time policy steering through human interactions. In *International Conference on Robotics and Automation (ICRA)*, pp. 15626–15633. IEEE, 2025c.
- Junjie Wen, Yichen Zhu, Jinming Li, Minjie Zhu, Zhibin Tang, Kun Wu, Zhiyuan Xu, Ning Liu, Ran Cheng, Chaomin Shen, et al. Tinyvla: Towards fast, data-efficient vision-language-action models for robotic manipulation. *Robotics and Automation Letters (RAL)*, 2025a.
- Junjie Wen, Yichen Zhu, Minjie Zhu, Zhibin Tang, Jinming Li, Zhongyi Zhou, Xiaoyu Liu, Chaomin Shen, Yaxin Peng, and Feifei Feng. Diffusionvla: Scaling robot foundation models via unified diffusion and autoregression. In *International Conference on Machine Learning (ICML)*, 2025b.
- Zehang Weng, Haofei Lu, Danica Kragic, and Jens Lundell. Dexdiffuser: Generating dexterous grasps with diffusion models. *Robotics and Automation Letters (RAL)*, 2024.
- Thaddäus Wiedemer, Prasanna Mayilvahanan, Matthias Bethge, and Wieland Brendel. Compositional generalization from first principles. *Advances in Neural Information Processing Systems (NeurIPS)*, 36:6941–6960, 2023.
- Rosa Petra Wolf, Yitian Shi, Sheng Liu, and Rania Rayyes. Diffusion models for robotic manipulation: A survey. *Frontiers in Robotics and AI*, 12:1606247, 2025.
- Lik Hang Kenny Wong, Xueyang Kang, Kaixin Bai, and Jianwei Zhang. A survey of robotic navigation and manipulation with physics simulators in the era of embodied ai. *arXiv preprint arXiv:2505.01458*, 2025.
- Zhou Xian and Nikolaos Gkanatsios. Chaineddiffuser: Unifying trajectory diffusion and keypose prediction for robotic manipulation. In *Conference on Robot Learning (CoRL)*. Proceedings of Machine Learning Research, 2023.
- Tian-Yu Xiang, Ao-Qun Jin, Xiao-Hu Zhou, Mei-Jiang Gui, Xiao-Liang Xie, Shi-Qi Liu, Shuang-Yi Wang, Sheng-Bin Duan, Fu-Chao Xie, Wen-Kai Wang, et al. Parallels between vla model post-training and human motor learning: Progress, challenges, and trends. *arXiv preprint arXiv:2506.20966*, 2025.
- Bin Xiao, Haiping Wu, Weijian Xu, Xiyang Dai, Houdong Hu, Yumao Lu, Michael Zeng, Ce Liu, and Lu Yuan. Florence-2: Advancing a unified representation for a variety of vision tasks. In *Computer Vision and Pattern Recognition (CVPR)*, pp. 4818–4829, 2024.
- Han Xue, Jieji Ren, Wendi Chen, Gu Zhang, Yuan Fang, Guoying Gu, Huazhe Xu, and Cewu Lu. Reactive diffusion policy: Slow-fast visual-tactile policy learning for contact-rich manipulation. *arXiv preprint arXiv:2503.02881*, 2025.
- Ge Yan, Jiyue Zhu, Yuquan Deng, Shiqi Yang, Ri-Zhao Qiu, Xuxin Cheng, Marius Memmel, Ranjay Krishna, Ankit Goyal, Xiaolong Wang, et al. Manifold: A general robot manipulation policy via consistency flow training. *arXiv preprint arXiv:2509.01819*, 2025.
- Mengjiao Yang, Yilun Du, Bo Dai, Dale Schuurmans, Joshua B Tenenbaum, and Pieter Abbeel. Probabilistic adaptation of text-to-video models. *arXiv preprint arXiv:2306.01872*, 2023a.
- Quantao Yang, Michael C Welle, Danica Kragic, and Olov Andersson. S2-diffusion: Generalizing from instance-level to category-level skills in robot manipulation. *arXiv preprint arXiv:2502.09389*, 2025.

- Zhutian Yang, Jiayuan Mao, Yilun Du, Jiajun Wu, Joshua B Tenenbaum, Tomás Lozano-Pérez, and Leslie Pack Kaelbling. Compositional diffusion-based continuous constraint solvers. In *Conference on Robot Learning (CoRL)*, pp. 3242–3265. PMLR, 2023b.
- Seonghyeon Ye, Joel Jang, Byeongguk Jeon, Sejeun Joo, Jianwei Yang, Baolin Peng, Ajay Mandlekar, Reuben Tan, Yu-Wei Chao, Bill Yuchen Lin, et al. Latent action pretraining from videos. *arXiv preprint arXiv:2410.11758*, 2024.
- Tianhe Yu, Ted Xiao, Austin Stone, Jonathan Tompson, Anthony Brohan, Su Wang, Jaspiar Singh, Clayton Tan, Jodilyn Peralta, Brian Ichter, et al. Scaling robot learning with semantically imagined experience. *arXiv preprint arXiv:2302.11550*, 2023.
- Yanjie Ze, Zixuan Chen, Wenhao Wang, Tianyi Chen, Xialin He, Ying Yuan, Xue Bin Peng, and Jiajun Wu. Generalizable humanoid manipulation with 3d diffusion policies. *arXiv preprint arXiv:2410.10803*, 2024a.
- Yanjie Ze, Gu Zhang, Kangning Zhang, Chenyuan Hu, Muhan Wang, and Huazhe Xu. 3d diffusion policy. *Robotics: Science and Systems (RSS)*, 2024b.
- Andy Zhai, Brae Liu, Bruno Fang, Chalse Cai, Ellie Ma, Ethan Yin, Hao Wang, Hugo Zhou, James Wang, Lights Shi, Lucy Liang, Make Wang, Qian Wang, Roy Gan, Ryan Yu, Shalfun Li, Starrick Liu, Syllas Chen, Vincent Chen, and Zach Xu. Igniting vlms toward the embodied space. *arXiv preprint arXiv:2509.11766*, 2025.
- Gengyu Zhang, Hao Tang, and Yan Yan. Versatile navigation under partial observability via value-guided diffusion policy. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 17943–17951, 2024a.
- Jiazhao Zhang, Kunyu Wang, Rongtao Xu, Gengze Zhou, Yicong Hong, Xiaomeng Fang, Qi Wu, Zhizheng Zhang, and He Wang. Navid: Video-based vlm plans the next step for vision-and-language navigation. *arXiv preprint arXiv:2402.15852*, 2024b.
- Kun Zhang, Peng Yun, Jun Cen, Junhao Cai, Didi Zhu, Hangjie Yuan, Chao Zhao, Tao Feng, Michael Yu Wang, Qifeng Chen, et al. Generative artificial intelligence in robotic manipulation: A survey. *arXiv preprint arXiv:2503.03464*, 2025a.
- Qinsheng Zhang, Jiaming Song, Xun Huang, Yongxin Chen, and Ming-Yu Liu. Diffcollage: Parallel generation of large content with diffusion models. In *Computer Vision and Pattern Recognition (CVPR)*, pp. 10188–10198. IEEE, 2023.
- Wenbo Zhang, Tianrun Hu, Yanyuan Qiao, Hanbo Zhang, Yuchu Qin, Yang Li, Jiajun Liu, Tao Kong, Lingqiao Liu, and Xiao Ma. Chain-of-action: Trajectory autoregressive modeling for robotic manipulation. *arXiv preprint arXiv:2506.09990*, 2025b.
- Xinyu Zhang, Yuhan Liu, Haonan Chang, Liam Schramm, and Abdeslam Boularias. Autoregressive action sequence learning for robotic manipulation. *IEEE Robotics and Automation Letters*, 2025c.
- Tony Z Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. *Robotics: Science and Systems (RSS)*, 2023.
- Tony Z Zhao, Jonathan Tompson, Danny Driess, Pete Florence, Seyed Kamyar Seyed Ghasemipour, Chelsea Finn, and Ayzaan Wahid. Aloha unleashed: A simple recipe for robot dexterity. In *Conference on Robot Learning (CoRL)*, pp. 1910–1924. PMLR, 2025.
- Haoyu Zhen, Xiaowen Qiu, Peihao Chen, Jincheng Yang, Xin Yan, Yilun Du, Yining Hong, and Chuang Gan. 3d-vla: a 3d vision-language-action generative world model. In *International Conference on Machine Learning (ICML)*, pp. 61229–61245, 2024.
- Ying Zheng, Lei Yao, Yuejiao Su, Yi Zhang, Yi Wang, Sicheng Zhao, Yiyi Zhang, and Lap-Pui Chau. A survey of embodied learning for object-centric robotic manipulation. *Machine Intelligence Research*, pp. 1–39, 2025.

Yifan Zhong, Fengshuo Bai, Shaofei Cai, Xuchuan Huang, Zhang Chen, Xiaowei Zhang, Yuanfei Wang, Shaoyang Guo, Tianrui Guan, Ka Nam Lui, et al. A survey on vision-language-action models: An action tokenization perspective. *arXiv preprint arXiv:2507.01925*, 2025.

Zhongyi Zhou, Yichen Zhu, Minjie Zhu, Junjie Wen, Ning Liu, Zhiyuan Xu, Weibin Meng, Ran Cheng, Yaxin Peng, Chaomin Shen, et al. Chatvla: Unified multimodal understanding and robot control with vision-language-action model. *arXiv preprint arXiv:2502.14420*, 2025.

Minjie Zhu, Yichen Zhu, Jinming Li, Junjie Wen, Zhiyuan Xu, Ning Liu, Ran Cheng, Chaomin Shen, Yaxin Peng, Feifei Feng, et al. Scaling diffusion policy in transformer to 1 billion parameters for robotic manipulation. *arXiv preprint arXiv:2409.14411*, 2024.

Brianna Zitkovich, Tianhe Yu, Sichun Xu, Peng Xu, Ted Xiao, Fei Xia, Jialin Wu, Paul Wohlhart, Stefan Welker, Ayzaan Wahid, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control. In *Conference on Robot Learning (CoRL)*, pp. 2165–2183. PMLR, 2023.

附录

1. 假设、符号与预备事实——基本假设、符号及预备知识。
2. 命题 4.1 的证明（单步凸改进）——单步凸改进结果的形式化证明。
3. 命题 4.2 的证明（分数到样本的稳定性）——分数到样本映射的详细稳定性分析。
4. 推论 4.1 的证明（GPC 收紧终端界）——证明 GPC 改善了整体误差界。
5. 详细工具：范数导数、积分因子与不等式——数学工具用于证明中。
6. 命题与推论如何相互关联——主要结果之间的逻辑联系。
7. 广义预测校正（GPC）对任意预测类型的灵活性——GPC 在不同预测类型上的扩展。
8. 深入分析 GPC 成功的原因——对 GPC 成功因素的分析。
9. 实验细节——实验设置、架构与超参数。
10. 补充实验结果——扩展的定量比较。
11. 机器人任务可视化——机器人任务执行过程的可视化。
12. 详细文献综述——相关工作的扩展综述。
13. 未来工作——开放挑战与未来研究方向。

A 假设、符号与预备事实

动力学。 采样过程被建模为常微分方程或随机微分方程:

$$\dot{x}(t) = F(t, x(t), s(t, x(t))), \quad t \in [0, T], \quad x(0) \sim \mu_0, \quad (8)$$

where $x(t) \in \mathbb{R}^d$, the score $s : [0, T] \times \mathbb{R}^d \rightarrow \mathbb{R}^d$, and $F : [0, T] \times \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}^d$ represents the transformed score due to noise schedule, parameterization, or solver.

理想流与实际流。 本文比较了求解方程 8 的理想轨迹 $x^*(t)$ (使用 s^*) 与实际轨迹 $x_{\hat{s}}(t)$ (使用 $\hat{s}$) ; 两者具有相同的初始条件。

Score error.

$$\Delta_s(t, x) := \hat{s}(t, x) - s^*(t, x).$$

得分误差界假设。

本文假设: 存在一个非负函数 $\kappa(t)$, 使得对于所有 x ,

$$\|\Delta_s(t, x)\| \leq \kappa(t).$$

正则性假设。

本文假设:

(A1) $F(\cdot)$ 的利普希茨性 (Sohrab, 2003; Thomson et al., 2008) 对于几乎处处的 $t \in [0, T]$, 存在可积的 $L_x, L_s \geq 0$, 使得对于所有 x, y, s, r ,

$$\|F(t, x, s) - F(t, y, r)\| \leq L_x(t)\|x - y\| + L_s(t)\|s - r\|.$$

(A2) **分数正则性。** $s^*(t, \cdot)$ 和 $\hat{s}(t, \cdot)$ 在流所经过的管状区域上局部利普希茨, 具有 (时间依赖的) 模量 $\Lambda^*(t), \hat{\Lambda}(t) \in L^1([0, T])$, 且至多线性增长。

绝对连续性与范数导数。 若 $e : [0, T] \rightarrow \mathbb{R}^d$ 绝对连续, 则 $e'(t)$ 几乎处处存在, $e(t) = e(0) + \int_0^t e'(\tau) d\tau$,

且 $\phi(t) := \|e(t)\|$ 绝对连续, 我们在 § E 中给出完整证明。

$$\phi'(t) \leq \|e'(t)\| \quad \text{for a.e. } t. \quad (9)$$

为何利普希茨性是合理的。 对于基于分数的模型的概率流常微分方程, F 关于 s (e.g. 是仿射的。反向常微分方程 (Song et al., 2020b): $F = f(t, x) - g(t)^2 s(t, x)$), so $L_s(t) = g(t)^2$ (已知, 在有限 T 上有界)。对 x 的依赖通过 $f(t, x)$ (通常光滑) 以及 s 体现; 在紧致管状区域上的网络满足局部利普希茨性, 并产生有限的利普希茨模量 $\Lambda^*(t), \hat{\Lambda}(t)$ 。这些在神经常微分方程和概率流常微分方程的稳定性分析中是标准的。

B 命题 4.1 的证明（单步凸改进）

陈述重述。 以 (t, x_t) 为条件，假设我们有两个估计器

$$\varepsilon_i = s^*(t, x_t) + b_i(t, x_t) + \eta_i, \quad i = \{1, 2\},$$

其中 $s^*(t, x_t)$ 为真实得分， b_i 为确定性偏差， η_i 为零均值随机噪声。对于 $w \in [0, 1]$ ，定义凸组合

$$\varepsilon(w) = w\varepsilon_1 + (1 - w)\varepsilon_2, \quad Q(w) := \mathbb{E}_\eta \|\varepsilon(w) - s^*(t, x_t)\|^2. \quad (10)$$

记号。 这一抽象（方程 10）统一了不同的建模范式：

- 当存在噪声时，估计器可视为扩散模型的输出，残差项 η 在时间反转的随机动力学（*e.g.*，即逆向常微分方程）中扮演扩散分量的角色。
- 当噪声项消失（*i.e.*， $\eta = 0$ ）时，该公式退化为确定性传输设定，即流匹配情形。

η_i 的作用类似于扩散前向过程中引入的随机噪声（对于净样本的 *e.g.*，高斯扰动），确保即使 (t, x_t) 固定，每个估计器 ε_i 仍保持随机性。因此，命题 4.1 中的所有期望均关于 (η_1, η_2) 的联合分布取值，且随机性仅来源于 (η_1, η_2) 。我们将期望写为

$$\mathbb{E}[\cdot] \equiv \mathbb{E}_\eta[\cdot] \equiv \mathbb{E}_{\eta_1, \eta_2}[\cdot \mid x_t, t].$$

目标。 证明 $Q(w)$ 为凸二次函数，推导其系数、极小值点 w^* 、极小值，以及相对于端点 $w = 0, 1$ 的改进条件。

Decomposition. Subtracting $s^*(t, x_t)$, we write

$$\varepsilon(w) - s^* = u(w) + v(w),$$

where

$$u(w) = wb_1 + (1 - w)b_2, \quad v(w) = w\eta_1 + (1 - w)\eta_2.$$

Hence

$$\begin{aligned} Q(w) &= \mathbb{E} \|u(w) + v(w)\|^2 \\ &= \|u(w)\|^2 + 2\mathbb{E} \langle u(w), v(w) \rangle + \mathbb{E} \|v(w)\|^2. \end{aligned} \quad (11)$$

由于 $\mathbb{E}[\eta_i] = 0$ ，交叉项消失，剩下

$$Q(w) = \|u(w)\|^2 + \mathbb{E} \|v(w)\|^2.$$

偏差贡献。 展开 $\|u(w)\|^2$ 得到

$$\|u(w)\|^2 = \|b_2 + w(b_1 - b_2)\|^2 = \|b_2\|^2 + 2w\langle b_2, b_1 - b_2 \rangle + w^2\|b_1 - b_2\|^2.$$

噪声贡献。 展开 $\mathbb{E} \|v(w)\|^2$ 得到

$$\begin{aligned} \mathbb{E} \|v(w)\|^2 &= \mathbb{E} \|w\eta_1 + (1 - w)\eta_2\|^2 \\ &= w^2 \mathbb{E} \|\eta_1\|^2 + (1 - w)^2 \mathbb{E} \|\eta_2\|^2 + 2w(1 - w) \mathbb{E} \langle \eta_1, \eta_2 \rangle. \end{aligned}$$

二次型。 结合两项贡献， $Q(w)$ 是一个二次函数

$$Q(w) = Aw^2 + Bw + C,$$

其中

$$\begin{aligned} A &= \|b_1 - b_2\|^2 + \mathbb{E} \|\eta_1\|^2 + \mathbb{E} \|\eta_2\|^2 - 2\mathbb{E} \langle \eta_1, \eta_2 \rangle, \\ B &= 2\langle b_2, b_1 - b_2 \rangle - 2\mathbb{E} \|\eta_2\|^2 + 2\mathbb{E} \langle \eta_1, \eta_2 \rangle, \\ C &= \|b_2\|^2 + \mathbb{E} \|\eta_2\|^2. \end{aligned}$$

凸性。根据柯西-施瓦茨不等式,

$$\mathbb{E}\langle\eta_1, \eta_2\rangle \leq \sqrt{\mathbb{E}\|\eta_1\|^2 \mathbb{E}\|\eta_2\|^2},$$

so

$$A \geq (\sqrt{\mathbb{E}\|\eta_1\|^2} - \sqrt{\mathbb{E}\|\eta_2\|^2})^2 + \|b_1 - b_2\|^2 \geq 0.$$

因此 $Q(w)$ 是凸的, 并且除非偏差和

噪声都相同, 否则是严格凸的。

最小化器。如果 $A > 0$, 唯一的最小化器是

$$w^* = -\frac{B}{2A} = \frac{\mathbb{E}\|\eta_2\|^2 - \mathbb{E}\langle\eta_1, \eta_2\rangle - \langle b_2, b_1 - b_2\rangle}{\|b_1 - b_2\|^2 + \mathbb{E}\|\eta_1\|^2 + \mathbb{E}\|\eta_2\|^2 - 2\mathbb{E}\langle\eta_1, \eta_2\rangle}.$$

最小值为

$$Q(w^*) = C - \frac{B^2}{4A}.$$

Endpoint comparison. At $w = 0, 1$, we have

$$Q(0) = C, \quad Q(1) = A + B + C.$$

差距为

$$Q(0) - Q(w^*) = \frac{B^2}{4A} \geq 0, \quad Q(1) - Q(w^*) = \frac{(2A+B)^2}{4A} \geq 0,$$

除非 $B = 0$ 或 $2A + B = 0$, 否则严格不等式成立。

特例一: 无偏情形。若 $b_1 = b_2 = 0$, 则 $A = \mathbb{E}\|\eta_1\|^2 + \mathbb{E}\|\eta_2\|^2 - 2\mathbb{E}\langle\eta_1, \eta_2\rangle$,

$B = -2\mathbb{E}\|\eta_2\|^2 + 2\mathbb{E}\langle\eta_1, \eta_2\rangle$, $C = \mathbb{E}\|\eta_2\|^2$, 与 $A \geq 0$ 且 $A > 0$, 除非 η_1, η_2 完全相关且具有相同的二阶矩。对于 $A > 0$, 唯一极小化元为

$$w^* = \frac{\mathbb{E}\|\eta_2\|^2 - \mathbb{E}\langle\eta_1, \eta_2\rangle}{\mathbb{E}\|\eta_1\|^2 + \mathbb{E}\|\eta_2\|^2 - 2\mathbb{E}\langle\eta_1, \eta_2\rangle},$$

端点间隙为

$$Q(0) - Q(w^*) = \frac{B^2}{4A} = \frac{(\mathbb{E}\|\eta_2\|^2 - \mathbb{E}\langle\eta_1, \eta_2\rangle)^2}{\mathbb{E}\|\eta_1\|^2 + \mathbb{E}\|\eta_2\|^2 - 2\mathbb{E}\langle\eta_1, \eta_2\rangle} > 0$$

每当 $\mathbb{E}\langle\eta_1, \eta_2\rangle \neq \mathbb{E}\|\eta_2\|^2$, 且

$$Q(1) - Q(w^*) = \frac{(2A + B)^2}{4A} = \frac{(\mathbb{E}\|\eta_1\|^2 - \mathbb{E}\langle\eta_1, \eta_2\rangle)^2}{\mathbb{E}\|\eta_1\|^2 + \mathbb{E}\|\eta_2\|^2 - 2\mathbb{E}\langle\eta_1, \eta_2\rangle} > 0$$

每当 $\mathbb{E}\langle\eta_1, \eta_2\rangle \neq \mathbb{E}\|\eta_1\|^2$ 。因此 $Q(w^*) < \min\{Q(0), Q(1)\}$ 每当 η_1, η_2 并非完全 correlate

Special Case II: No-noise (deterministic) case with bias Assume $\eta_1 = \eta_2 = 0$ (deterministic estimators with bias). Then

$$Q(w) = \|wb_1 + (1-w)b_2\|^2 = \|b_2 + w(b_1 - b_2)\|^2, \quad w \in [0, 1].$$

Write $Q(w) = \alpha w^2 + 2\beta w + \gamma$ with

$$\alpha = \|b_1 - b_2\|^2, \quad \beta = \langle b_2, b_1 - b_2 \rangle, \quad \gamma = \|b_2\|^2.$$

If $b_1 \neq b_2$ then $\alpha > 0$ and the unconstrained minimizer is $w_{\mathbb{R}}^* = -\beta/\alpha$, giving

$$\min_{w \in \mathbb{R}} Q(w) = \gamma - \frac{\beta^2}{\alpha}. \quad \text{因此端点间隙为}$$

$$Q(0) - \min Q = \frac{\beta^2}{\alpha} = \frac{\langle b_2, b_1 - b_2 \rangle^2}{\|b_1 - b_2\|^2} \geq 0, \quad Q(1) - \min Q = \alpha + 2\beta + \frac{\beta^2}{\alpha} = \frac{(\alpha + \beta)^2}{\alpha} \geq 0.$$

因此, 若 $w_{\mathbb{R}}^* \in (0, 1)$ (从而在 $[0, 1]$ 上的约束极小化元等于无约束极小化元), 则有 $Q(w^*) = \min Q < \min\{Q(0), Q(1)\}$, 且严格不等式成立, 除非 $\beta = 0$ (对于 $Q(0)$) 或 $\alpha + \beta = 0$ (对于 $Q(1)$)。若 $w_{\mathbb{R}}^* \notin (0, 1)$, 则约束极小化元位于端点, 且无法在两个端点之上取得严格改进。若 $b_1 = b_2$, 则 $\alpha = 0$ 且 $Q(w) \equiv \|b_1\|^2$ 对所有 w 成立。

关于严格改进的注记。严格改进要求无约束最优解位于 $(0, 1)$ 内。若某个估计器显著优于另一个，则最优权重位于边界上，从而恢复最佳单一估计器的性能。

C 命题 4.2 的证明（分数到样本的稳定性）

证明前的概述。分数到样本稳定性结果的目标是展示分数估计中的误差如何转化为生成轨迹的偏差。形式上，我们将采样视为形如 $\dot{x}(t) = F(t, x(t), s(t, x(t)))$ 的常微分方程，其中分数 s 直接驱动动力学， F 表示经过调度器、参数化或求解器后的变换输出。用估计器 $\hat{s}$ 替换真实分数 s^* 会扰动该向量场，由此产生的轨迹偏差可以被量化。

证明通过分析轨迹差 $e(t) = x_{\hat{s}}(t) - x^*(t)$ 进行。其导数自然分为两项：与 $\|e(t)\|$ 成比例的利普希茨增长分量，以及与分数误差 $\|\hat{s} - s^*\|$ 成比例的强迫分量。这将问题简化为常微分方程的标准稳定性不等式。应用格朗沃尔不等式（Gronwall, 1919; Bellman, 1943）后，得到以积分分数误差表示的轨迹级界。

最后，该稳定性保证与命题 4.1 相联系：由于凸组合在单步层面严格改进分数估计，该界意味着组合策略继承了严格更紧的轨迹偏差界。这为推论 4.1 奠定了基础，该推论将结果整合为 GPC 的轨迹性能保证。

Statement restated. Let $x^*(t)$ 和 $x_{\hat{s}}(t)$ solve

$$\dot{x}^*(t) = F(t, x^*(t), s^*(t, x^*(t))), \quad \dot{x}_{\hat{s}}(t) = F(t, x_{\hat{s}}(t), \hat{s}(t, x_{\hat{s}}(t))),$$

具有相同的 $x(0)$ 。在假设 (A1) – (A2) 下，

$$\tilde{L}(t) := L_x(t) + L_s(t)\hat{\Lambda}(t),$$

对所有 $T \in [0, T]$ ，我们有：

$$\|x_{\hat{s}}(T) - x^*(T)\| \leq \int_0^T \exp\left(\int_t^T \tilde{L}(\tau) d\tau\right) L_s(t) \|\Delta_s(t, x^*(t))\| dt. \quad (12)$$

取期望，应用柯西-施瓦茨不等式和詹森不等式，并利用得分误差界假设，我们得到

$$\mathbb{E}\|x_{\hat{s}}(T) - x^*(T)\| \leq \left(\int_0^T e^{2\int_t^T \tilde{L}(\tau) d\tau} L_s(t)^2 dt \right)^{1/2} \left(\int_0^T \kappa(t)^2 dt \right)^{1/2}, \quad (13)$$

其中 $\kappa(t)$ 是一个非负函数 $\kappa(t)$ ，使得对所有 x ，

$$\|\Delta_s(t, x)\| \leq \kappa(t).$$

(i.e. 得分误差界假设)。详细证明如下。

A. 绝对连续性与误差微分不等式

Let $e(t) := x_{\hat{s}}(t) - x^*(t)$. we have

$$e'(t) = F(t, x_{\hat{s}}(t), \hat{s}(t, x_{\hat{s}}(t))) - F(t, x^*(t), s^*(t, x^*(t))) \quad \text{for a.e. } t. \quad (14)$$

插入并减去两个中间项以分离 x 和 s 的贡献：

$$\|e'(t)\| \leq \|F(t, x_{\hat{s}}, \hat{s}(t, x_{\hat{s}})) - F(t, x_{\hat{s}}, \hat{s}(t, x^*))\| \quad (15)$$

$$+ \|F(t, x_{\hat{s}}, \hat{s}(t, x^*)) - F(t, x_{\hat{s}}, s^*(t, x^*))\| \quad (16)$$

$$+ \|F(t, x_{\hat{s}}, s^*(t, x^*)) - F(t, x^*, s^*(t, x^*))\|. \quad (17)$$

根据 (A1), 第一个 (15) 和第二个 (16) 方程分别由 $L_s(t)\|\hat{s}(t, x_s) - \hat{s}(t, x^*)\|$ 和 $L_s(t)\|\hat{s}(t, x^*) - s^*(t, x^*)\|$ 界定; 第三个方程 17 由 $L_x(t)\|x_s - x^*\| = L_x(t)\|e(t)\|$ 界定。利用 (A2) 中 $\hat{s}$ 的 x -利普希茨连续性,

$$\|\hat{s}(t, x_s) - \hat{s}(t, x^*)\| \leq \hat{\Lambda}(t) \|e(t)\|.$$

Therefore,

$$\|e'(t)\| \leq \underbrace{(L_x(t) + L_s(t)\hat{\Lambda}(t))}_{:=\tilde{L}(t)} \|e(t)\| + L_s(t) \|\Delta_s(t, x^*(t))\|. \quad (18)$$

B. FROM $\|e'(t)\|$ TO $\phi'(t)$

令 $\phi(t) := \|e(t)\|$ 。根据方程 9, ϕ 是绝对连续的, 且

$$\phi'(t) \leq \|e'(t)\| \quad \text{for a.e. } t.$$

结合方程 18 可得标量微分不等式

$$\phi'(t) \leq \tilde{L}(t) \phi(t) + L_s(t) \|\Delta_s(t, x^*(t))\| \quad \text{for a.e. } t, \quad \phi(0) = 0. \quad (19)$$

C. 格朗沃尔 (积分因子) 与逐路径界

Define $A(t) := \int_0^t \tilde{L}(\tau) d\tau$ 和 $g(t) := e^{-A(t)} \phi(t)$. Then a.e.

$$g'(t) = e^{-A(t)} (\phi'(t) - \tilde{L}(t)\phi(t)) \leq e^{-A(t)} L_s(t) \|\Delta_s(t, x^*(t))\|.$$

从 0 积分到 T ; 由于 $\phi(0) = 0$ (相同初始条件), 我们有 $g(0) = 0$:

$$g(T) \leq \int_0^T e^{-A(t)} L_s(t) \|\Delta_s(t, x^*(t))\| dt.$$

乘以 $e^{A(T)}$:

$$\phi(T) = e^{A(T)} g(T) \leq \int_0^T e^{A(T)-A(t)} L_s(t) \|\Delta_s(t, x^*(t))\| dt.$$

Since $A(T) - A(t) = \int_t^T \tilde{L}(\tau) d\tau$, the bound

$$\phi(T) = \|e(T)\| \leq \int_0^T \exp\left(\int_t^T \tilde{L}(\tau) d\tau\right) L_s(t) \|\Delta_s(t, x^*(t))\| dt \quad (20)$$

由此可得, 这正是方程 12。

D. 期望与可读上界

首先对逐路径界方程 20 取期望:

$$\mathbb{E}\|e(T)\| = \mathbb{E}\left[\int_0^T e^{\int_t^T \tilde{L}(\tau) d\tau} L_s(t) \|\Delta_s(t, x^*(t))\| dt\right].$$

记号。期望 $\mathbb{E}[\cdot]$ 是对初始条件的随机性取的。这已经

提供了一个有效 (且紧致) 的期望界。在下文中, 我们通过应用经典不等式给出一个稍显宽松但更清晰的形式, 该形式更易于阅读和实际应用。

根据托内利定理 (非负被积函数) (Fubini, 1907; Tonelli, 1909):

$$= \int_0^T e^{\int_t^T \tilde{L}(\tau) d\tau} L_s(t) \mathbb{E}\|\Delta_s(t, x^*(t))\| dt.$$

Apply Cauchy-Schwarz (Cauchy, 1821) in $L^2([0, T])$:

$$\int_0^T W(t) \mathbb{E}\|\Delta_s(t, x^*(t))\| dt \leq \left(\int_0^T W(t)^2 dt\right)^{1/2} \left(\int_0^T (\mathbb{E}\|\Delta_s(t, x^*(t))\|)^2 dt\right)^{1/2},$$

其中

$$W(t) := e^{\int_t^T \tilde{L}(\tau) d\tau} L_s(t).$$

对 $(\mathbb{E} \|\Delta_s\|)^2 \leq \mathbb{E} \|\Delta_s\|^2$ 使用詹森不等式 (Jensen, 1906) 可得

$$(\mathbb{E} \|\Delta_s(t, x^*(t))\|)^2 \leq \mathbb{E} \|\Delta_s(t, x^*(t))\|^2.$$

可读的期望界。综合以上结果可得

$$\mathbb{E} \|e(T)\| \leq \left(\int_0^T e^{2 \int_t^T \tilde{L}(\tau) d\tau} L_s(t)^2 dt \right)^{1/2} \left(\int_0^T \mathbb{E} \|\Delta_s(t, x^*(t))\|^2 dt \right)^{1/2} \quad (21)$$

关于评分误差的假设。利用评分误差界的假设，该假设保证

$\|\Delta_s(t, x)\| \leq \kappa(t)$ 对于所有 x , then

$$\mathbb{E} \|e(T)\| \leq \left(\int_0^T e^{2 \int_t^T \tilde{L}(\tau) d\tau} L_s(t)^2 dt \right)^{1/2} \left(\int_0^T \kappa(t)^2 dt \right)^{1/2}.$$

这正是方程 13 以及命题 4.2 的结果。 $\square$

D 推论 4.1 的证明 (GPC 收紧终端界)

陈述重述。设 $\mathcal{B}(\hat{s})$ 表示命题 4.2 中推导出的期望采样误差的上界。若一个凸组合 $s_{\text{comp}} = ws_1 + (1-w)s_2$ 满足

$$\int_0^T \mathbb{E} \|s_{\text{comp}} - s^*\|^2 dt < \min_i \int_0^T \mathbb{E} \|s_i - s^*\|^2 dt,$$

则相应的理论误差界被严格减小:

$$\mathcal{B}(s_{\text{comp}}) < \min_i \mathcal{B}(s_i).$$

证明: 由命题 4.2, 任意估计器 $\hat{s}$ 的期望轨迹误差有界为:

$$\mathbb{E} \|x_{\hat{s}}(T) - x^*(T)\| \leq \mathcal{B}(\hat{s}) := \left(\int_0^T e^{2 \int_t^T \tilde{L}(\tau) d\tau} L_s(t)^2 dt \right)^{1/2} \cdot \left(\int_0^T \mathbb{E} \|\hat{s} - s^*\|^2 dt \right)^{1/2},$$

其中 $\left(\int_0^T e^{2 \int_t^T \tilde{L}(\tau) d\tau} L_s(t)^2 dt \right)^{1/2} > 0$ 是一个与分数无关的系统相关常数

估计器。界函数 $\mathcal{B}(\cdot)$ 关于积分均方误差 (MSE) 严格单调递增。由于前提表明复合得分 s_{comp} 的积分均方误差严格小于各单独估计器 s_i 的积分均方误差, 因此立即得到:

$$\mathcal{B}(s_{\text{comp}}) < \min_i \mathcal{B}(s_i).$$

因此, 凸得分复合严格收紧了轨迹仿真误差的理论保证。 $\square$

E 详细工具: 范数导数、积分因子与不等式

E.1 范数导数不等式

设 $e : [0, T] \rightarrow \mathbb{R}^d$ 为绝对连续函数。定义 $\phi(t) = \|e(t)\|$ 。我们证明 ϕ 是绝对连续

() $\leq \|e'(t)\|$ 对几乎处处成立。 t 的, 并且

Absolute continuity. Since $e(t) = e(0) + \int_0^t e'(\tau) d\tau$ 满足 $e' \in L^1$ ，且范数是 1-利普希茨的， ϕ 是绝对连续的。

差商证明。 固定一点，其中 e' 存在。则

$$\frac{\phi(t+h) - \phi(t)}{h} = \frac{\|e(t+h)\| - \|e(t)\|}{h} \leq \frac{\|e(t+h) - e(t)\|}{h}.$$

取 $h \rightarrow 0$ 得到 $\phi'(t) \leq \|e'(t)\|$ 。这对几乎处处的 t 成立。

链式法则证明 (当 $e(t) \neq 0$). 对 $g(x) = \|x\|$, $\nabla g(x) = x/\|x\|$ when $x \neq 0$. Then

$$\phi'(t) = \langle \nabla g(e(t)), e'(t) \rangle = \left\langle \frac{e(t)}{\|e(t)\|}, e'(t) \right\rangle \leq \|e'(t)\|.$$

在 $e(t) = 0$ 存在的点处，使用上述差商论证。

E.2 积分因子

从 $\phi'(t) \leq a(t)\phi(t) + b(t)$ 含 $\phi(0) = 0$ 和 $a, b \in L^1$, define $A(t) = \int_0^t a(\tau) d\tau$ 和 $g(t) = e^{-A(t)}\phi(t)$. Then

$$g'(t) = e^{-A(t)}(\phi'(t) - a(t)\phi(t)) \leq e^{-A(t)}b(t).$$

积分:

$$g(T) \leq \int_0^T e^{-A(t)}b(t) dt \Rightarrow \phi(T) \leq \int_0^T e^{A(T)-A(t)}b(t) dt.$$

Since $A(T) - A(t) \leq \int_0^T a$, a looser bound is $\phi(T) \leq e^{\int_0^T a} \int_0^T b(t) dt$.

E.3 托内利、柯西 - 施瓦茨与詹森

给定 $\Omega \times [0, T]$ 上的非负被积函数 $H(\omega, t)$ ，托内利定理表明

$$\mathbb{E} \left[\int_0^T H(\omega, t) dt \right] = \int_0^T \mathbb{E}[H(\omega, t)] dt.$$

对于函数 $f, g \in L^2([0, T])$, $\int_0^T fg \leq \|f\|_2 \|g\|_2$ 。对于随机变量 Z ，詹森不等式给出 $(\mathbb{E}\|Z\|)^2 \leq \mathbb{E}\|Z\|^2$ 。

F 命题与推论如何衔接

命题 4.1 在温和且可检验的条件下（异质模型降低互相关性并分散偏差）保证了凸权重（通常为内部点）的存在，从而降低得分均方误差。命题 4.2 将（时间积分的）得分均方误差的任何降低转化为非渐近终端误差界的收紧。推论 4.1 仅将二者结合：一旦函数层面的不等式严格成立，经认证的采样界便相应收紧。

G 广义预测校正 (GPC) 对任意预测类型的灵活性

通用策略组合 (General Policy Composition, GPC) 的一个关键优势在于其灵活性, 并且不依赖于用于训练底层扩散或流匹配策略的具体参数化方式。GPC 的基本原理是对数据分布的底层得分函数进行组合, $s_\theta(\tau_t, t) = \nabla_{\tau_t} \log p_t(\tau_t)$ 。常见的参数化方式, 如噪声预测、数据预测和 $\mathbf{v}$ 预测, 在数学上都可以相互转换, 并且表示同一个底层得分函数。这确保了 GPC 能够无缝组合使用不同预测目标训练的策略, 而无需额外训练。

让我们形式化这些参数化之间的关系。扩散前向过程定义了时间 t 处从初始轨迹 τ_0 和高斯噪声样本 $\epsilon \sim \mathcal{N}(0, I)$ 得到的含噪轨迹 τ_t :

$$\tau_t = \alpha_t \tau_0 + \sigma_t \epsilon, \quad (22)$$

其中 α_t 和 σ_t 是与调度相关的系数。

得分预测 (s -预测)。这种参数化方式直接对得分函数进行建模。得分与噪声 ϵ 通过以下恒等式相关联 (Song 等人, 2020b):

$$s(\tau_t, t) = \nabla_{\tau_t} \log p_t(\tau_t) = -\frac{\epsilon}{\sigma_t}. \quad (23)$$

组合得分是 GPC 的核心。任何其他参数化方式都可以在组合之前转换为得分。

噪声预测 (ϵ -预测)。这是最常用的参数化方式, 用于最初的 DDPM (Ho 等人, 2020)。模型 $\epsilon_\theta(\tau_t, t)$ 被训练来预测噪声 ϵ 。基于噪声预测训练的模型可以转换为得分预测模型:

$$s_\theta(\tau_t, t) = -\frac{\epsilon_\theta(\tau_t, t)}{\sigma_t}. \quad (24)$$

由于该关系是线性的, 用权重 w_i 组合预测噪声等价于用相同权重组合分数。

数据预测 (τ_0 -预测)。该参数化训练模型 $(\tau_0)_\theta(\tau_t, t)$ 从噪声输入 τ_t 中预测原始干净数据 τ_0 。预测噪声 ϵ 可通过前向过程定义从预测数据中恢复:

$$\epsilon_\theta(\tau_t, t) = \frac{\tau_t - \alpha_t (\tau_0)_\theta(\tau_t, t)}{\sigma_t}. \quad (25)$$

这使得数据预测策略能够转换为分数或噪声表示以进行组合。

速度预测 ($\mathbf{v}$ -预测)。由 (Salimans & Ho, 2022) 提出, $\mathbf{v}$ -预测提供了更好的数值稳定性。目标 $\mathbf{v}$ 定义为 $\mathbf{v} = \alpha_t \epsilon - \sigma_t \tau_0$ 。训练模型 $\mathbf{v}_\theta(\tau_t, t)$ 来预测该目标。我们可以通过以下方式从 $\mathbf{v}$ -预测模型的输出中恢复噪声 ϵ :

$$\epsilon_\theta(\tau_t, t) = \alpha_t \mathbf{v}_\theta(\tau_t, t) + \sigma_t \tau_t. \quad (26)$$

由此可以计算出等效分数。

对通用策略组合 (GPC) 的启示。这些参数化之间的可互换性正是使 GPC 具备“求解器无关性”的原因。假设我们想要组合两个策略, π_1 和 π_2 。如果 π_1 使用噪声预测进行训练 (输出 ϵ_θ^1), 而 π_2 使用 $\mathbf{v}$ 预测进行训练 (输出 $\mathbf{v}_\theta^2$), 我们可以先将它们的输出转换为一种通用表示, 然后进行组合。

例如, 我们可以将两者都转换为分数表示:

$$s_\theta^1(\tau_t, t) = -\frac{\epsilon_\theta^1(\tau_t, t)}{\sigma_t} \quad (27)$$

$$s_\theta^2(\tau_t, t) = -\frac{\alpha_t \mathbf{v}_\theta^2(\tau_t, t) + \sigma_t \tau_t}{\sigma_t} \quad (28)$$

然后，我们可以在分数空间中执行凸组合：

$$s_{\text{comp}} = w_1 s_{\theta}^1 + w_2 s_{\theta}^2. \quad (29)$$

这个组合后的分数 s_{comp} 随后可用于任何标准的 ODE/SDE 求解器步骤，以生成 τ_{t-1} 下一个状态。

或者，在实践中通常更直接的方法是，在组合之前将所有输出转换为噪声（ ϵ ）表示，由于分数与噪声之间的线性关系，这会产生等价的结果。这种灵活性使 GPC 能够作为一个通用的即插即用模块，用于组合各种预训练的基于扩散或基于流的策略，无论它们的具体训练目标或参数化方式如何。

H 关于 GPC 成功原因的深入分析

直观上，GPC 可以被视为形成一种专家乘积分布：组合分数是各个分数的凸组合，对应于它们概率密度的（重新加权的）乘积。对某个策略赋予更高的权重仅仅意味着其密度对最终目标分布的贡献更强，从而将概率质量集中在两个专家都认为可能的轨迹上。

H.1 理论视角：为什么凸分数组合可能更好

优于单一策略 基于命题 4.1，我们证明在每个扩散时间步存在一个凸权重 w^* ，使得组合得分相对于理想得分 s^* 的误差小于任何单一策略。命题 4.2 将此从单步扩展到整个去噪轨迹：若每一步组合得分更接近 s^* ，则整个轨迹上的误差累积更有利，导致轨迹分布更接近理想分布。换言之，一旦建立了逐步得分质量的改进，生成过程的稳定性使这一优势沿整个轨迹传播，使凸得分组合在可证明意义上优于依赖单一策略。

H.2 经验视角：什么驱动某些组合获得更大收益

在高层次上，我们将 GPC 视为一种将不同基础策略学到的“良好知识”聚合到单一、更高似然目标分布的方法，从而从组合得分采样产生的轨迹质量高于从任何单一策略单独采样。在实践中，什么算作“良好知识”受几个因素影响：

互补模态提供更丰富的信息。当 GPC 组合在不同模态上训练的策略（*e.g.*，即 RGB 与点云）时，组合得分有效利用场景的互补视图：RGB 捕获外观、纹理和颜色线索，而点云提供精确的三维几何和深度结构。与单独使用任一模态相比，这种多模态融合减少了感知模糊性，可视为增加了组合策略可用的“信息丰富度”。DP+DP3 组合是这一点的良好示例，图 5(a) 中其样本分布的可视化支持这一解释。

多样化的架构捕获不同的归纳偏置。即使策略共享相同的输入模态，不同的架构也能编码不同的归纳偏置和误差模式。例如， π_0 基于 DiT，而 Flow Policy 使用 U-Net 风格的主干网络。它们可能建模相似的底层动作分布，但强调数据中的不同结构。GPC 可以通过聚合它们的优势同时平均掉特有弱点来利用这种多样性，这反映在性能改进和图 5(b) 的定性分析中。

任务特定的优势塑造组合收益。任务选择也很重要：在某些任务中，某个基础策略可能明显较弱。在这种情况下，朴素平均（或不平衡的权重）会让较弱的策略拖累整体性能。我们在第 6.3 节（发现 3）中的分析表明，当性能较好的基础策略获得更大权重时，GPC 表现最佳，这在任务难度或不匹配对某个策略的影响大于另一个策略时尤为重要。因此，任务特定的策略强度以及调整权重的能力是观察到的增益背后的关键因素。

权重选择在组合分布中很重要。我们的理论保证了最优权重 w^* 的存在，但在实践中，GPC 仍然需要选择具体的权重。这些权重控制着每个基础分布对最终组合分布的贡献程度，因此直接影响有多少概率质量被分配到高质量轨迹上。这就是我们进行大量权重扫描研究的原因：展示不同权重如何影响性能，并为实际部署中的权重选择提供经验指导。我们将设计更好的、可能具有自适应性的策略来逼近 w^* 视为未来工作的重要方向。

I 实验细节

I.1 ROBOMIMIC

Robomimic 基准 (Mandlekar 等人, 2022) 包含三个操作任务: Can、Lift 和 Square。我们以批大小 1024 训练所有基线, 共 1000 个训练轮次。训练使用 DDIM 采样, 采用缩放线性 beta 调度器和 epsilon 预测。扩散步数在训练时设为 100, 推理时设为 10。每个模型使用观测范围=2 和块大小=16 进行训练。评估在 20 个并行环境中进行, 每个环境运行 10 个回合, 总共 200 次 rollout。Robomimic 的原始代码来自 <https://github.com/ARISE-Initiative/robomimic>。我们基于 <https://github.com/EDiRobotics/mimictest> 中的代码复现了基线。

I.2 PUSH T

PushT 基准 (Florence 等人, 2021) 涉及在二维工作空间中的平面推动。这里, 训练使用批大小 256, 运行 500 个训练轮次, 所有其他参数与 Robomimic 保持一致。评估遵循相同的 200 次 rollout 协议。Robomimic 的原始代码来自 https://github.com/real-stanford/diffusion_policy 和 <https://github.com/google-research/ibc>。我们基于 <https://github.com/EDiRobotics/mimictest> 中的代码复现了基线。

I.3 机器人孪生 (RoboTwin)

机器人孪生 (RoboTwin) (Mu 等人, 2025) 是一个双臂操作基准, 结合了真实世界遥操作演示与高保真合成数据, 为研究大规模操作学习提供了标准化平台。扩展版机器人孪生 2.0 (RoboTwin 2.0) (Chen 等人, 2025) 涵盖超过 50 项任务, 支持多样且复杂的场景。基线基于 <https://github.com/RoboTwin-Platform/RoboTwin/tree/RoboTwin-1.0> 和 <https://github.com/RoboTwin-Platform/RoboTwin/tree/main> 的代码复现。每项任务的成功率由 100 次 rollout 确定。

在我们的实验中, 我们在一个精选的任务子集上进行评估:

- 机器人孪生 1.0 (RoboTwin 1.0): 空杯放置、双瓶抓取 (困难)、双瓶抓取 (简单)、鞋子放置、双鞋放置、杂乱苹果抓取、积木锤击打。
- 机器人孪生 2.0 (RoboTwin 2.0): 挂马克杯、打开笔记本电脑、放置汉堡薯条、将物体放入柜子、堆叠碗、三向旋转开关。

DPimg 和 DPpcd 分别对应基于 RGB 图像的扩散策略 (*i.e.*, DP (Chi 等人, 2023) 和基于点云的扩散策略 (*i.e.*, DP3 (Ze et al., 2024b))。在机器人孪生 1.0 (RoboTwin 1.0) 中, 我们使用随机种子 0 复现了 DPimg 和 DPpcd (不使用点云颜色)。由于不同策略的扩散分数在每个去噪步骤中组合 (算法 1), 我们统一了 DPpcd 和 DPimg 的训练设置。具体而言, 它们使用 DDPM 进行训练, 训练和推理步骤均为 100 步。在机器人孪生 2.0 (RoboTwin 2.0) 实验中, 我们使用与 RDT 相同的设置训练 DP, 以确保兼容性, 从而使我们的 GPC 能够一致地应用。例如, RDT 采用样本预测, 我们通过在单一预测设置下训练 DPimg 和 DPpcd 来相应地调整我们的扩散模型。

机器人孪生 (RoboTwin) 中的任务提示。这里我们为 VLA 提供详细的文本描述及其对应的文本提示。例如, 对于放置汉堡任务, 任务描述和模式为:

- **完整描述:** “使用双臂拿起汉堡和薯条, 并将它们放到托盘上。”
- **模式:** “A 表示汉堡, B 表示托盘, C 表示薯条”

在训练过程中, 视觉-语言-动作模型 (VLA) 会接收到该任务的多种改写提示, 例如:

- “使用双臂将 A 和 C 移动到 B。”




图 7：实验设置示意图。




图 8：放置瓶子真实世界实验的跟踪结果。

- “将 A 和 C 提起，整齐地放在 B 上”

在测试时，我们使用具有相同模式但未见过的改写句，*e.g.*:

- “拿起 A 和 C，然后将它们放在 B 上。”
- “一起抓住 A 和 C，将它们放在 B 上。”

I.4 真实世界实验

我们选择 DPimg 和 DPpcd 作为真实世界实验的基础策略。对于 DPimg，我们使用分辨率为 640×480 的英特尔实感 D435 RGB 相机（主视图和腕部视图）获取 RGB 图像。对于 DPpcd，我们使用分辨率为 640×480 的英特尔实感 L515 深度相机，通过深度图像结合相机内参获得点云。机器人平台为 Piper，采用主从式遥控操作设置。真实世界实验设置的示意图如图 7 所示。与基础策略相比，我们的 GPC 实现了更优越的性能，

在图 8 中展示了更好的轨迹。训练遵循官方配置：DP_{pcd} 训练 600 个训练轮次，批大小为 256（官方代码），而 DP_{img} 训练 20k 步，批大小为 64（Lerobot（Cadene 等人，2024）扩散实现）。

I.5 GPC 灵活性的符号表示

值得注意的是，扩散模型中的预测类型并不严格局限于单一形式（*e.g.*, ϵ 预测、 x_0 预测或 v 预测），而是可以在我们的框架内自由组合。当同时采用异构预测类型时，去噪过程需要适当的对齐以确保一致性。我们在第 G 节中从理论角度详细指导如何在 GPC 中协调不同的预测类型，进一步证明了所提方法的灵活性。

J 补充实验结果

在本节中，我们提供完整的实验结果以补充正文。这些结果包括凸分数组合的所有权重配置，以及逻辑与和逻辑或操作下的结果。

Robomimic 和 PushT。我们报告了 Robomimic（Can、Lift、Square）和 PushT 任务的详细结果。除了正文中报告的平均性能外，我们还包括（i）凸分数组合、逻辑与和逻辑或组合的完整表格（表 10），以及（ii）每个任务在不同凸权重 w 下的性能分解：Can（表 11 和图 9）、Square（表 13 和图 10）、Lift（表 12 和图 11）和 PushT（表 14 和图 12）。这些结果说明了 GPC 如何适应不同的权重配置，并提供了关于模态和模型骨干之间权衡的洞见。

RoboTwin。我们还提供了 RoboTwin 2.0 在所有任务上的完整结果。特别是，我们包括比较基础策略及其组合（*e.g.*, DP_{img} + DP_{pcd}、RDT + DP_{pcd}）的完整表格，以及所有测试的权重设置：Open Laptop（表 15）、Place Burger（表 16 和图 21）、Put Object Cabinet（表 17 和图 24）、Hanging Mug（表 18 和图 23）、Stack Bowls Three（表 19 和图 14）和 Turn Switch（表 20 和图 20）。这些详细数字证实了 GPC 在各种操作任务上的鲁棒性，并进一步验证了第 6 节中的发现。

真实世界实验。我们进一步报告了四个真实世界任务的完整结果：放置瓶子（表 21 和图 27）、挂杯子（表 22 和图 26）、清洁桌子（表 23 和图 25）和打孔（表 24 和图 28）。与仿真基准类似，我们在所有测试的权重设置下，提供了基础策略与其 GPC 组合之间的完整比较。这些结果一致表明，GPC 比单个策略获得更高的成功率，从而证实了其在实际机器人场景中的有效性。

总结。这些扩展结果共同提供了 GPC 在不同算子和权重下经验行为的全面视图。它们可作为参考，不仅用于理解平均改进，还用于理解性能对权重选择和组合策略的敏感性。

表 10: 在凸分数组合、逻辑与和逻辑或下, GPC 在 Robomimic 和 PushT 上的实验。

Method	Generative Mode	Model Type	Robomimic			PushT	
			Can	Lift	Square	PushT	Average
Base Policies							
Diffusion Policy (DP)	Diffusion	VA	34.50	98.50	2.00	21.75	39.19
Mamba Policy (MP)	Flow Matching	VA	5.00	98.50	3.00	12.06	29.64
Flow Policy (FP)	Diffusion	VA	95.00	13.00	77.50	54.25	59.94
Florence Policy-D	Diffusion	VLA	61.50	97.00	46.50	40.00	61.25
Florence Policy-F	Flow Matching	VLA	89.00	98.50	88.50	39.38	78.84
π_0	Flow Matching	VLA	96.50	99.00	92.50	57.69	86.42
Composed Policies via Convex Score Combination							
DP+MP	Diffusion	VA & VA	34.50	99.50	8.00	23.63	41.41 +2.22
Florence-Policy-D+DP	Diffusion	VLA & VA	62.50	100.00	61.50	43.06	66.76 +5.51
Florence-Policy-D+MP	Diffusion	VLA & VA	63.00	100.00	54.50	40.88	64.60 +3.35
Florence-Policy-F+FP	Flow Matching	VLA & VA	98.50	98.50	92.50	56.06	86.39 +7.55
π_0 +FP	Flow Matching	VLA & VA	99.50	100.00	94.00	62.25	88.94 +2.52
Composed Policies via Logical AND Composition							
DP+MP	Diffusion	VA & VA	84.00	99.50	48.00	28.18	64.92 +25.73
Florence-Policy-D+DP	Diffusion	VLA & VA	90.50	100.00	90.00	36.31	79.20 +17.95
Florence-Policy-D+MP	Diffusion	VLA & VA	83.00	100.00	90.00	37.38	77.60 +16.35
Composed Policies via Logical OR Composition							
DP+MP	Diffusion	VA & VA	82.50	99.50	44.00	29.13	63.78 +24.59
Florence-Policy-D+DP	Diffusion	VLA & VA	83.50	100.00	89.00	37.87	77.59 +16.34
Florence-Policy-D+MP	Diffusion	VLA & VA	86.50	100.00	86.50	38.44	77.86 +16.61

表 11: 不同权重下 GPC 在 Robomimic Can 上的实验。

Method	Generative Mode	Model Type	Can										
			0.0	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9	1.0
DP+Mamba Policy	Diffusion	VA & VA	5.00	10.00	10.50	10.50	16.50	20.00	20.00	23.00	25.00	29.00	34.50
Florence DiT + DP	Diffusion	VLA & VA	34.50	34.50	42.50	48.00	56.00	62.50	60.50	63.50	58.00	62.50	61.50
Florence DiT + MambaP	Diffusion	VLA & VA	5.00	11.50	21.50	30.50	39.00	44.50	47.50	46.50	63.00	61.50	61.50
Florence Flow+FlowP	Flow Matching	VLA & VA	95.00	98.50	98.50	96.00	96.50	97.00	93.00	92.00	90.00	90.50	89.00
π_0 +FlowP	Flow Matching	VLA & VA	95.00	96.00	99.00	98.00	97.50	98.50	99.50	98.00	96.00	96.00	96.50

表 12: 不同权重下 GPC 在 Robomimic Lift 上的实验。

Method	Generative Mode	Model Type	Lift										
			0.0	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9	1.0
DP+Mamba Policy	Diffusion	VA & VA	98.50	99.00	99.50	96.50	99.00	98.50	98.50	98.50	98.50	98.50	98.50
Florence DiT + DP	Diffusion	VLA & VA	98.50	99.50	99.00	100.00	99.50	99.50	99.50	99.50	99.50	98.00	97.00
Florence DiT + MambaP	Diffusion	VLA & VA	98.50	100.00	99.50	99.00	99.50	99.00	99.00	97.50	98.50	97.00	97.00
Florence Flow+FlowP	Flow Matching	VLA & VA	13.00	10.50	12.50	23.50	55.00	81.50	93.00	98.00	100.00	98.50	98.50
π_0 +FlowP	Flow Matching	VLA & VA	13.00	12.50	17.00	32.50	67.50	92.50	98.50	100.00	100.00	99.50	99.00

表 13: 不同权重下 GPC 在 Robomimic Square 上的实验。

Method	Generative Mode	Model Type	Square										
			0.0	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9	1.0
DP+Mamba Policy	Diffusion	VA & VA	3.00	3.00	4.00	1.50	8.00	4.50	6.00	6.00	3.50	7.50	2.00
Florence DiT + DP	Diffusion	VLA & VA	2.00	12.50	20.00	34.00	44.00	49.00	61.50	57.00	59.50	54.50	46.50
Florence DiT + MambaP	Diffusion	VLA & VA	3.00	8.00	8.50	17.00	22.00	34.00	45.00	45.50	50.00	54.50	46.50
Florence Flow+FlowP	Flow Matching	VLA & VA	77.50	79.00	85.00	92.00	92.00	92.00	91.00	88.00	88.50	92.50	88.50
π_0 +FlowP	Flow Matching	VLA & VA	77.50	80.50	84.50	94.00	93.50	94.00	93.50	93.00	90.50	93.50	92.50

表 14: 不同权重下 GPC 在 PushT 上的实验。

Method	Generative Mode	Model Type	PushT										
			0.0	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9	1.0
DP+Mamba Policy	Diffusion	VA & VA	12.06	19.81	18.31	18.87	19.94	19.88	18.13	21.50	23.63	22.38	21.75
Florence DiT + DP	Diffusion	VLA & VA	21.75	26.75	29.38	32.75	36.06	39.69	41.13	43.06	40.50	40.56	40.00
Florence DiT + MambaP	Diffusion	VLA & VA	12.06	22.88	25.81	30.62	33.94	37.00	38.44	40.50	40.75	40.88	40.00
Florence Flow+FlowP	Flow Matching	VLA & VA	54.25	56.06	54.50	50.81	47.38	48.31	47.69	50.50	46.19	40.75	39.38
$\pi 0$ +FlowP	Flow Matching	VLA & VA	54.25	54.31	56.81	56.37	53.31	57.69	59.12	61.50	62.25	61.50	57.69

表 15: 不同权重下 RoboTwin 打开笔记本电脑任务中 GPC 的实验结果。

Method	Generative Mode	Model Type	RoboTwin: Open Laptop										
			0.0	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9	1.0
DP+DP3	Diffusion	VA & VA	0.93	0.93	0.92	0.93	0.93	0.87	0.84	0.79	0.77	0.74	0.74
RDT + DP	Diffusion	VLA & VA	0.74	0.74	0.77	0.78	0.79	0.80	0.75	0.76	0.73	0.68	0.69
RDT + DP3	Diffusion	VLA & VA	0.93	0.92	0.92	0.91	0.92	0.94	0.91	0.86	0.77	0.67	0.69

表 16: 不同权重下 RoboTwin 放置汉堡薯条任务中 GPC 的实验结果。

Method	Generative Mode	Model Type	RoboTwin: Place Burger Fries										
			0.0	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9	1.0
DP+DP3	Diffusion	VA & VA	0.72	0.73	0.78	0.74	0.72	0.65	0.68	0.64	0.66	0.54	0.49
RDT + DP	Diffusion	VLA & VA	0.49	0.54	0.56	0.57	0.53	0.49	0.50	0.48	0.45	0.45	0.46
RDT + DP3	Diffusion	VLA & VA	0.72	0.79	0.83	0.83	0.77	0.78	0.72	0.67	0.67	0.55	0.46

表 17: 不同权重下 RoboTwin 将物体放入柜子任务中 GPC 的实验结果。

Method	Generative Mode	Model Type	RoboTwin: Put Object Cabinet										
			0.0	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9	1.0
DP+DP3	Diffusion	VA & VA	0.71	0.80	0.82	0.73	0.66	0.73	0.63	0.67	0.67	0.55	0.56
RDT + DP	Diffusion	VLA & VA	0.56	0.54	0.59	0.54	0.51	0.52	0.40	0.35	0.27	0.32	0.32
RDT + DP3	Diffusion	VLA & VA	0.71	0.71	0.78	0.71	0.69	0.61	0.58	0.46	0.37	0.40	0.32

表 18: 不同权重下 RoboTwin 悬挂马克杯任务中 GPC 的实验结果。

Method	Generative Mode	Model Type	RoboTwin: Hanging Mug										
			0.0	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9	1.0
DP+DP3	Diffusion	VA & VA	0.21	0.23	0.20	0.22	0.18	0.17	0.16	0.11	0.15	0.11	0.10
RDT + DP	Diffusion	VLA & VA	0.10	0.13	0.09	0.15	0.11	0.18	0.18	0.15	0.14	0.12	0.13
RDT + DP3	Diffusion	VLA & VA	0.21	0.26	0.31	0.30	0.36	0.25	0.25	0.22	0.24	0.15	0.13

表 19: 不同权重下 RoboTwin 堆叠三个碗任务中 GPC 的实验结果。

Method	Generative Mode	Model Type	RoboTwin: Stack Bowls Three										
			0.0	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9	1.0
DP+DP3	Diffusion	VA & VA	0.64	0.70	0.66	0.71	0.60	0.53	0.63	0.56	0.59	0.49	0.52
RDT + DP	Diffusion	VLA & VA	0.52	0.65	0.66	0.57	0.66	0.59	0.58	0.50	0.40	0.32	0.47
RDT + DP3	Diffusion	VLA & VA	0.64	0.71	0.73	0.55	0.71	0.70	0.60	0.59	0.48	0.42	0.47

表 20: 不同权重下 RoboTwin 转动开关任务中 GPC 的实验结果。

Method	Generative Mode	Model Type	RoboTwin: Turn Switch										
			0.0	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9	1.0
DP+DP3	Diffusion	VA & VA	0.71	0.68	0.60	0.63	0.67	0.56	0.50	0.45	0.41	0.42	0.38
RDT + DP	Diffusion	VLA & VA	0.38	0.28	0.31	0.28	0.36	0.37	0.34	0.30	0.38	0.35	0.30
RDT + DP3	Diffusion	VLA & VA	0.71	0.52	0.54	0.48	0.51	0.59	0.51	0.43	0.42	0.45	0.30

表 21: 不同权重下真实世界放置瓶子任务中 GPC 的实验结果。

Method	Generative Mode	Model Type	Real-world: Place Bottle					
			0.0	0.2	0.4	0.6	0.8	1.0
DP+DP3	Diffusion	VA & VA	11/20	13/20	11/20	12/20	10/20	7/20

表 22: 不同权重下真实世界悬挂马克杯任务中 GPC 的实验结果。

Method	Generative Mode	Model Type	Real-world: Hang Mug					
			0.0	0.2	0.4	0.6	0.8	1.0
DP+DP3	Diffusion	VA & VA	6/20	7/20	5/20	7/20	6/20	5/20

表 23: 不同权重下真实世界清洁桌面使用 GPC 的实验。

Method	Generative Mode	Model Type	Real-world: Clean Table					
			0.0	0.2	0.4	0.6	0.8	1.0
DP+DP3	Diffusion	VA & VA	7/20	7/20	14/20	10/20	12/20	12/20

表 24: 不同权重下真实世界打孔使用 GPC 的实验。

Method	Generative Mode	Model Type	Real-world: Punch Holes					
			0.0	0.2	0.4	0.6	0.8	1.0
DP+DP3	Diffusion	VA & VA	6/20	6/20	5/20	7/20	9/20	7/20

K 机器人任务可视化




图 9: Robomimic Can 任务示意图。



图 10: Robomimic Square 任务示意图。




图 11: Robomimic Lift 任务示意图。



图 12: PushT 任务示意图。




图 13: RoboTwin 1.0 Blocks Stack (困难) 任务示意图。




图 14: RoboTwin 1.0 碗堆叠示意图。




图 15: RoboTwin 1.0 双瓶抓取（困难）示意图。




图 16: RoboTwin 1.0 双鞋放置示意图。



图 17: RoboTwin 1.0 空杯放置示意图。




图 18: RoboTwin 1.0 杂乱苹果抓取示意图。




图 19: RoboTwin 1.0 将瓶子放入垃圾桶示意图。




图 20: RoboTwin 2.0 旋转开关示意图。




图 21: RoboTwin 2.0 放置汉堡薯条示意图。




图 22: RoboTwin 2.0 打开笔记本电脑示意图。



图 23: RoboTwin 2.0 悬挂马克杯示意图。




图 24: RoboTwin 2.0 将物体放入柜子示意图。




图 25: 真实世界实验清洁桌面示意图。




图 26：真实世界实验悬挂马克杯示意图。




图 27：真实世界实验放置瓶子示意图。




图 28：真实世界实验打孔示意图。

L 详细文献综述

鉴于正文篇幅所限，本文在附录中扩展相关工作部分，提供详细的文献综述。本附录旨在更全面地概述先前工作，重点介绍正文中未能详细讨论的额外研究与应用。这些工作均对机器人学领域做出了重要贡献。

L.1 组合式生成建模

组合式生成建模近年来作为大规模单体模型的一种有力替代方案而兴起，其核心思想是通过组合更简单的因子来更有效地捕捉复杂数据分布。研究者认为，分布可以被分解并以模块化方式进行建模，而非依赖单一、过度参数化的模型，从而降低数据需求并提升可解释性（Koller & Friedman, 2009; Murphy, 2022）。这一研究方向受到概率图模型和基于能量的公式的启发，并已扩展至现代深度生成架构。

组合式建模的一个关键动机是数据效率。通过将分布分解为可管理的组件，即使在训练数据有限的情况下也能实现精确建模。例如，Janner 等人（2022）和 Ajay 等人（2022）表明，将序列分解为组件有利于轨迹生成，从而加快训练速度并提升泛化能力。在自然语言处理领域，Du 等人（2023b）证明，通过组合多个大语言模型，在“多智能体”框架下跨模型组合因子，可以提升推理能力。类似地，Liu 等人（Liu et al., 2021）提出了用于文本到图像生成的可组合扩散模型，其中局部句子级因子组合起来以合成复杂的全局场景。

除效率外，组合性为泛化到新任务和新分布提供了一种自然机制。在决策与规划领域，Ajay 等人（2023）提出了层次化基础模型，整合语言、视频和动作策略，实现灵活重组以支持零样本规划（Wang 等人，2025c）。在机器人操作中，Yang 等人（2023b）和 Mishra 等人（2023）表明，物体重排任务可通过组合局部约束因子来解决，而 Wang 等人（2024c）将这一思想扩展到异构策略组合（Wang 等人，2024b; Wang, 2025）。在视觉领域，Du 等人（2023a）和 Zhang 等人（2023）开发了通过分解区域条件来组装图像拼贴的方法，而 Yang 等人（2023a）证明视频风格迁移可通过组合预训练先验与轻量级风格模型来实现。

另一类工作研究如何自动发现组合结构。Du 等人（2021）和 Su 等人（2024）表明，使用专家乘积似然训练的自编码器能自然揭示对象级因子，这些因子随后可重组以生成混合场景。在动力系统中，Comas 等人（2023）推断粒子间的关系势，从而能够重组发现的交互规则。类似地，Liu 等人（2023）发现，在 ImageNet 上学习的组合组件对应于语义类别，使得合成未见过的多类组合图像成为可能。

在方法论层面，基于能量的模型（EBMs）为组合提供了自然框架，因为能量在构造上具有可加性（Hinton, 2002; Du & Mordatch, 2019; Grathwohl 等人，2021）。这一视角已被应用于扩散模型，其中每个时间步定义了一个隐式 EBM，组合通过跨模型能量相加来实现（Song & Ermon, 2019; Ho 等人，2020; Du 等人，2023a）。在离散领域的扩展采用带有学习提议的 Metropolis-Hastings 方法（Li 等人，2022; Verkuil 等人，2022），而 Garipov 等人（2023）展示了约束能量如何在推理时“塑造”生成轨迹。

尽管取得了这些进展，挑战依然存在。当前方法通常假设组合的固定结构，限制了适应性。Wiedemer 等人（2023）、Lachapelle 等人（2023）、Misino 等人（2022）以及 Sehgal 等人（2023）的工作强调了建立稳健理论框架的必要性，这些框架能够解释组合泛化并提供自动推断适当因子分解结构的方法。解决这些开放问题对于组合模型实现规模化并无缝集成到现实世界生成系统中至关重要。

L.2 机器人学习中的扩散模型

扩散模型已成为机器人学习的核心范式，为高效轨迹生成和规划提供了概率框架。基于近期综述（Barreiros 等人，2025；Shao 等人，2025；Zhong 等人，2025；Xiang 等人，2025；Firoozi 等人，2025；Song 等人，2025；Sapkota 等人，2025；Wong 等人，2025；Wolf 等人，2025；An 等人，2025；Zhang 等人，2025a；Adilkhanov 等人，2025；Lin 等人，2024b；Ma 等人，2024b；Zheng 等人，2025；Liu 等人，2025b；Urain 等人，2024），我们将基于扩散的机器人策略分为两类（Song 等人，2025）：（i）小规模基于扩散的策略，将卷积神经网络或变换器骨干与扩散头集成，并在任务特定数据集上训练，以实现高效的视觉运动控制；（ii）大规模扩散策略，将扩散模块与预训练基础模型或大型机器人数据集耦合，以实现更广泛的语义基础和跨具身泛化。这些发展共同表明，扩散既可以作为专门任务中的轻量级控制原语，也可以作为基础风格机器人策略中的可扩展组件，弥合低级随机控制与高级语义推理之间的差距。

基于小规模卷积神经网络/变换器的扩散策略。越来越多的视觉运动研究将紧凑的卷积神经网络或变换器编码器与扩散头相结合，表明随机去噪可以在多种操作场景中作为有效的控制原语。在这一方向中，若干工作直接使用扩散将观测映射到动作：扩散策略（Diffusion Policy，Chi 等人，2023）确立了基于卷积神经网络和变换器骨干的动作扩散基本方法，DP3（Ze 等人，2024b）将该范式扩展到点云输入以增强三维空间泛化。iDP3（Ze 等人，2024a）将 DP3 扩展用于人形机器人，以从噪声人类数据中学习。Mamba 策略（Cao 等人，2025b）通过引入线性复杂度架构 Mamba（Gu 和 Dao，2024；Dao 和 Gu，2024），H³DP（Lu et al., 2025）显式地融入层次结构，以加强视觉特征与动作生成之间的整合，从而改进 DP3。MCDP（Cao 等人，2025a）通过组合扩散将 DP 和 DP3 集成，以获得增强的性能。面向规划的时序架构出现在运动规划扩散（Motion Planning Diffusion，Carvalho 等人，2023）中，而设计消融研究突出了有效的扩散变换器组件（DiT-Block 策略（Dasari 等人，2025）），并引入了基于注意力的条件化以实现引导控制（MTDP（Wang 等人，2025a））。灵巧抓取综合由 DexDiffuser（Weng 等人，2024）处理，该工作逐步对多指手的抓取配置进行去噪。超越池化嵌入，3D Diffuser Actor（Ke 等人，2025）以标记化的三维场景表示为条件，R&D（Vosylius 等人，2024）提出了使用视觉变换器编码器的统一图像-动作公式。对于长时程或结构化问题，ALOHA Unleashed（Zhao 等人，2025）训练了一个具有扩散损失的变换器用于双臂技能；Chained-Diffuser（Xian 和 Gkanatsios，2023）首先预测末端执行器关键位姿，然后用可行轨迹将其连接；HDP（Ma 等人，2024a）注入运动学感知先验以提高物理真实感。类别级鲁棒性由 S²-Diffusion（Yang 等人，2025）通过视觉基础先验获取空间语义，以及由 C3DM（Saxena 等人，2023）通过带注视步骤的约束上下文条件化来抵抗干扰物。扩散也被用作规划的行为先验：Diffuser（Janner 等人，2022）将基于采样的规划框架化为概率行为综合，而 DTP（Fan 等人，2025）在两阶段流程中增加了二维轨迹引导。语言和以对象为中心的公式包括 StructDiffusion（Liu 等人，2022），它在语言目标下将对象中心的变换器与扩散融合，以及 PlayFusion（Chen 等人，2023），它使用离散瓶颈来获取语言标注的技能。从数据方面来看，ROSIE（Yu 等人，2023）利用最先进的文本到图像扩散进行激进的数据增强，Ha 等人（2023）则扩展了跨任务的语言条件化。最后，可以通过专家路由在不进行完全单体扩展的情况下增加容量：GSC（Mishra 等人，2023）通过基于分类器的引导概率性地链接已学习技能以满足约束，DBC（Chen 等人，2024）通过将专家状态-动作对的行为克隆建模为基于扩散的建模来稳定学习。

在核心的基于扩散的框架之外，已经提出了许多扩展，以提高视觉运动策略学习中的效率、泛化性和适应性。流式扩散策略（Streaming Diffusion Policy）（Høeg 等人，2024）通过生成部分去噪的轨迹来加速策略综合，其中每个动作可能保留不同的噪声水平，而双向解码（Bidirectional Decoding，BID）（Liu 等人，2024b）通过动作分块和闭环适应的组合实现测试时推理。交叉扩散（Crossway Diffusion）（Li 等人，2024b）引入了一个专门的状态解码器以及

一个辅助的自监督学习目标来增强策略鲁棒性，等变扩散策略（Equivariant Diffusion Policy）（Wang 等人，2024a）利用领域对称性在去噪过程中实现更高的样本效率和更好的泛化。Lin 等人（2024a）的补充实证工作研究了大规模模仿学习中的数据缩放效应。其他方法扩展了策略的表示能力，例如想象策略（Imagination Policy）（Huang 等人，2025a），它生成目标状态的点云预测，然后将其转换为可执行动作，以及一致性策略（Consistency Policy）（Prasad 等人，2024），它通过一致性正则化过程蒸馏出更快的视觉运动策略。对于微调，DPPO（Ren 等人，2024）提供了一个统一的框架，将策略梯度技术与连续控制领域中的扩散策略相结合。对触觉丰富场景的扩展包括反应式扩散策略（Reactive Diffusion Policy）（Xue 等人，2025），它结合了快慢视觉-触觉模仿学习，用于接触丰富的操作。

近期若干研究也将推理与序列建模融入扩散范式。统一视频动作模型（Unified Video Action Model）（Li 等，2025）联合优化视频预测与动作推理，以实现精确且高效的轨迹生成；而动作链（Chain-of-Action, CoA）（Zhang 等，2025b）从任务目标出发显式反向推理，通过动作级思维链机制生成连贯轨迹。在扩散之外，流匹配已成为一种强有力的替代方案：ManiFlow（Yan 等，2025）将流匹配与一致性训练相结合，仅需一至两步即可合成灵巧动作；流匹配策略梯度（Flow Matching Policy Gradients）（McAllister 等，2025）将流匹配直接嵌入强化学习的策略梯度算法中；VITA 在流匹配框架下将潜在视觉状态演化为潜在动作；引导你的扩散策略（Steering Your Diffusion Policy）（Wagenmaker 等，2025）通过在潜在噪声空间上执行强化学习来调整行为克隆策略，提供了一种无需从头重新训练即可灵活引导策略行为的方式。除上述扩展外，近期工作还探索了安全与动力学感知引导。DynaGuide（Du & Song，2025）通过将外部动力学模型的反馈直接引入去噪过程，为扩散策略引入一种引导机制，从而生成物理上更一致的动作。潜在策略屏障（Latent Policy Barrier, LPB）（Sun & Song，2025）受控制屏障函数启发，将专家潜在嵌入形式化为隐式安全边界，以区分分布内状态与分布外状态，从而增强视觉运动策略学习的鲁棒性。

综合来看，这些结果表明，当具身与任务分布相对受限时，通过更强的场景编码器、子目标脚手架、数据增强或专家混合（MoE）风格（Jiang 等，2024）路由增强的轻量级扩散策略具有竞争力且数据高效。

基于大语言模型（LLM）的大规模扩散策略。在更大规模上，扩散模块与预训练的视觉-语言模型（VLM）或大语言模型（LLM）骨干网络集成，或在广泛的跨具身语料库上进行训练，将语义理解与概率动作生成相结合。利用通用数据预训练的方法使用基础模型注入世界知识和语言结构：MDT（Reuss 等，2024）基于 CLIP（Radford 等，2021）和 Voltron（Karamcheti 等，2023）进行稀疏语言的长时程操作，通过 GPT-4（Achiam 等，2023）丰富指令；Ha 等（2023）使用大语言模型进行高层计划综合和成功推断，同时将低层控制委托给扩散策略；ROSIE（Yu 等，2023）使用大语言模型编写的提示驱动文本到图像扩散，以实现有针对性的数据增强；TinyVLA（Wen 等，2025a）冻结多模态骨干网络并应用参数高效微调（ $\sim 5\%$ 可训练）以高效生成动作。组合规划栈进一步收紧语言与扩散之间的循环：HiP（Ajay 等，2023）组合专家模型——大语言模型用于任务规划、视频扩散用于轨迹提议、逆模型用于动作映射，而 Plan Diffuser（Sharan 等，2024）使用大语言模型自回归地生成文本子目标，并通过扩散将其转换为视觉子目标以用于下游控制。与此同时，机器人数据预训练专注于大型异构机器人数据集，以增强具身迁移。Octo（Team 等，2024）聚合来自 Open X-Embodiment（O’Neill 等，2024）的 25 个数据集，训练一个带扩散头的变换器，将观测/任务标记映射到跨具身的动作标记；Diffusion-VLA（Wen 等，2025b）在 Open X-Embodiment 和 DROID（Khazatsky 等，2024）上预训练，并通过 LoRA（Hu 等，2022）适应任务；ChatVLA（Zhou 等，2025）在机器人和推理数据上联合训练，采用分阶段对齐和 MoE 路由以减少任务干扰；RDT-1B（Liu 等，2024a）通过标准化异构机器人上的统一动作空间，专注于细粒度（包括双手）技能；LAPA（Ye 等，2024）使用 BridgeV2（Walke 等，2023）和 Open X-Embodiment（O’Neill 等，2024）。 π_0 （Black 等，2024）系统研究跨具身预训练，耦合了一个预训练的

视觉-语言骨干与流匹配动作专家相结合，实现精确、平滑的操作；基于 $\pi_0, \pi_{0.5}$ (Intelligence 等人 (2025)) 利用异构任务协同训练以实现广泛泛化；Pertsch 等人 (2025) 和 Driess 等人 (2025) 基于实证研究专注于加速视觉语言动作模型；Enerverse (Huang 等人, 2025b) 和视频预测策略 (Hu 等人, 2024) 使用扩散模型学习视觉表示，以改善场景理解并随后提升策略性能；HybridVLA (Liu 等人, 2025a) 在单一大型语言模型内统一了基于扩散的动作连续性与自回归的上下文推理；GR00T N1 (Bjorck 等人, 2025) 是一种双系统 (图, 2024; Cui 等人, 2025) 视觉语言动作模型，适用于通用机器人，在多种机器人形态上达到最先进的性能；Galaxea G0 (Jiang 等人, 2025) 同样采用双系统，将视觉语言模型用于多模态规划与视觉语言动作模型用于底层机器人控制相结合；Agibot GO-1 (Bu 等人, 2025) 是一种通用策略，利用潜在动作表示最大化数据利用率；Gemini Robotics 系列 (Team 等人, 2025) 在多种任务中实现泛化能力，包括机器人控制、目标检测、指向、轨迹和抓取预测。除了使用扩散策略作为动作头之外，还有许多优秀工作采用流匹配 (Lipman 等人, 2023; Liu, 2022) 进行动作预测；GraspVLA 将自回归感知任务与基于流匹配的动作生成集成到统一的思维链过程中；GR-3 (Cheang 等人, 2025) 擅长理解具有抽象概念的复杂指令，并有效泛化到新物体和环境；WALL-OSS (Zhai 等人, 2025) 提出一种耦合架构，统一了指令推理、子目标分解和细粒度动作综合。

总体而言，这些大规模策略揭示了一种收敛的范式：语言模型构建目标和子目标，扩散过程合成轨迹和动作，预训练（基于通用或机器人中心语料库）提供鲁棒泛化所需的语义和形态先验。

L.3 机器人学习中的非扩散模型

尽管基于扩散的方法近来备受关注，但众多非扩散架构仍在机器人学习中扮演关键角色。这些模型通常利用序列建模、空间推理和大规模视觉-语言-动作系统来构建通用的操作与导航能力。与依赖迭代去噪的扩散策略不同，非扩散框架往往强调通过多层感知机或变换器 (Transformer) (Vaswani et al., 2017) 进行直接策略学习、分层控制或数据扩展策略。下文将总结操作与导航领域的代表性进展，重点阐述非扩散模型如何补充并拓展机器人学习的研究版图。

操作。非扩散视觉运动学习中的一个主要方向是将控制建模为序列建模。ACT (Zhao 等, 2023) 引入了一种条件编码器-解码器变换器，预测动作序列而非单步动作，从而在长时间跨度上减轻累积误差。基于这一思想，MT-ACT (Bharadhwaj 等, 2024) 在训练中融入任务语义，以学习通用的多任务操作器，而 CogACT (Li 等, 2024a) 结合视觉-语言-动作 (VLA) 骨干网络，使语言引导的认知与底层电机控制协同优化。分块因果变换器 (Zhang 等, 2025c) 保留了 ACT 风格的自回归策略，但将轨迹分割为块，从而提升长序列的稳定性和样本效率。除纯序列解码外，若干工作丰富了空间定位与三维控制：Act3D (Gervet 和 Xiao, 2023) 是一种语言条件变换器，用于六自由度操作，通过自适应三维计算输出连续分辨率的三维动作图；ICRT (Fu 等, 2024) 在实体机器人上实现了真正的上下文学习，利用少量上下文轨迹执行未见任务而无需额外训练；空间策略 (Liu 等, 2025c) 显式建模场景几何，使视觉预测与可执行的末端执行器运动对齐。另一条互补路线通过数据和层级扩展 VLA 系统：RT-1 (Brohan 等, 2023) 证明在大规模多样化机器人数据集上训练的变换器可产生强大的通用模型；RT-2 (Zitkovich 等, 2023) 将网络衍生的视觉-语言知识迁移到控制中；RT-X (O’Neill 等, 2024) 表明在大规模 OXE 数据上预训练可设立新的性能标杆，凸显数据规模的价值；RT-H (Belkhale 等, 2024) 插入语言-运动层，通过显式层级连接高层指令与底层动作。Beyond Sight (Jones 等, 2025) (采用 Octo 风格微调，使通用视觉运动策略适应异构传感器)、OpenVLA (Kim 等, 2025) (完全

发布了训练/测试配方)，以及 RoboVLM (Li 等人, 2024c) (一项设计研究, 提炼了 VLA 流程中最关键的选择)。最后, 新兴的具身模型将感知与协调提升到三维和灵巧操作场景: 3D-VLA (Zhen 等人, 2024) 通过生成式世界模型连接三维感知、推理与行动; Bi-VLA (Gbagbe 等人, 2024) 面向协调的双臂操作; LEO (Huang 等人, 2024) 作为多模态通才, 能够在三维环境中感知、定位、推理、规划与行动; SpatialBot (Cai 等人, 2025) 通过融合 RGB 与深度来增强空间理解; Lift3D (Jia 等人, 2024) 将二维基础特征提升为鲁棒的三维操作表示; RoboDual (Bu 等人, 2024) 在协同双策略框架中统一了通才广度与专才精度。

进一步的进展聚焦于面向操作的约束驱动表示。关系关键点约束 (ReKep) (Huang 等人, 2025c) 将视觉定义的约束定义为 Python 函数, 将场景中的三维关键点集合映射为数值代价, 为编码任务特定关系提供了灵活的接口。VosPoser (Huang 等人, 2023) 利用大语言模型从自然语言中提取可供性与约束, 在观测空间中组合三维价值图, 以结构化方式引导机器人交互。

这些工作共同表明, 非扩散架构, 特别是序列模型和 VLA 系统, 通过长时程解码、显式空间定位、数据扩展和模块化层次结构, 实现了强大的操作泛化能力。

导航。在运动与导航方面, 非扩散方法同样利用层次结构、蒸馏和语言基础。Cheng 等人 (2024b) 开发了极限腿部跑酷, 首先通过强化学习训练教师策略, 然后将其能力蒸馏到仅依赖机载深度信息运行的学生策略中, 从而在野外实现敏捷行为。Mobility VLA (Chiang 等人, 2024) 采用分层设计: 高层由长上下文视觉语言模型提供场景理解和常识推理, 低层由稳健的导航器沿拓扑图执行计划。NaVid (Zhang 等人, 2024b) 将流式 RGB 视频和自然语言指令转化为机器人可执行的一系列文本动作指令, 强调纯视觉输入下的语言即动作。NaVILA (Cheng 等人, 2024a) 将这一思想扩展到腿部视觉语言导航, 采用两级控制: 微调后的视觉语言模型输出中层语言动作 (e.g., “右转 30”), 学习到的视觉运动控制器忠实执行这些命令。这些系统凸显了非扩散导航中反复出现的模式: 将高层意图分解为紧凑的语言子目标, 并与稳健的低层策略配对以实现精确的机器人控制。

M 未来工作

这项工作为未来探索开辟了若干途径。在方法论方面，一个关键方向是超越固定的测试时权重离散化。可以开发更具适应性的加权策略，例如强化学习或基于梯度的元优化，以自动调整跨任务和环境的凸权重。另一个自然的扩展是从双策略组合扩展到多策略组合。由于天真地增加组合策略的数量会带来高昂的计算成本，未来工作可以探索特征共享机制或紧凑的潜在表示以实现高效集成。最后，设计更强的组合算子仍然是一个开放的挑战。我们在超扩散方面的初步结果凸显了其潜力，但更高效的变体以及与基于流的模型集成的扩展，可以进一步放大策略性能。

在更广泛的层面上，策略组合的原则可能超越基于扩散的策略。相同的组合框架可应用于多样的策略类别与架构，实现异构技能的模块化集成。此外，尽管我们的实验聚焦于操作任务中的机器人视觉动作（VA）与视觉语言动作（VLA），我们预期在相关领域产生更广泛影响。例如，视觉语言导航（VLN）任务，如一些成功的最先进方法 TrackVLA（Wang 等，2025b）和 LOVON（Peng 等，2025），也可能受益于组合策略以增强泛化与鲁棒性。探索这些方向将进一步验证 GPC 作为在复杂序贯决策领域中利用预训练模型的通用范式。