

通过元强化学习在动态真实环境中学会适应

**Anusha Nagabandi*, Ignasi Clavera*, Simin Liu,
Ronald S. Fearing, Pieter Abbeel, Sergey Levine, & Chelsea Finn**
University of California, Berkeley
{nagaban2, iclavera, simin.liu}@berkeley.edu
{ronf, pabbeel, svlevine, cbfinn}@berkeley.edu

摘要

尽管强化学习方法在仿真中能够取得令人印象深刻的结果，但现实世界带来了两大挑战：生成样本极其昂贵，以及意外的扰动或未见情况导致熟练但专精的策略在测试时失效。鉴于训练单独的策略以适应智能体在现实世界中可能遇到的所有情况是不切实际的，本文提出学习如何快速有效地在线适应新任务。为了实现样本高效的学习，我们考虑在基于模型的强化学习框架下学习在线适应。我们的方法利用元学习来训练一个动力学模型先验，使得该先验在与近期数据结合时，能够迅速适应局部环境。我们的实验展示了在仿真和现实世界智能体上针对连续控制任务的在线适应能力。我们首先展示了仿真智能体在线调整其行为以适应新地形、受损肢体以及高度动态的环境。我们还通过将我们的方法应用于一个真实的动态腿式微型机器人，说明了将在线适应纳入在现实世界中运行的自主智能体的重要性。我们展示了该智能体学习到的能力：快速在线适应缺失的腿、调整以适应新地形和斜坡、考虑姿态估计中的校准误差或错误，以及补偿牵引负载。¹

1 引言

基于模型和无模型的强化学习方法通常运行在两种模式之一：所有训练提前完成，生成一个模型或策略，可在测试时用于在近似匹配训练期间所见环境的设置中做出决策；或者，训练在线进行（例如，在线时序差分学习的情况），在这种情况下，智能体可以在与环境交互时缓慢修改其行为。然而，在这两种情况下，动态变化，如机器人组件故障、遇到新地形、光照和风等环境因素，或其他意外扰动，都可能导致智能体失败。相比之下，人类可以快速适应未见过的物理扰动和自身动态变化（Braun 等人，2009）：成年人只需几秒钟就能学会拄拐杖行走，人们几乎可以瞬间适应拿起意外沉重的物体，能在毛毯和草地上行走的儿童可以迅速学会如何在冰上行走，而无需重新学习走路。这怎么可能呢？如果智能体过去遇到过大量扰动，原则上可以利用这些经验来学习如何适应。在这项工作中，我们提出了一种用于学习在线适应的元学习方法。

受处理现实世界应用能力的激励，我们专门开发了一种基于模型的元强化学习算法。在这种设置下，用于更新模型的数据在每个时间步以最近经验的形式随时可用。但更关键的是，训练这种自适应模型的元训练过程可以比无模型元强化学习方法（Duan 等人，2016；Wang 等人，2016；Finn 等人，2017）具有更高的样本效率。此外，我们的方法放弃了

¹Videos available at: <https://sites.google.com/berkeley.edu/metaadaptivecontrol>



图 1: 我们在真实的腿式微型机器人上实现了我们的样本高效元强化学习算法, 使其能够在线适应新任务和意外情况, 例如失去一条腿 (如图所示)、新地形和斜坡、姿态估计误差以及牵引负载。

无模型元强化学习 (Model-Free Meta-RL) 方法所依赖的情景框架中, 任务被预定义为不同的奖励或环境, 且任务仅存在于轨迹层面。相反, 本文方法将每个时间步都视为潜在的新“任务”, 其中任何细节或设置都可能在任何时间步发生变化。这种观点通过允许任务的概念涵盖从处于状态空间的不同部分、经历扰动到尝试实现新目标等各种情形, 从而引出了一个更通用的元强化学习问题设定。

学习自适应模型缓解了基于模型的强化学习 (Model-Based Reinforcement Learning) 的一个核心挑战: 获取一个在整个状态空间中都准确的全局模型的问题。此外, 即使训练一个全局准确的动力学模型是实用的, 动力学本身也会随着不可控且通常不可观测的环境因素 (如上文所述) 而变化。如果我们拥有一个能够在线自适应的模型, 它就不必先验地在所有地方都完美。这一特性此前已被自适应控制方法所利用 (Åström 和 Wittenmark, 2013; Sastry 和 Isidori, 1989; Pastor 等, 2011; Meier 等, 2016); 但是, 将此类方法扩展到复杂任务和非线性系统是极其困难的。即使使用深度神经网络 (Deep Neural Network) 来建模复杂非线性系统 (Kurutach 等, 2018), 实现自适应也极其困难, 因为此类模型通常需要大量数据和许多梯度步骤才能有效学习。通过专门训练一个神经网络模型, 使其仅需少量经验即可自适应, 我们能够在复杂环境中实现有效的在线自适应, 同时减轻对完美全局模型的需求。

本文的主要贡献是一种高效的元强化学习方法, 能够在动态环境中实现在线自适应。据作者所知, 这是首个应用于真实机器人系统的元强化学习算法。我们的算法高效地训练一个全局模型, 该模型能够利用其近期经验快速适应, 从而在动态环境中实现快速在线自适应。我们评估了两种版本的方法: 基于循环的自适应学习器 (ReBAL) 和基于梯度的自适应学习器 (GrBAL), 在具有复杂接触动力学的随机和模拟连续控制任务上进行测试 (图 2)。在实验中, 我们展示了四足“蚂蚁”适应不同腿部故障, 以及“半猎豹”机器人适应不同关节故障、在不同坡度的地形上导航, 以及在浮力不同的浮动平台上行走。我们的基于模型的元强化学习方法在训练数据量相近的情况下, 相比先前方法 (包括标准基于模型的方法、在线模型自适应方法、无模型方法和先前的元强化学习方法) 取得了显著改进。在所有实验中, 跨多个任务的元训练具有样本高效性, 仅使用相当于 1.5 – 3 小时的真实世界经验, 大约比无模型方法学习单个任务所需的数据少 $10\times$ 。最后, 我们在一个真实的动态腿式微型机器人上演示了 GrBAL (见图 2)。为了不仅突出我们基于元模型的强化学习方法的样本效率, 还强调真实世界中快速在线自适应的重要性, 我们展示了智能体学习到的在线适应能力, 能够应对缺腿、新地形和坡度、姿态估计的误校准或误差以及新的待拉载荷等任务。

2 相关工作

学习控制策略的进展已在众多复杂和高维任务中取得成功 (Schulman 等, 2015; Lillicrap 等, 2015; Mnih 等, 2015; Levine 等, 2016; Silver 等, 2017)。虽然强化学习算法为学习新任务提供了框架, 但它们主要关注掌握单个技能, 而非泛化并快速适应新场景。此外, 无模型方法 (Peters 和 Schaal, 2008) 需要大量

系统交互以学习成功的控制策略，这往往使其难以应用于现实世界系统。相比之下，基于模型的方法通过先学习系统动力学模型，再利用该模型优化策略，从而获得更优的样本效率（Deisenroth 等, 2013; Lenz 等, 2015; Levine 等, 2016; Nagabandi 等, 2017b; Williams 等, 2017）。本文方法通过允许模型根据近期观测在线自动适应不同场景，减轻了学习单一全局模型的需求。基于模型的强化学习方法面临的一个关键挑战是难以学习在整个状态空间都准确的全局模型。先前的基于模型的方法通过使用高斯过程（Gaussian Processes, GPs）纳入模型不确定性来解决这一问题（Ko 和 Fox, 2009; Deisenroth 和 Rasmussen, 2011; Doerr 等, 2017）。然而，这些方法对系统做出了额外假设（如平滑性），并且无法扩展到高维环境。Chua 等（2018）最近表明，神经网络模型也能从纳入不确定性中获益，并且可以使得基于模型的方法达到无模型方法的性能，同时显著降低样本复杂度。本文方法与他们的方法正交，并且可以从纳入此类不确定性中获益。

先前的在线自适应方法（Tanaskovic et al., 2013; Aswani et al., 2012）旨在学习一个近似的全局模型，然后在测试时对其进行调整。例如，动态评估算法（Rei, 2015; Krause et al., 2017; 2016; Fortunato et al., 2017）在训练时学习一个近似的全局分布，并在测试时通过梯度下降调整这些模型参数以适应当前的局部分布。在基于模型的强化学习和自适应控制领域，已有大量关于在线自适应的先前工作（Sasthy and Isidori, 1989）。与逆模型自适应（Kelouwani et al., 2012; Underwood and Husain, 2010; Pastor et al., 2011; Meier et al., 2016; Meier and Schaal, 2016; Rai et al., 2017）不同，我们关注的是前向模型的自适应问题，这与在线系统辨识密切相关（Manganiello et al., 2014）。模型自适应方面的工作（Levine and Koltun, 2013; Gu et al., 2016; Fu et al., 2015; Weinstein and Botvinick, 2017）表明，完美的全局模型并非必需，先验知识可以通过微调来处理小的变化。然而，这些方法面临模型训练目标与测试时使用方式之间的不匹配。在本文中，我们通过显式训练一个能够快速有效自适应的模型来弥合这一差距。因此，与这些先前工作相比，我们的模型实现了更有效的自适应，这一点在我们的实验中得到了验证。

我们的问题设定与元学习（Meta-Learning）相关，这是机器学习中一个长期关注的问题，旨在通过学会学习使人工智能体能够高效地学习新任务（Thrun 和 Pratt, 1998; Schmidhuber 和 Huber, 1991; Naik 和 Mammone, 1992; Lake 等人, 2015）。元学习器可以通过决定学习器的架构（Baker 等人, 2016）或为学习器指定优化算法或更新规则（Bengio 等人, 1990; Schmidhuber, 1992; Younger 等人, 2001; Andrychowicz 等人, 2016; Li 和 Malik, 2016; Ravi 和 Larochelle, 2018）等方式来控制学习过程。另一种流行的元学习方法涉及直接展开一个接收数据的循环神经网络（Recurrent Neural Network, RNN）（Santoro 等人, 2016; Munkhdalai 和 Yu, 2017; Munkhdalai 等人, 2017; Mishra 等人, 2017），并学习算法本身的内部表示，我们方法的一个实例（ReBAL）建立在这些方法之上。另一方面，我们方法的另一个实例（GrBAL）建立在 MAML（Finn 等人, 2017）之上。GrBAL 与 MAML 的监督版本不同之处在于，MAML 假设可以访问手工设计的任务分布。相反，我们的主要贡献之一是在线元学习公式，其中任务对应于时间片段，使得“任务”能够从环境中的经验自动构建。

强化学习背景下的元学习主要集中在无模型方法上（Duan 等人, 2016; Wang 等人, 2016; Sung 等人, 2017; Al-Shedivat 等人, 2017）。然而，这些算法比非元无模型强化学习方法表现出更高的（元）训练样本复杂度，这使它们无法应用于现实世界。最近的工作（Sæmundsson 等人, 2018）开发了一种基于模型的元强化学习算法，将元学习框架为分层潜变量模型，训练用于对动力学变化进行情景适应；建模使用高斯过程完成，并在倒立摆和双摆智能体上展示了结果。相比之下，我们提出了一种用于学习高容量神经网络动力学模型在线适应的方法；我们提出了这种通用方法的两个实例，并在模拟智能体和真实腿式机器人上展示了结果。

3 预备知识

在本节中，我们介绍基于模型的强化学习，引入元学习公式，并描述两种主要的元学习方法。

3.1 基于模型的强化学习

强化学习智能体旨在执行能够最大化某种累积奖励概念的动作。具体而言，考虑一个由元组定义 $(\mathcal{S}, \mathcal{A}, p, r, \gamma, \rho_0, H)$ 的马尔可夫决策过程 (MDP)。其中， $\mathcal{S}$ 是状态集， $\mathcal{A}$ 是动作集， $p(\mathbf{s}'|\mathbf{s}, \mathbf{a})$ 是状态转移分布， $r: \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$ 是有界奖励函数， $\rho_0: \mathcal{S} \rightarrow \mathbb{R}_+$ 是初始状态分布， γ 是折扣因子， H 是时间范围。轨迹片段记为 $\tau(i, j) := (\mathbf{s}_i, \mathbf{a}_i, \dots, \mathbf{s}_j, \mathbf{a}_j, \mathbf{s}_{j+1})$ 。最后，轨迹的期望奖励之和即为回报。在此框架下，强化学习旨在寻找一个策略 $\pi: \mathcal{S} \rightarrow \mathcal{A}$ ，该策略为每个状态规定最优动作，以最大化期望回报。

基于模型的强化学习旨在通过学习转移分布 $p(\mathbf{s}'|\mathbf{s}, \mathbf{a})$ （也称为动力学模型）来解决该问题。这可以通过使用函数逼近器 $\hat{p}_\theta(\mathbf{s}'|\mathbf{s}, \mathbf{a})$ 来近似动力学，其中权重 θ 被优化以最大化观测数据 $\mathcal{D}$ 的对数似然。在实践中，该模型随后用于动作选择过程，方式包括生成用于训练策略的数据点，或生成供控制器优化的预测和动力学约束。

3.2 元学习 元学习关注自动学习比从头学习更高效、更有效的学习算法。这些算法利用来自先前任务的数据来获取能够快速适应新任务的学习过程。这些方法基于以下假设：先前的元训练任务和新的元测试任务来自相同的任务分布 $\rho(\mathcal{T})$ ，并共享可被利用以实现快速学习的共同结构。在监督学习设置中，我们旨在学习一个带参数 θ 的函数 f_θ ，以最小化监督损失 $\mathcal{L}_\mathcal{T}$ 。然后，元学习的目标是找到一个学习过程，记为 $\theta' = u_\psi(\mathcal{D}_\mathcal{T}^\text{tr}, \theta)$ ，它能够从小数据集 $\mathcal{D}_\mathcal{T}^\text{tr}$ 中学习一系列任务 $\mathcal{T}$ 。

我们可以将这一元学习问题形式化为对学习过程参数 θ, ψ 的优化，如下所示：

$$\min_{\theta, \psi} \mathbb{E}_{\mathcal{T} \sim \rho(\mathcal{T})} [\mathcal{L}(\mathcal{D}_\mathcal{T}^\text{test}, \theta')] \quad \text{s.t.} \quad \theta' = u_\psi(\mathcal{D}_\mathcal{T}^\text{tr}, \theta) \quad (1)$$

其中 $\mathcal{D}_\mathcal{T}^\text{tr}, \mathcal{D}_\mathcal{T}^\text{test}$ 是从元训练数据集 $\mathcal{D}_\mathcal{T}$ 中无放回采样的。

一旦元训练优化了参数 θ_*, ψ_* ，学习过程 $u_\psi(\cdot, \theta)$ 便可用于从少量数据中学习新的留出任务。我们也将学习过程 u 称为更新函数。

基于梯度的元学习。模型无关元学习 (Model-Agnostic Meta-Learning, MAML) (Finn 等, 2017) 旨在学习神经网络的初始参数，使得从该初始化出发进行一步或几步梯度下降即可有效泛化（或少样本泛化）到新任务。随后，当面对新任务时，具有元学习初始化的模型可以利用新任务中的少量数据点快速微调。沿用前文记号，MAML 使用梯度下降作为学习算法：

$$u_\psi(\mathcal{D}_\mathcal{T}^\text{tr}, \theta) = \theta - \alpha \nabla_\theta \mathcal{L}(\mathcal{D}_\mathcal{T}^\text{tr}, \theta) \quad (2)$$

学习率 α 可以是可学习参数（此时 $\psi = \alpha$ ），也可以固定为超参数，从而得到 $\psi = \emptyset$ 。尽管更新规则固定，但过参数化深度网络的学习初始化加上梯度下降，其表达能力与深度循环网络所表示的更新规则相当 (Finn 和 Levine, 2017)。

基于循环的元学习。另一种元学习方法使用循环模型。此时，更新函数始终是学习得到的， ψ 对应于更新隐藏状态的循环模型的权重。预测模型的参数 θ 对应于循环模型其余权重和隐藏状态。基于梯度和基于循环的元学习方法均已用于元无模型强化学习 (Finn 等, 2017; Duan 等, 2016)。我们将基于这些思想开发一种元基于模型的强化学习算法，以在线方式实现动态环境中的适应。

4 面向在线模型适应的元学习

本节提出面向在线模型适应的元学习方法。如第 3.2 节所述，标准元学习公式要求学习到的模型 θ_* , ψ_* 利用来自某个新“任务”的 M 个数据点进行学习。在先前基于梯度和基于模型的元强化学习方法中 (Finn 等, 2017; Sæmundsson 等, 2018), M 对应于 M 条轨迹, 导致分幕式适应。

本文对“任务”的定义更为灵活, 轨迹的每一段都可视为不同的“任务”, 过去 M 个时间步的观测 (而非过去 M 个回合) 可视为提供当前任务设置的信息。由于系统动力学、地形细节或其他环境变化可能随时发生, 我们在每个时间步考虑利用过去 M 个时间步来调整模型, 以预测未来 K 个时间步。在此设置下, M 和 K 是预先指定的超参数; 这些参数的敏感性分析见附录。

本文使用环境 $\mathcal{E}$ 的概念来表示特定问题的不同设置或配置, 范围从系统关节故障到外部干扰状态。假设环境分布 $\rho(\mathcal{E})$ 共享某些共同结构, 例如相同的观测空间和动作空间, 但动力学 $p_{\mathcal{E}}(\mathbf{s}'|\mathbf{s}, \mathbf{a})$ 可能不同。轨迹段记为 $\tau_{\mathcal{E}}(i, j)$, 表示在环境 $\mathcal{E}$ 内采样的状态和动作序列 $(\mathbf{s}_i, \mathbf{a}_i, \dots, \mathbf{s}_j, \mathbf{a}_j, \mathbf{s}_{j+1})$ 。本文算法假设环境是局部一致的, 即每个长度为 $j-i$ 的段具有相同的的环境。尽管该假设并非总是成立, 但它允许我们在不知道环境何时变化的情况下从数据中学习适应。由于本文的适应速度很快 (不到一秒), 该假设很少被违反。

本文将这种设置下的元强化学习问题表述为在 (θ, ψ) 上关于最大似然元目标的优化。元目标是预测模型 $\hat{p}_{\theta'}(\mathbf{s}'|\mathbf{s}, \mathbf{a})$ 在参数 θ' 下数据的似然, 其中 $\theta' = u_{\psi}(\tau_{\mathcal{E}}(t-M, t-1), \theta)$ 对应于使用过去 M 个数据点更新后的模型参数。具体而言, 这对应于以下优化:

$$\min_{\theta, \psi} \mathbb{E}_{\tau_{\mathcal{E}}(t-M, t+K) \sim \mathcal{D}} [\mathcal{L}(\tau_{\mathcal{E}}(t, t+K), \theta'_{\mathcal{E}})] \quad \text{s.t.:} \quad \theta'_{\mathcal{E}} = u_{\psi}(\tau_{\mathcal{E}}(t-M, t-1), \theta), \quad (3)$$

其中 $\tau_{\mathcal{E}}(t-M, t+K) \sim \mathcal{D}$ 对应于从先前经验中采样的轨迹段, 损失 $\mathcal{L}$ 对应于模型下数据的负对数似然:

$$\mathcal{L}(\tau_{\mathcal{E}}(t, t+K), \theta'_{\mathcal{E}}) \triangleq -\frac{1}{K} \sum_{k=t}^{t+K} \log \hat{p}_{\theta'_{\mathcal{E}}}(\mathbf{s}_{k+1}|\mathbf{s}_k, \mathbf{a}_k). \quad (4)$$

在方程 3 的元目标中, 注意到过去的 M 点被用来将 θ 适配为 θ' , 并且该 θ' 的损失是在未来的 K 点上评估的。因此, 我们利用过去的 M 个时间步来提供洞见, 了解如何适配我们的模型, 使其在邻近的未来时间步上表现良好。如算法 1 所述, 内部更新的更新规则 u_{ψ} 和外部更新中对 θ 的梯度步骤使我们能够优化这一适配的元目标。因此, 我们在测试时通过仅使用 M 个数据点对模型进行微调, 实现了快速适配。

虽然我们在实验中专注于强化学习问题, 但这种元学习方法可用于在各种序列建模领域中在线学习适配。我们接下来将讨论使用循环和基于梯度的元学习器来呈现我们的算法。

基于梯度的自适应学习器 (GrBAL)。GrBAL 使用基于梯度的元学习来执行在线适配; 特别地, 我们使用 MAML (Finn 等人, 2017)。在这种情况下, 我们的更新规则由梯度下降规定 (5.)

$$\theta'_{\mathcal{E}} = u_{\psi}(\tau_{\mathcal{E}}(t-M, t-1), \theta) = \theta_{\mathcal{E}} + \psi \nabla_{\theta} \frac{1}{M} \sum_{m=t-M}^{t-1} \log \hat{p}_{\theta_{\mathcal{E}}}(\mathbf{s}_{m+1}|\mathbf{s}_m, \mathbf{a}_m) \quad (5)$$

基于循环的自适应学习器 (ReBAL)。ReBAL 则利用循环模型, 该模型学习自己的更新规则 (即通过其内部门控结构)。在这种情况下, ψ 和 u_{ψ} 对应于更新其隐藏状态的循环模型的权重。

Algorithm 1 Model-Based Meta-Reinforcement Learning (train time)**Require:** Distribution $\rho_{\mathcal{E}}$ over tasks**Require:** Learning rate $\beta \in \mathbb{R}^+$ **Require:** Number of sampled tasks N , dataset $\mathcal{D}$ **Require:** Task sampling frequency $n_S \in \mathbb{Z}^+$

```

1: Randomly initialize  $\theta$ 
2: for  $i = 1, \dots$  do
3:   if  $i \bmod n_S = 0$  then
4:     Sample  $\mathcal{E} \sim \rho(\mathcal{E})$ 
5:     Collect  $\tau_{\mathcal{E}}$  using Alg. 2
6:      $\mathcal{D} \leftarrow \mathcal{D} \cup \{\tau_{\mathcal{E}}\}$ 
7:   end if
8:   for  $j = 1 \dots N$  do
9:      $\tau_{\mathcal{E}}(t-M, t-1), \tau_{\mathcal{E}}(t, t+K) \sim \mathcal{D}$ 
10:     $\theta'_{\mathcal{E}} \leftarrow u_{\psi}(\tau_{\mathcal{E}}(t-M, t-1), \theta)$ 
11:     $\mathcal{L}_j \leftarrow \mathcal{L}(\tau_{\mathcal{E}}(t, t+K), \theta'_{\mathcal{E}})$ 
12:   end for
13:    $\theta \leftarrow \theta - \beta \nabla_{\theta} \frac{1}{N} \sum_{j=1}^N \mathcal{L}_j$ 
14:    $\psi \leftarrow \psi - \eta \nabla_{\psi} \frac{1}{N} \sum_{j=1}^N \mathcal{L}_j$ 
15: end for
16: Return  $(\theta, \psi)$  as  $(\theta_*, \psi_*)$ 

```

Algorithm 2 Online Model Adaptation (test time)**Require:** Meta-learned parameters θ_*, ψ_* **Require:** controller(), H, r, n_A

```

1:  $\mathcal{D} \leftarrow \emptyset$ 
2: for each timestep  $t$  do
3:    $\theta'_* \leftarrow u_{\psi_*}(\mathcal{D}(t-M, t-1), \theta_*)$ 
4:    $\mathbf{a} \leftarrow \text{controller}(\theta'_*, r, H, n_A)$ 
5:   Execute  $\mathbf{a}$ , add result to  $\mathcal{D}$ 
6: end for
7: Return rollout  $\mathcal{D}$ 

```




图 2: 我们的方法在两个真实世界和四个模拟环境中进行评估, 适配对于成功至关重要 (例如, 适配不同的坡度和腿部故障)

5 基于模型的元强化学习

在讨论了实现在线自适应的方法之后, 本文接下来提出如何基于这一思想构建基于模型的元强化学习算法。首先, 解释智能体如何利用自适应模型执行任务, 给定通过优化元学习目标得到的参数 θ_* 和 ψ_* 。

给定 θ_* 与 ψ_* , 本文利用智能体近期经验来调整模型参数: $\theta'_* = u_{\psi_*}(\tau(t-M, t), \theta_*)$ 。由此得到模型 $\hat{p}_{\theta'_*}$, 该模型能更准确地捕捉当前设置、任务或环境中的局部动态特性。随后, 将这一调整后的模型连同奖励函数 r 与规划时域 H 一并传递给控制器。本文采用的规划 H 小于适应时域 K , 因为调整后的模型仅在当前上下文内有效。本文使用模型预测路径积分控制 (Model Predictive Path Integral Control, MPPI) (Williams 等人, 2015), 但原则上, 所提出的模型适应方法不依赖于所使用的模型预测控制 (Model Predictive Control, MPC) 具体方法。

模型预测控制 (MPC) 的使用通过在每个时间步使用更新后的状态信息重新规划, 防止了误差累积, 从而补偿了模型的不准确性。MPC 在这种在线适应设置中还带来了额外的好处, 因为模型 $\hat{p}_{\theta'_*}$ 本身在下一个时间步也会得到改进。在采取每一步之后, 我们将得到的状态转移添加到数据集中, 将模型参数重置回 θ_* , 并在每个时间步重复整个规划过程。此适应过程见算法 2。最后, 除了测试时, 我们还在元训练阶段本身执行此在线适应过程, 为元训练提供在线策略的轨迹。完整的元强化学习算法见算法 1。

6 实验

我们的评估旨在回答以下问题: (1) 适配是否真正改变了模型?

(2) 本文方法能否在训练分布内外, 针对动态变化、任务及环境实现快速适应? (3) 本文方法的性能与其他方法相比如何? (4) GrBAL 与 ReBAL 相比如何? (5) 在这些实验中, 基于元模型的强化学习与无模型元强化学习在样本效率和性能方面相比如何?

(6) 我们的方法能否在真实机器人上实现在线自适应, 如果可以, 其表现如何? 接下来我们

基于这些问题，我们展示了实验设置与结果。视频可在网上获取²，进一步的分析见附录。我们首先在多种模拟机器人上，使用 MuJoCo 物理引擎（Todorov 等人，2012）对我们的算法进行了对比评估。在所有环境中，我们将转移概率建模为高斯随机变量，其均值由神经网络模型（3 个隐藏层，每层 512 个单元，使用 ReLU 激活函数）参数化，方差固定。在这种情况下，最大似然估计等价于最小化均方误差。下面描述各环境的设置（图 2），每个智能体在运行时需要不同类型的适应才能成功：

半猎豹（Half-cheetah, HC）：关节失效。在元训练的每次 rollout 中，我们随机选择一个关节使其失效（即智能体无法对该关节施加力矩）。测试时，我们在两种不同情况下评估性能：失效一个训练中未见过的关节，以及在一次 rollout 中切换失效关节。前者考察对分布外环境的泛化能力，后者测试对动态变化的快速适应能力。

HC：斜坡地形。在元训练的每次 rollout 中，我们随机选择一个低坡度的上坡或下坡。测试时，我们在未见过的设置上评估性能，包括缓上坡、陡上坡，以及先上后下的陡峭山丘。

HC：码头。在此实验中，猎豹跑过一系列漂浮在水面上的方块。每个方块被踩踏时会上下移动，由于每个方块具有不同的阻尼和摩擦特性，动态变化非常迅速。HC 通过改变这些方块属性进行元训练，并在一个特定的（随机选择的）属性配置上进行测试。

蚂蚁（Ant）：腿部残疾。对于每次元训练展开，我们随机选择一条腿使其在该四足机器人上失效。这会导致底层动力学发生意外且剧烈的变化。我们在测试时通过使训练分布之外的一条腿失效，以及在一次展开内从正常运行过渡到有一条腿失效的状态，来评估该智能体。

在以下章节中，我们将评估基于模型的元强化学习方法（GrBAL 和 ReBAL），并与若干先前方法进行比较：

- **无模型强化学习（TRPO）：**为了评估自适应的重要性，我们与一个使用 TRPO（Schulman 等人，2015）在多个环境中训练的无模型强化学习智能体 $\mathcal{E} \sim \rho(\mathcal{E})$ 进行比较。
- **无模型元强化学习（MAML-RL）：**我们与最先进的无模型元强化学习方法 MAML-RL（Finn 等人，2017）进行比较。
- **基于模型的强化学习（MB）：**与无模型智能体类似，我们还与一个单一的基于模型的强化学习智能体进行比较，以评估自适应的重要性。该模型使用监督模型误差和迭代模型自举进行训练。
- **基于模型的强化学习与动态评估（MB+DE）：**本文将其与采用基于模型的强化学习训练的智能体进行比较，如上所述。然而，在测试阶段，模型通过在每个时间步利用过去 M 个观测值进行梯度更新来适应，类似于动态评估（Krause 等人，2017）。这一最终比较评估了显式训练适应性的益处。

所有基于模型的方法（MB、MB+DE、GrBAL 和 ReBAL）均使用模型引导，采用相同的神经网络架构，并在实验中使用相同的规划器：模拟实验使用 MPPI（Williams 等人，2015），真实世界实验使用随机射击（RS）（Nagabandi 等人，2017a）。

6.1 适应性的影响

首先，本文分析模型适应性的影响，并展示在三个环境中的测试阶段运行结果：HC 码头、具有陡峭上下坡的 HC 倾斜地形，以及蚂蚁残腿环境，其中被选中的腿在训练期间未被视为残腿。图 3 展示了三个 GrBAL 运行中更新前与更新后模型预测误差之间的分布偏移，表明利用过去 M 个时间

步将 θ^* （更新前）更新为 θ'^* （post）确实降低了预测后续时间步的模型误差。

²Videos available at: <https://sites.google.com/berkeley.edu/metaadaptivecontrol>

6.2 性能与元训练样本效率

我们首先研究元训练过程的样本效率。图 4 展示了测试环境中平均回报与元训练所用数据量的关系。我们将无模型方法（TRPO 和 MAML-RL）进行（元）训练直至收敛，所用数据量相当于约两天的真实世界经验。相比之下，我们使用相当于 1.5 至 3 小时的真实世界经验来元训练基于模型的方法（包括我们的方法）。我们的方法在性能上优于或等同于使用 1000 倍数据训练的无模型智能体。我们的方法还超越了未进行元学习的基于模型方法的性能。最后，我们的性能在半猎豹残疾任务中与无模型元强化学习方法的高渐近性能非常接近，在蚂蚁残废任务中达到次优性能，但同样仅使用了相当于 1000 分之一的数据。需要注意的是，这种渐近性能的次优性是基于模型方法的一个已知问题，因此是未来工作的一个有趣方向。使用基于模型方法带来的样本效率提升与先前发现一致（Deisenroth 和 Rasmussen, 2011; Nagabandi 等, 2017a; Kurutach 等, 2018）；最重要的评估，我们接下来将更详细讨论，是我们的方法能否在仅几个时间步内在线适应剧烈的动力学变化。




图 3: GrBAL 归一化 K 步模型预测误差的直方图，展示了更新后模型预测相对于更新前模型的改进。




图 4: 与无模型强化学习、无模型元强化学习和基于模型的强化学习方法相比，我们的基于模型的元强化学习方法以少 $1000 \times$ 的数据实现了良好的性能。虚线表示收敛时的性能。对于 MB+DE+MPPI，我们在测试时对最终的 MB+MPPI 模型进行动态评估。

6.3 测试时性能：在线适应与泛化

在第二个对比评估中，我们评估了 GrBAL 和 ReBAL 与上述方法相比的最终测试时性能。为了开发适用于实际应用的高效算法，我们在所有实验中对所有方法都采用低数据量设置：可用于（元）训练的数据量在各方法间固定，根据领域不同大致相当于 1.5 至 3 小时的真实世界经验。我们还提供了 MB 预言机的性能，该预言机仅使用来自给定测试环境的无限数据进行训练（而不需要泛化到各种训练环境）。

在这些实验中，请注意所有智能体都在任务/环境分布上进行了元训练（如上所述），但我们在测试时评估它们在未见环境上的适应能力。我们测试每种方法适应环境突变的能力，以及泛化到训练环境之外的能力。我们在半猎豹（HC）禁用关节、蚂蚁残废腿和半猎豹码头环境上评估快速适应（F.A.）组件。在前两个环境中，我们在一次运行中途使机器人的一个关节/腿发生故障。我们还在以下任务上评估泛化组件：

半猎豹禁用关节和蚂蚁残废腿任务，但这次发生故障的腿/关节在训练期间未曾以残废形式出现过。我们测试泛化的最后一个环境是半猎豹斜坡地形，智能体需要在一个陡坡上上下下奔跑，这超出了它在训练期间经历的平缓坡度范围。结果如图 5 所示，回报经过归一化处理，使得基于模型 (MB) 的预言机达到 1 的回报。

在所有实验中，由于训练数据量少，TRPO 表现不佳。尽管 MB+DE 比 MB 实现了更好的泛化，但其适应速度缓慢导致它在需要快速适应的环境中落后于 MB。另一方面，我们的方法在所有实验中都超越了其他方法。事实上，在半猎豹码头和蚂蚁环境的快速适应中，我们的方法超越了基于模型的预言机。这一结果展示了在随机环境中适应的重要性，即使使用大量数据训练的模型也无法对意外事件或干扰保持鲁棒。ReBAL 在需要更长序列输入以更好评估当前环境设置的场景中展现了其优势，但总体而言，GrBAL 在泛化和快速适应方面似乎表现更好。




图 5: 在各种动态测试环境中的仿真结果。GrBAL 在所有需要快速适应的实验中均优于其他方法，甚至优于基于模型的预言机。这些结果凸显了训练全局模型的难度以及适应的重要性。

6.4 真实世界结果

为了测试我们基于元模型的强化学习方法的样本效率，以及其执行快速有效在线适应的能力，我们将 GrBAL 应用于一个真实的腿式微型机器人，并与基于模型的强化学习进行比较

(MB) 以及带动态评估的基于模型的强化学习 (MB+DE)。由于运行真实机器人实验的成本较高，我们选择了性能更优的方法 (即 GrBAL) 在真实机器人上进行评估。如图 1 和图 2 所示，这种小型六足机器人具有高度随机和动态的运动特性，给建模和控制带来了挑战。该机器人是在线自适应的理想对象，原因如下：其快速制造工艺和众多定制设计步骤使得每次都无法复现相同的动力学特性；其连杆和其他身体部件会随时间磨损；其运动速度极快且动态性强。

该机器人的状态空间是一个 24 维向量，包括质心位置和速度、质心姿态和角速度、电机的反电动势读数、腿部电机角度和速度的编码器读数以及电池电压。我们将动作空间定义为旋转腿的速度设定值。由于每侧的一个电机与该侧的三条腿耦合，动作空间的维度为二。所有实验均在动作捕捉室中进行。计算在外部计算机上完成，速度设定值通过无线电以 10 Hz 的频率传输，由机器人机载微控制器上的 PID 控制器执行。

我们使用方程 3 中描述的元目标为该机器人元训练一个动力学模型，并训练其在完全来自三种不同训练地形 (地毯、泡沫塑料和草皮) 的真实世界数据上进行自适应。我们从三种训练地形中各收集了约 30 分钟的数据。这些数据完全使用随机策略结合安全策略收集，安全策略的唯一目的是防止机器人离开感兴趣区域。

我们的第一组结果 (表 1) 表明，当使用随机策略的数据训练动力学模型时，采用标准监督学习目标训练的模型 (MB) 和 GrBAL 模型在执行训练分布内地形上的期望轨迹方面达到了相当的性能。

接下来，我们测试了本方法在其预期用途上的性能：在测试时对学习模型进行快速在线自适应，以成功执行新的、变化的或分布外环境。与上述比较类似，我们将 GrBAL 与一种基于模型的方法 (MB) 进行比较，该方法既不涉及元训练也不涉及在线自适应，同时还与一种动态评估方法进行比较，该方法涉及对该 MB 模型进行在线自适应 (MB+DE)。我们的结果 (图 6) 表明，GrBAL 显著优于 MB 和 MB+DE，并且与 MB 和 MB+DE 不同，GrBAL 能够快速：1) 在线自适应缺失的腿，2) 适应新的地形和坡度，3) 处理姿态估计中的校准错误或误差，以及 4) 补偿牵引负载。这些环境均未

		Left	Str	Z-z	F-8
Carpet	GrBAL	4.07	3.26	7.08	5.28
	MB	3.94	3.26	6.56	5.21
Styrofoam	GrBAL	3.90	3.75	7.55	6.01
	MB	4.09	4.06	7.48	6.54
Turf	GrBAL	1.99	1.65	2.79	3.40
	MB	1.87	1.69	3.52	2.61

表 1: 在训练期间见过的三种地形上测试时, 真实世界 GrBAL 和 MB 结果的轨迹跟踪代价。此处测试了左转 (Left)、直线 (Str)、之字形 (Z-z) 和 8 字形 (F-8) 形状。两种方法性能相当, 表明在训练地形中不需要在线自适应, 但包含在线自适应也无害。




图 6: 在需要在线自适应和/或训练期间从未见过的环境中测试时, GrBAL 明显优于 MB 和 MB+DE。

这些环境在训练期间均未见, 但智能体学会如何学习的能力使其能够快速利用先验知识并进行微调, 以在线适应新环境。此外, MB 和 MB+DE 基线的较差性能不仅表明需要自适应, 还表明需要良好的初始参数来进行自适应 (在本例中为元学习参数)。图 7 中这些实验的定性结果表明, 即使在测试时出现新环境和意外扰动 (如腿部缺失) 的情况下, 机器人也能够使用我们的方法进行在线自适应并有效跟踪目标轨迹。

跳跃式步态; 因此, 其动力学特性强烈依赖于当前的地形或环境。




图 7: 黑色虚线表示 xy 平面中的期望轨迹。通过有效的在线自适应, 本文方法能够防止因缺失腿部而产生的漂移, 防止沿斜坡侧向滑动, 考虑姿态标定误差, 并适应牵引负载 (从左至右)。值得注意的是, 这些任务或环境在训练期间均未出现, 且需要快速有效的在线自适应才能成功。

7 结论

本文提出一种基于模型的元强化学习方法, 能够在动态环境中对大型且表达能力强的模型进行快速在线自适应。研究表明, 对在线自适应模型进行元学习, 可使方法适应未见情形或环境的突然剧烈变化, 同时训练样本效率高。本文给出该方法的两种实例 (ReBAL 和 GrBAL), 并在一系列连续控制任务上与先前方法进行比较。最后, 与无模型元强化学习方法相比, 本文方法在实际应用中具有实用性, 且快速自适应能力在复杂真实动态环境下尤为重要。

参考文献

- M. Al-Shedivat, T. Bansal, Y. Burda, I. Sutskever, I. Mordatch, and P. Abbeel. Continuous adaptation via meta-learning in nonstationary and competitive environments. *CoRR*, abs/1710.03641, 2017.
- M. Andrychowicz, M. Denil, S. G. Colmenarejo, M. W. Hoffman, D. Pfau, T. Schaul, and N. de Freitas. Learning to learn by gradient descent by gradient descent. *CoRR*, abs/1606.04474, 2016.
- K. J. Åström and B. Wittenmark. *Adaptive control*. Courier Corporation, 2013.
- A. Aswani, P. Bouffard, and C. Tomlin. Extensions of learning-based model predictive control for real-time application to a quadrotor helicopter. In *American Control Conference (ACC)*, 2012. IEEE, 2012.
- B. Baker, O. Gupta, N. Naik, and R. Raskar. Designing neural network architectures using reinforcement learning. *arXiv preprint arXiv:1611.02167*, 2016.
- Y. Bengio, S. Bengio, and J. Cloutier. *Learning a synaptic learning rule*. Université de Montréal, Département d’informatique et de recherche opérationnelle, 1990.
- D. A. Braun, A. Aertsen, D. M. Wolpert, and C. Mehring. Learning optimal adaptation strategies in unpredictable motor tasks. *Journal of Neuroscience*, 2009.
- K. Chua, R. Calandra, R. McAllister, and S. Levine. Deep reinforcement learning in a handful of trials using probabilistic dynamics models. *arXiv preprint arXiv:1805.12114*, 2018.
- M. Deisenroth and C. E. Rasmussen. Pilco: A model-based and data-efficient approach to policy search. In *International Conference on machine learning (ICML)*, pages 465–472, 2011.
- M. P. Deisenroth, G. Neumann, J. Peters, et al. A survey on policy search for robotics. *Foundations and Trends® in Robotics*, 2(1–2):1–142, 2013.
- A. Doerr, D. Nguyen-Tuong, A. Marco, S. Schaal, and S. Trimpe. Model-based policy search for automatic tuning of multivariate PID controllers. *CoRR*, abs/1703.02899, 2017. URL <http://arxiv.org/abs/1703.02899>.
- Y. Duan, J. Schulman, X. Chen, P. L. Bartlett, I. Sutskever, and P. Abbeel. RL²: Fast reinforcement learning via slow reinforcement learning. *CoRR*, abs/1611.02779, 2016.
- C. Finn and S. Levine. Meta-learning and universality: Deep representations and gradient descent can approximate any learning algorithm. *CoRR*, abs/1710.11622, 2017.
- C. Finn, P. Abbeel, and S. Levine. Model-agnostic meta-learning for fast adaptation of deep networks. *CoRR*, abs/1703.03400, 2017.
- M. Fortunato, C. Blundell, and O. Vinyals. Bayesian recurrent neural networks. *arXiv preprint arXiv:1704.02798*, 2017.
- J. Fu, S. Levine, and P. Abbeel. One-shot learning of manipulation skills with online dynamics adaptation and neural network priors. *CoRR*, abs/1509.06841, 2015.
- S. Gu, T. Lillicrap, I. Sutskever, and S. Levine. Continuous deep q-learning with model-based acceleration. In *International Conference on Machine Learning*, pages 2829–2838, 2016.
- S. Kelouwani, K. Adegbon, K. Agbossou, and Y. Dube. Online system identification and adaptive control for pem fuel cell maximum efficiency tracking. *IEEE Transactions on Energy Conversion*, 27(3):580–592, 2012.
- J. Ko and D. Fox. Gp-bayesfilters: Bayesian filtering using gaussian process prediction and observation models. *Autonomous Robots*, 27(1):75–90, 2009.
- B. Krause, L. Lu, I. Murray, and S. Renals. Multiplicative lstm for sequence modelling. *arXiv preprint arXiv:1609.07959*, 2016.
- B. Krause, E. Kahembwe, I. Murray, and S. Renals. Dynamic evaluation of neural sequence models. *CoRR*, abs/1709.07432, 2017.
- T. Kurutach, I. Clavera, Y. Duan, A. Tamar, and P. Abbeel. Model-ensemble trust-region policy optimization. *arXiv preprint arXiv:1802.10592*, 2018.
- B. M. Lake, R. Salakhutdinov, and J. B. Tenenbaum. Human-level concept learning through probabilistic program induction. *Science*, 2015.

- I. Lenz, R. A. Knepper, and A. Saxena. Deepmpc: Learning deep latent features for model predictive control. In *Robotics: Science and Systems*, 2015.
- S. Levine and V. Koltun. Guided policy search. In *International Conference on Machine Learning*, pages 1–9, 2013.
- S. Levine, C. Finn, T. Darrell, and P. Abbeel. End-to-end training of deep visuomotor policies. *Journal of Machine Learning Research (JMLR)*, 2016.
- K. Li and J. Malik. Learning to optimize. *arXiv preprint arXiv:1606.01885*, 2016.
- T. P. Lillicrap, J. J. Hunt, A. Pritzel, N. Heess, T. Erez, Y. Tassa, D. Silver, and D. Wierstra. Continuous control with deep reinforcement learning. *CoRR*, abs/1509.02971, 2015.
- P. Manganiello, M. Ricco, G. Petrone, E. Monmasson, and G. Spagnuolo. Optimization of perturbative pv mppt methods through online system identification. *IEEE Trans. Industrial Electronics*, 61(12):6812–6821, 2014.
- F. Meier and S. Schaal. Drifting gaussian processes with varying neighborhood sizes for online model learning. In *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA) 2016*. IEEE, May 2016.
- F. Meier, D. Kappler, N. Ratliff, and S. Schaal. Towards robust online inverse dynamics learning. In *Proceedings of the IEEE/RSJ Conference on Intelligent Robots and Systems*. IEEE, 2016.
- N. Mishra, M. Rohaninejad, X. Chen, and P. Abbeel. A simple neural attentive meta-learner. In *NIPS 2017 Workshop on Meta-Learning*, 2017.
- V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski, et al. Human-level control through deep reinforcement learning. *Nature*, 2015.
- T. Munkhdalai and H. Yu. Meta networks. *arXiv preprint arXiv:1703.00837*, 2017.
- T. Munkhdalai, X. Yuan, S. Mehri, T. Wang, and A. Trischler. Learning rapid-temporal adaptations. *arXiv preprint arXiv:1712.09926*, 2017.
- A. Nagabandi, G. Kahn, R. S. Fearing, and S. Levine. Neural network dynamics for model-based deep reinforcement learning with model-free fine-tuning. *CoRR*, abs/1708.02596, 2017a.
- A. Nagabandi, G. Yang, T. Asmar, R. Pandya, G. Kahn, S. Levine, and R. S. Fearing. Learning image-conditioned dynamics models for control of under-actuated legged millirobots. *arXiv preprint arXiv:1711.05253*, 2017b.
- D. K. Naik and R. Mammone. Meta-neural networks that learn by learning. In *Neural Networks, 1992. IJCNN., International Joint Conference on*, volume 1, pages 437–442. IEEE, 1992.
- P. Pastor, L. Righetti, M. Kalakrishnan, and S. Schaal. Online movement adaptation based on previous sensor experiences. In *IEEE International Conference on Intelligent Robots and Systems (IROS)*, pages 365–371, 9 2011.
- J. Peters and S. Schaal. Reinforcement learning of motor skills with policy gradients. *Neural networks*, 2008.
- A. Rai, G. Sutanto, S. Schaal, and F. Meier. Learning feedback terms for reactive planning and control. In *Proceedings 2017 IEEE International Conference on Robotics and Automation (ICRA)*, Piscataway, NJ, USA, May 2017. IEEE.
- S. Ravi and H. Larochelle. Optimization as a model for few-shot learning. *International Conference on Learning Representations (ICLR)*, 2018.
- M. Rei. Online representation learning in recurrent neural language models. *CoRR*, abs/1508.03854, 2015.
- S. Sæmundsson, K. Hofmann, and M. P. Deisenroth. Meta reinforcement learning with latent variable gaussian processes. *arXiv preprint arXiv:1803.07551*, 2018.
- A. Santoro, S. Bartunov, M. Botvinick, D. Wierstra, and T. Lillicrap. One-shot learning with memory-augmented neural networks. *arXiv preprint arXiv:1605.06065*, 2016.
- S. S. Sastry and A. Isidori. Adaptive control of linearizable systems. *IEEE Transactions on Automatic Control*, 1989.
- J. Schmidhuber. Learning to control fast-weight memories: An alternative to dynamic recurrent networks. *Neural Computation*, 1992.

- J. Schmidhuber and R. Huber. Learning to generate artificial fovea trajectories for target detection. *International Journal of Neural Systems*, 1991.
- J. Schulman, S. Levine, P. Moritz, M. I. Jordan, and P. Abbeel. Trust region policy optimization. *CoRR*, abs/1502.05477, 2015.
- D. Silver, J. Schrittwieser, K. Simonyan, I. Antonoglou, A. Huang, A. Guez, T. Hubert, L. Baker, M. Lai, A. Bolton, et al. Mastering the game of go without human knowledge. *Nature*, 2017.
- F. Sung, L. Zhang, T. Xiang, T. Hospedales, and Y. Yang. Learning to learn: Meta-critic networks for sample efficient learning. *arXiv preprint arXiv:1706.09529*, 2017.
- M. Tanaskovic, L. Fagiano, R. Smith, P. Goulart, and M. Morari. Adaptive model predictive control for constrained linear systems. In *Control Conference (ECC), 2013 European*. IEEE, 2013.
- S. Thrun and L. Pratt. Learning to learn: Introduction and overview. In *Learning to learn*. Springer, 1998.
- E. Todorov, T. Erez, and Y. Tassa. Mujoco: A physics engine for model-based control. In *IROS*, pages 5026–5033. IEEE, 2012.
- S. J. Underwood and I. Husain. Online parameter estimation and adaptive control of permanent-magnet synchronous machines. *IEEE Transactions on Industrial Electronics*, 57(7):2435–2443, 2010.
- J. X. Wang, Z. Kurth-Nelson, D. Tirumala, H. Soyer, J. Z. Leibo, R. Munos, C. Blundell, D. Kumaran, and M. Botvinick. Learning to reinforcement learn. *arXiv preprint arXiv:1611.05763*, 2016.
- A. Weinstein and M. Botvinick. Structure learning in motor control: A deep reinforcement learning model. *CoRR*, abs/1706.06827, 2017.
- G. Williams, A. Aldrich, and E. Theodorou. Model predictive path integral control using covariance variable importance sampling. *CoRR*, abs/1509.01149, 2015.
- G. Williams, N. Wagener, B. Goldfain, P. Drews, J. M. Rehg, B. Boots, and E. A. Theodorou. Information theoretic mpc for model-based reinforcement learning. In *International Conference on Robotics and Automation (ICRA)*, 2017.
- A. S. Younger, S. Hochreiter, and P. R. Conwell. Meta-learning with backpropagation. In *International Joint Conference on Neural Networks*. IEEE, 2001.

A 模型预测误差：更新前与更新后

本节展示 GrBAL 中自适应的效果。具体而言，给出 K 步归一化误差的直方图，以及轨迹中该误差的逐时间步可视化。在所有任务和环境中，更新后的模型 $\hat{p}_{\theta'}$ 比更新前的模型 $\hat{p}_{\theta}$ 取得更低的预测误差。




图 8：不同任务下 K 步归一化误差的直方图。GrBAL 使用更新规则给出的参数时，模型误差更低。




图 9：在每个时间步展示不同任务下 K 步归一化误差。GrBAL 使用更新规则给出的参数时，模型误差更低。




图 10: 元训练分布对测试性能的影响

B 元训练分布的影响

为了探究训练分布如何影响测试性能，我们进行了一项实验，使用 GrBAL 训练 7 自由度机械臂的模型。每个模型在元训练期间使用的数据点数量相同，但这些数据点来自不同的力扰动范围。我们观察到（如下图所示）：

1. 训练期间见识更多数据有助于测试——在训练期间见识大范围力扰动的模型表现最佳
2. 训练期间未见识任何扰动力模型表现最差
3. 中间 3 个模型在“恒定力= 4”情形下表现相当，该情形对这些模型而言属于分布外任务。因此，训练期间需要见识什么内容以便在训练时实现适应，实际上并没有很强的限制（尽管总体趋势是见识越多越好）

C K 和 M 的敏感性

本节分析我们的算法对超参数 K 和 M 的敏感程度。在本文所有实验中，我们将 K 设为等于 M 。图 11 展示了对于不同的 $K = M$ 值，GrBAL 在元训练迭代过程中的平均回报。对于这些超参数的不同取值，智能体的性能基本不受影响，这表明我们的算法对这些值并不特别敏感。对于不同的智能体，这些超参数的最优值取决于各种任务细节，例如状态中包含的信息量（完全信息的状态变量无需额外的过去时间步）以及单个时间步的持续时间（较长的时间步持续时间使得预测更远的未来更加困难）。




图 11: 不同 $K = M$ 取值下，GrBAL 在半猎豹残疾与斜坡地形环境中的学习曲线。横轴表示元训练期间的数据聚合迭代次数，纵轴表示使用特定迭代得到的元学习模型进行在线自适应时取得的平均回报。曲线表明，GrBAL 的性能对这些超参数的取值相当稳健。

D 奖励函数

对于每个 MuJoCo 智能体，其各项任务均采用相同的奖励函数。表 2 展示了各智能体所使用的奖励函数。我们用 x_t 表示智能体在时刻 t , e_t 的 x 坐标，该坐标指 7 自由度机械臂末端执行器的位置，而 g 则对应期望目标的位置。

表 2: 奖励函数

奖励函数	半猎豹	蚂蚁 7
自由度机械臂	$\frac{x_{t+1} - x_t}{0.01} - 0.05 \ e_t\ _2^2$	$\frac{x_{t+1} - x_t}{0.05} - 0.005 \ a_t\ _2^2 + 0.05$

E 超参数

下面列出我们实验中的超参数。在所有实验中，我们对 GrBAL 的更新规则使用单步梯度。TRPO 的学习率 (LR) 对应 Kullback – Leibler 发散约束。 $\# \text{ Task/itr}$ 表示用于收集数据以训练模型所采用的任务数量，而 $\# \text{ TS/itr}$ 是所有任务收集的总时间步数。最后， T 指任务的时间范围。

表 3: 半猎豹任务的超参数

	LR	Inner LR	Epochs	K	M	Batch Size	$\# \text{ Tasks/itr}$	$\# \text{ TS/itr}$	T	$n_A \text{ Train}$	H Train	$n_A \text{ Test}$	H Test
GrBAL	0.001	0.01	50	32	32	500	32	64000	1000	1000	10	2500	15
ReBAL	0.001	-	50	32	32	500	32	64000	1000	1000	10	2500	15
MB	0.001	-	50	-	-	500	64	64000	1000	1000	10	2500	15
TRPO	0.05	-	-	-	-	50000	50	50000	1000	-	-	-	-

表 4: 蚂蚁任务的超参数

	LR	Inner LR	Epochs	K	M	Batch Size	$\# \text{ Tasks/itr}$	$\# \text{ TS/itr}$	T	$n_A \text{ Train}$	H Train	$n_A \text{ Test}$	H Test
GrBAL	0.001	0.001	50	10	16	500	32	24000	500	1000	15	1000	15
ReBAL	0.001	-	50	32	16	500	32	32000	500	1000	15	1000	15
MB	0.001	-	70	-	-	500	10	10000	500	1000	15	1000	15
TRPO	0.05	-	-	-	-	50000	50	50000	500	-	-	-	-

表 5: 七自由度机械臂任务的超参数

	LR	Inner LR	Epochs	K	M	Batch Size	$\# \text{ Tasks/itr}$	$\# \text{ TS/itr}$	T	$n_a \text{ Train}$	H Train	$n_a \text{ Test}$	H Test
GrBAL	0.001	0.001	50	32	16	1500	32	24000	500	1000	15	1000	15
ReBAL	0.001	-	50	32	16	1500	32	24000	500	1000	15	1000	15
MB	0.001	-	70	-	-	10000	10	10000	500	1000	15	1000	15
TRPO	0.05	-	-	-	-	50000	50	50000	500	-	-	-	-