

面向端到端多模态规划的广义轨迹评分

Zhenxin Li^{1,2} Wenhao Yao² Zi Wang¹ Xinglong Sun¹ Joshua Chen¹
Nadine Chang¹ Maying Shen¹ Zuxuan Wu² Shiyi Lan¹ Jose M. Alvarez¹
¹NVIDIA ²Fudan University

摘要

端到端多模态规划是自动驾驶中一种有前景的范式，能够利用多样化的轨迹候选进行决策。其中一个关键组件是鲁棒的轨迹评分器，能够从这些候选中选择最优轨迹。尽管近期轨迹评分器侧重于对大量静态轨迹或少量动态生成的轨迹进行评分，但两种方法在泛化方面均面临显著局限性。静态词汇表提供了有效的粗粒度离散化，但难以进行细粒度自适应；而动态提议提供了精细的精确性，却无法捕捉更广泛的轨迹分布。为克服这些挑战，本文提出 GTRS（广义轨迹评分），一个统一的端到端多模态规划框架，结合了粗粒度和细粒度轨迹评估。GTRS 包含三项互补创新：（1）基于扩散的轨迹生成器，产生多样化的细粒度提议；（2）词汇表泛化技术，在超密集轨迹集上使用随机失活正则化训练评分器，使其能够在较小子集上进行鲁棒推理；（3）传感器增强策略，增强域外泛化能力，同时结合关键轨迹判别的细化训练。作为 Navsim v2 挑战赛的获胜方案，GTRS 即使在传感器输入次优的情况下也展现出卓越性能，接近依赖真值感知的特权方法。代码将在 <https://github.com/NVlabs/GTRS> 提供。

端到端多模态规划的典型问题涉及在给定原始传感器数据、无法获取真值感知的情况下，通过评分 [1, 3, 16, 18, 19, 24] 评估多个轨迹提议。规划器选择具有最高似然的轨迹作为决策。

当前的轨迹评分方法通常分为两类：（1）对大型静态词汇表进行评分 [3, 16, 18, 24]，以及（2）对少量动态生成的候选轨迹进行评分 [19, 30]。这两种方法在泛化方面都面临挑战。固定的轨迹词汇表 [3, 16, 18] 灵活性有限，因为它们无法适应需要动态候选轨迹的情况。同时，依赖少量动态候选轨迹的方法 [19, 30] 往往无法泛化到未见过的轨迹，因为评分器在训练期间只接触到狭窄的子集。理想情况下，一个稳健的评分器应该能够跨多样化的轨迹分布进行泛化——无论是静态的还是动态的——以处理现实世界场景的全部复杂性。为了解决这些局限性，我们提出了 GTRS（广义轨迹评分）用于端到端多模态规划。GTRS 建立在一个关键洞见之上：有效的轨迹评分器必须在粗粒度和细粒度的轨迹分布上进行训练，以培养稳健的泛化能力。我们的方法包含三种互补的技术，每种技术都对应一个专门的子网络，如图 1 所示：1. 基于扩散的轨迹生成（DP）：扩散策略（DP）[4] 以鸟瞰图特征为条件生成多样化的轨迹候选。DP 提供了对于安全关键情况至关重要的细粒度细节，而这些细节是粗粒度、固定词汇表无法捕捉的。（第 2.1 节）

1. 引言

端到端多模态规划已成为自动驾驶中一种强大的方法。与预测单一轨迹的传统单模态规划器 [5, 11, 12] 不同，多模态方法 [1, 3, 6, 15, 16, 18, 19] 生成多个候选，从而在推理过程中实现更大的适应性。这种适应性支持广泛的应用，包括响应语言指令 [21 – 23, 28]、适应不同驾驶风格 [15, 25] 以及导航复杂驾驶环境 [16, 18, 24]。

2. 轨迹词汇表泛化（GTRS-Dense）：

我们在覆盖广泛驾驶场景的超密集轨迹样本词汇表（16,384 条轨迹）上进行训练。为了最大化固定轨迹词汇表的泛化能力，我们提出了一种轨迹随机失活训练策略。其思想是故意在训练和推理词汇表之间制造不匹配——训练模型在推理期间有效地泛化到未见过的轨迹分布。（第 2.2 节）

3. 带细化的传感器增强（GTRS-Aug）：

为了处理意外的轨迹事件和数据分布




图 1. GTRS 的三大支柱。

针对视点变化形式的分布偏移，本文引入一种数据增强策略，通过对传感器输入施加旋转扰动，显著提升了对域外环境的鲁棒性。此外，一种精化训练机制使模型能够区分细微不同的轨迹选项。（第 2.3 节）在 Navhard 基准上评估表明，即使在次优传感器条件下，GTRS 也展现出强大的轨迹评分能力。本文贡献如下：1. 本文提出 GTRS，一种可泛化的端到端多模态规划框架，结合了基于扩散的轨迹生成与词汇评分。借助超密集词汇表、传感器增强和精化策略，GTRS 能够对动态和静态候选轨迹进行有效评分。2. GTRS 在 Navhard 基准 [2] 上展现出卓越的规划性能和对域外数据的泛化能力。通过模型集成，本文基于传感器的 GTRS——Navsim v2 挑战赛的获胜方案——接近最先进的规划器 PDM-Closed [6] 的性能，后者基于真值感知运行，不受传感器输入退化的影响。

2. 广义张量秩稀疏性的三大支柱

2.1. 轨迹生成器

为了在推理过程中获得高质量的动态轨迹提案，扩散模型（Diffusion Model）因其生成多模态轨迹候选的能力，已成为自动驾驶领域的常用方法 [4, 13, 15, 19, 29 – 31, 33]。本文采用基于扩散策略（Diffusion Policy）的轨迹生成器，遵循 [4] 的方法生成多个轨迹提案。该子网络由图像骨干网络组成，用于提取图像特征

tures，一个鸟瞰图编码器，其中鸟瞰图查询通过变换器编码器 [26] 关注图像特征，以及一个扩散 Transformer，它根据鸟瞰图特征生成 N 轨迹提案 $\mathcal{V}_{dp}$ 。在训练过程中，我们遵循 Transfuser [5]，并加入一个鸟瞰图分割头，为鸟瞰图特征提供监督。对于扩散 Transformer，我们对真实轨迹航点应用一阶微分以归一化输入，并使用 DDPM 调度策略 [10] 对真实轨迹进行去噪。

2.2. 具备词汇泛化能力的评分器

虽然基于扩散的轨迹生成器提供了细粒度的轨迹建议，但它们在捕捉可能驾驶场景的全部广度方面仍然有限。为了实现鲁棒的泛化，我们引入了一种新颖的词汇泛化技术，该技术训练模型有效地评估多样化的轨迹分布，即使是训练期间未见过的分布。我们提出了广义词汇评分器 **GTRS-Dense**，它建立在 Hydra-MDP [18] 之上，但在轨迹评估中引入了关键创新。该架构包括图像主干、将候选编码为特征表示的轨迹分词器，以及建模轨迹和图像标记之间复杂交互的变换器解码器 [26]。我们的关键创新是双重的：首先，我们刻意在超密集轨迹词汇表（ $\mathcal{V}_{XL}$ 具有 16,384 条不同轨迹）上进行训练，全面覆盖轨迹空间，同时在较小的词汇表（ $\mathcal{V}_L$ （具有 8,192 条轨迹））上进行推理——迫使模型开发可泛化的表示。其次，我们在训练期间对 $\mathcal{V}_{XL}$ 应用词汇随机失活，随机移除一半的

方法	图像分辨率	主干	训练词汇表	推理词汇表	EPDMS1	EPDMS2	EPDMS
DP w/o Scorer			512×2048	V2-99	-	$\mathcal{V}_{dp}$ (Random)	60.9 40.8 25.6
GTRS-Dense			512×2048	EVA-ViT-L	$\mathcal{V}_{XL}$	$\mathcal{V}_{dp}$	76.6 48.6 36.7
			512×2048	EVA-ViT-L	$\mathcal{V}_{XL}$	$\mathcal{V}_{XL}$	78.1 50.2 39.7
			512×2048	EVA-ViT-L	$\mathcal{V}_{XL}$	$\mathcal{V}_{dp} \cup \mathcal{V}_{XL}$	77.4 52.7 40.8
			512×2048	EVA-ViT-L	$\mathcal{V}_{XL}$	$\mathcal{V}_{dp} \cup \mathcal{V}_L$	71.8 57.3 42.0
			512×2048	EVA-ViT-L	$\mathcal{V}_{XL}$ (Dropout)	$\mathcal{V}_{dp} \cup \mathcal{V}_L$	73.1 59.0 43.4
Baseline Scorer [18]			256×1024	ViT-L	$\mathcal{V}_L$	$\mathcal{V}_{dp} \cup \mathcal{V}_L$	73.4 54.1 40.6
GTRS-Aug			256×1024	ViT-L	$\mathcal{V}_L$	$\mathcal{V}_{dp} \cup \mathcal{V}_L$	75.0 56.9 43.4

表 1. 广义轨迹评分路线图。随机表示我们在推理期间从 $\mathcal{V}_{dp}$ 中随机选择一条轨迹。V2-99 [14] 从 DD3D [20] 预训练，EVA-ViT-L [9] 从 StreamPETR [27] 初始化，ViT-L [8] 来自 Depth Anything [32]。




图 2. GTRS 的推理流程。每个批次中的轨迹。这有多种目的：（1）它在训练和推理期间对齐轨迹标记的数量，（2）它创建有意的分布偏移以提高鲁棒性，以及（3）它作为有效的正则化器防止过拟合特定轨迹模式。这种词汇化技术使我们的模型能够有效地评分静态轨迹词汇表和动态生成的建议，而无需对两种类型进行专门训练——这是以前方法难以实现的能力。

2.3. 传感器增强评分器与细化

为了进一步增强模型在多样化和域外环境中的鲁棒性，我们开发了一种系统化的传感器增强策略，以及一种精化训练机制。该方法聚焦于两个关键挑战：处理传感器数据中的感知分布偏移，以及在安全关键场景中区分细微不同的轨迹选项。首先，我们引入结构化传感器扰动，通过对输入图像应用受控的二维水平视角旋转。与随机增强不同，这些扰动专门针对模型在不同观察条件下保持轨迹评估一致性的能力。为了保持标签一致性，我们对用于训练的真值应用相应的变换。其次，我们开发了一种专注于细粒度轨迹判别的精化训练机制。作为一个仅用于训练模块，它引入了一个额外的变换器解码器，逐步精化前 k 个最有前景候选轨迹的得分，使模型能够捕捉相似轨迹之间的细微差异。

精化过程由自蒸馏框架引导，其中模型的指数移动平均副本提供软监督信号：

$$\tilde{y}_i^m = \hat{y}_i^m + \text{clip}(s_{i,\text{teacher}}^m - y_i^m, -\delta_m, \delta_m), \quad (1)$$

其中 $\tilde{y}_i^m$ 表示精化后的目标得分， $\hat{y}_i^m$ 是真值得分， $s_{i,\text{teacher}}^m$ 是教师模型的预测。裁剪参数 δ_m 确保精化后的目标保持在真值的合理范围内。这些策略共同使 **GTRS-Aug** 能够在具有挑战性的域外环境中稳健运行，而无需特定领域的适应。3. 推理时集成

在训练上述子网络之后，我们在推理阶段将轨迹生成器与其中一个轨迹评分器（即 GTRS-Dense、GTRS-Aug）结合，如图 2 所示。生成器产生的动态提议 $\mathcal{V}_{dp}$ 被追加到推理词汇表 $\mathcal{V}_L$ 中，合并后的集合 $\mathcal{V}_{dp} \cup \mathcal{V}_L$ 由评分器进行分词和评分。这种在推理时而非训练时顺序集成动态提议的做法，是一种刻意的设计选择，旨在发挥两种方法的优势。通过仅在多样化的静态词汇表上训练，评分器在广泛的轨迹模式上培养了稳健的泛化能力。随后，在推理阶段，基于扩散的生成器提供针对当前场景量身定制的细粒度、上下文感知的轨迹。同时，该设计避免了将扩散采样集成到训练循环中带来的计算开销和潜在不稳定性，同时仍能在部署期间受益于动态生成轨迹的精确性。

4. 实验

4.1. 数据集与度量

Navsim 数据集 [7] 专为评估端到端驾驶系统而设计，解决了先前基准测试 [17] 中的局限性。Navsim v2 挑战赛引入了一个新的划分——Navhard，其中包含困难的真实世界场景及其使用 3DGS 生成的合成延续。

Method	Img. Resolution	Backbone	Stage	NC	DAC	DDC	TLC	EP	TTC	LK	HC	EC	EPDMS
PDM-Closed [6]	GT Perception	-	Stage 1 Stage 2	94.4 88.1	98.8 90.6	100 96.3	99.5 98.5	100 100	93.5 83.1	99.3 73.7	87.7 91.5	36.0 25.4	51.3
LTF [5]	256×1024	ResNet34	Stage 1 Stage 2	96.2 77.7	79.5 70.2	99.1 84.2	99.5 98.0	84.1 85.1	95.1 75.6	94.2 45.4	97.5 95.7	79.1 75.9	23.1
GTRS-Dense	512×2048	V2-99	Stage 1 Stage 2	98.7 91.4	95.8 89.2	99.4 94.4	99.3 98.8	72.8 69.5	98.7 90.1	95.1 54.6	96.9 94.1	40.4 49.7	41.7
		EVA-ViT-L	Stage 1 Stage 2	97.6 91.9	95.8 91.3	99.7 92.7	99.8 99.0	77.2 72.7	97.8 90.4	95.3 53.8	97.3 94.1	46.7 41.6	43.4
		ViT-L	Stage 1	98.9	98.2	99.8	99.6	73.9	98.9	95.3	97.3	40.0	45.3
			Stage 2	91.5	90.8	94.7	98.5	70.8	90.1	55.4	97.2	54.2	
GTRS-Aug	512×2048	V2-99	Stage 1 Stage 2	98.9 87.9	95.1 88.8	99.2 89.6	99.6 98.8	76.1 80.3	99.1 86.0	94.7 53.5	97.6 97.1	54.2 56.1	42.1
		EVA-ViT-L	Stage 1 Stage 2	98.7 89.5	98.0 89.6	99.1 92.9	99.8 98.5	75.9 78.9	98.7 86.4	94.7 55.3	97.6 96.5	49.8 52.7	44.7
	256×1024	ViT-L	Stage 1	97.8	97.3	98.9	99.3	77.1	98.2	95.8	97.6	50.2	43.4
			Stage 2	90.3	88.9	90.8	98.9	81.1	87.4	54.2	95.1	48.3	
GTRS-E-Lite	512×2048	EVA-ViT-L	Stage 1 Stage 2	98.2 90.6	98.9 91.7	99.6 93.6	99.6 98.5	75.8 77.1	98.4 89.0	96.9 56.1	97.3 96.3	53.3 47.8	46.6
GTRS-E	*	*	Stage 1 Stage 2	98.9 92.3	99.3 93.3	99.8 94.6	99.8 99.2	75.2 73.1	98.4 91.2	96.0 53.9	97.6 96.7	51.6 56.8	49.4

表 2. Navhard 基准上的性能。骨干设置遵循表 1。GTRS-E-Lite 将 GTRS-Dense 和 GTRS-Aug 与 EVA-ViT-L 集成。挑战赛获胜方案 GTRS-E 集成了来自 GTRS-Dense 和 GTRS-Aug 的全部六个模型。

然而，我们观察到合成数据质量欠佳，通常包含失真和模糊等工件，可能损害基于传感器的规划器的性能。Navsim v2 挑战赛基于扩展 PDM 分数 (EPDMS) [16] 评估端到端模型，该分数是 PDM 分数 [7] 的扩展，通过聚合多个基于规则的度量¹实现。最后，它使用两阶段评分流程分别聚合真实世界数据（阶段 1）和合成数据（阶段 2）上的度量。

4.2. 实现细节

我们在 Navtrain 划分上使用 24 块 NVIDIA A100 GPU 训练所有模型，而 Navhard 划分和其他合成传感器数据不用于训练。默认情况下，训练进行 20 个轮次，总批大小为 528，而轨迹生成器的训练持续 50 个轮次。学习率和权重衰减分别为 2×10^{-4} 和 0.0。我们将前视图与中心裁剪的前左视图和前右视图拼接起来形成输入图像。对于轨迹生成器 DP，我们从后视图、右后视图和左后视图构建类似的输入图像，用于 BEV 构建。最后，我们使用 DDPM 调度器 [10] 进行 100 步去噪，并在 $\mathcal{V}_{dp}$ 中生成 100 个提议。

4.3. 通往广义轨迹评分的路线图

轨迹词汇泛化。我们使用多种推理词汇表对 GTRS-Dense 进行评估（表 4.3）。值得注意的是，尽管仅在超密集静态词汇表 $\mathcal{V}_{XL}$ 上训练，该评分器仍能很好地泛化到 $\mathcal{V}_{dp}$ 中未见过的动态提议（EPDMS: 36.7），展现出强大的零样本能力。

¹<https://github.com/autonomousvision/navsim/blob/main/docs/metrics.md>

通过大幅超越随机选择的生成器 (+11.1 EPDMS)，实现了少样本泛化。当将 $\mathcal{V}_{dp}$ 与 $\mathcal{V}_{XL}$ 结合时，性能比 $\mathcal{V}_{XL}$ 提高了 +1.1 EPDMS，证实了推理时动态提议的互补优势。有趣的是， $\mathcal{V}_{dp} \cup \mathcal{V}_L$ 优于 $\mathcal{V}_{dp} \cup \mathcal{V}_{XL}$ ，这可能是因为词汇复杂度的降低使得在域外合成数据上具有更好的泛化能力。最后，在训练期间对 $\mathcal{V}_{XL}$ 应用随机失活（dropout）获得了最佳性能（EPDMS: 43.4），表明词汇随机失活显著增强了泛化能力。

传感器增强与细化。最后，本文评估了融合传感器增强与精炼训练的 GTRS-Aug 模型。该模型达到了与最佳 GTRS-Dense 变体相同的顶级性能（EPDMS: 43.4），以显著优势（+2.8 EPDMS）超越了基线评分器 [18]。这证实了增强与精炼训练能够大幅提升轨迹评分性能。

4.4. 主要结果

如表 2 所示，我们的 GTRS 变体相较于 LTF 基线 [5] 取得了显著提升。通过将图像骨干网络扩展至 ViT-L [8] 和 EVA-ViT-L [9]，我们最佳的单模型在 Navhard 基准上达到了 45.3 EPDMS。此外，GTRS-E-Lite——在评分阶段由 GTRS-Dense 与 GTRS-Aug 组成的集成模型——达到了 46.6 EPDMS。我们赢得挑战的参赛方案 GTRS-E，即全部六个变体的集成，达到了 49.4 EPDMS，接近 PDM-Closed [6] 的性能——后者是一种依赖真实感知的特权规划器——尽管我们使用的是具有挑战性的合成传感器输入。这证明了我们的方法在轨迹分布和感知域两方面均具有卓越的泛化能力。

参考文献

- [1] Sourav Biswas, Sergio Casas, Quinlan Sykora, Ben Aggro, Abbas Sadat, and Raquel Urtasun. Quad: Query-based interpretable neural motion planning for autonomous driving. In *IEEE International Conference on Robotics and Automation*, pages 14236–14243. IEEE, 2024. 1
- [2] Wei Cao, Marcel Hallgarten, Tianyu Li, Daniel Dauner, Xunjiang Gu, Caojun Wang, Yakov Miron, Marco Aiello, Hongyang Li, Igor Gilitschenski, et al. Pseudo-simulation for autonomous driving. *arXiv preprint arXiv:2506.04218*, 2025. 2
- [3] Shaoyu Chen, Bo Jiang, Hao Gao, Bencheng Liao, Qing Xu, Qian Zhang, Chang Huang, Wenyu Liu, and Xinggang Wang. Vadv2: End-to-end vectorized autonomous driving via probabilistic planning. *arXiv preprint arXiv:2402.13243*, 2024. 1
- [4] Cheng Chi, Zhenjia Xu, Siyuan Feng, Eric Cousineau, Yilun Du, Benjamin Burchfiel, Russ Tedrake, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. *The International Journal of Robotics Research*, page 02783649241273668, 2023. 1, 2
- [5] Kashyap Chitta, Aditya Prakash, Bernhard Jaeger, Zehao Yu, Katrin Renz, and Andreas Geiger. Transfuser: Imitation with transformer-based sensor fusion for autonomous driving. *IEEE TPAMI*, 2022. 1, 2, 4
- [6] Daniel Dauner, Marcel Hallgarten, Andreas Geiger, and Kashyap Chitta. Parting with misconceptions about learning-based vehicle motion planning. In *Conference on Robot Learning*, pages 1268–1281. PMLR, 2023. 1, 2, 4
- [7] Daniel Dauner, Marcel Hallgarten, Tianyu Li, Xinshuo Weng, Zhiyu Huang, Zetong Yang, Hongyang Li, Igor Gilitschenski, Boris Ivanovic, Marco Pavone, Andreas Geiger, and Kashyap Chitta. Navsim: Data-driven non-reactive autonomous vehicle simulation and benchmarking. In *NeurIPS*, 2024. 3, 4
- [8] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, et al. An image is worth 16x16 words: Transformers for image recognition at scale. *arXiv preprint arXiv:2010.11929*, 2020. 3, 4
- [9] Yuxin Fang, Quan Sun, Xinggang Wang, Tiejun Huang, Xinlong Wang, and Yue Cao. Eva-02: A visual representation for neon genesis. *arXiv preprint arXiv:2303.11331*, 2023. 3, 4
- [10] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. *NeurIPS*, 33:6840–6851, 2020. 2, 4
- [11] Yihan Hu, Jiazhi Yang, Li Chen, Keyu Li, Chonghao Sima, Xizhou Zhu, Siqi Chai, Senyao Du, Tianwei Lin, Wenhai Wang, et al. Planning-oriented autonomous driving. In *CVPR*, pages 17853–17862, 2023. 1
- [12] Bo Jiang, Shaoyu Chen, Qing Xu, Bencheng Liao, Jiajie Chen, Helong Zhou, Qian Zhang, Wenyu Liu, Chang Huang, and Xinggang Wang. Vad: Vectorized scene representation for efficient autonomous driving. In *ICCV*, pages 8340–8350, 2023. 1
- [13] Chiyu Jiang, Andre Cornman, Cheolho Park, Benjamin Sapp, Yin Zhou, Dragomir Anguelov, et al. Motiondiffuser: Controllable multi-agent motion prediction using diffusion. In *CVPR*, pages 9644–9653, 2023. 2
- [14] Youngwan Lee, Joong-won Hwang, Sangrok Lee, Yuseok Bae, and Jongyoul Park. An energy and gpu-computation efficient backbone network for real-time object detection. In *CVPRW*, pages 0–0, 2019. 3
- [15] Derun Li, Jianwei Ren, Yue Wang, Xin Wen, Pengxiang Li, Leimeng Xu, Kun Zhan, Zhongpu Xia, Peng Jia, Xianpeng Lang, et al. Finetuning generative trajectory model with reinforcement learning from human feedback. *arXiv preprint arXiv:2503.10434*, 2025. 1, 2
- [16] Kailin Li, Zhenxin Li, Shiyi Lan, Yuan Xie, Zhizhong Zhang, Jiayi Liu, Zuxuan Wu, Zhiding Yu, and Jose M Alvarez. Hydra-mdp++: Advancing end-to-end driving via expert-guided hydra-distillation. *arXiv preprint arXiv:2503.12820*, 2025. 1, 4
- [17] Zhiqi Li, Zhiding Yu, Shiyi Lan, Jiahao Li, Jan Kautz, Tong Lu, and Jose M Alvarez. Is ego status all you need for open-loop end-to-end autonomous driving? *arXiv preprint arXiv:2312.03031*, 2023. 3
- [18] Zhenxin Li, Kailin Li, Shihao Wang, Shiyi Lan, Zhiding Yu, Yishen Ji, Zhiqi Li, Ziyue Zhu, Jan Kautz, Zuxuan Wu, et al. Hydra-mdp: End-to-end multimodal planning with multi-target hydra-distillation. *arXiv preprint arXiv:2406.06978*, 2024. 1, 2, 3, 4
- [19] Bencheng Liao, Shaoyu Chen, Haoran Yin, Bo Jiang, Cheng Wang, Sixu Yan, Xinbang Zhang, Xiangyu Li, Ying Zhang, Qian Zhang, et al. Diffusiondrive: Truncated diffusion model for end-to-end autonomous driving. In *CVPR*, 2025. 1, 2
- [20] Dennis Park, Rares Ambrus, Vitor Guizilini, Jie Li, and Adrien Gaidon. Is pseudo-lidar needed for monocular 3d object detection? In *ICCV*, pages 3142–3152, 2021. 3
- [21] Katrin Renz, Long Chen, Ana-Maria Marcu, Jan Hünermann, Benoit Hanotte, Alice Karnsund, Jamie Shotton, Elahe Arani, and Oleg Sinavski. Carllava: Vision language models for camera-only closed-loop driving. *arXiv preprint arXiv:2406.10165*, 2024. 1
- [22] Katrin Renz, Long Chen, Elahe Arani, and Oleg Sinavski. Simlingo: Vision-only closed-loop autonomous driving with language-action alignment. *arXiv preprint arXiv:2503.09594*, 2025.
- [23] Chonghao Sima, Katrin Renz, Kashyap Chitta, Li Chen, Hanxue Zhang, Chengen Xie, Jens Beißwenger, Ping Luo, Andreas Geiger, and Hongyang Li. Drivelm: Driving with graph visual question answering. In *ECCV*, pages 256–274. Springer, 2024. 1
- [24] Chonghao Sima, Kashyap Chitta, Zhiding Yu, Shiyi Lan, Ping Luo, Andreas Geiger, Hongyang Li, and Jose M Alvarez. Centaur: Robust end-to-end autonomous driving with test-time training. *arXiv preprint arXiv:2503.11650*, 2025. 1
- [25] Yingqi Tang, Zhuoran Xu, Zhaotie Meng, and Erkang Cheng. Hip-ad: Hierarchical and multi-granularity planning with deformable attention for autonomous driving in a single decoder. *arXiv preprint arXiv:2503.08612*, 2025. 1
- [26] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *NeurIPS*, 30, 2017. 2

- [27] Shihao Wang, Yingfei Liu, Tiancai Wang, Ying Li, and Xiangyu Zhang. Exploring object-centric temporal modeling for efficient multi-view 3d object detection. In *ICCV*, pages 3621–3631, 2023. [3](#)
- [28] Shihao Wang, Zhiding Yu, Xiaohui Jiang, Shiyi Lan, Min Shi, Nadine Chang, Jan Kautz, Ying Li, and Jose M Alvarez. Omnidrive: A holistic llm-agent framework for autonomous driving with 3d perception, reasoning and planning. *arXiv preprint arXiv:2405.01533*, 2024. [1](#)
- [29] Theodor Westny, Björn Olofsson, and Erik Frisk. Diffusion-based environment-aware trajectory prediction. *arXiv preprint arXiv:2403.11643*, 2024. [2](#)
- [30] Zebin Xing, Xingyu Zhang, Yang Hu, Bo Jiang, Tong He, Qian Zhang, Xiaoxiao Long, and Wei Yin. Goalflow: Goal-driven flow matching for multimodal trajectories generation in end-to-end autonomous driving. In *CVPR*, 2025. [1](#)
- [31] Brian Yang, Huangyuan Su, Nikolaos Gkanatsios, Tsung-Wei Ke, Ayush Jain, Jeff Schneider, and Katerina Fragkiadaki. Diffusion-es: Gradient-free planning with diffusion for autonomous and instruction-guided driving. In *CVPR*, pages 15342–15353, 2024. [2](#)
- [32] Lihe Yang, Bingyi Kang, Zilong Huang, Xiaogang Xu, Jia-ashi Feng, and Hengshuang Zhao. Depth anything: Unleashing the power of large-scale unlabeled data. *arXiv preprint arXiv:2401.10891*, 2024. [3](#)
- [33] Yinan Zheng, Ruiming Liang, Kexin Zheng, Jinliang Zheng, Liyuan Mao, Jianxiong Li, Weihao Gu, Rui Ai, Shengbo Eben Li, Xianyu Zhan, et al. Diffusion-based planning for autonomous driving with flexible guidance. *arXiv preprint arXiv:2501.15564*, 2025. [2](#)