

Hydra-MDP: 基于多目标多头蒸馏的端到端多模态规划

Zhenxin Li^{1,2} Kailin Li³ Shihao Wang^{1,4} Shiyi Lan¹ Zhiding Yu¹ Yishen Ji⁵
 Zhiqi Li⁵ Ziyue Zhu⁶ Jan Kautz¹ Zuxuan Wu² Yu-Gang Jiang² Jose M. Alvarez¹
¹NVIDIA ²Fudan University ³East China Normal University
⁴Beijing Institute of Technology ⁵Nanjing University ⁶Nankai University

摘要

本文提出 Hydra-MDP，一种在师生模型中采用多教师的新颖范式。该方法利用来自人类教师和基于规则的教师的知识蒸馏来训练学生模型，该模型具有多头解码器，以学习针对各种评估度量量身定制的多样化轨迹候选。借助基于规则的教师的知识，Hydra-MDP 以端到端的方式学习环境如何影响规划，而非诉诸不可微的后处理。该方法在 Navsim 挑战赛中取得 1st 名次，展示了在不同驾驶环境和条件下泛化能力的显著提升。更多详情请访问 <https://github.com/NVlabs/Hydra-MDP>。

1. 引言

端到端自动驾驶，即利用原始传感器输入学习神经规划器，被视为实现完全自主的有前景的方向。尽管该领域取得了令人鼓舞的进展 [11, 12]，近期研究 [4, 8, 14] 揭示了模仿学习方法的多个脆弱性和局限性，尤其是开环评估中的固有问题，如失效的度量和隐式偏置 [8, 14]。这一点至关重要，因为它无法保证安全性、效率、舒适性以及对交通规则遵守。为解决这一主要局限性，若干工作提出引入闭环度量，通过确保机器学习规划器不仅模仿人类驾驶员，还能满足基本标准，从而更有效地评估端到端自动驾驶。因此，端到端规划理想上是一个多目标和多模态任务，其中多目标规划涉及满足来自开环和闭环设置的各种评估度量。在此背景下，多模态表示每个度量存在多个最优解。现有的端到端方法 [4, 11, 12] 通常试图




图 1. 端到端规划范式之间的比较。

考虑通过后处理进行闭环评估，这种方式不够精简，且与完全端到端的流程相比，可能导致额外信息的丢失。与此同时，基于规则的规划器 [8, 18] 难以应对不完美的感知输入。这些不完美的输入在闭环和开环度量下都会降低基于规则的规划性能，因为它们依赖预测的感知而非真值（GT）标签。为解决这些问题，本文提出一种新颖的端到端自动驾驶框架，称为 Hydra-MDP（基于多目标 Hydra 蒸馏的多模态规划）。Hydra-MDP 基于一种新颖的教师-学生知识蒸馏（KD）架构。学生模型通过来自人类教师和基于规则教师的知识蒸馏，学习针对各种评估度量量身定制的多样化轨迹候选。本文利用多头解码器实例化多目标 Hydra 蒸馏，从而有效整合来自专业教师的知识。Hydra-MDP 还具有可扩展的




图 2. Hydra-MDP 的整体架构。

知识蒸馏架构，便于轻松集成额外的教师模型。学生模型在训练期间使用环境观测，而教师模型使用真值（GT）数据。这种设置使教师模型能够生成更优的规划预测，帮助学生模型有效学习。通过使用环境观测训练学生模型，它能够熟练应对测试期间无法获取真值感知的现实条件。本文的贡献总结如下：1. 本文提出一种通过多目标 Hydra 蒸馏实现端到端多模态规划的通用框架，使模型能够以可扩展的方式同时从基于规则的规划器和人类驾驶员中学习。2. 本文方法在 Navsim 的基于仿真的评估度量下达到了最先进的性能。

2. 解决方案

2.1. 预备知识

设 O 表示传感器观测， $\hat{F}$ 和 F 分别表示真值感知与预测感知（例如三维目标检测、车道线检测）， $\hat{T}$ 为专家轨迹， T^* 为预测轨迹。 $\mathcal{L}_{im}$ 表示模仿损失。本节首先介绍两种主流范式及本文提出的范式（图 1）：A. 单模态规划 + 单目标学习。在该范式 [11, 12, 14] 中，规划网络直接从传感器观测回归出规划轨迹。真值感知可作为辅助监督，但不影响规划输出。为简洁起见，公式中省略感知损失。整个处理过程可表示为：

$$\mathcal{L} = \mathcal{L}_{im}(T^*, \hat{T}), \quad (1)$$

其中 $\mathcal{L}_{im}$ 通常为 L2 损失。B. 多模态规划 + 单目标学习。该方法 [1, 4] 预测多条轨迹 $\{T_i\}_{i=1}^k$ ，并计算它们与专家轨迹的相似度：

$$\mathcal{L} = \sum_i \mathcal{L}_{im}(T_i, \hat{T}), \quad (2)$$

其中 $\mathcal{L}_{im}$ 可以是 KL 散度 [4] 或最大间隔损失 [1]。感知输出 F 被显式地用于通过代价函数 $f(T_i, P)$ 对合适的轨迹进行后处理。选择代价最低的轨迹：

$$T^* = \arg \min_{T_i} f(T_i, P), \quad (3)$$

这是一个基于不完美感知的不可微过程
感知 P 。

C. 多模态规划 + 多目标学习。本文

提出该范式，通过神经网络 $\tilde{f}$ 同时预测多种代价（例如碰撞代价、可行驶区域合规代价）。该过程以师生蒸馏方式进行，其中教师可访问真值感知 $\hat{F}$ ，而学生仅依赖传感器观测 O 。该范式可表示为：

$$\mathcal{L} = \sum_i \mathcal{L}_{im}(T_i, \hat{T}) + \mathcal{L}_{kd}(f(T_i, \hat{P}), \tilde{f}(T_i, O)). \quad (4)$$

此处为清晰起见，仅考虑一个代价函数 f 。选择预测代价最低的轨迹：

$$T^* = \arg \min_{T_i} \tilde{f}(T_i, O). \quad (5)$$

本文强调，该框架不受不可微后处理的限制。通过引入更多代价函数或在实现中利用模仿相似性（第 2.4 节），可以轻松地以端到端方式进行扩展。

2.2 总体框架

如图 2 所示, Hydra-MDP 由两个网络组成: 一个感知网络 以及一个轨迹解码器。

感知网络。 本文的感知网络构建于官方挑战基线变换器 (Transfuser) [5, 6] 之上, 该基线由图像主干网络、激光雷达主干网络以及用于三维目标检测和鸟瞰图分割的感知头组成。多个变换器层 [19] 连接两个主干网络各阶段的特征, 从不同模态中提取有意义的信息。感知网络的最终输出包含环境令牌 F_{env} , 这些令牌编码了源自图像和激光雷达点云的丰富语义信息。

轨迹解码器。 遵循 Vadv2 [4], 我们构建了一个固定的规划词汇表, 以离散化连续动作空间。为构建该词汇表, 我们首先从原始 nuPlan 数据库 [2] 中随机采样 70 万条轨迹。每条轨迹 $T_i (i = 1, \dots, k)$ 包含 40 个时间戳的 $(x, y, heading)$, 对应挑战中所需的 10Hz 频率和 4 秒未来时域。规划词汇表 $\mathcal{V}_k$ 由这 70 万条轨迹的 K 均值聚类中心构成, 其中 k 表示词汇表的大小。 $\mathcal{V}_k$ 随后通过多层感知机嵌入为 k 个潜在查询, 送入多层变换器编码器 [19], 并与自车状态 E 相加:

$$\mathcal{V}'_k = \text{Transformer}(Q, K, V = \text{Mlp}(\mathcal{V}_k)) + E. \quad (6)$$

为在 F_{env} 中融入环境线索, 采用了变换器解码器:

$$\mathcal{V}''_k = \text{Transformer}(Q = \mathcal{V}'_k, K, V = F_{env}). \quad (7)$$

利用日志回放轨迹 $\hat{T}$, 本文实现了一种基于距离的交叉熵损失, 以模仿人类驾驶员:

$$\mathcal{L}_{im} = - \sum_{i=1}^k y_i \log(\mathcal{S}_i^{im}), \quad (8)$$

其中 $\mathcal{S}_i^{im}$ 是 i 的第 $\mathcal{V}''_k$ 个 Softmax 函数得分, y_i 是由对数回放与词汇表之间的 L2 距离产生的模仿目标。Softmax 函数应用于 L2 距离以生成概率分布:

$$y_i = \frac{e^{-(\hat{T}-T_i)^2}}{\sum_{j=1}^k e^{-(\hat{T}-T_j)^2}}. \quad (9)$$

该模仿目标的直觉在于奖励接近人类驾驶行为的轨迹提议。

2.3. 多目标多头蒸馏

尽管模仿目标为规划器提供了一定线索, 但在闭环设置下, 模型难以将规划决策与驾驶环境相关联, 从而导致碰撞和偏离等失败情况

可行驶区域 [14]。因此, 为提升端到端规划器的闭环性能, 本文提出多目标多头蒸馏 (Multi-target Hydra-Distillation) 学习策略, 使规划器与该挑战中基于仿真的度量对齐。蒸馏过程通过两个步骤扩展学习目标: (1) 对整个训练数据集运行规划词汇 $\mathcal{V}_k$ 的离线仿真 [8]; (2) 在训练过程中对 $\mathcal{V}_k$ 中的每条轨迹引入仿真分数的监督。对于给定场景, 步骤 1 为每个度量 $m \in M$ 和 i -th 轨迹生成真实仿真分数 $\{\hat{\mathcal{S}}_i^m | i = 1, \dots, k\}_{m=1}^{|M|}$, 其中 M 表示挑战中使用的闭环度量集合。对于分数预测, 潜在向量 $\mathcal{V}''_k$ 通过一组多头预测头 (Hydra Prediction Heads) 处理, 得到预测分数 $\{\mathcal{S}_i^m | i = 1, \dots, k\}_{m=1}^{|M|}$ 。利用二元交叉熵损失, 将基于规则的驾驶知识蒸馏到端到端规划器中:

$$\mathcal{L}_{kd} = - \sum_{m,i} \hat{\mathcal{S}}_i^m \log \mathcal{S}_i^m + (1 - \hat{\mathcal{S}}_i^m) \log(1 - \mathcal{S}_i^m). \quad (10)$$

对于轨迹 T_i , 其每个子分数的蒸馏损失在公式 4 中充当学习到的代价值, 用于衡量与该度量相关的特定交通规则的违反程度。

2.4. 推理与后处理

2.4.1 推理

给定预测的模仿分数 $\{\mathcal{S}_i^{im} | i = 1, \dots, k\}$ 和度量子分数 $\{\mathcal{S}_i^m | i = 1, \dots, k\}_{m=1}^{|M|}$, 本文计算一个综合代价, 用于衡量在给定场景中每条轨迹被选中的可能性, 如下所示:

$$\tilde{f}(T_i, O) = - (w_1 \log \mathcal{S}_i^{im} + w_2 \log \mathcal{S}_i^{NC} + w_3 \log \mathcal{S}_i^{DAC} + w_4 \log (5\mathcal{S}_i^{TTC} + 2\mathcal{S}_i^C + 5\mathcal{S}_i^{EP})), \quad (11)$$

where $\{w_i\}_{i=1}^4$ 表示置信度加权参数, 用于缓解不同教师模型拟合不完美的问题。权重的最优组合通过网格搜索获得, 通常落在以下范围内: $0.01 \leq$

$w_1 \leq 0.1, 0.1 \leq w_2, w_3 \leq 1, 1 \leq w_4 \leq 10$, 表明有必要优先考虑基于规则的代价而非模仿代价。

最终, 选择综合代价最低的轨迹。

2.4.2 模型集成

我们提出了两种模型集成技术: 编码器混合与子分数集成。前者使用线性层来组合来自不同视觉编码器的特征, 而后者计算来自独立模型的子分数的加权和以进行轨迹选择。

3. 实验

3.1. 数据集与度量

数据集。 Navsim 数据集建立在现有的 Open-Scene [7] 数据集之上, 后者是 nuPlan [3] 的一个紧凑版本, 仅包含

Method	Inputs	NC	DAC	EP	TTC	C	Score
PDM-Closed [8]◇	Perception GT	94.6	99.8	89.9	86.9	99.9	89.1
Transfuser [5]	LiDAR & Camera	96.5	87.9	73.9	90.2	100	78.0
Vadv2- $\mathcal{V}_{4096}$ [4]*	LiDAR & Camera	97.1	88.8	74.9	91.4	100	79.7
Vadv2- $\mathcal{V}_{4096}$ [4]*-PP	LiDAR & Camera	97.0	89.1	75.0	91.2	100	79.9
Vadv2- $\mathcal{V}_{8192}$ [4]*	LiDAR & Camera	97.2	89.1	76.0	91.6	100	80.9
Hydra-MDP- $\mathcal{V}_{4096}$	LiDAR & Camera	97.7	91.5	77.5	92.7	100	82.6
Hydra-MDP- $\mathcal{V}_{8192}$	LiDAR & Camera	97.9	91.7	77.6	92.9	100	83.0
Hydra-MDP- $\mathcal{V}_{8192}$ -PDM	LiDAR & Camera	97.5	88.9	74.8	92.5	100	80.2
Hydra-MDP- $\mathcal{V}_{8192}$ -W	LiDAR & Camera	98.1	96.1	77.8	93.9	100	85.7
Hydra-MDP- $\mathcal{V}_{8192}$ -W-EP	LiDAR & Camera	98.3	96.0	78.7	94.6	100	86.5

表 1. 在 Navtest 划分上的性能。◇ 官方 Navsim 实现的 PDM-Closed 可能由于与 nuPlan 实现 [8] 相比不一致的制动操作和偏移公式而容易出错。所有端到端方法都使用官方 Transfuser [5] 作为感知网络。* 我们采用基于距离的模仿损失进行训练。PP: Transfuser 感知用于后处理。PDM: 学习目标是总体 PDM 分数。W: 推理期间的加权置信度。EP: 模型被训练以拟合连续的 EP (自我进展) 度量。

Method	Img. Resolution	Backbone	NC	DAC	EP	TTC	C	Score
PDM-Closed [8]◇	-	-	94.6	99.8	89.9	86.9	99.9	89.1
Hydra-MDP-A	256 × 1024	ViT-L*	98.4	97.7	85.0	94.5	100	89.9
Hydra-MDP-B	512 × 2048	V2-99	98.4	97.8	86.5	93.9	100	90.3
Hydra-MDP-C	256 × 1024	ViT-L*	98.7	98.2	86.5	95.0	100	91.0
	256 × 1024	ViT-L†						
	512 × 2048	V2-99						

表 2. 在 Navtest 划分上扩大规模的影响。◇ 官方 Navsim 实现的 PDM-Closed。* ViT-L 从 Depth Anything [20] 初始化。†ViT-L 是在 Objects365 [17] 和 COCO [15] 上预训练的 EVA [9]。V2-99 [13] 从 DD3D [16] 初始化。

相关标注和传感器数据以 2 Hz 采样。该数据集主要关注涉及意图变化的场景，其中自我车辆的历史数据无法外推到未来计划。该数据集提供了带有语义类别的标注二维高清地图和物体的三维边界框。数据集分为两部分：Navtrain 和 Navtest，分别包含 1192 和 136 个场景用于训练/验证和测试。

度量。 针对本挑战，我们基于规划距离度量 (PDM) 分数评估模型，其公式如下：

$$PDM_{score} = NC \times DAC \times DDC \times \frac{(5 \times TTC + 2 \times C + 5 \times EP)}{12}, \quad (12)$$

其中子度量 NC, DAC, TTC, C, EP 分别对应无责任碰撞、可行驶区域合规性、碰撞时间、舒适度与自车进度。在蒸馏过程及后续结果中，由于实现问题， DDC 被忽略。¹

3.2. 实现细节

我们在导航训练集 (Navtrain) 划分上训练模型，使用 8 块英伟达 A100 图形处理器 (GPU)，总批大小为 256，训练 20 个训练轮次。学习率与权重衰减分别设为 1×10^{-4} 和 0.0，遵循官方基线。来自 4 帧的激光雷达点被投影到鸟瞰图 (BEV) 平面上形成密度鸟瞰特征，并使用残差网络 34 (ResNet34) [10] 进行编码。对于图像，前视图与中心裁剪的左前视和右前视图图像拼接，默认输入分辨率为 256×1024 。除非另有说明，残差网络 34 也 ¹ <https://github.com/autonomousvision/navsim/issues/14>

用于特征提取。未使用任何数据增强或测试时增强。

3.3. 主要结果

表 1 中呈现的结果凸显了水螅多决策规划器 (Hydra-MDP) 相对于基线的绝对优势。在我们对不同规划词汇 [4] 的探索中，利用更大的词汇 $\mathcal{V}_{8192}$ 在不同方法上均表现出改进。此外，不可微后处理带来的性能增益少于我们的框架，而加权置信度则全面提升了性能。为消融不同学习目标的影响，早期实验未考虑连续度量自车进度 (EP)，并尝试对整体规划距离度量分数进行蒸馏。然而，规划距离度量分数的不规则分布导致性能下降，这表明了多目标学习范式的必要性。在最终版本的水螅多决策规划器- $\mathcal{V}_{8192}$ -加权-自车进度中，自车进度的蒸馏能够改善相应度量。

3.4. 扩展与模型集成

先前文献 [11] 表明，更大的骨干网络仅能带来规划性能的轻微提升。尽管如此，本文进一步展示了模型在更大骨干网络下的可扩展性。表 2 展示了以 ViT-L[9, 20] 和 V2-99[13] 作为图像骨干的 Hydra-MDP 的三个最佳版本。对于最终提交，本文使用这三个模型的集成子分数进行推理。

参考文献

- [1] Sourav Biswas, Sergio Casas, Quinlan Sykora, Ben Agro, Abbas Sadat, and Raquel Urtasun. Quad: Query-based interpretable neural motion planning for autonomous driving. *arXiv preprint arXiv:2404.01486*, 2024. 2
- [2] Holger Caesar, Juraj Kabzan, Kok Seang Tan, Whye Kit Fong, Eric Wolff, Alex Lang, Luke Fletcher, Oscar Beijbom, and Sammy Omari. nuplan: A closed-loop ml-based planning benchmark for autonomous vehicles. *arXiv preprint arXiv:2106.11810*, 2021. 3
- [3] Holger Caesar, Juraj Kabzan, Kok Seang Tan, Whye Kit Fong, Eric Wolff, Alex Lang, Luke Fletcher, Oscar Beijbom, and Sammy Omari. nuplan: A closed-loop ml-based planning benchmark for autonomous vehicles. *arXiv preprint arXiv:2106.11810*, 2021. 3
- [4] Shaoyu Chen, Bo Jiang, Hao Gao, Bencheng Liao, Qing Xu, Qian Zhang, Chang Huang, Wenyu Liu, and Xinggang Wang. Vad2: End-to-end vectorized autonomous driving via probabilistic planning. *arXiv preprint arXiv:2402.13243*, 2024. 1, 2, 3, 4
- [5] Kashyap Chitta, Aditya Prakash, Bernhard Jaeger, Zehao Yu, Katrin Renz, and Andreas Geiger. Transfuser: Imitation with transformer-based sensor fusion for autonomous driving. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2022. 3, 4
- [6] NAVSIM Contributors. Navsim: Data-driven non-reactive autonomous vehicle simulation. <https://github.com/autonomousvision/navsim>, 2024. 3
- [7] OpenScene Contributors. Openscene: The largest up-to-date 3d occupancy prediction benchmark in autonomous driving. <https://github.com/OpenDriveLab/OpenScene>, 2023. 3
- [8] Daniel Dauner, Marcel Hallgarten, Andreas Geiger, and Kashyap Chitta. Parting with misconceptions about learning-based vehicle motion planning. In *Conference on Robot Learning*, pages 1268–1281. PMLR, 2023. 1, 3, 4
- [9] Yuxin Fang, Quan Sun, Xinggang Wang, Tiejun Huang, Xinlong Wang, and Yue Cao. Eva-02: A visual representation for neon genesis. *arXiv preprint arXiv:2303.11331*, 2023. 4
- [10] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770–778, 2016. 4
- [11] Yihan Hu, Jiazhi Yang, Li Chen, Keyu Li, Chonghao Sima, Xizhou Zhu, Siqi Chai, Senyao Du, Tianwei Lin, Wenhui Wang, et al. Planning-oriented autonomous driving. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 17853–17862, 2023. 1, 2, 4
- [12] Bo Jiang, Shaoyu Chen, Qing Xu, Bencheng Liao, Jiajie Chen, Helong Zhou, Qian Zhang, Wenyu Liu, Chang Huang, and Xinggang Wang. Vad: Vectorized scene representation for efficient autonomous driving. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 8340–8350, 2023. 1, 2
- [13] Youngwan Lee, Joong-won Hwang, Sangrok Lee, Yuseok Bae, and Jongyoul Park. An energy and gpu-computation efficient backbone network for real-time object detection. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition workshops*, pages 0–0, 2019. 4
- [14] Zhiqi Li, Zhiding Yu, Shiyi Lan, Jiahao Li, Jan Kautz, Tong Lu, and Jose M Alvarez. Is ego status all you need for open-loop end-to-end autonomous driving? *arXiv preprint arXiv:2312.03031*, 2023. 1, 2, 3
- [15] Tsung-Yi Lin, Michael Maire, Serge Belongie, James Hays, Pietro Perona, Deva Ramanan, Piotr Dollár, and C Lawrence Zitnick. Microsoft coco: Common objects in context. In *Computer Vision–ECCV 2014: 13th European Conference, Zurich, Switzerland, September 6–12, 2014, Proceedings, Part V 13*, pages 740–755. Springer, 2014. 4
- [16] Dennis Park, Rares Ambrus, Vitor Guizilini, Jie Li, and Adrien Gaidon. Is pseudo-lidar needed for monocular 3d object detection? In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 3142–3152, 2021. 4
- [17] Shuai Shao, Zeming Li, Tianyuan Zhang, Chao Peng, Gang Yu, Xiangyu Zhang, Jing Li, and Jian Sun. Objects365: A large-scale, high-quality dataset for object detection. In *Proceedings of the IEEE/CVF international conference on computer vision*, pages 8430–8439, 2019. 4
- [18] Martin Treiber, Ansgar Hennecke, and Dirk Helbing. Congested traffic states in empirical observations and microscopic simulations. *Physical review E*, 62(2):1805, 2000. 1
- [19] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in neural information processing systems*, 30, 2017. 3
- [20] Lihe Yang, Bingyi Kang, Zilong Huang, Xiaogang Xu, Jiashi Feng, and Hengshuang Zhao. Depth anything: Unleashing the power of large-scale unlabeled data. *arXiv preprint arXiv:2401.10891*, 2024. 4