

IDQL: 作为演员-评论家方法的隐式 Q 学习与扩散策略

Philippe Hansen-Estruch Ilya Kostrikov Michael Janner
 Jakub Grudzien Kuba Sergey Levine
 UC Berkeley
 {hansenpmeche, kostrikov, janner, kuba}@berkeley.edu
 svlevine@eecs.berkeley.edu

摘要

有效的离线强化学习方法需要妥善处理分布外动作。隐式 Q 学习 (IQL) 通过修改贝尔曼备份，仅使用数据集动作训练 Q 函数来解决这一问题。然而，目前尚不清楚哪种策略实际上能够达到该隐式训练的 Q 函数所表示的值。在本文中，我们通过推广评论家目标并将其与行为正则化的隐式演员相连接，将 IQL 重新解释为一种演员-评论家方法。这种推广展示了所诱导的演员如何在奖励最大化和与行为策略的偏离之间取得平衡，而具体的损失函数选择决定了这种权衡的性质。值得注意的是，该演员可能表现出复杂且多模态的特征，这表明先前方法中使用的优势加权回归 (AWR) 拟合条件高斯演员存在不足。因此，我们提出使用来自扩散参数化行为策略的样本，并根据评论家计算的权重进行重要性采样，以得到我们预期的策略。我们引入了隐式扩散 Q 学习 (IDQL)，将我们通用的 IQL 评论家与策略提取方法相结合。IDQL 保持了 IQL 易于实现的特点，同时优于先前的离线强化学习方法，并展现出对超参数的鲁棒性。代码可在 github.com/philippe-eecs/IDQL 获取。

1 引言

离线强化学习有望从静态数据集中学习策略。价值函数估计为许多现代离线强化学习方法提供了基本构建模块，但此类方法需要处理在评估学习策略时出现的分布外动作。尽管已经提出了多种基于约束和正则化的方法来解决这一问题，但在本文中，我们将研究隐式 Q 学习 (IQL) [26]，该方法完全避免了对未见动作的价值查询。在 IQL 中，Q 函数通过使用状态价值函数作为目标值的贝尔曼备份进行训练。状态价值函数通过对 Q 值进行期望回归来训练，隐式地执行对动作的最大化。虽然 IQL 为其他离线强化学习方法提供了一种有吸引力的替代方案，但学习到的价值函数究竟对应何种策略仍不清楚，这反过来又使得理解 IQL 类算法中的瓶颈变得困难。

本文推导出 IQL 的一种变体，该变体显著提升了原始方法的性能，对超参数相对不敏感，并且优于更近期的离线强化学习方法。我们的关键观察基于一个新的视角，将 IQL 重新解释为演员-评论家方法。这是通过将 IQL 中的价值优化问题推广为使用任意凸损失来实现的，随后我们将其与隐式行为正则化的演员联系起来。这种推广具有重要意义，因为它展示了评论家目标的不同选择如何产生不同的隐式演员分布，这些分布在不同程度上偏离行为策略。




图 1：比较 IQL 使用的单峰 AWR 与我们的 IDQL 扩散策略。（左）具有三个动作和奖励函数 $r(a_1, a_2) = a_1 + a_2$ 的二维赌博机。对于奖励分布的第 90 个期望分位数，我们计算了使用 AWR（如 IQL 所用）拟合的相应单峰高斯策略在不同逆温度下的等高线图（中），以及我们提出的提取方法的样本（右）。单峰演员在所有温度下都错误地近似了隐式策略，而扩散提取方法准确地捕捉了隐式策略。

因此，研究该隐式演员的特征不仅揭示了 IQL 在评论家学习中所做的权衡，还揭示了改进该方法的潜在途径。

我们的分析表明，隐式演员是复杂的且可能具有多模态性，这揭示了 IQL 所使用的策略提取方案存在的问题 [26]，其中单模态高斯演员通过优势加权回归（AWR）进行训练 [38, 37, 33]。这种参数化方式不太可能准确逼近隐式演员（图 1）。与传统的演员-评论家算法不同，在传统算法中评论家会适应显式演员的参数化，而 IQL 的优势在于其评论家训练与显式演员完全解耦，从而避免了不稳定性与超参数敏感性。然而，这要求策略提取能够准确逼近隐式演员。应对这一挑战的一个有益观察是，通过评论家学习诱导出的隐式演员可以表示为行为策略的重新加权，这可以通过重要性权重来近似。因此，对于策略提取，我们提出使用评论家计算的权重对来自扩散参数化行为模型的样本进行重新加权，然后可以重新采样以表达隐式策略和贪婪策略。扩散模型 [41, 20, 43] 是使我们的策略提取方法能够准确表示多模态分布的关键细节。

我们引入了隐式扩散 Q 学习（IDQL）。我们的主要贡献是：（1）将 IQL 推广到演员-评论家方法，其中评论家损失的选择诱导出一个隐式演员分布，该分布可以表示为行为策略的重新加权；

（2）一种基于扩散的策略提取算法，该算法将来自表达性扩散模型的样本与重新加权方案相结合，以恢复对隐式演员的准确逼近，或最大化评论家价值。IDQL 在 D4RL 离线强化学习基准 [11] 上优于先前的方法，包括基于 IQL 的方法和其他使用扩散模型的方法。此外，IDQL 具有很强的可移植性，在不同领域（例如，蚂蚁迷宫、运动控制）中只需有限的超参数调整，就能在离线强化学习和使用离线预训练的在线微调中表现良好。

2 相关工作

尽管离线强化学习已通过广泛的算法框架 [30, 31] 进行处理，但近期方法常采用源自 Q 学习和异策略演员-评论家方法的价值基算法。为使方法适应离线设置，必须避免对分布外动作的高估 [27]。为此，近期方法使用隐式发散约束 [38, 37, 33, 45]、显式密度模型 [47, 13, 27, 15] 和监督学习项 [12]。部分工作还直接惩罚分布外动作的 Q 值 [25, 28]。近期，隐式时序差分备份被开发出来，通过使用具有 SARSA 风格同策略备份的非对称损失函数，避免在 Q 函数中使用样本外动作。该方法在 IQL [26] 中被提出，其使用期望损失训练 Q 函数，然后利用 AWR [37] 提取策略。然而，提取过程本身施加了 KL 散度约束，这与评论家所捕获的策略不一致。极端 Q 学习（EQL）[14] 修改了 IQL 中的 Q 函数目标，以估计与熵正则化 AWR 策略一致的软值。同时，Xu 等人 [49] 在行为正则化马尔可夫决策过程中提供了 IQL 的另一种泛化，得到了两个新的隐式 Q 学习目标。我们的广义 IQL 推导与之相关，但具有不同的

泛化形式。与这些专注于 Q 学习的论文相反，我们的主要实用贡献在于受此泛化启发的策略提取步骤。

我们的方法利用表达性生成模型来捕获策略。为此，我们回顾了使用表达性生成模型进行离线强化学习的工作。EMaQ[15] 使用自回归行为克隆模型定义策略，并在评论家学习中使用该策略的 argmax 动作进行备份。决策 Transformer 和轨迹 Transformer[8, 21] 使用变换器克隆整个轨迹空间，并分别应用奖励条件或束搜索，使采样轨迹偏向更高奖励。扩散模型也被用于行为克隆和离线强化学习。Florence 等人 [10] 和 Pearce 等人 [36] 分别使用基于能量的模型和扩散模型进行行为克隆。Janner 等人 [22] 和 Ajay 等人 [1] 使用扩散直接建模和采样轨迹空间；样本通过梯度引导或奖励条件进行引导。Reuss 等人 [40] 使用扩散策略进行目标条件模仿学习。

与本文工作最接近的是先前在离线强化学习中用扩散模型表示行动者的方法。扩散 Q 学习 (Diffusion Q-learning, DQL) [44] 将扩散引入以在 TD3+BC 风格算法 [12] 中参数化行动者。从行为候选中选择 (Select from Behavior Candidates, SfBC) [7] 利用扩散行为模型的重要性重加权来定义策略，然后使用来自策略的样本通过价值迭代训练评论家。动作受限 Q 学习 (Action-Restricted Q-learning, ARQ) [16] 使用扩散行为模型执行评论家更新，然后使用 AWR 提取策略。本文方法与这些方法不同之处在于，扩散行为模型与评论家学习过程保持分离，仅在评估时与评论家交互。这使得超参数调优相对高效。此外，据我们所知，本文是首个将扩散应用于在线微调的方法。

3 预备知识

强化学习在马尔可夫决策过程 (Markov Decision Process, MDP) 的框架下表述，其定义为一个元组 $(\mathcal{S}, \mathcal{A}, p_0(s), p_M(s'|s, a), r(s, a), \gamma)$ ，包含状态空间 $\mathcal{S}$ 、动作空间 $\mathcal{A}$ 、初始状态分布 $p_0(s)$ 、转移动态 $p_M(s'|s, a)$ 、奖励函数 $r(s, a)$ 和折扣因子 γ 。目标是恢复一个策略 $\pi(a|s)$ ，以最大化 MDP 中的折扣奖励和或回报。在离线强化学习中，智能体只能访问从行为策略分布 $\mu(a|s)$ 收集的固定转移数据集 $\mathcal{D} = \{s, a, r, s'\}$ 。

Implicit Q-learning. Instead of constraining the policy or regularizing the critic, Kostrikov et al. [26] proposed to approximate the expectile τ over the distribution of actions. For a parameterized critic $Q_\theta(s, a)$, target critic $Q_{\hat{\theta}}(s, a)$, and value network $V_\psi(s)$ the value objective is

$$\mathcal{L}_V(\psi) = \mathbb{E}_{(s,a) \sim \mathcal{D}} [L_2^\tau(Q_{\hat{\theta}}(s, a) - V_\psi(s))] \quad (1)$$

where $L_2^\tau(u) = |\tau - \mathbb{1}(u < 0)|u^2$.

期望回归使用简单的非对称平方误差，仅需从数据集中采样动作，无需任何显式策略。然后，该价值函数用于更新 Q 函数：

$$\mathcal{L}_Q(\theta) = \mathbb{E}_{(s,a,s') \sim \mathcal{D}} [(r(s, a) + \gamma V_\psi(s') - Q_\theta(s, a))^2]. \quad (2)$$

Q 函数是在期望值所定义的隐式策略分布下诱导的。对于策略提取，IQL 使用 AWR[38, 37, 33]，通过最小化加权回归来训练策略

$$\mathcal{L}_\pi(\phi) = \mathbb{E}_{(s,a) \sim \mathcal{D}} [\exp(\alpha(Q_{\hat{\theta}}(s, a) - V_\psi(s))) \log \pi_\phi(a|s)]. \quad (3)$$

温度参数 $\alpha \in [0, \infty]$ 用于平衡评论家利用与行为克隆。

扩散模型。我们简要回顾用于行为克隆的扩散，因为它是本文策略提取算法的基础。扩散模型 [41, 20, 43] 是潜变量模型，使用马尔可夫加噪和去噪过程来建模参数化的行为分布 $\mu_\phi(a_0|s) = \int \mu_\phi(a_{0:T}|s) da_{1:T}$ ，其中隐变量为 $a_1, \dots, a_T$ 。前向加噪过程遵循固定的方差调度 $\beta_1, \dots, \beta_T$ ，其分布为

$$q(a_t|a_{t-1}) = \mathcal{N}(\sqrt{1 - \beta_t}a_{t-1}, \beta_t I).$$

遵循去噪扩散概率模型 (DDPM) [20]，本文的实用实现直接参数化评分网络 $\mu_\phi(a_{t-1}|a_t, s, t)$ ，以恢复行为克隆目标。

$$\mathcal{L}_\mu(\phi) = \mathbb{E}_{t \sim \mathcal{U}(1, T), \epsilon \sim \mathcal{N}(0, I), s, a \sim \mathcal{D}} [||\epsilon - \mu_\phi(\sqrt{\hat{\alpha}_t}a + \sqrt{1 - \hat{\alpha}_t}\epsilon, s, t)||]. \quad (4)$$

为从 $\mu_\phi(a_0|s)$ 采样, 本文采用朗之万采样或反向扩散, 其中 $a_T \sim \mathcal{N}(0, I)$ 和 $\epsilon \sim \mathcal{N}(0, I)$ 在每一步重新采样。

$$a_{t-1} \leftarrow \frac{1}{\sqrt{\alpha_t}} \left(a_t - \frac{\beta_t}{\sqrt{1-\hat{\alpha}_t}} \mu_\phi(a_t|s, t) \right) + \sqrt{\beta_t} \epsilon, \text{ for } t = \{T, \dots, 1\} \quad (5)$$

4 隐式 Q 学习作为演员-评论家方法

本节将提出隐式 Q 学习 (IQL) 的一种泛化形式, 不仅为隐式 Q 学习提供更完整的概念理解, 也有助于理解该方法如何改进。Kostrikov 等人 [26] 证明, 当方程 1 中的 τ 趋近于 1 时, IQL 在极限情况下恢复 Q 学习, 但这并未描述在实际中当 $0.5 < \tau < 1$ 时 Q 函数所捕获的策略。通过将 IQL 重新解释为演员-评论家方法, 可以更好地理解其真实行为, 其中评论家学习诱导出隐式行为正则化演员 $\pi_{\text{imp}}(a|s)$ 。这种泛化将有助于理解 IQL 如何改进, 以及 IQL 超参数和损失函数形式所捕获的权衡。

4.1 广义隐式 Q 学习

为将 IQL 重新推导为演员-评论家方法, 首先将方程 1 中的价值损失泛化为对差值 $Q(s, a) - V(s)$ 使用任意凸损失 f 。对于给定的 $Q(s, a)$, 广义 IQL 评论家更新可定义为

$$V^*(s) = \arg \min_{V(s)} \mathbb{E}_{a \sim \mu(a|s)} [f(Q(s, a) - V(s))] = \arg \min_{V(s)} \mathcal{L}_V^f(V(s)). \quad (6)$$

当 $f(u) = L_2^2(u)$ 时, 恢复 IQL, 如方程 1 所示, 但本文也将考虑其他非对称凸损失。为定义隐式演员, 遵循演员-评论家方法中价值函数的常规定义, 其中

$$V(s) = \mathbb{E}_{a \sim \pi_{\text{imp}}(a|s)} [Q(s, a)]. \quad (7)$$

$f' = \frac{\partial f}{\partial V(s)}$ 本文使用 f 关于 $V(s)$ 的导数作为简写。

定理 4.1。 对于每个状态 s 和凸损失函数 f , 其中 $f'(0) = 0$, 方程 6 中定义的优化问题的解也是优化问题的解

$$\arg \min_{V(s)} \mathbb{E}_{a \sim \pi_{\text{imp}}(a|s)} [(Q(s, a) - V(s))^2],$$

其中 $\pi_{\text{imp}}(a|s) \propto \frac{\mu(a|s) |f'(Q(s, a) - V^*(s))|}{|Q(s, a) - V^*(s)|}$ 。

证明见附录 B。 □

定理 4.1 为我们提供了 (广义) IQL 损失函数 f 与相应的隐式演员 $\pi_{\text{imp}}(a|s)$ 之间的关系, 从而表明 IQL 是一种演员-评论家方法。为了明确隐式演员与行为策略 $\mu(a|s)$ 的关系, 我们可以定义一个重要性权重

$$w(s, a) = \frac{|f'(Q(s, a) - V^*(s))|}{|Q(s, a) - V^*(s)|}, \quad (8)$$

这给出了隐式演员的表达式为 $\pi_{\text{imp}}(a|s) \propto \mu(a|s) w(s, a)$ 。 f 的形式影响 $\pi_{\text{imp}}(a|s)$ 偏离 $\mu(a|s)$ 的程度。由于 IQL 可以在不显式构建策略的情况下恢复价值函数 $V^*(s)$, 因此隐式演员只需在评论家训练结束时提取。然而, 方程 8 中权重的复杂度带来了挑战, 因为使用表达能力较弱的策略类进行策略提取可能导致对隐式演员的近似效果不佳。我们将在下一节回到这一点, 但首先, 我们将提供三个潜在函数 f 的例子, 并推导它们相应的隐式策略。




图 2：在简单赌博机上比较广义 IQL 的不同损失函数。赌博机的连续动作空间有三个簇，分别对应低、中、高奖励，并带有加性噪声（左）。我们根据第 4 节中的不同目标，在赌博机分布上计算超参数选择的值（中）。最后，我们展示了由每个目标诱导的隐式演员（来自定理 4.1）样本的性能均值和标准差（右）。每个目标捕获了奖励分布的不同特征。

期望值。分布的期望分位数（expectile）对应于条件均值，若高于期望分位数的点比标准分布中采样更频繁。对于给定的 τ ，期望分位数目标对应于 $f(u) = L_2^\tau(u)$ （来自方程 1）及解 $V_\tau^2(s)$ 。根据定理 4.1，

$$w_2^\tau(s, a) = |\tau - \mathbb{1}(Q(s, a) < V_\tau^2(s))|. \quad (9)$$

增大期望分位数的 τ 会直接增大与行为策略的偏差。

分位数。分位数统计量衡量行为策略性能的前 $\tau\%$ 。这类似于期望分位数中出现的均值行为性能（SARSA）与 Q 学习之间的权衡，但改为平衡中位数行为性能与 Q 学习。对于给定的 τ ，分位数目标对应于 $f(u) = |\tau - \mathbb{1}(u < 0)||u|$ 及解 $V_\tau^1(s)$ 。根据定理 4.1，

$$w_1^\tau(s, a) = \frac{|\tau - \mathbb{1}(Q(s, a) < V_\tau^1(s))|}{|Q(s, a) - V_\tau^1(s)|}. \quad (10)$$

与期望分位数一样，增大 τ 会直接影响对行为策略的外推程度。对于该隐式策略，点应聚集在分位数附近。

指数型。另一个有趣的 f 选择是线性指数（linex）函数 $f(u) = \alpha \exp(u) - \alpha u$ ，其中温度 $\alpha \in [0, \infty]$ 用于平衡匹配行为策略与优化评论家。该目标的解（推导见附录 C）为

$$V_{\text{exp}}(s) = \frac{1}{\alpha} \log \sum_a \exp(\alpha Q(s, a) + \log \mu(a|s)). \quad (11)$$

$V_{\text{exp}}(s)$ 的推导表明它是 AWR 策略（方程 3）的归一化因子，其中。实际上， $\pi_{\text{awr}}(a|s) \propto \exp(\alpha Q(s, a) + \log \mu(a|s))$ 该损失施加了 KL 散度约束。

该目标与 Garg 等人 [14] 和 Xu 等人 [49] 所使用的评论家目标一致，并且也与 Haarnoja 等人 [17] 所使用的软策略定义相似。根据定理 4.1，

$$w_{\text{exp}}(s, a) = \frac{\alpha |\exp(\alpha(Q(s, a) - V_{\text{exp}}(s))) - 1|}{|Q(s, a) - V_{\text{exp}}(s)|}. \quad (12)$$

这赋予了具有最高 Q 值的动作最大的权重。如果 IQL 与 AWR 策略提取一起使用，那么选择 f 将提供正确的对应评论家，尽管我们稍后表明在实践中这种损失并不会带来最佳性能。

比较不同的损失函数。定理 4.1 表明，IQL 可以推广为演员-评论家方法，其中损失函数 f 的选择会影响隐式策略。在每种情况下，都有一个超参数控制隐式演员偏离行为策略的程度。在一个简单的赌博机问题中（图 2），期望值随 τ 平滑增加，分位数对应于累积分布函数，指数与最大值对齐。隐式策略分布也因目标而异：期望值演员覆盖了广泛的结果范围，分位数演员紧密集中在均值附近，指数演员在最大值附近有一些覆盖。尽管指数评论家似乎学习到了最优策略，但在实践中我们发现它可能不稳定，正如我们将在第 6.3 节中展示的那样。

4.2 策略提取与通用算法

Algorithm 1 General IQL Training

Hyperparameters: LR λ , EMA η

Initialize: $\theta, \hat{\theta}, \psi$, and ϕ

while training not converged **do**

$\psi \leftarrow \psi - \lambda \nabla_{\psi} \mathcal{L}_V^f(\psi)$ (Equation 6)

$\theta \leftarrow \theta - \lambda \nabla_{\theta} \mathcal{L}_Q(\theta)$ (Equation 2)

$\hat{\theta} \leftarrow (1 - \eta)\hat{\theta} + \eta\theta$

$\phi \leftarrow \phi - \lambda \nabla_{\phi} \mathcal{L}_{\mu}(\phi)$ (Equation 4)

end while

Algorithm 2 General IQL Policy Extraction

Hyperparameters: Samples per state N

Pretraining: $Q_{\hat{\theta}}(s, a)$, $V_{\psi}(s)$, and $\mu_{\phi}(a|s)$

while not done with episode **do**

Observe current state s

Sample $a_i \sim \mu_{\phi}(a|s)$, $i = 1, \dots, N$

Compute $w(s, a_i)$ using Eqns. 9, 10, 12, or 13

Normalize: $p_i = \frac{w(s, a_i)}{\sum_j w(s, a_j)}$

Select a_{taken} as a categorical from p_i

end while

定理 4.1 表明，与使用 IQL 训练的评论家相对应的隐式演员可能是复杂且多模态的。然而，标准 IQL 用单峰条件高斯策略 [26] 来近似这些复杂的隐式演员，并且由于评论家不知道这种近似，它不会适应这种近似（与标准演员-评论家方法中评论家会适应演员的局限性形成对比）。虽然将演员与评论家解耦应该使该方法对超参数不那么敏感，但我们假设在实践中，只有当最终显式演员足够强大以捕捉复杂的隐式演员分布时，这种好处才能实现。

训练更具表现力的执行者的一种方法是使用更强大的条件生成模型（例如扩散模型、归一化流）配合 AWR 风格的重要性加权目标。然而，文献中已知，将高表现力模型与重要性加权目标结合使用可能存在问题，因为此类模型可能增加所有训练点的似然，而不管其权重如何 [6, 48]。我们发现，在 DDPM 目标中使用 AWR 并不能提升性能（附录 F）。为了在不需大量调参的情况下捕捉这些策略，我们训练一个高表现力的策略来表示行为策略，然后对该模型的样本进行重新加权。

将学习到的行为策略模型记为 $\mu_{\phi}(a|s)$ ，我们可以从该模型生成样本，然后使用评论家对这些动作重新加权，最终在重采样时形成预期策略。该方法总结于算法 2，并提供来自正确隐式执行者分布的样本。在实践中，我们还发现，简单地选择 Q 值最高的动作往往能在评估时获得更好的性能，这对应于将 $w(s, a)$ 选择为独热向量。这种方法类似于随机执行者方法通常在评论家学习中使用随机执行者，而在评估时使用确定性执行者，[5, 17]。由此得到确定性策略

$$\pi(s) = \arg \max_{a_i \sim \mu(a|s), i=1 \dots N} Q(s, a_i). \quad (13)$$

通用算法总结。对于损失 f 和生成模型参数化的选择，我们的完整算法总结在训练阶段（算法 1）和推理阶段（算法 2）中。理论上，任何生成模型参数化都可用于我们方法中的行为克隆。然而，我们发现扩散模型在我们的实用方法中能产生最佳结果，我们将在后续章节中讨论。

在线微调过程。由于通用 IQL 仅在评估期间提取策略，因此在探索需求不显著的情况下，可能无需微调行为分布。我们概述了使用通用 IQL 进行微调的两种方法：（1）冻结行为策略 $\mu_{\phi}(a|s)$ ，采样最大动作进行探索，仅微调 $Q_{\theta}(s, a)$ 和 $V_{\psi}(s)$ ；（2）采样 $\pi_{\text{imp}}(a|s)$ 进行探索，并微调 $Q_{\theta}(s, a)$, $V_{\psi}(s)$ 和 $\mu_{\phi}(a|s)$ 。

5 隐式扩散 Q 学习

如第 4.2 节所述，策略提取算法需要具有表现力的行为分布来准确建模隐式执行者。扩散模型在此处非常合适，因为它们已被用于




图 3: 来自玩具二维连续数据集上 DDPM 配置的样本。MLP 的批大小为 256, 具有两个大小为 256 的隐藏层。+Batch 将批大小增加到 4096, +capacity 使用批大小 4096 和 3 个隐藏层。LN_Resnet 遵循相同的模式, 但最初使用 2 个隐藏块, 然后对于 +capacity 使用 3 个隐藏块。

为了对图像 [20] 以及连续动作空间 [44, 36] 先验中的复杂分布进行建模, 对于算法 1 和算法 2 中描述的一般 IQL 算法的实用实现, 我们使用扩散模型参数化 $\mu_\phi(a|s)$ 和 DDPM 目标 (方程 4)。我们将此方法称为隐式扩散 Q 学习 (IDQL)。

连续空间表达与扩散中的问题。在连续空间上直接实现 DDPM 可能会在输出异常值和准确表达分布方面存在问题。例如, 我们在二维连续数据集上测试了 DDPM 的简单实现。在图 3 中, 简单的 MLP 架构未能捕捉数据分布, 并产生了许多分布外样本。异常值尤其成问题, 因为它们可能超出训练好的 Q 函数的分布范围, 从而可能错误地获得高 Q 值。

正如在图像扩散 [35] 中所展示的, 我们发现增加 MLP 网络的批大小和容量能更好地拟合分布, 但仍有许多异常值。受适用于变换器 [39] 的架构启发, 我们发现更理想的扩散网络应具有高容量且正则化良好。我们使用带有层归一化 [2](LN_resnet) 的残差网络 [18] 作为得分网络参数化 (见附录 G)。图 3 显示, 与标准 MLP 架构相比, 我们的架构选择产生了更高质量的样本和更少的异常值。我们在第 6.4 节中证明, 这种架构选择对于强性能和降低对 N 的敏感性至关重要。本节提供了关于批大小、容量和架构选择如何影响连续空间扩散建模的贡献。尽管之前已经提出了类似的用于动作建模的扩散架构 [7, 36, 40]。

6 实验评估

为了评估本文方法的性能、可扩展性和鲁棒性, 我们采用两种协议将其与先前工作进行比较: (1) 在 D4RL 基准 [11] 上使用已报告数值进行直接比较; (2) “单超参数评估”, 即对每个领域仅调整一个超参数设置, 重新运行表现最佳的方法。我们还分析了本文方法在第 4 节所述批评家目标以及在线微调方面的性能。更多实验细节和结果分别见附录 D 和附录 F。

6.1 离线强化学习结果

离线强化学习方法的主要吸引力在于其无需任何在线交互即可产生有效策略。给定方法所需的调参越少, 在实际应用中就越容易使用。因此, 在本节中, 我们既在允许任意数量超参数 (或报告结果) 的情况下评估所选方法, 也在每个领域仅允许调整一个超参数的条件下进行评估。我们选择保守 Q 学习 (Conservative Q-learning, CQL) [28]、隐式 Q 学习 (Implicit Q-learning, IQL) [26] 和扩散 Q 学习 (Diffusion Q-learning, DQL) [44] 作为重点, 因为它们在标准离线强化学习设置中表现强劲。我们将“-A”表示为允许任意调参的报告结果, 将“-1”表示为仅允许在领域间调整一个超参数的结果 (对于 IDQL, 所有运动任务使用 $\tau = 0.7$, 所有蚁穴任务使用 $\tau = 0.9$)。结果见表 1。我们还在表 2 中加入了与 %BC、决策 Transformer (Decision Transformers, DT) [8], TD3+BC (TD3) [12]、极端 Q 学习 (Extreme Q-learning, EQL) [14] 以及从行为候选中选择 (Selecting from Behavior Candidates, SfBC) [7] 的比较 (完整表格见附录 F)。

在标准评估协议下, IDQL 在运动任务上与最佳先前方法表现相当, 而在蚁穴任务上优于先前方法。在单超参数条件下, IDQL 的性能相比表 1 中的结果仅略有下降, 而其他

Dataset	CQL-A	IQL-A	DQL-A	IDQL-A	CQL-1	IQL-1	DQL-1	IDQL-1
halfcheetah-med	44.0	47.4	51.1	51.0	46.4	47.6	50.6	49.7
hopper-med	58.5	66.3	90.5	65.4	64.4	63.7	75.2	63.1
walker2d-med	72.5	78.3	87.0	82.5	81.6	81.9	83.4	80.2
halfcheetah-med-rep	45.5	44.2	47.8	45.9	45.4	43.1	45.8	45.1
hopper-med-rep	95.0	94.7	101.3	92.1	88.5	42.5	94.5	82.4
walker2d-med-rep	77.2	73.9	95.5	85.1	74.5	78.4	86.7	79.8
halfcheetah-med-exp	91.6	86.7	96.8	95.9	64.6	88.1	93.3	94.4
hopper-med-exp	105.4	91.5	111.1	108.6	99.3	73.7	102.1	105.3
walker2d-med-exp	108.8	109.6	110.1	112.7	109.6	110.5	109.6	111.6
locomotion-v2 total	698.5	692.4	791.2	739.2	674.3	629.5	741.2	711.6
antmaze-umaze	74.0	87.5	93.4	94.0	65.0	86.4	47.6	93.8
antmaze-umaze-div	84.0	62.2	66.2	80.2	41.3	62.4	35.8	62.0
antmaze-med-play	61.2	71.2	76.6	84.5	31.4	76.0	42.5	86.6
antmaze-med-div	53.7	70.0	78.6	84.8	25.8	74.8	46.3	83.5
antmaze-large-play	15.8	39.6	46.4	63.5	8.5	31.6	19.0	57.0
antmaze-large-div	14.9	47.5	57.3	67.9	7.0	36.4	25.2	56.4
antmaze-v0 total	303.6	378.0	418.5	474.6	180.0	368.4	216.4	439.3
total	1002.1	1070.4	1209.7	1213.8	854.3	997.9	957.4	1150.9
training time	80m	20m	240m	60m	80m	20m	240m	40m

表 1：重点离线强化学习比较。IDQL 与其他最先进的离线强化学习方法表现相当或更优。“-A”表示报告结果，“-1”仅允许一个超参数。

Dataset	%BC	DT	TD3	CQL	IQL	EQL	SfBC	DQL	IDQL
locomotion-v2 total	666.2	672.6	677.4	698.5	692.4	725.3	680.4	791.2	739.2
antmaze-v0 total	134.2	112.2	163.8	303.6	378.0	386	445.2	418.5	474.6
total	800.4	784.8	841.2	1002.1	1070.4	1111.3	1125.6	1209.7	1213.8
training time	10m	960m	20m	80m	20m	20m	785m	240m	60m

表 2：离线强化学习完整比较。我们将 IDQL-A 与其他先前离线强化学习方法进行比较。IDQL 在总分上优于所有方法，并取得了最强的蚁穴结果。

先前的方法性能下降更为显著，尤其是在更具挑战性的蚂蚁迷宫（antmaze）领域。因此，在有限的调参下，IDQL 以非常大的优势超越了先前的方法。这在蚂蚁迷宫领域尤为明显，我们的单一超参数结果比最佳方法（IQL）高出 +70 分。本实验的细节见附录 D。

此外，我们在表 4 中比较了不同方法之间的训练时间。IDQL 与 IQL 一样保持计算高效。特别是，IDQL 比其他两种扩散方法 Chen 等人 [7] 和 Wang 等人 [44] 快得多。尽管 IDQL 使用了更具表达力的策略模型，但评论家训练与该模型完全分离，从而实现了 IDQL 的计算效率。

6.2 在线微调

离线训练后，策略可以通过在线交互得到改进。我们测试了冻结行为策略并仅微调价值网络，以及微调所有网络的过程，如第 4.2 节所述。我们与当前最先进的微调方法进行了比较：Cal-QL [34]、RLPD [3] 和 IQL [26]。结果见表 3。与 IQL 相比，我们在预训练和最终微调性能上都看到了大幅提升。IDQL 在微调方面也保持与 RLPD 和 Cal-QL 的竞争力，同时具有更强的预训练结果。大部分收益来自最困难的蚂蚁迷宫大型环境的改进。

6.3 IQL 目标消融

In Section 4, we discussed different objectives and the different implicit policies they induce. We compare the critic losses on the D4RL benchmarks in Figure 4. Both expectiles and quantiles perform well with argmax extraction, but the exponential loss is unstable and performs worse. This indicates that the exponential critic proposed by Garg et al. [14] and Xu et al. [49] require more tuning and

Dataset	Cal-QL	RLPD	IQL	IDQL-Max	IDQL-Imp
antmaze-umaze	— → —	0.0 → 99.0	86.7 → 96.0	92.0 → 99.0	93.5 → 99.5
antmaze-umaze-diverse	— → —	0.0 → 99.0	75.0 → 84.0	78.7 → 85.6	78.4 → 73.0
antmaze-medium-play	54.0 → 98.0	0.0 → 99.5	72.0 → 95.0	83.3 → 97.8	84.4 → 94.0
antmaze-medium-diverse	73.0 → 98.0	0.0 → 98.0	68.3 → 92.0	84.7 → 98.0	84.0 → 98.7
antmaze-large-play	28.0 → 90.0	0.0 → 88.0	25.5 → 46.0	60.1 → 88.0	60.3 → 90.0
antmaze-large-diverse	32.0 → 94.0	0.0 → 87.5	42.6 → 60.7	61.1 → 90.7	61.4 → 93.0
total	— → —	0.0 → 571.0	408.2 → 473.7	459.9 → 559.1	462 → 548.2

表 3：在线微调结果。我们使用两种方法比较 IDQL 的微调性能：“-Max”表示冻结行为策略并微调价值网络，“-Imp”表示如第 4.2 节所述微调所有网络。




图 4：目标和架构消融。我们在所有 D4RL 任务上使用 argmax 提取（第一）和隐式策略提取（第二）比较 IQL 目标。我们还包括架构选择的消融（MLP 与 LN_Resnet）在运动（第三）和蚂蚁迷宫（第四）任务上的比较。

这些工作也报告了目标的不稳定性问题，尽管它们需要一些技巧才能表现良好。隐式策略分布的表现也不如 argmax 提取，但这很可能是因为这些策略有非零概率采取较差动作。这与类似的发现一致：随机策略最适合评论家学习，而确定性策略最适合评估 [17, 5]。总体而言，期望目标与贪婪提取相结合表现最强。

6.4 评估扩散架构选择

在第 5 节中，我们介绍了对减少异常值和提高扩散模型表达能力至关重要的设计选择。为了确认我们的架构有助于提升性能并降低对 N 的敏感性，我们将 LN_Resnet 架构与具有相似激活层数的三层多层感知机（MLP）进行了比较。我们对 N 进行了扫描，并测量了最终总分。结果如图 4 所示。使用 LN_resnet 对于降低对 N 的敏感性至关重要：在运动任务中，较高的 N 能带来更强的性能；而在蚂蚁迷宫任务中，增加 N 对结果影响较小。对于多层感知机架构，增加 N 会降低性能，尤其是在蚂蚁迷宫任务中。

7 讨论与局限性

在这项工作中，我们将隐式 Q 学习（IQL）推广为一种演员-评论家方法，其中凸非对称评论家损失的选择诱导出一个行为正则化的隐式演员（定理 4.1）。该隐式策略被证明是一个复杂的、基于重要性加权的分布。这表明先前工作中基于简单高斯策略的策略提取方法在 IQL 中可能表现不佳。我们通过提出一种基于表达性扩散模型的新策略提取方法来验证这一假设，描述了一系列使此类策略在实际中表现良好的架构设计决策，并在离线强化学习基准上展示了最先进的结果。当超参数调优受到限制时，我们的方法表现尤为出色，这对于调优通常困难或不可能的离线强化学习实际应用非常重要。尽管 IDQL 在大多数环境中表现良好，但在动作空间维度较小的环境（如运动任务）中存在过拟合问题。添加随机失活可以缓解这一问题，但会牺牲其他环境的表现。此外，IDQL 在 Adroit 环境的在线微调中效果不佳。我们推测，过度的预训练损害了该领域中的在线微调性能。

我们的分析表明，尽管我们可以将 IQL 推广到使用多种损失函数，但原始的期望损失在当前任务上最终表现最佳。然而，我们相信这一点

泛化性在指导未来研究方面仍具有相当价值。首先，它阐明了 IQL 实际上是一种演员-评论家方法，并为一整类隐式演员-评论家方法提供了基础。未来工作可以探索更新且更有效的损失函数。我们的工作还说明了策略提取方法的选择对于隐式 Q 学习方法至关重要。最后，我们的工作提供了一种有效、易于实现、计算高效且对超参数相对不敏感的方法，用于将扩散模型集成到离线强化学习中。

8 致谢

本研究得到了海军研究办公室和 AFOSR FA9550-22-1-0273 的支持，计算资源由伯克利研究计算提供。我们感谢 Manan Tomar 对论文早期草稿的帮助。

参考文献

- [1] Anurag Ajay, Yilun Du, Abhi Gupta, Joshua Tenenbaum, Tommi Jaakkola, and Pulkit Agrawal. Is conditional generative modeling all you need for decision-making? *arXiv preprint arXiv:2211.15657*, 2022.
- [2] Jimmy Lei Ba, Jamie Ryan Kiros, and Geoffrey E Hinton. Layer normalization. *arXiv preprint arXiv:1607.06450*, 2016.
- [3] Philip J Ball, Laura Smith, Ilya Kostrikov, and Sergey Levine. Efficient online reinforcement learning with offline data. *arXiv preprint arXiv:2302.02948*, 2023.
- [4] James Bradbury, Roy Frostig, Peter Hawkins, Matthew James Johnson, Chris Leary, Dougal Maclaurin, George Necula, Adam Paszke, Jake VanderPlas, Skye Wanderman-Milne, and Qiao Zhang. JAX: composable transformations of Python+NumPy programs, 2018. URL <http://github.com/google/jax>.
- [5] David Brandfonbrener, Will Whitney, Rajesh Ranganath, and Joan Bruna. Offline rl without off-policy evaluation. *Advances in neural information processing systems*, 34:4933–4946, 2021.
- [6] Jonathon Byrd and Zachary Lipton. What is the effect of importance weighting in deep learning? In *International conference on machine learning*, pages 872–881. PMLR, 2019.
- [7] Huayu Chen, Cheng Lu, Chengyang Ying, Hang Su, and Jun Zhu. Offline reinforcement learning via high-fidelity generative behavior modeling. *arXiv preprint arXiv:2209.14548*, 2022.
- [8] Lili Chen, Kevin Lu, Aravind Rajeswaran, Kimin Lee, Aditya Grover, Misha Laskin, Pieter Abbeel, Aravind Srinivas, and Igor Mordatch. Decision transformer: Reinforcement learning via sequence modeling. *Advances in neural information processing systems*, 34:15084–15097, 2021.
- [9] Will Dabney, Mark Rowland, Marc Bellemare, and Rémi Munos. Distributional reinforcement learning with quantile regression. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 32, 2018.
- [10] Pete Florence, Corey Lynch, Andy Zeng, Oscar A Ramirez, Ayzaan Wahid, Laura Downs, Adrian Wong, Johnny Lee, Igor Mordatch, and Jonathan Tompson. Implicit behavioral cloning. In *5th Annual Conference on Robot Learning*, 2021. URL <https://openreview.net/forum?id=rif3a5NAxU6>.
- [11] Justin Fu, Aviral Kumar, Ofir Nachum, George Tucker, and Sergey Levine. D4rl: Datasets for deep data-driven reinforcement learning. *arXiv preprint arXiv:2004.07219*, 2020.
- [12] Scott Fujimoto and Shixiang Shane Gu. A minimalist approach to offline reinforcement learning. *Advances in neural information processing systems*, 34:20132–20145, 2021.
- [13] Scott Fujimoto, David Meger, and Doina Precup. Off-policy deep reinforcement learning without exploration. In *International conference on machine learning*, pages 2052–2062. PMLR, 2019.

- [14] Divyansh Garg, Joey Hejna, Matthieu Geist, and Stefano Ermon. Extreme q-learning: Maxent rl without entropy. *arXiv preprint arXiv:2301.02328*, 2023.
- [15] Seyed Kamyar Seyed Ghasemipour, Dale Schuurmans, and Shixiang Shane Gu. Emaq: Expected-max q-learning operator for simple yet effective offline and online rl. In *International Conference on Machine Learning*, pages 3682–3691. PMLR, 2021.
- [16] Wonjoon Goo and Scott Niekum. Know your boundaries: The necessity of explicit behavioral cloning in offline rl. *arXiv preprint arXiv:2206.00695*, 2022.
- [17] Tuomas Haarnoja, Aurick Zhou, Pieter Abbeel, and Sergey Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *International conference on machine learning*, pages 1861–1870. PMLR, 2018.
- [18] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770–778, 2016.
- [19] Jonathan Heek, Anselm Levskaya, Avital Oliver, Marvin Ritter, Bertrand Rondepierre, Andreas Steiner, and Marc van Zee. Flax: A neural network library and ecosystem for JAX, 2023. URL <http://github.com/google/flax>.
- [20] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. *Advances in Neural Information Processing Systems*, 33:6840–6851, 2020.
- [21] Michael Janner, Qiyang Li, and Sergey Levine. Offline reinforcement learning as one big sequence modeling problem. *Advances in neural information processing systems*, 34:1273–1286, 2021.
- [22] Michael Janner, Yilun Du, Joshua B Tenenbaum, and Sergey Levine. Planning with diffusion for flexible behavior synthesis. *arXiv preprint arXiv:2205.09991*, 2022.
- [23] Diederik P Kingma and Jimmy Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.
- [24] Ilya Kostrikov. JAXRL: Implementations of Reinforcement Learning algorithms in JAX, 10 2021. URL <https://github.com/ikostrikov/jaxrl>.
- [25] Ilya Kostrikov, Rob Fergus, Jonathan Tompson, and Ofir Nachum. Offline reinforcement learning with fisher divergence critic regularization. In *International Conference on Machine Learning*, pages 5774–5783. PMLR, 2021.
- [26] Ilya Kostrikov, Ashvin Nair, and Sergey Levine. Offline reinforcement learning with implicit q-learning. *arXiv preprint arXiv:2110.06169*, 2021.
- [27] Aviral Kumar, Justin Fu, Matthew Soh, George Tucker, and Sergey Levine. Stabilizing off-policy q-learning via bootstrapping error reduction. *Advances in Neural Information Processing Systems*, 32, 2019.
- [28] Aviral Kumar, Aurick Zhou, George Tucker, and Sergey Levine. Conservative q-learning for offline reinforcement learning. *Advances in Neural Information Processing Systems*, 33: 1179–1191, 2020.
- [29] Arsenii Kuznetsov, Pavel Shvechikov, Alexander Grishin, and Dmitry Vetrov. Controlling overestimation bias with truncated mixture of continuous distributional quantile critics. In *International Conference on Machine Learning*, pages 5556–5566. PMLR, 2020.
- [30] Sascha Lange, Thomas Gabel, and Martin Riedmiller. Batch reinforcement learning. *Reinforcement learning: State-of-the-art*, pages 45–73, 2012.
- [31] Sergey Levine, Aviral Kumar, George Tucker, and Justin Fu. Offline reinforcement learning: Tutorial, review, and perspectives on open problems. *arXiv preprint arXiv:2005.01643*, 2020.
- [32] Ilya Loshchilov and Frank Hutter. Sgdr: Stochastic gradient descent with warm restarts. *arXiv preprint arXiv:1608.03983*, 2016.

- [33] Ashvin Nair, Abhishek Gupta, Murtaza Dalal, and Sergey Levine. Awac: Accelerating online reinforcement learning with offline datasets. *arXiv preprint arXiv:2006.09359*, 2020.
- [34] Mitsuhiro Nakamoto, Yuexiang Zhai, Anikait Singh, Max Sobol Mark, Yi Ma, Chelsea Finn, Aviral Kumar, and Sergey Levine. Cal-ql: Calibrated offline rl pre-training for efficient online fine-tuning. *arXiv preprint arXiv:2303.05479*, 2023.
- [35] Alexander Quinn Nichol and Prafulla Dhariwal. Improved denoising diffusion probabilistic models. In *International Conference on Machine Learning*, pages 8162–8171. PMLR, 2021.
- [36] Tim Pearce, Tabish Rashid, Anssi Kanervisto, Dave Bignell, Mingfei Sun, Raluca Georgescu, Sergio Valcarcel Macua, Shan Zheng Tan, Ida Momennejad, Katja Hofmann, and Sam Devlin. Imitating human behaviour with diffusion models. In *International Conference on Learning Representations*, 2023. URL <https://openreview.net/forum?id=Pv1GPQzRrC8>.
- [37] Xue Bin Peng, Aviral Kumar, Grace Zhang, and Sergey Levine. Advantage-weighted regression: Simple and scalable off-policy reinforcement learning. *arXiv preprint arXiv:1910.00177*, 2019.
- [38] Jan Peters and Stefan Schaal. Reinforcement learning by reward-weighted regression for operational space control. In *Proceedings of the 24th International Conference on Machine Learning*, volume 227 of *ACM International Conference Proceeding Series*, pages 745–750. ACM, 2007. ISBN 978-1-59593-793-3. doi: 10.1145/1273496.1273590.
- [39] Alec Radford, Jeff Wu, Rewon Child, David Luan, Dario Amodei, and Ilya Sutskever. Language models are unsupervised multitask learners. 2019.
- [40] Moritz Reuss, Maximilian Li, Xiaogang Jia, and Rudolf Lioutikov. Goal-conditioned imitation learning using score-based diffusion policies. *arXiv preprint arXiv:2304.02532*, 2023.
- [41] Jascha Sohl-Dickstein, Eric Weiss, Niru Maheswaranathan, and Surya Ganguli. Deep unsupervised learning using nonequilibrium thermodynamics. In *International Conference on Machine Learning*, pages 2256–2265. PMLR, 2015.
- [42] Kihyuk Sohn, Honglak Lee, and Xinchen Yan. Learning structured output representation using deep conditional generative models. In C. Cortes, N. Lawrence, D. Lee, M. Sugiyama, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 28. Curran Associates, Inc., 2015. URL <https://proceedings.neurips.cc/paper/2015/file/8d55a249e6baa5c06772297520da2051-Paper.pdf>.
- [43] Yang Song, Jascha Sohl-Dickstein, Diederik P Kingma, Abhishek Kumar, Stefano Ermon, and Ben Poole. Score-based generative modeling through stochastic differential equations. *arXiv preprint arXiv:2011.13456*, 2020.
- [44] Zhendong Wang, Jonathan J Hunt, and Mingyuan Zhou. Diffusion policies as an expressive policy class for offline reinforcement learning. *arXiv preprint arXiv:2208.06193*, 2022.
- [45] Ziyu Wang, Alexander Novikov, Konrad Zolna, Josh S Merel, Jost Tobias Springenberg, Scott E Reed, Bobak Shahriari, Noah Siegel, Caglar Gulcehre, Nicolas Heess, et al. Critic regularized regression. *Advances in Neural Information Processing Systems*, 33:7768–7778, 2020.
- [46] Christopher JCH Watkins and Peter Dayan. Q-learning. *Machine learning*, 8:279–292, 1992.
- [47] Yifan Wu, George Tucker, and Ofir Nachum. Behavior regularized offline reinforcement learning. *arXiv preprint arXiv:1911.11361*, 2019.
- [48] Da Xu, Yuting Ye, and Chuanwei Ruan. Understanding the role of importance weighting for deep learning. *arXiv preprint arXiv:2103.15209*, 2021.
- [49] Haoran Xu, Li Jiang, Jianxiong Li, Zhuoran Yang, Zhaoran Wang, Victor Wai Kin Chan, and Xianyu Zhan. Offline rl with no ood actions: In-sample learning via implicit value regularization. *arXiv preprint arXiv:2303.15810*, 2023.

A 强化学习定义

强化学习是在马尔可夫决策过程（MDP）的背景下制定的，该过程定义为一个元组 $(\mathcal{S}, \mathcal{A}, p_0(s), p_M(s'|s, a), r(s, a), \gamma)$ ，包含状态空间 $\mathcal{S}$ 、动作空间 $\mathcal{A}$ 、初始状态分布 $p_0(s)$ 、转移动态 $p_M(s'|s, a)$ 、奖励函数 $r(s, a)$ 和折扣因子 γ 。目标是恢复一个策略 $\pi(a|s)$ ，以最大化 MDP 中的折扣奖励总和或回报，

$$\pi^* = \arg \max_{\pi} \mathbb{E}_{\rho(\pi)} \left[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t) \right],$$

其中 $\rho(\pi)$ 描述了由给定策略 π 诱导的轨迹分布 $\{s_t, a_t \sim \pi(a|s_t), s'_t \sim p_M(s'|s_t, a_t)\}_{t=0}^{\infty}$ 。离线强化学习中广泛使用的框架是 Q 学习 [46]，它涉及拟合一个 Q 函数 $Q(s, a)$ ，以匹配从状态 s 和动作 a 开始的折扣回报，并在下一个状态 s' （遵循当前最佳策略 $\arg \max_{a'} Q(s', a')$ ）。

B 理论结果证明

B.1 定理 4.1 的证明

证明。我们写出方程 6 中的目标函数。

$$\arg \min_{V(s)} \mathbb{E}_{a \sim \mu(a|s)} [f(Q(s, a) - V(s))]$$

注意，目标函数关于 $V(s)$ 是凸的

$$\begin{aligned} 0 &= \frac{\partial}{\partial V(s)} \mathbb{E}_{a \sim \mu(a|s)} [f(Q(s, a) - V(s))] \Big|_{V=V^*} \\ &= -\mathbb{E}_{a \sim \mu(a|s)} [f'(Q(s, a) - V^*(s))] \end{aligned}$$

由于凸性及假设 f

$$\begin{aligned} f'(0) &= 0, f'(x) = |f'(x)| \cdot \text{sign}(x) = |f'(x)| \frac{x}{|x|} \\ &= \mathbb{E}_{a \sim \mu(a|s)} \left[\frac{|f'(Q(s, a) - V^*(s))| (Q(s, a) - V^*(s))}{|Q(s, a) - V^*(s)|} \right]. \end{aligned}$$

然后我们定义隐式策略为，其中 $Z_{\text{imp}} \pi_{\text{imp}}(a|s) = \frac{\mu(a|s) |f'(Q(s, a) - V^*(s))|}{Z_{\text{imp}} |Q(s, a) - V^*(s)|}$ 是归一化常数，并将上述表达式重写为

$$\begin{aligned} &= \mathbb{E}_{a \sim \pi_{\text{imp}}(a|s)} [(Q(s, a) - V^*(s))] \\ &= \frac{\partial}{\partial V(s)} - \frac{1}{2} \cdot \mathbb{E}_{a \sim \pi_{\text{imp}}(a|s)} [(Q(s, a) - V(s))^2] \Big|_{V=V^*} = 0 \end{aligned}$$

这意味着 $V^*(s)$ 是该优化问题的一个解

$$\arg \min_{V(s)} \mathbb{E}_{a \sim \pi_{\text{imp}}(a|s)} [(Q(s, a) - V(s))^2]$$

□

C 附加推导

C.1 指数目标最优解的证明

证明。我们可以重写目标函数以去除无关项。

$$\begin{aligned} &\arg \min_{V(s)} \mathbb{E}_{a \sim \mu(a|s)} [\exp(\alpha(Q(s, a) - V(s))) - \alpha(Q(s, a) - V(s))] \\ &= \arg \min_{V(s)} \mathbb{E}_{a \sim \mu(a|s)} [\exp(\alpha(Q(s, a) - V(s))) + \alpha V(s)] \end{aligned}$$

我们展开目标函数的期望。假设 $\mu(a|s) > 0$

$$= \arg \min_{V(s)} \sum_a \mu(a|s) \left(\exp(\alpha(Q(s, a) - V(s))) + \alpha V(s) \right)$$

注意，目标函数关于 $V(s)$ 是凸的。

$$\begin{aligned}
0 &= \left. \frac{\partial}{\partial V(s)} \right|_{V=V^*} \sum_a \mu(a|s) \left(\exp(\alpha(Q(s, a) - V(s))) + \alpha V(s) \right) \\
&= \sum_a \mu(a|s) \left(-\alpha \exp(\alpha(Q(s, a) - V^*(s))) + \alpha \right) \\
&= \alpha \sum_a \mu(a|s) \left(-\exp(\alpha(Q(s, a) - V^*(s))) \right) + \alpha \sum_a \mu(a|s) \\
&= \alpha \sum_a \mu(a|s) \left(-\exp(\alpha(Q(s, a) - V^*(s))) \right) + \alpha \\
&= \alpha \exp(-\alpha V^*(s)) \sum_a \left(-\exp(\alpha Q(s, a) + \log \mu(a|s)) \right) + \alpha
\end{aligned}$$

现在我们可以轻松求解 $V^*(s)$ 。

$$\begin{aligned}
1 &= \exp(-\alpha V^*(s)) \sum_a \left(\exp(\alpha Q(s, a) + \log \mu(a|s)) \right) \\
&\quad \frac{1}{\sum_a \left(\exp(\alpha Q(s, a) + \log \mu(a|s)) \right)} = \exp(-\alpha V^*(s)) \\
\frac{1}{\alpha} \log \sum_a \left(\exp(\alpha Q(s, a) + \log \mu(a|s)) \right) &= V^*(s) = V_{\text{exp}}(s)
\end{aligned}$$

□

C.2 指数隐式策略与行为分布之间的库尔贝克-莱布勒散度

我们旨在计算指数分布的隐式策略与行为策略之间的库尔贝克-莱布勒散度。

$$\begin{aligned}
D_{KL}(\mu(a|s) \parallel \pi_{\text{exp}}(a|s)) &= \sum_a \mu(a|s) \log \left(\frac{\mu(a|s)}{\pi_{\text{exp}}(a|s)} \right) \\
&= \sum_a \mu(a|s) \log \left(\frac{\exp(\log \mu(a|s))}{\exp(\alpha(Q(s, a) - V(s)) + \log \mu(a|s))} \right) \\
&= \sum_a \mu(a|s) \log \left(\frac{1}{\exp(\alpha(Q(s, a) - V(s)))} \right) \\
&= \sum_a \mu(a|s) \alpha (V(s) - Q(s, a)) \\
&= \mathbb{E}_{(s, a) \sim \mathcal{D}} [\alpha (V(s) - Q(s, a))]
\end{aligned}$$

这表明行为策略与隐式策略之间的散度与优势以及温度超参数相关。

D 实验细节

我们的实现基于 jaxrl 仓库 [24]，该仓库使用基于 Flax [19] 的 JAX [4] 框架。为了计算结果，我们使用大学提供的集群中的 Titan X GPU。该集群包含 80 多块 GPU。

D.1 标准离线强化学习

对于标准离线强化学习基准，我们使用 150 万次梯度更新训练评论家，使用 300 万次梯度更新训练扩散行为策略。我们发现当更新次数超过 200 万时，评论家学习会略微不稳定。表 1 中所有报告的结果（“A”）均取自 Kostrikov 等人 [26] 的表 1，但 EQL、SfBC 和 DQL 除外，它们直接取自其主要的离线强化学习结果表。与 IQL 一样，我们对运动任务标准化奖励，并对 antmaze 任务将奖励减去 1。在先前方法（“-1”）的单超参数重跑中，为了公平性也进行了同样的处理。关于训练时间，我们也从 Kostrikov 等人 [26] 和 Chen 等人 [7] 获取数据。

D.2 单超参数离线强化学习

对于单超参数实验，我们从 IQL 仓库重新实现了 IQL，从 CQL 仓库重新运行了 CQL，并从 DQL 仓库重新运行了 DiffusionQL。我们仅对论文中提到的主要超参数进行扫描，并为每个领域选择表现最佳的一个；所有其他超参数保持不变。对于 CQL，我们扫描 $\lambda \in \{1.0, 2.0, 5.0, 10.0\}$ 或 CQL 项的权重；对于 DQL，我们扫描 $\eta \in \{1.0, 2.0, 2.5, 3.0\}$ 或 Q 最大化目标的权重；对于 IQL 和 IDQL，我们扫描期望值 $\tau \in \{0.6, 0.7, 0.8, 0.9\}$ 。对于每个领域（运动控制和 antmaze），我们选择表现最佳的超参数（例如，运动控制使用 $\tau = 0.7$ ，antmaze 使用 $\tau = 0.9$ ）。

虽然这可能无法公平地代表每种算法，但我们的主要目的是展示我们的方法如何开箱即用（即发布的 GitHub 实现）就能表现良好，而无需过度调参。我们发现许多非 IQL 方法倾向于过度调整其 antmaze 结果，使其包含比运动控制任务中更多的改动。例如，CQL 需要对其运动控制配置进行许多更改（链接在此）才能获得强大的 antmaze 结果。虽然这本身并不坏，但确实表明这些方法需要更仔细的调参才能在不同领域良好工作。此外，有些方法没有公平地呈现其结果，因为它们要么针对每个环境调整其方法，要么取其评估曲线的最大值。因此，我们的另一个意图是明确说明一种协议，以便公平地并排比较算法。

D.3 微调

在微调阶段，我们对评论家网络进行 100 万步预训练，对扩散行为克隆演员网络进行 200 万步预训练。在线微调期间，每个环境步对评论家网络执行一次梯度更新。若同时微调演员网络，则每个环境步执行两次梯度更新。我们发现，在灵巧操作任务上，微调未能相较预训练带来提升，但这并不意外。灵巧操作微调任务需要大量探索才能获得高回报，因此行为正则化可能有害。我们将此留作未来工作。

E 表 超参数

评论家网络与价值网络采用与 IQL [26] 相同的参数化方式（2 层多层感知机，隐藏层维度 256，修正线性单元激活）。其余架构细节针对扩散模型。

LR (For all networks)	3e-4
Critic Batch Size	256
Actor Batch Size	1024
τ Expectiles	0.7 (locomotion), 0.9 (antmaze)
τ Quantiles	0.6 (locomotion), 0.8 (antmaze)
α Exponential	1.0 (locomotion), 0.5 (antmaze)
Critic Grad Steps	1.5e6 ("-A"), 1e6 ("-I")
Actor Grad Steps	3e6 ("-A"), 2e6 ("-I")
Critic Pre-Training Steps	1e6 (Figure 3)
Actor Pre-Training Steps	2e6 (Figure 3)
Target Critic EMA	0.005
T	5
N	32 (antmaze "-A"), 128 (loco "-A"), 64 ("-I")
Beta schedule	Variance Preserving [43]
Dropout Rate [42]	0.1
Number Residual Blocks	3
Actor Cosine Decay [32]	Number of Actor Grad Steps
优化器 Adam [23]	

F 附加实验与结果

F.1 其他先前离线强化学习工作结果

我们将所提方法与相关工作部分讨论的多种近期离线强化学习算法进行比较：%BC、决策 Transformer（Decision Transformers，DT）[8]、TD3+BC (TD3) [12]、保守 Q 学习（conservative Q-learning，CQL）[28]、隐式

Dataset	%BC	DT	TD3	CQL	IQL	EQL	SfBC	DQL	IDQL
halfcheetah-m	48.4	42.6	48.3	44.0	47.4	47.7	45.9	51.1	51.0
hopper-m	56.9	67.6	59.3	58.5	66.3	71.1	57.1	90.5	65.4
walker2d-m	75.0	74.0	83.7	72.5	78.3	77.9	81.5	87.0	82.5
halfcheetah-mr	40.6	36.6	44.6	45.5	44.2	44.8	37.1	47.8	45.9
hopper-mr	75.9	82.7	60.9	95.0	94.7	97.3	86.2	101.3	92.1
walker2d-mr	62.5	66.6	81.8	77.2	73.9	75.9	65.1	95.5	85.1
halfcheetah-me	92.9	86.8	90.7	91.6	86.7	89.8	92.6	96.8	95.9
hopper-me	110.9	110.9	98.0	105.4	91.5	107.1	108.6	111.1	108.6
walker2d-me	109.0	108.1	110.1	108.8	109.6	109.6	109.8	110.1	112.7
locomotion-v2 total	666.2	672.6	677.4	698.5	692.4	725.3	680.4	791.2	739.2
antmaze-u	62.8	59.2	78.6	74.0	87.5	87.2	92.0	93.4	94.0
antmaze-ud	50.2	53.0	71.4	84.0	62.2	69.2	85.3	66.2	80.2
antmaze-mp	5.4	0.0	10.6	61.2	71.2	73.5	81.3	76.6	84.2
antmaze-md	9.8	0.0	3.0	53.7	70.0	71.2	82.0	78.6	84.8
antmaze-lp	0.0	0.0	0.2	15.8	39.6	41	59.3	46.4	63.5
antmaze-ld	6.0	0.0	0.0	14.9	47.5	47.3	45.5	57.3	67.9
antmaze-v0 total	134.2	112.2	163.8	303.6	378.0	386	445.2	418.5	474.6
total	800.4	784.8	841.2	1002.1	1070.4	1111.3	1125.6	1209.7	1213.8
training time	10m	960m	20m	80m	20m	20m	785m	240m	60m

表 4：离线强化学习标准评估。 IDQL 性能与其他最先进离线强化学习方法相当或更优。算法名称缩写以节省空间。本方法结果基于 10 个随机种子取平均。

Dataset	IQL	Diffuser	IDQL
umaze	47.4	113.9	57.9
medium	34.9	121.5	89.5
large	58.6	123.0	90.1
total	94	358.5	237.5

表 5：迷宫二维（Maze2D）结果。 我们纳入了与 IQL 和扩散器（Diffuser）对比的迷宫二维结果。本文方法优于 IQL，并接近扩散器的性能。

Q 学习（IQL）[26]、极端 Q 学习（EQL）[14] 以及从行为候选中选择（SfBC）[7]。为节省篇幅，且由于本文的“-1”方法优于除 DQL 外所有已报告的方法，我们未在正文中包含全部比较。部分先前工作对超参数进行了粗略调整，例如 Wang 等人 [44] 在运动控制和蚂蚁迷宫任务上均采用逐任务调整，Garg 等人 [14] 则取训练过程中的最大评估值。这通常会带来更好的性能，但隐含了能够进行逐任务在线超参数选择的假设。结果报告于表 4。IDQL 在运动控制任务上保持与所有先前方法的竞争力，并在蚂蚁迷宫任务上优于所有先前方法。

F.2 迷宫二维结果

与其他离线强化学习方法相比，IQL 在迷宫二维环境中表现相当差。具体而言，扩散器 [22] 在与 IQL 对比时表现非常强劲，并利用了扩散。我们考察本文方法是否有助于提升 IQL 的性能。结果见表 5。本文方法一致优于 IQL，但不及扩散器。我们推测基于模型的规划在迷宫二维环境中具有更好的泛化能力。

F.3 T 扩散步数 与 贝塔调度

扩散步数（ T ）的选择对 D4RL 上的良好性能也相当关键。奇怪的是，简单二维连续数据集获得高质量样本所需的 T 远大于 D4RL 所需。我们发现二维数据集的最佳 T 为=50，而 D4RL 的最佳 T 为=5。这可能是因为控制数据集比所呈现的连续数据集更具确定性（后者在简单信号上添加了大量噪声），但这仍是一个开放问题。我们在图 5 中纳入了 D4RL 上不同 T 的消融实验。增加 T 对性能有轻微但负面的影响。需要注意的是，当 $T > 20$ 时，由于需要在马尔可夫过程的每一步重新采样整个链，评估相当缓慢。

此外，贝塔调度的选择对性能有显著影响。我们在图 5 中对线性 [20]、余弦 [35] 和方差保持调度 [43] 进行了消融实验。我们发现方差保持调度在 D4RL 上效果最佳，但余弦调度在 T 较小时也表现很好。线性调度需要非常大的 T 才能表现良好，最终




图 5: 不同调度和 T 的扫描。低 T 的方差保持调度通常效果最佳。




图 6: 批大小消融。较高的批大小对蚂蚁迷宫任务很重要，但对运动任务不重要。

对于 D4RL 任务来说是一个较差的选择。我们推测调度引起的信噪比在正确表达中非常重要。特别是，第一个噪声步骤是加噪过程的关键部分。总之，我们建议扫描不同的 T 和调度，以实现动作空间的最佳建模。

F.4 批大小

如第 5 节所述，批大小对于减少异常样本很重要。我们在 D4RL 基准上对 DDPM 损失的不同批大小进行了消融。结果如图 6 所示。虽然批大小对运动任务影响较小，但较大的批大小在蚂蚁迷宫任务上带来更强的性能。不过，批大小不如架构选择或模型容量那么关键。

F.5 AWR 加权 DDPM 消融。

为了证明我们的方法优于直接训练策略，我们使用 AWR 对一批 DDPM 损失进行加权消融。我们尝试了两种版本：一种只采样策略一次，另一种采样 $N = 64$ 次并取使评论家最大化的样本。结果如图 7 所示。在单样本方法的情况下，AWR 加权目标通常比 IDQL 整体表现更差，最多与多样本设置相当。因此，AWR 对于实现强性能并非必要，反而增加了一个不必要的训练参数。




图 7: 使用 AWR 的加权 DDPM 损失消融。我们尝试了单样本（左）和多样本加 `argmax`（右）。结果在 10 个种子上取平均。




图 8：容量、随机失活和层范数对离线结果的消融。




图 9：antmaze-large 任务的在线微调结果。针对 antmaze-large 任务，我们方法在不同采样和微调策略下的微调训练曲线。冻结的 actor 仅需 10 万样本即可达到峰值性能。

F.6 其他重要架构细节

在 D4RL 上取得强性能还有其他重要的架构细节。我们在图 8 中消融了容量（残差块数量）、层范数和随机失活的影响。如第 5 节所示，更大的容量和良好正则化的网络对于强性能至关重要。随机失活在减少过拟合方面有很大益处，而层范数对整体性能有小幅提升。

F.7 在线微调的训练曲线

为了比较我们策略提取方法的样本效率和有效性，我们在图 9 中将 IDQL 与 IQL 在 antmaze-large 环境中进行了对比。训练曲线显示相对于 IQL 有性能提升和样本效率提升，表明 IDQL 在微调方面的优势。

F.8 完整学习曲线

图 10 和图 11 是 IDQL 单超参数 ("-1") 变体的学习曲线。




图 10: 单超参数变体 IDQL 在运动任务上的训练曲线。





图 11: 单超参数变体 IDQL 在蚁穴任务上的训练曲线。

G LN_Resnet 架构

我们描述了第 5 节中 LN_Resnet 所使用的架构。在实用实现中，我们采用隐藏维度 256 和 $n = 3$ 个块。



H 额外相关工作

其他离线强化学习方法。Brandfonbrener 等人 [5] 使用 SARSA 评论家目标（等价于期望 $\tau = 0.5$ ）进行评论家学习，然后通过 AWR 进行贪婪提取。

强化学习的统计度量。在算法家族中，我们提出分位数作为一种潜在的统计测度，用以诱导隐式策略分布。分位数统计此前也已在强化学习（RL）中用于估计 Q 函数上的分布 [9, 29]。然而，与 IQL 类似，我们避免在分布外动作上查询 Q 函数。