

通过人类交互的推理时策略引导

Yanwei Wang^{†*}, Lirui Wang[†], Yilun Du[†], Balakumar Sundaralingam[‡], Xuning Yang[‡], Yu-Wei Chao[‡],
Claudia Pérez-D'Arpino[‡], Dieter Fox[‡], Julie Shah[†]

摘要——利用人类示范训练的生成式策略能够自主完成多模态、长时程任务。然而，在推理阶段，人类通常被排除在策略执行循环之外，这限制了在多个预测中将预训练策略引导至特定子目标或轨迹形态的能力。朴素的人类干预可能无意中加剧分布偏移，导致约束违反或执行失败。为了更好地使策略输出与人类意图对齐而不引入分布外误差，本文提出一种推理时策略引导（Inference-Time Policy Steering, ITPS）框架，利用人类交互来偏置生成采样过程，而非基于交互数据微调策略。我们在三个仿真与真实世界基准上评估了 ITPS，测试了三种形式的人类交互及相关的对齐距离度量。在六种采样策略中，本文提出的结合扩散策略的随机采样在对齐与分布偏移之间取得了最佳权衡。视频见 <https://yanweiw.github.io/itps/>。

I. 引言

行为克隆（Behavior Cloning）[1] 推动了近期通用策略的浪潮 [2]、[3]、[4]，这些策略能够利用单一深度生成模型 [5] 解决多项任务。随着这些模型从多模态¹人类演示中习得越来越多的灵巧技能 [6]、[7]、[8]，一个自然的问题随之而来：如何调整这些技能以遵循特定的用户目标？目前，在推理时直接干预并纠正这些开箱即用策略行为的机制很少，尤其是当它们的行为与用户意图不一致时——这通常源于任务规范不足或部署过程中的分布偏移。一种将面向自主行为生成的策略适配到实时人机交互的方法是，在交互数据（如语言纠正 [9]）上对其进行微调。然而，这种方法需要额外的数据收集和训练，而且语言未必是捕捉底层连续意图的最佳模式 [10]。本文探索了是否可以在不进行微调的情况下，引导一个冻结的预训练策略生成与用户意图一致的行为——这些意图直接通过任务空间中的点目标 [11]、轨迹草图 [10] 和物理纠正 [12] 来指定（图 1）。尽管在任务空间中进行推理时干预提供了一种直接引导行为的方式，但它们可能无意中加剧分布偏移——这是行为克隆中一个众所周知的问题，往往导致执行失败 [13]。先前解决该问题的工作 [14]、[15]、[16]、[17] 在很大程度上




图 1：推理时策略引导（ITPS）。本文提出一个新颖的框架，统一各种形式的人类交互以引导冻结的生成策略。用户交互“提示”预训练策略在推理时合成一致的行为。

仅关注单任务场景，限制了其在多任务策略中的适用性。为克服这一局限性，本文利用多模态生成模型生成满足似然约束的轨迹 [18]、[19]、[20]，确保策略即使在引导后也能生成有效动作。具体而言，本文将策略引导构建为从已学习生成策略的似然分布中进行条件采样。从成功演示中学习到的似然约束使本文能够一致地合成有效轨迹，而条件采样则确保这些轨迹与用户目标对齐。通过将预训练策略与推理时目标相结合，本文能够灵活地将通用策略适配到每个新的下游交互模式，而无需以任何方式修改预训练策略。为评估推理时引导的有效性，本文制定了离散和连续对齐度量，以捕捉人类在离散任务执行和连续运动塑造中的偏好。本文研究了一套六种将交互输入转换为生成模型条件采样的方法。本文识别出对齐与约束满足之间的权衡：随着这些方法改善对齐，它们往往会产生更多的约束违反和任务失败。为解决这一问题，本文提出一种针对扩散策略 [6] 的马尔可夫链蒙特卡洛（MCMC）过程 [21]，该过程在交互引导采样期间缓解分布偏移，实现最佳的对齐。

[†] 麻省理工学院计算机科学与人工智能实验室（MIT CSAIL），[‡] 英伟达（NVIDIA）。* 部分工作于英伟达实习期间完成。¹ 本文中，多模态指数据分布，而非交互或传感器模式。




图 2: 策略引导方法。给定用户输入, 方法 (a-c) 通过 (a) 扰动、(b) 排序或 (c) 初始化为在推理之前或之后纳入对齐目标, 而方法 (d,e) 则在推理过程中直接集成该目标。

Algorithm 1: Stochastic Sampling

Input: diffusion policy π_θ , user interaction $\mathbf{z}$, alignment objective $\xi(\cdot)$

- 1: Initialize plan $\tau_N \sim \mathcal{N}(0, I)$
- 2: **for** $i = N, \dots, 1$: // denoising steps
- 3: **for** $j = 1, \dots, M$: // sampling steps
- 4: $\epsilon \leftarrow \pi_\theta(\tau_i)$ // denoising gradient
- 5: $\delta \leftarrow \nabla \xi(\tau_i, \mathbf{z})$ // alignment gradient
- 6: **if** $j < M$:
- 7: $\tau_i \leftarrow \text{reverse}(\tau_i, \epsilon + \beta_i \delta, i)$
- 8: **else:**
- 9: $\tau_{i-1} \leftarrow \text{reverse}(\tau_i, \epsilon + \beta_i \delta, i-1)$

算法 1: 随机采样。与引导扩散算法相比 仅需四行改动。

约束满足权衡, 涵盖生成策略与采样策略的各种组合。贡献: (1) 本文提出一种新颖的推理时框架 (ITPS), 该框架结合实时用户交互来引导冻结的模仿策略。(2) 本文引入一组对齐目标以及用于优化这些目标的采样方法, 并阐明对齐与约束满足之间的权衡。(3) 本文设计一种新的扩散策略推理算法——随机采样, 该算法在保持数据流形内约束的同时, 改善样本与用户意图的对齐。

II. 策略引导

A. 引导朝向用户意图

在这项工作中, 我们探索如何从冻结的生成模型中生成轨迹 τ , 使其与用户意图对齐, 这些意图可以指定为离散任务 (例如, 如图 1 所示选择左碗或右碗) 或连续运动。对于离散偏好, 我们的目标是最大化任务对齐 (**Task Alignment, TA**), 即预测技能执行预期任务的百分比。对于连续偏好, 我们的目标是最大化运动对齐 (**Motion Alignment, MA**), 即生成轨迹与目标轨迹之间的负 $\mathcal{L}_2$ 距离。除了明确指定的用户目标外, 我们还测量满足物理约束的生成计划的百分比——这些约束是隐式用户意图, 如避免碰撞或完成任务——称为约束满足率 (**Constraint Satisfaction rate, CS**)。我们将引导朝向用户意图定义为在最大化 **CS** 的同时提高 **TA** 或 **MA**。具体来说, 最大化 **CS** 是通过在预训练策略的分布中采样实现的, 而提高 **TA** 或 **MA** 是通过最小化目标函数 $\xi(\tau, \mathbf{z})$ 实现的, 其中用户通过交互 $\mathbf{z}$ 告知其意图, 以对轨迹空间 τ 进行评分。我们考虑以下三种交互类型和目标函数。

点输入。 第一个目标函数 ξ 要求用户在图像上指定一个点坐标, 我们希望机器人轨迹能够到达该点。给定生成的轨迹 $\tau = (s_1, s_2, \dots, s_T) \in \mathbb{R}^3$, 我们使用 RGB-D 场景相机中的深度信息将指定的像素映射到

对应的 3D 状态 $\mathbf{z}^{\text{point}} \in \mathbb{R}^3$ 。然后, 与用户意图的对齐被定义为最小化目标函数:

$$\xi(\tau, \mathbf{z}^{\text{point}}) = \sum_{t=1}^T \frac{1}{T} \|\mathbf{s}_t - \mathbf{z}^{\text{point}}\|_2, \quad (1)$$

该函数捕获生成轨迹中所有状态与目标 3D 状态 $\mathbf{z}^2$ 之间的平均 $\mathcal{L}_2$ 距离。该目标函数允许用户场景中灵活地指定目标点, 例如在真实世界厨房环境中指定要操作的对象 (图 1)。

草图输入。 我们考虑的下一个目标函数 ξ 允许用户指定更连续的意图, 通过生成我们希望机器人遵循的部分轨迹草图 $\mathbf{z}^{\text{sketch}} \in \mathbb{R}^{T \times 3}$ 。给定该草图, 我们将 ξ 定义为:

$$\xi(\tau, \mathbf{z}^{\text{sketch}}) = \sum_{t=1}^T \|\mathbf{s}_t - \mathbf{z}_t^{\text{sketch}}\|_2. \quad (2)$$

当草图 $\mathbf{z}$ 的长度与生成轨迹 τ 不同时, 我们均匀重采样 $\mathbf{z}^{\text{sketch}}$ 以匹配生成样本³的时间维度。与点输入相比, 该目标函数允许用户通过机器人工作空间中的方向路径指定轨迹的形状偏好 (图 5)。

物理修正输入。 最后, 我们考虑一个目标 ξ , 它允许用户通过对机器人的物理修正 $\mathbf{z}^{\text{nudge}}$ 来指定意图。最小化该目标

$$\xi(\tau, \mathbf{z}^{\text{nudge}}) = \begin{cases} 0, & \mathbf{s}_t = \mathbf{z}_t^{\text{nudge}} \text{ for } t \leq k \\ \infty, & \text{otherwise} \end{cases} \quad (3)$$

对应于用用户指定的 $\mathbf{z}^{\text{nudge}}$ 覆盖轨迹 τ 的起始部分 (例如前 k 步):

$$\tau = [\mathbf{z}_1^{\text{nudge}}, \dots, \mathbf{z}_k^{\text{nudge}}, \mathbf{s}_{k+1}, \dots, \mathbf{s}_T]. \quad (4)$$

与之前的交互类型相比, 物理修正直接干预机器人的运动执行 (图 1)。

²While $\min_{s_1 \dots s_T} \|\mathbf{s}_t - \mathbf{z}\|_2$ 更准确, 但梯度不平滑。³ $\mathcal{L}_2$ 用于替代动态时间规整 [22], 以获得平滑梯度和线性时间复杂度。




图 3：引导扩散与随机采样。在一个玩具示例中，目标是从预训练分布中采样可能的数据点，同时与目标点对齐。GD 采样近似两个分布的和，而随机采样近似它们的乘积，如核密度估计 [23] 的等高线所示。因此，当点输入不与任何分布模式对齐时，GD 引入分布偏移，而随机采样识别最接近的分布内模式。

B. 推理时交互条件采样

给定轨迹 τ 上的推理时对齐目标 $\xi(\tau, \mathbf{z})$ ，我们探索了六种偏置轨迹生成以最小化该目标的方法。前三种方法适用于由 θ 参数化的各类生成模型，而后三种方法则专门利用扩散过程中的隐式优化过程。图 2 展示了这些优化过程。

随机采样 (RS)。 在随机采样基线中，我们直接从预训练模型采样轨迹 $\tau \sim \pi_\theta$ ，不做任何修改。该方法不显式优化任何目标函数 ξ ，但作为轨迹生成的基线。

输出扰动 (OP)。 在输出扰动中，我们首先从 π_θ 采样轨迹 τ ，并应用事后扰动以最小化目标 $\xi(\tau, \mathbf{z}^{\text{nudge}})$ 。然后从 $\mathbf{z}_k^{\text{nudge}}$ 重新采样以完成轨迹的剩余部分。如果用户无法提供直接的物理修正，则草图输入的前 k 个状态可用作 $\mathbf{z}^{\text{nudge}}$ 。尽管该采样策略在步骤 k 之前最大化对齐，但它不能保证从扰动状态 $\mathbf{z}_k^{\text{nudge}}$ 合成的轨迹

将满足约束。

事后排序 (PR)。 在后验排序中，我们从 π_θ 生成一批 N 条轨迹 $\{\tau_j\}_{j=1}^N$ ，并选择使目标 $\xi(\tau, \mathbf{z}^{\text{point}})$ 或 $\xi(\tau, \mathbf{z}^{\text{sketch}})$ 最小化的 τ^* 。当至少有一个生成样本与输入 $\mathbf{z}$ 紧密对齐时，该方法表现良好；但如果机器人处于没有多模态策略预测的状态，这一条件可能不成立。

有偏初始化。 在有偏初始化中，受 [24] 启发，我们修改了反向扩散过程的初始化。不再使用噪声轨迹 $\tau_N^4 \sim \mathcal{N}(0, I)$ 进行初始化，而是使用用户输入 $\mathbf{z}^{\text{point}}$ 或 $\mathbf{z}^{\text{sketch}}$ 的高斯扰动版本作为 τ_N ，从一开始就将过程拉近到期望的模式。虽然这种方法




图 4：迷宫 2D 中的对齐与碰撞。我们比较了使用草图输入引导的动作分块 Transformer 和扩散策略的各种采样方法。(1) 引导冻结策略可改善对齐，但代价是约束满足度降低和碰撞增加。此外，(2) 使用先验重放引导的多模态策略（扩散策略）在不显著分布偏移的情况下改善对齐，而 (3) 单模态策略（动作分块 Transformer）更难有效引导，特别是当它们缺乏鲁棒性时（见图 6）。(4) 最后，使用随机采样引导的扩散策略实现了最佳的对齐-约束满足权衡。

在初始化时指定了用户意图，但采样过程仍可能偏离该输入。

引导扩散 (GD)。 在引导扩散中，我们使用目标函数 $\xi(\tau, \mathbf{z})$ 来引导扩散过程 [18] 中的轨迹综合。具体而言，在每个扩散时间步 i ，给定 $\mathbf{z}^{\text{point}}$ 或 $\mathbf{z}^{\text{sketch}}$ ，我们计算对齐梯度 $\nabla_{\tau_i} \xi(\tau_i, \mathbf{z})$ 以偏置采样：

$$\tau_{i-1} = \alpha_i(\tau_i - \gamma_i(\epsilon_\theta(\tau_i, i) + \beta_i \nabla_{\tau_i} \xi(\tau_i, \mathbf{z}))) + \sigma_i \eta, \quad (5)$$

其中 $\epsilon_\theta(\tau_i, i)$ 是去噪网络， $\eta \sim \mathcal{N}(0, I)$ 是高斯噪声， β_i 是控制对齐梯度影响的引导比率， $\alpha_i, \gamma_i, \sigma_i$ 是扩散特定的超参数。该对齐梯度将反向过程引向与 $\mathbf{z}$ 对齐的轨迹，有可能在无条件的预测原本是单模态且远离 $\mathbf{z}$ 的状态下发现新的行为模式。然而，使用方程 5 中去噪梯度与对齐梯度的加权和进行采样，近似于从策略分布和目标分布的加权和而非其乘积 [21] 中采样，这可能导致分布外样本（图 3）。

随机采样 (Stochastic Sampling) (SS)。 最后，在随机采样中，我们使用退火 MCMC 来优化扩散模型 π_θ 与目标 $\xi(\tau, \mathbf{z})$ 的合成 [21]。这里，每个时间步 i 的去噪函数 $\epsilon_\theta(\tau_i, i)$ 表示一系列概率分布 $\{p_i(\tau)\}_{0 \leq i \leq N}$ 的得分 $\nabla_{\tau} \log p_i(\tau)$ ，其中 $p_N(\tau)$ 为高斯分布， $p_0(\tau)$ 为环境中有效轨迹的分布。同时，目标 $\xi(\tau, \mathbf{z})$ 定义了一个基于能量的模型 (EBM) 分布 $q(\tau) \propto e^{-\xi(\tau, \mathbf{z})}$ 。朝向用户意图的引导则对应于从 $p_N(\tau)q(\tau)$ 到 $p_0(\tau)q(\tau)$ 的顺序采样，最终从 $p_0(\tau)q(\tau)$ 得到既在环境中有效又最小化指定目标的样本。我们使用退火 ULA MCMC 采样器实现这一顺序采样，该采样器可以

4 下标表示 τ_i 的扩散步数和 s_t 的轨迹时间步。




图 5: Maze2D 定性比较。我们可视化了在给定灰色草图的情况下，从两种策略类别（ACT 和 DP）中通过各种引导方法采样的轨迹（颜色从蓝色到红色随时间变化）。轨迹粗细反映了排序后与草图的相似度，发生碰撞的样本被染成白色。SS 在保持无碰撞约束的同时与用户意图对齐。

与引导扩散代码 [21] 相似的形式。首先，我们初始化一条噪声轨迹 $\tau_N \sim \mathcal{N}(0, I)$ ，对应于来自 $p_N(\tau)q(\tau)$ 的样本。然后，在时间步 i 使用更新方程运行 M 步 MCMC 采样：

$$\tau_i = \tau_i - \gamma_i(\epsilon_\theta(\tau_i, i) + \beta_i \nabla_{\tau_i} \xi(\tau_i, \mathbf{z})) + \sigma_i \eta, \quad (6)$$

重复 $M - 1$ 次，随后执行方程 5 中的最终逆向步骤，以获得来自 $p_{i-1}(\tau)q(\tau)$ 的样本 τ_{i-1} 。这些步骤与方程 5 中的逆向采样非常相似，只需修改引导扩散代码中的四行即可实现（算法 1）。为实现方程 6 的采样，我们取通过 τ_i 上的逆向采样获得的中间干净轨迹预测 $\tilde{\tau}_0$ ，然后以噪声水平 i 进行前向扩散步骤以更新 τ_i 。在固定噪声水平上增加多个逆向采样步骤能更好地近似从乘积分布中采样，如图 3 所示，从而产生满足似然约束和用户目标的样本。在我们的所有实验中，SS 提供了最熟练的策略引导。

三、实验

我们评估推理时转向方法在改进连续运动对齐方面的有效性。迷宫二维（Maze2D）中的迷宫对齐（MA）以及方块堆叠和真实世界厨房重排任务中的离散任务对齐（TA）。此外，我们报告了引导如何影响样本间的约束满足（CS）。

A. Maze2D - 连续运动对齐（MA）对于连续运动对齐，我们使用 Maze2D [25] 来评估一个仅在无碰撞导航演示上训练的生成策略，在受到违反约束的草图引导时，是否能保持在无碰撞运动流形上。为了测试预训练策略类别的影响，我们在迷宫环境中随机位置之间的 400 万导航步骤上训练了一个基于 VAE 的动作分块变换器（ACT）[7] 和一个扩散策略（DP）[6]。DP 使用 DDIM [26] 调度器在 100 个训练步骤（ $N = 100$ ）上进行训练。训练目标聚焦于




图 6: ACT/DP 在 Maze2D 中的鲁棒性。

		RS	PR	OP	BI	GD	SS
ACT	Min $\mathcal{L}_2 \downarrow$	0.26	0.26	0.26	-	-	-
	Avg $\mathcal{L}_2 \downarrow$	0.26	0.26	0.26	-	-	-
	Collision $\downarrow$	0.16	0.16	0.35	-	-	-
DP	Min $\mathcal{L}_2 \downarrow$	0.27	0.16	0.16	0.11	0.11	0.10
	Avg $\mathcal{L}_2 \downarrow$	0.28	0.28	0.28	0.14	0.18	0.12
	碰撞 $\downarrow$	0.01	0.01	0.02	0.06	0.06	0.01

表 1: Maze2D 结果。各试验批次中 $\mathbf{z}^{\text{sketch}}$ 与最近样本（最小值）/所有样本（平均值）之间的平均碰撞率和 $\mathcal{L}_2$ 距离。SS 以最小的碰撞实现了最佳对齐。

仅对数据分布进行建模（即无碰撞随机游走），不包含任何目标导向的目标。在推理时，给定的策略保持冻结，以基准测试各种引导方法。我们在迷宫中生成 100 个随机位置，每个位置配有一个用户草图 $\mathbf{z}^{\text{sketch}}$ ，该草图可能并非无碰撞。这些草图输入引导策略每次试验生成一批 32 条轨迹。对于 DP，调度器分配 10 个推理步骤，引导比率为 $\beta_{i \leq N} = 20$ 用于 GD， $\beta_{i \leq N} = 60$ 用于 SS，其中 MCMC 采样步数设为 $M = 4$ 。为了在 OP 采样过程中纳入 $\mathbf{z}^{\text{sketch}}$ ，对草图的前段进行采样以识别无碰撞状态，并相应重置起始位置。为评估引导效果，我们报告碰撞率（ $1 - \text{CS}$ ）以及草图与每批中最接近轨迹（最小 $\mathcal{L}_2$ ）或所有轨迹（平均 $\mathcal{L}_2$ ）之间的 $\mathcal{L}_2$ 距离，该距离衡量负 MA。Min $\mathcal{L}_2$ 显示最佳对齐，而平均 $\mathcal{L}_2$ 捕捉引导后的整体分布对齐。我们的发现如图 4 所示，揭示了对齐与约束满足之间的权衡。具体而言，激进的引导改善了 MA，但降低了 CS 并增加了碰撞。此外，具有多模态预测的策略（DP）与 PR 结合可有效改善对齐，而不会加剧分布偏移。然而，如果预期计划不在初始采样批次中，PR 无法发现它（图 5）。相比之下，具有单模态预测的策略（ACT）无法通过 PR 引导来改善对齐。如果策略缺乏鲁棒性（图 6），OP 可能引入显著的分佈偏移。最后，扩散特定的引导方法可以将违反约束的草图转换为数据流形上最近的无碰撞样本。其中，SS 实现了最佳的 MA 和 CS 权衡，如表 1 和图 5 所示。

B. 积木堆叠 - 离散任务对齐（TA）我们通过测试多步生成策略（每一步具有多模态预测）是否能够被引导以遵循用户偏好的执行序列来解决长时程任务，从而评估离散任务对齐。为此，




图 7：积木堆叠定性比较。(a) 来自 DP 的无条件采样可能错过预期计划，(b) PR 无法恢复，但 (c) GD 可以。(d) 通过引导调整扩散步数（设置引导比率 $\beta_i = 0$ ）平衡了与草图的相似性和对训练分布的遵循。

我们在艾萨克仿真 (Isaac Sim) 环境中设计了一个四积木堆叠领域 [27]。仿真将四个积木初始化在随机位置，并使用库罗博 (CuRobo) 生成运动轨迹 [28]。规划器随机选择要抓取和放置的积木，有时会拆解部分塔以在其他位置重建。我们使用该数据集的五百万步训练了一个扩散策略 (DDIM，其中 $N = 100$)，以学习有效抓取-放置动作的运动流形，而不包含目标导向行为。如图 7(a) 所示，学习到的策略在一组离散轨迹上表现出多模态性。在推理时，我们引导策略实现特定的堆叠顺序，完成四积木塔。为便于三维引导，我们开发了一个基于虚拟现实 (VR) 的系统，允许用户在仿真环境中提供三维草图。在每次交互试验中，用户先观察策略的无条件展开，然后提供草图进行条件采样。如果与草图具有最小 $\mathcal{L}_2$ 距离的条件样本对应于目标积木，则该试验被视为成功对齐。如果策略执行也成功，则该试验被视为满足约束。我们在表二中报告了使用 $\beta_{i \leq N} = 25$ 的 PR 和 GD 在交互试验中的 TA 和 CS。再次看到，较高的 TA 与较低的 CS 相关。此外，我们尝试了一种策略来减轻使用 GD 采样时的分布偏移。我们没有为所有 $i = N, \dots, 1$ ，保持恒定的引导比率 β_i ，而是通过在后续步骤中设置 $\beta_{i \leq I} = 0$ 来停用引导。该方法在早期扩散步骤中将噪声样本的低频分量与用户输入对齐，同时在步骤 I 之后恢复为无条件采样。图 7(cd) 表明，原始 GD 产生了一条类似草图的弯曲轨迹，而修改后的 GD ($I = 50$ 从 CuRobo 训练数据集中检索到一条具有正确离散对齐的直线轨迹。

C. 真实世界厨房——离散任务对齐 (TA) 为评估真实场景中多步骤、多模态策略的推理时引导，我们构建了一个玩具厨房环境，并通过动觉示教生成演示。我们聚焦于两项任务：

(1) 将碗放入微波炉，(2) 将碗放入水槽。针对每项任务，我们收集 60 个演示并将其合并为一个数据集，用于训练扩散策略 (DP) 40,000 步。图 8 表明，学习到的运动流形根据末端执行器位姿和夹爪状态展现出不同的多模态技能。与积木堆叠实验不同，

Method Type (DP)	PR	GD ($\beta_{i < 50} = 0$)	GD ($\beta_i = 100$)
TA (Alignment: AS+AF)	33%	83%	86%
CS (Success: AS+MS)	100%	84%	15%
Aligned Success (AS)	33%	67%	15%
Aligned Failure (AF)	0%	16%	71%
Misaligned Success (MS)	67%	17%	0%
Misaligned Failure (MF)	0%	0%	14%

表二：积木堆叠结果。TA 表示实现对齐执行的交互百分比，无论结果如何。CS 表示抓取/放置成功的百分比，无论对齐与否。

合并来自不同任务的数据集引入了技能序列不可行的场景——例如，在打开微波炉门之前将碗放入微波炉中。因此，在此背景下，CS 度量不仅衡量单个技能的成功，还评估所得序列是否有效，如图 9 所示。在推理时，用户可以通过点击场景相机视图中的像素来指定预期技能，从而将执行引导至首选的有效序列。该像素对应的三维位置以红色球体可视化，在激活引导输入后变为绿色。我们还实验了对末端执行器位姿进行物理校正以触发行为切换，但如图 10 所示，这种交互方式往往导致执行失败。我们评估了 GD、SS 和 OP 在帮助用户实现特定离散技能序列方面的有效性。在实时策略展开 (7 Hz) 期间，用户观察随机采样的技能，并通过交互选择不同的技能。我们在表 III 中报告交互是否成功引起预期的行为切换，以及是否导致成功执行。对于 GD，我们在所有扩散步骤 ($N = 100$) 中使用引导比率 $\beta_i = 5$ ，而对于 SS，使用 $\beta_i = 100$ 。这些选择基于以下观察：增加 GD 的引导比率会扰乱扩散过程，而不会改善对齐 (图 11)。相比之下，SS 的较高引导比率可增强对齐，而不会产生噪声轨迹。因此，GD 与 $\beta_i = 5$ 作为弱引导的基线，而 OP——允许用户在执行期间物理校正机器人末端执行器轨迹——则作为强引导基线。GD 和 SS 均通过像素输入进行引导。在表 III 中，随着对齐 TA 增加，约束满足率 CS 下降。最佳引导方法 (SS) 的失败率高于随机展开 (RS)，但在没有任何微调的情况下将对齐成功率提高了 21%。

IV. 相关工作

学习 用于人机交互。近年来，从演示中学习 [6]、[7] 在机器人操作领域取得了显著成功。尽管取得了这些进展，但在推理时策略执行过程中往往缺乏实时人类输入。为弥补这一不足，在将机器人部署到人类环境时，采用了自然的人机接口 [29]、[30]。此外，还研究了语言、草图、目标等多种输入形式 [3]、[31]、[32]、[33]、[34]、[9]，以将人类意图传递给机器人。




图 8: 多模态技能。




图 9: 厨房清洁的多模态有效序列。引导选择一条首选的合法技能序列，执行直至到达终止状态。该任务至少需要六个步骤。




图 10: 对齐与分布偏移之间的权衡。当用户引导策略以对齐其意图时，推理时的交互可能加剧分布偏移并导致执行失败。




图 11: 对引导比率 β_i 的敏感性。当 β_i 较小时，引导（此处通过点输入）对引导扩散和随机采样均无效。随着 ξ_i 增大， GD 开始产生不连贯的轨迹，而随机采样成功识别出预期技能。对所有 $i \leq N$ ($N = 100$)，应用相同的 β_i 。

	Method Type (DP)	RS	GD	SS	OP
	交互类型	N/A	Point	Point	Correction
100%	TA (Alignment: AS+AF)	38%	37%	71%	89%
	CS (Success: AS+MS)	90%	82%	73%	37%
	Aligned Success (AS)	34%	32%	55%	30%
	Aligned Failure (AF)	4%	5%	16%	59%
	Misaligned Success (MS)	56%	50%	18%	7%
	Misaligned Failure (MF)	6%	13%	11%	4%

表 III: 真实世界厨房结果。我们评估用户能否引导策略从随机采样的技能切换到预期技能并保持成功执行。总体而言，随着对齐度（目标达成率）的提高，成功率（完成率）下降。

受 [24]、[35] 启发，本文框架将预训练生成式策略重新用于人机交互场景，以适应实时人类输入。本文聚焦于物理交互，因其常提供与语言提示互补的接地信息。从人类演示中学习。生成式建模 [5]、[6]、[36] 推动了多模态、长时程演示的模仿学习，使灵巧技能习得成为可能。扩散模型 [6] 尤其擅长捕捉人类演示的多模态特性，其隐式函数表示允许与外部概率分布灵活组合 [18]、[37]、[21]。先前研究探索了利用潜在计划支持长时程任务 [38]、[7]、[39]，但这些工作聚焦于单一、高质量行为模式的演示。本文聚焦于多行为模式的生成式建模 [17]，这对于实现需要策略在推理时适应输入的用户交互至关重要。

推理时行为综合。在机器人学中，推理时组合已被探索为实现结构化泛化的方法 [40]、[18]、[41]、[42]、[43]、[44]、[45]。诸如 BESO[43] 等方法利用学习到的评分函数结合无分类器引导，实现目标条件行为生成。类似地，SE3 扩散场 [45] 使用学习到的代价函数为关节运动与抓取规划生成梯度，而 V-GPS[46] 采用学习到的价值函数通过重排序引导通用策略。PoCo[47] 通过基于梯度的策略组合，跨不同领域、模态、约束和任务综合行为，支持分布外泛化。基于 PoCo，本文研究不同类型的实时物理交互如何在推理时有效引导策略。

五、结论

本文提出推理时策略引导 (Inference-Time Policy Steering, ITPS) 框架，该框架在推理过程中整合实时人类交互以控制策略行为，无需显式策略训练。我们展示了该方法如何使人类能够引导策略，并在仿真与真实世界实验中对多种算法进行基准测试。本工作的一个局限性在于依赖昂贵的采样过程来产生与人类意图一致的行为。未来工作中，我们旨在将引导过程蒸馏为交互条件策略，以实现对人类交互的更快响应，并开展用户研究以进一步验证可引导性。

六、致谢

感谢 Michael Hagenow、Andreea Bobu、Phillip Isola、Jiayuan Mao、Leslie Kaelbling、Chuer Pan、Cheng Chi 和 Sixian Wang 的宝贵建议与帮助。

参考文献

- [1] T. Osa, J. Pajarinen, G. Neumann, J. A. Bagnell, P. Abbeel, J. Peters, *et al.*, “An algorithmic perspective on imitation learning,” *Foundations and Trends® in Robotics*, vol. 7, no. 1-2, pp. 1–179, 2018.
- [2] A. O’Neill, A. Rehman, A. Gupta, A. Maddukuri, A. Gupta, A. Padalkar, A. Lee, A. Pooley, A. Gupta, A. Mandlekar, *et al.*, “Open x-embodiment: Robotic learning datasets and rt-x models,” *arXiv preprint arXiv:2310.08864*, 2023.
- [3] O. M. Team, D. Ghosh, H. Walke, K. Pertsch, K. Black, O. Mees, S. Dasari, J. Hejna, T. Kreiman, C. Xu, *et al.*, “Octo: An open-source generalist robot policy,” *arXiv preprint arXiv:2405.12213*, 2024.
- [4] M. J. Kim, K. Pertsch, S. Karamcheti, T. Xiao, A. Balakrishna, S. Nair, R. Rafailov, E. Foster, G. Lam, P. Sanketi, *et al.*, “Openvla: An open-source vision-language-action model,” *arXiv preprint arXiv:2406.09246*, 2024.
- [5] J. Urain, A. Mandlekar, Y. Du, M. Shafiullah, D. Xu, K. Fragkiadaki, G. Chaitzaki, and J. Peters, “Deep generative models in robotics: A survey on learning from multimodal demonstrations,” *arXiv preprint arXiv:2408.04380*, 2024.
- [6] C. Chi, S. Feng, Y. Du, Z. Xu, E. Cousineau, B. Burchfiel, and S. Song, “Diffusion policy: Visuomotor policy learning via action diffusion,” *arXiv preprint arXiv:2303.04137*, 2023.
- [7] T. Z. Zhao, V. Kumar, S. Levine, and C. Finn, “Learning fine-grained bimanual manipulation with low-cost hardware,” *arXiv preprint arXiv:2304.13705*, 2023.
- [8] Z. Fu, T. Z. Zhao, and C. Finn, “Mobile aloha: Learning bimanual mobile manipulation with low-cost whole-body teleoperation,” *arXiv preprint arXiv:2401.02117*, 2024.
- [9] L. X. Shi, Z. Hu, T. Z. Zhao, A. Sharma, K. Pertsch, J. Luo, S. Levine, and C. Finn, “Yell at your robot: Improving on-the-fly from language corrections,” *arXiv preprint arXiv:2403.12910*, 2024.
- [10] J. Gu, S. Kirmani, P. Wohlhart, Y. Lu, M. G. Arenas, K. Rao, W. Yu, C. Fu, K. Gopalakrishnan, Z. Xu, *et al.*, “Rt-trajectory: Robotic task generalization via hindsight trajectory sketches,” *arXiv preprint arXiv:2311.01977*, 2023.
- [11] C. C. Kemp, C. D. Anderson, H. Nguyen, A. J. Trevor, and Z. Xu, “A point-and-click interface for the real world: laser designation of objects for mobile manipulation,” in *Proceedings of the 3rd ACM/IEEE international conference on human robot interaction*, 2008, pp. 241–248.
- [12] Y. Wang, T.-H. Wang, J. Mao, M. Hagenow, and J. Shah, “Grounding language plans in demonstrations through counterfactual perturbations,” *arXiv preprint arXiv:2403.17124*, 2024.
- [13] S. Ross, G. Gordon, and D. Bagnell, “A reduction of imitation learning and structured prediction to no-regret online learning,” in *Proceedings of the fourteenth international conference on artificial intelligence and statistics. JMLR Workshop and Conference Proceedings*, 2011, pp. 627–635.
- [14] D. P. Losey, C. G. McDonald, E. Battaglia, and M. K. O’Malley, “A review of intent detection, arbitration, and communication aspects of shared control for physical human–robot interaction,” *Applied Mechanics Reviews*, vol. 70, no. 1, p. 010804, 2018.
- [15] D. P. Losey, A. Bajcsy, M. K. O’Malley, and A. D. Dragan, “Physical interaction as communication: Learning robot objectives online from human corrections,” *The International Journal of Robotics Research*, vol. 41, no. 1, pp. 20–44, 2022.
- [16] A. Billard, S. Mirrazavi, and N. Figueroa, *Learning for adaptive and reactive robot control: a dynamical systems approach*. MIT Press, 2022.
- [17] Y. Wang, N. Figueroa, S. Li, A. Shah, and J. Shah, “Temporal logic imitation: Learning plan-satisficing motion policies from demonstrations,” *arXiv preprint arXiv:2206.04632*, 2022.
- [18] M. Janner, Y. Du, J. B. Tenenbaum, and S. Levine, “Planning with diffusion for flexible behavior synthesis,” *arXiv preprint arXiv:2205.09991*, 2022.
- [19] A. Ajay, Y. Du, A. Gupta, J. Tenenbaum, T. Jaakkola, and P. Agrawal, “Is conditional generative modeling all you need for decision-making?” *arXiv preprint arXiv:2211.15657*, 2022.
- [20] S. Ye and M. Gombolay, “Efficient trajectory forecasting and generation with conditional flow matching,” *arXiv preprint arXiv:2403.10809*, 2024.
- [21] Y. Du, C. Durkan, R. Strudel, J. B. Tenenbaum, S. Dieleman, R. Fergus, J. Sohl-Dickstein, A. Doucet, and W. S. Grathwohl, “Reduce, reuse, recycle: Compositional generation with energy-based diffusion models and mcmc,” in *International conference on machine learning*. PMLR, 2023, pp. 8489–8510.
- [22] M. Müller, “Dynamic time warping,” *Information retrieval for music and motion*, pp. 69–84, 2007.
- [23] M. L. Waskom, “seaborn: statistical data visualization,” *Journal of Open Source Software*, vol. 6, no. 60, p. 3021, 2021. [Online]. Available: <https://doi.org/10.21105/joss.03021>
- [24] T. Yoneda, L. Sun, B. Stadie, M. Walter, *et al.*, “To the noise and back: Diffusion for shared autonomy,” *arXiv preprint arXiv:2302.12244*, 2023.
- [25] J. Fu, A. Kumar, O. Nachum, G. Tucker, and S. Levine, “D4rl: Datasets for deep data-driven reinforcement learning,” *arXiv preprint arXiv:2004.07219*, 2020.
- [26] J. Song, C. Meng, and S. Ermon, “Denoising diffusion implicit models,” *arXiv preprint arXiv:2010.02502*, 2020.
- [27] M. Mittal, C. Yu, Q. Yu, J. Liu, N. Rudin, D. Hoeller, J. L. Yuan, R. Singh, Y. Guo, H. Mazhar, A. Mandlekar, B. Babich, G. State, M. Hutter, and A. Garg, “Orbit: A unified simulation framework for interactive robot learning environments,” *IEEE Robotics and Automation Letters*, vol. 8, no. 6, pp. 3740–3747, 2023.
- [28] B. Sundaralingam, S. K. S. Hari, A. Fishman, C. Garrett, K. Van Wyk, V. Blukis, A. Millane, H. Oleynikova, A. Handa, F. Ramos, *et al.*, “Curobo: Parallelized collision-free robot motion generation,” in *2023 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2023, pp. 8112–8119.
- [29] D. Perzanowski, A. C. Schultz, W. Adams, E. Marsh, and M. Bugajska, “Building a multimodal human-robot interface,” *IEEE intelligent systems*, vol. 16, no. 1, pp. 16–21, 2001.
- [30] J. Berg and S. Lu, “Review of interfaces for industrial human-robot interaction,” *Current Robotics Reports*, vol. 1, pp. 27–34, 2020.
- [31] A. Brohan, Y. Chebotar, C. Finn, K. Hausman, A. Herzog, D. Ho, J. Ibarz, A. Irpan, E. Jang, R. Julian, *et al.*, “Do as i can, not as i say: Grounding language in robotic affordances,” in *Conference on robot learning*. PMLR, 2023, pp. 287–318.
- [32] P. Sundaresan, Q. Vuong, J. Gu, P. Xu, T. Xiao, S. Kirmani, T. Yu, M. Stark, A. Jain, K. Hausman, *et al.*, “Rt-sketch: Goal-conditioned imitation learning from hand-drawn sketches,” *arXiv preprint arXiv:2403.02709*, 2024.
- [33] Y. Ding, C. Florensa, P. Abbeel, and M. Phielipp, “Goal-conditioned imitation learning,” *Advances in neural information processing systems*, vol. 32, 2019.
- [34] O. Mees, L. Hermann, and W. Burgard, “What matters in language conditioned robotic imitation learning over unstructured data,” *IEEE Robotics and Automation Letters*, vol. 7, no. 4, pp. 11 205–11 212, 2022.
- [35] E. Ng, Z. Liu, and M. Kennedy, “Diffusion co-policy for synergistic human-robot collaborative tasks,” *IEEE Robotics and Automation Letters*, 2023.

- [36] S. Lee, Y. Wang, H. Etukuru, H. J. Kim, N. M. M. Shafiullah, and L. Pinto, "Behavior generation with latent actions," *arXiv preprint arXiv:2403.03181*, 2024.
- [37] N. Liu, S. Li, Y. Du, A. Torralba, and J. B. Tenenbaum, "Compositional visual generation with composable diffusion models," in *European Conference on Computer Vision*. Springer, 2022, pp. 423–439.
- [38] L. Wang, X. Meng, Y. Xiang, and D. Fox, "Hierarchical policies for cluttered-scene grasping with latent plans," *IEEE Robotics and Automation Letters*, vol. 7, no. 2, pp. 2883–2890, 2022.
- [39] C. Lynch, M. Khansari, T. Xiao, V. Kumar, J. Tompson, S. Levine, and P. Sermanet, "Learning latent plans from play," in *Conference on robot learning*. PMLR, 2020, pp. 1113–1132.
- [40] Y. Du, T. Lin, and I. Mordatch, "Model based planning with energy based models," in *Conference on Robot Learning*, 2019.
- [41] N. Gkanatsios, A. Jain, Z. Xian, Y. Zhang, C. Atkeson, and K. Fragkiadaki, "Energy-based models as zero-shot planners for compositional scene rearrangement," *arXiv preprint arXiv:2304.14391*, 2023.
- [42] Z. Yang, J. Mao, Y. Du, J. Wu, J. B. Tenenbaum, T. Lozano-Pérez, and L. P. Kaelbling, "Compositional diffusion-based continuous constraint solvers," *arXiv preprint arXiv:2309.00966*, 2023.
- [43] M. Reuss, M. Li, X. Jia, and R. Lioutikov, "Goal-conditioned imitation learning using score-based diffusion policies," *arXiv preprint arXiv:2304.02532*, 2023.
- [44] U. A. Mishra, S. Xue, Y. Chen, and D. Xu, "Generative skill chaining: Long-horizon skill planning with diffusion models," in *Conference on Robot Learning*. PMLR, 2023, pp. 2905–2925.
- [45] J. Urain, N. Funk, J. Peters, and G. Chalvatzaki, "Se (3)-diffusionfields: Learning smooth cost functions for joint grasp and motion optimization through diffusion," in *2023 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2023, pp. 5923–5930.
- [46] M. Nakamoto, O. Mees, A. Kumar, and S. Levine, "Steering your generalists: Improving robotic foundation models via value guidance," *arXiv preprint arXiv:2410.13816*, 2024.
- [47] L. Wang, J. Zhao, Y. Du, E. H. Adelson, and R. Tedrake, "Poco: Policy composition from and for heterogeneous robot learning," *arXiv preprint arXiv:2402.02511*, 2024.