

LocoFormer: 通过长上下文适应实现通用运动

刘敏 迪帕克·帕塔克 阿纳尼耶·阿加瓦尔 斯基尔德人工智能




图 1: 我们提出 LocoFormer: 一种通用的全身体运动模型, 能够零样本迁移到任何类型的机器人身体, 无论是完全不同的形态还是因肢体损伤导致的身体变化, 甚至无需在这些机器人上进行训练 (上两行)。关键创新在于通过大规模强化学习训练的长时多回合适应——这使得仅通过在随机生成的过程化机器人上训练, 就能泛化到各种真实机器人 (底行)。我们观察到在极长上下文中的涌现适应行为, 甚至在少数几次试验中的少样本多回合适应, 其中 LocoFormer 利用次优的初始轨迹在后续回合中改进。视频见 generalist-locomotion.github.io。

摘要: 现代运动控制器通常针对特定实体进行手动调优。我们提出 LocoFormer, 一种通用的全身体运动模型, 能够控制此前未见过的腿式和轮式机器人, 甚至无需精确了解其运动学。LocoFormer 能够在测试时适应形态和动力学的变化。我们发现两个关键选择使适应成为可能。首先, 我们在过程化生成的机器人上训练大规模强化学习, 并采用激进的领域随机化。其次, 与以往短上下文长度的短视策略相比, 我们将上下文长度扩展了数个数量级, 以跨越回合边界。我们将同一个 LocoFormer 部署到各种机器人上, 并展示了在重量变化和电机故障等大扰动下的鲁棒控制。在极端场景中, 我们观察到跨回合的涌现适应, LocoFormer 从早期回合的跌倒中学习, 以改进后续回合的控制策略。我们相信, 这种简单而通用的方法未来可用于训练其他机器人技能的基础模型。视频见 generalist-locomotion.github.io。

关键词: 跨实体学习, 腿式运动, 在线适应

1 引言

人类和动物在控制方面表现出非凡的灵活性。以运动为例，它们展现出高度自适应的行为，例如出生后不久就学会行走 [2]，或适应肢体截肢 [3]。即使是刚出生的人类也具备交替迈步等反射，这些反射促进了稳健运动的学习 [4]。这与当今的机器人运动形成鲜明对比，后者通常通过强化学习从零开始学习，并针对特定形态进行调优 [5, 6, 7, 8, 9, 10]。尽管此类策略能适应一定的随机化，但这种适应非常狭窄且短视，时间尺度仅为几百毫秒 [11, 12, 5]。这种设计选择偏向于分布内性能而非通用性，因为短视的策略无法适应更广泛的分布，导致性能下降。因此，这些控制器无法泛化到新的形态，并且在发生重大变化（如电机烧毁、腿部断裂或建模错误）时会灾难性地失效。这通常意味着成功的仿真到现实迁移需要对每个机器人进行艰苦的系统辨识。此外，狭窄的任务分布不太可能促进通用且可复用策略的学习。

Adaptation to OOD Domain Randomization (2x training)




图 2：我们通过将领域随机化的范围加倍来测试分布外场景。我们看到 LocoFormer 利用数秒的历史信息来提升性能。相比之下，之前的策略是短视的，无法在几百毫秒之外有所改进。图设计来自 [1]

在本文中，我们提出了 LocoFormer，这是一种通用的全形态运动模型，能够控制任何类型的机器人身体，即使是完全分布外的形态。它还能适应诸如肢体锁定或损坏等重大变化，即使未在这些变化上进行训练。我们假设，学习此类控制器的关键在于在极端领域随机化下训练广泛的任务分布。当训练期间面临巨大的任务多样性时，策略必须学习通用策略，以高效地进行任务识别，然后调整控制以实现良好的任务性能 [1]。在大语言模型中也观察到类似现象，网络规模的预训练使其能够在测试时对新任务进行上下文适应 [13]。我们设计了一个大型的程序化生成机器人空间，包含腿式和轮式的双足与四足机器人，并积极随机化这些机器人的参数，包括惯性、控制增益和关节极限的大幅变化。

遗憾的是，现有方法无法在该任务空间中学习到有效的策略。这些方法仅在上下文中维持数百毫秒的环境交互信息。虽然这在单一实体上训练专用控制器时已足够，但如此短暂的历史记录所包含的信息不足以在大规模任务空间中进行适应。为增加策略可用的信息量，本文将上下文长度扩展了数个数量级。研究发现，这些简单的改动结合大规模训练，能够催生涌现的适应策略。

我们在未见过的真实机器人上测试了 LocoFormer，包括 Go2（轮式和腿式变体）的双足和四足模式、G1 和 H1 机器人等。我们发现，在分布外

（OOD）场景下，LocoFormer 能够提升多个回合中的性能（图 2）。特别是，当测试时使用的领域随机化程度是训练时的两倍时，我们发现 LocoFormer 能够在数秒的时间跨度内持续调整行为（至少比先前工作大两个数量级）。这一能力至少具有两个实际意义。首先，LocoFormer 更有可能弥合仿真到现实的差距，因为它能够在训练时承受更大的领域随机化，并在测试时适应分布外动态。其次，由于 LocoFormer 能够适应形态上的巨大变化，配备此类策略的机器人即使在面临肢体缺失等不利情况下，也很有可能继续正常工作。

尽管本文仅展示了在运动控制中的应用，但所提方法简洁且具有普适性，适用于任何能够生成大规模数据的场景，例如仿真环境。我们设想该方法亦可用于训练其他底层机器人技能的通用控制器。




图 3: 为了实现长上下文适应, 我们允许局部变换器 (LocoFormer) 关注先前试验中的状态。我们采用长上下文变换器 (Transformer) 骨干网络, 将上下文划分为固定长度的片段。在处理当前片段时, 键和值也从前一个 (缓存的) 片段中的状态计算得出, 但梯度不进行传播 (蓝色线条)。随着层数的增加, 这使得局部变换器甚至能够利用缓存片段之前的信息 (绿色线条)。

2 方法

本文旨在训练一个通用的运动策略, 能够稳健地控制任意机器人并适应剧烈变化。对于未见过的机器人, 该策略可在数秒内完成适应并快速部署。本文提出的 LocoFormer 通过预训练过程实现测试时的高效上下文学习 (第 2.1 节), 并采用支持长期记忆的策略架构以适应变化 (第 2.2 节)。图 3 展示了 LocoFormer 的总体框架。

2.1 预训练以学习上下文

腿式机器人在运动学和动力学方面存在显著差异, 因此需要截然不同的控制策略。训练跨异构机器人的统一策略的一种方法是, 将策略条件化于详细的运动学和动力学信息 [14]。然而, 这种方法通常需要大量的系统辨识, 并且容易受到长期磨损导致的不准确性影响。相比之下, LocoFormer 采用不同的方法, 在测试时启用上下文学习。

然而, 直接采用现有运动策略架构并将其应用于程序生成的任务空间, 效果并不理想。这是因为大多数运动控制器是短视的, 仅利用几百毫秒的历史信息进行适应。这在狭窄的任务空间中表现良好, 但在大规模任务空间中, 如此短的历史信息不足以有效适应, 从而导致失败。因此, 本文需要训练更长的上下文长度, 有时可能跨越试验边界 [15]。具体而言, 本文让策略在一个回合中运行多个试验。记忆跨试验持续存在, 目标是最大化整个回合的期望累积奖励。

问题表述 设 $M = (\mathcal{S}, \mathcal{A}, \mathcal{T}, \mathcal{R}, \rho_0, \gamma, T)$ 表示一个马尔可夫决策过程 (Markov Decision Process), 其状态空间为 $\mathcal{S}$, 动作空间为 $\mathcal{A}$, 转移函数为 $\mathcal{T}: \mathcal{S} \times \mathcal{A} \rightarrow \mathcal{S}$, 奖励函数为 $\mathcal{R}: \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$, 初始状态分布为 ρ_0 , 折扣因子为 $\gamma \in [0, 1)$, 时间范围为 $T, \mathcal{A}$ 。一次试验是从初始状态 $s_0 \sim \rho_0(s_0)$ 生成的单条轨迹 $\tau^M = [s_0, a_0, \dots]$ 。一个回合由 k 次试验组成, $\mathcal{E}^{M,k} = [\tau_1^M, \dots, \tau_k^M]$, 其中 k 从 $\rho_K =$ 均匀分布 $(1, \dots, K)$ 中采样。依赖历史的策略 $\pi_\theta(a_t | s_{0:t}, a_{0:t-1})$ 基于回合内先前的全部状态和动作历史来选择动作。

设 H_i 表示截至第 i 次试验的累积轨迹长度，约定 $H_0 = 0$ 。考虑一组马尔可夫决策过程 $\mathcal{M}$ 上的分布 $\rho_{\mathcal{M}}$ 。目标是最大化期望折扣回报：

$$J(\pi_{\theta}) = \mathbb{E}_{\substack{M \sim \rho_{\mathcal{M}} \\ k \sim \rho_K \\ \mathcal{E}^{M,k} \sim \pi_{\theta}}} \left[\sum_{i=1}^k \sum_{t=0}^T \gamma^{t+H_{i-1}} \mathcal{R}^M(s_t, a_t) \right]. \quad (1)$$

任务生成 上述公式假设能够获取马尔可夫决策过程（MDP）的分布。在我们的设定中，我们程序化地生成各种腿式机器人，并随机化其物理参数以创建多样的 MDP 实例。具体而言，我们主要关注常见形态，如双足、四足及其轮式变体，而不实际纳入市场上任何精确的机器人参数。对于每种形态，我们融入现有腿式机器人的通用设计原则。我们随机化常规运动学参数，包括关节、关节序列等。动力学参数同样被随机化，包括质量、质心等。生成的机器人样本见图 1，更多信息见附录。

统一的观测、动作与奖励空间 为了训练跨不同腿式机器人共享的策略，我们使用一个简单的统一关节空间，通过拼接一个包含当代腿式机器人大多数电机数量的关节超集，来实现一致的观测和动作表示。策略在统一关节空间内输出目标关节位置，从中为每个特定机器人提取相关关节状态。对于奖励，我们采用受 [12] 启发的设计方案，包括命令跟踪奖励和惩罚项，以减少扭矩使用、鼓励平滑动作并防止硬件损坏。

仿真中的大规模强化学习 运动任务通常跨越较长的试验。为了强调适应学习过程，我们对公式稍作修改：不是直接采样固定数量的试验，而是采样一个适应时间预算 u 秒， $u \sim$ 均匀分布 $(0, U)$ ，允许策略在最终试验前在该分配时间内进行任意数量的试验。在修改后的设定下，我们使用近端策略优化（PPO）[16] 在物理仿真中大规模优化策略。训练分两个阶段进行：最初，我们使用较短的试验持续时间和较小的 U 值，以优先获取适应行为。随后，我们延长试验长度和适应时间，为策略在真实世界部署做好准备。

部署 预训练策略可以以零样本和小样本两种方式进行上下文学习。在零样本设置（ $u = 0$ ）下，策略能在数秒内快速适应未见过的形态，通常能立即实现稳定的运动。然而，初始探索偶尔可能导致失败。在这种情况下，策略受益于小样本学习，通过利用先前试验的经验逐步提升性能。

2.2 具有长期记忆的策略架构

基于变换器（Transformer）的策略具有强大的表示能力，可以关注其历史中的任意位置，这对于有效的大规模跨形态学习至关重要。然而，高频控制任务会迅速产生大量上下文——即使约 5 秒的短暂经验也可能转化为数百个标记，这对普通变换器构成了显著的计算挑战，因为其成本随序列长度呈二次方增长。为了计算上的可行性，我们利用变换器-XL（Transformer-XL, TXL）架构 [17] 作为我们依赖历史的策略的骨干，该架构引入了段级循环机制以建模长程依赖关系。我们在时间步 t 通过多层感知机（MLP）将观测编码为嵌入 x_t 。这些嵌入作为 TXL 策略的输入，其输出随后由独立的行动者（actor）和评论家（critic）头（各为一个 MLP）解码为动作和价值估计。下面，我们详细介绍变换器-XL 骨干（图 3），并描述我们加速推理的方法。

Method	Biped					Quadruped			Wheeled		Average
	G1	H1	GR1	TRON1	BK-H	A1	Spot	AnyMal C	TRON1-W	Go2-W	
Ours (zero-shot)	0.96±0.16	0.98±0.12	0.95±0.21	0.87±0.31	0.98±0.11	0.92±0.26	1.00±0.06	0.95±0.22	0.99±0.07	0.97±0.16	0.96±0.19
Ours (few-shot)	0.98±0.11	0.99±0.08	0.99±0.09	0.96±0.18	0.99±0.09	0.94±0.23	1.00±0.05	0.96±0.19	1.00±0.04	0.98±0.10	0.98±0.13
GRU	0.09±0.06	0.08±0.11	0.09±0.11	0.03±0.03	0.47±0.40	0.46±0.44	0.68±0.37	0.42±0.45	0.66±0.34	0.74±0.36	0.37±0.41
Conditioning	0.94±0.17	0.94±0.16	0.81±0.33	0.07±0.15	0.62±0.38	0.93±0.24	0.99±0.09	0.89±0.28	0.72±0.40	0.92±0.22	0.78±0.37
Expert Policy	1.00±0.00	1.00±0.00	1.00±0.00	1.00±0.00	1.00±0.00	0.97±0.18	0.99±0.08	1.00±0.04	1.00±0.00	0.98±0.12	0.99±0.07

表 1: 我们在每台机器人 1,000 个仿真环境中评估每种方法, 这些环境包含崎岖地形和广泛的领域随机化, 覆盖了 10 台此前未见过的机器人, 分属三个类别。每个条目报告了朝随机采样目标点的平均位移, 归一化到 $[0, 1]$ 区间。LocoFormer 在零样本设置下表现具有竞争力, 并在短暂的 5 秒适应窗口后展现出进一步提升 (在 TRON1 上提升 10%)。平均而言, 它接近专家策略的性能, 优于 GRU 和条件基线。

Transformer-XL Policy Suppose $\mathbf{o}_t$ are the observations at each timestep encoded into tokens $\mathbf{x}_t$. Transformer-XL (TXL) divides tokens into segments of length L , consider two such consecutive segments: $\sigma_z = [\mathbf{x}_{z,1}, \dots, \mathbf{x}_{z,L}]$ and $\sigma_{z+1} = [\mathbf{x}_{z+1,1}, \dots, \mathbf{x}_{z+1,L}]$. Let $\mathbf{h}_z^n \in \mathbb{R}^{L \times d}$ denote the hidden states of the n -th Transformer layer for segment σ_z . TXL uses cached hidden states from previous segments to compute current attention keys and values but doesn't backpropagate gradients to them to save compute and memory. Formally, given previous hidden states $\mathbf{h}_z^{n-1}$, TXL computes:

$$\tilde{\mathbf{h}}_{z+1}^{n-1} = [\text{SG}(\mathbf{h}_z^{n-1}) \circ \mathbf{h}_{z+1}^{n-1}], \quad (2)$$

$$\mathbf{q}_{z+1}^n, \mathbf{k}_{z+1}^n, \mathbf{v}_{z+1}^n = \mathbf{h}_{z+1}^{n-1} \mathbf{W}_q, \tilde{\mathbf{h}}_{z+1}^{n-1} \mathbf{W}_k, \tilde{\mathbf{h}}_{z+1}^{n-1} \mathbf{W}_v, \quad (3)$$

$$\mathbf{h}_{z+1}^n = \text{Transformer-Layer}(\mathbf{q}_{z+1}^n, \mathbf{k}_{z+1}^n, \mathbf{v}_{z+1}^n) \quad (4)$$

其中 $\text{SG}(\cdot)$ 表示停止梯度操作, $\circ$ 表示沿序列长度维度的拼接, $\mathbf{W}_q, \mathbf{W}_k, \mathbf{W}_v$ 表示可学习的模型参数。我们使用标准变换器架构 [18] 作为 TXL。

在强化学习训练中, 每个片段被缓存以条件化后续迭代。这种片段级递归导致有效上下文长度增长为 $O(NL)$, 其中 N 是层数, L 是片段长度。例如, 具有 6 层且片段长度为 128 的变换器 (Transformer) 可实现最大 896 个时间步的记忆, 在 50 赫兹控制频率下约对应 18 秒。注意, 片段可能跨越回合边界, 此时注意力掩码被修改, 使得注意力不跨越回合边界。

推理加速 变换器的推理复杂度随片段长度二次增长, 这会显著降低推理速度。为缓解计算瓶颈, 我们利用键值缓存 (KV-cache) [19] 将推理复杂度从对时间步 t 的二次依赖降低为线性依赖。在训练时推演中, 我们使用前一片段隐藏状态导出的键和值初始化键值缓存, 然后逐步追加新时间步。对于实时部署, 键值缓存仅保留最近 $2 \times L - 1$ 个时间步, 这对应于训练期间遇到的最大直接条件化历史长度。

3 实验结果

3.1 仿真评估

我们在仿真中比较了 LocoFormer 与多个基线的性能。此外, 我们评估了策略如何随着适应时间的增长而改进, 并考察了适应过程中其内部表示的动态。

基线 我们考虑以下基线: (1) 门控循环单元策略 (GRU Policy): 在与 LocoFormer 相同设置下训练的基于门控循环单元的策略, 用于评估架构选择的影响; (2) 条件化 (Conditioning): 一种变换器策略, 以特权运动学信息为条件, 但适应记忆受限 (上下文长度 64); (3) 专家策略 (Expert Policy): 直接在目标实体上训练的变换器策略, 作为完全访问部署域的上限。LocoFormer 在零样本和少样本设置下进行评估。在少样本设置下, 策略在评估前允许有 5 秒的适应窗口。




图 4：(a) 不同适应时间下局部形态变换器 (LocoFormer) 的性能。我们在强化领域随机化条件下，将策略部署到四种形态类型的过程生成机器人上，并报告在不同适应时间预算下 6 秒推演的平均存活率。我们的策略始终受益于更长的适应时间。**(b) 策略表征的时间演化。**我们可视化四个仿人变体在 4,096 次零样本推演中第二变换器层随时间的平均输出。表征初始相似，但逐渐分化，到 5 秒时形成明显簇。这表明局部形态变换器无需显式形态规格，即可在线动态构建稳定的、具身特定的表征。

未见机器人上的评估 我们在先前未见过的机器人集合上测试所有方法：五个双足机器人（宇树 G1、H1、傅利叶 GR1、逐际动力 TRON1、伯克利人形机器人 BK-H）、三个四足机器人（宇树 A1、波士顿动力 Spot、苏黎世联邦理工学院 AnyMal C）和两个轮式机器人（TRON1-W、宇树 Go2-W）。评估在 1,000 个具有崎岖地形和强化领域随机化的随机仿真环境中进行。我们在每个环境中随机采样一个目标，并测量朝目标的平均位移。结果见表 1。尽管事先未接触这些机器人，我们的方法在零样本和少样本设置下均达到接近专家策略的性能。虽然它能以零样本方式有效适应，但在挑战性场景中延长适应时间被证明是有益的。例如，在 TRON1——一个无踝关节的双足机器人上——评估前 5 秒的适应带来 10% 的性能提升。相比之下，门控循环单元 (GRU) 基线表现不佳，平均得分为 0.37，凸显了架构选择对跨具身泛化的重要性。条件基线受益于形态输入，但受限于其短上下文窗口，导致性能中等。

适应性能 为评估 LocoFormer 的适应能力，我们将领域随机化强度加倍，并在崎岖地形上部署程序化生成的机器人。我们记录在不同适应时间预算（每种设置 5 万回合）下，6 秒 rollout 中的平均跌倒时间。如图 6c 所示，LocoFormer 即使在零样本情况下也能有效适应具有挑战性的领域，并且短时间的适应期能带来显著提升。所有形态的存活率都随适应时间的增加而提高，凸显了长上下文学习的优势。

表征动态 我们通过追踪内部表征的时间演化进一步分析适应过程。具体而言，我们监测四个仿人变体在 4096 次零样本 rollout 中第二层 Transformer 的平均输出（图 6d）。最初相似的嵌入（在第一秒内）随时间分化，反映出策略在不同实施例上日益增强的专门化。到 5 秒时，出现明显的表征簇，表明策略能够在没有显式机器人描述符的情况下形成稳定的、针对特定实施例的内部模型。

3.2 真实世界评估

我们首先评估 LocoFormer 在真实世界中向未见机器人的迁移能力。我们的测试集包括四台宇树机器人：G1、H1、Go2 和 Go2-W，如图 1 所示。值得注意的是，我们还通过仅激活后腿来评估 Go2 和 Go2-W 的双足模式。我们的策略在这些机器人上零样本部署，并在数秒内完成适应，无需任何事先调优或重新训练。




图 5：我们展示了涌现的适应行为，全部来自同一个 LocoFormer 模型。A：一个膝盖被锁定，LocoFormer 适应用剩余三条腿行走。这并非训练的一部分。B：如果 LocoFormer 在一次试验中无法适应，它会保留之前试验的记忆并提高性能。C：轮子被锁定，LocoFormer 检测到突然变化，并切换到行走步态。当附加质量时，LocoFormer 也能适应。D：加装高跷后，LocoFormer 适应延长的腿长以继续行走。E：在一条或两条腿被锁定的情况下，LocoFormer 调整其运动以保持平衡。F：小腿被截断后，机器人在数十秒内适应用膝盖行走，尽管在训练时从未见过这种情况。

LocoFormer 在不同形态上进行了大规模训练，并承受了严重的在线扰动，同时融入了跨试验的记忆。我们假设这使策略能够应对现实世界中的大扰动，如形态突变和附加负载，并利用先验经验实现高效控制。我们在下文展示了这些能力（见图 5）。

A、E：腿部锁定 当 Go2 正常行走时，通过将 PD 设定点覆盖为硬编码值来锁定膝关节。这将四足机器人转变为三足机器人，使其失稳。为了恢复，策略必须采用一种步态，使质心保持在三角形支撑多边形内——这是一个未见过的场景，因为三足机器人不在我们的设计空间内。LocoFormer 最初会向前倾斜，但学会了将重心向后转移到三条腿上，并在适应 2-3 秒后甚至能够行走。类似的行为也出现在轮式四足机器人上：当一条或两条腿被锁定时，LocoFormer 会调整其步态以重新分配负载，在驱动减少的情况下保持平衡和移动性。

B：跨试验适应 在高度不稳定的情况下，单次尝试内的适应可能是不可能的。我们将 LocoFormer 作为双足机器人运行，没有踝关节电机，只有一个支撑点。这是一个高度不稳定的平台，在失败发生前几乎没有时间进行稳定。由于 LocoFormer 对形态一无所知，它在第一次试验中失败了。然而，我们可以将失败的轨迹信息保留在 TransformerXL 缓存中，并关注它，从而在后续试验中提高性能。在第三次试验中，机器人以双足模式稳定行走，甚至对推力和重物具有鲁棒性。

C：轮子锁定和负载变化 当 Go2-W 最初滚动时，我们在执行过程中通过软件将增益设为零来程序化地锁定轮子。这立即改变了机器人的动力学，因为它不能再使用滚动来移动。LocoFormer 检测到这种差异，因为向轮子发送命令不再产生相同的效果。它迅速适应这种变化，并切换到行走步态，就像标准的腿式双足机器人一样。在某个时刻，轮子再次解锁。LocoFormer 检测到这一点，并切换到能量更低的滚动步态。类似地，当添加外部质量时，LocoFormer 会调整其步态以保持平衡。

D：踩高跷行走 我们将高跷连接到机器人的腿部，使有效腿身比远超训练期间所见。这改变了运动的运动学和动力学特性，表现为

抬高质心并改变摆动/支撑的杠杆作用。起初，机器人迈出几步不稳定的步伐，但 LocoFormer 迅速调整其协调性——调整步态时机和落脚位置——以适应延长的形态，并能够以稳定、可重复的步态向前行走。

F: 截断小腿 我们将机器人的小腿截断至大腿处。这实质上移除了 4 个自由度并降低了肢体长度。该配置在训练中未曾出现。起初，机器人无法有效移动，仅在原地踏步。然而，经过 7-8 秒的适应后，它发现需要在大腿关节处进行大幅度摆动，此后便能有效移动。

4 相关工作

4.1 腿足运动

近年来，仿真到现实迁移已成为训练运动控制的有效范式。对于无视觉机器人，通过在仿真中结合领域随机化训练自适应策略，然后零样本迁移到现实世界，这已应用于四足机器人 [5, 6, 7, 8, 9, 10] 和人形机器人 [11, 20, 21, 22, 23, 24]。后续工作将运动与视觉结合，根据前方地形几何调整行走行为，采用隐式 [12, 25, 26, 27, 28, 29] 或显式映射 [30, 31, 32]。在所有这些工作中，控制器针对特定机器人进行调优，动力学随机化范围较窄，且适应上下文长度较短（数百毫秒）。相比之下，我们训练了一个单一的通用策略，能够在长上下文中适应截然不同的形态和动力学。

4.2 跨形态学习

语言和视觉领域大规模预训练的成功激发了人们对开发类似机器人模型的兴趣，这些模型能够吸收来自多种形态机器人的数据。在运动控制方面，许多方法侧重于根据机器人形态向策略架构添加结构性偏差，形式包括在图神经网络上进行消息传递 [33]，或通过变换器中的注意力掩码 [34]。Gupta 等人 [35] 将运动控制器与机器人形态共同进化。其他方法则侧重于参数化策略的动作和观测空间以促进知识迁移。Doshi 等人 [36] 使用模仿学习训练一个变换器，该变换器使用不同的动作头将读出让牌解码到不同的形态。Bohlinger 等人 [14] 在少数选定的机器人上使用强化学习进行训练，并采用自定义的潜在观测空间，该空间编码关节观测以及机器人的精确运动学结构。相比之下，Reed 等人 [37] 仅通过在多形态数据上进行下一令牌预测来训练。与我们的工作密切相关的是，Feng 等人 [38] 在程序化生成的四足机器人上训练单一控制器。与这些工作的关键区别在于，我们在更大规模上使用长上下文进行训练，任务空间涵盖轮式和腿式四足机器人以及人形机器人，范围要大得多。我们证明这带来了新颖且高度灵活的适应策略。

4.3 适应

适应、元学习 [39] 和上下文学习 [13] 是相关概念，它们处理的是从少量示例中实现高任务性能的问题。元强化学习或微调可用于快速适应专家运动策略以应对动力学变化 [40, 41, 42]。在类似游戏的环境中，[15] 表明，使用跨越回合的上下文进行训练会导致自适应行为，策略学会从早期错误中改进。Team 等人 [1] 表明，在开放式任务空间中进行大规模训练，使智能体能够通过长上下文推理在人类时间尺度上学会适应。在本文中，我们研究高频闭环控制环境中的适应问题，并提出一个能够适应不同形态和动力学的单一策略。

5 结论

本文提出 LocoFormer，一种通用运动策略，能够在现实世界中稳健控制多种腿式与轮式机器人。这一能力源于涌现的自适应行为，策略可利用长上下文作为信息以提升性能。尽管本文仅讨论运动控制，我们相信这一方法具有通用性，未来可用于训练其他技能的通用控制器，尤其是在可进行大规模强化学习的仿真环境中。

6 局限性

我们识别出本方法的几个关键局限性：

- 与专用策略相比，训练 LocoFormer 资源消耗极高。考虑到任务分布与上下文范围更广，这并不意外，但在大规模并行强化学习设置中可能存在算法改进空间 [43]。
- LocoFormer 依赖手工设计的程序化生成任务空间。这在一般情况下可能难以设计。未来工作可探索利用大语言模型或其他网络规模来源自动生成任务，这或许是更具可扩展性的方法。

致谢

感谢 Kevin Gmelin、Jayesh Singla、Jared Meija、Shikhar Bahl 的有益讨论。

参考文献

- [1] A. A. Team, J. Bauer, K. Baumli, S. Baveja, F. Behbahani, A. Bhoopchand, N. Bradley-Schmiege, M. Chang, N. Clay, A. Collister, et al. Human-timescale adaptation in an open-ended task space. *arXiv preprint arXiv:2301.07608*, 2023.
- [2] G. D. Muir. Early ontogeny of locomotor behaviour: a comparison between altricial and precocial animals. *Brain research bulletin*, 53(5):719–726, 2000.
- [3] B. Goldner, A. Fuchs, I. Nolte, and N. Schilling. Kinematic adaptations to tripedal locomotion in dogs. *The Veterinary Journal*, 204(2):192–200, 2015. ISSN 1090-0233. doi:<https://doi.org/10.1016/j.tvjl.2015.03.003>. URL <https://www.sciencedirect.com/science/article/pii/S1090023315001008>.
- [4] E. Thelen and D. M. Fisher. Newborn stepping: An explanation for a” disappearing” reflex. *Developmental psychology*, 18(5):760, 1982.
- [5] A. Kumar, Z. Fu, D. Pathak, and J. Malik. Rma: Rapid motor adaptation for legged robots. *arXiv preprint arXiv:2107.04034*, 2021.
- [6] J. Lee, J. Hwangbo, L. Wellhausen, V. Koltun, and M. Hutter. Learning quadrupedal locomotion over challenging terrain. *Science robotics*, 5(47):eabc5986, 2020.
- [7] I. M. A. Nahrendra, B. Yu, and H. Myung. Dreamwaq: Learning robust quadrupedal locomotion with implicit terrain imagination via deep reinforcement learning. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, pages 5078–5084. IEEE, 2023.
- [8] G. B. Margolis and P. Agrawal. Walk these ways: Tuning robot control for generalization with multiplicity of behavior. In *Conference on Robot Learning*, pages 22–31. PMLR, 2023.
- [9] Y. Kim, H. Oh, J. Lee, J. Choi, G. Ji, M. Jung, D. Youm, and J. Hwangbo. Not only rewards but also constraints: Applications on legged robot locomotion. *IEEE Transactions on Robotics*, 40: 2984–3003, 2024. doi:[10.1109/TRO.2024.3400935](https://doi.org/10.1109/TRO.2024.3400935).
- [10] L. Smith, J. C. Kew, T. Li, L. Luu, X. B. Peng, S. Ha, J. Tan, and S. Levine. Learning and adapting agile locomotion skills by transferring experience. *arXiv preprint arXiv:2304.09834*, 2023.
- [11] I. Radosavovic, T. Xiao, B. Zhang, T. Darrell, J. Malik, and K. Sreenath. Real-world humanoid locomotion with reinforcement learning. *Science Robotics*, 9(89):eadi9579, 2024.
- [12] A. Agarwal, A. Kumar, J. Malik, and D. Pathak. Legged locomotion in challenging terrains using egocentric vision. In *Conference on robot learning*, pages 403–415. PMLR, 2023.
- [13] T. Brown, B. Mann, N. Ryder, M. Subbiah, J. D. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, et al. Language models are few-shot learners. *Advances in neural information processing systems*, 33:1877–1901, 2020.
- [14] N. Bohlinger, G. Czechmanowski, M. Krupka, P. Kicki, K. Walas, J. Peters, and D. Tateo. One policy to run them all: an end-to-end learning approach to multi-embodiment locomotion. *arXiv preprint arXiv:2409.06366*, 2024.
- [15] Y. Duan, J. Schulman, X. Chen, P. L. Bartlett, I. Sutskever, and P. Abbeel. RL²: Fast reinforcement learning via slow reinforcement learning. *arXiv preprint arXiv:1611.02779*, 2016.
- [16] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
- [17] Z. Dai, Z. Yang, Y. Yang, J. Carbonell, Q. V. Le, and R. Salakhutdinov. Transformer-xl: Attentive language models beyond a fixed-length context. *arXiv preprint arXiv:1901.02860*, 2019.

- [18] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin. Attention is all you need. *Advances in neural information processing systems*, 30, 2017.
- [19] R. Pope, S. Douglas, A. Chowdhery, J. Devlin, J. Bradbury, J. Heek, K. Xiao, S. Agrawal, and J. Dean. Efficiently scaling transformer inference. *Proceedings of Machine Learning and Systems*, 5:606–624, 2023.
- [20] X. Cheng, Y. Ji, J. Chen, R. Yang, G. Yang, and X. Wang. Expressive whole-body control for humanoid robots. *arXiv preprint arXiv:2402.16796*, 2024.
- [21] T. He, W. Xiao, T. Lin, Z. Luo, Z. Xu, Z. Jiang, J. Kautz, C. Liu, G. Shi, X. Wang, et al. Hover: Versatile neural whole-body controller for humanoid robots. *arXiv preprint arXiv:2410.21229*, 2024.
- [22] Z. Chen, X. He, Y.-J. Wang, Q. Liao, Y. Ze, Z. Li, S. S. Sastry, J. Wu, K. Sreenath, S. Gupta, et al. Learning smooth humanoid locomotion through lipschitz-constrained policies. *arXiv preprint arXiv:2410.11825*, 2024.
- [23] Y. Xue, W. Dong, M. Liu, W. Zhang, and J. Pang. A unified and general humanoid whole-body controller for fine-grained locomotion. *arXiv preprint arXiv:2502.03206*, 2025.
- [24] J. Siekmann, Y. Godse, A. Fern, and J. Hurst. Sim-to-real learning of all common bipedal gaits via periodic reward composition. In *2021 IEEE International Conference on Robotics and Automation (ICRA)*, pages 7309–7315. IEEE, 2021.
- [25] H. Duan, B. Pandit, M. S. Gadde, B. Van Marum, J. Dao, C. Kim, and A. Fern. Learning vision-based bipedal locomotion for challenging terrain. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 56–62. IEEE, 2024.
- [26] X. Cheng, K. Shi, A. Agarwal, and D. Pathak. Extreme parkour with legged robots. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 11443–11450. IEEE, 2024.
- [27] Z. Zhuang, Z. Fu, J. Wang, C. Atkeson, S. Schwertfeger, C. Finn, and H. Zhao. Robot parkour learning. *arXiv preprint arXiv:2309.05665*, 2023.
- [28] S. Luo, S. Li, R. Yu, Z. Wang, J. Wu, and Q. Zhu. Pie: Parkour with implicit-explicit learning framework for legged robots. *IEEE Robotics and Automation Letters*, 2024.
- [29] R. Yang, G. Yang, and X. Wang. Neural volumetric memory for visual locomotion control. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 1430–1440, 2023.
- [30] W. Sun, B. Cao, L. Chen, Y. Su, Y. Liu, Z. Xie, and H. Liu. Learning perceptive humanoid locomotion over challenging terrain. *arXiv preprint arXiv:2503.00692*, 2025.
- [31] T. Miki, J. Lee, J. Hwangbo, L. Wellhausen, V. Koltun, and M. Hutter. Learning robust perceptive locomotion for quadrupedal robots in the wild. *Science robotics*, 7(62):eabk2822, 2022.
- [32] H. Wang, Z. Wang, J. Ren, Q. Ben, T. Huang, W. Zhang, and J. Pang. Beamdojo: Learning agile humanoid locomotion on sparse footholds. *arXiv preprint arXiv:2502.10363*, 2025.
- [33] W. Huang, I. Mordatch, and D. Pathak. One policy to control them all: Shared modular policies for agent-agnostic control. In *International Conference on Machine Learning*, pages 4455–4464. PMLR, 2020.
- [34] C. Sferrazza, D.-M. Huang, F. Liu, J. Lee, and P. Abbeel. Body transformer: Leveraging robot embodiment for policy learning. *arXiv preprint arXiv:2408.06316*, 2024.

- [35] A. Gupta, S. Savarese, S. Ganguli, and L. Fei-Fei. Embodied intelligence via learning and evolution. *Nature communications*, 12(1):5721, 2021.
- [36] R. Doshi, H. Walke, O. Mees, S. Dasari, and S. Levine. Scaling cross-embodied learning: One policy for manipulation, navigation, locomotion and aviation. *arXiv preprint arXiv:2408.11812*, 2024.
- [37] S. Reed, K. Zolna, E. Parisotto, S. G. Colmenarejo, A. Novikov, G. Barth-Maron, M. Gimenez, Y. Sulsky, J. Kay, J. T. Springenberg, et al. A generalist agent. *arXiv preprint arXiv:2205.06175*, 2022.
- [38] G. Feng, H. Zhang, Z. Li, X. B. Peng, B. Basireddy, L. Yue, Z. Song, L. Yang, Y. Liu, K. Sreenath, et al. Genloco: Generalized locomotion controllers for quadrupedal robots. In *Conference on Robot Learning*, pages 1893–1903. PMLR, 2023.
- [39] C. Finn, P. Abbeel, and S. Levine. Model-agnostic meta-learning for fast adaptation of deep networks. In *International conference on machine learning*, pages 1126–1135. PMLR, 2017.
- [40] K. Bao, C. Li, Y. As, A. Krause, and M. Hutter. Toward task generalization via memory augmentation in meta-reinforcement learning. *arXiv preprint arXiv:2502.01521*, 2025.
- [41] X. Song, Y. Yang, K. Choromanski, K. Caluwaerts, W. Gao, C. Finn, and J. Tan. Rapidly adaptable legged robots via evolutionary meta-learning. In *2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 3769–3776. IEEE, 2020.
- [42] L. Smith, I. Kostrikov, and S. Levine. A walk in the park: Learning to walk in 20 minutes with model-free reinforcement learning. *arXiv preprint arXiv:2208.07860*, 2022.
- [43] J. Singla, A. Agarwal, and D. Pathak. Sapg: split and aggregate policy gradients. *arXiv preprint arXiv:2407.20230*, 2024.

附录

A 实现细节

本节概述了生成多样化机器人形态、随机化环境动力学、设计奖励以及训练 LocoFormer 策略的流程。

A.1 程序化机器人生成

我们生成四类形态：四足机器人、双足机器人及其相应的轮式版本。随机样本如图 6 所示。虽然我们的程序化生成覆盖了广泛的形态空间，但并非穷尽。我们的目标是训练一个能够泛化到分布外机器人的策略。在实践中，未见过的机器人往往偏离我们的设计假设。例如，Berkeley-Humanoid 在髋关节横滚和偏航关节中均表现出下反角——而我们的双足机器人最多只包含一个。此外，像 G1 这样的机器人具有沿 x 轴偏移的关节轴，这一特征未在我们的参数化中体现。至于动力学随机化，我们对标准参数 [12] 进行了随机化，但范围要大得多，以便模型学会适应。

A.2 奖励设计

我们设计了一个统一的奖励结构，结合了形态无关和形态特定的项。为清晰起见，某些表达式中省略了时间下标 t 。

共享奖励组件

$$\begin{aligned} & \cdot \text{线速度指令跟踪 } \exp(\|v_{xy} - v_{xy}^{cmd}\|^2/s_1) \cdot \text{角速度指令跟踪} \\ & \exp(\|w_z - w_z^{cmd}\|^2/s_2) \cdot \text{基座线速度惩罚 } \|v_z\|^2 \cdot \text{基座角 } \|\theta\|^2/s_2) \\ & \text{速度惩罚 } \|w_{xy}\|^2 \cdot \text{基座高度惩罚 } \|x_z - x_z^{nominal}\|^2 \cdot \\ & \text{关节加速度惩罚 } \|\ddot{q}\|^2 \cdot \text{力矩惩罚 } -\|\tau\|^2 \cdot \text{存活奖励:} \\ & 1 \end{aligned}$$

$\| \|^2$


B 实验细节

图 7 展示了用于与基线方法比较的 10 个模拟机器人。其中，我们观察到 TRON1 机器人存在显著的跨试验适应迹象，通过 5 秒的预评估适应实现了 10% 的性能提升。我们发现该机器人在早期试验中最初失败，但逐渐学会稳定并有效控制自身。这一适应过程的一个示例见图 8。


我们在 generalist-locomotion.github.io 上提供了真实世界评估的视频。

C 计算成本


LocoFormer 是一种高性能的通用运动模型，采用大容量变换器（Transformer）模型在 10 万台机器人上进行训练。与专用策略相比，LocoFormer 的计算量增加了 500 倍，但机器人数量增加了 10 万倍——这显著降低了每台机器人的摊销计算成本（1 天对比 0.005 天）。




(a)



(b)



(c)



(d)

图 6：程序化生成机器人样本的可视化。(a) 四足机器人。(b) 带轮四足机器人。(c) 双足机器人。(d) 带轮双足机器人。




图 7：在仿真中与基线方法进行对比的机器人。第一行：宇树 G1、H1、傅利叶 GR1、逐际动力 TRON1、伯克利人形机器人。第二行：宇树 A1、波士顿动力 Spot、苏黎世联邦理工学院 AnyMal C、逐际动力 TRON1-WF、宇树 Go2-W。




图 8：仿真中 TRON1 的跨试验适应。机器人在早期试验中失败，但通过试验 4 逐步学会稳定和有效移动。

进一步优化计算：我们大规模训练了 LocoFormer 以获得最佳模型。然而，性能与计算之间存在有利的权衡——即使使用少得多的计算训练的变体也显示出明显的适应和跨具身泛化迹象（图 9）。由于我们使用变换器（Transformer）骨干，大语言模型（LLM）文献中的技术可以直接用于进一步降低计算需求，例如混合精度、零冗余优化器（ZeRO）内存优化。




图 9：我们使用不同数量的 GPU 和 TXL 层训练 4K 次迭代（6 层 TXL 为 28 小时），并在 10 个机器人上进行评估。左图显示训练集中机器人的奖励，右图报告所选检查点在 10 个评估机器人（包括表 1 中描述的分布外情况）上的平均位移。虽然更多 GPU 能产生最佳模型，但性能与计算之间存在有利的权衡。