

用于深度网络快速适应的模型无关元学习

Chelsea Finn¹ Pieter Abbeel^{1,2} Sergey Levine¹

摘要

本文提出了一种模型无关的元学习算法，其兼容任何使用梯度下降训练的模型，并适用于包括分类、回归和强化学习在内的多种学习问题。元学习的目标是在多种学习任务上训练模型，使其仅需少量训练样本即可解决新任务。本文方法显式地训练模型参数，使得在新任务上使用少量训练数据进行少量梯度步骤即可在该任务上取得良好的泛化性能。实际上，本文方法训练模型使其易于微调。实验表明，该方法在两个少样本图像分类基准上达到了最先进的性能，在少样本回归上取得了良好结果，并加速了使用神经网络策略的策略梯度强化学习的微调。

完成任务所需的计算形式。

本文提出了一种通用的、与模型无关的元学习算法，可直接应用于任何采用梯度下降过程训练的模型。我们重点关注深度神经网络模型，但同时也展示了该方法如何以最小的改动轻松适应不同的架构和问题设置，包括分类、回归以及策略梯度强化学习。在元学习中，训练模型的目标是利用少量新数据快速学习新任务，而模型由元学习器训练，以便能够在大量不同任务上进行学习。我们方法的核心思想是训练模型的初始参数，使得模型在通过少量新任务数据计算的一个或多个梯度步骤更新参数后，在新任务上达到最佳性能。与先前学习更新函数或学习规则的元学习方法不同（Schmidhuber, 1987; Bengio et al., 1992; Andrychowicz et al., 2016; Ravi & Larochelle, 2017），我们的算法不增加学习参数的数量，也不对模型架构施加约束（例如要求循环模型（Santoro et al., 2016）或孪生网络（Koch, 2015）），并且可以轻松地与全连接、卷积或循环神经网络结合使用。它还可以与多种损失函数配合使用，包括可微的监督损失和不可微的强化学习目标。

1. 引言

快速学习是人类智能的标志，无论是从少量示例中识别物体，还是在几分钟经验后快速学习新技能。人工代理也应具备同样的能力，能够从少量示例中快速学习和适应，并在更多数据可用时持续适应。这种快速而灵活的学习具有挑战性，因为代理必须将先验经验与少量新信息相结合，同时避免对新数据过拟合。此外，先验经验和新数据的形式取决于任务。因此，为了获得最广泛的适用性，学习学习（或元学习）的机制应具有任务通用性，并且 1 加州大学伯克利分校 2OpenAI。通讯作者：Chelsea Finn <cbfinn@eecs.berkeley.edu>。

从特征学习的角度来看，训练模型参数的过程，使得少量梯度步骤甚至单个梯度步骤就能在新任务上取得良好结果，可以视为构建一种广泛适用于许多任务的内部表示。如果内部表示适用于许多任务，只需对参数进行轻微微调（例如，主要修改前馈模型中顶层权重）就能取得良好结果。实际上，我们的过程优化的是易于快速微调的模型，使适应发生在适合快速学习的正确空间中。从动力系统的角度来看，我们的学习过程可以视为最大化新任务损失函数对参数的敏感性：当敏感性高时，参数的微小局部变化就能导致

任务损失的大幅降低。

本文的主要贡献是一种简单且模型无关、任务无关的元学习算法，该算法训练模型参数，使得少量梯度更新即可在新任务上实现快速学习。我们在不同模型类型上演示了该算法，包括全连接网络和卷积网络，并在多个不同领域进行了验证，包括小样本回归、图像分类和强化学习。评估结果表明，我们的元学习算法在参数更少的情况下，与专为监督分类设计的最先进的小样本学习方法相比具有优势，同时还能直接应用于回归，并在任务变化的情况下加速强化学习，显著优于直接预训练作为初始化的方法。

2. 模型无关元学习

本文旨在训练能够实现快速适应的模型，该问题通常被形式化为小样本学习。本节将定义问题设置并给出算法的一般形式。

2.1. 元学习问题设置

小样本元学习的目标是训练一个模型，使其仅使用少量数据点和训练迭代即可快速适应新任务。为此，模型或学习器在元学习阶段在一组任务上进行训练，使得训练后的模型能够仅使用少量示例或试验快速适应新任务。实际上，元学习问题将整个任务视为训练示例。本节以一般方式形式化该元学习问题设置，并简要介绍不同学习领域的示例。我们将在第3节详细讨论两个不同的学习领域。

我们考虑一个模型，记为 f ，它将观测值 $\mathbf{x}$ 映射到输出 $\mathbf{a}$ 。在元学习过程中，模型被训练为能够适应大量或无限数量的任务。由于我们希望将该框架应用于从分类到强化学习的各种学习问题，下面引入学习任务的一般概念。形式上，每个任务

$\mathcal{T} = \{\mathcal{L}(\mathbf{x}_1, \mathbf{a}_1, \dots, \mathbf{x}_H, \mathbf{a}_H), q(\mathbf{x}_1), q(\mathbf{x}_{t+1}|\mathbf{x}_t, \mathbf{a}_t), H\}$ 由一个损失函数 $\mathcal{L}$ 、初始观测上的分布 $q(\mathbf{x}_1)$ 、转移分布 $q(\mathbf{x}_{t+1}|\mathbf{x}_t, \mathbf{a}_t)$ ，以及回合长度 H 组成。在独立同分布监督学习问题中，长度 $H=1$ 。模型可以通过在每个时间 t 选择输出 $\mathbf{a}_t$ 来生成长度为 H 的样本。该损失函数 $\text{loss } \mathcal{L}(\mathbf{x}_1, \mathbf{a}_1, \dots, \mathbf{x}_H, \mathbf{a}_H) \rightarrow \mathbb{R}$ 提供任务特定的反馈，其形式可能是误分类损失或马尔可夫决策过程中的代价函数。




图1. 我们的模型无关元学习算法（MAML）示意图，该算法优化一个表示 θ ，使其能够快速适应新任务。

在我们的元学习场景中，我们考虑一个任务分布 $p(\mathcal{T})$ ，希望模型能够适应该分布。在 K 样本学习设置中，模型被训练为仅使用从 q_i 抽取的 K 个样本以及由 $\mathcal{T}_i$ 生成的反馈 $\mathcal{L}_{\mathcal{T}_i}$ ，来学习从 $p(\mathcal{T})$ 中抽取的新任务 $\mathcal{T}_i$ 。在元训练期间，从 $p(\mathcal{T})$ 中采样任务 $\mathcal{T}_i$ ，使用 K 个样本和来自 $\mathcal{T}_i$ 的相应损失 $\mathcal{L}_{\mathcal{T}_i}$ 的反馈训练模型，然后在来自 $\mathcal{T}_i$ 的新样本上进行测试。随后，通过考虑来自 q_i 的新数据的测试误差相对于参数的变化来改进模型 f 。实际上，采样任务 $\mathcal{T}_i$ 上的测试误差充当元学习过程的训练误差。在元训练结束时，从 $p(\mathcal{T})$ 中采样新任务，并通过模型在从 K 个样本学习后的性能来衡量元性能。通常，用于元测试的任务在元训练期间被保留。

2.2. 模型无关元学习算法

与先前工作不同——先前工作试图训练能够摄取整个数据集的循环神经网络（Recurrent Neural Network）（Santoro 等，2016；Duan 等，2016b），或训练可在测试时与非参数方法结合的特征嵌入（Vinyals 等，2016；Koch，2015）——本文提出一种方法，通过元学习（Meta-Learning）学习任意标准模型的参数，使该模型为快速适应做好准备。该方法背后的直觉是，某些内部表征比其他表征更具可迁移性。例如，神经网络可能学习到广泛适用于 $p(\mathcal{T})$ 中所有任务的内部特征，而非仅适用于单个任务。如何促使此类通用表征的出现？本文对该问题采取显式方法：由于模型将在新任务上使用基于梯度的学习规则进行微调，因此本文旨在以这样的方式学习模型，使该基于梯度的学习规则能够在从 $p(\mathcal{T})$ 中抽取的新任务上快速取得进展，同时避免过拟合。实际上，本文旨在找到对任务变化敏感的模型参数，使得当参数沿任务损失函数的梯度方向调整时，参数的微小变化能够对从 $p(\mathcal{T})$ 中抽取的任意任务的损失函数产生大幅改进（见图1）。

Algorithm 1 Model-Agnostic Meta-Learning**Require:** $p(\mathcal{T})$: distribution over tasks**Require:** α, β : step size hyperparameters

```

1: randomly initialize  $\theta$ 
2: while not done do
3:   Sample batch of tasks  $\mathcal{T}_i \sim p(\mathcal{T})$ 
4:   for all  $\mathcal{T}_i$  do
5:     Evaluate  $\nabla_{\theta} \mathcal{L}_{\mathcal{T}_i}(f_{\theta})$  with respect to  $K$  examples
6:     Compute adapted parameters with gradient descent:  $\theta'_i = \theta - \alpha \nabla_{\theta} \mathcal{L}_{\mathcal{T}_i}(f_{\theta})$ 
7:   end for
8:   Update  $\theta \leftarrow \theta - \beta \nabla_{\theta} \sum_{\mathcal{T}_i \sim p(\mathcal{T})} \mathcal{L}_{\mathcal{T}_i}(f_{\theta'_i})$ 
9: end while

```

本文不对模型形式作任何假设，仅假设模型由某个参数向量 θ 参数化，且损失函数关于 θ 足够平滑，从而可以使用基于梯度的学习技术。

形式上，本文考虑由参数化函数 f_{θ} 表示的模型，其参数为 θ 。当适应新任务 $\mathcal{T}_i$ 时，模型参数 θ 变为 θ'_i 。在本方法中，更新后的参数向量 θ'_i 通过在任务 $\mathcal{T}_i$ 上执行一次或多次梯度下降更新计算得到。例如，当使用一次梯度更新时， $\theta'_i = \theta - \alpha \nabla_{\theta} \mathcal{L}_{\mathcal{T}_i}(f_{\theta})$ 。步长 α 可以作为超参数固定，也可以通过元学习获得。为简化符号，本节其余部分仅考虑一次梯度更新，但使用多次梯度更新是直接的扩展。

模型参数的训练通过优化 $f_{\theta'_i}$ 相对于 θ 在从 $p(\mathcal{T})$ 中采样的任务上的性能来完成。更具体地，元目标如下：

$$\min_{\theta} \sum_{\mathcal{T}_i \sim p(\mathcal{T})} \mathcal{L}_{\mathcal{T}_i}(f_{\theta'_i}) = \sum_{\mathcal{T}_i \sim p(\mathcal{T})} \mathcal{L}_{\mathcal{T}_i}(f_{\theta - \alpha \nabla_{\theta} \mathcal{L}_{\mathcal{T}_i}(f_{\theta})})$$

注意，元优化是在模型参数 θ 上进行的，而目标函数则是使用更新后的模型参数 θ' 来计算的。实际上，本文提出的方法旨在优化模型参数，使得在新任务上进行一个或少量梯度步骤后，能够在该任务上产生最大有效的行为。

跨任务的元优化通过随机梯度下降（SGD）进行，模型参数 θ 按如下方式更新：

$$\theta \leftarrow \theta - \beta \nabla_{\theta} \sum_{\mathcal{T}_i \sim p(\mathcal{T})} \mathcal{L}_{\mathcal{T}_i}(f_{\theta'_i}) \quad (1)$$

其中 β 是元步长。完整算法在一般情况下的概述见算法 1。

MAML 元梯度更新涉及梯度的梯度。在计算上，这需要对 f 进行额外的反向传播来计算 Hessian 向量积，

标准深度学习库如 TensorFlow (Abadi 等人, 2016) 支持这一操作。在实验中，本文还比较了省略该反向传播并使用一阶近似的方法，相关内容将在第 5.2 节讨论。

3. MAML 的变体

本节讨论元学习算法在监督学习和强化学习中的具体实例。这些领域在损失函数的形式、任务生成数据的方式以及数据呈现给模型的方式上有所不同，但相同的基本适应机制可以应用于两种情况。

3.1. 监督回归与分类

小样本学习在监督任务领域已得到深入研究，其目标是在仅给定少量输入/输出对的情况下学习一个新函数，并利用来自相似任务的先验数据进行元学习。例如，目标可能是在仅见过一个或少数几个赛格威 (Segway) 示例后对其图像进行分类，而模型此前已见过许多其他类型的物体。类似地，在小样本回归中，目标是在许多具有相似统计特性的函数上训练后，仅根据从该函数采样的少量数据点预测连续值函数的输出。

为了在第 2.1 节元学习定义的背景下形式化监督回归和分类问题，我们可以定义时间范围 $H = 1$ ，并省略 $\mathbf{x}_t$ 上的时间步下标，因为模型接受单个输入并产生单个输出，而不是输入和输出的序列。任务 $\mathcal{T}_i$ 从 q_i 生成 K 个独立同分布的观测值 $\mathbf{x}$ ，任务损失由模型对 $\mathbf{x}$ 的输出与该观测值和任务对应的目标值 $\mathbf{y}$ 之间的误差表示。

用于监督分类和回归的两种常见损失函数是交叉熵 (cross-entropy) 和均方误差 (MSE)，我们将在下文描述；不过，也可以使用其他监督损失函数。对于使用均方误差的回归任务，损失形式为：

$$\mathcal{L}_{\mathcal{T}_i}(f_{\phi}) = \sum_{\mathbf{x}^{(j)}, \mathbf{y}^{(j)} \sim \mathcal{T}_i} \|f_{\phi}(\mathbf{x}^{(j)}) - \mathbf{y}^{(j)}\|_2^2, \quad (2)$$

其中 $\mathbf{x}^{(j)}, \mathbf{y}^{(j)}$ 是从任务 $\mathcal{T}_i$ 采样的输入/输出对。在 K 样本回归任务中，为每个任务的学习提供 K 个输入/输出对。

类似地，对于使用交叉熵损失的离散分类任务，损失形式为：

$$\begin{aligned} \mathcal{L}_{\mathcal{T}_i}(f_{\phi}) = \sum_{\mathbf{x}^{(j)}, \mathbf{y}^{(j)} \sim \mathcal{T}_i} & \mathbf{y}^{(j)} \log f_{\phi}(\mathbf{x}^{(j)}) \\ & + (1 - \mathbf{y}^{(j)}) \log(1 - f_{\phi}(\mathbf{x}^{(j)})) \end{aligned} \quad (3)$$

Algorithm 2 MAML for Few-Shot Supervised Learning

Require: $p(\mathcal{T})$: distribution over tasks
Require: α, β : step size hyperparameters

- 1: randomly initialize θ
- 2: **while** not done **do**
- 3: Sample batch of tasks $\mathcal{T}_i \sim p(\mathcal{T})$
- 4: **for all** $\mathcal{T}_i$ **do**
- 5: Sample K datapoints $\mathcal{D} = \{\mathbf{x}^{(j)}, \mathbf{y}^{(j)}\}$ from $\mathcal{T}_i$
- 6: Evaluate $\nabla_{\theta} \mathcal{L}_{\mathcal{T}_i}(f_{\theta})$ using $\mathcal{D}$ and $\mathcal{L}_{\mathcal{T}_i}$ in Equation (2) or (3)
- 7: Compute adapted parameters with gradient descent: $\theta'_i = \theta - \alpha \nabla_{\theta} \mathcal{L}_{\mathcal{T}_i}(f_{\theta})$
- 8: Sample datapoints $\mathcal{D}'_i = \{\mathbf{x}^{(j)}, \mathbf{y}^{(j)}\}$ from $\mathcal{T}_i$ for the meta-update
- 9: **end for**
- 10: Update $\theta \leftarrow \theta - \beta \nabla_{\theta} \sum_{\mathcal{T}_i \sim p(\mathcal{T})} \mathcal{L}_{\mathcal{T}_i}(f_{\theta'_i})$ using each $\mathcal{D}'_i$ and $\mathcal{L}_{\mathcal{T}_i}$ in Equation 2 or 3
- 11: **end while**

根据传统术语， K 样本分类任务使用每个类别的 K 个输入/输出对，对于 N 路分类，总共有 NK 个数据点。给定任务分布 $p(\mathcal{T}_i)$ ，这些损失函数可以直接代入第 2.2 节中的方程以执行元学习，如算法 2 所述。

3.2 强化学习

在强化学习（Reinforcement Learning, RL）中，小样本元学习的目标是使智能体仅利用测试环境中的少量经验，就能快速获得适用于新测试任务的策略。新任务可能涉及在新环境中达成新目标，或在先前训练过的目标上取得成功。例如，智能体可以学习快速掌握迷宫导航方法，从而在面对新迷宫时，仅凭少量样本就能确定如何可靠地到达出口。本节将讨论如何将模型无关元学习（Model-Agnostic Meta-Learning, MAML）应用于强化学习的元学习。

每个强化学习任务 $\mathcal{T}_i$ 包含初始状态分布 $q_i(\mathbf{x}_1)$ 和转移分布 $q_i(\mathbf{x}_{t+1}|\mathbf{x}_t, \mathbf{a}_t)$ ，损失 $\mathcal{L}_{\mathcal{T}_i}$ 对应于（负）奖励函数 R 。因此，整个任务是一个具有时间范围 H 的马尔可夫决策过程（Markov Decision Process, MDP），其中学习者被允许查询有限数量的样本轨迹以进行小样本学习。在 $p(\mathcal{T})$ 中，马尔可夫决策过程的任何方面都可能随任务变化。被学习的模型 f_{θ} 是一个策略，它在每个时间步 $t \in \{1, \dots, H\}$ 将状态 $\mathbf{x}_t$ 映射到动作分布 $\mathbf{a}_t$ 。任务 $\mathcal{T}_i$ 和模型 f_{ϕ} 的损失形式为

$$\mathcal{L}_{\mathcal{T}_i}(f_{\phi}) = -\mathbb{E}_{\mathbf{x}_t, \mathbf{a}_t \sim f_{\phi}, q_{\mathcal{T}_i}} \left[\sum_{t=1}^H R_i(\mathbf{x}_t, \mathbf{a}_t) \right]. \quad (4)$$

在 K 样本强化学习中，来自 f_{θ} 和任务 $\mathcal{T}_i$, $(\mathbf{x}_1, \mathbf{a}_1, \dots, \mathbf{x}_H)$ 的 K 次展开以及相应的奖励 $R(\mathbf{x}_t, \mathbf{a}_t)$ 可用于新任务 $\mathcal{T}_i$ 的适应。

Algorithm 3 MAML for Reinforcement Learning

Require: $p(\mathcal{T})$: distribution over tasks
Require: α, β : step size hyperparameters

- 1: randomly initialize θ
- 2: **while** not done **do**
- 3: Sample batch of tasks $\mathcal{T}_i \sim p(\mathcal{T})$
- 4: **for all** $\mathcal{T}_i$ **do**
- 5: Sample K trajectories $\mathcal{D} = \{(\mathbf{x}_1, \mathbf{a}_1, \dots, \mathbf{x}_H)\}$ using f_{θ} in $\mathcal{T}_i$
- 6: Evaluate $\nabla_{\theta} \mathcal{L}_{\mathcal{T}_i}(f_{\theta})$ using $\mathcal{D}$ and $\mathcal{L}_{\mathcal{T}_i}$ in Equation 4
- 7: Compute adapted parameters with gradient descent: $\theta'_i = \theta - \alpha \nabla_{\theta} \mathcal{L}_{\mathcal{T}_i}(f_{\theta})$
- 8: Sample trajectories $\mathcal{D}'_i = \{(\mathbf{x}_1, \mathbf{a}_1, \dots, \mathbf{x}_H)\}$ using $f_{\theta'_i}$ in $\mathcal{T}_i$
- 9: **end for**
- 10: Update $\theta \leftarrow \theta - \beta \nabla_{\theta} \sum_{\mathcal{T}_i \sim p(\mathcal{T})} \mathcal{L}_{\mathcal{T}_i}(f_{\theta'_i})$ using each $\mathcal{D}'_i$ and $\mathcal{L}_{\mathcal{T}_i}$ in Equation 4
- 11: **end while**

由于期望奖励通常因动力学未知而不可微，我们使用策略梯度方法来估计模型梯度更新和元优化中的梯度。由于策略梯度是一种同策略算法，在 f_{θ} 的适应过程中，每个额外的梯度步骤都需要从当前策略 $f_{\theta'_i}$ 中获取新样本。我们在算法 3 中详细描述了该算法。该算法与算法 2 结构相同，主要区别在于步骤 5 和 8 需要从对应于任务 $\mathcal{T}_i$ 的环境中采样轨迹。该方法的实用实现还可以采用最近为策略梯度算法提出的各种改进，包括状态或动作相关的基线和信任区域（Schulman et al., 2015）。

4. 相关工作

本文提出的方法针对元学习（Meta-Learning）的一般问题（Thrun & Pratt, 1998; Schmidhuber, 1987; Naik & Mammone, 1992），其中包括小样本学习。元学习的一种流行方法是训练一个元学习器，学习如何更新学习者模型的参数（Bengio et al., 1992; Schmidhuber, 1992; Bengio et al., 1990）。该方法已被应用于学习优化深度网络（Hochreiter et al., 2001; Andrychowicz et al., 2016; Li & Malik, 2017），以及学习动态变化的循环网络（Ha et al., 2017）。最近的一种方法同时学习权重初始化和优化器，用于小样本图像识别（Ravi & Larochelle, 2017）。与这些方法不同，MAML 学习器的权重使用梯度进行更新，而非学习到的更新；本文方法不引入额外的元学习参数，也不要求特定的学习器架构。

小样本学习方法也已针对

特定任务，如生成建模（Edwards & Storkey, 2017; Rezende et al., 2016）和图像识别（Vinyals et al., 2016）。少样本分类的一种成功方法是学习在习得的度量空间中比较新样本，例如使用孪生网络（Koch, 2015）或带有注意力机制的循环网络（Vinyals et al., 2016; Shyam et al., 2017; Snell et al., 2017）。这些方法产生了一些最成功的结果，但难以直接扩展到其他问题，如强化学习。相比之下，本文的方法对模型形式和特定学习任务均不敏感。

另一种元学习方法是在许多任务上训练记忆增强模型，其中循环学习器在展开过程中被训练以适应新任务。此类网络已应用于少样本图像识别（Santoro 等, 2016; Munkhdalai 和 Yu, 2017）以及学习“快速”强化学习智能体（Duan 等, 2016b; Wang 等, 2016）。我们的实验表明，我们的方法在少样本分类上优于循环方法。此外，与这些方法不同，我们的方法仅提供一个良好的权重初始化，并对学习器和元更新使用相同的梯度下降更新。因此，可以轻松地对学习器进行微调以进行额外的梯度步骤。

我们的方法也与深度网络初始化方法相关。在计算机视觉中，在大规模图像分类上预训练的模型已被证明能为一系列问题学习到有效特征（Donahue et al., 2014）。相比之下，我们的方法明确优化模型以实现快速适应，使其仅用少量示例就能适应新任务。我们的方法也可以被视为明确最大化新任务损失对模型参数的敏感性。许多先前的工作已经探索了深度网络中的敏感性，通常是在初始化的背景下（Saxe et al., 2014; Kirkpatrick et al., 2016）。这些工作大多考虑了良好的随机初始化，尽管一些论文已经解决了数据依赖的初始化器（Krähenbühl et al., 2016; Salimans & Kingma, 2016），包括学习到的初始化（Husken & Goerick, 2000; Maclaurin et al., 2015）。相比之下，我们的方法明确训练参数对给定任务分布的敏感性，从而允许在仅一个或几个梯度步骤内对诸如 K -样本学习和快速强化学习等问题进行极其高效的适应。

5. 实验评估

本文实验评估旨在回答以下问题：（1）MAML 能否实现新任务的快速学习？（2）MAML 能否用于多个不同领域的元学习，包括监督回归、分类和强化学习？（3）能否

使用 MAML 学习的模型能否通过额外的梯度更新和/或样本持续改进？

本文考虑的所有元学习问题在测试时都需要对新任务进行一定程度的适应。在可能的情况下，我们将结果与一个预言机进行比较，该预言机接收任务的身份（这是一个与问题相关的表示）作为额外输入，作为模型性能的上界。所有实验均使用 TensorFlow（Abadi 等人, 2016 年）进行，该框架允许在元学习过程中通过梯度更新进行自动微分。代码可在网上获取¹。

5.1. 回归

我们从一个简单的回归问题开始，以说明模型无关元学习（MAML）的基本原理。每个任务涉及从正弦波的输入回归到输出，其中正弦波的振幅和相位在不同任务间变化。因此， $p(\mathcal{T})$ 是连续的，振幅在 $[0.1, 5.0]$ 内变化，相位在 $[0, \pi]$ 内变化，输入和输出的维度均为 1。在训练和测试期间，数据点 $\mathbf{x}$ 从 $[-5.0, 5.0]$ 中均匀采样。损失为预测值 $f(\mathbf{x})$ 与真实值之间的均方误差。回归器是一个具有 2 个隐藏层、每层 40 个单元、使用修正线性单元（ReLU）非线性的神经网络模型。在使用 MAML 训练时，我们使用一次梯度更新，包含 $K = 10$ 个样本，固定步长为 $\alpha = 0.01$ ，并使用 Adam 作为元优化器（Kingma & Ba, 2015）。基线方法同样使用 Adam 训练。为评估性能，我们在不同数量的 K 个样本上微调单个元学习模型，并与两个基线进行比较：(a) 在所有任务上预训练，即训练一个网络回归随机正弦函数，然后在测试时使用自动调整的步长对提供的 K 个点进行梯度下降微调；(b) 一个接收真实振幅和相位作为输入的预言机。在附录 C 中，我们展示了与其他多任务和自适应方法的比较。

我们通过在 $K = \{5, 10, 20\}$ 个数据点上微调 MAML 学到的模型和预训练模型来评估性能。在微调期间，每个梯度步骤使用相同的 K 个数据点计算。定性结果如图 2 所示，并在附录 B 中进一步展开，表明学到的模型能够仅用 5 个数据点（紫色三角形所示）快速适应，而在所有任务上使用标准监督学习预训练的模型在如此少的数据点下无法充分适应，且会出现灾难性过拟合。关键的是，当 K 个数据点全部位于输入范围的一半时，1 回归和监督实验的代码位于 github.com/cbfinn/maml，强化学习实验的代码位于 github.com/cbfinn/maml_rl




图 2. 简单回归任务的小样本适应。左图：注意 MAML 能够估计没有数据点的曲线部分，表明模型已经学习了正弦波的周期结构。右图：在相同任务分布上预训练但未使用 MAML 的模型进行微调，并调整了步长。由于预训练任务上输出常常相互矛盾，该模型无法恢复合适的表示，也无法从少量测试样本中进行外推。




图 3. 正弦回归的定量结果，展示了元测试时的学习曲线。注意 MAML 在元测试期间通过额外的梯度步骤持续改进，而不会对极小的数据集过拟合，达到了显著低于基线微调方法的损失。

使用 MAML 训练的模型仍然能够推断另一半范围内的振幅和相位，表明 MAML 训练的模型 f 已经学会了建模正弦波的周期性质。此外，我们在定性和定量结果（图 3 和附录 B）中都观察到，使用 MAML 学习的模型在额外的梯度步骤下持续改进，尽管其训练目标是在一个梯度步骤后达到最佳性能。这种改进表明 MAML 优化参数使其位于适合快速适应且对损失函数敏感的区域 $p(\mathcal{T})$ ，如第 2.2 节所讨论的，而不是过拟合到仅在一步后改善的参数 θ 。

5.2. 分类

为了评估 MAML 与先前元学习和小样本学习算法的比较，我们将方法应用于 Omniglot (Lake 等人, 2011 年) 和 MiniImagenet 数据集上的小样本图像识别。Omniglot 数据集包含来自 50 种不同字母表的 1623 个字符，每个字符有 20 个实例。每个实例由不同的人绘制。MiniImagenet 数据集由 Ravi 和 Larochelle (2017 年) 提出，包含 64 个训练类别、12 个验证类别和 24 个测试类别。Omniglot 和 MiniImagenet 图像识别任务是最近最常用的小样本学习基准 (Vinyals 等人, 2016 年; Santoro 等人, 2016 年; Ravi 和 Larochelle, 2017 年)。

我们遵循 Vinyals 等人 (2016) 提出的实验方案，该方案涉及 N 类分类的快速学习，支持 1 次或 5 次样本。 N 类分类问题设置如下：选择 N 个未见过的类别，为模型提供每个 N 类别的 K 个不同实例，并评估模型在 N 个类别内对新实例的分类能力。对于 Omniglot 数据集，我们随机选择 1200 个字符用于训练，不考虑字母表，其余用于测试。按照 Santoro 等人 (2016) 的建议，Omniglot 数据集通过 90 度的倍数旋转进行增强。

我们的模型采用与 Vinyals 等人 (2016) 使用的嵌入函数相同的架构，该架构包含 4 个模块，每个模块具有 3×3 卷积和 64 个滤波器，随后是批归一化 (Ioffe & Szegedy, 2015)、ReLU 非线性激活和 2×2 最大池化。Omniglot 图像被下采样至 28×28 ，因此最后一个隐藏层的维度为 64。与 Vinyals 等人 (2016) 使用的基线分类器一样，最后一层输入到 softmax 函数。对于 Omniglot，我们使用步长卷积代替最大池化。对于 MiniImagenet，我们每层使用 32 个滤波器以减少过拟合，如 (Ravi & Larochelle, 2017) 所做。为了与记忆增强神经网络 (Santoro 等人, 2016) 进行公平比较，并测试 MAML 的灵活性，我们还提供了非卷积网络的结果。为此，我们使用一个具有 4 个隐藏层的网络，大小分别为 256、128、64、64，每层包含批归一化和 ReLU 非线性激活，随后是线性层和 softmax。对于所有模型，损失函数是预测类别与真实类别之间的交叉熵误差。额外的超参数细节见附录 A.1。

我们在表 1 中展示了结果。MAML 学习的卷积模型在该任务上与最先进的结果相当，略微优于先前的方法。其中一些现有方法，如匹配网络、孪生网络和记忆模型，是为少样本分类而设计的，不易应用于强化学习等领域。此外，使用 MAML 学习的模型使用

表 1. 在留出 Omniglot 字符（上）和 MiniImagenet 测试集（下）上的少样本分类。MAML 取得的结果与最先进的卷积和循环模型相当或更优。孪生网络、匹配网络和记忆模块方法均专用于分类，不能直接应用于回归或强化学习场景。± 显示了任务上的 95% 置信区间。注意，Omniglot 结果可能无法严格比较，因为先前工作中使用的训练/测试划分不可用。MiniImagenet 上基线方法和匹配网络的评估来自 Ravi & Larochelle (2017)。

Omniglot (Lake et al., 2011)	5-way Accuracy		20-way Accuracy	
	1-shot	5-shot	1-shot	5-shot
MANN, no conv (Santoro et al., 2016)	82.8%	94.9%	—	—
MAML, no conv (ours)	89.7 ± 1.1%	97.5 ± 0.6%	—	—
Siamese nets (Koch, 2015)	97.3%	98.4%	88.2%	97.0%
matching nets (Vinyals et al., 2016)	98.1%	98.9%	93.8%	98.5%
neural statistician (Edwards & Storkey, 2017)	98.1%	99.5%	93.2%	98.1%
memory mod. (Kaiser et al., 2017)	98.4%	99.6%	95.0%	98.6%
MAML (ours)	98.7 ± 0.4%	99.9 ± 0.1%	95.8 ± 0.3%	98.9 ± 0.2%

MiniImagenet (Ravi & Larochelle, 2017)	5-way Accuracy	
	1-shot	5-shot
fine-tuning baseline	28.86 ± 0.54%	49.79 ± 0.79%
nearest neighbor baseline	41.08 ± 0.70%	51.04 ± 0.65%
matching nets (Vinyals et al., 2016)	43.56 ± 0.84%	55.31 ± 0.73%
meta-learner LSTM (Ravi & Larochelle, 2017)	43.44 ± 0.77%	60.60 ± 0.71%
MAML, first order approx. (ours)	48.07 ± 1.75%	63.15 ± 0.91%
MAML (ours)	48.70 ± 1.84%	63.11 ± 0.92%

与匹配网络和元学习器 LSTM 相比，总体参数更少，因为该算法除了分类器本身的权重外不引入任何额外参数。与这些先前方法相比，记忆增强神经网络 (Santoro et al., 2016) 以及更广泛的循环元学习模型代表了一类更广泛适用的方法，与 MAML 一样，可用于其他任务，如强化学习 (Duan et al., 2016b; Wang et al., 2016)。然而，如比较所示，MAML 在 5-way Omniglot 和 MiniImagenet 分类上显著优于记忆增强网络和元学习器 LSTM，在 1-shot 和 5-shot 情况下均如此。

MAML 中一个显著的计算开销来自在元目标中通过梯度算子反向传播元梯度时使用二阶导数（见方程 (1)）。在 MiniImagenet 上，我们展示了与 MAML 的一阶近似的比较，其中省略了这些二阶导数。注意，所得方法仍在更新后参数值 θ'_i 处计算元梯度，这提供了有效的元学习。然而令人惊讶的是，该方法的性能几乎与使用完整二阶导数时相同，表明 MAML 的大部分改进来自更新后参数值处目标的梯度，而不是通过梯度更新微分得到的二阶更新。过去的工作观察到 ReLU 神经网络局部几乎线性 (Goodfellow et al., 2015)，这表明二阶导数在大多数情况下可能接近零，部分解释了良好的性能。




图 4. 上：二维导航任务的定量结果，下：使用 MAML 学习的模型与从预训练网络微调的模型之间的定性比较。

一阶近似的性能。该近似消除了额外反向传播中计算黑塞向量积的需要，我们发现这使网络计算速度提升了约 33%。

5.3. 强化学习

为了在强化学习问题上评估 MAML，我们基于 rllab 基准套件 (Duan 等人, 2016a) 中的模拟连续控制环境构建了多组任务。我们在下文讨论各个领域。在所有领域中，MAML 训练的模型是一个具有两个隐藏层（大小为 100）和 ReLU 非线性激活的神经网络策略。梯度更新使用普通策略梯度 (REINFORCE) (Williams, 1992)，我们使用信任区域策略优化 (TRPO) 作为元优化器 (Schulman 等人, 2015)。为了避免计算三阶导数，




图 5. 半猎豹和蚂蚁运动任务的强化学习结果，任务显示在最右侧。与监督学习任务不同，每个梯度步骤需要从环境中获取额外样本。结果表明，MAML 能够比传统预训练或随机初始化更快地适应新的目标速度和方向，仅需两到三个梯度步骤即可达到良好性能。我们排除了目标速度的随机基线曲线，因为回报要差得多（猎豹为 < -200 ，蚂蚁为 < -25 ）。

我们使用有限差分来计算 TRPO 的黑塞向量积。对于学习和元学习更新，我们使用 Duan 等人 (2016a) 提出的标准线性特征基线，该基线在每次迭代中针对批次中每个采样任务分别拟合。我们与三个基线模型进行比较：(a) 在所有任务上预训练一个策略然后微调，(b) 从随机初始化权重训练策略，以及 (c) 一个接收任务参数作为输入的预言机策略，对于以下任务，这些参数对应于智能体的目标位置、目标方向或目标速度。基线模型 (a) 和 (b) 使用手动调整步长的梯度下降进行微调。学习到的策略视频可在 sites.google.com/view/maml 查看

二维导航。 在首个元强化学习实验中，我们研究了一组任务：点状智能体需在二维空间中移动到不同目标位置，每个任务的目标位置在单位正方形内随机选取。观测为当前二维位置，动作对应速度指令，并被裁剪至 $[-0.1, 0.1]$ 范围内。奖励为到目标负平方距离，当智能体位于目标 0.01 范围内或达到 $H = 100$ 时间上限时，回合终止。策略使用 MAML 训练，以在 1 次策略梯度更新后使用 20 条轨迹最大化性能。该问题及后续强化学习问题的额外超参数设置见附录 A.2。在评估中，我们比较了使用最多 4 次梯度更新（每次 40 个样本）对新任务的适应能力。图 4 中的结果展示了使用 MAML 初始化、在相同任务集上进行常规预训练、随机初始化以及接收目标位置作为输入的理想策略的适应性能。结果表明，MAML 能够学习到一个模型，在单次梯度更新中适应速度显著更快，并且随着额外更新继续提升。

运动。 为研究 MAML 在更复杂深度强化学习问题上的可扩展性，我们还使用 MuJoCo 模拟器 (Todorov 等人, 2012) 研究了高维运动任务上的适应。任务要求两个模拟机器人——平面猎豹和三维四足机器人（“蚂蚁”）——沿特定方向或以特定速度奔跑。在目标速度实验中，奖励为

智能体当前速度与目标之间的负绝对值，其中目标在 0.0 和 2.0 之间均匀随机选择（猎豹任务），在 0.0 和 3.0 之间均匀随机选择（蚂蚁任务）。在目标方向实验中，奖励是前进或后退方向上的速度大小，每个任务在 $p(\mathcal{T})$ 中随机选择。时间范围为 $H = 200$ ，除蚂蚁前进/后退任务使用每次梯度步骤 40 次回滚外，所有问题每次梯度步骤使用 20 次回滚。图 5 中的结果表明，MAML 学习到的模型即使仅进行一次梯度更新也能快速调整其速度和方向，并且随着更多梯度步骤继续改进。结果还表明，在这些具有挑战性的任务上，MAML 初始化显著优于随机初始化和预训练。事实上，预训练在某些情况下比随机初始化更差，这一现象在之前的强化学习工作中已被观察到 (Parisotto 等人, 2016)。

6. 讨论与未来工作

我们提出了一种基于通过梯度下降学习易于调整的模型参数的元学习方法。我们的方法具有多个优点。它简单，且不引入任何用于元学习的学习参数。它可以与任何适合基于梯度训练的模型表示以及任何可微目标相结合，包括分类、回归和强化学习。最后，由于我们的方法仅产生权重初始化，因此可以使用任意数量的数据和任意数量的梯度步骤进行适应，尽管我们在每类仅有一个或五个示例的分类任务上展示了最先进的结果。我们还表明，我们的方法可以使用策略梯度和非常有限的经验来适应强化学习智能体。

重用过去任务中的知识可能是使高容量可扩展模型（如深度神经网络）能够使用小数据集快速训练的关键因素。我们相信，这项工作朝着一种简单且通用的元学习技术迈出了一步，该技术可应用于任何问题和任何模型。该领域的进一步研究可以使多任务初始化成为深度学习和强化学习中的标准组成部分。

致谢

作者感谢陈曦 (Xi Chen) 和特雷弗·达雷尔 (Trevor Darrell) 的有益讨论, 感谢严端 (Yan Duan) 和亚历克斯·李 (Alex Lee) 的技术建议, 感谢尼基尔·米什拉 (Nikhil Mishra)、唐浩然 (Haoran Tang) 和格雷格·卡恩 (Greg Kahn) 对论文早期草稿的反馈, 以及匿名审稿人的意见。本工作部分由海军研究办公室 (ONR) PECASE 奖和国家自然科学基金会 (NSF) GRFP 奖资助。

参考文献

- Abadi, Martín, Agarwal, Ashish, Barham, Paul, Brevdo, Eugene, Chen, Zhifeng, Citro, Craig, Corrado, Greg S, Davis, Andy, Dean, Jeffrey, Devin, Matthieu, et al. Tensorflow: Large-scale machine learning on heterogeneous distributed systems. *arXiv preprint arXiv:1603.04467*, 2016.
- Andrychowicz, Marcin, Denil, Misha, Gomez, Sergio, Hoffman, Matthew W, Pfau, David, Schaul, Tom, and de Freitas, Nando. Learning to learn by gradient descent by gradient descent. In *Neural Information Processing Systems (NIPS)*, 2016.
- Bengio, Samy, Bengio, Yoshua, Cloutier, Jocelyn, and Gecsei, Jan. On the optimization of a synaptic learning rule. In *Optimality in Artificial and Biological Neural Networks*, pp. 6–8, 1992.
- Bengio, Yoshua, Bengio, Samy, and Cloutier, Jocelyn. *Learning a synaptic learning rule*. Université de Montréal, Département d’informatique et de recherche opérationnelle, 1990.
- Donahue, Jeff, Jia, Yangqing, Vinyals, Oriol, Hoffman, Judy, Zhang, Ning, Tzeng, Eric, and Darrell, Trevor. Decaf: A deep convolutional activation feature for generic visual recognition. In *International Conference on Machine Learning (ICML)*, 2014.
- Duan, Yan, Chen, Xi, Houthoofd, Rein, Schulman, John, and Abbeel, Pieter. Benchmarking deep reinforcement learning for continuous control. In *International Conference on Machine Learning (ICML)*, 2016a.
- Duan, Yan, Schulman, John, Chen, Xi, Bartlett, Peter L, Sutskever, Ilya, and Abbeel, Pieter. RL2: Fast reinforcement learning via slow reinforcement learning. *arXiv preprint arXiv:1611.02779*, 2016b.
- Edwards, Harrison and Storkey, Amos. Towards a neural statistician. *International Conference on Learning Representations (ICLR)*, 2017.
- Goodfellow, Ian J, Shlens, Jonathon, and Szegedy, Christian. Explaining and harnessing adversarial examples. *International Conference on Learning Representations (ICLR)*, 2015.
- Ha, David, Dai, Andrew, and Le, Quoc V. Hypernetworks. *International Conference on Learning Representations (ICLR)*, 2017.
- Hochreiter, Sepp, Younger, A Steven, and Conwell, Peter R. Learning to learn using gradient descent. In *International Conference on Artificial Neural Networks*. Springer, 2001.
- Husken, Michael and Goerick, Christian. Fast learning for problem classes using knowledge based network initialization. In *Neural Networks, 2000. IJCNN 2000, Proceedings of the IEEE-INNS-ENNS International Joint Conference on*, volume 6, pp. 619–624. IEEE, 2000.
- Ioffe, Sergey and Szegedy, Christian. Batch normalization: Accelerating deep network training by reducing internal covariate shift. *International Conference on Machine Learning (ICML)*, 2015.
- Kaiser, Lukasz, Nachum, Ofir, Roy, Aurko, and Bengio, Samy. Learning to remember rare events. *International Conference on Learning Representations (ICLR)*, 2017.
- Kingma, Diederik and Ba, Jimmy. Adam: A method for stochastic optimization. *International Conference on Learning Representations (ICLR)*, 2015.
- Kirkpatrick, James, Pascanu, Razvan, Rabinowitz, Neil, Veness, Joel, Desjardins, Guillaume, Rusu, Andrei A, Milan, Kieran, Quan, John, Ramalho, Tiago, Grabska-Barwinska, Agnieszka, et al. Overcoming catastrophic forgetting in neural networks. *arXiv preprint arXiv:1612.00796*, 2016.
- Koch, Gregory. Siamese neural networks for one-shot image recognition. *ICML Deep Learning Workshop*, 2015.
- Krähenbühl, Philipp, Doersch, Carl, Donahue, Jeff, and Darrell, Trevor. Data-dependent initializations of convolutional neural networks. *International Conference on Learning Representations (ICLR)*, 2016.
- Lake, Brenden M, Salakhutdinov, Ruslan, Gross, Jason, and Tenenbaum, Joshua B. One shot learning of simple visual concepts. In *Conference of the Cognitive Science Society (CogSci)*, 2011.
- Li, Ke and Malik, Jitendra. Learning to optimize. *International Conference on Learning Representations (ICLR)*, 2017.
- Maclaurin, Dougal, Duvenaud, David, and Adams, Ryan. Gradient-based hyperparameter optimization through reversible learning. In *International Conference on Machine Learning (ICML)*, 2015.

- Munkhdalai, Tsendsuren and Yu, Hong. Meta networks. *International Conference on Machine Learning (ICML)*, 2017.
- Naik, Devang K and Mammone, RJ. Meta-neural networks that learn by learning. In *International Joint Conference on Neural Networks (IJCNN)*, 1992.
- Parisotto, Emilio, Ba, Jimmy Lei, and Salakhutdinov, Ruslan. Actor-mimic: Deep multitask and transfer reinforcement learning. *International Conference on Learning Representations (ICLR)*, 2016.
- Ravi, Sachin and Larochelle, Hugo. Optimization as a model for few-shot learning. In *International Conference on Learning Representations (ICLR)*, 2017.
- Rei, Marek. Online representation learning in recurrent neural language models. *arXiv preprint arXiv:1508.03854*, 2015.
- Rezende, Danilo Jimenez, Mohamed, Shakir, Danihelka, Ivo, Gregor, Karol, and Wierstra, Daan. One-shot generalization in deep generative models. *International Conference on Machine Learning (ICML)*, 2016.
- Salimans, Tim and Kingma, Diederik P. Weight normalization: A simple reparameterization to accelerate training of deep neural networks. In *Neural Information Processing Systems (NIPS)*, 2016.
- Santoro, Adam, Bartunov, Sergey, Botvinick, Matthew, Wierstra, Daan, and Lillicrap, Timothy. Meta-learning with memory-augmented neural networks. In *International Conference on Machine Learning (ICML)*, 2016.
- Saxe, Andrew, McClelland, James, and Ganguli, Surya. Exact solutions to the nonlinear dynamics of learning in deep linear neural networks. *International Conference on Learning Representations (ICLR)*, 2014.
- Schmidhuber, Jurgen. Evolutionary principles in self-referential learning. *On learning how to learn: The meta-meta-... hook.) Diploma thesis, Institut f. Informatik, Tech. Univ. Munich*, 1987.
- Schmidhuber, Jürgen. Learning to control fast-weight memories: An alternative to dynamic recurrent networks. *Neural Computation*, 1992.
- Schulman, John, Levine, Sergey, Abbeel, Pieter, Jordan, Michael I, and Moritz, Philipp. Trust region policy optimization. In *International Conference on Machine Learning (ICML)*, 2015.
- Shyam, Pranav, Gupta, Shubham, and Dukkipati, Ambedkar. Attentive recurrent comparators. *International Conference on Machine Learning (ICML)*, 2017.
- Snell, Jake, Swersky, Kevin, and Zemel, Richard S. Prototypical networks for few-shot learning. *arXiv preprint arXiv:1703.05175*, 2017.
- Thrun, Sebastian and Pratt, Lorian. *Learning to learn*. Springer Science & Business Media, 1998.
- Todorov, Emanuel, Erez, Tom, and Tassa, Yuval. Mujoco: A physics engine for model-based control. In *International Conference on Intelligent Robots and Systems (IROS)*, 2012.
- Vinyals, Oriol, Blundell, Charles, Lillicrap, Tim, Wierstra, Daan, et al. Matching networks for one shot learning. In *Neural Information Processing Systems (NIPS)*, 2016.
- Wang, Jane X, Kurth-Nelson, Zeb, Tirumala, Dhruva, Soyer, Hubert, Leibo, Joel Z, Munos, Remi, Blundell, Charles, Kumaran, Dhharshan, and Botvinick, Matt. Learning to reinforcement learn. *arXiv preprint arXiv:1611.05763*, 2016.
- Williams, Ronald J. Simple statistical gradient-following algorithms for connectionist reinforcement learning. *Machine learning*, 8(3-4):229–256, 1992.

A. 附加实验细节

在本节中，我们提供实验设置和超参数的附加细节。

A.1. 分类

对于 N-way、K-shot 分类，每个梯度使用批大小为 NK 的样本计算。对于 Omniglot，5-way 卷积和非卷积 MAML 模型均使用 1 个梯度步进行训练，步长为 $\alpha = 0.4$ ，元批大小为 32 个任务。网络使用 3 个梯度步进行评估，步长相同为 $\alpha = 0.4$ 。20-way 卷积 MAML 模型使用 5 个梯度步进行训练和评估，步长为 $\alpha = 0.1$ 。训练期间，元批大小设置为 16 个任务。对于 MiniImagenet，两个模型均使用 5 个梯度步进行训练，步长为 $\alpha = 0.01$ ，测试时使用 10 个梯度步进行评估。遵循 Ravi & Larochelle (2017) 的方法，每个类别使用 15 个样本评估更新后的元梯度。对于 1-shot 和 5-shot 训练，我们分别使用元批大小为 4 和 2 个任务。所有模型均在单个 NVIDIA Pascal Titan X GPU 上训练 60000 次迭代。

A.2. 强化学习

在所有强化学习实验中，MAML 策略使用单个梯度步进行训练，步长为 $\alpha = 0.1$ 。在评估期间，我们发现第一个梯度步后将学习率减半能产生更优的性能。因此，适应过程中的步长设置为第一步 $\alpha = 0.1$ ，后续所有步为 $\alpha = 0.05$ 。基线方法的步长针对每个领域手动调整。在 2D 导航中，我们使用元批大小为 20；在运动问题中，我们使用元批大小为 40 个任务。MAML 模型最多训练 500 次元迭代，训练期间平均回报最佳的模型用于评估。对于蚂蚁目标速度任务，我们在每个时间步添加正奖励奖励，以防止蚂蚁提前结束回合。

B. 附加正弦波结果

图 6 展示了 MAML 模型在 10 样本学习下训练，并在 5 样本、10 样本和 20 样本上评估的完整定量结果。图 7 展示了 MAML 与预训练基线在随机采样的正弦波上的定性性能。

C. 附加比较

本节包含对本方法的更全面评估，包括额外的多任务基线以及 Re (2015) 方法具有代表性的比较。

C.1. 多任务基线

正文中的预训练基线在所有任务上训练单一网络，我们称之为“在所有任务上预训练”。与 MAML 一样，为了评估该模型，我们在每个测试任务上使用 K 个样本对其进行微调。在我们研究的领域中，不同任务对相同输入产生不同的输出值。因此，通过在所有任务上预训练，模型将学会对特定输入值输出平均输出。在某些情况下，该模型可能对实际领域学习甚少，反而学习到输出空间的范围。

我们尝试了一种多任务方法以提供比较基准，该方法不是在输出空间中取平均，而是在参数空间中取平均。为了在参数空间中实现平均，我们依次在从 $p(\mathcal{T})$ 中抽取的 500 个任务上训练了 500 个独立模型。每个模型随机初始化，并在其分配任务的大量数据上进行训练。然后，我们取各模型参数向量的平均值，并使用调整后的步长在 5 个数据点上进行调整。由于计算需求，该方法的所有实验均在正弦波任务上进行。各个回归器的误差较低：在各自的正弦波上小于 0.02。

我们尝试了此设置的三种变体。在训练各个回归器时，我们尝试使用以下之一：无正则化、标准 ℓ_2 权重衰减，以及对迄今为止已训练回归器的均值参数向量施加 ℓ_2 权重正则化。后两种变体促使各个模型寻找简约解。使用正则化时，我们将正则化强度设为在不显著损害性能的前提下尽可能高。在结果中，我们将此方法称为“多任务”。如表 2 结果所示，我们发现参数空间中的平均（多任务）表现不如输出空间中的平均（在所有任务上预训练）。这表明在分别训练各任务时难以找到多任务的简约解，而 MAML 学到的解比均值最优参数向量更为精细。

C.2. 上下文向量自适应

Rei (2015) 提出了一种可在线自适应的上下文向量学习方法，应用于循环语言模型。该上下文向量中的参数以与 MAML 模型中参数相同的方式学习和自适应。为了与在元学习问题中使用此类上下文向量进行比较，我们将一组自由参数 $\mathbf{z}$ 与输入 $\mathbf{x}$ 拼接，并仅允许梯度步骤修改 $\mathbf{z}$ ，而非像 MAML 那样修改模型参数 θ 。对于图像输入， $\mathbf{z}$ 按通道与输入拼接。




图 6. 正弦回归的定量结果，展示了不同 K 测试时样本数量下的测试时学习曲线。每个梯度步骤使用相同的 K 个样本计算。注意，MAML 在元测试期间即使面对极小数据集也能通过额外梯度步骤持续改进而不发生过拟合，并达到显著低于基线微调方法的损失。

表 2. 正弦回归域上的额外多任务基线，展示 5 样本均方误差。结果表明 MAML 学到的解比均值最优参数向量更为精细。

num. grad steps	1	5	10
multi-task, no reg	4.19	3.85	3.69
multi-task, l2 reg	7.18	5.69	5.60
multi-task, reg to mean θ	2.91	2.72	2.71
pretrain on all tasks	2.41	2.23	2.19
MAML (ours)	0.67	0.38	0.35

表 3. 5 路 Omniglot 分类

	1-shot	5-shot
context vector	94.9 $\pm$ 0.9%	97.7 $\pm$ 0.3%
MAML	98.7 $\pm$ 0.4%	99.9 $\pm$ 0.1%

对于图像输入， $\mathbf{z}$ 按通道与输入拼接。

图像。我们在 Omniglot 和两个强化学习领域上按照相同的实验协议运行了该方法。结果报告在表 3、表 4 和表 5 中。学习可适应的上下文向量在简单的点质量问题上表现良好，但在更困难的问题上表现欠佳，这可能是由于元优化的灵活性较低。

表 4. 二维点质量，平均回报

num. grad steps	0	1	2	3
context vector	-42.42	-13.90	-5.17	-3.18
MAML (ours)	-40.41	-11.68	-3.33	-3.23

表 5. 半猎豹前进/后退，平均回报

num. grad steps	0	1	2	3
context vector	-40.49	-44.08	-38.27	-42.50
MAML (ours)	-50.69	293.19	313.48	315.65




图 7. 正弦回归任务中定性结果的随机样本。