

备忘录：通过适应与 增强实现测试时鲁棒性

Marvin Zhang¹, Sergey Levine¹, Chelsea Finn²
¹UC Berkeley ²Stanford University

摘要

尽管神经网络在分布内测试点上能够达到良好的准确率，但许多应用要求模型在面对输入中的意外扰动、领域变化或其他分布偏移来源时仍具备鲁棒性。本文研究测试时鲁棒化问题，即利用测试输入来提升模型鲁棒性。近期已有工作提出了测试时适应方法，然而这些方法各自引入了额外假设，例如需要访问多个测试点，从而阻碍了广泛采用。本文旨在研究并设计不依赖于模型训练过程假设、且在测试时广泛适用的方法。我们提出一种简单方法，适用于模型具有概率性和可适应性的任何测试场景：当给定一个测试样本时，对数据点执行不同的数据增强，然后通过最小化模型在增强样本上的平均（或边缘）输出分布的熵来适应（全部）模型参数。直观上，该目标鼓励模型在不同增强下做出相同预测，从而强化这些增强所编码的不变性，同时保持预测置信度。在实验中，我们评估了两个基线残差网络模型、两个鲁棒的残差网络-50 模型以及一个鲁棒的视觉变换器模型，并证明该方法相比标准模型评估实现了 1-8% 的准确率提升，且通常优于先前的增强和适应策略。在仅有一个测试点可用的场景下，我们在 ImageNet-C、ImageNet-R 以及（在残差网络-50 模型中）ImageNet-A 分布偏移基准上取得了最先进的结果。

1 引言

神经网络模型在许多机器学习问题（如图像分类）上取得了优异的性能，但往往较为脆弱，容易受到分布偏移相关问题的影响。例如，深度图像分类器在遇到输入扰动（如噪声或光照变化 [12]）或现实应用中自然发生的领域偏移 [21] 时，准确率可能急剧下降。因此，针对这些测试偏移对深度模型进行鲁棒化是一个重要且活跃的研究领域。

该领域的大多数先前工作都集中在训练时鲁棒化技术上，包括利用更大的模型和数据集 [34]、各种形式的对抗训练 [39, 48] 以及激进的数据增强 [51, 13, 24, 14]。采用这些技术需要修改训练过程，这在涉及大量计算或非公开数据等情况下可能不可行。此外，这些技术不依赖模型必须预测的测试点的任何信息，尽管这些测试点可能为提升模型鲁棒性提供重要信息。最近，一些工作提出了在观察到测试数据后通过自适应来提升准确率的方法，通常通过更新模型权重的子集 [44, 45, 18]、归一化统计量 [40] 或两者兼有 [46, 52]。尽管这些方法在处理测试分布偏移方面有效，




图 1: 左: 在测试时, 如第 3 节所述, 我们有一个单独的测试输入 $\mathbf{x}$ 、一组数据增强函数 $\{a_1, \dots, a_M\}$, 以及一个输出概率预测分布并具有可适应参数 θ 的已训练模型。我们对 $\mathbf{x}$ 执行不同的增强, 并将这些增强后的输入传递给模型, 以估计在增强上平均的边际输出分布。右: 我们对模型执行梯度更新, 以最小化该边际分布的熵, 从而鼓励模型预测在不同增强之间保持不变, 同时保持置信预测。最终预测在原始数据点上, 即示意图右上角的预测分布。

这些方法有时仍需要专门的训练程序, 并且通常依赖于通过批次甚至整个测试输入集来提取信息, 从而引入了额外的假设。

本文聚焦于测试时鲁棒性方法, 其中可利用特定测试输入来改进模型在该点上的预测。我们致力于研究和设计“即插即用”的模型鲁棒性改进方法, 即能够直接适用于多种预训练模型和测试设置。我们还希望这些方法能与其他鲁棒化技术协同作用, 从而获得比单独使用任一方法更高的性能。基于这些目标, 我们设计了一种基于适应与增强的新颖测试时鲁棒性方法。如图 1 所示, 当给定一个测试点时, 我们通过对该测试点进行不同方式的增强来适应模型, 同时鼓励模型做出一致的预测, 从而尊重数据增强中编码的不变性。我们进一步鼓励模型做出置信的预测, 由此得到所提出的方法: 最小化模型在测试点增强版本上预测的边际熵。

我们将所提出的方法称为单测试点边际熵最小化 (MEMO), 这是本文的主要贡献。MEMO 直接利用预训练模型, 不假设其特定的训练过程或架构, 且仅需单个测试输入即可进行适应。在第 4 节中, 我们通过实验证明, MEMO 在多个具有挑战性的 ImageNet 分布偏移基准上持续提升了 ResNet [11] 和视觉变换器 [7] 模型的性能, 在仅有一个测试点可用的设置下, 为这些模型取得了若干新的最先进结果。MEMO 在 ImageNet-C [12] 和 ImageNet-R [14] 测试集上始终优于非自适应的边际分布预测 (提升 1-10%), 表明适应在提高预测准确率方面起着关键作用。MEMO 同时鼓励跨增强的不变性和置信预测, 第 4 节的消融实验表明, 这两个组成部分对于最大化性能增益都很重要。此外, 据我们所知, MEMO 是首个在 ImageNet-A 测试集 [15] 上提升性能 (较标准模型评估提升 1-4%) 的适应方法。

2 相关工作

分布偏移已在多种框架下得到研究 [36], 包括领域自适应 [41, 6, 47]、领域泛化 [5, 32, 9] 以及分布鲁棒优化 [4, 16, 39]。这些框架通常利用额外的训练或测试假设, 以使分布偏移问题更易处理。与这些框架基本独立的是, 还提出了各种经验方法来处理偏移, 例如增大模型和训练数据集

规模或使用重度训练增强 [34, 51, 14]。本文工作的重点与这些努力互补：MEMO 适用于广泛的预训练模型，包括通过鲁棒性方法训练的模型，并可通过测试时自适应获得进一步的性能提升。

先前的测试时自适应方法通常要么做出显著的训练或测试假设。一些方法使用批量甚至整个测试输入集来更新模型，例如通过在测试集上计算批归一化统计量 [25, 19, 33, 40]、计算类别原型 [18]，或在一批测试数据上最小化模型预测的（条件）熵 [46]。后一种方法与 MEMO 密切相关。不同之处在于，MEMO 使用单个测试点和数据增强来最小化边缘熵，并自适应所有模型参数，而不仅仅是与归一化层相关的参数，因此不需要多个测试点或特定的模型架构。其他测试时自适应方法可应用于单个测试点，但需要特定的训练过程或模型 [44, 17, 40, 1, 3]。测试时训练 [44] 需要具有旋转预测头的专用模型以及不同的训练过程。Schneider 等人 [40] 表明，即使只有一个测试点，批归一化自适应也能有效。正如我们在第 3 节中讨论的，MEMO 与这种“单点”批归一化自适应技术能很好地协同。Mao 等人 [29] 提出了一种基于输入扰动的测试时自适应方法，以增强对对抗攻击的鲁棒性。与我们的工作同时，Sivaprasad 和 Fleuret [43] 提出了一种类似的测试时自适应方法，通过鼓励对数据增强的不变性，并在损坏的 CIFAR 和 VisDA [35] 数据集上测试了他们的方法。

许多研究指出，对训练集施加不同形式的强数据增强能够提升所得模型的鲁棒性 [51, 13, 24, 14]。数据增强有时也直接用于测试数据，方法是对测试点的增强副本取模型输出的平均值 [23, 42]，即根据模型的边缘输出分布进行预测。当使用裁剪作为增强方式时，该技术通常被称为多裁剪评估 [22]。我们则使用术语测试时增强（TTA），因为除了裁剪之外我们还使用了其他增强方式 [13]。已有研究表明，TTA 既能提升模型准确率和校准性能 [2]，也能应对分布偏移 [31]。我们将这一思想进一步推进，显式地调整模型，使其边缘输出分布具有低熵。这为改进模型提取了额外的学习信号，而且调整后的模型可以在干净的测试点上进行最终预测，而非在增强副本上预测。我们在第 4 节中通过实验证明，这些差异相较于非自适应的 TTA 基线带来了性能提升。

3 测试时的增强与自适应

数据增强通常用于训练模型以遵守某些不变性——例如，光照或视角的变化不应改变底层类别标签——但尤其在面临分布偏移时，模型并不能保证在测试时遵守同样的不变性。在本节中，我们介绍 MEMO，一种测试时鲁棒性方法，它调整模型使其在测试输入上遵守这些不变性。我们使用“测试时鲁棒性”特指直接作用于预训练模型和单个测试输入的技术——如第 2 节所述的单点 BN 自适应和 TTA，都是先前测试时鲁棒性方法的例子。

在测试时鲁棒性设定中，给定一个已训练模型 f_θ ，其参数为 $\theta \in \Theta$ 。我们不要求任何特殊的训练过程，也不对模型做任何假设，除了 θ 是可适应的，且 f_θ 产生的条件输出分布 $p_\theta(y|\mathbf{x})$ 关于 θ ¹ 可微。所有标准深度神经网络模型都满足这些假设。单个点 $\mathbf{x} \in \mathcal{X}$ 被呈现给 f_θ ，模型必须立即为其预测标签 $\hat{y} \in \mathcal{Y}$ 。注意，这与常规监督学习模型的标准测试时推理过程完全相同——实际上，我们只是修改了推理方式，而没有对训练过程或测试时数据可用性增加任何额外假设。这使得测试时鲁棒性方法成为普遍且标准的测试时推理过程的简单“即插即用”替代方案。我们假设可以采样访问一组增强函数 $\mathcal{A} \triangleq \{a_1, \dots, a_M\}$ ，这些函数可以应用于测试点 $\mathbf{x}$ 。我们利用这些增强和下文详述的自监督目标，在模型对 $\mathbf{x}$ 进行预测之前对其进行适应。当给定一组测试输入时，模型对每个测试点独立地进行适应和预测。我们不假设可以访问任何真实标签。

¹ 单点批量归一化适应还假设模型具有批量归一化层——如第 4 节经验所示，这是我们不要求但也可以受益的假设。

Algorithm 1 Test time robustness via MEMO

Require: trained model f_θ , test point $\mathbf{x}$, number of augmentations B , learning rate η , update rule G

- 1: Sample $a_1, \dots, a_B \stackrel{\text{i.i.d.}}{\sim} \mathcal{U}(\mathcal{A})$ and produce augmented points $\tilde{\mathbf{x}}_i = a_i(\mathbf{x})$ for $i \in \{1, \dots, B\}$
 - 2: Compute estimate $\tilde{p} = \frac{1}{B} \sum_{i=1}^B p_\theta(y|\tilde{\mathbf{x}}_i) \approx \bar{p}_\theta(y|\mathbf{x})$ and $\tilde{\ell} = H(\tilde{p}) \approx \ell(\theta; \mathbf{x})$, i.e., Eq. 2
 - 3: Adapt parameters via update rule $\theta' \leftarrow G(\theta, \eta, \tilde{\ell})$
 - 4: Predict $\hat{y} \triangleq \arg \max_y p_{\theta'}(y|\mathbf{x})$
-

3.1 单测试点的边际熵最小化

给定测试点 $\mathbf{x}$ 和一组增强函数 $\mathcal{A}$ ，我们从 $\mathcal{A}$ 中采样 B 个增强，并将其应用于 $\mathbf{x}$ ，以生成一批增强数据 $\tilde{\mathbf{x}}_1, \dots, \tilde{\mathbf{x}}_B$ 。模型关于增强点的平均（即边际）输出分布由下式给出

$$\bar{p}_\theta(y|\mathbf{x}) \triangleq \mathbb{E}_{\mathcal{U}(\mathcal{A})} [p_\theta(y|a(\mathbf{x}))] \approx \frac{1}{B} \sum_{i=1}^B p_\theta(y|\tilde{\mathbf{x}}_i), \quad (1)$$

其中期望是关于均匀采样的增强 $a \sim \mathcal{U}(\mathcal{A})$ 。我们希望这个边际分布具有什么性质？为了回答这个问题，考虑数据增强在训练期间通常所起的作用。对于每个训练点 $(\mathbf{x}^{\text{train}}, y^{\text{train}})$ ，模型 f_θ 使用输入的多种增强形式 $\tilde{\mathbf{x}}_1^{\text{train}}, \dots, \tilde{\mathbf{x}}_B^{\text{train}}$ 进行训练，以遵守增强与标签之间的不变性——无论对 $\mathbf{x}^{\text{train}}$ 施加何种增强，都应自信地预测相同的标签 y^{train} 。我们寻求在测试时设计一个类似的学习信号，而无需任何真实标签。也就是说，在适应之后：

(1) 模型 f_θ 的预测应在测试点的增强版本之间保持不变，且 (2) 模型 f_θ 应对其预测保持自信，即使对于测试点的重度增强版本也应如此，因为所有版本都具有相同的底层标签。

优化模型以获得更自信的预测，其合理性在于假设类别之间的真实底层决策边界位于数据空间的低密度区域 [8]。基于这两个目标，我们提出利用模型在增强上的边际输出分布的熵（式 1）来适应模型，即：

$$\ell(\theta; \mathbf{x}) \triangleq H(\bar{p}_\theta(\cdot|\mathbf{x})) = - \sum_{y \in \mathcal{Y}} \bar{p}_\theta(y|\mathbf{x}) \log \bar{p}_\theta(y|\mathbf{x}). \quad (2)$$

注意，该目标不同于优化模型在增强上的预测分布的平均条件熵，即：

$$\ell_{\text{CE}}(\theta; \mathbf{x}) \triangleq \frac{1}{B} \sum_{i=1}^B H(p_\theta(\cdot|\tilde{\mathbf{x}}_i)). \quad (3)$$

一个在不同增强上预测自信但结果不同的模型会最小化式 3，而不会最小化式 2。优化式 2 同时鼓励自信和不变性，因为当模型无论增强如何都输出相同（自信）的预测时， $\bar{p}_\theta(\cdot|\mathbf{x})$ 的熵被最小化。

算法 1 给出了测试时适应的整体方法 MEMO。尽管先前的测试时适应方法必须谨慎选择要适应的参数以避免退化解 [46]，但我们的适应过程只需简单地适应模型的所有参数 θ （第 3 行）。鉴于 $p_\theta(y|\mathbf{x})$ 关于 θ 可微，我们可以直接使用基于梯度的优化根据式 2 来适应 θ 。我们对每个测试点仅使用一步梯度，因为经验表明这足以提升性能且计算效率更高。在此步骤之后，我们使用适应后的模型 $f_{\theta'}$ 对原始测试输入 $\mathbf{x}$ 进行预测（第 4 行）。

3.2 将 MEMO 与先前方法组合

MEMO 的另一个优势是它能与其他处理分布偏移的方法协同作用。特别是，MEMO 可以与先前用于训练鲁棒模型和适应模型统计量的方法组合，从而利用每种技术的性能提升。




图 2: 我们可视化了从“高斯噪声等级 3”ImageNet-C 测试集中随机选择的数据点的增强。即使对于使用重度数据增强训练的鲁棒模型 [14], 其预测准确率和置信度 (如上两行所示) 在遇到测试偏移时也会急剧下降。如下两行所示, 这些下降可以通过 MEMO 适应来弥补。

预训练鲁棒模型。由于边际熵最小化 (MEMO) 对模型训练过程不做任何假设, 也不进行任何修改, 因此在预训练鲁棒模型 (例如使用重度数据增强训练的模型) 之上执行自适应, 与使用任何其他预训练模型一样简单。关键的是, 我们发现, 在实践中, 测试增强集合 $\mathcal{A}$ 不必与训练模型时使用的增强相匹配。为了简单和高效, 我们使用易于采样且直接应用于模型输入 $\mathbf{x}$ 的增强。这些性质不适用于基于图像翻译模型的数据增强技术, 例如深度增强 (DeepAugment) [14], 或特征混合, 例如矩交换 (moment **exchange**) [24]。然而, 我们仍然可以使用这些数据增强技术训练的模型作为自适应的起点, 从而改进它们的最先进结果。如上所述, 对于需要复杂或专门训练过程和模型架构的自适应方法, 例如测试时训练 (TTT) [44] 或自适应风险最小化 (ARM) [52], 使用预训练模型并不容易实现。在我们的实验中, 我们使用增强混合 (**AugMix**) 作为我们的增强集合 [13], 因为它满足上述性质, 并且在应用时仍能产生显著的多样性, 如图 2 所示。注意, 增强混合明确不使用与 CIFAR-10-C 和 ImageNet-C 测试集中的损坏相似的增强 [12, 13]。

自适应批归一化统计量。施耐德等人 [40] 表明, 即使仅呈现单个测试点, 部分自适应模型中每个批归一化 (BN) 层激活的估计均值和方差在某些情况下仍能有效处理分布偏移。在此设置中, 为了防止对测试点过拟合, 从该点估计的通道均值和方差 $[\mu_{\text{test}}, \sigma_{\text{test}}^2]$ 根据先验强度 N 与训练期间计算的均值和方差 $[\mu_{\text{train}}, \sigma_{\text{train}}^2]$ 混合。即, 对于 $\nu \in \{\mu, \sigma^2\}$,

$$\nu \triangleq \frac{N}{N+1} \nu_{\text{train}} + \frac{1}{N+1} \nu_{\text{test}}.$$

该技术也很容易与边际熵最小化 (MEMO) 结合: 我们只需在计算模型输出分布时使用自适应批归一化统计量。我们在实验中发现, 该技术从不降低, 并且通常提高测试时自适应的性能, 因此我们在适用时默认将边际熵最小化与该技术结合。按照施耐德等人 [40] 的建议, 我们在下一节的所有实验中设置 $N = 16$ 。

4 实验

我们的实验旨在回答以下问题：

- (1) MEMO 与先前的测试时自适应和测试时鲁棒性方法相比如何？
- (2) MEMO 能否与多种模型架构和预训练方法结合？
- (3) MEMO 的哪个方面，自适应还是增强，最为重要？

我们在总共五个分布偏移基准上评估 MEMO。我们在 CIFAR-10-C [12] 和 CIFAR-10.1 [37] 测试集上进行 CIFAR-10 [22] 实验，并在 ImageNet-C [12]、ImageNet-R [14] 和 ImageNet-A [15] 测试集上进行 ImageNet [38] 实验。

为回答问题 (1)，我们在 CIFAR-10 实验中与测试时训练 (TTT) [44] 进行比较，为此我们按照其协议和专用架构训练 ResNet-26 模型。由于训练最先进模型的计算需求以及 Sun 等人 [44] 未报告有竞争力的 ImageNet 结果，我们未在 ImageNet 实验中与 TTT 进行比较。对于 ImageNet 实验，我们与 Tent [46] 和 BN 自适应进行比较，这些方法可用于预训练模型，但需要多个测试输入（甚至整个测试集）进行自适应。我们一次为 BN 自适应提供 256 个测试输入，并设置先验强度 $N = 256$ [40]。

对于 Tent，我们使用 64 的测试批大小，并且对于 ResNet-50 模型，同时测试“在线”自适应（模型在整个评估过程中持续自适应）和“情景”自适应（模型在每个测试批次后重置）[46]。请注意，这两种方法的评估协议不同：MEMO 的任务是在自适应后立即对每个测试点进行预测，而 BN 自适应在批次上计算 BN 统计量后对 256 个测试点的批次进行预测，Tent 在自适应后对 64 个输入的批次进行预测，但在在线设置中还会在整个评估过程中持续自适应。在所有实验中，我们进一步与单点 BN 自适应 [40] 和仅根据 $\bar{p}_\theta(y|\mathbf{x})$ （公式 1）[23, 2] 进行预测的 TTA 基线进行比较。我们实验协议的完整细节见附录 A。

为回答问题 (2)，本文将边际熵最小化方法应用于多个具有不同架构、经多种训练流程得到的预训练模型之上。对于 CIFAR-10 数据集，本文自行训练了 ResNet-26[11] 模型。对于 ImageNet 数据集，本文采用先前工作中性能最佳的 ResNet-50 鲁棒模型，包括使用 DeepAugment 和 AugMix 增强训练的模型 [14]，以及使用矩交换和 CutMix 训练的模型 [24]。为评估先前测试时鲁棒性方法与边际熵最小化方法的通用性，本文还评估了小型鲁棒视觉变换器 (RVT * -small)，该模型在三个 ImageNet 分布偏移基准上均优于鲁棒 ResNet-50 模型 [30]。最后，本文在 ImageNet-A 上评估了 ResNext-101 模型 [50, 28]，因为这些模型此前在该测试集上取得了最强结果 [14]。

最后，为回答问题 (3)，本文在 4.2 节进行了消融研究：首先确定最大化置信度（通过熵最小化）与强制每个测试点增强副本间预测不变性的相对重要性，其次确定所用特定增强函数的重要性，第三确定每次推理所需增强样本的数量。与非自适应测试时增强基线的比较也有助于确定仅对测试点进行增强是否足够，还是自适应调整具有额外帮助。在附录 B 中，本文进一步提供了专门针对增强组件的消融实验。

4.1 主要结果

我们在表 1 中总结了 CIFAR-10、CIFAR-10.1 和 CIFAR-10-C 的结果，完整的 CIFAR-10-C 结果见附录 C。我们使用缩进来表示组合方式，例如，TTT 是在其专门的联合训练过程之上于测试时执行的。在 CIFAR-10-C 的所有损坏类型中，MEMO 相比基线、非自适应 TTA 和 TTT 均持续改善了测试误差。与 TTT 相比，MEMO 在 CIFAR-10.1 上也提供了更大的性能提升。我们发现，对于这些相对简单的测试集，非自适应 TTA 基线具有竞争力，但在 CIFAR-10-C 上不如 MEMO。在这三个测试集中，CIFAR-10-C 是唯一明确引入分布偏移的基准，这表明当测试偏移更为显著时，自适应是有用的。TTA 和 MEMO 在原始 CIFAR-10 测试集（无分布偏移）上也能有效提升性能，进一步支持了标准评估协议中广泛使用数据增强的做法 [23, 2]。

表 1: CIFAR-10、CIFAR-10.1 和 CIFAR-10-C 的结果。* 结果来自 Sun 等人 [44]。

	CIFAR-10 Error (%)	CIFAR-10.1 Error (%)	CIFAR-10-C Average Error (%)
ResNet-26 [11]	9.2	18.4	22.5
+ TTA	7.3 (−1.9)	14.8 (−3.6)	19.9 (−2.6)
+ MEMO (ours)	7.3 (−1.9)	14.7 (−3.7)	19.6 (−2.9)
+ Joint training* [44]	8.1	16.7	22.8
+ TTT* [44]	7.9 (−0.2)	15.9 (−0.8)	21.5 (−1.3)

表 2: ImageNet 测试集的测试结果。在单测试点设置下，MEMO 在 ResNet-50 模型的每个基准上均达到了新的最先进性能。对于 RVT * -small，MEMO 在所有基准上均提升了性能，并在 ImageNet-C 和 ImageNet-R 上达到了新的最先进水平。与先前方法相比，MEMO 提供了更一致的改进。

	ImageNet-C ↓ 错误率 (%)	ImageNet-R 错误率 (%)	ImageNet-A mCE
Baseline ResNet-50 [11]	76.7	63.9	100.0
+ TTA	77.9 (+1.2)	61.3 (−2.6)	98.4 (−1.6)
+ Single point BN	71.4 (−5.3)	61.1 (−2.8)	99.4 (−0.6)
+ MEMO (ours)	69.9 (−6.8)	58.8 (−5.1)	99.1 (−0.9)
+ BN ($N = 256, n = 256$)	61.6 (−15.1)	59.7 (−4.2)	99.8 (−0.2)
+ Tent (online) [46]	54.4 (−22.3)	57.7 (−6.2)	99.8 (−0.2)
+ Tent (episodic)	64.7 (−12.0)	61.0 (−2.9)	99.7 (−0.3)
+ DeepAugment+AugMix [14]	53.6	53.2	96.1
+ TTA	55.2 (+1.6)	51.0 (−2.2)	93.5 (−2.6)
+ Single point BN	51.3 (−2.3)	51.2 (−2.0)	95.4 (−0.7)
+ MEMO (ours)	49.8 (−3.8)	49.2 (−4.0)	94.8 (−1.3)
+ BN ($N = 256, n = 256$)	45.4 (−8.2)	48.8 (−4.4)	96.8 (+0.7)
+ Tent (online)	43.5 (−10.1)	46.9 (−6.3)	96.7 (+0.6)
+ Tent (episodic)	47.1 (−6.5)	50.1 (−3.1)	96.6 (+0.5)
+ MoEx+CutMix [24]	74.8	64.5	91.9
+ TTA	75.7 (+0.9)	62.7 (−1.8)	89.5 (−2.4)
+ Single point BN	71.0 (−3.8)	62.6 (−1.9)	91.1 (−0.8)
+ MEMO (ours)	69.1 (−5.7)	59.4 (−3.3)	89.0 (−2.9)
+ BN ($N = 256, n = 256$)	60.9 (−13.9)	61.6 (−2.9)	93.9 (+2.0)
+ Tent (online)	54.0 (−20.8)	58.7 (−5.8)	94.4 (+2.5)
+ Tent (episodic)	66.2 (−8.6)	63.9 (−0.6)	94.7 (+2.8)
RVT*-small [30]	49.4	52.3	73.9
+ TTA	53.0 (+3.6)	49.0 (−3.3)	68.9 (−5.0)
+ Single point BN	48.0 (−1.4)	51.1 (−1.2)	74.4 (+0.5)
+ MEMO (ours)	40.6 (−8.8)	43.8 (−8.5)	69.8 (−4.1)
+ BN ($N = 256, n = 256$)	44.3 (−5.1)	51.0 (−1.3)	78.3 (+4.4)
+ Tent (online)	46.8 (−2.6)	50.7 (−1.6)	82.1 (+8.2)
+ Tent (adapt all)	44.7 (−4.7)	74.1 (+21.8)	81.1 (+7.2)

我们在表 2 中总结了 ImageNet-C、ImageNet-R 和 ImageNet-A 的结果，完整的 ImageNet-C 结果见附录 C。我们再次使用缩进来表示组合方式，例如，在我们的设置中，ImageNet-C 上的最佳结果是通过结合使用 DeepAugment 和 AugMix 训练的模型 [14] 并在其上使用 MEMO 而获得的。对于 ImageNet-C 和 ImageNet-R，以及 ResNet-50 和 RVT * -small 模型，将 MEMO 与鲁棒训练技术相结合，在每次仅观察一个测试点的方法中达到了新的最先进性能。我们用灰色突出显示需要多个测试点进行自适应的方法，并用粗体列出这些方法中优于测试时鲁棒性方法的最佳结果。如表 2 和先前工作所示 [40, 46]，对于 ImageNet-C 和 ImageNet-R 等基准，访问多个测试点可能非常有效，在这些基准中，推断的统计信息

来自测试输入分布的信息可能有助于预测。然而，这些方法对 ImageNet-A 不仅没有帮助，甚至常常有害。此外，我们发现这些方法在 RVT * -small 模型上效果较差，这可能表明它们对模型架构选择较为敏感。因此，对于该模型，我们还测试了 Tent 的一种修改版本，该版本适应所有参数，并发现此版本的 Tent 在 ImageNet-C 上表现更好，但在 ImageNet-R 上显著变差。

MEMO 也为 ImageNet-A 带来了显著改进。此前没有任何测试时适应方法报告过在 ImageNet-A 上的改进，有些方法甚至报告了明确的负面结果 [40]。如前所述，依赖多个测试点的适应方法在其他基准（如 ImageNet-C）上取得更大成功是合理的，因为一批输入提供了关于必须处理的特定损坏的显著信息。相比之下，ImageNet-A 没有与输入分布相关的明显特征，它只是一组难以分类的图像集合。由于 MEMO 从单个测试点提取学习信号，据我们所知，它是第一个在该测试平台上报告成功结果的测试时适应方法。我们认为 MEMO 在不同测试集上一致优于最佳先前方法（这些方法在不同测试集上表现不一）是所提方法的一个主要优势。

测试时增强（TTA）是 ImageNet-A 上最具竞争力的先前方法，例如，对于 RVT * -small 模型，它比 MEMO 带来了更大的改进。然而，MEMO 在 ResNet-50 模型中达到了最先进的性能。为了进一步比较 MEMO 与 TTA，在表 3 中，我们评估 MEMO 能否成功适应 ResNext-101 模型 [50]，并进一步提升在这一具有挑战性的测试集上的性能。我们评估了在 ImageNet 上预训练的 ResNext-101 (32x8d) 基线模型，以及使用弱监督学习（WSL）在数十亿 Instagram 图像上预训练的同一模型 [28]。对于 WSL 模型，我们没有为 MEMO 使用单点批归一化（BN）适应，因为我们发现该技术实际上对性能有害，这印证了先前的发现 [40]。从结果可以看出，尽管 TTA 和 MEMO 都显著改善了基线模型评估，但 MEMO 最终以显著优势取得了最佳准确率，因为它更成功地适应了 WSL 模型。这表明 MEMO 可能与大规模预训练产生良好的协同作用，进一步探索这种组合是未来工作的一个有趣方向。

表 3: ResNext-101s 的 ImageNet-A 结果。

	ImageNet-A Error (%)
ResNext-101 [50]	90.0
+ TTA	83.2 (−6.8)
+ Single point BN	88.8 (−1.2)
+ MEMO (ours)	84.3 (−5.7)
+ WSL [28]	54.9
+ TTA	49.1 (−5.8)
+ Single point BN	58.9 (+4.0)
+ MEMO (ours)	43.2 (−11.7)

4.2 消融研究

MEMO 同时使用了适应和数据增强。在本节中，我们对适应过程和增强数量进行消融，并在附录 B 中对增强选择进行消融。

适应过程。从上述结果中，我们得出结论：适应通常比仅使用 TTA 通过边际输出分布进行预测带来额外的好处 $\bar{p}_\theta(y|\mathbf{x})$ 。然而，我们可以分离出两种可能对适应有效的不同自监督学习信号：鼓励跨测试点不同增强的预测不变性，以及通过熵最小化鼓励置信度。公式 2 中的边际熵目标包含了这两种学习信号，但它不容易分解为这些部分。我们改用两种消融适应方法，每种方法仅利用其中一种学习信号。

首先，我们考虑优化每对增强点之间的成对交叉熵，即

$$\ell_{\text{PCE}}(\theta; \mathbf{x}) \triangleq \frac{1}{B \times (B-1)} \sum_{i=1}^B \sum_{j \neq i} H(p_\theta(\cdot|\tilde{\mathbf{x}}_i), p_\theta(\cdot|\tilde{\mathbf{x}}_j)),$$

其中 $\tilde{\mathbf{x}}_i$ 再次指应用于 $\mathbf{x}$ 的第 i 个采样增强。直观上，该损失函数鼓励模型进行适应，使其对测试点的所有增强产生相同的预测分布，但它不鼓励模型产生置信的预测。

表 4: 消融自适应目标, 以测试基于成对交叉熵和条件熵 (CE) 的自适应。MEMO 通常表现最佳, 表明鼓励增强间不变性和置信度都有助于模型自适应。

	CIFAR-10 Error (%)	CIFAR-10.1 Error (%)	CIFAR-10-C Average Error (%)
ResNet-26 [11]	9.2	18.4	22.5
+ MEMO (ours)	7.3 (−1.9)	14.7 (−3.7)	19.6 (−2.9)
− ℓ (Eq. 2) + ℓ_{PCE}	7.6 (−1.6)	15.3 (−3.1)	20.0 (−2.5)
− ℓ (Eq. 2) + ℓ_{CE}	7.6 (−1.6)	14.7 (−3.7)	20.0 (−2.5)
	ImageNet-C mCE ↓	ImageNet-R Error (%)	ImageNet-A Error (%)
RVT*-small [30]	49.4	52.3	73.9
+ MEMO (ours)	40.6 (−8.8)	43.8 (−8.5)	69.8 (−4.1)
− ℓ (Eq. 2) + ℓ_{CE}	41.2 (−8.2)	44.2 (−8.1)	69.7 (−4.2)




图 3: 绘制 MEMO 效率, 横轴为每次评估的秒数, 纵轴为 ImageNet-R 上的测试错误率 (%), 分别针对 ResNet-50 模型 (左) 和 RVT*-small (右), 同时改变 $B = \{1, 2, 4, 8, 16, 32, 64, 128\}$ 。注意横轴为对数刻度。

相反, 作为鼓励置信度但不鼓励不变性的目标, 我们还考虑优化式 3 中详述的条件熵目标。该消融实际上是 Tent[46] 的情景变体版本, 它生成单个测试点的增强副本, 而非假设可访问测试批次。我们首先在 CIFAR-10 测试集上评估这些消融。我们使用相同的自适应过程和超参数, 将 ℓ 替换为上述目标。

结果见表 4。我们发现 MEMO (即边缘熵最小化) 通常优于使用任一替代目标的自适应。这支持了以下假设: 增强间的不变性和增强上的置信度都是自监督自适应的重要学习信号。面对 CIFAR-10.1 时, 基于成对交叉熵的自适应方法表现不佳。在原始 CIFAR-10 测试集和 CIFAR-10-C 上, 消融方法表现几乎相同, 且一致差于 MEMO。为了进一步测试 ℓ_{CE} 消融 (两种消融中较强的一种), 我们还在 RVT*-small 模型的 ImageNet 测试集上对其进行了评估。我们发现, 类似地, 最小化条件熵通常能相对于基线评估提升性能。MEMO 在 ImageNet-C 和 ImageNet-R 上表现更优。通过 ℓ_{CE} 进行自适应在 ImageNet-A 上略好, 但对于该问题和模型, TTA 仍是最佳方法。因此, 与仅在增强上最大化置信度相比, MEMO 带来了相对较小但一致的性能提升。

增强数量。在图 3 中, 我们分析了 MEMO 自适应在 ImageNet-R 上的测试错误率 (%) 与自适应效率 (以每次评估的秒数衡量) 之间的关系。我们通过改变增强副本数量 B 来实现各种权衡。

$\{1, 2, 4, 8, 16, 32, 64, 128\}$ 我们注意到, 较小的 B 值 (如 4 和 8) 已经能够带来显著的性能提升, 因此可以在效率与准确率之间实现实用的权衡。

对于较大的 B , 实际运行时间主要由计算增强操作所主导。对于基线 ResNet-50 模型, 单点批量归一化自适应平均每个测试点需要 0.0252 秒。使用 $B = 64$ 的 TTA 和 MEMO 则慢得多——每个测试点分别需要 0.7742 秒和 0.9746 秒——但通过使用 $B = 4$ 个增强样本可以显著提高效率——分别降至 0.0631 秒和 0.1037 秒。在我们的实现中, 我们没有并行计算增强操作, 尽管原则上对于 AugMix 这是可行的, 并且应当能大幅提升整体效率。这些实验使用了四个 Intel Xeon Skylake 6130 CPU 和一个 NVIDIA TITAN RTX GPU。

5 讨论

我们提出了 MEMO, 一种通过自适应和增强在测试时对分布偏移进行鲁棒化的方法。MEMO 不需要访问或更改模型训练过程, 因此广泛适用于以多种不同方式预训练的各种模型架构。此外, MEMO 在测试时使用单个测试输入进行自适应, 因此它不像几种最近的测试时自适应方法那样假设可以访问多个测试点 [40, 46]。在一系列 CIFAR-10 和 ImageNet 分布偏移基准上, 对于 ResNet、视觉变换器以及在一定程度上 ResNext 模型, MEMO 在测试时持续提升性能, 并在单测试点设置下为这些模型取得了若干新的最先进结果。

通过 MEMO 进行推理比标准模型推理的计算成本更高, 这是由于其增强和适应过程所致——不过, 如上述实验所示, 通过减小 B (每个测试点的增强次数) 的值, 可以在效率与准确率之间实现更有利的权衡。未来工作的一个有趣方向是开发选择性确定何时调整模型的技术, 以实现更高效的推理。例如, 对于校准良好的模型 [10], 当预测置信度超过某个阈值时, 我们可以运行简单的“前馈”推理, 从而获得更好的效率。此外, 在允许模型随着更多测试数据的观测而持续适应的测试设置中探索 MEMO 也很有意义。我们在该设置下的初步实验中, MEMO 倾向于导致退化解, 例如模型无论输入如何都预测一个具有最大置信度的恒定标签。这种失败模式可能通过仔细选择要适应的参数来纠正, 例如仅适应 BN 层中的参数 [46], 或者对模型进行正则化, 使其与预训练模型相比不会发生过于剧烈的变化 [26]。

致谢与资助披露

我们感谢机器人人工智能与学习实验室和伯克利人工智能研究中心的成员提供的有益讨论和反馈。MZ 部分由 NDSG 奖学金支持。CF 是 CIFAR 研究员。本研究部分由 ARL DCIST CRA W911NF-17-2-0181 和 ARO W911NF-21-1-0097 资助。

参考文献

- [1] F. Alet, M. Bauza, K. Kawaguchi, N. Kuru, T. Lozano-Pérez, and L. Kaelbling. Tailoring: Encoding inductive biases by optimizing unsupervised objectives at prediction time. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.
- [2] A. Ashukha, A. Lyzhov, D. Molchanov, and D. Vetrov. Pitfalls of in-domain uncertainty estimation and ensembling in deep learning. In *International Conference on Learning Representations (ICLR)*, 2020.
- [3] A. Bartler, A. Bühler, F. Wiewel, M. Döbler, and B. Yang. MT3: Meta test-time training for self-supervised test-time adaption. In *International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2022.
- [4] A. Ben-Tal, D. den Hertog, A. De Waegenaere, B. Melenberg, and G. Rennen. Robust solutions of optimization problems affected by uncertain probabilities. *Management Science*, 2013.

- [5] G. Blanchard, G. Lee, and C. Scott. Generalizing from several related classification tasks to a new unlabeled sample. In *Advances in Neural Information Processing Systems (NIPS)*, 2011.
- [6] G. Csurka. Domain adaptation for visual applications: A comprehensive survey. *arXiv preprint arXiv:1702.05374*, 2017.
- [7] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations (ICLR)*, 2021.
- [8] Y. Grandvalet and Y. Bengio. Semi-supervised learning by entropy minimization. In *Advances in Neural Information Processing Systems (NIPS)*, 2005.
- [9] I. Gulrajani and D. Lopez-Paz. In search of lost domain generalization. In *International Conference on Learning Representations (ICLR)*, 2021.
- [10] C. Guo, G. Pleiss, Y. Sun, and K. Weinberger. On calibration of modern neural networks. In *International Conference on Machine Learning (ICML)*, 2017.
- [11] K. He, X. Zhang, S. Ren, and J. Sun. Deep residual learning for image recognition. In *Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.
- [12] D. Hendrycks and T. Dietterich. Benchmarking neural network robustness to common corruptions and perturbations. In *International Conference on Learning Representations (ICLR)*, 2019.
- [13] D. Hendrycks, N. Mu, E. Cubuk, B. Zoph, J. Gilmer, and B. Lakshminarayanan. AugMix: A simple data processing method to improve robustness and uncertainty. In *International Conference on Learning Representations (ICLR)*, 2020.
- [14] D. Hendrycks, S. Basart, N. Mu, S. Kadavath, F. Wang, E. Dorundo, R. Desai, T. Zhu, S. Parajuli, M. Guo, D. Song, J. Steinhardt, and J. Gilmer. The many faces of robustness: A critical analysis of out-of-distribution generalization. In *IEEE International Conference on Computer Vision (ICCV)*, 2021.
- [15] D. Hendrycks, K. Zhao, S. Basart, J. Steinhardt, and D. Song. Natural adversarial examples. In *Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021.
- [16] W. Hu, G. Niu, I. Sato, and M. Sugiyama. Does distributionally robust supervised learning give robust classifiers? In *International Conference on Machine Learning (ICML)*, 2018.
- [17] Y. Huang, J. Gornet, S. Dai, Z. Yu, T. Nguyen, D. Tsao, and A. Anandkumar. Neural networks with recurrent generative feedback. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.
- [18] Y. Iwasawa and Y. Matsuo. Test-time classifier adjustment module for model-agnostic domain generalization. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.
- [19] A. Kaku, S. Mohan, A. Parnandi, H. Schambra, and C. Fernandez-Granda. Be like water: Robustness to extraneous variables via adaptive feature normalization. *arXiv preprint arXiv:2002.04019*, 2020.
- [20] D. Kingma and J. Ba. Adam: A method for stochastic optimization. In *International Conference on Learning Representations (ICLR)*, 2015.
- [21] P. Koh, S. Sagawa, H. Marklund, S. Xie, M. Zhang, A. Balsubramani, W. Hu, M. Yasunaga, R. Phillips, I. Gao, T. Lee, E. David, I. Stavness, W. Guo, B. Earnshaw, I. Haque, S. Beery, J. Leskovec, A. Kundaje, E. Pierson, S. Levine, C. Finn, and P. Liang. WILDS: A benchmark of in-the-wild distribution shifts. In *International Conference on Machine Learning (ICML)*, 2021.
- [22] A. Krizhevsky. Learning multiple layers of features from tiny images. Technical report, University of Toronto, 2009.

- [23] A. Krizhevsky, I. Sutskever, and G. Hinton. ImageNet classification with deep convolutional neural networks. In *Advances in Neural Information Processing Systems (NIPS)*, 2012.
- [24] B. Li, F. Wu, S. Lim, S. Belongie, and K. Weinberger. On feature normalization and data augmentation. In *Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021.
- [25] Y. Li, N. Wang, J. Shi, J. Liu, and X. Hou. Revisiting batch normalization for practical domain adaptation. In *International Conference on Learning Representations Workshop (ICLRW)*, 2017.
- [26] Y. Liu, P. Kothari, B. van Delft, B. Bellot-Gurlet, T. Mordan, and A. Alahi. TTT++: When does self-supervised test-time training fail or thrive? In *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.
- [27] I. Loshchilov and F. Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations (ICLR)*, 2019.
- [28] D. Mahajan, R. Girshick, V. Ramanathan, K. He, M. Paluri, Y. Li, A. Bharambe, and L. van der Maaten. Exploring the limits of weakly supervised pretraining. In *European Conference on Computer Vision (ECCV)*, 2018.
- [29] C. Mao, M. Chiquier, H. Wang, J. Yang, and C. Vondrick. Adversarial attacks are reversible with natural supervision. In *IEEE International Conference on Computer Vision (ICCV)*, 2021.
- [30] X. Mao, G. Qi, Y. Chen, X. Li, R. Duan, S. Ye, Y. He, and H. Xue. Towards robust vision transformer. In *Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022.
- [31] D. Molchanov, A. Lyzhov, Y. Molchanova, A. Ashukha, and D. Vetrov. Greedy policy search: A simple baseline for learnable test-time augmentation. In *Conference on Uncertainty in Artificial Intelligence (UAI)*, 2020.
- [32] K. Muandet, D. Balduzzi, and B. Schölkopf. Domain generalization via invariant feature representation. In *International Conference on Machine Learning (ICML)*, 2013.
- [33] Z. Nado, S. Padhy, D. Sculley, A. D’Amour, B. Lakshminarayanan, and J. Snoek. Evaluating prediction-time batch normalization for robustness under covariate shift. *arXiv preprint arXiv:2006.10963*, 2020.
- [34] A. Orhan. Robustness properties of Facebook’s ResNeXt WSL models. *arXiv preprint arXiv:1907.07640*, 2019.
- [35] X. Peng, B. Usman, N. Kaushik, J. Hoffman, D. Wang, and K. Saenko. VisDA: The visual domain adaptation challenge. *arXiv preprint arXiv:1710.06924*, 2017.
- [36] J. Quiñero Candela, M. Sugiyama, A. Schwaighofer, and N. Lawrence. *Dataset Shift in Machine Learning*. The MIT Press, 2009.
- [37] B. Recht, R. Roelofs, L. Schmidt, and V. Shankar. Do CIFAR-10 classifiers generalize to CIFAR-10? *arXiv preprint arXiv:1806.00451*, 2018.
- [38] O. Russakovsky, J. Deng, H. Su, J. Krause, S. Satheesh, S. Ma, Z. Huang, A. Karpathy, A. Khosla, M. Bernstein, A. Berg, and F. Li. Imagenet large scale visual recognition challenge. *International Journal of Computer Vision (IJCV)*, 2015.
- [39] S. Sagawa, P. Koh, T. Hashimoto, and P. Liang. Distributionally robust neural networks for group shifts: On the importance of regularization for worst-case generalization. In *International Conference on Learning Representations (ICLR)*, 2020.
- [40] S. Schneider, E. Rusak, L. Eck, O. Bringmann, W. Brendel, and M. Bethge. Improving robustness against common corruptions by covariate shift adaptation. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.
- [41] H. Shimodaira. Improving predictive inference under covariate shift by weighting the log-likelihood function. *Journal of Statistical Planning and Inference (JSPI)*, 2000.

- [42] C. Shorten and T. Khoshgoftaar. A survey on image data augmentation for deep learning. *Journal of Big Data*, 2019.
- [43] P. Sivaprasad and F. Fleuret. Test time adaptation through perturbation robustness. *arXiv preprint arXiv:2110.10232*, 2021.
- [44] Y. Sun, X. Wang, Z. Liu, J. Miller, A. Efros, and M. Hardt. Test-time training with self-supervision for generalization under distribution shifts. In *International Conference on Machine Learning (ICML)*, 2020.
- [45] T. Varsavsky, M. Orbes-Arteaga, C. Sudre, M. Graham, P. Nachev, and M. Cardoso. Test-time unsupervised domain adaptation. *arXiv preprint arXiv:2010.01926*, 2020.
- [46] D. Wang, E. Shelhamer, S. Liu, B. Olshausen, and T. Darrell. Tent: Fully test-time adaptation by entropy minimization. In *International Conference on Learning Representations (ICLR)*, 2021.
- [47] G. Wilson and D. Cook. A survey of unsupervised deep domain adaptation. *ACM Transactions on Intelligent Systems and Technology (TIST)*, 2020.
- [48] E. Wong, L. Rice, and J. Kolter. Fast is better than free: Revisiting adversarial training. In *International Conference on Learning Representations (ICLR)*, 2020.
- [49] Y. Wu and K. He. Group normalization. In *European Conference on Computer Vision (ECCV)*, 2018.
- [50] S. Xie, R. Girshick, P. Dollár, Z. Tu, and K. He. Aggregated residual transformations for deep neural networks. In *Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017.
- [51] D. Yin, R. Lopes, J. Shlens, E. Cubuk, and J. Gilmer. A Fourier perspective on model robustness in computer vision. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2019.
- [52] M. Zhang, H. Marklund, A. Gupta, S. Levine, and C. Finn. Adaptive risk minimization: Learning to adapt to domain shift. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.

检查清单

1. 对于所有作者...

(a) 摘要和引言中提出的主要声明是否准确反映了论文的贡献和范围? [是]

(b) 您是否描述了工作的局限性? [是] 见第 5 节。

(c) 您是否讨论了您的工作可能产生的任何负面社会影响? [否]

(d) 您是否阅读了伦理审查指南,并确保您的论文符合这些指南? [是] 2. 如果您包含理论结果……

(a) 您是否陈述了所有理论结果的完整假设集? [N/A] (b) 您是否包含了所有理论结果的完整证明? [N/A] 3. 如果您进行了实验……

(a) 您是否包含了复现主要实验结果所需的代码、数据和说明(在补充材料中或作为网址)? [是] 请参见补充材料。

(b) 您是否指定了所有训练细节(例如,数据划分、超参数、它们是如何选择的)? [是] 请参见附录 A。(c) 您是否报告了误差线(例如,在多次运行实验后关于随机种子的)?

[N/A] (d) 您是否包含了所使用的总计算量和资源类型(例如, GPU 类型、内部集群或云提供商)? [否] 4. 如果您使用现有资产(例如,代码、数据、模型)或整理/发布新资产……

(a) 如果您的工作使用了现有资产,您是否引用了创建者? [是]

(b) 您是否提及了资产的许可证? [否] 所有资产都是公开且免费可用的。

(c) 您是否在补充材料中或作为网址包含了任何新资产? [否]

(d) 您是否讨论了如何从您正在使用或整理的数据所属的个人处获得同意? [N/A] (e) 您是否讨论了您正在使用或整理的数据是否包含个人信息或冒犯性内容? [N/A] 5. 如果您使用了众包或进行了涉及人类受试者的研究……

(a) 是否包含了提供给参与者的完整说明文本及截图(如有)适用吗? [N/A]

(b) 您是否描述了任何潜在的参与者风险,并在适用的情况下附上机构审查委员会(IRB)的批准链接? [N/A] (c) 是否包含了支付给参与者的估计时薪以及用于参与者补偿的总金额? [N/A]

A 实验方案

本文利用 CIFAR-10-C 和 ImageNet-C 提供的四个不相交验证损坏集 [12] 选择超参数。由于其他基准仅为测试集且未提供验证集，本文采用基于损坏验证集确定的超参数，且不进行额外调优。在执行网格搜索时，本文考虑了以下超参数。

- Learning rate η : 10^{-3} , 10^{-4} , 10^{-5} , 10^{-6} ; then, $5\times$, $2.5\times$, and $0.5\times$ the best value.
- 梯度步数: 1、2。
- 用于触发自适应的最大损失值百分比阈值: 50、100。
- 先验强度 N : 8, 16, 32.

除学习率与梯度步数外，我们还评估了一种简单的“阈值”策略：仅当边际熵大于最大值的 50% (ImageNet-C 为 $\log 1000$) 时才执行自适应，但发现这会导致验证性能略有下降。我们还考虑了单点批量归一化自适应中先验强度 N 的不同取值，发现 16 在验证集上表现最佳，这与 Schneider 等人 [40] 的建议一致。对于 ResNet 模型，我们使用随机梯度作为更新规则 G ；对于 ResNet-26 模型，我们设置增强次数 $B = 32$ 和学习率 $\eta = 0.005$ ；对于 ResNet-50 模型，我们设置 $B = 64$ 和 $\eta = 0.00025$ 。

对于 RVT * -small，我们在网格搜索中还考虑了以下超参数。

- 更新规则 G ：随机梯度、Adam[20, 27]。
- 权重衰减: 0.0, 0.1。
- 先验强度 N : 1, 2, 4, 8, 16, 32, ∞ (即不进行单点批量归一化自适应)。

基于 ImageNet-C 验证集，我们采用 AdamW[27] 作为更新规则 G ，学习率为 $\eta = 0.00001$ ，权重衰减为 0.01，以及 $B = 64$ 。对于 ResNext-101 模型，我们使用相同的超参数，未进行额外调优，但由于内存限制，我们使用 $B = 32$ 。

在 CIFAR 评估中，我们与 TTT 进行比较，如前所述，TTT 也可应用于单个测试输入，但需要专门的训练过程 [44]。因此，我们方法所使用的 ResNet-26 模型严格遵循 Sun 等人 [44] 提出的修改，以提供公平的比较点。特别是，Sun 等人 [44] 选择使用组归一化 [49] 而非批归一化，因此单点批归一化自适应不适用于该模型架构。如前所述，TTT 还需要联合训练一个单独的旋转预测头，从而进一步改变模型架构，而 MEMO 直接适配标准预训练模型。

TTA 结果使用与 MEMO 相同的 AugMix 增强获得。单点批归一化自适应结果使用 $N = 16$ ，如 Schneider 等人 [40] 所建议。如前所述，批归一化自适应结果（使用多个测试点）使用 $N = 256$ 作为先验强度，并以 256 个测试输入为批次进行自适应。对于 Tent，我们使用 Wang 等人 [46] 建议的超参数：随机梯度，学习率 0.00025，动量 0.9。自适应使用 64 个输入的测试批次进行——对于 Tent 的在线版本，预测和自适应同时发生，模型在整个测试轮次中持续自适应。由于 Wang 等人 [46] 未对变换器模型进行实验，我们还尝试使用 Adam[20] 和 AdamW[27] 以及上述针对 RVT * -small 模型的各种超参数运行 Tent；然而，我们发现这通常导致性能比使用随机梯度更新更差。

基线 ResNet-50 和 ResNext-101 (32x8d) 参数直接从 torchvision 库获取。使用 DeepAugment 和 AugMix 训练的 ResNet-50 参数从 https://drive.google.com/file/d/1QKmc_p6-qDkh51WvsaS9HKFv8bX5jLnP 获取。使用矩交换和 CutMix 训练的 ResNet-50 参数从 <https://drive.google.com/file/d/1cCvhQKV93pY-jj8f5jITywkB9EabiQDA> 获取。小型鲁棒视觉变换器 (RVT * -small) 模型参数从 <https://drive.google.com/file/d/1g40huqDVthjS2H5sQV3ppcfWEzn9ekv> 获取。使用 WSL 训练的 ResNext-101 (32x8d) 参数从 https://download.pytorch.org/models/ig_resnext101_32x8-c38310e5.pth 获取。

表 5: 评估批大小为 1 的 Tent 情景版本, 这对应于测试时鲁棒性设置下的简单熵最小化方法。该方法也使用单点批归一化自适应, 熵最小化并未提供太多额外增益。

	ImageNet-C 错误率 (%)	ImageNet-R 错误率 (%)	ImageNet-A mCE ↓
Baseline ResNet-50 [11]	76.7	63.9	100.0
+ Single point BN	71.4 (−5.3)	61.1 (−2.8)	99.4 (−0.6)
+ MEMO (ours)	69.9 (−6.8)	58.8 (−5.1)	99.1 (−0.9)
+ Tent (episodic, batch size 1) [46]	70.4 (−6.3)	60.0 (−3.9)	99.3 (−0.7)
+ DeepAugment+AugMix [14]	53.6	53.2	96.1
+ Single point BN	51.3 (−2.3)	51.2 (−2.0)	95.4 (−0.7)
+ MEMO (ours)	49.8 (−3.8)	49.2 (−4.0)	94.8 (−1.3)
+ Tent (episodic, batch size 1)	50.7 (−2.9)	50.7 (−2.5)	95.2 (−0.9)
+ MoEx+CutMix [24]	74.8	64.5	91.9
+ Single point BN	71.0 (−3.8)	62.6 (−1.9)	91.1 (−0.8)
+ MEMO (ours)	69.1 (−5.7)	59.4 (−3.3)	89.0 (−2.9)
+ Tent (episodic, batch size 1)	69.9 (−4.9)	61.7 (−2.8)	90.6 (−1.3)
RVT*-small [30]	49.4	52.3	73.9
+ Single point BN	48.0 (−1.4)	51.1 (−1.2)	74.4 (+0.5)
+ MEMO (ours)	40.6 (−8.8)	43.8 (−8.5)	69.8 (−4.1)
+ Tent (episodic, batch size 1)	47.9 (−1.5)	50.9 (−1.4)	74.4 (+0.5)

表 6: 消融增强函数以测试标准增强（随机缩放裁剪和水平翻转）。当改变所使用的增强时, 适应后的性能通常变化不大, 但在 CIFAR-10-C 上损失最大。

	CIFAR-10 Error (%)	CIFAR-10.1 Error (%)	CIFAR-10-C Average Error (%)
ResNet-26 [11]	9.2	18.4	22.5
+ MEMO (ours)	7.3 (−1.9)	14.7 (−3.7)	19.6 (−2.9)
– AugMix [13] + standard augs	7.2 (−2.0)	14.6 (−3.8)	20.2 (−2.3)

B 增强分析

人们可能会问: 首先是否需要增强? 在测试时鲁棒性设置中, 当只有一个测试点可用时, 简单的熵最小化会如何表现? 我们在表 5 中通过评估 Tent 的情景变体 (即每个批次后重置模型) 来回答这个问题, 测试批大小为 1。这种方法也类似于不使用增强的 MEMO 变体, 因为对于一个测试点且没有增强副本, 条件熵和边际熵是相同的。与 MEMO 类似, 我们还结合了单点 BN 适应 $N = 16$, 代替 Tent 通常使用测试输入批次进行的标准 BN 适应。表 5 的结果表明, 对单个测试点进行熵最小化通常仅比单点 BN 适应提供边际性能提升。这从经验上表明, 使用增强对于实现所报告的结果很重要。

我们还希望了解增强函数选择的重要性 $\mathcal{A}$ 。如前所述, 我们在之前的实验中使用了 **AugMix**[13], 因为它最符合我们的标准: **AugMix** 只需要输入 $\mathbf{x}$, 随机采样的增强会产生多样化的增强数据点。一个简单的替代方案是使用 ImageNet 训练中常用的“标准”增强集, 即随机缩放裁剪和随机水平翻转。我们也在 CIFAR-10 测试集上评估了使用标准增强的 MEMO 消融, 同样使用相同的超参数值。从表 6 的结果可以看出, MEMO 在更简单的增强函数下仍然有效。特别是在没有测试偏移的情况下 (如原始 CIFAR-10 测试集) 或细微偏移 (如 CIFAR-10.1) 中尤其如此; 然而, 对于更严重和系统性的 CIFAR-10-C 偏移, 使用更重的 **AugMix** 数据增强会带来更大的

相较于标准增强，性能有所提升。此外，该消融实验使用 ResNet-26 模型进行，该模型采用标准增强训练——对于表 2 中的鲁棒模型，AugMix 在测试时可能提供更大优势，因为这些模型在训练期间经历了重度增强。

C 完整的 CIFAR-10-C 和 ImageNet-C 结果

在以下表格中，我们按损坏类型和级别展示了 CIFAR-10-C 上表 1 所评估方法的测试结果。我们省略了联合训练和 TTT，因为这些结果可从 Sun 等人 [44] 处获得。我们在 ImageNet-C 上的测试结果见补充材料中的 CSV 文件。

表 7: CIFAR-10-C 第 5 级损坏的测试误差 (%)。

	高斯噪声	散粒噪声	脉冲噪声	散焦	玻璃模糊	运动模糊	缩放	雪	霜	雾	亮度	对比度	弹性变换	像素化	压缩
ResNet-26	48.4	44.8	50.3	24.1	47.7	24.5	24.1	24.1	33.1	28.0	14.1	29.7	25.6	43.7	28.3
+ TTA	43.4	39.6	42.9	28.3	44.7	26.3	26.3	21.4	28.5	23.3	12.1	32.9	21.7	43.2	21.7
+ MEMO (ours)	43.5	39.8	43.3	26.4	44.4	25.1	25.0	20.9	28.3	22.8	11.9	28.3	21.1	42.8	21.7

表 8: CIFAR-10-C 第 4 级损坏的测试误差 (%)。

	高斯噪声	散粒噪声	脉冲噪声	散焦	玻璃模糊	运动模糊	缩放	雪	霜	雾	亮度	对比度	弹性变换	像素化	压缩
ResNet-26	43.8	37.2	39.3	14.8	48.0	19.9	18.7	22.0	24.9	15.1	11.4	16.8	19.1	27.9	24.9
+ TTA	39.5	32.0	31.8	15.4	45.0	20.9	20.2	18.9	21.7	12.9	9.3	16.8	17.7	25.7	18.9
+ MEMO (ours)	39.7	32.3	32.2	14.7	45.0	20.0	19.2	18.7	21.1	12.5	9.3	15.2	16.9	25.2	18.9

表 9: CIFAR-10-C 第 3 级损坏的测试误差 (%)。

	高斯噪声	散粒噪声	脉冲噪声	散焦	玻璃模糊	运动模糊	缩放	雪	霜	雾	亮度	对比度	弹性变换	像素化	压缩
ResNet-26	40.0	33.8	26.4	11.5	37.3	20.0	16.6	20.0	24.7	12.2	10.5	13.6	15.0	18.4	22.7
+ TTA	34.3	27.7	20.3	11.3	32.9	20.7	16.7	16.3	21.1	9.8	8.5	12.5	13.7	14.5	17.2
+ MEMO (ours)	34.4	27.9	20.5	10.8	32.8	19.8	16.1	16.1	20.9	9.6	8.6	11.7	13.2	14.5	17.2

表 10: CIFAR-10-C 第 2 级损坏的测试误差 (%)。

	高斯噪声	散粒噪声	脉冲噪声	散焦	玻璃模糊	运动模糊	缩放	雪	霜	雾	亮度	对比度	弹性变换	像素化	压缩
ResNet-26	30.1	21.8	21.1	9.7	38.3	15.3	13.8	21.2	17.6	10.5	9.7	11.6	12.9	15.4	21.3
+ TTA	25.3	16.9	15.8	8.5	33.8	15.3	13.7	17.8	14.5	8.7	7.8	10.0	11.0	12.0	16.1
+ MEMO (ours)	25.3	16.9	15.9	8.4	33.5	14.6	13.0	17.7	14.4	8.5	7.7	9.6	10.7	11.9	16.2

表 11: CIFAR-10-C 一级损坏的测试误差 (%)。

	高斯噪声	散粒噪声	脉冲噪声	散焦	玻璃模糊	运动模糊	缩放	雪	霜	雾	亮度	对比度	弹性变换	像素化	压缩
ResNet-26	20.8	16.5	15.8	9.2	38.9	11.8	12.8	13.9	13.4	9.7	9.4	9.6	13.1	12.0	16.4
+ TTA	15.8	12.8	11.8	7.3	35.1	10.8	12.5	11.0	10.8	7.4	7.4	7.7	11.4	9.2	12.5
+ MEMO (ours)	16.1	12.9	11.9	7.4	34.7	10.4	12.1	11.0	10.7	7.4	7.3	7.5	10.9	9.2	12.5