

ORPA: 面向机器人操作控制的 在线残差策略自适应与人类反馈

Muhammad A. Muttaqien* Tomohiro Motoda* Ryo Hanai Yukiyasu Domae

Embodied AI Research Team, National Institute of AIST, Tokyo, Japan

muha.muttaqien@aist.go.jp tomohiro.motoda@aist.go.jp ryo.hanai@aist.go.jp domae.yukiyasu@aist.go.jp

摘要——通过模仿学习训练的机器人操作策略，例如基于变换器的动作分块（ACT），在理想条件下能够实现较强的性能，但通常对微小的执行误差和分布偏移仍然敏感。纠正这些失败通常需要数据集聚合和全策略重训练，这在计算上代价高昂，且不适合实时部署。在本文中，我们提出了在线残差策略自适应（ORPA）框架，该框架能够在不修改底层策略参数的情况下，实现即时的、由反馈驱动的机器人动作纠正。ORPA 通过一个轻量级的、以反馈为条件的模块来增强预训练的控制策略，该模块直接在关节空间中预测残差调整量，从而使系统能够在运行时调整其行为。我们在 ALOHA 平台上对一组精度敏感的操纵任务评估了 ORPA，结果表明，与基线控制策略和基于规则的逆运动学纠正相比，ORPA 在成功率和从小扰动中恢复的能力方面均有提升。索引词——机器人控制，机器人操作，模仿学习，人类反馈集成

1. 引言

模仿学习的最新进展使机器人操作系统能够在广泛的任务中实现令人印象深刻的性能 [1], [2]。特别是，基于变换器的策略，如基于变换器的动作分块（ACT），已经展示了直接从人类演示中学习长时操作行为的强大能力。结合低成本的双臂机器人平台（如 ALOHA），这些方法加速了向可扩展且易于获取的机器人学习系统方向的研究。尽管取得了这些进展，模仿学习策略在实际部署中仍然常常对微小的执行误差、环境变化和分布偏移高度敏感。在实际的机器人操作场景中，即使末端执行器在位置、方向或时间上的微小偏差也可能导致任务失败。这个问题在精度敏感的任务中尤为关键，例如杂乱物体抓取、狭窄空间中的拾取与放置以及协调的双臂操作，在这些任务中，微小的空间偏移可能导致碰撞、不稳定的抓取或物体操作失败

迁移。尽管预训练策略在标称条件下可能达到较高的成功率，但当物体发生轻微位移、视角变化或执行条件偏离训练分布时，其性能可能下降。提升策略鲁棒性的常见方法是收集额外演示，并利用数据集聚合（Dataset Aggregation）技术重新训练或微调策略 [3] – [5]。虽然有效，但基于重新训练的流程计算成本高，需要反复收集数据，且通常不适合交互或实时机器人部署。此外，即使失败仅源于局部执行误差，这些方法通常也会修改整个策略网络。另一种直接替代方案是利用正运动学和逆运动学进行基于规则的几何校正，将“太左”或“太高”等反馈信号转换为预定义的末端执行器偏移量，并投影回关节空间。尽管直观，但此类方法假设相同反馈始终对应相同校正行为，而实际上适当的校正往往取决于任务阶段、物体配置和执行上下文。因此，基于重新训练的适应方法和固定规则校正方法都难以提供高效灵活的实时适应。ORPA 不修改底层策略参数，而是通过一个以反馈为条件的残差模块增强预训练控制策略，该模块直接在关节空间中预测校正动作调整。给定当前策略输出和外部反馈，所提出的模块产生时间一致的残差校正，在执行过程中细化机器人行为，同时保持原始策略性能。与基于重新训练的方法不同，ORPA 无需对基础策略进行额外优化即可实现即时适应。此外，通过学习残差校正而非依赖预定义几何规则，所提出的框架能够捕捉超越简单末端执行器偏移的上下文相关和行为级调整。我们在 ALOHA 平台上对一组精度敏感的机器人操作任务评估了 ORPA。

¹ 这些作者对本文贡献相同。




图 1: 所提出的 ORPA 概览。由人类反馈生成的在线残差校正细化预训练 ACT 动作，以实现鲁棒操作。

我们的实验聚焦于微小执行误差会显著影响任务成功的场景，包括空间扰动和协调敏感的双臂任务。实验结果表明，与基线动作分块变换器策略和基于规则的逆运动学校正方法相比，在线残差策略适应显著提升了任务鲁棒性和恢复性能。

II. 相关工作

模仿学习 (Imitation Learning) 已成为机器人操作的主导范式之一，因其能够直接从人类演示中学习复杂行为 [6]。基于变换器 (Transformer) 架构的最新进展显著提升了操作策略对序列动作和多模态观测的建模能力。特别是，动作分块变换器 (Action Chunking with Transformers, ACT) 引入了动作分块策略，用于在双臂机器人操作任务中实现高效且稳定的策略学习。结合 ALOHA 等平台，这些方法实现了可扩展的操作演示采集，并在多种桌面任务中展现出强大性能。然而，尽管模仿学习策略有效，它们在部署过程中往往对微小的分布偏移和执行扰动仍然敏感。多项研究探索了通过在线适应和迭代优化来提升策略鲁棒性的方法。一种常见策略是数据集聚合 (Dataset Aggregation) 与策略重训练，通过纳入新的演示或校正样本以改善未来性能。代表性方法如 DAgger [3] 和 HG-DAgger [7] 迭代地收集校正监督，以减少策略执行过程中的复合误差。更近期的方法研究了通过反馈驱动的更新和持续学习 (Continual Learning) 机制实现机器人操作的在线策略适应。然而，其中许多方法需要昂贵的优化过程、反复重训练或修改底层策略参数，限制了它们在实时机器人系统中的应用。在近期工作中，OLAF [8] 和 YAY Robot [9] 引入了一种交互式学习框架，将人类口头校正纳入机器人操作。OLAF 展示了语言引导的校正监督和离线策略优化

通过迭代数据收集和微调改进机器人行为的另一种常见策略是使用基于规则的正向和逆向运动学几何校正，将人类反馈或任务误差映射为预定义的末端执行器偏移量，并通过逆向运动学求解器转换回关节空间动作。虽然此类方法对于简单的局部调整直观且计算高效，但它们假设相同的反馈始终对应相同的校正行为。然而在实践中，适当的校正往往取决于任务阶段、物体配置、机器人姿态和执行上下文。例如，相同的反馈信号（如“太靠左”）在物体接近、抓取或放置阶段可能需要不同的校正幅度。与先前方法相比，ORPA 结合了轻量级在线适应的高效性与基于学习的残差校正的灵活性。通过以人类反馈为条件校正动作，同时保留预训练的操控策略，ORPA 实现了实时行为细化，无需全策略重训练或人工设计校正规则。

三、实验设置

所提出的在线残差策略自适应 (ORPA) 框架如图 1 所示，在仿真和真实环境中使用 ALOHA 平台进行了评估。实验设置包括一个具有视觉和关节状态信息的双臂双手操控系统，以及需要协调控制和严格公差规格的精密操控任务。本节描述了整个实验中使用的实验设置。

A. ALOHA 仿真

仿真实验使用基于 MuJoCo 的 [10] ALOHA 仿真环境进行，该环境与 ACT 框架集成。仿真器模拟了一个同步双臂操控系统，由两个具有平行夹爪的六自由度机械臂组成，产生包含夹爪驱动的 14 维关节空间动作表示。环境以 50 Hz 的控制频率运行。

B. ALOHA 工作空间

真实世界实验采用 ALOHA 平台进行，该平台是一个双臂机器人操控系统，专为双手模仿学习与操控研究而设计。系统配置包括两台协作机械臂、平行夹爪以及多视角 RGB 视觉装置，具体如下所述。

- **机械臂：**真实世界机器人平台基于 ALOHA 系统构建，由两台同步的六自由度机械臂组成，配置用于




图 2: 所提出的在线残差策略自适应 (ORPA) 框架的训练流程。左图: 预训练的动作分块 Transformer (ACT) 策略根据视觉观测和机器人状态生成标称关节空间动作。引入结构化扰动以产生合成误差及相应的纠正反馈标签。右图: 反馈编码器 (FE) 与策略更新器 (PU) 被训练用于在 RGB 图像、机器人状态、错误动作和人类反馈的条件下预测残差动作修正。预测残差通过扰动动作与参考动作之间的差异进行监督。

双手操控任务。双臂均通过基于 ROS 的 [11] 关节空间接口以 50 赫兹频率控制, 提供包含夹爪驱动的 14 维联合控制空间。ACT 预测分块关节轨迹, 而 ORPA 在执行过程中在线生成残差关节空间修正。

- **夹爪:** 每台机械臂配备平行夹爪, 支持可变宽度抓取, 既能实现捏取也能实现包络抓取。夹爪支持实时驱动控制, 并直接集成到策略动作表示中, 以实现协调的双手操控。

- **视觉系统:** 该平台利用四个同步的 RGB 相机, 包括两个腕部相机和两个外部桌面相机, 提供工作空间的多视角观测。所有 RGB 图像被调整为 640×480 分辨率, 并直接由 ACT 视觉编码器处理, 无需显式的目标检测模块。

四、在线残差策略自适应

所提出的在线残差策略自适应 (ORPA) 框架建立在预训练的基于变换器的动作分块 (ACT) 策略之上, 作为底层操控控制器。ACT 是一种模仿学习框架, 从多模态观测 (包括多视角 RGB 图像和机器人关节状态) 中预测时间上连贯的关节空间动作块。通过预测动作序列而非单个低级命令, ACT 能够实现长时程操控任务的平滑稳定执行。在本工作中, ACT 作为冻结的基础策略, 在 ORPA 训练或部署期间不被修改。

给定当前观测 o_t , ACT 预测未来动作块 $\hat{a}_{t:t+k}$, 提供标称操控行为。虽然 ACT 在标称条件下表现出强大的性能, 但在部署期间出现执行误差、物体扰动或分布偏移时, 其性能可能下降。ORPA 通过引入反馈条件残差自适应模块来解决这一局限性, 该模块在线细化 ACT 动作, 无需重新训练底层策略, 非常适合实时校正。

A. ORPA 架构

图 2 展示了所提出的 ORPA 框架的整体架构。该框架由预训练的 ACT 策略、反馈编码器和策略更新模块组成。在执行过程中, ACT 首先基于当前视觉观测和机器人状态生成标称动作块 $\hat{a}_{t:t+k}$ 。同时, 人类操作员提供的外部校正反馈被编码为紧凑的潜在表示。编码后的反馈与当前机器人状态、视觉观测和 ACT 预测相结合, 以估计残差动作校正 Δa_t 。ORPA 不替换原始 ACT 输出, 而是通过将预测的校正添加到 ACT 动作上来执行残差自适应:

$$a_{t:t+k}^{final} = \hat{a}_{t:t+k} + \Delta a_t \quad (1)$$

其中 $\hat{a}_{t:t+k}$ 表示名义动作分块变换器 (Action Chunking Transformer, ACT) 预测值, Δa_t 表示以反馈为条件的残差校正量。该残差公式保留了动作分块变换器学习到的原始操作行为, 同时允许在执行过程中进行局部校正调整。由于在线残差策略自适应 (Online Residual Policy Adaptation, ORPA) 直接在关节空间中运行, 校正动作可以

无需显式的前向或逆向运动学计算即可施加。

B. 反馈编码器与策略更新器

为实现在线校正自适应，在线残差策略自适应引入了两个轻量级基于变换器（Transformer）的组件：反馈编码器（Feedback Encoder）和策略更新器（Policy Updater）。反馈编码器将人类校正反馈转换为适合策略自适应的潜在表示。在训练和评估过程中，反馈以离散或连续信号的形式表示。离散反馈使用诸如“太左”“太右”“太高”和“良好”等分类指令，而连续反馈则以数值方式编码校正方向和幅度。这些反馈信号由人类观察者在机器人初次尝试未能成功执行任务后立即提供。每个反馈信号首先被表示为一个离散标记，然后映射到可学习的嵌入空间中。设 f_t 表示时间步 t 处的反馈信号。反馈编码器生成潜在反馈表示：

$$r_t = f_\psi(f_t) \quad (2)$$

其中 r_t 捕获校正指令的语义含义。策略更新器接收编码后的反馈表示以及当前机器人观测和动作分块变换器预测值。该模块预测残差动作校正量：

$$\Delta a_t = g_\omega(r_t, o_t, a_{t:t+k}) \quad (3)$$

其中 o_t 表示当前观测值， $a_{t:t+k}$ 表示与当前操作上下文相关联的动作轨迹。通过将残差动作同时以反馈和执行上下文为条件，在线残差策略自适应能够生成上下文相关的校正量，其幅度和方向随任务阶段、物体配置和机器人状态而变化。这与基于规则的逆向运动学方法不同，后者无论执行上下文如何都施加相同的校正。

C. 合成数据生成

从人类操作员收集大规模纠正性演示既昂贵又耗时。为克服这一局限性，ORPA 从成功演示轨迹中自动生成纠正性训练样本。如图 3 所示，首先通过遥操作收集成功的操作轨迹，并用于训练 ACT 策略。随后，通过在预定义范围内修改物体的位置和方向，向操作环境中引入受控扰动。这些扰动制造出与部署过程中常见执行错误相似的失败场景。对于每个扰动，根据扰动方向分配相应的反馈标签。例如，物体向左位移被标记为“过于”

Algorithm 1 ACT Training

```

1: Given: Demo dataset  $\mathcal{D}$ , chunk size  $k$ , weight  $\beta$ .
2: Let  $a_t, o_t$  represent action and observation at timestep  $t$ ,  $\bar{o}_t$  represent  $o_t$  without image observations.
3: Initialize encoder  $q_\phi(z | a_{t:t+k}, \bar{o}_t)$ 
4: Initialize decoder  $\pi_\theta(\hat{a}_{t:t+k} | o_t, z)$ 
5: for iteration  $n = 1, 2, \dots$  do
6:   Sample  $o_t, a_{t:t+k}$  from  $\mathcal{D}$ 
7:   Sample  $z$  from  $q_\phi(z | a_{t:t+k}, \bar{o}_t)$ 
8:   Predict  $\hat{a}_{t:t+k}$  from  $\pi_\theta(\hat{a}_{t:t+k} | o_t, z)$ 
9:    $\mathcal{L}_{\text{reconst}} = \text{MSE}(\hat{a}_{t:t+k}, a_{t:t+k})$ 
10:   $\mathcal{L}_{\text{reg}} = D_{KL}(q_\phi(z | a_{t:t+k}, \bar{o}_t) \| \mathcal{N}(0, I))$ 
11:  Update  $\theta, \phi$  with ADAM and  $\mathcal{L} = \mathcal{L}_{\text{reconst}} + \beta \mathcal{L}_{\text{reg}}$ 
12: end for

```

左侧，而向上位移则被标记为过高。由此构建的数据集包含扰动后的观测、纠正性反馈标签，以及从原始成功演示中获取的对应参考动作。残差纠正目标计算为参考动作与扰动动作之间的差值：

$$\Delta a_t^* = a_t^{\text{ref}} - a_t^{\text{perturbed}} \quad (4)$$

其中 a_t^{ref} 表示来自成功轨迹的动作， $a_t^{\text{perturbed}}$ 表示与扰动执行相关的动作。该过程能够可扩展地生成纠正性监督，而无需额外的遥操作演示。

D. 训练目标

ORPA 在保持 ACT 策略固定的情况下进行训练。训练期间，预训练的 ACT 策略首先根据当前观测预测一个标称动作块。随后，反馈编码器和策略更新器基于反馈信号和执行上下文估计残差校正。最终校正后的动作计算如下：

$$a_{t:t+k}^{\text{final}} = \hat{a}_{t:t+k} + \Delta a_t \quad (5)$$

残差自适应模块通过修正动作与参考动作之间的均方误差目标进行优化：

$$L_{\text{ORPA}} = \frac{1}{N} \sum_{i=1}^N \|a_i^{\text{final}} - a_i^{\text{ref}}\|^2 \quad (6)$$

where a_i^{ref} 表示从原始成功演示中获得的目标动作。完整训练流程总结于算法 2 中。由于仅优化反馈编码器（Feedback Encoder）与策略更新器（Policy Updater），ORPA 在保留原始 ACT 策略参数的同时，仅引入极小的计算开销。

Algorithm 2 ORPA Training with Pretrained ACT Policy

- 1: **Given:** Pretrained ACT policy π_θ , feedback dataset $\mathcal{D}_f$.
- 2: Initialize feedback encoder f_ψ .
- 3: Initialize policy updater g_ω .
- 4: **for** iteration $n = 1, 2, \dots$ **do**
- 5: Sample $(o_t, f_t, a_{t:t+k})$ from $\mathcal{D}_f$
- 6: Predict ACT action chunk: $\hat{a}_{t:t+k} = \pi_\theta(o_t)$
- 7: Encode feedback signal: $r_t = f_\psi(f_t)$
- 8: Predict residual correction: $\Delta a_t = g_\omega(r_t, o_t, a_{t:t+k})$
- 9: Apply residual correction: $\hat{a}_{t:t+k}^{\text{final}} = \hat{a}_{t:t+k} + \Delta a_t$
- 10: Compute residual loss: $\mathcal{L}_{\text{ORPA}} = \text{MSE}(\hat{a}_{t:t+k}^{\text{final}}, a_{t:t+k})$
- 11: Update ψ, ω with ADAM
- 12: **end for**

表 I: ORPA 训练所使用的超参数。

ORPA Training	
Batch Size	8
Chunk Size	100
KL Weight	10
Learning Rate	1e-5
Number of Epochs	2000
ORPA (Feedback Encoder)	
Embedding Dimension	32
Hidden Dimension	128
Output Dimension	64
Learning Rate	1e-5
ORPA (Policy Updater)	
Action Dimension	14
Feedback Dimension	64
Hidden Dimension	128
Number of Attention Heads	6
Number of Layers	2
Learning Rate	1e-5

五、实验与分析

A. 任务

本文在 ALOHA 平台上评估了所提出的 ORPA 框架在多个精度敏感的双手操作任务中的表现 [19] – [21]。评估任务包括精密拾放、杂乱物体抓取、受限放置以及协调双手操作场景。选择这些任务是因为微小的空间或时间偏差会显著影响任务成功率。评估过程中，物体位姿相对于演示轨迹被随机扰动，以模拟现实的分布偏移和执行误差。任务执行期间在线提供“太左”“太右”“太高”等纠正性反馈信号，以评估残差动作级自适应的有效性。




图 3: 用于 ORPA 训练的合成操作误差生成。物体在预定义工作空间边界内随机初始化（上行），首先收集成功演示作为参考轨迹（良好）。随后对目标物体位姿引入笛卡尔扰动，产生失败场景（太左和太远）。

B. ACT 超参数调优

ACT 策略采用基于变换器（Transformer）架构的分块关节空间动作预测进行训练。动作块大小设置为 100 个控制步，策略更新频率为 50 Hz。分辨率 640×480 的多视角 RGB 观测通过卷积视觉骨干网络编码后与本体感受机器人状态融合。超参数根据验证成功率和操作执行过程中的轨迹稳定性进行选择。详细超参数设置总结于表一。

C. 实验结果

实验表明，与基线 ACT 策略和基于规则的逆运动学（IK）校正方法相比，所提出的 ORPA 框架在微小执行扰动和分布偏移下提高了操作鲁棒性。如表二所示，ORPA 始终取得更高的成功率

在所有评估任务中。对于立方体转移任务，原始动作分块 Transformer 策略在失败条件下实现了 60.0% 的成功率，而在线残差策略对齐使用离散和连续反馈分别将性能提升至 92.3% 和 91.7%。在双手插入任务中也观察到类似的改进，成功率从 60.0% 提高到 80.3% 和 84.7%。双手插入任务比立方体转移更具挑战性，因为其几何约束更严格。立方体转移仅要求接收夹爪牢固地握住立方体，而成功插入需要精确的销钉-目标对齐和物理接触，使得该任务对小的位置、旋转和时间误差的容忍度显著降低。尽管如此，在线残差策略对齐相对于基线动作分块 Transformer 策略保持了显著的性能提升，证明了其在精度敏感的操控场景中的有效性。在线残差策略对齐还一致地优于基于规则的逆运动学基线。固定逆运动学假设相同的反馈应产生相同的纠正运动，当实际误差幅度变化时可能导致过度纠正或纠正不足。相比之下，在线残差策略对齐直接从视觉输入、机器人状态和策略输出中预测以反馈为条件的残差动作，在执行过程中无需正逆运动学转换即可实现上下文相关的纠正。基于规则的逆运动学也缺乏任务阶段意识，在接近、抓取、提升或转移过程中应用相同的纠正。通过从演示轨迹中学习，在线残差策略对齐隐式地捕获任务上下文，并能相应地调整纠正强度。结合平移和旋转反馈的结果进一步证明了该方法的灵活性，尽管由于额外的方向约束，旋转纠正仍然更具挑战性。

D. 与在线潜在因子对齐的比较

我们还将 ORPA 与 OLAF 进行了比较，OLAF 是一种基于语言的修正框架，通过大语言模型（LLM）推理融入人类反馈。当适配于在线修正时，OLAF 的成功率达到 78.5%，证明了反馈引导的操作恢复的有效性。然而，其性能仍低于所提出的 ORPA 框架。OLAF 在实时部署中的一个关键局限是推理延迟，因为每次修正都需要额外的 LLM 推理步骤。此外，修正决策是在单个执行步骤上生成的，而不是直接针对动作轨迹，这可能会降低操作过程中的时序一致性。OLAF 还需要一个正向运动学和逆向运动学转换流程，将反馈转化为可执行动作。相比之下，ORPA 直接在关节空间中预测残差修正，并作用于 ACT 生成的块状动作轨迹。

表 II：仿真中故障条件下的性能。所有方法在正常条件下均达到 90.0%（立方体转移）和 84.0%（双手插入）的成功率。

Method	Feedback	Data Type	Failures
Cube Transfer (Sim)			
Original ACT	Translation	–	60.0%
ACT + ORPA (Ours)	Translation	Discrete	92.3%
ACT + ORPA (Ours)	Translation	Continuous	91.7%
ACT + ORPA (Ours)	Trans. + Rotation	Discrete	85.9%
ACT + Rule-based IK	Translation	Discrete	81.0%
ACT + Rule-based IK	Translation	Continuous	76.0%
ACT + OLAF	Translation	–	78.5%
Bimanual Insertion (Sim)			
Original ACT	Translation	–	60.0%
ACT + ORPA (Ours)	Translation	Discrete	80.3%
ACT + ORPA (Ours)	Translation	Continuous	84.7%

六、真实世界验证

A. 部署设置

为了评估所提出的 ORPA 框架的实用性，我们将系统部署在真实世界的 ALOHA 机器人平台上。实验在三个对精度敏感的操作任务上进行：零食盒转移、薯片筒开启和物体分类。这些任务需要精确抓取、协调运动和精确的物体交互，使其适合评估真实世界条件下的在线修正适应能力。原始的 ACT 策略使用每个任务 100 次成功的遥操作演示进行训练。训练后的 ACT 策略表现出强大的操作能力，并能在某些情况下执行有限的恢复行为。例如，当物体抓取最初失败时，策略偶尔会重新尝试抓取并成功完成任务。为了训练 ORPA 模块，即反馈编码器和策略更新器，使用两种策略生成修正数据：（1）仅动作扰动，以及（2）动作扰动结合扰动观测。

B. 任务评估

表 III 总结了原始 ACT 策略与所提出的 ORPA 变体在三个操作任务上的实际性能：零食盒转移、薯片筒开启和物体分拣。每个任务在 30 次试验中通过任务完成评分进行评估，完全成功得分为 1.0，部分完成得分为 0.5。部分得分分配给中间结果，例如成功抓取但未成功放置。结果表明，原始 ACT 策略在所有任务上已经取得了较强的性能。这一观察与定性发现一致，即 ACT 表现出一定程度的鲁棒性，并且偶尔能从执行失败中恢复，例如在初次未命中后重新尝试抓取物体。此类行为




图 4：所提出的 ORPA 框架在三个真实世界操作任务上的定性结果：零食盒转移、薯片筒开启和物体分拣。每个序列展示了初始化阶段以及随后的关键操作子任务。带有绿色框的子任务表示通常发生在线适应的子任务。

表明 ACT 在训练分布内具备插值能力。

表 III：真实世界任务性能。部分任务完成得分为 0.5，完全任务成功得分为 1.0。注意，原始 ACT 在正常条件下评估，没有引入故障。

Method	Transfer	Open	Sort
Original ACT	0.83	0.79	0.80
ACT + ORPA (Action Only)	0.85	0.81	0.81
ACT + ORPA (Action + Observation)	0.86	0.82	0.83

然而，薯片筒开启任务仍然特别具有挑战性，因为它涉及接触丰富的交互、精确的对齐要求以及对时序误差的敏感性，导致其在评估任务中基线性能最低。引入仅带动作扰动的 ORPA 提高了任务得分，表明残差策略适应能够在部署期间有效纠正执行失败。此外，

引入扰动观测进一步增强了鲁棒性，并提升了所有任务的性能。这些结果表明，少量额外的观测级校正数据能够在保持数据效率的同时显著提高鲁棒性。重要的是，现实世界中的失败不仅限于平移和旋转误差。其他失败模式包括时序不匹配、不完美的接触交互以及由物体动力学引起的执行不一致。因此，ORPA 被设计为基于提供的反馈信号执行校正性适应，而不是假设预定义的失败类别。

C. 定性结果

图 4 展示了所提出的 ORPA 框架在三个真实世界操作任务上的代表性执行序列：零食盒转移、薯片筒开启和物体分类。每个序列展示了机器人在在线校正反馈下的行为，突出了失败恢复和成功完成任务。真实世界实验表明，ORPA

能够通过在线校正反馈有效提高操作鲁棒性。当机器人遇到执行失败时，诸如太左、太右或太高等反馈信号会产生残差校正，从而在不修改底层 ACT 策略的情况下细化动作轨迹。与固定规则校正方法不同，ORPA 根据当前执行上下文和任务阶段调整其校正行为。定性结果表明，ORPA 保留了 ACT 的平滑、时间一致的行为，同时在部署期间实现了校正性适应。ORPA 纠正了零食盒转移中的抓取和放置错误，提高了接触丰富的薯片筒开启任务的稳定性，并在分类任务中跨物体配置保持鲁棒。现实世界中的失败还包括超出简单平移和旋转的时序、接触和物体动力学错误。通过直接在关节空间中预测残差校正，ORPA 从各种失败中恢复，同时保留了基础 ACT 行为。校正反馈并非总是必需的；如图 5 所示，太低的扰动仍处于 ACT 的原始恢复能力范围内。




图 5: 执行扰动下操作结果的代表性特写视图。诸如太左和太远等空间误差导致任务失败，而太低的情况仍能成功抓取执行。

VII. 结论

本文提出了在线残差策略自适应 (Online Residual Policy Adaptation, ORPA) 框架，该框架是一种轻量级方案，旨在通过人类反馈实现机器人操作控制中的实时纠正性自适应。通过在预训练控制策略上增加一个以反馈为条件的残差模块，ORPA 能够在不重新训练底层策略的情况下，实现即时的动作级细化。与基于规则的逆运动学 (IK) 纠正方法不同，本文所提方法学习到的是具有上下文感知且时间一致的关节空间控制调整，从而在微小执行扰动和分布偏移下提升鲁棒性。在精度敏感的 ALOHA 任务上的实验结果表明，与基线 ACT 和基于 IK 的纠正方法相比，所提方法在恢复能力和成功率上均有提升，凸显了在线残差自适应作为一种实用方法，有助于实现更具适应性的机器人操作。

致谢 我们衷心感谢日本产业技术综合研究所 (AIST) 提供的宝贵支持与资源，使本研究得以完成。

参考文献

- [1] Torabi, F., Warnell, G., and Stone, P. (2018). "Behavioral Cloning from Observation." In *Proceedings of the 27th International Joint Conference on Artificial Intelligence (IJCAI)*.
- [2] Chi, C., Feng, S., Du, Y., et al. (2023). "Diffusion Policy: Visuomotor Policy Learning via Action Diffusion." In *Proceedings of Robotics: Science and Systems (RSS 2023)*.
- [3] Ross, S., Gordon, G. J., and Bagnell, J. A. (2011). "A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning." In *Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics (AISTATS)*.
- [4] Lee, J., Fox, R., Dragan, A., et al. (2017). "DART: Noise Injection for Robust Imitation Learning." In *Proceedings of the 1st Annual Conference on Robot Learning (CoRL 2017)*.
- [5] Bi, J., Dhiman, V., Xiao, T., et al. (2020). "Learning from Interventions using Hierarchical Policies for Safe Learning." In *Proceedings of the AAAI Conference on Artificial Intelligence (AAAI 2020)*.
- [6] Zare, M., Kebria, P. M., Khosravi, A., et al. (2024). "A Survey of Imitation Learning: Algorithms, Recent Developments, and Challenges." *IEEE Transactions on Cybernetics*, vol. 54, no. 12.
- [7] Kelly, M., Sidrane, C., Driggs-Campbell, K., et al. (2019). "HG-Dagger: Interactive Imitation Learning with Human Experts." In *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA 2019)*.
- [8] Liu, H., Chen, A., Zhu, Y., et al. (2023). "Interactive Robot Learning from Verbal Correction." In *CoRL 2023 Workshop on Language and Robot Learning (LangRob)*.
- [9] Shi, L. X., Hu, Z., Zhao, T. Z., et al. (2024). "Yell At Your Robot: Improving On-the-Fly from Language Corrections." In *Proceedings of Robotics: Science and Systems (RSS 2024)*.
- [10] Todorov, E., Erez, T., & Tassa, Y. (2012). "Mujoco: A Physics Engine for Model-Based Control." *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*.
- [11] Quigley, M., Conley, K., et al. (2009). "ROS: An Open-Source Robot Operating System." In *ICRA Workshop*.
- [12] Devlin, J., Chang, M.-W., Lee, K., et al. (2019). "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding." In *Proc. NAACL-HLT 2019*.
- [13] Brown, T. B., Mann, B., Ryder, N., et al. (2020). "Language Models are Few-Shot Learners." In *Advances in Neural Information Processing Systems (NeurIPS 2020)*.
- [14] Vaswani, A., Shazeer, N., et al. (2017). "Attention Is All You Need." In *Advances in Neural Information Processing Systems*, 30 (NeurIPS).
- [15] Hochreiter, S., & Schmidhuber, J. (1997). "Long Short-Term Memory." *Neural Computation*, 9(8), 1735-1780.
- [16] He, K., Zhang, X., Ren, S., et al. (2016). "Deep Residual Learning for Image Recognition." In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR 2016)*.
- [17] Redmon, J., Divvala, S., Girshick, R., et al. (2016). "You Only Look Once: Unified, Real-Time Object Detection." In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR 2016)*.
- [18] Paszke, A., Gross, S., Massa, F., et al. (2019). "PyTorch: An Imperative Style, High-Performance Deep Learning Library." *Advances in Neural Information Processing Systems (NeurIPS)*, 32.
- [19] Zhao, T. Z., Kumar, V., et al. (2023). "Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware." In *Proceedings of Robotics: Science and Systems (RSS)*.
- [20] Fu, Z., Zhao, T. Z., and Finn, C. (2024). "Mobile ALOHA: Learning Bimanual Mobile Manipulation with Low-Cost Whole-Body Teleoperation." In *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA 2024)*.
- [21] Aldaco, J., Armstrong, T., Baruch, R., et al. (2024). "ALOHA 2: An Enhanced Low-Cost Hardware for Bimanual Teleoperation." *arXiv preprint arXiv:2405.02292*.