

部署期间的自监督策略自适应

Nicklas Hansen¹², Rishabh Jangir¹³, Yu Sun⁴, Guillem Alenyà³,
Pieter Abbeel⁴, Alexei A Efros⁴, Lerrel Pinto⁵, Xiaolong Wang¹

¹UC San Diego ²Technical University of Denmark

³IRI, CSIC-UPC ⁴UC Berkeley ⁵NYU

摘要

在大多数现实场景中，通过强化学习在一个环境中训练的策略需要部署到另一个可能截然不同的环境中。然而，跨不同环境的泛化是众所周知的难题。一个自然的解决方案是在新环境中部署后继续训练，但如果新环境不提供奖励信号，则无法进行。我们的工作探索了利用自监督使策略在部署后无需任何奖励即可继续训练。以往方法显式地预测新环境的变化，而我们假设对这些变化没有任何先验知识，却仍能获得显著改进。我们在 DeepMind Control 套件和 ViZDoom 的多种仿真环境以及持续变化环境中的真实机器人操作任务上进行了实证评估，观测来自未标定相机。我们的方法在 36 个环境中的 31 个上改善了泛化性能，并在大多数环境中优于领域随机化。¹

1 引言

深度强化学习 (RL) 与卷积神经网络结合，从图像像素中推导动作，已取得相当成功 (Mnih 等, 2013; Levine 等, 2016; Nair 等, 2018; Yan 等, 2020; Andrychowicz 等, 2020)。然而，基于视觉的强化学习在现实世界部署中仍面临一个重大挑战：在一个环境中训练的策略可能无法泛化到训练期间未见过的其他新环境。这一挑战对于强化学习本身已很困难，当策略面对高维视觉输入时更加严峻。

一类被广泛探索的解决方案是学习对环境变化具有不变性的鲁棒策略 (Rajeswaran et al., 2016; Tobin et al., 2017; Sadeghi & Levine, 2016; Pinto et al., 2017b; Lee et al., 2019)。例如，领域随机化 (Domain Randomization) (Tobin et al., 2017; Peng et al., 2018; Pinto et al., 2017a; Yang et al., 2019) 在模拟环境中应用数据增强来训练单一鲁棒策略，期望增强后的环境能够覆盖测试环境中足够多的变化因素。然而，当测试环境完全未知时，这一期望可能难以实现。随机化程度过高时，训练一个能够同时适应众多增强环境的策略需要更大的模型和样本复杂度。随机化程度过低时，测试环境中的实际变化可能未被覆盖，且由于随机化因素此时已不相关，领域随机化可能弊大于利。这两种现象在我们的实验中均已观察到。在所有情况下，这类解决方案都需要人类专家在见到测试环境之前预测其变化。随着更多具有更多样变化的测试环境被加入，这种方法无法扩展。

与其学习一个对所有可能环境变化都不变的鲁棒策略，我们认为策略在部署过程中持续学习并适应其实际新环境更为可取。在强化学习 (RL) 中实现这一点的朴素方法是利用奖励作为监督在新环境中微调策略 (Rusu et al., 2016; Kalashnikov et al., 2018; Julian et al., 2020)。然而，虽然在训练期间设计密集奖励函数相对容易 (Gu et al., 2017; Pinto & Gupta, 2016)，但在部署期间这通常不切实际，且可能需要大量的工程努力。

¹Webpage and implementation: <https://nicklashansen.github.io/PAD/>

本文针对基于视觉的强化学习 (RL) 中另一种问题设定：在无任何奖励的情况下，将预训练策略适配到未知环境。为此，我们引入自监督机制，在部署阶段获取“免费”的训练信号。标准自监督学习利用辅助任务，仅凭输入数据自动生成训练标签（详见第 2 节）。受此启发，我们的策略联合训练两个目标：标准强化学习目标，以及施加于策略网络中间表示的自监督目标。训练期间两个目标同时激活，在最大化期望奖励的同时通过自监督约束中间表示。测试/部署阶段，仅自监督目标（作用于原始观测数据）保持激活，迫使中间表示适应新环境。

我们在仿真和真实机器人上进行了实验。仿真中，我们在两组环境上评估：DeepMind Control 套件 (Tassa 等, 2018) 和 CRLMaze ViZDoom (Lomonaco 等, 2019; Wydmuch 等, 2018) 导航任务。我们通过在训练期间未知视觉变化的新环境中测试来评估泛化能力。在 DeepMind Control 套件的 22 个测试环境中，我们的方法在 19 个环境中提升了泛化性能；在 CRLMaze 的所有测试环境中均有所提升。除仿真外，我们还在 Kinova Gen3 机器人上执行了从仿真到现实 (Sim2Real) 的迁移，涵盖到达和推动任务。在仿真中训练后，我们成功将策略迁移并适配到 6 种不同环境，包括持续变化的迪斯科灯光，且真实机器人仅依赖未标定相机运行。在仿真和真实实验中，我们的方法在大多数环境中优于领域随机化。

2 相关工作

自监督学习 是从无标签数据中学习视觉表征的一种强大方法 (Vincent 等, 2008; Doersch 等, 2015; Wang 与 Gupta, 2015; Zhang 等, 2016; Pathak 等, 2016; Noroozi 与 Favaro, 2016; Zhang 等, 2017; Gidaris 等, 2018)。研究者提出使用辅助数据预测任务，例如还原旋转 (Gidaris 等, 2018)、解决拼图 (Noroozi 与 Favaro, 2016)、跟踪 (Wang 等, 2019) 等，以提供监督信号替代标签。在强化学习 (RL) 中，同时学习视觉表征和动作的想法已被研究 (Lange 与 Riedmiller, 2010; Jaderberg 等, 2016; Pathak 等, 2017; Ha 与 Schmidhuber, 2018; Yarats 等, 2019; Srinivas 等, 2020; Laskin 等, 2020; Yan 等, 2020)。例如，Srinivas 等 (2020) 使用自监督对比学习技术 (Chen 等, 2020; H'enaft 等, 2019; Wu 等, 2018; He 等, 2020)，通过联合训练自监督目标和强化学习目标来提高强化学习的样本效率。然而，这尚未被证明能泛化到未见过的环境。其他工作已应用自监督以实现跨环境更好的泛化 (Pathak 等, 2017; Ebert 等, 2018; Sekar 等, 2020)。例如，Pathak 等 (2017) 使用自监督预测任务为在新环境中的探索提供密集奖励。虽然从零开始的环境探索结果令人鼓舞，但如何将训练好的策略（带有外部奖励）迁移到新环境仍不清楚。因此，这些方法不能直接应用于本文提出的问题。

跨不同分布的泛化 是机器学习中的一个核心挑战。在领域自适应中，假设目标领域数据是可访问的 (Geirhos 等, 2018; Tzeng 等, 2017; Ganin 等, 2016; Gong 等, 2012; Long 等, 2016; Sun 等, 2019; Julian 等, 2020)。例如，Tzeng 等 (2017) 利用对抗学习在训练期间对齐源领域和目标领域的特征表示。类似地，领域泛化的设定 (Ghifary 等, 2015; Li 等, 2018; Matsuura 和 Harada, 2019) 假设所有领域都从同一元分布中采样，但同样的挑战依然存在，并且现在变成了跨元分布的泛化。我们的工作则聚焦于泛化到真正未见的环境变化这一设定，这些变化在训练时无法预料。

在我们的设定中，近期出现了若干用于图像识别的基准 (Hendrycks 和 Dietterich, 2018; Recht 等, 2018; 2019; Shankar 等, 2019)。例如，在 Hendrycks 和 Dietterich (2018) 中，一个在常规图像上训练的分类器在损坏图像上进行测试，损坏类型在训练期间未知；Hendrycks 等 (2019) 的方法被提出以提升在该基准上的鲁棒性。遵循类似的精神，在强化学习的背景下，领域随机化 (Tobin 等, 2017; Pinto 等, 2017a; Peng 等, 2018; Ramos 等, 2019; Yang 等, 2019; James 等, 2019) 帮助在仿真中训练的策略泛化到真实机器人。例如，Tobin 等 (2017)；Sadeghi 和 Levine (2016) 提出用随机纹理渲染仿真环境，并在其上训练策略。学习到的策略被证明可以泛化到真实




图 1. 左：部署前的训练。对于离策略方法，观测从回放缓冲区中采样；对于在策略方法，观测在 rollout 过程中收集。我们联合优化强化学习和自监督目标。右：部署期间的策略自适应。观测从测试环境在线收集，我们仅优化自监督目标。

机器人操作任务。我们不是部署一个固定策略，而是利用部署期间自然揭示的观测数据，在新环境中训练并自适应策略。

深度学习的测试时自适应 正开始应用于计算机视觉领域（Shocher 等人，2017；2018；Bau 等人，2019；Mullapudi 等人，2019；Sun 等人，2020；Wortsman 等人，2018）。例如，Shocher 等人（2018）表明，仅通过尝试对输入图像的下采样版本进行上采样，即可在测试时（从零开始）学习图像超分辨率。Bau 等人（2019）表明，将生成对抗网络的先验适应于测试图像的统计特性，可以改善照片处理任务。我们的工作与 Sun 等人（2020）的测试时训练方法密切相关，该方法将图像识别与基于旋转预测的自监督学习（Gidaris 等人，2018）进行联合优化，然后在测试期间使用自监督目标来适应单个图像的代表。与图像识别不同，我们以在线方式对具有视觉输入的强化学习执行测试时自适应。当智能体与环境交互时，我们持续以流的形式获取新的观测数据，用于训练视觉表示。

3 方法

在本节中，我们描述所提出的部署期间策略自适应（PAD）方法。它可以实现在任何策略网络和标准强化学习算法（包括在线策略和离线策略）之上，这些算法可以通过使用随机梯度下降最小化某个强化学习目标 $J(\theta)$ （关于参数集合 θ ）来描述。

3.1 网络架构

我们设计网络架构，使策略和自监督预测能够共享特征。对于给定策略网络 π 的参数集合 θ ，我们将其按顺序拆分为 $\theta = (\theta_e, \theta_a)$ ，其中 θ_e 收集特征提取器的参数， θ_a 是输出动作分布的头。我们定义参数为 θ_e 的网络 π_e 和参数为 θ_a 的网络 π_a ，使得 $\pi(s; \theta) = \pi_a(\pi_e(s))$ ，其中 s 表示图像观测。直观上，可以将 π_e 视为特征提取器，将 π_a 视为基于这些特征的控制策略。我们方法的目标是在测试时使用自监督任务的梯度更新 π_e ，使得 π_e （以及随之而来的 π_θ ）能够泛化。令参数为 θ_s 的 π_s 为自监督预测头及其参数集合， π_s 的输入为 π_e 的输出（如图 1 所示）。在这项工作中，自监督任务是用于控制的逆动力学预测，以及用于导航的旋转预测。

3.2 逆动力学预测与旋转预测

在每个时间步，无论是在训练还是测试阶段，我们总能观察到形如 (s_t, a_t, s_{t+1}) 的转移序列。自然地，自监督可以通过截取序列的一部分并预测其余部分来获得。逆动力学模型以转移前后的状态为输入，预测中间的动作。在本文中，逆动力学模型 π_s 作用于由 π_e 提取的特征空间上。我们可以将逆动力学预测目标正式写为

$$L(\theta_s, \theta_e) = \ell(a_t, \pi_s(\pi_e(s_t), \pi_e(s_{t+1}))) \quad (1)$$

对于连续动作， ℓ 是真实值与模型输出之间的均方误差。对于离散动作，输出是动作空间上的 soft-max 分布， ℓ 是交叉熵损失。

经验上，我们发现这种自监督任务在连续动作下最为有效，可能是因为在离散动作的小空间中进行逆动力学预测并不具有挑战性。注意，我们预测的是逆动力学而非前向动力学，因为在特征空间中操作时，后者可能产生平凡解，例如每个状态的特征恒为零²。如果我们改为在像素空间中进行前向动力学预测，由于像素预测存在很大的不确定性，该任务将极具挑战性。

作为另一种自监督任务，我们使用旋转预测（Gidaris et al., 2018）。我们将图像旋转 0、90、180 或 270 度之一作为网络输入，并将其转化为一个四分类问题，以确定图像被旋转了哪一种方式。该任务已被证明能有效学习物体配置和场景结构的表示，这对视觉识别有益（Hendrycks et al., 2019; Doersch & Zisserman, 2017）。

3.3 训练与测试

在策略部署之前，由于我们同时拥有来自奖励和自监督辅助任务的信号，我们可以采用多任务学习的方式进行训练。这对应于训练期间的以下优化问题 $\min_{\theta_a, \theta_s, \theta_e} J(\theta_a, \theta_e) + \alpha L(\theta_s, \theta_e)$ ，其中 $\alpha > 0$ 是一个权衡超参数。在部署期间，由于奖励不可用，我们无法再优化 J ，但仍可以优化 L 来更新 θ_s 和 θ_e 。经验上，我们发现测试时保持 θ_s 固定仅有可忽略的差异，因此我们更新两者，因为无论如何都必须计算梯度；我们在附录 C 中对该决策进行了消融研究。随着我们从环境中的视觉输入流获得新图像， θ 持续更新直到回合结束。这对应于每次迭代 $t = 1 \dots T$ ：

$$\mathbf{s}_t \sim p(\mathbf{s}_t | \mathbf{a}_{t-1}, \mathbf{s}_{t-1}) \quad (2)$$

$$\theta_s(t) = \theta_s(t-1) - \nabla_{\theta_s} L(\mathbf{s}_t; \theta_s(t-1), \theta_e(t-1)) \quad (3)$$

$$\theta_e(t) = \theta_e(t-1) - \nabla_{\theta_e} L(\mathbf{s}_t; \theta_s(t-1), \theta_e(t-1)) \quad (4)$$

$\mathbf{a}_t = \pi(\mathbf{s}_t; \theta(t))$ 其中 $\theta(t) = (\theta_e(t), \theta_a)$ ，(5) 其中 $\theta_s(0) = \theta_s, \theta_e(0) = \theta_e, \mathbf{s}_0$ 是由环境给出的初始条件， $\mathbf{a}_0 = \pi_\theta(\mathbf{s}_0)$ ， p 是未知的环境转移， L 是如前所述的自监督目标。

4 实验

在这项工作中，我们研究在一个环境（称为训练环境）中训练的智能体如何泛化到未见过的多样化测试环境。在评估期间，智能体无法访问奖励信号，并且期望在没有试验或关于测试环境的先验知识的情况下进行泛化。在仿真中，我们在 DeepMind Control (DMControl) 套件（Tassa 等人，2018）的连续控制任务以及 CRLMaze（Lomonaco 等人，2019）导航任务上广泛评估了我们的方法（PAD）和基线，并实验了静态（颜色、物体、纹理、光照）和非静态（视频）环境变化。我们进一步表明，PAD 从仿真迁移到真实机器人，并在两个机器人操作任务的部署期间成功适应环境差异。DMControl 和 CRLMaze 环境的样本如图 2 所示，机器人实验的样本如图 4 所示。实现可在 <https://nicklashansen.github.io/PAD/> 获取。

网络细节。 对于深度思维控制（DMControl）和机器人操作任务，我们在软演员-评论家（Soft Actor-Critic, SAC）（Haarnoja 等，2018）之上实现了 PAD，并采用了 Yarats 等（2019）的网络架构和超参数，仅做了少量修改：特征提取器 π_e 具有 8 个卷积层，由强化学习头 π_a 和自监督头 π_s 共享，并且我们按照 π_e 将网络拆分为结构相同的头。每个头由 3 个卷积层和随后的 4 个全连接层组成。对于 CRLMaze，我们使用优势演员-评论家（Advantage Actor-Critic, A2C）作为基础算法（Mnih 等，2016），并采用与其他实验相同的架构，但将 π_e 实现为仅 6 个卷积层。观测是大小为 100×100 的 k 彩色帧堆叠（在 DMControl 和 CRLMaze 上为 $k = 3$ ；在机器人操作中为 $k = 1$ ），并像 Srinivas 等（2020）那样应用时间一致的随机裁剪。在部署期间，我们针对 θ_e, θ_s 在线优化自监督目标，每次时间迭代执行一个梯度步。实现细节见附录 F。

²在特征空间中运行的前向动力学模型可以通过学习将每个状态映射到常数向量（例如 $\mathbf{0}$ ）而轻易实现 $\mathbf{0}$ 损失。然而，逆向动力学模型不存在这种平凡解。




图 2. 左: DMControl (上) 和 CRLMaze (下) 的训练环境。右: DMControl (上) 和 CRLMaze (下) 的测试环境。对 DMControl 的改动包括随机颜色、视频背景和干扰物; 对 CRLMaze 的改动包括纹理和光照。

表 1. 在具有随机颜色的测试环境中的回合回报, 10 个种子的均值和标准差。每个任务上的最佳方法以粗体和蓝色标出, 比较了带和不带 PAD 的 SAC+IDM。

Random colors	SAC	+DR	+IDM	+IDM (PAD)	10x episode length	
					+IDM	+IDM (PAD)
Walker, walk	414±74	594±104	406±29	468±47	3830±547	5505±592
Walker, stand	719±74	715±96	743±37	797±46	7832±209	8566±121
Cartpole, swingup	592±50	647±48	585±73	630±63	6528±539	7093±592
Cartpole, balance	857±60	867±37	835±40	848±29	7746±526	7670±293
Ball in cup, catch	411±183	470±252	471±75	563±50	—	—
Finger, spin	626±163	465±314	757±62	803±72	7249±642	7496±655
Finger, turn_easy	270±43	167±26	283±51	304±46	—	—
Cheetah, run	154±41	145±29	121±38	159±28	1117±530	1208±487
Reacher, easy	163±45	105±37	201±32	214±44	1788±441	2152±506

4.1 深度思维控制

深度思维控制 (DeepMind Control, DMControl) (Tassa 等, 2018) 是一组连续控制任务, 其中智能体仅观察原始像素。DMControl 上的泛化基准代表了多样化的现实世界运动控制任务, 并包含与奖励信号无关的干扰性环境。

实验设置。 我们在来自 DM-Control 的 9 个任务上进行实验, 并衡量对四类测试环境的泛化能力: (i) 随机颜色; (ii) 自然视频作为背景; (iii) 场景中放置干扰物体; 以及 (iv) 未修改的训练环境。对于每个测试环境, 我们在 10 个随机种子和 100 个随机初始化条件下评估各方法。如果某个测试环境不适用于某些任务, 例如某个任务没有背景可设置视频背景, 则将其排除。任务的选择基于多样性, 以及先前工作中基于视觉的强化学习的成功经验 (Yarats 等人, 2019; Srinivas 等人, 2020; Laskin 等人, 2020; Kostrikov 等人, 2020)。我们在 SAC 之上实现 PAD, 并使用逆动力学模型 (IDM) 进行自监督, 因为我们发现学习动力学模型对运动控制效果良好。为完整性起见, 我们对自监督的选择进行了消融实验。学习曲线见附录 B。我们将我们的方法与以下基线进行比较: (i) 未做任何改动的 SAC (记为 SAC); (ii) 在固定 100 种颜色集合上使用领域随机化训练的 SAC (记为 +DR); 以及 (iii) 与 IDM 联合训练但不使用 PAD 的 SAC (记为 +IDM)。我们使用 IDM 和 PAD 的方法记为 +IDM (PAD)。对于领域随机化, 颜色从与评估相同的分布中采样, 但方差更低, 因为我们发现直接在测试分布上训练无法收敛。




图 3. PAD 在随机颜色环境中瞬时奖励随时间的相对改进。

颜色的随机扰动。 对颜色等细微变化的鲁棒性对于强化学习策略在真实世界中的部署至关重要。我们在前景、背景和智能体本身的固定 100 种颜色集合上评估泛化能力, 结果报告在表 1 (前 4 列) 中。我们发现 PAD 在所有考虑的任务中都改善了泛化性能, 在 9 个任务中有 6 个任务上优于使用领域随机化训练的 SAC。

令人惊讶的是，尽管领域随机化的训练域和测试域之间存在大量重叠，但它在大多数任务上的泛化性能并不比普通 SAC 更好。

长期稳定性。我们发现 PAD 的相对改进随时间推移而增加，如图 3。

为考察 PAD 的长期稳定性，我们在 10 倍于原剧集长度的设置下进一步评估，并将结果汇总于表 1 的最后两列（目标导向任务除外）。虽然我们未明确阻止嵌入偏离强化学习任务，但经验表明，即使在较长的时间跨度内，PAD 也不会降低策略的性能；而当 PAD 未能带来提升时，其负面影响也极小。我们推测，这是因为我们并非在学习新任务，而是继续优化与联合训练期间相同的（自监督）目标，且这两个任务相互兼容。在此设置下，PAD 在 7 个任务中的 6 个上仍能提升泛化能力，因此自然超越了单剧集部署的范畴。为完整性起见，我们还在训练环境中评估了各方法，结果见附录 A。我们发现，虽然 PAD 能提升对新环境的泛化能力，但在训练环境上的性能几乎不变。我们推测，这是因为自监督任务已被完全学会，继续在相同数据分布上训练影响甚微。

非平稳环境。为探究 PAD 能否在非平稳环境中泛化，我们在非平稳环境中（上）我们干扰物体（下）的测试环境中的单剧集训练，210 个随机种子的均值与标准差。每个任务上的最佳方法以粗体显示，蓝色用于比较带与不带 PAD 的 SAC+IDM。

上比领域随机化高出多达

104%。领域随机化对视频的泛

化能力相对较差，我们推测这并

非因为环境非平稳，而是因为视

频的图像统计特性未被其随机颜

色训练域所覆盖。事实上，在大

多数带视频背景的任务中，领域

随机化甚至不如普通 SAC，这与

Packer 等人（2018）的发现一

致。

Video backgrounds	SAC	+DR	+IDM	+IDM (PAD)
Walker, walk	616±80	655±55	694±85	717±79
Walker, stand	899±53	869±60	902±51	935±20
Cartpole, swingup	375±90	485±67	487±90	521±76
Cartpole, balance	693±109	766±92	691±76	687±58
Ball in cup, catch	393±175	271±189	362±69	436±55
Finger, spin	447±102	338±207	605±61	691±80
Finger, turn_easy	355±108	223±91	355±110	362±101
Cheetah, run	194±30	150±34	164±42	206±34
Distracting objects	SAC	+DR	+IDM	+IDM (PAD)
Cartpole, swingup	815±60	809±24	776±58	771±64
Cartpole, balance	969±20	938±35	964±26	960±29
Ball in cup, catch	177±111	331±189	482±128	545±173
Finger, spin	652±184	564±288	836±62	867±72
Finger, turn_easy	302±68	165±12	326±101	347±48

场景内容。我们假设：（i）使用逆动力学模型（IDM）训练的智能体受场景内容干扰相对较小，因为与动作无关的物体不提供预测能力；（ii）PAD 能适应场景中意外出现的物体。我们通过在场景前景和背景的多种位置放置彩色形状（无物理交互）来测试这些假设，并测量鲁棒性。结果总结于表 2。PAD 在 5 个任务中的 3 个上优于所有基线，在接球任务（Ball in cup, catch）上相对 SAC 提升 **208%**。在 PAD 未提升的两个倒立摆任务中，所有方法受干扰物的影响本来就相对较小。

自监督任务的选择。我们研究自监督任务的选择对我们方法整体成功的贡献程度，并考虑以下消融实验：（i）将逆动力学替换为第 3.2 节描述的旋转预测任务；（ii）将其替换为最近提出的用于强化学习的 CURL（Srinivas et al., 2020）对比学习算法。如表 3 所示，在随机颜色基准的大多数任务上，PAD 提升了 CURL 的泛化能力，在 9 个任务中的 4 个上使用旋转预测也有提升。然而，逆动力学作为辅助任务产生的结果更一致，整体泛化性更好。我们认为学习 IDM 能为运动控制产生更好的表示，因为它直接将观测与动作联系起来，而 CURL 和旋转预测仅基于观测。总体而言，我们发现 PAD 的改进在显著依赖视觉信息的任务中更大（见附录 A），并推测选择能学习对强化学习任务有用特征的自监督任务对 PAD 的成功至关重要，我们将在第 4.2 节进一步讨论。

表 3. 在 DMC 随机颜色域上的消融实验。所有方法均使用 SAC。CURL 表示带有对比学习任务的强化学习 (Srinivas et al., 2020)，Rot 表示旋转预测 (Gidaris et al., 2018)。离线 PAD 在此简称为 O-PAD，而 PAD 的默认用法是在线设置。最佳方法以粗体和蓝色显示，并比较了有无 PAD 的 +IDM。

随机颜色	CURL	CURL (PAD)	Rot	Rot (PAD)	IDM	IDM (O-PAD)	IDM (PAD)
Walker, walk	445±99	495±70	335±7	330±30	406±29	441±16	468±47
Walker, stand	662±54	753±49	673±4	653±27	743±37	727±21	797±46
Cartpole, swingup	454±110	413±67	493±52	477±38	585±73	578±69	630±63
Cartpole, balance	782±13	763±5	710±72	734±81	835±40	796±37	848±29
Ball in cup, catch	231±92	332±78	291±54	314±60	471±75	490±16	563±50
Finger, spin	691±12	588±22	695±36	689±20	757±62	767±43	803±72
Finger, turn_easy	202±32	186±2	283±68	230±53	283±51	321±10	304±46
Cheetah, run	202±22	211±20	127±3	135±12	121±38	112±35	159±28
Reacher, easy	325±32	378±62	99±29	120±7	201±32	241±24	214±44

表 4. PAD 与基线方法在 CRLMaze 环境中的回合回报。PAD 在所有考虑的环境中均提升了泛化能力，并以较大幅度优于 A2C 和领域随机化。所有方法均使用 A2C。我们报告 10 个随机种子的均值与标准误差。每个环境中的最佳方法以粗体显示，蓝色表示有 PAD 与无 PAD 的旋转预测对比。

CRLMaze	Random	A2C	+DR	+IDM	+IDM (PAD)	+Rot	+Rot (PAD)
Walls	-870±30	-380±145	-260±137	-302±150	-428±135	-206±166	-74±116
Floor	-868±23	-320±167	-438±59	-47±198	-530±106	-294±123	-209±94
Ceiling	-872±30	-171±175	-400±74	166±215	-508±104	128±196	281±83
Lights	-900±29	-30±213	-310±106	239±270	-460±114	-84±53	312±104

离线学习与在线学习。顺序到达的观测高度相关，因此我们假设本文方法从在线学习中获益显著。为验证该假设，我们运行了本文方法的离线变体，其中每一步后网络更新被遗忘。在此设置下，本文方法只能适应单个观测，无法从随时间的学习中获益。结果见表 3。我们发现本文方法从在线学习中获益显著，但离线学习仍能在特定任务上提升泛化能力。

4.2 CRLMAZE

CRLMaze (Lomonaco 等人, 2019) 是 ViZDoom (Wydmuch 等人, 2018) 中一个时间受限、离散动作的 3D 导航任务，智能体需在迷宫中导航并收集物体。绿色柱子对应正奖励，灯笼以及存活对应负奖励。有关任务和环境的详细信息，请读者参阅相应论文。

实验设置。我们在单一环境上训练智能体，并测量其对具有新颖墙壁、地板和天花板纹理以及光照环境的泛化能力，如图 2 所示。我们在 A2C (Mnih 等人, 2016) 之上实现 PAD，并使用旋转预测（见 3.2 节）作为自监督任务。学习导航新场景需要泛化的场景理解，我们发现旋转预测比 IDM 更能促进这一点。我们与以下基线方法进行比较：(i) 随机智能体（记为 Random）；(ii) 未做改动的 A2C（记为 A2C）；(iii) 使用领域随机化训练的 A2C（记为 +DR）；(iv) 以 IDM 作为辅助任务的 A2C（记为 +IDM）；(v) 以旋转预测作为辅助任务的 A2C（记为 +Rot）。我们将带 PAD 的 Rot 记为 +Rot (PAD)。领域随机化使用 56 种不同纹理组合，部分与测试分布重叠，我们发现需要将领域随机化训练两倍的回合数才能收敛。我们严格遵循 (Lomonaco 等人, 2019) 的评估流程，在 20 个起始位置和 10 个随机种子上评估各方法。

结果。我们在表 4 中报告了 CRLMaze 环境上的性能。PAD 在所有考虑的测试环境中均提升了泛化能力，大幅优于 A2C 和领域随机化。领域随机化在所有环境中表现一致，但整体效果较差。我们进一步通过一个简单的消融实验来检验选择合适辅助任务的重要性：将旋转预测替换为用于导航任务的 IDM。我们推测，虽然辅助任务可以在学习到的表示中施加结构，但其特征（以及相应的梯度）需要与主要的强化学习任务充分相关，PAD 才能在部署中取得成功。




图 4. 推动机器人操作任务的样本。任务是将黄色立方体推到红色圆盘的位置。智能体在设置 (a) 中训练，并在设置 (b-d) 中评估。

虽然带有旋转预测的 PAD 在所有考虑的测试环境中均提升了泛化能力，但 IDM 并未做到，这表明旋转预测更适合需要场景理解的任务，而 IDM 则适用于需要运动控制的任务。我们将自动选择合适辅助任务的过程留待未来工作。

4.3 机器人操作任务

我们将方法和基线部署在真实的 Kinova Gen3 机器人上，并评估两个操作任务：(i) 到达，机器人到达由红色圆盘标记的目标位置的任务；(ii) 推动，机器人将立方体推到红色圆盘位置的任务。两个任务均使用 XY 动作空间，其中执行器的 Z 位置固定。智能体完全基于像素观测进行操作，无法访问状态信息。在部署期间，我们不尝试校准相机、光照或物理属性（如尺寸、质量和摩擦），策略应在对测试环境无先验知识的情况下实现泛化。推动任务的样本如图 4 所示，到达任务的样本见附录 E。

表 5. PAD 和基线方法在真实机械臂上的成功率。每个环境中的最佳方法以粗体显示，蓝色表示+IDM 在有 PAD 情况下的对比。

Real robot	SAC	+DR	+IDM	+IDM (PAD)
Reach (default)	100%	100%	100%	100%
Reach (cloth)	48%	80%	56%	80%
Reach (disco)	72%	76%	88%	92%
Push (default)	88%	88%	92%	100%
Push (cloth)	60%	64%	64%	88%
Push (disco)	60%	68%	72%	84%

实验设置。 我们在 SAC (Haarnoja 等人, 2018) 之上实现 PAD，并采用与第 4.1 节相同的实验设置，使用逆动力学模型 (IDM) 进行自监督，但不使用帧堆叠（即 $k = 1$ ）。智能体在仿真中通过密集奖励和随机初始化的机械臂、目标及箱体构型进行训练，并测量其在真实世界中 3 个新环境上的泛化能力：(i) 默认环境，像素观测大致模拟仿真；(ii) 图案桌布，视觉上分散注意力并显著增加摩擦；(iii) 迪斯科，具有非平稳视觉迪斯科灯光干扰的环境。

值得注意的是，与训练环境相比，所有 3 个环境在动力学上还存在细微差异，例如物体尺寸、质量、摩擦以及未校准的动作。在每个设置中，我们评估 25 次测试运行的成功率，这些运行跨越桌面上 5 个预定义目标位置。两个任务的目标位置不同，每次运行后机器人复位。我们与第 4.1 节中的直接迁移和领域随机化基线进行比较。此外，我们通过考虑仿真环境的一个变体来评估对动力学变化的泛化能力，该变体修改了物体质量、尺寸和摩擦、机械臂安装位置以及末端执行器速度。我们分别和联合考虑每个设置，并在 50 个独特配置上评估成功率，每次运行后机器人复位。

表 6. 在动力学变化的测试环境中，PAD 与基线方法在仿真机械臂上执行推动任务的成功率。变化包括物体质量、尺寸和摩擦、机械臂安装位置以及末端执行器速度。每个环境中的最佳方法以粗体和蓝色标出，并比较了带与不带 PAD 的+IDM。

Simulated robot	SAC	+DR	+IDM	+IDM (PAD)
Push (object)	66%	64%	72%	82%
Push (mount)	68%	58%	86%	84%
Push (velocity)	70%	68%	70%	78%
Push (all)	56%	50%	48%	76%

结果。 我们在表 5 中报告迁移结果。虽然所有方法都能成功迁移到抓取（默认）任务，但我们观察到 PAD 在基线方法表现不佳的所有设置中均改善了泛化能力。

次优性能。我们发现策略自适应部署 (Policy Adaptation during Deployment, PAD) 对于涉及动力学的推动任务尤为有效, 在推布任务中性能提升高达 **24%**。虽然领域随机化在到达布任务中表现出高效性, 但在其他设置中未观察到显著益处, 这表明 PAD 在推动等具有挑战性的任务中可能更为适用。为隔离动力学的影响, 我们进一步评估了在推动任务中对多种模拟动力学变化的泛化能力。结果如表 6 所示。我们发现 PAD 能够提升对物体和末端执行器物理属性变化的泛化能力, 而 SAC+IDM 和 PAD 对安装位置的变化相对不敏感。与第 5 节中的真实机器人结果一致, 当动力学变化非平凡时, PAD 最为有效, 在推动 (全部) 设置中性能提升高达 **28%**, 该设置同时考虑了全部 3 种环境变化。这些结果表明, PAD 可以作为一种简单而有效的方法, 用于泛化到视觉和动力学均发生变化的多样未知环境。

5 结论

以往工作通过学习对任何可预见环境变化具有不变性的策略来解决强化学习中的泛化问题, 而本文在基于视觉的强化学习中提出了另一种问题设定: 能否在无奖励的情况下将预训练策略适应到新环境。我们提出了部署期间策略自适应 (Policy Adaptation during Deployment), 一种用于测试时在线自适应的自监督框架, 并通过实验证明该方法能够提升策略在多种模拟和真实世界环境变化下的泛化能力, 涵盖多种任务。我们发现该方法从在线学习中获益显著, 并系统评估了自监督任务选择对性能的影响。虽然当前框架依赖于选择自监督任务进行策略自适应的先验知识, 但我们认为本文工作是解决基于视觉策略适应未知环境问题的初步步骤。我们最终设想未来的具身智能体能够持续学习, 在部署前后灵活地结合有奖励和无奖励的学习方式。

致谢。本研究部分得到了美国国防高级研究计划局 (DARPA)、美国国家科学基金会 (NSF) 1730158 号项目“认知硬件与软件生态系统社区基础设施” (CHASE-CI)、NSF ACI-1541349 号项目“太平洋研究平台”以及高通 (Qualcomm) 和图森未来 (TuSimple) 的捐赠支持。本研究还部分得到了伯克利深驱 (Berkeley DeepDrive)、思爱普 (SAP) 以及欧盟地平线 2020 计划下欧洲研究理事会 (ERC) 第 741930 号协议 (CLOTHILDE) 的资助。感谢洪丰禄 (Fenglu Hong) 和乔伊·赫伊纳 (Joey Hejna) 的有益讨论。

参考文献

- OpenAI: Marcin Andrychowicz, Bowen Baker, Maciek Chociej, Rafal Jozefowicz, Bob McGrew, Jakub Pachocki, Arthur Petron, Matthias Plappert, Glenn Powell, Alex Ray, et al. Learning dexterous in-hand manipulation. *The International Journal of Robotics Research*, 39(1):3–20, 2020. [1](#)
- David Bau, Hendrik Strobelt, William Peebles, Jonas Wulff, Bolei Zhou, Jun-Yan Zhu, and Antonio Torralba. Semantic photo manipulation with a generative image prior. *ACM Trans. Graph.*, 38(4), 2019. ISSN 0730-0301. [3](#)
- Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. A simple framework for contrastive learning of visual representations, 2020. [2](#)
- Carl Doersch and Andrew Zisserman. Multi-task self-supervised visual learning. In *Proceedings of the IEEE International Conference on Computer Vision*, pp. 2051–2060, 2017. [4](#)
- Carl Doersch, Abhinav Gupta, and Alexei A Efros. Unsupervised visual representation learning by context prediction. In *Proceedings of the IEEE International Conference on Computer Vision*, pp. 1422–1430, 2015. [2](#)
- Frederik Ebert, Chelsea Finn, Sudeep Dasari, Annie Xie, Alex Lee, and Sergey Levine. Visual foresight: Model-based deep reinforcement learning for vision-based robotic control, 2018. [2](#)

- Yaroslav Ganin, Evgeniya Ustinova, Hana Ajakan, Pascal Germain, Hugo Larochelle, François Laviolette, Mario Marchand, and Victor Lempitsky. Domain-adversarial training of neural networks. *The Journal of Machine Learning Research*, 17(1):2096–2030, 2016. 2
- Robert Geirhos, Carlos R. Medina Temme, Jonas Rauber, Heiko H. Schütt, Matthias Bethge, and Felix A. Wichmann. Generalisation in humans and deep neural networks. In *NeurIPS*, 2018. 2
- Muhammad Ghifary, W. Bastiaan Kleijn, Mengjie Zhang, and David Balduzzi. Domain generalization for object recognition with multi-task autoencoders. In *Proceedings of the 2015 IEEE International Conference on Computer Vision (ICCV)*, ICCV ’15, pp. 2551–2559. IEEE Computer Society, 2015. ISBN 9781467383912. 2
- Spyros Gidaris, Praveer Singh, and Nikos Komodakis. Unsupervised representation learning by predicting image rotations, 2018. 2, 3, 4, 7
- Boqing Gong, Yuan Shi, Fei Sha, and Kristen Grauman. Geodesic flow kernel for unsupervised domain adaptation. In *2012 IEEE Conference on Computer Vision and Pattern Recognition*, pp. 2066–2073. IEEE, 2012. 2
- Shixiang Gu, Ethan Holly, Timothy Lillicrap, and Sergey Levine. Deep reinforcement learning for robotic manipulation with asynchronous off-policy updates. In *2017 IEEE international conference on robotics and automation (ICRA)*, pp. 3389–3396. IEEE, 2017. 1
- David Ha and Jürgen Schmidhuber. Recurrent world models facilitate policy evolution. In *Advances in Neural Information Processing Systems 31*, pp. 2451–2463. Curran Associates, Inc., 2018. 2
- Tuomas Haarnoja, Aurick Zhou, Kristian Hartikainen, George Tucker, Sehoon Ha, Jie Tan, Vikash Kumar, Henry Zhu, Abhishek Gupta, Pieter Abbeel, and Sergey Levine. Soft actor-critic algorithms and applications, 2018. 4, 8, 17
- Kaiming He, Haoqi Fan, Yuxin Wu, Saining Xie, and Ross Girshick. Momentum contrast for unsupervised visual representation learning. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2020. 2
- Dan Hendrycks and Thomas G. Dietterich. Benchmarking neural network robustness to common corruptions and surface variations. *arXiv: Learning*, 2018. 2
- Dan Hendrycks, Mantas Mazeika, Saurav Kadavath, and Dawn Song. Using self-supervised learning can improve model robustness and uncertainty. *ArXiv*, abs/1906.12340, 2019. 2, 4
- Olivier J. Hénaff, Aravind Srinivas, Jeffrey De Fauw, Ali Razavi, Carl Doersch, S. M. Ali Eslami, and Aaron van den Oord. Data-efficient image recognition with contrastive predictive coding, 2019. 2
- Max Jaderberg, Volodymyr Mnih, Wojciech Marian Czarnecki, Tom Schaul, Joel Z Leibo, David Silver, and Koray Kavukcuoglu. Reinforcement learning with unsupervised auxiliary tasks, 2016. 2
- Stephen James, Paul Wohlhart, Mrinal Kalakrishnan, D. Kalashnikov, A. Irpan, J. Ibarz, S. Levine, Raia Hadsell, and Konstantinos Bousmalis. Sim-to-real via sim-to-sim: Data-efficient robotic grasping via randomized-to-canonical adaptation networks. *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 12619–12629, 2019. 2
- R. Julian, B. Swanson, G. Sukhatme, Sergey Levine, Chelsea Finn, and Karol Hausman. Never stop learning: The effectiveness of fine-tuning in robotic reinforcement learning. *arXiv: Learning*, 2020. 1, 2, 15
- D. Kalashnikov, A. Irpan, P. Pastor, J. Ibarz, A. Herzog, Eric Jang, Deirdre Quillen, Ethan Holly, Mrinal Kalakrishnan, V. Vanhoucke, and S. Levine. Qt-opt: Scalable deep reinforcement learning for vision-based robotic manipulation. *ArXiv*, abs/1806.10293, 2018. 1
- Ilya Kostrikov, Denis Yarats, and Rob Fergus. Image augmentation is all you need: Regularizing deep reinforcement learning from pixels. 2020. 5, 17

- Alex Krizhevsky, Ilya Sutskever, and Geoffrey E. Hinton. Imagenet classification with deep convolutional neural networks. In *NIPS*, 2012. 17
- Sascha Lange and Martin A. Riedmiller. Deep auto-encoder neural networks in reinforcement learning. In *The 2010 International Joint Conference on Neural Networks (IJCNN)*, pp. 1–8, 2010. 2
- Michael Laskin, Kimin Lee, Adam Stooke, Lerrel Pinto, Pieter Abbeel, and Aravind Srinivas. Reinforcement learning with augmented data. *arXiv preprint arXiv:2004.14990*, 2020. 2, 5, 17
- Kimin Lee, Kibok Lee, Jinwoo Shin, and Honglak Lee. A simple randomization technique for generalization in deep reinforcement learning. *ArXiv*, abs/1910.05396, 2019. 1
- Sergey Levine, Chelsea Finn, Trevor Darrell, and Pieter Abbeel. End-to-end training of deep visuomotor policies. *The Journal of Machine Learning Research*, 17(1):1334–1373, 2016. 1
- Ya Feng Li, Mingming Gong, Xinmei Tian, Tongliang Liu, and Dacheng Tao. Domain generalization via conditional invariant representations. In *AAAI*, 2018. 2
- Vincenzo Lomonaco, Karen Desai, Eugenio Culurciello, and Davide Maltoni. Continual reinforcement learning in 3d non-stationary environments. *arXiv preprint arXiv:1905.10112*, 2019. 2, 4, 7, 16, 17
- Mingsheng Long, Han Zhu, Jianmin Wang, and Michael I Jordan. Unsupervised domain adaptation with residual transfer networks. In *Advances in Neural Information Processing Systems*, pp. 136–144, 2016. 2
- Toshihiko Matsuura and Tatsuya Harada. Domain generalization using a mixture of multiple latent domains, 2019. 2
- Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Alex Graves, Ioannis Antonoglou, Daan Wierstra, and Martin Riedmiller. Playing atari with deep reinforcement learning. *arXiv preprint arXiv:1312.5602*, 2013. 1
- Volodymyr Mnih, Adrià Puigdomènech Badia, Mehdi Mirza, Alex Graves, Timothy P. Lillicrap, Tim Harley, David Silver, and Koray Kavukcuoglu. Asynchronous methods for deep reinforcement learning, 2016. 4, 7, 17
- Ravi Teja Mullapudi, Steven Chen, Keyi Zhang, Deva Ramanan, and Kayvon Fatahalian. Online model distillation for efficient video inference. *2019 IEEE/CVF International Conference on Computer Vision (ICCV)*, Oct 2019. doi: 10.1109/iccv.2019.00367. 3
- Ashvin V Nair, Vitchyr Pong, Murtaza Dalal, Shikhar Bahl, Steven Lin, and Sergey Levine. Visual reinforcement learning with imagined goals. In *Advances in Neural Information Processing Systems*, pp. 9191–9200, 2018. 1
- Mehdi Noroozi and Paolo Favaro. Unsupervised learning of visual representations by solving jigsaw puzzles. In *European Conference on Computer Vision*, pp. 69–84. Springer, 2016. 2
- Charles Packer, Katelyn Gao, Jernej Kos, Philipp Krähenbühl, Vladlen Koltun, and Dawn Song. Assessing generalization in deep reinforcement learning, 2018. 6
- Deepak Pathak, Philipp Krahenbuhl, Jeff Donahue, Trevor Darrell, and Alexei A Efros. Context encoders: Feature learning by inpainting. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 2536–2544, 2016. 2
- Deepak Pathak, Pulkit Agrawal, Alexei A. Efros, and Trevor Darrell. Curiosity-driven exploration by self-supervised prediction. In *ICML*, 2017. 2
- Xue Bin Peng, Marcin Andrychowicz, Wojciech Zaremba, and Pieter Abbeel. Sim-to-real transfer of robotic control with dynamics randomization. *2018 IEEE International Conference on Robotics and Automation (ICRA)*, May 2018. 1, 2

- Lerrel Pinto and Abhinav Gupta. Supersizing self-supervision: Learning to grasp from 50k tries and 700 robot hours. In *2016 IEEE international conference on robotics and automation (ICRA)*, pp. 3406–3413. IEEE, 2016. 1
- Lerrel Pinto, Marcin Andrychowicz, Peter Welinder, Wojciech Zaremba, and Pieter Abbeel. Asymmetric actor critic for image-based robot learning. *arXiv preprint arXiv:1710.06542*, 2017a. 1, 2
- Lerrel Pinto, James Davidson, Rahul Sukthankar, and Abhinav Gupta. Robust adversarial reinforcement learning. In *Proceedings of the 34th International Conference on Machine Learning-Volume 70*, pp. 2817–2826. JMLR. org, 2017b. 1
- Aravind Rajeswaran, Sarvjeet Ghotra, Balaraman Ravindran, and Sergey Levine. Epopt: Learning robust neural network policies using model ensembles. *arXiv preprint arXiv:1610.01283*, 2016. 1
- Fabio Ramos, Rafael Possas, and Dieter Fox. Bayessim: Adaptive domain randomization via probabilistic inference for robotics simulators. *Robotics: Science and Systems XV*, Jun 2019. 2
- Benjamin Recht, Rebecca Roelofs, Ludwig Schmidt, and Vaishal Shankar. Do cifar-10 classifiers generalize to cifar-10? *arXiv preprint arXiv:1806.00451*, 2018. 2
- Benjamin Recht, Rebecca Roelofs, Ludwig Schmidt, and Vaishal Shankar. Do imagenet classifiers generalize to imagenet? *arXiv preprint arXiv:1902.10811*, 2019. 2
- Andrei A Rusu, Neil C Rabinowitz, Guillaume Desjardins, Hubert Soyer, James Kirkpatrick, Koray Kavukcuoglu, Razvan Pascanu, and Raia Hadsell. Progressive neural networks. *arXiv preprint arXiv:1606.04671*, 2016. 1
- Fereshteh Sadeghi and Sergey Levine. Cad2rl: Real single-image flight without a single real image. *arXiv preprint arXiv:1611.04201*, 2016. 1, 2
- Ramanan Sekar, Oleh Rybkin, Kostas Daniilidis, Pieter Abbeel, Danijar Hafner, and Deepak Pathak. Planning to explore via self-supervised world models, 2020. 2
- Vaishal Shankar, Achal Dave, Rebecca Roelofs, Deva Ramanan, Benjamin Recht, and Ludwig Schmidt. A systematic framework for natural perturbations from videos. *arXiv preprint arXiv:1906.02168*, 2019. 2
- Assaf Shocher, Nadav Cohen, and Michal Irani. Zero-shot super-resolution using deep internal learning, 2017. 3
- Assaf Shocher, Shai Bagon, Phillip Isola, and Michal Irani. Ingan: Capturing and remapping the ”dna” of a natural image, 2018. 3
- Aravind Srinivas, Michael Laskin, and Pieter Abbeel. Curl: Contrastive unsupervised representations for reinforcement learning. *arXiv preprint arXiv:2004.04136*, 2020. 2, 4, 5, 6, 7, 17
- Yu Sun, Eric Tzeng, Trevor Darrell, and Alexei A Efros. Unsupervised domain adaptation through self-supervision. *arXiv preprint*, 2019. 2
- Yu Sun, Xiaolong Wang, Zhuang Liu, John Miller, Alexei A. Efros, and Moritz Hardt. Test-time training with self-supervision for generalization under distribution shifts. *ICML*, 2020. 3
- Christian Szegedy, Wei Liu, Yangqing Jia, Pierre Sermanet, Scott Reed, Dragomir Anguelov, Dumitru Erhan, Vincent Vanhoucke, and Andrew Rabinovich. Going deeper with convolutions. *2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 1–9, 2015. 17
- Yuval Tassa, Yotam Doron, Alistair Muldal, Tom Erez, Yazhe Li, Diego de Las Casas, David Budden, Abbas Abdolmaleki, Josh Merel, Andrew LeFrancq, Timothy Lillicrap, and Martin Riedmiller. DeepMind control suite. Technical report, DeepMind, January 2018. 2, 4, 5, 16, 17
- Josh Tobin, Rachel Fong, Alex Ray, Jonas Schneider, Wojciech Zaremba, and Pieter Abbeel. Domain randomization for transferring deep neural networks from simulation to the real world. *2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, Sep 2017. 1, 2

- Eric Tzeng, Judy Hoffman, Kate Saenko, and Trevor Darrell. Adversarial discriminative domain adaptation. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 7167–7176, 2017. 2
- Pascal Vincent, Hugo Larochelle, Yoshua Bengio, and Pierre-Antoine Manzagol. Extracting and composing robust features with denoising autoencoders. In *Proceedings of the 25th international conference on Machine learning*, pp. 1096–1103. ACM, 2008. 2
- Xiaolong Wang and Abhinav Gupta. Unsupervised learning of visual representations using videos. In *ICCV*, 2015. 2
- Xiaolong Wang, Allan Jabri, and Alexei A. Efros. Learning correspondence from the cycle-consistency of time. In *CVPR*, 2019. 2
- Mitchell Wortsman, Kiana Ehsani, Mohammad Rastegari, Ali Farhadi, and Roozbeh Mottaghi. Learning to learn how to learn: Self-adaptive visual navigation using meta-learning, 2018. 3
- Zhirong Wu, Yuanjun Xiong, Stella X Yu, and Dahua Lin. Unsupervised feature learning via non-parametric instance discrimination. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 3733–3742, 2018. 2
- Marek Wydmuch, Michał Kempka, and Wojciech Jaśkowski. Vizdoom competitions: Playing doom from pixels. *IEEE Transactions on Games*, 2018. 2, 7, 16
- Wilson Yan, Ashwin Vangipuram, Pieter Abbeel, and Lerrel Pinto. Learning predictive representations for deformable objects using contrastive estimation. *arXiv preprint arXiv:2003.05436*, 2020. 1, 2
- Jiachen Yang, Brenden Petersen, Hongyuan Zha, and Daniel Faissol. Single episode policy transfer in reinforcement learning, 2019. 1, 2
- Denis Yarats, Amy Zhang, Ilya Kostrikov, Brandon Amos, Joelle Pineau, and Rob Fergus. Improving sample efficiency in model-free reinforcement learning from images, 2019. 2, 4, 5, 17
- Richard Zhang, Phillip Isola, and Alexei A Efros. Colorful image colorization. In *European conference on computer vision*, pp. 649–666. Springer, 2016. 2
- Richard Zhang, Phillip Isola, and Alexei A Efros. Split-brain autoencoders: Unsupervised learning by cross-channel prediction. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 1058–1067, 2017. 2

训练环境性能

历史上，在仅在仿真中基准测试强化学习算法时，智能体通常在与训练相同的环境中进行训练和评估。尽管这种评估方式未考虑泛化性，但它仍然是比较算法样本效率和稳定性的有用度量。为完整起见，我们也在 DMControl 和 CRLMaze 上评估了我们的方法和基线。DMControl 结果见表 7，CRLMaze 环境结果见表 8。在此设置下，我们还在 DMControl 上增加了一个基线：一个仅基于先前动作的盲智能体（SAC）。盲智能体的性能表明给定任务从视觉信息中获益的程度。我们发现，虽然 PAD 改善了对新环境的泛化，但在与训练相同的环境中评估时性能几乎不变。我们推测这是因为算法已经适应了训练环境，因此在相同数据分布上的任何继续训练影响甚微。我们进一步强调，即使在训练环境中评估，PAD 在大多数任务上仍优于基线。例如，在 Finger, spin 任务上，我们观察到相对于 SAC 有 **15%** 的相对提升。我们假设这种性能提升是因为自监督目标通过约束策略的中间表示来改善学习。盲智能体在此特定任务上并不比随机好，这表明智能体在 Finger, spin 中从视觉信息中获益显著。因此，学习该信息的良好中间表示对强化学习目标非常有益，我们发现 PAD 通过其自监督学习框架促进了这一点。同样，SAC 基线在 Cartpole, balance 上仅比盲智能体提高 51%，这表明从观测中提取视觉信息在此任务上并不那么关键。因此，PAD 和基线在此任务上取得了相似的性能。

表 7. DMControl 中 9 个任务在训练环境上的回合回报，10 个种子的均值和标准差。每个任务上的最佳方法以粗体显示，蓝色比较了带 PAD 和不带 PAD 的+IDM。结果表明，当环境不变时，PAD 的负面影响极小。

Training env.	Blind	SAC	+DR	+IDM	+IDM (PAD)
Walker, walk	235±17	847±71	756±71	911±24	895±28
Walker, stand	388±10	959±11	928±36	966±8	956±20
Cartpole, swingup	132±41	850±28	807±36	849±30	845±34
Cartpole, balance	646±131	978±22	971±30	982±20	979±21
Ball in cup, catch	150±96	725±355	469±339	919±118	910±129
Finger, spin	3±2	809±138	686±295	928±45	927±45
Finger, turn_easy	172±27	462±146	243±124	462±152	455±160
Cheetah, run	264±75	387±74	195±46	384±88	380±91
Reacher, easy	107±11	264±113	92±45	390±126	365±114

表 8. PAD 与基线方法在 CRLMaze 训练环境中的回合回报。所有方法均使用 A2C。我们报告 10 个随机种子的均值与标准误差。最佳方法以粗体和蓝色标示，比较了有无 PAD 的旋转预测。

CRLMaze	Random	A2C	+DR	+IDM	+IDM (PAD)	+Rot	+Rot (PAD)
Training env.	-868±34	371±198	-355±93	585±246	-416±135	729±148	681±99

B 深度思维控制上的学习曲线

所有方法在 DMControl 上训练直至收敛（500,000 帧）。虽然本研究未考虑方法及基线的样本效率，但为完整性起见，我们在图 5 中报告了 SAC、SAC+IDM 以及使用领域随机化训练的 SAC 在三个任务上的学习曲线。使用与不使用 IDM 的 SAC 在样本效率和最终性能上相似，而领域随机化始终表现出更差的样本效率、更大的种子间差异，并在所示三个任务中的两个上收敛至次优性能。




图 5. SAC、使用领域随机化训练的 SAC（此处记为 SAC (DR)）以及 SAC+IDM 在深度思维控制套件（DMControl）三个任务上的学习曲线。回合回报在 10 个随机种子上取平均，95% 置信区间以阴影区域显示。SAC 与 SAC+IDM 表现出相似的样本效率和最终性能，而领域随机化始终表现出更差的样本效率、更大的种子间差异，并在所示三个任务中的两个上收敛至次优性能。

C KEEPING π_s 策略适应期间固定 我们现在考虑 PAD 的一种变体，其中自监督任务头 π_s 在测试时固定，使得自监督目标 L 仅针对 π_e 进行优化，如第 3.3 节所述。我们测量对具有随机化颜色的测试环境的泛化能力，并在表 9 中报告深度思维控制套件中三个任务的结果。我们通过实验发现更新 π_s 与保持其固定之间的差异可忽略不计，因此默认选择更新 π_s ，因为其梯度无论如何都会通过反向传播计算。

表 9. 在具有随机化颜色的测试环境中的回合回报，10 个随机种子的均值与标准差。所有方法均使用 SAC。IDM (PAD, 固定 π_s) 考虑 PAD 的一种变体，其中 π_s 在测试时固定，而 IDM (PAD) 表示 PAD 的默认用法，即在测试时使用自监督目标同时优化 π_e 和 π_s 。

Random colors	IDM	IDM (PAD, fixed π_s)	IDM (PAD)
Walker, walk	406±29	452±38	468±47
Walker, stand	743±37	802±41	797±46
Cartpole, swingup	585±73	623±57	630±63

D 与基于奖励的自适应的比较

虽然本文方法不需要部署前收集的数据，也不假设能够获得奖励信号，但本文仍将所提方法与一种朴素的微调方法进行了比较，该方法使用部署前从目标环境收集的转移样本和奖励。为了利用奖励微调预训练策略，本文使用学习到的策略在保持其参数不变的情况下，在每个目标环境中收集包含 1、10 和 100 个回合的数据集，然后按照训练阶段相同的训练流程，在收集到的数据上微调 π_e 和 π_a 。这种微调方法类似于 Julian 等人（2020）的方法，但在适应过程中不使用原始环境的数据。结果见表 10。本文发现，使用部署前收集的数据朴素地微调策略可以改善泛化性能，但需要比 PAD 多得多的数据，并且需要获得目标环境中的奖励信号。这一发现表明，在目标环境数据稀缺且部署前不易获取的场景下，PAD 可能是更合适的方法。

E 附加机器人操作样本

图 6 展示了抓取机器人操作任务中训练环境和测试环境的样本。智能体在仿真中训练，并部署到真实机器人上。推动任务的样本如图 4 所示。

表 10. 在颜色随机化的测试环境中的回合回报，均值和标准差基于 10 个随机种子。所有方法均使用以逆动力学模型（IDM）作为辅助任务的 SAC。本文方法记为 IDM（PAD），并与一种朴素的微调方法进行比较，该方法假设在部署前可以分别从目标环境收集 1、10 和 100 个回合的转移样本和奖励。

Random colors	Fine-tuning w/ rewards				
	IDM	IDM (PAD)	1 episode	10 episodes	100 episodes
Walker, walk	406±29	468±47	395±78	489±104	561±62
Walker, stand	743±37	797±46	661±65	728±44	784±31
Cartpole, swingup	585±73	630±63	538±53	605±51	650±58




图 6. 抓取机器人操作任务的样本。任务是将机器人夹爪移动到红色圆盘的位置。智能体在设置（a）中训练，并在真实机器人上于设置（b-d）中评估，观测来自未标定的相机。

F 实现细节

本节详细阐述在 DeepMind Control（DMControl）套件（Tassa 等人，2018）和用于 ViZDoom（Wydmuch 等人，2018）的 CRLMaze（Lomonaco 等人，2019）上的实验实现细节。机器人操作实验的实现与 DMControl 的实现基本一致。代码可在 <https://nicklashansen.github.io/PAD/> 获取。




图 7. 用于 DMControl、CRLMaze 和机器人操作实验的网络架构。 π^s 和 π^a 使用共享特征提取器 π^e 。观测是 100×100 个彩色帧的堆叠。策略和值函数的实现取决于学习算法。

架构。我们的网络架构如图 7 所示。观测是堆叠的帧 ($k = 3$ ，以 100×100 渲染并裁剪为 84×84 ，即网络输入的维度为 $9 \times 84 \times 84$ ，其中第一维表示通道数，后续维度表示空间维度。同一裁剪应用于堆叠中的所有帧。共享特征提取器 π^e 由 8 个（DMControl、机器人操作）或 6 个（CRLMaze）卷积层组成，在 DMControl 和机器人操作中输出大小为 $32 \times 21 \times 21$ 的特征，在 CRLMaze 中输出大小为 $32 \times 25 \times 25$ 的特征。 π^e 的输出同时用作自监督头 π^s 和强化学习头 π^a 的输入，两者均由 3 个卷积层和随后的 3 个全连接层组成。所有

表 11. 用于 DMControl (Tassa 等人, 2018) 任务的超参数。

Hyperparameter	Value
Frame rendering	$3 \times 100 \times 100$
Frame after crop	$3 \times 84 \times 84$
Stacked frames	3
Action repeat	2 (finger) 8 (cartpole) 4 (otherwise)
Discount factor γ	0.99
Episode length	1,000
Learning algorithm	Soft Actor-Critic
Self-supervised task	Inverse Dynamics Model
Number of training steps	500,000
Replay buffer size	500,000
Optimizer (π^e, π^a, π^s)	Adam ($\beta_1 = 0.9, \beta_2 = 0.999$)
Optimizer (α)	Adam ($\beta_1 = 0.5, \beta_2 = 0.999$)
Learning rate (π^e, π^a, π^s)	$3e-4$ (cheetah) $1e-3$ (otherwise)
Learning rate (α)	$1e-4$
Batch size	128
Batch size (test-time)	32
π^e, π^s update freq.	2
π^e, π^s update freq. (test-time)	1

表 12. 用于 CRLMaze (Lomonaco 等人, 2019) 导航任务的超参数。

Hyperparameter	Value
Frame rendering	$3 \times 100 \times 100$
Frame after crop	$3 \times 84 \times 84$
Stacked frames	3
Action repeat	4
Discount factor γ	0.99
Episode length	1,000
Learning algorithm	Advantage Actor-Critic
Self-supervised task	Rotation Prediction
Number of training episodes	1,000 (dom. rand.) 500 (otherwise)
Number of processes	20
Optimizer	Adam ($\beta_1 = 0.9, \beta_2 = 0.999$)
Learning rate	$1e-4$
Learning rate (test-time)	$1e-5$
Batch size	20
Batch size (test-time)	32
π^e, π^s loss coefficient	0.5
π^e, π^s loss coefficient (test-time)	1
π^e, π^s update freq.	1
π^e, π^s update freq. (test-time)	1

卷积层使用 32 个滤波器, 所有全连接层使用 1024 的隐藏大小, 如 Yarats 等人 (2019) 所述。

学习算法。我们在 DMControl 和机器人操作中使用软演员-评论家 (SAC) (Haarnoja 等人, 2018), 在 CRLMaze 中使用优势演员-评论家 (A2C)。网络输出取决于任务和学习算法。由于 DMControl 和机器人操作的动作空间是连续的, SAC 学习的策略输出动作上高斯分布的均值和方差。CRLMaze 具有离散动作空间, 因此 A2C 学习的策略学习动作上的 soft-max 分布。关于 SAC 和 A2C 学习的评论家的详细信息, 请分别参考 Haarnoja 等人 (2018) 和 Mnih 等人 (2016)。

超参数。在适用的情况下, 我们采用 Yarats 等人 (2019) (DMControl、机器人操作) 和 Lomonaco 等人 (2019) (CRLMaze) 的超参数。对于机器人操作实验, 我们的实现与 DMControl 的实现非常接近, 仅观测中的帧数不同。对于 DMControl 和 CRLMaze, 我们使用 $k = 3$ 帧的帧堆叠, 而对于机器人操作, 仅使用 $k = 1$ 帧。为完整起见, 我们在表 11 和表 12 中详细列出了 DMControl 和 CRLMaze 环境所使用的所有超参数。

数据增强。随机裁剪是计算机视觉系统中常用的一种数据增强方法 (Krizhevsky 等人, 2012; Szegedy 等人, 2015), 但直到最近才作为强化学习文献中的一种随机正则化技术引起关注 (Srinivas 等人, 2020; Kostrikov 等人, 2020; Laskin 等人, 2020)。我们采用 Srinivas 等人 (2020) 提出的随机裁剪: 将渲染的观测从尺寸 100×100 裁剪到 84×84 , 并对堆叠观测中的所有帧应用相同的裁剪。这既带来了正则化的好处, 又保留了帧间的时空模式。在学习逆动力学模型时, 我们对给定观测的所有帧应用相同的裁剪, 但对用于预测动作 $\mathbf{a}_t$ 的连续观测 $(\mathbf{s}_t, \mathbf{s}_{t+1})$ 应用两种不同的裁剪。

部署期间策略自适应。我们通过智能体在单一环境中训练、在一组测试环境中测试的回合回报来评估我们的方法和基线, 每个测试环境与训练环境都有不同的变化。我们假设测试时没有奖励信号, 并且智能体需要在新环境中无需预训练或重置即可泛化。因此, 我们使用自监督目标对策略进行更新, 并以在线方式使用环境中的观测进行训练, 且不依赖记忆, 即每一步仅使用最近的观测进行一次更新。

经验上，我们发现：（i）训练期间使用的随机裁剪数据增强有助于在测试时对学习进行正则化；
（ii）我们的算法从一批随机裁剪的观测中学习比从单个观测中学习更有利，即使批次中的所有观测都是最近观测的增强副本。因此，在执行部署期间策略自适应时，我们同时应用这两种技术，并使用批大小为 32。然而，当使用策略采取动作时，策略的输入仅为中央裁剪后的观测。