

# 摒弃关于基于学习的车辆运动规划的误解

Daniel Dauner<sup>1,2</sup> Marcel Hallgarten<sup>1,3</sup> Andreas Geiger<sup>1,2</sup> Kashyap Chitta<sup>1,2</sup>

<sup>1</sup>University of Tübingen <sup>2</sup>Tübingen AI Center <sup>3</sup>Robert Bosch GmbH

[https://github.com/autonomousvision/tuplan\\_garage](https://github.com/autonomousvision/tuplan_garage)

**摘要：**nuPlan 的发布标志着车辆运动规划研究的新纪元，提供了首个大规模真实世界数据集和评估方案，要求同时具备精确的短期规划和长时域自车预测能力。现有系统难以同时满足这两项要求。事实上，我们发现这些任务在根本上是不一致的，应当独立处理。我们进一步评估了该领域闭环规划的现状，揭示了基于学习的方法在复杂真实场景中的局限性，以及通过车道图搜索算法选择中心线等简单基于规则的先验知识的价值。更令人惊讶的是，对于开环子任务，我们观察到仅使用该中心线作为场景上下文（即忽略所有关于地图和其他智能体的信息）时取得了最佳结果。结合这些洞见，我们提出了一种极其简单且高效的规划器，其性能超越了众多竞争者，赢得了 2023 年 nuPlan 规划挑战赛。

**关键词：**运动规划，自动驾驶，数据驱动仿真

## 1 引言

尽管基于学习的系统在车辆运动规划研究中取得了成功 [1, 2, 3, 4, 5]，但缺乏用于基准测试的标准化大规模数据集阻碍了它们从研究向应用的转化 [6, 7, 8]。近期发布的 nuPlan 数据集和仿真器 [9] 收集了 1300 小时的真实世界车辆运动数据，改变了这一现状，使得新一代学习型运动规划器的开发成为可能，这些规划器有望减少人工设计工作并提高可扩展性。借助这一新基准，我们首次在用于车辆运动规划的大规模、开源、数据驱动仿真器上进行了严格的实证分析，包括使用官方度量标准对一组全面的最先进（SoTA）规划器 [10, 11, 12] 进行评估。我们的分析得出了几个令人惊讶的发现：

**开环评估与闭环评估不一致。**大多数学习型规划器通过监督学习任务进行训练，该任务是在给定目标位置的条件下预测自车未来运动。我们将此设置称为自车预测 [2, 3, 13, 14]。在 nuPlan 中，规划器可以通过两种方式进行评估：（1）开环评估，使用基于距离的度量来衡量自车预测准确率；或（2）闭环评估，在仿真中使用进度或碰撞率等度量来评估实际驾驶性能。开环评估缺乏动态反馈，并且与闭环驾驶的相关性可能很小，正如之前在简单的 CARLA 仿真器上所示 [15, 16]。我们的主要贡献在于揭示了两种评估方案之间的负相关性。学习型规划器在自车预测方面表现出色，但难以制定安全的闭环计划，而基于规则的规划器则表现出相反的趋势。

**基于规则的规划具有泛化性。**我们惊讶地发现，一个二十多年前建立的基于规则的规划基线 [17] 在我们的基准测试中，在闭环评估度量方面超越了所有最先进的学习型方法。这与大多数学习型规划器研究中普遍使用的动机性主张相矛盾，即基于规则的规划在泛化方面面临困难。

这之前仅在更简单的基准测试上得到验证 [4, 10, 11]。因此，当前大多数关于学习型规划的工作仅与其他学习方法进行比较，而忽略了基于规则的基线 [3, 5, 18]。

**仅需中心线即可进行自车预测。**我们实现了一个朴素的学习型规划基线，该基线不包含关于场景中其他智能体的任何输入，仅根据所需路线的中心线表示来外推自车状态。该基线在我们的基准测试中为开环评估设立了新的最先进水平。它不需要复杂的场景表示（例如车道图、矢量化地图、栅格化地图、标记化对象），而这些一直是先前工作的核心研究主题 [10, 11, 12]。这些先前的研究均未考虑仅使用中心线的简单表示作为基线，这或许是因为其极其简单。

本文贡献如下：（1）我们揭示并分析了规划中开环与闭环评估方案之间的错位。（2）我们提出一种轻量级 IDM 扩展 [17]，具备实时能力，达到最先进的闭环性能。（3）我们使用仅以当前动态状态和中心线为条件的开环规划器进行实验，表明其优于具有复杂输入表示的复杂模型。（4）通过将两种模型结合为混合规划器，我们建立了一个简单基线，在 nuPlan 挑战赛 2023 中击败了 24 种其他方法（多为基于学习的方法）并夺冠。

## 2 相关工作


**基于规则的规划。**基于规则的规划器提供结构化、可解释的决策框架 [17, 19, 20, 21, 22, 23, 24, 25, 26]。它们采用显式规则确定自动驾驶车辆的行为（例如，当正前方有物体时刹车）。基于规则的规划中一个开创性方法是智能驾驶员模型（IDM[17]），旨在跟随交通中的前车并保持安全距离。IDM 存在扩展 [27]，专注于实现高速公路上的变道。然而，这不是本文的目标。相反，我们通过执行具有不同超参数的多个策略并对其评分以选择最佳选项来扩展 IDM。

先前工作还将基于规则的决策与学习组件相结合，例如学习到的智能体预测 [28]、可供性指标 [23, 24]、基于代价的模仿学习 [4, 29, 30, 31, 32]，或基于学习的规划与基于规则的安全过滤 [33]。这些混合规划器通常预测未来环境状态，从而实现知情且条件化的驾驶决策。这种预测可以是智能体中心的 [34, 35, 36]，为每个参与者确定轨迹，也可以是环境中心的 [4, 31, 30, 29, 37, 38]，涉及占用或代价地图。此外，预测可以以自车计划为条件，建模自车对场景未来的影响 [39, 40, 41, 42]。我们采用一个智能体中心的预测模块，该模块比现有方法简单得多，使其可作为新发布的 nuPlan 框架中的起点。

**自车预测。**与预测性规划不同，自我预测方法利用观测数据直接确定未来轨迹。自我预测方法包括端到端方法 [43]，这些方法利用激光雷达扫描 [44, 45]、RGB 图像 [46, 47, 48, 49, 14, 50] 或两者结合 [13, 51, 5, 52]，以及涉及低维输入的模块化方法，如鸟瞰图（BEV）网格或状态向量 [24, 53, 11, 54, 55, 56]。一项同期研究引入了一个简单的多层感知机，输入当前动态状态，在 nuScenes 数据集 [57] 上取得了具有竞争力的自我预测结果，且没有场景上下文输入 [58]。我们的发现补充了这些结果，不同之处在于我们在具有挑战性的 2023 年 nuPlan 挑战场景测试分布 [9] 中评估了长期（8 秒）自我预测。我们表明，在这种设置下，完全移除场景上下文（如 [58]）是有害的，而简单的中心线表示上下文足以实现强大的开环性能。

## 3 自我预测与规划不一致

在本节中，我们提供关于数据驱动模拟器 nuPlan[9] 的相关背景。我们描述了两个基线用于初步实验，以证明尽管自我预测和规划通常被认为是相关任务，但根据它们在 nuPlan 上的定义，它们并不完全一致。一个任务的改进往往会导致另一个任务的退化。



**图 1：规划与自我预测。**我们展示了一个 nuPlan 场景，用灰色突出可行驶区域，用黑色虚线表示原始人类轨迹。在每个快照中，我们显示自我代理及其预测。（左）观察 IDM 预测（受限于基于规则的中心线）与人类轨迹之间的显著位移，导致低开环分数。（中+右）在模拟 0.5 秒后，学习的 PDM-Open 规划器外推其自身误差并最终偏离道路，导致次优的闭环分数。

### 3.1 背景

**nuPlan.** nuPlan 仿真器是首个公开可用的真实世界规划基准，能够实现运动规划器的快速原型设计与测试。nuPlan 通过数据驱动仿真构建尽可能接近真实世界驾驶环境的模拟场景 [59, 60, 61, 62, 63, 64, 65]。该方法从包含 1300 小时真实世界驾驶数据的预记录数据集中提取道路地图、交通模式以及物体属性（位置、朝向和速度）。随后，这些元素被用于初始化场景，即用于评估开环与闭环驾驶性能的 15 秒仿真。因此，在仿真中，本文方法依赖于详细的高精地图信息和真值感知，即不考虑定位误差、地图缺陷或误检测。在开环仿真中，整个日志仅被回放（包括自车和其他参与者）。相反，在闭环仿真中，自车在被测规划器的控制下运行。闭环仿真有两种版本：非反应式，其中所有其他参与者沿其原始轨迹回放；反应式，其中其他车辆采用智能驾驶员模型（IDM）规划器 [17]，其细节将在下文阐述。

**度量指标。**nuPlan 提供三种官方评估度量：开环分数（OLS）、闭环分数非反应式（CLS-NR）和闭环分数反应式（CLS-R）。尽管 CLS-NR 和 CLS-R 的计算方式相同，但它们在背景交通行为上有所不同。每个分数是子分数的加权平均，这些子分数乘以一组惩罚项。在 OLS 中，子分数考虑了在较长时间段（8 秒）内的位移和航向误差，包括平均误差和最终误差。此外，如果预测误差超过阈值，惩罚会导致该场景的 OLS 分数为零。类似地，CLS 中的子分数包括碰撞时间、沿专家路线的进展、限速合规性和舒适性。CLS 的乘法惩罚包括责任碰撞、可行驶区域或行驶方向违规以及未取得进展。这些惩罚会导致 CLS 大幅降低，大多数情况下场景分数为零，例如与车辆碰撞时。值得注意的是，CLS 主要依赖于短期动作，而非一致的长期规划。所有分数（包括 OLS/CLS）的范围从 0 到 100，分数越高越好。鉴于 nuPlan 度量的复杂构成，我们参考补充材料以获取详细描述。

**智能驾驶员模型。**简单的规划基线智能驾驶员模型（IDM）[17] 不仅在 nuPlan 的 CLS-R 评估中模拟非自车车辆，还作为自车规划的基线。nuPlan 地图以图的形式提供，中心线段作为节点。通过图搜索算法选择一组要跟随的节点后，IDM 沿所选中心线推断纵向轨迹。给定当前纵向位置  $x$ 、速度  $v$  以及沿中心线到前车的距离  $s$ ，它迭代地应用以下策略

计算纵向加速度：

$$\frac{dv}{dt} = a \left( 1 - \left( \frac{v}{v_0} \right)^\delta - \left( \frac{s^*}{s} \right)^2 \right). \quad (1)$$

加速度极限  $a$ 、目标速度  $v_0$ 、安全裕度  $s^*$  和指数  $\delta$  均为人工选定。直观上，该策略采用加速度  $a$ ，除非速度已接近  $v_0$  或前车距离仅为  $s^*$ 。更多细节及精确的超参数选择见补充材料。

### 3.2 失配

**基于中心线条件约束的自我轨迹预测。** 我们现在提出预测性驾驶模型（开放版），即 PDM-Open，它是一个直接的多层感知器（MLP），旨在预测未来航点。该 MLP 的输入是由 IDM 提取的中心线（ $\mathbf{c}$ ）和自车历史（ $\mathbf{h}$ ）。为了适应 nuPlan 中观察到的高速（最高可达 15 m/s）和自车预测范围（延伸至 8 秒），中心线以 1 米分辨率采样，长度可达 120 米。同时，自车历史包含车辆前两秒的位置、速度和加速度，采样率为 5Hz。 $\mathbf{c}$  和  $\mathbf{h}$  均被线性投影到大小为 512 的特征向量，拼接后输入 MLP  $\phi_{\text{open}}$ ，该 MLP 具有两个 512 维隐藏层。输出是 8 秒范围内的未来航点，间隔 0.5 秒，表示为  $\mathbf{w}_{\text{open}} = \phi_{\text{open}}(\mathbf{c}, \mathbf{h})$ 。模型使用  $L_1$  损失在我们的 177k 样本训练数据集上进行训练（见第 4 节）。从设计上讲，PDM-Open 比现有的学习型规划器 [10, 12] 简单得多。

**普通最小二乘法与条件最小二乘法对比。** 在表 1 中，我们使用 nuPlan 度量对 IDM 和 PDM-Open 基线进行了基准测试。我们展示了两种具有不同最大加速度值的 IDM 变体（默认  $a = 1.0\text{ms}^{-2}$  和  $a = 0.1\text{ms}^{-2}$ ）以及基于不同输入的四种 PDM-Open 变体。我们观察到，降低 IDM 的加速度可改善开环评分（OLS），但对闭环评分（CLS）产生负面影响。虽然 IDM 展现出强大的闭环性能，但 PDM-Open 在开环中优于 IDM，即使它仅使用当前自车状态作为输入（第一行）。历史自车状态（History）仅带来微小改进，并导致 CLS 下降。最重要的是，添加中心线显著有助于自车预测性能。CLS 与 OLS 之间的明显权衡表明，自车预测与规划的目标之间存在不一致。考虑到当前规划文献中自车预测的使用日益增多，nuPlan 上的这种逆相关性是出乎意料的 [3, 10, 12, 11]。虽然自车预测对于驾驶性能并非必需，但 nuPlan 挑战要求同时具备高 OLS 和高 CLS。


| Method              | Centerline   | History      | CLS-R $\uparrow$ | CLS-NR $\uparrow$ | OLS $\uparrow$ |
|---------------------|--------------|--------------|------------------|-------------------|----------------|
| IDM [17]            | $a = 1.0$    | $\checkmark$ | 77               | 76                | 38             |
|                     |              |              |                  |                   | 54             |
|                     | $a = 0.1$    | -            | 51               | 50                | 69             |
|                     |              |              |                  |                   | 4              |
| 产品数据管理开放 (PDM-Open) | $\checkmark$ | $\checkmark$ | 54               | 50                | 72             |
|                     |              |              |                  |                   | 3              |
|                     |              |              |                  |                   | 85             |
|                     |              |              |                  |                   | <b>86</b>      |

**表 1：OLS-CLS 权衡。** 在 nuPlan 上使用不同输入的基线得分。

在图 1 中，我们展示了 OLS 与 CLS 度量之间的不一致性。在所描绘的场景中，基于规则 IDM 选择了与人类驾驶员不同的车道。然而，在整个仿真过程中，它始终保持在道路上的位置。这导致了较高的 CLS 但较低的 OLS。相反，学习得到的 PDM-Open 沿着人类驾驶员选择的车道生成预测，从而获得了较高的 OLS。尽管如此，由于在仿真过程中其短期预测误差不断累积 [66, 67]，模型的轨迹偏离了可行驶区域，最终导致 CLS 较差。

### 3.3 方法

我们现在通过引入模型预测控制中的若干概念来扩展 IDM，包括预测、提议、仿真、评分和选择，如图 2（顶部）所示。我们将该模型称为 PDM-Closed。需要注意的是，作为第一步，我们仍然需要图搜索来找到沿路线的一系列车道并提取其中心线，这与 IDM 规划器中的做法相同。



**图 2：架构。** PDM-Closed 选择一条中心线，预测环境，并生成不同的轨迹提议，这些提议经过仿真和评分以进行轨迹选择。PDM-Hybrid 模块利用 PDM-Closed 的中心线、轨迹和自车历史来预测偏移量，仅修正长期航路点，从而限制学习模型在闭环仿真中的影响。

**预测。** 在 nuPlan 中，仿真器为每个动态智能体（如车辆或行人）提供方向向量和速度。我们利用一种简单而有效的恒定速度预测 [68, 69, 70]，在  $F$  8 秒的时间范围内以 10Hz 的频率进行。

**提议。** 在校准 IDM 规划器的过程中，我们观察到在为目标速度超参数（ $v_0$ ）选择单一值时存在权衡，这要么导致激进的驾驶行为，要么在各种场景中进展不足。因此，我们通过以五个不同的目标速度实施 IDM 策略来生成一组轨迹提议，即指定速度限制的  $\{20\%, 40\%, 60\%, 80\%, 100\%\}$ 。对于每个目标速度，我们还加入了具有三个横向中心线偏移（ $\pm 1$  米和 0 米）的提议，从而总共产生  $N = 15$  个提议。为了规避后续阶段的计算需求，这些提议的预测范围缩短为  $H$  步，对应于 10Hz 频率下的 4 秒。

**仿真。** 在 nuPlan 中，轨迹通过迭代地从 LQR 控制器 [71] 获取动作，并使用运动学自行车模型 [72, 73] 推进自车来仿真。我们使用相同的参数和该两阶段流程的更快重新实现来仿真提案。因此，提案基于闭环中的预期运动进行评估。

**评分。** 每个仿真提案都被评分，以偏向交通规则合规性、进展和舒适性。通过考虑具有横向和纵向多样性的提案，规划器可以避免与智能体预测的碰撞，并纠正当控制器无法准确跟踪预期轨迹时可能出现的漂移。此外，我们的评分函数与 nuPlan 评估度量非常相似。我们引导读者参阅补充材料以获取更多细节。

**轨迹选择。** 最后，PDM-Closed 选择得分最高的提案，该提案使用相应的 IDM 策略扩展到完整的预测范围  $F$ 。如果最佳轨迹预计在 2 秒内发生碰撞，则输出将被紧急制动操作覆盖。

**增强长时域精度。** 为了将 PDM-Open 的准确自车预测能力与 PDM-Closed 的精确短期动作相结合，我们现在提出 PDM 的混合版本，即 PDM-Hybrid。具体来说，PDM-Hybrid 使用学习模块 PDM-Offset 来预测 PDM-Closed 航路点的偏移量，如图 2（底部）所示。



| Method            | Rep.       | CLS-R $\uparrow$ | 闭环非反应性 $\uparrow$ | OLS $\uparrow$ | Time $\downarrow$ |
|-------------------|------------|------------------|-------------------|----------------|-------------------|
| Urban Driver [10] | Polygon    | 50               | 53                | 82             | 64                |
| GC-PGP [12]       | Graph      | 55               | 59                | 83             | 100               |
| PlanCNN [11]      | Raster     | 72               | 73                | 64             | 43                |
| IDM [17]          | Centerline | 77               | 76                | 38             | 27                |
| PDM-Open          | Centerline | 54               | 50                | <b>86</b>      | <b>7</b>          |
| PDM-Closed        | Centerline | <b>92</b>        | <b>93</b>         | 42             | 91                |
| PDM-Hybrid        | Centerline | <b>92</b>        | <b>93</b>         | 84             | 96                |
| PDM-Hybrid*       | Graph      | <b>92</b>        | <b>93</b>         | 84             | 172               |
| <i>Log Replay</i> | <i>GT</i>  | <i>80</i>        | <i>94</i>         | <i>100</i>     | -                 |

**表 2: Val14 基准。**我们展示了多个规划器的闭环得分反应性/非反应性 (CLS-R/CLS-NR)、开环得分 (OLS) 以及运行时间 (毫秒)。我们指定了每个规划器使用的输入表示 (Rep.)。PDM-Hybrid 实现了强大的自行车预测 (OLS) 和规划 (CLS)。\*这是 PDM-Hybrid 的初步版本, 它结合了 PDM-Closed 与 GC-PGP[12], 并用于我们的在线排行榜提交 (表 3)。

实际上, nuPlan 中使用的 LQR 控制器在闭环中确定动作时仅依赖轨迹的前 2 秒。因此, 仅对长期航点 (即默认超过 2 秒的航点, 我们称之为校正视界  $C$ ) 应用校正, 使 PDM-Hybrid 能够保持闭环规划性能。最终规划器输出航点 (直至预测视界  $F$ )  $\{\mathbf{w}_{\text{Hybrid}}^t\}_{t=0}^F$ , 由以下公式给出:

$$\mathbf{w}_{\text{Hybrid}}^t = \mathbf{w}_{\text{Closed}}^t + \mathbb{1}_{[t>C]} \phi_{\text{Offset}}^t(\mathbf{w}_{\text{Closed}}, \mathbf{c}, \mathbf{h}). \quad (2)$$

其中  $\mathbf{c}$  和  $\mathbf{h}$  分别是中心线和历史 (与 PDM-Open 的输入相同)。 $\{\mathbf{w}_{\text{Closed}}^t\}_{t=0}^F$  是添加到混合方法中的 **PDM-Closed** 航点,  $\phi_{\text{Offset}}$  是一个 MLP。其架构与  $\phi_{\text{Open}}$  相同, 除了额外的线性投影以适应  $\mathbf{w}_{\text{Closed}}$  作为额外输入。

值得注意的是, PDM-Hybrid 的设计具有高度模块化, 能够在出现多样化需求时用替代选项替换单个组件。例如, 我们在补充材料中展示了使用不同开环模块的结果。鉴于其整体简洁性, 一个有趣的探索方向是像 [34] 中那样将模块化但可微分的算法作为组件纳入。探索这些模块在统一多任务架构中的集成是另一个有趣的方向。我们将此类探索留待未来工作。

## 4 实验

我们现在概述所提出的基准, 并突出我们方法的驾驶性能。

**Val14 基准。**我们提供了用于训练和评估的标准化数据划分。训练使用 nuPlan 中全部 70 种场景类型, 每种类型最多限制为 4k 个场景, 共得到  $\sim 177\text{k}$  个训练场景。评估使用排行榜所考虑的 14 种场景类型中的 100 个场景, 共计 1,118 个场景。尽管存在轻微不平衡 (14 种类型并非都有 100 个可用场景), 我们的验证划分与在线排行榜评估一致 (表 2 和表 3), 证实了我们的 Val14 基准作为在线测试集代理的适用性。

**基线。**我们在研究中纳入了几种采用自我预测进行规划的额外最先进方法。Urban Driver [10] 使用 PointNet 层编码多边形, 并在多头注意力块之后通过线性层预测轨迹。我们的研究使用了在开环设置下训练的 Urban Driver 实现。GC-PGP [12] 在返回最可能的聚类中心之前, 基于路线约束的车道图遍历对轨迹提议进行聚类。PlanCNN [11] 使用 CNN 从栅格化网格特征预测航点, 且不输入自行车状态。它与该领域的开创性工作 ChauffeurNet [8] 有若干相似之处。赢得 nuPlan 竞赛的 PDM-Hybrid 初步版本使用 GC-PGP 作为其自我预测组件, 我们将其作为基线。我们在补充材料中提供了该版本的完整描述。

**结果。**我们的结果见表 2。PlanCNN 在学习型规划器中取得了最佳的闭环得分，可能得益于其设计选择：从输入中移除自车状态，以开环得分为代价换取闭环得分的提升。与社区在预测和规划中日益偏好基于图和向量的场景表示的趋势相反 [74, 11, 75, 76]，这些结果表明栅格表示在闭环任务中并无明显劣势，且 PlanCNN 还提供了更低的运行时间。令人意外的是，本研究中最简单的基于规则的方法 IDM 优于最佳学习型规划器 PlanCNN。此外，我们观察到 PDM-Closed 在闭环得分上优于 IDM：得益于第 3 节的思想，得分从 76-77 提升至 92-93。令人惊讶的是，PDM-Open 仅使用中心线和自车状态作为输入，就取得了 86 的最高开环得分，运行时间仅为 7 毫秒。我们观察到 PDM-Open 在精确的长时域车道跟随方面优于其他方法，详见补充材料。接下来，尽管 PDM-Closed 的开环得分仅为 42，PDM-Hybrid 成功地将 PDM-Closed 与 PDM-Open 相结合。PDM-Hybrid 的中心线版本和图版本在我们的评估中取得了相同的分数。然而，最终的中心线版本使用 PDM-Open 而非 GC-PGP，在推理时更加高效。最后，输出真实自车未来轨迹的特权方法（日志回放）未能取得完美的闭环得分，部分原因是 nuPlan 框架的 LQR 控制器偶尔会偏离所提供的轨迹。PDM-Hybrid 通过基于预期控制器结果评估候选轨迹来弥补这一点，使其在闭环评估中达到或超过日志回放的表现。

**挑战赛。**在 2023 年 nuPlan 挑战赛中，PDM-Hybrid 的初步（图）版本在 25 支参赛队伍中排名第一。排行榜综合考虑闭环得分-反应式、闭环得分-非反应式和开环得分的平均值。虽然开环性能略有落后，但闭环性能表现出色，最终取得了整体最先进的分数。遗憾的是，由于排行榜关闭，我们最终（中心线）版本的 PDM-Hybrid（用更简单的 PDM-Open 模块替换 GC-PGP）无法进行基准测试。所有顶尖竞争者都将学习型自车预测与基于规则的后求解器或后处理相结合，以提升挑战赛中的闭环得分 [77, 78, 79]。因此，我们预计未来会出现更多混合方法。

| Method             | CLS-R $\uparrow$ | CLS-NR $\uparrow$ | OLS $\uparrow$ | Score $\uparrow$ |
|--------------------|------------------|-------------------|----------------|------------------|
| PDM-Hybrid*        | <b>93</b>        | <b>93</b>         | 83             | <b>90</b>        |
| hoplan             | 89               | 88                | 85             | 87               |
| pegasus_multi_path | 82               | 85                | <b>88</b>      | 85               |
| Urban Driver [10]  | 68               | 70                | 86             | 75               |
| IDM [17]           | 72               | 75                | 29             | 59               |

**表 3：2023 年 nuPlan 挑战赛。**

重要的是，我们在 Val14 基准（表 2）和官方排行榜（表 3）上提交的结果得分几乎相同。请注意，排行榜上的 Urban Driver 和 IDM 结果由 nuPlan 团队提供，因此它们可能使用了与表 2 中我们的实现不同的训练数据和超参数。

**消融实验。**我们通过表 4 中的消融实验深入探讨设计选择。表 4a 展示了 PDM-Hybrid 在不同校正时域（ $C$ ）从 0 秒到 3 秒下的闭环得分反应性（CLS-R）和开环得分（OLS）。将路径点校正应用于所有路径点（即  $C = 0$ ）在 OLS 上优于 PDM-Open（87 对 86，见表 2），但与默认值  $C = 2$  相比，CLS-R 显著下降。另一方面，当校正从轨迹更深处开始时（例如  $C = 3$ ），OLS 明显下降，而对 CLS-R 的影响很小。

对于 PDM-Closed（表 4b），我们在三种场景下比较 CLS-R 和运行时间（毫秒）与基础规划器：移除横向中心线偏移（“横向”）、纵向 IDM 提议（“纵向”）和环境预测（“预测”）。我们的分析表明，消除提议会降低 CLS-R 的有效性，但会加快运行时间。当排除用于创建和评估提议的预测时，性能显著下降。然而，运行时间几乎保持不变，显示了简单预测机制的有效性。

至于 PDM-Open（表 4c），我们测试了三种变体：较短的中心线（30 米对 120 米）、较粗的中心线（每 10 米对每 1 米）以及隐藏维度减小的较小 MLP（从 512 降至 256）。较小的 MLP 和缩短的中心线长度都会导致性能下降，但与完全忽略中心线相比（表 1，OLS=72），影响相对较小。同时，较粗中心线的影响可以忽略不计。

| $C$  | CLS-R $\uparrow$ | OLS $\uparrow$ | Method   | CLS-R $\uparrow$ | Time $\downarrow$ | Method             | OLS $\uparrow$ |
|------|------------------|----------------|----------|------------------|-------------------|--------------------|----------------|
| 0.0s | 58               | <b>87</b>      | Base     | <b>92</b>        | 91                | Baseline           | <b>86</b>      |
| 2.0s | <b>92</b>        | 84             | No lat.  | 89               | <b>55</b>         | Shorter centerline | 84             |
| 2.5s | <b>92</b>        | 84             | No lon.  | 88               | 64                | Coarser centerline | <b>86</b>      |
| 3.0s | <b>92</b>        | 72             | No cast. | 86               | 90                | Smaller MLP        | 84             |

(a) PDM-Hybrid                      (b) PDM-Closed                      (c) PDM-Open

**表 4：消融实验。**我们展示了闭环得分反应性（CLS-R）、开环得分（OLS）和运行时间（毫秒）。我们研究了（a）PDM-Hybrid 的不同校正时域，（b）忽略 PDM-Closed 的子模块，以及（c）输入和架构选择对 PDM-Open 的影响。默认配置以灰色突出显示，实现了最佳权衡。

## 5 讨论

尽管基于规则的规划常因泛化能力有限而受到批评，但我们的结果在最接近真实世界评估的闭环 nuPlan 任务中展现了强大的性能。值得注意的是，开环成功在一定程度上需要以牺牲闭环性能为代价。因此，经过模仿训练的自我预测方法在闭环中表现不佳。这表明基于规则的规划器仍然具有前景，值得进一步探索。同时，鉴于它们在开箱即用时的表现不佳，基于模仿的方法在 nuPlan 上仍有改进空间。

结合闭环规划与开环自我预测的优势，我们提出了一种混合模型。然而，这并未提升闭环驾驶性能；相反，它在执行相同驾驶操作时提升了开环性能。我们得出结论，将精确的开环自我预测视为实现长期规划目标的先决条件是一种误导。

认识到自我预测对于可解释性和评估类人行为的潜在重要性，我们建议将这一评估聚焦于与闭环驾驶相关的短时域（例如 2 秒）。当前的 nuPlan 开环仿真定义要求单模态 8 秒自我预测，这可能仅适用于其他应用，例如为数据驱动交通仿真中的背景智能体设定目标，或更好地分配计算资源，例如优先处理自我车辆预期行驶区域的感知或预测。我们不鼓励将开环度量作为规划性能的主要指标 [18]。

**局限性。**尽管我们显著改进了既有的智能驾驶员模型（IDM），预测性驾驶模型（PDM）仍不执行换道操作。当自行车位于两车道之间时，换道尝试往往导致碰撞，根据 nuPlan 度量标准产生高额惩罚。PDM 依赖高清地图和精确的离线感知 [80, 9]，这些在实际驾驶场景中可能不可用。虽然基于学习的方法已展示出真实世界部署能力 [81, 33, 8]，但对基于规则的方法而言，这仍是一项重大挑战。此外，除留出测试集外，我们的实验未专门评估模型在遭遇分布偏移（如未见过的城镇或新颖场景类型）时的泛化能力。所有实验均在单一仿真器 nuPlan 上进行。因此，必须认识到 nuPlan 数据驱动仿真方法固有的局限性。当规划器比人类驾驶日志推进得更快时，仿真中物体会突然出现在自行车前方。对于 CLS-NR，车辆如现实中观察到的那样独立移动，无视自行车代理，导致行为过于激进。相反，CLS-R 背景代理依赖 IDM 并严格沿中心线行驶，导致行为不切实际地被动。我们认为，为未来工作开发更精细的反应式环境具有很高价值。

**结论。**本文识别了基于学习的车辆运动规划中普遍存在的误解。基于我们的洞见，我们提出了 PDM-Hybrid，它在 IDM 基础上结合了学习的自行车预测组件。它超越了一系列全面的竞争者，并在 2023 年 nuPlan 竞赛中夺冠。



## 致谢

Andreas Geiger 获得 ERC 启动基金 LEGO-3D (850533)、BMW 项目 KI Delta Learning (项目编号 19A19013O) 以及 DFG EXC 编号 2064/1 - 项目编号 390727645 的支持。Kashyap Chitta 获得德国联邦教育与研究部 (BMBF): Tübingen AI 中心, FKZ: 01IS18039A 的支持。我们感谢国际马克斯·普朗克智能系统研究院 (IMPRS-IS) 对 Kashyap Chitta 的支持。同时感谢 Pat Karnchanachari 和 Gianmarco Bernasconi 协助解决排行榜提交中的技术问题, 感谢 Niklas Hanselmann 校对, 以及 Andreas Zell 的有益讨论。

## 参考文献

- [1] F. Codevilla, M. Miiller, A. López, V. Koltun, and A. Dosovitskiy. End-to-end driving via conditional imitation learning. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2018.
- [2] F. Codevilla, E. Santana, A. M. López, and A. Gaidon. Exploring the limitations of behavior cloning for autonomous driving. In *Proc. of the IEEE International Conf. on Computer Vision (ICCV)*, 2019.
- [3] N. Rhinehart, R. McAllister, K. Kitani, and S. Levine. PRECOG: prediction conditioned on goals in visual multi-agent settings. In *Proc. of the IEEE International Conf. on Computer Vision (ICCV)*, 2019.
- [4] W. Zeng, W. Luo, S. Suo, A. Sadat, B. Yang, S. Casas, and R. Urtasun. End-to-end interpretable neural motion planner. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2019.
- [5] K. Chitta, A. Prakash, B. Jaeger, Z. Yu, K. Renz, and A. Geiger. Transfuser: Imitation with transformer-based sensor fusion for autonomous driving. *IEEE Trans. on Pattern Analysis and Machine Intelligence (PAMI)*, 2022.
- [6] M. Bojarski, D. D. Testa, D. Dworakowski, B. Firner, B. Flepp, P. Goyal, L. D. Jackel, M. Monfort, U. Muller, J. Zhang, X. Zhang, J. Zhao, and K. Zieba. End to end learning for self-driving cars. *arXiv.org*, 1604.07316, 2016.
- [7] A. Kendall, J. Hawke, D. Janz, P. Mazur, D. Reda, J. M. Allen, V. D. Lam, A. Bewley, and A. Shah. Learning to drive in a day. *arXiv.org*, abs/1807.00412, 2018.
- [8] M. Bansal, A. Krizhevsky, and A. S. Ogale. Chauffeurnet: Learning to drive by imitating the best and synthesizing the worst. In *Proc. Robotics: Science and Systems (RSS)*, 2019.
- [9] H. Caesar, J. Kabzan, K. S. Tan, W. K. Fong, E. M. Wolff, A. H. Lang, L. Fletcher, O. Beijbom, and S. Omari. nuplan: A closed-loop ml-based planning benchmark for autonomous vehicles. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR) Workshops*, 2021.
- [10] O. Scheel, L. Bergamini, M. Wolczyk, B. Osiński, and P. Ondruska. Urban driver: Learning to drive from real-world demonstrations using policy gradients. In *Proc. Conf. on Robot Learning (CoRL)*, 2021.
- [11] K. Renz, K. Chitta, O.-B. Mercea, A. S. Koepke, Z. Akata, and A. Geiger. Plant: Explainable planning transformers via object-level representations. In *Proc. Conf. on Robot Learning (CoRL)*, 2022.
- [12] M. Hallgarten, M. Stoll, and A. Zell. From Prediction to Planning With Goal Conditioned Lane Graph Traversals. *arXiv.org*, 2302.07753, 2023.

- [13] A. Prakash, K. Chitta, and A. Geiger. Multi-modal fusion transformer for end-to-end autonomous driving. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2021.
- [14] K. Chitta, A. Prakash, and A. Geiger. Neat: Neural attention fields for end-to-end autonomous driving. In *Proc. of the IEEE International Conf. on Computer Vision (ICCV)*, 2021.
- [15] F. Codevilla, A. M. Lopez, V. Koltun, and A. Dosovitskiy. On offline evaluation of vision-based driving models. In *Proc. of the European Conf. on Computer Vision (ECCV)*, 2018.
- [16] A. Dosovitskiy, G. Ros, F. Codevilla, A. Lopez, and V. Koltun. CARLA: An open urban driving simulator. In *Proc. Conf. on Robot Learning (CoRL)*, 2017.
- [17] M. Treiber, A. Hennecke, and D. Helbing. Congested traffic states in empirical observations and microscopic simulations. *Physical review E*, 2000.
- [18] Y. Hu, J. Yang, L. Chen, K. Li, C. Sima, X. Zhu, S. Chai, S. Du, T. Lin, W. Wang, L. Lu, X. Jia, Q. Liu, J. Dai, Y. Qiao, and H. Li. Planning-oriented autonomous driving. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2023.
- [19] S. Thrun, M. Montemerlo, H. Dahlkamp, D. Stavens, A. Aron, J. Diebel, P. Fong, J. Gale, M. Halpenny, G. Hoffmann, K. Lau, C. M. Oakley, M. Palatucci, V. R. Pratt, P. Stang, S. Strohband, C. Dupont, L. Jendrossek, C. Koelen, C. Markey, C. Rummel, J. van Niekerk, E. Jensen, P. Alessandrini, G. R. Bradski, B. Davies, S. Ettinger, A. Kaehler, A. V. Nefian, and P. Mahoney. Stanley: The robot that won the DARPA grand challenge. *Journal of Field Robotics (JFR)*, 23(9):661–692, 2006.
- [20] A. Bacha, C. Bauman, R. Faruque, M. Fleming, C. Terwelp, C. Reinholtz, D. Hong, A. Wicks, T. Alberi, D. Anderson, et al. Odin: Team victortango’s entry in the darpa urban challenge. *Journal of Field Robotics (JFR)*, 25(8), 2008.
- [21] J. J. Leonard, J. P. How, S. J. Teller, M. Berger, S. Campbell, G. A. Fiore, L. Fletcher, E. Frazzoli, A. S. Huang, S. Karaman, O. Koch, Y. Kuwata, D. Moore, E. Olson, S. Peters, J. Teo, R. Truax, M. R. Walter, D. Barrett, A. Epstein, K. Maheloni, K. Moyer, T. Jones, R. Buckley, M. E. Antone, R. Galejs, S. Krishnamurthy, and J. Williams. A perception-driven autonomous urban vehicle. *Journal of Field Robotics (JFR)*, 25(10):727–774, 2008.
- [22] C. Urmson, J. Anhalt, D. Bagnell, C. Baker, R. Bittner, M. Clark, J. Dolan, D. Duggins, T. Galatali, C. Geyer, et al. Autonomous driving in urban environments: Boss and the urban challenge. *Journal of Field Robotics (JFR)*, 25(8), 2008.
- [23] C. Chen, A. Seff, A. L. Kornhauser, and J. Xiao. Deepdriving: Learning affordance for direct perception in autonomous driving. In *Proc. of the IEEE International Conf. on Computer Vision (ICCV)*, pages 2722–2730, 2015.
- [24] A. Sauer, N. Savinov, and A. Geiger. Conditional affordance learning for driving in urban environments. In *Proc. Conf. on Robot Learning (CoRL)*, 2018.
- [25] H. Fan, F. Zhu, C. Liu, L. Zhang, L. Zhuang, D. Li, W. Zhu, J. Hu, H. Li, and Q. Kong. Baidu apollo EM motion planner. *arXiv.org*, 1807.08048, 2018.
- [26] A. Sadat, M. Ren, A. Pokrovsky, Y. Lin, E. Yumer, and R. Urtasun. Jointly learnable behavior and trajectory planning for self-driving vehicles. In *Proc. IEEE International Conf. on Intelligent Robots and Systems (IROS)*, 2019.
- [27] A. Kesting, M. Treiber, and D. Helbing. General lane-changing model mobil for car-following models. *Transportation Research Record*, 1999(1), 2007.
- [28] R. Chekroun, T. Gilles, M. Toromanoff, S. Hornauer, and F. Moutarde. Mbappe: Mcts-built-around prediction for planning explicitly. *arXiv.org*, 2309.08452, 2023.

- [29] A. Cui, A. Sadat, S. Casas, R. Liao, and R. Urtasun. Lookout: Diverse multi-future prediction and planning for self-driving. In *Proc. of the IEEE International Conf. on Computer Vision (ICCV)*, 2021.
- [30] S. Casas, A. Sadat, and R. Urtasun. Mp3: A unified model to map, perceive, predict and plan. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2021.
- [31] A. Sadat, S. Casas, M. Ren, X. Wu, P. Dhawan, and R. Urtasun. Perceive, predict, and plan: Safe motion planning through interpretable semantic representations. In *Proc. of the European Conf. on Computer Vision (ECCV)*, 2020.
- [32] Z. Huang, P. Karkus, B. Ivanovic, Y. Chen, M. Pavone, and C. Lv. Dtp: Differentiable joint conditional prediction and cost evaluation for tree policy planning in autonomous driving. *arXiv.org*, 2310.05885, 2023.
- [33] T. Phan-Minh, F. Howington, T.-S. Chu, M. S. Tomov, R. E. Beaudoin, S. U. Lee, N. Li, C. Dicle, S. Findler, F. Suarez-Ruiz, et al. Driveirl: Drive in real life with inverse reinforcement learning. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2023.
- [34] P. Karkus, B. Ivanovic, S. Mannor, and M. Pavone. Diffstack: A differentiable and modular control stack for autonomous vehicles. In *Proc. Conf. on Robot Learning (CoRL)*, 2022.
- [35] M. H. Danesh, P. Cai, and D. Hsu. Leader: Learning attention over driving behaviors for planning under uncertainty. In *Proc. Conf. on Robot Learning (CoRL)*, 2022.
- [36] Z. Huang, H. Liu, J. Wu, and C. Lv. Differentiable integrated motion prediction and planning with learnable cost function for autonomous driving. *arXiv.org*, 2207.10422, 2022.
- [37] B. Wei, M. Ren, W. Zeng, M. Liang, B. Yang, and R. Urtasun. Perceive, attend, and drive: Learning spatial attention for safe self-driving. *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2021.
- [38] S. Hu, L. Chen, P. Wu, H. Li, J. Yan, and D. Tao. St-p3: End-to-end vision-based autonomous driving via spatial-temporal feature learning. In *Proc. of the European Conf. on Computer Vision (ECCV)*, 2022.
- [39] H. Song, W. Ding, Y. Chen, S. Shen, M. Y. Wang, and Q. Chen. Pip: Planning-informed trajectory prediction for autonomous driving. In *Proc. of the European Conf. on Computer Vision (ECCV)*, 2020.
- [40] N. Rhinehart, J. He, C. Packer, M. A. Wright, R. McAllister, J. E. Gonzalez, and S. Levine. Contingencies from observations: Tractable contingency planning with learned behavior models. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2021.
- [41] Y. Chen, P. Karkus, B. Ivanovic, X. Weng, and M. Pavone. Tree-structured policy planning with learned behavior models. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2023.
- [42] Z. Huang, H. Liu, and C. Lv. Gameformer: Game-theoretic modeling and learning of transformer-based interactive prediction and planning for autonomous driving. *arXiv.org*, 2303.05760, 2023.
- [43] L. Chen, P. Wu, K. Chitta, B. Jaeger, A. Geiger, and H. Li. End-to-end autonomous driving: Challenges and frontiers. *arXiv.org*, 2306.16927, 2023.
- [44] N. Rhinehart, R. McAllister, and S. Levine. Deep imitative models for flexible inference, planning, and control. In *Proc. of the International Conf. on Learning Representations (ICLR)*, 2020.

- [45] A. Filos, P. Tigas, R. McAllister, N. Rhinehart, S. Levine, and Y. Gal. Can autonomous vehicles identify, recover from, and adapt to distribution shifts? In *Proc. of the International Conf. on Machine learning (ICML)*, 2020.
- [46] H. Xu, Y. Gao, F. Yu, and T. Darrell. End-to-end learning of driving models from large-scale video datasets. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, pages 3530–3538, 2017.
- [47] D. Chen, B. Zhou, V. Koltun, and P. Krähenbühl. Learning by cheating. In *Proc. Conf. on Robot Learning (CoRL)*, 2019.
- [48] E. Ohn-Bar, A. Prakash, A. Behl, K. Chitta, and A. Geiger. Learning situational driving. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2020.
- [49] A. Behl, K. Chitta, A. Prakash, E. Ohn-Bar, and A. Geiger. Label efficient visual abstractions for autonomous driving. In *Proc. IEEE International Conf. on Intelligent Robots and Systems (IROS)*, 2020.
- [50] P. Wu, X. Jia, L. Chen, J. Yan, H. Li, and Y. Qiao. Trajectory-guided control prediction for end-to-end autonomous driving: A simple yet strong baseline. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.
- [51] D. Chen and P. Krähenbühl. Learning from all vehicles. In *CVPR*, 2022.
- [52] B. Jaeger, K. Chitta, and A. Geiger. Hidden biases of end-to-end driving models. *Proc. of the IEEE International Conf. on Computer Vision (ICCV)*, 2023.
- [53] N. Hanselmann, K. Renz, K. Chitta, A. Bhattacharyya, and A. Geiger. King: Generating safety-critical driving scenarios for robust imitation via kinematics gradients. In *Proc. of the European Conf. on Computer Vision (ECCV)*, 2022.
- [54] M. Vitelli, Y. Chang, Y. Ye, A. Ferreira, M. Wołczyk, B. Osiński, M. Niendorf, H. Grimmer, Q. Huang, A. Jain, et al. Safetynet: Safe planning for real-world self-driving vehicles using machine-learned policies. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2022.
- [55] S. Pini, C. S. Perone, A. Ahuja, A. S. R. Ferreira, M. Niendorf, and S. Zagoruyko. Safe real-world autonomous driving by learning to predict and plan with a mixture of experts. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2023.
- [56] J. Cheng, Y. Chen, X. Mei, B. Yang, B. Li, and M. Liu. Rethinking imitation-based planner for autonomous driving. *arXiv.org*, 2309.10443, 2023.
- [57] H. Caesar, V. Bankiti, A. H. Lang, S. Vora, V. E. Liong, Q. Xu, A. Krishnan, Y. Pan, G. Baldan, and O. Beijbom. nuscenes: A multimodal dataset for autonomous driving. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2020.
- [58] J.-T. Zhai, Z. Feng, J. Du, Y. Mao, J.-J. Liu, Z. Tan, Y. Zhang, X. Ye, and J. Wang. Rethinking the open-loop evaluation of end-to-end autonomous driving in nuscenes. *arXiv.org*, 2305.10430, 2023.
- [59] M. Althoff, M. Koschi, and S. Manzing. Commonroad: Composible benchmarks for motion planning on roads. In *Proc. IEEE Intelligent Vehicles Symposium (IV)*, 2017.
- [60] L. Bergamini, Y. Ye, O. Scheel, L. Chen, C. Hu, L. D. Pero, B. Osinski, H. Grimmer, and P. Ondruska. Simnet: Learning reactive self-driving simulations from real-world observations. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2021.

- [61] S. Suo, S. Regalado, S. Casas, and R. Urtasun. Trafficsim: Learning to simulate realistic multi-agent behaviors. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2021.
- [62] Z. Zhong, D. Rempe, D. Xu, Y. Chen, S. Veer, T. Che, B. Ray, and M. Pavone. Guided conditional diffusion for controllable traffic simulation. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2023.
- [63] D. Xu, Y. Chen, B. Ivanovic, and M. Pavone. Bits: Bi-level imitation for traffic simulation. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2023.
- [64] Z. Zhang, A. Liniger, D. Dai, F. Yu, and L. Van Gool. TrafficBots: Towards world models for autonomous driving simulation and motion prediction. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2023.
- [65] L. Feng, Q. Li, Z. Peng, S. Tan, and B. Zhou. Trafficgen: Learning to generate diverse and realistic traffic scenarios. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2023.
- [66] S. Ross, G. J. Gordon, and D. Bagnell. A reduction of imitation learning and structured prediction to no-regret online learning. In *Conference on Artificial Intelligence and Statistics (AISTATS)*, 2011.
- [67] A. Prakash, A. Behl, E. Ohn-Bar, K. Chitta, and A. Geiger. Exploring data aggregation in policy learning for vision-based urban autonomous driving. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2020.
- [68] S. Poddar, C. Mavrogiannis, and S. S. Srinivasa. From crowd motion prediction to robot navigation in crowds. *arXiv preprint arXiv:2303.01424*, 2023.
- [69] C. Schöller, V. Aravantinos, F. Lay, and A. Knoll. What the constant velocity model can teach us about pedestrian motion prediction. *IEEE Robotics and Automation Letters*, 5(2):1696–1703, 2020.
- [70] H. Wu, T. Phong, C. Yu, P. Cai, S. Zheng, and D. Hsu. What truly matters in trajectory prediction for autonomous driving? *arXiv preprint arXiv:2306.15136*, 2023.
- [71] Y. Tassa, N. Mansard, and E. Todorov. Control-limited differential dynamic programming. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2014.
- [72] R. Rajamani. *Vehicle dynamics and control*. Springer Science & Business Media, 2011.
- [73] P. Polack, F. Altché, B. d’Andréa Novel, and A. de La Fortelle. The kinematic bicycle model: A consistent model for planning feasible trajectories for autonomous vehicles? In *Proc. IEEE Intelligent Vehicles Symposium (IV)*, 2017.
- [74] N. Deo, E. M. Wolff, and O. Beijbom. Multimodal Trajectory Prediction Conditioned on Lane-Graph Traversals. In *Proc. Conf. on Robot Learning (CoRL)*, 2021.
- [75] N. Nayakanti, R. Al-Rfou, A. Zhou, K. Goel, K. S. Refaat, and B. Sapp. Wayformer: Motion forecasting via simple and efficient attention networks. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2023.
- [76] A. Cui, S. Casas, K. Wong, S. Suo, and R. Urtasun. Gorela: Go relative for viewpoint-invariant motion forecasting. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2023.
- [77] Y. Hu, K. Li, P. Liang, J. Qian, Z. Yang, H. Zhang, W. Shao, Z. Ding, W. Xu, and Q. Liu. Imitation with spatial-temporal heatmap: 2nd place solution for nuplan challenge. *arXiv.org*, 2306.15700, 2023.



- [78] W. Xi, L. Shi, and G. Cao. An imitation learning method with data augmentation and post processing for planning in autonomous driving. URL [https://opendrive-lab.com/e2ead/AD23Challenge/Track\\_4\\_pegasus\\_weitao.pdf](https://opendrive-lab.com/e2ead/AD23Challenge/Track_4_pegasus_weitao.pdf).
- [79] Z. Huang, H. Liu, X. Mo, and C. Lyu. Gameformer planner: A learning-enabled interactive prediction and planning framework for autonomous vehicles. URL [https://opendrive-lab.com/e2ead/AD23Challenge/Track\\_4\\_AID.pdf](https://opendrive-lab.com/e2ead/AD23Challenge/Track_4_AID.pdf).
- [80] C. R. Qi, Y. Zhou, M. Najibi, P. Sun, K. Vo, B. Deng, and D. Anguelov. Offboard 3d object detection from point cloud sequences. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2021.
- [81] O. Scheel, L. Bergamini, M. Wolczyk, B. Osinski, and P. Ondruska. Urban driver: Learning to drive from real-world demonstrations using policy gradients. In *Proc. Conf. on Robot Learning (CoRL)*, 2021.