

粉红噪声即所需：深度强化学习中的有色噪声探索

Onno Eberhard¹ **Jakob Hollenstein^{2,1}** **Cristina Pinneri^{3,1}** **Georg Martius¹**
¹Max Planck Institute for Intelligent Systems, Tübingen, Germany ² 因斯布鲁克大学
³Max Planck ETH Center for Learning Systems
{firstname.lastname}@tuebingen.mpg.de

摘要


在具有连续动作空间的离策略深度强化学习中，探索通常通过在动作选择过程中注入动作噪声来实现。基于随机策略的流行算法，如 SAC 或 MPO，通过从不相关的高斯分布中采样动作来注入白噪声。然而，在许多任务中，白噪声不能提供足够的探索，因此使用时间相关的噪声代替。常见的选择是奥恩斯坦-乌伦贝克

(OU) 噪声，它与布朗运动（红噪声）密切相关。红噪声和白噪声都属于有色噪声这一广泛家族。在这项工作中，我们对 MPO 和 SAC 进行了全面的实验评估，以探索其他颜色的噪声作为动作噪声的有效性。我们发现，粉红噪声介于白噪声和红噪声之间，在广泛的环境中显著优于白噪声、OU 噪声和其他替代方案。因此，我们推荐将其作为连续控制中动作噪声的默认选择。

1 引言

探索在强化学习 (RL) 中至关重要，用于发现状态空间中未知的高奖励区域。这在连续控制设置（如机器人技术）中尤其具有挑战性，因为通常需要协调多步行为才能达到足够不同的状态。最简单的探索方法是使用动作噪声，它向策略的动作添加小的随机扰动。在离策略算法中，探索性行为策略不需要与目标策略匹配，动作噪声可以从任何随机过程中抽取。如果策略是确定性的，如 DDPG (Lillicrap 等人, 2016) 和 TD3 (Fujimoto 等人, 2018)，动作噪声通常是白噪声（从时间上不相关的高斯分布中抽取）或奥恩斯坦-乌伦贝克 (OU) 噪声，并添加到策略的动作中。在策略是随机的算法中，如 SAC (Haarnoja 等人, 2018) 或 MPO (Abdolmaleki 等人, 2018)，动作采样本身引入了随机性。由于采样噪声通常在时间上不相关，这些算法实际上采用了加性白噪声的尺度调制版本，其中噪声尺度随不同状态而变化。

白噪声 粉红噪声 奥恩斯坦-乌伦贝克噪声 图 1: 纯噪声智能体在有界积分器环境上的轨迹（第 6 节）。白动作噪声（左）在该环境中无法到达远处，因此无法收集边缘处的稀疏奖励：它只进行局部探索。奥恩斯坦-乌伦贝克噪声（右）仅进行全局探索并卡在边缘。粉红噪声（中）提供了局部与全局探索的平衡，并且比其他两种噪声更均匀地覆盖状态空间。



在许多情况下，白噪声探索不足以到达相关状态。最大后验策略优化（MPO）和软演员-评论家（SAC）由于探索不足，在某些简单任务（如山地车）上存在严重问题。与双延迟深度确定性策略梯度（TD3）或深度确定性策略梯度（DDPG）一样，这些算法的离策略特性使得可以用不同的随机过程替换隐式用于动作采样的白噪声过程。动作选择中时间相关性的有效性此前已被注意到（例如 Osband 等人，2016），并在图 1 中进行了说明，其中在简单积分器环境上比较了白噪声（不相关）与具有中等（粉红噪声）和强（奥恩斯坦-乌伦贝克噪声）时间相关性的噪声的探索行为（详见第 6 节）。使用高度相关的噪声（如奥恩斯坦-乌伦贝克噪声）可以产生足够的探索来处理这些困难情况，但它也引入了另一个问题：强离策略轨迹。过多的探索不利于学习好的策略，因为在训练期间必须覆盖在策略状态访问分布，以使统计学习成为可能。因此，典型的方法是默认使用白噪声，仅在必要时使用奥恩斯坦-乌伦贝克噪声等替代方案。在这项工作中，我们的目标是找到一种更好的策略，通过考虑具有中等时间相关性的噪声，希望这些噪声在白噪声足够的环境和需要增加探索的环境上都能表现良好。

为此，本文研究了有色噪声作为深度强化学习中动作噪声的有效性。有色噪声是一类具有时间相关性的噪声过程，其参数 β 用于控制相关强度。它推广了白噪声（ $\beta = 0$ ）和布朗运动（红噪声， $\beta = 2$ ），后者与 OU 噪声密切相关。我们发现，在广泛的环境范围内，通过使用具有中等时间相关性（ $0 < \beta < 2$ ）的有色动作噪声，平均性能可以得到显著提升。特别是，我们发现粉红噪声（ $\beta = 1$ ）是一个极佳的默认选择。有趣的是，粉红噪声也已在人类运动中被观察到：静止站立受试者的轻微晃动，以及音乐家相对于节拍的时间偏差，都被测量出具有与粉红噪声一致的时间相关性（Duarte & Zatsiorsky, 2001; Hennig et al., 2011）。

本文的工作对 MPO 和 SAC 上各种动作噪声类型进行了全面的实验评估。我们发现，粉红噪声不仅在我们所选环境中具有最佳的平均性能，而且在 80% 的情况下，它没有被任何其他噪声类型超越。我们还发现，粉红噪声的性能与针对环境调优噪声类型的预言机相当，而白噪声和 OU 噪声的性能分别位于最差噪声类型选择与预言机之间的 50% 和 25% 处。为了探究是否存在更好的噪声策略，我们测试了一种颜色调度方案，即在训练过程中从全局探索的红噪声过渡到局部探索的白噪声，以及一种自动调优噪声颜色以最大化轨迹回报的赌博机方法。这两种方法虽然与白噪声和 OU 噪声相比显著提高了平均性能，但仍然被粉红噪声显著超越。除了实验结果之外，我们还尝试通过构建具有简化动态的环境并分析粉红噪声、白噪声和 OU 噪声的不同行为，来解释粉红噪声作为默认选择为何如此有效。我们的建议是从当前默认的白噪声切换到粉红噪声。

2 背景与相关工作

强化学习（Reinforcement Learning, RL）已取得令人瞩目的成果，尤其是在离散控制环境中，例如利用深度网络作为函数逼近器，在雅达利（Atari）游戏中通过深度 Q 网络（DQN）达到人类水平的表现（Mnih 等，2015），或掌握围棋（Silver 等，2016）。本文关注连续控制环境，该环境在机器人学中尤为适用。在连续动作空间中，通过在动作空间上优化价值函数来选择动作通常是不可行的。这使得许多为离散控制设计的深度强化学习方法（如 DQN）无法适用。相反，研究者开发了策略搜索方法（例如 Williams, 1992; Silver 等，2014），直接对策略进行参数化。这些方法可分为同策略算法，如信任区域策略优化（TRPO）（Schulman 等，2015）和近端策略优化（PPO）（Schulman 等，2017），以及异策略算法，如深度确定性策略梯度（DDPG）、双延迟深度确定性策略梯度（TD3）、软演员-评论家（SAC）和最大后验策略优化（MPO）。

所有这些算法都必须解决探索问题，这是强化学习的基础：为了提升策略性能，智能体需要探索新行为，同时仍学习最优行动。解决探索的一种思路是在奖励中加入新颖性奖励（例如 Thrun, 1992）。在深度强化学习中，可以通过基于样本密度（Tang et al., 2017）或预测误差（Burda et al., 2019）的奖励来实现。另一种鼓励探索的方法是从汤普森采样（Thompson Sampling）等赌博机方法中获得启发（例如 Russo et al., 2018），并采取乐观行动

关于 Q 函数不确定性的探索 (Osband 等人, 2016 年)。然而, 最简单的策略是随机扰动策略参数 (Plappert 等人, 2018 年; Mania 等人, 2018 年) 或动作本身。这可以通过以下方式实现: 为每个回合随机采样一个函数, 该函数确定性地改变动作选择 (Raffin 与 Stulp, 2020 年); 通过学习动作维度与状态空间维度之间的相关性, 以在环境中诱导不断增强的激励 (Schumacher 等人, 2022 年); 或从任务无关数据中学习动作先验 (Bagatella 等人, 2022 年)。

本文考虑连续控制中最简单且最常见的探索形式: 动作噪声。动作噪声可以显式地加到策略上, 也可以通过从随机策略中随机采样动作来隐式地加入。最常见的动作噪声形式是白噪声, 通常来自每个时间步从独立高斯分布中采样。除了白动作噪声之外, Lillicrap 等人 (2016) 成功使用了时间相关的奥恩斯坦-乌伦贝克噪声, Pinneri 等人 (2020) 通过利用有色噪声在模型预测控制中取得了改进。受此成功启发, 本文在无模型强化学习的背景下, 特别是在 MPO 和 SAC 上, 研究有色动作噪声的有效性。

3 方法

本文研究使用动作噪声进行探索。在 DDPG 和 TD3 等算法中, 学习到的策略 μ 是确定性的, 动作噪声被简单地加到策略上:

$$a_t = \mu(s_t) + \sigma \varepsilon_t, \quad (1)$$

其中 $\varepsilon_{1:T} = (\varepsilon_1, \dots, \varepsilon_T)$ 从随机过程中采样, σ 是尺度参数。如果 ε_t 在每个时间步独立采样, 例如从高斯分布中采样, 那么 $\varepsilon_{1:T}$ 被称为白噪声 (WN)。这是动作噪声的主流选择, 尽管使用时间相关的奥恩斯坦-乌伦贝克噪声 ($\varepsilon_{1:T} \sim \text{OU}_T$) (乌伦贝克和奥恩斯坦, 1930) 也很常见。

参数化随机策略的算法, 如 SAC 和 MPO, 也使用动作噪声。在连续动作空间中, 最常见的策略分布是对角高斯分布, 由函数 $\mu(s_t)$ 和 $\sigma(s_t)$: $a_t \sim \mathcal{N}(\mu(s_t), \text{diag}(\sigma(s_t))^2)$ 表示。这可以等价地写为

$$a_t = \mu(s_t) + \sigma(s_t) \odot \varepsilon_t, \quad (2)$$

其中 $\varepsilon_t \sim \mathcal{N}(0, I)$ 。在这种情况下, 动作噪声 $\varepsilon_{1:T}$ 同样是高斯白噪声, 由函数 σ 进行尺度调制。白噪声在时间上不相关 ($\text{cov}[\varepsilon_t, \varepsilon_{t'}] = 0$)。在某些环境中, 这会导致探索非常缓慢, 进而导致状态空间覆盖不足, 使高奖励区域未被发现。因此, 使用具有时间相关性的动作噪声 ($\text{cov}[\varepsilon_t, \varepsilon_{t'}] > 0$ 通常是有益的, 例如奥恩斯坦-乌伦贝克 (OU) 噪声。OU 噪声被推荐为 DDPG 的默认选择, 并已被证明能显著增加状态空间覆盖 (Hollenstein 等人, 2022)。OU 噪声由随机微分方程 (SDE) 定义

$$\dot{\varepsilon}_t = -\theta \varepsilon_t + \sigma \eta_t, \quad (3)$$

其中 η_t 是一个白噪声过程。若 $\theta = 0$, 则该方程定义积分白噪声, 亦称布朗运动。布朗运动具有时间相关性, 但若以此方式生成, 则不能用作动作噪声, 因为其方差随时间无界增长, 违反动作空间限制。通过设定 $\theta > 0$ (典型选择为 $\theta = 0.15$) 可解决此问题, 从而限制方差。关于 OU 噪声与布朗运动的更多细节见附录 A。

一类广泛的时间相关噪声由有色噪声给出, 它推广了白噪声和布朗运动 (在此语境下称为红噪声)。

定义 1 (有色噪声)。若从某随机过程中抽取的信号 $\varepsilon(t)$ 具有性质 $|\hat{\varepsilon}(f)|^2 \propto f^{-\beta}$, 其中 $\hat{\varepsilon}(f) = \mathcal{F}[\varepsilon(t)](f)$ 表示 $\varepsilon(t)$ (f 的傅里叶变换 (频率)), $|\hat{\varepsilon}(f)|^2$ 称为功率谱密度 (PSD), 则该随机过程称为颜色参数为 β 的有色噪声。

颜色参数 β 控制信号中时间相关性的程度。不同 β 的有色噪声的 PSD 如图 A.2 所示。若 $\beta = 0$, 则信号不相关, PSD 平坦, 意味着所有频率被同等表示。此噪声类比光而称为白噪声, 在光中, 所有可见频率上功率相等的信号被感知为白色。




图 2: 我们使用的环境: 倒立摆、小车杆 (平衡+摆动任务)、杯中球、山地车、跳跃者、步行者、机械臂、猎豹、门。更多细节见附录 C。图片部分经许可取自 Tassa 等人 (2018)。

红噪声 ($\beta = 2$) 因在较低频率上具有更大权重而得名, 这在光中对应光谱的红色部分。具有恒定方差的高斯有色噪声可以高效生成, 且一个回合的完整噪声信号可一次性采样, 根据方程 (1) 和 (2) 用作动作噪声。若以此方式生成 (我们记为 $\varepsilon_{1:T} \sim \text{CN}_T(\beta)$, 更多细节见附录 A), 白噪声等同于在每个时间步独立从高斯分布采样。红噪声 ($\text{CN}_T(2)$) 与默认设置 $\theta = 0.15$ 下的 OU 噪声非常相似, 因为两者本质上都是方差有界的布朗运动 (见图 A.2)¹。通过设定 $0 < \beta < 2$, 有色噪声使我们能够寻找具有白噪声与红噪声之间中等时间相关性的更优默认动作噪声类型。一个特例是粉红噪声, 其定义为 $\beta = 1$ 。

4 粉红噪声是否就是全部所需?

Fujimoto 等人 (2018) 发现, 动作噪声的类型 (白噪声或 OU 噪声) 通常不会影响 TD3 的性能。与此相反, Hollenstein 等人 (2022) 发现噪声类型确实有影响, 但这种选择的影响以及哪种噪声类型更可取, 完全取决于环境。我们首先确认后者结果², 并将白噪声和 OU 动作噪声与一系列有色动作噪声 ($\beta \in [0, 2]$) 在实现的性能方面进行比较。在我们所有的实验中, 我们使用 MPO 和 SAC, 分别依赖 Pardo (2020) 和 Raffin 等人 (2021) 的实现。我们发现这两种算法在各项任务上都显著优于 TD3, 因此仅在 B.1 节中简要讨论 TD3。由于动作噪声类型的最优性取决于环境, 我们在来自 DeepMind 控制套件 (Tassa 等人, 2018)、OpenAI Gym (Brockman 等人, 2016) 和 Adroit 手部套件 (Rajeswaran 等人, 2018) 的 10 个不同任务的多样化集合上进行实验。这些环境如图 2 所示, 并在 C 节中更详细地描述。我们在 G 节中报告了一些额外任务的结果。

为了评估训练过程的性能 (该过程始终持续 10^6 次环境交互), 我们每 10^4 次交互运行 5 次评估 rollout。然后将性能报告为所有这些评估 rollout 的平均回报。由于该性能与学习曲线下的面积相关, 它是一种结合了最终策略性能和算法样本效率的测度。更详细的结果, 包括学习曲线和最终策略性能的分析, 可以在 B.2 节和 H 节中找到。

4.1 噪声类型是否重要?

为了评估动作噪声选择的重要性, 我们评估了 SAC 和 MPO 在使用白噪声、OU 噪声和有色噪声作为动作噪声时所实现的性能 (其中 1OU 噪声的其他 θ 设置, 与红噪声不太相似, 在 A 节中讨论。在正文中我们只考虑 $\theta = 0.15$ 的默认设置² 我们还确认了之前的结果 (见 B.1 节), 但发现有有色噪声 (尤其是粉红噪声) 在 TD3 上优于白噪声和 OU 噪声。




图 3: MPO 和 SAC 使用不同动作噪声类型的预期平均性能的自举分布 (详情见 B.2 节)。突出显示的是白噪声 (WN)、粉红噪声 ($\beta = 1$) 和 Ornstein-Uhlenbeck 噪声 (OU)。

Environment	Best noise	p	Pink?
Pendulum	2.0	0.01	X
Cartpole (b.)	1.0 (Pink)	—	✓
Cartpole (s.)	1.0 (Pink)	—	✓
Ball-In-Cup	0.75	0.88	✓
MountainCar	2.0	0.59	✓
Hopper	1.0 (Pink)	—	✓
Walker	0.5	0.36	✓
Reacher	White noise	0.02	X
Cheetah	0.75	0.62	✓
Door	0.75	0.65	✓


表 1: 韦尔奇 t 检验显示, 粉红噪声与最佳噪声之间的性能差异仅在十个环境中的两个中显著。最右列回答了粉红噪声是否与最佳噪声类型表现相当。

$\beta \in \{0.1, 0.2, 0.35, 0.5, 0.75, 1, 1.5, 2\}$), 在如图 2 所示的基准环境上。我们用 20 个不同的随机种子重复所有学习运行, 总共进行 $20 \times 10 \times 2 \times 10 = 4000$ 次实验³, 每次报告一个标量性能。为了控制算法和环境对特定噪声类型性能的影响, 我们将所有结果按算法和任务分组, 并将其归一化为零均值和单位方差。然后计算噪声类型的平均性能: 使用该噪声类型的所有运行的归一化性能, 在算法和环境上取平均。在图 3 中, 展示了预期平均性能的自举分布, 使用每个任务和算法可用的 20 个随机种子生成 (详见第 B.2 节)。可以看出, 噪声类型确实对性能有影响。对粉红噪声 ($\beta = 1$) 的明显偏好变得可见, 它在各任务上显著优于白噪声和 OU 噪声。在第 B.2 节中, 可以在相应的学习曲线上看到这种性能差异, 我们比较了白噪声、OU 噪声和粉红噪声。

在所有环境中取得最佳平均性能, 并不等同于在每个单独环境中都是表现最佳的选项。这引出了一个问题: 粉红噪声 (最佳通用选项) 何时也能表现得与环境的最佳噪声类型一样好。我们对每个环境执行韦尔奇 t 检验, 以检查粉红噪声与任务特定最佳噪声⁴的性能期望差异是否显著。结果列于表 1。尽管粉红噪声仅在十个任务中的三个上取得了跨种子的最高均值, 但统计分析表明, 粉红噪声与最佳噪声类型之间的差异仅在十分之二的情况下显著。换言之, 在测试环境中, 粉红噪声在 80% 的情况下与最佳噪声类型选择的表现相当! 那么粉红噪声被其他噪声类型超越的两个环境——摆锤和机械臂——又如何呢? 在摆锤上, 粉红噪声平均达到红噪声性能的 83% ($\beta = 2$)。相比之下, 白噪声仅达到红噪声性能的 39% (OU 噪声表现与红噪声相近)。在机械臂上, 粉红噪声达到白噪声性能的 99%, 而 OU 噪声仅达到 76%。因此, 即使在粉红噪声被显著超越的少数环境中, 它作为默认选择也明显优于白噪声和 OU 噪声。这些结果表明, 粉红噪声似乎就是您所需要的全部。

4.2 粉红噪声是良好的默认选择吗?

在给定环境上的最佳性能总是通过任务特定的最佳动作噪声类型实现。始终使用这种最佳噪声类型固然理想, 但通常不切实际, 因为需要运行大规模超参数搜索来找到它, 尤其是在包含许多可能颜色 β 时。因此, 通常坚持使用“默认”选择, 这通常是白噪声。在上一节中, 我们看到粉红噪声是比白噪声更好的默认选择, 但仍不清楚这是否是 3 个种子 $\times$ 任务 $\times$ 算法 $\times$ 噪声类型 (白噪声 + OU + 8 种颜色)⁴ 为了计算最佳噪声类型, 我们归一化掉算法的贡献 (类似于平均性能), 并取每个环境上随机种子的平均性能。



足够，或者是否需要超参数搜索才能获得良好性能。在本节中，我们将分析坚持使用白噪声、粉红噪声或 OU 噪声的默认值相比使用任务特定最佳噪声类型会损失多少性能。

我们通过一种“理想”方法选择任务特定最佳噪声类型，该方法可视为非常详尽的网格搜索：通过查看所有噪声类型的结果，并在 10 个随机种子上选择性能最佳的选项来确定环境的最佳噪声类型。同时进行“反理想”实验，在每个环境上选择最差的噪声类型（即可能的最不幸噪声类型选择），我们可以定义一个新的“性能增益”测度，这可能比前一节中的平均性能更易于解释。⁵ 噪声类型的性能增益指定其平均性能落在反理想性能（0%）和理想性能（100%）之间的位置。图 4 展示了使用白噪声、奥恩斯坦-乌伦贝格噪声和粉红噪声作为所有环境默认值的性能增益。

始终使用奥恩斯坦-乌伦贝格噪声只能实现最高可能性能增益的约 25%，且所得性能更接近使用反理想方法。改用白噪声则已实现超过 50% 的性能增益。然而，选择粉红噪声似乎与理想方法相比没有牺牲任何性能！⁶ 从默认白噪声切换到粉红噪声所获得的增益既可观又显著，我们建议将粉红噪声作为默认动作噪声。

5 彩虹的所有颜色

我们发现，在广泛的环境中，粉红噪声是最佳的默认动作噪声。然而，仍有一些环境中，粉红噪声被其他噪声类型超越，具体而言，在机械臂（Reacher）和倒立摆（Pendulum）任务上分别被白噪声和红噪声超越。这表明可能不存在一种在所有环境中都表现最佳的单一噪声类型。然而，这一考虑仅在噪声在训练过程中保持不变时才成立。如果我们尝试一种不同的方法，为每次轨迹展开单独选择噪声类型，我们可能会找到一种在任何地方都不被超越的策略。在本节中，我们讨论两种这样的非恒定方法，它们在轨迹展开的噪声类型选择方式上有所不同：一种是从 $\beta = 2$ 到 $\beta = 0$ 的颜色调度，另一种是旨在为环境找到最优颜色的赌博机方法。

5.1 颜色调度是否优于粉红噪声？

为了找到比粉红噪声更有效的探索方法，理解为什么在倒立摆和机械臂环境中其他噪声类型的学习效果更好是有帮助的。倒立摆环境是欠驱动的，需要通过缓慢来回摆动逐渐积累动量。强相关的动作噪声（如红噪声）使这种行为更有可能发生。另一方面，机械臂任务既没有特别大的状态空间，也没有表现出

⁵ 反预言机（anti-oracle）在未用于噪声类型选择的 10 个种子上进行评估，以避免采样偏差。我们通过在（前）10 个种子上选择（评估）一次，并在（后）10 个种子上再选择（评估）一次来重复此过程。⁶ 看起来粉红噪声甚至超过了预言机的性能。这种差异在统计上不显著，并且是由于预言机只能访问未用于评估的 10 个种子。

Environment	P > S	P < S	Pink $\geq$ Schedule?	P > B	P < B	Pink $\geq$ Bandit?
Pendulum		<0.01	$\times$		0.73	$\checkmark$
Cartpole (b.)	<0.01		$\checkmark$	0.10		$\checkmark$
Cartpole (s.)	0.01		$\checkmark$	<0.01		$\checkmark$
Ball-In-Cup	<0.01		$\checkmark$	0.47		$\checkmark$
MountainCar		0.15	$\checkmark$	0.29		$\checkmark$
Hopper	0.05		$\checkmark$	0.15		$\checkmark$
Walker	<0.01		$\checkmark$		0.28	$\checkmark$
Reacher	<0.01		$\checkmark$		0.50	$\checkmark$
Cheetah	0.05		$\checkmark$	0.64		$\checkmark$
Door	0.15		$\checkmark$	0.27		$\checkmark$

表 2: 粉红噪声与调度和赌博机方法相比如何? 对于每个环境, 我们执行韦尔奇 t 检验来检验粉红噪声与调度/赌博机方法性能的不等式。 p 值的排列显示了哪种性能更高。在大多数环境中, 粉红噪声的性能显著优于调度。与赌博机算法相比, 粉红噪声总体表现更好, 但在大多数环境中差异不显著。在“粉红 $\geq$...?”列中, () 表示粉红噪声的性能并不显著劣于替代方法。

欠驱动, 因此白噪声非常适合探索该空间。在此情况下, 时间相关的噪声只会导致离策略的轨迹数据, 从而抑制学习。一般而言, 强相关噪声导致更全局的探索, 而不相关噪声则更局部地探索。我们将在第 6 节回到这些思想, 分析高相关性和低相关性对两个简单环境的影响。

我们的方法在这两种环境以及需要局部与全局探索相结合的环境上都应表现良好。因此, 我们寻求一种平衡局部与全局探索的策略。一个简单的想法是颜色调度: 从高度相关的红噪声 ($\beta = 2$ 开始, 然后在训练过程中缓慢降低 β 至白噪声 $\beta = 0$ 。该策略背后的原理是, 在训练初期当 β 较大时, 可以快速发现高奖励区域, 而随着时间的推移轨迹变得更加在策略, 有助于像 Reacher 这样的环境。事实上, 一种类似的调度动作噪声尺度的方法已被证明效果很好 (Hollenstein 等, 2022)。

我们在 MPO 和 SAC 上实现了从 $\beta = 2$ 线性过渡到 $\beta = 0$ 的 β 调度, 并在所有环境上用 20 个随机种子重复实验。跨环境期望平均性能的自举分布如图 4 所示 (标记为 Schedule)。结果表明, 该调度通常优于 OU 噪声和白噪声, 但未超过粉红噪声。实际上, 粉红噪声显著更好, 因为置信区间不重叠。如果我们更详细地查看各个环境 (表 2), 可以看到由于额外的高相关噪声, 调度在 Pendulum 环境上确实如预期那样优于粉红噪声。然而, 在所有其他环境中, 粉红噪声要么显著优于调度, 要么性能相当, 因此我们仍然推荐默认使用粉红噪声。

5.2 老虎机颜色选择是否优于粉红噪声?

上一节的结果表明, 虽然在训练过程中改变噪声类型可以提升性能, 但从全局探索的红色噪声简单过渡到更局部探索的白色噪声, 并不能超越粉色噪声。本节不再尝试寻找适用于所有环境的固定调度, 而是考虑一种自适应方法。通过使用赌博机算法, 根据过去回合的回报为每个回合选择动作噪声颜色, 或许不仅能找到给定环境下总体最佳的噪声, 甚至能自动适应训练的不同阶段。我们使用的赌博机算法基于汤普森采样, 细节见第 D 节。

我们直接使用回合回报作为赌博机的奖励信号。理由是: 在需要强探索的环境中 (如摆锤和山地车), 只有强相关动作才能获得高回报。反之, 如果环境不需要相关动作, 或者已经学到较强的策略, 那么对策略扰动最小的动作噪声 (即低相关性的噪声) 应能获得最高回报。

作为额外的基线，我们还进行了一项实验，每个回合随机选择一种颜色（ β ）。⁷ 两种方法都使用与第 4.1 节相同的 β 值列表（包括 $\beta = 0$ ），并用 20 个随机种子重复实验。MPO 和 SAC 上的结果如图 4（标记为 Bandit 和 Random）和表 2 所示。可以看出，赌博机方法再次被粉色噪声超越。事实上，自助法检验显示，跨环境的期望平均性能存在高度显著差异（ $p = 0.005$ ）。从单个任务的结果（表 2）来看，赌博机方法似乎在两个问题环境（摆锤和机械臂）上确实优于粉色噪声，但这一差异并不显著。赌博机与其随机基线的详细比较见表 D.1，结果显示两种方法在任何环境上都没有显著优于对方。这表明，虽然在训练过程中改变噪声类型可能有一定价值，但回合回报所包含的信息似乎太少，不足以有效指导噪声类型的选择。因此，我们推荐使用粉色噪声作为默认设置的建议保持不变。

6 动作噪声与环境动态如何相互作用？

为什么粉红噪声是良好的默认噪声类型？在第 5.1 节中，我们简要讨论了局部探索和全局探索的概念，并假设最佳的探索行为能够在两者之间取得平衡，从而既能发现高奖励区域，又能使轨迹不至于过于偏离策略。为了分析不同噪声类型的行为，我们将考察一个简化的有界积分器环境：一个在盒子中运动的速度控制二维粒子（详见第 F.2 节）。如果我们仅用噪声控制该粒子，就可以在脱离策略的情况下分析探索行为。作为第一项测试，我们在大小为 250×250 的环境中运行 20 个回合，每回合 1000 步，分别使用白噪声、粉红噪声和 OU 噪声（均具有单位方差， x 和 y 速度独立控制）。得到的轨迹如图 1 所示。可以看出，粉红噪声提供了局部探索和全局探索的最佳组合：它能够到达边界（与白噪声不同），但不会陷入边界（与 OU 噪声不同）。

局部探索和全局探索的良好结合能够带来更均匀的状态空间覆盖，如图 1 所示。因此，一种噪声类型的探索效果在很大程度上取决于环境的大小：如果环境小得多，白噪声就足以覆盖整个空间，而粉红噪声的轨迹看起来会类似于这里展示的 OU 轨迹。另一方面，如果环境更大，那么粉红噪声将无法到达边界，而 OU 噪声的探索效果会更好。状态空间覆盖的均匀性通过状态访问分布的熵来衡量。我们使用直方图密度近似来估计由噪声类型引起的熵：将状态空间划分为若干盒子（ $50 \times 50 = 2500$ 个盒子），采样 10^4 条轨迹，并统计每个盒子中采样点的数量。

图 5 展示了白噪声、OU 噪声和粉红噪声在不同环境规模下所达到的熵。所选规模反映了 1000 步回合长度下单位方差的完整合理范围：从极小（ 50×50 ）到极大（ 2000×2000 ）。粉红噪声并非在所有环境中都表现最佳的“特殊”噪声，这一点在前几节中已经看到。然而，它在由回合长度决定的“中等规模”上表现最佳，并且在整个合理环境范围内不会出现严重的性能退化。如果我们不知道给定环境位于该范围的哪个位置，那么粉红噪声显然比白噪声或 OU 噪声是更好的默认选择。

除了积分动作外，环境动力学的另一个常见方面是振荡。振荡动力学在 Pendulum 和 MountainCar 环境⁸中占主导地位，但在其他领域如 Ball-In-Cup、Cartpole 和 Walker 中也很重要。为了模拟这些动力学，我们构建了第二个环境：简谐振荡器。该系统是一个无摩擦的一维物理装置，其中质量 m 连接到刚度为 k 的理想弹簧上。状态空间由质量的位置和速度组成，动作描述了施加在质量上的力。目标是最大化振荡器系统中的能量（相当于最大化振幅），类似于 MountainCar 和 Pendulum 任务，在这些任务中，这是收集稀疏奖励所必需的。

振荡器环境由系统的共振频率 f 参数化，该频率通过设置刚度 $k = 4\pi^2$ 和质量 $m = 1/f^2$ 来固定（详见第 F.1 节）。图 5 展示了

⁷ 如果未提供赌博机奖励信号，该方法大致等同于赌博机方法。⁸ 参见第 E 节，其中介绍了一种利用此特性解决 MountainCar 的简单方法。




图 5: 粉红噪声在广泛的环境范围内, 在白噪声和 Ornstein-Uhlenbeck 噪声之间取得了有利的折中。在由规模参数化的有界积分器环境 (左) 和由共振频率参数化的简谐振荡器环境 (右) 上, 它在产生良好结果的参数范围方面更具通用性, 并且在所有合理的参数化范围内都表现良好。我们认为这一特性使其成为良好的默认选择。

振荡器系统中的平均能量 (超过 1000 个回合, 每个回合 1000 步) 作为共振频率 f 的函数, 我们将共振频率从非常低 ($f = 1$, 回合长度 = 1 个周期) 变化 $\frac{1}{1000}$ 到非常高 ($f = \frac{1}{2}$, 奈奎斯特频率), 驱动噪声分别为白噪声、粉红噪声和 OU 噪声。能量相对于共振频率下正弦激励所达到的平均能量进行测量, 记为 harm_f 。尽管这与有界积分器的设置完全不同, 并且我们使用了非常不同的性能度量, 但两幅图看起来非常相似。这再次表明粉红噪声作为默认动作噪声的强大之处: 如果我们不知道给定环境的共振频率, 粉红噪声是最佳选择。

这两个环境 (有界积分器和振荡器) 相当简单。然而, 许多真实系统的动力学无疑包含类似振荡的部分 (当存在弹簧或摆时)、单重或双重积分 (当速度/步长或力/扭矩转化为位置时) 或接触动力学 (如有界积分器中的盒子)。如果环境的动力学非常复杂, 即包含许多这样的独立部分, 那么理想的行动噪声应在每个“子任务”上得分很高。然而, 如果所有这些独立部分具有不同的参数 (如上述环境大小或共振频率), 那么最合理的单一行动噪声将是足够通用、能适应所有参数化的噪声, 即粉红噪声。另一方面, 图 3 中所有环境的平均性能可以解释为在一个非常复杂的环境中的性能, 其中子任务是“实际”环境。这可能解释了为什么我们看到这条曲线: 所有子任务具有非常不同的参数, 需要不同的行动噪声 (如表 1 所示), 但粉红噪声足够通用, 能在所有子任务上表现良好, 因此轻松优于白噪声或 OU 噪声等仅在非常特定环境上表现良好的噪声类型 (见图 5)。

7 结论

本文对彩色噪声作为深度强化学习连续控制中动作噪声进行了全面的实验评估。我们将多种彩色噪声与标准选择的白噪声和奥恩斯坦-乌伦贝克噪声进行了比较, 发现在一组标准基准上平均而言, 粉红噪声优于所有其他噪声类型。粉红噪声仅在十个环境中的两个上被其他噪声类型显著超越, 并且总体上与噪声类型的预言机选择表现相当。此外, 我们将粉红噪声与在训练过程中改变噪声类型的更复杂方法进行了比较: 颜色调度、赌博机方法和随机选择方案。没有任何方法优于粉红噪声, 我们建议使用粉红噪声作为默认动作噪声。最后, 我们在两个简化环境 (有界积分器和简谐振荡器) 上研究了纯噪声智能体的行为。结果表明, 相对于环境参数化, 粉红噪声比白噪声和奥恩斯坦-乌伦贝克噪声更具通用性, 这在一定程度上揭示了它作为默认选择表现如此出色的原因。

致谢

我们要感谢 Marco Bagatella、Sebastian Blaes 和 Pierre Schumacher 对本文早期版本提出的宝贵反馈，以及马克斯·普朗克 ETH 学习系统中心对 Cristina Pinneri 的支持。Georg Martius 是机器学习卓越集群成员，EXC 编号 2064/1 - 项目编号 390727645。我们感谢德国联邦教育与研究部（BMBF）通过蒂宾根人工智能中心（FKZ: 01IS18039B）提供的支持。

可复现性声明

我们已将代码作为补充材料提交，并在网上提供了完善版本

(<https://github.com/martius-lab/pink-noise-rl>)。为确保可复现性，我们特别注意对算法中所有随机部分应用随机种子，包括环境、算法初始化和训练以及动作噪声信号。在附录 C 中，我们提供了所用确切算法和环境的详细信息。我们方法的超参数包含在代码提交中。此外，我们的主要实验均使用 20 个不同的随机种子重复进行，以消除统计偶然性。

参考文献

- Abbas Abdolmaleki, Jost Tobias Springenberg, Yuval Tassa, Rémi Munos, Nicolas Heess, and Martin A. Riedmiller. Maximum a posteriori policy optimisation. In *6th International Conference on Learning Representations, ICLR 2018, Vancouver, BC, Canada, April 30 - May 3, 2018, Conference Track Proceedings*. OpenReview.net, 2018. URL <https://openreview.net/forum?id=SlANxQW0b>. 1
- Marco Bagatella, Sammy Joe Christen, and Otmar Hilliges. SFP: State-free priors for exploration in off-policy reinforcement learning. *Transactions on Machine Learning Research*, 2022. URL <https://openreview.net/forum?id=qYNfwFCX9a>. 3
- Greg Brockman, Vicki Cheung, Ludwig Pettersson, Jonas Schneider, John Schulman, Jie Tang, and Wojciech Zaremba. Openai gym. *CoRR*, abs/1606.01540, 2016. URL <http://arxiv.org/abs/1606.01540>. 4, 20
- Yuri Burda, Harrison Edwards, Amos J. Storkey, and Oleg Klimov. Exploration by random network distillation. In *7th International Conference on Learning Representations, ICLR 2019, New Orleans, LA, USA, May 6-9, 2019*. OpenReview.net, 2019. URL <https://openreview.net/forum?id=H1lJJnR5Ym>. 2
- James W. Cooley and John W. Tukey. An algorithm for the machine calculation of complex fourier series. *Mathematics of Computation*, 19:297–301, 1965. 13
- Marcos Duarte and Vladimir M. Zatsiorsky. Long-range correlations in human standing. *Physics Letters A*, 283(1):124–128, 2001. ISSN 0375-9601. URL <https://www.sciencedirect.com/science/article/pii/S0375960101001888>. 2
- Scott Fujimoto, Herke van Hoof, and David Meger. Addressing function approximation error in actor-critic methods. In *Proceedings of the 35th International Conference on Machine Learning, ICML 2018, Stockholmsmässan, Stockholm, Sweden, July 10-15, 2018*, volume 80 of *Proceedings of Machine Learning Research*, pp. 1582–1591. PMLR, 2018. URL <http://proceedings.mlr.press/v80/fujimoto18a.html>. 1, 4, 18
- Aurélien Garivier and Eric Moulines. On upper-confidence bound policies for non-stationary bandit problems. arXiv: 0805.3415, 2008. URL <https://arxiv.org/abs/0805.3415>. 20
- Tuomas Haarnoja, Aurick Zhou, Pieter Abbeel, and Sergey Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *Proceedings of the 35th International Conference on Machine Learning, ICML 2018, Stockholmsmässan, Stockholm, Sweden, July 10-15, 2018*, volume 80 of *Proceedings of Machine Learning Research*, pp. 1856–1865. PMLR, 2018. URL <http://proceedings.mlr.press/v80/haarnoja18b.html>. 1

- Holger Hennig, Ragnar Fleischmann, Anneke Fredebohm, York Hagmayer, Jan Nagler, Annette Witt, Fabian J. Theis, and Theo Geisel. The nature and perception of fluctuations in human musical rhythms. *PLOS ONE*, 6(10):1–7, 10 2011. URL <https://doi.org/10.1371/journal.pone.0026457>. 2
- Jakob Hollenstein, Sayantan Auddy, Matteo Saveriano, Erwan Renaudo, and Justus Piater. Action noise in off-policy deep reinforcement learning: Impact on exploration and performance. *Transactions on Machine Learning Research*, 2022. ISSN 2835-8856. URL <https://openreview.net/forum?id=NljBlZ6hmG>. Survey Certification. 3, 4, 7
- Timothy P. Lillicrap, Jonathan J. Hunt, Alexander Pritzel, Nicolas Heess, Tom Erez, Yuval Tassa, David Silver, and Daan Wierstra. Continuous control with deep reinforcement learning. In *4th International Conference on Learning Representations, ICLR 2016, San Juan, Puerto Rico, May 2-4, 2016, Conference Track Proceedings*, 2016. URL <http://arxiv.org/abs/1509.02971>. 1, 3, 15
- Horia Mania, Aurelia Guy, and Benjamin Recht. Simple random search of static linear policies is competitive for reinforcement learning. In *Advances in Neural Information Processing Systems 31: Annual Conference on Neural Information Processing Systems 2018, NeurIPS 2018, December 3-8, 2018, Montréal, Canada*, pp. 1805–1814, 2018. URL <https://proceedings.neurips.cc/paper/2018/hash/7634ea65a4e6d9041cfd3f7de18e334a-Abstract.html>. 3
- Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A. Rusu, Joel Veness, Marc G. Belle-mare, Alex Graves, Martin A. Riedmiller, Andreas Fidjeland, Georg Ostrovski, Stig Petersen, Charles Beattie, Amir Sadik, Ioannis Antonoglou, Helen King, Dhharshan Kumaran, Daan Wierstra, Shane Legg, and Demis Hassabis. Human-level control through deep reinforcement learning. *Nat.*, 518(7540):529–533, 2015. URL <https://doi.org/10.1038/nature14236>. 2
- Ian Osband, Charles Blundell, Alexander Pritzel, and Benjamin Van Roy. Deep exploration via bootstrapped DQN. In *Advances in Neural Information Processing Systems 29: Annual Conference on Neural Information Processing Systems 2016, December 5-10, 2016, Barcelona, Spain*, pp. 4026–4034, 2016. URL <https://proceedings.neurips.cc/paper/2016/hash/8d8818c8e140c64c743113f563cf750f-Abstract.html>. 2, 3
- Fabio Pardo. Tonic: A deep reinforcement learning library for fast prototyping and benchmarking. *CoRR*, abs/2011.07537, 2020. URL <https://arxiv.org/abs/2011.07537>. 4, 15, 20
- Cristina Pinneri, Shambhuraj Sawant, Sebastian Blaes, Jan Achterhold, Joerg Stueckler, Michal Rolínek, and Georg Martius. Sample-efficient cross-entropy method for real-time planning. In *4th Conference on Robot Learning, CoRL 2020, 16-18 November 2020, Virtual Event / Cambridge, MA, USA*, volume 155 of *Proceedings of Machine Learning Research*, pp. 1049–1065. PMLR, 2020. URL <https://proceedings.mlr.press/v155/pinneri21a.html>. 3
- Matthias Plappert, Rein Houthooft, Prafulla Dhariwal, Szymon Sidor, Richard Y. Chen, Xi Chen, Tamim Asfour, Pieter Abbeel, and Marcin Andrychowicz. Parameter space noise for exploration. In *6th International Conference on Learning Representations, ICLR 2018, Vancouver, BC, Canada, April 30 - May 3, 2018, Conference Track Proceedings*. OpenReview.net, 2018. URL <https://openreview.net/forum?id=ByBA12eAZ>. 3
- Antonin Raffin and Freek Stulp. Generalized state-dependent exploration for deep reinforcement learning in robotics. *CoRR*, abs/2005.05719, 2020. URL <https://arxiv.org/abs/2005.05719>. 3
- Antonin Raffin, Ashley Hill, Adam Gleave, Anssi Kanervisto, Maximilian Ernestus, and Noah Dormann. Stable-baselines3: Reliable reinforcement learning implementations. *J. Mach. Learn. Res.*, 22:268:1–268:8, 2021. URL <http://jmlr.org/papers/v22/20-1364.html>. 4, 15, 20
- Aravind Rajeswaran, Vikash Kumar, Abhishek Gupta, Giulia Vezzani, John Schulman, Emanuel Todorov, and Sergey Levine. Learning complex dexterous manipulation with deep reinforcement learning and demonstrations. In *Robotics: Science and Systems XIV, Carnegie Mellon*

- University, Pittsburgh, Pennsylvania, USA, June 26-30, 2018, 2018. URL <http://www.roboticsproceedings.org/rss14/p49.html>. 4, 20
- Daniel Russo, Benjamin Van Roy, Abbas Kazerouni, Ian Osband, and Zheng Wen. A tutorial on thompson sampling. *Found. Trends Mach. Learn.*, 11(1):1–96, 2018. URL <https://doi.org/10.1561/22000000070>. 2
- John Schulman, Sergey Levine, Pieter Abbeel, Michael I. Jordan, and Philipp Moritz. Trust region policy optimization. In *Proceedings of the 32nd International Conference on Machine Learning, ICML 2015, Lille, France, 6-11 July 2015*, volume 37 of *JMLR Workshop and Conference Proceedings*, pp. 1889–1897. JMLR.org, 2015. URL <http://proceedings.mlr.press/v37/schulman15.html>. 2
- John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *CoRR*, abs/1707.06347, 2017. URL <http://arxiv.org/abs/1707.06347>. 2
- Pierre Schumacher, Daniel Häufle, Dieter Büchler, Syn Schmitt, and Georg Martius. Dep-rl: Embodied exploration for reinforcement learning in overactuated and musculoskeletal systems. *arXiv*: 2206.00484, 2022. URL <https://arxiv.org/abs/2206.00484>. 3
- David Silver, Guy Lever, Nicolas Heess, Thomas Degris, Daan Wierstra, and Martin A. Riedmiller. Deterministic policy gradient algorithms. In *Proceedings of the 31th International Conference on Machine Learning, ICML 2014, Beijing, China, 21-26 June 2014*, volume 32 of *JMLR Workshop and Conference Proceedings*, pp. 387–395. JMLR.org, 2014. URL <http://proceedings.mlr.press/v32/silver14.html>. 2
- David Silver, Aja Huang, Chris J. Maddison, Arthur Guez, Laurent Sifre, George van den Driessche, Julian Schrittwieser, Ioannis Antonoglou, Vedavyas Panneershelvam, Marc Lanctot, Sander Dieleman, Dominik Grewe, John Nham, Nal Kalchbrenner, Ilya Sutskever, Timothy P. Lillicrap, Madeleine Leach, Koray Kavukcuoglu, Thore Graepel, and Demis Hassabis. Mastering the game of go with deep neural networks and tree search. *Nat.*, 529(7587):484–489, 2016. URL <https://doi.org/10.1038/nature16961>. 2
- Haoran Tang, Rein Houthoofd, Davis Foote, Adam Stooke, Xi Chen, Yan Duan, John Schulman, Filip De Turck, and Pieter Abbeel. #exploration: A study of count-based exploration for deep reinforcement learning. In *Advances in Neural Information Processing Systems 30: Annual Conference on Neural Information Processing Systems 2017, December 4-9, 2017, Long Beach, CA, USA*, pp. 2753–2762, 2017. URL <https://proceedings.neurips.cc/paper/2017/hash/3a20f62a0af1aa152670bab3c602feed-Abstract.html>. 2
- Yuval Tassa, Yotam Doron, Alistair Muldal, Tom Erez, Yazhe Li, Diego de Las Casas, David Budden, Abbas Abdolmaleki, Josh Merel, Andrew Lefrancq, Timothy P. Lillicrap, and Martin A. Riedmiller. Deepmind control suite. *CoRR*, abs/1801.00690, 2018. URL <http://arxiv.org/abs/1801.00690>. 4, 20
- Sebastian Thrun. Efficient exploration in reinforcement learning. Technical Report CMU-CS-92-102, Carnegie Mellon University, Pittsburgh, PA, January 1992. 2
- Jens Timmer and Michel Koenig. On generating power law noise. *Astronomy and Astrophysics*, 300: 707, 1995. 13
- G. E. Uhlenbeck and L. S. Ornstein. On the theory of the brownian motion. *Phys. Rev.*, 36:823–841, Sep 1930. URL <https://link.aps.org/doi/10.1103/PhysRev.36.823>. 3
- Ronald J. Williams. Simple statistical gradient-following algorithms for connectionist reinforcement learning. *Mach. Learn.*, 8:229–256, 1992. URL <https://doi.org/10.1007/BF00992696>. 2

补充材料

粉红噪声即所需

彩色噪声与奥恩斯坦-乌伦贝克噪声

彩色噪声具有一个正文中未提及的有趣性质：对参数为 β 的彩色噪声信号进行积分，会再次得到一个彩色噪声信号，只是参数变为 $\beta + 2$ 。这源于傅里叶变换的一个性质：时域中的积分对应于频域中乘以 $(i2\pi f)^{-1}$ 。设 $v(t)$ 为原始彩色噪声信号，其参数为 $|\hat{v}(f)|^2 \propto f^{-\beta}$ 。则 $x(t) = \int_0^t v(\tau) d\tau$ 的功率谱密度 $\int_0^t v(\tau) d\tau$ 为

$$|\hat{x}(f)|^2 = \left| \mathcal{F} \left[\int_0^t v(\tau) d\tau \right] (f) \right|^2 = \left| \frac{1}{i2\pi f} \hat{v}(f) \right|^2 \propto f^{-2} |\hat{v}(f)|^2 \propto f^{-(\beta+2)}. \quad (4)$$

由此，并结合白噪声的定义（即参数为 $\beta = 0$ 的彩色噪声），可以得出布朗运动（白噪声的积分）也是参数为 $\beta = 2$ 的彩色噪声。在图 A.1 中，展示了本文使用的大部分噪声类型的采样信号；在图 A.2 中，绘制了其中部分噪声的功率谱密度。




图 A.1: 噪声尺度为 $\sigma = 1$ 的各种动作噪声过程的采样信号。奥恩斯坦-乌伦贝克噪声是例外，其噪声尺度经过调整，使得 $\text{var}[\varepsilon_t] = 1$ （见下文讨论）。

我们使用 Timmer & Koenig (1995) 描述的基于快速傅里叶变换 (FFT) (Cooley & Tukey, 1965) 的方法生成彩色噪声。该方法非常高效，只需在频域中采样高斯信号（在频域中对功率谱密度进行整形），然后通过 FFT 将其变换到时域。特别地，该过程比采样奥恩斯坦-乌伦贝克信号（使用下文描述的最常用方法）更快。我们使用 colorednoise Python 包 (<https://github.com/felixpatzelt/colorednoise>) 来采样彩色噪声信号，并且总是采样完整回合长度的信号（记为 $\varepsilon_{1:T} \sim \text{CN}_T(\beta)$ ）。该 Python 实现包含一个错误，该错误导致生成的“白噪声”具有相关性，我们对此错误的修复已包含在该包的 2.1.0 版本中。按照此过程采样的彩色噪声是平稳且高斯的：信号在边缘分布上与标准高斯分布相同，即 $p(\varepsilon_t) = \mathcal{N}(\varepsilon_t | 0, 1)$ 。与白噪声（每个时间步独立的高斯样本）的唯一区别在于它们具有时间相关性： $p(\varepsilon_t, \varepsilon_{t'}) \neq p(\varepsilon_t)p(\varepsilon_{t'})$ 。这在图 A.3 中以粉红噪声为例进行了实证展示。




图 A.2: 左: 在采样的有色噪声信号的功率谱密度 (PSD) 中可以看到幂律趋势。右: 布朗运动 (此处通过对从 $\mathcal{N}(0, 1)$ 采样的白噪声进行积分生成) 与两种相关的平稳噪声进行比较: 奥恩斯坦-乌伦贝格噪声 ($\theta = 0.15$) 和红噪声。OU 噪声与红噪声之间的相似性可见。所有信号的长度均为 $T = 1000$ 。

A.1 奥恩斯坦-乌伦贝格噪声的生成与方差校正

图 A.3 中还包含了奥恩斯坦-乌伦贝格 (OU) 噪声。可以看出, OU 噪声起初是非平稳的, 但很快收敛到与其他噪声类型相同的边缘分布 $p(\varepsilon_t) = \mathcal{N}(\varepsilon_t | 0, 1)$ 。需要注意的是, 所有这些噪声类型之所以适合用作动作噪声, 是因为它们是 (或很快变为) 平稳的, 因此其方差不会无界增长 (与布朗运动相反)。所有噪声类型具有相同边缘分布这一特性表明, 我们的结果仅源于动作噪声时间相关性的变化, 而非分布尺度或形状的变化, 因为这与常规高斯白噪声相同。为确保 OU 噪声收敛到标准高斯边缘分布, 我们不能使用 $\sigma = 1$ 的噪声尺度, 而必须对其进行校正。奥恩斯坦-乌伦贝格噪声可由以下随机微分方程定义

$$dx_t = -\theta x_t dt + \sigma dw_t, \quad (5)$$




图 A.3: 我们用作动作噪声的有色噪声与独立高斯样本具有相同的边缘分布。我们从以下随机过程中各采样了 3×10^5 个长度为 $T = 1000$ 的动作噪声信号: 独立高斯样本 (白噪声, 左)、粉红噪声 (中)、奥恩斯坦-乌伦贝格噪声 (右)。在每个时间步 t , 我们展示了动作噪声值 ε_t 的直方图密度估计。这表明我们的结果仅源于动作噪声信号时间相关性的增强, 因为边缘分布与白噪声相比保持不变。

其中 w_t 是维纳过程（积分白噪声，具有对任意 $0 \leq t' < t$ 有 $w(t) - w(t') \sim \mathcal{N}(0, t - t')$ 的性质）。奥恩斯坦-乌伦贝格噪声的这一定义等价于正文中的朗之万方程（3），但更便于处理，因为白噪声过程 η_t 作为维纳过程的导数是不良定义的。我们通过离散化上述方程来采样 OU 噪声信号：

$$x[t + \Delta t] = x[t] - \theta x[t]\Delta t + \sigma \sqrt{\Delta t} \varepsilon, \quad (6)$$

其中 $\varepsilon \sim \mathcal{N}(0, 1)$ 。记 $x_t := x[t\Delta t]$ （其中 $x_{-1} = 0$ ）和 $\varepsilon_t \sim \mathcal{N}(0, 1)$ 对于所有 $t \in \mathbb{N}_0$ ，它可以 be seen that

$$\begin{aligned} x_0 &= \sigma \sqrt{\Delta t} \varepsilon_0 \\ x_1 &= x_0 - \theta x_0 \Delta t + \sigma \sqrt{\Delta t} \varepsilon_1 \\ &= \sigma \sqrt{\Delta t} (1 - \theta \Delta t) \varepsilon_0 + \sigma \sqrt{\Delta t} \varepsilon_1 \\ x_2 &= \sigma \sqrt{\Delta t} (1 - \theta \Delta t)^2 \varepsilon_0 + \sigma \sqrt{\Delta t} (1 - \theta \Delta t) \varepsilon_1 + \sigma \sqrt{\Delta t} \varepsilon_2 \\ &\vdots \\ x_t &= \sigma \sqrt{\Delta t} \sum_{\tau=0}^t (1 - \theta \Delta t)^{t-\tau} \varepsilon_\tau. \end{aligned}$$

因此，作为零均值高斯分布之和，边际分布为：

$$\begin{aligned} p(x_t) &= \sigma \sqrt{\Delta t} \mathcal{N} \left(0, \sum_{\tau=0}^t ((1 - \theta \Delta t)^{t-\tau})^2 \right) \\ &= \mathcal{N} \left(0, \sigma^2 \Delta t \sum_{\tau=0}^t (1 - \theta \Delta t)^{2\tau} \right). \end{aligned}$$

该分布的方差是一个几何级数，当 $t \rightarrow \infty$ 时收敛，若 $(1 - \theta \Delta t)^2 < 1$ ，这成立当 $0 < \theta \Delta t < 2$ 。有趣的是，若 $\theta \Delta t = 1$ ，则方程（6）退化为白噪声，即 $\Delta t \varepsilon$ 。另一方面，若 $\theta \Delta t = 0$ ，该方程描述积分白噪声（布朗运动），其方差无界。若 $1 < \theta \Delta t < 2$ ，则信号呈现负时间相关性，这由方程（6）可得。若几何级数收敛，则极限方差为

$$\frac{\sigma^2 \Delta t}{1 - (1 - \theta \Delta t)^2}.$$

因此，通过将噪声尺度设为“校正”值，可以确保（极限情况下）标准高斯边际分布：

$$\sigma = \sqrt{\frac{1 - (1 - \theta \Delta t)^2}{\Delta t}}, \quad (7)$$

这正是本文中设置 OU 噪声尺度的方式，以使白噪声与有色噪声的比较公平。在图 A.3 中可见，该极限边际分布很快达到。在附录 B 中，我们还报告了更常见选择 $\sigma = 1$ 下的 Ornstein-Uhlenbeck 结果，发现其通常表现略差（参见图 B.1）。

若方差已校正，则 $\theta \Delta t$ 是 OU 噪声的唯一参数，例如（ $\theta = 0.3$, $\Delta t = 1$ ）等价于（ $\theta = 30$, $\Delta t = 0.01$ ）。这通过将方程（7）代入方程（6）立即得到，产生 $x_{t+1} = (1 - \theta \Delta t)x_t + \sqrt{1 - (1 - \theta \Delta t)^2} \varepsilon_t$ ，其中仅包含乘积 $\theta \Delta t$ 作为参数。因此本文不失一般性地设 $\Delta t = 0.01$ 。在正文中，我们也仅将 OU 噪声视为强相关布朗运动的替代，并始终设 $\theta = 0.15$ ，因为这是实践中最常用的默认设置。⁹ 然而，如上所述，通过设 $0 < \theta < 100$ （i.e. $0 < \theta \Delta t < 1$ ），Ornstein-Uhlenbeck 噪声也可呈现介于白噪声与布朗运动之间的中间时间相关性。这引出一个问题：是否存在某种 OU 噪声参数化，其一般性与粉红噪声相当。

我们选择这些 Δt 和 θ 的值，是因为它们是我们所考虑的强化学习库（Raffin 等人，2021；Pardo，2020）的默认选择。Lillicrap 等人（2016）也推荐 $\theta = 0.15$ 。如果不对方差进行校正（我们在第 B 节报告了这些实验），那么 Δt 的选择确实会产生影响。




图 A.4: 左: OU 噪声的功率谱密度。OU 噪声通过改变低通滤波器的截止频率 (该滤波器对白噪声进行滤波), 在白噪声和布朗运动之间进行插值。中: 在有界积分器环境中, 不同 θ 的 OU 噪声所达到的熵。没有任何 θ 能达到比粉红噪声更高的最坏情况熵。右: 在谐振子环境中, 不同 θ 的 OU 噪声所达到的能量。没有任何 θ 能达到接近粉红噪声的最坏情况能量。

A.2 奥恩斯坦-乌伦贝克噪声的普适性

OU 噪声通过选择 $\theta \in (0, 100)$ 在白噪声和布朗运动之间进行插值的方式, 与具有 $\beta \in (0, 2)$ 的有色噪声非常不同。我们已经证明 (例如在图 A.2 中), 具有中等时间相关性的有色噪声具有幂律功率谱密度, 且指数 (或对数-对数图中的斜率) 为中间值。另一方面, 奥恩斯坦-乌伦贝克噪声可以解释为白噪声的“泄漏积分”, 即通过低通滤波器的白噪声。这个积分器的“泄漏”程度由参数 θ 控制: 如果 $\theta = 0$, 则积分器是理想的, 产生积分白噪声 (方差发散的布朗运动)。如果 $\theta = 100$ (其中 $\Delta t = 0.01$), 则积分器“完全泄漏” (全通滤波器), 白噪声未经积分直接通过。就功率谱密度而言, θ 的这种变化对应于低通滤波器截止频率的移动。这在图 A.4 的左侧针对 $\theta \in \{0.01, 0.03, 0.1, 0.3, 1, 3, 10, 30, 100\}$ 进行了展示。

为使一种动作噪声类型具有普适性 (参见第 6 节), 我们希望它能在所有环境中都表现良好。在功率谱密度图中已经可以看出, 粉红噪声在频率上的功率分布比任何 θ 的奥恩斯坦-乌伦贝克噪声都“普遍”得多: 在任意给定频率 f 处, 粉红噪声的功率高于大多数 θ 值, 而所有 θ 值在大多数频率上的功率都低于粉红噪声。为什么这使粉红噪声成为更通用的动作噪声, 可以通过回顾第 6 节中引入的有界积分器和谐波振荡器环境来更具体地说明。噪声的通用性衡量了它对环境选择或参数化的鲁棒性: 最通用的噪声类型是在最具对抗性的环境参数化下表现最佳的噪声类型。因此, 对于由参数 α 参数化的环境, 最通用的 θ 求解以下优化问题:

$$\max_{\theta} \min_{\alpha} \text{perf}(\alpha, \theta),$$

其中性能度量 $\text{perf}(\alpha, \theta)$ 应适当归一化, 使得对于不同的 α 值可获得的最大性能相同。这可以通过简单地除以每个 α 值的最佳 θ 所达到的性能来确保:

$$\max_{\theta} \min_{\alpha, \theta'} \underbrace{\frac{\text{perf}(\alpha, \theta)}{\text{perf}(\alpha, \theta')}}_{\text{generality}(\theta)}. \quad (8)$$

这给出了最通用噪声在最坏情况环境下的性能, 以在该最坏情况环境下通过改变噪声类型所能达到的最佳性能来表示。通过将表达式 $\text{perf}(\alpha, \theta)$ 替换为 $\text{perf}(\alpha, \text{粉红})$ 并移除对 θ 的最大化, 我们也可以计算粉红噪声的通用性。

如第 6 节所述，噪声类型在有界积分器和振荡器环境上的性能分别由所达到的熵和能量给出。这在图 A.4 中针对所有 θ 值（以及粉红噪声）进行了展示，其中参数化参数 α 对于有界积分器是环境大小，对于谐振子是谐振频率。已经可以看出，在这两种环境中，对于每个 θ 的选择，都存在一个参数 α ，使得 θ 的性能比粉红噪声的最坏情况性能更差。这可以通过根据公式 (8) 计算每个 θ 和粉红噪声在这些环境上的通用性来量化。在有界积分器上，OU 噪声的最大通用性为 77%，在振荡器环境上最大通用性为 9.1%。在这两种环境中，最大值由 $\theta = 3$ 达到。粉红噪声在有界积分器和振荡器环境上分别实现了 79% 和 22% 的通用性。这进一步证明了粉红噪声是一个良好的默认选择。

B 附加结果

B.1 TD3

除了 MPO 和 SAC 之外，我们还在 TD3 上执行了正文中的所有实验。MPO 和 SAC 参数化了一个随机策略，这意味着它们学习动作噪声尺度作为状态 $\sigma(s)$ 的函数。另一方面，TD3 使用确定性策略，动作噪声独立于状态添加。通常，噪声尺度 σ 在训练过程中保持固定，我们在实验中也这样处理。然而， σ 是一个重要的超参数，没有单一的值能在所有环境中都表现良好。因此，我们使用所有 $\sigma \in \{0.05, 0.1, 0.3, 0.5, 1\}$ 值和 10 个不同的随机种子重复我们的实验。

在图 B.1 中，恒定噪声类型的 TD3 实验结果以期望平均性能的平均分布形式展示，并与 MPO 和 SAC 上的相同实验以及类似图 3 的图（其中智能体的影响已被归一化）进行了比较。由于我们有一个额外的超参数（ σ ），我们首先在所有 σ 值上平均 TD3 性能，然后计算跨任务的平均性能。粉红噪声的有益效果




图 B.1: 所有三种算法（MPO、SAC、TD3）都显示出对粉红动作噪声的明显偏好，这是通过图 2 中环境的平均性能来衡量的。使用未校正噪声尺度 $\sigma = 1$ 的 OU 实验结果用虚线中位数标记。




图 B.2: 各环境的平均性能由所有 β 值 (含白噪声) 合并而成。可以看出, TD3 始终被 MPO 和 SAC 超越。进一步观察每个单独环境上所有 β 值的平均性能, 发现 TD3 在所有环境中均被 MPO 和 SAC 超越。

在 TD3 上也能清晰看到。在此图中, 我们还展示了噪声尺度为 $\sigma = 1$ 的奥恩斯坦-乌伦贝格噪声结果, 而非式 (7) 中修正后的噪声尺度。附带地, 这些结果也证实了 Fujimoto 等人 (2018) 的发现: 在 TD3 上, 白噪声与 OU 噪声 ($\theta = 0.15$) 表现相似。

我们未将 TD3 纳入正文分析的原因是, 我们发现 TD3 始终被 MPO 和 SAC 超越。在图 B.2 中, 各环境的平均性能由所有 β 值 (含白噪声) 合并而成, 并展示了 MPO、SAC 和 TD3 的结果。可以看出, TD3 通常表现远差于 MPO 和 SAC。观察每个单独环境上所有 β 值的平均性能, TD3 在所有环境中均被 MPO 和 SAC 超越。因此, 我们决定将 TD3 排除在主要分析之外。

B.2 MPO 与 SAC

在本文的大部分内容中, 我们以训练过程中平均评估回报来衡量性能。我们采用此方法, 因为它隐式地衡量了最终策略性能和样本效率 (算法达到高性能的速度)。我们呈现的大部分数据还进行了归一化, 这是为了在不同环境间聚合性能所必需的, 因此结果往往不太容易精确解释 (除了识别统计显著性)。在本节中, 我们希望能以更熟悉的形式呈现部分结果, 即学习曲线和最终策略性能。

为验证使用 (平均) 性能而非最终策略性能的方法, 我们使用最终策略性能 (训练过程最后 5% 的平均评估回报) 复现了图 3 的结果, 如图 B.3 所示。在图 B.4 中, 我们展示了 MPO 和 SAC 在所有环境上白噪声、粉红噪声和 OU 噪声的学习曲线。两种可视化均证实了我们的结论: 粉红噪声是比白噪声或 OU 噪声更好的默认动作噪声。更详细的结果见第 H 节。

期望平均性能的自举分布 (如图 3、图 4、图 B.1 和图 B.3 所示) 通过为每个环境随机选择一个种子来构建, 从而得到一个标量。




图 B.3: 平均最终性能类似于平均性能 (见第 4 节), 但仅使用训练最后 5% 的评估回报, 从而衡量最终学习策略的质量。该图展示了与图 3 相同的对 MPO 和 SAC 的分析, 并表明粉红噪声在最终策略性能方面也更优。




图 B.4: 两种基线动作噪声类型白噪声 (White Noise, WN) 和奥恩斯坦-乌伦贝格噪声 (Ornstein-Uhlenbeck, OU) 以及我们建议的粉红噪声的学习曲线 (评估回报的中位数和四分位距)。可以看出, 粉红噪声虽然并非在所有环境中都优于两者, 但却是最佳的默认选择。它从未同时被白噪声和 OU 噪声超越, 并且经常超越白噪声 (例如 MountainCar)、OU 噪声 (例如 Door) 或两者 (例如 Hopper)。

每个环境的 (归一化) 性能, 假设所有其他变量 (如算法和噪声类型) 固定。对这些归一化性能进行平均 (在每个环境上归一化性能的原因是为了使这种平均合理) 可以得到给定变量 (例如噪声类型和算法) 跨环境的平均性能估计。由于存在 S 个不同的随机种子 (通常为 $S = 20$), 我们可以重复此过程 S 次 (有放回抽样), 并取所有 S 个平均性能估计的均值, 从而得到给定变量的期望平均性能估计。重复此过程 N 次 (我们使用 $N = 10^5$), 可以将 N 个期望平均性能估计收集到自举分布中, 如这些图所示。

C 环境与算法

我们在 10 个不同的任务上评估我们的方法（见图 2）。其中大多数来自 DeepMind 控制套件（DMC, Tassa 等人, 2018），但我们也使用了 OpenAI Gym（Brockman 等人, 2016）和 Adroit 手部套件（Rajeswaran 等人, 2018）。所有环境的相应来源和确切 ID 汇总在表 C.1 中。其他任务的结果见第 G 节。

Environment	Source	ID
Pendulum	DMC	pendulum (swingup)
Cartpole (b.)	DMC	cartpole (balance_sparse)
Cartpole (s.)	DMC	cartpole (swingup_sparse)
Ball-In-Cup	DMC	ball_in_cup (catch)
MountainCar	Gym	MountainCarContinuous-v0
Hopper	DMC	hopper (hop)
Walker	DMC	walker (run)
Reacher	DMC	reacher (hard)
Cheetah	DMC	cheetah (run)
Door	Adroit	door-v0

表 C.1: 本工作中使用的环境（另见图 2）。

在实验中，我们采用了稳定基线 3（Stable-Baselines3）库（Raffin 等, 2021）中的双延迟深度确定性策略梯度（TD3）与软演员-评论家（SAC）实现，以及 Tonic 强化学习库（Pardo, 2020）中的最大后验策略优化（MPO）实现。我们仅使用了这些库提供的算法默认超参数。我们用于在这些库中使用有色噪声的代码已在线公开于 <https://github.com/martius-lab/pink-noise-rl>。

D 强盗方法细节

为了使用老虎机算法为一次展开选择动作噪声颜色 β ，有必要定义老虎机奖励，该奖励应根据所选的 β 对展开进行评分。在我们的案例中，我们使用展开回报（奖励之和）作为评分，如第 5.2 节所述。此外，我们必须选择一个颜色列表（“老虎机臂”）进行搜索： $B = (\beta_1, \beta_2, \dots, \beta_K)$ （在我们的案例中为 $\beta_k \in [0, 2], \forall k$ ）。如果我们假设老虎机奖励（= 展开评分）服从已知标准差 σ 的高斯分布，我们可以使用贝叶斯推断来估计奖励分布的均值（ $\mu \in \mathbb{R}^K$ ）。在此背景下，我们可以使用的一种简单老虎机算法是汤普森采样，如算法 D.1（ $\mathbb{S}^K$ 所示（ $+$ 表示正半定 $K \times K$ 矩阵的集合）。随机变量之间的关系如图 D.1a 中的贝叶斯网络所示。

Algorithm D.1: Thompson Sampling

Input: Arms $B = (\beta_1, \dots, \beta_K)$,
Reward distributions std σ
Initialize $\mathbf{m} \in \mathbb{R}^K, \Sigma \in \mathbb{S}_+^K$
for $i \in \mathbb{N}$ **do**
 Sample $\mathbf{q} \sim \mathcal{N}(\mathbf{m}, \Sigma)$
 $a_i \leftarrow \arg \max_{k \in \{1, \dots, K\}} q_k$
 $\tau_i \leftarrow$ 使用 β_{a_i} 执行推演 $r_i \leftarrow$ 推演得分 τ_i 对 $\mathbf{m}$, 进行贝叶斯更新 Σ 使用 $\{a_j, r_j\}_{j=1}^i, \sigma$
end

在算法 D.1 所示的汤普森采样算法中（类似地，对于其他算法如 UCB），存在第二个强假设：它假设奖励分布是平稳的，即它们不随时间变化。这在强化学习的背景下并不成立：如果 rollout 分数 r_i 被定义为回报，那么，如果强化学习算法有效，策略自然会随时间改进，因此平均而言， $r_i > r_j$ 对于 $i \gg j$ 。这种非平稳老虎机分布设置可以通过使用滑动窗口方法来解决（例如 Garivier & Moulines, 2008）：不是根据整个观测历史来更新信念参数 $\mathbf{m}$, Σ ，而是只保留最后 N 次 rollout 的窗口。

还存在另一个问题：如何选择先验参数 $\mathbf{m}$ 和 Σ 以及奖励分布的方差 σ^2 ？对于 Σ ，最简单的解决方案是假设各臂独立，即令




图 D.1: (a) 具有高斯奖励分布的贝叶斯赌博机。臂 k 的奖励从 $\mathcal{N}(\mu_k, \sigma)$ 中采样。汤普森采样 (算法 D.1) 可以在探索与利用之间权衡的同时推断 μ 。(b) 通过引入常数 b 和 c ，算法可以通过对归一化奖励 $\tilde{r}_i = (r_i - b)/c$ 执行汤普森采样而具有尺度不变性。

Σ 对角矩阵。这不一定是最有效的解决方案，因为可以想象两个相似的 β 值在它们的展开中也会表现相似。¹⁰ 对于 $\mathbf{m}$ ，非平稳性成为一个问题：再次假设我们使用展开回报作为分数，这些分数在训练开始时很可能比训练结束时低得多。此外，我们甚至可能不知道任务中回报的尺度。为了解决这个问题，有必要使先验方差 Σ_{kk} 非常大/无信息。类似地， σ 需要很大，以考虑赌博机奖励分布的未知尺度。然而，这意味着需要更多的样本（展开）来收紧信念分布。这是一个问题，特别是因为在使用滑动窗口方法时我们只有一小部分 N 展开。

理想的情况是一种对奖励的仿射变换具有不变性的赌博机方法，即如果所有奖励 r 被变换为 $br + c$ （对于某些常数 $b > 0$ 和 $c \in \mathbb{R}$ ，对所有臂都成立），该方法不会产生任何差异。在图 D.1b 中，这种情况在贝叶斯网络中展示。这里，生成过程与之前几乎相同（见图 D.1a），除了奖励 $\tilde{r}_i$ 在观测前被 $r_i = b\tilde{r}_i + c$ 缩放和平移。如果如图所示，常数 b 和 c 与所选臂无关且在窗口内保持不变，则可以通过最大边际似然来优化它们，给定过去观测 r_i 的窗口。

赌博机推断任务是从动作（颜色索引） $\mathbf{a} = (a_i)_{i=1}^N$ 和奖励（展开分数） $\mathbf{r} = (r_i)_{i=1}^N$ 中推断分布均值 $\mu = (\mu_1, \dots, \mu_k)$ 。我们将信念分布的先验均值设为 $\mathbf{0}$ ($\mathbf{m} = \mathbf{0}$)，因为我们希望归一化奖励分布以 0 为中心。目前，我们不固定 Σ ，而是让它为任意半正定 $K \times K$ 矩阵。 $\mathbf{r}$ 的生成模型通过以下先验和似然函数定义：

$$p(\mu | \Sigma) = \mathcal{N}(\mu | \mathbf{0}, \Sigma) \quad (9)$$

$$p(\mathbf{r} | \mu, \mathbf{a}, b, c, \sigma) = \prod_i \mathcal{N}(r_i | b\mu_{a_i} + c, (b\sigma)^2) \quad (10)$$

这些引导我们得到以下证据/边际似然函数：

$$p(\mathbf{r} | \mathbf{a}, b, c, \sigma, \Sigma) = \prod_i p(r_i | a_i, b, c, \sigma, \Sigma) \quad (11)$$

$$= \prod_i \int p(r_i | \mu, a_i, b, c, \sigma) p(\mu | \Sigma) d\mu \quad (12)$$

$$= \prod_i \int \mathcal{N}(r_i | b\mathbf{e}_{a_i}^\top \mu + c, (b\sigma)^2) \mathcal{N}(\mu | \mathbf{0}, \Sigma) d\mu \quad (13)$$

$$= \prod_i \mathcal{N}(r_i | b\mathbf{e}_{a_i}^\top \mathbf{0} + c, (b\sigma)^2 + b\mathbf{e}_{a_i}^\top \Sigma b\mathbf{e}_{a_i}) \quad (14)$$

我们还尝试了一种不同的方法，使用修改后的径向基函数核矩阵来考虑臂之间的协方差，但结果与独立臂的情况基本相同。

$$= \prod_i \mathcal{N}(r_i | c, b^2(\sigma^2 + \Sigma_{a_i a_i})), \quad (15)$$

其中我们使用规范基向量来表示 $\mu_{a_i} = \mathbf{e}_{a_i}^\top \boldsymbol{\mu}$ 。对于最大化问题，使用对数证据更为方便：

$$\log p(\mathbf{r} | \mathbf{a}, b, c, \sigma, \Sigma) = \log \prod_i \mathcal{N}(r_i | c, b^2(\sigma^2 + \Sigma_{a_i a_i})) \quad (16)$$

$$= \sum_i -\frac{1}{2} \log(2\pi b^2(\sigma^2 + \Sigma_{a_i a_i})) - \frac{(c - r_i)^2}{2b^2(\sigma^2 + \Sigma_{a_i a_i})} \quad (17)$$

$$=: L(b, c) \quad (18)$$

现在我们可以通过将偏导数设为零来最大化证据：

$$\partial_c L(b, c) \propto \sum_i (c - r_i) = 0 \quad (19)$$

$$\partial_b L(b, c) = \sum_i \frac{-1}{b} + \frac{(c - r_i)^2}{b^3(\sigma^2 + \Sigma_{a_i a_i})} = 0 \quad (20)$$

求解这些方程得到

$$c = \frac{1}{N} \sum_i r_i \quad (21)$$

$$b^2 = \frac{1}{N} \sum_i \frac{(c - r_i)^2}{\sigma^2 + \Sigma_{a_i a_i}}. \quad (22)$$

利用这些值，我们可以“重建”未缩放/归一化的奖励

$$\tilde{r}_i = \frac{r_i - c}{b} \quad (23)$$

并针对 $\tilde{r}_i$ 执行汤普森采样。该归一化汤普森采样算法（包括滑动窗口修改）在算法 D.2 中给出。

Algorithm D.2: Normalized TS

Input: Arms $B = (\beta_1, \dots, \beta_K)$,
Window size N

Initialize

$\mathbf{m} \leftarrow \mathbf{0} \in \mathbb{R}^K, \Sigma \in \mathbb{S}_+^K, \sigma \leftarrow 1$

for $l \in \mathbb{N}$ **do**

$i \leftarrow l \bmod N$

$M \leftarrow \min\{l, N\}$

 Sample $\mathbf{q} \sim \mathcal{N}(\mathbf{m}, \Sigma)$

$a_i \leftarrow \arg \max_{k \in \{1, \dots, K\}} q_k$

$\tau_i \leftarrow \text{Run rollout with } \beta_{a_i}$

$r_i \leftarrow \text{score of rollout } \tau_i$

$c \leftarrow \frac{1}{M} \sum_{j=1}^M r_j$

$b \leftarrow \sqrt{\frac{1}{M} \sum_{j=1}^M \frac{(c - r_j)^2}{\sigma^2 + \Sigma_{a_j a_j}}}$

$\tilde{r}_i \leftarrow \frac{r_i - c}{b}$

 Do Bayesian update of $\mathbf{m}, \Sigma$ using
 $\{a_j, \tilde{r}_j\}_{j=1}^M, \sigma$

end

接下来，我们希望证明该方法确实对老虎机奖励的仿射变换具有不变性。

命题 1. 归一化老虎机算法（算法 D.2）中关于 $\boldsymbol{\mu}$ 的后验分布对于观测值 $\mathbf{r} = (r_1, \dots, r_N)$ 和 $\mathbf{r}' = b'\mathbf{r} + c'$ 是相同的，对于所有 $b' > 0$ 和 $c' \in \mathbb{R}$ 。换言之，该算法对奖励的缩放和平移具有不变性。

证明。在此设定下，观测到的奖励 r_i 为 normalized to

$$\tilde{r}_i = \frac{r_i - c(\mathbf{r})}{b(\mathbf{r})} \quad (24)$$

具有

$$c(\mathbf{r}) = \frac{1}{N} \sum_{i=1}^N r_i \quad (25)$$

$$b(\mathbf{r}) = \sqrt{\frac{1}{N} \sum_{i=1}^N \frac{(c(\mathbf{r}) - r_i)^2}{\sigma^2 + \Sigma_{a_i a_i}}}. \quad (26)$$

为证明算法的不变性，本文仅需证明该归一化奖励对于两组观测是相同的，即 $\tilde{\mathbf{r}} = \tilde{\mathbf{r}}'$ 。那么，显然后验 $p(\boldsymbol{\mu} | \tilde{\mathbf{r}})$ 与 $p(\boldsymbol{\mu} | \tilde{\mathbf{r}}')$ 也将相同。展开 $\tilde{\mathbf{r}}'$ ，可得：

$$\tilde{\mathbf{r}}' = \frac{\mathbf{r}' - c(\mathbf{r}')}{b(\mathbf{r}')} \quad (27)$$

$$= \frac{b'\mathbf{r} + c' - c(b'\mathbf{r} + c')}{b(b'\mathbf{r} + c')} \quad (28)$$

$$= \frac{b'\mathbf{r} + c' - \frac{1}{N} \sum_{i=1}^N (b'r_i + c')}{\sqrt{\frac{1}{N} \sum_{i=1}^N \frac{(\frac{1}{N} \sum_{j=1}^N (b'r_j + c') - (b'r_i + c'))^2}{\sigma^2 + \Sigma_{a_i a_i}}}} \quad (29)$$

$$= \frac{b'\mathbf{r} + c' - b' \frac{1}{N} \sum_{i=1}^N r_i - c'}{\sqrt{\frac{1}{N} \sum_{i=1}^N \frac{(b' \frac{1}{N} \sum_{j=1}^N r_j + c' - b'r_i - c')^2}{\sigma^2 + \Sigma_{a_i a_i}}}} \quad (30)$$

$$= \frac{b'(\mathbf{r} - c(\mathbf{r}))}{\sqrt{\frac{1}{N} \sum_{i=1}^N \frac{b'^2 (c(\mathbf{r}) - r_i)^2}{\sigma^2 + \Sigma_{a_i a_i}}}} \quad (31)$$

$$= \frac{\mathbf{r} - c(\mathbf{r})}{b(\mathbf{r})} \quad (32)$$

$$= \tilde{\mathbf{r}} \quad (33)$$

因此，可以得出结论：奖励归一化确实保证了汤普森采样等算法对仿射奖励变换的不变性。 $\square$

通过这种奖励归一化，先验参数 $\mathbf{m}$ （属于 $\mathbf{m} = \mathbf{m}\mathbf{1}$ ）和 $\mathbf{s}$ （属于 $\Sigma = s^2 \mathbf{I}$ ）变得冗余。我们已经设定 $\mathbf{m} = \mathbf{0}$ ，现在也将先验方差 Σ_{kk} 设为 1。这促使算法保持归一化均值估计 μ_k 近似服从 $\mathcal{N}(0, 1)$ 分布。“似然”参数 σ 仍需调整，但现在无需考虑奖励尺度上的巨大不确定性，因为 σ 只关注归一化奖励。在我们的实验中，我们始终设定 $\sigma = 1$ 。

D.1 老虎机与随机

尽管我们发现归一化老虎机算法（Alg. D.2）在简单的非平稳任务上表现良好，但在强化学习环境中（用于选择 β 时），其性能与每次展开的随机 β 选择相当。在表 D.1 中，我们列出了韦尔奇 t 检验的结果，该检验用于检验老虎机算法与随机 β 选择在每个环境上取得的性能分布是否不等。可以看出，这两种方法在统计上无法区分。这表明老虎机方法并未按预期工作，因为“随机臂选择”应当是一个容易超越的基线。其原因可能在于展开回报作为老虎机奖励信号的信息量不足。

Environment	Bandit $\neq$ Random	p
Pendulum	$\times$	0.98
Cartpole (b.)	$\times$	0.09
Cartpole (s.)	$\times$	0.67
Ball-In-Cup	$\times$	0.87
MountainCar	$\times$	0.54
Hopper	$\times$	0.09
Walker	$\times$	0.15
Reacher	$\times$	0.70
Cheetah	$\times$	0.20
Door	$\times$	0.59

表 D.1: 老虎机与随机（韦尔奇 t 检验）

用快速傅里叶变换求解山地车问题

山地车是一个十分简单的环境。尽管其动力学几乎等同于谐振子，但与第 6 节中的振荡器环境存在一处差异：山地车的振荡动力学是非线性的。在山地车谷底（见图 2），可采用非线性振荡器的小角度近似，但若要使运动到达顶部，其行为便不同于简谐运动。尽管如此，我们可以利用这一洞见，开发一种非常简单的开环控制算法来求解该环境：先执行一次不施加任何动作的轨迹展开（仅让山体使小车来回运动片刻），随后分析所得轨迹，并通过快速傅里叶变换算法推断山坡的（小角度）共振频率。最后，我们只需以该共振频率来回摆动小车即可实现控制。该算法在此任务上表现极佳，如下所示。

导入 gym 库, 导入 numpy 库, 从
scipy.fft 导入 rfft 函数

```
# 初始化环境 env = gym.make('MountainCarContinuous-v0')
T = env._max_episode_steps

# 执行一次无外力轨迹展开。将 x 坐标保存至 `x`。obs = env.reset() x = [obs[0]]

for t in range(T): obs, *_ =
env.step([0]) x.append(obs[0])

# 寻找共振频率 = FFT 最高峰（排除直流分量）
f = (np.argmax(abs(rfft(x)[1:])) + 1) / (T + 1)

# 行动计划（谐波激励）
a = np.sin(2*np.pi*f * np.arange(T))

# 在 1000 次回放上测试
N = 1000
solved = 0
对于 i 在范围 (N) 内: 环
境重置()
    对于 t 在范围 (T) 内:
        r, *_ = env.step([a[t]])
        if r > 0:
            solved += 1
            中断

打印(f'已解决: {solved / N * 100:.0f} %.') # 打印 "已解决: 100%."
```

F 玩具环境细节

F.1 振荡器环境

第 6 节的振荡器环境（我们将其作为健身房环境在线提供

（<https://github.com/onnoeberhard/oscillator-gym>）模拟了一个质量为 m 的粒子的一维运动，该粒子通过刚度系数为 k 的理想弹簧连接到原点，受到摩擦系数为 b 的阻尼，并由一个力（动作） F 驱动。该运动由常微分方程描述

$$m\ddot{x} = F - b\dot{x} - kx, \quad (34)$$

其中 x 是粒子的位置。在我们的实验中，我们将摩擦系数 b 设为零，即系统无阻尼。这种设置被称为简谐振荡器。振荡器的能量为

振荡器的能量是动能与势能之和：

$$E = \frac{1}{2}m\dot{x}^2 + \frac{1}{2}kx^2. \quad (35)$$

共振频率为：

$$f = \frac{1}{2\pi}\sqrt{\frac{k}{m}}. \quad (36)$$

由于我们希望将振荡器配置为具有给定的共振频率 f ，因此需要相应地找到 m 和 k 。为了得到唯一解，我们施加第二个约束：在 $x = 1$ 和 $\dot{x} = 0$ 处的能量应为 $E = 2\pi^2$ 。如果现在对 m 和 k 求解方程 (35) 和 (36)，并施加对 E 的约束，我们得到解

$$k = 4\pi^2 \quad (37)$$

$$m = \frac{1}{f^2} \quad (38)$$

来设置共振频率。在图 F.1 中，展示了振荡器环境上的几条纯噪声轨迹（类似于图 1）。




图 F.1: 振荡器环境上的轨迹。对于 3 个共振频率 $f \in \{0.002, 0.02, 0.2\}$ 中的每一个，我们采样 5 个长度为 10 的 $\bar{f}$ 动作噪声信号，包括白噪声、粉红噪声和 OU 噪声。我们可以看到图 5 中已经展示的内容：粉红噪声对参数化的敏感度远低于白噪声和 OU 噪声，并且总是能将振荡器激励到一定幅度。白噪声和 OU 噪声分别仅在高频和低频范围内表现良好。

F.2 有界积分器环境

第 6 节中的有界积分器环境具有非常简单的动力学：

$$s_{t+1} = \text{clip}(s_t + a_t, -c, c), \quad (39)$$

其中 $s_0 = 0$ 和 c 是决定环境大小的参数。因此，图 5 中的“面积”由 c^2 给出。在图 1 中，该参数固定为 $c = 250$ ，而在图 F.2 中，这些轨迹（中间行）与较小环境（顶行）和较大环境（底行）上的轨迹进行比较，其精神与图 F.1 类似。




图 F.2: 有界积分器环境上的轨迹。对于 3 种环境大小中的每一种 $c \in \{25, 250, 1000\}$ ，我们采样 20 个长度为 1000 步的动作噪声信号，分别为白噪声、粉红噪声和 OU 噪声。我们可以看到图 5 中已经展示的内容：粉红噪声对参数化的敏感度低于白噪声（白噪声在探索中大型环境时太慢）和 OU 噪声（OU 噪声在中型和小型环境上会卡在边缘，无法探索内部）。

G 附加环境

除了第 C 节中描述的环境外，我们还在“MuJoCo-Maze”套件

(<https://github.com/kngwyu/mujoco-maze>) 的几个任务上进行了实验。结果以学习曲线和每种噪声类型在所有六个环境上的平均性能（参见第 B.2 节）的形式显示在图 G.1 中。我们测试了白噪声、粉红噪声和（方差校正的，参见第 A.1 节）Ornstein-Uhlenbeck 噪声，并使用 20 个种子在所有环境上训练 MPO 和 SAC，进行 10^6 次交互。粉红噪声再次作为跨环境的默认选择优于白噪声和 Ornstein-Uhlenbeck 噪声。这些实验是为了在不同的




图 G.1: 白噪声、粉红噪声和 OU 噪声在几个“MuJoCo-Maze”任务（均为稀疏奖励）上的性能。可以看出，粉红噪声是三者中最佳的默认选择，因为它具有最高的平均性能（第 B.2 节）。

问题集上验证我们的方法，因此未包含在主要分析中。结果进一步支持了我们的主要结论：粉红噪声是非常好的默认动作噪声。

H 详细结果

Environment	Agent	Final Performance			Mean Performance					
		WN	OU	Pink	WN	OU	Pink	Oracle	Anti	Gain
Pendulum	MPO	311	702	574	247	651	558	670	239	430
	SAC	224	350	446	158	283	294	361	158	202
Cartpole (b.)	MPO	999	1000	1000	928	940	967	967	928	39
	SAC	960	908	958	939	890	941	950	890	59
Cartpole (s.)	MPO	703	784	788	535	499	666	666	489	177
	SAC	377	608	730	226	459	532	533	159	374
Ball-In-Cup	MPO	974	973	978	926	909	948	948	909	39
	SAC	976	975	979	930	901	933	941	901	39
MountainCar	MPO	13	56	92	13	52	91	92	13	78
	SAC	0	90	94	0	89	93	93	0	93
Hopper	MPO	25	62	108	14	34	69	69	14	54
	SAC	89	94	119	43	53	77	80	43	36
Walker	MPO	530	377	448	384	284	363	390	284	106
	SAC	593	506	602	437	363	471	472	363	108
Reacher	MPO	956	856	966	864	600	871	888	581	306
	SAC	955	914	940	776	653	745	776	653	122
Cheetah	MPO	666	612	678	481	440	543	543	440	103
	SAC	631	577	640	469	439	483	502	439	63
Door	MPO	2586	2492	2909	1830	1376	2207	2207	1376	830
	SAC	2192	1535	2195	1332	546	1183	1332	546	785

表 H.1: 所有环境中最终策略性能（见 B.2 节）与训练过程平均性能（第 4 节）的比较。结果在多个随机种子间取平均，并分别展示白噪声（WN）、奥恩斯坦-乌伦贝格噪声（OU）和粉红噪声（Pink）作为 MPO 和 SAC 上的动作噪声。此外，还展示了 Oracle 和 Anti-Oracle（“Anti”）的性能。两者之间的增益（最右列）表示通过改变噪声类型可实现的差异，是第 4.2 节中使用的“性能增益”测度的基础。