

端到端自动驾驶中的后训练：统一视角

Ruining Yang^{1*}, Muxing Wang^{1*}, Yixiao Chen¹, Tongfei Guo¹, Yi Xu¹,
Can Cui², Zichong Yang², Yitian Zhang¹, Ziran Wang², Yun Fu¹, and Lili Su¹

¹ Northeastern University, Boston, USA

² Purdue University, West Lafayette, USA

摘要。将多模态输入直接映射到未来轨迹/动作的端到端模型，已成为自动驾驶领域日益突出的研究范式。这类模型既包括视觉-语言-动作模型，也包括轨迹生成式规划器。与经典机器学习应用不同，自动驾驶汽车运行在安全关键且交互密集的环境中，传统的对专家示范进行开环模仿不足以确保可靠性。特别是，微小的执行误差会随时间累积，而训练数据中恢复行为十分稀缺。此外，安全性和驾驶舒适性等长时域目标也无法通过逐点标签来刻画。这些局限性推动了向超越纯模仿、进一步精炼驾驶策略的后训练技术的转变。本综述通过界定后训练的范围，并根据所用监督形式将现有文献归纳为四大类，从而提出自动驾驶后训练的统一视角。针对每一类，我们讨论其能力、局限性和待解决的挑战。我们旨在促进对这一新兴领域的系统性理解，并激发未来在可靠且高效的自动驾驶后训练方面的研究。相关论文合集可在 <https://github.com/RYNing/Awesome-Post-Training-In-Autonomous-Driving-Papers> 获取。

关键词：自动驾驶 · 后训练 · 强化学习 · 蒸馏 · 偏好对齐

1 引言

端到端模型已成为自动驾驶领域日益突出的研究范式，其中单一网络接收多模态输入（如摄像头图像、导航指令和车辆自身状态），并直接输出指导自车动作的未来轨迹 [19, 25, 44]。其日益普及的驱动力在于能够联合

* 同等贡献。邮箱：yang.ruini@northeastern.edu, wang.muxin@northeastern.edu

2 杨睿、王明等




图 1：自动驾驶策略的两阶段训练范式。阶段 1 通过模仿学习建立初始驾驶能力，阶段 2 通过后训练进一步改进策略。

优化感知、预测与规划，减少对手工设计中间接口的依赖，学习更丰富的跨模态表征，并展现出对复杂驾驶场景更强的适应性。具有代表性的端到端驾驶模型已从早期行为克隆方法（将前置摄像头原始像素与高层导航指令（如左转/右转）直接映射为底层控制量 [5, 10]）演进为预测未来轨迹的轨迹生成式规划器 [9, 22, 30, 72, 77, 95]，以及利用先进多模态表征和语言推理来提升场景理解与决策能力的视觉-语言-动作（VLA）模型 [46, 84, 85, 86]。尽管这些方法在架构上存在差异，它们大多依赖模仿学习（即对离线训练数据进行监督学习）来生成粗略动作或轨迹，以模仿专家示范中的驾驶行为。与经典机器学习应用 [79, 82] 不同，自动驾驶汽车运行在安全关键且交互密集的环境中，传统的开环模仿不足以确保可靠的驾驶行为。在闭环执行中，模型的行动会影响未来观测，即使微小误差也可能随时间累积；例如，如图 1 所示，轻微的居中偏差可能逐渐累积，最终使车辆驶出可行驶区域。此外，驾驶质量的许多重要方面难以通过逐点模仿损失充分刻画：两条轨迹相对于专家示范可能具有相似的位移误差，但其中一条可能包含不必要的急刹车和急加速，而另一条则平稳流畅。这些局限性凸显了超越离线示范的监督需求，本文将其称为后训练。近年来，针对驾驶的特定反馈与评估进展使后训练在自动驾驶中日益可行。基于规则的驾驶评分 [11]、视觉-语言模型（VLM）评判器 [59]、人类接管日志 [97]、世界模型 [58, 78] 以及闭环 [2, 23] 或伪闭环模拟器 [7] 提供了评估安全性、舒适性、行驶进度、交互性和规则合规性的途径，超越了专家示范。这些发展催生了快速增长但零散的文献，本综述旨在围绕后训练对其进行梳理

细化流程。第 2 节首先定义后训练，并阐明其与初始模仿学习和从零开始学习的区别。第 3 至 6 节随后回顾后训练方法的四大主要家族：蒸馏、基于偏好的对齐、强化学习和测试时细化。第 7 节讨论评估协议与挑战，第 8 节概述未解决的问题和未来方向。现有综述大多涵盖端到端驾驶 [71, 81]、视觉-语言-动作模型 [18, 27]、基础模型 [15] 和闭环训练 [29]，但后训练较少被视为一个独立阶段。本文的贡献有三方面：

- **统一的定义与分类法。**本文将后训练定义为一个独立阶段，将其与初始训练和从零开始学习区分开来，并根据监督形式将文献组织为四个家族：蒸馏、基于偏好的对齐、强化学习和测试时细化。
- **对四种监督家族的结构化综述。**对于每个家族，本文考察监督如何构建、训练数据或轨迹如何收集，以及策略或其输出如何改进。
- **对评估挑战和未解决问题的讨论。**本文总结了评估后训练策略的主要困难，包括基准饱和、粗粒度闭环度量、有限的实车评估和推理成本，并概述了未来方向。

2 后训练：定义与家族

本节定义后训练，并给出其主要方法家族的统一分类法。为便于阐述，本文使用模仿学习来泛指在离线演示上的初始监督训练，同时认识到实际训练流程可能包含额外组件 [9, 19, 25]。随后，本文将后训练定义为使用超出此初始训练阶段的监督对预训练模型进行的任何后续细化。

模仿学习。给定离线数据集 $\mathcal{D}_{\text{IL}} = \{(o_i, y_i)\}_{i=1}^N \cup \{\mathcal{D}_{\text{IL}}\}_{\text{text}}$ ，其中 o_i 表示驾驶观测， y_i 表示对应的专家目标（例如动作或未来轨迹），初始策略 π_{θ_0} 通过求解以下问题进行监督训练

$$\min_{\theta} \frac{1}{N} \sum_{(o_i, y_i) \in \mathcal{D}_{\text{IL}}} \mathcal{L}_{\text{IL}}(y_i, \pi_{\theta}(o_i)), \quad (1)$$

其中 $\mathcal{L}_{\text{IL}}$ 是衡量模型预测与对应专家目标之间差异的损失。我们将得到的策略 π_{θ_0} 称为模仿学习策略。对于传统模型架构（即没有基础模型骨干的架构）， y_i 通常表示为连续路点或轨迹，策略通过轨迹回归损失 [35, 94] 进行优化。对于包含基础模型骨干的端到端模型， y_i 通常表示为专家动作或轨迹令牌，策略通过令牌级

4 R. Yang, M. Wang 等人

交叉熵损失 [21, 45, 96]。此外，当采用基础模型骨干时，式 (1) 中的目标通常不从零开始优化。相反，预训练模型通过少样本微调或其他参数高效适配技术适应驾驶领域。

后训练。后训练是应用于该模仿学习策略的任何后续细化阶段。它旨在通过减轻误差累积并提升安全性、舒适性以及驾驶质量的其他方面来改善闭环行为。然而，这些目标通常无法归结为适合标准优化工具的通用且完全指定的优化问题。相反，它们往往通过异构的监督形式来传达，例如特权教师策略、偏好比较、奖励信号或测试时反馈。尽管形式多样，一大类后训练方法可以通过一个共同的抽象来理解：

$$\min_{\theta \in B(\theta_0)} \mathbb{E}_{(\tilde{o}, \text{signal}) \sim \mathcal{D}_{\text{PT}}} \left[\mathcal{L}_{\text{PT}}(\pi_{\theta}(\tilde{o}), \text{signal}) \right] + \lambda \Omega(\theta), \quad (2)$$

其中 $B(\theta_0)$ 表示模仿策略 θ_0 周围预先指定的邻域，在该邻域内对策略进行精炼； $\tilde{o}$ 是训练后观测数据（可能与 $\mathcal{D}_{\text{IL}}$ 中的观测数据不同），这些数据经过精心设计或选择，以反映期望的训练后目标（例如驾驶舒适性和安全性）；信号表示监督信号，其具体形式在不同训练后方法中有所不同。通常，——（1）基于蒸馏的训练后方法（第 3 节）利用特权教师策略提供密集的行为指导，例如恢复演示以减轻误差累积。形式上，信号可以采取教师策略 $\pi_{\text{teacher}}(\tilde{o})$ 或教师动作 $\hat{y}(\tilde{o})$ 的形式。——（2）基于偏好的训练后方法（第 4 节）使用候选行为之间的相对比较来指示哪种行为更受偏好。形式上，信号是一个偏好-拒绝对 (y^w, y^l) 。——（3）强化学习（第 5 节）将更丰富的指导编码为对采样行为的标量奖励。形式上，信号是 $r(\tilde{o}, y) \in \mathbb{R}$ 。

训练后损失 $\mathcal{L}_{\text{PT}}$ 同样有所不同（例如，蒸馏使用 KL 散度，偏好使用 DPO 损失，强化学习使用策略梯度或替代损失），但这些差异主要反映优化公式的不同，而非监督来源的不同。通常还涉及一个额外的正则化项 $\lambda \Omega(\theta)$ ，其中 λ 是正则化系数， $\Omega(\theta)$ 是与信号无关的正则化器（例如到参考策略的距离，如 $\text{KL}(\pi_{\theta} \parallel \pi_{\text{ref}})$ ）。

——（4）测试时训练后方法（第 6 节）：与公式 (2) 不同，该系列方法不更新策略参数。相反，固定策略 π_{θ_0} 通过测试时选择或验证进行精炼。形式上，

$$y^* = \operatorname{argmax}_{y \in \mathcal{Y}_{\text{cand}}(o)} v(o, y), \quad (3)$$




图 2：自动驾驶主要训练后方法系列概览。

其中 o 为驾驶观测， $\mathcal{Y}_{\text{cand}}(o)$ 是从固定策略中采样的一组候选输出， $\pi_{\theta_0}, v(o, y)$ 是评估候选 y 质量的验证器得分， y^* 是测试时细化后选择的最终输出。

3 蒸馏

蒸馏利用来自更强教师模型的密集目标来细化 π_{θ_0} ，例如专家规划器、更大的视觉语言模型或策略自身的缓慢更新副本。形式上，蒸馏通过使用教师提供的信号作为训练后监督来实例化式 (2)。令 $\mathcal{D}_{\text{dis}}$ 表示用于蒸馏的训练后观测，令 $s_T(\tilde{o})$ 表示观测 $\tilde{o}$ 的教师信号，例如策略分布 $\pi_{\text{teacher}}(\cdot | \tilde{o})$ 或教师目标 $\hat{y}(\tilde{o})$ 。然后通过以下方式优化学生模型：

$$\min_{\theta \in \mathcal{B}(\theta_0)} \mathbb{E}_{\tilde{o} \sim \mathcal{D}_{\text{dis}}} [\ell_{\text{dis}}(\pi_{\theta}(\tilde{o}), s_T(\tilde{o}))] + \lambda \Omega(\theta), \quad (4)$$

其中 ℓ_{dis} 衡量学生输出与教师信号之间的不匹配程度， $\Omega(\theta)$ 可选地将策略正则化到稳定参考。例如， ℓ_{dis} 可以是用于分布匹配的 KL 散度，或用于逐点教师标签的回归/交叉熵损失。CRAFT [8] 使用策略自身作为教师：它通过向指数移动平均副本的 Kullback – Leibler (KL) 项正则化更新，在奖励驱动的细化过程中使策略保持接近稳定参考；本文关注这一蒸馏组件，而其反事实奖励设计将在第 5.1 节讨论。PaIR-Drive [34] 使用专家演示作为教师信号，并行模仿分支与强化学习分支同时运行。RAPID [68] 从强化学习教师中蒸馏，并将其与在线策略自适应相结合。此外，更大的模型可以作为教师。VLM-AD [75] 通过辅助头将视觉语言模型生成的推理和动作标注蒸馏到端到端策略中。CoPhy [69] 将语言对齐模型的推理蒸馏到

行动策略。Found-RL[51] 将基础模型蒸馏与强化学习相结合，将高层驾驶知识迁移到快速策略中。数据问题在于如何构建获得教师标签的后训练观测 $\tilde{o}$ 。对于闭环驾驶，当 $\tilde{o}$ 对应于学生在推演过程中访问的状态，而不仅仅是来自固定专家数据集的状态时，教师目标最为有用。这直接解决了闭环执行中的分布偏移和累积误差问题。这一思想可追溯到 DAgger 式模仿：学生行动，教师为访问的状态打标签，学生在自己的状态分布上重新训练。CRAFT 和 PaIR-Drive 遵循这一模式，将教师信号应用于策略自身的推演，而非固定的专家数据集。在大多数系统中，教师信号本身并不更新策略。相反，它约束并稳定奖励驱动的强化学习更新，例如通过添加 KL 项使策略保持接近教师，或让教师生成并标注推演。与基于奖励的排序相比，这种更密集的监督使模型能够在接近闭环分布的状态上学习，而无需复杂的奖励设计，同时教师作为稳定参考，防止策略漂移并丧失在监督微调 (SFT) 中获得的能力。

4 基于偏好的对齐

基于偏好的对齐通过行为之间的相对比较来监督策略，这在实践中更容易获得。在自动驾驶中，许多场景的关键问题不是轨迹是否可行，而是在多个可行选择中哪一个更合适。这一家族与 RLHF 密切相关，但通常避免训练显式奖励模型。相反，策略直接从偏好对中优化。形式上，基于偏好的对齐通过使用相对比较作为后训练监督来实例化式 (2)。令 $\mathcal{D}_{\text{pref}} = \{(\tilde{o}_i, y_i^w, y_i^l)\}_{i=1}^M$ 表示偏好数据集，其中在观测 $\tilde{o}_i$ 下， y_i^w 优于 y_i^l 。通用偏好目标为

$$\min_{\theta \in \mathcal{B}(\theta_0)} \mathbb{E}_{(\tilde{o}, y^w, y^l) \sim \mathcal{D}_{\text{pref}}} [\ell_{\text{pref}}(\pi_{\theta}; \tilde{o}, y^w, y^l)] + \lambda \Omega(\theta), \quad (5)$$

其中 ℓ_{pref} 在被拒绝行为 y^l 被赋予高于偏好行为 y^w ， $\Omega(\theta)$ 的偏好分数时对策略进行惩罚，可选地将策略正则化至参考策略， $\lambda \geq 0$ 控制该正则化的强度。DPO[52] 是代表性方法：它利用偏好样本与被拒绝样本之间的相对排序来更新策略。遵循 DPO， ℓ_{pref} 可实例化为

$$-\log \sigma \left(\beta \left[\log \frac{\pi_{\theta}(y^w | \tilde{o})}{\pi_{\text{ref}}(y^w | \tilde{o})} - \log \frac{\pi_{\theta}(y^l | \tilde{o})}{\pi_{\text{ref}}(y^l | \tilde{o})} \right] \right),$$

其中 $\sigma(\cdot)$ 为 Sigmoid 函数， π_{ref} 通常为模仿学习或 SFT 策略， β 控制偏好更新的强度。基于该思想的驾驶方法主要区别在于如何构建偏好对以及如何将损失适配至驾驶特定目标。在此类方法中，偏好对既是监督信号也是数据，因此其构建是核心设计选择。DriveDPO[56] 提出安全 DPO，将模仿相似性与基于规则的安全分数相结合。通过这种方式，模型学习接近人类驾驶的轨迹，同时避免看似拟人但实际不安全的行为。VL-DPO[76] 利用视觉语言模型从驾驶回放中自动生成偏好对，减少了对人工标注的需求。CSN[33] 将 Plackett – Luce DPO 与负对数似然正则化相结合，使视觉语言动作策略能够从多个候选轨迹的排序中学习类人驾驶偏好。CPO++[80] 在偏好优化过程中向推理与感知注入反事实扰动，从而降低虚假相关性产生错误偏好的可能性。其他方法从更专门的监督来源构建偏好对。TakeAD[37] 利用专家接管与脱离事件构建偏好对，以进一步优化模仿策略，实现更好的闭环行为。Drive My Way[65] 将视觉语言动作策略与个人驾驶习惯及自然语言意图对齐，实现个性化驾驶。偏好对齐的有效性关键取决于所选轨迹对的信息量及其比较在多大程度上反映真实世界的人类偏好。若被比较的轨迹未能揭示有意义的行为权衡（就舒适性或安全性等目标而言），则精炼策略的改进可能有限或适中。

5 强化学习后训练

基于强化学习的驾驶后训练受到更广泛的大语言模型（Large Language Model, LLM）后训练文献的启发，包括基于奖励模型的基于人类反馈的强化学习（RLHF）[49]、直接偏好优化（DPO）[52]，以及群体相对方法，如群体相对策略优化（Group Relative Policy Optimization, GRPO）[12, 57]。然而，驾驶并非这些目标的直接迁移。驾驶质量本质上是多维的、长时程的，并且高度依赖上下文，反映了碰撞避免、可行驶区域合规性、乘客舒适度和驾驶进度之间的复杂权衡。在基于强化学习的后训练中，监督由分配给采样驾驶行为的奖励提供。这些奖励可能来自基于规则的度量、学习到的批评者、世界模型、反事实比较或推理一致性检查。形式上，令 τ 表示一个采样的驾驶行为，例如轨迹、动作序列或推理-动作输出，并令 $R(\tau)$ 表示分配给它的标量奖励或回报。一个通用的正则化强化学习目标可以写为

$$\min_{\theta \in \mathcal{B}(\theta_0)} -\mathbb{E}_{\tau \sim p_{\pi_\theta}(\tau)} [R(\tau)] + \lambda \Omega(\theta), \quad (6)$$




图 3：自动驾驶后训练的强化学习设计空间概览。

其中 $p_{\pi_\theta}(\tau)$ 表示由当前策略 π_θ , $\Omega(\theta)$ 诱导的采样或推演分布, 可选地将更新后的策略正则化到参考策略, $\lambda \geq 0$ 控制该正则化的强度。当奖励定义在多个时间步上时, $R(\tau)$ 可以聚合逐步奖励, 例如, $R(\tau) = \sum_t \gamma^t r_t$, 其中 r_t 是第 t 步的奖励, γ 是折扣因子。它们的有效性取决于用于训练的推演, 因此推演生成、探索、数据多样性和失败场景构建是强化学习后训练的核心。最终的设计选择是如何将这些推演上的奖励转化为策略更新, 这取决于策略输出空间, 例如令牌序列、连续轨迹、扩散输出或混合推理-动作策略。在操作上, 强化学习后训练在预训练或驾驶特定的监督微调 (SFT) 之后细化一个有能力的基础策略, 有时随后进行测试时扩展。我们围绕该阶段内的主要设计选择来组织本节: 第 5.1 节回顾如何将奖励构建为监督信号; 第 5.2 节讨论如何通过探索、数据多样性和负面/恢复案例构建来收集信息丰富的训练数据和推演; 第 5.3 节回顾优化算法如何在不同策略空间中将奖励和推演转化为策略更新。

5.1 奖励设计作为监督构建

在基于强化学习的后训练中, 奖励作为监督信号, 指示哪些采样行为应被强化。与逐点轨迹标签不同, 驾驶奖励必须同时捕捉多种质量, 包括安全性、进展、舒适性、规则遵守和交互。因此, 本小节按奖励信号的构建方式进行组织。

基于规则和度量衍生的奖励。基于规则的奖励将可观测的 rollout 属性 (如碰撞、偏离道路、碰撞时间 (TTC)、进展和平滑性) 转换为标量信号。它们计算成本低、易于复现, 并在标准基准上广泛使用。一种常见形式是直接使用基准分数, 例如 NAVSIM 预测驾驶

模型分数 (PDMS) [11] 及其扩展 PDMS (EPDMS) [7], 将碰撞避免、可行驶区域合规性、TTC、舒适性和进展组合为单一奖励。另一种形式是手工设计加权组件, 如 AutoDrive-R² [85] 中的空间、动态和时间奖励, FeaXDrive [63] 中的曲率可行性, 以及 PanoEnv [36] 中的几何感知 3D 空间理解。这些奖励是可解释的, 但固定规则往往忽略交互语义, 例如变道是否自然或让行时机是否恰当。因此, 它们通常与学习到的奖励或引导信号结合使用; 例如, SARAD [67] 将碰撞预测奖励与 LLM 引导配对。

学习到的奖励模型。学习得到的奖励模型为难以写成固定规则的品质提供监督。它们使用学习到的批评者、视觉语言模型评估器、偏好模型、验证器或不确定性信号来对候选行为进行评分。在视觉语言动作系统中, 视觉语言模型批评者尤为自然: DriveMind [66] 使用视觉语言模型进行语义锚定, CoPhy [69] 添加了一个语言对齐的评分器, DriveCritic [59] 从成对的人类偏好中训练视觉语言模型评估器, VDRive [17] 在演员-评论家框架中使用学习到的批评者。此类别还包括基于奖励模型的来自人类反馈的强化学习, 其中反馈首先用于训练显式奖励模型, 然后再进行策略优化。Sun 等人 [60] 使用物理和生理反馈与近端策略优化, 而 Zhuang 等人 [98] 使用脑电图衍生信号。学习到的奖励也可以作为验证器或不确定性信号出现: LaViPlan [48] 将可验证奖励的强化学习适配到分级轨迹评估, ExploreVLA [58] 奖励世界模型的不确定性, IRL-VLA [24] 从基于 EPDMS 的度量标签中学习轻量级奖励世界模型, 然后将其用于基于近端策略优化的视觉语言动作微调。

世界模型耦合奖励。世界模型耦合奖励使用预测的未来状态来评估动作, 因为变道、让行或制动决策的质量取决于场景如何演变。CoPhy [69] 从鸟瞰图推演和认知评分器中推导出物理奖励, DreamerAD [78] 在潜空间中计算密集奖励, FLARE [70] 使用未来感知的视觉语言模型潜变量对轨迹进行评分, OmniDreams [2] 和 MAPLE [83] 等生成模型评估自车行为、生成未来和其他智能体之间的交互。在这些方法中, 世界模型通过从预测的未来中提取行为相关信号与未来感知表示, 与奖励计算耦合。

反事实与对比奖励。反事实与对比奖励将轨迹与附近的替代方案进行比较, 在失败罕见或小的动作变化导致不同结果时提供更密集的监督。CRAFT [8] 使用反事实优势作为稀疏闭环优势的密集代理, 将信号分解为代理项和由交互关键事件校正的接地残差。相关构造也出现在 SafeAlign-VLA 的安全对 (第 5.2 节) 和 CPO++ 的反事实扰动 (第 4 节) 中。

推理质量与一致性奖励。对于视觉语言动作策略, 奖励不仅可以监督最终轨迹, 还可以监督其背后的推理过程

10 R. Yang, M. Wang 等

它。Alpamayo-R1 [46] 惩罚与执行动作不匹配的解释，因为动作正确但推理不一致可能只是偶然有效。Drive-R1 [32] 使用一种 GRPO 奖励，该奖励结合了轨迹准确率、元动作正确性、重复惩罚和格式合规性。OmniDrive-R1 [89] 进一步针对视觉定位，采用基于 CLIP 的感兴趣区域（Region-of-Interest, ROI）定位奖励。其他工作沿推理链分配奖励：AutoDrive-P³ [84] 分别奖励感知、预测和规划，ELF-VLA [41] 使用故障诊断反馈，AutoDrive-R₂ [85]、ThinkDrive [90] 和 MindDriver [88] 将思维链（Chain-of-Thought, CoT）推理与强化学习优化相结合。另一条研究路线学习何时调用思维链，如 AdaThinkDrive [42] 和 AutoVLA [96]。相比之下，NoRD [53] 表明 Dr. GRPO 也可以应用于无需显式推理的视觉语言动作驾驶。

5.2 轨迹收集与信息性数据

信息性轨迹组。强化学习后训练不仅取决于奖励，还取决于用于训练的轨迹展开。在组相对方法（如分组相对策略优化）中，学习来自采样组内的奖励差异。如果所有候选方案获得相似的奖励，优势会变得很小，更新提供的信号微弱。这在驾驶场景中尤为常见。监督微调策略倾向于接近演示，因此重排序无法恢复从未被采样到的轨迹 [40]。同时，常规场景往往导致奖励饱和，使得长尾、交互密集和安全关键案例更具信息量。因此，有用的轨迹展开组需要具备两个特性。首先，策略必须能够采样不同的操作，因为强化学习无法改进从未出现的行为。DIAL[40] 通过无分类器引导将流头条件化于意图标签，DriveAnchor[77] 使用轨迹锚点词汇表，Reflect-Drive[31] 使用离散动作码本。这些方法在输出空间中构建多样性，而不是仅依赖随机采样。其次，采样到的候选方案必须在质量上有所差异。PaIR-Drive[34] 在操作上使用树结构采样器，而 SCORP[1] 利用组内奖励方差来门控更新。最佳 N 也提供了一个有用的诊断：如果性能随着 N 的增加而迅速饱和，那么局限性很可能在于采样分布而非重排序器 [40]。

负样本与恢复数据构建。获取信息丰富训练数据的另一种方法是关注负样本和恢复案例。此类案例在专家日志中罕见，且难以通过朴素探索到达，但它们通过暴露策略无法处理的情况提供了强大的学习信号。SafeAlign-VLA[62] 从风险场景中构建正负样本对，用于基于锚点的分组相对策略优化。SpanVLA[97] 添加负样本和恢复样本，使模型既学会避免不安全行为，也学会纠正错误。TakeVLA[16] 通过场景梦强化微调挖掘人类接管数据。Counterfactual-VLA[50] 使用轨迹展开-过滤-标注流水线来挖掘高价值轨迹展开场景，并为动作纠正标注反事实推理迹。

ELF-VLA[41] 将全零长尾奖励转化为针对规划、推理和执行的故障诊断反馈。

世界模型轨迹展开。世界模型（World Model）能够评估在不同动作下想象的后续发展，而不仅仅是日志中记录的未来。ExploreVLA [58] 利用世界模型的不确定性来鼓励探索不确定状态。MAPLE [83] 运行多智能体潜在推演，以生成数据中缺失的交互案例。CoPhy [69] 和 OmniDreams [2] 也使用预测的未来来支持奖励计算和推演生成。当生成的未来保留了训练所需的关键驾驶结果时，这些方法最为有效，例如其他智能体是否做出反应、自车是否有碰撞风险，以及交互是否成功或失败。

5.3 策略优化算法

在将奖励分配给推演之后，优化算法将其转化为策略更新。这一选择取决于信用分配单元和策略输出空间，例如令牌序列、连续轨迹、基于流的生成器、扩散策略或演员-评论家架构。

针对令牌序列策略的组相对优化。许多驾驶后训练方法将策略输出表述为自回归令牌序列，包括动作令牌、轨迹令牌、思维链（CoT）理由和输出格式。GRPO 风格的目标函数适用于此设置，通过为同一查询采样多个补全，为每个补全分配任务特定的奖励，并在没有独立价值网络的情况下计算组归一化优势。相同的优化模板支持面向规划质量的奖励，如 AlphaDrive [26] 所示，以及令牌化动作或轨迹策略，如 AutoVLA [96] 和 NoRD [53] 所示。它还支持面向推理的奖励，涉及思维链一致性、过程结构或视觉定位，如 AutoDrive-P [84]、Drive-R1 [32] 和 OmniDrive-R1 [89] 所示。

组感知的组相对策略优化（GRPO）变体。由于组相对优势取决于比较哪些候选，若干方法修改组构建或组统计量的使用，而非仅改变奖励。DIAL [40] 使用多意图 GRPO 构建意图平衡的候选组，张成所有预定义意图类别；SCORP [1] 使用方差门控 GRPO，根据组内奖励方差门控采样组或改变归一化，以减少优势坍缩和梯度不稳定；SafeAlign-VLA [62] 在正负风险场景候选上使用基于锚点的 GRPO，使比较集明确以安全为中心；DriveAgent-R1 [93] 通过模式划分 GRPO 进一步将这一思想适配到混合推理策略，强制纯文本和工具增强响应进入同一归一化组，使更新在推理模式内部和跨模式之间进行比较。超越自回归解码的序列级组相对优化

解码。Flow-GRPO [38] 将组相对策略优化适配到流匹配生成器，其中轨迹样本通过去噪过程而非从左到右的令牌解码产生。WAM-Diff [73] 使用组

序列策略优化 (GSPO) 框架, 该框架使用掩码扩散策略来细化未来轨迹的完整序列。

基于价值和基于奖励模型的策略梯度。并非所有强化学习后训练方法都使用组相对目标。当学习到的奖励模型或评论家可用时, PPO 或演员-评论家更新变得自然。IRL-VLA [24] 学习 RWM, 然后使用 PPO 在学习到的奖励反馈下微调 VLA 策略。VDRive [17] 在演员-评论家框架中训练其扩散策略头, 使用学习到的评论家指导策略优化。

6 测试时细化

测试时优化是指在推理过程中改进模型输出, 而不更新模型参数。它不重新训练策略; 相反, 策略 π_{θ_0} 保持固定, 并对其生成的输出进行优化。根据公式 (3), 给定观测 o , 可以从固定策略中采样候选集 $\mathcal{Y}_{\text{cand}}(o) = \{y_i\}_{i=1}^K$, 其中

$y_i \sim \pi_{\theta_0}(\cdot | o)$, 并由验证器或重排序器 $v(o, y)$ 选择最终输出 y^* 。最

常见的方法是先生成多个候选轨迹, 然后使用评分模型选择最佳轨迹。DriveCritic[59] 中的人类对齐评估器可以在推理过程中用作重排序器。然而, 只有当采样候选已经包含良好轨迹时, Best-of- N 才有用; 如果基础策略只产生低质量候选, 重排序器只能在较差选项中做出选择, 性能会迅速饱和 [40]。因此, 测试时优化更适合被理解为其其他后训练方法的补充: 它可以帮助强策略选择更好的输出, 但无法真正学习策略从未生成过的行为。另一类方法是自我反思, 模型首先生成初始决策, 然后检查其中是否包含不安全或不合理部分, 并尝试进行修正。ReflectDrive[31] 使用离散动作码本表示驾驶行为, 并通过搜索和替换不安全动作标记来改进输出。AutoDrive-R² [85] 将自我反思纳入其推理策略。C-CoT[61] 进一步在推理时引入反事实思维链推理。这使得视觉语言模型能够在高风险场景中考虑不同选择的可能结果, 然后再做出最终决策。Seong 等人 [55] 将交互行为模型的强化学习后训练与测试时扩展相结合。他们的结果表明, 测试时优化可以补充参数更新方法, 而不是取代它们。

车载效率约束。与语言模型中的测试时扩展相比, 自动驾驶中的测试时优化探索较少。一个重要原因是车载延迟约束严格, 因此推理无法承受任意额外计算。因此, 如何在有限的计算预算下进行更有效的候选生成、搜索和重排序是该方向的关键问题。Fast-dDrive[87] 中的块扩散解码是沿此方向的一种效率导向设计。

表 1：nuScenes 和 WOD-E2E 上的开环结果。L2/ADE：位移误差；Col.：碰撞率；RFS：人类评分员反馈分数。

Method	nuScenes		Waymo E2E (WOD-E2E)			Backbone
	L2 ↓	Col. ↓	RFS ↑	ADE 5s ↓	ADE 3s ↓	
AutoDrive-R2 [85]	0.19	0.07	—	—	—	Qwen2.5-VL-7B
Reasoning-VLA [86]	0.23	0.08	—	—	—	Qwen2.5-VL-7B
VDRive [17]	0.29	0.18	—	—	—	InternVL3-8B
VLA-World [64]	0.30	0.10	—	—	—	Qwen2-VL-2B
Drive-R1 [32]	0.31	0.09	—	—	—	InternVL2-4B
LLaViDA [39]	0.31	0.10	—	—	—	LLaVA-NeXT-8B
Fast-dDrive [87]	0.32	—	7.823	2.907	1.254	Qwen2.5-VL-3B
AutoDrive-P3 [84]	0.33	0.06	—	—	—	Qwen2.5-VL-3B
MindDriver [88]	0.33	0.12	—	—	—	Qwen2.5-VL-3B
LaST-VLA [43]	0.38	0.18	—	—	—	InternVL3-8B
AutoVLA [96]	0.40	0.20	7.557	2.958	1.351	Qwen2.5-VL-3B
ExploreVLA [58]	0.44	0.10	—	—	—	Show-o-1.3B
Poutine [54]	—	—	7.990	2.740	1.210	Qwen2.5-VL-3B
NoRD [53]	—	—	7.709	2.893	1.250	Qwen2.5-VL-3B

7 评估协议

7.1 开环评估

自动驾驶后训练的评估协议范围从记录数据上的开环测试到完全闭环仿真。在开环评估中，模型在固定场景上进行测试，其动作不会影响未来状态。常见基准包括 nuScenes [6] 和用于端到端驾驶的 Waymo 开放数据集（WOD-E2E）[74]。典型度量包括平均和最终位移误差（ADE/FDE）、碰撞率以及 WOD-E2E 中的评分员反馈分数（RFS）。开环评估成本低、可复现，并且有助于衡量模型对记录轨迹或人类偏好标注的拟合程度。表 1 总结了后训练策略在 nuScenes 和 WOD-E2E 上报告的开环结果。然而，开环评估无法捕捉策略动作如何改变未来状态。因此，它无法衡量累积误差、多智能体交互或恢复能力。这对于旨在改善闭环行为的后训练尤其具有局限性。因此，开环分数应被视为辅助指标，而非驾驶质量的最终证据。Zhao 等人 [92] 进一步表明，开环到闭环的差距源于观测域偏移和目标不匹配，并且标准开环协议可能掩盖闭环失败。

7.2 伪闭环与闭环评估

闭环评估与后训练最为一致，因为策略的动作会影响未来状态。在实践中，常见基准在闭环程度上有所不同。NAVSIM v1 [11] 是一种一次性、非反应式仿真：策略根据记录的观测进行一次规划，然后该规划被展开几秒钟。由于策略不接收反馈且场景不做出反应，它最好被视为

14 R. Yang, M. Wang 等人

被视为基于仿真度量的开环评估。其 PDMS 分数综合了碰撞、可行驶区域、自车进度、舒适性和 TTC。NAVSIM v2 [7] 通过两阶段伪仿真协议向闭环评估靠拢，其中合成的后续观测取决于第一阶段的行为。其 EPDMS 度量在 PDMS 基础上增加了行驶方向合规性、交通信号灯合规性、车道保持和额外的舒适性项，并且更难的 navhard 划分在该协议下进行评估。Bench2Drive [23] 是完全闭环的。它构建于 CARLA 之上，具有反应式多智能体交通，并报告驾驶分数（DS）和成功率（SR），使其更适合评估长期误差和交互行为。近期工作还将闭环测试扩展到游戏引擎之外。AlpaSim [47] 使用神经渲染进行逼真传感器仿真，从而能够在真实感传感器流上进行闭环测试。此外，nuReasoning [20] 专注于长尾推理场景。其 nuReasoning 规划分数（NPS）遵循 NAVSIM 风格的安全门控分数，并以 5 秒 ADE 报告。表 2 收集了在 NAVSIM 和 Bench2Drive 上报告的结果，按策略是否使用基础模型骨干进行分组。

7.3 当前评估中的主要挑战

闭环评估比开环评估更符合后训练的目标，但当前协议仍存在若干局限性。

基准饱和。NAVSIM 已成为许多近期工作的默认评估平台。如表 2 所示，PDMS 和 EPDMS 分数现在聚集在一个狭窄范围内，使得单一的总分难以区分真正的方法进步与随机波动。尽管 PDMS 已经包含碰撞、可行驶区域合规性、TTC、舒适性和进度等子分数，但许多方法在常规场景中这些分量上的表现相似。因此，微小的分数差异往往难以解释。更具区分度的评估应关注更难的分布，例如长尾、安全关键和交互密集的划分（如 navhard），在这些划分中分量级的差异更可能保持可见。

稀缺且不可比的真实世界评估。实车测试需要车辆平台、安全驾驶员和测试许可，这对大多数学术团队而言难以获得。尽管如此，近期一些工作已开始超越基准评估。例如，Alpamayo-R1 [46] 报告了部署延迟，HDP [95] 报告了真实道路测试，DriveAnchor [77] 和 RAD-2 [14] 报告了实车验证，VLM-AutoDrive [4] 在真实行车记录仪视频上评估了安全关键事件检测。然而，由于车辆平台、传感器、场景和度量标准各不相同，这些结果在不同论文之间仍然难以比较。

推理成本报告不足。如果模型无法满足车载实时约束，训练后增益的实用价值有限，但许多论文仍然省略了推理成本。与实车测试不同，这一指标无需车辆即可测量。延迟、参数量和吞吐量可以在车规级硬件上进行性能分析，如 Alpamayo-R1 的端到端延迟为 99 毫秒，DriveAnchor 的推理时间为 2.06 毫秒，以及 BPF [3]

表 2：训练后驾驶策略的报告结果。NAVSIM: PDMS/EPDMS; Bench2Drive: 驾驶得分（DS）和成功率（SR）。

Method	NAVSIM			Bench2Drive		Backbone
	v1↑	v2↑	navhard↑	DS↑	SR↑	
<i>With Foundation Model</i>						
Reasoning-VLA [86]	91.7	—	—	—	—	Qwen2.5-VL-7B
FLARE [70]	91.4	86.3	—	—	—	Qwen3-VL-4B
LaST-VLA [43]	91.3	87.1	—	—	—	InternVL3-8B
ReflectDrive [31]	91.1	—	—	—	—	LLaDA-V-8B
ELF-VLA [41]	91.0	87.1	—	—	—	InternVL3-8B
AutoDrive-P3 [84]	90.6	89.9	—	—	—	Qwen2.5-VL-3B
ExploreVLA [58]	90.4	88.8	—	—	—	Show-o-1.3B
EponaV2 [72]	90.4	88.9	52.0	—	—	Qwen3-VL-4B
SpanVLA [97]	90.3	86.4	40.1	—	—	Qwen2.5-VL-3B
AdaThinkDrive [42]	90.3	—	—	—	—	InternVL3-8B
FeaXDrive [63]	90.0	—	—	—	—	InternVL3-2B
AutoVLA [96]	89.1	—	—	78.84	57.73	Qwen2.5-VL-3B
AutoDrive-R2 [85]	89.1	—	—	—	—	Qwen2.5-VL-7B
SafeAlign-VLA [62]	89.1	—	—	—	—	Qwen2.5-VL-7B
NoRD [53]	85.6	—	—	—	—	Qwen2.5-VL-3B
TakeVLA [16]	—	—	—	89.72	73.73	Qwen2-0.5B
MAPLE [83]	—	—	—	88.30	70.50	Qwen2.5-VL-1.5B
Drive My Way [65]	—	—	—	82.72	71.56	InternVL2-1B
CoReVLA [13]	—	—	—	72.18	50.00	Qwen2.5-VL-7B
VDRive [17]	—	—	—	66.25	50.51	InternVL3-8B
MindDriver [88]	—	—	—	65.48	39.55	Qwen2.5-VL-3B
<i>Without Foundation Model</i>						
EvaDrive [28]	94.9	86.3	—	64.96	40.45	—
CoPhy [69]	91.4	86.1	—	—	—	—
PaIR-Drive [34]	91.2	87.9	—	—	—	—
DriveDPO [56]	90.0	—	—	62.02	30.62	—
TSA-MPR [91]	89.8	—	—	—	—	—
DreamerAD [78]	88.7	87.7	—	—	—	—
CRAFT [8]	—	—	—	75.79	56.36	—
TakeAD [37]	—	—	—	71.39	40.83	—

通过在强化学习过程中进行剪枝，Jetson AGX Orin 上的解码吞吐量最高提升 27%。这些结果表明，车载效率也应与闭环性能一同报告。

8 开放问题与未来方向

自动驾驶的训练后处理仍处于早期阶段，其最重要的开放问题跨越四个类别，而非仅属于其中任何一个。

奖励与探索作为一个耦合设计问题。大多数基于强化学习的后训练方法结合了多种奖励来源，例如基于规则的评分、学习到的评论家、世界模型推演以及推理一致性项。然而，这些奖励的组合方式往往研究不足：权重通常是手动调整的，门控规则并不总是被报告，并且综合得分可能通过利用一个容易的组件而提高，而不是改善整体驾驶质量。

16 R. Yang, M. Wang 等人

它还可能掩盖安全性、进展、舒适性和规则遵守之间的权衡，因此得分增益应在组件层面进行分析。奖励设计也与探索相关。只有当采样的推演显示出有意义的质量差异时，奖励才能指导学习。如果一组中的所有候选者获得相似的分数，组相对优势就会变小或消失，更新提供的信号很少。因此，目标不是为了多样性而多样性，而是奖励相关的多样性：采样的行为应在奖励能够可靠区分的方面有所不同。共同设计奖励和探索，使奖励反映驾驶质量并且推演组保持信息量，是基于强化学习的后训练的一个核心开放问题。世界模型信号是否与行为相关？世界模型越来越多地被用作奖励提供者（第 5.1 节）和探索引擎（第 5.2 节）。它们对后训练的价值不仅在于视觉真实感，还在于反事实反馈：它们可以估计在记录数据中未采取的行动下会发生什么。这使后训练能够获得静态监督无法提供的结果导向信号。然而，许多世界模型在像素或传感器层面运行，而后训练需要行为层面的信号，例如安全性、进展、交互和规则遵守。因此，对于策略学习，关键要求不仅仅是像素级保真度，而是行为级保真度：模型应保留影响驾驶奖励的因素，例如碰撞、智能体反应、路线进展和交通规则违规。世界模型奖励在与基于规则或学习到的评论家信号结合时可能最有用，其中世界模型提供反事实的未来状态，显式奖励项将优化锚定到驾驶目标。

从一次性细化到数据反馈循环。后训练依赖于初始模型训练完成后可用的数据和反馈信号。在自动驾驶中，最有用的信号往往不是普通的记录轨迹，而是揭示模型弱点的案例：接管、脱离、险情、违规、恢复行为和困难交互。近期工作如 TakeAD [37]、TakeVLA [16] 和 SpanVLA [97] 开始利用此类现场信号或面向恢复的数据来改进后训练。然而，这些信号仍大多离线使用，作为单一后训练阶段的固定数据集。所缺少的是一个更系统的反馈回路：部署或评估的策略应暴露失败，这些失败应转化为可用的监督、偏好、奖励或恢复目标，然后精炼后的策略应在相同类型的困难案例上重新评估。构建此类数据反馈回路可能对于使后训练成为持续改进过程而非一次性精炼步骤至关重要。

超越基于群体相对策略优化（GRPO）的优化。当前大多数基于强化学习的自动驾驶后训练方法使用基于 GRPO 的优化，大体上遵循近期大语言模型对齐中的实践。虽然这是一个有用的起点，但驾驶具有更结构化的学习信号：轨迹由时间、安全、交互和物理可行性塑造。因此，未来的方法可能需要更具驾驶感知的更新。与其为整个 rollout 分配一个标量奖励，

它们可以在关键事件（如变道、让行、制动或近碰撞事件）周围使用更局部的反馈。它们还可以分离安全、进度和舒适性约束，因为一个维度的改进可能掩盖另一个维度的退化。更广泛地说，后训练不必仅依赖强化学习。蒸馏可以提供来自规划器、更强的视觉语言模型或修正后的 rollouts 的密集教师目标，尤其是对于失败和恢复案例。基于偏好的对齐可以在期望行为难以表达为逐点标签时比较替代轨迹。关键问题不是哪个算法家族最好，而是哪种学习信号最匹配每个驾驶问题。

9 结论

本文提出了自动驾驶后训练的统一视角：该阶段在初始策略获得后应用，其目标是闭环行为而非离线拟合。按监督形式组织文献可得到四个家族：蒸馏、基于偏好的对齐、强化学习和测试时细化。在最成熟的家族——强化学习中，核心设计问题是奖励构建和探索，而非优化器，而随着闭环基准趋于饱和，评估正成为瓶颈。我们希望本综述能提供一致的参考，并希望其分类法和开放问题有助于构建未来工作。

参考文献

- [1] Bai, H., Li, A., et al.: Scorp: Scene-consistent multi-agent diffusion planning with stable online reinforcement post-training for cooperative driving. arXiv preprint (2026) [10](#), [11](#)
- [2] Basant, A., Kar, A., et al.: Nvidia omnidreams: Real-time generative world model for closed-loop autonomous vehicle simulation. arXiv preprint (2026) [2](#), [9](#), [11](#)
- [3] Benfenati, L., Azimi, A., et al.: Before parc fermé: RL-time pruning for efficient embodied llms in autonomous driving. arXiv preprint (2026) [14](#)
- [4] Bhat, M.Q., Huang, Y., et al.: Vlm-autodrive: Post-training vision-language models for safety-critical autonomous driving events. arXiv preprint (2026) [14](#)
- [5] Bojarski, M., Del Testa, D., Dworakowski, D., Firner, B., Flepp, B., Goyal, P., Jackel, L.D., Monfort, M., Muller, U., Zhang, J., et al.: End to end learning for self-driving cars. arXiv preprint arXiv:1604.07316 (2016) [2](#)
- [6] Caesar, H., Bankiti, V., Lang, A.H., et al.: nuscenes: A multimodal dataset for autonomous driving. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (2020) [13](#)
- [7] Cao, W., Hallgarten, M., Li, T., et al.: Pseudo-simulation for autonomous driving. Conference on Robot Learning (2025) [2](#), [9](#), [14](#)
- [8] Chen, K., Ye, N., et al.: Craft: Counterfactual-to-interactive reinforcement fine-tuning for driving policies. arXiv preprint (2026) [5](#), [9](#), [15](#)
- [9] Chitta, K., Prakash, A., Jaeger, B., Yu, Z., Renz, K., Geiger, A.: Trans-fuser: Imitation with transformer-based sensor fusion for autonomous driving. IEEE transactions on pattern analysis and machine intelligence **45**(11), 12878–12895 (2022) [2](#), [3](#)
- [10] Codevilla, F., Müller, M., López, A., Koltun, V., Dosovitskiy, A.: End-to-end driving via conditional imitation learning. In: 2018 IEEE international conference on robotics and automation (ICRA). pp. 4693–4700. IEEE (2018) [2](#)
- [11] Dauner, D., Hallgarten, M., Li, T., et al.: Navsim: Data-driven non-reactive autonomous vehicle simulation and benchmarking. Advances in Neural Information Processing Systems (2024) [2](#), [9](#), [13](#)
- [12] DeepSeek-AI: Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning. arXiv preprint (2025) [7](#)
- [13] Fang, S., Cui, Y., Liang, H., Lv, C., Hang, P., Sun, J.: Corevla: A dual-stage end-to-end autonomous driving framework for long-tail scenarios via collect-and-refine. arXiv preprint (2025) [15](#)
- [14] Gao, H., Chen, S., et al.: Rad-2: Scaling reinforcement learning in a generator-discriminator framework. arXiv preprint (2026) [14](#)
- [15] Gao, H., Wang, Z., Li, Y., Long, K., Yang, M., Shen, Y.: A survey for foundation models in autonomous driving. In: 2025 6th International Conference

- on Computer Vision and Data Mining (ICCVDM). pp. 63–71. IEEE (2025) [3](#)
- [16] Gao, Y., Liu, D., et al.: Learning from mistakes: Post-training for driving vla with takeover data. arXiv preprint (2026) [10](#), [15](#), [16](#)
 - [17] Guo, Z., Zhang, Z., et al.: Vdrive: Leveraging reinforced vla and diffusion policy for end-to-end autonomous driving. arXiv preprint (2025) [9](#), [12](#), [13](#), [15](#)
 - [18] Hu, T., Liu, X., Wang, S., Zhu, Y., Liang, A., Kong, L., Zhao, G., Gong, Z., Cen, J., Huang, Z., et al.: Vision-language-action models for autonomous driving: Past, present, and future. arXiv preprint arXiv:2512.16760 (2025) [3](#)
 - [19] Hu, Y., Yang, J., Chen, L., Li, K., Sima, C., Zhu, X., Chai, S., Du, S., Lin, T., Wang, W., et al.: Planning-oriented autonomous driving. In: Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. pp. 17853–17862 (2023) [1](#), [3](#)
 - [20] Huang, Z., Liu, J., Song, R., Zhou, Z., Yang, R., et al.: nureasoning: A reasoning-centric dataset and benchmark for long-tail autonomous driving. arXiv preprint arXiv:2605.31572 (2026) [14](#)
 - [21] Hwang, J.J., Xu, R., Lin, H., Hung, W.C., Ji, J., Choi, K., Huang, D., He, T., Covington, P., Sapp, B., et al.: Emma: End-to-end multimodal model for autonomous driving. arXiv preprint arXiv:2410.23262 (2024) [4](#)
 - [22] Jia, X., Wu, P., Chen, L., Xie, J., He, C., Yan, J., Li, H.: Think twice before driving: Towards scalable decoders for end-to-end autonomous driving. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. pp. 21983–21994 (2023) [2](#)
 - [23] Jia, X., Yang, Z., Li, Q., et al.: Bench2drive: Towards multi-ability benchmarking of closed-loop end-to-end autonomous driving. Advances in Neural Information Processing Systems (2024) [2](#), [14](#)
 - [24] Jiang, A., Gao, Y., Wang, Y., Sun, Z., Wang, S., Heng, Y., Sun, H., Tang, S., Zhu, L., Chai, J., et al.: Irl-vla: Training an vision-language-action policy via reward world model. arXiv preprint arXiv:2508.06571 (2025) [9](#), [12](#)
 - [25] Jiang, B., Chen, S., Xu, Q., Liao, B., Chen, J., Zhou, H., Zhang, Q., Liu, W., Huang, C., Wang, X.: Vad: Vectorized scene representation for efficient autonomous driving. In: Proceedings of the IEEE/CVF International Conference on Computer Vision. pp. 8340–8350 (2023) [1](#), [3](#)
 - [26] Jiang, B., Chen, S., et al.: Alphadrive: Unleashing the power of vlms in autonomous driving via reinforcement learning and reasoning. arXiv preprint (2025) [11](#)
 - [27] Jiang, S., Huang, Z., Qian, K., Luo, Z., Zhu, T., Zhong, Y., Tang, Y., Kong, M., Wang, Y., Jiao, S., et al.: A survey on vision-language-action models for autonomous driving. In: Proceedings of the IEEE/CVF International Conference on Computer Vision. pp. 4524–4536 (2025) [3](#)
 - [28] Jiao, S., Qian, K., Ye, H., Zhong, Y., Luo, Z., et al.: Evadrive: Evolutionary adversarial policy optimization for end-to-end autonomous driving. arXiv preprint (2025) [15](#)

- [29] Karkus, P., Igl, M., Chen, Y., Chitta, K., Packer, J., Douillard, B., Tian, R., Naumann, A., Garcia-Cobo, G., Tan, S., et al.: Beyond behavior cloning in autonomous driving: a survey of closed-loop training techniques. *Authorea Preprints* (2025) [3](#)
- [30] Li, H., Li, T., Yang, J., Shang, M., Wu, G., Wang, C., Tian, H., Lin, Z., Hao, Z., Lang, X., et al.: Plannerrft: Reinforcing diffusion planners through closed-loop and sample-efficient fine-tuning pp. 24929–24938 (2026) [2](#)
- [31] Li, P., Zheng, Y., et al.: Discrete diffusion for reflective vision-language-action models in autonomous driving. *arXiv preprint* (2025) [10](#), [12](#), [15](#)
- [32] Li, Y., Tian, M., Zhu, D., Zhu, J., Lin, Z., Xiong, Z., Zhao, X.: Drive-r1: Bridging reasoning and planning in vlms for autonomous driving with reinforcement learning. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. vol. 40, pp. 6708–6716 (2026) [10](#), [11](#), [13](#)
- [33] Li, Y., Zhang, Y., et al.: Causal scene narration with runtime safety supervision for vision-language-action driving. *arXiv preprint* (2026) [7](#)
- [34] Lian, Z., Wang, H., Yan, X., Lin, W., Zhang, X., Chen, Y., Hu, J.: Fine-tuning is not enough: A parallel framework for collaborative imitation and reinforcement learning in end-to-end autonomous driving pp. 920–930 (2026) [5](#), [10](#), [15](#)
- [35] Liao, B., Chen, S., Yin, H., Jiang, B., Wang, C., Yan, S., Zhang, X., Li, X., Zhang, Y., Zhang, Q., et al.: Diffusiondrive: Truncated diffusion model for end-to-end autonomous driving. In: *Proceedings of the Computer Vision and Pattern Recognition Conference*. pp. 12037–12047 (2025) [3](#)
- [36] Lin, Z., Zheng, X.: Panoenv: Exploring 3d spatial intelligence in panoramic environments with reinforcement learning pp. 9647–9657 (2026) [9](#)
- [37] Liu, D., Gao, Y., Qian, D., Zhang, Q., Ye, X., Han, J., Zheng, Y., Liu, X., Xia, Z., Ding, D., et al.: Takead: Preference-based post-optimization for end-to-end autonomous driving with expert takeover data. *IEEE Robotics and Automation Letters* **11**(2), 1738–1745 (2025) [7](#), [15](#), [16](#)
- [38] Liu, J., Liu, G., Liang, J., Li, Y., Liu, J., Wang, X., Wan, P., Zhang, D., Ouyang, W.: Flow-grpo: Training flow matching models via online rl. *Advances in neural information processing systems* **38**, 40783–40818 (2026) [11](#)
- [39] Liu, Y., Hallyburton, S., Kim, J., Lin, Y., Li, Y., et al.: Llvida: A large language vision driving assistant for explicit reasoning and enhanced trajectory planning. *arXiv preprint* (2025) [13](#)
- [40] Lu, H., Huang, V.S.J., et al.: Driving intents amplify planning-oriented reinforcement learning. *arXiv preprint* (2026) [10](#), [11](#), [12](#)
- [41] Luo, Y., Li, F., Chen, Q., Xu, S., Liu, J., Song, Z., Yang, Z.x., Wen, F.: Unleashing vla potentials in autonomous driving via explicit learning from failures pp. 24833–24842 (2026) [10](#), [11](#), [15](#)
- [42] Luo, Y., Li, F., Xu, S., Lai, Z., Yang, L., et al.: Adathinkdrive: Adaptive thinking via reinforcement learning for autonomous driving. *arXiv preprint* (2025) [10](#), [15](#)
- [43] Luo, Y., Li, F., et al.: Last-vla: Thinking in latent spatio-temporal space for vision-language-action in autonomous driving. *arXiv preprint* (2026) [13](#), [15](#)

- [44] Ma, Y., Wei, T., Zhong, N., Mei, J., Hu, T., Wen, L., Yang, X., Shi, B., Liu, Y.: Leapvad: A leap in autonomous driving via cognitive perception and dual-process thinking. *IEEE Transactions on Neural Networks and Learning Systems* (2025) [1](#)
- [45] Mao, J., Qian, Y., Ye, J., Zhao, H., Wang, Y.: Gpt-driver: Learning to drive with gpt. *arXiv preprint arXiv:2310.01415* (2023) [4](#)
- [46] NVIDIA: Alpmayo-r1: Bridging reasoning and action prediction for generalizable autonomous driving in the long tail. *arXiv preprint* (2025) [2](#), [10](#), [14](#)
- [47] NVIDIA: Alpasim: A modular, lightweight, and data-driven research simulator for autonomous driving. <https://github.com/NVlabs/alpasim> (2025) [14](#)
- [48] Oh, H., et al.: Laviplan: Language-guided visual path planning with rlvr pp. 863–872 (2025) [9](#)
- [49] Ouyang, L., Wu, J., Jiang, X., et al.: Training language models to follow instructions with human feedback. *Advances in Neural Information Processing Systems* (2022) [7](#)
- [50] Peng, Z., Ding, W., You, Y., Chen, Y., Luo, W., Tian, T., Cao, Y., Sharma, A., Xu, D., Ivanovic, B., et al.: Counterfactual vla: Self-reflective vision-language-action model with adaptive reasoning. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. pp. 4022–4031 (2026) [10](#)
- [51] Qu, Y., Sheng, Z., et al.: Found-rl: Foundation model-enhanced reinforcement learning for autonomous driving. *arXiv preprint* (2026) [6](#)
- [52] Rafailov, R., et al.: Direct preference optimization: Your language model is secretly a reward model. *Advances in Neural Information Processing Systems* (2023) [6](#), [7](#)
- [53] Rawal, I., Gupta, S., Hu, Y., Zhan, W.: Nord: A data-efficient vision-language-action model that drives without reasoning pp. 10965–10975 (2026) [10](#), [11](#), [13](#), [15](#)
- [54] Rowe, L., de Schaetzen, R., Girgis, R., Pal, C., Paull, L.: Poutine: Vision-language-trajectory pre-training and reinforcement learning post-training enable robust end-to-end autonomous driving. *arXiv preprint* (2025) [13](#)
- [55] Seong, H., Lee, J.K., Myeong, H., Shin, Y., Cho, H.M., et al.: Post-training and test-time scaling of generative agent behavior models for interactive autonomous driving. *arXiv preprint* (2025) [12](#)
- [56] Shang, S., Chen, Y., Wang, Y., Li, Y., ZHANG, Z.X.: Drivedpo: Policy learning via safety dpo for end-to-end autonomous driving. *Advances in Neural Information Processing Systems* **38**, 81565–81585 (2026) [7](#), [15](#)
- [57] Shao, Z., Wang, P., Zhu, Q., Xu, R., Song, J., Bi, X., Zhang, H., Zhang, M., Li, Y., Wu, Y., et al.: Deepseekmath: Pushing the limits of mathematical reasoning in open language models. *arXiv preprint arXiv:2402.03300* (2024) [7](#)
- [58] Sheng, Z., Ye, X., et al.: Explorevla: Dense world modeling and exploration for end-to-end autonomous driving. *arXiv preprint* (2026) [2](#), [9](#), [11](#), [13](#), [15](#)

- [59] Song, J., Li, Z., et al.: Drivecritic: Towards context-aware, human-aligned evaluation for autonomous driving with vision-language models. arXiv preprint (2025) [2](#), [9](#), [12](#)
- [60] Sun, Y., Salami Pargoo, N., Jin, P., Ortiz, J.: Optimizing autonomous driving for safety: A human-centric approach with llm-enhanced rlhf pp. 76–80 (2024) [9](#)
- [61] Tian, K., Lian, Y., Yang, K., Chen, X., Li, S.: C-cot: Counterfactual chain-of-thought with vision-language models for safe autonomous driving. arXiv preprint (2026) [12](#)
- [62] Tian, K., Lian, Y., et al.: Safealign-vla: A negative-enhanced safe alignment framework for risk-aware autonomous driving. arXiv preprint (2026) [10](#), [11](#), [15](#)
- [63] Wang, B., Li, Z., et al.: Feaxdrive: Feasibility-aware trajectory-centric diffusion planning for end-to-end autonomous driving. arXiv preprint (2026) [9](#), [15](#)
- [64] Wang, G., Tang, P., Ren, X., Zhao, G., Feng, B., Ma, C.: Learning vision-language-action world models for autonomous driving pp. 1073–1084 (2026) [13](#)
- [65] Wang, Z., Jiang, H., Dong, S., Wang, Y., Qiu, H., Li, J.: Drive my way: Preference alignment of vision-language-action model for personalized driving pp. 25204–25214 (2026) [7](#), [15](#)
- [66] Wasif, D., Moore, T.J., et al.: Drivemind: A dual visual language model-based reinforcement learning framework for autonomous driving. arXiv preprint (2025) [9](#)
- [67] Wu, K., Cui, P., et al.: Sarad: Llm-based safety-aware hybrid reinforcement learning with collision prediction for autonomous driving. arXiv preprint (2026) [9](#)
- [68] Wu, S., Liu, J., et al.: Robust rl with llm-driven data synthesis and policy adaptation for autonomous driving. arXiv preprint (2024) [5](#)
- [69] Wu, Y., Meng, Q., et al.: Distill to think, foresee to act: Cognitive-physical reinforcement learning for autonomous driving. arXiv preprint (2026) [5](#), [9](#), [11](#), [15](#)
- [70] Xie, C., Sima, C., et al.: Flare: Learning future-aware latent representations from vision-language models for autonomous driving. arXiv preprint (2026) [9](#), [15](#)
- [71] Xu, C., Cui, Y., Liu, J., Guo, Y., Qin, C., Zhang, G., Dong, X., Fang, S., Hang, P., Sun, J.: A survey on end-to-end autonomous driving training from the perspectives of data, strategy, and platform. IEEE Transactions on Intelligent Transportation Systems (2026) [3](#)
- [72] Xu, J., Zhong, Z., et al.: Eponav2: Driving world model with comprehensive future reasoning. arXiv preprint (2026) [2](#), [15](#)
- [73] Xu, M., Cui, J., Cai, F., Shang, H., Zhu, Z., Luan, S., Xu, Y., Zhang, N., Li, Y., Cai, J., et al.: Wam-diff: A masked diffusion vla framework with moe and online reinforcement learning for autonomous driving. arXiv preprint arXiv:2512.11872 (2025) [11](#)

- [74] Xu, R., Lin, H., Jeon, W., Feng, H., Zou, Y., Sun, L., Gorman, J., Tolstaya, K., Tang, S., White, B., et al.: Wod-e2e: Waymo open dataset for end-to-end driving in challenging long-tail scenarios pp. 3709–3718 (2026) [13](#)
- [75] Xu, Y., Hu, Y., Zhang, Z., Meyer, G.P., Mustikovela, S.K., Srinivasa, S., Wolff, E.M., Huang, X.: Vlm-ad: End-to-end autonomous driving through vision-language model supervision. In: Conference on Robot Learning. pp. 3778–3803 (2025) [5](#)
- [76] Xu, Z., Jerfel, G., et al.: Vl-dpo: Vision-language-guided finetuning for preference-aligned autonomous driving. arXiv preprint (2026) [7](#)
- [77] Yan, L., Tang, H., et al.: Driveanchor: Progressive anchor-based flow learning for autonomous driving planning. arXiv preprint (2026) [2](#), [10](#), [14](#)
- [78] Yang, P., Zheng, Y., et al.: Dreamerad: Efficient reinforcement learning via latent world model for autonomous driving. arXiv preprint (2026) [2](#), [9](#), [15](#)
- [79] Yang, R., Xu, Y., Fu, Y., Su, L.: Den-tp: A density-balanced data curation and evaluation framework for trajectory prediction. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. pp. 10632–10641 (2026) [2](#)
- [80] Yang, X., Yu, E., et al.: Towards robust endogenous reasoning: Unifying drift adaptation in non-stationary tuning. arXiv preprint (2026) [7](#)
- [81] Yang, Y., Han, C., Mao, R., Wang, H., Chen, Z., Yang, Y., Ma, Q., Chen, X., Shi, S., Zhang, Z.: Survey of general end-to-end autonomous driving: A unified perspective. Authorea Preprints (2025) [3](#)
- [82] Yao, Y., Yang, R., Gedeon, T.: Bipartite mode matching for vision training set search from a hierarchical data server. arXiv preprint arXiv:2601.09531 (2026) [2](#)
- [83] Yasarla, R., Hegde, D., et al.: Maple: Latent multi-agent play for end-to-end autonomous driving. arXiv preprint (2026) [9](#), [11](#), [15](#)
- [84] Ye, Y., Zhang, Z., et al.: Autodrive-p³: Unified chain of perception-prediction-planning thought via reinforcement fine-tuning. arXiv preprint (2026) [2](#), [10](#), [11](#), [13](#), [15](#)
- [85] Yuan, Z., Qian, C., et al.: Autodrive-r²: Incentivizing reasoning and self-reflection capacity for vla model in autonomous driving. arXiv preprint (2025) [2](#), [9](#), [10](#), [12](#), [13](#), [15](#)
- [86] Zhang, D., Yuan, Z., et al.: Reasoning-vla: A fast and general vision-language-action reasoning model for autonomous driving. arXiv preprint (2025) [2](#), [13](#), [15](#)
- [87] Zhang, K., Wang, J., Gao, S., Wu, C., Cao, Y., et al.: Fast-ddrive: Efficient block-diffusion vlm for autonomous driving. arXiv preprint (2026) [12](#), [13](#)
- [88] Zhang, L., Yuan, Y., Wu, C., Chang, X., Cai, X., Zeng, S., Shi, L., Wang, S., Zhang, H., Xu, M.: Minddriver: Introducing progressive multimodal reasoning for autonomous driving pp. 17831–17841 (2026) [10](#), [13](#), [15](#)
- [89] Zhang, Z., Zheng, H., Wang, Y., Xu, L., Deng, T., Chen, X., Chen, Q., Zhang, B., Huang, W.: Omnidrive-r1: Reinforcement-driven interleaved multi-modal chain-of-thought for trustworthy vision-language autonomous driving. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. pp. 1106–1116 (2026) [10](#), [11](#)

- [90] Zhao, C., Yang, Z., et al.: Thinkdrive: Chain-of-thought guided progressive reinforcement learning fine-tuning for autonomous driving. arXiv preprint (2026) [10](#)
- [91] Zhao, J., Ban, T., Li, X., Gui, X., Zhou, H., Liu, L., Zhao, H., Li, B.: Autoregressive end-to-end planning with time-invariant spatial alignment and multi-objective policy refinement. arXiv preprint (2025) [15](#)
- [92] Zhao, S.Z., Wang, L., Ruan, H., Bao, Y., Chen, Y., Leng, Z., et al.: Bridgesim: Unveiling the ol-cl gap in end-to-end autonomous driving. arXiv preprint (2026) [13](#)
- [93] Zheng, W., Mao, X., Ye, N., Li, P., Zhan, K., Lang, X., Zhao, H.: Driveagent-r1: Advancing vlm-based autonomous driving with active perception and hybrid thinking. arXiv preprint arXiv:2507.20879 (2025) [11](#)
- [94] Zheng, Y., Liang, R., Zheng, K., Zheng, J., Mao, L., Li, J., Gu, W., Ai, R., Li, S., Zhan, X., et al.: Diffusion-based planning for autonomous driving with flexible guidance. In: International Conference on Learning Representations. vol. 2025, pp. 37207–37227 (2025) [3](#)
- [95] Zheng, Y., Tan, T., et al.: Unleashing the potential of diffusion models for end-to-end autonomous driving. arXiv preprint (2026) [2](#), [14](#)
- [96] Zhou, Z., Cai, T., Zhao, S., Zhang, Y., Huang, Z., Zhou, B., Ma, J.: Autovla: A vision-language-action model for end-to-end autonomous driving with adaptive reasoning and reinforcement fine-tuning. Advances in Neural Information Processing Systems **38**, 27920–27956 (2026) [4](#), [10](#), [11](#), [13](#), [15](#)
- [97] Zhou, Z., Yang, R., et al.: Spanvla: Efficient action bridging and learning from negative-recovery samples for vision-language-action model. arXiv preprint (2026) [2](#), [10](#), [15](#), [16](#)
- [98] Zhuang, Z., Chang, Y.C., Wang, Y.K., Do, T., Lin, C.T.: Neuro-cognitive reward modeling for human-centered autonomous vehicle control pp. 10599–10609 (2026) [9](#)