

# PriGo: 面向自适应机器人操作的 扩散与流策略的测试时基元引导

Zezeng Li<sup>1</sup>, Enda Xiang<sup>2</sup>, Thuy Tran<sup>1</sup>, Di Huang<sup>2</sup>, Momath Thiam<sup>1</sup>, Liming Chen<sup>1</sup>

<sup>1</sup>École Centrale de Lyon, France    <sup>2</sup>Beihang University, China

**摘要:** 模仿学习已在机器人操作领域取得显著进展, 尤其是基于扩散与流的策略能够直接从演示中生成复杂的视觉运动行为。然而, 尽管这些策略性能强劲, 它们往往难以跨任务与环境泛化。一个关键原因在于现有策略倾向于模仿表面的动作相关性, 而非底层意图。受人类行为组合结构的启发, 本文提出 PriGo, 一种基元引导的测试时自适应框架, 用于鲁棒的机器人操作。PriGo 引入 PANet, 一个轻量级基元预测模块, 直接从观测中推断基元分布。本文进一步提出一种可微的基元引导机制, 在推理过程中细化生成的动作, 将轨迹引导至语义一致的行为。与先前基于基元条件的方法不同, PriGo 完全在测试时运行, 无需重新训练即可无缝集成到预训练的扩散与流策略中。在 LIBERO、CALVIN、SIMPLER 及真实世界机器人任务上的大量实验表明, PriGo 在扩散与流策略上均持续提升鲁棒性、长时程执行能力与泛化能力。代码已发布于 PriGo。

## 1 引言

模仿学习 (Imitation Learning) 已成为机器人操作的主导范式, 使策略能够直接从专家演示中习得复杂的视觉运动行为, 而无需人工设计奖励函数。近期基于扩散与流的策略通过建模多模态动作分布并利用大规模视觉语言表征, 进一步提升了动作生成质量。尽管取得这些进展, 现有策略在分布偏移下仍显脆弱, 包括物体、光照、干扰物及未见任务的变化 [1, 2]。

一个关键的局限性在于, 当前策略主要学习观测与低层动作之间的相关性, 而非操作行为背后的结构意图。因此, 生成的动作可能在局部上类似于专家演示, 却无法保持成功完成任务所需的预期运动结构。如图 1.a 所示, 在开门时, 策略在旋转钥匙之前错误地拉动, 或在环境扰动下产生不稳定的抓取动作。此类失败在长时程操作中尤为严重, 因为微小的局部误差会在多个子任务中累积。为了提高鲁棒性和泛化能力, 一个重要的方向是将结构化动作先验融入策略生成。人类操作行为天然呈现组合结构, 复杂任务由少量可复用的运动基元 (如抓取、推动、拉动和旋转) 构成。这些基元并非将动作视为无约束的连续轨迹, 而是提供了一种紧凑的结构先验, 将策略约束在语义一致的行为上。

近期工作 [3, 4] 试图将基元分解为离散类型及其相关参数, 同时捕捉类别抽象和低层动作预测。然而, 它们将基元集限制在基本动作上, 这限制了其在更复杂任务中的适用性。此外,

由八种操作基元组成的基元分类法, 在结构表达能力和跨任务泛化之间取得了平衡。

这些方法将基元视为额外输入，而非强制约束，导致生成的动作不符合所需基元。为此，我们提出了 PriGo，一种用于机器人操作策略的基元引导测试时自适应框架。PriGo 无需重新训练现有策略，而是在推理过程中以即插即用的方式引入结构化基元引导。具体而言，我们首先训练一个轻量级基元分类器 PANet，它直接从视觉观测和语言指令中预测基元分布。我们采用一种紧凑的




图 1: 比较 a) 使用 PriGo 的策略（产生结构化基元动作）与 b) 不使用 PriGo 的普通策略（缺乏结构化基元动作输出）。

随后，我们将可微分的基元引导同时融入扩散策略与流策略。在推理阶段，利用由基元一致性目标导出的梯度对动作进行细化，促使轨迹与预测的操作结构保持一致。与以往主要依赖任务奖励或语言监督的引导式扩散方法不同，PriGo 引入了专为机器人操作设计的结构化动作级引导。本文贡献总结如下：

- 本文提出 PriGo，一种即插即用的基元引导测试时自适应框架，用于机器人操作策略。
- 本文引入一种可微分的基元引导机制，在不重新训练的情况下，约束扩散与流策略生成朝向结构化操作行为。
- 本文设计了一种轻量级基元分类框架，具备稳定的跨任务基元表示和概率性多基元引导。
- 本文进行了全面的实验并提供了深入分析，证明了 PriGo 在仿真和真实机器人任务中的优越性，超越了最先进的方法。

## 2 相关工作

**面向操作的扩散与流策略。**扩散策略（Diffusion Policies, DPs）[5 – 18] 近年来已成为视觉运动策略学习的有效框架，其将动作生成建模为迭代去噪过程。现有方法大致可分为两类。第一类是轻量级扩散策略 [5 – 14]，已从最初的二维扩散策略演进为三维变体，并进一步发展能为更好利用对称性的等变形式。第二类为通用扩散策略 [15 – 20]，将扩散与大规模视觉-语言模型（Vision – Language Model, VLM）相结合，以实现跨多种任务的通用机器人行为。

与基于扩散的方法并行，流匹配（flow matching）也因其稳定的优化和高效的推理而被用于机器人策略学习。现有方法大致可分为两类：（1）轻量级基于流的策略，如 FlowMS [21]、FMP [22] 和 ActionFlow [23]，侧重于稳定的轨迹生成和空间推理；（2）集成视觉语言模型（VLM）的流策略和视觉语言动作（VLA）系统，包括  $\pi_0$  [24]、HiRobot [25]、GraspVLA [26] 和 SmolVLA [27]，它们将流匹配与大规模视觉语言表示相结合，以提高泛化能力、仿真到现实迁移和部署效率。

尽管取得了成功，现有的扩散和流策略在测试时仍对分布偏移敏感。近期一些工作试图通过引导采样或测试时自适应来解决这一问题。MetaDiffuser [28] 采用分类器引导，利用预训练模型引导扩散过程，而 LDuS [29] 利用大语言模型（LLM）使采样偏向于目标一致的动作。最近，ADPro [30] 提出了任务感知初始化，并沿任务流形和球面流形约束更新，从而产生更具泛化能力的策略。然而，这些方法主要关注任务级目标或奖励引导，并未在动作生成过程中显式地强制执行结构化操作行为。




图 2: PriGo 概述, 一个用于机器人操作策略的基元引导框架。给定视觉观测和语言指令, 基元分类器 PANet 预测概率性操作基元。在推理过程中, 预训练扩散或流策略生成的动作被转换为软基元分布, 并通过可微基元引导与预测的基元对齐。由此产生的基于梯度的细化将动作引导至语义一致的轨迹, 而无需重新训练骨干策略。

**基于基元的策略。**基于原语的控制长期以来一直被研究用于提高策略的组合性和泛化能力。早期方法 [31 – 34] 采用组合网络将原语组合成复杂行为, 其中复合策略的动作分布是一组潜在特征原语的加权和。然而, 其表达能力受到高斯原语简单性的限制。其他研究者利用大语言模型将任务指令分解为提示原语, 使用思维链推理来指导策略执行 [35 – 37]。虽然在某些情况下有效, 但它们严重依赖于基于大语言模型分解的可靠性。

最近的一些工作进一步探索了可扩展的网络原语, 通过增量添加的策略模块进行扩展, 通常使用轻量级适配器 (如 LoRA) 实现 [18, 38, 39], 从而支持跨不同任务的持续学习 [40, 41]。然而, 随着库规模的扩大, 这在存储效率和专家分配管理方面带来了挑战。更近期的工作 [3, 4] 试图将原语解耦为具有相关参数的离散类型。然而, 它们通常将原语集限制为少数基本动作, 限制了在更复杂任务中的适用性。

与先前工作不同, 本文关注测试时原语引导, 而非原语条件策略学习。PriGo 无需重新训练策略, 而是在推理过程中引入可微分的原语约束。此外, 本文的公式自然支持概率性多原语引导, 实现操作原语之间的平滑过渡。

### 3 方法

如图 2 所示, PriGo 为机器人操作策略引入了原语引导的测试时自适应。本文框架包含两个组件: 一个原语分类器 PANet, 用于从观测中预测原语分布; 以及一个可微分的原语引导机制, 在推理过程中约束动作生成。PriGo 可以无缝集成到预训练的扩散和流策略中, 无需重新训练。

**问题陈述。**给定一组包含动作-观测对的专家演示, 记作  $\mathcal{D} = \{(\mathbf{O}^k, \mathbf{A}^k)\}_{k=1}^N$ , 本文的目标是拟合一个操作策略, 将观测  $\mathbf{O}$  映射到动作  $\mathbf{A}$ 。其中,  $\mathbf{O}$  由 RGB 图像和语言指令组成, 动作  $\mathbf{a} := (\mathbf{x}, \mathbf{r}, w)$  是一个 7 维位姿, 由平移  $\mathbf{x} = (x, y, z)$ 、旋转  $\mathbf{r} = (\text{横滚}, \text{俯仰}, \text{偏航})$  以及夹爪宽度  $w \in [0, 1]$  定义。为避免歧义, 本文使用  $k$  的上标  $\mathbf{a}^k$  表示帧索引, 而噪声动作  $\mathbf{a}_t$  的下标  $t$  表示去噪过程中的时间步。

#### 3.1 基元表示与分类

PriGo 并非直接约束连续动作, 而是引入一组紧凑的操作基元作为结构化动作先验  $\mathcal{Y} = \{ \text{“空闲”、“抓取”、“释放”、“推动”、“拉动”、“旋转”、“推动+旋转”、“拉动+旋转”} \}$ 。本文采用这种紧凑的基元分类法, 以平衡结构表达能力和跨任务泛化能力。经验表明, 过于细粒度的基元分解会引入长尾不平衡和语义歧义, 而所提出的基元集在不同任务中产生稳定的基元分布。

**定义 3.1.** (基元动作硬分类)。给定阈值  $\tau_{\text{trans}}, \tau_{\text{rot}}, \tau_w > 0$ , 动作  $\mathbf{a}^k \rightarrow y$  的硬分类  $\Phi: \mathbf{a} := (\mathbf{x}, \mathbf{r}, w)$  由平移幅值  $\|\mathbf{x}^k\|$ 、旋转幅值  $\|\mathbf{r}^k\|$  和夹爪宽度  $w$  表示为:

$$\Phi(\mathbf{a}^k) = \begin{cases} 0 & \text{if } \|\mathbf{x}^k\| < \tau_{\text{trans}}, \|\mathbf{r}^k\| < \tau_{\text{rot}}, |w^k - w^{k-1}| < \tau_w \quad (\text{idle}) \\ 1 & \text{if } w^{k-1} - w^k \geq \tau_w \quad (\text{grasp}) \\ 2 & \text{if } w^k - w^{k-1} \geq \tau_w \quad (\text{release}) \\ 3 & \text{if } \|\mathbf{x}^k\| \geq \tau_{\text{trans}}, \|\mathbf{r}^k\| < \tau_{\text{rot}}, |w^k - w^{k-1}| < \tau_w, \mathbf{x}_1^k > 0 \quad (\text{push}) \\ 4 & \text{if } \|\mathbf{x}^k\| \geq \tau_{\text{trans}}, \|\mathbf{r}^k\| < \tau_{\text{rot}}, |w^k - w^{k-1}| < \tau_w, \mathbf{x}_1^k < 0 \quad (\text{pull}) \\ 5 & \text{if } \|\mathbf{x}^k\| < \tau_{\text{trans}}, \|\mathbf{r}^k\| \geq \tau_{\text{rot}}, |w^k - w^{k-1}| < \tau_w, \quad (\text{rotation}) \\ 6 & \text{if } \|\mathbf{x}^k\| \geq \tau_{\text{trans}}, \|\mathbf{r}^k\| \geq \tau_{\text{rot}}, \mathbf{x}_1^k > 0, |w^k - w^{k-1}| < \tau_w \quad (\text{push+rotation}) \\ 7 & \text{if } \|\mathbf{x}^k\| \geq \tau_{\text{trans}}, \|\mathbf{r}^k\| \geq \tau_{\text{rot}}, \mathbf{x}_1^k < 0, |w^k - w^{k-1}| < \tau_w \quad (\text{pull+rotation}) \end{cases} \quad (1)$$

定义 3.1 在机器人中心动作坐标系中表述, 以确保简单性和稳定的跨任务一致性, 同时对于 7 自由度操作控制是完备的。通过基元组合, 该表示支持广泛的机器人操作任务。式 (1) 能够自动生成基元标签, 从而允许本文在无需人工标注的情况下学习基元分类器。随后, 本文训练一个分类器 PANet:  $\hat{\mathbf{y}}^k = \text{PANet}(\mathbf{O}^k)$ , 该分类器从观测中预测基元分布。

PANet 采用 DINOv2 [42] 作为视觉编码器, T5 [43] 作为文本编码器, 后接多模态融合模块和多层感知机分类头。

重要的是, PANet 预测的是概率性基元分布而非硬标签。这种概率化表述提高了基元之间模糊转换下的鲁棒性, 并自然支持长时程操作中的多基元引导。

### 3.2 基元引导

为了实现可微引导, 同时保持与相应硬基元分配之间的局部一致性, 我们定义了一个由生成动作诱导的软基元分布。

**定义 3.2** (软分类)。给定可微评分函数:  $\mathbf{f}^k := (- (\|\mathbf{x}^k\| + \|\mathbf{r}^k\| + |w^k - w^{k-1}|), w^{k-1} - w^k, w^k - w^{k-1}, \mathbf{x}_1^k, -\mathbf{x}_1^k, (\|\mathbf{r}^k\| - \|\mathbf{x}^k\|), \mathbf{x}_1^k + \|\mathbf{r}^k\|, -\mathbf{x}_1^k + \|\mathbf{r}^k\|)$ . 软分类, 即基元类别上的概率分布, 通过温度缩放的 Softmax 函数获得, 即  $\mathbf{p}^k = \text{softmax}(\mathbf{f}(\mathbf{a}^k)/\tau)$ , 其中  $\tau > 0$  为温度。

给定预测的基元分布  $\hat{\mathbf{y}}^k$  和生成的动作  $\mathbf{a}^k$ , 基元引导为:

$$\mathcal{L}_{PG}(\mathbf{a}^k, \mathbf{O}^k) = -\frac{1}{B} \sum_{k=1}^B H(\hat{\mathbf{y}}^k, \mathbf{p}^k) = -\frac{1}{B} \sum_{i=1}^B H(\text{PANet}(\mathbf{O}^k), \mathbf{p}^k), \quad (2)$$

其中  $H(\cdot, \cdot)$  表示预测基元分布与动作诱导基元分布之间的交叉熵,  $B$  为批大小。与硬基元约束或单标签引导不同, 这种概率化形式使得基元之间能够平滑过渡, 并提高了长时程执行过程中的鲁棒性。特别地, 在过渡阶段 (例如从推切换到旋转) 多个基元可能同时获得不可忽略的概率。这种软引导减少了动作的突然修正, 并提高了轨迹一致性。

### 3.3 带基元引导的扩散策略

扩散策略将操作过程形式化为马尔可夫过程, 并利用去噪扩散概率模型 (DDPM) [44] 对具有多模态观测  $\mathbf{O}^k$  的操作策略进行建模。给定观测  $\mathbf{O}^k$ , 它从随机动作  $\mathbf{a}_T^k \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$  开始执行  $T$  步去噪, 以生成动作  $\mathbf{a}_0^k$ , 迭代公式为  $\mathbf{a}_{t-1}^k = \alpha_t(\mathbf{a}_t^k - \gamma_t \varepsilon_\theta(\mathbf{O}^k, \mathbf{a}_t^k, t) + \epsilon)$ , 其中  $\epsilon \sim \mathcal{N}(\mathbf{0}, \sigma_t^2 \mathbf{I})$ 。系数  $\alpha_t, \gamma_t, \sigma_t$  是去噪步骤  $t$  的预定义噪声调度。

为了提高扩散策略的可迁移性, 我们将第 3.2 节介绍的基元引导机制融入去噪过程。通过利用测试时观测来细化



生成的动作，所提出的方法将去噪更新引导至与基元一致的轨迹，从而在分布偏移下产生更鲁棒且语义连贯的动作生成。由此得到以下引导扩散策略：

$$\begin{aligned}\tilde{\mathbf{a}}_{t-1}^k &= \alpha_t(\mathbf{a}_t^k - \gamma_t \varepsilon_\theta(\mathbf{O}^k, \mathbf{a}_t^k, t) + \epsilon), \\ \hat{\mathbf{a}}_0^k &= (\tilde{\mathbf{a}}_{t-1}^k - \sqrt{1 - \bar{\alpha}_t} \varepsilon_\theta(\mathbf{O}^k, \mathbf{a}_t^k, t)) / \sqrt{\bar{\alpha}_t}, \\ \mathbf{a}_{t-1}^k &= \tilde{\mathbf{a}}_{t-1}^k - \eta \nabla_{\mathbf{a}} \mathcal{L}_{\text{PG}}(\hat{\mathbf{a}}_0^k, \mathbf{O}^k),\end{aligned}\tag{3}$$

此处， $\hat{\mathbf{a}}_0^k$  表示通过预定义的逆扩散调度获得的估计无噪声动作。通过引入基元引导项  $\nabla_{\mathbf{a}} \mathcal{L}_{\text{PG}}(\cdot, \cdot)$ , Eq. (3)，约束了逆扩散过程的更新方向，确保与预期基元动作的一致性。

### 3.4 带基元引导的流策略

流策略利用流匹配学习从噪声到专家动作的连续变换。给定动作  $\mathbf{a}$ ，流路径定义为  $\mathbf{a}_t = \alpha_t \mathbf{a} + b_t \mathbf{z}$ ,  $t \in [0, 1]$ ，其中  $\alpha_t$  和  $b_t$  是预定义的调度， $\mathbf{z} \sim p(\mathbf{z})$  是初始噪声动作。常用的调度为  $\alpha_t = t$  和  $b_t = 1 - t$ ，则速度场为  $\mathbf{v}_\theta(\mathbf{a}_t, t) = \frac{d\mathbf{a}_t}{dt} = \mathbf{a} - \mathbf{z}$ 。流策略由  $\theta$  参数化，预测速度场  $\mathbf{v}_\theta(\mathbf{a}_t, \mathbf{O}, t)$ 。训练后，它通过前向欧拉规则  $\mathbf{a}_{t+\delta} = \mathbf{a}_t + \delta \mathbf{v}_\theta(\mathbf{a}_t, \mathbf{O}, t)$  从噪声  $\mathbf{a}_0 = \mathbf{z}$  生成  $\mathbf{a}_1$ ，其中  $\delta$  是积分步长。

类似地，我们将第 3.2 节中的测试时基元引导集成到流策略的推理阶段。具体而言，我们利用从测试时观测中推导出的基元来约束生成的连续动作，从而产生与目标基元一致的动作。从预定义的流调度中，我们可以推导出以下引导流策略：

$$\begin{aligned}\tilde{\mathbf{a}}_{t+\delta}^k &= \mathbf{a}_t^k + \delta \mathbf{v}_\theta(\mathbf{a}_t^k, \mathbf{O}^k, t), \\ \hat{\mathbf{a}}_1^k &= \mathbf{a}_t^k + (1 - t) \mathbf{v}_\theta(\mathbf{a}_t^k, \mathbf{O}^k, t), \\ \mathbf{a}_{t+\delta}^k &= \tilde{\mathbf{a}}_{t+\delta}^k - \eta \nabla_{\mathbf{a}} \mathcal{L}_{\text{PG}}(\hat{\mathbf{a}}_1^k, \mathbf{O}^k).\end{aligned}\tag{4}$$

这等价于定义一个引导速度场  $\mathbf{v}_\theta^{\text{guided}}$ 。我们的方法  $\mathbf{v}_\theta^{\text{guided}} = \mathbf{v}_\theta - \frac{\eta}{\delta} \nabla_{\mathbf{a}} \mathcal{L}_{\text{PG}}(\hat{\mathbf{a}}_1, \mathbf{O})$ 。

在基于扩散和基于流的策略的动作细化过程中施加了更强的约束，从而生成符合所需结构化基元的动作。与原始策略模型相比，引导策略产生的动作与目标动作的偏差是有界的，这一性质我们在补充材料中进一步阐述。

## 4 实验

我们设计实验以回答以下问题：i) PANet 在基元预测方面的准确率和鲁棒性如何？ii) 所提出的基元引导能否在不重新训练的情况下提升预训练策略的操作性能？iii) PriGo 能否有效泛化到真实世界的机器人操作任务？iv) 每个核心组件对整体性能的贡献如何？我们首先在第 4.1 节评估 PANet 的准确率和鲁棒性。接着，在第 4.2 节展示 PriGo 在仿真基准上的性能提升，并在第 4.3 节展示其在真实世界机器人任务上的表现。最后，在第 4.4 节进行消融研究。

### 4.1 PANet 鲁棒性分析

为评估 PANet 的可靠性，我们在图 3 左侧子图中报告其基元分类准确率和混淆矩阵。PANet 在 LIBERO 上达到 94.0% 的准确率。大多数错误发生在语义相邻的基元之间，例如推+旋转与推或旋转，这表明误分类主要仍处于相似的局部动作流形内。

我们进一步分析 PriGo 对阈值  $\tau_{\text{trans}}$ ,  $\tau_{\text{rot}}$  和  $\tau_w$  的敏感性。如图 3 右侧子图所示，性能在较宽的阈值范围内保持稳定，表明 PriGo 对特定超参数值的选择并不十分敏感。

| Type      | Idle      | Grasp     | Rel.      | Push      | Pull      | Rot.      | Push+Rot. | Pull+Rot. |
|-----------|-----------|-----------|-----------|-----------|-----------|-----------|-----------|-----------|
| Idle      | <b>90</b> | 6         | 2         | 1         | 1         | 0         | 0         | 0         |
| Grasp     | 7         | <b>96</b> | 1         | 0         | 1         | 0         | 0         | 0         |
| Rel.      | 1         | 2         | <b>96</b> | 1         | 0         | 0         | 0         | 0         |
| Push      | 0         | 0         | 0         | <b>94</b> | 2         | 1         | 3         | 0         |
| Pull      | 0         | 0         | 0         | 1         | <b>95</b> | 1         | 0         | 3         |
| Rot.      | 0         | 0         | 0         | 1         | 2         | <b>93</b> | 2         | 2         |
| Push+Rot. | 0         | 0         | 0         | 5         | 0         | 4         | <b>91</b> | 0         |
| Pull+Rot. | 0         | 0         | 0         | 0         | 6         | 4         | 0         | <b>90</b> |




图 3: PANet 基元分类的混淆矩阵 (左) 和自动标注阈值的敏感性分析 (右)。Rel. 和 Rot. 分别表示释放和旋转。表 1: LIBERO 上四种设置 (空间、物体、目标、长时程) 的成功率。比较使用 (w/ PG) 和不使用 (w/o PG) 基元引导 PriGo 的情况。此处  $\pi_0$ +PG 和 SmolVLA+PG 为 PriGo-FP。DP+PG 和 CogACT+PG 为 PriGo-DP。

| Methods      | Spatial |       | Object |       | Goal   |       | Long   |       | Avg.   |       |
|--------------|---------|-------|--------|-------|--------|-------|--------|-------|--------|-------|
|              | w/o PG  | w/ PG | w/o PG | w/ PG | w/o PG | w/ PG | w/o PG | w/ PG | w/o PG | w/ PG |
| $\pi_0$ [24] | 89.2    | 91.0  | 84.6   | 87.8  | 94.4   | 95.2  | 75.2   | 78.8  | 85.6   | 88.2  |
| SmolVLA [27] | 92.0    | 93.6  | 93.4   | 94.4  | 91.4   | 93.2  | 75.8   | 79.8  | 88.2   | 90.3  |
| DP [5]       | 76.2    | 80.6  | 87.4   | 90.8  | 70.4   | 72.6  | 54.2   | 58.4  | 72.1   | 75.6  |
| CogACT [17]  | 91.1    | 95.6  | 92.0   | 97.3  | 91.5   | 95.8  | 76.4   | 80.4  | 87.8   | 92.3  |

## 4.2 仿真评估

**LIBERO 上的评估。** LIBERO [45] 是一个大规模基准，包含超过 130 个任务，分为五个不同的套件。为验证所提出的基元引导的有效性，我们将其集成到一系列预训练策略中，包括流策略  $\pi_0$  [24]、SmolVLA [27]、扩散策略 DP [5] 和 CogACT [17]。这种集成产生了两种策略变体，即 PriGo-DP 和 PriGo-FP。对于  $\pi_0$  和 SmolVLA，我们采用 LeRobot<sup>1</sup> 提供的预训练模型和超参数配置。至于 DP 和 CogAct，由于没有 LIBERO 上的官方预训练检查点，我们因此在 LIBERO 上对这两个模型进行了微调。

表 1 展示了四种预训练策略在有无集成我们原始引导模块情况下的评估结果。如图所示，所提出的 PriGo 在基于流和基于扩散的策略上均一致地提升了 3–5 个点的性能，无论骨干网络是大规模模型（如  $\pi_0$  和 CogAct）还是轻量级模型（DP）。这种一致的提升源于 PriGo 的直接干预：通过强制生成的动作符合任务所需的原语，PriGo 产生更结构化的动作，从而带来更高的成功率。

**在 SIMPLER 上的评估。** SIMPLER 基准 [46] 提供了两种评估设置：视觉匹配（Visual Matching），通过最小化仿真与物理环境之间的差距来紧密模拟真实场景；以及变体聚合（Variant Aggregations），在背景、光照、干扰物和桌面纹理方面引入变化。我们将 PriGo-DP 与其他五个 VLA 模型进行比较，相应结果总结在表 2 中。值得注意的是，表中呈现的所有基线结果均来自 CogACT。如图所示，PriGo-DP 以明显优势超越了所有现有基线方法。具体而言，相对于 CogACT，我们的方法在视觉匹配设置下平均提升 5 个百分点，在变体聚合设置下提升 7 个点。这些结果表明，PriGo 能够以即插即用的方式有效提升 VLA 模型 CogACT 的测试时性能，而无需额外重新训练。

**在 CALVIN 上的评估。** CALVIN [49] 是一个以 Franka Panda 机器人在参数丰富的桌面环境中交互为中心的基准。它包含四个在桌面纹理和物体摆放上有所不同的环境。该基准定义了 34 个任务，需顺序执行语言条件指令，每条指令包含五个步骤。我们将所提出的原始引导集成到预训练的扩散策略 3D Diffuser Actor (3DDA) [11] 中，并在 CALVIN 上将其性能与几种最先进方法进行比较，包括 DTP [50]、DP3 [9]、3DDA 和 ADPro [30]。结果报告在表 3 中。

<sup>1</sup><https://github.com/huggingface/lerobot>


表 2: 在 Google 机器人上, 我们的方法 PriGo-DP (带 PriGo 的 CogACT) 与现有 VLA 模型在两种 SIMPLER 设置下的四个任务中的比较。

| Google Robot                     | Method          | Pick<br>Coke Can | Move<br>Near | Open/Close<br>Drawer | Open Top Drawer<br>and Place Apple | Average     |
|----------------------------------|-----------------|------------------|--------------|----------------------|------------------------------------|-------------|
| SIMPLER<br>(Visual Matching)     | RT-2-X [47]     | 78.7             | 77.9         | 25.0                 | 3.7                                | 46.3        |
|                                  | Octo-Base [15]  | 17.0             | 4.2          | 22.7                 | 0.0                                | 11.0        |
|                                  | OpenVLA [48]    | 18.0             | 56.3         | 63.0                 | 0.0                                | 34.3        |
|                                  | CogACT [17]     | 91.3             | 85.0         | 71.8                 | 50.9                               | 74.8        |
|                                  | <b>PriGo-DP</b> | <b>93.2</b>      | <b>89.3</b>  | <b>77.5</b>          | <b>59.7</b>                        | <b>79.9</b> |
| SIMPLER<br>(Variant Aggregation) | RT-2-X [47]     | 82.3             | 79.2         | 35.3                 | 20.6                               | 54.4        |
|                                  | Octo-Base [15]  | 0.6              | 3.1          | 1.1                  | 0.0                                | 1.2         |
|                                  | OpenVLA [48]    | 60.8             | 67.7         | 28.8                 | 0.0                                | 39.3        |
|                                  | CogACT [17]     | 89.6             | 80.8         | 28.3                 | 46.6                               | 61.3        |
|                                  | <b>PriGo-DP</b> | <b>92.5</b>      | <b>83.6</b>  | <b>44.1</b>          | <b>55.0</b>                        | <b>68.8</b> |


如表 3 所示, 我们的 PriGo-DP (带 PriGo 的 3DDA) 以显著优势优于其他扩散策略。具体而言, PriGo-DP 相比原始扩散策略 3DDA 将平均长度提高了 0.8, 增强了其在零样本长时程任务上的性能。这些结果表明, PriGo 能够有效提升测试时泛化能力, 即使对于非 VLA 模型也是如此。

表 3: CALVIN 上的零样本 (训练 A、B、C → 测试 D) 长时程评估。平均长度表示正确预测轨迹的平均长度。


| Method          | Task completed in a row |             |             |             |             | Avg. Len ↑  |
|-----------------|-------------------------|-------------|-------------|-------------|-------------|-------------|
|                 | 1                       | 2           | 3           | 4           | 5           |             |
| DTP             | 94.5                    | 82.5        | 72.8        | 61.3        | 50.0        | 3.61        |
| DP3             | 53.9                    | 44.7        | 38.0        | 34.3        | 29.0        | 2.00        |
| 3DDA            | 93.8                    | 80.3        | 66.2        | 53.3        | 41.2        | 3.35        |
| ADPro           | 94.7                    | 83.0        | 73.6        | 61.4        | 51.1        | 3.64        |
| <b>PriGo-DP</b> | <b>98.1</b>             | <b>92.1</b> | <b>87.6</b> | <b>80.4</b> | <b>59.9</b> | <b>4.18</b> |



(a) Rollout for the “Prepare a set of tableware task”.



(b) Rollout for the “Bring back a set of tableware to the basket” task.



(c) Rollout for the “Prepare two sets of tableware” task.

图 4: 我们的 PriGo-DP 在三个桌面服务任务上的执行过程。PriGo-DP 将生成的动作与任务基元对齐, 从而提升策略对新任务的泛化能力。

### 4.3 真实机器人评估

在真实世界设置中, 我们使用 Franka Emika Panda 机器人和两个 RGB 传感器进行实验。我们设计了三个餐厅风格的顺序桌面服务任务, 包括: 1) 准备一套餐具, 2) 将一套餐具放回篮子, 3) 准备两套餐具。实验中使用的餐具包括盘子、碗、杯子、叉子和勺子。每个任务进行 10 次试验的平均成功率报告在表 4 中。即使训练演示样本不超过 20 个, 我们的方法仍达到了 81% 的成功率。与原始 CogACT 相比, 我们的 PriGo-DP 在三个任务上平均性能提升了 26 个百分点。这表明 PriGo 对长序列非常有益。

为了说明我们策略的实际效果, 我们可视化了三个任务中具有代表性的测试案例。相应的定性结果如图 4 所示, 每个子图描绘了从初始状态观察到最终目标达成的关键顺序步骤。这些可视化展示了我们的方法在真实世界任务中的鲁棒性。

### 4.4 消融研究

所提出的基元引导方法 PriGo 可以即插即用, 这一特性已通过表 1 至表 4 中的实验结果得到充分验证。

表 4: PriGo-DP (结合 PriGo 的 CogACT) 在三个长时程真实世界任务上的成功率。w/o PG 与 w/ PG 分别表示不使用与使用 PriGo。

| Task                  | #Train | w/o PG        | w/ PG        |
|-----------------------|--------|---------------|--------------|
| prepare one tableware | 12     | 47 $\pm$ 9.3  | 76 $\pm$ 7.3 |
| bring back tableware  | 18     | 55 $\pm$ 11.3 | 81 $\pm$ 9.6 |
| prepare two tableware | 20     | 40 $\pm$ 8.3  | 62 $\pm$ 8.0 |

表 5: 消融实验。使用全部 8 种原语学习得到的策略优于不区分“推”与“拉” (PP) 以及不使用混合原语 (HP) 的对照策略。

| Dataset | w/o PP | w/o HP | FULL |
|---------|--------|--------|------|
| LIBERO  | 89.9   | 91.0   | 92.3 |
| SIMPLER | 77.1   | 77.8   | 79.9 |

所提出的原语引导能够以即插即用的方式运行——这一特性已由表 1 至表 4 中的实验结果验证。为进一步剖析原语各组成部分的有效性，我们对三种不同方案进行了消融实验：1) 不区分平移原语（即将“推”与“拉”视为统一的平移原语类型）；2) 不使用混合原语（排除“推+旋转”与“拉+旋转”）；3) 使用全部八种原语动作。实验结果见表 5，表明这些原语动作对策略模型的学习与优化具有积极作用。




图 5: 通过统一流形逼近与投影 (UMAP) 和 t-分布随机邻域嵌入 (t-SNE) 对两个回合中的动作与原语标签进行可视化。

如表 5 所示，省略“推”与“拉” (PP) 类型会导致策略性能最显著的下降。若不区分推与拉，生成的动作往往在方向上出现偏差，直接导致任务失败。移除混合原语同样会使模型性能下降。值得注意的是，我们的观察表明，引入混合原语能够使策略输出的动作更加平滑。

此外，为直观展示原语动作分类结果，我们在图 5 中使用统一流形逼近与投影 (UMAP) 和 t-分布随机邻域嵌入 (t-SNE) 对原语动作实例进行了可视化。前两个子图来自 LIBERO 的 Object 子集，包含 7281 个动作；第三和第四个子图来自 Spatial 子集，包含 5796 个动作。此处不同颜色表示由式 (1) 生成的不同类别。结果表明，同一原语在降维后呈现出清晰的聚类。

## 5 结论

本文提出 PriGo，一种可与轻量级策略及大型视觉-语言-动作模型协同工作的基元引导方法。PriGo 有效解耦了离散基元规划与连续动作学习。为捕捉给定任务及其视觉观测的基元规划，我们提出了一种新颖的基元分类模块和一种自动基元标注方法，从而能够直接从当前观测中预测基元。为确保生成的动作与预测的基元一致，我们引入了一种可微基元引导机制，该机制约束动作生成，从而实现更鲁棒的操控。该引导可无缝集成到预训练的扩散策略和流策略中，提供了一种灵活、即插即用的解决方案，无需重新训练即可提升性能。实验结果表明，我们的策略在仿真和真实世界任务中均优于基线方法。

**局限性。** 尽管 PriGo 在测试阶段同时改进了基于流和基于扩散的策略，但提升仍然有限。这主要源于两个因素。首先，即插即用的设计使得无需重新训练即可部署，但本质上限制了性能提升。未来工作可探索与端到端训练的更紧密集成。其次，PANet 的泛化能力仍受模型规模和训练数据规模的制约。更合适的数据以及融入历史机器人状态可能进一步提升引导机制的有效性。

## 致谢

本工作部分得到法国研究署 ANR (l’Agence Nationale de Recherche) 通过以下项目的支持: Chiron (ANR-20-IADJ-0001-01)、Aristotle (ANR-21-FAI1-0009-01)、Astérix (ANR-23-EDIA-0002) 和 DEMETER 项目 (ANR-25-HTCE-0002), 法国国家投资优先计划通过 PSPC FAIR WASTE 项目, 以及中法碳中和研究中心通过 Artemis 项目。

## 参考文献

- [1] R. Sapkota, Y. Cao, K. I. Roumeliotis, and M. Karkee. Vision-language-action models: Concepts, progress, applications and challenges. *arXiv preprint arXiv:2505.04769*, 2025.
- [2] Z. Li, A. Chapin, E. Xiang, R. Yang, B. Machado, N. Lei, E. Dellandrea, D. Huang, and L. Chen. Robotic manipulation via imitation learning: Taxonomy, evolution, benchmark, and challenges. *arXiv preprint arXiv:2508.17449*, 2025.
- [3] A. Hiranaka, M. Hwang, S. Lee, C. Wang, L. Fei-Fei, J. Wu, and R. Zhang. Primitive skill-based robot learning from human evaluative feedback. In *2023 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 7817–7824. IEEE, 2023.
- [4] T. Gao, S. Nasiriany, H. Liu, Q. Yang, and Y. Zhu. Prime: Scaffolding manipulation tasks with behavior primitives for data-efficient imitation learning. *IEEE Robotics and Automation Letters*, 2024.
- [5] C. Chi, Z. Xu, S. Feng, E. Cousineau, Y. Du, B. Burchfiel, R. Tedrake, and S. Song. Diffusion policy: Visuomotor policy learning via action diffusion. *The International Journal of Robotics Research*, page 02783649241273668, 2023.
- [6] K. Black, M. Nakamoto, P. Atreya, H. R. Walke, C. Finn, A. Kumar, and S. Levine. Zero-shot robotic manipulation with pre-trained image-editing diffusion models. In *The Twelfth International Conference on Learning Representations*, 2024.
- [7] Z. Xian, N. Gkanatsios, T. Gervet, T.-W. Ke, and K. Fragkiadaki. Chaineddiffuser: Unifying trajectory diffusion and keypose prediction for robotic manipulation. In *Conference on Robot Learning*, pages 2323–2339. PMLR, 2023.
- [8] Y. Wang, X. Zhang, R. Wu, Y. Li, Y. Shen, M. Wu, Z. He, Y. Wang, and H. Dong. Adamanip: Adaptive articulated object manipulation environments and policy learning. In *The Thirteenth International Conference on Learning Representations*, 2025.
- [9] Y. Ze, G. Zhang, K. Zhang, C. Hu, M. Wang, and H. Xu. 3d diffusion policy: Generalizable visuomotor policy learning via simple 3d representations. In *ICRA 2024 Workshop on 3D Visual Representations for Robot Manipulation*, 2024.
- [10] J. Yang, Z. Cao, C. Deng, R. Antonova, S. Song, and J. Bohg. Equibot: Sim (3)-equivariant diffusion policy for generalizable and data efficient learning. In *8th Annual Conference on Robot Learning*, 2024.
- [11] T.-W. Ke, N. Gkanatsios, and K. Fragkiadaki. 3d diffuser actor: Policy diffusion with 3d scene representations. In *8th Annual Conference on Robot Learning*, 2024.
- [12] D. Wang, S. Hart, D. Surovik, T. Kelestemur, H. Huang, H. Zhao, M. Yeatman, J. Wang, R. Walters, and R. Platt. Equivariant diffusion policy. *8th Annual Conference on Robot Learning*, 2024.
- [13] H. He, C. Bai, L. Pan, W. Zhang, B. Zhao, and X. Li. Learning an actionable discrete diffusion policy via large-scale actionless video pre-training. *Advances in Neural Information Processing Systems*, 37:31124–31153, 2025.



- [14] E. Xiang, H. Ma, X. Ma, Z. Liu, and D. Huang. Graspdp: Towards generalizable grasping policy via latent diffusion. *arXiv preprint arXiv:2602.22862*, 2026.
- [15] O. M. Team, D. Ghosh, H. Walke, K. Pertsch, K. Black, O. Mees, S. Dasari, J. Hejna, T. Kreiman, C. Xu, et al. Octo: An open-source generalist robot policy. *arXiv:2405.12213*, 2024.
- [16] J. Wen, M. Zhu, Y. Zhu, Z. Tang, J. Li, Z. Zhou, C. Li, X. Liu, Y. Peng, C. Shen, et al. Diffusion-vla: Scaling robot foundation models via unified diffusion and autoregression. *arXiv:2412.03293*, 2024.
- [17] Q. Li, Y. Liang, Z. Wang, L. Luo, X. Chen, M. Liao, F. Wei, et al. Cogact: A foundational vision-language-action model for synergizing cognition and action in robotic manipulation. *arXiv:2411.19650*, 2024.
- [18] Z. Zhou, Y. Zhu, M. Zhu, J. Wen, N. Liu, Z. Xu, W. Meng, Y. Peng, C. Shen, F. Feng, et al. Chatvla: Unified multimodal understanding and robot control with vision-language-action model. In *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*, pages 5377–5395, 2025.
- [19] S. Liu, L. Wu, B. Li, H. Tan, H. Chen, Z. Wang, K. Xu, H. Su, and J. Zhu. Rdt-1b: a diffusion foundation model for bimanual manipulation. *arXiv:2410.07864*, 2024.
- [20] J. Liu, H. Chen, P. An, Z. Liu, R. Zhang, C. Gu, X. Li, Z. Guo, S. Chen, M. Liu, et al. Hybridvla: Collaborative diffusion and autoregression in a unified vision-language-action model. *arXiv:2503.10631*, 2025.
- [21] Q. Rouxel, A. Ferrari, S. Ivaldi, and J.-B. Mouret. Flow matching imitation learning for multi-support manipulation. In *2024 IEEE-RAS 23rd International Conference on Humanoid Robots (Humanoids)*, pages 528–535. IEEE, 2024.
- [22] F. Zhang and M. Gienger. Affordance-based robot manipulation with flow matching. *arXiv preprint arXiv:2409.01083*, 2024.
- [23] N. Funk, J. Urain, J. Carvalho, V. Prasad, G. Chalvatzaki, and J. Peters. Actionflow: Efficient, accurate, and fast policies with spatially symmetric flow matching. In *R: SS workshop: Structural Priors as Inductive Biases for Learning Robot Dynamics*, 2024.
- [24] K. Black, N. Brown, D. Driess, A. Esmail, M. Equi, C. Finn, N. Fusai, L. Groom, K. Hausman, B. Ichter, et al.  $\pi 0$ : A vision-language-action flow model for general robot control, 2024. *arXiv preprint arXiv:2410.24164*, 2024.
- [25] L. X. Shi, B. Ichter, M. Equi, L. Ke, K. Pertsch, Q. Vuong, J. Tanner, A. Walling, H. Wang, N. Fusai, et al. Hi robot: Open-ended instruction following with hierarchical vision-language-action models. *arXiv preprint arXiv:2502.19417*, 2025.
- [26] S. Deng, M. Yan, S. Wei, H. Ma, Y. Yang, J. Chen, Z. Zhang, T. Yang, X. Zhang, H. Cui, et al. Graspvla: a grasping foundation model pre-trained on billion-scale synthetic action data. *arXiv preprint arXiv:2505.03233*, 2025.
- [27] M. Shukor, D. Aubakirova, F. Capuano, P. Kooijmans, S. Palma, A. Zouitine, M. Aractingi, C. Pascal, M. Russi, A. Marafioti, et al. Smolvla: A vision-language-action model for affordable and efficient robotics. *arXiv:2506.01844*, 2025.
- [28] F. Ni, J. Hao, Y. Mu, Y. Yuan, Y. Zheng, B. Wang, and Z. Liang. Metadiffuser: Diffusion model as conditional planner for offline meta-rl. In *International Conference on Machine Learning*, pages 26087–26105. PMLR, 2023.
- [29] W. K. Kim, Y. Lee, J. Kim, and H. Woo. Llm-based skill diffusion for zero-shot policy adaptation. *Advances in Neural Information Processing Systems*, 37:6749–6775, 2024.



- [30] Z. Li, R. Yang, R. Chen, Z. Luo, and L. Chen. Adpro: a test-time adaptive diffusion policy for robot manipulation via manifold and initial noise constraints. *arXiv preprint arXiv:2508.06266*, 2025.
- [31] X. B. Peng, M. Chang, G. Zhang, P. Abbeel, and S. Levine. Mcp: Learning composable hierarchical control with multiplicative compositional policies. *Advances in neural information processing systems*, 32, 2019.
- [32] J. Merel, L. Hasenclever, A. Galashov, A. Ahuja, V. Pham, G. Wayne, Y. Teh, and N. Heess. Neural probabilistic motor primitives for humanoid control. In *International Conference on Learning Representations*, 2019.
- [33] M. Knaust and D. Koert. Guided robot skill learning: A user-study on learning probabilistic movement primitives with non-experts. In *2020 IEEE-RAS 20th International Conference on Humanoid Robots (Humanoids)*, pages 514–521. IEEE, 2021.
- [34] M. Dalal, D. Pathak, and R. R. Salakhutdinov. Accelerating robotic reinforcement learning via parameterized action primitives. *Advances in Neural Information Processing Systems*, 34: 21847–21859, 2021.
- [35] J. Zhang, J. Zhang, K. Pertsch, Z. Liu, X. Ren, M. Chang, S.-H. Sun, and J. J. Lim. Bootstrap your own skills: Learning to solve new tasks with large language model guidance. In *7th Annual Conference on Robot Learning*, 2023.
- [36] R. Garcia, S. Chen, and C. Schmid. Towards generalizable vision-language robotic manipulation: A benchmark and llm-guided 3d policy. In *2025 IEEE International Conference on Robotics and Automation (ICRA)*, pages 8996–9002. IEEE, 2025.
- [37] M. Pan, J. Zhang, T. Wu, Y. Zhao, W. Gao, and H. Dong. Omnimanip: Towards general robotic manipulation via object-centric interaction primitives as spatial constraints. In *Proceedings of the Computer Vision and Pattern Recognition Conference*, pages 17359–17369, 2025.
- [38] Q. Sun, L. Yang, W. Tang, W. Huang, K. Xu, Y. Chen, M. Liu, J. Yang, H. Zhu, Y. Wang, et al. Learning primitive embodied world models: Towards scalable robotic learning. *arXiv preprint arXiv:2508.20840*, 2025.
- [39] T. Liu, J. Li, Y. Zheng, H. Niu, Y. Lan, X. Xu, and X. Zhan. Skill expansion and composition in parameter space. In *The Thirteenth International Conference on Learning Representations*, 2025.
- [40] W. Wan, Y. Zhu, R. Shah, and Y. Zhu. Lotus: Continual imitation learning for robot manipulation through unsupervised skill discovery. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 537–544, 2024.
- [41] Y. Guo, B. Tang, I. Akinola, D. Fox, A. Gupta, and Y. Narang. Srsa: Skill retrieval and adaptation for robotic assembly tasks. In *The Thirteenth International Conference on Learning Representations*, 2025.
- [42] M. Oquab, T. Darcet, T. Moutakanni, H. Vo, M. Szafraniec, V. Khalidov, P. Fernandez, D. Haziza, F. Massa, A. El-Nouby, et al. Dinov2: Learning robust visual features without supervision. *Transactions on Machine Learning Research Journal*, pages 1–31, 2024.
- [43] C. Raffel, N. Shazeer, A. Roberts, K. Lee, S. Narang, M. Matena, Y. Zhou, W. Li, and P. J. Liu. Exploring the limits of transfer learning with a unified text-to-text transformer. *Journal of Machine Learning Research*, 21(140):1–67, 2020. URL <http://jmlr.org/papers/v21/20-074.html>.
- [44] J. Ho, A. Jain, and P. Abbeel. Denoising diffusion probabilistic models. In *Advances in Neural Information Processing Systems*, volume 33, pages 6840–6851, 2020.

- [45] B. Liu, Y. Zhu, C. Gao, Y. Feng, Q. Liu, Y. Zhu, and P. Stone. Libero: Benchmarking knowledge transfer for lifelong robot learning. *Advances in Neural Information Processing Systems*, 36: 44776–44791, 2023.
- [46] X. Li, K. Hsu, J. Gu, O. Mees, K. Pertsch, H. R. Walke, C. Fu, I. Lunawat, I. Sieh, S. Kirmani, et al. Evaluating real-world robot manipulation policies in simulation. In *Conference on Robot Learning*, pages 3705–3728. PMLR, 2025.
- [47] Q. Vuong, S. Levine, H. R. Walke, K. Pertsch, A. Singh, R. Doshi, C. Xu, J. Luo, L. Tan, D. Shah, et al. Open x-embodiment: Robotic learning datasets and rt-x models. In *Towards Generalist Robots: Learning Paradigms for Scalable Skill Acquisition@ CoRL2023*, 2023.
- [48] M. J. Kim, K. Pertsch, S. Karamcheti, T. Xiao, A. Balakrishna, S. Nair, R. Rafailov, E. P. Foster, P. R. Sanketi, Q. Vuong, et al. Openvla: An open-source vision-language-action model. In *Conference on Robot Learning*, pages 2679–2713. PMLR, 2025.
- [49] O. Mees, L. Hermann, E. Rosete-Beas, and W. Burgard. Calvin: A benchmark for language-conditioned policy learning for long-horizon robot manipulation tasks. *IEEE Robotics and Automation Letters*, 7(3):7327–7334, 2022.
- [50] Z. Hou, T. Zhang, Y. Xiong, H. Pu, C. Zhao, R. Tong, Y. Qiao, J. Dai, and Y. Chen. Diffusion transformer policy. *arXiv preprint arXiv:2410.15959*, 2024.
- [51] J. Li, D. Li, S. Savarese, and S. Hoi. Blip-2: Bootstrapping language-image pre-training with frozen image encoders and large language models. In *International conference on machine learning*, pages 19730–19742. PMLR, 2023.

This document presents the error-bound proposition, along with implementation details for PANet and a primitive-action analysis. It also provides additional experimental results, including the impact of different methods for deriving discrete primitive action types, and qualitative comparisons on real-world robotic tasks.

## A 误差界

**命题 A.1** (误差界)。假设预训练策略  $\epsilon_\theta$  在步骤  $t$  产生动作  $\tilde{\mathbf{a}}_t$ ，其与动作  $\mathbf{a}_*$  的误差为  $\tilde{\mathcal{E}}_t = \|\tilde{\mathbf{a}}_t - \mathbf{a}_*\|$ 。当应用原语引导的扩散去噪或流速度场时，所得动作  $\mathbf{a}_t$  满足严格更紧的误差界：

$$\mathcal{E}_t \leq \frac{1}{1+C} \cdot \tilde{\mathcal{E}}_t + \mathcal{O}(\tau_t) \quad (5)$$

其中  $\mathcal{E}_t = \|\mathbf{a}_t - \mathbf{a}_*\|$ ,  $C$  是与动作流形的局部曲率及损失函数  $L$  的利普希茨连续性相关的正系数， $\tau_t$  是来自随机过程的残差项。

证明。基元引导的扩散去噪和基元引导的流更新均可统一写为如下引导校正步骤：

$$\mathbf{a}_t = \tilde{\mathbf{a}}_t - \eta G(\tilde{\mathbf{a}}_t) + \boldsymbol{\xi}_t, \quad (6)$$

其中  $G(\cdot)$  是基元诱导的引导场， $\eta > 0$  是步长， $\boldsymbol{\xi}_t$  是满足以下条件的随机残差项

$$\mathbb{E}\|\boldsymbol{\xi}_t\| = \mathcal{O}(\tau_t). \quad (7)$$

假设目标动作  $\mathbf{a}_*$  是引导场的不动点：

$$G(\mathbf{a}_*) = 0, \quad (8)$$

且  $G$  在  $\mathbf{a}_*$  的邻域内局部强单调：存在常数  $C_0 > 0$  使得

$$\langle G(\mathbf{a}) - G(\mathbf{a}_*), \mathbf{a} - \mathbf{a}_* \rangle \geq C_0 \|\mathbf{a} - \mathbf{a}_*\|^2. \quad (9)$$

考虑引导更新后的误差：

$$\mathbf{a}_t - \mathbf{a}_* = (\tilde{\mathbf{a}}_t - \mathbf{a}_*) - \eta G(\tilde{\mathbf{a}}_t) + \boldsymbol{\xi}_t. \quad (10)$$

取平方范数并求期望可得：

$$\mathbb{E}\|\mathbf{a}_t - \mathbf{a}_*\|^2 = \|\tilde{\mathbf{a}}_t - \mathbf{a}_*\|^2 - 2\eta \langle G(\tilde{\mathbf{a}}_t), \tilde{\mathbf{a}}_t - \mathbf{a}_* \rangle + \eta^2 \|G(\tilde{\mathbf{a}}_t)\|^2 + \mathcal{O}(\tau_t^2). \quad (11)$$

Using  $G(\mathbf{a}_*) = 0$ , we have

$$\langle G(\tilde{\mathbf{a}}_t), \tilde{\mathbf{a}}_t - \mathbf{a}_* \rangle = \langle G(\tilde{\mathbf{a}}_t) - G(\mathbf{a}_*), \tilde{\mathbf{a}}_t - \mathbf{a}_* \rangle \geq C_0 \|\tilde{\mathbf{a}}_t - \mathbf{a}_*\|^2. \quad (12)$$

对于足够小的  $\eta$ ，二次项  $\eta^2 \|G(\tilde{\mathbf{a}}_t)\|^2$  可以被吸收到收缩系数中，从而得到

$$\mathbb{E}\|\mathbf{a}_t - \mathbf{a}_*\|^2 \leq (1 - 2\eta C_0) \|\tilde{\mathbf{a}}_t - \mathbf{a}_*\|^2 + \mathcal{O}(\tau_t^2). \quad (13)$$

取平方根并选择  $C$  使得

$$\frac{1}{1+C} = \sqrt{1 - 2\eta C_0}, \quad (14)$$

我们得到最终界限：

$$\|\mathbf{a}_t - \mathbf{a}_*\| \leq \frac{1}{1+C} \|\tilde{\mathbf{a}}_t - \mathbf{a}_*\| + \mathcal{O}(\tau_t). \quad (15)$$

由于  $C > 0$ ，因子  $1/(1+C) < 1$ ，这保证了向目标动作  $\mathbf{a}_*$  的加速收敛。  $\square$

## B 实现细节与基元分析

本节详细阐述 PANet 的实现与训练细节，以及本文提出的基元分类器。

PANet 以观测  $\mathbf{O}$  为输入，输出下一动作的基元类型，即  $y^k = \text{PANet}(\mathbf{O}^k)$ 。在实现中，我们采用 T5[43] 作为文本编码器，DINOv2[42] 作为图像编码器。随后，我们利用多模态因果 Q-Former[51] 融合这两种模态的特征，并将其输入分类头以输出类别概率。Q-Former 配置为 3 层，嵌入维度为 1280，交叉注意力维度为 768，8 个注意力头，32 个查询。分类头采用多层感知机（MLP）架构，由三个 MLP 层与修正线性单元（ReLU）激活函数交错组成（即 MLP→ReLU→MLP→ReLU→MLP）。分类头的输入和输出特征维度分别为 1280 和 8：1280 对应文本与图像特征的拼接维度，8 表示基元动作类型的数量。中间 MLP 层配置为 256 个输入和输出通道。详细的实现细节请参阅我们公开的代码库 PriGo。

在训练中，PANet 使用交叉熵损失进行优化，其中真实标签通过本文中的公式 (2) 获得。我们采用 AdamW 优化器，超参数为  $\beta_1 = 0.9$ ， $\beta_2 = 0.99$ ，学习率为  $lr = 5 \times 10^{-5}$ 。模型在 LIBERO 上使用单个 NVIDIA A100 GPU 进行训练，总训练时间约为 1 天。

**原始动作的统计分析。**我们进行了初步实验，分析不同设置下原始类型的分布，并根据这些统计数据为所有实验选择了一组八个原始动作。具体来说，我们观察到某些复合原始动作极为罕见，例如，抓取加推动在所有 10 个类别中仅占 0.07%。这导致了长尾分类问题，降低了整体准确率和对不频繁类别的性能。此外，过度指定原始动作可能引入歧义。例如，将旋转拆分为左旋和右旋通常是不必要的，因为在许多场景中两者都可能有效（例如，抓取手柄或杯子）。在这种情况下强制固定标签会降低策略灵活性并引入标签噪声。另外，更细粒度的原始动作会导致不同任务间原始动作分布的更大变化，从而削弱跨任务泛化能力。

例如，当旋转被拆分为顺时针和逆时针方向时，任务“拿起沙拉酱并将其放入篮子”的原始动作分布变为：{ ‘0’: 14.43%, ‘1’: 5.05%, ‘2’: 4.48%, ‘3’: 8.73%, ‘4’: 12.85%, ‘5’: 10.79%, ‘6’: 2.80%, ‘7’: 14.51%, ‘8’: 6.95%, ‘9’: 12.07%, ‘10’: 7.34% }。对于“拿起奶油奶酪并将其放入篮子”，分布变为：{ ‘0’: 13.27%, ‘1’: 5.14%, ‘2’: 7.72%, ‘3’: 10.86%, ‘4’: 10.86%, ‘5’: 5.79%, ‘6’: 11.60%, ‘7’: 14.79%, ‘8’: 14.79%, ‘9’: 12.07%, ‘10’: 7.34% }。值得注意的是，最后一个类别的分布在不同任务间变化显著。相比之下，使用原始的 10 个原始动作会产生更稳定的分布。

对于第一个任务：‘0’: 16.04%, ‘1’: 6.34%, ‘2’: 5.16%, ‘3’: 8.47%, ‘4’: 13.58%, ‘5’: 13.94%, ‘6’: 18.98%, ‘7’: 17.49%，对于第二个任务：{ ‘0’: 13.34%, ‘1’: 7.18%, ‘2’: 7.76%, ‘3’: 10.91%, ‘4’: 10.91%, ‘5’: 16.87%, ‘6’: 14.30%, ‘7’: 18.73% }。

## C 附加结果

在本节中，我们进一步评估并可视化所提出的原始动作引导方法 PriGo 在机器人操作任务上的有效性。

有两种可选策略可获得离散类别输出：选择最大概率索引或进行基于概率的采样。我们在 LIBERO 上进行了实验，以探索这两种方法对后续机器人操作的影响，结果如下

表 6。尽管采样仅带来 0.2% 的性能提升，这一增益在实际中可忽略不计。鉴于效果有限且采样引入额外计算开销，

本文在实现中采用更简单直接的极大概率索引策略。

为评估真实机器人任务上的推理开销，本文进行了墙钟时间分析，比较 PriGo 与无引导基线。在单块 NVIDIA RTX A6000 GPU 上，基线 (CogACT) 每步约需 181 毫秒，而 PriGo 将延迟增加至每步 208 毫秒，对应 15% 的开销。然而，由于每个推理周期生成  $k = 16$  个动作的序列，这产生了 77 赫兹的有效控制频率，超过了反应式操作的标准实时要求（通常约 50 赫兹）。此外，本文测量了平均任务完成时间，观察到与基线 (2.85 分钟) 相比，本文方法 (2.56 分钟) 减少了 10%。这一改进源于生成动作序列的结构一致性增强，使得子任务执行更平滑，并减少了达到目标所需的总步数。

表 6: 在 LIBERO 上四种设置 (空间、物体、目标、长时程) 下的成功率。极大概率索引 (argmax) 与基于概率的采样 (sampling) 之间的比较。

| Methods  | Spatial | Object | Goal | Long | Avg. Succ. |
|----------|---------|--------|------|------|------------|
| argmax   | 95.6    | 97.3   | 95.8 | 80.4 | 92.3       |
| sampling | 95.2    | 97.6   | 96.3 | 80.9 | 92.5       |

为说明本文引导的纠正效果，针对同一任务，本文从策略展开中选取了五个代表性帧，分别在有和没有引入 PriGo 的情况下。这些结果可视化于图 6，其中顶行显示本文 PriGo-DP 的结果，底行显示基线扩散策略 CogACT。从结果可以观察到，本文方法产生的动作序列与所需原语类型良好对齐：旋转（放置盘子）、推和释放（将碗放到盘子上）、抓取把手后释放（将杯子放入碗中）。相比之下，基线未能生成结构化的动作序列。具体而言，它缺少所需的旋转（导致盘子倒置），引入了不必要的旋转（在放置碗期间），并表现出错误的抓取行为（抓取杯子的内壁）以及在半空中过早释放（在放置杯子期间）。




图 6: 本文提出的 PriGo-DP (上行) 与原始扩散策略 (下行) 在“准备一套餐具”任务上的比较。