

基于动作分块的强化学习

Qiyang Li, Zhiyuan Zhou, Sergey Levine

UC Berkeley

{qccli,zhiyuan_zhou,svlevine}@eecs.berkeley.edu

摘要

本文提出 Q 分块（**Q-chunking**），一种简单而有效的改进强化学习（Reinforcement Learning, RL）算法的方法，适用于长时程、稀疏奖励任务。该方法专为离线到在线强化学习场景设计，旨在利用离线先验数据集最大化在线学习的样本效率。在该场景中，有效探索和样本高效学习仍是核心挑战，因为如何利用离线数据获得良好的探索策略并不明确。我们的关键洞见是，动作分块（Action Chunking）这一在模仿学习中流行的技术——在每个时间步预测未来动作序列而非单一动作——可应用于基于时序差分（Temporal Difference, TD）的强化学习方法，以缓解探索挑战。Q 分块通过在“分块”动作空间中直接运行强化学习来采用动作分块，使智能体能够（1）利用离线数据中时间一致的行为进行更有效的在线探索，以及（2）使用无偏 n 步回溯进行更稳定高效的时序差分学习。实验结果表明，Q 分块展现出强大的离线性能和在线样本效率，在一系列长时程、稀疏奖励操作任务上优于先前最佳的离线到在线方法。




图 1：Q 分块利用动作分块实现快速价值回溯和基于时间一致动作的有效探索。左：方法概览：Q 分块在时间扩展的动作空间中运行，可实现（1）高效的价值回溯和（2）通过时间一致动作进行有效探索；右：我们的方法（QC）首先在离线数据集上预训练 100 万步（灰色），然后利用在线数据再更新 100 万步（白色）。在 OGBench 的五个具有挑战性的长时程稀疏奖励领域中，我们的方法取得了强大的综合性能。代码：github.com/ColinQiyangLi/qc。

1 引言

强化学习 (Reinforcement Learning, RL) 有望仅基于奖励函数解决任意给定任务。然而, 这种对强化学习问题的简单直接表述往往不切实际: 在复杂环境中, 完全从零开始探索以学习有效策略的代价可能高得令人望而却步, 因为这要求智能体在学到良好策略之前, 先通过随机偶然成功完成任务。事实上, 即使是人类和动物也很少完全从零开始解决新任务, 而是利用过去的经验和技能。受此启发, 近期许多工作试图将先验离线数据纳入在线强化学习探索中 [28, 39, 85]。但这带来了一系列新的挑战: 离线数据的分布可能与智能体在线应遵循的策略不匹配, 从而引入分布偏移, 而且如何利用离线数据来获得良好的在线探索策略并不显而易见。

在相邻的模仿学习 (Imitation Learning, IL) 领域, 近年来广泛使用的一种方法是动作分块 (Action Chunking), 即不再训练策略根据先前数据中的状态观测预测单个动作, 而是训练策略预测一小段未来动作序列 (一个“动作块”) [90, 11]。虽然动作分块在模仿学习中有效性的完整解释仍是一个开放问题, 但其有效性至少可以部分归因于更好地处理离线数据中的非马尔可夫行为, 本质上为建模可能出现在 (例如) 人类提供的演示或不同行为混合中的复杂分布提供了更强大的工具 [90]。动作分块在强化学习中尚未被广泛使用, 这或许是因为在完全观测的马尔可夫决策过程 (MDP) 中最优策略是马尔可夫的 [74], 因此分块可能显得没有必要。

我们观察到, 尽管我们可能期望一个最终的最优马尔可夫策略, 但探索问题可以通过非马尔可夫和时序扩展的技能更好地解决, 而动作分块提供了一种非常简单且便捷的方法来实现这一点。此外, 动作分块提供了一种更好的利用离线数据的方式 (更好地处理数据中的非马尔可夫行为), 甚至通过启用无偏的 n 步备份 (其中 n 与分块长度匹配) 来提高基于时序差分 (TD) 的强化学习的稳定性和效率。因此, 结合离线数据预训练, 动作分块为缓解强化学习中的探索挑战提供了一种引人注目且非常简单的方法。

我们提出了带有动作分块的 Q 学习 (简称 Q 分块), 这是一种在离线到在线强化学习设置中改进通用基于时序差分的演员-评论家强化学习算法的方法 (图 1)。其核心思想是在动作序列层面运行强化学习——(1) 策略预测接下来 h 步的动作序列, 并以开环方式逐个执行它们, (2) 评论家接收当前状态和一个动作序列, 并估计执行整个序列而非单个动作的价值。在这个扩展动作空间上运行强化学习的好处有两方面: (1) 通过将策略正则化到表现出这种连贯性的某些先验行为数据上, 可以优化策略以生成时序连贯的动作, (2) 使用标准时序差分备份损失训练的评论家实际上执行的是 n 步备份, 没有离策略偏差 (这种偏差通常出现在朴素的 n 步回报方法中), 因为评论家考虑了完整的动作序列。

我们的主要贡献是 **QC**, 一种实用的离线到在线强化学习算法, 它由我们的 Q 分块方案实例化而来, 本质上是在分块动作空间中运行带有行为正则化的强化学习。**QC** 实现简单, 仅需训练 (1) 使用标准流匹配损失的动作分块行为策略, 以及 (2) 使用标准时序差分损失的时间扩展评论家 (算法 1)。**QC** 在六个具有挑战性的长时程、稀疏奖励领域上取得了强劲性能, 超越了先前的离线到在线方法。此外, Q 分块是一种通用方案, 可以以最小的修改应用于现有的离线到在线算法。在这项工作中, 我们通过将其应用于 FQL [58] 来展示一个这样的实例化, 得到 **QC-FQL** (算法 2), 相比原始方法有显著改进。

2 相关工作

离线到在线强化学习 方法专注于利用先前的离线数据来加速在线强化学习 [88, 71, 37, 1, 89, 91, 7, 51, 92, 39]。解决离线到在线强化学习最简单的方法是使用现有的离线强化学习算法先在离线数据上进行预训练, 然后使用相同的离线优化目标, 在包含原始离线数据和回放缓冲区数据的不断增长的数据集上继续在线训练, 该数据集

结合了原始离线数据和回放缓冲区数据 [50, 36, 33, 77, 58, 2, 42, 37]。虽然直接, 但这种朴素的方法往往导致过度悲观, 阻碍探索, 从而影响在线样本效率。一些先前的工作试图通过在线调整悲观程度来解决这个问题 [92, 51, 42, 37, 82]。然而, 这些方法可能难以调优, 有时在在线样本效率上仍不如一个简单的、良好正则化的在线强化学习算法, 该算法从头开始在离线数据和在线回放缓冲区数据上学习 [7]。我们的方法通过价值备份加速和时间连贯探索, 朝着提高离线到在线强化学习方法的样本效率迈出了一步。

动作分块 这是一种由机器人学家推广的模仿学习 (Imitation Learning, IL) 技术, 其中策略以开环方式预测并执行一系列动作 (“动作块”) [90]。动作分块已被证明能提升策略鲁棒性 [90, 23, 8], 并处理离线数据中的非马尔可夫行为 [90]。现有结合动作分块的强化学习方法通常侧重于微调通过模仿学习预训练的策略 [61]。Tian 等人 [78] 提出通过将 n 步回报与变换器 (Transformer) 集成来学习动作块上的评论家。然而, 他们的方法仅将分块应用于评论家, 仍优化单步演员。Li 等人 [38] 也观察到, 在短动作块上学习评论家可消除 n 步回报备份中的离策略偏差, 从而实现更稳定有效的价值学习。他们的工作与我们的工作存在关键差异——Li 等人 [38] 在在线回合制强化学习设置 [84, 31] 中操作, 并使用高斯策略预测运动基元 (Movement Primitive, MP) 的参数 [63, 54], 然后在每个回合开始时生成完整动作序列。相比之下, 我们在传统的离线到在线强化学习设置中操作, 并利用更具表达力的基于流匹配的策略 (我们发现高斯策略无效, 如图 2 所示) 直接在原始动作空间中预测短动作序列。Seo 和 Abbeel [65] 也在动作块上训练评论家, 并施加与 Q 分块原理一致的行为克隆损失。与我们工作的关键区别在于他们使用多级分解评论家架构 [66], 通过迭代离散化从粗到细生成和细化动作块。在每个级别, 动作空间被离散化为多个区间, Q 函数针对每个动作维度和时间步独立建模, 条件于上一较粗级别预测的整个动作块。虽然这种分解评论家设计使价值最大化动作采样可行, 但它对动作空间施加了强结构假设, 限制了每个细化级别的策略表达力。相比之下, 我们的方法不做此类假设, 从而能够推导出两种通用算法, 其中评论家和策略都直接作用于动作块, 无需分解或迭代离散化/细化。

具有时间连贯动作的探索。现有方法要么依赖通过启发式方法构建的时间相关动作噪声 [40]; 要么采用分层结构策略 (见下一段), 这类策略在在线训练中往往难以稳定; 要么使用预训练的冻结技能策略 [60, 85], 这些策略不适合进行细粒度的在线微调。本文方法使用单一网络表示策略, 以生成时间扩展的动作块, 并通过单一目标函数进行训练, 该目标函数优化稳定。本文方法中也不存在冻结的预训练组件, 从而保证了在线微调的灵活性。

分层强化学习, 选项框架。学习时间扩展动作在分层强化学习 (HRL) 文献中也被广泛研究 [14, 16, 80, 13, 35, 81, 59, 62, 49, 3, 67, 60, 22, 87]。HRL 方法通常训练一个低层策略空间, 这些策略可以直接与环境交互, 同时训练一个高层策略在这些低层策略中进行选择。这些低层策略可以是手工设计的 [12]、在线自动发现的 [16, 35, 80, 81, 49], 或使用离线技能发现方法预训练的 [54, 47, 67, 3, 70, 60, 79, 52, 28, 20, 9, 57]。选项框架提供了一种更精细且更强大的表述, 其中低层策略额外关联可学习的启动条件和终止条件, 使得低层策略的利用更加灵活 [75, 46, 10, 44, 68, 69, 32, 13, 72, 53, 19, 4, 30, 5, 6, 15]。HRL 中长期存在的挑战是其双层优化问题: 当低层和高层策略在训练过程中同时更新时, 高层策略必须优化一个移动的目标函数, 这可能导致不稳定 [49]。为缓解这一问题, 一些方法在初始预训练后保持低层策略冻结 [3, 60, 85], 以提高在线训练的稳定性。本文方法是 HRL 的一种特例, 其中低层技能以开环方式执行一系列动作。这一设计选择使我们能够将双层优化问题坍塌为时间扩展动作空间中的标准强化学习目标, 同时保留与 HRL 方法相关的许多探索优势。虽然

分层强化学习（HRL）的先前工作也探索过此类思想 [45, 17]，它们通常利用一组离散的动作序列，这些序列要么从先前经验中启发式提取，要么预先给定。相比之下，我们采用基于流匹配的表达式策略，直接参数化连续的动作序列空间，并通过强化学习在线直接训练和微调。

多步潜空间规划与搜索 是基于模型的强化学习方法中常用的一种技术，它们利用学习到的模型来优化短视界动作序列，使其朝向高回报轨迹 [53, 64]。这些方法通过在编码的潜空间上训练动力学模型来工作，模型接收潜状态和动作，预测下一个潜状态及相应的奖励值。该潜动力学模型与潜状态上的价值网络相结合，能够对从给定潜状态出发的任意动作序列，通过在潜动力学模型中简单模拟该动作序列，即时提供 Q 值的估计。相比之下，我们不学习潜动力学模型，而是训练一个 Q 网络直接估计动作序列的价值。最后，这些方法在纯在线强化学习设置下运行，而我们专注于离线到在线强化学习设置。

3 背景

离线到在线强化学习。 本文考虑一个无限时域、完全可观测的马尔可夫决策过程（MDP）， $(\mathcal{S}, \mathcal{A}, \rho, T, r, \gamma)$ ，其中 $\mathcal{S}$ 为状态空间， $\mathcal{A}$ 为动作空间， $T(s'|s, a) : \mathcal{S} \times \mathcal{A} \mapsto \Delta(\mathcal{S})$ 为转移核函数， $r(s, a) : \mathcal{S} \times \mathcal{A} \mapsto \mathbb{R}$ 为奖励函数， $\rho : \Delta(\mathcal{S})$ 为初始状态分布， $\gamma \in [0, 1)$ 为折扣因子。我们还假设存在一个先验离线数据集 $\mathcal{D}$ ，由来自 $\mathcal{M}$ 的转移轨迹 $\{(s, a, s', r)\}$ 组成。离线到在线强化学习的目标是找到一个策略 $\pi(a|s) : \mathcal{S} \mapsto \Delta(\mathcal{A})$ ，最大化期望折扣累积奖励（或折扣回报）： $\mathbb{E}_{s \sim \rho, a \sim \pi} \sum_{t=0}^{\infty} \gamma^t r(s_t, a_t)$ 。通常，离线到在线强化学习算法在两个不同阶段运行：离线阶段，策略在离线数据 $\mathcal{D}$ 上预训练；在线阶段，策略通过环境交互进一步在线微调。我们的方法遵循相同的模式。

时序差分与多步回报。 基于时序差分（TD）的强化学习算法通常学习 $Q_\theta(s, a)$ ，以近似从状态 s 和动作 a 出发，策略所能获得的最大期望折扣累积奖励，其使用的时序差分（TD）损失为 [74]：

$$L(\theta) = \left[Q_\theta(s_t, a_t) - \hat{V} \right]^2, \quad (1)$$

其中 $\hat{V}$ 是对 $Q(s_t, a_t)$ 的估计，通常选择为 $\hat{V}_1$ 步：

$$\hat{V}_{1\text{-step}} := r_t + \gamma Q_{\bar{\theta}}(s_{t+1}, a_{t+1}), \quad a_{t+1} \sim \pi_\psi(\cdot | s_{t+1}), \quad (2)$$

并且 s_t, a_t, s_{t+1}, r 从某些离线策略轨迹中采样， $\bar{\theta}$ 是 θ 的延迟版本，不允许梯度通过以保证学习稳定性。当 TD 误差被最小化时， Q_θ 收敛到策略 π_ψ 的期望折扣值。随着有效视界 $\tilde{H} = 1/(1-\gamma)$ 增大，学习会变慢，因为值只能向后传播 1 步（从 s_{t+1} 到 s_t ）。为了加速长视界值备份，一种常见策略是采样长度为 n 的轨迹片段 $(s_t, a_t, s_{t+1}, \dots, a_{t+n-1}, s_{t+n})$ ，并从中构造 n 步回报 [83, 74]：

$$\hat{V}_{n\text{-step}} := \sum_{t'=t}^{t+n-1} \left[\gamma^{t'-t} r_{t'} \right] + Q_{\bar{\theta}}(s_{t+n}, a_{t+n}), \quad a_{t+n} \sim \pi_\psi(\cdot | s_{t+n}), \quad (3)$$

其中同样 $r_t = r(s_t, a_t)$ 。这种对 $Q(s_t, a_t)$ 的值估计允许值在时间步数上以 n 倍的速度向后传播。该估计器有时被称为未校正的 n 步回报估计器 [18, 34]，因为当数据收集策略与当前策略 π_ψ 不同时它是有偏的。尽管如此，由于 n 步回报实现简单，它已被普遍采用于大规模强化学习系统 [48, 26, 29, 86]。

4 Q 分块

在本节中，我们首先描述 Q 分块的两个主要设计原则：（1）在时间扩展动作空间（动作块空间）上进行 Q 学习，以及（2）在该扩展动作空间中的行为约束，随后给出 Q 分块（**QC**、**QC-FQL**）作为有效的基于 TD 的离线到在线强化学习算法的实用实现。

4.1 时间扩展动作空间上的 Q 学习

Q 分块的第一个设计原则是在时间扩展动作空间上应用 Q 学习。与训练 Q 函数 $Q(s_t, a_t)$ 和策略 $\pi(a_t | s_t)$ 的普通 1 步基于 TD 的演员-评论家方法不同，我们改为用 h 个连续动作的跨度来训练评论家和演员：¹

$$Q\text{-Chunking Policy: } \pi_\psi(\mathbf{a}_{t:t+h} | s_t) := \pi_\psi(a_t, a_{t+1}, \dots, a_{t+h-1} | s_t)$$

$$Q\text{-Chunking Critic: } Q_\theta(s_t, \mathbf{a}_{t:t+h}) := Q_\theta(s_t, a_t, a_{t+1}, \dots, a_{t+h-1})$$

在实践中，这涉及在由随机状态 s_t 、动作序列 $\mathbf{a}_{t:t+h}$ 及其后续状态、以及未来 h 步的状态 s_{t+h} 组成的转移批次上更新评论家与行动者。具体而言，我们使用以下时序差分损失来训练 Q_θ ：

$$L(\theta) = \mathbb{E}_{s_t, \mathbf{a}_{t:t+h}, s_{t+h} \sim \mathcal{D}} \left[\left(Q_\theta(s_t, \mathbf{a}_{t:t+h}) - \sum_{t'=0}^{h-1} \gamma^{t'} r_{t+t'} - \gamma^h Q_{\bar{\theta}}(s_{t+h}, \mathbf{a}_{t+h:t+2h}) \right)^2 \right] \quad (4)$$

其中 $\mathbf{a}_{t+h:t+2h} \sim \pi_\psi(\cdot | s_{t+h})$ 和 $\bar{\theta}$ 是目标网络参数，通常是 θ [25] 的指数移动平均。

上述时序差分损失与方程 3 中的 n 步回报具有显著相似性（其中 n 与 h ）匹配），但存在一个关键差异—— Q 步回报备份中使用的 n 函数仅接收一个动作（在时间步 t ），而我们的 Q 函数接收整个动作序列。这一差异的启示在写出标准 1 步 TD, n 步回报与 Q 分块的时序差分备份方程后能够得到最佳解释：

$$Q(s_t, a_t) \leftarrow r_t + \gamma Q(s_{t+1}, a_{t+1}) \quad (\text{standard 1-step TD}) \quad (5)$$

$$Q(s_t, a_t) \leftarrow \underbrace{\sum_{t'=t}^{t+h-1} \left[\gamma^{t'-t} r_{t'} \right]}_{\text{biased}} + \gamma^h Q(s_{t+h}, a_{t+h}), \quad (n\text{-step return, } n = h) \quad (6)$$

$$Q(s_t, \mathbf{a}_{t:t+h}) \leftarrow \underbrace{\sum_{t'=t}^{t+h-1} \left[\gamma^{t'-t} r_{t'} \right]}_{\text{unbiased}} + \gamma^h Q(s_{t+h}, \mathbf{a}_{t+h:t+2h}). \quad (\text{Q-chunking}) \quad (7)$$

对于标准 1 步时序差分，每次备份步骤仅将价值回传 1 个时间步。 n 步回报将价值回传速度提升 $h \times$ 倍，但当 $s_{t:t+h}$ 和 $\mathbf{a}_{t:t+h}$ 为离策略时，可能遭受有偏价值估计问题 [18]。这是因为来自数据集或回放缓冲区的 n 步奖励 $r_{t:t+h}$ 的折现和不再是当前策略 π 下期望 n 步奖励的无偏估计。Q 分块价值备份与 n 步回报类似，每一步也将价值回传 h 个时间步，但不会遭受这种有偏估计问题。与 n 步回报将价值传播到 1 步 Q 函数不同，Q 分块备份将价值传播回一个 h 步 Q 函数，该函数接收与获得 n 步奖励 $r_{t:t+h}$ 完全相同的动作，从而消除了有偏价值估计。我们在定理 A.1 中形式化了这一论证。因此，Q 分块价值备份在保持无偏价值估计的同时，享有价值传播的加速。

4.2 用于时间连贯探索的行为约束

Q 分块的第二个设计原则通过在 π_ψ 的目标中利用行为约束来解决动作不连贯问题：

$$L(\psi) = -\mathbb{E}_{\mathbf{a}_{t:t+h} \sim \pi_\psi(\cdot | s_t)} [Q_\theta(s_t, \mathbf{a}_{t:t+h})], \text{ s.t. } D(\pi_\psi(\mathbf{a}_{t:t+h} | s_t), \pi_\beta(\mathbf{a}_{t:t+h} | s_t)) \leq \varepsilon \quad (8)$$

其中我们将 $\pi_\beta(\mathbf{a}_{t:t+h} | s_t)$ 表示为离线数据 $\mathcal{D}$ 中的行为分布， D 为某种距离度量，用于衡量学习到的策略 π 偏离 π_β 的程度。

直观而言，对时间扩展动作序列施加行为约束，使我们能够利用离线数据集中时间连贯的动作序列。这在 1 中尤为有利。我们使用 $\mathbf{a}_{t:t+h}$ （或简写为 $\mathbf{a}_t$ ）来表示 h 个连续动作的拼接： $\mathbb{R}^{Ah}$ ，以便于符号表示。对于 $s_{t:t+h}$ 和 $r_{t:t+h}$ 也类似。 $[a_t \dots a_{t+h-1}] \in$




图 2: 在在线强化学习中天真地使用动作分块与高斯策略会导致性能不佳。(1) RLPD 在离线数据和在线回放缓冲区 [7] 上运行在线强化学习。(2) RLPD-AC 与 RLPD 算法相同, 但在时间扩展动作空间 (动作块大小为 5) 中运行。(3) QC-RLPD 额外在演员上使用行为克隆损失 (4 个种子)。

在时间扩展动作空间中相较于原始动作空间, 因为离线数据往往表现出非马尔可夫结构 (例如, 来自脚本策略 [56]、人类遥操作员 [43] 或子任务的噪声专家策略 [56, 21]), 这种结构无法被马尔可夫行为约束很好地捕捉。时间上连贯的动作对于在线探索是可取的, 因为它们类似于时间扩展的技能 (例如, 为导航朝某个方向移动、为越过障碍物而进行的跳跃动作), 有助于以结构化的方式穿越环境, 而不是使用随机动作, 后者往往导致数据集中在初始状态附近。对动作分块策略施加行为约束是一种非常简单的近似提取技能的方法, 无需像基于技能的方法通常所需的那样训练具有双层结构的策略 (更多讨论见第 2 节)。我们观察到, 带有此类行为约束的 Q 分块能够以时间上连贯的动作进行探索 (见第 5.3 节), 从而缓解探索挑战。

4.3 实用实现

Q 分块的一个关键实现挑战是施加良好的行为约束, 以在动作序列层面捕捉非马尔可夫行为。施加良好行为约束的前提之一是策略能够捕捉复杂的行为分布 (例如, 使用流或扩散策略)。高斯策略是在在线强化学习算法中的默认选择, 但不足以胜任。事实上, 如果我们天真地采用现成的在线算法, 例如 RLPD [7], 并应用带有行为克隆损失的 Q 分块, 我们发现它通常表现不佳 (图 2)。

为施加良好的行为约束, 我们首先使用流匹配目标 [41] 训练行为克隆流策略以捕捉行为分布。该流策略由状态条件速度场预测模型 $f(s, z, u) : \mathcal{S} \times \mathbb{R}^{A_h} \times [0, 1] \mapsto \mathbb{R}^{A_h}$ 参数化, 我们将 $f_\xi(\cdot | s)$ 表示为流策略参数化的动作分布, 作为离线数据中真实行为分布的近似 ($f_\xi \approx \pi_\beta$)。现在, 我们准备介绍主要方法:

质量控制: 带隐式 KL 行为约束的 Q 分块。我们通过学到的行为分布对策略施加 KL 约束:

$$D_{\text{KL}}(\pi_\psi \| f_\xi(\cdot | s)) \leq \varepsilon \quad (9)$$

虽然可以将 KL 作为损失的一部分, 但估计流模型的 KL 散度或对数概率在实践中具有挑战性。相反, 我们使用最佳 N 采样 [73] 来最大化 Q 值, 同时隐式施加此 KL 约束。实际上, 这涉及首先从学到的行为策略 $f_\xi(\cdot | s)$ 中采样 N 个动作块,

$$\{\mathbf{a}^1, \mathbf{a}^2, \dots, \mathbf{a}^N\} \sim f_\xi(\cdot | s),$$

然后选择使时间扩展 Q 函数最大化的动作块样本:

$$\mathbf{a}^* \leftarrow \arg \max_{\mathbf{a} \in \{\mathbf{a}^1, \mathbf{a}^2, \dots, \mathbf{a}^N\}} Q(s, \mathbf{a})$$

先前工作表明，最佳 N 采样对原始分布 [27] 的 KL 散度具有闭式上界：

$$D_{\text{KL}}(\mathbf{a}^* \| f_{\xi}(\cdot | s)) \leq \log N - \frac{N-1}{N}, \quad (10)$$

这近似隐式满足 KL 约束（方程 9）。调整 N 的值直接对应约束强度。

由于我们用最佳 N 采样近似策略优化（方程 8），可以完全避免单独参数化策略 π_{ψ} ，仅从行为策略 $f_{\xi}(\cdot | s_t)$ 采样。特别地，我们使用最佳 N 采样生成动作，既用于（1）与环境交互，也用于（2）按照 Ghasemipour 等人 [24] 的方法在 TD 备份中提供动作样本。因此，我们的算法只有一个额外的损失函数：

$$L(\theta) = \mathbb{E}_{\substack{s_t, \mathbf{a}_t \sim D \\ \{\mathbf{a}_{t+h}^i\}_{i=1}^N \sim f_{\xi}(\cdot | s_{t+h})}} \left[\left(Q_{\theta}(s_t, \mathbf{a}_t) - \sum_{t'=0}^{h-1} \gamma^{t'} r_{t+t'} - \gamma^h Q_{\bar{\theta}}(s_{t+h}, \mathbf{a}_{t+h}^*) \right)^2 \right] \quad (11)$$

where again $\mathbf{a}_{t+h}^* := \arg \max_{\mathbf{a} \in \{\mathbf{a}_{t+h}^i\}} Q(s, \mathbf{a})$.

虽然质量控制（QC）简单且易于实现，但它确实会带来与最佳 N 采样相关的一些额外计算成本。在我们的实验中，我们尝试了另外两种变体（**QC-FQL** 和 **QC-IFQL**），它们利用了更便宜的现成离线/离线到在线强化学习方法（分别为 FQL 和 IFQL[58]）。我们在下面展示 FQL 版本，因为它在经验上表现更好。

QC-FQL：具有 2-Wasserstein 距离行为约束的 Q 分块。 对于此方法的变体，我们利用最优传输框架，通过学到的行为策略 $f_{\xi}(\cdot | s)$ 施加 Wasserstein 距离（ W_2 ）约束）：

$$W_2(\pi_{\psi}, f_{\xi}(\cdot | s)) \leq \varepsilon \quad (12)$$

遵循 FQL[58]，我们用噪声条件动作预测模型 $\mu_{\psi}(s, \mathbf{z}) : \mathcal{S} \times \mathbb{R}^{A_h} \mapsto \mathbb{R}^{A_h}$ 参数化策略 π_{ψ} ，该模型在一次网络前向传播中直接从高斯噪声输出动作。该噪声条件策略被训练以最大化 Q 分块评论家 $Q_{\theta}(s_t, \mathbf{a}_{t:t+h})$ ，同时通过 BC 损失被正则化以接近行为克隆流匹配策略，该 BC 损失被证明是平方 2-Wasserstein 距离的上界 [58]：

$$L(\psi) = \mathbb{E}_{s_t \sim \mathcal{D}, \mathbf{z}^0 \sim \mathcal{N}(0, \mathbf{I}_{A_h})} \left[\alpha \|\mathbf{z}^1 - \mu_{\psi}(s_t, \mathbf{z}^0)\|_2^2 - Q(s_t, \mu_{\psi}(s_t, \mathbf{z})) \right] \quad (13)$$

$$\geq \mathbb{E}_{s_t \sim \mathcal{D}, \mathbf{z}^0 \sim \mathcal{N}(0, \mathbf{I}_{A_h})} \left[\alpha W_2(\pi_{\psi}(\cdot | s_t), f_{\xi}(\cdot | s_t))^2 - Q(s_t, \mu_{\psi}(s_t, \mathbf{z})) \right], \quad (14)$$

其中 $\mathbf{z}^1$ 是从 $u = 0$ 到 $u = 1$ 遵循 $d\mathbf{z}^u = f_{\xi}(s_t, \mathbf{z}^u, u)du$ 的 ODE 解（初始值 $\mathbf{z}^0$ 从单位高斯采样）。实值超参数 α 直接控制蒸馏损失的大小。最后，TD 损失与前一节相同，唯一区别在于我们如何参数化策略：

$$L(\theta) = \mathbb{E}_{s_t, \mathbf{a}_t, s_{t+h} \sim \mathcal{D}, \mathbf{z}} \left[\left(Q_{\theta}(s_t, \mathbf{a}_t) - \sum_{t'=0}^{h-1} \gamma^{t'} r_{t+t'} - \gamma^h Q_{\bar{\theta}}(s_{t+h}, \mu_{\psi}(s_{t+h}, \mathbf{z})) \right)^2 \right] \quad (15)$$

再次强调 $\mathbf{z} \sim \mathcal{N}(0, \mathbf{I}_{A_h})$ 。

离线到在线强化学习的考虑。 由于我们方法的两种变体都使用行为约束（QC 的隐式 KL，QC-FQL 的显式 W_2 ），我们也可以直接运行它们进行离线强化学习预训练。对于离线和在线训练，我们使用相同的行为约束强度（QC 为 *e.g.*, N ，QC-FQL 为 α ）。我们对离线和在线训练使用相同的算法，唯一区别在于是否存在环境交互。有关在线训练期间 QC 和 QC-FQL 的概述，请参见第 C 节、算法 1 和算法 2。

5 实验结果

我们进行了大量实验，以分析我们的方法在一系列长时程、稀疏奖励领域中的经验有效性。具体而言，我们将回答以下问题：

		puzzle-3x3-sparse (5 tasks)	scene-sparse (5 tasks)	cube-double (5 tasks)	cube-triple (5 tasks)	cube-quadruple (5 tasks)	overall (25 tasks)
From Scratch (1-step TD)	RLPD	- → 100	- → 94	- → 99	- → 41	- → 0	- → 67
	RLPD-AC	- → 100	- → 91	- → 96	- → 11	- → 7	- → 61
	SUPE-GT	- → 100	- → 92	- → 67	- → 0	- → 0	- → 52
Gaussian (1-step TD)	IQL	0 → 20	0 → 39	0 → 0	0 → 0	0 → 0	0 → 12
	ReBRAC	55 → 100	11 → 99	3 → 30	0 → 0	1 → 20	14 → 50
Flow (1-step TD)	IFQL	98 → 97	68 → 74	11 → 59	0 → 3	0 → 0	36 → 47
	FQL	100 → 100	58 → 95	29 → 76	1 → 18	0 → 3	37 → 58
	BFN	98 → 100	85 → 99	68 → 79	4 → 23	1 → 12	51 → 63
Flow (n-step TD)	IFQL-n	94 → 100	68 → 92	5 → 29	0 → 0	0 → 0	34 → 44
	FQL-n	98 → 100	18 → 70	11 → 77	0 → 1	7 → 36	27 → 57
	BFN-n	58 → 90	57 → 97	11 → 65	0 → 0	0 → 0	25 → 50
Q-chunking (Ours)	QC-IFQL	100 → 100	83 → 98	12 → 78	0 → 0	1 → 19	39 → 59
	QC-FQL	63 → 100	84 → 99	39 → 100	4 → 53	1 → 77	38 → 86
	QC	100 → 100	84 → 99	67 → 98	6 → 64	4 → 73	52 → 86

表 1: OGBench 离线到在线强化学习结果汇总表。对于每个单元格，我们报告了经过 100 万训练步后的离线性能，以及再经过 100 万额外在线步后的在线性能。每列中最佳方法以粗体和颜色突出显示。Q 分块方法在在线训练结束时优于所有先前方法。完整结果见表 6（完整表格）和图 10（单独图表）。




图 3: Robomimic 结果。QC 在所有三个 robomimic 任务中均取得了强劲性能。前 100 万步为离线训练，后 100 万步为在线训练，每个训练步对应一个环境步（5 个随机种子）。

（问题 1）与先前的离线到在线强化学习方法相比，Q 分块方法的表现如何？

（问题 2）为什么动作分块有助于在线学习？

（问题 3）分块长度、评论家集成规模以及更新与数据比率如何影响性能？

5.1 环境与数据集

我们考虑了六个稀疏奖励的机器人操作领域，任务难度各异。其中包括来自 OGBench 的 5 个领域（每个领域 5 个任务）[55]，即场景稀疏、3x3 稀疏拼图、双/三/四立方体，以及来自 robomimic 的 3 个任务 [43]。对于 OGBench，我们使用默认的游玩风格数据集，但四立方体任务除外，该任务我们使用了更大的 1 亿规模数据集。对于 robomimic，我们使用多人数据集。更多细节见附录 B。

5.2 比较

我们与先前加速价值备份的方法以及先前最佳的离线到在线强化学习方法进行了比较。下面简要介绍这些方法，更多细节见第 C 节。

BFN（最佳- N ） 是我们提出的一个基线，它将期望最大化 Q 算子 [24] 与表达力强的行为策略略相结合。BFN 在原始动作空间中运行，并使用最佳- N 采样从 N 个动作中选出使当前 Q 值最大化的动作。该基线作为消融实验，用于分离 QC 中 Q 分块带来的益处。




图 5: 训练早期的末端执行器运动以及 cube-triple-task3 上的时间连贯性分析。左图: 在最初 1000 个环境步骤中, 与 BFN 相比, **QC** 覆盖了更多样化的状态。右图: 与 BFN 相比, **QC** 在末端执行器上表现出更高的时间连贯性。

FQL [58] 是最近提出的一种离线强化学习方法, 在离线以及离线到在线强化学习方面均取得了强劲的性能。该基线作为消融实验, 用于分离 **QC-FQL** 中 Q 分块带来的益处。

BFN-n/FQL-n。这些基线与 BFN/FQL 相同, 但使用 n 步备份配合 $n > 1$ (方程 3), 而非标准的 1 步 TD 备份。该基线享有价值备份加速的优势, 但不使用分块评论家或行动者, 可能受到偏差问题的影响。

RLPD [7], RLPD-AC。RLPD 是一种样本高效的强化学习算法, 将离线数据视为额外的离策略数据, 并从头开始在线学习。**RLPD-AC** 与 RLPD 相同, 但在时间扩展的动作空间上运行。两者均不使用行为约束。

本文还与 **SUPE-GT [85]** 进行比较, 后者是最近提出的基于技能的方法, 专为离线到在线强化学习设计。原始方法通过奖励模型和奖励加成本来处理无标签数据集。本文通过直接使用真实奖励将其适配到当前设置。

最后, 本文与额外基线进行比较: **IQL [33]**、**ReBRAC [76]**、**IFQL (Park 等人 [58])** 中实现的基线, 将 **IQL** 与拒绝采样策略提取相结合) 以及 **IFQL-n** (使用 n 步回报备份的 IFQL)。

5.3 本文方法相比先前的离线到在线强化学习方法表现如何?

本文在表 1 (OGBench) 中报告所有 Q 分块方法和基线的性能, 并在图 3 (robomimic) 中报告选择性 (强) 子集。**QC** 在离线阶段取得有竞争力的性能, 通常匹配或有时超越最佳先前方法。在线阶段, **QC** 展现出强大的样本效率, 尤其是在两个最难的 OGBench 领域 (立方体三倍/四倍) 上, 大幅超越所有先前方法 (尤其在立方体四倍上)。此外, 在 OGBench 领域, 所有 Q 分块方法 (**QC**、**QC-FQL**、**QC-IFQL**) 均优于其对应的 1 步 TD 对应方法 (BFN、FQL、IFQL) 及其对应的 n 步回报对应方法 (BFN-n、FQL-n、IFQL-n)。类似趋势在 robomimic 任务上延续, 如图 4 所示。在 OGBench 和 robomimic 上, 不使用分块评论家或策略的 n 步回报基线, 其性能显著差于 Q 分块方法。




图 4: robomimic 上的 n 步回报消融。两种 Q 分块方法均一致优于其 n 步和 1 步 TD 对应方法 (5 个种子)。

5.4 动作分块为何有助于探索?

我们在第 4.2 节中假设, 动作分块策略能产生时间上更连贯的动作, 从而带来更好的状态覆盖和探索效果。本节通过实验研究这一假设在多大程度上成立。我们首先可视化训练初期 **QC** 和 BFN 的末端执行器运动 (图 5 左)。BFN 的轨迹包含许多停顿 (表现为一个非常大且密集的




图 6：敏感性分析：动作块大小（ h ）、评论家集成规模（ K ）和更新数据比（UTD）。左：在所有 5 个立方体三任务（5 个种子）上使用不同 h 的 **QC-FQL**。使用 $h = 1$ 的 **QC-FQL** 等同于 **FQL**。中：将集成规模增加到 $K = 10$ 可提升 **QC** 和 **BFN** 在立方体三任务 3（5 个种子）上的性能。右：在立方体三任务 3（5 个种子）上使用 UTD 为 5 的 **QC**。我们仅报告在线阶段结果，因为所有方法在离线阶段的成功率都接近零。

可视化中心附近的聚类），尤其是在末端执行器下降以拾取立方体时。相比之下，**QC** 的停顿更少（聚类更少且更浅），并且在末端执行器空间中具有更多样化的状态覆盖。我们在附录 E 的图 8 和图 9 中提供了更多示例。为了定量衡量动作的时间连贯性，我们在整个训练过程中每 5 个时间步记录一次三维末端执行器位置： $\{x_0^{\text{ef}}, x_5^{\text{ef}}, \dots\}$ ，并计算相邻两个末端执行器位置差向量的平均 L_2 范数。如果存在任何停顿或抖动运动，该平均范数会很小，因此它是衡量动作时间连贯性的良好指标。如图 5（右）所示，与 **BFN** 相比，**QC** 在整个训练过程中表现出更高的动作时间连贯性。这表明 Q 分块提高了动作的时间连贯性，从而解释了 Q 分块带来的样本效率提升。

5.5 动作块长度、评论家集成规模和 UTD 比率如何影响性能？

在图 6（左）中，我们考察了 **QC-FQL** 在立方体-三元组领域上不同动作块长度（ $h \in \{1, 5, 10, 25, 50\}$ ）的性能。增加块长度有助于提升性能，直至 $h = 10$ ，此后渐近性能开始下降。尽管 $h = 25$ 显示出更快的早期学习速度，但在在线微调结束时未能达到与 $h = 10$ 相同的性能。更大的块长度（ $h = 50$ ）则完全无法取得成功。我们推测，过大的块尺寸要么过度损害策略的反应性，要么使策略学习过于困难，因为网络必须一次性预测更长的动作序列。我们在所有其他实验中使用 $h = 5$ ，因为 $h = 5$ 通常表现良好且运行成本更低。我们还在图 14 中给出了各任务的细分结果，并在图 15 中给出了立方体-四元组上的额外消融结果。在图 6（中）中，我们研究了评论家集成规模对方法性能的影响。使用 10 个评论家同时改善了 **QC** 和 **BFN**。我们在其他实验中使用 $K = 2$ ，因为其运行成本低。使用 $K = 10$ 可能使 Q 分块在我们所考虑的基准任务上表现得更好。最后，提高更新数据比（UTD）并未改善 **QC** 的样本效率（图 6，右）。

6 讨论

我们展示了如何通过一种简单的方法将动作分块集成到离线到在线强化学习智能体中。我们的方法加速了价值备份，并通过时间上连贯的动作更有效地进行在线探索。因此，它在一系列具有挑战性的长时程任务上优于先前的离线到在线方法。我们的工作朝着训练非马尔可夫策略以实现从先前离线数据进行有效在线探索迈出的一步。仍存在若干挑战，为未来研究开辟了有前景的方向。首先，我们的方法使用固定的动作块，但除了任务特定的超参数调优外，如何选择该尺寸尚不清楚。一个自然的后续步骤是开发自动确定块边界的机制。其次，动作分块仅代表非马尔可夫策略的一个有限子类，在需要高频控制反馈回路的环境中可能表现不佳。开发用于训练更通用的非马尔可夫策略以进行在线探索的实用技术，将进一步改善离线到在线强化学习算法的在线样本效率。

致谢

本研究部分得到了 RAI 和 ONR N00014-22-1-2773 的资助。本研究使用了加州大学伯克利分校伯克利研究计算项目提供的 Savio 计算集群资源。我们感谢 Seohong Park 为 cube-quadruple 提供了代码基础设施和 1 亿数据集。我们还要感谢 Ameesh Shah、Chuer Pan、Oleg Rybkin、Andrew Wagenmaker、Seohong Park、Yifei Zhou、Fangchen Liu、William Chen 就方法进行的讨论以及对论文早期草稿的反馈。我们还要感谢 Chongyi Zheng 和 Hyunwoo Park 指出论文中的笔误。最后，我们感谢 NeurIPS 评审委员会提出的深思熟虑的意见和建议。

参考文献

- [1] Rishabh Agarwal, Max Schwarzer, Pablo Samuel Castro, Aaron C Courville, and Marc Bellemare. Reincarnating reinforcement learning: Reusing prior computation to accelerate progress. In S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, and A. Oh, editors, *Advances in Neural Information Processing Systems*, volume 35, pages 28955–28971. Curran Associates, Inc., 2022.
- [2] Rishabh Agarwal, Max Schwarzer, Pablo Samuel Castro, Aaron C Courville, and Marc Bellemare. Reincarnating reinforcement learning: Reusing prior computation to accelerate progress. *Advances in neural information processing systems*, 35:28955–28971, 2022.
- [3] Anurag Ajay, Aviral Kumar, Pulkit Agrawal, Sergey Levine, and Ofir Nachum. OPAL: Offline primitive discovery for accelerating offline reinforcement learning. In *International Conference on Learning Representations*, 2021. URL <https://openreview.net/forum?id=V69LGwJ01IN>.
- [4] Pierre-Luc Bacon, Jean Harb, and Doina Precup. The option-critic architecture. In *Proceedings of the AAAI conference on artificial intelligence*, volume 31, 2017.
- [5] Akhil Bagaria and George Konidaris. Option discovery using deep skill chaining. In *International Conference on Learning Representations*, 2019.
- [6] Akhil Bagaria, Ben Abbatematteo, Omer Gottesman, Matt Corsaro, Sreehari Rammohan, and George Konidaris. Effectively learning initiation sets in hierarchical reinforcement learning. *Advances in Neural Information Processing Systems*, 36, 2024.
- [7] Philip J Ball, Laura Smith, Ilya Kostrikov, and Sergey Levine. Efficient online reinforcement learning with offline data. In *International Conference on Machine Learning*, pages 1577–1594. PMLR, 2023.
- [8] Homanga Bharadhwaj, Jay Vakil, Mohit Sharma, Abhinav Gupta, Shubham Tulsiani, and Vikash Kumar. Roboagent: Generalization and efficiency in robot manipulation via semantic augmentations and action chunking. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 4788–4795. IEEE, 2024.
- [9] Boyuan Chen, Chuning Zhu, Pulkit Agrawal, Kaiqing Zhang, and Abhishek Gupta. Self-supervised reinforcement learning that transfers using random features. *Advances in Neural Information Processing Systems*, 36, 2024.
- [10] Nuttapon Chentanez, Andrew Barto, and Satinder Singh. Intrinsically motivated reinforcement learning. *Advances in neural information processing systems*, 17, 2004.
- [11] Cheng Chi, Zhenjia Xu, Siyuan Feng, Eric Cousineau, Yilun Du, Benjamin Burchfiel, Russ Tedrake, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. *The International Journal of Robotics Research*, page 02783649241273668, 2023.
- [12] Murtaza Dalal, Deepak Pathak, and Russ R Salakhutdinov. Accelerating robotic reinforcement learning via parameterized action primitives. *Advances in Neural Information Processing Systems*, 34:21847–21859, 2021.

- [13] Christian Daniel, Gerhard Neumann, Oliver Kroemer, and Jan Peters. Hierarchical relative entropy policy search. *Journal of Machine Learning Research*, 17(93):1–50, 2016.
- [14] Peter Dayan and Geoffrey E Hinton. Feudal reinforcement learning. *Advances in neural information processing systems*, 5, 1992.
- [15] Anita de Mello Koch, Akhil Bagaria, Bingnan Huo, Zhiyuan Zhou, Cameron Allen, and George Konidaris. Learning transferable sub-goals by hypothesizing generalizing features. 2025.
- [16] Thomas G Dietterich. Hierarchical reinforcement learning with the maxq value function decomposition. *Journal of artificial intelligence research*, 13:227–303, 2000.
- [17] Ishan P Durugkar, Clemens Rosenbaum, Stefan Dernbach, and Sridhar Mahadevan. Deep reinforcement learning with macro-actions. *arXiv preprint arXiv:1606.04615*, 2016.
- [18] William Fedus, Prajit Ramachandran, Rishabh Agarwal, Yoshua Bengio, Hugo Larochelle, Mark Rowland, and Will Dabney. Revisiting fundamentals of experience replay. In *International conference on machine learning*, pages 3061–3071. PMLR, 2020.
- [19] Roy Fox, Sanjay Krishnan, Ion Stoica, and Ken Goldberg. Multi-level discovery of deep options. *arXiv preprint arXiv:1703.08294*, 2017.
- [20] Kevin Frans, Seohong Park, Pieter Abbeel, and Sergey Levine. Unsupervised zero-shot reinforcement learning via functional reward encodings. In Ruslan Salakhutdinov, Zico Kolter, Katherine Heller, Adrian Weller, Nuria Oliver, Jonathan Scarlett, and Felix Berkenkamp, editors, *Proceedings of the 41st International Conference on Machine Learning*, volume 235 of *Proceedings of Machine Learning Research*, pages 13927–13942. PMLR, 21–27 Jul 2024. URL <https://proceedings.mlr.press/v235/frans24a.html>.
- [21] Justin Fu, Aviral Kumar, Ofir Nachum, George Tucker, and Sergey Levine. D4RL: Datasets for deep data-driven reinforcement learning. *arXiv preprint arXiv:2004.07219*, 2020.
- [22] Jonas Gehring, Gabriel Synnaeve, Andreas Krause, and Nicolas Usunier. Hierarchical skills for efficient exploration. *Advances in Neural Information Processing Systems*, 34:11553–11564, 2021.
- [23] Abraham George and Amir Barati Farimani. One act play: Single demonstration behavior cloning with action chunking transformers. *arXiv preprint arXiv:2309.10175*, 2023.
- [24] Seyed Kamyar Seyed Ghasemipour, Dale Schuurmans, and Shixiang Shane Gu. Emaq: Expected-max q-learning operator for simple yet effective offline and online rl. In *International Conference on Machine Learning*, pages 3682–3691. PMLR, 2021.
- [25] Tuomas Haarnoja, Aurick Zhou, Pieter Abbeel, and Sergey Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *International conference on machine learning*, pages 1861–1870. PMLR, 2018.
- [26] Matteo Hessel, Joseph Modayil, Hado Van Hasselt, Tom Schaul, Georg Ostrovski, Will Dabney, Dan Horgan, Bilal Piot, Mohammad Azar, and David Silver. Rainbow: Combining improvements in deep reinforcement learning. In *Proceedings of the AAAI conference on artificial intelligence*, volume 32, 2018.
- [27] Jacob Hilton. Kl divergence of max-of-n, 2023. URL https://www.jacobh.co.uk/bon_kl.pdf.
- [28] Hao Hu, Yiqin Yang, Jianing Ye, Ziqing Mai, and Chongjie Zhang. Unsupervised behavior extraction via random intent priors. In *Thirty-seventh Conference on Neural Information Processing Systems*, 2023. URL <https://openreview.net/forum?id=4vGVQVz5KG>.
- [29] Steven Kapturowski, Georg Ostrovski, John Quan, Remi Munos, and Will Dabney. Recurrent experience replay in distributed reinforcement learning. In *International conference on learning representations*, 2018.
- [30] Taesup Kim, Sungjin Ahn, and Yoshua Bengio. Variational temporal abstraction. *Advances in Neural Information Processing Systems*, 32, 2019.

- [31] Jens Kober and Jan Peters. Policy search for motor primitives in robotics. *Advances in neural information processing systems*, 21, 2008.
- [32] George Dimitri Konidaris. *Autonomous robot skill acquisition*. University of Massachusetts Amherst, 2011.
- [33] Ilya Kostrikov, Ashvin Nair, and Sergey Levine. Offline reinforcement learning with implicit Q-learning. *arXiv preprint arXiv:2110.06169*, 2021.
- [34] Tadashi Kozuno, Yunhao Tang, Mark Rowland, Rémi Munos, Steven Kapturowski, Will Dabney, Michal Valko, and David Abel. Revisiting peng’s $q(\lambda)$ for modern reinforcement learning. In *International Conference on Machine Learning*, pages 5794–5804. PMLR, 2021.
- [35] Tejas D Kulkarni, Karthik Narasimhan, Ardavan Saeedi, and Josh Tenenbaum. Hierarchical deep reinforcement learning: Integrating temporal abstraction and intrinsic motivation. *Advances in neural information processing systems*, 29, 2016.
- [36] Aviral Kumar, Aurick Zhou, George Tucker, and Sergey Levine. Conservative Q-learning for offline reinforcement learning. *Advances in Neural Information Processing Systems*, 33:1179–1191, 2020.
- [37] Seunghyun Lee, Younggyo Seo, Kimin Lee, Pieter Abbeel, and Jinwoo Shin. Offline-to-online reinforcement learning via balanced replay and pessimistic Q-ensemble. In *Conference on Robot Learning*, pages 1702–1712. PMLR, 2022.
- [38] Ge Li, Dong Tian, Hongyi Zhou, Xinkai Jiang, Rudolf Lioutikov, and Gerhard Neumann. TOP-ERL: Transformer-based off-policy episodic reinforcement learning. In *The Thirteenth International Conference on Learning Representations*, 2025. URL <https://openreview.net/forum?id=N4NhVN30ph>.
- [39] Qiyang Li, Jason Zhang, Dibya Ghosh, Amy Zhang, and Sergey Levine. Accelerating exploration with unlabeled prior data. *Advances in Neural Information Processing Systems*, 36, 2024.
- [40] Timothy P Lillicrap, Jonathan J Hunt, Alexander Pritzel, Nicolas Heess, Tom Erez, Yuval Tassa, David Silver, and Daan Wierstra. Continuous control with deep reinforcement learning. *arXiv preprint arXiv:1509.02971*, 2015.
- [41] Xingchao Liu, Chengyue Gong, and Qiang Liu. Flow straight and fast: Learning to generate and transfer data with rectified flow. *arXiv preprint arXiv:2209.03003*, 2022.
- [42] Yicheng Luo, Jackie Kay, Edward Grefenstette, and Marc Peter Deisenroth. Finetuning from offline reinforcement learning: Challenges, trade-offs and practical solutions. *arXiv preprint arXiv:2303.17396*, 2023.
- [43] Ajay Mandlekar, Danfei Xu, Josiah Wong, Soroush Nasiriany, Chen Wang, Rohun Kulkarni, Li Fei-Fei, Silvio Savarese, Yuke Zhu, and Roberto Martín-Martín. What matters in learning from offline human demonstrations for robot manipulation. In *arXiv preprint arXiv:2108.03298*, 2021.
- [44] Shie Mannor, Ishai Menache, Amit Hoze, and Uri Klein. Dynamic abstraction in reinforcement learning via clustering. In *Proceedings of the twenty-first international conference on Machine learning*, page 71, 2004.
- [45] Amy McGovern and Richard S Sutton. Macro-actions in reinforcement learning: An empirical analysis. 1998.
- [46] Ishai Menache, Shie Mannor, and Nahum Shimkin. Q-cut—dynamic discovery of sub-goals in reinforcement learning. In *Machine Learning: ECML 2002: 13th European Conference on Machine Learning Helsinki, Finland, August 19–23, 2002 Proceedings 13*, pages 295–306. Springer, 2002.
- [47] Josh Merel, Leonard Hasenclever, Alexandre Galashov, Arun Ahuja, Vu Pham, Greg Wayne, Yee Whye Teh, and Nicolas Heess. Neural probabilistic motor primitives for humanoid control. *arXiv preprint arXiv:1811.11711*, 2018.

- [48] Volodymyr Mnih, Adria Puigdomenech Badia, Mehdi Mirza, Alex Graves, Timothy Lillicrap, Tim Harley, David Silver, and Koray Kavukcuoglu. Asynchronous methods for deep reinforcement learning. In *International conference on machine learning*, pages 1928–1937. PmLR, 2016.
- [49] Ofir Nachum, Shixiang Shane Gu, Honglak Lee, and Sergey Levine. Data-efficient hierarchical reinforcement learning. *Advances in neural information processing systems*, 31, 2018.
- [50] Ashvin Nair, Abhishek Gupta, Murtaza Dalal, and Sergey Levine. Awac: Accelerating online reinforcement learning with offline datasets. *arXiv preprint arXiv:2006.09359*, 2020.
- [51] Mitsuhiro Nakamoto, Simon Zhai, Anikait Singh, Max Sobol Mark, Yi Ma, Chelsea Finn, Aviral Kumar, and Sergey Levine. Cal-QL: Calibrated offline RL pre-training for efficient online fine-tuning. *Advances in Neural Information Processing Systems*, 36, 2024.
- [52] Soroush Nasiriany, Tian Gao, Ajay Mandlkar, and Yuke Zhu. Learning and retrieval from prior data for skill-based imitation learning. In *Conference on Robot Learning*, 2022.
- [53] Junhyuk Oh, Satinder Singh, and Honglak Lee. Value prediction network. *Advances in neural information processing systems*, 30, 2017.
- [54] Alexandros Paraschos, Christian Daniel, Jan R Peters, and Gerhard Neumann. Probabilistic movement primitives. *Advances in neural information processing systems*, 26, 2013.
- [55] Seohong Park, Kevin Frans, Benjamin Eysenbach, and Sergey Levine. Ogbench: Benchmarking offline goal-conditioned rl. *ArXiv*, 2024.
- [56] Seohong Park, Kevin Frans, Benjamin Eysenbach, and Sergey Levine. Ogbench: Benchmarking offline goal-conditioned rl. *arXiv preprint arXiv:2410.20092*, 2024.
- [57] Seohong Park, Tobias Kreiman, and Sergey Levine. Foundation policies with hilbert representations. In *Forty-first International Conference on Machine Learning*, 2024. URL <https://openreview.net/forum?id=LhNsSaAKub>.
- [58] Seohong Park, Qiyang Li, and Sergey Levine. Flow Q-learning. *arXiv preprint arXiv:2502.02538*, 2025.
- [59] Xue Bin Peng, Glen Berseth, KangKang Yin, and Michiel Van De Panne. Deeploco: Dynamic locomotion skills using hierarchical deep reinforcement learning. *Acm transactions on graphics (tog)*, 36(4):1–13, 2017.
- [60] Karl Pertsch, Youngwoon Lee, and Joseph Lim. Accelerating reinforcement learning with learned skill priors. In *Conference on robot learning*, pages 188–204. PMLR, 2021.
- [61] Allen Z Ren, Justin Lidard, Lars L Ankile, Anthony Simeonov, Pulkit Agrawal, Anirudha Majumdar, Benjamin Burchfiel, Hongkai Dai, and Max Simchowitz. Diffusion policy policy optimization. *arXiv preprint arXiv:2409.00588*, 2024.
- [62] Martin Riedmiller, Roland Hafner, Thomas Lampe, Michael Neunert, Jonas Degraeve, Tom Wiele, Vlad Mnih, Nicolas Heess, and Jost Tobias Springenberg. Learning by playing solving sparse reward tasks from scratch. In *International conference on machine learning*, pages 4344–4353. PMLR, 2018.
- [63] Stefan Schaal. Dynamic movement primitives-a framework for motor control in humans and humanoid robotics. In *Adaptive motion of animals and machines*, pages 261–280. Springer, 2006.
- [64] Julian Schrittwieser, Ioannis Antonoglou, Thomas Hubert, Karen Simonyan, Laurent Sifre, Simon Schmitt, Arthur Guez, Edward Lockhart, Demis Hassabis, Thore Graepel, et al. Mastering atari, go, chess and shogi by planning with a learned model. *Nature*, 588(7839):604–609, 2020.
- [65] Younggyo Seo and Pieter Abbeel. Reinforcement learning with action sequence for data-efficient robot learning. *arXiv preprint arXiv:2411.12155*, 2024.

- [66] Younggyo Seo, Jafar Uruç, and Stephen James. Continuous control with coarse-to-fine reinforcement learning. In *8th Annual Conference on Robot Learning*, 2024. URL <https://openreview.net/forum?id=WjDR48cL30>.
- [67] Tanmay Shankar and Abhinav Gupta. Learning robot skills with temporal variational inference. In *International Conference on Machine Learning*, pages 8624–8633. PMLR, 2020.
- [68] Özgür Şimşek and Andrew G Barto. Using relative novelty to identify useful temporal abstractions in reinforcement learning. In *Proceedings of the twenty-first international conference on Machine learning*, page 95, 2004.
- [69] Özgür Şimşek and Andrew G. Barto. Betweenness centrality as a basis for forming skills. Workingpaper, University of Massachusetts Amherst, April 2007.
- [70] Avi Singh, Huihan Liu, Gaoyue Zhou, Albert Yu, Nicholas Rhinehart, and Sergey Levine. Parrot: Data-driven behavioral priors for reinforcement learning. In *International Conference on Learning Representations*, 2021. URL <https://openreview.net/forum?id=Ysuv-WOFeKR>.
- [71] Yuda Song, Yifei Zhou, Ayush Sekhari, Drew Bagnell, Akshay Krishnamurthy, and Wen Sun. Hybrid RL: Using both offline and online data can make RL efficient. In *The Eleventh International Conference on Learning Representations*, 2023. URL <https://openreview.net/forum?id=yyBis80iUuU>.
- [72] Aravind Srinivas, Ramnandan Krishnamurthy, Peeyush Kumar, and Balaraman Ravindran. Option discovery in hierarchical reinforcement learning using spatio-temporal clustering. *arXiv preprint arXiv:1605.05359*, 2016.
- [73] Nisan Stiennon, Long Ouyang, Jeffrey Wu, Daniel Ziegler, Ryan Lowe, Chelsea Voss, Alec Radford, Dario Amodei, and Paul F Christiano. Learning to summarize with human feedback. *Advances in neural information processing systems*, 33:3008–3021, 2020.
- [74] Richard S Sutton, Andrew G Barto, et al. *Reinforcement learning: An introduction*, volume 1. MIT press Cambridge, 1998.
- [75] Richard S Sutton, Doina Precup, and Satinder Singh. Between MDPs and semi-MDPs: A framework for temporal abstraction in reinforcement learning. *Artificial intelligence*, 112(1-2): 181–211, 1999.
- [76] Denis Tarasov, Vladislav Kurenkov, Alexander Nikulin, and Sergey Kolesnikov. Revisiting the minimalist approach to offline reinforcement learning. *Advances in Neural Information Processing Systems*, 36:11592–11620, 2023.
- [77] Denis Tarasov, Vladislav Kurenkov, Alexander Nikulin, and Sergey Kolesnikov. Revisiting the minimalist approach to offline reinforcement learning. *Advances in Neural Information Processing Systems*, 36, 2024.
- [78] Dong Tian, Ge Li, Hongyi Zhou, Onur Celik, and Gerhard Neumann. Chunking the critic: A transformer-based soft actor-critic with n-step returns. *arXiv preprint arXiv:2503.03660*, 2025.
- [79] Ahmed Touati, Jérémy Rapin, and Yann Ollivier. Does zero-shot reinforcement learning exist? In *The Eleventh International Conference on Learning Representations*, 2022.
- [80] Alexander Vezhnevets, Volodymyr Mnih, Simon Osindero, Alex Graves, Oriol Vinyals, John Agapiou, et al. Strategic attentive writer for learning macro-actions. *Advances in neural information processing systems*, 29, 2016.
- [81] Alexander Sasha Vezhnevets, Simon Osindero, Tom Schaul, Nicolas Heess, Max Jaderberg, David Silver, and Koray Kavukcuoglu. Feudal networks for hierarchical reinforcement learning. In *International conference on machine learning*, pages 3540–3549. PMLR, 2017.
- [82] Shenzhi Wang, Qisen Yang, Jiawei Gao, Matthieu Lin, Hao Chen, Liwei Wu, Ning Jia, Shiji Song, and Gao Huang. Train once, get a family: State-adaptive balances for offline-to-online reinforcement learning. *Advances in Neural Information Processing Systems*, 36:47081–47104, 2023.

- [83] Christopher John Cornish Hellaby Watkins et al. Learning from delayed rewards. 1989.
- [84] Darrell Whitley, Stephen Dominic, Rajarshi Das, and Charles W Anderson. Genetic reinforcement learning for neurocontrol problems. *Machine Learning*, 13(2):259–284, 1993.
- [85] Max Wilcoxson, Qiyang Li, Kevin Frans, and Sergey Levine. Leveraging skills from unlabeled prior data for efficient online exploration. *arXiv preprint arXiv:2410.18076*, 2024.
- [86] Peter R Wurman, Samuel Barrett, Kenta Kawamoto, James MacGlashan, Kaushik Subramanian, Thomas J Walsh, Roberto Capobianco, Alisa Devlic, Franziska Eckert, Florian Fuchs, et al. Outracing champion gran turismo drivers with deep reinforcement learning. *Nature*, 602(7896): 223–228, 2022.
- [87] Kevin Xie, Homanga Bharadhwaj, Danijar Hafner, Animesh Garg, and Florian Shkurti. Latent skill planning for exploration and transfer. In *International Conference on Learning Representations*, 2021. URL <https://openreview.net/forum?id=jXe91kq3jAq>.
- [88] Tengyang Xie, Nan Jiang, Huan Wang, Caiming Xiong, and Yu Bai. Policy finetuning: Bridging sample-efficient offline and online reinforcement learning. *Advances in neural information processing systems*, 34:27395–27407, 2021.
- [89] Haichao Zhang, Wei Xu, and Haonan Yu. Policy expansion for bridging offline-to-online reinforcement learning. In *The Eleventh International Conference on Learning Representations*, 2023. URL <https://openreview.net/forum?id=-Y34L45JR6z>.
- [90] Tony Z Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. *arXiv preprint arXiv:2304.13705*, 2023.
- [91] Han Zheng, Xufang Luo, Pengfei Wei, Xuan Song, Dongsheng Li, and Jing Jiang. Adaptive policy learning for offline-to-online reinforcement learning. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 37, pages 11372–11380, 2023.
- [92] Zhiyuan Zhou, Andy Peng, Qiyang Li, Sergey Levine, and Aviral Kumar. Efficient online reinforcement learning fine-tuning need not retain offline data. *arXiv preprint arXiv:2412.07762*, 2024.

理论依据

命题 A.1 (Q 分块执行无偏 n 步回报备份)。设 $s_t, a_t, \dots, s_{t+n}$ 为遵循数据收集策略 $\pi_\beta(a_t, \dots, a_{t+n}|s_t)$ (i.e., 生成的轨迹片段 $s_{t+k} \sim T(\cdot | s_{t+k-1}, a_{t+k-1}), \forall k \in \{1, \dots, n\}$), $r_t, r_{t+1}, \dots, r_{t+n-1}$ 为每个相应时间步获得的奖励 (i.e., $r_{t+k} = r(s_{t+k}, a_{t+k})$)。设 $V^\pi(s_t)$ 为动作分块策略 $\pi(a_t, \dots, a_{t+n}|s_t)$ 从状态 s_t 开始的值。设 $Q^\pi(s_t, a_t, a_{t+1}, \dots, a_{t+n-1})$ 为从状态 s_t 开始并执行动作序列 $a_t, a_{t+1}, \dots, a_{t+n-1}$ 的 π 的 Q 值。

在 n 步回报估计下, 对 $\hat{V}_{n\text{-step}}(s_t, a_t) = \sum_{t'=t}^{t+n-1} [\gamma^{t'-t} r_{t'}] + \hat{V}(s_{t+n})$ 是无偏的, 只要 $\hat{V}(s_{t+n})$ 是无偏的对 $V^\pi(s_{t+n})$ 。

证明。根据 $Q^\pi(s_t, a_t, a_{t+1}, \dots, a_{t+n-1})$ 的定义, 我们可以将其写为期望形式:

$$Q^\pi(s_t, a_t, a_{t+1}, \dots, a_{t+n-1}) = \mathbb{E}_{s_{t'} \sim T(\cdot | s_t, a_t)} \left[\sum_{t'=t}^{t+n-1} [\gamma^{t'-t} r(s_{t'}, a_{t'})] + V^\pi(s_{t+n}) \right] \quad (16)$$

$$= \mathbb{E}_{s_{t+n}, r_{t+1}, r_{t+2}, \dots, r_{t+n-1}} \left[\sum_{t'=t}^{t+n-1} [\gamma^{t'-t} r_{t'}] + V^\pi(s_{t+n}) \right] \quad (17)$$

$$= \mathbb{E}_{s_{t+n}, r_{t+1}, r_{t+2}, \dots, r_{t+n-1}} \left[\sum_{t'=t}^{t+n-1} [\gamma^{t'-t} r_{t'}] + \hat{V}(s_{t+n}) \right] \quad (18)$$

$$= \mathbb{E} [\hat{V}_{n\text{-step}}] . \quad (19)$$

第二行利用了奖励 $r_t, r_{t+1}, \dots, r_{t+n-1}$ 与轨迹片段 $s_t, a_t, \dots, s_{t+n}$ 相关联这一事实。第三行利用了 $\hat{V}(s_{t+n})$ 是 $V^\pi(s_{t+n})$ 的无偏估计这一事实。第四行利用了 $\hat{V}_n$ 步的定义。□

该定理的启示是, 如果我们对分块 Q 函数 $Q(s_t, a_t, a_{t+1}, \dots, a_{t+n-1})$ 使用 n 步回报备份 (其价值估计为 $\hat{V}_s \leftarrow Q(s_t, a_t, a_{t+1}, \dots, a_{t+n-1})$), 则在相同策略 $Q^\pi(s_t, a_t, a_{t+1}, \dots, a_{t+n-1})$ 下, 它会收敛到真实 Q 值。相比之下, 在原始动作空间中使用 n 步回报备份不会收敛到正确的 Q 值 (i.e., $Q^\pi(s_t, a_t, a_{t+1}, \dots, a_{t+n-1})$)。)

B 领域细节

我们在图 7 中概述了实验中使用的六个领域。表 2 还列出了数据集大小、回合长度和动作维度。在以下各节中, 我们将详细描述每个领域。

B.1 OGBench 环境

我们考虑了来自 OGBench[55] 的五个操作领域, 并在实验中采用了其公开的单任务版本。对于 scene-sparse 和 puzzle-3x3-sparse, 我们对奖励函数进行了稀疏化处理, 使得任务未完成时奖励值为 -1 , 任务完成时为 0 。对于 cube-double/triple/quadruple, 强化学习智能体需要指挥 UR-5 机械臂将两个/三个/四个立方体拾取并放置到目标位置。特别是 cube-triple 和 cube-quadruple 仅从离线数据中求解极其困难, 通常成功率为零。强化学习智能体必须在这些领域中进行高效的在线探索才能解决任务。cube-*领域为离线到在线强化学习算法的样本效率提供了极好的测试平台, 这也是我们主要关注的重点。对于 cube-quadruple, 我们使用了 1 亿规模的数据集。该数据集过大, 无法完全载入 CPU 内存, 因此我们定期 (每 1000 个梯度步后) 加载一个 100 万规模的数据块用于离线训练。对于 RLDP 和 QC-RLDP 的在线训练, 我们使用

Tasks	Dataset Size	Episode Length	Action Dimension (A)
scene-sparse-*	1M	750	5
puzzle-3x3-sparse-*	1M	500	5
cube-double-*	1M	500	5
cube-triple-*	3M	1000	5
cube-quadruple-100M-*	100M	1000	5
lift	31 127	500	7
can	62 756	500	7
square	80 731	500	7

表 2: 领域元数据。数据集大小（转移数量）、回合长度和动作维度。对于 OGBench 任务，动作维度为 5（ x 位置、 y 位置、 z 位置、夹爪偏航角和夹爪开合度）。对于 robomimic 任务，square 的动作维度为 7，用于控制单臂（平移 3 个自由度（DoF）、旋转 3 个自由度以及夹爪开合 1 个自由度）。

采用相同策略，即加载数据集中大小为 100 万的数据块作为离线数据，并进行 50/50 采样（例如，50% 的数据来自 100 万大小的离线数据块，50% 的数据来自在线回放缓冲区）。对于在线微调 **QC-***，FQL、**FQL-n**、BFN 和 **BFN-n** 中，我们保留离线数据集中固定 1M 大小的块作为初始化 $\mathcal{D}$ 并添加新数据至 $\mathcal{D}$ 直接使用。离线数据中剩余的 9900 万条转移未被在线利用。现对五个领域逐一详细说明：场景稀疏：该领域包含一个抽屉、一扇窗户、一个立方体以及两个控制抽屉和窗户能否打开的按钮锁。这些任务通常涉及一系列动作。例如，场景任务 2 要求机械臂先解锁两个锁，将抽屉和窗户移动到目标位置，然后再锁上两个锁。场景任务 4 要求机械臂解锁抽屉，打开抽屉，将立方体放入抽屉，再关闭抽屉。奖励为二值：-1 若尚未达到目标构型则为 1，若已达到目标构型（且回合终止）则为 0。拼图-3x3-稀疏：该领域包含一个 3×3 按钮网格。每个按钮有两种状态，由其颜色（蓝色或红色）表示。按下任意按钮会使其颜色及所有相邻按钮的颜色翻转（红色 $\rightarrow$ 蓝色与蓝色 $\rightarrow$ 红色）。目标是达到预先指定的颜色配置。拼图-3x3-任务 2 开始时所有按钮均为蓝色，目标是将恰好一个按钮（左上角那个）翻转为红色。拼图-3x3-任务 4 开始时四个按钮（上中、下中、左中、右中）为蓝色，目标是将所有按钮变为蓝色。奖励是二元的：-1 若尚未达到目标构型则为该值，若已达到目标构型（且回合终止）则为 0。双立方体/三立方体/四立方体：这三个领域分别包含 2/3/4 个立方体。三个领域中的任务均涉及将立方体移动到其目标位置。奖励为 $-n_{\text{wrong}}$ 是处于错误位置的立方体数量。当所有立方体均处于正确位置时（奖励为 0），回合终止。

$-n_{\text{wrong}}$

B.2 Robomimic 环境。

我们使用来自 robomimic 领域 [43] 的三个具有挑战性的任务。我们使用由六名人类操作员收集的多人数据集。每个数据集包含 300 条成功轨迹。这三个任务描述如下。

- 提升：该任务要求机械臂抓取一个小立方体。这是基准中最简单的任务。
- 罐子：该任务要求机械臂拾起一个可乐罐，并将其放入一个较小的容器箱中。
- 方形：该任务要求机械臂拾起一个方形螺母，并将其放置在一根杆上。螺母略大于杆，需要机械臂精确移动才能成功完成任务。




图 7: 我们在多个具有挑战性的长时程、稀疏奖励领域进行了实验。每个领域的详细任务描述见附录 B。上述机器人模仿任务的渲染图像取自 Mandlekar 等人 [43]。

所有三个机器人模仿任务均使用二元任务完成奖励，即当任务未完成时智能体获得 -1 奖励，当任务完成时获得 0 奖励。

C 实现细节

在本节中，我们提供关于两种 Q 分块方法（QC、QC-FQL）以及实验中使用的基线的更多实现细节。对于 IFQL、ReBRAC、IQL，我们直接使用 Park 等人 [58] 的实现。

Algorithm 1 QC

Input: Behavior policy and critic: $f_\xi(\mathbf{a}_{t:t+h}|s)$ and $Q_\theta(s_t, \mathbf{a}_{t:t+h})$.
 $\mathcal{D} \leftarrow$ offline prior data.
for every environment step t **do**
 if $t \bmod h \equiv 0$ **then**
 $\mathbf{a}_{t:t+h}^1 \cdots \mathbf{a}_{t:t+h}^N \sim f_\xi(\cdot|s_t)$
 $\mathbf{a}_{t:t+h}^* \leftarrow \arg \max_{\mathbf{a}_{t:t+h}^i} Q_\theta(s, \mathbf{a}_{t:t+h}^i)$
 Act with $\mathbf{a}_{t:t+h}^*$ and receive s_{t+1}, r_t .
 $\mathcal{D} \leftarrow \mathcal{D} \cup \{(s_t, \mathbf{a}_{t:t+h}^*, s_{t+1}, r_t)\}$
 Update f_ξ via flow-matching loss using $\mathcal{D}$.
 Update Q_θ via Eq (11) using $\mathcal{D}$.
Output: f_ξ, Q_θ .

Algorithm 2 QC-FQL

Input: Behavior policy, critic, one-step policy: $f_\xi(\mathbf{a}_{t:t+h}|s)$, $Q_\theta(s_t, \mathbf{a}_{t:t+h})$, $\mu_\psi(s, \mathbf{z})$.
 $\mathcal{D} \leftarrow$ offline prior data.
for every environment step t **do**
 if $t \bmod h \equiv 0$ **then**
 $\mathbf{z} \sim \mathcal{N}(0, \mathbf{I}_{Ah})$
 $\mathbf{a}_{t:t+h} \leftarrow \mu_\psi(s_t, \mathbf{z})$
 Act with $\mathbf{a}_{t:t+h}$ and receive s_{t+1}, r_t .
 $\mathcal{D} \leftarrow \mathcal{D} \cup \{(s_t, \mathbf{a}_{t:t+h}, s_{t+1}, r_t)\}$
 Update f_ξ via flow-matching loss using $\mathcal{D}$.
 Update μ_ψ and Q_θ via Eq. (13, 15) using $\mathcal{D}$.
Output: $f_\xi, Q_\theta, \mu_\psi(s, \mathbf{z})$.

C.1 QC-FQL

我们在 FQL ([58]) 的基础上构建了本方法的实现。FQL 是近期提出的一种离线强化学习/离线到在线强化学习方法，采用 TD3+BC 风格的目标函数。该方法使用一步噪声条件策略（而非强化学习中常用的高斯策略）实现，并利用行为流匹配策略的蒸馏损失作为行为克隆损失。为适配动作分块，我们仅在时间扩展的动作空间上应用 FQL——行为流匹配策略生成动作序列，一步噪声条件策略预测动作序列。

且 Q 网络也以状态和动作序列作为输入。更具体地，我们训练三个网络：

1. $Q_\theta(s, a_1, \dots, a_h) : \mathcal{S} \times \mathcal{A}^h \mapsto \mathbb{R}$ —— 价值函数，以状态和动作序列（动作块）为输入。实践中，我们训练一个由 Q 个网络组成的集成。我们将集成元素的权重记为 $\theta = (\theta_1, \dots, \theta_K)$ 。
2. $\mu_\psi(s, z) : \mathcal{S} \times \mathbb{R}^{A_h} \mapsto \mathbb{R}^{A_h}$ —— 一步噪声条件策略，以状态和噪声为输入，并输出以它们为条件的动作序列。
3. $f_\xi(s, m, u) : \mathcal{S} \times \mathbb{R}^{A_h} \times [0, 1] \mapsto \mathbb{R}^{A_h}$ —— 由速度预测网络参数化的流匹配行为策略。该网络以状态、流的中间状态和时间作为输入，并输出中间动作序列在指定时间应移动的速度方向。关于如何使用该速度预测网络从噪声向量生成动作的更多细节，请参见算法 3。

我们将策略记为 $\pi_\psi(\cdot|s)$ 。其实现方式是首先采样高斯噪声 $z \sim \mathcal{N}(0, I_{A_h})$ ，然后将其通过一步噪声条件策略 $[a_1 \dots a_h] \leftarrow \mu_\psi(s, z)$ 。为了训练这三个网络，我们采样一个高层转移 $w = (s_t, a_t, a_{t+1}, \dots, a_{t+h-1}, s_{t+h}, R_t^h) \sim \mathcal{D}$ ，其中 $R_t^h = \sum_{t'=0}^{h-1} \gamma^{t'} r_{t+t'}$ ，以构建以下损失：

1) 评论家损失：

$$L(\theta_k, w) = \left(Q_{\theta_k}(s_t, a_t, \dots, a_{t+h-1}) - R_t^h - \frac{\gamma^h}{K} \sum_{k'=1}^K Q_{\bar{\theta}_{k'}}(s_{t+h}, a_{t+h}, \dots, a_{t+2h-1}) \right)^2, \quad (20)$$

其中 $[a_{t+h} \dots a_{t+2h-1}] \sim \pi_\psi(\cdot|s_{t+h})$, $k \in \{1, 2, \dots, K\}$ 。

(2) 演员损失：

$$L(\psi, w) = -Q_\theta(s_t, \mu_\psi(s_t, z_t)) + \alpha \left\| \mu_\psi(s_t, z_t) - [a_t^\xi \dots a_{t+h-1}^\xi] \right\|_2^2, \quad (21)$$

where $z_t \sim \mathcal{N}(0, I_{A_h})$ and $[a_t^\xi \dots a_{t+h-1}^\xi]$ 是使用算法 3 从 z_t 运行行为策略 $f_\xi(s, m, t)$ 的结果，而 $\alpha \in \mathbb{R}$ 是一个可调参数，用于控制行为正则化的强度（ α 越高，行为正则化越强）。

(3) 流匹配行为策略损失：

$$L(\xi, w) = \|f_\xi(s_t, u[a_t \dots a_{t+h-1}] + (1-u)z_t, u) - ([a_t \dots a_{t+h-1}] - z_t)\|_2^2, \quad (22)$$

$u \sim U([0, 1])$, $z_t \sim \mathcal{N}(0, I_{A_h})$ 。其中 实践中，我们采样一批转移 $\{w_1, w_2, \dots, w_M\}$ ，并优化每个网络的平均损失：

$$\mathcal{L}(\theta) = \frac{1}{M} \sum_{i=1}^M \sum_{k=1}^K \mathcal{L}(\theta_k, w_i), \mathcal{L}(\psi) = \frac{1}{N} \sum_{i=1}^M \mathcal{L}(\psi, w_i), \mathcal{L}(\xi) = \frac{1}{N} \sum_{i=1}^M \mathcal{L}(\xi, w_i).$$

C.2 FQL

FQL [58] 是近期提出的一种离线强化学习/离线到在线强化学习方法，采用 TD3+BC 风格的目标函数。当 $h = 1$ 时，该方法与本文方法等价。为完整起

$w = (s_t, a_t, r_t, s_{t+1})$ ：见，我们写出单个转移样本的目标函数

$$L(\theta_k, w) = \left(Q_{\theta_k}(s_t, a_t) - r_t - \frac{\gamma}{K} \sum_{k'=1}^K Q_{\bar{\theta}_{k'}}(s_{t+1}, \mu_\psi(s_{t+1}, z_t^{k'})) \right)^2, z_t^{k'} \sim \mathcal{N}(0, I_A), \quad (23)$$

$$L(\psi, w) = -Q_\theta(s_t, \mu_\psi(s_t, z_t)) + \alpha \left\| \mu_\psi(s_t, z_t) - a_t^\xi \right\|_2^2, \quad (24)$$

$$a_t^\xi \leftarrow \text{FlowODE_Euler}(s_t, z_t, f_\xi, T), z_t \sim \mathcal{N}(0, I_A), \quad (25)$$

$$L(\xi, w) = \|f_\xi(s_t, u a_t + (1-u)z_t, u) - (a_t - z_t)\|_2^2, z_t \sim \mathcal{N}(0, I_A), u \sim U([0, 1]). \quad (26)$$

$$\sum_{i=1}^N \sum_{k=1}^K \mathcal{L}(\theta_k, w_i), \mathcal{L}(\psi) = \frac{1}{N} \sum_{i=1}^N \mathcal{L}(\psi, w_i), \mathcal{L}(\xi) = \frac{1}{N} \sum_{i=1}^N \mathcal{L}(\xi, w_i).$$

实践中，我们采样一批转移样本 $\{w_1, w_2, \dots, w_N\}$ ，并

对每个网络优化平均损失： $\mathcal{L}(\theta) = \frac{1}{N}$ 20

Algorithm 3 FlowODE_Euler(s_t, z_t, f_ξ, T): generate actions from the behavior flow policy $f_\xi(s, m, u)$ with Euler’s method.

Input: State s_t , noise z_t and flow model $f_\xi(s, m, u)$, number of flow steps T .

$m^0 \leftarrow z_t$

for $i \in \{1, \dots, T\}$ **do**

$m^i \leftarrow f_\xi(s_t, m^{i-1}, (i-1)/T)$

Output: m^T .

C.3 FQL-n

为实现 n 步回报基线，我们采用 FQL 并将 1 步时序差分更新替换为 h 步时序差分更新：

$$L(\theta_k, w) = \left(Q_{\theta_k}(s_t, a_t) - \sum_{t'=0}^{h-1} (\gamma^{t'} r_{t+t'}) - \frac{\gamma^h}{K} \sum_{k'=1}^K Q_{\bar{\theta}_{k'}}(s_{t+h}, \mu_\psi(s_{t+h}, z_t^{k'})) \right)^2, \quad (27)$$

其中对于所有 $k' \in \{1, 2, \dots, K\}$, $z_t^{k'} \sim \mathcal{N}(0, I_A)$ 。演员损失和流匹配损失与 FQL 保持一致。

C.4 QC

流匹配行为策略的训练损失与 **QC-FQL**（方程 (22)）中使用的损失相同。在流匹配行为策略之上，我们通过从行为策略中采样多个动作块并选择使 Q 值最大的动作块，隐式地参数化策略 π 。具体地，令 $\{z_t^1, z_t^2, \dots, z_t^N\} \sim \mathcal{N}(0, I_{Ah})$ 和 $= \text{FlowODE_Euler}(s_t, z_t^i, f_\xi, T)$

$$[a_t^i \quad \dots \quad a_{t+h-1}^i]$$

策略输出 N 中使 Q 值最大化的一个动作块，其中

$$[a_t^{i^*} \quad \dots \quad a_{t+h-1}^{i^*}],$$

$$i^* \leftarrow \arg \max_{i \in [N]} Q(s, [a_t^i \quad \dots \quad a_{t+h-1}^i]).$$

最后，我们直接使用这个隐式参数化策略来生成动作，以计算时序差分目标用于时序差分损失：

$$L(\theta_k, w) = \left(Q_{\theta_k}(s_t, a_t, \dots, a_{t+h-1}) - R_t^h - \frac{\gamma^h}{K} \sum_{k'=1}^K Q_{\bar{\theta}_{k'}}(s_{t+h}, a_{t+h}^{i^*}, \dots, a_{t+2h-1}^{i^*}) \right)^2 \quad (28)$$

其中 $a_{t+h}^{i^*}, \dots, a_{t+2h-1}^{i^*} \sim \pi(\cdot | s_{t+h})$ 。

基线 **BFN-n** 和 BFN 的实现与 **FQL-n** 和 FQL 类似，均在原始动作空间中操作。

C.5 RLPD、RLPD-AC、QC-RLPD

所有 RLPD 基线结果均通过运行官方代码库（如 Ball 等人 [7] 中链接）获得，并额外修改以纳入动作分块和行为克隆。该基线从头开始运行在线强化学习，使用离线转换，其中 50% 来自离线数据集，另外 50% 来自在线回放缓冲区。它本质上更多地加权在线数据，使在线强化学习智能体能够更快地学习。这与 **QC-***、BFN、**BFN-n**、FQL、**FQL-n** 采样离线转换的方式不同（我们是从结合了离线数据集和在线回放缓冲区数据的数据集中采样，没有加权）。RLPD 基线均使用高斯策略。这也与我们的方法不同，因为我们的方法使用噪声条件策略，可以表示更广泛的分布。对于 **RLPD-AC**，我们修改了所有演员和评论家网络，使其能够处理动作块而不是单个动作。该基线与我们的方法完全相同，只是演员和评论家的更新方式与 RLPD 相同

更新其演员和评论家。对于 **QC-RLPD**，我们在演员损失中添加行为克隆损失如下（下方红色高亮）：

$$\mathcal{L}(\psi) = \mathbb{E}_{a'_t \sim \pi_\psi(\cdot|s_t)} \left[-\frac{1}{K} \sum_{k=1}^K Q_{\theta_k}(s_t, a'_t) \text{ } -\alpha \log \pi_\psi(a_t|s_t) \right]. \quad (29)$$

C.6 SUPE-GT

对于该基线，我们改编自最近提出的基于技能的离线到在线强化学习方法 [85]。原始方法具有额外的模块，如奖励模型和随机蒸馏网络，以处理离线数据集未标记（例如，缺少奖励信息）的问题设置。我们移除了这两个模块，因为我们的离线数据集中有真实奖励信息。该方法有两个阶段：（1）技能预训练和（2）使用技能的在线强化学习。在第一阶段，基线使用轨迹变分自编码器来学习潜在条件技能策略。在第二阶段，基线使用 RLPD 学习一个高层策略，该策略输出潜在向量，以在每 h 步后指挥潜在条件技能策略。这种基于技能的方法在理论上允许时间上连贯的动作作用于探索和价值备份加速。

D 实验细节

D.1 计算资源

We use NVIDIA RTX-A5000 GPU to run all our experiments. Each complete offline-to-online experiment run takes around 4-7 hours. To reproduce all our results in Table 6, we estimate that it would take around $\underbrace{6}_{\text{hours per single run}} \times \underbrace{15}_{\text{\# of methods}} \times \underbrace{25}_{\text{\# of tasks}} \times \underbrace{4}_{\text{\# of seeds}} = 9\,000$ GPU hours. Each robomimic experiment run takes longer (around 8-12 hours). While each single run takes longer, we only run a subset of strong methods/baselines on robomimic tasks. We estimate it would take around $\underbrace{10}_{\text{hours per single run}} \times \underbrace{8}_{\text{\# of methods}} \times \underbrace{3}_{\text{\# of tasks}} \times \underbrace{5}_{\text{\# of seeds}} = 1\,350$ GPU hours. In total, we estimate that it would 复现本文所有主要结果大约需要 10350 个图形处理器小时。

D.2 评估协议

除非另有说明，对于所有方法，我们在每个 OGBench 任务上运行 4 个随机种子，在每个 robomimic 任务上运行 5 个随机种子。所有图表均使用 95% 置信区间（Confidence Interval）并采用分层采样（5000 个样本）。成功率通过让策略在环境中运行 50 个回合并记录策略成功解决任务的次数（再除以 50）来计算。

D.3 超参数调优

质量控制，**BFN**，**BFN-n**。我们调整了采样的动作数量 N ，用于期望最大化 Q 算子。在 OGBench 领域上，我们对 $\{2, 4, 8, 16, 32, 64, 128\}$ 进行了扫描，并为每个领域和任务 2 上的每种方法选择了最佳参数。我们在表 1 和图 1（所有任务）中报告了每种方法在最佳 α 下的性能。表 5 总结了我们在每个任务中使用的 α 值。

QC-FQL，**FQL**，**FQL-n**。我们调整行为正则化系数 α 。在 OGBench 领域，我们采用 FQL 在每个领域的默认超参数 α_{default} ，并在每个领域的任务 2 上调整所有方法，使用三种 α : $\{\alpha_{\text{default}}/3, \alpha_{\text{default}}, 3\alpha_{\text{default}}\}$ 选择（我们的 α_{default} 来自 Park 等人 [58] 的表 6）。在 robomimic 领域，我们扫描更大的 α 值： $\{100, 1000, 10000\}$ 。我们在表 1 和图 1（所有任务）中报告每种方法在最佳 α 下的性能。表 4 总结了我们为每个任务使用的 α 值。

RLPD，**RLPD-AC**，**QC-RLPD**。我们遍历了（1）是否使用截断双 Q 学习（CDQ），以及（2）是否使用熵备份。我们发现，对于所有 RLPD 基线，不使用 CDQ 且不使用熵备份表现最佳，并在所有领域中使用该设置。尽管我们的方法和其他 FQL 基线使用 $K = 2$ 评论家集成规模，但我们对 RLPD 使用 $K = 10$ 评论家集成规模，以保持与原始论文 [7] 中的超参数一致。

Parameter	Value
Batch size (M)	256
Discount factor (γ)	0.99
Optimizer	Adam
Learning rate	3×10^{-4}
Target network update rate (τ)	5×10^{-3}
Critic ensemble size (K)	10 for RLPD , RLPD-AC , QC-RLPD , and SUPE-GT 2 for QC-FQL , FQL , FQL-n , QC-BFN , BFN , BFN-n
UTD Ratio	1
Number of flow steps (T)	10
Number of offline training steps	10^6 except RLPD -based approaches (0)
Number of online environment steps	1×10^6
Network width	512
Network depth	4 hidden layers

表 3: 常见超参数。

Environments	FQL	FQL-n	QC-FQL	ReBRAC
scene-sparse-*	300	100	300	0.1
puzzle-3x3-sparse-*	100	100	300	0.1
cube-double-*	300	100	300	0.1
cube-triple-*	300	100	100	0.1
cube-quadruple-100M-*	300	100	100	0.1
lift	10000	10000	10000	-
can	10000	10000	10000	-
square	10000	10000	10000	-

表 4: 行为正则化系数 (α)。

对于 **QC-RLPD**，我们扫描行为正则化系数 $\alpha \in \{0.001, 0.01, 0.1\}$ 并选取 0.01，因为它效果最佳。对于

SUPE-GT。We tune the KL coefficient the VAE skill-pretraining from $\{0.001, 0.003, 0.01, 0.03, 0.1\}$ and pick 0.003 as it works the best.

重放缓冲强化注意力课程 (ReBRAC)。本文从 $\{0.01, 0.03, 0.1, 0.3, 1.0\}$ 中调整行为正则化系数，并选取 0.1，因其效果最佳。

IFQL。我们直接采用 Park 等人 [58] ($N = 32, \tau = 0.9$) 的默认超参数作为该基线。第一个参数 $N = 32$ 表示在在线策略展开和策略评估中，我们采样 32 个动作并选择具有最高 Q 值的动作。第二个参数 $\tau = 0.9$ 是期望分位数系数。

IQL。我们直接采用 Park 等人 [58] 的默认超参数作为该基线。对于 cube-*, 我们使用 $\alpha = 0.3$ 。对于 scene 和 puzzle-3x3, 我们使用 $\alpha = 10.0$ 。对于期望分位数系数，我们使用 $\tau = 0.9$ 。

E 完整结果

E.1 末端执行器可视化

我们提供了 **QC** 和 **BFN** 在 cube-triple-task3 在线训练过程中轨迹展开的更多示例。在图 8 中，我们展示了前 9000 个时间步（分为 9 个子图，每个子图可视化 1000 个时间步）。在图 9 中，我们展示了训练后期（从环境步 9×10^5 开始）的另外 9000 个时间步。第一个示例与

图 5 中使用的相同。

Environments	BFN	BFN-n	QC-BFN
scene-sparse*	4	4	32
puzzle-3x3-sparse-*	4	4	64
cube-*	4	4	32
lift, can, square	4	4	16

表 5: BFN 方法的期望最大 Q 算子 (N) 采样的动作数量。




图 8: 训练早期的末端执行器轨迹。上方每个子图显示连续 1000 个时间步的轨迹。我们包含到第 9000 步。




图 9: 训练后期末端执行器轨迹可视化。上方每个子图展示了连续 1000 个时间步的轨迹（从第 900000 步到第 909000 步）。

E.2 按任务划分的 OGBench 结果

按任务划分的主要结果。表 1 和图 10 展示了所有方法的性能分解。

		RLPD	RLPD-AC	SUPE-GT	IQL	ReBRAC	IFQL	FQL	BFN	IFQL-n	FQL-n	BFN-n	QC-RLPD	QC-IFQL	QC-FQL	QC
puzzle-3x3-sparse	task1	$\rightarrow 100$	$\rightarrow 100$	$\rightarrow 100$	$0 \rightarrow 99$	$96 \rightarrow 100$	$100 \rightarrow 100$	$99 \rightarrow 100$	$98 \rightarrow 100$	$97 \rightarrow 100$	$100 \rightarrow 100$	$88 \rightarrow 100$	$\rightarrow 100$	$100 \rightarrow 100$	$100 \rightarrow 100$	$100 \rightarrow$
	task2	$\rightarrow 100$	$\rightarrow 100$	$\rightarrow 100$	$0 \rightarrow 0$	$70 \rightarrow 100$	$98 \rightarrow 100$	$99 \rightarrow 100$	$98 \rightarrow 100$	$98 \rightarrow 100$	$100 \rightarrow 100$	$72 \rightarrow 100$	$\rightarrow 100$	$100 \rightarrow 100$	$86 \rightarrow 100$	$100 \rightarrow$
	task3	$\rightarrow 100$	$\rightarrow 100$	$\rightarrow 100$	$0 \rightarrow 0$	$27 \rightarrow 100$	$100 \rightarrow 98$	$100 \rightarrow 100$	$95 \rightarrow 100$	$95 \rightarrow 100$	$100 \rightarrow 100$	$56 \rightarrow 82$	$\rightarrow 100$	$100 \rightarrow 100$	$50 \rightarrow 100$	$100 \rightarrow$
	task4	$\rightarrow 100$	$\rightarrow 100$	$\rightarrow 100$	$0 \rightarrow 0$	$29 \rightarrow 100$	$97 \rightarrow 87$	$100 \rightarrow 100$	$98 \rightarrow 100$	$86 \rightarrow 100$	$100 \rightarrow 100$	$37 \rightarrow 66$	$\rightarrow 100$	$100 \rightarrow 100$	$75 \rightarrow 100$	$100 \rightarrow$
	task5	$\rightarrow 100$	$\rightarrow 100$	$\rightarrow 100$	$0 \rightarrow 0$	$54 \rightarrow 100$	$98 \rightarrow 99$	$100 \rightarrow 100$	$97 \rightarrow 100$	$96 \rightarrow 100$	$91 \rightarrow 100$	$47 \rightarrow 100$	$\rightarrow 100$	$100 \rightarrow 100$	$4 \rightarrow 100$	$100 \rightarrow$
	avg. (5 tasks)	$\rightarrow 100$	$\rightarrow 100$	$\rightarrow 100$	$0 \rightarrow 0$	$55 \rightarrow 100$	$98 \rightarrow 97$	$100 \rightarrow 100$	$98 \rightarrow 100$	$94 \rightarrow 100$	$98 \rightarrow 100$	$58 \rightarrow 90$	$\rightarrow 100$	$100 \rightarrow 100$	$63 \rightarrow 100$	$100 \rightarrow$
scene-sparse	task1	$\rightarrow 100$	$\rightarrow 100$	$\rightarrow 100$	$1 \rightarrow 97$	$4 \rightarrow 100$	$98 \rightarrow 100$	$69 \rightarrow 100$	$99 \rightarrow 100$	$86 \rightarrow 99$	$22 \rightarrow 100$	$64 \rightarrow 100$	$\rightarrow 100$	$93 \rightarrow 100$	$99 \rightarrow 100$	$100 \rightarrow$
	task2	$\rightarrow 100$	$\rightarrow 100$	$\rightarrow 100$	$0 \rightarrow 97$	$51 \rightarrow 100$	$95 \rightarrow 100$	$93 \rightarrow 99$	$99 \rightarrow 99$	$52 \rightarrow 97$	$4 \rightarrow 42$	$15 \rightarrow 98$	$\rightarrow 100$	$68 \rightarrow 100$	$88 \rightarrow 100$	$98 \rightarrow$
	task3	$\rightarrow 99$	$\rightarrow 100$	$\rightarrow 97$	$0 \rightarrow 0$	$0 \rightarrow 99$	$49 \rightarrow 88$	$68 \rightarrow 100$	$93 \rightarrow 100$	$38 \rightarrow 97$	$1 \rightarrow 24$	$34 \rightarrow 97$	$\rightarrow 100$	$65 \rightarrow 99$	$98 \rightarrow 100$	$90 \rightarrow$
	task4	$\rightarrow 89$	$\rightarrow 92$	$\rightarrow 95$	$0 \rightarrow 0$	$0 \rightarrow 98$	$73 \rightarrow 86$	$75 \rightarrow 96$	$86 \rightarrow 97$	$81 \rightarrow 97$	$50 \rightarrow 94$	$92 \rightarrow 94$	$\rightarrow 97$	$93 \rightarrow 98$	$92 \rightarrow 97$	$93 \rightarrow$
	task5	$\rightarrow 82$	$\rightarrow 74$	$\rightarrow 75$	$0 \rightarrow 0$	$0 \rightarrow 97$	$32 \rightarrow 1$	$25 \rightarrow 81$	$38 \rightarrow 99$	$83 \rightarrow 72$	$14 \rightarrow 91$	$71 \rightarrow 98$	$\rightarrow 82$	$93 \rightarrow 91$	$41 \rightarrow 99$	$43 \rightarrow$
	avg. (5 tasks)	$\rightarrow 94$	$\rightarrow 91$	$\rightarrow 92$	$0 \rightarrow 39$	$11 \rightarrow 99$	$68 \rightarrow 73$	$57 \rightarrow 95$	$85 \rightarrow 99$	$68 \rightarrow 93$	$18 \rightarrow 70$	$57 \rightarrow 97$	$\rightarrow 96$	$83 \rightarrow 98$	$84 \rightarrow 99$	$84 \rightarrow$
cube-double	task1	$\rightarrow 99$	$\rightarrow 99$	$\rightarrow 100$	$1 \rightarrow 0$	$12 \rightarrow 99$	$24 \rightarrow 98$	$63 \rightarrow 99$	$70 \rightarrow 97$	$9 \rightarrow 89$	$33 \rightarrow 99$	$23 \rightarrow 100$	$\rightarrow 100$	$17 \rightarrow 100$	$66 \rightarrow 100$	$84 \rightarrow$
	task2	$\rightarrow 99$	$\rightarrow 98$	$\rightarrow 77$	$0 \rightarrow 0$	$0 \rightarrow 16$	$11 \rightarrow 63$	$36 \rightarrow 92$	$79 \rightarrow 88$	$5 \rightarrow 12$	$8 \rightarrow 96$	$8 \rightarrow 65$	$\rightarrow 99$	$15 \rightarrow 100$	$43 \rightarrow 100$	$79 \rightarrow$
	task3	$\rightarrow 99$	$\rightarrow 99$	$\rightarrow 83$	$0 \rightarrow 0$	$0 \rightarrow 34$	$6 \rightarrow 61$	$22 \rightarrow 96$	$83 \rightarrow 87$	$5 \rightarrow 10$	$1 \rightarrow 92$	$7 \rightarrow 73$	$\rightarrow 99$	$8 \rightarrow 92$	$38 \rightarrow 99$	$68 \rightarrow$
	task4	$\rightarrow 99$	$\rightarrow 97$	$\rightarrow 5$	$0 \rightarrow 0$	$0 \rightarrow 0$	$1 \rightarrow 1$	$9 \rightarrow 1$	$22 \rightarrow 38$	$1 \rightarrow 0$	$0 \rightarrow 2$	$1 \rightarrow 0$	$\rightarrow 98$	$5 \rightarrow 3$	$11 \rightarrow 100$	$22 \rightarrow$
	task5	$\rightarrow 96$	$\rightarrow 88$	$\rightarrow 85$	$0 \rightarrow 0$	$1 \rightarrow 1$	$14 \rightarrow 72$	$12 \rightarrow 92$	$82 \rightarrow 96$	$4 \rightarrow 35$	$13 \rightarrow 96$	$13 \rightarrow 78$	$\rightarrow 88$	$17 \rightarrow 98$	$37 \rightarrow 99$	$74 \rightarrow$
	avg. (5 tasks)	$\rightarrow 99$	$\rightarrow 96$	$\rightarrow 85$	$0 \rightarrow 0$	$3 \rightarrow 30$	$11 \rightarrow 58$	$29 \rightarrow 76$	$68 \rightarrow 80$	$5 \rightarrow 25$	$11 \rightarrow 77$	$11 \rightarrow 65$	$\rightarrow 96$	$12 \rightarrow 79$	$39 \rightarrow 100$	$67 \rightarrow$
cube-triple	task1	$\rightarrow 100$	$\rightarrow 51$	$\rightarrow 0$	$0 \rightarrow 1$	$1 \rightarrow 1$	$2 \rightarrow 16$	$5 \rightarrow 87$	$17 \rightarrow 97$	$1 \rightarrow 0$	$0 \rightarrow 3$	$2 \rightarrow 1$	$\rightarrow 45$	$0 \rightarrow 0$	$19 \rightarrow 100$	$13 \rightarrow$
	task2	$\rightarrow 61$	$\rightarrow 1$	$\rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$1 \rightarrow 0$	$1 \rightarrow 8$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$\rightarrow 8$	$0 \rightarrow 0$	$1 \rightarrow 89$	$1 \rightarrow$
	task3	$\rightarrow 1$	$\rightarrow 2$	$\rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 5$	$1 \rightarrow 11$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$\rightarrow 1$	$0 \rightarrow 0$	$0 \rightarrow 51$	$7 \rightarrow$
	task4	$\rightarrow 43$	$\rightarrow 0$	$\rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$\rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 26$	$0 \rightarrow$
	task5	$\rightarrow 0$	$\rightarrow 0$	$\rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$\rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow$
	avg. (5 tasks)	$\rightarrow 41$	$\rightarrow 11$	$\rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 3$	$1 \rightarrow 18$	$7 \rightarrow 23$	$0 \rightarrow 0$	$0 \rightarrow 1$	$0 \rightarrow 0$	$\rightarrow 1$	$0 \rightarrow 0$	$4 \rightarrow 53$	$6 \rightarrow$
cube-quadruple-100M	task1	$\rightarrow 2$	$\rightarrow 7$	$\rightarrow 0$	$0 \rightarrow 0$	$7 \rightarrow 98$	$0 \rightarrow 0$	$1 \rightarrow 14$	$7 \rightarrow 56$	$1 \rightarrow 0$	$28 \rightarrow 97$	$0 \rightarrow 0$	$\rightarrow 37$	$4 \rightarrow 96$	$6 \rightarrow 98$	$16 \rightarrow$
	task2	$\rightarrow 0$	$\rightarrow 26$	$\rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 3$	$0 \rightarrow 0$	$2 \rightarrow 49$	$0 \rightarrow 0$	$\rightarrow 17$	$0 \rightarrow 0$	$0 \rightarrow 97$	$0 \rightarrow$
	task3	$\rightarrow 0$	$\rightarrow 3$	$\rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$5 \rightarrow 4$	$0 \rightarrow 0$	$\rightarrow 1$	$0 \rightarrow 0$	$0 \rightarrow 94$	$3 \rightarrow$
	task4	$\rightarrow 0$	$\rightarrow 4$	$\rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$1 \rightarrow 32$	$0 \rightarrow 0$	$\rightarrow 2$	$0 \rightarrow 0$	$0 \rightarrow 94$	$1 \rightarrow$
	task5	$\rightarrow 0$	$\rightarrow 0$	$\rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$\rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow 0$	$0 \rightarrow$
	avg. (5 tasks)	$\rightarrow 0$	$\rightarrow 7$	$\rightarrow 0$	$0 \rightarrow 0$	$1 \rightarrow 20$	$0 \rightarrow 0$	$0 \rightarrow 3$	$1 \rightarrow 12$	$0 \rightarrow 0$	$7 \rightarrow 36$	$0 \rightarrow 0$	$\rightarrow 0$	$1 \rightarrow 19$	$1 \rightarrow 77$	$4 \rightarrow$
overall	avg. (25 tasks)	$\rightarrow 67$	$\rightarrow 61$	$\rightarrow 52$	$0 \rightarrow 12$	$14 \rightarrow 50$	$36 \rightarrow 47$	$37 \rightarrow 58$	$51 \rightarrow 63$	$34 \rightarrow 44$	$27 \rightarrow 57$	$25 \rightarrow 50$	$\rightarrow 63$	$39 \rightarrow 59$	$38 \rightarrow 86$	$52 \rightarrow$

表 6: 完整的 OGBench 离线到在线强化学习结果。4 个随机种子。95% 置信区间。




图 10: 按任务划分的完整 OGBench 离线到在线强化学习结果。4 个随机种子。95% 置信区间。




图 11: 按任务划分的完整 OGBench 结果 (选定的基线)。顶部: 按领域划分的汇总图; 底部: 按任务划分的单独图。

选定的基线。图 11 展示了所选基线的结果 (例如, BFN、FQL、RLPD 和 RLPD-AC)。

n 步回报消融结果按任务划分。图 12 展示了图 4 的性能分解。

使用高斯策略的 Q 分块。以下图表展示了性能分解, 针对

图 2。此外, 我们引入了一种新方法进行比较, 即 QC-RLPD, 其中我们在 RLPD-AC (带动作分块的 RLPD) 上添加了行为克隆损失。




图 12: 完整的 OGBench 结果按任务划分 (所选基线)。




图 13: 完整的 RLPD 结果按任务划分。QC-RLPD 是 RLPD-AC (在时间扩展动作空间上的 RLPD)，其中我们额外添加了固定行为克隆系数 0.01。

动作分块大小消融。图 14 包含动作分块大小消融实验的各个任务结果。我们还在图 15 中展示了最难的立方体四重任务的结果。




图 14: 在立方体三重任务上的动作分块大小消融。增大动作分块大小通常有助于提升性能，直到 $h = 25$ 。令人惊讶的是， $h = 25$ 是唯一一个分块大小，使得 QC-FQL 在最难的立方体三重游戏任务 5 上取得了非平凡的成功 (其他方法均无法做到)。




图 15: 在立方体四重游戏任务 4 上的动作分块大小消融。 n 步回报基线（即 FQL-n）在在线学习初期能够取得良好的初始成功率，但随后迅速崩溃。相比之下，我们的方法（即 QC-FQL）不会出现这种崩溃，并且在合理较大的分块大小（*e.g.*, $h \in \{5, 7, 9\}$ ）下能够稳定地解决任务。结果基于 5 个随机种子。

E.3 Robomimic 消融结果

图 16 展示了 QC、QC-FQL、BFN-n、FQL-n、BFN、FQL 在我们三个 Robomimic 任务上的性能。该图展示了图 4（右）的性能分解。




图 16: 按任务划分的完整 Robomimic 消融。对于每个方法在每个任务上，我们使用 5 个随机种子。

E.4 Q 分块在资源效率方面表现如何？

在图 17 中，我们报告了我们的方法和基线在代表性任务立方体三重任务 1 上的运行时间。总体而言，QC-FQL 在离线和在线训练中的运行时间与我们的基线（例如 FQL 和 RLPD）相当。QC 在离线训练中较慢，因为它需要为每个训练样本采样 32 个动作来进行智能体更新（BFN 更快，因为它只需要采样 4 个动作）。对于在线训练，我们每个环境步骤执行一次梯度更新，这使得 QC 仅比其他方法贵约 50%。

最后，我们在下方表 7 中列出了这些方法在代表性领域立方体-三元组-*上的参数数量（假设所有 Q 分块方法的 $h = 5$ ）。

Methods	Parameter Count (in millions)
QC	≈ 4.2
BFN	≈ 4.1
QC-FQL	≈ 5.0
FQL	≈ 4.9
RLPD	≈ 17.2

表 7：各方法的参数数量。RLPD 的参数数量远大于其他方法，因为它使用了 $K = 10$ 个评论家网络，而所有其他方法和基线仅使用 $K = 2$ 个。




图 17：各方法单步执行所需时间（毫秒）。左：离线。右：在线（一个智能体训练步骤和一个环境步骤）。运行时间是在单个 RTX-A5000 上，使用本文默认超参数在立方体-三元组-任务 1 上测量的。