

RDumb: 一种质疑持续测试时自适应进展的简单方法

奥里·普雷斯^{1*} 斯特芬·施奈德^{1,2} 马蒂亚斯·屈默勒^{1†} 马蒂亚斯·贝特格^{1†}

¹ 图宾根大学, 图宾根人工智能中心, 德国 ² 洛桑联邦理工学院, 日内瓦, 瑞士

摘要

测试时自适应 (Test-Time Adaptation) 允许在部署时更新预训练模型以适应不断变化的数据分布。早期工作针对单个固定分布偏移测试这些算法, 而近期工作则提出并应用了长时间尺度持续自适应的方法。为了检验该领域所报告的进展, 我们提出了持续变化损坏 (CCC) 基准, 用以衡量测试时自适应技术的渐近性能。我们发现, 最终除一种最先进的方法外, 所有方法都会崩溃, 且性能不如非自适应模型, 包括那些专门为抵抗性能崩溃而提出的模型。此外, 我们引入了一个简单的基线方法“RDumb”, 它定期将模型重置为其预训练状态。RDumb 在所有考虑的基准上表现优于或与先前提出的最先进方法相当。我们的结果表明, 先前的测试时自适应方法既不能有效正则化自适应以避免崩溃, 也无法超越简单的重置策略。

1 引言

生物视觉在适应持续变化的环境方面表现出非凡的鲁棒性。想象在阴天骑车穿越森林并观察周围世界: 你会遇到各种各样的动物和物体, 并能毫不费力地识别它们。即使天气变化、开始下雨, 或者你骑得更快, 人类视觉系统也能轻松适应并稳健地估计周围环境 [45]。赋予机器视觉类似的能力是一个长期存在且尚未解决的挑战, 在自动驾驶、医学影像和质量控制等众多应用中都有体现。

提升 ImageNet 规模 [37] 分类模型对域偏移鲁棒性的技术包括: 在多样化或大规模数据集上预训练大型模型 [26, 33, 50], 以及通过专门设计的数据增强来强化较小模型 [11, 14, 36]。虽然这些技术在训练阶段应用, 但近期工作 [8, 28, 29, 30, 35, 38, 47, 48] 探索了通过测试时自适应 (Test-Time Adaptation, TTA) 进一步调整模型的可能性。此类方法仅利用输入数据持续更新给定的预训练模型, 而无需访问其标签。测试时熵最小化 (Tent; 47) 已成为最先进 TTA 方法的基础。给定输入图像流, Tent 通过最小化模型输出的熵来更新预训练分类模型, 从而持续提高模型对每张输入图像预测的置信度。

以往的 TTA 工作 [8, 28, 29, 35, 38, 47, 54] 在 ImageNet-C [13] 或较小规模的图像分类基准 [18, 20] 上评估其模型。ImageNet-C 包含 ImageNet 验证集的 75 个副本, 其中每个副本根据 15 种不同噪声在 5 个不同严重级别下进行损坏。当 TTA 模型在 ImageNet-C 上评估时, 它们会针对每种噪声和严重级别 * ori.press@bethgelab.org . [†] 共同资深作者。代码: <https://github.com/oripress/CCC> 分别从其预训练权重开始进行自适应。




图 1: 连续变化的损坏揭示了现有 TTA 方法的局限性。(a) ImageNet-Val、CIN-C 和 CCC 之间的比较。所提出的 CCC 版本比 CIN-C 长 $10 \times$ 倍, 并且可以在不重复图像的情况下自然进一步扩展。CCC 由从一种 ImageNet-C 噪声平滑过渡到另一种噪声的序列组成。对于每一对这样的噪声, 我们构建一条从一种纯噪声连续插值到另一种纯噪声的轨迹, 使得基线准确率保持恒定。对于轨迹上的每个点, 我们从 ImageNet-Val 中采样一批 1k、2k 或 5k 张图像, 随机裁剪和翻转, 并应用噪声组合。(b) 由于其长度短且难度变化大, CIN-C (顶部) 无法揭示 ETA 和 CoTTA 等方法的崩溃, 而 CCC (中部和底部) 可以。

这种一次性自适应方法在将 TTA 模型部署到现实场景中时意义不大。相反, 部署后长时间运行中的稳定性能才是理想目标。

测试时自适应 (TTA) 方法在设计上天然适用于这一场景, 且近期该领域已开始转向在持续自适应设置下测试 TTA 模型 [7, 30, 48]。引人注目的是, 这一转变揭示了主流的 TTA 方法 Tent[47] 的准确率会随时间下降, 最终低于不进行自适应的预训练模型 [30, 48]。在本文中, 我们将任何分类准确率低于不进行自适应的预训练模型的模型称为“崩溃”。

Tent 的这种崩溃行为表明, 若不进行修改, 它无法在长时间尺度的持续自适应中使用。尽管先前的 TTA 基准测试已经揭示了 Tent 的崩溃, 但我们的工作表明, 事实上所有当前的 TTA 方法迟早都会崩溃, 包括那些内置了明确防崩溃策略的方法。

由于现有基准不足以检测多个模型的崩溃, 我们引入了一个图像分类基准, 旨在全面评估 TTA 模型的长期行为。我们的基准名为连续变化损坏 (Continuously Changing Corruptions, CCC), 测试模型在不断变化的图像损坏条件下进行自适应的能力, 类似于雾转为雨或白天转为黑夜。CCC 使我们能够轻松控制可能影响给定方法持续自适应能力的不同因素: 损坏类型及其顺序、图像本身的难度以及损坏转换的速度。最重要的是, 我们的基准长度是先前基准的十倍, 并且通过包含各种损坏组合而更加多样化 (见图 1a)。利用 CCC, 我们发现七个最近发表的最先进的 TTA 方法的准确率低于不进行自适应的预训练模型。虽然 Tent 已被证明会崩溃 [7, 30, 48], 但我们表明这一问题并非 Tent 所独有, 许多其他方法——包括专门设计的持续自适应方法——同样会崩溃。

最后，我们提出“RDumb”¹ 作为一种极简的基线机制，它只是定期将模型重置为其预训练权重。先前的工作采用了更复杂的方法，将熵最小化与各种正则化方法相结合，但我们表明 RDumb 在现有基准和我们的基准（CCC）上都更优越。我们的结果对迄今为止在持续测试时适应方面取得的进展提出了质疑，并为未来方法的现实评估提供了更丰富的基准集。

我们的贡献如下：

- 我们引入了持续适应基准 CCC。我们表明，先前的基准太短，无法有意义地评估长期持续适应行为，并且太不受控制，无法评估短期学习动态。
- 使用 CCC，我们表明，在长时间尺度上训练时，除一种方法外，所有当前测试时适应方法的性能都低于非适应的预训练基线。
- 我们提出“RDumb”作为基线，并表明它通过极简的重置策略优于所有先前的方法。

2 CCC：面向无限测试的持续变化损坏

直到最近，通常仅在单个域偏移的数据集（如 ImageNet-C 的损坏 [13]）上评估测试时适应方法。然而，世界在不断变化，最近社区开始转向持续适应，即评估方法适应持续域偏移的能力 [30, 42, 48]。

在 ImageNet 规模上评估持续适应的主要方法是将 15 种 ImageNet-C 损坏的最高严重程度数据集连接成一个大数据集。我们将 [48] 引入的该数据集的变体称为连接 ImageNet-C（CIN-C）。CIN-C 被 [7, 30, 48] 用来证明 Tent 的崩溃以及近期测试时适应方法的稳定性。

在图 1b 中，我们在 CIN-C 上评估了一系列测试时自适应（TTA）方法，并注意到三个潜在问题：首先，ETA [30] 看似稳定且优于未自适应的预训练基线，但在 CCC 上测试时却暴露出崩溃现象。此外，虽然 CoTTA[48] 的性能明显下降，但尚不清楚它是崩溃还是稳定在基线性能之上或之下。从根本上说，CIN-C 被证明太短，无法产生可靠、结论性的结果。其次，CIN-C 中不同损坏类型之间基线性能的显著变化进一步模糊了对自适应动态的评估。这不仅是影响自适应本身的一个因素（如 [30, 47] 所示），还导致多次运行中性能的大幅波动，使得难以获得清晰可靠的评估。最后，CIN-C 仅包含不同损坏类型之间的突变。相比之下，在现实世界中，领域变化往往可能是平滑、微妙且速度各异的：白天到黑夜、雨到晴、或相机上灰尘的积累。因此，同样重要的是在不受特定时间点约束的持续领域变化上检验 TTA 方法，这构成了稳定持续自适应的相关测试。

本文提出一个新的基准，即连续变化扰动（Continuously Changing Corruptions, CCC），以解决上述问题。CCC 以简单有效的方式解决了基准长度、不受控的基线难度以及过渡平滑性等问题。首先，长度问题得到解决，因为 CCC 的每次运行由一个生成过程构建，该过程能够在不重复使用图像的情况下生成非常长的数据集。本文使用 750 万张图像的生成长度，是 CIN-C 的 10 倍。若未来工作（其中坍塌更慢）需要比较方法，在 CCC 框架内生成更长的基准也轻而易举。其次，由于 [30, 47] 均表明数据集难度是研究适应时的混杂因素，因此各基准运行的难度保持稳定。此外，本文考察了三种不同的难度级别，以确保评估全面且受控。最后，CCC 展现出平滑的域偏移：它对每张图像施加两种扰动。随时间推移，一种扰动的严重程度平滑增加，而另一种的严重程度平滑降低，从而维持所需难度。本文还研究了应用此过程的三种不同速度。接下来将概述数据集的生成过程。

¹ 该名称灵感来源于 GDumb [32]。




图 2: (a) CCC 的每种扰动由在不同严重程度下施加两种 ImageNet-C 扰动组成。本文将单个严重程度扩展得比 ImageNet-C 更细粒度，从而允许更平滑的噪声变化，并指数级增加（噪声，严重程度）组合。角落已放大以便查看，放大可查看更多细节。(b) 具有恒定基线准确率的数据集序列。序列从左侧开始，此时运动模糊被置零，并在顶部结束，此时高斯噪声被置零。红色、橙色和黄色分别对应 CCC-Easy、CCC-Medium 和 CCC-Hard 中的轨迹。

连续变化的图像扰动 为了实现不同损坏之间的平滑过渡，本文为 ImageNet-C 数据集引入了一套更细粒度的严重程度等级体系。我们将原始损坏的参数（整数严重程度 1 至 5）插值到更细粒度的严重程度等级，范围从 0 到 5，步长为 0.25。对每张图像施加两种不同的 ImageNet-C 损坏，从而可以在降低一种损坏严重程度的同时提高另一种损坏的严重程度。因此，CCC 的损坏由四元组 (c_1, s_1, c_2, s_2) 给出，其中 c_1 和 c_2 是 ImageNet-C 损坏类型， s_1 和 s_2 是严重程度等级。在施加此类损坏时，先施加 c_1 ，再施加 c_2 ，并分别采用相应的严重程度（见图 2a）。

校准至期望基线准确率 为了控制基线准确率，需要了解两种噪声及其各自严重程度的每种组合的难度。为此，首先从 ImageNet 验证集中选取 5,000 张图像的子集。对于每种损坏 (c_1, s_1, c_2, s_2) ，对全部 5,000 张图像施加相应损坏，并使用预训练的 ResNet-50 [10] 评估所得图像。所得准确率即本文所称的基线准确率，用于控制难度。总计评估超过 4.63 亿张损坏图像。先前工作 [12] 使用 AlexNet [19] 测量归一化准确率，这在当前背景下相关性较低。此外，非自适应视觉变换器在 CCC 上的准确率同样稳定（图 4）。

生成基准运行 在完成损坏对的校准后，我们准备了具有不同基线准确率、转换速度和噪声顺序的基准运行。我们选择了 3 种不同的基线准确率：34%、17% 和 2%（分别对应 CCC-Easy、CCC-Medium、CCC-Hard）。对于每种难度，我们进一步选择 3 种转换速度：1k、2k、5k。最后，对于每种难度和转换速度的组合，我们使用由 3 个随机种子确定的 3 种不同的噪声顺序。为了生成每次运行，我们首先选择在校准中与期望基线准确率最接近的严重程度下的初始损坏。然后，我们通过反复将第一种噪声的严重程度降低 0.25 或将第二种噪声的严重程度提高 0.25，过渡到噪声顺序中的第二种损坏，以使基线准确率尽可能接近目标（见图 2）。在每条路径的每一步中，我们根据期望的转换速度从 ImageNet 验证集中采样 1k、2k 或 5k 张图像。每张图像都经过随机裁剪和翻转以增加数据集的多样性，然后进行损坏处理。

一旦从初始损坏到第二种损坏的路径完成，就重复该过程以过渡到第三种损坏，依此类推（更多细节见附录 B）。最终，我们得到了 3 种难度，每种难度包含 9 个基准运行。速度为 2k 的 CCC-Medium 大致对应于 CIN-C 的难度和转换速度。

3 RDumb：关闭再打开你的模型

持续测试时自适应需要在部署期间在任意长的时间尺度上成功自适应模型。以固定间隔将模型重置为其初始权重，从设计上满足了这一标准，同时允许在短时间尺度上受益于自适应。令人惊讶的是，这种方法以前从未被尝试过（更多讨论见附录 E）。

关于自适应损失的选择，我们基于 ETA 中使用的加权熵 [30]。对于输入图像流 $\mathbf{x}_1, \mathbf{x}_2, \dots$ ，我们计算类别概率 $\mathbf{y}_t = f_{\Theta_t}(\mathbf{x}_t)$ 并优化损失函数

$$L(\mathbf{y}_t; \bar{\mathbf{y}}_{t-1}) = \left(\frac{\mathbb{1}[(|\cos(\mathbf{y}_t, \bar{\mathbf{y}}_{t-1})| < \epsilon) \wedge (H(\mathbf{y}_t) < H_0)]}{\exp(H(\mathbf{y}_t) - H_0)} \right) H(\mathbf{y}_t) \quad (1)$$

该权重利用每个预测与先前预测类概率平均值的相似度来加权其熵 $H(\mathbf{y}_t) = -\mathbf{y}_t^\top (\log \mathbf{y}_t)$ ，并与固定熵阈值进行比较 $H_0 \cdot \cos(\mathbf{u}, \mathbf{v})$ ，其中 $\bar{\mathbf{y}}_t = (\mathbf{y}_1 + \dots + \mathbf{y}_t)/t$ 表示向量 $\mathbf{u}$ 与 $\mathbf{v}$ 之间的余弦相似度。在每一步中，使用 Adam 优化器 [17] 更新（部分）权重 Θ_t 。每 T 步，将 Θ_t 重置为基线权重 Θ_0 。我们遵循 [30] 使用 $\epsilon = 0.05$ 和 $H_0 = 0.4 \times \ln 10^3$ ，并根据 IN-C 中的保留噪声选择 $T = 1000$ （见第 6 节）。

4 实验设置

我们将 RDumb 与一系列近期发表的测试时自适应模型进行基准比较。所有模型均采用批大小为 64 的设置。在所有模型中，批归一化统计量实时估计，仿射偏移和缩放参数根据下述模型特定策略进行优化。

- **批归一化 (BN) 自适应** [29, 38] 在测试时分别对每个批次估计批归一化统计量（均值和方差）。仿射变换参数不进行自适应。
- Tent[46] 在测试集上优化熵目标，以更新批归一化的缩放和偏移参数（除学习统计量外）。
- **鲁棒伪标签 (Robust Pseudo Labeling (RPL))** [35] 采用教师-学生方法并结合抗标签噪声损失。
- **共轭伪标签 (Conjugate Pseudo Labels, CPL)** [8] 利用元学习在一类可能的函数中学习最优的自适应目标函数。
- **软似然比 (Soft Likelihood Ratio, SLR)** [28] 使用一种类似于熵的损失函数，但不存在梯度消失问题。抗坍缩机制：引入额外损失以鼓励模型在各类别上产生均匀预测，并保持网络最后一层冻结。
- **持续测试时自适应 (Continual Test Time Adaptation, CoTTA)** [48] 采用教师-学生方法并结合数据增强。抗坍缩机制：每次迭代中，0.1% 的权重被重置回其预训练值。
- **高效测试时自适应 (Efficient Test Time Adaptation, EATA)** [30] 使用两个加权函数对其输出进行加权：第一个基于熵（熵较低的输出获得更高权重），第二个基于多样性（与之前见过的输出相似的输出被排除）。抗坍缩机制：使用 L_2 正则化损失以鼓励模型权重保持接近其初始值。
- **无权重正则化的高效测试时自适应 (ETA)** 为完整性起见，本文还测试了 ETA，即去除正则化损失的高效测试时自适应方法，该方法由 [30] 提出。
- RDumb 是本文提出的通过重置来缓解坍缩的基线方法。本文每 $T = 1,000$ 步重置一次，该步数由在留出集上的超参数搜索确定（第 6 节）。

遵循原始实现，Tent、ETA、EATA 和 RDumb 使用学习率为 $2.5 \cdot 10^{-4}$ 的 SGD。RPL 使用学习率为 $5 \cdot 10^{-3}$ 的 SGD。SLR 使用 Adam 优化器，学习率为




图 3: 所有评估模型随已观测样本数量变化的适应性能。(a) CIN-C。模型性能在基准的 10 次运行上取平均。(b) CCC。模型性能在三个难度级别的 27 次运行上取平均。CCC 简单、中等和困难级别的单独图表见附录 C 图 10。

学习率为 $6 \cdot 10^{-4}$ 。CoTTA 使用学习率为 0.01 的 SGD，CPL 使用学习率为 0.001 的 SGD。

5 结果

与 CIN-C 不同，CCC 揭示了持续适应过程中的坍塌现象。对于所评估的三个模型，在 CIN-C 上的评估未能得出关于检测崩溃的结论或结果不准确：CoTTA 在 CCC 上崩溃，而 CIN-C 显示其呈下降趋势，但最终性能仍优于基线（图 3a）。此外，ETA 在 CIN-C 上未表现出崩溃迹象，但在 CCC 上崩溃非常明显（图 3b，更准确地说是在 CCC-Medium 和 CCC-Hard 上，见附录图 10）。当使用 ViT 骨干网络进行测试时，EATA 在 CIN-C 上优于预训练模型（图 4a），但在 CCC 上劣于预训练模型（图 4b，表 2、3）。最后，SLR 在 CIN-C 上似乎较为稳定，但准确率仅约为 10%。CCC 揭示这仅部分正确：在 CCC-Hard 上，SLR 不稳定并崩溃至接近随机猜测的准确率。

总之，在 CCC 上评估的模型显示出明显的极限，而这些极限在 CIN-C 上无法观察到。运行之间的难度方差较大，且其长度较短。

表 1: ResNet-50 模型在 CIN-C、CIN-3DCC 和 CCC 上的平均准确率。对于每个 CCC 划分（简单、中等和困难），取 9 次运行的平均值。对于 CIN-C 和 CIN-3DCC 实验，报告的准确率是 10 种不同噪声排列的平均值。灰色表示崩溃。

Adaptation method	CIN-C	CIN-3DCC	CCC-Easy	CCC-Medium	CCC-Hard	Average
Pretrained [10]	18.0 $\pm$ 0.0	31.5 $\pm$ 0.0	34.1 $\pm$ 0.22	17.3 $\pm$ 0.21	1.5 $\pm$ 0.02	20.5
BN [29, 38]	31.5 $\pm$ 0.02	35.7 $\pm$ 0.02	42.6 $\pm$ 0.39	27.9 $\pm$ 0.74	6.8 $\pm$ 0.31	28.9
Tent [47]	15.6 $\pm$ 3.5	24.4 $\pm$ 3.5	3.9 $\pm$ 0.58	1.4 $\pm$ 0.17	0.51 $\pm$ 0.07	9.2
RPL [35]	21.8 $\pm$ 3.6	30.0 $\pm$ 3.6	7.5 $\pm$ 0.83	2.7 $\pm$ 0.36	0.67 $\pm$ 0.14	12.5
SLR [28]	12.4 $\pm$ 7.7	12.2 $\pm$ 7.7	22.2 $\pm$ 18.4	7.7 $\pm$ 9.0	0.66 $\pm$ 0.57	11.0
CPL [8]	3.0 $\pm$ 3.3	5.7 $\pm$ 3.3	0.41 $\pm$ 0.06	0.22 $\pm$ 0.03	0.14 $\pm$ 0.01	1.9
CoTTA [48]	34.0 $\pm$ 0.68	37.6 $\pm$ 0.68	14.9 $\pm$ 0.88	7.7 $\pm$ 0.43	1.1 $\pm$ 0.16	19.1
EATA [30]	41.8 $\pm$ 0.98	43.6 $\pm$ 0.98	48.2 $\pm$ 0.6	35.4 $\pm$ 1.0	8.7 $\pm$ 0.8	35.5
ETA [30]	43.8 $\pm$ 0.33	42.7 $\pm$ 0.33	41.4 $\pm$ 0.95	1.1 $\pm$ 0.43	0.23 $\pm$ 0.05	25.8
RDumb (ours)	46.5 $\pm$ 0.15	45.2 $\pm$ 0.15	49.3 $\pm$ 0.88	38.9 $\pm$ 1.4	9.6 $\pm$ 1.6	37.9




图 4: 使用 ViT 骨干网络的测试时自适应: (a) 在 CIN-C 上, EATA 优于预训练基线 (44.4 个百分点对 40.1 个百分点)。 (b) 在 CCC-Medium 上, EATA 劣于预训练基线 (38.5 个百分点对 42.0 个百分点)。RDumb (本文方法) 始终优于 EATA 和基线。

表 2: 不同骨干网络架构在 CCC-Medium 上的平均准确率。报告的准确率是 9 次运行的平均值。使用的骨干网络: [3, 10, 23, 43, 51], † : AugMix [14], ‡ : DeepAugment [11]。灰色表示崩溃。

Method	RN18	RN34	RN50	RN50†	RN50‡†	RNxt101 †‡	ViT-B16	MaxViT-T	SwinViT-T
Pretrained	12.2	17.3	17.3	27.9	38.9	47.8	42.0	45.1	33.2
EATA	26.8	30.8	35.4	46.5	52.3	58.5	38.5	47.1	35.6
RDumb	32.5	37.2	38.9	47.0	51.9	58.4	50.2	49.9	36.5

RDumb 是持续自适应的强基线。RDumb 在既有基准 (CIN-C、CIN-3DCC) 以及我们的持续自适应基准 CCC 上均优于所有先前方法 (表 1 和图 3)。具体而言, 我们优于 EATA, 在 CIN-C 上准确率提升超过 11% (从 41.8 个百分点提升至 46.5 个百分点), 在所有评估数据集上平均提升近 7%。虽然无法超越 RDumb, 但我们注意到 EATA 也是防止崩溃的强方法, 除了表 2 中的反例。

结果迁移至 Imagenet-3D 常见损坏数据集。为进一步验证本文方法的有效性, 本文在 Imagenet-3DCC [16] 上展示结果, 该数据集包含 12 种损坏类型, 在应用于图像时考虑了物体间的几何关系与距离。与 CIN-C 类似, 本文在 IN-3DCC 所有噪声串联的 10 种不同排列上测试模型, 称之为 CIN-3DCC。与 CIN-C 和 CCC 的情况相同, RDumb 优于所有先前方法 (表 1)。

结果迁移至视觉变换器。为进一步验证本文观点, 本文使用视觉变换器 (ViT, 3) 骨干网络测试 EATA 与本文方法 (图 4)。与 ResNet-50 相比, 使用 ViT 时本文方法与 EATA 的平均准确率差距更大: 在 CIN-C 和 CCC 上差距分别为 10.9 个百分点和 11.7 个百分点。此外, EATA 在 CCC 上的准确率低于预训练且不进行适应的模型²。这种性能崩溃只能通过 CCC 观察到, 而在 CIN-C 上评估时无法发现。

RDumb 无需调参即可适应多种架构。本文在一系列主流骨干架构上评估 RDumb 与 EATA。在评估的九种架构中 (见

² 增大正则化参数值无助于稳定模型, 见附录 D。

表 3: 不同骨干架构在 CCC-Hard 上的平均准确率。报告的准确率为 9 次运行的平均值。使用的骨干网络: [3, 10, 23, 43, 51], † : AugMix [14], ‡ : DeepAugment [11]。灰色表示性能崩溃。

Method	RN18	RN34	RN50	RN50†	RN50 †‡	RNxt101 †‡	ViT-B16	MaxViT-T	SwinViT-T
Pretrained	0.82	1.3	1.5	5.6	24.3	15.6	22.0	22.0	9.3
EATA	6.4	7.6	8.7	17.7	30.3	36.3	8.6	15.4	8.6
RDumb	8.3	10.7	9.6	14.7	29.9	35.6	23.8	22.0	8.0

表 2、3) , RDumb 在其中的七个数据集上平均超出 EATA 4.5 个百分点, 而在其余两个数据集上仅平均落后 0.25 个百分点。

6 分析与消融

最优重置间隔。为确定最优重置间隔, 我们在 CIN-C 上使用 IN-C 保留噪声运行 ETA, 重置间隔为 $T \in [125, 250, 500, 1000, 1500, 2000]$ 。我们将 4 种保留噪声在严重度 5 下拼接作为基础测试集。该基础测试集重复使用, 直到模型处理 75 万张图像, 这与 CIN-C 的长度相等。我们对 4 种保留损坏的所有排列均执行此操作。在该保留集上, 我们发现最优 T 等于 1000。

表 4: 在 CIN-C 保留集上不同重置时间下本方法的准确率

T (步数)	125	250	500	1000	1500	2000	准确率 [%]
	42.1	44.4	46.0	46.7	46.5	46.4	

RDumb 对超参数较不敏感。本方法的另一优势在于其对超参数的敏感性低于 EATA。我们对 E_0 参数——该超参数控制因高熵而被过滤掉的输出数量——进行了简单的超参数搜索。本方法在所有测试的超参数下均一致优于 EATA (表 5), 且在最高值 0.7 时, EATA 在所有划分上的准确率几乎降至随机水平, 而本方法并未如此。此外, RDumb 的性能受益于微调 ($H_0 = \{0.2, 0.3\}$), 而 EATA 无法提升。

表 5: 在多种 H_0 取值下, 所有 CCC 划分的平均准确率。本文其余实验均采用 $H_0 = 0.4 \times \ln 10^3$, 与 [30] 一致。

$H_0 \times \ln 10^3$	0.1	0.2	0.3	0.4	0.5	0.6	0.7
EATA	27.8	27.9	29.9	30.8	28.7	28.0	0.33
RDumb (ours)	31.6	32.9	33.1	32.6	30.7	25.7	16.8

RDumb 之所以有效, 是因为 ETA 能迅速达到最大适应性能。ETA 能够快速从零开始适应新噪声。在每个保留集噪声及其严重程度上, ETA 仅需观察约 12,500 个样本 (约 200 个适应步骤) 即可达到最大准确率 (图 5a)。此后, 准确率以比初始增长更慢的速度衰减。因此, 当从零开始重置并重新适应时, 仅需经历少数几步预测明显次优的阶段, 性能便再次接近最优。

重置与正则化的比较。以往工作通常优化两个损失项: 一个损失鼓励对未见数据的适应, 另一个损失对模型进行正则化以防止崩溃。优化两个损失应比仅优化一个更难——我们在 CIN-C 上的短期适应中发现了相关证据 (图 5b): ETA 与 EATA 优化相同的损失, 但 EATA 额外优化了一个防崩溃损失。因此, ETA 在 CIN-C 上比 EATA 高出 2 个百分点。




图 5: (a) ETA 在 ImageNet-C 保留噪声及其各严重程度上的归一化准确率随时间变化。对于保留集中的每种噪声, ETA 都能非常迅速地达到最大准确率。(b) Rdumb 具有与 ETA 相同的快速适应特性, 而 EATA 中的正则化则减缓了适应速度。

崩溃分析。我们现在研究所观察到的崩溃行为的潜在原因与影响。我们提出了一个理论模型（完整说明见附录 A），该模型能够解释崩溃与非崩溃两种运行情况。该模型由一个批归一化层和一个线性层组成，使用 Tent 目标进行训练。在此模型框架下，我们可以展示两种情形。第一种情形中，模型成功适应并在高准确率处趋于平稳（图 7a）。第二种情形中，我们观察到早期适应之后随之发生崩溃（图 6a、7a）。数据中噪声的特性决定了我们观察到的是成功适应还是失败适应的情况。

有趣的是，模型预测权重幅值在优化过程中会增大；这种熵最小化的特征既出现在理论模型中，也出现在使用 RDumb 且不重置的 CCC-Medium 真实实验中（图 6）。遗憾的是，权重爆炸仅在模型性能已经崩溃之后才发生（图 8b）。该效应在所有层中均可观察到（图 6c、8）。

7 讨论与相关工作

领域自适应。在实践中，部署时的数据分布与训练时不同，因此领域自适应任务，即让模型适应不同目标分布的任务，受到了广泛关注 [6, 14, 21, 22, 36, 42, 47]。领域自适应方法根据适应期间假设可用的信息分为不同类别。有些方法假设可以访问目标分布的标注数据 [27, 53]，而无监督领域自适应方法则假设模型在适应时可以访问标注的源数据和未标注的目标数据 [5, 21, 22, 41]。对实际应用最有用的是测试时自适应，其任务是在不访问完整目标分布或原始训练分布的情况下，即时适应目标数据 [29, 30, 35, 38, 42, 47, 54]。

除了上述划分之外，还可以进一步区分对目标域变化方式所做的假设。许多学术基准关注一次性分布偏移。然而，在实际应用中，目标分布很容易随时间持续变化，例如由于天气和光照条件变化，或传感器损坏。因此，持续自适应这一设置最近受到越来越多的关注。据我们所知，最早将分类器适应于不断演变的目标域的例子是 [15]，它学习一系列变换以保持数据表示随时间相似。[5, 44, 49] 为此使用了对抗性领域自适应方法。[2] 指出其中两种方法可能容易发生灾难性遗忘 [34]。为了解决这个问题，人们提出了不同的解决方案 [1, 2, 24, 28, 30, 48]。

测试时自适应方法传统上应用于一次性领域变化的场景，但也可直接应用于持续适应场景，且近期一些方法已明确针对持续适应进行设计和测试 [30, 47, 48]。由于测试时自适应方法仅使用测试数据且不改变训练过程，因此特别易于应用，并已被证明优于其他领域自适应方法 [6, 29, 36, 38]。因此，本文仅关注测试时自适应方法，并在第 4 节中进行了更详细的讨论。




图 6: 真实数据上熵最小化崩溃的分析。在 (a) 中展示了由批归一化和线性层组成的双层玩具模型 (b) 在准确率和权重幅度方面的学习动态。与理论分析一致, 我们发现所有层的自适应权重随时间持续增加 (c), 即使在 CCC-Medium 上的准确率表明崩溃发生很久之后仍然如此。关于玩具模型 (a - b) 的更多性质以及 (c) 的放大视图, 请参见图 7 - 8 和附录 A。

持续适应基准。 尽管持续变化的数据集在持续学习文献中被使用, 例如 [4, 9, 25, 39, 40, 52], 但它们仅在最近才被用于测试时自适应基准。与所有先前基准相比, 本文旨在评估持续适应方法在噪声连续变化时, 在长时间跨度内的变化情况。用于测试时自适应的最长数据集总共包含数十万张带标签图像, 而本文每次运行适应 750 万张图像。其他数据集由长度为 10-20 秒的短视频片段组成 [25, 39, 40]。除了最大化数据集长度外, 本文还致力于创建一个校准良好且与著名的 ImageNet-C 数据集密切相关的数据集。此外, 通过本文的噪声综合方法, 可以保证每次评估运行中包含多种噪声, 控制噪声变化的速度, 并控制生成噪声的难度。最后, CCC 考虑了不同的适应速度, 正如 [35] 和 [28] 所证明的那样。他们表明, 在 ImageNet-C 上训练其方法超过一个训练轮次可带来更好的性能。

8 结论

测试时自适应 (Test-Time Adaptation, TTA) 技术正越来越多地应用于持续自适应场景。然而, 本文表明, 当前所有 TTA 技术在部分持续自适应场景中都会失效, 最终表现甚至不如非自适应模型。尽管某些方法在特定情况下保持稳定, 但其性能仍被本文提出的简单基线“RDumb”所超越。RDumb 通过周期性将模型重置为预训练状态来避免失效。上述观察得益于本文新提出的持续自适应基准 (CCC), 该基准经过精心设计, 用于精确评估 TTA 方法的长期与短期自适应行为。本文期望 CCC 能够成为开发更稳定自适应方法的有用工具。

致谢

感谢 Evgenia Rusak、Çağatay Yıldız、Shyamgopal Karthik 和 Ofir Press 对手稿的有益讨论与反馈。

感谢国际马克斯·普朗克智能系统研究学院 (IMPRS-IS) 对 OP 和 StS 的支持; StS 确认其为欧洲学习与智能系统实验室 (ELLIS) 博士项目成员。StS 获得谷歌研究博士奖学金支持。MB 为机器学习卓越集群成员 (卓越集群编号 2064/1 – 项目编号 390727645), 并感谢德国研究基金会 (DFG) 的支持: SFB 1233, 鲁棒视觉: 推理原理与神经机制, 子项目 TP 4, 项目编号: 276693517。本工作由图宾根人工智能中心支持。作者声明无利益冲突。

作者贡献

以下作者顺序按各贡献类别确定。概念构思, RDumb: OP, 所有作者提供意见; 概念构思, CCC: StS、MB、MK; 方法论: OP、StS; 软件: OP; 数据策展: OP; 调查: OP; 形式化分析: MK、StS、OP; 可视化: StS、OP, 所有作者提供意见; 撰写, 初稿: OP、StS、MK; 撰写, 审阅与编辑: 所有作者; 监督: MB、MK、StS。

参考文献

- [1] Abnar, S., Berg, R. v. d., Ghiasi, G., Dehghani, M., Kalchbrenner, N., and Sedghi, H. (2021). Gradual domain adaptation in the wild: When intermediate distributions are absent. *arXiv preprint arXiv:2106.06080*.
- [2] Bobu, A., Tzeng, E., Hoffman, J., and Darrell, T. (2018). Adapting to continuously shifting domains. *Workshop Track - ICLR 2018*.
- [3] Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., et al. (2020). An image is worth 16x16 words: Transformers for image recognition at scale. *arXiv preprint arXiv:2010.11929*.
- [4] Feng, F., Chan, R. H., Shi, X., Zhang, Y., and She, Q. (2019). Challenges in task incremental learning for assistive robotics. *IEEE Access*, 8:3434–3441.
- [5] Ganin, Y., Ustinova, E., Ajakan, H., Germain, P., Larochelle, H., Laviolette, F., Marchand, M., and Lempitsky, V. (2016). Domain-adversarial training of neural networks. *The journal of machine learning research*, 17(1):2096–2030.
- [6] Geirhos, R., Rubisch, P., Michaelis, C., Bethge, M., Wichmann, F. A., and Brendel, W. (2018). Imagenet-trained cnns are biased towards texture; increasing shape bias improves accuracy and robustness. *arXiv preprint arXiv:1811.12231*.
- [7] Gong, T., Jeong, J., Kim, T., Kim, Y., Shin, J., and Lee, S.-J. (2022). Note: Robust continual test-time adaptation against temporal correlation. In *Advances in Neural Information Processing Systems*.
- [8] Goyal, S., Sun, M., Raghunathan, A., and Kolter, Z. (2022). Test-time adaptation via conjugate pseudo-labels. *arXiv preprint arXiv:2207.09640*.
- [9] Han, J., Liang, X., Xu, H., Chen, K., Lanqing, H., Mao, J., Ye, C., Zhang, W., Li, Z., Liang, X., et al. (2021). Soda10m: A large-scale 2d self/semi-supervised object detection dataset for autonomous driving. In *Thirty-fifth Conference on Neural Information Processing Systems Datasets and Benchmarks Track (Round 2)*.
- [10] He, K., Zhang, X., Ren, S., and Sun, J. (2016). Deep residual learning for image recognition. In *2016 IEEE Conference on Computer Vision and Pattern Recognition, CVPR 2016, Las Vegas, NV, USA, June 27-30, 2016*, pages 770–778. IEEE Computer Society.

- [11] Hendrycks, D., Basart, S., Mu, N., Kadavath, S., Wang, F., Dorundo, E., Desai, R., Zhu, T., Parajuli, S., Guo, M., et al. (2020a). The many faces of robustness: A critical analysis of out-of-distribution generalization. *ArXiv preprint*, abs/2006.16241.
- [12] Hendrycks, D. and Dietterich, T. (2019a). Benchmarking neural network robustness to common corruptions and perturbations. *arXiv preprint arXiv:1903.12261*.
- [13] Hendrycks, D. and Dietterich, T. G. (2019b). Benchmarking neural network robustness to common corruptions and perturbations. In *7th International Conference on Learning Representations, ICLR 2019, New Orleans, LA, USA, May 6-9, 2019*. OpenReview.net.
- [14] Hendrycks, D., Mu, N., Cubuk, E. D., Zoph, B., Gilmer, J., and Lakshminarayanan, B. (2020b). Augmix: A simple data processing method to improve robustness and uncertainty. In *8th International Conference on Learning Representations, ICLR 2020, Addis Ababa, Ethiopia, April 26-30, 2020*. OpenReview.net.
- [15] Hoffman, J., Darrell, T., and Saenko, K. (2014). Continuous manifold based adaptation for evolving visual domains. In *Computer Vision and Pattern Recognition (CVPR)*.
- [16] Kar, O. F., Yeo, T., Atanov, A., and Zamir, A. (2022). 3d common corruptions and data augmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 18963–18974.
- [17] Kingma, D. P. and Ba, J. (2014). Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*.
- [18] Krizhevsky, A., Hinton, G., et al. (2009). Learning multiple layers of features from tiny images.
- [19] Krizhevsky, A., Sutskever, I., and Hinton, G. E. (2012). Imagenet classification with deep convolutional neural networks. In Bartlett, P. L., Pereira, F. C. N., Burges, C. J. C., Bottou, L., and Weinberger, K. Q., editors, *Advances in Neural Information Processing Systems 25: 26th Annual Conference on Neural Information Processing Systems 2012. Proceedings of a meeting held December 3-6, 2012, Lake Tahoe, Nevada, United States*, pages 1106–1114.
- [20] LeCun, Y., Cortes, C., and Burges, C. (2010). Mnist handwritten digit database. *ATT Labs [Online]*. Available: <http://yann.lecun.com/exdb/mnist>, 2.
- [21] Lee, D.-H. (2013). Pseudo-label: The simple and efficient semi-supervised learning method for deep neural networks. In *ICML Workshop : Challenges in Representation Learning (WREPL)*.
- [22] Liang, J., Hu, D., Wang, Y., He, R., and Feng, J. (2021). Source data-absent unsupervised domain adaptation through hypothesis transfer and labeling transfer. *IEEE Transactions on Pattern Analysis and Machine Intelligence*.
- [23] Liu, Z., Hu, H., Lin, Y., Yao, Z., Xie, Z., Wei, Y., Ning, J., Cao, Y., Zhang, Z., Dong, L., Wei, F., and Guo, B. (2022). Swin transformer v2: Scaling up capacity and resolution. In *International Conference on Computer Vision and Pattern Recognition (CVPR)*.
- [24] Liu, Z., Miao, Z., Pan, X., Zhan, X., Lin, D., Yu, S. X., and Gong, B. (2020). Open compound domain adaptation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 12406–12415.
- [25] Lomonaco, V. and Maltoni, D. (2017). Core50: a new dataset and benchmark for continuous object recognition. In Levine, S., Vanhoucke, V., and Goldberg, K., editors, *Proceedings of the 1st Annual Conference on Robot Learning*, volume 78 of *Proceedings of Machine Learning Research*, pages 17–26. PMLR.
- [26] Mahajan, D., Girshick, R., Ramanathan, V., He, K., Paluri, M., Li, Y., Bharambe, A., and van der Maaten, L. (2018). Exploring the limits of weakly supervised pretraining. In *Proceedings of the European Conference on Computer Vision (ECCV)*.
- [27] Motiian, S., Jones, Q., Iranmanesh, S., and Doretto, G. (2017). Few-shot adversarial domain adaptation. *Advances in neural information processing systems*, 30.

- [28] Mummadi, C. K., Hutmacher, R., Rambach, K., Levinkov, E., Brox, T., and Metzen, J. H. (2021). Test-time adaptation to distribution shift by confidence maximization and input transformation. *arXiv preprint arXiv:2106.14999*.
- [29] Nado, Z., Padhy, S., Sculley, D., D’Amour, A., Lakshminarayanan, B., and Snoek, J. (2020). Evaluating prediction-time batch normalization for robustness under covariate shift. *ArXiv preprint, abs/2006.10963*.
- [30] Niu, S., Wu, J., Zhang, Y., Chen, Y., Zheng, S., Zhao, P., and Tan, M. (2022). Efficient test-time model adaptation without forgetting. *arXiv preprint arXiv:2204.02610*.
- [31] Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., Gimelshein, N., Antiga, L., et al. (2019). Pytorch: An imperative style, high-performance deep learning library. *Advances in neural information processing systems*, 32.
- [32] Prabhu, A., Torr, P. H., and Dokania, P. K. (2020). Gdumb: A simple approach that questions our progress in continual learning. In *Computer Vision—ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part II 16*, pages 524–540. Springer.
- [33] Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Askell, A., Mishkin, P., Clark, J., et al. (2021). Learning transferable visual models from natural language supervision. In *International Conference on Machine Learning*, pages 8748–8763. PMLR.
- [34] Ratcliff, R. (1990). Connectionist models of recognition memory: constraints imposed by learning and forgetting functions. *Psychological review*, 97(2):285.
- [35] Rusak, E., Schneider, S., Pachitariu, G., Eck, L., Gehler, P. V., Bringmann, O., Brendel, W., and Bethge, M. (2021). If your data distribution shifts, use self-learning. *Transactions of Machine Learning Research*.
- [36] Rusak, E., Schott, L., Zimmermann, R., Bitterwolf, J., Bringmann, O., Bethge, M., and Brendel, W. (2020). Increasing the robustness of dnns against image corruptions by playing the game of noise. *ArXiv preprint, abs/2001.06057*.
- [37] Russakovsky, O., Deng, J., Su, H., Krause, J., Satheesh, S., Ma, S., Huang, Z., Karpathy, A., Khosla, A., Bernstein, M., et al. (2015). Imagenet large scale visual recognition challenge. *International journal of computer vision (IJCV)*.
- [38] Schneider, S., Rusak, E., Eck, L., Bringmann, O., Brendel, W., and Bethge, M. (2020). Improving robustness against common corruptions by covariate shift adaptation. In *Advances in neural information processing systems*.
- [39] Shi, X., Li, D., Zhao, P., Tian, Q., Tian, Y., Long, Q., Zhu, C., Song, J., Qiao, F., Song, L., Guo, Y., Wang, Z., Zhang, Y., Qin, B., Yang, W., Wang, F., Chan, R. H. M., and She, Q. (2020). Are we ready for service robots? the OpenLORIS-Scene datasets for lifelong SLAM. In *2020 International Conference on Robotics and Automation (ICRA)*, pages 3139–3145.
- [40] Sun, P., Kretzschmar, H., Dotiwalla, X., Chouard, A., Patnaik, V., Tsui, P., Guo, J., Zhou, Y., Chai, Y., Caine, B., Vasudevan, V., Han, W., Ngiam, J., Zhao, H., Timofeev, A., Ettinger, S., Krivokon, M., Gao, A., Joshi, A., Zhang, Y., Shlens, J., Chen, Z., and Anguelov, D. (2020). Scalability in perception for autonomous driving: Waymo open dataset. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*.
- [41] Sun, Y., Tzeng, E., Darrell, T., and Efros, A. A. (2019a). Unsupervised domain adaptation through self-supervision. *ArXiv preprint, abs/1909.11825*.
- [42] Sun, Y., Wang, X., Liu, Z., Miller, J., Efros, A. A., and Hardt, M. (2019b). Test-time training for out-of-distribution generalization. *ArXiv preprint, abs/1909.13231*.
- [43] Tu, Z., Talebi, H., Zhang, H., Yang, F., Milanfar, P., Bovik, A., and Li, Y. (2022). Maxvit: Multi-axis vision transformer. In *Computer Vision—ECCV 2022: 17th European Conference, Tel Aviv, Israel, October 23–27, 2022, Proceedings, Part XXIV*, pages 459–479. Springer.

- [44] Tzeng, E., Hoffman, J., Saenko, K., and Darrell, T. (2017). Adversarial discriminative domain adaptation. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 7167–7176.
- [45] Van de Ven, G. M. and Tolias, A. S. (2019). Three scenarios for continual learning. *arXiv preprint arXiv:1904.07734*.
- [46] Wang, D., Shelhamer, E., Liu, S., Olshausen, B., and Darrell, T. (2020a). Fully test-time adaptation by entropy minimization. *ArXiv preprint*, abs/2006.10726.
- [47] Wang, D., Shelhamer, E., Liu, S., Olshausen, B., and Darrell, T. (2020b). Tent: Fully test-time adaptation by entropy minimization. *arXiv preprint arXiv:2006.10726*.
- [48] Wang, Q., Fink, O., Van Gool, L., and Dai, D. (2022). Continual test-time domain adaptation. *arXiv preprint arXiv:2203.13591*.
- [49] Wulfmeier, M., Bewley, A., and Posner, I. (2018). Incremental adversarial domain adaptation for continually changing environments. In *2018 IEEE International conference on robotics and automation (ICRA)*, pages 4489–4495. IEEE.
- [50] Xie, Q., Luong, M., Hovy, E. H., and Le, Q. V. (2020). Self-training with noisy student improves imagenet classification. In *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition, CVPR 2020, Seattle, WA, USA, June 13-19, 2020*, pages 10684–10695. IEEE.
- [51] Xie, S., Girshick, R. B., Dollár, P., Tu, Z., and He, K. (2017). Aggregated residual transformations for deep neural networks. In *2017 IEEE Conference on Computer Vision and Pattern Recognition, CVPR 2017, Honolulu, HI, USA, July 21-26, 2017*, pages 5987–5995. IEEE Computer Society.
- [52] Yu, F., Chen, H., Wang, X., Xian, W., Chen, Y., Liu, F., Madhavan, V., and Darrell, T. (2020). Bdd100k: A diverse driving dataset for heterogeneous multitask learning. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*.
- [53] Yue, X., Zheng, Z., Zhang, S., Gao, Y., Darrell, T., Keutzer, K., and Vincentelli, A. S. (2021). Prototypical cross-domain self-supervised learning for few-shot unsupervised domain adaptation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 13834–13844.
- [54] Zhang, M., Levine, S., and Finn, C. (2022). Memo: Test time robustness via adaptation and augmentation. *Advances in Neural Information Processing Systems*, 35:38629–38642.

二维示例实验与分析




图 7：分布偏移下自适应的理论分析。通过一个简单的二维高斯二分类示例、一个轻微旋转数据并添加高斯噪声的域偏移，以及一个由批归一化层后接逻辑回归组成的模型，可以重现熵最小化的坍塌或非坍塌行为。顶部：批归一化前 (a) 和后 (b) 两个类别的干净与损坏数据。中部：从初始参数（黄色标记）开始，熵最小化在二维自适应参数空间中随时间的学习动态。底部：准确率、熵和自适应权重大小随时间的变化。

为了更好地理解坍塌，我们构建了一个简单的二维高斯二分类示例。

数据。二维数据集的构建方式如下：通过从两个具有相同方差的高斯团中采样得到数据，这两个高斯团对应两个类别 $\mathcal{N}(\mu_i, \Sigma)$ 。对于损坏情况，数据随后旋转角度 θ ，并与额外的加性高斯噪声结合 $\mathcal{N}(0, \Sigma_{\text{corrupt}})$ 。最后，在干净数据和损坏数据两种情况下，数据都旋转角度 $-\frac{\pi}{4}$ （以最小化模型中批归一化的影响）。

$$Y \sim \text{Ber}(0.5) \quad (2)$$

$$X \sim \mathcal{N}(\mu_Y, \Sigma) \quad (3)$$

$$X_{\text{clean}} = R_{-\frac{\pi}{4}} X \quad (4)$$

$$X_{\text{corrupt}} \sim \mathcal{N}(R_{\theta_{c_1}} X_{\text{clean}}, R_{-\frac{\pi}{4}} R_{\theta_{c_2}}^{\top} \tilde{\Sigma} R_{\theta_{c_2}} R_{-\frac{\pi}{4}}) \quad (5)$$

$$\text{含 } \Sigma = \begin{pmatrix} \sigma_1 & 0 \\ 0 & \sigma_2 \end{pmatrix}, \quad \sigma_1 \gg \sigma_2 \quad (6)$$

$$\tilde{\Sigma} = \begin{pmatrix} \tilde{\sigma}_1 & 0 \\ 0 & \tilde{\sigma}_2 \end{pmatrix}, \quad \tilde{\sigma}_2 \geq \tilde{\sigma}_1 \quad (7)$$

$$R_{\theta} = \begin{pmatrix} \cos(\theta) & \sin(\theta) \\ -\sin(\theta) & \cos(\theta) \end{pmatrix} \quad (8)$$

注意，对于干净数据，我们将大部分方差分配给类别维度， σ_1 。在损坏数据上，我们主要在与类别维度垂直的方向上添加噪声（ $\tilde{\sigma}_2$ ），这是决定是否观察到坍塌行为的主要因素。 $\theta_{c_1} \neq \theta_{c_2}$ 用于打破数据中信号与噪声之间的对称性，这导致 Tent 开始向噪声方向偏离。

在我们的示例中，我们按如下方 mode 式参数化该模型：在条件 1 中， $\mu_i = (\pm 1, 0)$ 且 $\Sigma = \begin{pmatrix} 1 & 0 \\ 0 & 0.03 \end{pmatrix}$ ， $\theta = -\frac{\pi}{9}$ ， $\Sigma_{\text{corrupt}}^2 = R_{\theta_c}^{\top} \begin{pmatrix} 0.25 & 0 \\ 0 & 4 \end{pmatrix} R_{\theta_c} = I$ 且，其中 R_{θ_c} 是角度为




图 8: 真实数据上熵最小化坍塌的分析。(a) 与图 7 中的理论分析一致, 我们发现所有层中的自适应权重随时间持续增加, 即使在 CCC-Medium 上的准确率表明坍塌发生很久之后仍然如此。(b) 显示了一个放大视图, 在坍塌发生后很久, 这种增加尚不明显。

$$\theta_c = -6. \text{ 在条件 2 中, 除 } \Sigma_{\text{corrupt}}^2 = R_{\theta_c}^T \begin{pmatrix} 0.25 & 0 \\ 0 & 25 \end{pmatrix} \text{ 外, 其余均相同} \quad \left. \vphantom{\theta_c} \right) R_{\theta_c}. \text{ 在两者中}$$

条件下, 本文采样 300 000 个数据点, 这些数据点在两个类别上均匀分布。

模型。该分类模型接收形状为 $N \times 2$ 的数据集, 由一个批归一化层 ($\epsilon = 0$) 和随后的全连接层组成, 该全连接层具有两个输入通道、一个输出通道、无偏差项以及 Sigmoid 函数非线性。由于数据始终居中, 我们不学习批归一化层中仿射适应的偏移参数, 仅学习尺度参数。

模型训练。模型经过训练, 以最小化干净数据上的二元交叉熵。我们在整个 300,000 个样本数据集上使用批量梯度下降, 学习率为 0.1, 无动量。我们在 1000 步和 2000 步后将学习率衰减为原来的 0.1 倍, 并在 3000 步后停止训练。

模型学习与自适应。本文采用 Tent 方法在损坏数据上对模型进行适配。具体而言, 本文优化批归一化层的尺度参数, 以最小化预测的熵, 使用随机梯度下降 (SGD), 学习率为 0.01, 无动量。本文将整个数据集作为一个批次处理, 并适配 60,000 步。

结果。在玩具模型中, 出现了简单情形: 损失不会导致坍塌, 或反之 (分别见图 7a 和图 7b), 这主要取决于信号与噪声的方差和方向之间的关系。

玩具示例进一步预测, 模型的适配参数在长期运行中应当增长, 并且我们确实在 CCC-Medium 上对 ResNet50 运行 ETA 时发现了这一效应 (图 8), 这表明我们的最小化设置成功再现了大规模情况下的相关方面。然而, 权重爆炸仅在坍塌发生后才变得明显, 因此仅靠权重正则化不足以避免坍塌 (图 8(b))。

在图 7(a) 的示例中, 我们找到了目标域性能较高的方向并停留在那里; 在这种情况下, 熵最小化是稳定的。在图 7(b) 的实验中, 域偏移增加了几乎与信号方向正交的噪声, 熵最小化试图利用这些噪声来做出高置信度的预测: 我们最初仍然找到了目标域性能较高的方向, 但穿越了这个区域, 并继续进入低熵和低准确率的方向。这表明, 即使在线性示例中, 熵最小化也可能先表现出性能提升, 然后崩溃。

B 路径寻找算法

算法 1 描述了用于生成 CCC 的算法的伪代码。该算法基于一组校准矩阵, 类似于图 2 中所示的一个。对于每一对 (n_a, n_b) , 存在一个矩阵 m , 使得 $m[i][j]$ 等于预训练的 ResNet-50 在上的准确率

噪声组合 (n_a, n_b) 与严重程度 $(i/5, j/5)$ 。我们将在论文发表时发布完整的矩阵集合。

此外，算法 2 使用了一个函数最小有效路径 (s_1, s_2) ：该函数返回从 (s_1, s_2) 开始并在 $(0, s_j)$ 结束的路径，其中 s_k 。路径的代价就是路径上所有条目的平均值。最小路径定义为代价在绝对值上最接近 b_a 的路径。最后，路径只有在以下情况下才有效：它以 s_2 等于 0 开始，每次转移要么将 s_1 减少 0.25，要么将 s_2 增加 0.25，并且一旦 s_1 等于 0 就停止。

Algorithm 1 Algorithm used to generate each split of CCC

Require: ba, k, T ▷ Baseline accuracy, transition speed, and total split size.
1: $t = 0$ ▷ Initialize the total images generated counter
2: $c_1, c_2 \sim \text{Uniform}(\{1 \dots 15\})$ ▷ Initialize the first two corruptions.
3: $\text{path} \leftarrow \text{CalculatePath}(c_1, c_2, ba)$ ▷ Calculate path along the noise pair with an average accuracy closest to ba .
4: **loop**
5: $s_1, s_2 \leftarrow \text{path}[p]$
6: $\text{Subset} \sim \text{Uniform}(\text{ImageNetVal})$
7: $\text{apply}(c_1, s_1, c_2, s_2)$ to Subset
8: save Subset
9: $t \leftarrow k$
10: **if** $t \geq T$ **then** return
11: **end if**
12: **if** $p = \text{len}(\text{path}) - 1$ **then**
13: $c_1 \leftarrow c_2$
14: $c_2 \sim \text{Uniform}(\{1 \dots 14\})$
15: $\text{path} \leftarrow \text{CalculatePath}(c_1, c_2, ba)$ ▷ Calculate new path along the new noise pair.
16: $p \leftarrow 0$
17: **else**
18: $p \leftarrow p + 1$ ▷ Move to the next severity combination
19: **end if**
20: **end loop**

Algorithm 2 CalculatePath

Require: c_1, c_2, ba ▷ The 2 noises, and the baseline accuracy
1: $m \leftarrow \text{CalibrationMatrix}[c_1][c_2]$
2: $\text{MinPath}, \text{MinCost} \leftarrow \text{MinValidPath}(0, 0, m, ba)$
3: **for** $s_1 \in 0.25, 0.5, 0.75, \dots, 5$ **do**
4: $m \leftarrow \text{MinValidPath}(1, 0, m, ba)$
5: $\text{MinPath}, \text{MinCost} \leftarrow \text{MinValidPath}(s_1, 0, m, ba)$
6: **end for**
7: **return** MinPath

由此产生的数据集具有两种不同噪声之间的过渡，如图 9（a）所示。此外，我们在图 9（b）中绘制了预训练 ResNet-50 的准确率以及不同噪声的严重程度。




图 9：（a）CCC-Medium 从缩放模糊到雪花的平滑过渡可视化。注意：CCC 还使用了随机翻转和裁剪，此处未显示。（b）当 CCC 在噪声之间过渡时，第一种噪声（红色）和第二种噪声（蓝色）的严重程度相应上下波动，以保持预训练模型的准确率稳定。

此外，我们分享了关于 CCC-Easy/Medium/Hard 中遍历长度的以下元数据：

表 6：CCC 遍历长度统计，针对每个 CCC 划分。

	Min	Max	Mean	Median
CCC-Easy	11	36	22.8	23
CCC-Medium	21	41	33.9	34
CCC-Hard	41	41	41	41

C CCC 图




图 10: 使用 ResNet-50 骨干网络的所有评估模型的适应性能。(a) CCC Easy。(b) CCC Medium。(c) CCC Hard。对于所有子图，模型性能是在相应难度级别的 9 次运行中取平均得到的。

D EATA 实现与消融

我们对 EATA 的实现与官方实现³不同。原因是官方实现使用干净的 ImageNet 验证图像来计算其正则化器的 Fisher 向量矩阵⁴。这与该方法相矛盾，该方法在测试时不应访问训练分布，如论文表 1 所示。

本文未使用 2,000 图像网络 (ImageNet) 验证图像，而是利用数据流中的前 2,000 张图像计算费舍尔矩阵。我们对权重正则化权衡参数 β 进行了超参数搜索：

β	25	50	100	250	500	1000	1500	2000
Acc. [%]	46.5	46.9	47.1	46.7	46.1	45.6	44.8	44.0

表 7: 不同权重正则化损失值下，EATA 在 CIN-C 保持噪声上的准确率。

使用最优值时，100 在 CCC 上导致的结果比默认值 2000 更差：

	CIN-C	CCC-Easy	CCC-Medium	CCC-Hard	CCC Avg
EATA-100	46.7	47.7	36.5	3.8	29.3
EATA-2000	41.8	48.2	35.4	8.7	30.8
Ours	46.5	49.3	38.9	9.6	32.6

表 8: 不同费舍尔阿尔法值下，EATA 在 CIN-C 保持噪声上的准确率。

最终，本文采用原始值 2000，因为该值在 CCC 数据集上表现最优。

此外，本文在视觉变换器 (ViT) 骨干网络上对 EATA 进行了超参数搜索。如表 4 所示，在该设置下，EATA 的表现不如预训练且未进行自适应的基线。为此，本文尝试通过增大 β 的值来稳定模型，该超参数控制抗遗忘正则化器的权重。与前述实验一致，原始值 2000 为最优。

³<https://github.com/mr-eggplant/EATA>, version f739b3668c

⁴<https://github.com/mr-eggplant/EATA/blob/f739b3668c/main.py#L144>

β	2000	3000	4000
Acc. [%]	38.5	27.8	16.5

表 9: 使用视觉变换器骨干网络时, 不同正则化器值 β 下, EATA 在 CCC-中等噪声上的准确率。

E 重置的新颖性

我们的工作为首个提出通过重置来解决测试时自适应方法中崩溃问题的研究。值得注意的是, 尽管先前的工作 [30, 47, 54] 曾简要提及情景重置的概念, 但其方法论和应用与测试时自适应中的崩溃问题存在显著差异且不相关。

- Tent[47] 在分割任务中针对单样本过拟合（类似于 [54] 中的单样本过拟合）的背景下提到了情景重置。这里的重置与崩溃无关, 因为该论文完全没有讨论崩溃问题。

- 尽管 MEMO[54] 使用了重置, 但这是因为它在每一步都对单张图像（及其增强）进行过拟合。MEMO 没有讨论崩溃或灾难性遗忘。MEMO 将自己与每一步后重置的 Tent 版本（他们称之为 Tent + 情景重置）进行比较, 因为不带增强的 MEMO 类似于批大小为 1 的 Tent + 情景重置。（注意: 当使用标准批大小 64 时, MEMO 的性能不如 BN/Tent/ETA）

- EATA[30] 在其表格中展示了每一步后 Tent + 情景重置的结果, 但没有提供这样做的理由或讨论。Tent + 情景重置的性能不如常规 Tent。

F CIFAR10 实验

我们进行了 CIFAR10 实验, 以证明需要 ImageNet 规模的基准。Tent 在没有抗崩溃机制的情况下, 在 CIFAR10-C 上即使处理了 1 亿张图像后也不会崩溃（图 11a,b）。与 ImageNet 类似, CIFAR10-C 的噪声在难度上也表现出高方差（图 11c）。




图 11: (a) 在无限拼接的严重度 5 噪声上测试时, Tent 即使处理了 1 亿张 CIFAR 规模图像后也不会崩溃。(b) 在 CIFAR10-C 渐变的长期变体上测试时, Tent 不会崩溃到随机水平。(c) CIFAR10-C 在单个损坏之间表现出巨大差异, 类似于 ImageNet-C。

G 计算细节

所有实验均在英伟达 RTX 2080 TI 图形处理器 (GPU) 上进行, 每块设备显存为 12GB。除针对更大模型的研究外, 其余实验均在单块 GPU 上完成。对于 CoTTA 实验, 我们采用两块 GPU 进行数据并行训练。本工作的大部分计算开销用于在包含 4.63 亿张图像的校准数据集上计算基线准确率。

H 软件与数据集许可证

H.1 数据集

- ImageNet-C [12]: 知识共享署名 4.0 国际许可协议,
<https://zenodo.org/record/2235448>
- ImageNet-C [12], 用于生成损坏的代码: Apache 许可证 2.0
<https://github.com/hendrycks/robustness>
- ImageNet-3D-CC [16]: CC-BY-NC 4.0 许可证
<https://github.com/EPFL-VILAB/3DCommonCorruptions>

H.2 模型

- PyTorch 的 [31] 骨干网络
<https://pytorch.org/vision/stable/models.html>
- Adaptive BN [29, 38]:
Apache License 2.0, <https://github.com/bethgelab/robustness>
- Tent [47]: MIT License,
<https://github.com/DequanWang/tent>
- RPL [35]: Apache 许可证 2.0,
<https://github.com/bethgelab/robustness>
- CoTTA [48]: MIT 许可证,
<https://github.com/qinenergy/cotta>
- CPL [8]: MIT 许可证,
https://github.com/locuslab/tta_conjugate
- EATA [30]: MIT 许可证
<https://github.com/mr-eggplant/EATA>