

恢复强化学习：基于学习 恢复区域的安全强化学习

Brijen Thananjeyan^{*1}, Ashwin Balakrishna^{*1}, Suraj Nair², Michael Luo¹, Krishnan Srinivasan²,
Minho Hwang¹, Joseph E. Gonzalez¹, Julian Ibarz³, Chelsea Finn², Ken Goldberg¹

摘要——安全性仍是阻碍强化学习在现实世界中广泛应用的核心障碍：在不确定环境中学习新任务需要大量探索，但安全性又要求限制探索。本文提出恢复强化学习（Recovery RL）算法，通过以下方式权衡这一矛盾：（1）利用离线数据在策略学习之前学习约束违规区域；（2）将提升任务性能与满足约束这两个目标分离到两个策略中：一个任务策略仅优化任务奖励，一个恢复策略在可能违反约束时引导智能体回到安全状态。我们在 6 个仿真领域上评估恢复强化学习，包括两个接触丰富的操作任务、一个基于图像的导航任务，以及一个在实体机器人上的基于图像的避障任务。我们将恢复强化学习与 5 种先前通过约束优化或奖励塑形联合优化任务性能和安全性的安全强化学习方法进行比较，发现恢复强化学习在所有领域上均优于次优的先前方法。结果表明，恢复强化学习在仿真领域中权衡约束违规与任务成功的效率高 2 至 20 倍，在实体实验中高出 3 倍。视频和补充材料见 <https://tinyurl.com/rl-recovery>。

索引词——强化学习，安全性

一、引言

强化学习（Reinforcement Learning, RL）为机器人获取新技能提供了通用框架，并在导航 [27]、运动 [15] 和操作 [19, 23] 等多种机器人领域展现出潜力。然而，在现实世界中部署强化学习智能体时，无约束的探索可能导致高度次优的行为，从而损坏机器人、破坏周围物体或阻碍学习进程。例如，考虑一个被指派学习从冰箱中取出牛奶盒的智能体。如果它打翻了牛奶盒，不仅可能弄坏盒子并造成混乱，还需要耗费人力擦拭牛奶并更换盒子，因此




图 1: Recovery RL 能够在仿真实验和物理机器人系统上，从高维图像观测中安全地学习接触丰富任务的策略。我们在达芬奇研究套件（左上）上评估了 Recovery RL 在基于图像的避障任务中的表现，该任务采用增量位置控制，并使用俯视图像观测（右上）。我们发现 Recovery RL 显著优于先前方法（图 6），这表明它可用于物理机器人的视觉运动控制。我们还发现 Recovery RL 能够在仿真中执行具有挑战性的接触丰富操作任务；如底行所示，Recovery RL 通过学会在抓取前将红色方块从其他方块旁轻轻推开，成功取出红色方块而未碰到其他方块。

机器人能够继续学习。与此同时，在违规后果得到纠正之前，机器人无法收集经验或改进其策略。因此，赋予强化学习智能体在学习过程中满足约束的能力，不仅能使机器人安全交互，还能使其在现实世界中更高效地学习。然而，在学习过程中对智能体行为施加约束具有挑战性，因为系统动力学和导致约束违规的状态可能最初未知，必须从经验中学习，尤其是在从图像等高维观测中学习时。安全探索面临一个权衡：通过环境交互学习新技能需要探索广泛的可能行为，但安全学习迫使智能体将探索限制在满足约束的状态内。

本文考虑一种受未来不安全行为概率约束的强化学习（RL）形式，并设计一种能够平衡任务导向探索与安全性这两个经常冲突目标的算法。此前安全强化学习的大多数工作将约束满足融入任务目标中，以

^{*} 同等贡献 稿件收到日期：2019 年 10 月 15 日；修订日期：2020 年 2 月 2 日；接受日期：2020 年 2 月 27 日。本文经副编辑和审稿人评审后，由编辑 Dana Kulic 推荐发表。1Brijen Thananjeyan, Ashwin Balakrishna, Suraj Nair, Michael Luo, Minho Hwang, Joseph E. Gonzalez 和 Ken Goldberg 就职于美国加州大学伯克利分校电气工程与计算机科学系 {bthananjeyan, ashwin_balakrishna, michael.luo, gkgkgk1215, jegonzal, goldberg}@berkeley.edu 2Suraj Nair, Krishnan Srinivasan 和 Chelsea Finn 就职于美国斯坦福大学计算机科学系 {surajn, krshna, cbfinn}@stanford.edu 3Julian Ibarz 就职于美国谷歌人工智能部门 julianibarz@google.com 数字对象标识符 (DOI)：见本页顶部。

联合优化这两者。尽管这些方法因其通用性和简洁性而具有吸引力,但有两个关键方面使它们在实际中难以使用。首先,探索学习新任务与限制探索以避免违反约束之间的固有目标冲突可能导致策略优化的次优性。其次,探索环境以学习约束需要在学习过程中产生大量的约束违反。然而,这可能导致智能体采取不受控制的动作,从而损害自身和环境。我们通过两个关键的算法思想朝着解决这些问题迈出了一步。首先,受近期鲁棒控制工作 [4, 11, 13, 21] 的启发,我们用两个策略来表示强化学习智能体:第一个策略专注于优化无约束的任务目标(任务策略),第二个策略在任务策略在不久的将来面临约束违反危险时接管控制(恢复策略)。与修改策略优化过程以鼓励约束满足(这可能会在学习的任务策略中引入次优性 [26])不同,恢复策略可以被视为对任务策略定义了一个替代的马尔可夫决策过程,在该过程中约束违反不太可能发生。将任务策略和恢复策略分离使得平衡任务性能与安全性更加容易,并允许对两者使用现成的强化学习算法。其次,我们利用离线数据来学习一个恢复集,该恢复集指示马尔可夫决策过程中未来约束违反可能发生的区域,以及一个恢复策略,在该集合内查询该策略以防止违反。这些离线数据可以在智能体与环境交互之前,在人类监督下收集,以展示期望行为的示例,或者可以包含机器人在环境中执行其他任务时先前经历的不安全行为。恢复集和策略都会随着智能体的经验在线更新,但离线数据允许智能体观察约束违反并从中学习,而无需任务策略在学习过程中直接经历过多的不受控制的违反。我们提出了恢复强化学习,一种用于安全机器人强化学习的新算法。与先前的工作不同,恢复强化学习 (1) 可以利用约束违反的离线数据在与环境交互之前学习约束,并且 (2) 使用任务和恢复的分离策略来安全地学习,而不会显著牺牲任务性能。我们在仿真中的 6 个导航和操作领域(包括视觉导航任务)上,将恢复强化学习与 5 种最先进的安全强化学习算法进行了评估,发现恢复强化学习在约束违反和任务成功之间的权衡效率比次优的先前方法高 2 到 20 倍。我们在物理机器人上的基于图像的避障任务上评估了恢复强化学习,发现它在约束违反和任务成功之间的权衡效率比次优的先前算法高 3 倍。

二、相关工作

先前工作已从多个角度研究强化学习中的安全性,包括对期望回报施加约束 [1, 34]、采用风险测度 [17, 29, 31, 33],以及避开马尔可夫决策过程中可能违反约束的区域 [4, 5, 10, 12, 36, 37]。

我们基于后一种方法,设计了一种算法,该算法使用学习到的恢复策略,将强化学习智能体保持在马尔可夫决策过程(MDP)中学习到的安全区域内。任务性能与安全性的联合优化:安全强化学习算法中的一种流行策略是修改标准强化学习算法的策略优化过程,以同时考虑任务奖励和约束,使用的方法包括信任区域 [1]、优化拉格朗日松弛 [25, 30, 34] 或构造李雅普诺夫函数 [6, 7]。这些工作中与恢复强化学习最相似的是 Srinivasan 等人 [30] 的工作,该工作训练一个安全评论家来估计当前策略下未来约束违反的概率,并优化拉格朗日目标函数,以在最大化任务奖励的同时限制约束违反的概率。与 Srinivasan 等人 [30] 使用安全评论家修改任务策略优化目标不同,恢复强化学习使用它来决定何时执行学习到的恢复策略,该策略最小化安全评论家,以将智能体保持在 MDP 的安全区域内。这一思想使恢复强化学习能够比联合优化任务性能和安全性的算法更有效地平衡任务性能和约束满足。使用辅助策略限制探索:安全强化学习的另一种方法是使用恢复或屏蔽机制,将策略探索明确限制在 MDP 的安全子集内。这一思想已在 [4, 11] 中进行了探索,该工作利用哈密顿-雅可比可达性分析来定义任务策略和安全控制器,并在屏蔽的背景下进行了探索 [2, 13, 21]。与这些假设系统动力学近似已知或需要预先精确了解约束的工作相比,恢复强化学习从离线数据和在线经验的组合中学习有关 MDP 的信息,例如约束和动力学。这使得恢复强化学习能够扩展到高维状态空间(如图像),在这些空间中,系统动力学和约束的精确规范可能非常具有挑战性,而且往往是不可能的。此外,恢复强化学习考虑的是机会约束而非鲁棒约束,当动力学未知时,鲁棒约束可能难以满足。Fisac 等人 [11] 在已知动力学和鲁棒控制不变安全集的鲁棒最优控制设置中,为基于学习的控制器设计并证明了安全保证。在这些额外假设下,恢复强化学习也具有类似的理论性质。Han 等人 [16] 和 Eysenbach 等人 [10] 引入了重置策略,该策略与任务策略联合训练,以将智能体重置到其初始状态分布,确保任务策略只学习可被重置的行为 [10]。然而,强制完全重置的能力可能不切实际或效率低下。受此工作启发,恢复强化学习在约束违反可能发生时,执行近似重置到附近的安全状态。Richter 等人 [27] 学习以动作计划为条件的约束违反概率,以激活手工设计的安全控制器。相比之下,恢复强化学习使用学习到的恢复机制,可以广泛应用于不同的任务。利用演示进行安全强化学习与控制:先前也有大量工作研究了如何利用演示来实现安全探索。




图 2: 恢复强化学习: 为直观展示, 我们在一个二维迷宫导航任务中说明恢复强化学习, 其中约束违反对应于撞墙。恢复强化学习首先利用来自某个行为策略 π_b 的离线数据学习安全评价器 $\hat{Q}_{\phi, \text{risk}}^\pi$, 该策略提供了少量受控的约束违反行为为演示, 如左图所示。为便于说明, 我们可视化了恢复强化学习在 100 个动作样本上学习到的 $\hat{Q}_{\phi, \text{risk}}^\pi$ 的平均值。然后, 在每个时间步, 恢复强化学习向任务策略 π_{task} 查询状态 s 下的某个动作 a , 评估 $\hat{Q}_{\phi, \text{risk}}^\pi(s, a)$, 并在 $\hat{Q}_{\phi, \text{risk}}^\pi(s, a) > \epsilon_{\text{risk}}$ 时执行恢复策略 π_{rec} , 否则执行 π_{task} 。任务策略、恢复策略和安全评价器在智能体经验的每次转移后更新。

罗索利亚等人 [28] 和塔纳杰扬等人 [35] 引入了模型预测控制算法, 这些算法利用初始满足约束的演示, 在安全保证下迭代提升性能, 塔纳杰扬等人 [36] 将这些思想扩展到强化学习设置。与这些工作相比, 恢复强化学习学习一个更大的安全集, 该安全集显式建模未来的约束满足, 并且在没有任务特定演示的情况下从先前经验中学习问题约束。此外, 恢复强化学习与无模型强化学习算法兼容, 而 [35, 36] 需要动力学模型来在线评估基于可达性的安全性。

III. 问题陈述

我们考虑马尔可夫决策过程 (MDP), 由 $(S, A, P(\cdot | \cdot, \cdot), R(\cdot, \cdot), \gamma, \mu)$ 其中 S 和 A 是状态和动作空间。随机动力学模型 $P: S \times A \times S \rightarrow [0, 1]$ 将状态和动作映射到后续状态上的概率分布, $\gamma \in [0, 1]$ 是折扣因子, μ 是初始状态分布 ($s_0 \sim \mu$), $R: S \times A \rightarrow \mathbb{R}$ 是奖励函数。我们用一个额外的约束代价函数 $C: S \rightarrow \{0, 1\}$ 来增强 MDP, 该函数指示状态是否违反约束, 以及相关的折扣因子 $\gamma_{\text{risk}} \in [0, 1]$ 。这产生了以下新的 MDP: $(S, A, P(\cdot | \cdot, \cdot), R(\cdot, \cdot), \gamma, C(\cdot), \gamma_{\text{risk}})$ 。我们假设回合在违反时终止, 等价于转移到一个满足约束的零奖励吸收状态。令 Π 为马尔可夫平稳策略集合。给定策略 $\pi \in \Pi$, 期望回报定义为 $R^\pi = \mathbb{E}_{\pi, \mu, P}[\sum_t \gamma^t R(s_t, a_t)]$, 期望折扣约束违反概率定义为 $Q_{\phi, \text{risk}}^\pi(s_i, a_i) = \mathbb{E}_{\pi, \mu, P}[\sum_{t=i} \gamma_{\text{risk}}^t C(s_{t+1})] = \sum_{t=i} \gamma_{\text{risk}}^t P(C(s_{t+1}) = 1)$, 我们希望其低于阈值 $\epsilon_{\text{risk}} \in [0, 1]$ 。目标是求解以下约束优化问题:

$$\pi^* = \arg \max_{\pi \in \Pi} \{R^\pi : Q_{\phi, \text{risk}}^\pi(s_0, a_0) \leq \epsilon_{\text{risk}}\} \quad (\text{III.1})$$

该设置与 [3] 中的约束马尔可夫决策过程 (CMDP) 公式完全对应, 但约束代价仅限于违反约束状态的二元指示函数。我们选择二元指示函数, 因为它们比成形代价更容易提供, 并使用 $Q_{\phi, \text{risk}}^\pi$ 来传递关于延迟约束代价的信息。我们定义可行策略集合 $\{\pi : Q_{\phi, \text{risk}}^\pi \leq \epsilon\}$, 即 ϵ -安全策略集合 Π_ϵ 。观察到如果 $\gamma_{\text{risk}} = 1$, 则根据违反约束时终止的假设, $Q_{\phi, \text{risk}}^\pi(s_i, a_i) = \mathbb{P}(\bigcup_t C(s_t) = 1)$, 即未来发生约束违反的概率。同时设置 $\epsilon_{\text{risk}} = 0$ 则得到一个鲁棒最优控制问题。我们提出一种算法来优化方程 (III.1), 通过利用一对策略: 任务策略 π_{task} , 其训练目标是在 $\pi_{\text{task}} \in \Pi$ 上最大化 R^π ; 以及恢复策略 π_{rec} , 它试图将智能体引导回状态-动作元组 (s, a) , 其中 $Q_{\phi, \text{risk}}^\pi(s, a) \leq \epsilon_{\text{risk}}$ 。我们假设可以访问来自离线数据 ($\mathcal{D}$ 离线) 的一组转移, 其中包含约束违反的示例。与典型的模仿学习设置不同, 这些数据不需要展示任务成功, 而是展示违反约束的可能方式。我们利用 $\mathcal{D}$ 离线来约束任务策略的探索, 以降低环境交互过程中约束违反的概率。

四、恢复强化学习

我们概述恢复强化学习 (Recovery RL) 的核心思想。在第四-A 节中, 我们回顾如何学习安全评价器来估计智能体策略未来约束违反的概率。然后在第四-B 节中, 我们展示如何使用该安全评价器来定义恢复强化学习的恢复策略以及激活它的恢复集。在第四-C 节中, 我们讨论如何从离线数据初始化安全评价器和恢复策略, 在第四-D 节中我们讨论实现细节。参见算法 1 和图 2 以进一步说明恢复强化学习。

A. 预备知识: 训练安全评价器

As in Srinivasan *et al.* [30], Recovery RL learns a critic function $Q_{\phi, \text{risk}}^\pi$ that estimates the discounted future probability

当前策略 π 的约束违反概率:

$$\begin{aligned} Q_{\text{risk}}^{\pi}(s_t, a_t) &= \mathbb{E}_{\pi} \left[\sum_{t'=t}^{\infty} \gamma_{\text{risk}}^{t'-t} c_{t'} | s_t, a_t \right] \\ &= c_t + (1 - c_t) \gamma_{\text{risk}} \mathbb{E}_{\pi} [Q_{\text{risk}}^{\pi}(s_{t+1}, a_{t+1}) | s_t, a_t]. \end{aligned} \quad (\text{IV.1})$$

这里 $c_t = 1$ 表示状态 s_t 违反约束, 否则 $c_t = 0$ 。注意我们不假设可以访问真实的约束代价函数 C 。这与标准贝尔曼方程不同, 因为假设当 $c_t = 1$ 时回合终止。在实践中, 我们训练一个基于样本的近似 $\hat{Q}_{\phi, \text{risk}}^{\pi}$, 由 ϕ 参数化, 通过使用采样转移 (s_t, a_t, s_{t+1}, c_t) 来近似这些方程。我们通过最小化相对于目标 (方程 IV.1 的右侧) 的以下均方误差损失来训练 $\hat{Q}_{\phi, \text{risk}}^{\pi}$ 。

$$\begin{aligned} J_{\text{risk}}(s_t, a_t, s_{t+1}; \phi) &= \frac{1}{2} \left(\hat{Q}_{\phi, \text{risk}}^{\pi}(s_t, a_t) - (c_t \right. \\ &\quad \left. + (1 - c_t) \gamma_{\text{risk}} \mathbb{E}_{\pi} [\hat{Q}_{\phi, \text{risk}}^{\pi}(s_{t+1}, a_{t+1})]) \right)^2 \end{aligned} \quad (\text{IV.2})$$

我们使用目标网络来生成目标值 [14, 30]。

B. 定义恢复集与策略恢复强化学习在环境中执行一个复合策略 π , 该策略在每个时间步根据智能体是否在不久的将来面临约束违反的危险, 在任务驱动策略 π_{task} 和恢复策略 π_{rec} 之间进行选择。为了量化这种风险, 我们使用 Q_{risk}^{π} 构建一个恢复集, 其中包含 π 可能无法避免约束违反的状态-动作元组。然后, 如果智能体发现自己处于恢复集中, 它将执行学习到的恢复策略而不是 π_{task} , 以导航回已知足够安全的马尔可夫决策过程区域。具体来说, 定义两个互补集合: 安全集 $\mathcal{T}_{\text{safe}}^{\pi}$ 和恢复集 $\mathcal{T}_{\text{rec}}^{\pi}$:

$$\begin{aligned} \mathcal{T}_{\text{safe}}^{\pi} &= \{(s, a) \in \mathcal{S} \times \mathcal{A} : Q_{\text{risk}}^{\pi}(s, a) \leq \epsilon_{\text{risk}}\} \\ \mathcal{T}_{\text{rec}}^{\pi} &= \mathcal{S} \times \mathcal{A} \setminus \mathcal{T}_{\text{safe}}^{\pi} \end{aligned}$$

如果在状态 s 中采取动作 a 后, 执行 π 的约束违反折扣概率小于 ϵ_{risk} , 我们认为状态-动作元组 (s, a) 是安全的。如果任务策略 π_{task} 在状态 s 处提出动作 $a^{\pi_{\text{task}}}$ 使得 $(s, a^{\pi_{\text{task}}}) \notin \mathcal{T}_{\text{safe}}^{\pi}$, 则执行从 π_{rec} 采样的恢复动作而不是 $a^{\pi_{\text{task}}}$ 。因此, 恢复强化学习中的恢复策略可以被视为将 π_{task} 投影到策略空间的安全区域中, 在该区域中约束违反不太可能发生。恢复策略 π_{rec} 也是一个强化学习智能体, 但被训练以最小化 $\hat{Q}_{\phi, \text{risk}}^{\pi}(s, a)$, 以降低在 π 下的约束违反风险。令 $a_t^{\pi_{\text{task}}} \sim \pi_{\text{task}}(\cdot | s_t)$ 和 $a_t^{\pi_{\text{rec}}} \sim \pi_{\text{rec}}(\cdot | s_t)$ 。然后 π 按如下方式选择动作:

$$a_t = \begin{cases} a_t^{\pi_{\text{task}}} & (s_t, a_t^{\pi_{\text{task}}}) \in \mathcal{T}_{\text{safe}}^{\pi} \\ a_t^{\pi_{\text{rec}}} & (s_t, a_t^{\pi_{\text{task}}}) \in \mathcal{T}_{\text{rec}}^{\pi} \end{cases} \quad (\text{IV.3})$$

恢复强化学习过滤掉可能导致不安全状态的提议动作, 相当于用新的动力学修改 π_{task} 运行的环境:

$$P_{\epsilon_{\text{risk}}}^{\pi_{\text{rec}}}(s' | s, a) = \begin{cases} P(s' | s, a) & (s, a) \in \mathcal{T}_{\text{safe}}^{\pi} \\ P(s' | s, a^{\pi_{\text{rec}}}) & (s, a) \in \mathcal{T}_{\text{rec}}^{\pi} \end{cases} \quad (\text{IV.4})$$

我们在来自 π 的样本上训练 $\hat{Q}_{\phi, \text{risk}}^{\pi}$, 因为 π_{task} 并非直接在环境中执行, 而是通过 π 进行过滤。容易看出, 如果 $\hat{Q}_{\phi, \text{risk}}^{\pi}$ 正确且执行 π_{rec} 会降低其值, 所提出的恢复机制将使智能体避开可能违反约束的区域。然而, 这带来一个潜在问题: 虽然智能体可能是安全的, 但如何确保 π_{task} 在方程 IV.4 定义的新马尔可夫决策过程 (MDP) 中能够取得进展? 假设 π_{task} 在 $\hat{Q}_{\phi, \text{risk}}^{\pi}$ 下提出一个不安全动作 $a_t^{\pi_{\text{task}}}$ 。然后, 恢复强化学习 (Recovery RL) 执行恢复动作 $a_t^{\pi_{\text{rec}}}$, 并在环境中观察到转移 $(s_t, a_t^{\pi_{\text{rec}}}, s_{t+1}, r_t)$ 。然而, 如果 π_{task} 用这个观察到的转移进行更新, 它将无法学会在新 MDP 中将其提出的动作 ($a_t^{\pi_{\text{task}}}$) 与 r_t 和 s_{t+1} 关联起来。结果, π_{task} 可能会继续提出相同的不安全动作, 而没有意识到它观察到的是从 π_{rec} 采样的动作的结果。为了解决这个问题, 在训练 π_{task} 时, 我们将所有动作重新标记为 π_{task} 提出的动作。因此, 不是用执行的转移训练 π_{task} , 而是用转移 $(s_t, a_t^{\pi_{\text{task}}}, s_{t+1}, r_t)$ 训练 (s_t, a_t, s_{t+1}, r_t) , π_{task} 。这与定义一个安全 MDP 的解释一致, 该 MDP 的动力学为 $P_{\epsilon_{\text{risk}}}^{\pi_{\text{rec}}}(s' | s, a)$, 供 π_{task} 在其中行动, 因为用于训练 π_{task} 的所有转移都被重新标记, 就好像 π_{task} 被直接执行一样。

Algorithm 1 Recovery RL

Require: $\mathcal{D}_{\text{offline}}$, task horizon H , number of episodes N

- 1: Pretrain π_{rec} and $\hat{Q}_{\phi, \text{risk}}^{\pi}$ on $\mathcal{D}_{\text{offline}}$ $\triangleright$ Section IV-C
- 2: $\mathcal{D}_{\text{task}} \leftarrow \emptyset$, $\mathcal{D}_{\text{rec}} \leftarrow \mathcal{D}_{\text{offline}}$
- 3: $s_0 \leftarrow \text{env.reset}()$
- 4: **for** $i \in \{1, \dots, N\}$ **do**
- 5: **for** $t \in \{1, \dots, H\}$ **do**
- 6: **if** $c_t = 1$ or $\text{is_terminal}(s_t)$ **then**
- 7: $s_t \leftarrow \text{env.reset}()$
- 8: **end if**
- 9: $a_t^{\pi_{\text{task}}} \sim \pi_{\text{task}}(\cdot | s_t)$ $\triangleright$ Query task policy
- 10: $\triangleright$ Check if task policy will be unsafe
- 11: **if** $(s_t, a_t^{\pi_{\text{task}}}) \in \mathcal{T}_{\text{rec}}^{\pi}$ **then**
- 12: $a_t \sim \pi_{\text{rec}}(\cdot | s_t)$ $\triangleright$ Select recovery policy
- 13: **else**
- 14: $a_t = a_t^{\pi_{\text{task}}}$ $\triangleright$ Select task policy
- 15: **end if**
- 16: Execute a_t
- 17: Observe s_{t+1} , $r_t = R(s_t, a_t)$, $c_t = C(s_t)$
- 18: $\triangleright$ Relabel transition
- 19: $\mathcal{D}_{\text{task}} \leftarrow \mathcal{D}_{\text{task}} \cup \{(s_t, a_t^{\pi_{\text{task}}}, s_{t+1}, r_t)\}$
- 20: $\mathcal{D}_{\text{rec}} \leftarrow \mathcal{D}_{\text{rec}} \cup \{(s_t, a_t, s_{t+1}, c_t)\}$
- 21: Train π_{task} on $\mathcal{D}_{\text{task}}$, π_{rec} on $\mathcal{D}_{\text{rec}}$
- 22: Train $\hat{Q}_{\phi, \text{risk}}^{\pi}$ on $\mathcal{D}_{\text{rec}}$ $\triangleright$ Eq. IV.2
- 23: **end for**
- 24: **end for**

C. 离线预训练

为了在与环境交互之前传达约束信息, 我们向智能体提供一组包含约束违反的离线转移 $\mathcal{D}$ 用于预训练。虽然这需要在环境中违反约束, 但这些数据可以由人类定义的策略或在人类监督下收集, 从而为机器人智能体提供

约束违反的示例，而无需机器人在线经历太多不受控制的示例。我们通过最小化方程 IV.2 在从 $\mathcal{D}$ 离线采样的离线批次上预训练 $\hat{Q}_{\phi, \text{risk}}^{\pi}$ 。我们还使用 $\mathcal{D}$ 离线预训练 π_{rec} 。然后， π_{task} 、 π_{rec} 和 $\hat{Q}_{\phi, \text{risk}}^{\pi}$ 都使用来自智能体复合策略的经验在线更新，如第 IV-B 节所述并在算法 1 中说明。任何强化学习算法都可以用来表示 π_{task} ，而任何离线策略强化学习算法都可以用来学习 π_{rec} 。对于探索具有挑战性的某些环境，我们使用一组单独的任务演示来初始化 π_{task} 以加快学习。

D. 实用实现

恢复策略：任何离策略强化学习算法均可用于学习 π_{rec} 。本文探索了无模型和基于模型的强化学习算法来学习 π_{rec} 。对于无模型恢复，我们在安全评论家 $\hat{Q}_{\phi, \text{risk}}^{\pi}(s, \pi_{\text{rec}}(s))$ 上执行梯度下降，类似于流行的离策略强化学习算法 DDPG[22]。对于基于模型的恢复，我们使用安全评论家作为代价函数，在学习到的动力学模型 f_{θ} 上执行模型预测控制。对于低维任务，我们利用 Chua 等人 [8] 提出的 PETS 算法在学习的随机动力学模型上进行规划，而对于具有视觉观测的任务，我们使用基于变分自编码器的潜在动力学模型。任务策略：我们利用流行的最大熵强化学习算法 SAC[14] 来学习 π_{task} ，但任何强化学习算法均可使用。两种策略的实现细节见补充材料。

五、实验

在以下实验中，我们旨在研究恢复强化学习是否能够（1）比先前联合优化两者的算法更有效地权衡任务性能与约束满足，以及（2）有效利用离线数据进行安全强化学习。

领域：我们在 6 个仿真领域（图 3）和一个基于图像的物理机器人避障任务（图 6）上评估恢复强化学习。所有实验都涉及状态空间约束下的策略学习，其中违反约束会终止当前回合。这使得学习尤其具有挑战性，因为违反约束直接阻止了进一步的探索。该设置反映了各种现实世界环境，在这些环境中，违反约束可能需要因机器人自身或周围环境受损而停止机器人。我们首先考虑三个二维导航领域：导航 1、导航 2 和迷宫。在这里，智能体仅观察其在二维空间中的位置，如果撞到障碍物、墙壁或工作空间边界，就会经历约束违反。然后，我们考虑三个更高维度的任务，以评估恢复强化学习是否可以应用于接触丰富的操作任务（物体提取、物体提取（动态障碍物））和基于视觉的连续控制（图像迷宫）。在物体提取环境中，目标是在不倾倒任何方块的情况下提取红色方块，而在物体提取（动态障碍物）的情况下，还要避免与在工作空间内外移动的动态障碍物接触。图像迷宫是迷宫的一个较短时间范围版本，但

智能体仅获得图像观测，而非其在环境中的 (x, y) 位置。

随后，我们在达芬奇研究套件（dVRK）[20] 上基于图像的避障任务中评估恢复强化学习（Recovery RL），机器人必须从两个可能的起始位置引导其末端执行器到达目标位置 2 毫米范围内，且不得触碰工作空间中红色的 3D 打印障碍物。

实验装置示意图见图 1。dVRK 为缆绳驱动，控制精度相对较低，因此需要闭环控制策略来补偿这些误差 [18]。此外，dVRK 系统过去曾被用于评估安全强化学习算法 [36]，因其成本高昂且机械臂结构精密，安全学习至关重要。所有仿真与物理实验的环境、任务及数据收集细节详见补充材料。离线数据收集：为有效初始化 $\hat{Q}_{\phi, \text{risk}}^{\pi}$ ， $\mathcal{D}$ 离线数据理想情况下应包含以不同方式违反约束的多样化轨迹集。由于 $\mathcal{D}$ 离线数据无需任务特定，可使用环境中其他任务的数据，或采用简单的人工定义策略来展示违反约束的行为。我们采用后一种方法：对于所有导航环境（导航 1、导航 2、迷宫、图像迷宫及物理实验），离线数据通过将智能体初始化在环境的不同区域并引导其朝最近的障碍物移动来收集。对于物体提取环境（物体提取、物体提取（动态障碍物）），演示通过引导末端执行器朝目标红色块移动，并在其足够接近目标物体时向控制量添加高斯噪声以增加倾倒可能性来收集。恢复强化学习及所有具有安全评论家的比较方法均使用相同的离线数据集 $\mathcal{D}$ 离线。数据收集过程、所有离线数据集的总转移次数及违反约束状态数详见补充材料。

评估度量：由于恢复强化学习（Recovery RL）与先前方法在安全性与任务进展之间进行权衡，本文报告每个回合中累计任务成功次数与累计约束违反次数的比值以说明这一点（越高越好）。本文调整所有算法以最大化该比值，任务成功通过在每个环境的状态空间中定义目标集来确定。为避免除零问题，在计算该比值时对累计任务成功次数和约束违反次数各加 1。该度量提供了一个标量值，用于量化不同算法在平衡任务完成与约束满足方面的效率。本文不报告每回合奖励，因为回合在任务完成或约束违反时终止。仿真实验的每次运行在 10 个随机种子上重复，并报告均值和标准误。对于物理实验，本文对每个算法在 3 个随机种子上运行，并可视化全部 3 次运行。在补充材料中，本文还报告每个实验的额外度量：累计任务成功次数、累计约束违反次数和奖励学习曲线。本文发现，恢复强化学习违反约束的频率低于比较方法，同时保持相似的任务成功率，并更高效地优化任务奖励。




图 3: 仿真实验域: 本文在一组二维导航任务、两个接触丰富的操作环境和一个视觉导航任务上评估恢复强化学习。在导航 1 和导航 2 中, 目标是从起始集导航到目标集而不与障碍物 (红色) 碰撞; 在迷宫导航任务中, 目标是从左侧走廊导航到右侧走廊中的红点而不与墙壁或边界碰撞。在两个物体提取环境中, 目标是抓取并举起红色方块, 而不推倒任何方块或与干扰臂碰撞 (动态障碍环境)。




图 4: 仿真实验: 左图: 在线训练过程中成功次数与约束违反次数的比值。在所有导航任务中, 我们发现恢复强化学习 (Recovery RL) 在使用无模型和基于模型的恢复策略时均显著优于先前方法; 而在物体提取环境中, 采用基于模型恢复策略的恢复强化学习显著优于先前算法, 而采用无模型恢复策略的恢复强化学习表现不佳。我们推测这是由于基于模型的恢复机制能够更好地补偿 $\hat{Q}_{\phi, \text{risk}}^\pi$ 中的不完美之处。每个算法的结果均为 10 次运行的平均值; 锯齿状模式源于约束违反, 导致比值突然下降。右图: 累计成功次数与约束违反次数。此外, 我们展示了物体提取任务中所有算法的累计任务成功次数和累计约束违反次数, 发现采用基于模型恢复的恢复强化学习比所有比较方法成功次数更多, 同时约束违反次数最少。所有其他实验领域的类似图表可在补充材料中找到。

比较: 我们将恢复强化学习与以下算法进行比较: 忽略约束的算法 (无约束) 或通过优化目标 (LR、SQRL、RSPO) 或通过奖励塑形 (RP、RCPO) 来强制约束的算法。

- **无约束: 优化任务奖励, 忽略约束。**
- **拉格朗日 Relaxation (LR):** 最小化 $L_{\text{policy}}(s, a, r, s'; \pi) + \lambda (\mathbb{E}_{a \sim \pi(\cdot|s)} [\hat{Q}_{\phi, \text{risk}}^\pi(s, a)] - \epsilon_{\text{risk}})$, 其中 L_{policy} 是策略优化损失, 第二项近似强制 $\hat{Q}_{\phi, \text{risk}}^\pi(s, a) \leq \epsilon_{\text{risk}}$ 。策略参数和 λ 通过双梯度下降更新。
- **强化学习安全 Q 函数 (Safety Q-Functions for RL, SQRL)** $\pi(s, a) > \epsilon_{\text{risk}}$ [30]: 将 LR 方法与过滤机制相结合, 以拒绝那些
- **风险敏感策略优化 (Risk Sensitive Policy Optimization, RSPO) [29]:** 迷你 mizes $L_{\text{policy}}(s, a, r, s'; \pi) + \lambda_t (\mathbb{E}_{a \sim \pi(\cdot|s)} [\hat{Q}_{\phi, \text{risk}}^\pi(s, a)] - \epsilon_{\text{risk}})$, 其中 λ_t 是一个递减至 0 的序列。
- **奖励惩罚 (Reward Penalty, RP):** 观察到一种对约束违反进行惩罚的奖励函数: $R'(s, a) = R(s, a) - \lambda C(s)$ 。• 评论家惩罚奖励约束策略优化
- **mization (RCPO) [34]:** 通过双梯度下降与策略优化拉格朗日松弛

梯度技巧。策略梯度更新最大化 $\mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t (R(s_t, a_t) - \lambda \hat{Q}_{\phi, \text{risk}}^\pi(s_t, a_t)) \right]$, 乘子更新与 LR 中相同。

所有这些算法均采用相同的基础算法来学习任务策略 (软演员 - 评论家 (Soft Actor-Critic) [14]), 除无约束 (Unconstrained) 和 RP 外, 其余方法均修改为使用相同的安全评论家 $\hat{Q}_{\phi, \text{risk}}^\pi$, 该评论家在所有方法上均基于 $\mathcal{D}_{\text{offline}}$ 进行预训练。因此, 恢复强化学习 (Recovery RL) 与先前方法的关键区别在于如何利用 $\hat{Q}_{\phi, \text{risk}}^\pi$: 比较方法采用联合目标, 利用 $\hat{Q}_{\phi, \text{risk}}^\pi$ 训练单一策略, 同时优化任务性能和约束满足, 而恢复强化学习将这两个目标分离到两个子策略中。本文对所有先前算法进行调优, 并报告在每个任务上针对基于比率的评估度量找到的最佳超参数设置。恢复强化学习及所有比较算法的详细信息见补充材料。

结果: 我们首先在图 4 中研究了恢复强化学习 (Recovery RL) 及先前方法在所有仿真领域中的性能。结果表明, 采用无模型和基于模型的恢复机制的恢复强化学习在全部 3 个二维点质量导航环境中均显著优于先前算法。




图 5：敏感性实验：我们报告了在物体提取任务上，针对多种不同超参数设置，恢复强化学习及比较算法在训练结束时的最终任务成功次数和约束违反次数（10 次运行的平均值）。我们发现，比较算法对惩罚参数 λ 的值相对敏感，而在给定固定 γ_{risk} 的情况下，恢复强化学习在一系列 ϵ_{risk} 取值范围内实现了相对较少的约束违反，同时保持了任务性能。




图 6：物理实验：我们在 dVRK（图 1）上评估了恢复强化学习在基于图像的避障任务（红色障碍物）中的表现。我们为所有算法提供俯视 RGB 图像作为输入，并将每个算法运行 3 次。我们发现，恢复强化学习显著优于无约束方法和 LR 方法。

（导航 1、导航 2、迷宫）和视觉导航环境（图像迷宫）。在物体提取环境中，我们发现采用基于模型的恢复机制的恢复强化学习显著优于先前算法，而采用无模型恢复机制的恢复强化学习表现则远不及前者。我们推测，基于模型的恢复机制能够更好地补偿 $\hat{\pi}_{\phi, \text{risk}}$ 中的近似误差，从而产生更稳健的恢复策略。我们发现，先前方法往往获得非常低的比率，因为它们倾向于实现与恢复强化学习相似的任务完成次数，但约束违反次数却多得多。相比之下，恢复强化学习通常能够有效地在任务性能与安全性之间进行权衡。图 4 右侧面板对此进行了说明，表明采用基于模型的恢复机制的恢复强化学习不仅对比算法更常成功，而且约束违反次数也更少。我们在补充材料中对此进行了进一步研究。最后，我们在图 1 所示的基于图像的避障任务上评估了恢复强化学习和先前算法，发现恢复强化学习显著优于先前方法，这表明恢复强化学习可用于现实世界中接触丰富的视觉运动控制任务（图 6）。我们研究了




图 7：消融实验：我们首先研究了恢复强化学习不同算法组件的影响（左图）。结果表明， π_{rec} 和 $\hat{Q}_{\phi, \text{risk}}$ 的离线预训练对于良好性能至关重要，而移除在线更新导致的性能下降要小得多。此外，我们发现用于训练 π_{task} 的动作重标记方法（第 IV-B 节）对于良好性能至关重要。然后，我们研究了恢复强化学习对于预训练 π_{rec} 和 $\hat{Q}_{\phi, \text{risk}}$ 的离线转移数量的敏感性（右图），发现即使在物体提取任务的 $\mathcal{D}$ 离线中仅有 1000 个转移，恢复强化学习也能表现良好，当转移数量减少超过此点时性能会下降。

当恢复强化学习在补充材料中违反约束时，我们发现大多数任务中，恢复策略在约束违反发生时已经被激活。这是令人鼓舞的，因为如果恢复策略难以学习，恢复强化学习仍然可以用来查询人类监督者进行干预。

消融实验：我们对恢复强化学习的不同组件进行消融实验，并研究恢复强化学习对 $\mathcal{D}$ 离线数据中转移数量的敏感性，实验环境为物体提取领域，见

图 7。结果表明，当 π_{rec} 和 $\hat{Q}_{\phi, \text{risk}}$ 未使用 $\mathcal{D}$ 离线数据进行预训练时，恢复强化学习的性能显著下降，这表明在与环境交互之前学习安全推理具有重要价值。然而，当 π_{rec} 和 $\hat{Q}_{\phi, \text{risk}}$ 不在线更新时，性能下降幅度较小。恢复强化学习的一个关键组件是在训练任务策略时对动作进行重新标记，使 π_{task} 能够学习将其提出的动作与结果关联起来（第 IV-B 节）。我们发现，如果没有这种重新标记，恢复强化学习几乎无法完成任务成功，性能非常差。此外，我们发现尽管报告的仿真实验为恢复强化学习和所有先前方法提供了 20,000 条 $\mathcal{D}$ 离线转移数据用于

物体提取任务, 恢复强化学习仅需 1000 条 $\mathcal{D}$ 离线转移数据即可达到良好性能, 只有当 $\mathcal{D}$ 离线数据规模减少到低于此数量时, 性能才会显著下降。

敏感性实验: 我们为恢复强化学习和所有基线方法调整超参数以确保公平比较。我们首先为恢复强化学习调整 γ_{risk} 和 ϵ_{risk} , 然后对先前方法使用相同的 γ_{risk} 和 ϵ_{risk} , 以确保所有算法使用相同的安全评论家训练过程。这两个超参数是恢复强化学习和安全 Q 强化学习唯一调整的超参数。对于惩罚策略、约束策略优化和拉格朗日松弛方法, 我们在固定上述 γ_{risk} 和 ϵ_{risk} 的情况下调整惩罚项 λ 。对于安全策略优化, 我们采用一种调度方案, 将 λ 从调整拉格朗日松弛比较时找到的 λ 最佳值的 2 倍线性衰减到 0, 衰减过程均匀分布在整个训练回合中。在图 5 中, 我们研究了基于模型的恢复强化学习以及惩罚策略、约束策略优化和拉格朗日松弛比较方法在物体提取任务上对不同超参数选择的敏感性。在我们考虑的 γ_{risk} 取值范围内, 恢复强化学习对超参数的敏感性低于比较方法。

六、结论

我们提出恢复强化学习 (Recovery RL), 这是一种新的安全强化学习算法, 在 6 个仿真领域和一项基于图像的物理机器人避障任务中, 比 5 种最先进的安全强化学习算法更有效地平衡任务性能与约束满足。未来工作中, 我们希望进一步探索在物理机器人上的评估, 建立形式化保证, 并利用离线强化学习的思想更有效地预训练恢复策略。我们将探索约束违反可能并非灾难性的场景, 以及大规模机器人学习的应用。

七、致谢

本研究在加州大学伯克利分校自动化实验室 (AUTOLAB) 进行, 隶属于伯克利人工智能研究 (BAIR) 实验室、实时智能安全执行 (RISE) 实验室、谷歌大脑机器人部门和斯坦福人工智能研究实验室。作者还得到了 SAIL-丰田研究计划、可扩展协作人机学习 (SCHoL) 项目、美国国家科学基金会国家机器人计划奖 1734633 的支持, 以及谷歌、西门子、亚马逊机器人、丰田研究所的捐赠和英伟达的设备资助。本文仅反映作者的观点和结论, 不代表资助方或其关联机构的观点。A.B. 和 S.N. 受美国国家科学基金会研究生研究奖学金计划 (NSF GRFP) 支持。我们感谢提供有益反馈、代码和建议的同事, 特别是 Jie Tan, Jeffrey Ichnowski 和 Wisdom Agboh。

参考文献

- [1] J. Achiam, D. Held, A. Tamar, and P. Abbeel, "Constrained policy optimization", in *Proc. Int. Conf. on Machine Learning*, 2017.
- [2] M. Alshiekh, R. Bloem, R. Ehlers, B. Könighofer, S. Niekum, and U. Topcu, "Safe reinforcement learning via shielding", 2018.
- [3] E. Altman, *Constrained Markov Decision Processes*. 1999, p. 260.
- [4] S. Bansal, M. Chen, S. Herbert, and C. J. Tomlin, "Hamilton-jacobi reachability: A brief overview and recent advances", in *Conference on Decision and Control (CDC)*, 2017.
- [5] F. Berkenkamp, M. Turchetta, A. P. Schoellig, and A. Krause, "Safe model-based reinforcement learning with stability guarantees", in *Proc. Advances in Neural Information Processing Systems*, 2017.
- [6] Y. Chow, O. Nachum, E. Duéñez-Guzmán, and M. Ghavamzadeh, "A lyapunov-based approach to safe reinforcement learning", in *NeurIPS*, 2018.
- [7] Y. Chow, O. Nachum, A. Faust, M. Ghavamzadeh, and E. Duéñez-Guzmán, "Lyapunov-based safe policy optimization for continuous control", in *ICML Workshop RL4RealLife*, 2019.
- [8] K. Chua, R. Calandra, R. McAllister, and S. Levine, "Deep reinforcement learning in a handful of trials using probabilistic dynamics models", *Proc. Advances in Neural Information Processing Systems*, 2018.
- [9] F. Ebert, C. Finn, S. Dasari, A. Xie, A. Lee, and S. Levine, "Visual foresight: Model-based deep reinforcement learning for vision-based robotic control", *arXiv preprint arXiv:1812.00568*, 2018.
- [10] B. Eysenbach, S. Gu, J. Ibarz, and S. Levine, "Leave no trace: Learning to reset for safe and autonomous reinforcement learning", *International Conference on Learning Representations*, 2018.
- [11] J. F. Fisac, A. K. Akametalu, M. N. Zeilinger, S. Kaynama, J. Gillula, and C. J. Tomlin, "A general safety framework for learning-based control in uncertain robotic systems", in *IEEE Transactions on Automatic Control*, 2018.
- [12] J. F. Fisac, N. F. Lugovoy, V. Rubies-Royo, S. Ghosh, and C. J. Tomlin, "Bridging hamilton-jacobi safety analysis and reinforcement learning", in *Proc. IEEE Int. Conf. Robotics and Automation (ICRA)*, 2019.
- [13] J. H. Gillula and C. J. Tomlin, "Guaranteed safe online learning via reachability: Tracking a ground target using a quadrotor", in *Proc. IEEE Int. Conf. Robotics and Automation (ICRA)*, 2012.
- [14] T. Haarnoja, A. Zhou, P. Abbeel, and S. Levine, "Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor", *Proc. Int. Conf. on Machine Learning*, 2018.
- [15] T. Haarnoja, A. Zhou, K. Hartikainen, G. Tucker, S. Ha, J. Tan, V. Kumar, H. Zhu, A. Gupta, P. Abbeel, and S. Levine, "Soft actor-critic algorithms and applications", *CoRR*, 2018.
- [16] W. Han, S. Levine, and P. Abbeel, "Learning compound multi-step controllers under unknown dynamics", *Proc. IEEE/RSJ Int. Conf. on Intelligent Robots and Systems (IROS)*, 2015.
- [17] M. Heger, "Consideration of risk in reinforcement learning", in *Machine Learning Proceedings*, 1994.
- [18] M. Hwang, B. Thananjeyan, S. Paradis, D. Seita, J. Ichnowski, D. Fer, T. Low, and K. Goldberg, "Efficiently calibrating cable-driven surgical robots with rgbd sensing, temporal windowing, and linear and recurrent neural network compensation", *Robotics and Automation Letters (RAL)*, 2020.
- [19] D. Kalashnikov, A. Irpan, P. Pastor, J. Ibarz, A. Herzog, E. Jang, D. Quillen, E. Holly, M. Kalakrishnan, V. Vanhoucke, and S. Levine, "Qt-opt: Scalable deep reinforcement learning for vision-based robotic manipulation", *Conference on Robot Learning (CoRL)*, 2018.
- [20] P. Kazanzides, Z. Chen, A. Deguet, G. S. Fischer, R. H. Taylor, and S. P. DiMaio, "An open-source research kit for the da Vinci surgical system", in *Proc. IEEE Int. Conf. Robotics and Automation (ICRA)*, 2014.
- [21] S. Li and O. Bastani, "Robust model predictive shielding for safe reinforcement learning with stochastic dynamics", in *Proc. IEEE Int. Conf. Robotics and Automation (ICRA)*, 2020.
- [22] T. P. Lillicrap, J. J. Hunt, A. Pritzel, N. Heess, T. Erez, Y. Tassa, D. Silver, and D. Wierstra, "Continuous control with deep reinforcement learning", *Proc. Int. Conf. on Learning Representations*, 2016.
- [23] A. Nagabandi, K. Konoglie, S. Levine, and V. Kumar, "Deep dynamics models for learning dexterous manipulation", *Conference on Robot Learning (CoRL)*, 2019.
- [24] S. Nair, S. Savarese, and C. Finn, "Goal-aware prediction: Learning to model what matters", *Proc. Int. Conf. on Machine Learning*, 2020.
- [25] F. W. Petter Geibel, "Risk-sensitive reinforcement learning applied to control under constraints", in *Journal of Artificial Intelligence Research*, vol. 24, 2005.
- [26] A. Ray, J. Achiam, and D. Amodei, "Benchmarking safe exploration in deep reinforcement learning", in *NeurIPS Deep Reinforcement Learning Workshop*, 2019.
- [27] C. Richter and N. Roy, "Safe visual navigation via deep learning and novelty detection", *Robotics Science and Systems (RSS)*, 2013.
- [28] U. Rosolia and F. Borrelli, "Learning model predictive control for iterative tasks: a data-driven control framework", *IEEE Transactions on Automatic Control*, 2018.
- [29] Y. Shen, M. J. Tobia, T. Sommer, and K. Obermayer, "Risk-sensitive reinforcement learning", in *Neural Computation*, vol. 26, 2014.
- [30] K. Srinivasan, B. Eysenbach, S. Ha, J. Tan, and C. Finn, "Learning to be safe: Deep rl with a safety critic", *arXiv preprint arXiv:2010.14603*, 2020.
- [31] A. Tamar, Y. Glassner, and S. Mannor, "Policy gradients beyond expectations: Conditional value-at-risk", in *CoRR*, 2014.
- [32] P. Tandon, *Pytorch implementation of soft actor critic*, <https://github.com/pranz24/pytorch-soft-actor-critic>, 2020.
- [33] Y. C. Tang, J. Zhang, and R. Salakhutdinov, "Worst cases policy gradients", *Conf. on Robot Learning (CoRL)*, 2019.
- [34] C. Tessler, D. J. Mankowitz, and S. Mannor, "Reward constrained policy optimization", in *Proc. Int. Conf. on Learning Representations*, 2019.
- [35] B. Thananjeyan, A. Balakrishna, U. Rosolia, J. E. Gonzalez, A. Ames, and K. Goldberg, "Abc-Impc: Safe sample-based learning mpc for stochastic nonlinear dynamical systems with adjustable boundary conditions", in *Workshop on the Algorithmic Foundations of Robotics*, 2020.
- [36] B. Thananjeyan, A. Balakrishna, U. Rosolia, F. Li, R. McAllister, J. E. Gonzalez, S. Levine, F. Borrelli, and K. Goldberg, "Safety augmented value estimation from demonstrations (saved): Safe deep

- model-based rl for sparse cost robotic tasks”, *Robotics and Automation Letters (RAL)*, 2020.
- [37] M. Turchetta, F. Berkenkamp, and A. Krause, “Safe exploration in finite markov decision processes with gaussian processes”, in *Proc. Advances in Neural Information Processing Systems*, 2016.
- [38] Q. Vuong, *Pytorch implementation of pets*, <https://github.com/quanvuong/handful-of-trials-pytorch>, 2020.

Recovery RL: Safe Reinforcement Learning with Learned Recovery Zones Supplementary Material

The supplementary material is structured as follows: In Section VIII we discuss brief theoretical motivation for Recovery RL and possible variants and in Section IX we discuss algorithmic details for Recovery RL and comparison algorithms. In Section X, we report additional metrics for all domains and comparisons and in Section XI we visualize the safety critic for all navigation experiments. We provide additional details about algorithm implementation in Section XII, and on domain-specific algorithm hyperparameters in Section XIII. Finally, we report simulation and physical environment details in Section XIV.

VIII. RECOVERY RL THEORETICAL MOTIVATION AND VARIANTS

In this section, we will briefly and informally discuss additional properties of Recovery RL and then discuss some variants of Recovery RL.

A. 理论动机

回顾任务策略在具有修改动力学的环境中运行:

$$P_{\text{risk}}^{\pi_{\text{rec}}}(s'|s, a) = \begin{cases} P(s'|s, a) & (s, a) \in \mathcal{T}_{\text{safe}}^{\pi} \\ P(s'|s, a^{\pi_{\text{rec}}}) & (s, a) \in \mathcal{T}_{\text{rec}}^{\pi} \end{cases} \quad (\text{VIII.1})$$

然而, $P_{\text{risk}}^{\pi_{\text{rec}}}$ 随时间变化 (即使在同一回合内), 非平稳马尔可夫决策过程 (MDP) 中的策略学习分析目前仍具挑战性且是正在进行的工作。假设 $P_{\text{risk}}^{\pi_{\text{rec}}}$ 在预训练阶段后是平稳的, 则立即得出 π_{task} 在平稳 MDP $\mathcal{M}' = (\mathcal{S}, \mathcal{A}, P_{\text{risk}}^{\pi_{\text{rec}}}, R(\cdot, \cdot), \gamma, \mu)$ 中运行, 因此 π_{task} 在平稳 MDP 中的所有性质在 $\mathcal{M}'$ 中均适用。观察到 π_{task} 在 $\mathcal{M}'$ 中的迭代改进意味着 π 在 $\mathcal{M}$ 中的迭代改进, 因为两个 MDP 共享相同的奖励函数, 且 π_{task} 在 $\mathcal{M}'$ 中采取的动作等价于 π_{task} 在 $\mathcal{M}$ 中尝试该动作, 之后可能被 π_{rec} 捕获。

B. 安全价值函数

恢复强化学习 (Recovery RL) 的一种变体可以使用状态值函数 $V_{\text{risk}}^{\pi}(s)$ 作为安全评论家, 而非状态-动作值函数。虽然这种实现更简单, 但论文中使用的 Q_{risk}^{π} 版本可以切换到安全动作而非不安全动作, 而不是等待到达不安全状态才开始恢复行为。

C. 基于可达性的变体 另一种变体可以使用基于模型的恢复策略中学习到的动力学模型, 执行一步 (或 k 步) 前瞻, 以查看未来状态-动作元组是否在 $\mathcal{T}_{\text{safe}}^{\pi}$ 中。虽然 Q_{risk}^{π} 原则上携带关于未来安全性的信息, 但这是检查未来状态的另一种方法。

IX. 算法细节

A. 恢复强化学习

恢复策略: 原则上, 任何离线强化学习算法都可以用于学习恢复策略 π_{rec} 。在本文中, 我们探索了无模型和基于模型的强化学习算法来学习 π_{rec} 。对于无模型恢复, 我们对安全评论家 $\hat{Q}^{\pi}$ 执行梯度下降, 如同流行的离线强化学习 $\text{risk}(s, \pi_{\text{rec}}(s))$ 算法 DDPG [22]。我们选择 DDPG 风格的目标函数而非其他方案, 因为我们不希望恢复策略进行广泛探索。对于基于模型的恢复, 我们通过学习到的动力学模型 f_{θ} 执行模型预测控制 (MPC), 最小化以下目标:

$$L_{\theta}(s_t, a_t) = \mathbb{E} \left[\sum_{i=0}^H \hat{Q}_{\phi, \text{risk}}^{\pi}(\hat{s}_{t+i}, a_{t+i}) \right] \quad (\text{IX.1})$$

其中 $\hat{s}_{t+i+1} \sim f_{\theta}(\hat{s}_{t+i}, a_{t+i})$ 、 $\hat{s}_t = s_t$ 和 $\hat{a} = a_t$ 。对于低维任务, 我们利用 Chua 等人 [8] 的 PETS 算法在学习到的随机动力学模型上进行规划; 对于具有视觉观测的任务, 我们利用基于 VAE 的潜空间动力学模型。在离线预训练阶段, 当使用无模型恢复时, 批次从 $\mathcal{D}$ 离线数据中顺序采样, 每个批次用于 (1) 训练 $\hat{Q}_{\phi, \text{risk}}^{\pi}$ 和 (2) 优化 DDPG 策略以最小化当前 $\hat{Q}_{\phi, \text{risk}}^{\pi}$ 。当使用基于模型的恢复时, 数据

在 $\mathcal{D}$ 离线数据中首先用于学习动力学模型 f_{θ} , 使用 PETS (低维任务) 或潜空间动力学 (基于图像的任务)。然后, $\hat{Q}_{\phi}^{\pi}$ 风险被单独优化, 以在从 $\mathcal{D}$ 离线数据采样的批次上进行。在线强化学习阶段, 所有方法使用来自复合策略 π 的在线策略数据在线更新。

任务策略: 在实验中, 我们采用流行的最大熵强化学习算法软演员-评论家 (Soft Actor-Critic, SAC) [14] 来学习 π_{task} , 但需注意任何强化学习算法均可用于训练 π_{task} 。通常 π_{task} 仅在在线强化学习阶段更新。然而, 在探索困难的特定领域中, 我们会在少量任务特定演示上预训练软演员-评论家以加速学习。为此, 与训练无模型恢复策略类似, 我们离线地从 $\mathcal{D}$ 中顺序采样批次, 每个批次用于 (1) 训练 $\hat{Q}_{\phi, \text{risk}}^{\pi}$ 以及 (2) 优化软演员-评论家策略以最小化 $\hat{Q}_{\phi, \text{risk}}^{\pi}$ 。为了确保 π_{task} 学习到哪些动作会导致恢复行为, 我们在转移上训练 π_{task} 的 $(s_t, a_t, \pi_{\text{task}}(s_t), s_{t+1})$ 即使执行了 π_{rec} 。

B. 无约束

我们采用流行的无模型强化学习算法软演员-评论家 (Soft Actor-Critic) [14, 32] 的实现, 该算法通过随机演员函数最大化任务奖励与策略熵的组合。

C. 拉格朗日松弛 (Lagrangian Relaxation, LR)

本节将简要阐述并推导拉格朗日松弛比较方法。如前所述, 我们希望求解以下约束优化问题:

$$\min_{\pi} L_{\text{policy}}(s; \pi) \text{ s.t. } \mathbb{E}_{a \sim \pi(\cdot|s)} [Q_{\text{risk}}^{\pi}(s, a)] \leq \epsilon_{\text{risk}}$$

其中 L_{policy} 是我们希望最小化的策略损失函数 (例如来自 SAC 的)。与先前解决约束优化问题的方法一样, 我们可以转而求解以下无约束问题:

$$\max_{\lambda} \min_{\pi} L_{\text{policy}}(s; \pi) + \lambda (\mathbb{E}_{a \sim \pi(\cdot|s)} [Q_{\text{risk}}^{\pi}(s, a)] - \epsilon_{\text{risk}})$$

我们的目标是通过交替梯度下降找到拉格朗日函数的鞍点。在实践中, 每次评估目标函数时, 我们通过从 $\pi(\cdot|s)$ 采样一个动作来近似目标中的期望。

D. 风险敏感策略优化 (RSPO)

我们通过实现第 IX-C 节中讨论的拉格朗日松弛方法来实现风险敏感策略优化, 其中乘子序列随时间递减。这鼓励初始约束满足, 随后逐渐增加对任务目标的优先级, 其灵感来源于 [29] 中的风险敏感 Q 学习算法。

E. 强化学习的安全 Q 函数 (SQRL)

该比较与 LR 相同, 只是额外添加了一个 Q 滤波器, 该滤波器对策略分布 $\pi(\cdot|s_t)$ 执行拒绝采样, 直到找到一个动作 a_t 使得 $Q_{\text{risk}}^{\pi}(s_t, a_t) \leq \epsilon_{\text{risk}}$ 。

F. 奖励惩罚 (Reward Penalty, RP) 奖励惩罚比较方法仅在约束被违反时, 从任务奖励函数中减去一个常数惩罚 λ 。这是除无约束方法外唯一不使用学习得到的 Q_{risk}^{π} 或约束示范的比较算法, 但由于其出人意料的效力和简洁性而被纳入。

G. 离线策略奖励约束策略优化 (RCPO) 在在线策略 RCPO[34] 中, 策略通过策略梯度估计器进行优化, 最大化 $\mathbb{E}_{\pi} [\sum_{i=0}^{\infty} (\gamma R(s, a) - \lambda \gamma_{\text{risk}} D(s, a))]$ 。本文采用 $D(s, a) = Q_{\text{risk}}^{\pi}(s, a)$, 并按照 LR 中的方式更新拉格朗日乘子 λ 。也可以使用 $D(s, a) = C(s)$, 这将与 RP 比较方法几乎相同。本文没有使用在线策略强化学习来优化该目标, 而是使用 SAC 以离线策略方式进行优化, 以与其他比较方法保持一致。

X. 附加实验度量

在图 8 和图 9 中，我们报告了所有仿真实验中所有方法的累计任务成功次数和约束违反次数。我们在图 11 中报告了基于图像的避障物理实验的这些统计量。我们观察到，恢复强化学习（Recovery RL）在大多数领域中通常非常成功，且约束违反相对较少。一些更成功的比较方法往往有更多的约束违反。此外，在图 10 和图 12 中，我们绘制了恢复强化学习和所有比较算法所获得的累计奖励，以评估恢复强化学习是否在安全学习的同时学习得更高效。对于所有图，我们展示了每个回合获得的总奖励，并在 100 回合长度的窗口上进行了平滑处理。此外，当约束被违反时，我们不显示结果，以防止对可能非常频繁违反约束的算法产生负偏差，这解释了图中的空白，尤其是对于倾向于非常频繁违反约束的无约束算法。因此，这些图展示了所有算法在未违反约束条件下获得的奖励，这为所找到解的质量提供了一个良好的测度。我们发现，除了图 9 结果所证明的恢复强化学习的安全学习之外，图 10 和图 12 的结果表明，当恢复强化学习满足约束时，它通常比较算法更快地收敛到更高质量的解。这些结果进一步证明，恢复强化学习将任务导向优化和约束满足这两个经常冲突的目标分离开来的方式，使其不仅在学习过程中更安全，而且学习得更高效。在表 I 中，我们报告了约束违反发生时的实证结果。结果表明，在大多数任务中，当违反确实发生时，恢复策略已经被激活。因此，在这些失败案例中，恢复强化学习能够成功预测未来的违反，但无法阻止它们。这是令人鼓舞的，并表明对于恢复策略非常难以学习的环境，恢复强化学习仍然可以用于向人类监督者请求干预。

十一、安全评论家可视化

我们在图 14 中可视化了导航领域预训练后的安全评论家，并观察到增加 γ_{risk} 会导致障碍物附近区域更渐进地增加。增加 γ_{risk} 在 $Q_{risk}^{\pi}(s,a)$ 中携带更多关于可能未来违规的信息。然而，过度增加 γ_{risk} 会导致安全评论家在整个状态-动作空间中过度扩散，如最右列所示，使得难以区分安全和不安全状态。

十二、实现细节

这里我们概述了恢复强化学习（Recovery RL）及所有比较方法的实现和超参数细节。恢复策略（ π_{rec} ）和任务策略（ π_{task} ）在离线阶段和在线阶段都被实例化和训练。在离线阶段，使用来自 $\mathcal{D}$ 的离线数据预训练恢复策略；在在线阶段，恢复强化学习在由学习到的安全评论家和恢复策略约束的探索下更新任务策略。安全评论家和恢复策略也在线更新。对于所有实验，我们基于 [32] 中提供的软演员评论家（Soft Actor Critic）[15] 的 PyTorch 实现，所有训练网络均使用学习率为 $3e-4$ 的 Adam 优化器进行优化。我们首先在第十二-B 节中概述恢复强化学习和比较方法共享的超参数和训练细节，然后在第十二-C 节中讨论恢复强化学习中恢复策略的实现。

A. 网络架构 对于低维实验，我们使用具有 2 个隐藏层（每层 256 个单元）的全连接神经网络来表示评论家，并使用 ReLU 激活函数。策略同样使用具有 2 个隐藏层（每层 256 个单元）的全连接网络表示，使用 ReLU 激活函数，并输出条件高斯的参数。对于无模型恢复策略，我们使用相同策略的确定性版本。对于基于图像的实验，我们使用具有 3 个卷积层（用于嵌入输入图像）和 2 个全连接层（用于嵌入输入动作）的卷积神经网络来表示评论家。然后，将这些嵌入拼接起来，并通过另外两个全连接层。所有全连接层每层都有 256 个隐藏单元。我们使用 3 个卷积层，分别具有 128、64 和 16 个滤波器。所有层都使用核大小为 3、步长为 2、填充为 1。所有层之间使用 ReLU 激活函数，并为卷积层添加批归一化单元。对于所有使用安全评论家的算法（Recovery RL、LR、SQRL、RSPO、RCPO）， Q_{risk}^{π} 使用与任务评论家相同的架构表示，不同之处在于在输出头添加了 sigmoid

激活函数，以确保输出在 $[0, 1]$ 上，从而有效地学习约束违反的概率。任务策略和无模型恢复策略在基于图像的实验中也使用相同的架构，不同之处在于它们分别输出动作空间上的条件高斯的参数或一个动作。

B. 全局训练细节

为防止高估偏差，本文训练两份所有评论家网络，以计算 Q 值的悲观估计（任务评论家取最小值，安全评论家取最大值）。每个评论家均关联一个目标网络，并采用 Polyak 平均平滑地退火目标网络参数。除操作环境外，所有实验均使用大小为 1000000 的重放缓冲区，目标平滑系数为 $\tau = 0.005$ ；操作环境中重放缓冲区大小为 100000，目标平滑系数为 $\tau = 0.0002$ 。所有网络均以 256 个转移样本的批次进行训练。最后，对于 SAC，本文利用熵正则化系数 $\alpha = 0.2$ ，且不在线更新该系数。每个时间步后，本文以批大小 1000 执行一次梯度步以更新安全评论家。若适用，本文还在每个时间步以相同批次更新无模型恢复策略。若使用基于模型的恢复策略，则在每个回合结束时更新 5 个训练轮次。对于预训练，本文训练安全评论家和无模型恢复策略 100,000 步。本文训练基于模型的恢复策略 50 个训练轮次。

C. 恢复策略训练细节

本节描述所有任务中恢复策略所使用的神经网络架构与训练流程。

1) 无模型恢复：对于所有任务，无模型恢复策略采用与任务策略相同的架构，如第 XII-A 节所述。

然而，它直接在动作空间中输出一个动作，而非动作空间上的分布，并贪婪地最小化 $\hat{J}^{\pi}$ ，而不像 [14] 中那样包含熵正则化项。恢复策略在每个时间步以来自重放缓冲区的 1000 个样本批次进行训练。

2) 基于模型的恢复训练细节：对于非图像基于模型的恢复策略，我们使用 PETS[8, 38]，它在神经网络概率集成上进行训练和规划。我们使用 5 个神经网络的集成，每个网络有 3 个隐藏层，大小为 200，激活函数为 swish（输出层除外），输出条件高斯分布的参数。我们采用 Chua 等人 [8] 的 TS- ∞ trajectory 采样方案，并在所有环境中使用 400 个样本、40 个精英和 5 次迭代优化 MPC 优化问题。对于基于图像的任务，我们利用如 Nair 等人 [24] 所述的基于 VAE 的潜空间动力学模型。我们联合训练编码器、解码器和动力学模型，其中编码器和解码器为卷积神经网络，前向动力学模型为全连接网络。我们遵循与 Nair 等人 [24] 相同的架构。对于编码器，我们使用以下卷积层（通道数、核大小、步长）：[(32, 4, 2), (32, 3, 1), (64, 4, 2), (64, 3, 1), (128, 4, 2), (128, 3, 1), (256, 4, 2), (256, 3, 1)]，后接大小为 [1024, 512, 2L] 的全连接层，其中 L 为潜空间大小（预测均值和方差）。除最后一层外，所有层均使用 ReLU 激活函数。解码器从维度为 L 的潜空间中采样，然后通过全连接层 [128, 128, 128]，后接反卷积层（通道数、核大小、步长）：[(128, 5, 2), (64, 5, 2), (32, 6, 2), (3, 6, 2)]。除最后一层使用 Sigmoid 激活函数外，所有层同样使用 ReLU 激活函数。

对于前向动力学模型，我们使用全连接网络，层为 [128, 128, 128, L]，除最后一层外均使用 ReLU 激活函数。

XIII. 环境特定算法参数

对于 LR、RSPO、SQRL 和 RCPO，我们使用相同的 γ_{risk} 和 ϵ_{risk} 。对于 LR、RSPO 和 SQRL，我们发现 λ 的初始选择强烈影响算法的整体性能，并对此进行了大量调优。对于 LR 和 SQRL，我们使用相同的 λ 值，并将 LR 找到的最佳值的两倍作为 RSPO 中 λ 调度的初始化。我们还对 RP 和 RCPO 的 λ 进行了大量调优。这些值在每个环境中显示于表 III 和表 II。

XIV. 环境细节

在本节中，我们提供每个用于评估的环境的额外细节。




图 8: 仿真实验累计成功次数: 我们绘制了每个仿真域中各算法的累计任务成功次数, 所有算法的结果均为 10 次运行的平均值。我们观察到恢复强化学习 (Recovery RL, 绿色) 通常是最成功的算法之一。在成功次数较低的情况下, 我们观察到它更安全 (图 9)。我们发现, 除物体提取 (动态障碍物) 环境外, 恢复强化学习在所有环境中的任务成功率均高于或相当于次优算法。




图 9: 仿真实验累计违规次数: 我们绘制了每个仿真域中各算法的累计约束违规次数, 所有算法的结果均为 10 次运行的平均值。我们观察到恢复强化学习 (Recovery RL, 绿色) 在所有域中均属于最安全的算法之一。在安全性低于对比算法的情况下, 它的任务成功率更高 (图 8)。




图 10：仿真实验奖励学习曲线：我们展示了每个仿真域中每个回合获得的总奖励，经过 100 回合长度窗口的平滑处理，所有算法的结果均为 10 次运行的平均值。当约束被违反时，我们不显示结果，以避免对可能频繁违反约束的算法产生负偏差，这解释了图中的空白，尤其是对于倾向于频繁违反约束的无约束算法。因此，这些图展示了所有算法在不违反约束条件下获得的奖励，这为所找到解的质量提供了一个良好的测度。我们发现，除动态障碍物域外，恢复强化学习在任务奖励函数方面能够对比算法更快地收敛到更高质量的解。这表明与对比算法相比，恢复强化学习不仅学习更安全，而且学习更高效。




图 11：物理实验成功次数与违规次数：我们绘制了在 dVRK 上基于图像的避障任务中，每种算法 3 次运行的累计约束违规次数和任务成功次数。我们观察到恢复强化学习通常比 LR 和无约束算法更成功且更安全。

A. 导航环境

导航 1 和导航 2 环境具有线性高斯动力学，是从零开始构建的，而迷宫环境则基于 [24] 中的迷宫环境构建。在所有导航环境中，离线数据通过反复在环境中随机初始化点质量智能体并执行控制使其与最近的障碍物碰撞来收集。

1) 导航 1 和导航 2：该环境具有单积分器动力学，并带有从 $\mathcal{N}(0, \sigma^2 I_2)$ 采样的加性高斯噪声，其中 $\sigma = 0.05$ ，阻力系数为 0.2。起始位置从 $\mathcal{N}((-50, 0)^\top, I_2)$ 采样，如果智能体到达原点 1 单位以内，则任务被视为成功完成。我们使用到目标的负欧氏距离作为奖励函数。使用安全批评家的方法在离线预训练时获得 8000 个转移数据。对于导航 1，这些转移中有 455 个包含违反约束的状态，而在导航 2 中，这些转移中有 778 个包含违反约束的状态。

2) 迷宫：该环境在 MuJoCo 中实现，我们再次使用到目标的负欧氏距离作为奖励函数。使用安全批评家的方法在离线预训练时获得 10,000 个转移数据，其中 1163 个包含违反约束的状态。

B. 操作环境

我们在视觉预览仓库 [9] 中的夹爪小车环境之上构建了两个操作环境。机器人可以在基本方向上平移并打开/关闭其夹爪。在操作环境中，离线数据通过调整比例控制器引导机器人末端执行器朝向物体来收集。对于离线约束违反，当末端执行器足够接近物体时，在控制中加入高斯噪声以增加约束违反的可能性。此外，为了为 SAC 播种任务批评家函数以简化所有算法的探索，我们利用相同的 PID 控制器收集任务演示，展示当末端执行器足够接近红色物体时，通过自动打开和关闭夹爪成功举起红色物体。

1) 物体提取：该环境在 MuJoCo 中实现，奖励函数为 -1 ，直到物体被抓住并举起，此时奖励为 0 且回合终止。约束违反通过检查任何物体的方向是否绕 x 轴或 y 轴旋转至少 15 度来确定。所有使用安全评论家的方法都获得 20,000 条转移数据进行离线预训练，其中 363 条包含约束违反状态。所有方法都获得

表 I: 约束违反分解: 我们报告了每个环境中当恢复策略被激活时发生约束违反的比例 (格式为均值 $\pm$ 标准误)。如果大多数约束违反发生在恢复策略激活时, 这表明安全评论家足够准确, 能够检测到必须激活恢复策略, 但可能无法提供足够的信息来避免约束违反。我们注意到, 如果安全评论家检测到需要恢复行为的时间太晚, 那么这些错误归因于恢复策略。对于两个迷宫环境和物体提取环境, 大多数约束违反发生在恢复策略激活时。在导航 1 中, 恢复策略激活时没有发生约束违反, 但在这个环境中约束几乎从未被违反。在基于图像的避障任务中, 大多数违反发生在恢复策略未激活时, 这表明该任务的瓶颈是安全评论家的质量。在导航 2 中, 恢复 RL 从未违反约束, 并且仅在物理机器人上为恢复 RL 运行了无模型恢复。在动态障碍物物体提取环境中, 我们观察到约束违反期间低安全评论家值和恢复错误的组合更加均匀。

	Navigation 1	Navigation 2	Maze	Object Extraction	Object Extraction (Dynamic Obstacle)	Image Maze	Image Obstacle Avoidance
MF Recovery	N/A	N/A	0.828 ± 0.115	0.954 ± 0.024	0.550 ± 0.049	0.717 ± 0.156	0.000 ± 0.000
MB Recovery	N/A	1.000 ± 0.000	0.858 ± 0.039	0.98344 ± 0.01655	0.269 ± 0.055	0.583 ± 0.059	N/A

表 II: 所有领域中恢复 RL 和比较方法的超参数

	LR	RP	RCPO	MF Recovery	MB Recovery
Navigation 1	(0.8, 0.3, 5000)	1000	(0.8, 0.3, 1000)	(0.8, 0.3)	(0.8, 0.3, 5)
Navigation 2	(0.65, 0.2, 1000)	3000	(0.65, 0.2, 5000)	(0.65, 0.2)	(0.65, 0.2, 5)
Maze	(0.5, 0.15, 100)	50	(0.5, 0.15, 50)	(0.5, 0.15)	(0.5, 0.15, 15)
Object Extraction	(0.75, 0.25, 50)	50	(0.75, 0.25, 50)	(0.75, 0.25)	(0.85, 0.35, 15)
Object Extraction (Dyn. Obstacle)	(0.85, 0.25, 20)	25	(0.85, 0.25, 10)	(0.85, 0.35)	(0.85, 0.25, 15)
Image Maze	(0.65, 0.1, 10)	20	(0.65, 0.1, 20)	(0.65, 0.1)	(0.6, 0.05, 10)
Image Obstacle Avoidance	(0.55, 0.05, 1000)	N/A	N/A	(0.55, 0.05)	N/A




图 12: 物理实验奖励学习曲线: 我们展示了每个回合获得的总奖励, 经过 10 回合长度窗口的平滑处理, 并给出了所有算法 3 次运行的结果。当约束被违反时, 我们不显示结果, 以防止对可能频繁违反约束的算法产生负偏差, 这解释了图中的空白或为什么有些图只有一条线 (3 次运行中只有 1 次满足约束)。注意, 无约束算法未出现在图中, 因为它在任务较难的初始配置上从未取得进展。因此, 这些图展示了所有算法在不违反约束条件下获得的奖励, 这为所找到解的质量提供了一个很好的度量。我们发现, 与对比算法相比, 恢复强化学习能够更快地收敛到关于任务奖励函数的更高质量解。这表明, 与对比算法相比, 恢复强化学习不仅学习更安全, 而且学习更高效。

1000 条任务演示数据用于预训练任务策略的评论家函数。

2) 物体提取 (动态障碍物): 该环境在 MuJoCo 中实现, 奖励函数为 -1 , 直到物体被抓住并举起, 此时奖励为 0 且回合终止。约束违反通过检查任何物体的方向是否绕 x 轴或 y 轴旋转至少 15 度来确定。此外, 工作空间中有一个干扰臂以周期性方式来回移动。手臂碰撞也被视为约束违反。所有使用安全评论家的方法都获得 000 条数据进行离线预训练, 其中 896 条包含约束违反状态。所有方法都获得 1000 条任务演示数据用于预训练任务策略, 略的评论家函数。




图 13: 附加物理实验: dVRK 上的图像到达任务涉及引导末端执行器到达目标位置, 同时避开工作空间中心的一个不可见禁区。我们绘制了 dVRK 上图像到达任务的累积约束违反和任务成功次数。我们观察到, 恢复强化学习比 LR 和无约束方法更成功且更安全。

表 III: 恢复强化学习及所有对比算法的超参数。

Algorithm Name	Hyperparameter Format
LR	$(\gamma_{risk}, \epsilon_{risk}, \lambda)$
RP	λ
RCPO	$(\gamma_{risk}, \epsilon_{risk}, \lambda)$
MF Recovery	$(\gamma_{risk}, \epsilon_{risk})$
MB Recovery	$(\gamma_{risk}, \epsilon_{risk}, H)$

C. 图像迷宫

该迷宫同样在 MuJoCo 中实现, 其墙壁与具有真实状态的迷宫不同。若机器人与墙壁发生碰撞, 则会产生约束违反。所有方法均以 RGB 图像作为输入, 且所有使用安全批评家的方法均提供 20,000 条转移数据进行预训练, 其中 3466 条包含约束违反状态。




图 14: $\hat{Q}^{\pi}_{\phi, \text{risk}}$ 可视化: 我们使用基本方向(左、右、上、下)作为动作输入, 绘制导航环境的安全批评家 Q^{π}_{risk} 。可以看到, 随着 γ_{risk} 的增加, 梯度降低, 函数在接近障碍物时更加平缓地上升。增加 γ_{risk} 实质上增加了从未来可能约束违反中保留的信息量, 使其能够更早地被检测到。这些图还说明了安全批评家值的动作条件化。例如, 向下动作将墙壁和障碍物正上方的状态标记为比向上动作更不安全。

D. 物理实验

物理实验在达芬奇研究套件 (dVRK) [20] 上进行, 这是一种缆绳驱动的双边手术机器人。观测由 Zivid OnePlus RGBD 相机记录并提供给策略。然而, 我们仅使用 RGB 图像, 因为捕获速率更快, 并且我们对图像进行子采样, 使输入图像尺寸为 $48 \times 64 \times 3$ 。环境通过机器人里程计检查末端执行器位置以判断任务完成情况, 但该信息不提供给任何策略。实际上, 由于滞后等缆绳效应, 机器人末端执行器位置可能略有误差 [18], 但本文忽略这些影响。我们训练一个神经网络, 根据当前读数和关节位置对机器人是否发生碰撞进行分类。所有使用安全批评家的方法均提供 6,000 条数据转移进行预训练, 其中 649 条包含约束违反状态。与导航环境一样, 离线数据通过在环境中随机初始化末端执行器并将其引导至最近障碍物来收集。

为减少学习过程中的外推误差, 我们以相等概率在工作空间左右两侧采样起始状态。

E. 附加物理实验

本文还在基于图像的任务上评估了恢复强化学习 (Recovery RL) 及其比较方法, 该任务要求机器人确保末端执行器位置不与工作空间中心的禁入区相交, 而非物理保险杠。该设置与第十四-D 节中描述的设置几乎相同。本文再次向算法提供 RGB 图像, 并使用 10,000 次转移来预训练安全评论家。本文再次发现, 恢复强化学习在该任务上能够优于比较方法, 无论是在约束满足方面还是在任务完成方面。