

利用离线数据的高效在线强化学习

菲利普·J·鲍尔^{*1} Laura Smith^{*2} Ilya Kostrikov^{*2} Sergey Levine²

摘要

样本效率和探索仍然是在线强化学习 (RL) 中的主要挑战。一种可用于解决这些问题的有效方法是纳入离线数据，例如来自人类专家或次优探索策略的先前轨迹。以往的方法依赖于大量修改和额外复杂性来确保有效利用这些数据。相反，我们提出疑问：在在线学习时，能否简单地应用现有的离策略方法来利用离线数据？在这项工作中，我们证明了答案是肯定的；然而，需要对现有离策略强化学习算法进行一组最小但重要的修改，以实现可靠的性能。我们广泛地消融了这些设计选择，展示了最影响性能的关键因素，并得出了一组从业者可以轻松应用的建议，无论他们的数据包含少量专家演示还是大量次优轨迹。我们看到，正确应用这些简单的建议可以在各种竞争性基准上提供 $2.5\times$ 的改进，且没有额外的计算开销。我们已在此处发布代码：github.com/ikostrikov/rlpd。




图 1. 我们的方法 RLPD 扩展了标准的离策略强化学习，并在利用离线数据的多个任务上实现了可靠的最先进在线性能。这里我们展示了困难的 D4RL AntMaze 领域（10 个种子，1 个标准差阴影），平均了所有 6 个任务。由于早期收敛，我们运行 RLPD 300k 步。

通常依赖于与环境进行大量在线交互，这通常通过使用模拟器才变得可行。然而，在现实世界问题中，我们经常面临样本昂贵且奖励稀疏的场景，高维状态和动作空间往往加剧了这一问题。

解决这一问题的一个有前景的方法是在训练深度强化学习算法时纳入由先前策略或人类专家生成的数据（通常称为离线数据（Levine 等，2020）），这一点在理论上（Wagenmaker 和 Pacchiano，2022；Song 等，2023）以及 Cabi 等（2019）、Nair 等（2020）、Lu 等（2021）的现实世界示例中均得到了证实。通过为算法提供初始数据集来“启动”学习过程，可以缓解样本效率和探索方面的挑战，这些数据既可以是高质量的专家演示，也可以是低质量但高覆盖率的探索轨迹。这也为我们提供了一条利用大型预收集数据集来学习有用策略的途径。

一些先前的工作侧重于通过预训练来使用这些数据，而其他方法则在线训练时引入约束以处理分布偏移问题。然而，每种方法都有其缺点，例如额外的训练时间和超参数，或者分别仅能有限地超越行为策略。退一步看，我们注意到标准的离策略算法应该能够利用这些离线数据，而且问题

1. 引言

深度强化学习 (RL) 在多个复杂领域取得了成功，例如雅达利 (Mnih 等人，2015 年) 和围棋 (Silver 等人，2016 年)，以及芯片设计 (Mirhoseini 等人，2021 年) 和人类偏好对齐 (Ouyang 等人，2022 年) 等现实世界应用。在许多这些场景中，强大的强化学习性能依赖于^{*}同等贡献 1 牛津大学 2 加州大学伯克利分校。通讯作者：菲利普·J·鲍尔 <ball@robots.ox.ac.uk>，劳拉·史密斯 <smithlaura@berkeley.edu>，伊利亚·科斯特里科夫 <kostrikov@berkeley.edu>。

Proceedings of the 40th International Conference on Machine Learning, Honolulu, Hawaii, USA. PMLR 202, 2023. Copyright 2023 by the author(s).

在这种设置下，分布偏移的问题应该得到缓解，因为我们可以在线探索环境。然而，迄今为止，这类方法在此问题设置中取得的成功有限。因此，在这项工作中，我们提出以下问题：我们能否简单地应用现有的离策略方法，在在线学习时利用离线数据，而无需离线强化学习预训练或显式的模仿项来偏向先前的离线数据？

通过对一系列广泛研究的基准进行大量实验，我们表明这个问题的答案是肯定的。然而，直接应用现有的在线离策略强化学习算法可能导致性能相对较差，如图 1 中“SAC + 离线数据”与“IQL + 微调”的对比所示。相反，必须考虑一组最小的关键设计选择以确保其成功。具体而言，我们首先引入一种极其简单的离线数据采样方法，称为“对称采样”，该方法在多种领域中无需超参数调整即可表现良好。然后，我们发现在复杂环境中（例如稀疏奖励、离线数据量少、高维度等），防止价值函数过度外推至关重要。为此，我们提供了一个新颖的视角，说明层归一化（Layer Normalization）如何隐式地防止灾难性的价值过度外推，从而在许多场景中大幅提高样本效率和稳定性，同时对现有方法的修改极小。接着，为了提高离线数据的利用速率，我们纳入并比较了样本高效无模型强化学习的最新进展，发现大型集成在多种领域中非常有效。最后，我们识别并提供证据表明，近期强化学习文献中的关键设计选择实际上对环境敏感，揭示了一个令人惊讶的结果：具有相似属性的环境实际上需要完全不同的选择，并为从业者推荐了一个工作流程，以加速将我们的见解应用于新领域。

我们证明，我们最终的方法——称为 **RLPD**（带先验数据的强化学习）——在许多竞争性领域上优于先前报告的结果，如图 1 所示，有时提升 $2.5\times$ 。关键的是，由于我们的改动很小，我们保持了在线算法的吸引人的特性，如易于实现和计算效率高。此外，我们看到了我们方法的通用性，它在多种多样的离线数据集上取得了强劲的性能，从包含有限专家演示的数据集，到由大量次优轨迹组成的数据。

本文认为，这些洞见对社区和从业者具有重要价值。研究表明，在线离策略强化学习算法在利用离线数据进行学习时能够表现出显著的有效性。然而，本文也指出，其可靠性能的前提是

基于几个关键设计选择，即离线数据的采样方式、一种关键的评论家更新归一化方法，以及使用大型集成来提高样本效率。虽然强化学习与预训练数据（RLPD）的各个组成部分是对现有强化学习组件的简单修改，但本文表明它们的组合在多个流行的带离线数据的在线强化学习基准上达到了最先进的性能，超越了显著更复杂的先前方法，并推广到多种不同类型的离线数据，无论是专家演示还是次优轨迹。本文已在 github.com/ikostrikov/rlpd 发布强化学习与预训练数据（RLPD）。

2. 相关工作

离线强化学习预训练。我们注意到与离线强化学习（Offline RL）的联系（Ernst 等，2005；Fujimoto 等，2019；Levine 等，2020）；许多先前的工作先进行离线强化学习，随后进行在线微调（Hester 等，2018；Kalashnikov 等，2018；Nair 等，2020；Lee 等，2021；Kostrikov 等，2022）。值得注意的是，Lee 等（2021）在在线学习时也考虑了大型集成和每个时间步多个梯度更新的设置。然而，本文的方法采用了一种显著更简单的采样机制，无需任何超参数，并且不依赖于成本高昂的离线预训练，后者还会引入额外的超参数。本文还强调，所提出的归一化更新并非离线强化学习方法——本文不进行任何离线预训练，而是从头开始运行在线强化学习，并将离线数据包含在经验回放缓冲区中。

约束至先验数据。离线强化学习预训练范式的一种替代方案是显式约束在线智能体的更新，使其表现出与离线数据相似的行为（Levine & Koltun, 2013; Fox et al., 2016; Hester et al., 2018; Nair et al., 2018a; Rajeswaran et al., 2018; Rudner et al., 2021）。与本文方法尤为相关的是 Rajeswaran et al. (2018) 的工作，该工作通过加权更新来增强策略梯度更新，显式地包含演示数据。相比之下，本文采用样本高效的离策略范式，且不进行任何预训练。与本文工作类似的还有 Nair et al. (2018a)，他们也使用带有固定离线回放缓冲区的离策略算法。然而，本文并未使用行为克隆项来限制策略，也不会重置到演示状态。此外，本文注意到这些方法通常要求离线数据具有高质量（即“从演示数据中学习”（Asada & Hanafusa, 1979; Schaal, 1996）），而本文方法的重要之处在于对数据质量不敏感。

使用先验数据的无约束方法。先前的工作也考虑了在没有任何约束的情况下融入离线数据的方法。一些方法侧重于用离线数据初始化回放缓冲区（Većerík et al., 2017; Hester et al.,

2018)，而其他工作则利用平衡采样策略来处理在线和离线数据 (Nair et al., 2018b; Kalashnikov et al., 2018; Hansen et al., 2022; Zhang et al., 2023)。最近，Song et al. (2023) 对此类方法进行了理论分析，表明平衡采样在理论和实践中都很重要。在本文的实验中，本文也证明了平衡采样有助于使用离线数据进行在线强化学习；然而，在一系列基准任务上直接使用这种方法是不够的，本文提出的其他设计决策对于在所有任务上取得良好性能至关重要。

3. 预备知识

本文考虑可以形式化为马尔可夫决策过程 (Markov Decision Process, MDP) (Bellman, 1957) 的问题，描述为一个元组 $(\mathcal{S}, \mathcal{A}, \gamma, p, r, d_0)$ ，其中 $\mathcal{S}$ 是状态空间， $\mathcal{A}$ 是动作空间， $\gamma \in (0, 1)$ 是折扣因子。动态由转移函数 $p(s'|s, a)$ ；控制，存在奖励函数 $r(s, a)$ 和初始状态分布 $d_0(s)$ 。强化学习的目标是最大化折扣奖励的期望总和：
$$\mathbb{E}_{\pi} \left[\sum_{t=1}^{\infty} \gamma^t r(s_t, a_t) \right]。$$

本文聚焦于强化学习 (Reinforcement Learning, RL)，同时可访问离线数据集 $\mathcal{D}$ (Levine 等人, 2020)，即由特定马尔可夫决策过程 (MDP) 生成的 (s, a, r, s') 元组集合。离线数据集的一个关键特性是它们通常不提供完整的状态-动作覆盖，即 $\{s, a \in \mathcal{D}\}$ 是 $\mathcal{S} \times \mathcal{A}$ 的一个小子集。由于缺乏在策略覆盖，使用函数逼近的方法在此数据上学习时可能会过度外推值，从而对学习性能产生显著影响 (Fujimoto 等人, 2019)。

4. 结合离线数据的在线强化学习

如第 3 节所述，本文考虑标准强化学习设置，并额外加入预先收集的数据集。本文旨在设计一种通用方法，该方法对预先收集数据的质量和数量不敏感。例如，这些数据可以是少量人类演示，也可以是大量次优的探索性数据。此外，本文希望所提建议对问题设置的性质不敏感，例如观测是状态还是基于像素的，或者奖励是稀疏还是密集的。

为此，本文提出一种基于离策略无模型强化学习的方法，无需预训练或显式约束，称为 **RLPD (Reinforcement Learning with Prior Data)**，利用先验数据的强化学习)。如第 4.5 节所述，本文算法设计基于 SAC (Haarnoja 等人, 2018a; b)，但原则上这些设计选择也可能改进其他离策略强化学习方法。首先，本文提出一种简单的机制来整合先验数据。然后，本文识别出将离策略方法直接应用于此问题时存在的一种病态现象，




图 2. 使用 SAC 与本文对称采样方法可能因 Q 值发散而导致不稳定；在评论家网络中加入 LayerNorm 后该现象消失，性能得到提升。

并提出一种简单且侵入性最小的解决方案。之后，本文通过引入样本高效强化学习的最新方法，提高离线数据的利用速率。最后，本文强调近期深度强化学习中常见的设计选择实际上对环境敏感，实践者应相应调整。

4.1. 设计选择 1：一种简单高效的策略以

整合离线数据

我们从一个简单的方法开始，该方法引入先验数据，不增加任何计算开销，同时对离线数据的性质保持不可知。我们称之为“对称采样”，即对于每个批次，我们从回放缓冲区采样 50% 的数据，其余 50% 从离线数据缓冲区采样，类似于罗斯与巴格内尔 (2012) 使用的方案。正如我们将在后续章节中看到的，这种采样策略在各种场景下出奇地有效，并且我们对该方案的各个要素进行了广泛的消融研究 (见第 5.1 节)。然而，将这种方法应用于典型的异策略方法，如软演员-评论家 (SAC) (哈诺亚等人, 2018a)，并不能产生强劲的性能，如图 1 所示，因此必须考虑进一步的设计选择。

4.2. 设计选择 2：层归一化缓解

灾难性高估

标准的异策略强化学习算法会查询学习到的 Q 函数以获取分布外 (OOD) 动作，这些动作在学习过程中可能未被定义。因此，由于使用函数逼近，实际值可能被显著高估 (特伦与施瓦茨, 1993)。在实践中，当评论家试图追赶不断增长的价值时，这种现象会导致训练不稳定和可能的发散。

特别是，我们发现在复杂任务中直接应用我们的对称采样方法时会出现这种情况 (见图 2)。评论家发散是一个被广泛研究的问题，尤其是在离线环境中，策略无法生成新的经验。然而，在我们的问题设置中，我们可以从环境中采样。因此，我们不需要创建一个明确阻止分布外动作的机制 (这可以被视为反探索 (雷扎伊法尔等人, 2022))，而是需要简单地确保

学习到的函数不会以不受约束的方式进行外推。为此，我们证明层归一化（LayerNorm）（巴等人，2016）可以限制网络的外推，但关键的是，它并不明确约束策略保持接近离线数据。这反过来又不会阻止策略探索状态-动作空间中未知且可能有价值的区域。特别是，我们证明层归一化限制了值，并在经验上防止了灾难性的值外推。具体来说，考虑一个由 θ, w 参数化的 Q 函数 Q ，应用层归一化和中间表示 $\psi_\theta(\cdot, \cdot)$ 。对于任何 a 和 s ，我们可以说¹：

$$\begin{aligned} \|Q_{\theta, w}(s, a)\| &= \|w^T \text{relu}(\psi_\theta(s, a))\| \\ &\leq \|w\| \|\text{relu}(\psi_\theta(s, a))\| \leq \|w\| \|\psi(s, a)\| \\ &\leq \|w\| \end{aligned}$$

因此，由于层归一化（Layer Normalization）的作用，即使对于数据集之外的动作，Q 值也受到权重层范数的约束。因此，错误动作外推的影响被大大减轻，因为它们的 Q 值不太可能显著大于数据中已见过的值。实际上，回顾图 2，我们看到在评论家（critic）中引入层归一化通过缓解评论家发散显著提升了性能。

为了说明这一点，我们生成一个数据集，其中输入 x 分布在半径为 0.5 的圆内，标签为 $y = \|x\|$ 。我们研究一个带有修正线性单元（ReLU）激活的标准两层多层感知机（MLP）（在深度强化学习中常见）如何在数据分布之外进行外推，以及添加层归一化的效果。在图 3 中，标准参数化导致支持集之外的无界外推，而层归一化限制了值，大大减少了不受控制的外推的影响。

4.3. 设计选择 3：样本高效强化学习

我们现在拥有一种利用离线数据的在线方法，该方法也抑制了极端值外推，同时保持了无约束离策略方法的自由度。然而，离线和约束方法的一个好处是它们具有显式机制来高效地整合先验数据，例如通过预训练（Hester 等人，2018；Lee 等人，2021）或辅助监督项（Nair 等人，2018a；Rudner 等人，2021）。在我们的情况下，先验数据的整合是通过对离线转移进行在线贝尔曼备份隐式实现的。因此，这些贝尔曼备份必须尽可能样本高效地执行。

实现这一目标的一种方法是增加每个环境步骤执行的更新次数（也称为更新与数据（UTD）比率），允许离线数据被-

¹ 为简单起见，我们考虑不带偏差项的层归一化。这不会改变分析，因为它是一个常数。




图 3. 我们用不带层归一化的两层多层感知机（中）和带层归一化的两层多层感知机（右）拟合数据（左）。层归一化限制了值并防止了灾难性高估。

更快地“备份”。然而，正如近期在线强化学习文献所强调的，由于统计过拟合，这可能在优化过程中产生问题，并反而降低样本效率（Li 等，2022）。为缓解这一问题，先前工作提出了多种正则化方法，如简单的 L2 归一化（Veřer'ík 等，2017）、随机失活（Srivastava 等，2014；Hiraoka 等，2022）以及随机集成蒸馏（Chen 等，2021）。本文采用后一种随机集成蒸馏方法；我们将通过消融实验证明该方法表现最强，尤其是在稀疏奖励任务上。

我们还注意到，从图像进行时序差分学习时存在价值过拟合问题（Cetin 等，2022）。因此，在这些设置中，我们进一步加入随机平移增强（Kostrikov 等，2021；Yarats 等，2022）。

4.4. 各环境设计选择

在强调了可普遍适用于所有环境和离线数据集的三个关键设计选择之后，我们现在转向那些通常被视为理所当然、但实际上可能对环境敏感的设计选择。已有充分文献表明，深度强化学习算法对实现细节敏感（Henderson 等，2018；Engstrom 等，2020；Andrychowicz 等，2021；Furuta 等，2021）。因此，许多深度强化学习工作需要每个环境进行超参数调优。鉴于我们实验中考虑的任务种类繁多，我们认为有必要参与这一讨论，并强调某些设计选择——这些选择通常只是从先前实现中继承而来——实际上应当被仔细重新考虑，并且可能解释了为什么离策略方法在我们考虑的问题上迄今缺乏竞争力。因此，我们采取的观点是，鉴于深度强化学习对细节的敏感性已有充分记录，在评估新环境时展示一条关键的设计选择路径非常重要，并为实践者提供一个简化此过程的工作流程。

截断双 Q 学习（CDQ）。基于价值的方法结合函数逼近和随机优化会受到估计不确定性的影响，这种不确定性与 Q 学习的最大化目标相结合，会导致价值高估（van Hasselt 等，2016）（如第 4.2 节所讨论）。为了缓解这一问题

问题在于，藤本等人（2018）引入了截断双 Q 学习（Clipped Double Q-Learning, CDQ），该方法在计算时序差分备份时，取两个 Q 函数集成中的最小值。他们为更新评论家定义的目标如下：

$$y = r(s, a) + \gamma \min_{i=1,2} Q_{\theta_i}(s', a') \text{ 其中 } a' \sim \pi(\cdot | s').$$

然而，这相当于拟合比实际目标值低一个标准差的目标 Q 值，而近期研究（莫斯科维茨等人，2021）表明，这种设计选择可能并非普遍适用，因为它可能过于保守。因此，这一点值得重新考虑，尤其是在其最初设计领域之外，例如我们问题设置中普遍存在的稀疏奖励任务。

Maximum Entropy RL. MaxEnt RL augments the traditional return objective with an entropy term:

$$\max_{\pi} \mathbb{E}_{s \sim \rho^{\pi}, a \sim \pi} \left[\sum_{t=0}^{\infty} \gamma^t (r_t + \alpha \mathcal{H}(\pi(a|s))) \right].$$

这相当于在每个时间步最大化折扣奖励和期望策略熵。这些方法的动机集中在鲁棒性和探索上（即，在尽可能随机行动的同时最大化奖励）。依赖此目标的方法在经验上表现出色（哈尔诺亚等人，2018a; b; 陈等人，2021; 平冈等人，2022）。因此，我们认为在在线微调背景下，这种设计选择值得关注，因为此时奖励通常稀疏且需要探索。

架构。网络架构对深度强化学习性能有显著影响，在一个环境中最优的架构在另一个环境中可能次优（古田等人，2021）。为简化搜索空间，我们考虑演员和评论家中 2 层或 3 层的影响，研究表明即使在典型任务上，这也会影响性能（鲍尔和罗伯茨，2021）。

4.5. RLPD: 方法概述

此处我们给出方法的伪代码，以绿色突出显示对我们方法重要的元素，以紫色突出显示环境特定的设计选择。

RLPD 的关键因素在于算法 1 的第 1 行和第 13 行，采用了层归一化（LayerNorm）、大型集成、样本高效学习以及对称采样方法来融合在线与离线数据。对于环境特定的选择，我们推荐以下作为起点：

- 第 3 行：子集 2 个评论家
- 第 16 行：移除熵
- 第 1 行：利用更深的 3 层多层感知机（MLP）

作为实用的工作流程，我们建议首先消融这些紫色设计选择，并按照上述顺序进行。

Algorithm 1 Online RL with Offline Data (RLPD)

```

1: Select LayerNorm, Large Ensemble Size  $E$ , Gradient Steps  $G$ , and architecture.
2: Randomly initialize Critic  $\theta_i$  (set targets  $\theta'_i = \theta_i$ ) for  $i = 1, 2, \dots, E$  and Actor  $\phi$  parameters. Select discount  $\gamma$ , temperature  $\alpha$  and critic EMA weight  $\rho$ .
3: Determine number of Critic targets to subset  $Z \in \{1, 2\}$ 
4: Initialize empty replay buffer  $\mathcal{R}$ 
5: Initialize buffer  $\mathcal{D}$  with offline data
6: while True do
7:   Receive initial observation state  $s_0$ 
8:   for  $t = 0, T$  do
9:     Take action  $a_t \sim \pi_{\phi}(\cdot | s_t)$ 
10:    Store transition  $(s_t, a_t, r_t, s_{t+1})$  in  $\mathcal{R}$ 
11:    for  $g = 1, G$  do
12:      Sample minibatch  $b_R$  of  $\frac{N}{2}$  from  $\mathcal{R}$ 
13:      Sample minibatch  $b_D$  of  $\frac{N}{2}$  from  $\mathcal{D}$ 
14:      Combine  $b_R$  and  $b_D$  to form batch  $b$  of size  $N$ 
15:      Sample set  $Z$  of  $Z$  indices from  $\{1, 2, \dots, E\}$ 
16:      With  $b$ , set
          
$$y = r + \gamma \left( \min_{i \in Z} Q_{\theta'_i}(s', \tilde{a}') \right), \quad \tilde{a}' \sim \pi_{\phi}(\cdot | s')$$

17:      Add entropy term  $y = y + \gamma \alpha \log \pi_{\phi}(\tilde{a}' | s')$ 
18:      for  $i = 1, E$  do
19:        Update  $\theta_i$  minimizing loss:
          
$$L = \frac{1}{N} \sum_i (y - Q_{\theta_i}(s, a))^2$$

20:      end for
21:      Update target networks  $\theta'_i \leftarrow \rho \theta'_i + (1 - \rho) \theta_i$ 
22:    end for
23:    With  $b$ , update  $\phi$  maximizing objective:
          
$$\frac{1}{E} \sum_{i=1}^E Q_{\theta_i}(s, \tilde{a}) - \alpha \log \pi_{\phi}(\tilde{a} | s), \quad \tilde{a} \sim \pi_{\phi}(\cdot | s)$$

24:  end for
25: end while

```

5. 实验

我们设计实验不仅是为了证明设计选择的重要性，还为了提供洞见，使实践者能够快速将 RLPD 适应到他们的问题中。因此，我们旨在回答以下问题：

1. RLPD 是否在没有使用预训练也没有显式约束的情况下，仍能与先前工作竞争？
2. RLPD 能否迁移到基于像素的环境？
3. 层归一化能否缓解价值发散？
4. 围绕环境特定设计选择所提出的工作流程能否带来可靠的性能？




图 4. RLPD 在多个不同流行基准上超越了先前最先进的性能，同时显著更简单。结果在 21 个不同环境上聚合（10 个种子，1 个标准差阴影）。在每种情况下，我们与先前已知的最佳工作（Adroit 和 AntMaze 中的 IQL+微调，Locomotion 中的 Off2On）以及 SACfD（一种使用离线数据的典型离策方法）进行比较。

对于（1），我们将 RLPD 与那些设计用于利用离线数据加速在线学习的方法进行比较。对于（2），我们考虑一组额外的任务来研究 RLPD 在基于视觉领域的适用性。然后，对于（3），我们进行分析以证明使用层归一化的重要性。最后，对于（4），我们在最具挑战性的任务上展示我们提出的工作流程（见第 4.5 小节）。

RLPD 如何比较？ 我们考虑来自既定基准的以下 21 个任务：

- **稀疏 Adroit**（奈尔等人，2020）。这三项灵巧操作任务——转笔、开门、移球——具有挑战性且奖励稀疏。离线数据是多模态的，包含少量人类演示和大量由基于这些人类数据训练的行为克隆策略生成的轨迹。我们遵循科斯特里科夫等人（2022）的严格评估标准，即性能基于完成速度而非成功率。IQL 加微调代表了最强的先前工作（科斯特里科夫等人，2022）。

- **D4RL 蚁迷宫**（傅等人，2020）。这六个稀疏奖励任务要求蚂蚁智能体学会行走并穿越迷宫到达目标。离线数据仅包含次优轨迹，原则上可以“拼接”在一起。同样，IQL 加微调代表了最强的先前工作（科斯特里科夫等人，2022）。

- **D4RL 运动**（傅等人，2020）。最后，我们有十二个密集奖励的运动任务，其离线数据具有不同水平的专业性。离线到在线（李等人，2021）在这组任务上具有最先进的性能。

在评估中，我们首先纳入 SACfD，这是先前工作中研究过的基线（韦切日克等人，2017；奈尔等人，2020），与 RLPD 类似，它是一种在训练期间纳入离线数据的离策方法。然而，SACfD 仅用离线数据初始化在线回放缓冲区。我们使用 SAC 实现该基线，但不采用第 4.5 小节中讨论的额外设计决策。然后，由于没有单一的先前方法能在所有任务组上取得最佳性能，我们与每组任务特定的最先进方法进行比较（如上所列）。我们在图中将此比较称为先前最先进。对于所有

本工作中的实验，我们报告十个随机种子下的均值和标准差，并在上述三组任务内汇总结果。按任务细分的完整详细结果见附录 A，更多环境细节见附录 B.1。

我们看到 RLPD 表现强劲，在这些具有挑战性的基准上要么持平，要么显著超越已知的最佳先前工作（见图 4）。我们重申，与先前的 SOTA 方法不同，我们呈现的 RLPD 和 SACfD 结果未进行任何预训练。因此，虽然先前工作（以蓝色显示）可能取得强劲的初始性能，但在线改进较为温和。另一方面，我们的方法仅需约 1 万个在线样本即可达到或超越这一性能。值得注意的是，我们在稀疏 Adroit“Door”任务上以 $2.5\times$ 超越了最佳报告性能。此外，据我们所知，我们的方法是首个有效“解决”所有 AntMaze 任务的方法。而且，我们能够在不到先前方法分配的时间步预算三分之一的情况下做到这一点。

RLPD 能否迁移到像素输入？ 这里我们考虑 V-D4RL（Lu 等人，2022 年）中的中等和专家运动任务，这是一个仅包含像素观测的离线数据集。V-D4RL 尤其具有挑战性，因为行为策略是基于状态的，这意味着数据在像素空间中部分可观测。这在“Humanoid Walk”中最为明显，身体部位被视觉遮挡，因此行为克隆（BC）难以取得强劲性能。在评估方面，由于我们的方法旨在利用离线数据加速在线学习，我们关注数据效率——我们引入一个称为“10%DMC”的挑战，即仅使用 Yarats 等人（2022 年）推荐的总时间步的 10% 来训练策略。由于我们使用中等和专家数据，我们加入了 BC 基线。为了评估 RLPD 高效利用离线数据提升在线学习的能力，我们与不使用离线数据的基线方法进行比较。为了隔离离线数据利用的影响，我们使用与我们的方法相同的架构和策略优化器，并在图中将该基线标记为 **Online**。然后，为了评估这与基于像素的最先进样本高效 RL 方法的比较，我们与 **DrQ-v2**（Yarats 等人，2022 年）进行比较。




图 5. 我们的方法可推广到基于视觉的领域，相比现有方法提供一致的改进。

从图 5² 可以看出，RLPD 相比纯在线方法提供了一致的改进，并且在许多情况下相比行为克隆基线有大幅提升。通过 RLPD（黑色和紫色虚线）与在线基线的差异可以看出，RLPD 有效利用离线数据来引导学习。这一结论在与最先进的基于视觉的强化学习方法（蓝色）比较时依然成立。

最后，我们在其中一个任务——使用专家离线数据的猎豹奔跑任务上测试将更新数据比提高到 10。图 6 显示，在使用离线数据集学习时性能有显著提升。据我们所知，这是首次证明高更新数据比方法能够改进基于像素的无模型连续控制。




图 6. 在 RLPD 中提高更新数据比可大幅提升基于像素的样本效率。

5.1. RLPD 分析与消融实验

在此，我们通过量化层归一化的影响并展示所提工作流程的可靠性（见第 4.5 小节），来回应第 (3) 和 (4) 点。

层归一化能否缓解价值发散？ 我们现在说明层归一化在缓解灾难性价值发散中的重要性，并重点关注容易产生过估计的任务。在图 7 中，我们看到层归一化对于 Adroit 领域的优异性能至关重要；去除层归一化会导致不同随机种子间的方差显著增大，并降低平均性能。

为了更清晰地展示这一效果，我们构建了一个仅包含 Adroit 稀疏任务中专家人类演示数据的数据集（见图 7 中的“专家 Adroit 稀疏任务”）。该子集仅包含原始数据集中 500 条轨迹中的 22 条，且分布范围更窄——代表一个奖励稀疏、演示有限且离线数据覆盖范围狭窄的任务——这很可能加剧价值发散。在此我们看到了显著的结果：尽管数据受到严格限制，RLPD 仍然超越了先前的工作。此外，去除层归一化后




图 7. 层归一化对于取得优异性能至关重要，尤其是在数据有限或分布狭窄的情况下。

导致性能崩溃，所有任务均无进展。我们进一步观察到，在 AntMaze 和 Humanoid Walk 中加入层归一化，通过减少过度外推，提升了样本效率。更多实验与结果见附录 A。

设计选择工作流程。

我们现在在第 4.5 节中阐述工作流程的动机，以证明这些设计选择的重要性。我们聚焦于最困难的任务，即 Adroit Sparse 中的“Relocate”、AntMaze 中的“Large Diverse”以及 V-D4RL 中的“Humanoid Expert”，因为我们发现这些任务最为敏感。我们在附录 A 中提供了所有任务的完整结果，并注意到在较难领域中的最优决策在较易领域中也同样能产生最优结果。




图 8. 我们推荐的起始设计选择与工作流程在所有任务上均取得了优异性能。

从图 8 中可以看出，采用推荐的环境特定设计选择能够带来优异性能；而使用熵备份和更小的网络则始终导致性能下降。然而，在“AntMaze Large Diverse”中，我们发现使用 CDQ 会导致性能恶化。遵循我们的工作流程，并通过将评论家数量削减为 1 进行消融，对于恢复优异性能至关重要。同样的情况也适用于“Humanoid Walk Expert”，我们惊讶地发现 CDQ 对性能有害，尽管它在近期实现中很受欢迎。我们还展示了在基于像素的任务中，更大的集成所带来的惊人正面效果：我们默认在 RLPD 中使用的 10 成员评论家集成，其表现优于标准的 2 成员集成。

最后，我们进行了额外的消融实验，以理解我们为方法所提出的设计选择的重要性。结果表明，尽管单个设计决策很简单，但它们对于取得良好性能至关重要。

² V-D4RL 的归一化回报为回合回报除以 10。

评论家正则化。

此处我们考察评论家正则化对性能的影响。我们比较三种方法：权重衰减³ (Većerík 等, 2017)、随机失活 (Hiraoka 等, 2022) 和集成 (Chen 等, 2021)。我们从 AntMaze、Adroit 和 Locomotion 部分选取了先前实验的一个子集进行评估。




图 9. 总体而言，评论家集成提供了最佳性能。随机失活在稀疏奖励任务中表现较差。

在图 9 中，我们看到集成是最强的正则化形式。值得注意的是，虽然随机失活在 Locomotion 领域 'walker2d-medium-v0' 中表现良好，正如 Hiraoka 等 (2022) 所证实的那样，但它并不能泛化到具有挑战性的稀疏奖励环境。我们还看到，权重衰减正则化在所有领域中性能都较差。

缓冲区初始化。

在本节中，我们将对称采样与依赖于用离线数据初始化回放缓冲区的方法进行比较。





图 10. 对称采样提高了样本效率并降低了不同种子间的方差，并且其作用并非通过简单地增加批次中的奖励密度来实现。

首先回到 Adroit 中具有挑战性的人类专家演示设置，

图 10 展示了两个对比示例，证明对称采样能有效地在回放数据与离线数据之间进行权衡。我们观察到在 Pen 环境中，对称采样通过确保小批量中奖励密度不断增加，明显改善了探索。³ 我们发现权重衰减值为 0.01 在多种设置下效果最佳。大量数据初始化缓冲区限制了改进。



相比之下，我们看到尽管缓冲区初始化方法在 Door 环境中探索效果同样良好，但对称采样具有提高稳定性和降低方差的重要作用，因为它较少依赖在线策略生成的高方差数据。

现在我们考虑一种拥有大量次优离线数据的情况，并再次看到我们的平衡采样方法提高了样本效率。在图 11 中，用大量中等质量运动数据初始化缓冲区，初始性能优于在线性能，但渐近性能难以提升，这可能是由于缺乏对在线改进至关重要的在线策略数据采样。另一方面，我们的对称采样方法提高了样本效率，达到了渐近性能，同时降低了方差。

采样比例敏感性。

我们评估了采样方法在偏离 50% 在线/离线“对称”比例时的敏感性。




图 12. RLPD 对重放比例不敏感；50% 在方差、收敛速度和渐近性能之间提供了最佳折衷。

如图 12 所示，RLPD 对采样比例不太敏感。虽然在 'walker2dmedium-v0' 中采样 25% 的离线数据可以略微提升渐近性能，但这在稀疏奖励任务中会以方差和样本效率为代价。我们还通过 100% 离线结果确认，RLPD 不是一种离线方法，其成功的关键在于它如何在无限制探索或行为学习的情况下控制发散。

6. 结论

本文表明，离线策略方法可经调整以在在线训练时利用离线数据。我们发现，通过审慎应用关键设计选择，RLPD 能够取得极为优异的性能，并在共计 30 个不同任务上予以验证。具体而言，对称采样、层归一化作为值外推正则化器以及样本高效学习的独特组合是其成功的关键，使我们在众多竞争性基准上超越先前工作最高达 $2.5\times$ 。此外，与纯在线方法相比，我们的建议对计算效率的影响可忽略不计，且实现简单，使从业者能够轻松将本工作的洞见融入现有方法。

为进一步提升可采纳性，我们为从业者推荐并演示了一套工作流程，该流程在广泛任务上提升了性能，从而表明在应用离线策略方法时应重新审视某些规范设计选择。最后，为促进未来研究，我们已发布 RLPD 代码库：github.com/ikostrikov/rlpd，该代码库在单一 JAX (Bradbury 等人, 2018) 代码库中为本体感知和基于像素的任务提供了高度优化的离线策略算法。

致谢

PJB 由 Willowgrove 基金会和 Les Woods 纪念基金资助。本研究部分得到 DARPA RACER 项目、ARO W911NF-21-1-0097、海军研究办公室 N00014-21-1-2838 和 N00014-19-12042 的支持。本研究使用了加州大学伯克利分校伯克利研究计算项目提供的 Savio 计算集群资源（由加州大学伯克利分校校长、研究副校长和首席信息官支持）。

参考文献

- Andrychowicz, M., Raichuk, A., Stańczyk, P., Orsini, M., Girgin, S., Marinier, R., Hussenot, L., Geist, M., Pietquin, O., Michalski, M., Gelly, S., and Bachem, O. What matters for on-policy deep actor-critic methods? a large-scale study. In *International Conference on Learning Representations*, 2021. URL <https://openreview.net/forum?id=nIAxjsniDzg>.
- Asada, H. and Hanafusa, H. Playback control of force teachable robots. *Transactions of the Society of Instrument and Control Engineers*, 15(3):410–411, 1979. doi: 10.9746/sicetr1965.15.410.
- Ba, J. L., Kiros, J. R., and Hinton, G. E. Layer normalization, 2016. URL <https://arxiv.org/abs/1607.06450>.
- Ball, P. J. and Roberts, S. J. Offcon³: What is state of the art anyway?, 2021. URL <https://arxiv.org/abs/2101.11331>.
- Bellman, R. A markovian decision process. *Indiana Univ. Math. J.*, 6:679–684, 1957. ISSN 0022-2518.
- Bradbury, J., Frostig, R., Hawkins, P., Johnson, M. J., Leary, C., Maclaurin, D., Necula, G., Paszke, A., VanderPlas, J., Wanderman-Milne, S., and Zhang, Q. JAX: composable transformations of Python+NumPy programs, 2018. URL <http://github.com/google/jax>.
- Cabi, S., Colmenarejo, S. G., Novikov, A., Konyushkova, K., Reed, S. E., Jeong, R., Zolna, K., Aytar, Y., Budden, D., Vecerík, M., Sushkov, O. O., Barker, D., Scholz, J., Denil, M., de Freitas, N., and Wang, Z. Scaling data-driven robotics with reward sketching and batch reinforcement learning. *Robotics: Science and Systems XVI*, 2019.
- Cetin, E., Ball, P. J., Roberts, S., and Celiktutan, O. Stabilizing off-policy deep reinforcement learning from pixels. In Chaudhuri, K., Jegelka, S., Song, L., Szepesvari, C., Niu, G., and Sabato, S. (eds.), *Proceedings of the 39th International Conference on Machine Learning*, volume 162 of *Proceedings of Machine Learning Research*, pp. 2784–2810. PMLR, 17–23 Jul 2022. URL <https://proceedings.mlr.press/v162/cetin22a.html>.
- Chen, X., Wang, C., Zhou, Z., and Ross, K. W. Randomized ensembled double q-learning: Learning fast without a model. In *International Conference on Learning Representations*, 2021. URL <https://openreview.net/forum?id=AY8zfZm0tDd>.
- Engstrom, L., Ilyas, A., Santurkar, S., Tsipras, D., Janoos, F., Rudolph, L., and Madry, A. Implementation matters in deep rl: A case study on ppo and trpo. In *International Conference on Learning Representations*, 2020. URL <https://openreview.net/forum?id=r1etN1rtPB>.
- Ernst, D., Geurts, P., and Wehenkel, L. Tree-based batch mode reinforcement learning. *Journal of Machine Learning Research*, 6(18):503–556, 2005. URL <http://jmlr.org/papers/v6/ernst05a.html>.
- Fox, R., Pakman, A., and Tishby, N. Taming the noise in reinforcement learning via soft updates. In *32nd Conference on Uncertainty in Artificial Intelligence (UAI)*, 2016.
- Fu, J., Kumar, A., Nachum, O., Tucker, G., and Levine, S. D4rl: Datasets for deep data-driven reinforcement learning, 2020.
- Fujimoto, S., van Hoof, H., and Meger, D. Addressing function approximation error in actor-critic methods. *ArXiv*, abs/1802.09477, 2018.
- Fujimoto, S., Meger, D., and Precup, D. Off-policy deep reinforcement learning without exploration. In Chaudhuri, K. and Salakhutdinov, R. (eds.), *Proceedings of the 36th International Conference on Machine Learning*, volume 97 of *Proceedings of Machine Learning Research*, pp. 2052–2062. PMLR, 09–15 Jun 2019. URL <https://proceedings.mlr.press/v97/fujimoto19a.html>.

- Furuta, H., Kozuno, T., Matsushima, T., Matsuo, Y., and Gu, S. Co-adaptation of algorithmic and implementational innovations in inference-based deep reinforcement learning. In Beygelzimer, A., Dauphin, Y., Liang, P., and Vaughan, J. W. (eds.), *Advances in Neural Information Processing Systems*, 2021. URL https://openreview.net/forum?id=vLyI__SoeAe.
- Haarnoja, T., Zhou, A., Abbeel, P., and Levine, S. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. *International Conference on Machine Learning (ICML)*, 2018a.
- Haarnoja, T., Zhou, A., Hartikainen, K., Tucker, G., Ha, S., Tan, J., Kumar, V., Zhu, H., Gupta, A., Abbeel, P., and Levine, S. Soft actor-critic algorithms and applications, 2018b. URL <https://arxiv.org/abs/1812.05905>.
- Hansen, N., Lin, Y., Su, H., Wang, X., Kumar, V., and Rajeswaran, A. Modem: Accelerating visual model-based reinforcement learning with demonstrations. *arXiv preprint*, 2022.
- Henderson, P., Islam, R., Bachman, P., Pineau, J., Precup, D., and Meger, D. Deep reinforcement learning that matters. *Proceedings of the AAAI Conference on Artificial Intelligence*, 32(1), Apr. 2018. doi: 10.1609/aaai.v32i1.11694. URL <https://ojs.aaai.org/index.php/AAAI/article/view/11694>.
- Hester, T., Vecerik, M., Pietquin, O., Lanctot, M., Schaul, T., Piot, B., Horgan, D., Quan, J., Sendonaris, A., Osband, I., Dulac-Arnold, G., Agapiou, J., Leibo, J., and Gruslys, A. Deep q-learning from demonstrations. *Proceedings of the AAAI Conference on Artificial Intelligence*, 32(1), Apr. 2018. doi: 10.1609/aaai.v32i1.11757. URL <https://ojs.aaai.org/index.php/AAAI/article/view/11757>.
- Hiraoka, T., Imagawa, T., Hashimoto, T., Onishi, T., and Tsuruoka, Y. Dropout q-functions for doubly efficient reinforcement learning. In *International Conference on Learning Representations*, 2022. URL <https://openreview.net/forum?id=xCVJMsPv3RT>.
- Kalashnikov, D., Irpan, A., Pastor, P., Ibarz, J., Herzog, A., Jang, E., Quillen, D., Holly, E., Kalakrishnan, M., Vanhoucke, V., and Levine, S. Scalable deep reinforcement learning for vision-based robotic manipulation. In Billard, A., Dragan, A., Peters, J., and Morimoto, J. (eds.), *Proceedings of The 2nd Conference on Robot Learning*, volume 87 of *Proceedings of Machine Learning Research*, pp. 651–673. PMLR, 29–31 Oct 2018. URL <https://proceedings.mlr.press/v87/kalashnikov18a.html>.
- Kostrikov, I., Yarats, D., and Fergus, R. Image augmentation is all you need: Regularizing deep reinforcement learning from pixels. In *International Conference on Learning Representations*, 2021. URL <https://openreview.net/forum?id=GY6-6sTvGaf>.
- Kostrikov, I., Nair, A., and Levine, S. Offline reinforcement learning with implicit q-learning. In *International Conference on Learning Representations*, 2022. URL <https://openreview.net/forum?id=68n2s9ZJWF8>.
- Lee, S., Seo, Y., Lee, K., Abbeel, P., and Shin, J. Offline-to-online reinforcement learning via balanced replay and pessimistic q-ensemble. In *5th Annual Conference on Robot Learning*, 2021. URL <https://openreview.net/forum?id=AlJXhEI6J5W>.
- Levine, S. and Koltun, V. Guided policy search. In Dasgupta, S. and McAllester, D. (eds.), *Proceedings of the 30th International Conference on Machine Learning*, volume 28 of *Proceedings of Machine Learning Research*, pp. 1–9, Atlanta, Georgia, USA, 17–19 Jun 2013. PMLR. URL <https://proceedings.mlr.press/v28/levine13.html>.
- Levine, S., Kumar, A., Tucker, G., and Fu, J. Offline reinforcement learning: Tutorial, review, and perspectives on open problems, 2020. URL <https://arxiv.org/abs/2005.01643>.
- Li, Q., Kumar, A., Kostrikov, I., and Levine, S. Efficient deep reinforcement learning requires regulating statistical overfitting. In *Deep Reinforcement Learning Workshop NeurIPS 2022*, 2022. URL <https://openreview.net/forum?id=Jwfa-oyQduy>.
- Lu, C., Ball, P. J., Rudner, T. G. J., Parker-Holder, J., Osborne, M. A., and Teh, Y. W. Challenges and opportunities in offline reinforcement learning from visual observations. In *Workshop on Learning from Diverse, Offline Data*, 2022. URL <https://openreview.net/forum?id=bPOBIKaqLba>.
- Lu, Y., Hausman, K., Chebotar, Y., Yan, M., Jang, E., Herzog, A., Xiao, T., Irpan, A., Khansari, M., Kalashnikov, D., and Levine, S. Aw-opt: Learning robotic skills with imitation and reinforcement at scale. In *5th Annual Conference on Robot Learning*, 2021.
- Mirhoseini, A., Goldie, A., Yazgan, M., Jiang, J. W., Songhori, E. M., Wang, S., Lee, Y.-J., Johnson, E., Pathak, O., Nazi, A., Pak, J., Tong, A., Srinivasa, K., Hang, W., Tuncer, E., Le, Q. V., Laudon, J., Ho, R., Carpenter, R., and Dean, J. A graph placement methodology for fast chip design. *Nature*, 594 7862:207–212, 2021.

- Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A. A., Veness, J., Bellemare, M. G., Graves, A., Riedmiller, M., Fidjeland, A. K., Ostrovski, G., Petersen, S., Beattie, C., Sadik, A., Antonoglou, I., King, H., Kumaran, D., Wierstra, D., Legg, S., and Hassabis, D. Human-level control through deep reinforcement learning. *Nature*, 518 (7540):529–533, February 2015. ISSN 00280836. URL <http://dx.doi.org/10.1038/nature14236>.
- Moskovitz, T., Parker-Holder, J., Pacchiano, A., Arbel, M., and Jordan, M. Tactical optimism and pessimism for deep reinforcement learning. In Ranzato, M., Beygelzimer, A., Dauphin, Y., Liang, P., and Vaughan, J. W. (eds.), *Advances in Neural Information Processing Systems*, volume 34, pp. 12849–12863. Curran Associates, Inc., 2021. URL <https://proceedings.neurips.cc/paper/2021/file/6abcc8f24321d1eb8c95855eab78ee95-Paper.pdf>.
- Nair, A., McGrew, B., Andrychowicz, M., Zaremba, W., and Abbeel, P. Overcoming exploration in reinforcement learning with demonstrations. In *2018 IEEE International Conference on Robotics and Automation (ICRA)*, pp. 6292–6299. IEEE Press, 2018a. doi: 10.1109/ICRA.2018.8463162. URL <https://doi.org/10.1109/ICRA.2018.8463162>.
- Nair, A., McGrew, B., Andrychowicz, M., Zaremba, W., and Abbeel, P. Overcoming exploration in reinforcement learning with demonstrations. In *2018 IEEE international conference on robotics and automation (ICRA)*, pp. 6292–6299. IEEE, 2018b.
- Nair, A., Gupta, A., Dalal, M., and Levine, S. AWAC: Accelerating online reinforcement learning with offline datasets. *arXiv*, June 2020.
- Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C., Mishkin, P., Zhang, C., Agarwal, S., Slama, K., Gray, A., Schulman, J., Hilton, J., Kelton, F., Miller, L., Simens, M., Aspell, A., Welinder, P., Christiano, P., Leike, J., and Lowe, R. Training language models to follow instructions with human feedback. In Oh, A. H., Agarwal, A., Belgrave, D., and Cho, K. (eds.), *Advances in Neural Information Processing Systems*, 2022. URL <https://openreview.net/forum?id=TG8KACxEON>.
- Rajeswaran, A., Kumar, V., Gupta, A., Vezzani, G., Schulman, J., Todorov, E., and Levine, S. Learning Complex Dexterous Manipulation with Deep Reinforcement Learning and Demonstrations. In *Proceedings of Robotics: Science and Systems (RSS)*, 2018.
- Rezaeifar, S., Dadashi, R., Vieillard, N., Hussenot, L., Bachem, O., Pietquin, O., and Geist, M. Offline reinforcement learning as anti-exploration. *Proceedings of the AAAI Conference on Artificial Intelligence*, 36 (7):8106–8114, Jun. 2022. doi: 10.1609/aaai.v36i7.20783. URL <https://ojs.aaai.org/index.php/AAAI/article/view/20783>.
- Ross, S. and Bagnell, J. A. Agnostic system identification for model-based reinforcement learning. In *Proceedings of the 29th International Conference on Machine Learning, ICML’12*, pp. 1905–1912, Madison, WI, USA, 2012. Omnipress. ISBN 9781450312851.
- Rudner, T. G. J., Lu, C., Osborne, M., Gal, Y., and Teh, Y. W. On pathologies in KL-regularized reinforcement learning from expert demonstrations. In Beygelzimer, A., Dauphin, Y., Liang, P., and Vaughan, J. W. (eds.), *Advances in Neural Information Processing Systems*, 2021. URL <https://openreview.net/forum?id=sS8rRmgAatA>.
- Schaal, S. Learning from demonstration. In Mozer, M., Jordan, M., and Petsche, T. (eds.), *Advances in Neural Information Processing Systems*, volume 9. MIT Press, 1996. URL <https://proceedings.neurips.cc/paper/1996/file/68d13cf26c4b4f4f932e3eff990093ba-Paper.pdf>.
- Silver, D., Huang, A., Maddison, C. J., Guez, A., Sifre, L., van den Driessche, G., Schrittwieser, J., Antonoglou, I., Panneershelvam, V., Lanctot, M., Dieleman, S., Grewe, D., Nham, J., Kalchbrenner, N., Sutskever, I., Lillicrap, T., Leach, M., Kavukcuoglu, K., Graepel, T., and Hassabis, D. Mastering the game of Go with deep neural networks and tree search. *Nature*, 529(7587):484–489, January 2016. doi: 10.1038/nature16961.
- Song, Y., Zhou, Y., Sekhari, A., Bagnell, D., Krishnamurthy, A., and Sun, W. Hybrid RL: Using both offline and online data can make RL efficient. In *International Conference on Learning Representations*, 2023. URL <https://openreview.net/forum?id=yyBis80iUuU>.
- Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., and Salakhutdinov, R. Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(56):1929–1958, 2014. URL <http://jmlr.org/papers/v15/srivastava14a.html>.
- Thrun, S. and Schwartz, A. Issues in using function approximation for reinforcement learning. In *Proceedings of 4th Connectionist Models Summer School*. Erlbaum Associates, June 1993.
- van Hasselt, H., Guez, A., and Silver, D. Deep reinforcement learning with double q-learning. *Proceedings of the AAAI Conference on Artificial Intelligence*, 30(1), Mar. 2016. doi: 10.1609/aaai.v30i1.

10295. URL <https://ojs.aaai.org/index.php/AAAI/article/view/10295>.

Večerík, M., Hester, T., Scholz, J., Wang, F., Pietquin, O., Piot, B., Heess, N., Rothörl, T., Lampe, T., and Riedmiller, M. Leveraging demonstrations for deep reinforcement learning on robotics problems with sparse rewards. *arXiv*, July 2017.

Wagenmaker, A. and Pacchiano, A. Leveraging offline data in online reinforcement learning. *arXiv preprint arXiv:2211.04974*, 2022.

Yarats, D., Fergus, R., Lazaric, A., and Pinto, L. Mastering visual continuous control: Improved data-augmented reinforcement learning. In *International Conference on Learning Representations*, 2022. URL https://openreview.net/forum?id=_SJ-_yyes8.

Zhang, H., Xu, W., and Yu, H. Policy expansion for bridging offline-to-online reinforcement learning. In *The Eleventh International Conference on Learning Representations*, 2023. URL <https://openreview.net/forum?id=-Y34L45JR6z>.

A. 详细实验

A.1. 稀疏 Adroit

完整结果 本文在此呈现稀疏灵巧操作（Sparse Adroit）的完整结果，包括层归一化（LayerNorm）及环境特定设计选择的消融实验。




图 13. 灵巧操作完整结果。

可见层归一化显著降低了笔（Pen）与门（Door）环境中的方差，但略微损害了重定位（Relocate）任务的平均性能。然而综合来看，层归一化仍是该领域实现可靠性能的关键要素。

A.2. 蚂蚁迷宫（AntMaze）

完整结果 本文在此呈现蚂蚁迷宫的完整结果，包括层归一化及环境特定设计选择的消融实验。




图 14. 蚂蚁迷宫完整结果

可见本文推荐的设计选择对于较难的“大型”任务取得优异性能至关重要，此外使用更深的 3 层网络似乎有助于提升所有任务的稳定性。如图所示，在“大型”环境中的最优设计选择同样适用于“超大型”（Umaze）与“中型”（Medium）环境。

每个环境步的梯度步数消融

其中我们

在图 15 中每个时间步执行一次梯度更新。这对于在真实机器人上的学习可能是必需的，因为计算效率很重要。




图 15. 带与不带层归一化的 SAC。

在图 16 中，我们看到增加每个时间步的梯度步数的影响。如我们所见，样本效率和稳定性都得到了极大的提升。




图 16. RLPD 对比 SAC+层归一化+离线数据。

完整的 IQL 比较 这里我们与 IQL+微调进行比较。我们在 x 轴上以负索引表示 IQL 的预训练梯度步数。如图 17 所示，尽管 IQL 学习到了强大的初始化，但它难以在此基础上进一步提升。相比之下，RLPD 能够迅速匹配，然后大幅超越 IQL。




图 17. RLPD 对比 IQL + 微调。我们使用负索引展示 IQL 的离线预训练步骤。

A.3. D4RL 运动任务

Full Results Here we present the full results for D4RL Locomotion, including LayerNorm and baselines. We emphasize that these tasks are not necessarily a good use case for online learning with offline datasets, as the tasks can be solved relatively quickly with purely online approaches, and there is no inherent difficulty regarding exploration.




图 18. D4RL 消融实验。

在图 18 中，层归一化的影响并不十分明确；这是可以预期的，因为在线方法在该领域已经取得了较强的结果。值得注意的是，与基线相比，我们在中等专家领域表现出强劲的性能。




图 19. D4RL 专家数据消融实验。

我们还测试了 (Lee 等人, 2021) 未测试的狭窄专家数据集。在图 19 中, 我们看到层归一化可以略微提升样本效率和渐近性能。

A.4. V-D4RL 运动任务

完整结果 这里我们展示 V-D4RL 运动任务的完整结果, 包括层归一化和环境特定设计选择的消融实验。




图 20. VD4RL 消融实验。


可以看出, 层归一化在 Walker 和 Humanoid 环境中带来了显著提升。同时, 在复杂的 Humanoid 领域中, 我们推荐的设计选择也展现出了积极的影响。

B. 实验细节


B.1. 更多环境细节



(a) The Sparse Adroit Domain. Pen, Door and Relocate tasks respectively.



(b) The AntMaze Domain. Umaze, Medium and Large tasks respectively.



(c) The V-D4RL Domain. Walker Walk, Cheetah Run and Humanoid Walk respectively.

图 21. 我们所考虑环境的可视化。

我们提供了所评估关键领域的更多细节。图 21 展示了这些环境的可视化。

稀疏 Adroit 在这些任务中，奖励是一个二元变量，表示任务是否成功完成。在先前的工作（Nair 等人，2020；Rudner 等人，2021）中，通常使用成功率作为度量，它仅判断任务是否在任意时间步内完成。然而，Kostrikov 等人（2022）采用了一种更具挑战性的度量，涉及完成速度。具体而言，回报计算为任务被认为已解决的总时间步的百分比（注意没有提前终止）。例如，在“Pen”任务中，时间范围为 100 个时间步，如果策略达到 80 的归一化分数，这意味着在 80 个时间步内任务被认为已解决。这实际上意味着策略能够在 20 个时间步内解决任务。在每次评估中，我们进行 100 次试验。

D4RL：蚂蚁迷宫 在这些任务中，奖励是一个二元变量，表示智能体是否到达目标。到达目标后，回合终止。因此，归一化回报是评估试验中成功的比例。我们遵循先前的工作，进行 100 次试验，并将归一化回报衡量为成功试验的百分比。

B.2. 超参数

这里我们在表 1 中列出了 RLPD 的超参数，在表 2 中列出了环境特定的超参数。

表 1. RLPD 超参数。

Parameter	Value
Online batch size	128
Offline batch size	128
Discount (γ)	0.99
Optimizer	Adam
Learning rate	3×10^{-4}
Ensemble size (E)	10
Critic EMA weight (ρ)	0.005
Gradient Steps (State Based) (G or UTD)	20
Network Width	256 Units
Initial Entropy Temperature (α)	1.0
Target Entropy	$-\dim(\mathcal{A})/2$
Pixel-Based Hyperparameters	
Action repeat	2
Observation size	[64, 64]
Image shift amount	4

表 2. 环境特定超参数。

Environment	CDQ	Entropy Backups	MLP Architecture
Locomotion	True	True	2 Layer
AntMaze	False	False	3 Layer
Adroit	True	False	3 Layer
DMC (Pixels)	False	False	2 Layer