

RMA：用于腿式机器人的快速运动自适应

Ashish Kumar
UC Berkeley

Zipeng Fu
Carnegie Mellon University

Deepak Pathak
Carnegie Mellon University

Jitendra Malik
UC Berkeley, Facebook




图 1：我们在多个具有挑战性的环境中展示了 RMA 的性能。机器人在沙子、泥地、远足小径、高草和土堆上均能成功行走，且在所有试验中无一失败。机器人在沿远足小径下楼梯时成功率为 70%，在穿越水泥堆和卵石堆时成功率为 80%。尽管在训练期间从未见过不稳定或下沉的地面、阻碍性植被或楼梯，机器人仍能达到如此高的成功率。所有部署结果均使用同一策略，未进行任何仿真校准或现实世界微调。视频见 <https://ashish-kmr.github.io/rma-legged-robots/>


摘要——腿式机器人在现实世界中的成功部署要求它们能够实时适应未见过的场景，如地形变化、负载变化、磨损等。本文提出快速运动自适应（Rapid Motor Adaptation, RMA）算法，以解决四足机器人的实时在线自适应问题。RMA 由两个组件组成：基础策略和自适应模块。这些组件的组合使机器人能够在几分之一秒内适应新情况。RMA 完全在仿真中训练，不使用任何领域知识，如参考轨迹或预定义足部轨迹生成器，并部署在 A1 机器人上，无需任何微调。我们使用基于生物能量学启发的奖励，在多样地形生成器上训练 RMA，并将其部署在各种困难地形上，包括岩石、湿滑、可变形表面，以及草地、高植被、混凝土、卵石、楼梯、沙子等环境。RMA 在多样化的现实世界和仿真实验中均展现出最先进的性能。视频结果见 <https://ashish-kmr.github.io/rma-legged-robots/>。

控制理论工具 [36, 43, 46, 16, 56, 63, 50, 26, 28, 2, 24]。这些方法要求人类设计者具备相当的专业知识，近年来，利用强化学习和模仿学习技术 [23, 18, 41, 55, 32] 复制这一成功引起了广泛关注，这可以降低设计负担，并可能提升性能。标准范式是在物理仿真环境中训练基于强化学习的控制器，然后利用各种仿真到现实迁移技术 [52, 40, 23] 将其迁移到现实世界。这种迁移已被证明极具挑战性，因为仿真到现实差距本身是多种因素共同作用的结果：（a）物理机器人与其在仿真器中的模型存在显著差异；（b）现实世界地形（图 1）与我们在仿真器中的模型差异很大；（c）物理仿真器无法准确捕捉现实世界的物理特性——这里涉及接触力、可变形表面等——这比模拟自由空间中运动的刚体要困难得多。本文报告了我们在解决这一问题上的进展

I. 引言

过去四十年间，通过物理动力学建模，腿式机器人技术取得了巨大进步

A) Training in Simulation



B) Deployment




图 2：RMA 由两个子系统组成——基础策略 π 和自适应模块 ϕ 。 上图：RMA 分两个阶段训练。第一阶段，基础策略 π 以当前状态 x_t 、上一动作 a_{t-1} 和特权环境因子 e_t 为输入，这些因子通过环境因子编码器 μ 编码为潜在外部向量 z_t 。基础策略在仿真中使用无模型强化学习进行训练。第二阶段，自适应模块 ϕ 通过监督学习，利用在线策略数据从状态和动作历史中预测外部向量 $\hat{z}_t$ 。下图：部署时，自适应模块 ϕ 以 10Hz 频率生成外部向量 $\hat{z}_t$ ，基础策略以 100Hz 频率生成期望关节位置，并通过 A1 的 PD 控制器转换为力矩。由于自适应模块运行频率较低，基础策略使用自适应模块预测的最新外部向量 $\hat{z}_t$ 进行预测 a_t 。这种异步设计对于在 A1 等计算资源有限的低成本机器人上实现无缝部署至关重要。视频见：<https://ashish-kmr.github.io/rma-legged-robots/>

四足机器人运动的挑战，以宇树科技（Unitree）相对廉价的 A1 机器人作为实验平台。图 1 展示了若干示例，视频中呈现了实际运行结果。在概述本文方法（图 2）之前，首先指出，人类在现实世界中的行走需要快速适应：在不同土壤上移动、上坡或下坡、携带负载、肌肉休息或疲劳，以及应对脚踝扭伤等情况。本文将这一核心问题同样聚焦于腿足机器人，并称之为快速运动适应（Rapid Motor Adaptation, RMA）。本文假设 RMA 必须在线进行，时间尺度为几分之一秒，这意味着没有时间在物理世界中执行多次实验、展开多条轨迹并优化以估计各种系统参数。情况可能更糟。若将四足机器人置于无先前经验的岩石表面，机器人策略将频繁失败，对机器人造成严重损害。为了调整行走策略而收集哪怕 3-5 分钟的行走数据，在实际中可能不可行。因此，本文的策略不仅要求基础

行走策略，而且 RMA 必须在仿真中训练，并直接部署到现实世界。但如何实现呢？图 2 显示 RMA 由两个子系统组成：基础策略 π 和自适应模块 ϕ ，它们协同工作，在非常多样化的环境配置上实现在线实时自适应。基础策略通过强化学习在仿真中训练，使用关于环境配置 e_t 的特权信息，如摩擦、负载等。向量 e_t 的知识使基础策略能够适当地适应给定环境。环境配置向量 e_t 首先通过编码器网络 μ 编码到潜在特征空间 z_t 中。这个潜在向量 z_t ，我们称之为外部因素，然后与当前状态 x_t 和上一个动作 a_{t-1} 一起输入到基础策略中。基础策略随后预测机器人的期望关节位置 a_t 。策略 π 和环境因子编码器 μ 通过强化学习在仿真中联合训练。不幸的是，这个策略不能直接部署，因为在现实世界中我们无法获得 e_t 。什么

我们需要做的是在运行时估计外部参数，这正是自适应模块 ϕ 的作用。关键洞见在于，当我们命令机器人关节进行某种运动时，实际运动与命令之间的差异取决于外部参数。因此，与其使用特权信息，我们或许可以利用智能体最近的状态历史来估计这个外部参数向量，类似于卡尔曼滤波器从可观测量的历史中进行状态估计的操作。具体而言， ϕ 的目标是从机器人最近的状态和动作历史中估计外部参数向量 z_t ，而不假设能够访问 e_t 。这是在运行时的情况，但在训练时，事情要简单得多。由于状态历史和外部参数向量 z_t 都可以在仿真中计算，我们可以通过监督学习来训练这个模块。在部署时，这两个模块协同工作，实现鲁棒且自适应的运动。在我们有限机载计算的实验设置中，基础策略 π 以 100 赫兹运行，而自适应模块 ϕ 较慢，以 10 赫兹运行。两者异步并行运行，没有中央时钟来对齐它们。基础策略只需上传自适应模块最近预测的外部参数向量 z_t 来预测动作 a_t 。我们的方法与以往基于学习的运动工作形成对比，那些工作通过从机器人遇到的每个新情况中收集的小数据集推断环境关键参数来调整学习到的策略。这些参数可以是物理参数，如摩擦等 [7]，也可以是它们的潜在编码 [41]。不幸的是，如前所述，在机器人尚未获得良好行走策略时收集这样的数据集，可能导致摔倒和机器人损坏。我们的方法避免了这一点，因为 RMA 通过快速估计 z_t 使行走策略能够快速适应 π 并避免摔倒。使用强化学习训练基础策略并加入环境参数作为额外参数的方法也已在 [57, 41] 中探索过。我们的新颖之处在于使用多样化的地形生成器和受生物能量学启发的“自然”奖励函数，这使我们能够在不使用任何参考演示的情况下学习行走策略 [41]。但本文真正新颖的贡献是自适应模块，它在仿真中训练，使 RMA 成为可能。在部署时，这具有系统辨识的特点，但它是在线版本的系统辨识，仅基于机器人在过去几分之一秒内看到的单条轨迹。人们可能会合理地质疑它为何能起作用，但我们可以提供一些推测：• 系统辨识传统上被视为一个优化问题。但在许多场景中，研究人员发现，给定优化问题的（输入，输出）样本对及其解，我们可以使用神经网络来逼近从问题到其解的映射 [1, 17]。实际上，这正是 ϕ 正在学习做的事情。• 我们不需要完美的系统辨识来

方法得以发挥作用。外部参数向量 z_t 是环境参数的低维非线性投影。这解决了某些参数可能因对可观测量的影响相同而共变所导致的不可辨识性问题。其次，我们并不要求该外部参数向量在某种“真实基准”意义上是正确的。关键在于它能导向“正确”的动作，而端到端训练正是为此进行优化。• 训练中见到的情境范围应涵盖机器人在现实世界中可能遇到的情况。我们使用分形地形生成器，并随机化质量、摩擦等参数，从而创造出步行机器人必须应对的多种物理情境。

在真实世界中实现腿式运动强化学习策略鲁棒性能方面，最具可比性的工作是 Lee 等人 [32] 的研究。与我们的工作不同，该方法依赖手工编码的领域知识，包括预定义轨迹生成器 [25] 和电机模型 [23]。我们在真实世界的多种地形上评估了 RMA（图 1）。所提出的自适应控制器能够在光滑表面、不平整地面、可变形表面（如泡沫、床垫等）以及自然环境中粗糙地形（如草地、高植被、混凝土、鹅卵石、岩石表面、沙地等）上行走。

II. 相关工作

传统上，腿式运动通常采用基于控制的方法 [36, 43, 16, 56, 50, 26, 28, 2, 24, 4]。麻省理工学院猎豹 3 号 [5] 通过使用正则化模型预测控制（MPC）和简化动力学 [12] 实现高速运动并跳过障碍物。ANYmal 机器人 [20] 通过优化参数化控制器并基于倒立摆模型进行规划 [15] 来实现运动。然而，这些方法需要对真实世界动力学进行精确建模，对机器人有深入的先验知识，并手动调整步态和行为。优化控制器与 MPC 相结合可以缓解部分问题 [30, 8, 9]，但仍需要大量针对特定任务的特征工程 [11, 15, 3]。

腿式运动的学习方法 将学习引入运动控制的最早期尝试可追溯至美国国防高级研究计划局的学习运动项目 [63, 64, 44, 62, 27]。近年来，深度强化学习（Reinforcement Learning, RL）为减轻对人类专业知识的依赖提供了另一种途径，并在仿真中展现出良好效果 [48, 33, 37, 14]。然而，此类策略难以迁移至现实世界 [31, 39, 6]。一种方法是在现实世界中直接训练 [18, 55]。然而，此类策略仅限于非常简单的设置，扩展到复杂设置需要不安全的探索和大量样本。

仿真到现实强化学习 为了利用强化学习在现实世界中实现复杂的行走行为，多种方法试图弥合仿真到现实的差距。领域随机化是一类方法，其中策略在广泛的环境参数和传感器噪声范围内进行训练，以学习

1RMA 耗时不足 1 秒，而 Peng 等人 [41] 需要收集 4–8 分钟（50 个片段，每个 5–10 秒）的数据。

在该范围内具有鲁棒性的行为 [51, 52, 40, 54, 38]。然而，领域随机化以最优性换取鲁棒性，导致策略过于保守 [34]。另一种方法是提高仿真的准确性以缩小仿真到现实的差距 [23, 51, 19]。Tan 等人 [51] 通过将分段线性函数拟合到实际电机的数据来改进电机模型 [51]。Hwangbo 等人 [23] 则使用神经网络对执行器模型进行参数化 [23, 32]。然而，这些方法需要从机器人收集初始数据以拟合电机模型，并且对于每个新设置都需要重复此过程。

系统辨识与自适应 策略不必对物理参数一无所知，而是可以通过在线系统辨识以这些参数为条件。在现实世界部署期间，物理参数可以通过在仿真中训练的模块进行推断 [57]，或使用进化算法直接优化以获得高回报 [58]。预测精确的系统参数通常不必要且困难，导致实际性能不佳。相反，可以使用低维潜在嵌入 [41, 61]。在测试时，可以通过使用策略梯度方法 [41]、贝叶斯优化 [59] 或随机搜索 [60] 利用现实世界的轨迹来优化该潜在变量。另一种方法是使用元学习来学习策略网络的初始化，以实现快速在线自适应 [13]。尽管这些方法已在真实机器人上得到验证 [49, 10]，但它们仍需要多次现实世界的轨迹来进行自适应。

III. 快速电机自适应

我们现在描述第一节第三段引入并在图 2 中总结的 RMA 算法的每个组成部分。后续章节依次讨论基础策略、适应模块以及在真实机器人上的部署。我们将使用与第一节相同的符号表示。

A. 基础策略

我们学习一个基础策略 π ，它以当前状态 $x_t \in \mathbb{R}^{30}$ 、上一动作 $a_{t-1} \in \mathbb{R}^{12}$ 和外向量 $z_t \in \mathbb{R}^8$ 作为输入，预测下一动作 a_t 。预测动作 a_t 是 12 个机器人关节的期望关节位置，通过 PD 控制器转换为力矩。外向量 z_t 是由 μ 生成的环境向量 $e_t \in \mathbb{R}^{17}$ 的低维编码。

$$z_t = \mu(e_t) \quad (1)$$

$$a_t = \pi(x_t, a_{t-1}, z_t) \quad (2)$$

我们将 μ 和 π 实现为多层感知机 (MLP) (详见第四节 B 部分)。我们使用无模型强化学习端到端地联合训练基础策略 π 和环境因子编码器 μ 。在时间步 t ， π ，以当前状态 x_t 、上一动作 a_{t-1} 和外向量 $z_t = \mu(e_t)$ 为输入，预测一个动作 a_t 。RL，以最大化策略 π 的以下期望回报：

$$J(\pi) = \mathbb{E}_{\tau \sim p(\tau|\pi)} \left[\sum_{t=0}^{T-1} \gamma^t r_t \right],$$

where $\tau = \{(x_0, a_0, r_0), (x_1, a_1, r_1) \dots\}$ is the trajectory of 智能体在执行策略 π 时， $p(\tau|\pi)$ 表示在 π 下轨迹的似然。

通过自然约束实现稳定步态：我们没有添加人工仿真噪声，而是在以下自然约束下训练智能体。首先，奖励函数的动机来自最小化做功和地面冲击的生物能量约束 [42]。我们发现这些奖励函数对于在仿真中学习逼真的步态至关重要。其次，我们在不平坦地形上训练策略（图 2），作为 [23] 用于足部离地间隙和对外部推力鲁棒性的额外奖励的替代。在这些自然约束下训练的行走策略无需任何修改即可迁移到真实世界中的简单场景（如混凝土地面或木地板）。这与其他仿真到现实的工作形成对比，这些工作要么用真实世界校准仿真 [51, 23]，要么在真实世界中微调策略 [41]。适应模块随后使其能够从简单场景扩展到如图 1 所示的极具挑战性的地形。

强化学习奖励：奖励函数鼓励智能体以最大速度 0.35 米/秒向前移动，并对颠簸和低效的运动进行惩罚。设线速度为 $\mathbf{v}$ ，姿态为 θ ，角速度为 ω ，均在机器人基坐标系中表示。此外，定义关节角度为 $\mathbf{q}$ ，关节速度为 $\dot{\mathbf{q}}$ ，关节力矩为 $\boldsymbol{\tau}$ ，足端地面反作用力为 $\mathbf{f}$ ，足端速度为 $\mathbf{v}_f$ ，二值足端接触指示向量为 $\mathbf{g}$ 。时刻 t 的奖励定义为以下各项之和：

- 1) Forward: $\min(v_x^t, 0.35)$
- 2) 横向移动与旋转: $-\|v_y^t\|^2 - \|\omega_{yaw}^t\|^2$
- 3) Work: $-\|\boldsymbol{\tau}^T \cdot (\mathbf{q}^t - \mathbf{q}^{t-1})\|$
- 4) Ground Impact: $-\|\mathbf{f}^t - \mathbf{f}^{t-1}\|^2$
- 5) Smoothness: $-\|\boldsymbol{\tau}^t - \boldsymbol{\tau}^{t-1}\|^2$
- 6) Action Magnitude: $-\|\mathbf{a}^t\|^2$
- 7) Joint Speed: $-\|\dot{\mathbf{q}}^t\|^2$
- 8) Orientation: $-\|\boldsymbol{\theta}_{roll, pitch}^t\|^2$
- 9) Z Acceleration: $-\|v_z^t\|^2$
- 10) Foot Slip: $-\|\text{diag}(\mathbf{g}^t) \cdot \mathbf{v}_f^t\|^2$

各奖励项的缩放因子分别为 20, 21, 0.002, 0.02, 0.001, 0.07, 0.002, 1.5, 2.0, 0.8。

训练课程：如果直接使用上述奖励函数训练智能体，由于关节运动惩罚项的存在，它会学会原地不动。为防止这种退化，我们采用 [23] 中描述的策略。训练开始时使用非常小的惩罚系数，然后通过固定课程逐步增大这些系数的强度。同时，随着训练进行，线性增加其他扰动（如质量、摩擦和电机强度）的难度。地形方面不设置课程，训练时从相同固定难度的地形剖面中随机采样。

B. 适应模块

特权环境配置 e_t 及其编码的外参向量 z_t 在真实世界部署时不可获取。因此，本文提出利用适应模块 ϕ 在线估计外参。适应模块不使用 e_t ，而是利用机器人近期状态 $x_{t-k:t-1}$ 和动作 $a_{t-k:t-1}$ 的历史来生成 $\hat{z}_t$ ，作为真实外参向量 z_t 的估计。在实验中，我们使用 $k = 50$ ，对应于 0.5s.。

$$\hat{z}_t = \phi(x_{t-k:t-1}, a_{t-k:t-1})$$

请注意，与典型系统辨识中预测 e_t 不同，我们直接估计外参 z_t ，它仅编码行为应如何改变以校正给定的环境向量 e_t 。为训练自适应模块，我们仅需状态-动作历史以及 z_t 的目标值（由环境因子编码器 μ 给出）。这两者在仿真中均可获得，因此 ϕ 可通过监督学习训练，以最小化： $\text{MSE}(\hat{z}_t, z_t) = \|\hat{z}_t - z_t\|^2$ ，其中 $z_t = \mu(e_t)$ 。我们将 ϕ 建模为一维卷积神经网络（1-D CNN）以捕捉时间相关性（第 IV-B 节）。收集状态-动作历史的一种方法是使用真实值 z_t 展开已训练的基础策略 π 。然而，这样的数据集仅包含机器人无缝行走的良好轨迹示例。基于此数据训练的自适应模块 ϕ 对偏离专家轨迹的情况不具备鲁棒性，而这种情况在部署期间经常会发生。我们通过使用在线策略数据训练 ϕ 来解决此问题（类似于 Ross 等人 [45]）。我们使用随机初始化的策略 ϕ 预测的 $\hat{z}_t$ 展开基础策略 π 。然后，我们使用该状态-动作历史，与真实值 z_t 配对，训练 ϕ 。我们迭代重复此过程直至收敛。该训练过程确保 RMA 在训练期间看到足够的探索轨迹，原因在于 a) 随机初始化的 ϕ ，和 b) $\hat{z}_t$ 的不完美预测。这为 RMA 在部署期间的性能增加了鲁棒性。

C. 异步部署

我们在仿真中完整训练 RMA，随后无需任何修改或微调即可部署到现实世界。RMA 的两个子系统异步运行，频率差异显著，因此只需极少的机载计算资源即可轻松运行。适应策略运行较慢，因为它基于 50 个时间步的状态-动作历史，大约每 0.1s (10 Hz). 更新一次外部向量 $\hat{z}_t$ 。基础策略以 100 赫兹运行，利用适应模块生成的最新 $\hat{z}_t$ ，结合当前状态和前一动作，预测 a_t 。这种异步执行在实践中不会损害性能，因为 $\hat{z}_t$ 在现实世界中变化相对不频繁。或者，我们也可以训练一个直接以状态和动作历史为输入的基础策略，而不将其解耦为两个模块。我们发现，这种方法（a）在仿真中导致不自然的步态和较差的性能，（b）在机载计算上只能以 10 赫兹运行，（c）缺乏异步设计，而异步设计对于无缝

Parameters	Training Range	Testing Range
Friction	[0.05, 4.5]	[0.04, 6.0]
K_p	[50, 60]	[45, 65]
K_d	[0.4, 0.8]	[0.3, 0.9]
Payload (Kg)	[0, 6]	[0, 7]
Center of Mass (cm)	[-0.15, 0.15]	[-0.18, 0.18]
Motor Strength	[0.90, 1.10]	[0.88, 1.22]
Re-sample Probability	0.004	0.01

表 I: 环境参数范围。

将 RMA 部署到真实机器人上，无需两个子系统的任何同步或校准。这种异步设计从根本上得益于将变化相对不频繁的外部向量与快速变化的机器人状态解耦。

四、实验设置

A. 环境细节

硬件细节：我们在所有真实世界实验中使用宇树科技的 A1 机器人。A1 是一款成本相对较低的中型四足机器人。它拥有 18 个自由度，其中 12 个为驱动自由度（每条腿 3 个电机），重量约为 12 公斤。为了测量机器人的当前状态，我们使用电机编码器的关节位置和速度、IMU 传感器的横滚角和俯仰角，以及足部传感器的二值化足部接触指示器。部署的策略对机器人关节采用位置控制。预测的期望关节位置通过固定增益的 PD 控制器转换为扭矩（ $K_p = 55$ 和 $K_d = 0.8$ ）。

仿真设置：我们使用 RaiSim 仿真器 [22] 进行刚体与接触动力学仿真。我们导入宇树（Unitree）的 A1 URDF 文件 [53]，并使用内置的分形地形生成器生成崎岖地形（分形倍频程 = 2，分形间隙度 = 2.0，分形增益 = 0.25，z 轴缩放 = 0.27）。每个强化学习回合最多持续 1000 步，若机器人高度降至 0.28 米以下、机体横滚角幅值超过 0.4 弧度或俯仰角超过 0.2 弧度则提前终止。策略的控制频率为 100 赫兹，仿真时间步长为 0.025s。

状态-动作空间：状态为 30 维，包含关节位置（12 个值）、关节速度（12 个值）、躯干横滚角和俯仰角以及二值足端接触指示器（4 个值）。对于动作，我们对 12 个机器人关节采用位置控制。RMA 预测期望关节角度 $a = \hat{\mathbf{q}} \in \mathbb{R}^{12}$ ，并通过 PD 控制器转换为力矩 τ ： $\tau = \ddot{(\hat{\mathbf{q}} - \mathbf{q})}$ 。 K_p 和 K_d 为手动的指定的增益，目标关节速度 $\dot{\hat{\mathbf{q}}}$ 设为 0。

环境变化：所有环境变化及其范围列于表 I。其中， e_t 包括质量及其在机器人上的位置（3 维）、电机强度（12 维）、摩擦（标量）和局部地形高度（标量），构成 17 维向量。注意，尽管地形剖面的难度固定，局部地形高度会随智能体移动而变化




图 3: 我们在真实世界中评估 RMA 在多种分布外设置下的表现。我们将 RMA 与 A1 的控制器以及无适应模块的 RMA 进行比较。我们发现 RMA 以 80% 的成功率走下 15 厘米高的台阶, 并以 100% 的成功率走过未见过的可变形表面, 如记忆海绵床垫和轻微不平整的泡沫。它还能成功攀爬斜坡和台阶。A1 的控制器无法走过不平整的泡沫。在底部, 我们还分析了三种方法的负载能力极限。我们看到 A1 控制器的性能在 8 千克负载能力时开始下降。无适应模块的 RMA 在负载超过 8 千克时无法移动, 但很少摔倒。作为参考, A1 机器人重 12 千克。总体而言, 所提出的方法始终优于基线方法。报告的数字为 5 次试验的平均值。

移动。我们将每只脚下的地形高度离散化到小数点后一位, 然后取四只脚中的最大值作为标量。这确保了控制器不会严重依赖对局部地形的快速准确感知, 并允许基础策略在部署期间以低得多的更新频率异步使用它。

B. 训练细节

基础策略与环境因子编码器架构: 基础策略是一个三层多层感知机 (MLP), 输入当前状态 $x_t \in \mathbb{R}^{30}$ 、上一动作 $a_{t-1} \in \mathbb{R}^{12}$ 和外参向量 $z_t \in \mathbb{R}^8$, 输出 12 维目标关节角度。隐藏层维度为 128。环境因子编码器是一个三层 MLP (隐藏层大小为 256、128), 将 $e_t \in \mathbb{R}^{17}$ 编码为 $z_t \in \mathbb{R}^8$ 。

自适应模块架构: 自适应模块首先使用两层 MLP 将最近的状态和动作嵌入为 32 维表示。然后, 一个三层一维卷积神经网络 (CNN) 在时间维度上对表示进行卷积, 以捕获输入中的时间相关性。每层的输入通道

数、输出通道数、核大小和步长分别为

$[32, 32, 8, 4], [32, 32, 5, 1], [32, 32, 5, 1]$ 。展平后的 CNN 输出被线性投影以估计 $\hat{z}_t$ 。

学习基础策略与环境因子编码器

网络: 本文使用近端策略优化 (PPO) [48] 联合训练基础策略与环境编码器网络, 共进行 15,000 次迭代, 每次迭代使用批大小 80,000 并划分为 4 个小批量。学习率设为 $5e-4$ 。奖励项系数在第三节中给出。在普通台式机上训练约需 24 小时, 其中使用 1 个 GPU 进行策略训练。在此期间, 仿真步数达 1.2 亿步。

学习自适应模块: 本文使用在线策略数据以监督学习方式训练自适应模块。采用 Adam 优化器 [29] 最小化均方误差损失。优化过程运行 1000 次迭代, 学习率为 $5e-4$, 每次迭代使用批大小 80,000 并划分为 4 个小批量。在普通台式机上训练该模块需 3 小时, 其中使用 1 个 GPU 进行策略训练。在此期间, 仿真步数为 8000 万步。




图 4: 本文分析机器人在覆盖油性塑料布且脚部附加塑料包裹的地面上行走时 RMA 的表现。图中绘制了膝关节扭矩和步态模式, 步态模式指示四足的接触情况 (F/R 表示前/后, R/L 表示右/左)。底部图显示自适应模块预测的外参向量 $\hat{z}$ 的 1^{st} 和 5^{th} 分量经中值滤波后的结果。当机器人进入湿滑区域时, 外参向量 $\hat{z}$ 的两个分量发生变化, 表明自适应模块已检测到打滑事件。注意, 自适应后恢复的步态周期与原始周期相似, 扭矩幅值增大, 且 $\hat{z}$ 持续反映地面仍然湿滑。在油性区域上, RMA 在 90% 的试验中成功通过。

五、结果与分析

本文在仿真中将 RMA 的性能与多个基线进行比较 (表 II)。此外, 在真实室内环境中与 A1 自带的制造商控制器进行对比 (图 3), 并在多种地形上对 RMA 进行野外测试 (图 1)。视频见 <https://ashish-kmr.github.io/rma-legged-robots/>

基线: 本文与以下基线方法进行比较:

- 1) A1 控制器: 机器人制造商默认控制器, 采用基于力的控制方案并结合模型预测控制 (MPC)。
- 2) 通过领域随机化实现鲁棒性 (鲁棒): 基础策略在训练时不使用 z_t , 以对训练范围 [52, 40] 内的变化具有鲁棒性。
- 3) 专家适应策略 (Expert): 在仿真中, 我们可以使用外参向量的真实值 z_t 。这是 RMA 性能的上界。
- 4) 无适应的 RMA: 我们还可以评估没有适应模块的基础策略的性能, 以消融适应模块的重要性。

- 5) 系统辨识 [57]: 不预测 $\hat{z}_t$, 而是直接预测系统参数 $\hat{e}_t$ 。
- 6) 面向领域自适应的优势加权回归 (AWR) [41]: 利用策略在测试环境中的真实世界轨迹, 通过 AWR 离线优化 $\hat{z}_t$ 。学习基线采用相同的架构、奖励函数及其他超参数进行训练。

度量: 本文将 RMA 与基线方法的性能进行对比, 采用以下度量指标: (1) 跌倒时间除以最大回合长度, 得到介于 0-1 之间的归一化值 (TTF); (2) 平均前进奖励; (3) 成功率; (4) 覆盖距离; (5) 适应所需的探索样本数; (6) 施加的扭矩; (7) 平滑度, 即扭矩的导数; 以及 (7) 地面冲击 (详见补充材料)。

A. 室内实验

在真实世界中, 我们将 RMA 与 A1 的控制器以及不带自适应模块的 RMA 进行比较 (图 3)。我们将比较限制在这两个基线上, 以避免损坏

	Success (%)	TTF	Reward	Distance (m)	Samples	Torque	Smoothness	Ground Impact
Robust [52, 40]	62.4	0.80	4.62	1.13	0	527.59	122.50	4.20
SysID [57]	56.5	0.74	4.82	1.17	0	565.85	149.75	4.03
AWR [41]	41.7	0.65	4.17	0.95	40k	599.71	162.60	4.02
RMA w/o Adapt	52.1	0.75	4.72	1.15	0	524.18	106.25	4.55
RMA	73.5	0.85	5.22	1.34	0	500.00	92.85	4.27
Expert	76.2	0.86	5.23	1.35	0	485.07	85.56	3.90

表 II：仿真测试结果：我们在仿真中将所提方法的性能与基线方法进行比较。训练和测试设置列于表 I 中。测试期间，我们在每个回合内以每步 0.01 的重采样概率对环境参数进行重采样。基线和度量在第 V 节中定义。报告的数字是在 3 个随机初始化策略和每个随机初始化 1000 个回合上取平均得到的。RMA 的性能优于所有基线，与专家相比仅有轻微的性能下降。

机器人硬件。我们对每种方法进行 5 次试验，并报告成功率、跌倒时间（TTF）和行进距离。注意，如果某种方法在任务中严重失败，我们只进行两次试验然后报告失败。这样做是为了尽量减少对机器人硬件的损坏。我们有以下室内设置：

- **n 公斤负载：**在顶部负载 n 公斤的情况下行走 300 厘米。
- **上台阶-n：**踏上一个 n 厘米高的台阶。
- **不平整泡沫：**在中央升高的泡沫上行走 180 厘米。
- **床垫：**在记忆海绵床垫上行走 60 厘米。
- **下台阶-n：**从 n 厘米高的台阶上走下。
- **斜坡：**在 6 度斜坡上向上行走。
- **油性表面：**穿越一片油污区域。

StepUp-n 和 **StepDown-n** 的每次试验在成功或失败后即终止。因此，我们仅报告这些任务的成功率，因为其他度量指标没有意义。我们观察到 RMA 在所有这些设置中均取得了较高的成功率，在某些情况下大幅超越了 A1 控制器的性能。我们发现关闭自适应模块会显著降低性能，这表明自适应模块对于解决这些任务至关重要。A1 的控制器在不平整的泡沫以及较大的下台阶和上台阶上表现挣扎。在大多数失败案例中，控制器因不稳定的落脚点而失去平衡。在负载分析中，A1 的控制器能够承受高于标称负载（5 公斤）的重量，但随着负载增加开始下沉，最终摔倒。相比之下，RMA 保持高度，并能够以较高的成功率承载高达 12 公斤（体重的 100%）的负载。没有自适应模块的 RMA 大多不会摔倒，但也不会向前移动。我们还评估了 RMA 在更具挑战性的任务中的表现，即用塑料包裹脚部穿越油污路径。机器人成功走过了油污区域。有趣的是，没有自适应模块的 RMA 能够在木地板上成功行走，无需任何微调或仿真校准。这与现有方法形成对比，现有方法即使在平坦和静态环境中也需要校准仿真 [51, 23] 或在测试时微调策略 [41]。

B. 户外实验

我们展示了 RMA 在多个具有挑战性的户外环境中的性能，如图 1 所示。

机器人在沙地、泥地和泥土上均能成功行走，且在所有试验中无一失败。这些地形因脚部易下陷和粘连而增加运动难度，要求机器人动态调整落脚点以确保稳定性。RMA 在高大植被或穿越灌木丛时行走成功率达 100%。此类地形会阻碍机器人脚部，使其行走过程中周期性失稳。为在这些环境中成功行走，机器人必须稳定应对脚部缠绕，并强力突破部分障碍。我们还评估了机器人在徒步小径上走下台阶的能力。机器人成功率为 70%，考虑到训练中从未见过楼梯，这一表现仍属出色。最后，我们在建筑废墟上测试机器人，下坡走过泥堆时成功率为 100%，横穿水泥堆和卵石堆时成功率为 80%。水泥堆和卵石堆本身位于陡峭侧倾的地面上，使机器人穿越堆体极具挑战性。

C. 仿真结果

我们在仿真中将所提方法与基线方法进行性能对比（表 II）。训练和测试参数按表 I 采样，并在回合内以每步 0.004 和 0.01 的重采样概率分别对训练和测试进行重采样。报告数值为 3 个随机初始化策略及每个随机初始化 1000 个回合的平均结果。RMA 表现最佳，与专家性能相比仅有轻微下降。持续变化的环境导致 AWR 适应速度极慢，性能较差。由于鲁棒基线对外部参数不敏感，其学习到的策略过于保守，性能受损。注意 SysID 的低性能表明显式估计 e_t 既困难又非实现卓越性能所必需。我们还与无自适应模块的 RMA 进行对比，结果显示缺少自适应模块时性能显著下降。

D. 自适应分析

我们分析了步态模式、力矩曲线以及估计的外参向量 $\hat{z}_t$ ，以研究在湿滑表面上的适应性（图

4). 我们将油倒在地面上的塑料表面上, 并额外用塑料包裹机器人的脚。机器人随后尝试穿越湿滑区域, 并能够成功适应。我们发现, RMA 在 90% 的油滑区域试验中取得了成功。对于其中一次试验, 我们在图 4 中绘制了膝关节的扭矩曲线、步态模式以及外参向量 $\hat{z}_t$ 的中值滤波 1^{st} 和 5^{th} 分量。当机器人在约 2 秒处开始打滑时, 打滑扰乱了机器人的正常运动, 随后进入适应阶段。这在所绘制的外参向量分量中很明显, 它们会响应打滑而变化。检测到的打滑使机器人能够恢复并继续在湿滑区域行走。注意, 尽管适应后扭矩稳定在略高的幅度, 步态周期大致恢复, 但外参向量并未恢复, 而是继续反映表面湿滑的事实。更多此类分析见补充材料。

六、结论

我们提出了 RMA 算法, 用于腿式机器人在多种地形中行走的实时适应。无需演示或预定义的运动模板。尽管仅能获取本体感觉数据, 机器人仍能下楼梯并穿越岩石。然而, 盲机器人存在局限性。较大的扰动, 例如下楼梯时突然跌倒, 或因岩石导致的多腿受阻, 有时会导致失败。为了开发真正可靠的行走机器人, 我们不仅需要使用本体感觉, 还需要使用带有机载视觉传感器的外部感觉。视觉在引导长距离、快速运动中的重要性已被充分研究, 例如 [35], 这是未来工作的重要方向。

致谢

我们感谢 Jemin Hwangbo 在仿真平台上的帮助, 以及 Koushil Sreenath 和 Stuart Anderson 在项目过程中提供的有益反馈。我们还要感谢 Claire Tomlin、Shankar Sastry、Chris Atkeson、Aravind Sivakumar、Ilija Radosavovic 和 Russell Mendonca 对论文的高质量反馈。本研究是 BAIR-FAIR 合作项目的一部分, 最近还得到了 DARPA 机器常识计划的支持。

参考文献

- [1] MYM Ahmed and N Qin. Surrogate-based aerodynamic design optimization: Use of surrogates in aerodynamic design optimization. In *International Conference on Aerospace Sciences and Aviation Technology*, 2009. 3
- [2] Aaron D Ames, Kevin Galloway, Koushil Sreenath, and Jessy W Grizzle. Rapidly exponentially stabilizing control lyapunov functions and hybrid zero dynamics. *IEEE Transactions on Automatic Control*, 2014. 1, 3
- [3] Taylor Apgar, Patrick Clary, Kevin Green, Alan Fern, and Jonathan W Hurst. Fast online trajectory optimization

- for the bipedal robot cassie. In *Robotics: Science and Systems*, 2018. 3
- [4] Monica Barragan, Nikolai Flowers, and Aaron M. Johnson. MiniRHex: A small, open-source, fully programmable walking hexapod. In *Robotics: Science and Systems Workshop on “Design and Control of Small Legged Robots”*, 2018. 3
- [5] Gerardo Bledt, Matthew J Powell, Benjamin Katz, Jared Di Carlo, Patrick M Wensing, and Sangbae Kim. Mit cheetah 3: Design and control of a robust, dynamic quadruped robot. In *2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. IEEE, 2018. 3
- [6] Adrian Boeing and Thomas Bräunl. Leveraging multiple simulators for crossing the reality gap. In *2012 12th International Conference on Control Automation Robotics & Vision (ICARCV)*. IEEE, 2012. 3
- [7] Josh C Bongard and Hod Lipson. Nonlinear system identification using coevolution of models and tests. *IEEE Transactions on Evolutionary Computation*, 2005. 3
- [8] Roberto Calandra, André Seyfarth, Jan Peters, and Marc Peter Deisenroth. Bayesian optimization for learning gaits under uncertainty. *Annals of Mathematics and Artificial Intelligence*, 2016. 3
- [9] Krzysztof Choromanski, Atil Iscen, Vikas Sindhwani, Jie Tan, and Erwin Coumans. Optimizing simulations with noise-tolerant structured exploration. In *2018 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2018. 3
- [10] Ignasi Clavera, Anusha Nagabandi, Simin Liu, Ronald S. Fearing, Pieter Abbeel, Sergey Levine, and Chelsea Finn. Learning to adapt in dynamic, real-world environments through meta-reinforcement learning. In *International Conference on Learning Representations*, 2019. 4
- [11] Martin De Lasa, Igor Mordatch, and Aaron Hertzmann. Feature-based locomotion controllers. *ACM Transactions on Graphics (TOG)*, 2010. 3
- [12] Jared Di Carlo, Patrick M Wensing, Benjamin Katz, Gerardo Bledt, and Sangbae Kim. Dynamic locomotion in the mit cheetah 3 through convex model-predictive control. In *2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. IEEE, 2018. 3
- [13] Chelsea Finn, Pieter Abbeel, and Sergey Levine. Model-agnostic meta-learning for fast adaptation of deep networks. In *International Conference on Machine Learning*. PMLR, 2017. 4
- [14] Scott Fujimoto, Herke Hoof, and David Meger. Addressing function approximation error in actor-critic methods. In *International Conference on Machine Learning*. PMLR, 2018. 3
- [15] Christian Gehring, Stelian Coros, Marco Hutter, Carmine Dario Bellicoso, Huub Heijnen, Remo Diethelm, Michael Bloesch, Péter Fankhauser, Jemin Hwangbo, Mark Hoepflinger, et al. Practice makes perfect: An optimization-based approach to controlling agile motions for a quadruped robot. *IEEE Robotics & Automation Magazine*, 2016. 3

- [16] Hartmut Geyer, Andre Seyfarth, and Reinhard Blickhan. Positive force feedback in bouncing gaits? *Proceedings of the Royal Society of London. Series B: Biological Sciences*, 2003. 1, 3
- [17] Xiaoxiao Guo, Wei Li, and Francesco Iorio. Convolutional neural networks for steady flow approximation. In *Proceedings of the 22nd ACM SIGKDD international conference on knowledge discovery and data mining*, 2016. 3
- [18] Tuomas Haarnoja, Sehoon Ha, Aurick Zhou, Jie Tan, George Tucker, and Sergey Levine. Learning to walk via deep reinforcement learning. In *Robotics: Science and Systems*, 2019. 1, 3
- [19] Josiah Hanna and Peter Stone. Grounded action transformation for robot learning in simulation. In *Proceedings of the AAAI Conference on Artificial Intelligence*, 2017. 4
- [20] Marco Hutter, Christian Gehring, Dominic Jud, Andreas Lauber, C Dario Bellicoso, Vassilios Tsounis, Jemin Hwangbo, Karen Bodie, Peter Fankhauser, Michael Bloesch, et al. Anymal-a highly mobile and dynamic quadrupedal robot. In *2016 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. IEEE, 2016. 3
- [21] Jemin Hwangbo. RaisimGymTorch. <https://raisim.com/sections/RaisimGymTorch.html>, 2020-2021. 12
- [22] Jemin Hwangbo, Joonho Lee, and Marco Hutter. Per-contact iteration method for solving contact dynamics. *IEEE Robotics and Automation Letters*, 2018. URL www.raisim.com. 5
- [23] Jemin Hwangbo, Joonho Lee, Alexey Dosovitskiy, Dario Bellicoso, Vassilios Tsounis, Vladlen Koltun, and Marco Hutter. Learning agile and dynamic motor skills for legged robots. *Science Robotics*, 2019. 1, 3, 4, 8, 12
- [24] Dong Jin Hyun, Jongwoo Lee, SangIn Park, and Sangbae Kim. Implementation of trot-to-gallop transition and subsequent gallop on the mit cheetah i. *The International Journal of Robotics Research*, 2016. 1, 3
- [25] Atil Iscen, Ken Caluwaerts, Jie Tan, Tingnan Zhang, Erwin Coumans, Vikas Sindhwani, and Vincent Vanhoucke. Policies modulating trajectory generators. In *Conference on Robot Learning*. PMLR, 2018. 3
- [26] Aaron M Johnson, Thomas Libby, Evan Chang-Siu, Masayoshi Tomizuka, Robert J Full, and Daniel E Koditschek. Tail assisted dynamic self righting. In *Adaptive Mobile Robotics*. World Scientific, 2012. 1, 3
- [27] Mrinal Kalakrishnan, Jonas Buchli, Peter Pastor, Michael Mistry, and Stefan Schaal. Fast, robust quadruped locomotion over challenging terrain. In *2010 IEEE International Conference on Robotics and Automation*. IEEE, 2010. 3
- [28] Mahdi Khoramshahi, Hamed Jalaly Bidgoly, Soroosh Shafiee, Ali Asaei, Auke Jan Ijspeert, and Majid Nili Ahmadabadi. Piecewise linear spine for speed–energy efficiency trade-off in quadruped robots. *Robotics and Autonomous Systems*, 2013. 1, 3
- [29] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In *3rd International Conference on Learning Representations*, 2015. 6, 12
- [30] Jens Kober, J Andrew Bagnell, and Jan Peters. Reinforcement learning in robotics: A survey. *The International Journal of Robotics Research*, 2013. 3
- [31] Sylvain Koos, Jean-Baptiste Mouret, and Stéphane Doncieux. Crossing the reality gap in evolutionary robotics by promoting transferable controllers. In *Proceedings of the 12th annual conference on Genetic and evolutionary computation*, 2010. 3
- [32] Joonho Lee, Jemin Hwangbo, Lorenz Wellhausen, Vladlen Koltun, and Marco Hutter. Learning quadrupedal locomotion over challenging terrain. *Science robotics*, 2020. 1, 3, 4
- [33] Timothy P. Lillicrap, Jonathan J. Hunt, Alexander Pritzel, Nicolas Heess, Tom Erez, Yuval Tassa, David Silver, and Daan Wierstra. Continuous control with deep reinforcement learning. In *ICLR*, 2016. 3
- [34] Jingru Luo and Kris Hauser. Robust trajectory optimization under frictional contact with iterative learning. *Autonomous Robots*, 2017. 4
- [35] Jonathan Samir Matthis, Jacob L Yates, and Mary M Hayhoe. Gaze and the control of foot placement when walking in natural terrain. *Current Biology*, 2018. 9
- [36] Hirofumi Miura and Isao Shimoyama. Dynamic walk of a biped. *The International Journal of Robotics Research*, 1984. 1, 3
- [37] Volodymyr Mnih, Adria Puigdomenech Badia, Mehdi Mirza, Alex Graves, Timothy Lillicrap, Tim Harley, David Silver, and Koray Kavukcuoglu. Asynchronous methods for deep reinforcement learning. In *International conference on machine learning*. PMLR, 2016. 3
- [38] Ofir Nachum, Michael Ahn, Hugo Ponte, Shixiang Shane Gu, and Vikash Kumar. Multi-agent manipulation via locomotion using hierarchical sim2real. In *Conference on Robot Learning*. PMLR, 2020. 4
- [39] Michael Neunert, Thiago Boaventura, and Jonas Buchli. Why off-the-shelf physics simulators fail in evaluating feedback controller performance—a case study for quadrupedal robots. In *Advances in Cooperative Robotics*. World Scientific, 2017. 3
- [40] Xue Bin Peng, Marcin Andrychowicz, Wojciech Zaremba, and Pieter Abbeel. Sim-to-real transfer of robotic control with dynamics randomization. In *2018 IEEE international conference on robotics and automation (ICRA)*. IEEE, 2018. 1, 4, 7, 8
- [41] Xue Bin Peng, Erwin Coumans, Tingnan Zhang, Tsang-Wei Edward Lee, Jie Tan, and Sergey Levine. Learning agile robotic locomotion skills by imitating animals. In *Robotics: Science and Systems*, 2020. 1, 3, 4, 7, 8
- [42] Delyle T Polet and John EA Bertram. An inelastic quadrupedal model discovers four-beat walking, two-beat running, and pseudo-elastic actuation as energetically optimal. *PLoS computational biology*, 2019. 4

- [43] Marc H Raibert. Hopping in legged systems—modeling and simulation for the two-dimensional one-legged case. *IEEE Transactions on Systems, Man, and Cybernetics*, 1984. 1, 3
- [44] Nathan Ratliff, Matt Zucker, J Andrew Bagnell, and Siddhartha Srinivasa. Chomp: Gradient optimization techniques for efficient motion planning. In *2009 IEEE International Conference on Robotics and Automation*. IEEE, 2009. 3
- [45] Stéphane Ross, Geoffrey Gordon, and Drew Bagnell. A reduction of imitation learning and structured prediction to no-regret online learning. In *Proceedings of the fourteenth international conference on artificial intelligence and statistics*, 2011. 5
- [46] Uluc Saranli, Martin Buehler, and Daniel E Koditschek. Rhex: A simple and highly mobile hexapod robot. *The International Journal of Robotics Research*, 2001. 1
- [47] John Schulman, Philipp Moritz, Sergey Levine, Michael I. Jordan, and Pieter Abbeel. High-dimensional continuous control using generalized advantage estimation. In *4th International Conference on Learning Representations*, 2016. 12
- [48] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017. 3, 6, 12
- [49] Xingyou Song, Yuxiang Yang, Krzysztof Choromanski, Ken Caluwaerts, Wenbo Gao, Chelsea Finn, and Jie Tan. Rapidly adaptable legged robots via evolutionary meta-learning. In *International Conference on Intelligent Robots and Systems (IROS)*, 2020. 4
- [50] Koushil Sreenath, Hae-Won Park, Ioannis Poulakakis, and Jessie W Grizzle. A compliant hybrid zero dynamics controller for stable, efficient and fast bipedal walking on mabel. *The International Journal of Robotics Research*, 2011. 1, 3
- [51] Jie Tan, Tingnan Zhang, Erwin Coumans, Atil Iscen, Yunfei Bai, Danijar Hafner, Steven Bohez, and Vincent Vanhoucke. Sim-to-real: Learning agile locomotion for quadruped robots. In *Robotics: Science and Systems*, 2018. 4, 8
- [52] Josh Tobin, Rachel Fong, Alex Ray, Jonas Schneider, Wojciech Zaremba, and Pieter Abbeel. Domain randomization for transferring deep neural networks from simulation to the real world. In *2017 IEEE/RSJ international conference on intelligent robots and systems (IROS)*. IEEE, 2017. 1, 4, 7, 8
- [53] Xingxing Wang. Unitree Robotics. <https://www.unitree.com/>. 5
- [54] Zhaoming Xie, Xingye Da, Michiel van de Panne, Buck Babich, and Animesh Garg. Dynamics randomization revisited: A case study for quadrupedal locomotion. *arXiv preprint arXiv:2011.02404*, 2020. 4
- [55] Yuxiang Yang, Ken Caluwaerts, Atil Iscen, Tingnan Zhang, Jie Tan, and Vikas Sindhwani. Data efficient reinforcement learning for legged robots. In *Conference on Robot Learning*. PMLR, 2020. 1, 3
- [56] KangKang Yin, Kevin Loken, and Michiel Van de Panne. Simbicon: Simple biped locomotion control. *ACM Transactions on Graphics (TOG)*, 2007. 1, 3
- [57] Wenhao Yu, Jie Tan, C. Karen Liu, and Greg Turk. Preparing for the unknown: Learning a universal policy with online system identification. In *Robotics: Science and Systems*, 2017. 3, 4, 7, 8
- [58] Wenhao Yu, C Karen Liu, and Greg Turk. Policy transfer with strategy optimization. In *International Conference on Learning Representations*, 2018. 4
- [59] Wenhao Yu, Visak C. V. Kumar, Greg Turk, and C. Karen Liu. Sim-to-real transfer for biped locomotion. In *2019 IEEE/RSJ International Conference on Intelligent Robots and Systems*. IEEE, 2019. 4
- [60] Wenhao Yu, Jie Tan, Yunfei Bai, Erwin Coumans, and Sehoon Ha. Learning fast adaptation with meta strategy optimization. *IEEE Robotics and Automation Letters*, 2020. 4
- [61] Wenxuan Zhou, Lerrel Pinto, and Abhinav Gupta. Environment probing interaction policies. In *7th International Conference on Learning Representations, ICLR 2019*, 2019. 4
- [62] J Zico Kolter and Andrew Y Ng. The stanford littledog: A learning and rapid replanning approach to quadruped locomotion. *The International Journal of Robotics Research*, 2011. 3
- [63] Matt Zucker, J Andrew Bagnell, Christopher G Atkeson, and James Kuffner. An optimization approach to rough terrain locomotion. In *2010 IEEE International Conference on Robotics and Automation*. IEEE, 2010. 1, 3
- [64] Matt Zucker, Nathan Ratliff, Martin Stolle, Joel Chestnutt, J Andrew Bagnell, Christopher G Atkeson, and James Kuffner. Optimization and learning for rough terrain legged locomotion. *The International Journal of Robotics Research*, 2011. 3

Supplementary for RMA: Rapid Motor Adaptation for Legged Robots

S1. METRICS

We use several metrics (in SI units) to evaluate and compare the performance of RMA against baselines:

- Success Rate: Average rate of successfully completing the task as defined in the next section.
- Time to Fall (TTF): Measures the time before a fall. We divide it by the maximum duration of the episode and report a normalized value between 0 and 1.
- Reward: Average step forward reward plus lateral reward over multiple episodes as defined in Section III-A RL Rewards of the main paper.
- Distance: Average distance covered in an episode. For real-world experiments, we report the normalized distance, where we normalize by the maximum distance which is specific to the task.
- Adaptation Samples: Number of control steps to explore in the testing environment needed for the motor policy to adapt.
- Torque: Squared L2 norm of torques at every joint $\|\tau^t\|^2$.
- Jerk: Squared L2 norm of delta torques $\|\tau^t - \tau^{t-1}\|^2$.
- Ground Impact: Squared L2 norm of delta ground reaction forces at every foot $\|f^t - f^{t-1}\|^2$.

S1. ADDITIONAL TRAINING AND DEPLOYMENT DETAILS

The training pipeline is shown in Algorithm 1, and the deployment pipeline is shown in Algorithm 2.

We use PPO [48] to train the base policy and the environmental factor encoder. We train for total 15,000 iterations. During each iteration, we collect a batch of 80,000 state-action transitions, which is evenly divided into 4 mini-batches. Each mini-batch is fed into the base policy and the Environment Factor Encoder in sequence for 4 rounds to compute the loss and error back-propagation. The loss is the sum of surrogate policy loss and 0.5 times the value loss. We clip the action log probability ratios between 0.8 and 1.2, and clip the target values to be within the 0.8 – 1.2 times range of the corresponding old values. We exclude the entropy regularization of the base policy, but constrain the standard deviation of the parameterized Gaussian action space to be large than 0.2 to ensure exploration. λ and γ in the generalization advantage estimation [47] are set to 0.95 and 0.998 respectively. We use the Adam optimizer [29], where we set the learning rate to $5e-4$, β to (0.9, 0.999), and ϵ to $1e-8$. The reference implementation can be found in the RaisimGymTorch Library [21].

If we naively train our agent with the reward function aggregating all the terms, it learns to fall because of the penalty terms. To prevent this collapse, we follow the strategy described in [23]. In addition the scaling factors of all reward terms, we apply a small multiplier k_t to the penalty terms 3 – 10, as defined in Section III-A of the main paper. We start the training

Algorithm 1: Rapid Motor Adaptation Training

Phase 1 Randomly initialize the base policy π ;
Randomly initialize the environmental factor encoder μ ; Empty replay buffer D_1 ;
for $0 \leq \text{itr} \leq N_{\text{itr}}^1$ **do**
 for $0 \leq i \leq N_{\text{env}}$ **do**
 $x_0, e_0 \leftarrow \text{envs}[i].\text{reset}()$;
 for $0 \leq t \leq T$ **do**
 $z_t \leftarrow \mu(e_t)$;
 $a_t \leftarrow \pi(x_t, a_{t-1}, z_t)$;
 $x_{t+1}, e_{t+1}, r_t \leftarrow \text{envs}[i].\text{step}(a_t)$;
 Store $((x_t, e_t), a_t, r_t, (x_{t+1}, e_{t+1}))$ in D_1 ;
 end
 end
 Update π and μ using PPO [48];
 Empty D_1 ;
end

Phase 2 Randomly initialize the adaptation module ϕ
parameterized by θ_ϕ ; Empty mini-batch D_2 ;
for $0 \leq \text{itr} \leq N_{\text{itr}}^2$ **do**
 for $0 \leq i \leq N_{\text{env}}$ **do**
 $x_0, e_0 \leftarrow \text{envs}[i].\text{reset}()$;
 for $0 \leq t \leq T$ **do**
 $\hat{z}_t \leftarrow \phi(x_{t-k:k}, a_{t-k-1:k-1})$;
 $z_t \leftarrow \mu(e_t)$;
 $a_t \leftarrow \pi(x_t, a_{t-1}, \hat{z}_t)$;
 $x_{t+1}, e_{t+1}, - \leftarrow \text{envs}[i].\text{step}(a_t)$;
 Store $(\hat{z}_t, z_t)$ in D_2 ;
 end
 end
 $\theta_\phi \leftarrow \theta_\phi - \lambda_{\theta_\phi} \nabla_{\theta_\phi} \frac{1}{TN_{\text{env}}} \sum \|\hat{z}_t - z_t\|^2$;
 Empty D_2 ;
end

with a very small k_0 set to 0.03, and then exponentially increase the these coefficients using a fixed curriculum: $k_{t+1} = k_t^{0.997}$, where t is the iteration number. The learning process is shown in Figure S2.

S1. ADDITIONAL REAL-WORLD ADAPTATION ANALYSIS

In addition to the oil-walking experiments in Figure 4 of the main paper, we also analyze the gait patterns and the torque profile for the mass adaptation case, shown in Figure S3. We throw a payload of 5kg on the back of the robot in the middle of a run and plot the torque profile of the knee, gait pattern, and the 2th and 7th components of the extrinsics vector $\hat{z}_t$ as shown in Figure S3. We observe that the additional payload disturbs the regular motion of the robot, after which it enters

Algorithm 2: Rapid Motor AdaptationDeployment

Process 1 operating at 100 Hz;

$t \leftarrow 0$;

while not fall do

$a_t \leftarrow \pi(x_t, a_{t-1}, \hat{z}_{\text{async}})$;

$x_{t+1} \leftarrow \text{env.step}(a_t)$;

$t \leftarrow t + 1$;

end

Process 2 operating at 10 Hz;

while not fall do

$\hat{z}_{\text{async}} \leftarrow \phi(x_{t-k:k}, a_{t-k-1:k-1})$;

end

S2. ADDITIONAL SIMULATION TESTINGS

In Figure S4, we further test RMA in extreme simulated environments and show its performance in three types of environment variations: the payloads added on the base of the A1 robot, the terrain elevation variation (z-scale used in the fractal terrain generator, details in Section IV Simulation Setup of the main paper), and the friction coefficient between the robot feet and the terrain. We show the superiority of RMA across all the cases in terms of Success Rate, TTF and Reward as defined in Section S1.

the adaptation phase and finally recovers from the disturbance. When the payload lands on the robot, it is noticeable that the plotted components of the extrinsics vector change in response to the slip. Post adaptation, we see that the torque stabilizes to a higher magnitude than before to account for the payload and the gait time period is roughly recovered.




Fig. S2: We plot the average step reward during the total 15,000 training iterations. We show the converging trend of the reward aggregating all reward terms, forward + lateral reward, and sum of penalty terms. It also shows the necessity of applying a small multiplier to the penalty terms at the beginning of training; otherwise, the robot will only have negative experience initially and unable to learn to walk quickly.




Fig. S3: We analyze the change in behavior of RMAas we throw a payload of 5kg on the back of the robot. As a note, we have flipped the images so that that movement appears from left to right which is why the label on the sandbag appears to be 2Kg. We plot the torque profile of the knee and the gait pattern. The bottom plot shows median filtered 2nd and 7th components of the extrinsics vector $\hat{z}$ predicted by the adaptation module. When the 5kg payload is thrown on the back of the robot, we see a dip in the center of mass of the robot, which the adaptation module subsequently recovers from. In the bottom plot, we see a jump in response in the plotted components of the estimated extrinsics vector, indicating that the additional payload has been detected by the adaptation module. Note that post adaptation, the recovered gait time period is roughly similar to the original, the torque magnitudes have increased and the extrinsics vector continues to capture the presence of the 5Kg payload on the back of the robot.




Fig. S4: Simulation Generalization Results: We further compare the generalization performance of our method to baseline methods in simulation. We pick three physics parameters that may vary to a large degree in the real world: the payload on robot, the terrain height variation, and the friction coefficient between the robot feet and the terrain. We set other environment parameters according to the training range in TABLE II of the main paper. Baselines and metrics are defined in Section V of the main paper and Section S1. We report the mean and standard deviation of the performance of 3 randomly initialized policies, which is characterized by the average of 100 testing trials in given settings. Despite no testing environment samples, RMA performs the best, the closest to Expert's performance. For reference, A1 robot without additional payloads weighs 12 kg, and is 0.35 m tall. The static friction coefficient between rubber and concrete is 1.00.