

RMA：腿式机器人的快速电机适应

Ashish Kumar 加州大学伯克利分校 付子鹏 卡内基梅隆大学 Deepak Pathak 卡内基梅隆大学

Jitendra Malik 加州大学伯克利分校, Facebook




图 1：我们展示了 RMA 在几种具有挑战性的环境中的性能。在我们的所有试验中，该机器人能够成功地在沙子、泥土、远足小径、高草和土堆上行走，没有出现任何故障。当沿着远足小道走下楼梯时，该机器人成功完成了 70% 的试验；在走过水泥堆和一堆卵石时，该机器人成功了 80% 的试验。尽管在训练过程中从未见过不稳定或下沉的地面、阻碍性植被或楼梯，但该机器人仍实现了如此高的成功率。所有部署结果均采用相同的策略，无需任何模拟校准或现实世界的微调。视频位于 <https://ashish-kmr.github.io/rma-legged-robots/>

Abstract—在现实世界中成功部署腿式机器人需要它们 *adapt in real-time* 应对看不见的场景，例如改变地形、改变有效负载、磨损。本文提出快速电机适应（RMA）算法来解决四足机器人的实时在线适应问题。RMA 由两个组件组成：基本策略和适应模块。这些组件的组合使机器人能够在几分之一秒内适应新的情况。RMA 完全在模拟中进行训练，无需使用参考轨迹或预定义足部轨迹生成器等任何领域知识，并且无需任何微调即可部署在 A1 机器人上。我们使用生物能学启发的奖励在各种地形生成器上训练 RMA，并将其部署在各种困难地形上，包括草、长植被、混凝土、卵石、楼梯、沙子等环境中的岩石、湿滑、可变形表面。RMA 在各种现实世界和模拟实验中显示了最先进的性能。视频结果位于 <https://ashish-kmr.github.io/rma-legged-robots/>。


控制理论工具[36,43,46,16,56,63,50,26,28,2,24]。这些方法需要人类设计师具备相当多的专业知识，近年来，人们对使用强化学习和模仿学习技术复制这种成功产生了很大的兴趣[23,18,41,55,32]，这可以减轻这种负担，也许还可以提高性能。标准范例是在物理模拟环境中训练基于强化学习的控制器，然后使用各种模拟到真实技术转移到现实世界[52,40,23]。事实证明，这种转移相当具有挑战性，因为模拟与真实的差距本身是多种因素造成的：(a) 物理机器人及其模拟器中的模型存在显著差异；(b) 现实世界的地形与我们在模拟器中的模型有很大差异（图 1）；(c) 物理模拟器无法准确捕捉现实世界的物理现象——我们在这里处理的是接触力、可变形表面等——这是一个比模拟在自由空间中移动的刚体要困难得多的问题。

一、简介

在过去的四十年中，通过物理动力学建模和腿式机器人技术取得了巨大进步。

在本文中，我们报告了解决此问题的进展

A) Training in Simulation



B) Deployment




图 2: RMA 由两个子系统组成 - 基本策略 π 和适应模块 ϕ 。上: RMA 培训分两个阶段。在第一阶段, 基本策略 π 将当前状态 x_t 、先前操作 a_{t-1} 和特权环境因素 e_t 作为输入, 使用环境因素编码器 μ 将其编码到潜在外在向量 z_t 中。基本策略是使用无模型强化学习进行模拟训练的。在第二阶段, 训练适应模块 ϕ , 通过使用策略数据进行监督学习, 从状态和动作的历史中预测外在因素 $\hat{z}_t$ 。底部: 在部署时, 自适应模块 ϕ 在 10Hz 下生成外部参数 $\hat{z}_t$, 基本策略在 100Hz 下生成所需的关节位置, 并使用 A1 的 PD 控制器将其转换为扭矩。由于自适应模块以较低的频率运行, 因此基本策略使用自适应模块预测的最新外在向量 $\hat{z}_t$ 来预测 a_t 。这种异步设计对于在 A1 等机载计算有限的低成本机器人上进行无缝部署至关重要。视频位于: <https://ashish-kmr.github.io/rma-legged-robots/>

四足运动挑战, 使用 Unitree 相对便宜的 A1 机器人作为实验平台。图 1 显示了视频中的一些示例以及实际结果。在概述我们的方法之前 (图 2), 我们首先指出, 人类在现实世界中行走需要快速适应, 因为我们在不同的土壤上移动, 上坡或下坡, 搬运货物, 休息或疲劳的肌肉, 以及应对扭伤的脚踝等。让我们也将其作为腿式机器人的核心问题来关注, 并将其称为快速电机适应 (RMA)。我们假设 RMA 必须以几分之一秒的时间尺度在线发生, 这意味着我们没有时间在物理世界中进行多次实验、推出多个轨迹并优化以估计各种系统参数。情况可能比这更糟。如果我们在没有经验的情况下将四足动物引入岩石表面, 机器人策略会经常失败, 从而对机器人造成严重损坏。为了适应步行政策而收集甚至 3-5 分钟的步行数据实际上可能是不可行的。因此, 我们的战略不仅包括基本的

行走策略, 而且 RMA 必须在模拟中进行训练, 并直接部署在现实世界中。但是, 怎么样?

图 2 显示 RMA 由两个子系统组成: 基本策略 π 和适应模块 ϕ , 它们协同工作以在非常多样化的环境配置集上实现线实时适应。基本策略通过模拟中的强化学习进行训练, 使用有关环境配置 e_t 的特权信息 (例如摩擦力、有效负载等)。向量 e_t 的知识允许基本策略适当地适应给定的环境。首先使用编码器网络 μ 将环境配置向量 e_t 编码到潜在特征空间 z_t 中。然后, 我们将这个潜在向量 z_t (我们称之为 *extrinsics*) 与当前状态 x_t 和之前的操作 a_{t-1} 一起输入到基本策略中。然后, 基本策略预测机器人所需的关节位置 a_t 。策略 π 和环境因素编码器 μ 通过 RL 在模拟中联合训练。

不幸的是, 这个策略无法直接部署, 因为我们无法在现实世界中访问 e_t 。什么

我们需要做的是在运行时估计外部因素，这就是适应模块 ϕ 的作用。关键的见解是，当我们命令机器人关节进行某种运动时，实际运动与取决于外部因素的运动有所不同。因此，我们可能希望使用代理状态的最近历史来估计这个外部向量，而不是使用特权信息，类似于卡尔曼滤波器的操作，用于根据可观测值的历史进行状态估计。具体来说， ϕ 的目标是根据机器人最近的状态和动作历史来估计外在向量 z_t ，而不假设对 e_t 进行任何访问。那是在运行时，但在训练时，生活会更容易。由于状态历史和外部向量 z_t 都可以在模拟中计算，因此我们可以通过监督学习来训练该模块。在部署时，这两个模块协同工作以执行稳健且自适应的运动。在我们的实验设置中，其板载计算有限，基本策略 π 以 100 Hz 运行，而自适应模块 ϕ 速度较慢，以 10 Hz 运行。两者异步并行运行，没有中央时钟来对齐它们。基本策略只是从适应模块上传外部向量 z_t 的最新预测来预测动作 a_{t+1} 。

我们的方法与之前基于学习的运动工作形成对比，后者通过从机器人引入的每个新情况中收集的小数据集推断有关环境的关键参数来调整学习策略。这些可以是物理参数，如摩擦力等[7]，也可以是它们的潜在编码[41]。不幸的是，如前所述，当机器人尚未获得良好的行走策略时，收集这样的数据集可能会导致机器人跌倒和损坏。我们的方法避免了这种情况，因为 RMA 通过快速估计 z_t 允许步行策略快速适应¹ 并避免跌倒。

[57, 41] 中也研究了使用 RL 以及环境参数的额外参数来训练基本策略。我们的新颖之处是使用各种地形生成器和由生物能量学驱动的“自然”奖励函数，这使我们能够在不使用任何参考演示的情况下学习步行策略[41]。但本文真正新颖的贡献是在模拟中训练的适应模块，这使得 RMA 成为可能。在部署时，这具有系统识别的味道，但它是系统识别的在线版本，仅基于机器人在过去几分之一秒中看到的单个轨迹。人们可能会合理地问为什么它应该起作用，但我们可以提供一些猜测：

- 系统辨识传统上被认为是一个优化问题。但在许多情况下，研究人员发现，给定优化问题的样本（输入、输出）对及其解决方案，我们可以使用神经网络来近似将问题映射到其解决方案的函数 [1, 17]。实际上，这就是 ϕ 正在学习做的事情。
- 我们不需要完美的系统识别

¹RMA takes less than 1s, whereas Peng et al. [41] need to collect 4–8mins (50 episodes of 5–10s) of data.

工作方法。外在向量 z_t 是环境参数的低维非线性投影。这解决了一些可识别性问题，其中一些参数可能对可观测值产生相同的影响。其次，我们不需要这个外在向量在某种“基本事实”意义上是正确的。重要的是它会导致“正确”的行动，并且端到端培训会为此进行优化。

- 训练中看到的情况范围应该涵盖机器人在现实世界中会遇到的情况。我们使用分形地形生成器，伴随着质量、摩擦力等参数的随机化，创建了步行机器人必须做出反应的各种物理环境。

在现实世界中腿部运动的 RL 策略的稳健性能方面，最具可比性的工作是 Lee 等人的工作。[32] 与我们的工作不同，它依赖于预定义轨迹生成器[25]和电机模型[23]的手工编码领域知识。我们评估了现实世界中各种地形的 RMA（图 1）。所提出的自适应控制器能够在光滑表面、不平坦地面、可变形表面（例如泡沫、床垫等）以及自然环境中的粗糙地形（例如草地、长植被、混凝土、卵石、岩石表面、沙子等）上行走。

二.相关工作

传统上，腿式运动是通过使用基于控制的方法来实现的[36,43,16,56,50,26,28,2,24,4]。MIT Cheetah 3 [5] 通过使用正则化模型预测控制（MPC）和简化动力学 [12] 可以实现高速并跳过障碍。ANYmal 机器人 [20] 通过优化参数化控制器并基于倒立摆模型 [15] 进行规划来进行运动。然而，这些方法需要对现实世界的动力学进行准确的建模，对机器人有深入的先验知识，并对步态和行为进行手动调整。优化控制器与 MPC 相结合，可以缓解一些问题 [30,8,9]，但是它们仍然需要大量特定于任务的特征工程 [11,15,3]。

腿部运动学习 将学习融入运动的一些最早尝试可以追溯到 DARPA 学习运动计划 [63,64,44,62,27]。最近，深度强化学习（RL）提供了一种替代方案来减轻对人类专业知识的依赖，并在模拟中显示出良好的结果[48,33,37,14]。然而，此类政策很难转移到现实世界[31,39,6]。一种方法是直接在现实世界中进行训练 [18, 55]。然而，此类策略仅限于非常简单的设置，并且扩展到复杂的设置需要不安全的探索和大量样本。

模拟到真实的强化学习 为了使用强化学习在现实世界中实现复杂的行走行为，有几种方法试图弥合模拟到真实的差距。域随机化是一类使用广泛的环境参数和传感器噪声来训练策略以学习的方法

在此范围内稳健的行为[51,52,40,54,38]。然而，域随机化以最优性换取鲁棒性，导致政策过于保守[34]。

或者，也可以通过使模拟更加准确来缩小模拟与真实的差距 [23,51,19]。谭等人。 [51]通过将分段线性函数拟合到实际电机的数据来改进电机模型[51]。黄博等人。 [23] 相反，使用神经网络来参数化执行器模型 [23, 32]。然而，这些方法需要从机器人收集初始数据以适应电机模型，并且需要为每个新设置完成此操作。

系统识别和适应策略可以通过在线系统识别来调节这些参数，而不是与物理参数无关。在现实世界中的部署过程中，物理参数可以通过在模拟中训练的模块来推断[57]，或者通过使用进化算法[58]直接优化以获得高回报。预测准确的系统参数通常是不必要且困难的，导致实践中性能不佳。相反，可以使用低维潜在嵌入[41, 61]。在测试时，可以通过使用策略梯度方法 [41]、贝叶斯优化 [59] 或随机搜索 [60]，使用现实世界的部署来优化此潜在变量。另一种方法是使用元学习来学习策略网络的初始化，以实现快速在线适应[13]。尽管它们已经在真实的机器人上得到了演示 [49, 10]，但它们仍然需要在现实世界中进行多次部署才能适应。

三. 快速电机适应

现在，我们描述第一节第三段中介绍的 RMA 算法的每个组件，并在图 2 中进行了总结。以下各节按顺序讨论基本策略、适应模块和真实机器人上的部署。我们将使用第一节中介绍的相同符号。

A. Base Policy

我们学习一个基本策略 π ，它将当前状态 $x_t \in \mathbb{R}^{30}$ 、先前操作 $a_{t-1} \in \mathbb{R}^{12}$ 和外部向量 $z_t \in \mathbb{R}^8$ 作为输入来预测下一个操作 a_t 。预测动作 a_t 是 12 个机器人关节的所需关节位置，使用 PD 控制器将其转换为扭矩。外部向量 z_t 是由 μ 生成的环境向量 $e_t \in \mathbb{R}^{17}$ 的低维编码。

$$z_t = \mu(e_t) \quad (1)$$

$$a_t = \pi(x_t, a_{t-1}, z_t) \quad (2)$$

我们将 μ 和 π 实现为 MLP（详细信息请参阅第 IV-B 节）。我们使用无模型强化学习端到端地联合训练基本策略 π 和环境因素编码器 μ 。在时间步 t ， π 采用当前状态 x_t 、先前操作 a_{t-1} 和外部变量 $z_t = \mu(e_t)$ 来预测操作 a_t 。RL 最大化策略 π 的以下预期回报：

$$J(\pi) = \mathbb{E}_{\tau \sim p(\tau|\pi)} \left[\sum_{t=0}^{T-1} \gamma^t r_t \right],$$

其中 $\tau = \{(x_0, a_0, r_0), (x_1, a_1, r_1) \dots\}$ 是智能体执行策略 π 时的轨迹， $p(\tau|\pi)$ 表示 π 下轨迹的可能性。

通过自然约束实现稳定步态：我们没有添加人工模拟噪声，而是在以下自然约束下训练我们的代理。首先，奖励函数的动机是最大限度地减少工作和地面影响的生物能约束[42]。我们发现这些奖励函数对于在模拟中学习真实的步态至关重要。其次，我们在不平坦的地形上训练我们的策略（图 2），作为[23]使用的额外奖励的替代品，以提高脚步间隙和对外部推动的鲁棒性。在这些自然约束下训练的步行策略无需任何修改即可转移到现实世界中的简单设置（例如混凝土或木地板）。这与其他从模拟到真实的工作形成鲜明对比，其他工作要么用现实世界校准模拟[51, 23]，要么微调现实世界中的策略[41]。然后，适应模块使其能够从简单的设置扩展到非常具有挑战性的地形，如图 1 所示。

RL 奖励：奖励函数鼓励智能体以 0.35 m/s 的最大速度前进，并对不稳定和低效的运动进行惩罚。我们将线速度表示为 $\mathbf{v}$ ，将方向表示为 θ ，将角速度表示为 ω ，所有这些都在机器人的基坐标系中。我们另外定义关节角度为 $\mathbf{q}$ ，关节速度为 $\dot{\mathbf{q}}$ ，关节扭矩为 $\boldsymbol{\tau}$ ，脚部的地面反作用力为 $\mathbf{f}$ ，脚的速度为 $\mathbf{v}_f$ ，二进制脚接触指示器向量为 $\mathbf{g}$ 。时间 t 的奖励被定义为以下数量的总和：

- 1) 前进： $\min(v_x^t, 0.35)$ 2) 横向运动和旋转： $-\|v_y^t\|^2 - \|\omega_{yaw}^t\|^2$ 3) 做功： $-\|\boldsymbol{\tau}^T \cdot (\mathbf{q}^t - \mathbf{q}^{t-1})\|$ 4) 地面冲击： $-\|\mathbf{f}^t - \mathbf{f}^{t-1}\|^2$ 5) 平滑度： $-\|\boldsymbol{\tau}^t - \boldsymbol{\tau}^{t-1}\|^2$ 6) 动作幅度： $-\|\mathbf{a}^t\|^2$ 7) 关节速度： $-\|\dot{\mathbf{q}}^t\|^2$ 8) 方向： $-\|\boldsymbol{\theta}_{roll, pitch}^t\|^2$ 9) Z 轴加速度： $-\|v_z^t\|^2$

- 10) 脚滑： $-\|\text{diag}(\mathbf{g}^t) \cdot \mathbf{v}_f^t\|^2$

每个奖励项的缩放因子分别为 20、21、0.002、0.02、0.001、0.07、0.002、1.5、2.0、0.8。

训练课程：如果我们用上述奖励函数天真地训练我们的智能体，它会因为关节运动的惩罚项而学会留在原地。为了防止这种崩溃，我们遵循[23]中描述的策略。我们以非常小的惩罚系数开始训练，然后使用固定课程逐渐增加这些系数的强度。随着训练的进行，我们还线性增加其他扰动的难度，例如质量、摩擦力和运动强度。我们没有任何关于地形的课程，而是通过从相同的固定难度中随机采样地形剖面来开始训练。

B. Adaptation Module

在现实世界中的部署过程中，无法访问特权环境配置 e_t 及其编码的外部向量 z_t 的知识。因此，我们建议使用适应模块 ϕ 在线估计外在因素。适应模块使用机器人状态 $x_{t-k:t-1}$ 和动作 $a_{t-k:t-1}$ 的最新历史记录而不是 e_t 来生成 $\hat{z}_t$ ，这是真实外在向量 z_t 的估计。在我们的实验中，我们使用 $k = 50$ 对应于 0.5s。

$$\hat{z}_t = \phi(x_{t-k:t-1}, a_{t-k:t-1})$$

请注意，我们不是预测典型系统识别中的情况 e_t ，而是直接估计外部变量 z_t ，该外部变量仅编码行为应如何改变以纠正给定的环境向量 e_{t_0} 。

为了训练适应模块，我们只需要状态动作历史和环境因素编码器 μ 给出的 z_t （目标值。这两者都可以在模拟中使用，因此，可以通过监督学习来训练 ϕ 以最小化：MSE($\hat{z}_t, z_t$) = $\|\hat{z}_t - z_t\|^2$ ，其中 $z_t = \mu(e_t)$ 。我们将 ϕ 建模为一维 CNN 以捕获时间相关性（第 IV-B 节）。

收集状态动作历史的一种方法是使用基本事实 z_t 展开经过训练的基本策略 π 。然而，这样的数据集将仅包含机器人无缝行走的良好轨迹的示例。在此数据上训练的适应模块 ϕ 对于偏离专家轨迹的情况并不稳健，这种情况在部署期间经常发生。

我们通过使用策略数据训练 ϕ 来解决这个问题（类似于 Ross 等人[45]）。我们展开基本策略 π 以及随机初始化策略 ϕ 预测的 $\hat{z}_{t_0}$ 。然后，我们使用此状态动作历史记录，与 *ground truth* z_t 配对来训练 ϕ 。我们迭代地重复这个直到收敛。由于 a) 随机初始化的 ϕ 和 b) 对 $\hat{z}_t$ 的不完美预测，此训练过程可确保 RMA 在训练期间看到足够的探索轨迹。这增加了部署期间 RMA 性能的稳健性。

C. Asynchronous Deployment

我们完全在模拟中训练 RMA，然后将其部署到现实世界中，无需任何修改或微调。RMA 的两个子系统以完全不同的频率异步运行，因此可以使用很少的板载计算轻松运行。适应策略很慢，因为它在 50 个时间步长的状态动作历史上运行，粗略地每 0.1s (10 Hz) 更新一次外在向量 $\hat{z}_{t_0}$ 。基本策略以 100 Hz 运行，并使用适应模块生成的最新 $\hat{z}_t$ 以及当前状态和之前的操作来预测 a_{t_0} 。这种异步执行在实践中不会损害性能，因为 $\hat{z}_t$ 在现实世界中变化相对较少。

或者，我们可以训练一个基本策略，直接将状态和动作历史记录作为输入，而不将它们解耦到两个模块中。我们发现，(a) 会导致步态不自然且仿真性能不佳，(b) 只能在板载计算上以 10Hz 运行，(c) 缺乏对于无缝运行至关重要的异步设计。

Parameters	Training Range	Testing Range
Friction	[0.05, 4.5]	[0.04, 6.0]
K_p	[50, 60]	[45, 65]
K_d	[0.4, 0.8]	[0.3, 0.9]
Payload (Kg)	[0, 6]	[0, 7]
Center of Mass (cm)	[-0.15, 0.15]	[-0.18, 0.18]
Motor Strength	[0.90, 1.10]	[0.88, 1.22]
Re-sample Probability	0.004	0.01

表 I: 环境参数的范围。

在真实机器人上部署 RMA，无需对两个子系统进行任何同步或校准。这种异步设计从根本上是通过将相对不频繁变化的外在矢量与快速变化的机器人状态解耦来实现的。

四. 实验装置

A. Environment Details

硬件详细信息：我们使用 Unitree 的 A1 机器人进行所有实际实验。A1 是一款成本相对较低的中型四足机器狗。它有 18 个自由度，其中 12 个被驱动（每条腿有 3 个电机），重量约为 12 公斤。为了测量机器人的当前状态，我们使用电机编码器的关节位置和速度、IMU 传感器的滚动和俯仰以及脚传感器的二值化脚接触指示器。部署的策略使用机器人关节的位置控制。使用具有固定增益 ($K_p = 55$ 和 $K_d = 0.8$) 的 PD 控制器将预测的所需关节位置转换为扭矩。

模拟设置：我们使用 RaiSim 模拟器 [22] 进行刚体和接触动力学模拟。我们从 Unitree [53] 导入 A1 URDF 文件，并使用内置的分形地形生成器生成不平坦的地形（分形八度音阶 = 2、分形空隙度 = 2.0、分形增益 = 0.25、z 尺度 = 0.27）。每个强化学习阶段最多持续 1000 步，如果机器人的高度低于 0.28m、身体侧倾幅度超过 0.4 弧度或俯仰超过 0.2 弧度，则提前终止。策略的控制频率为 100 Hz，模拟时间步长为 0.025s。

状态-动作空间：状态为 30 维，包含关节位置（12 个值）、关节速度（12 个值）、躯干的滚动和俯仰以及二进制脚接触指示器（4 个值）。对于动作，我们对 12 个机器人关节使用位置控制。RMA 预测所需的关节角度 $a = \hat{\mathbf{q}} \in \mathbb{R}^{12}$ ，使用 PD 控制器将其转换为扭矩 τ ： $\tau = K_p(\hat{\mathbf{q}} - \mathbf{q}) + K_d(\dot{\hat{\mathbf{q}}} - \dot{\mathbf{q}})$ 。 K_p 和 K_d 是手动指定的增益，目标关节速度 $\dot{\hat{\mathbf{q}}}$ 设置为 0。

环境变化：表 I 中列出了所有环境变化及其范围。其中， e_t 包括质量及其在机器人上的位置（3 维）、电机强度（1 2 维）、摩擦力（标量）和局部地形高度（标量），使其成为 17 维矢量。请注意，虽然地形剖面的难度是固定的，但局部地形高度会随着智能体的变化而变化。




图 3: 我们在现实世界中的几种分销外设置中评估 RMA。我们将 RMA 与 A1 的控制器和 不带适配模块的 RMA 进行比较。我们发现, RMA 从 15 厘米的高度下降, 成功率为 80%, 并在看不见的可变形表面上行走, 例如记忆海绵床垫和稍微不平坦的泡沫, 成功率为 100%。它能够成功地攀爬斜坡和台阶。A1 的控制器无法在不平坦的泡沫上行走。下面我们还分析了三种方法的有效载荷承载限制。我们看到 A1 控制器的性能在 8Kg 负载能力时开始下降。不带适配的 RMA 对于超过 8 公斤的有效负载无法移动, 但很少掉落。作为参考, A1 机器人重量为 12Kg。总体而言, 所提出的方法始终主导基线方法。报告的数字是 5 次试验的平均值。

移动。我们将每英尺下的地形高度离散化到小数点后第一位, 然后取四英尺中的最大值以获得标量。这确保了控制器并不严重依赖于对本地地形的快速准确的感知, 并允许基本策略在部署期间以低得多的更新频率异步使用它。

B. Training Details

基本策略和环境因素编码器架构: 基本策略是一个 3 层多层感知器 (MLP), 它接收当前状态 $x_t \in \mathbb{R}^{30}$ 、先前动作 $a_{t-1} \in \mathbb{R}^{12}$ 和外部向量 $z_t \in \mathbb{R}^8$, 并输出 12 维目标关节角度。隐藏层的维度为 128。环境因子编码器是 3 层 MLP (256、128 隐藏层大小), 并将 $e_t \in \mathbb{R}^{17}$ 编码为 $z_t \in \mathbb{R}^8$ 。

适应模块架构: 适应模块首先使用 2 层 MLP 将最近的状态和动作嵌入到 32 维表示中。然后, 3 层 1-D CNN 对时间维度上的表示进行卷积, 以捕获输入中的时间相关性。输入通道

每层的数量、输出通道数、内核大小和步幅为 [32, 32, 8, 4], [32, 32, 5, 1], [32, 32, 5, 1]。扁平化 CNN 输出被线性投影以估计 $\hat{z}_t$ 。

学习基础策略和环境因素编码器网络: 我们使用 PPO [48] 联合训练基础策略和环境编码器网络, 进行 15, 000 次迭代, 每次迭代使用 80, 000 的批量大小, 分为 4 个小批量。学习率设置为 $5e-4$ 。第三节提供了奖励条件的系数。在普通台式机上训练大约需要 24 小时, 有 1 个 GPU 用于策略训练。在此持续时间内, 它模拟了 1.20 亿步。

学习适应模块: 我们使用监督学习和在策略数据来训练适应模块。我们使用 Adam 优化器 [29] 来最小化 MSE 损失。我们以 $5e-4$ 的学习率为 $5e-4$ 运行优化过程 1000 次迭代, 每次迭代使用 80, 000 的批量大小, 分为 4 个小批量。在普通台式机上训练需要 3 个小时, 并使用 1 个 GPU 来训练策略。在此期间, 它模拟了 8000 万步。




图 4: 我们在机器人走过油性塑料片并在其脚上覆盖额外的塑料片时分析 RMA。我们绘制了膝盖的扭矩和指示四脚接触的步态模式 (F/R 表示前/后, R/L 表示右/左)。下图显示了适应模块预测的外在向量 $\hat{z}$ 的中值过滤 1^{st} 和 5^{th} 分量。当机器人进入湿滑区域时, 我们看到外在向量 $\hat{z}$ 的两个分量发生变化, 表明自适应模块已检测到滑动事件。请注意, 适应后, 恢复的步态时间段与原始步态时间段相似, 扭矩大小已增加, 并且 $\hat{z}$ 继续捕获表面仍然光滑的事实。RMA 在油性斑块上的运行中 90% 都是成功的。

五、结果与分析

我们将 RMA 的性能与模拟中的几个基线进行比较 (表 I)。我们还与 A1 附带的制造商控制器在现实世界的室内设置中进行比较 (图 3), 并在各种地形的野外运行 RMA (图 1)。视频位于 <https://ashish-kmr.github.io/rma-legged-robots/>

基线: 我们与以下基线进行比较:

- 1) A1 控制器: 默认的机器人制造商的控制器, 使用基于力的控制方案和 MPC。
- 2) 通过域随机化实现鲁棒性 (鲁棒性): 基本策略在没有 z_t 的情况下进行训练, 以对训练范围的变化具有鲁棒性 [52, 40]。
- 3) 专家适应策略 (Expert): 在模拟中, 我们可以使用外在向量 z_t 的真实值。这是 RMA 性能的上限。
- 4) 不带适应的 RMA: 我们还可以在没有适应模块的情况下评估基本策略的性能, 以消除适应模块的重要性。

- 5) 系统识别[57]: 我们不预测 $\hat{z}_t$, 而是直接预测系统参数 $\hat{e}_t$ 。
- 6) 域适应的优势加权回归 (AWR) [41]: 通过在测试环境中使用策略的实际部署, 使用 AWR 离线优化 $\hat{z}_t$ 。

学习基线使用相同的架构、奖励函数和其他超参数进行训练。

指标: 我们使用以下指标将 RMA 的性能与基线进行比较: (1) 跌倒时间除以最大情节长度, 以获得 0 – 1 (TTF) 之间的标准化值; (2) 平均前向奖励, (3) 成功率, (4) 覆盖距离, (5) 适应所需的探索样本, (6) 施加的扭矩, (7) 扭矩导数的平滑度和 (7) 地面冲击 (补充中的详细信息)。

A. Indoor Experiments

在现实世界中, 我们将带有 A1 控制器的 RMA 和不带适配模块的 RMA 进行比较 (图 3)。我们限制与这两个基线的比较, 以避免损坏

	Success (%)	TTF	Reward	Distance (m)	Samples	Torque	Smoothness	Ground Impact
Robust [52, 40]	62.4	0.80	4.62	1.13	0	527.59	122.50	4.20
SysID [57]	56.5	0.74	4.82	1.17	0	565.85	149.75	4.03
AWR [41]	41.7	0.65	4.17	0.95	40k	599.71	162.60	4.02
RMA w/o Adapt	52.1	0.75	4.72	1.15	0	524.18	106.25	4.55
RMA	73.5	0.85	5.22	1.34	0	500.00	92.85	4.27
Expert	76.2	0.86	5.23	1.35	0	485.07	85.56	3.90

表二：模拟测试结果：我们将我们的方法与模拟中的基准方法的性能进行比较。我们的训练和测试设置列于表 I。我们在测试期间以每步 0.01 的重新采样概率对一个情节内的环境参数进行重新采样。基线和指标在第五节中定义。报告的数字是 3 个随机初始化策略和每个随机初始化 1000 个事件的平均值。RMA 的性能优于所有基线，与 Expert 相比，性能仅略有下降。

机器人硬件。我们对每种方法进行 5 次试验，并报告成功率、跌倒时间 (TTF) 和行走距离。请注意，如果某个方法在一项任务中彻底失败，我们只会运行两次试验，然后报告失败。这样做是为了最大限度地减少对机器人硬件的损坏。我们有以下室内设置：

- n-kg 有效负载：在顶部放置 n-kg 有效负载步行 300 厘米。
- StepUp-n：登上 n 厘米高的台阶。
- 不均匀泡沫：在中心升高的泡沫上行走 180 厘米。
- 床垫：在记忆海绵床垫上行走 60 厘米。
- StepDown-n：走下 n 厘米高的台阶。
- 斜坡：沿 6 度的斜坡向上行走。
- 油性表面：穿过油性斑块。

StepUp-n 和 StepDown-n 的每次尝试在成功或失败后终止。因此，我们只报告这些任务的成功率，因为其他指标没有意义。

我们观察到 RMA 在所有这些设置中都取得了很高的成功率，在某些情况下大幅优于 A1 控制器的性能。我们发现关闭适应模块会大大降低性能，这意味着适应模块对于解决这些任务至关重要。A1 的控制器遇到了不均匀的泡沫以及大幅度的下降和上升的问题。控制器在大多数故障中都是由于立足点不稳定而不稳定。在有效负载分析中，A1 的控制器能够处理高于宣传的有效负载（5 公斤），但开始下垂，并最终随着有效负载的增加而下降。相比之下，RMA 保持高度，最多可承载 12Kg（体重的 100%），成功率很高。没有适应的 RMA 大多不会下降，但也不会前进。我们还在一项更具挑战性的任务中评估了 RMA，即用塑料包裹的脚穿越油路。机器人成功地走过了油污地。有趣的是，无需任何微调或模拟校准，RMA 无需适应就能在木地板上成功行走。这与现有的方法形成鲜明对比，现有的方法即使在平坦和静态的环境中也会校准模拟 [51, 23] 或在测试时微调其策略 [41]。

B. Outdoor Experiments

我们展示了 RMA 在几种具有挑战性的室外环境中的性能，如图 1 所示。

在我们的所有试验中，机器人成功地能够在沙子、泥土和污垢上行走，没有出现任何故障。这些地形由于脚下沉和粘滞而导致移动困难，这需要机器人动态地改变立足点以确保稳定性。RMA 在高大植被上行走或穿越灌木丛的成功率为 100%。这些地形阻碍了机器人的脚，使其在行走时周期性地不稳定。为了成功地在这些设置中行走，机器人必须保持稳定，防止脚被缠住，并积极地通过其中一些障碍物。我们还评估了我们的机器人走下远足小道上的一些楼梯的情况。该机器人在 70% 的试验中取得了成功，考虑到机器人在训练过程中从未见过楼梯，这仍然很了不起。最后，我们在建筑垃圾上测试了机器人，在泥浆堆上下坡行走时成功率为 100%，在水泥堆和鹅卵石堆上行走时成功率为 80%。水泥堆和鹅卵石本身位于一个向侧面陡峭倾斜的地面上，这使得机器人穿过水泥堆非常具有挑战性。

C. Simulation Results

我们将我们的方法与模拟中的基线方法的性能进行比较（表二）。我们根据表 I 对训练和测试参数进行采样，并在一个 episode 内对它们进行重新采样，每步的重采样概率分别为 0.004 和 0.01，以进行训练和测试。报告的数字是 3 个随机初始化策略和每个随机初始化 1000 个事件的平均值。RMA 的性能最好，与 Expert 的性能相比仅略有下降。不断变化的环境导致 AWR 性能不佳，适应速度非常慢。由于鲁棒基线对于外部因素是不可知的，因此它学习了一种非常保守的策略，这会导致性能下降。请注意，SysID 的低性能意味着显式估计 e_t 很难且没有必要实现卓越的性能。我们还与不带适配的 RMA 进行了比较，这表明没有适配模块时性能会显著下降。

D. Adaptation Analysis

我们分析了步态模式、扭矩曲线和估计的外在矢量 $\hat{z}_t$ ，以适应光滑表面（图

4).我们将油倒在地面的塑料表面上,并用塑料覆盖机器人的脚。然后,机器人尝试穿过湿滑的路面,并成功地适应了它。我们发现,RMA在油性斑块上的运行中90%都是成功的。对于这样一个试验,我们在图4中绘制了膝盖的扭矩曲线、步态模式以及外在向量 $\hat{z}_t$ 的中值滤波 1^{st} 和 5^{th} 分量。当机器人第一次在2秒左右开始滑动时,滑动会干扰机器人的常规运动,之后机器人进入适应阶段。这在随滑移而变化的外在向量的绘制分量中是显而易见的。检测到的滑移使机器人能够恢复并继续在湿滑的路面上行走。请注意,尽管在适应后,扭矩稳定到稍高的幅度并且步态时间段大致恢复,但外在矢量没有恢复并继续捕获表面光滑的事实。请参阅补充更多此类分析。

六. 结论

我们提出了RMA算法,用于实时适应在各种地形中行走的腿式机器人。不需要演示或预定义的运动模板。尽管只能访问本体感受数据,机器人也可以下楼并走过岩石。然而,盲人机器人也有局限性。较大的扰动,例如下楼时突然跌倒,或由于多条腿被岩石阻挡,有时会导致故障。为了开发真正可靠的步行机器人,我们不仅需要使用本体感觉,还需要使用带有板载视觉传感器的*exteroception*。视觉在引导远距离、快速运动中的重要性已得到充分研究,例如:通过[35],这是未来工作的一个重要方向。

致谢

我们要感谢Jemin Hwangbo在模拟平台方面提供的帮助,并感谢Koushil Sreenath和Stuart Anderson在该项目过程中提供的有用反馈。我们还要感谢Claire Tomlin、Shankar Sastry、Chris Atkeson、Aravind Sivakumar、Ilija Radosavovic和Russell Mendonca对本文的高质量反馈。这项研究是BAIR-FAIR合作项目的一部分,最近还得到了DARPA机器人常识项目的支持。

参考

[1] MYM 艾哈迈德, N 秦。基于替代的空气动力学设计优化:在空气动力学设计优化中使用替代。*International Conference on Aerospace Sciences and Aviation Technology*, 2009年。3 [2] Aaron D Ames, Kevin Galloway, Koushil Sreenath 和 Jessy W Grizzle。快速指数稳定控制李雅普诺夫函数和混合零动态。*IEEE Transactions on Automatic Control*, 2014. 1, 3 [3] 泰勒·阿普加、帕特里克·克拉里、凯文·格林、艾伦·费恩和乔纳森·W赫斯特。快速在线轨迹优化

对于双足机器人卡西。*Robotics: Science and Systems*, 2018年。3 [4] Monica Barragan、Nikolai Flowers和Aaron M. Johnson。MiniRHex:一款小型、开源、完全可编程的步行六足机器人。*Robotics: Science and Systems Workshop on "Design and Control of Small Legged Robots"*, 2018年。3 [5] Gerardo Blede, Matthew J Powell、Benjamin Katz、Jared Di Carlo、Patrick M Wensing和Sangbae Kim。Mit cheetah 3:设计和控制坚固、动态的四足机器人。在*2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*中。IEEE, 2018。3 [6] 阿德里安·波音和托马斯·Bräunl。利用多个模拟器来跨越现实差距。在*2012 12th International Conference on Control Automation Robotics & Vision (ICARCV)*中。IEEE, 2012。3 [7] 乔什·C邦加德(Josh C Bongard)和霍德·利普森(Hod Lipson)。使用模型和测试的协同进化进行非线性系统识别。*IEEE Transactions on Evolutionary Computation*, 2005。3 [8] 罗伯特·卡兰德拉、安德烈·塞法斯、扬·彼得斯和马克·彼得·戴森罗斯。不确定性下学习步态的贝叶斯优化。*Annals of Mathematics and Artificial Intelligence*, 2016。3 [9] Krzysztof Choromanski、Atil Iscen、Vikas Sindhwani、Jie Tan和Erwin Coumans。通过耐噪声结构化探索优化模拟。在*2018 IEEE International Conference on Robotics and Automation (ICRA)*中。IEEE, 2018。3 [10] Ignasi Clavera、Anusha Nagabandi、Simin Liu、Ronald S. Fearing、Pieter Abbeel、Sergey Levine和Chelsea Finn。通过元强化学习学习适应动态的现实环境。*International Conference on Learning Representations*, 2019年。4 [11] Martin De Lasa、Igor Mordatch和Aaron Hertzmann。基于特征的运动控制器。*ACM Transactions on Graphics (TOG)*, 2010。3 [12] Jared Di Carlo、Patrick M Wensing、Benjamin Katz、Gerardo Blede和Sangbae Kim。通过凸模型预测控制实现mit cheetah 3的动态运动。在*2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*中。IEEE, 2018。3 [13] Chelsea Finn、Pieter Abbeel和Sergey Levine。用于快速适应深度网络的模型无关元学习。在*International Conference on Machine Learning*中。PMLR, 2017。4 [14] Scott Fujimoto、Herke Hoof和David Meger。解决演员批评家方法中的函数逼近错误。在*International Conference on Machine Learning*中。PMLR, 2018。3 [15] Christian Gehring、Stelian Coros、Marco Hutter、Carmine Dario Bellicoso、Huub Heijnen、Remo Diethelm、Michael Bloesch、Peter Fankhauser、Jemin Hwangbo、Mark Hoepflinger等。熟能生巧:一种基于优化的方法来控制四足机器人的敏捷运动。*IEEE Robotics & Automation Magazine*, 2016. 3

- [16] 哈特穆特·盖耶、安德烈·塞法斯和莱因哈德·布里克汉。弹跳步态中的正力反馈? *Proceedings of the Royal Society of London. Series B: Biological Sciences*, 2003. 1, 3 [17] 郭晓晓, 李伟, Francesco Iorio。用于稳定流近似的卷积神经网络。 *Proceedings of the 22nd ACM SIGKDD international conference on knowledge discovery and data mining*, 2016 年。3 [18] Tuomas Haarnoja, Sehoon Ha, Aurick Zhou, Jie Tan, George Tucker 和 Sergey Levine。通过深度强化学习学习走路。在 *Robotics: Science and Systems*, 2019. 1, 3 [19] Josiah Hanna 和 Peter Stone。模拟中机器人学习的基础动作转换。 *Proceedings of the AAAI Conference on Artificial Intelligence*, 2017. 4 [20] Marco Hutter, Christian Gehring, Dominic Jud, Andreas Lauber, C Dario Bellicoso, Vassilios Tsounis, Jemin Hwangbo, Karen Bodie, Peter Fankhauser, Michael Bloesch 等人。Anymal——高度机动且动态的四足机器人。在 *2016 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*中。IEEE, 2016. 3 [21] Jemin Hwangbo。RaisimGymTorch。 <https://raisim.com/sections/RaisimGymTorch.html>, 2020-2021 年。12 [22] Jemin Hwangbo, Joonho Lee 和 Marco Hutter。用于求解接触动力学的逐接触迭代方法。 *IEEE Robotics and Automation Letters*, 2018。网址 www.raisim.com。5 [23] Jemin Hwangbo, Joonho Lee, Alexey Dosovitskiy, Dario Bellicoso, Vassilios Tsounis, Vladlen Koltun 和 Marco Hutter。学习腿式机器人的敏捷和动态运动技能。 *Science Robotics*, 2019.1,3,4,8,12 [24] Dong Jin Hyun, Jongwoo Lee, SangIn Park 和 Sangbae Kim。在 mit cheetah i 上实现小跑到疾驰的过渡以及随后的疾驰。 *The International Journal of Robotics Research*, 2016. 1, 3 [25] Atil Iscen, Ken Caluwaerts, Jie Tan, Tingnan 张, Erwin Coumans, Vikas Sindhwani 和 Vincent Vanhoucke。调整轨迹生成器的策略。在 *Conference on Robot Learning*中。PMLR, 2018. 3 [26] Aaron M Johnson, Thomas Libby, Evan Chang-Siu, Masayoshi Tomizuka, Robert J Full 和 Daniel E Koditschek。尾部辅助动态自动扶正。在 *Adaptive Mobile Robotics*中。世界科学, 2012. 1, 3 [27] Mrinal Kalakrishnan, Jonas Buchli, Peter Pastor, Michael Mistry 和 Stefan Schaal。四足动物在具有挑战性的地形上快速、稳健地运动。在 *2010 IEEE International Conference on Robotics and Automation*中。IEEE, 2010. 3 [28] Mahdi Khoramshahi, Hamed Jalaly Bidgoly, Soroosh Shafiee, Ali Asaei, Auke Jan Ijspeert 和 Majid Nili Ahmadabadi。四足机器人中分段线性脊柱的速度与能量效率权衡。 *Robotics and Autonomous Systems*, 2013. 1, 3 [29] Diederik P. Kingma 和 Jimmy Ba。Adam: 一种随机优化方法。 *3rd International Conference on Learning Representations*, 2015. 6, 12 [30] Jens Koher, J Andrew Bagnell 和 Jan Peters。机器人技术中的强化学习: 一项调查。 *The International Journal of Robotics Research*, 2013. 3 [31] Sylvain Koos, Jean-Baptiste Mouret 和 Stéphane Doncieux。通过推广可转移控制器来跨越进化机器人技术的现实差距。 *Proceedings of the 12th annual conference on Genetic and evolutionary computation*, 2010. 3 [32] Joonho Lee, Jemin Hwangbo, Lorenz Wellhausen, Vladlen Koltun 和 Marco Hutter。学习在具有挑战性的地形上的四足运动。 *Science robotics*, 2020. 1, 3, 4 [33] Timothy P. Lillicrap, Jonathan J. Hunt, Alexander Pritzel, Nicolas Heess, Tom Erez, Yuval Tassa, David Silver 和 Daan Wierstra。通过深度强化学习进行持续控制。 *ICLR*, 2016. 3 [34] Jingru Luo 和 Kris Hauser。通过迭代学习进行摩擦接触下的鲁棒轨迹优化。 *Autonomous Robots*, 2017. 4 [35] 乔纳森·萨米尔·马蒂斯、雅各布·L·耶茨和玛丽·M·海霍。在自然地形中行走时的注视和足部放置的控制。 *Current Biology*, 2018. 9 [36] 三浦博文和下山功。Biped 的动态行走。 *The International Journal of Robotics Research*, 1984. 1, 3 [37] Volodymyr Mnih, Adria Puigdomenech Badia, Mehdi Mirza, Alex Graves, Timothy Lillicrap, Tim Harley, David Silver 和 Koray Kavukcuoglu。深度强化学习的异步方法。在 *International conference on machine learning*中。PMLR, 2016. 3 [38] Ofir Nachum, Michael Ahn, Hugo Ponte, Shiyang Shane Gu 和 Vikash Kumar。使用分层 sim2real 通过运动进行多智能体操作。在 *Conference on Robot Learning*中。PMLR, 2020. 4 [39] Michael Neunert, Thiago Boaventura 和 Jonas Buchli。为什么现成的物理模拟器无法评估反馈控制器性能——四足机器人的案例研究。在 *Advances in Cooperative Robotics*中。世界科学, 2017. 3 [40] Xue Bin Peng, Marcin Andrychowicz, Wojciech Zaremba 和 Pieter Abbeel。通过动态随机化实现机器人控制的模拟到真实的转换。在 *2018 IEEE international conference on robotics and automation (ICRA)*中。IEEE, 2018. 1,4,7,8 [41] Xue Bin Peng, Erwin Coumans, Tingnan 张, Tsang-Wei Edward Lee, Jie Tan 和 Sergey Levine。通过模仿动物学习机器人敏捷的运动技能。在 *Robotics: Science and Systems*, 2020. 1, 3, 4, 7, 8 [42] Delye T Polet 和 John EA Bertram。非弹性四足模型发现四节拍行走、两节拍跑步和伪弹性驱动在能量上是最佳的。 *PLoS computational biology*, 2019.4

[43] 马克·H·雷伯特。有腿系统中的跳跃——二维单腿情况的建模和仿真。

IEEE Transactions on Systems, Man, and Cybernetics, 1984. 1, 3 [44] Nathan Ratliff, Matt Zucker, J Andrew Bagnell 和 Siddhartha Srinivasa。Chomp: 用于高效运动规划的梯度优化技术。在2009 *IEEE*

*International Conference on Robotics and Automation*中。IEEE, 2009. 3 [45] Stéphane Ross, Geoffrey Gordon 和 Drew Bagnell。将模仿学习和结构化预测减少为无悔的在线学习。 *Proceedings of the fourteenth*

international conference on artificial intelligence and statistics, 2011 年。5 [46] Uluc Saranli, Martin Buehler 和 Daniel E Koditschek。Rhex: 一种简单且高度机动的六足机器人。 *The International Journal of Robotics Research*, 2001. 1 [47] 约翰·舒尔曼、菲利普·莫里茨、谢尔盖·莱文、迈克尔·乔丹和彼得·阿贝尔。使用广义优势估计的高维连续控制。 4th

International Conference on Learning Representations, 2016 年。12 [48] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford 和 Oleg Klimov。近端策略优化算法。 *arXiv preprint arXiv:1707.06347*, 2017. 3, 6, 12 [49] 宋兴友,

杨宇翔, Krzysztof Choromanski, Ken Caluwaerts, 高文波, Chelsea Finn, 谭杰。通过进化元学习快速适应的腿式机器人。 *International Conference on Intelligent*

Robots and Systems (IROS), 2020 年。4 [50] Koushil Sreenath, Hae-Won Park, Ioannis Poulakakis 和 Jessy W Grizzle。一款兼容的混合零动态控制器, 可在 mabel 上实现稳定、高效和快速的双足行走。

The International Journal of Robotics Research, 2011. 1, 3 [51] 谭杰、张廷南、Erwin Coumans、Atil Iscen、白云飞、Daniyar Hafner、Steven Bohez 和 Vincent Vanhoucke。模拟真实: 学习四足机器人的敏捷运动。在

Robotics: Science and Systems, 2018. 4, 8 [52] Josh Tobin, Rachel Fong, Alex Ray, Jonas Schneider, Wojciech Zaremba 和 Pieter Abbeel。用于将深度神经网络从模拟转移到现实世界的域随机化。在

2017 *IEEE/RSJ international conference on intelligent robots and systems (IROS)*中。IEEE, 2017. 1, 4

, 7, 8 [53] 王星星。优树机器人公司。 <https://www.unitree.com/>. 5 [54] 谢兆明, 达兴业, Michiel van de Panne, Buck Babich, Animesh Garg。重新审视动力学随机化: 四足运动的案例研究。 *arXiv preprint arXiv:2011.02404*, 2020. 4 [

55] 杨宇翔、Ken Caluwaerts、Atil Iscen、张廷南、谭杰和 Vikas Sindhwani。腿式机器人的数据高效强化学习。在 *Conference*中

on Robot Learning。PMLR, 2020. 1, 3 [56] KangKang Yin, Kevin Loken 和 Michiel Van de Panne。Simbicon: 简单的两足动物运动控制。 *ACM*

Transactions on Graphics (TOG), 2007. 1, 3 [57] 于文浩, 谭杰, C. Karen Liu, Greg Turk。为未知做好准备: 通过在线系统识别学习通用策略。 *Robotics: Science and Systems*, 2017. 3, 4, 7, 8 [58] Wenhao Yu, C Karen Liu, Greg Turk。

政策转移与策略优化。 *International Conference on Learning Representations*, 2018 年。4 [59] Wenhao Yu、Visak C. V. Kumar, Greg Turk 和 C. Karen Liu。双足运动的模拟到真实传输。在2019

*IEEE/RSJ International Conference on Intelligent Robots and Systems*中。IEEE, 2019. 4 [60] Wenhao Yu, Jie Tan, Yunfei Bai, Erwin Coumans 和 Sehoon Ha。通过元策略优化学习快速适应。 *IEEE Robotics and Automation Letters*, 2020. 4 [61] 周文轩, Lerrel Pinto, Abhinav Gupta。环境探测交互策略。 7th *International*

Conference on Learning Representations, ICLR 2019, 2019 年。4 [62] J Zico Kolter 和 Andrew Y Ng。斯坦福小狗: 四足动物运动的学习和快速重新规划方法。

The International Journal of Robotics Research, 2011. 3 [63] Matt Zucker, J Andrew Bagnell, Christopher G Atkeson 和 James Kuffner。崎岖地形运动的优化方法。在 2010 *IEEE International*

*Conference on Robotics and Automation*中。IEEE, 2010. 1, 3 [64] Matt Zucker, Nathan Ratliff, Martin Stolle, Joel Chestnutt, J Andrew Bagnell, Christopher G Atkeson 和 James Kuffner。崎岖地形腿部运动的优化和学习。

The International Journal of Robotics Research, 2011. 3

RMA 补充：腿式机器人的快速

电机适应

S1. 指标

我们使用几个指标（以 SI 单位）来评估 RMA 的性能并将其与基线进行比较：

- 成功率：成功完成下一节中定义的任务的平均率。
- 跌倒时间 (TTF)：测量跌倒前的时间。我们将其除以剧集的最大持续时间，并报告 0 到 1 之间的标准化值。
- 奖励：平均前进奖励加上多个回合的横向奖励，如主论文第 III-A 节 RL 奖励中所定义。
- 距离：一集中所经过的平均距离。对于现实世界的实验，我们报告归一化距离，其中我们通过特定于任务的最大距离进行归一化。
- 适应样本：在测试环境中探索电机策略适应所需的控制步骤数量。
- 扭矩：每个关节处的扭矩 L2 范数的平方 $\|\tau^t\|^2$ 。
- 加加速度：增量扭矩 $\|\tau^t - \tau^{t-1}\|^2$ 的 L2 范数平方。
- 地面冲击：每英尺处 Delta 地面反作用力的平方 L2 范数 $\|\mathbf{f}^t - \mathbf{f}^{t-1}\|^2$ 。

S1. 额外的培训和部署细节

训练流程如算法 1 所示，部署流程如算法 2 所示。

我们使用 PPO [48] 来训练基本策略和环境因素编码器。我们总共训练 15,000 次迭代。在每次迭代期间，我们收集一批 80,000 个状态-动作转换，这些转换被均匀地分为 4 个小批次。每个小批量都按顺序输入到基本策略和环境因子编码器中，进行 4 轮，以计算损失和错误反向传播。损失是替代保单损失与 0.5 倍价值损失之和。我们将动作日志概率比限制在 0.8 和 1.2 之间，并将目标值限制在相应旧值的 0.8 – 1.2 倍范围内。我们排除了基本策略的熵正则化，但将参数化高斯动作空间的标准差限制为大于 0.2 以确保探索。泛化优势估计[47]中的 λ 和 γ 分别设置为0.95和0.998。我们使用 Adam 优化器 [29]，将学习率设置为 $5e-4$ ， β 为 (0.9, 0.999)， ϵ 为 $1e-8$ 。参考实现可以在 Raisim GymTorch 库 [21] 中找到。

如果我们天真地用聚合所有项的奖励函数来训练我们的代理，它就会因为惩罚项而学习下降。为了防止这种崩溃，我们遵循[23]中描述的策略。除了所有奖励项的缩放因子之外，我们还将一个小的乘数 k_t 应用于惩罚项 3 – 10，如主论文第 III-A 节中所定义。我们开始训练

Algorithm 1: Rapid Motor Adaptation Training

Phase 1 Randomly initialize the base policy π ;
Randomly initialize the environmental factor encoder μ ; Empty replay buffer D_1 ;
for $0 \leq \text{itr} \leq N_{\text{itr}}^1$ **do**
 for $0 \leq i \leq N_{\text{env}}$ **do**
 $x_0, e_0 \leftarrow \text{envs}[i].\text{reset}()$;
 for $0 \leq t \leq T$ **do**
 $z_t \leftarrow \mu(e_t)$;
 $a_t \leftarrow \pi(x_t, a_{t-1}, z_t)$;
 $x_{t+1}, e_{t+1}, r_t \leftarrow \text{envs}[i].\text{step}(a_t)$;
 Store $((x_t, e_t), a_t, r_t, (x_{t+1}, e_{t+1}))$ in D_1 ;
 end
 end
Update π and μ using PPO [48];
Empty D_1 ;
end

Phase 2 随机初始化由 θ_ϕ 参数化的适配模块 ϕ ；空小批量 D_2 ；**for** $0 \leq \text{itr} \leq N_{\text{itr}}^2$ **do** **for** $0 \leq i \leq N_{\text{env}}$ **do**
 $x_0, e_0 \leftarrow \text{envs}[i].\text{reset}()$ ；对于 $0 \leq t \leq T$ 执行
 $\hat{z}_t \leftarrow \phi(x_{t-k:k}, a_{t-k-1:k-1})$ ； $z_t \leftarrow \mu(e_t)$ ；
 $a_t \leftarrow \pi(x_t, a_{t-1}, \hat{z}_t)$ ； $x_{t+1}, e_{t+1}, _ \leftarrow \text{envs}[i].\text{step}(a_t)$ ；
将 $(\hat{z}_t, z_t)$ 存储在 D_2 中；结束
 $\theta_\phi \leftarrow \theta_\phi - \lambda_{\theta_\phi} \nabla_{\theta_\phi} \frac{1}{TN_{\text{env}}} \sum \|\hat{z}_t - z_t\|^2$ ；空 D_2 ；**结**
尾

将非常小的 k_0 设置为 0.03，然后使用固定课程以指数方式增加这些系数： $k_{t+1} = k_t^{0.997}$ ，其中 t 是迭代数。学习过程如图 S2 所示。

S1. 额外的现实世界适应分析

除了主论文图 4 中的油行走实验之外，我们还分析了质量适应情况下的步态模式和扭矩曲线，如图 S3 所示。我们在跑步过程中将 5kg 的有效负载放在机器人的背部，并绘制膝盖的扭矩曲线、步态模式以及外在矢量 $\hat{z}_t$ 的 2^{th} 和 7^{th} 分量，如图 S3 所示。我们观察到额外的有效负载扰乱了机器人的正常运动，之后它进入

Algorithm 2: Rapid Motor AdaptationDeployment

Process 1 operating at 100 Hz;

$t \leftarrow 0$;

while not fall do

$a_t \leftarrow \pi(x_t, a_{t-1}, \hat{z}_{\text{async}})$;

$x_{t+1} \leftarrow \text{env.step}(a_t)$;

$t \leftarrow t + 1$;

end

Process 2 operating at 10 Hz;

while not fall do

$\hat{z}_{\text{async}} \leftarrow \phi(x_{t-k:k}, a_{t-k-1:k-1})$;

end

适应阶段，最后从干扰中恢复。当有效负载落在机器人上时，值得注意的是，绘制的外在向量分量会随着滑动而变化。适应后，我们看到扭矩稳定到比以前更高的幅度，以说明有效负载，并且步态时间段大致恢复。




图 S2: 我们绘制了总共 15,000 次训练迭代期间的平均步数奖励。我们展示了奖励聚合所有奖励项、前向+横向奖励和惩罚项之和的收敛趋势。它还表明了训练开始时对惩罚项应用小乘数的必要性；否则，机器人最初只会有负面的体验，无法学会快速行走。

S2. 额外的模拟测试

在图S4中，我们进一步在极端模拟环境中测试RMA，并展示了其在三种环境变化中的性能：A1机器人底座上添加的有效负载、地形高程变化（分形地形生成器中使用的z尺度，详细信息请参见本文的第四节模拟设置）以及机器人脚与地形之间的摩擦系数。我们在 S1 节中定义的成功率、TTF 和奖励方面展示了 RMA 在所有案例中的优越性。




图 S3: 我们分析了当我们把 5 公斤的有效负载扔到机器人背部时, RMA 行为的变化。请注意, 我们翻转了图像, 以便从左向右显示运动, 这就是沙袋上的标签看起来为 2 公斤的原因。我们绘制了膝盖的扭矩曲线和步态模式。下图显示了适应模块预测的外在向量 $\hat{z}$ 的中值过滤 2^{nd} 和 7^{th} 分量。当 5 公斤的有效负载被扔到机器人的背部时, 我们看到机器人的质心下降, 适应模块随后从中恢复。在底部图中, 我们看到估计的外在向量的绘制分量中出现响应跳跃, 表明自适应模块已检测到额外的有效负载。请注意, 适应后, 恢复的步态时间段与原始步态时间段大致相似, 扭矩大小有所增加, 并且外在矢量继续捕获机器人背面 5 公斤有效负载的存在。




图 S4: 模拟泛化结果: 我们进一步将我们的方法与模拟中的基线方法的泛化性能进行比较。我们选择了三个在现实世界中可能有很大变化的物理参数: 机器人的有效负载、地形高度变化以及机器人脚与地形之间的摩擦系数。我们根据主论文表二中的训练范围设置其他环境参数。基线和指标在主论文的第五节和 S1 节中定义。我们报告了 3 个随机初始化策略的性能平均值和标准差, 其特征是给定设置中 100 次测试试验的平均值。尽管没有测试环境样本, 但 RMA 的表现最好, 最接近 Expert 的表现。作为参考, 没有额外负载的 A1 机器人重 12 kg, 高 0.35 m。橡胶和混凝土之间的静摩擦系数为 1.00。