

即时适应：面向单次生命周期机器人部署的行为调制

Annie S. Chen*
Stanford University

Govind Chada*
Stanford University

Laura Smith
UC Berkeley

Archit Sharma
Stanford University

Zipeng Fu
Stanford University

Sergey Levine
UC Berkeley

Chelsea Finn
Stanford University

摘要

为了在现实世界中取得成功，机器人必须应对与训练期间所见不同的情况。我们研究了在部署过程中即时适应此类新颖场景的问题，通过利用先前学习行为的多样化库。我们的方法，鲁棒自主调制（ROAM），引入了一种基于预训练行为感知价值的机制，以选择并调整预训练行为来适应当前情境。关键的是，这一适应过程完全在测试时的单个回合内完成，无需任何人工监督。我们提供了选择机制的理论分析，并证明 ROAM 使机器人能够在仿真和真实 Go1 四足机器人上快速适应动力学变化，甚至在脚上穿着轮滑鞋时也能成功前进。在面对部署期间各种分布外情况时，我们的方法通过有效选择和即时调整相关行为，适应效率比现有方法高出 2 倍以上。




图 1：通过鲁棒自主调制（ROAM）实现即时适应。智能体在部署过程中不可避免地会遇到各种情况，处理这些情况可能需要多种不同的行为。我们提出鲁棒自主调制（ROAM），在部署过程中动态采用相关行为以应对不同情况。

1 引言

顺序决策智能体广泛应用的一个主要障碍是其无法适应意外情况，这将其用途主要限制在严格控制的环境中。即使具备先验经验和预训练，智能体在部署时仍不可避免地会遇到分布外（Out-of-Distribution, OOD）情况，这可能需要大量的即时适应。在这项工作中，我们旨在使机器人能够自主处理部署期间遇到的新场景，同时利用一组多样化的预训练行为来提高其多功能性。我们假设，通过在预训练行为的空间中进行部分适应（而不仅仅是在参数空间中进行适应），我们可以更快地反应并适应新情况。通过在线或离线的情节强化学习，积累一组不同的行为策略是一项相对直接的任务。

可以使用不同的奖励函数或技能发现方法。然而，在部署期间，特别是在新环境中，对这些行为的即时选择和适应提出了重大挑战。考虑给一个四足机器人分配任务，该机器人通过仿真训练已经获得了许多不同的行为，例如行走、蹲伏和跛行，现在要在现实世界中执行搜救任务。当部署到具有非结构化障碍物的任务中时，机器人可能会撞到障碍物并损坏其腿，它必须能够动态调整其行为选择，以便在受损情况下继续执行任务。

现有的自适应方法通常在标准的、分幕式训练范式下运作，其中假设智能体每次都会被重置并有机会再次尝试任务（Cully 等人，2015；Song 等人，2020；Julian 等人，2020）。然而，这些是理想化的条件，在实践中往往依赖于人工干预。在上述搜索与救援示例中，机器人的状态无法被任意恢复；在部署期间，机器人无法被修复，如果它陷入无法处理的困境，由人类将其取回也是不可行的。这种情况要求在测试时既快速又自主地进行自适应，以便在单个幕内成功完成任务。因此，我们将问题设定为单次生命部署（Single-Life Deployment）的一个实例（Chen 等人，2022），其中智能体被赋予先验知识，但根据其在后续“单次生命”试验中成功完成给定任务的能力进行评估，在该试验期间没有人工提供的重置。机器人在分幕式强化学习下训练得到一组多样化的先验行为，而单次生命则呈现一系列新的情境。

为了解决这个问题，机器人必须在部署期间识别出在给定时间步下最适合其情境的行为，并具备实时微调这些行为的能力，因为预训练的行为可能无法最优地适应新的挑战。我们提出了一种简单的方法，称为鲁棒自主调制（ROBust Autonomous Modulation, ROAM），其首要目标是在单次生命部署期间的每个时间点，快速从其预训练集合中识别出最合适的行为。我们没有引入额外的组件（如高层控制器）来选择行为，而是利用了每个行为的价值函数。价值函数已经估计了每个策略是否会成功，但对于在该行为训练期间未遇到的状态，其估计可能不准确。因此，在部署之前，我们使用一个正则化目标来微调每个行为的价值函数，以鼓励行为的可辨识性：该正则化项是一个行为分类损失。然后，在部署期间的每一步，ROAM 根据其分类概率按比例采样一个行为，执行该行为的一个动作，并可选择性地微调所选行为以进行额外的自适应。

本文的主要贡献是一种用于自主、部署时适应新场景的简单算法。在给定状态下，借助额外的交叉熵正则化项，ROAM 能够将每个行为的价值约束为低于该状态出现更频繁的行为的价值。因此，本文方法激励每个行为区分熟悉与不熟悉的状态，使 ROAM 能更好地识别行为何时有用。我们在仿真运动任务和真实的 Go1 四足机器人上进行了实验。在仿真中，本文方法完成部署任务的平均速度比现有方法快两倍以上，包括两种专为快速适应而设计的先前方法。我们还实证分析了 ROAM 损失函数中额外的交叉熵项如何有助于更成功地利用先验行为。此外，ROAM 使 Go1 机器人能够在现实世界中无需人工干预或监督即可实时适应各种分布外情况。借助 ROAM，机器人能够成功拉动沉重行李、拉动动态重量的负载，甚至在前脚穿着两只旱冰鞋的情况下向前滑行，尽管它在训练期间从未遇到过负载或穿过旱冰鞋。

2 相关工作

本文考虑使智能体在迁移到训练时未知的非结构化测试条件时能够鲁棒行动的问题。该问题的一个常见实例是迁移到不同的动力学环境，例如将仿真中训练的策略迁移到现实世界。在动力学偏移下实现迁移的一种流行方法是领域随机化，即在训练期间随机化动力学参数（Cutler 等，2014；Rajeswaran 等，2016；Sadeghi 和 Levine，2016；Tobin 等，2017；Peng 等，2018；Tan 等，2018；Yu 等，2019；Akkaya 等，2019；Xie 等，2021；Margolis 等，2022；Haarnoja 等，2023），以学习鲁棒策略。本文方法与之类似，也利用了训练期间不同的马尔可夫决策过程；然而，ROAM 的一个关键组成部分是利用和调节多样化的技能，而非单一的鲁棒策略。我们在第 5 节中发现，具有挑战性的测试时场景可能需要在不同时间采取不同的行为，因此我们设计的方法能够对这些异构条件保持鲁棒。

另一类方法涉及训练在动力学参数条件下表现出不同行为的策略，然后将这些策略蒸馏为可在目标域中部署的策略，其中这些信息无法直接观测。训练时的监督可以以参数值的形式提供（Yu 等人，2017；Ji 等人，2022），或以这些参数的学习表示形式提供（Lee 等人，2020；Kumar 等人，2021）。此后，先前工作探索了多种利用在线数据来实时识别适当行为的方法，例如在潜在空间中进行搜索

空间 (Yu 等人, 2019; Peng 等人, 2020; Yu 等人, 2020b), 或利用本体感受历史进行直接推断 (Lee 等人, 2020; Kumar 等人, 2021; Fu 等人, 2022), 或基于自我中心深度进行预测 (Miki 等人, 2022; Agarwal 等人, 2022; Zhuang 等人, 2023; Yang 等人, 2023)。在本文中, 我们不依赖特定领域的信息, 也不依赖外部监督来判断特定预训练行为何时有用。此外, 与上述许多工作相比, 我们专注于解决可能对所有先前行为单独而言都是分布外 (OOD) 的任务。

元强化学习 (Meta-RL) 是另一条工作线, 它通过在训练期间优化适应过程 (Wang et al., 2016; Duan et al., 2016; Finn et al., 2017; Nagabandi et al., 2018; Houthoofd et al., 2018; Rothfuss et al., 2018; Rusu et al., 2018; Mendonca et al., 2020; Song et al., 2020), 在没有特权信息的情况下实现快速适应, 以便在测试时能够快速适应新情况。元强化学习和上述基于领域随机化的方法将训练过程与数据收集纠缠在一起, 需要大量以特定方式收集的在线样本用于预训练。我们方法的关键概念差异在于, ROAM 对预训练策略和值函数的获取方式不敏感。此外, 虽然元强化学习方法通常使用数百个或更多的预训练任务, 但我们的方法即使在相对较少的预训练行为集 (例如, 第 5 节中仅 4 种不同行为就提高了性能) 下也能在新情况下提供改进。其他迁移学习方法通过快速零样本适应 (Hansen et al., 2020; Yoneda et al., 2021; Chen et al., 2022) 或通过扩展的情节在线训练 (Khetarpal et al., 2020; Rusu et al., 2016; Eysenbach et al., 2020; Xie et al., 2020; Xie & Finn, 2021) 将策略权重调整到新环境或任务。与这些工作不同, 我们专注于在单个情节内适应各种不同情况。

另一类丰富的研究工作考虑如何组合先验行为以解决长时程任务, 其中一些工作也专注于学习或发现有价值的技能 (Gregor 等, 2016; Achiam 等, 2018; Eysenbach 等, 2018; Nachum 等, 2018a; Sharma 等, 2019; Baumli 等, 2021; Laskin 等, 2022; Park 和 Levine, 2023)。这些方法中有许多涉及训练一个高层策略, 该策略学习将已学技能组合成长时程行为 (Bacon 等, 2017; Peng 等, 2019; Lee 等, 2019; Sharma 等, 2020; Strudel 等, 2020; Nachum 等, 2018b; Chitnis 等, 2020; Pertsch 等, 2021; Dalal 等, 2021; Nasiriany 等, 2022)。我们在第 5 节中表明, 这样的高层策略对于即时行为选择可能并不有效。此外, 我们的工作并不关注行为从何而来——它们可以由这些先前方法产生, 或者其奖励可以手动指定。相反, 我们专注于在分布外场景中快速选择和适应最合适的技能, 而无需额外的在线训练阶段来学习分层控制器。

3 预备知识

在本节中, 我们描述一些预备知识并形式化我们的问题陈述。我们给定一组 n 先验行为, 其中每个行为 b_i 通过对特定马尔可夫决策过程 (MDP) $\mathcal{M}_i = (\mathcal{S}, \mathcal{A}, \mathcal{P}_i, \mathcal{R}_i, \rho_0, \gamma)$ 的情景强化学习进行训练, 其中 $\mathcal{S}$ 是状态空间, $\mathcal{A}$ 是智能体的动作空间, $\mathcal{P}_i(s_{t+1}|s_t, a_t)$ 表示环境的转移动态, $\mathcal{R}_i: \mathcal{S} \rightarrow \mathbb{R}$ 表示奖励函数, $\rho_0: \mathcal{S} \rightarrow \mathbb{R}$ 表示初始状态分布, $\gamma \in [0, 1]$ 表示折扣因子。每个 n 个 MDP $\mathcal{M}_i$ 可能具有不同的动态和奖励函数 $\mathcal{P}_i$ 和 $\mathcal{R}_i$, 通常导致不同的状态访问分布。每个行为对应一个策略 π_i 和一个价值函数 V_i , 以及在此先验训练期间收集并使用目标 MDP 的奖励 $\mathcal{R}_{\text{target}}$ 重新标记的轨迹缓冲区 $\tau \in \mathcal{D}_i$ 。在测试时, 智能体与由 $\mathcal{M}_{\text{target}} = (\mathcal{S}, \mathcal{A}, \mathcal{P}_{\text{target}}, \mathcal{R}_{\text{target}}, \rho_0, \gamma)$ 定义的目标 MDP 交互, 该 MDP 呈现出任何先验 MDP 中都不存在的新颖性方面, 形式为新的动态 $\mathcal{P}_{\text{target}}(s_{t+1} | s_t, a_t)$, 可能在测试过程中发生变化。我们在单次部署设置中操作 (Chen 等人, 2022), 旨在最大化 $J = \sum_{t=0}^h \gamma^t \mathcal{R}(s_t)$, 其中 h 是试验时长, 可能为 ∞ 。智能体需要在没有额外监督或人工干预的情况下, 通过有效地选择和调整先验行为以适应手头情况, 在这个目标 MDP 中单次完成所需任务。

离策略强化学习 (RL) 算法通过贝尔曼最优算子的迭代应用来训练参数化 Q 函数, 表示为 $Q_\theta(s, a)$, 表达为

$$B^*Q(s, a) = r(s, a) + \gamma \mathbb{E}_{s' \sim P(s'|s, a)} \left[\max_{a'} Q(s', a') \right].$$

在演员-评论家框架中, 单独的策略被训练以最大化 Q 值。这些算法在策略评估和策略改进之间交替进行, 策略评估涉及贝尔曼算子 $B^\pi Q = r + \gamma P^\pi Q$, 策略改进则更新策略 $\pi(a|s)$ 以最大化期望 Q 值。我们使用最先进的离策略演员-评论家算法 RLPD (Ball 等人, 2023) 作为预训练和微调的基础算法, 该算法建立在正则化软演员-评论家 (Haarnoja 等人, 2018) 之上。




图 2: 鲁棒自主调制 (ROAM)。在 ROAM 的初始微调阶段, 我们利用每个行为现有的数据缓冲区和标准贝尔曼误差对其进行微调, 并添加一个额外的交叉熵损失, 该损失介于所有行为的 Softmax 函数值与行为索引 (作为标签) 之间, 其中行为索引表示状态被访问时所对应的行为。随后在测试时, 每个时间步, 我们从当前状态下各行为值的 Softmax 分布中采样, 并执行采样得到的策略。

4 鲁棒自主调制

本文提出鲁棒自主调制 (ROAM) 方法, 该方法通过附加损失对价值函数进行微调, 并提供了一种在多个价值函数间进行选择的机制, 使得在部署阶段, 智能体能够在每个时间步根据当前情境快速反应, 从先前行为中锁定最合适的行为。我们的核心观察是, 在适当的正则化下, 价值函数能够很好地指示不同行为的表现优劣, 因此可以利用它们快速识别合适的行为, 从而避免了学习单独元控制器或适应模块的需要。

基于价值函数的行为调制。本文方法的核心思想是直接利用价值函数 (Value Function) 的表达能力进行自适应行为选择, 因为价值函数天然包含每个行为在不同状态下潜在奖励的详细信息。本文提出利用行为的价值函数为给定状态选择最合适的行为——即在部署过程中的每个时间步, 选择在该状态下具有高价值的行为之一。由于在预训练行为时已经获得了价值函数, 该方法无需任何额外训练或数据收集。将价值函数作为代理选择器也为选择机制带来了更大的灵活性, 可以通过更新不同行为的价值函数在运行过程中灵活控制。然而, 直接使用预训练的价值函数可能无法得到高奖励的行为, 因为预训练的价值函数在新状态上可能过度估计, 且预训练的价值函数可能无法很好地泛化到分布外 (Out-of-Distribution, OOD) 情况。例如, 离线强化学习 (Offline RL) 领域的最新研究观察到, 由于训练时存在分布外动作, 价值函数存在过度估计偏差 (Levine et al., 2020), 这可能导致策略在新环境中部署时性能不佳。为缓解这些问题, 离线强化学习领域的工作提出了多种修改方案, 旨在对策略或价值函数进行正则化 (Kumar et al., 2020; Yu et al., 2020a; 2021)。尽管本文的设置有所不同, 因为处理的是分布外状态, 但面临类似的问题: 先验行为的价值函数对不熟悉情况的泛化能力较差。在下一节中, 本文将描述如何对价值函数进行保守正则化以改善其泛化能力。

使用 ROAM 微调价值函数。本文期望价值函数能够准确反映在给定状态下使用某行为所获得的期望奖励。因此, 本文希望对行为的价值函数进行微调, 以最小化在更适合其他行为的状态上的价值过度估计。可以通过激励行为的价值函数在该行为访问的状态上取值更高, 而在其他行为访问的状态上取值更低来实现。

给定一组先验行为 $\mathcal{B}$ 及其策略 π_i 和评论家 Q_i , 我们首先在贝尔曼误差之上, 通过额外的交叉熵损失对行为的价值函数进行微调, 该损失以给定状态下的值作为对数几率。给定状态下行为 b_i 的值 s 通过对 $N = 5$ 个采样动作 $a \sim \pi_i(\cdot | s)$ 的 $Q_i(s, a)$ 进行平均得到。更正式地, 对于每个先验数据缓冲区 $\mathcal{D}_i$, 我们使用以下方式微调每个行为 b_i 的评论家 $Q_i(s, a)$

更新:

$$\begin{aligned}\mathcal{L}_{\text{fine-tune}} &= (1 - \beta)\mathcal{L}_{\text{Bellman}} + \beta\mathcal{L}_{\text{交叉熵}} \\ &= (1 - \beta) \sum_i \mathbb{E}_{s,a,s' \sim \mathcal{D}_i} [(r(s,a) + \gamma \mathbb{E}_{a' \sim \pi_i(a'|s')} Q_i(s',a') - Q_i(s,a))^2] \\ &\quad + \beta \sum_j \mathbb{E}_{s \sim \mathcal{D}_j} \left[-\log \frac{\exp(V_j(s))}{\sum_{k=1}^n \exp(V_k(s))} \right],\end{aligned}\tag{1}$$

其中 $0 < \beta < 1$ 是超参数, $V_i(s) = \mathbb{E}_{a \sim \pi_i(a|s)}[Q_i(s,a)]$ 是行为 b_i 在状态 s 处的平均值, $\mathcal{D}_i$ 是由行为 b_i 收集的重放缓冲区。考虑交叉熵项关于价值函数 $V_i(s)$ 和 $V_k(s)$ 的导数, 其中 $i \neq k$, 对于 $\mathcal{D}_i$ 中的状态 s :

$$\frac{\partial \mathcal{L}_{\text{cross-entropy}}}{\partial V_i(s)} = \frac{\exp(V_i(s))}{\sum_{j=1}^n \exp(V_j(s))} - 1 < 0, \quad \frac{\partial \mathcal{L}_{\text{cross-entropy}}}{\partial V_k(s)} = \frac{\exp(V_k(s))}{\sum_{j=1}^n \exp(V_j(s))} > 0.$$

因此, 当最小化交叉熵损失时, 价值函数 $V_i(s)$ 将被推高 (因为其导数为负), 而 $k \neq i$ 的 $V_k(s)$ 将被推低。因此, 方程 1 中的交叉熵损失项会推高行为在其访问的状态上的价值函数, 并推低在其他行为访问的状态上的价值函数。价值函数在分布外状态上就不太可能高估, 从而使行为能够在状态空间的不同部分进行专门化, 这将有助于我们在测试时从当前状态更好地推断出适当的行为。

完整流程与单次生命周期部署。 总结 ROAM 的完整流程: 给定一组策略 π_i 和评论家 Q_i , 以及每个行为的一组先验数据缓冲区 $\mathcal{D}_i$, 这些缓冲区已用目标 MDP 奖励重新标记。或者, 可以放宽这一要求, 假设给定每个行为的一组先验数据缓冲区 $\mathcal{D}_i$, 我们可以使用这些缓冲区通过离线强化学习训练策略 π_i 和评论家 Q_i 。

然后, 我们通过引入方程 1 中的额外交叉熵损失项来微调行为的价值函数 $V_{i,\text{orig}}$, 得到用于行为选择的更新后的价值函数 V_i 。我们保留原始价值函数的副本, 以确保如果在测试时微调策略, 它们不会受到新学习的价值函数的影响。这防止了 ROAM 的交叉熵损失影响策略优化, 确保策略更新仅依赖于其原始训练目标。

在测试时的每个时间步, 从行为值在当前状态下的 Softmax 分布中采样一个行为 V_i 。具体而言, 给定当前状态 s , 从行为 b_i 中抽取动作 $a_i \sim \pi_i(a|s)$, 选择概率与 $\exp(V_i(s))$ 成正比。随后将转移 (s_t, a_t, r_t, s_{t+1}) 存入行为 b_i 的在线缓冲区 $\mathcal{D}_{\text{online}}^i$, 并使用来自 $\mathcal{D}_{\text{online}}^i$ 的数据对评论家 V_i 、策略 π_i 和原始值函数 $V_{i,\text{orig}}$ 进行微调 online 。重要的是, 微调后的值函数仅影响行为的选择, 不修改策略本身, 从而确保测试时自适应过程中策略优化保持无偏。

ROAM 的微调目标和单生命周期部署如图 2 所示, 完整算法总结在附录 A.2 的算法 1 和算法 2 中。在下一小节中, 我们进一步提供 ROAM 的理论分析, 以证明 ROAM 中额外的交叉熵损失将导致在每个时间步选择更合适的行为。

4.1 理论分析

接下来, 我们从理论上分析 ROAM, 以证明 ROAM 中额外的交叉熵损失将导致在每个时间步选择更合适的行为。特别地, ROAM 重新调整行为的值函数, 使其在对该行为而言分布外的状态下不太可能高估。我们的主要结果 (定理 4.1) 表明, 对于交叉熵项的某个权重 $\beta > 0$, 在给定状态下, ROAM 将每个行为的值约束为低于该状态出现更频繁的行为的值。该定理通过减少不熟悉状态下的值高估, 为我们提供了保守的泛化——具体而言, 所选行为的性能不会比最熟悉的行为更差。

该理论结果对所有局部极值均成立。在理想优化条件下, ROAM 在收敛时会达到局部最小值, 此时该结果成立。我们的分析隐含地假设了一个简化的表格型设定, 不存在近似误差和采样误差, 这与先前深度强化学习算法的理论分析 (例如 Kumar 等人 2020 年的部分分析) 一致。证明中我们采用 TD 误差的全梯度, 尽管实践中优化时仅使用半梯度。无论如何, 最优价值函数仍是 $\mathcal{L}_{\text{fine-tune}}$ 的最小值, 并且在收敛时应满足损失函数中的贝尔曼方程。我们还假设对所有状态 s 成立。本节陈述的完整证明见附录 A.1。

$$V_{\text{freq}}(s) - V_i(s) = (R_{\text{freq}}(s) + \gamma E_{s'} V_{\text{freq}}(s')) - (R_i(s) + \gamma E_{s'} V_i(s')) < \eta < \infty$$




图 3: 模拟 Go1 机器人上的结果。在两种评估设置下, ROAM 在完成任务的平均步数和中位步数上均比所有比较方法高效 2 倍以上。

定理 4.1. 令 $p_i(s)$ 表示行为 b_i 在状态 s 处的状态访问概率。对于任意状态 s , 若其对于行为 b_i 是分布外的, 而对于另一行为 b_j , i.e. $p_i(s) \ll p_j(s)$ 是分布内的, 则当 $\beta > 0$ 选择得足够大时, ROAM 学习到的行为 b_i 的价值将相对于行为 b_j , i.e. $V_i(s) \leq V_j(s)$ 的价值被上界约束。

因此, 对于任意状态 s , 若其对于行为 b_i 是分布外的, 而对于另一行为 b_j 是分布内的, 则当 β 选择得足够大时, 学习到的价值不会相对于行为 b_j 的价值产生高估。因此, 在每个时间步, 若一个或多个行为对当前状态是熟悉的, 则所选行为的性能不会比其价值函数估计差太多。通过这种方式, ROAM 根据熟悉程度调整价值估计, 从而降低高估风险。调整 β 参数的能力提供了一个灵活的框架, 用于在给定状态下优化具有最高价值的行为, 该行为至少与最熟悉的行为一样合适。

在下一节中, 我们通过实验发现, 在使用额外的交叉熵损失进行微调后, ROAM 能够有效地为给定状态实时选择相关行为, 从而实现分布外情况的鲁棒且快速的自适应。

5 实验结果

在本节中, 我们通过实验评估 ROAM 的性能, 并评估其在新情况下即时适应的有效性。具体而言, 我们旨在回答以下问题: (1) 在仿真和现实环境中, 当给定多样的先验行为/数据并部署在新情况下时, ROAM 与现有方法相比如何? (2) ROAM 损失函数中额外的交叉熵项如何有助于更成功地利用先验行为? 在本节剩余部分, 我们描述实验设置, 并展示在仿真和真实 Go1 四足机器人上的结果。定性视频结果见项目网页: <https://sites.google.com/view/adapt-on-the-go/home>。

通用实验设置。 我们使用运动部署设置来评估 ROAM, 因为这是一个具有挑战性的适应设置, 智能体可能自然面临各种不同情况, 并且必须在没有任何额外监督或人工干预的情况下即时调整其行走行为。我们使用宇树 Go1 四足机器人和 MuJoCo (Todorov 等人, 2012) 进行仿真。我们在相同的 SAC 最先进实现 (Smith 等人, 2022) 之上实现所有方法作为基础学习算法, 并按照 DroQ (Hiraoka 等人, 2021) 添加正则化, 对于进行在线微调的方法使用 RLPD (Ball 等人, 2023)。

比较。 我们将 ROAM 与以下先前方法一起评估: (1) RLPD 微调 (Ball 等人, 2023), 其中我们使用来自先验行为的所有数据通过 RLPD 微调单一策略; (2) RMA (Kumar 等人, 2021), 训练基础策略和估计环境信息的适应模块; (3) 高层分类器 (HLC), 在预训练行为的数据缓冲区上训练分类器, 并使用它在给定状态下选择使用哪个行为, 作为训练额外行为选择网络的代表性方法, 类似于 (Han 等人, 2023) 的工作。我们还考虑一个消融实验 ROAM-NoCE, 它使用先验行为的值在行为之间进行选择, 但不使用额外的交叉熵损失进行微调。我们允许 RMA 在预训练期间在每个先验 MDP 中访问无限的在线回合展开, 而所有其他方法使用相同的离线数据集和在先验 MDP 中预训练的先验行为。




图 4：单次生命周期行为选择准确率。图中展示了不同方法在当前情境下选择相关行为的步骤百分比。在适应测试时情境时，ROAM 平均能够显著更频繁地选择相关行为，优于 HLC 和 ROAM-noCE。

		Before FT	After FT
Changing Stiffness	Avg ID Values	779.2	778.7
	Avg OOD Values	746.4	542.9
Changing Frictions	Avg ID Values	1243.4	1247.6
	Avg OOD Values	1217.6	1192.8

图 5：交叉熵损失对 ID 和 OOD 值的影响。图中展示了在微调前后，ROAM 在由该行为访问的状态（ID）与其他行为访问的状态（OOD）中不同行为的平均值。ROAM 能够在 ID 状态下保持行为的高值，同时降低 OOD 状态下该行为的值。

5.1 在仿真中选择相关行为

设置。在仿真实验中，我们在两种独立设置下进行评估。第一种设置模拟机器人生命周期中不同关节损坏或卡住的情况。它使用 9 个先验行为：每个行为都是不同的跛行行为，其中不同的关节被冻结。在单次生命周期中，智能体必须行走总共 10 米的距离，每 100 步，先验数据中未涵盖的 3 个剩余关节之一被冻结，智能体必须调整其行走行为以继续行走。第二种设置模拟机器人因地形变化而在不同脚上遇到不同摩擦水平的情况。它使用 4 个不同的先验行为，每个行为都是在 4 只脚中的一只具有低摩擦的情况下训练的。在单次生命周期中，每 50 步，一只或两只脚的摩擦被改变为低于先验行为中的摩擦。为了收集先验行为，我们在相应的 MDP 中训练每个行为 250k 步（第一种设置）或 50k 步（第二种设置），并使用最后 40k 步作为先验数据。智能体最多有 10k 步来完成任务，如果在此时间内未完成任务，则视为不成功的试验。

结果。如图 3 所示，ROAM 在完成任务的平均步数和中位步数这三项指标上均优于所有其他方法。特别是在两种设置下，就平均时间步数而言，ROAM 完成任务的速度比次优方法快 2 倍以上。RLPD 微调和 RMA 在两种评估设置下均表现不佳，尤其是在刚度设置下，这表明在行为空间而非动作空间中进行自适应对于提高自适应效率至关重要。RLPD 和 RMA 在摩擦评估中表现更好，此时单一策略在单次生命周期中仍能在一定程度上适应各种情况。另一方面，HLC 和 ROAM-NoCE 在摩擦评估套件中均表现不佳，这表明损失函数中额外的交叉熵项对于鼓励状态空间不同区域中更显著的行为特化十分重要。当行为已经更加可区分时（如跛行评估套件中），这两种方法表现更好，但它们仍难以像 ROAM 那样高效地自适应。

在图 4 和图 5 中，我们提供了 ROAM 的额外实证分析。首先，在刚度评估中，我们绘制了不同方法在测试时部署期间选择相关行为的步数百分比，其中某个被固定的关节被冻结，相关行为是指同一条腿上相邻关节被冻结或相邻腿上同一关节被冻结。我们发现 ROAM 平均能够比 HLC 和 ROAM-noCE 更频繁地选择最相关的行为，而后者经常选择与当前情况无关的行为。此外，我们记录了在微调前后，使用额外交叉熵项时，ROAM 在不同行为访问的状态（ID）与其他行为访问的状态（OOD）中不同行为的平均值。我们发现 ROAM 能够有效地在熟悉状态下保持较高的行为值，同时降低在不熟悉的 OOD 状态下该行为的值。

5.2 在真实世界中即时自适应 1

设置。在 Go1 四足机器人上，我们在一个固定五种先验行为的设定下评估 ROAM：行走，以及四种不同的行为，其中每条腿都有一个关节被冻结。我们使用 (Smith 等人, 2022) 的系统，在真实世界中从头开始预训练一个基础行走行为，共 18000 步，并通过在冻结一个关节的情况下对行走行为进行额外 3000 步的微调来训练其他行为。在单次生命周期




图 6：真实世界单次生命周期任务。我们评估以下任务：（1）拉动 6.2 公斤（13.6 磅）的重型行李，（2）拉动重量在 2.36 公斤（5.2 磅）和 4.2 公斤（9.2 磅）之间动态变化的行李，以及（3）在机器人前两足穿上旱冰鞋向前移动。对于每次试验和每种方法，我们还展示了机器人在首次跌倒或调整之前的位置（红色为行走，蓝色为 HLC，紫色为 ROAM）。

	Heavy Luggage		Dynamic Luggage Load		Roller Skates	
	Avg. Time (s) ↓	Falls ↓	Avg. Time (s) ↓	Falls ↓	Avg. Time (s) ↓	Falls ↓
Walking	45.3	2.3	32	1	NC	NC
HLC	42.7	3	28.3	1.3	62.3	2.7
ROAM (ours)	25.7	0.7	24.3	0.3	27.3	1

表 1：在真实 Go1 机器人上 3 项不同任务的结果：在所有 3 项任务中，每种方法进行 3 次试验，ROAM 在平均墙钟时间（秒）和单次生命周期内完成任务所需的跌倒或调整次数方面均显著优于两种比较方法。NC（未完成）表示使用给定方法无法成功完成任务。

部署阶段，我们评估以下三项任务：（1）重型行李：机器人必须从起点线走到终点线，同时拉动一个 6.2 公斤（13.6 磅）的箱子，箱子连接在一条后腿上。（2）动态行李负载：机器人必须从起点线走到终点线，同时实时适应 2.36 公斤（5.2 磅）和 4.2 公斤（9.2 磅）之间变化的重量。我们通过在距起点相同距离处添加和移除重量来标准化每次试验。（3）旱冰鞋：我们将机器人的前两足穿上旱冰鞋，机器人必须调整其行为，滑动前腿并蹬后腿以走到终点线。我们报告每种方法 3 次试验的平均墙钟时间（秒）和单次生命周期内完成任务所需的跌倒或调整次数。任务如图 6 所示，以及每种方法每次试验中机器人在首次跌倒或调整之前的位置。

结果。尽管先前的行为均未针对这些特定的测试场景进行训练，机器人仍可利用先前行为的部分能力完成任务。如表 1 所示，在三个真实世界任务中，ROAM 在平均墙钟时间和单次生命周期内的跌倒或调整次数方面，均显著优于高层分类器（HLC）以及基线行走策略。定性来看，其他方法难以持续向前拉动行李箱，而我们的方法通常选择冻结附着行李箱的腿上的关节这一行为，因为该行为利用机器人其余三条腿更有效地向前拉动自身。其他方法在轮滑鞋任务上尤为吃力，该任务的动力学特性与典型行走截然不同，尤其依赖于选择大量使用后腿的相关行为。如图 6 所示，在三个任务中，HLC 和标准行走策略在每次单次生命周期试验中往往很早就跌倒或需要调整，而 ROAM 则更接近终点线，甚至经常在没有任何跌倒或调整的情况下完成任务。

5.3 ROAM 的实证分析

交叉熵项是一个正则化器，它使得更频繁访问给定状态的技能获得偏好。然而，这并非选择技能的唯一标准；它只是一个正则化器。如果某个技能的访问频率不是太低，即使其价值更高，也仍会被优先选择，ROAM 并非总是只选择最高频的行为。我们通过以下实验展示这一点，结果见表 2。在模拟刚度套件中，我们保留了与某一行为对应的一个缓冲区间中的大部分数据，仅留下 5k 个转移（原始为 40k），并在适合该行为的环境中评估智能体的测试时表现。我们发现，即使只有 5k 个转移（而其他所有行为均为 40k），ROAM 在大多数情况下仍会选择这个频率较低但合适的行为，从而获得相似的总体性能。

# Transitions	% Timesteps Chosen	Avg # Steps
5k	53.2	591.3
40k	78.4	573.8

表 2: ROAM 即使在访问频率较低的情况下也会选择高价值行为。我们发现，即使缓冲区小得多，因此许多状态的访问频率较低，ROAM 在遇到适合该行为的情境时仍会选择该行为。

β	Dynamic Friction		Dynamic Stiffness	
	Avg # Steps ($\downarrow$)	Frequency of Switching	Avg # Steps ($\downarrow$)	Frequency of Switching
0.01	7610 $\pm$ 854	17.20%	2698 $\pm$ 844	2.92%
0.1	2082 $\pm$ 382	15.63%	1331 $\pm$ 263	8.25%
0.5	772 $\pm$ 179	11.85%	628 $\pm$ 19	12.35%
0.9	1466 $\pm$ 534	9.36%	735 $\pm$ 54	13.36%

表 3: β 的敏感性与行为切换频率。我们发现一系列 β 值均能带来强劲性能。

接下来，我们研究 β 超参数的敏感性。我们在每个模拟套件中使用 β 的 4 个不同值 (0.01、0.1、0.5、0.9) 运行 ROAM，并在表 3 中展示性能。对于两项评估，这些值中的 3 个 (除 0.01 外) 均优于所有其他基线。

此外，ROAM 的一个优势在于能够在任意时间步在这些策略之间切换，使智能体能够适应新的和不可预见的情况，包括那些没有单一行为为最优适用的情况。然而，一个假设性的担忧可能是频繁切换行为可能导致次优性能。在表 3 中，我们测量了行为切换的频率，并试图观察行为切换频率是否与失败相关。我们发现不存在这种相关性。下面，我们展示智能体决定切换行为的时间步百分比，更频繁的切换与完成任务所需的平均步数增加并无相关性。

在测试时，ROAM 提供了使用收集的在线样本来进一步微调策略的选项。我们在模拟任务中对微调这一方面进行了额外的消融实验。在下面的表 4 中，我们发现仅进行微调 (RLPD 比较) 会导致适应速度慢得多。我们还在下表中添加了与没有低层行为微调的 ROAM (仅 ROAM 选择) 的比较，表明微调低层行为有所帮助，但效率收益的主要部分来自行为选择。因此，行为选择机制确实是快速适应的主要驱动力，但我们的框架也支持微调所选行为。

最后，在第 5 节的主要实验中，我们选择 4-9 种不同的先验行为。我们进行了一项额外实验，结合两个模拟套件中的所有行为，共 13 种，在表 5 中，我们发现对于每个套件，添加额外的无关行为并未显著损害性能，甚至可能提升性能 (如刚度评估中的情况)。

6 结论与未来工作

我们提出了鲁棒自主调制 (ROAM)，使智能体能够在部署期间快速适应变化的、分布外的情况。我们的贡献在于提供了一种有原则且高效的方式，让智能体在即时适应时利用预训练行为。在模拟和复杂的真实世界任务中，使用 Go1 四足机器人，我们的方法在适应新情况方面相比现有方法实现了超过 2 倍的效率。虽然 ROAM 在使智能体适应分布外场景方面取得了显著进展，但目前的一个局限性在于对预训练行为范围的依赖；某些场景可能相对于可用的先验行为过于分布外。未来的工作可以探索将 ROAM 集成到终身学习框架中，使智能体能够持续扩展其行为库，并提高其对更多不可预见情况的适应性。

	Dynamic Friction	Dynamic Stiffness
	Avg # Steps ($\downarrow$)	Avg # Steps ($\downarrow$)
RLPD	8089 $\pm$ 868	3797 $\pm$ 1029
ROAM (selection only)	1268 $\pm$ 334	1565 $\pm$ 339
ROAM	1018 $\pm$ 225	1199 $\pm$ 439

表 4: 行为级微调的消融研究。 ROAM 支持利用额外收集的数据对所选行为进行微调。大部分效率收益来自行为选择机制，尽管微调所选行为也能提升性能。

	Dynamic Friction	Dynamic Stiffness
	Avg # Steps ($\downarrow$)	Avg # Steps ($\downarrow$)
ROAM (original, selected skills)	1018 $\pm$ 225	1199 $\pm$ 439
ROAM (all skills)	1141 $\pm$ 115	871 $\pm$ 137

表 5: ROAM 与不相关行为。 向先验行为集中添加不相关行为不会显著损害性能，有时甚至会提升性能，如刚度评估所示。

参考文献

- Joshua Achiam, Harrison Edwards, Dario Amodei, and Pieter Abbeel. Variational option discovery algorithms. *arXiv preprint arXiv:1807.10299*, 2018.
- Ananye Agarwal, Ashish Kumar, Jitendra Malik, and Deepak Pathak. Legged locomotion in challenging terrains using egocentric vision. In *Conference on Robot Learning*, 2022.
- Ilge Akkaya, Marcin Andrychowicz, Maciek Chociej, Mateusz Litwin, Bob McGrew, Arthur Petron, Alex Paino, Matthias Plappert, Glenn Powell, Raphael Ribas, et al. Solving rubik’s cube with a robot hand. *arXiv preprint arXiv:1910.07113*, 2019.
- Pierre-Luc Bacon, Jean Harb, and Doina Precup. The option-critic architecture. In *Proceedings of the AAAI conference on artificial intelligence*, volume 31, 2017.
- Philip J Ball, Laura Smith, Ilya Kostrikov, and Sergey Levine. Efficient online reinforcement learning with offline data. *arXiv preprint arXiv:2302.02948*, 2023.
- Kate Baumli, David Warde-Farley, Steven Hansen, and Volodymyr Mnih. Relative variational intrinsic control. In *Proceedings of the AAAI conference on artificial intelligence*, volume 35, pp. 6732–6740, 2021.
- Annie Chen, Archit Sharma, Sergey Levine, and Chelsea Finn. You only live once: Single-life reinforcement learning. *Advances in Neural Information Processing Systems*, 35:14784–14797, 2022.
- Rohan Chitnis, Shubham Tulsiani, Saurabh Gupta, and Abhinav Gupta. Efficient bimanual manipulation using learned task schemas. In *2020 IEEE International Conference on Robotics and Automation (ICRA)*, pp. 1149–1155. IEEE, 2020.
- Antoine Cully, Jeff Clune, Danesh Tarapore, and Jean-Baptiste Mouret. Robots that can adapt like animals. *Nature*, 521(7553):503–507, 2015.
- Mark Cutler, Thomas J Walsh, and Jonathan P How. Reinforcement learning with multi-fidelity simulators. In *2014 IEEE International Conference on Robotics and Automation (ICRA)*, pp. 3888–3895. IEEE, 2014.
- Murtaza Dalal, Deepak Pathak, and Russ R Salakhutdinov. Accelerating robotic reinforcement learning via parameterized action primitives. *Advances in Neural Information Processing Systems*, 34:21847–21859, 2021.
- Yan Duan, John Schulman, Xi Chen, Peter L Bartlett, Ilya Sutskever, and Pieter Abbeel. RI^2 : Fast reinforcement learning via slow reinforcement learning. *arXiv preprint arXiv:1611.02779*, 2016.
- Benjamin Eysenbach, Abhishek Gupta, Julian Ibarz, and Sergey Levine. Diversity is all you need: Learning skills without a reward function. *arXiv preprint arXiv:1802.06070*, 2018.

- Benjamin Eysenbach, Swapnil Asawa, Shreyas Chaudhari, Sergey Levine, and Ruslan Salakhutdinov. Off-dynamics reinforcement learning: Training for transfer with domain classifiers. *arXiv preprint arXiv:2006.13916*, 2020.
- Chelsea Finn, Pieter Abbeel, and Sergey Levine. Model-agnostic meta-learning for fast adaptation of deep networks. In *International conference on machine learning*, pp. 1126–1135. PMLR, 2017.
- Zipeng Fu, Xuxin Cheng, and Deepak Pathak. Deep whole-body control: learning a unified policy for manipulation and locomotion. In *Conference on Robot Learning*, 2022.
- Karol Gregor, Danilo Jimenez Rezende, and Daan Wierstra. Variational intrinsic control. *arXiv preprint arXiv:1611.07507*, 2016.
- Tuomas Haarnoja, Aurick Zhou, Pieter Abbeel, and Sergey Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *International conference on machine learning*, pp. 1861–1870. PMLR, 2018.
- Tuomas Haarnoja, Ben Moran, Guy Lever, Sandy H Huang, Dhruva Tirumala, Markus Wulfmeier, Jan Humplik, Saran Tunyasuvunakool, Noah Y Siegel, Roland Hafner, et al. Learning agile soccer skills for a bipedal robot with deep reinforcement learning. *arXiv preprint arXiv:2304.13653*, 2023.
- Lei Han, Qingxu Zhu, Jiapeng Sheng, Chong Zhang, Tingguang Li, Yizheng Zhang, He Zhang, Yuzhen Liu, Cheng Zhou, Rui Zhao, et al. Lifelike agility and play on quadrupedal robots using reinforcement learning and generative pre-trained models. *arXiv preprint arXiv:2308.15143*, 2023.
- Nicklas Hansen, Rishabh Jangir, Yu Sun, Guillem Alenyà, Pieter Abbeel, Alexei A Efros, Lerrel Pinto, and Xiaolong Wang. Self-supervised policy adaptation during deployment. *arXiv preprint arXiv:2007.04309*, 2020.
- Takuya Hiraoka, Takahisa Imagawa, Taisei Hashimoto, Takashi Onishi, and Yoshimasa Tsuruoka. Dropout q-functions for doubly efficient reinforcement learning. *arXiv preprint arXiv:2110.02034*, 2021.
- Rein Houthooft, Yuhua Chen, Phillip Isola, Bradly Stadie, Filip Wolski, OpenAI Jonathan Ho, and Pieter Abbeel. Evolved policy gradients. *Advances in Neural Information Processing Systems*, 31, 2018.
- Gwanghyeon Ji, Juhyeok Mun, Hyeongjun Kim, and Jemin Hwangbo. Concurrent training of a control policy and a state estimator for dynamic and robust legged locomotion. *IEEE Robotics and Automation Letters*, 2022.
- Ryan Julian, Benjamin Swanson, Gaurav Sukhatme, Sergey Levine, Chelsea Finn, and Karol Hausman. Never stop learning: The effectiveness of fine-tuning in robotic reinforcement learning. 2020. URL <https://arxiv.org/abs/2004.10190>.
- Khimya Khetarpal, Matthew Riemer, Irina Rish, and Doina Precup. Towards continual reinforcement learning: A review and perspectives. *arXiv preprint arXiv:2012.13490*, 2020.
- Ashish Kumar, Zipeng Fu, Deepak Pathak, and Jitendra Malik. Rma: Rapid motor adaptation for legged robots. *arXiv preprint arXiv:2107.04034*, 2021.
- Aviral Kumar, Aurick Zhou, George Tucker, and Sergey Levine. Conservative q-learning for offline reinforcement learning. *Advances in Neural Information Processing Systems*, 33:1179–1191, 2020.
- Michael Laskin, Hao Liu, Xue Bin Peng, Denis Yarats, Aravind Rajeswaran, and Pieter Abbeel. Cic: Contrastive intrinsic control for unsupervised skill discovery. *arXiv preprint arXiv:2202.00161*, 2022.
- Joonho Lee, Jemin Hwangbo, Lorenz Wellhausen, Vladlen Koltun, and Marco Hutter. Learning quadrupedal locomotion over challenging terrain. *Science robotics*, 5(47):eabc5986, 2020.
- Youngwoon Lee, Jingyun Yang, and Joseph J Lim. Learning to coordinate manipulation skills via skill behavior diversification. In *International conference on learning representations*, 2019.
- Sergey Levine, Aviral Kumar, George Tucker, and Justin Fu. Offline reinforcement learning: Tutorial, review, and perspectives on open problems. *arXiv preprint arXiv:2005.01643*, 2020.
- Gabriel B Margolis, Ge Yang, Kartik Paigwar, Tao Chen, and Pulkit Agrawal. Rapid locomotion via reinforcement learning. *arXiv preprint arXiv:2205.02824*, 2022.

- Russell Mendonca, Xinyang Geng, Chelsea Finn, and Sergey Levine. Meta-reinforcement learning robust to distributional shift via model identification and experience relabeling. *arXiv preprint arXiv:2006.07178*, 2020.
- Takahiro Miki, Joonho Lee, Jemin Hwangbo, Lorenz Wellhausen, Vladlen Koltun, and Marco Hutter. Learning robust perceptive locomotion for quadrupedal robots in the wild. *Science Robotics*, 2022.
- Ofir Nachum, Shixiang Gu, Honglak Lee, and Sergey Levine. Near-optimal representation learning for hierarchical reinforcement learning. *arXiv preprint arXiv:1810.01257*, 2018a.
- Ofir Nachum, Shixiang Shane Gu, Honglak Lee, and Sergey Levine. Data-efficient hierarchical reinforcement learning. *Advances in neural information processing systems*, 31, 2018b.
- Anusha Nagabandi, Ignasi Clavera, Simin Liu, Ronald S Fearing, Pieter Abbeel, Sergey Levine, and Chelsea Finn. Learning to adapt in dynamic, real-world environments through meta-reinforcement learning. *arXiv preprint arXiv:1803.11347*, 2018.
- Soroush Nasiriany, Huihan Liu, and Yuke Zhu. Augmenting reinforcement learning with behavior primitives for diverse manipulation tasks. In *2022 International Conference on Robotics and Automation (ICRA)*, pp. 7477–7484. IEEE, 2022.
- Seohong Park and Sergey Levine. Predictable mdp abstraction for unsupervised model-based rl. *arXiv preprint arXiv:2302.03921*, 2023.
- Xue Bin Peng, Marcin Andrychowicz, Wojciech Zaremba, and Pieter Abbeel. Sim-to-real transfer of robotic control with dynamics randomization. In *2018 IEEE international conference on robotics and automation (ICRA)*, pp. 3803–3810. IEEE, 2018.
- Xue Bin Peng, Michael Chang, Grace Zhang, Pieter Abbeel, and Sergey Levine. Mdp: Learning composable hierarchical control with multiplicative compositional policies. *Advances in Neural Information Processing Systems*, 32, 2019.
- Xue Bin Peng, Erwin Coumans, Tingnan Zhang, Tsang-Wei Lee, Jie Tan, and Sergey Levine. Learning agile robotic locomotion skills by imitating animals. *arXiv preprint arXiv:2004.00784*, 2020.
- Karl Pertsch, Youngwoon Lee, Yue Wu, and Joseph J Lim. Guided reinforcement learning with learned skills. *arXiv preprint arXiv:2107.10253*, 2021.
- Aravind Rajeswaran, Sarvjeet Ghotra, Balaraman Ravindran, and Sergey Levine. Epopt: Learning robust neural network policies using model ensembles. *arXiv preprint arXiv:1610.01283*, 2016.
- Jonas Rothfuss, Dennis Lee, Ignasi Clavera, Tamim Asfour, and Pieter Abbeel. Prompt: Proximal meta-policy search. *arXiv preprint arXiv:1810.06784*, 2018.
- Andrei A Rusu, Neil C Rabinowitz, Guillaume Desjardins, Hubert Soyer, James Kirkpatrick, Koray Kavukcuoglu, Razvan Pascanu, and Raia Hadsell. Progressive neural networks. *arXiv preprint arXiv:1606.04671*, 2016.
- Andrei A Rusu, Dushyant Rao, Jakub Sygnowski, Oriol Vinyals, Razvan Pascanu, Simon Osindero, and Raia Hadsell. Meta-learning with latent embedding optimization. *arXiv preprint arXiv:1807.05960*, 2018.
- Fereshteh Sadeghi and Sergey Levine. Cad2rl: Real single-image flight without a single real image. *arXiv preprint arXiv:1611.04201*, 2016.
- Archit Sharma, Shixiang Gu, Sergey Levine, Vikash Kumar, and Karol Hausman. Dynamics-aware unsupervised discovery of skills. *arXiv preprint arXiv:1907.01657*, 2019.
- Mohit Sharma, Jacky Liang, Jialiang Zhao, Alex LaGrassa, and Oliver Kroemer. Learning to compose hierarchical object-centric controllers for robotic manipulation. *arXiv preprint arXiv:2011.04627*, 2020.
- Laura Smith, Ilya Kostrikov, and Sergey Levine. A walk in the park: Learning to walk in 20 minutes with model-free reinforcement learning. *arXiv preprint arXiv:2208.07860*, 2022.
- Xingyou Song, Yuxiang Yang, Krzysztof Choromanski, Ken Caluwaerts, Wenbo Gao, Chelsea Finn, and Jie Tan. Rapidly adaptable legged robots via evolutionary meta-learning. In *2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pp. 3769–3776. IEEE, 2020.

- Robin Strudel, Alexander Pashevich, Igor Kalevatykh, Ivan Laptev, Josef Sivic, and Cordelia Schmid. Learning to combine primitive skills: A step towards versatile robotic manipulation. In *2020 IEEE International Conference on Robotics and Automation (ICRA)*, pp. 4637–4643. IEEE, 2020.
- Jie Tan, Tingnan Zhang, Erwin Coumans, Atil Iscen, Yunfei Bai, Danijar Hafner, Steven Bohez, and Vincent Vanhoucke. Sim-to-real: Learning agile locomotion for quadruped robots. *arXiv preprint arXiv:1804.10332*, 2018.
- Josh Tobin, Rachel Fong, Alex Ray, Jonas Schneider, Wojciech Zaremba, and Pieter Abbeel. Domain randomization for transferring deep neural networks from simulation to the real world. In *2017 IEEE/RSJ international conference on intelligent robots and systems (IROS)*, pp. 23–30. IEEE, 2017.
- Emanuel Todorov, Tom Erez, and Yuval Tassa. Mujoco: A physics engine for model-based control. In *2012 IEEE/RSJ international conference on intelligent robots and systems*, pp. 5026–5033. IEEE, 2012.
- Saran Tunyasuvunakool, Alistair Muldal, Yotam Doron, Siqi Liu, Steven Bohez, Josh Merel, Tom Erez, Timothy Lillicrap, Nicolas Heess, and Yuval Tassa. dm_control: Software and tasks for continuous control. *Software Impacts*, 6:100022, 2020.
- Jane X Wang, Zeb Kurth-Nelson, Dhruva Tirumala, Hubert Soyer, Joel Z Leibo, Remi Munos, Charles Blundell, Dharshan Kumaran, and Matt Botvinick. Learning to reinforcement learn. *arXiv preprint arXiv:1611.05763*, 2016.
- Annie Xie and Chelsea Finn. Lifelong robotic reinforcement learning by retaining experiences. *arXiv preprint arXiv:2109.09180*, 2021.
- Annie Xie, James Harrison, and Chelsea Finn. Deep reinforcement learning amidst lifelong non-stationarity. *arXiv preprint arXiv:2006.10701*, 2020.
- Zhaoming Xie, Xingye Da, Michiel Van de Panne, Buck Babich, and Animesh Garg. Dynamics randomization revisited: A case study for quadrupedal locomotion. In *2021 IEEE International Conference on Robotics and Automation (ICRA)*, pp. 4955–4961. IEEE, 2021.
- Ruihan Yang, Ge Yang, and Xiaolong Wang. Neural volumetric memory for visual locomotion control. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2023.
- Takuma Yoneda, Ge Yang, Matthew R Walter, and Bradly Stadie. Invariance through inference. *arXiv preprint arXiv:2112.08526*, 2021.
- Tianhe Yu, Garrett Thomas, Lantao Yu, Stefano Ermon, James Y Zou, Sergey Levine, Chelsea Finn, and Tengyu Ma. Mopo: Model-based offline policy optimization. *Advances in Neural Information Processing Systems*, 33: 14129–14142, 2020a.
- Tianhe Yu, Aviral Kumar, Rafael Rafailov, Aravind Rajeswaran, Sergey Levine, and Chelsea Finn. Combo: Conservative offline model-based policy optimization. *Advances in neural information processing systems*, 34:28954–28967, 2021.
- Wenhao Yu, Jie Tan, C Karen Liu, and Greg Turk. Preparing for the unknown: Learning a universal policy with online system identification. *RSS*, 2017.
- Wenhao Yu, Visak CV Kumar, Greg Turk, and C Karen Liu. Sim-to-real transfer for biped locomotion. In *2019 IEEE/RSJ international conference on intelligent robots and systems (IROS)*, pp. 3503–3510. IEEE, 2019.
- Wenhao Yu, Jie Tan, Yunfei Bai, Erwin Coumans, and Sehoon Ha. Learning fast adaptation with meta strategy optimization. *IEEE Robotics and Automation Letters*, 2020b.
- Ziwen Zhuang, Zipeng Fu, Jianren Wang, Christopher G Atkeson, Sören Schwertfeger, Chelsea Finn, and Hang Zhao. Robot parkour learning. In *7th Annual Conference on Robot Learning*, 2023.

A 附录

A.1 理论分析

我们给出以下定理的证明，该定理在第 4 节中讨论。

定理 A.1。设 $p_i(s)$ 表示行为 b_i 在状态 s 下的状态访问概率。对于任何对行为 b_i 而言分布外、但对另一行为 b_j , i.e. $p_i(s) \ll p_j(s)$ 而言分布内的状态 s ，如果 $1 > \beta > 0$ 被选择得足够大，那么由 ROAM 学习到的行为 b_i 的值将相对于行为 b_j , i.e. $V_i(s) \leq V_j(s)$ 的值有上界。

证明：我们优化以下损失函数：

$$\mathcal{L}_{\text{fine-tune}} = (1 - \beta) \sum_i \sum_{s \sim \mathcal{D}_i} p_i(s) \left[(R_i(s) + \gamma \mathbb{E}_{s'} V_i(s') - V_i(s))^2 \right] + \beta \sum_j \sum_{s \sim \mathcal{D}_j} p_j(s) \left[-V_j(s) + \log \sum_{k=1}^n \exp(V_k(s)) \right].$$

对 $V_i(s)$ 求导，得到：

$$\begin{aligned} \frac{\partial \mathcal{L}_{\text{fine-tune}}}{\partial V_i(s)} &= 2(1 - \beta) p_i(s) (\gamma P_i(s|s, a) - 1) (R_i(s) + \gamma \mathbb{E}_{s'} V_i(s') - V_i(s)) \\ &\quad + \beta \left[p_i(s) \left(-1 + \frac{\exp(V_i(s))}{\sum_{k=1}^n \exp(V_k(s))} \right) + \sum_{j \neq i} p_j(s) \frac{\exp(V_i(s))}{\sum_{k=1}^n \exp(V_k(s))} \right] \\ &= 2(1 - \beta) p_i(s) (\gamma P_i(s|s, a) - 1) (R_i(s) + \gamma \mathbb{E}_{s'} V_i(s') - V_i(s)) + \beta \left[-p_i(s) + \sum_j p_j(s) \frac{\exp(V_i(s))}{\sum_{k=1}^n \exp(V_k(s))} \right]. \end{aligned}$$

令其等于 0，我们得到任意收敛点的如下特征：

$$\begin{aligned} V_i(s) &= (R_i(s) + \gamma \mathbb{E}_{s'} V_i(s')) + \frac{\beta}{2(1 - \beta) p_i(s) (\gamma P_i(s|s, a) - 1)} \left[-p_i(s) + \sum_j p_j(s) \frac{\exp(V_i(s))}{\sum_{k=1}^n \exp(V_k(s))} \right] \\ &= (R_i(s) + \gamma \mathbb{E}_{s'} V_i(s')) + \frac{\beta}{2(1 - \beta)(1 - \gamma P_i(s|s, a))} \left[1 - \sum_j \frac{p_j(s)}{p_i(s)} \frac{\exp(V_i(s))}{\sum_{k=1}^n \exp(V_k(s))} \right]. \end{aligned}$$

考虑一个状态 s ，其中对于某 $p_i(s)$ 个行为 $b_{\text{freq}} \neq b_i$ 有 $p_{\text{freq}}(s) \gg p_i(s)$ 。我们想要 $V_{\text{freq}}(s) > V_i(s)$ will dominate in the last term, so 证明在这样的状态下。则 $p_{\text{freq}}(s)$

$$\sum_j \frac{p_j(s)}{p_i(s)} \frac{\exp(V_i(s))}{\sum_{k=1}^n \exp(V_k(s))} \gg 1. \quad (2)$$

然后比较 $V_i(s)$ 和 $V_{\text{freq}}(s)$ 的收敛点值，我们得到

$$\begin{aligned} V_{\text{freq}}(s) - V_i(s) &= (R_{\text{freq}}(s) + \gamma \mathbb{E}_{s'} V_{\text{freq}}(s')) + \frac{\beta}{2(1 - \beta)(1 - \gamma P_{\text{freq}}(s|s, a))} \left[1 - \sum_j \frac{p_j(s)}{p_{\text{freq}}(s)} \frac{\exp(V_{\text{freq}}(s))}{\sum_{k=1}^n \exp(V_k(s))} \right] \\ &\quad - \left[(R_i(s) + \gamma \mathbb{E}_{s'} V_i(s')) + \frac{\beta}{2(1 - \beta)(1 - \gamma P_i(s|s, a))} \left[1 - \sum_j \frac{p_j(s)}{p_i(s)} \frac{\exp(V_i(s))}{\sum_{k=1}^n \exp(V_k(s))} \right] \right] \\ &= ((R_{\text{freq}}(s) + \gamma \mathbb{E}_{s'} V_{\text{freq}}(s')) - (R_i(s) + \gamma \mathbb{E}_{s'} V_i(s'))) \\ &\quad + \frac{\beta}{1 - \beta} \left(C_{\text{freq}} \left[1 - \sum_j \frac{p_j(s)}{p_{\text{freq}}(s)} \frac{\exp(V_{\text{freq}}(s))}{\sum_{k=1}^n \exp(V_k(s))} \right] - C_i \left[1 - \sum_j \frac{p_j(s)}{p_i(s)} \frac{\exp(V_i(s))}{\sum_{k=1}^n \exp(V_k(s))} \right] \right), \end{aligned}$$

其中 $C_{\text{freq}} = \frac{1}{2(1-\gamma P_{\text{freq}}(s|s,a))} > 0$ 和 $C_i = \frac{1}{2(1-\gamma P_i(s|s,a))} > 0$. 因此, 利用方程 2, 因为

$$1 - \sum_j \frac{p_j(s)}{p_i(s)} \frac{\exp(V_i(s))}{\sum_{k=1}^n \exp(V_k(s))} < 0,$$

该术语

$$\left(C_{\text{freq}} \left[1 - \sum_j \frac{p_j(s)}{p_{\text{freq}}(s)} \frac{\exp(V_{\text{freq}}(s))}{\sum_{k=1}^n \exp(V_k(s))} \right] - C_i \left[1 - \sum_j \frac{p_j(s)}{p_i(s)} \frac{\exp(V_i(s))}{\sum_{k=1}^n \exp(V_k(s))} \right] \right) > 0.$$

Hence, for some $0 < \beta < 1$, we have

$$V_{\text{freq}}(s) - V_i(s) = ((R_{\text{freq}}(s) + \gamma \mathbb{E}_{s'} V_{\text{freq}}(s')) - (R_i(s) + \gamma \mathbb{E}_{s'} V_i(s'))) + \frac{\beta}{1-\beta} \left(C_{\text{freq}} \left[1 - \sum_j \frac{p_j(s)}{p_{\text{freq}}(s)} \frac{\exp(V_{\text{freq}}(s))}{\sum_{k=1}^n \exp(V_k(s))} \right] - C_i \left[1 - \sum_j \frac{p_j(s)}{p_i(s)} \frac{\exp(V_i(s))}{\sum_{k=1}^n \exp(V_k(s))} \right] \right) > 0.$$

因此, 对于某些 $0 < \beta < 1$, 我们有 $V_i(s) < V_{\text{freq}}(s)$ 。

□

To illustrate the effect of the cross-entropy loss, consider the following example of choosing between two behaviors i and j at state s , where the true values $V_i^{\text{true}}(s) < V_j^{\text{true}}(s)$. The optimal choice is to choose behavior b_j and for sake of this example let us choose behavior b_j if $V_i^{\text{ROAM}}(s) < V_j^{\text{ROAM}}(s)$. There are the following four cases: (1) $p_i(s) < p_j(s)$ and the initial estimated $V_i(s) < V_j(s)$. Then with any $\beta > 0$, the final $V_i^{\text{ROAM}}(s) < V_j^{\text{ROAM}}(s)$; (2) $p_i(s) < p_j(s)$ and the initial estimated $V_i(s) > V_j(s)$. Then by Theorem A.1, with large enough $\beta > 0$, the final $V_i^{\text{ROAM}}(s) < V_j^{\text{ROAM}}(s)$; (3) $p_i(s) > p_j(s)$ and the initial estimated $V_i(s) < V_j(s)$. Then as long as β is chosen to be not too large, the final $V_i^{\text{ROAM}}(s) < V_j^{\text{ROAM}}(s)$. (4) $p_i(s) > p_j(s)$ and the initial estimated $V_i(s) > V_j(s)$. This is the only case where ROAM may not be adjusted to work well, but this case poses a difficult situation for any behavior selection method.

A.2 算法总结

我们在算法 1 和算法 2 中总结了 ROAM。

Algorithm 1 ROAM FINE-TUNING

```

1: Require:  $\mathcal{D}_i$ , pre-trained critics  $Q_{i,\text{orig}}$ 
2: while not converged do
3:   for all  $i$  in  $1, \dots, N_{\text{behaviors}}$  do
4:     Sample  $(s, a, s', r_{\text{target}}) \sim \mathcal{D}_i$ 
5:     Update  $Q_i$  according to Eq. 1
6:   end for
7: end while
8: return  $Q_1, \dots, Q_{N_{\text{behaviors}}}$ 
    
```

Algorithm 2 ROAM SINGLE-LIFE DEPLOYMENT

```

1: Require: Test MDP  $\mathcal{M}_{\text{test}}$ ,  $\mathcal{D}_i$ , policies  $\pi_i$  and fine-tuned critics  $Q_i$ ;
2: Initialize: online replay buffers  $\mathcal{D}_{\text{online}}^i$ ; timestep  $t = 0$ 
3: while task not complete do
4:   Compute values of each behavior  $\{V_i(s_t)\}_1^{N_{\text{behaviors}}}$ 
5:   Sample behavior  $b^*$  according to the distribution  $\text{softmax}(\exp(V_i(s_t)))$ .
6:   Take action  $a_t \sim \pi_{b^*}(a_t|s_t)$ .
7:    $\mathcal{D}_{\text{online}}^{b^*} \leftarrow \mathcal{D}_{\text{online}}^{b^*} \cup \{(s_t, a_t, r_t, s_{t+1})\}$ 
8:    $Q_{b^*,\text{orig}}(s, a), \pi_{b^*} \leftarrow \text{RL}(Q_{b^*,\text{orig}}(s, a), \pi_{b^*}, \mathcal{D}_{\text{online}}^{b^*})$ 
9:   Increment  $t$ 
10: end while
    
```

A.3 通用实验设置细节

按照基于学习的四足运动研究中的常见做法, 我们将动作定义为 12 个关节的 PD 位置目标, 并使用 20 Hz 的控制频率。动作以标称姿态为中心, 即 0 表示站立。下面我们描述仿真和真实世界实验中的观测。

我们首先详细说明用于定义四足行走任务的奖励函数。首先, 我们有一个速度跟踪项, 定义如下:

$$r_v(s, a) = 1 - \left| \frac{v_x - v_t}{v_t} \right|^{1.6}$$

其中 v_t 是目标速度， v_x 是机器人投影到地面平面的局部前向线速度，即 $v_x = v_{\text{local}} \cdot \cos(\phi)$ ，其中 ϕ 是根身体的俯仰角。然后我们有一个项 $r_{ori}(s, a)$ ，鼓励机器人保持直立。具体来说，我们计算机器人身体垂直向量与重力向量 $([0, 0, 1])$ 之间的余弦距离。然后我们将该项归一化到 0 和 1 之间：

$$r_{ori}(s, a) = (0.5 \cdot \text{dist} + 0.5)^2$$

其中 dist 是如上所述的余弦距离。我们将 r_v 和 r_{ori} 相乘，以便根据机器人保持直立的程度按比例给予速度跟踪奖励。然后我们有一个正则化项 r_{qpos} ，以偏好接近机器人标称站立姿态的解。该正则化项按每个关节的归一化项的乘积计算。下面， $\hat{q}^j$ 表示标称姿态关节 j 的局部旋转， q^j 表示机器人的关节，

$$r^{qpos} = 1 - \prod_j \text{q 距离}(\hat{q}^j, q^j)$$

其中 q 距离 在 0 和 1 之间，并以二次方式衰减，直到达到机器人动作极限的阈值。具体来说，我们遵循 (Tunyasuvunakool 等人, 2020) 提出的奖励结构。这些项在最终奖励中占据绝大多数权重。我们还包括避免不良行为（如摇晃或摆动）的项，这些项惩罚根身体横滚、俯仰和偏航中的任何角速度。我们还轻微惩罚能量消耗和扭矩平滑度。为了特别鼓励行走步态，我们添加了另一个正则化项，以鼓励对角肩关节和髋关节在任何给定时刻相同。

A.4 实现细节和超参数

我们在相同的先进 SAC 实现 (Smith 等人, 2022) 之上实现了所有方法，包括 ROAM、RMA 和 HLC，作为基础学习方法。对于所有比较，我们还使用高 UTD 比率、随机失活和层归一化，遵循 DroQ (Hiraoka 等人, 2021)，对于进行在线微调的方法，我们使用 50/50 采样，遵循 RLPD (Ball 等人, 2023)。我们使用默认超参数值：学习率为 3×10^{-4} ，在线批大小为 128，折扣因子为 0.99。策略和评论家网络是具有 2 个隐藏层（每层 256 个单元）和 ReLU 激活的 MLP。对于 ROAM，我们调整了 β ，值为 0.01、0.1、0.5、0.9。

模拟实验。在仿真实验中，状态空间由关节位置、关节速度、力矩、惯性测量单元 (IMU) 数据（横滚角、俯仰角、横滚角变化量、俯仰角变化量）以及归一化足部力组成，共计 44 维。对于位置控制器，我们分别采用 K_p 和 K_d 增益为 40 和 5，并以 500Hz 的频率对从当前关节角到期望关节角进行线性插值来计算力矩。我们将动作空间的界限定义为物理关节极限的 30%。

表 6: 仿真奖励函数参数详情

Parameter	Value
Target Velocity	1.0
Energy Penalty Weight	0.008
Qpos Penalty Weight	10.0
Smooth Torque Penalty Weight	0.005
Pitch Rate Penalty Factor	0.6
Roll Rate Penalty Factor	0.6
Joint Diagonal Penalty Weight	0.1
Joint Shoulder Penalty Weight	0.15
Smooth Change in Target Delta Yaw Steps	5

在第一种实验设置中，我们在 9 个不同的单关节上训练具有高刚度（10.0）的先验行为策略。具体而言，我们使用右前身体关节、右前膝关节、左前身体关节、左前膝关节、右后身体关节、右后膝关节、左后身体关节、左后大腿关节和左后膝关节。在部署过程中，我们每 100 步在 3 种条件之间切换。条件 1 是对右后大腿关节施加刚度 15.0，条件 2 是对左前大腿关节施加刚度 15.0，条件 3 是对右前大腿关节施加刚度 15.0。对于此设置，我们为 ROAM 使用 $\beta = 0.5$ 。

在第二种实验设置中，我们在 4 只脚上分别训练具有低足部摩擦（0.4）的先验行为策略。在部署过程中，我们每 50 步在 2 种条件之间切换。条件 1 是对右后脚施加足部摩擦 0.1，条件 2 是对左前脚施加足部摩擦 0.01，并对右后脚施加足部摩擦 0.1。对于此设置，我们为 ROAM 使用 $\beta = 0.5$ 。

真实世界实验。在真实世界实验中，状态空间由关节位置、关节速度、力矩、前向线速度、惯性测量单元（IMU）（横滚、俯仰、横滚变化、俯仰变化）以及归一化足部力组成，共计 47 维。我们使用基于英特尔 T265 相机的速度估计器来估计机载线速度。我们分别使用 K_p 和 K_d 增益 20 和 1，这些增益用于位置控制器。我们再次使用动作插值、动作范围为物理极限的 35% 以及 1 步动作历史。我们还使用二阶巴特沃斯低通滤波器，其高截止值为 8，以平滑位置目标。最后，为了重置机器人，我们使用（Smith 等人，2022）提供的重置策略。我们为真实世界实验训练了 4 个先验行为策略，每个策略都在冻结膝关节的情况下训练。具体来说，我们训练了冻结前右膝关节、冻结前左膝关节、冻结后右膝关节和冻结后左膝关节的策略。 $\beta = 0.5$ 用于所有真实世界实验中的 ROAM。

表 7: 真实世界奖励函数参数详情

Parameter	Value
Target Velocity	1.5
Energy Penalty Weight	0.0
Qpos Penalty Weight	2.0
Smooth Torque Penalty Weight	0.005
Pitch Rate Penalty Factor	0.4
Roll Rate Penalty Factor	0.2
Joint Diagonal Penalty Weight	0.03
Joint Shoulder Penalty Weight	0.0
Smooth Change in Target Delta Yaw Steps	1

高层控制器（HLC）详情。对于 HLC，我们有一个多层感知机（MLP），它以状态为输入，并输出在给定状态下选择哪个行为。该 MLP 有 3 个隐藏层，每层 256 个单元，使用修正线性单元（ReLU）激活函数，我们通过从所有先验行为的组合离线数据中采样进行训练。我们使用批大小 256，学习率 3×10^{-4} ，并训练 3,000 次迭代。

快速运动适应（RMA）详情。对于 RMA 训练，我们在每个回合之间改变环境动力学，并总共训练 2,000,000 次迭代。使用了（Kumar 等人，2021）的标准架构和超参数选择，并以 DroQ（Hiraoka 等人，2021）作为基础算法。