

RoboMonkey: 面向视觉-语言-动作模型的测试时采样与验证扩展

Jacky Kwok¹ Christopher Agia^{1,†} Rohan Sinha^{1,†} Matt Foutter^{1,†}
Shulu Li² Ion Stoica² Azalia Mirhoseini¹ Marco Pavone^{1,3}

¹Stanford University ²UC Berkeley ³NVIDIA Research

<https://robomonkey-vla.github.io>

摘要: 视觉-语言-动作 (VLA) 模型在视觉运动控制中展现出卓越能力, 然而确保其在非结构化真实环境中的鲁棒性仍是一项持续挑战。本文从采样与验证的视角研究测试时扩展, 以增强 VLA 的鲁棒性与泛化能力。我们首先证明, 在一系列 VLA 中, 动作误差与生成样本数量之间的关系遵循指数幂律, 表明推理时缩放定律的存在。基于这些洞见, 我们提出 RoboMonkey, 一个面向 VLA 的测试时扩展框架。部署时, RoboMonkey 从 VLA 中采样少量动作, 施加高斯扰动与多数投票以构建动作提议分布, 随后利用基于视觉语言模型 (VLM) 的验证器选择最优动作。我们提出一种合成数据生成流程, 用于训练此类基于 VLM 的动作验证器, 并证明扩展合成数据集能持续提升验证与下游准确率。通过大量仿真与硬件实验, 我们表明将现有 VLA 与 RoboMonkey 结合可带来显著性能提升, 在分布外任务上实现 25% 的绝对提升, 在分布内任务上实现 9% 的提升。此外, 在适应新机器人配置时, 我们证明同时微调 VLA 与动作验证器相比仅微调 VLA 可带来 7% 的性能提升。

1 引言

基于互联网规模数据预训练的基础模型在机器人领域展现出巨大潜力。视觉-语言-动作 (VLA) 模型 [1, 2, 3, 4, 5] 的最新进展表明, 在大规模机器人数据集 [6, 7] 上扩展训练计算可提升其能力与泛化性。尽管取得这些进展, VLA 在部署期间仍表现出多种失效模式 [8, 9], 例如抓取不精确、任务推进失败以及与周围物体碰撞。解决这些局限性可加速机器人在非结构化真实环境中的部署。

提升视觉-语言-动作模型 (VLA) 的鲁棒性与泛化能力的努力已逐渐从预训练阶段转向后训练阶段。在预训练阶段, 以往工作侧重于扩大数据收集规模 [10, 7, 11]、优化训练数据混合 [12, 2], 以及开发能够有效适配机器人控制的模型架构 [13, 1, 14, 15]。近期, 我们观察到范式向后训练阶段发展的转变, 例如通过思维链微调 VLA 以实现多步推理 [16, 17, 18], 以及将 VLA 与偏好对齐 [19, 20, 21]。然而, 除预训练与后训练之外, 对部署期间计算量扩展的关注较少, 因为 VLA 模型通常设计为每次观测仅生成单个动作块。

人类在遇到具有挑战性的问题时, 自然会分配更多时间。对于大语言模型 (LLM), 这一原理已通过测试时施加额外计算得到验证 [22, 23, 24, 25, 26, 27]。具体而言, 反复从模型中采样候选解已被证明能够提升 LLM 在数学、编程、对话及摘要等多个领域的能力 [22, 28, 29]。这引出一个问题: 基于重复采样的测试时扩展是否同样有益于

[†]同等贡献。通讯作者: jackykwok@stanford.edu




图 1：推理时缩放定律：我们观察到，在存在理想验证器的假设下，随着生成动作数量的增加，动作误差在多种采样方法下均持续下降。从机器人策略中重复采样动作、对少量采样动作施加高斯扰动，甚至随机采样，均优于单次尝试的 OpenVLA。我们还发现，通过高斯扰动生成的样本数量与动作误差之间的关系在多种 VLA 模型（包括 CogACT、Octo、OpenVLA 和 SpatialVLA）上近似遵循幂律。对于幂律拟合，我们将动作误差的对数 e 建模为样本数量 k : $\log(e) \approx \log(a) + b \cdot \log(k)$ 的函数，其中 a 和 b 为拟合的模型参数。

机器人学。更确切地说，本文提出如下问题：给定观测与任务指令，能否通过在部署时反复采样并验证动作来提升 VLA 的精确率与鲁棒性？

我们从两个方面回答这一问题。首先，我们系统研究了在静态操作任务领域中扩展测试时计算的优势，使用现成的通用视觉-语言-动作模型作为基础策略。通过实验，我们发现动作误差与生成样本数量之间的关系在一系列视觉-语言-动作模型上遵循指数幂律，证明了推理时缩放定律的存在。这一发现与大型语言模型中观察到的幂律缩放 [30, 22] 一致，并表明当与鲁棒的验证器配合使用时，重复采样可以显著提升任何现成视觉-语言-动作模型的性能。有趣的是，不同的采样技术——从视觉-语言-动作模型重复采样动作、对少量动作施加高斯扰动以及随机采样——表现出相似的缩放模式。其中，我们发现高斯扰动是最具成本效益的方法，因此在部署中采用。据我们所知，我们的工作首次刻画视觉-语言-动作模型的推理时缩放定律。

其次，我们研究利用这些缩放定律与学习到的动作验证器是否能提高策略鲁棒性，其直觉来自经典复杂度理论：验证提议通常比为任务生成解决方案更容易。为此，我们提出一种基于偏好的学习方案，自动为大规模模仿学习数据集整合合成动作比较，并用其训练一个基于 70 亿参数视觉-语言模型的 7B 动作验证器。结果表明，增加合成偏好数据集规模可带来持续的性能提升。随后，我们引入测试时缩放框架 RoboMonkey。在部署期间，RoboMonkey 从视觉-语言-动作模型采样一小批动作，应用高斯扰动和多数投票构建动作提议分布，然后使用微调后的基于视觉-语言模型的验证器选择最优动作。通过广泛评估，我们证明将现有视觉-语言-动作模型与 RoboMonkey 结合可显著提升其精确率和鲁棒性。

本文的贡献总结如下：

1. 我们提出了高效的动作采样方法，并证明在一系列视觉-语言-动作模型上，动作误差与样本数量之间的关系近似遵循幂律。
2. 本文提出了一种可扩展的流程，用于自动生成合成动作偏好，并给出了一种训练基于视觉语言模型的动作验证器的方法。
3. 本文表明，所提出的推理时扩展框架显著提升了视觉语言动作模型的性能，在真实世界分布外任务中实现了 25% 的绝对提升，在分布内 SIMPLER 环境中实现了 9% 的提升。
4. 本文证明，在 LIBERO-Long 基准上，同时微调视觉语言动作模型和动作验证器相比仅微调视觉语言动作模型可获得 7% 的性能提升。

2 预备知识

本文考虑一个马尔可夫决策过程 $M = (\mathcal{S}, \mathcal{A}, P, R)$ ，其中 $\mathcal{S} \subseteq \mathbb{R}^n$ 和 $\mathcal{A} \subseteq \mathbb{R}^m$ 分别表示机器人的状态空间和动作空间。在本工作中，状态空间和动作空间均为 7 维向量空间，对应于机器人末端执行器的位姿，由三个平移状态 $(x, y, z) \in \mathbb{R}^3$ 和三个旋转状态 $(u, v, w) \in \mathbb{R}^3$ 表征，最后一个维度对应一个二值状态 $g \in \{0, 1\}$ ，指示末端执行器夹爪是否张开。 $a_t = [\Delta x_t, \Delta y_t, \Delta z_t, \Delta u_t, \Delta v_t, \Delta w_t, g_t]'$ 表示在时间步 t 对每个状态变量进行增强的期望幅度和方向。此外， $P(s' | s, a) \in [0, 1]$ 表示机器人从当前状态 $s \in \mathcal{S}$ 采取动作 $a \in \mathcal{A}$ 转移到候选状态 $s' \in \mathcal{S}$ 的非确定性转移动态， $R: \mathcal{S} \times \mathcal{A} \times \mathcal{I} \rightarrow \mathbb{R}$ 给出在语言指令 $I \in \mathcal{I}$ 下于状态 $s \in \mathcal{S}$ 选择动作 $a \in \mathcal{A}$ 的奖励，其中 $\mathcal{I}$ 为可能指令的集合。本文框架假设可访问一个以语言为条件的机器人策略 $\pi_\theta: \mathcal{S} \times \mathcal{I} \rightarrow \mathcal{A}$ ，其参数为 $\theta \in \mathbb{R}^{|\theta|}$ ，在给定时间步 t 的状态和语言指令 $I \in \mathcal{I}$ 时，可从中采样多个动作。此外，本文假设可访问一个包含 N_D 条专家演示的数据集，这些演示执行一组操作任务： $\mathcal{D} = \{(\tau^i, I^i)\}_{i=1}^{N_D}$ ，其中每条演示在转移动态下构成一条到时间范围 $T \in \mathbb{N}_+$ 的有效轨迹 $\tau^i = (s_0^i, a_0^i, \dots, s_T^i)$ 。本文进一步整理了一个辅助数据集 $\mathcal{D}_{\text{buf}} \subset \mathcal{D}$ ，由元组 (s_t, a_t^*, I) 组成，其中 $a_t^* \in \mathcal{A}$ 为专家在状态 s_t 和指令 I 下采取的真实动作。本文假设通用策略 π_θ 通过最小化标准模仿学习目标在该数据集上进行微调以模仿专家演示，目标为

$$\mathcal{L}(\theta; \mathcal{D}) = -\mathbb{E}_{(s_t^j, a_t^j, I^j) \sim \mathcal{D}} [\log \pi_\theta(a_t^j | s_t^j, I^j)].$$

3 推理时缩放定律

视觉-语言-动作模型 (VLA) 的动作误差与其训练计算量 [31, 32] 之间的关系已有充分文献记载。然而，扩展测试时计算量对视觉-语言-动作模型的潜在益处仍远未得到充分探索。为弥补这一空白，本文在 Bridge V2 数据集 [11] 上进行了详细分析，考察生成样本数量与动作误差之间的关系。

具体而言，本文从辅助数据集 $\mathcal{D}_{\text{buf}}$ 中均匀采样 1,000 个 (s, a^*, I) 元组。对于每个元组，使用多种采样方法生成 10,000 个动作，并计算真实动作 a^* 与每个采样动作 $\{a_1, a_2, \dots, a_{10,000}\}$ 之间的归一化均方根误差 (RMSE)。

本文评估了三种采样方法：随机采样：根据 Brohan 等人 [5] 提出的方案，对每个维度均匀采样离散动作标记来生成候选动作。策略采样：从具有正温度的机器人策略 $\pi_\theta(a | s, I)$ 中重复采样动作。高斯扰动：仅从机器人策略 $\pi_\theta(a | s, I)$ 中采样 4 个动作，然后拟合一个高斯分布，所有候选动作均从该分布中抽取（详见第 4.4 节）。

结果如图 1 左图所示。假设存在一个始终选择均方根误差最低动作的理想验证器，本文观察到，随着生成样本数量的增加，所有采样方法的动作误差均持续下降。本文的主要发现如下：（1）均匀随机采样超过 100 个动作的性能优于使用 OpenVLA 的贪心解码；（2）使用策略采样从视觉-语言-动作模型中重生成动作始终获得最低的动作误差；（3）高斯扰动在计算效率更高的同时，性能几乎与策略采样相同。全面的延迟分析见第 5.4 节。

图 1 的右图表明，通过高斯扰动扩展生成样本数量在多种通用机器人策略上均有效，包括 CogACT、Octo、OpenVLA 和 SpatialVLA [33, 34, 2, 35]。我们发现动作误差与样本数量之间的关系通常遵循指数幂律。具体而言，对于 OpenVLA，采样 10,000 个动作时，均方根误差降低了 59.3%。总体而言，我们为如何构建通用机器人基础模型提供了一种新视角。我们的结果表明，与其将机器人控制纯粹视为生成问题，不如通过验证的视角来看待——生成多样化的候选动作并对其进行验证——可以显著提升性能。我们希望这些发现能够激励并指导面向机器人策略的可扩展动作验证器的开发。

4 提出的方法：RoboMonkey




图 2：阶段 1：训练动作验证器。 给定模仿学习数据集，我们从通用机器人策略中为每个状态采样 N 个候选动作，并应用聚类将其缩减为 K 个代表性动作。我们构建 $\binom{K}{2}$ 个合成动作比较，并根据每个采样动作与真实动作之间的均方根误差分配偏好。该合成偏好数据集随后用于微调基于视觉语言模型的动作验证器。阶段 2：扩展测试时计算。在部署时，我们根据给定的任务指令和观测从通用机器人策略中采样 N 个初始动作。我们对这些动作的平移和旋转分量 ($\Delta x, \Delta y, \Delta z, \Delta u, \Delta v, \Delta w$)，如第 2 节所述) 拟合高斯分布 $\mathcal{N}(\mu, \sigma)$ ，并使用多数投票确定夹爪状态。这创建了一个动作提议分布，我们可以从中高效采样候选动作，开销可忽略不计。最后，我们使用微调后的基于视觉语言模型的验证器评估这些 K 个候选动作，并选择最优动作。

4.1 动机

在第 3 节确立了机器人测试时计算扩展的潜力之后，我们现在提出 RoboMonkey，一个利用学习到的动作验证器来扩展测试时计算的框架。我们首先描述用于构建合成动作偏好数据集的方法，随后介绍 RoboMonkey 的生成-验证流程中使用的奖励建模和推理时技术。

4.2 合成数据生成流程

在本节中，我们概述了生成合成动作比较的方法，该方法利用现有的演示数据集 $\mathcal{D}$ 来生成具有高质量偏好标签的动作对，而无需人工标注。具体而言，对于来自辅助数据集 $\mathcal{D}_{\text{buf}}$ 的每个元组 (s_t, a_t^*, I) ，我们使用参考机器人策略生成 N 个候选动作。为确保样本的多样性，我们应用聚类算法，将这些候选动作缩减为 K 个代表性动作。随后，我们构建 $\binom{K}{2}$ 个成对比较，并计算每个采样动作 $\{a_t^1, a_t^2, \dots, a_t^K\}$ 与真实动作 a_t^* 之间的均方根误差。然后，任意两个动作 a_t^i 与 a_t^j 之间的“获胜”动作 a_t^W 和“失败”动作 a_t^L 按如下方式确定：

$$(a_t^W, a_t^L) = \begin{cases} (a_t^i, a_t^j), & \text{if } \text{RMSE}(a_t^i, a_t^*) < \text{RMSE}(a_t^j, a_t^*), \\ (a_t^j, a_t^i), & \text{otherwise.} \end{cases}$$

我们使用此过程来实例化由元组 $(a_t^W, a_t^L, a_t^*, s_t, I)$ 组成的动作偏好数据集 $\mathcal{D}_{\text{comp}}$ 。遵循 Ouyang 等人 [36] 的方法，我们将来自相同初始条件 (s_t, I) 的所有 $\binom{K}{2}$ 个成对比较组合在一起，作为单个批次进行训练。

4.3 奖励建模

训练奖励模型的损失函数遵循 Bradley-Terry 模型 [37]，并进行了额外修改以考虑偏好级别。形式上，我们将真实偏好级别定义为 $\Delta_t^* = |\text{RMSE}(a_t^W, a_t^*) - \text{RMSE}(a_t^L, a_t^*)|$ ，并将由参数 $\phi \in \mathbb{R}^{|\phi|}$ 化的动作验证器 $R_\phi : A \times S \times \mathcal{I} \rightarrow \mathbb{R}$ 预测的偏好级别定义为 $\hat{\Delta}_t$
 $t = |R_\phi(a_t^W, s_t, I) - R_\phi(a_t^L, s_t, I)|$ 。然后将这些组件整合到用于训练奖励模型的损失函数中：

$$\mathcal{L}(\phi; \mathcal{D}_{\text{comp}}) = -\mathbb{E}_{(a_t^W, a_t^L, a_t^*, s_t, I) \sim \mathcal{D}_{\text{comp}}} \left[\log \sigma \left(R_\phi(a_t^W, s_t, I) - R_\phi(a_t^L, s_t, I) - \alpha \left\| \Delta_t^* - \hat{\Delta}_t \right\|_2^2 \right) \right],$$

其中 $\sigma: \mathbb{R} \rightarrow [0, 1]$ 是 Sigmoid 函数， $\alpha \in \mathbb{R}$ 是控制偏好级别幅度的超参₂。我们发现，加入边际分量 $\Delta_t^* - \hat{\Delta}_t$ 2 可以提高准确率，特别是在区分明显不同的动作时。更详细的分析和消融研究请参见附录 E 和 F。动作验证器使用 LLaVA-7B[38, 39] 作为骨干网络，并将其最后的反嵌入层替换为奖励头。该架构集成 ViT-Large[40] 作为视觉编码器，并使用多层感知机将视觉特征映射到与语言模型词嵌入空间相同的维度。

4.4 动作采样与验证

图 2 展示了该流程的可视化。形式上，在指令 I 下的部署过程中，每个时间步 t ，RoboMonkey 首先以正温度 $\mathcal{T}$ 从 VLA 模型 $\pi_\theta(a|s_t, I; \mathcal{T})$ 中采样 $\hat{N}$ 个候选动作，得到候选动作集合 $\hat{A} = \{\hat{a}_t^1, \dots, \hat{a}_t^{\hat{N}}\} \in \mathbb{R}^{m \times \hat{N}}$ 。基于这些样本，我们通过对离散夹爪分量进行多数投票来确定夹爪动作 g_t ： $g_t = \text{众数}(\{g_t^i\}_{i=1}^{\hat{N}})$ 。然后，我们对平移分量 $\{[\Delta \hat{x}_t^i, \Delta \hat{y}_t^i, \Delta \hat{z}_t^i]\}_{i=1}^{\hat{N}}$ 和旋转分量 $\{[\Delta \hat{w}_t^i, \Delta \hat{v}_t^i, \Delta \hat{w}_t^i]\}_{i=1}^{\hat{N}}$ 拟合高斯分布 $\mathcal{N}(\mu_t, \Sigma_t)$ 。RoboMonkey 随后从该提议分布中采样 $\hat{K}$ 个新动作，并将固定的夹爪状态 g_t 附加到每个动作上，形成精炼动作集合 $\tilde{A} = \{\tilde{a}_t^1, \dots, \tilde{a}_t^{\hat{K}}\} \in \mathbb{R}^{m \times \hat{K}}$ 。最后，使用我们的奖励模型 $R_\phi(\tilde{a}_t^i, s_t, I)$ 对每个动作 $\tilde{a}_t^i$ 进行评分，从中选择奖励最高的动作执行 $a_t = \arg\max_{\tilde{a}_t^i \in \{\tilde{a}_t^1, \dots, \tilde{a}_t^{\hat{K}}\}} R_\phi(\tilde{a}_t^i, s_t, I)$ 。下面，算法 1 展示了我们详细的测试时扩展流程。

Algorithm 1: RoboMonkey Execution

Input: Generic VLA model $\pi_\theta: \mathcal{S} \times \mathcal{I} \rightarrow \mathcal{A}$, reward model $R_\phi: \mathcal{A} \times \mathcal{S} \times \mathcal{I} \rightarrow \mathbb{R}$, initial state $s_0 \in \mathcal{S}$, task instruction $I \in \mathcal{I}$, temperature $\mathcal{T} \in \mathbb{R}_{++}$, time horizon $T \in \mathbb{N}_+$, number of VLA samples $\hat{N} \in \mathbb{N}_+$, number of Gaussian samples $\hat{K} \in \mathbb{N}_+$.

for $t=0, 1, \dots, T$ **do**

Sample $\hat{A}_t = \{\hat{a}_t^i\}_{i=1}^{\hat{N}} \sim \pi_\theta(a|s_t, I; \mathcal{T})$
 Compute gripper state $g_t \leftarrow \text{mode}(\{\hat{g}_t^i\}_{i=1}^{\hat{N}})$
 Fit Gaussian distribution $\mathcal{N}(\mu_t, \Sigma_t)$ on $\{[\Delta \hat{x}_t^i, \Delta \hat{y}_t^i, \Delta \hat{z}_t^i, \Delta \hat{w}_t^i, \Delta \hat{v}_t^i, \Delta \hat{w}_t^i]\}_{i=1}^{\hat{N}}$
 Sample $\tilde{A}_t = \{\tilde{a}_t^i\}_{i=1}^{\hat{K}} \sim \mathcal{N}(\mu_t, \Sigma_t)$
 Set $\tilde{a}_t^i \leftarrow [\Delta \tilde{x}_t^i, \Delta \tilde{y}_t^i, \Delta \tilde{z}_t^i, \Delta \tilde{w}_t^i, \Delta \tilde{v}_t^i, \Delta \tilde{w}_t^i, g_t]'$ for all $i \in \{1, 2, \dots, \hat{K}\}$
 Select action $a_t \leftarrow \arg\max_{\tilde{a}_t^i \in \{\tilde{a}_t^1, \dots, \tilde{a}_t^{\hat{K}}\}} R_\phi(\tilde{a}_t^i, s_t, I)$
 Execute a_t and observe s_{t+1}

5 实验

我们的实验旨在评估为通用机器人策略扩展测试时计算的有效性。我们在仿真和真实环境中使用两种不同的机器人本体，在 4 个真实机器人任务和 14 个仿真任务上评估 RoboMonkey。




图 3: 扩展测试时计算显著提高了通用机器人策略在广泛操作任务中的精确率和鲁棒性。我们观察到在分布内 SIMPLER 环境 [41] 中平均成功率提高了 9%，在使用 WidowX 机器人的真实世界分布外实验中提高了 25%。

5.1 实现细节

我们使用 Bridge V2 数据集 [11] 作为主要训练数据集，该数据集包含在 24 个不同环境中使用 6 自由度 WidowX 机器人收集的超过 40,000 条真实世界机器人轨迹。按照第 4.2 节描述的过程，我们构建了一个包含 2000 万次比较的合成动作偏好数据集。训练在 8 块 NVIDIA H100 GPU 上进行，批大小为 256，使用 LoRA ($r=512$, $\alpha=128$)。所有实验均使用 OpenVLA 作为基础模型。RoboMonkey 和 V-GPS[42] 均通过将 OpenVLA 与各自的验证器检查点配对进行评估。在真实世界评估中，系统在单块 NVIDIA H100 GPU 上以约 1.5 Hz 的频率运行，总共使用 28 GB 的 GPU 内存。有关模型训练和部署的更多细节，请参阅附录 B。




图 4: SIMPLER、真实世界和 LIBERO 环境中的示例任务。

5.2 RoboMonkey 能否提升视觉语言动作模型在分布内任务上的精确率？

我们首先在 SIMPLER[41] 环境中对分布内任务评估我们的模型。该仿真环境专为弥合真实到仿真的差距而设计，通过复现 WidowX 机器人的真实世界条件。它已证明 SIMPLER 中的性能与真实世界结果之间存在很强的相关性 [41]。我们在四个任务上评估 RoboMonkey 和其他基线：将茄子放入黄色篮子、将胡萝卜放在盘子上、将勺子放在毛巾上，以及将绿色积木堆叠在黄色积木上。

图 3 展示了评估结果。RoboMonkey 的平均成功率达到 47.5%，平均比 OpenVLA 高出 9%。在将茄子放入篮子的任务中，RoboMonkey 比 OpenVLA 高出 19%。我们观察到，基础策略在尝试将茄子移向篮子时经常与墙壁发生碰撞。类似地，在积木堆叠任务中，RoboMonkey 比 OpenVLA 高出 10%。该任务要求对小物体进行精确抓取和精准放置。总体而言，这些结果凸显了对基础策略动作进行局部修正可以显著提升精确率。此外，我们观察到将 V-GPS 与 OpenVLA 结合使用的性能比单独使用 OpenVLA 和 RoboMonkey 都更差。有关任务设置和动作选择消融实验的详细信息，请参见附录 A 和 C。

5.3 RoboMonkey 能否提升视觉语言动作模型在分布外任务上的鲁棒性？

为了进行更全面的评估，我们在实体 WidowX-250 S 机器人上设计了一组真实世界操作任务，以在分布外设置下评估 RoboMonkey。如图 4 所示，这些任务包括未见过的指令、物体、干扰物和形状。我们在 4 个任务套件上评估每种方法，每个套件进行 10 次试验，总共 120 次运行。图 3 比较了 RoboMonkey、V-GPS 和 OpenVLA 在 WidowX 机器人上一系列任务中的性能。RoboMonkey 在多种任务中始终优于两个基线，包括堆叠杯子、举起锤子、将香蕉放入黄色篮子以及将辣椒放在盘子上。我们发现 RoboMonkey 有效缓解了部署时抓取不精确、任务推进失败和碰撞等问题。详细的任务分解和失败分析可在我们的项目页面上找到：<https://robomonkey-vla.github.io>。

值得注意的是，RoboMonkey 在需要视觉和语义泛化的任务上表现出显著提升。例如，在香蕉入篮任务中，OpenVLA 的成功率为 0%，因为它缺乏区分两个黄色物体（香蕉和黄色篮子）的语言和视觉定位能力，因此无法推进任务完成。此外，RoboMonkey 在精细操作任务（如叠杯和举锤）上的成功率高出 20% 以上。这些任务需要对抓取点进行精确推理，尤其是在新物体和新形状上。总体而言，RoboMonkey 的平均成功率达到 60%，而 OpenVLA 为 35%，V-GPS 为 30%，这表明我们的动作验证器对分布偏移的敏感度显著低于基础策略。因此，这些结果凸显了 RoboMonkey 在提升分布外场景下的鲁棒性和泛化能力方面的有效性。




图 5: 左: 重复采样可以利用键值缓存优化和批处理, 实现比贪心解码更高的吞吐量。因此, 我们扩展了 SGLang 的能力, 以正确支持 OpenVLA。我们的优化实现显著优于朴素的 OpenVLA 推理流程, 在不同批大小下实现了更低的延迟和显著更高的吞吐量。右: 随着采样数量的增加, 朴素策略采样与高斯扰动之间的延迟比较。

5.4 RoboMonkey 如何实现测试时扩展的实用部署？

虽然 RoboMonkey 引入了动作采样和验证带来的额外计算开销, 但我们通过实用的服务方案来降低这些成本。具体来说, 我们在 SGLang [43] 之上实现了一个视觉-语言-动作服务引擎, 以加速初始动作候选的重复采样 (见图 5), 并采用高斯扰动高效构建动作提议分布, 详见第 4.4 节。通过这些优化, RoboMonkey 可以在约 650 毫秒 (或 1.5 赫兹) 内采样并验证 16 个候选动作, 与朴素策略采样相比延迟降低了 41.3%, 如图 5 (右) 所示。高斯扰动被证明更高效, 因为延迟仅随验证成本扩展, 而朴素策略采样随着候选动作数量的增加, 采样和验证的延迟都会增加。关于动作误差与计算预算之间权衡的详细分析, 请参见附录 H。

SIMPLER 的结果是在两块 NVIDIA RTX 4090 图形处理器上获得的, 而真实世界实验和延迟分析则是在一块 NVIDIA H100 上进行的。LIBERO 评估使用了一块 NVIDIA RTX 6000 Ada。

5.5 扩展合成训练数据集如何影响下游成功率？




图 6: 在 SIMPLER 上四个任务的平均成功率随合成数据集大小的变化。扩大数据集规模（合成动作比较的数量）持续提升 RoboMonkey 动作验证器的性能，从而带来更高的闭环成功率。

我们证明，RoboMonkey 在 SIMPLER 上的闭环成功率随着合成数据集规模的增大而持续提升，平均成功率从 37.5% 上升到 46.3%，如

图 6。通过在超过 10^6 次动作比较上训练动作验证器，RoboMonkey 超越了 OpenVLA 和 V-GPS。在“堆叠立方体”等精细操作任务中，改进尤为显著，随着合成数据集的扩展，成功率从 27% 提升至 37%，再到 42%。我们发现，整体任务性能随合成数据集规模的增长几乎呈对数线性增长，这凸显了大规模合成数据生成在增强动作验证方面的潜力。

5.6 能否在新机器人配置与任务上有效微调动作验证器？

Task	OpenVLA	RoboMonkey
Soup and Sauce in Basket	36%	59%
Cheese and Butter in Basket	70%	79%
Turn on Stove and Place Moka	58%	58%
Black Bowl in Drawer	36%	37%
Mugs on Plates	42%	55%
Book in Caddy	84%	86%
Mug and Pudding on Plate	48%	59%
Soup and Cheese in Basket	56%	62%
Moka Pots on Stove	26%	26%
Mug in Microwave	42%	44%
Average Success Rate	49.8%	56.5%

表 1: OpenVLA 与 RoboMonkey 在 LIBERO-Long 基准上微调并评估的任务成功率比较。

我们进一步评估了 RoboMonkey 在新机器人配置上的适应性。本节中，我们展示了 RoboMonkey 在 LIBERO-Long 基准上的微调评估，该基准包含仿真中的长时程任务。在我们的实验中，我们按照第 4.2 节描述的过程构建了一个新的动作偏好数据集，用于微调动作验证器。用于比较的 OpenVLA-LIBERO 检查点是通过成功演示进行行为克隆训练得到的。所有方法均在 500 次试验中进行了评估。表 1 展示了结果，我们观察到 RoboMonkey 可以有效地适应 LIBERO 环境中的任务。我们发现，与仅在 LIBERO-Long 上微调 OpenVLA 相比，同时微调 OpenVLA 和动作验证器可使平均成功率提高 6.7%。

6 讨论与局限性

本文提出了 RoboMonkey，一种新颖的测试时扩展框架，旨在提升视觉-语言-动作（Vision-Language-Action, VLA）模型的精确率与鲁棒性。RoboMonkey 在分布内与分布外任务以及新机器人平台上均取得了显著的性能提升。研究结果表明，通过生成-验证范式扩展测试时计算，为构建通用机器人基础模型提供了一条实用且有效的路径。当前 RoboMonkey 框架存在若干局限性，留待未来工作解决：

计算开销：由于需要从 VLA 中采样多个候选动作，并采用独立的基于视觉语言模型（VLM）的动作验证器，部署过程中的计算开销有所增加。尽管本文通过实用的服务方案——使用 VLA 服务引擎和高斯扰动——缓解了这些成本，但该框架对于需要高频控制的任务可能仍不够适用。未来工作可探索更高效的动作验证模型架构，并应用系统级优化，以进一步降低扩展测试时计算的内存占用和延迟。

扩展合成数据集：实验结果表明，增加合成训练数据集的规模能够持续提升下游机器人性能。然而，受限于计算资源和微调的高昂成本，本文在 Bridge V2 数据集上的实验仅使用了 2000 万条合成动作比较数据。将合成数据生成扩展到跨本体、任务和环境的更大规模机器人数据集，是未来探索的一个有前景的方向。

评估范围：本文实验聚焦于两种常用的机械臂——WidowX 250S 和 Franka，未来工作应在更广泛的本体上评估 RoboMonkey。

7 相关工作

视觉语言动作模型：机器人学的最新进展已转向在大型机器人数据集 [11, 45] 上训练多任务通用机器人策略 [44]，这些数据集采集自多样化的场景和机器人形态。在此背景下，涌现出若干机器人基础模型。 π_0 、OpenVLA、PaLM-E 和 RT-X [1, 2, 3, 4, 5] 通过将变换器（Transformer）架构 [46] 或扩散策略 [13] 与模仿学习相结合，展现出强大的泛化能力。尽管这些通用策略在控制机器人方面表现出开箱即用的能力，但它们仍可能因分布偏移和累积预测误差而失效。本文的评估表明，RoboMonkey 显著提升了这些通用策略在部署时的鲁棒性和泛化性。

分布外鲁棒性：基于学习的系统在与训练分布不同的数据上表现不可靠这一挑战，在机器人学文献中已有记载 [47, 8, 9]。研究者们通过多种方法应对这一挑战，包括鲁棒训练以及使模型适应不同的环境分布偏移 [47, 48, 49]。基础模型（Foundation Models, FMs）的出现带来了重大突破。近年来，基础模型在机器人学中被广泛采用。例如，若干先前工作 [50, 51, 52] 探索利用视觉语言模型（VLMs）生成高层动作计划序列，随后由低层策略执行。相比之下，RoboMonkey 及若干同期工作 [53, 54] 并非主要将基础模型用于分层规划，而是将其用作动作验证器，评估机器人策略生成的低层动作。

重复采样：在测试时应用额外计算的方法论已在多个领域展现出显著的成功。对于大语言模型（LLM），重复采样已被证明能有效提升其在数学问题求解、编程和文本摘要等多种任务上的性能 [28, 22, 55]。在机器人领域，V-GPS [42] 采用了一种相关策略，通过离线强化学习训练价值函数来对候选动作进行重新排序，选择那些能带来更好结果的动作。RoboMonkey 引入了一种更具可扩展性的数据策展流程和模型架构，用于训练动作验证器。我们的实验结果表明，与先前基于验证器的方法相比，将现有视觉语言动作模型（VLA）与我们的验证器配对，能显著提升任务性能和泛化能力。RoboMonkey 不依赖于从机器人策略中进行简单的动作采样，而是使用高斯扰动来高效生成多样化的候选动作，并集成诸如多数投票等推理时技术来指导验证过程。

致谢

本工作由美国国防高级研究计划局（DARPA）和美国国家航空航天局（NASA）在大学领导力倡议计划下提供支持。

参考文献

- [1] K. Black, N. Brown, D. Driess, A. Esmail, M. Equi, C. Finn, N. Fusai, L. Groom, K. Hausman, B. Ichter, S. Jakubczak, T. Jones, L. Ke, S. Levine, A. Li-Bell, M. Mothukuri, S. Nair, K. Pertsch, L. X. Shi, J. Tanner, Q. Vuong, A. Walling, H. Wang, and U. Zhilinsky. π_0 : A vision-language-action flow model for general robot control, 2024. URL <https://arxiv.org/abs/2410.24164>.
- [2] M. J. Kim, K. Pertsch, S. Karamcheti, T. Xiao, A. Balakrishna, S. Nair, R. Rafailov, E. Foster, G. Lam, P. Sanketi, et al. Openvla: An open-source vision-language-action model. *arXiv preprint arXiv:2406.09246*, 2024.
- [3] D. Driess, F. Xia, M. S. M. Sajjadi, C. Lynch, A. Chowdhery, B. Ichter, A. Wahid, J. Tompson, Q. Vuong, T. Yu, W. Huang, Y. Chebotar, P. Sermanet, D. Duckworth, S. Levine, V. Vanhoucke, K. Hausman, M. Toussaint, K. Greff, A. Zeng, I. Mordatch, and P. Florence. Palm-e: An embodied multimodal language model, 2023. URL <https://arxiv.org/abs/2303.03378>.
- [4] A. Brohan, N. Brown, J. Carbajal, Y. Chebotar, J. Dabis, C. Finn, K. Gopalakrishnan, K. Hausman, A. Herzog, J. Hsu, et al. Rt-1: Robotics transformer for real-world control at scale. *arXiv preprint arXiv:2212.06817*, 2022.
- [5] A. Brohan, N. Brown, J. Carbajal, Y. Chebotar, X. Chen, K. Choromanski, T. Ding, D. Driess, A. Dubey, C. Finn, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control. *arXiv preprint arXiv:2307.15818*, 2023.
- [6] A. Khazatsky, K. Pertsch, S. Nair, A. Balakrishna, S. Dasari, S. Karamcheti, S. Nasiriany, M. K. Srirama, L. Y. Chen, K. Ellis, et al. Droid: A large-scale in-the-wild robot manipulation dataset. *arXiv preprint arXiv:2403.12945*, 2024.
- [7] A. O’Neill, A. Rehman, A. Gupta, A. Maddukuri, A. Gupta, A. Padalkar, A. Lee, A. Pooley, A. Gupta, A. Mandlekar, et al. Open x-embodiment: Robotic learning datasets and rt-x models. *arXiv preprint arXiv:2310.08864*, 2023.
- [8] C. Agia, R. Sinha, J. Yang, Z. ang Cao, R. Antonova, M. Pavone, and J. Bohg. Unpacking failure modes of generative policies: Runtime monitoring of consistency and progress, 2024. URL <https://arxiv.org/abs/2410.04640>.
- [9] R. Sinha, A. Elhafsi, C. Agia, M. Foutter, E. Schmerling, and M. Pavone. Real-time anomaly detection and reactive planning with large language models, 2024. URL <https://arxiv.org/abs/2407.08735>.
- [10] Z. Zhou, P. Atreya, A. Lee, H. Walke, O. Mees, and S. Levine. Autonomous improvement of instruction following skills via foundation models, 2024. URL <https://arxiv.org/abs/2407.20635>.
- [11] H. R. Walke, K. Black, T. Z. Zhao, Q. Vuong, C. Zheng, P. Hansen-Estruch, A. W. He, V. Myers, M. J. Kim, M. Du, et al. Bridgedata v2: A dataset for robot learning at scale. In *Conference on Robot Learning*, pages 1723–1736. PMLR, 2023.
- [12] J. Hejna, C. Bhateja, Y. Jiang, K. Pertsch, and D. Sadigh. Re-mix: Optimizing data mixtures for large scale imitation learning, 2024. URL <https://arxiv.org/abs/2408.14037>.
- [13] C. Chi, Z. Xu, S. Feng, E. Cousineau, Y. Du, B. Burchfiel, R. Tedrake, and S. Song. Diffusion policy: Visuomotor policy learning via action diffusion. *The International Journal of Robotics Research*, page 02783649241273668, 2023.

- [14] C.-L. Cheang, G. Chen, Y. Jing, T. Kong, H. Li, Y. Li, Y. Liu, H. Wu, J. Xu, Y. Yang, H. Zhang, and M. Zhu. Gr-2: A generative video-language-action model with web-scale knowledge for robot manipulation. *arXiv preprint arXiv:2410.06158*, 2024.
- [15] T. Z. Zhao, V. Kumar, S. Levine, and C. Finn. Learning fine-grained bimanual manipulation with low-cost hardware, 2023. URL <https://arxiv.org/abs/2304.13705>.
- [16] M. Zawalski, W. Chen, K. Pertsch, O. Mees, C. Finn, and S. Levine. Robotic control via embodied chain-of-thought reasoning, 2025. URL <https://arxiv.org/abs/2407.08693>.
- [17] J. Clark, S. Mirchandani, D. Sadigh, and S. Belkhale. Action-free reasoning for policy generalization, 2025. URL <https://arxiv.org/abs/2502.03729>.
- [18] Q. Zhao, Y. Lu, M. J. Kim, Z. Fu, Z. Zhang, Y. Wu, Z. Li, Q. Ma, S. Han, C. Finn, A. Handa, M.-Y. Liu, D. Xiang, G. Wetzstein, and T.-Y. Lin. Cot-vla: Visual chain-of-thought reasoning for vision-language-action models, 2025. URL <https://arxiv.org/abs/2503.22020>.
- [19] Z. Zhang, K. Zheng, Z. Chen, J. Jang, Y. Li, S. Han, C. Wang, M. Ding, D. Fox, and H. Yao. Grape: Generalizing robot policy via preference alignment, 2025. URL <https://arxiv.org/abs/2411.19309>.
- [20] B. Zhang, Y. Zhang, J. Ji, Y. Lei, J. Dai, Y. Chen, and Y. Yang. Safevla: Towards safety alignment of vision-language-action model via safe reinforcement learning, 2025. URL <https://arxiv.org/abs/2503.03480>.
- [21] D. Li, J. Ren, Y. Wang, X. Wen, P. Li, L. Xu, K. Zhan, Z. Xia, P. Jia, X. Lang, N. Xu, and H. Zhao. Finetuning generative trajectory model with reinforcement learning from human feedback, 2025. URL <https://arxiv.org/abs/2503.10434>.
- [22] B. Brown, J. Juravsky, R. Ehrlich, R. Clark, Q. V. Le, C. Ré, and A. Mirhoseini. Large language monkeys: Scaling inference compute with repeated sampling. *arXiv preprint arXiv:2407.21787*, 2024.
- [23] C. Snell, J. Lee, K. Xu, and A. Kumar. Scaling llm test-time compute optimally can be more effective than scaling model parameters. *arXiv preprint arXiv:2408.03314*, 2024.
- [24] J. Saad-Falcon, A. G. Lafuente, S. Natarajan, N. Maru, H. Todorov, E. Guha, E. K. Buchanan, M. Chen, N. Guha, C. Ré, et al. Archon: An architecture search framework for inference-time techniques. *arXiv preprint arXiv:2409.15254*, 2024.
- [25] L. Chen, J. Q. Davis, B. Hanin, P. Bailis, I. Stoica, M. Zaharia, and J. Zou. Are more llm calls all you need? towards scaling laws of compound inference systems. *arXiv preprint arXiv:2403.02419*, 2024.
- [26] Y. Song, G. Wang, S. Li, and B. Y. Lin. The good, the bad, and the greedy: Evaluation of llms should not ignore non-determinism. *arXiv preprint arXiv:2407.10457*, 2024.
- [27] D. Li, S. Cao, C. Cao, X. Li, S. Tan, K. Keutzer, J. Xing, J. E. Gonzalez, and I. Stoica. S*: Test time scaling for code generation, 2025. URL <https://arxiv.org/abs/2502.14382>.
- [28] G. Chen, M. Liao, C. Li, and K. Fan. Alphasat almost zero: process supervision without process. *arXiv preprint arXiv:2405.03553*, 2024.
- [29] K. Cobbe, V. Kosaraju, M. Bavarian, M. Chen, H. Jun, L. Kaiser, M. Plappert, J. Tworek, J. Hilton, R. Nakano, et al. Training verifiers to solve math word problems. *arXiv preprint arXiv:2110.14168*, 2021.
- [30] R. Schaeffer, J. Kazdan, J. Hughes, J. Juravsky, S. Price, A. Lynch, E. Jones, R. Kirk, A. Mirhoseini, and S. Koyejo. How do large language monkeys get their power (laws)?, 2025. URL <https://arxiv.org/abs/2502.17578>.

- [31] S. Sartor and N. Thompson. Neural scaling laws in robotics, 2025. URL <https://arxiv.org/abs/2405.14005>.
- [32] F. Lin, Y. Hu, P. Sheng, C. Wen, J. You, and Y. Gao. Data scaling laws in imitation learning for robotic manipulation, 2025. URL <https://arxiv.org/abs/2410.18647>.
- [33] Q. Li, Y. Liang, Z. Wang, L. Luo, X. Chen, M. Liao, F. Wei, Y. Deng, S. Xu, Y. Zhang, X. Wang, B. Liu, J. Fu, J. Bao, D. Chen, Y. Shi, J. Yang, and B. Guo. Cogact: A foundational vision-language-action model for synergizing cognition and action in robotic manipulation, 2024. URL <https://arxiv.org/abs/2411.19650>.
- [34] O. M. Team, D. Ghosh, H. Walke, K. Pertsch, K. Black, O. Mees, S. Dasari, J. Hejna, T. Kreiman, C. Xu, et al. Octo: An open-source generalist robot policy. *arXiv preprint arXiv:2405.12213*, 2024.
- [35] D. Qu, H. Song, Q. Chen, Y. Yao, X. Ye, Y. Ding, Z. Wang, J. Gu, B. Zhao, D. Wang, and X. Li. Spatialvla: Exploring spatial representations for visual-language-action model, 2025. URL <https://arxiv.org/abs/2501.15830>.
- [36] L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. L. Wainwright, P. Mishkin, C. Zhang, S. Agarwal, K. Slama, A. Ray, J. Schulman, J. Hilton, F. Kelton, L. Miller, M. Simens, A. Askell, P. Welinder, P. Christiano, J. Leike, and R. Lowe. Training language models to follow instructions with human feedback, 2022. URL <https://arxiv.org/abs/2203.02155>.
- [37] H. Touvron, L. Martin, K. Stone, P. Albert, A. Almahairi, Y. Babaei, N. Bashlykov, S. Batra, P. Bhargava, S. Bhosale, et al. Llama 2: Open foundation and fine-tuned chat models. *arXiv preprint arXiv:2307.09288*, 2023.
- [38] H. Liu, C. Li, Q. Wu, and Y. J. Lee. Visual instruction tuning, 2023.
- [39] Z. Sun, S. Shen, S. Cao, H. Liu, C. Li, Y. Shen, C. Gan, L.-Y. Gui, Y.-X. Wang, Y. Yang, K. Keutzer, and T. Darrell. Aligning large multimodal models with factually augmented rlhf, 2023. URL <https://arxiv.org/abs/2309.14525>.
- [40] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, and I. Sutskever. Learning transferable visual models from natural language supervision, 2021. URL <https://arxiv.org/abs/2103.00020>.
- [41] X. Li, K. Hsu, J. Gu, K. Pertsch, O. Mees, H. R. Walke, C. Fu, I. Lunawat, I. Sieh, S. Kirmani, S. Levine, J. Wu, C. Finn, H. Su, Q. Vuong, and T. Xiao. Evaluating real-world robot manipulation policies in simulation. *arXiv preprint arXiv:2405.05941*, 2024.
- [42] M. Nakamoto, O. Mees, A. Kumar, and S. Levine. Steering your generalists: Improving robotic foundation models via value guidance, 2025. URL <https://arxiv.org/abs/2410.13816>.
- [43] L. Zheng, L. Yin, Z. Xie, C. Sun, J. Huang, C. H. Yu, S. Cao, C. Kozyrakis, I. Stoica, J. E. Gonzalez, C. Barrett, and Y. Sheng. Sglang: Efficient execution of structured language model programs, 2024. URL <https://arxiv.org/abs/2312.07104>.
- [44] Y. Jiang, A. Gupta, Z. Zhang, G. Wang, Y. Dou, Y. Chen, L. Fei-Fei, A. Anandkumar, Y. Zhu, and L. Fan. Vima: General robot manipulation with multimodal prompts. *arXiv preprint arXiv:2210.03094*, 2(3):6, 2022.
- [45] H.-S. Fang, H. Fang, Z. Tang, J. Liu, J. Wang, H. Zhu, and C. Lu. Rh20t: A robotic dataset for learning diverse skills in one-shot. In *RSS 2023 Workshop on Learning for Task and Motion Planning*, 2023.
- [46] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin. Attention is all you need. *advances in neural information processing systems*, 30(2017), 2017.

- [47] R. Sinha, A. Sharma, S. Banerjee, T. Lew, R. Luo, S. M. Richards, Y. Sun, E. Schmerling, and M. Pavone. A system-level view on out-of-distribution data in robotics, 2023. URL <https://arxiv.org/abs/2212.14020>.
- [48] E. Zhu, M. Levy, M. Gwilliam, and A. Shrivastava. Nerf-aug: Data augmentation for robotics with neural radiance fields, 2025. URL <https://arxiv.org/abs/2411.02482>.
- [49] P. Mitrano and D. Berenson. Data augmentation for manipulation, 2022. URL <https://arxiv.org/abs/2205.02886>.
- [50] J. Liang, W. Huang, F. Xia, P. Xu, K. Hausman, B. Ichter, P. Florence, and A. Zeng. Code as policies: Language model programs for embodied control, 2023. URL <https://arxiv.org/abs/2209.07753>.
- [51] Y. Mu, Q. Zhang, M. Hu, W. Wang, M. Ding, J. Jin, B. Wang, J. Dai, Y. Qiao, and P. Luo. Embodiedgpt: Vision-language pre-training via embodied chain of thought, 2023. URL <https://arxiv.org/abs/2305.15021>.
- [52] L. X. Shi, B. Ichter, M. Equi, L. Ke, K. Pertsch, Q. Vuong, J. Tanner, A. Walling, H. Wang, N. Fusai, A. Li-Bell, D. Driess, L. Groom, S. Levine, and C. Finn. Hi robot: Open-ended instruction following with hierarchical vision-language-action models, 2025. URL <https://arxiv.org/abs/2502.19417>.
- [53] Y. Wu, R. Tian, G. Swamy, and A. Bajcsy. From foresight to forethought: Vlm-in-the-loop policy steering via latent alignment, 2025. URL <https://arxiv.org/abs/2502.01828>.
- [54] Y. Wang, L. Wang, Y. Du, B. Sundaralingam, X. Yang, Y.-W. Chao, C. Perez-D’Arpino, D. Fox, and J. Shah. Inference-time policy steering through human interactions, 2025. URL <https://arxiv.org/abs/2411.16627>.
- [55] R. Ehrlich, B. Brown, J. Juravsky, R. Clark, C. Ré, and A. Mirhoseini. Codemonkeys: Scaling test-time compute for software engineering, 2025. URL <https://arxiv.org/abs/2501.14723>.
- [56] B. Liu, Y. Zhu, C. Gao, Y. Feng, Q. Liu, Y. Zhu, and P. Stone. Libero: Benchmarking knowledge transfer for lifelong robot learning. *arXiv preprint arXiv:2306.03310*, 2023.

A 评估任务

如第 5.3 节所述及图 4 所示，我们在实体 WidowX-250 S 机器人上对 RoboMonkey、OpenVLA 和 V-GPS 在四个分布外（OOD）泛化任务上进行了评估。真实世界评估不可避免地会引入分布偏移，因为我们无法精确复现 Bridge V2 的设置。特别是相机位置、机器人定位、光照条件和背景的细微变化是不可避免的。我们将四个代表性泛化任务描述如下：

- **将蓝色杯子叠放在粉色杯子上：**目标是抓取蓝色杯子并将其叠放在粉色杯子之上。该任务的语言指令未包含在 Bridge V2 数据集中。
- **将锤子放入黄色篮子：**机器人必须举起锤子并将其放入黄色篮子内。重要的是，锤子代表一个未见过的物体，其新颖形状未出现在任何 Bridge V2 演示中。
- **将胡椒放到盘子上：**该语言基础任务要求机器人识别并接近胡椒，同时忽略干扰物（例如寿司）。机器人随后必须区分黄色篮子和盘子，然后正确放置胡椒。
- **将香蕉放入黄色篮子：**该任务的目标是将水槽中的香蕉放入黄色篮子。该任务提出了一个特别的挑战，因为系统必须区分两个黄色物体（香蕉和黄色篮子），需要视觉和语言基础才能成功完成任务。

有关分布内和微调评估的任务设置详情，请参阅 SIMPLER [41] 和 LIBERO-LONG [56] 基准。我们在图 7 中包含了任务执行示例。




图 7：真实世界、SIMPLER 和 LIBERO 环境中的代表性任务执行。

B 实现细节

B.1 训练

我们的动作验证器以 LLaVA-7B [38, 39] 为骨干网络，并将其最终的逆嵌入层替换为奖励头。该架构集成 ViT-Large [40] 作为视觉编码器，并使用多层感知机将视觉特征映射到与语言模型词嵌入空间相同的维度。我们将连续动作的每个维度离散化为 256 个区间，遵循 Brohan 等人 [4] 的方法，并用这些离散动作标记覆盖 LLaMA 分词器中频率最低的 256 个标记。

训练在 8 块 NVIDIA H100 GPU 上进行，采用 LoRA（秩=512， $\alpha=128$ ），代码库基于 LLaVA-RLHF [39] 构建。批大小为 256，训练数据为源自 Bridge V2 数据集的合成偏好数据集，包含 2000 万条比较。模型使用 Adam 优化器，学习率为 $2e-5$ ，训练一个轮次。对修改后的 Bradley-Terry 损失应用 0.1 的边际权重。动作验证器的示例提示如下：

```
USER: <image> shows the current observation from the robot's wrist-mounted camera. The robot manipulation arm is attempting to [instruction]. What action should the robot take to effectively accomplish the task?
ASSISTANT: The robot should take the action [Discrete Action Tokens]
USER: Please evaluate the quality of the robot action.
ASSISTANT: The quality score of the robot action is
```

B.2 部署

在真实世界评估中，我们首先以温度 1.0 从 OpenVLA 采样 5 个初始动作。对平移和旋转分量拟合高斯分布 $\mathcal{N}(\mu, \sigma)$ ，并使用多数投票确定夹爪状态。由此生成动作提议分布，从中采样 16 个候选动作。随后使用微调后的基于视觉语言模型的验证器选择最优动作执行。每个任务进行 10 次试验，报告平均成功率。在仿真中，我们改变初始动作采样数 $\hat{N} \in \{5, 9\}$ 和增强采样数 $\hat{K} \in \{8, 16, 32\}$ ，报告每个任务的最终结果。所有仿真实验均在一台配备两块 NVIDIA RTX 4090 GPU 的机器上进行，使用三个随机种子。

B.3 基线

我们使用 <https://huggingface.co/openvla/ope> 中公开发布的 OpenVLA 检查点 `nvla-7b`，以及 <https://github.com/nakamotoo/V-GPS> 中的 V-GPS 价值函数检查点。在仿真中，我们遵循 V-GPS 实现中概述的评估流程，对采样数 $\{10, 50\}$ 和 Softmax 温度 $\{0, 0.1, 1.0\}$ 进行扫描，并报告每个任务的最佳结果。在真实世界评估中，采样数固定为 10，温度固定为 1.0。值得注意的是，我们使用自研的 VLA 服务引擎为所有实验提供高效批量推理。

C 动作选择方法与样本数量的消融实验

为评估本文验证器的有效性，采用与第 3 节所述相似的实验设置。具体而言，从辅助数据集 $\mathcal{D}_{\text{buf}}$ （整理自 BridgeV2[11]）中均匀采样 1,000 (s, a^*, I) 个元组。对每个元组，使用参考策略 OpenVLA 生成 64 个候选动作，并应用多种选择技术——包括 RoboMonkey、V-GPS、多数投票和随机选择——以在样本中识别最优动作。报告各方法下真值动作与所选动作之间的归一化均方根误差。如图 8 所示，RoboMonkey 在不同样本数量下均持续取得最低动作误差。当生成 64 个样本时，RoboMonkey 相对于贪心解码基线将动作误差降低 21%，凸显了本文验证器在提升动作精确率方面的有效性。尽管先前工作如 V-GPS 通过离线强化学习训练也优于贪心解码，但其价值函数仅实现 6% 的动作误差降低。此外，观察到增加样本数量会导致对 V-GPS 价值函数的利用




图 8: 不同选择方法在生成样本数量增加时的动作误差（平均均方根误差）比较。RoboMonkey 持续优于其他基线，并能有效利用额外计算资源进行扩展。

函数，导致采样超过 8 个动作时性能下降。相比之下，RoboMonkey 对奖励黑客行为保持鲁棒性，并展现出随测试时计算增加的可扩展性。

D 通用机器人策略的消融实验

本文进行了额外实验，以消融 RoboMonkey 与不同视觉-语言-动作模型配对时的性能。对于生成动作块的模型，采用时间集成方法，并使用 Brohan 等人 [5] 提出的方案对输出进行离散化，以便动作验证器进行评分。遵循与附录 C 相似的评估设置，消融实验考虑三种通用机器人策略：CogACT、Octo 和 SpatialVLA。




图 9: RoboMonkey 在不同通用机器人策略下扩展测试时计算的效果。动作误差（平均均方根误差）随样本数量增加而降低。虚线表示各基础策略仅生成单个动作时的动作误差。

CogACT 是一个具有模块化架构的 70 亿参数视觉-语言-动作模型，该架构将认知推理与运动控制分离。**CogACT** 构建于 Prismatic 视觉-语言模型之上（视觉部分采用 DINOv2 与 SigLIP，语言部分采用 LLaMA-2），并引入了一个以扩散 Transformer 实现的专用动作模块。我们在实验中使用 **CogACT-base** 变体。将 RoboMonkey 与 **CogACT** 结合后，均方根误差达到 0.133，相比其单次尝试基线 0.145 降低了 8%。

Octo 是一种基于 Transformer 的通用策略，在 Open X-Embodiment 数据集的 80 万条演示上训练而成。该策略包含一个卷积神经网络编码器和一个视觉 Transformer 风格的骨干网络，并配备基于扩散的动作头来预测动作序列。我们使用 Octo-small 进行评估。将 RoboMonkey 与 Octo 集成后，均方根误差达到 0.166，相比其贪心基线（0.196）降低了 15.3%。

SpatialVLA 是一个具有 35 亿参数的空间感知视觉-语言-动作模型，在来自 OXE 和 RH20T 的 110 万条机器人轨迹上训练。该模型使用 Ego3D 位置编码将深度估计中的三维空间上下文整合到视觉特征中。它基于 PaLI-Gemma-2 骨干网络进行预训练。部署时，我们使用 0.5 的温度进行采样。**SpatialVLA** 与 RoboMonkey 结合后，均方根误差达到 0.1298，相比其基线 0.137 降低了 5.3%。

E 奖励建模中边距的消融实验

α	Precision	Recall	F1 Score
0	0.81	0.85	0.83
0.1	0.84	0.87	0.85
1.0	0.79	0.83	0.81

表 2: 不同边距权重 α 下动作验证器在损失函数中的性能比较。我们发现引入较小的边距 ($\alpha=0.1$) 可提升精确率、召回率和 F1 分数

如第 4.3 节所示，训练动作验证器的损失函数遵循 Bradley-Terry 模型 [37]，并附加一个边距分量以考虑偏好等级。

$$\mathcal{L}(\phi; \mathcal{D}_{\text{comp}}) = -\mathbb{E}_{(a_t^W, a_t^L, a_t^*, s_t, I) \sim \mathcal{D}_{\text{comp}}} \left[\log \sigma \left(R_\phi(a_t^W, s_t, I) - R_\phi(a_t^L, s_t, I) - \alpha \left\| \Delta_t^* - \hat{\Delta}_t \right\|_2^2 \right) \right],$$

其中 $\alpha \in \mathbb{R}$ 是控制偏好水平幅度的超参数。为评估该间隔项的有效性，我们按照第 4.2 节所述流程，从 Bridge V2 数据集生成了 10,000 个合成动作比较对。每个动作对由明显不同的动作组成。我们训练了两种带间隔项的动作验证器变体 ($\alpha \in 0.1, 1.0$)，并将其性能与不带间隔项的基线模型 ($\alpha=0$) 进行比较。表 2 报告了每种设置下的精确率、召回率和 F1 分数。采用 $\alpha=0.1$ 的变体取得了最高的 F1 分数 (0.85)，优于不带间隔的基线 ($\alpha=0$, F1 为=0.83) 和大间隔变体 ($\alpha=1.0$, F1 为=0.81)。这些结果表明，引入间隔项可以提升动作验证器的性能，但过大的间隔可能对验证准确率产生负面影响。基于此分析，我们采用 $\alpha=0.1$ 变体进行部署。

F 消融：基于偏好的学习




图 10: 基于偏好的学习与 RMSE 回归在不同样本数量下的比较。虽然两者在分布内表现相似，但偏好学习在分布外设置中泛化能力更强。

为进一步理解基于偏好的学习方法的有效性，我们进行消融实验，将 Bradley-Terry 目标与直接预测 RMSE 值的基线进行比较。具体而言，我们训练一个替代动作验证器，训练一个轮次，以最小化预测 RMSE 与真实 RMSE 之间的 L2 损失：

$$\mathcal{L}(\phi; \mathcal{D}_{\text{comp}}) = \mathbb{E}_{(a_t, a_t^*, s_t, I) \sim \mathcal{D}_{\text{comp}}} \|R_\phi(a_t, s_t, I) - \text{RMSE}(a_t, a_t^*)\|_2^2$$

其中验证器直接学习预测任意候选动作 a_t 与真实值之间的 RMSE action a_t^* .

我们遵循第 3 节和附录 C 中描述的设置，使用 Bridge V2 数据集 [11] 进行分布内评估。对于分布外分析，我们从具有未见指令和环境的保留轨迹中采样 1,000 个 (s, a^*, I) 元组。误差线表示三个随机种子下的标准差。

如图 10 所示，两种方法在分布内环境中性能相近，基于偏好的学习略优于均方根误差回归。然而，在分布外环境中性能差距显著。当采样 64 个候选动作时，基于偏好的学习相比均方根误差回归实现了低 6% 的动作误差。这一结果揭示了一个关键洞见：基于偏好的学习不是直接回归均方根误差值，而是教会模型在动作之间进行相对比较，从而实现更强的泛化。

G 采样与验证的延迟和吞吐量分析

Batch Sizes	OpenVLA		OpenVLA + SGLang		Action Verifier	
	Latency (s)	Throughput	Latency (s)	Throughput	Latency (s)	Throughput
1	0.15	6.5	0.13	7.6	0.092	11
2	0.31	3.3	0.21	9.6	0.099	20
4	0.61	1.6	0.28	15	0.13	32
8	1.2	0.82	0.42	19	0.20	39
16	2.4	0.41	0.72	22	0.35	46
32	4.9	0.20	1.3	25	0.65	49
64	9.8	0.10	2.4	27	1.3	50
128	20	0.050	4.6	28	2.5	51

表 3: OpenVLA 在不同批大小下的延迟（秒）和吞吐量（样本/秒）对比，Optimized OpenVLA, and 7B Action Verifier.

重复采样可以利用键值缓存优化和批处理来获得比贪心解码更高的吞吐量。然而，大多数视觉-语言-动作模型，包括 OpenVLA，都建立在棱镜视觉-语言模型之上，不支持批处理 [2]。SGLang 提供了高效的推理服务，具有前缀缓存、零开销中央处理器调度和分页注意力。因此，为了使 RoboMonkey 在实际部署中实用，我们扩展了 SGLang 的能力，以正确支持棱镜视觉-语言模型 [2]，从而在重复采样期间实现更高的吞吐量。用户可以使用我们提供的模板轻松地将他们的棱镜视觉-语言模型移植到 SGLang。

我们在单个 H100 上进行了实验，以测量 OpenVLA 推理在不同批大小下的延迟和吞吐量。如表 3 所示，我们的优化实现显著优于朴素版本 [2]。例如，在批大小为 32 时，我们的推理引擎将延迟降低了 74%，吞吐量提高了 120 倍以上。即使在较小的批大小（例如 4）下，我们的视觉-语言-动作推理引擎也实现了 54% 的延迟降低。

我们的动作验证器也显著受益于批推理，在批大小为 16 时实现了 46 个动作/秒的吞吐量。它明显快于 OpenVLA，因为它只需要在预填充阶段进行计算，可以充分利用图形处理器并行性。相比之下，OpenVLA 涉及预填充和解码两个阶段——动作标记必须自回归生成——导致吞吐量较低。

H 动作误差与计算开销之间的权衡

在本次消融实验中，我们考察了动作误差与计算开销之间的权衡。在图 11 中，我们复现了第 3 节的缩放曲线，但绘制的是动作误差随延迟的变化。在相同的计算预算下，高斯扰动相比策略采样实现了显著更低的预言机动作误差。我们观察到，随着计算预算的增加，两种方法之间的差距不断扩大。这一不断扩大的性能差距反映了高斯扰动仅随验证器扩展，




图 11: 动作误差（平均均方根误差）作为策略采样和高斯扰动计算开销的函数。在相同的计算预算下，高斯扰动始终实现更低的动作误差

而策略采样则因策略和验证器而产生额外开销。这些结果凸显了高斯扰动作为部署中更实用选择的优势。

I 符号说明

Symbol	Description
$\mathcal{S}$	State space
$\mathcal{A}$	Action space
τ	Trajectory
I	Task instruction
π_θ	Generalist robot policy parameterized by θ
a_t	Action at timestep t : $[\Delta x_t, \Delta y_t, \Delta z_t, \Delta u_t, \Delta v_t, \Delta w_t, g_t]$
g_t	Binary gripper state (open or close)
$P(s' s, a)$	Transition dynamics
$R_\phi(s, a, I)$	Reward model parameterized by ϕ
$\mathcal{D}$	Demonstration dataset
$\mathcal{D}_{\text{buf}}$	Auxiliary dataset of state-action-instruction tuples
$\mathcal{D}_{\text{comp}}$	Synthetic action preference dataset
σ	Sigmoid function
N, K	Number of candidate and clustered actions (training)
a_t^i	i -th action sampled from policy (training)
$\hat{N}, \hat{K}$	Number of sampled and augmented actions (test-time)
$\hat{a}_t^i$	i -th action sampled from policy (test-time)
$\tilde{a}_t^i$	i -th action sampled from proposal distribution
μ_t, Σ_t	Mean and covariance of a Gaussian distribution
(a_t^W, a_t^L)	Preferred and less preferred action pair
Δ_t^*	Ground-truth RMSE difference
$\hat{\Delta}_t$	Predicted RMSE difference
α	Margin weight in loss function