

RoboTTT: 机器人策略的上下文扩展


Yunfan Jiang^{1,2}, Yevgen Chebotar¹, Ruijie Zheng¹, Fengyuan Hu¹, Yunhao Ge¹

Jimmy Wu¹, Tianyuan Dai^{1,3}, Scott Reed¹, Li Fei-Fei^{2,†}, Yuke Zhu^{1,3,†}, Linxi “Jim” Fan^{1,†}

¹NVIDIA ²Stanford University ³The University of Texas at Austin [†]同等指导

research.nvidia.com/labs/gear/robottt

Better Long-Horizon Task Performance (Duration = 5 Minutes)




One-Shot Imitation from In-Context Human Demonstration

In-Context Human Demonstration



Robot Execution



On-the-Fly Improvement



Robustness to External Perturbation




图 1: RoboTTT, 一种长上下文视觉运动策略, 将测试时训练 (TTT) 集成到机器人基础模型中, 上下文扩展到 8K 时间步。RoboTTT 展现出从人类视频进行一次性上下文模仿和即时策略改进等能力。

摘要

近期机器人基础模型采用单步或短历史视觉运动上下文。本文提出测试时训练机器人策略 (RoboTTT)，一种机器人模型与训练方案，将视觉运动上下文扩展到 8K 时间步，比最先进策略高出三个数量级，且不增加推理延迟。在此上下文长度下，我们解锁了新的机器人能力：从人类视频演示进行一次性上下文模仿、即时策略改进、对扰动的鲁棒性，以及在多阶段、长时程任务上更强的性能。我们还首次观察到，随着预训练上下文长度的扩展，闭环性能稳步提升。RoboTTT 的核心是将测试时训练集成到机器人基础模型（如视觉-语言-动作策略）中，产生一个序列模型，其循环状态由快速权重组成，这些参数在训练和推理过程中通过梯度下降更新，将历史压缩到权重空间，并检索上下文信息以进行长上下文条件化。为扩展训练上下文长度，该方案结合了序列动作强制与时间截断反向传播。在具有挑战性的真实机器人操作任务上，RoboTTT 相比单步上下文基线整体性能提升 87%，并完全完成了一个五分钟、十阶段的装配任务，而所有基线均未能完成。使用 8K 时间步上下文训练的 RoboTTT 比使用 1K 时间步预训练的同一模型性能高出 62%，表明上下文长度是机器人基础模型的一个新扩展轴。视频可在 research.nvidia.com/labs/gear/robottt 获取。关键词：长上下文策略，测试时训练，机器人基础模型

1. 引言

大多数最先进的机器人基础模型以单步或短历史视觉运动上下文运行（5；7；8；29；36；37；41；47；51；60；67；75；76）。相比之下，上下文长度已成为大语言模型的重要扩展轴（9；16；27；46；53；71）。虽然机器人中的长期推理可以委托给外部记忆库（50；69），但长视觉运动上下文对于以下能力仍然重要：从人类视频演示中进行一次性上下文模仿（18）、从机器人自身部署历史中即时改进（39），以及在多阶段、长时程任务上实现更强的闭环性能。这引出一个自然的问题：我们如何构建能够从任意长上下文学习中学习并利用它们的视觉运动策略？

为了回答这个问题，我们提出了测试时训练机器人策略 (RoboTTT，图 1)，这是一种机器人模型和训练方案，将视觉运动上下文扩展到 8K 时间步（称为 RoboTTT-8K），比最先进的机器人基础模型（5；51；75）高出三个数量级，且不增加推理延迟。在此上下文长度下，RoboTTT 展现出新的机器人能力。通过长上下文条件化，它能够从单个上下文人类视频演示中进行一次性模仿，在 10 次试验中成功 6 次，而基线方法完全失败。它还表现出即时策略改进，比未针对此能力训练的同一模型性能提升 36%。在外部扰动下，它在 83% 的试验中成功，而最佳短上下文基线为 53%。在多阶段、长时程任务上，它比单步上下文基线整体任务性能提升 87%，并完全完成了一个持续超过五分钟、跨越十个阶段的装配任务，而没有任何基线能够做到。最后，我们首次证明扩展预训练上下文长度可带来闭环性能的稳定提升：RoboTTT-8K 的任务完成得分比使用 1K 时间步上下文预训练的同一模型高 63%，比最佳短上下文基线高 57%，这表明上下文长度是机器人基础模型的一个新扩展轴。

其核心在于，RoboTTT 将测试时训练 (Test-Time Training, TTT)（64；78）集成到机器人基础模型中，例如视觉-语言-动作 (Vision-Language-Action, VLA) 策略（51）。RoboTTT 是一种序列模型，其循环状态由快权重 (fast weights)（58）构成：与推理时冻结的慢权重不同，快权重在训练和推理过程中均通过梯度下降进行更新。该设计解决了长上下文视觉运动策略的三个挑战：以足够容量编码长历史、利用条件化上下文（12），以及保持推理成本不随上下文长度增长。首先，由快权重参数化的快模型（例如多层感知机）提供了

比循环神经网络的向量值状态更大的容量。其次，在部署期间训练快模型，能够在机器人观测和动作的密集、重复流中保留显著特征并丢弃冗余特征。第三，随时间传播快权重使推理成本保持恒定，而变换器（Transformer）推理即使使用键值缓存也会随历史增长。关键在于，通过在部署期间学习，RoboTTT 实现了新形式的上下文内适应和策略改进。例如，它根据展示新任务配置的人类视频进行条件化，从而实现一次性模仿。通过 DAgger 蒸馏（DAgger Distillation）这一训练过程，将 DAgger 风格（57）的失败到纠正映射蒸馏到快权重中，它学会了即时改进。为了扩展训练上下文长度，我们的方法将序列动作强制与截断的时间反向传播（TBPTT）相结合，使上下文增长而无需增加 GPU 内存。视频可在 research.nvidia.com/labs/gear/robottt 查看。

2. 预备知识

测试时训练机制 测试时训练（Test-Time Training, TTT）（64; 78）引入了快权重，在训练和推理过程中均进行更新，以动态建模上下文信息。这与慢权重（即模型参数）形成对比，慢权重仅在训练期间更新，推理时保持冻结。形式上，考虑一个由 d 维标记 X 组成的序列，以及由投影矩阵 $\theta_O, \theta_K, \theta_V$ 诱导的查询、键和值序列 Q, K, V ，其中 Q_t, K_t, V_t 表示时间步 t 处的投影。快权重 W 参数化一个小型神经网络 $f_W(\cdot): \mathbb{R}^d \rightarrow \mathbb{R}^d$ ，例如线性层或多层感知机。在时间步 t ，快权重被更新以将 K 与其对应的值投影 V 关联起来，通过

$$W_t \leftarrow W_{t-1} - \eta \nabla_W \mathcal{L}_{FW}(f_{W_{t-1}}(K_t), V_t), \quad (1)$$

其中 $\mathcal{L}_{FW}(\hat{v}, v) = \|\hat{v} - v\|^2$ 通常是均方误差， η 表示（可学习的）学习率。更新后的快速权重随后在应用步骤中计算输出 O_t ，具体为

$$O_t = f_{W_t}(Q_t). \quad (2)$$

这种“先更新后应用”的操作在训练和推理过程中都会发生。直观上，更新步骤将上下文信息编码到快速模型的参数空间 f_W 中，而应用步骤则将其提取出来用于下游预测。投影矩阵 $\theta_O, \theta_K, \theta_V$ 和快速权重初始化 W_0 通过外部任务损失进行学习，从而使历史机制针对当前任务进行优化。在推理时，TTT 因此将先前处理的标记压缩到其快速权重中，而标准全注意力则在内存中保留所有先前的键和值，并在每一步对其进行注意力计算。

机器人序列模型 在这项工作中，我们考虑以自身展开历史为条件的机器人策略，也称为机器人序列模型（22; 32; 56; 67）。具体而言，机器人轨迹 $\xi = \{(o_t, q_t, A_t)\}_{t=1}^T$ 由图像 o_t 、本体感知 q_t 和动作块 A_t 元组组成；为简单起见，我们省略了语言模态。我们学习策略 $\pi(A_t | \xi_{<t}, o_t, q_t)$ ，该策略以时间步 t 之前的历史 $\xi_{<t}$ 和当前观测为条件。对于长上下文策略，我们旨在扩展上下文长度 $|\xi_{<t}|$ 。

3. 方法：测试时训练机器人策略

在本节中，我们介绍测试时训练机器人策略（RoboTTT），这是一种用于在长上下文机器人轨迹上进行学习的机器人模型和训练方案。我们首先描述模型架构以及如何将 TTT 集成到现代机器人基础模型中，然后介绍一种将序列动作强制与截断时间反向传播（TBPTT）相结合的训练方案，以扩展训练上下文长度。接着，我们描述 RoboTTT 如何实现长上下文条件化，从而解锁新形式的上下文适应和策略改进：从上下文人类视频演示中进行一次性模仿，以及 DAgger 蒸馏，这是一种元学习方法，通过将 DAgger 风格（57）的纠正过程（将次优机器人动作映射到人类纠正）蒸馏到其快速权重中，教会策略即时改进。最后，我们分享实现细节。




图 2: RoboTTT 模型架构、训练与推理。TTT 层被添加在 DiT 动作头中的注意力层之后：注意力在每个时间步内运作，而 TTT 层跨时间步运作。训练使用序列流匹配损失与序列动作强制，对每个动作块独立采样噪声水平。推理从学习到的初始化 W_0 开始，在每个观测上更新快速权重并将其向前传播。

3.1. 模型架构

RoboTTT 将 TTT 层集成到机器人基础模型中，例如 VLA 模型，同时保持与底层架构的兼容性，因此适用于广泛的骨干网络。在本文中，我们在 GR00T N1.7 (51) 之上实例化 RoboTTT。

机器人动作的测试时训练 如图 2 所示，RoboTTT 由一个视觉语言模型 (VLM) 骨干和一个带有 TTT 层的扩散 Transformer (DiT) (52) 动作头组成。在时间步 t ，它预测一个 H 步的动作块 $A_t = [a_t, \dots, a_{t+H-1}]$ 。我们在自注意力和交叉注意力层之后添加 TTT 层，使得注意力处理单步信息，而 TTT 层处理跨时间维度的信息。具体而言，RoboTTT 的 DiT 输入是一个跨越 T 个时间步的机器人轨迹， $[R_1, \Phi_1, q_1, \bar{A}_1, \dots, R_T, \Phi_T, q_T, \bar{A}_T]$ ，其中 Φ_t 是 VLM 输出的视觉语言 (VL) token， q_t 是编码后的本体感觉 token， $\bar{A}_t$ 是加噪的动作 token， R_t 是 N 个学习到的寄存器 token (14; 30)，它们被前置在每个时间步并关注所有其他 token。注意力层作用于单步 token R_t, q_t 和 $\bar{A}_t$ ，并与该时间步的 VL token Φ_t 进行交叉注意力。每个时间步的注意力输出随后沿时间维度拼接， $X = [R_1, q_1, \bar{A}_1, \dots, R_T, q_T, \bar{A}_T]$ ，并通过 TTT 层进行快速权重更新 (公式 1) 和输出 (公式 2)。出于计算效率考虑，我们避免将 VL token Φ 直接通过 TTT 层，而是依赖数量较少 ($N = 16$) 的寄存器 token R 来跨时间传递 VL 信息。

用于保持预训练能力的门控机制 为保留预训练视觉语言动作模型的知识，RoboTTT 从基础模型权重初始化，并采用一种可学习的双曲正切门控机制 (1)，在训练开始时保持测试时训练贡献较小。具体而言，对于每个 DiT 层，我们学习 $\alpha \in \mathbb{R}^d$ ，初始化为接近零 (0.001)，并通过以下方式门控测试时训练贡献：

$$O = \tanh(\alpha) \odot O_{\text{TTT}} + O_{\text{attn}}, \quad (3)$$

其中 O_{TTT} 是公式 2 中的测试时训练层输出， O_{attn} 是注意力层输出。通过这种方式，RoboTTT 学会调整测试时训练层的贡献，而不会干扰预训练模型的计算。




图 3: 使用双曲正切门控的计算流程。TTT 输出在被加到注意力输出之前，由学习到的门控 $\tanh(\alpha)$ 加权。

3.2. RoboTTT 序列训练

我们在机器人轨迹序列上训练 RoboTTT，使得快速权重在每个训练序列内更新，同时学习合适的快速权重初始化及其更新动态。测试时训练投影矩阵 $\theta_O, \theta_K, \theta_V$ 和快速权重初始化 W_0 作为模型参数的一部分进行学习。具体而言，给定一个训练序列，我们在内循环中对其运行测试时训练，使用快速权重损失 $\mathcal{L}_{FW}$ （第 2 节），在每个时间步计算外部任务损失，并在平均损失上优化完整模型。通过这种方式，投影矩阵直接从外部任务梯度中学习， W_0 通过梯度的梯度进行元学习（21；65），使快速权重重新适应机器人轨迹。

具体而言，我们的数据集 $\mathcal{D} = \{\xi^{(i)}\}_{i=1}^N$ 包含 N 条轨迹，每条轨迹是语言、图像、本体感觉和动作块元组 $\xi = \{(l, o_t, q_t, A_t)\}_{t=1}^T$ 的序列，重新引入在轨迹中共享的语言指令 l 。每个训练序列是完整轨迹或连续子轨迹，最大上下文长度受限。将每步流匹配目标标记为 ℓ_t ，给定快速权重初始化 W_0 时轨迹 ξ 上的序列损失为

$$\mathcal{L}_{fm}(\xi; W_0) = \frac{1}{T} \sum_{t=1}^T \ell_t((l, o_t, q_t, A_t); W_{t-1}), \quad (4)$$

其中 W_{t-1} 是进入时间步 t 的快速权重状态，在测试时训练层内更新为 W_t （公式 1）。每个优化步骤随后对 $\mathcal{L}_{fm}$ 进行梯度更新，同时更新常规模型权重和快速权重初始化。

序列动作强制 RoboTTT 采用流匹配目标对动作进行训练：DiT 动作头学习去噪 $\tilde{A}_t = A_t = \tau A_t + (1 - \tau)\epsilon$ ，其中 $\tau \in [0, 1]$ 为流匹配时间步， $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 为采样噪声。在序列训练中，我们发现有必要为序列中的每个动作块独立采样噪声水平，我们将此技术称为序列动作强制。若不采用该技术，训练会不稳定，可能是因为在整个序列中共享同一噪声水平（全序列扩散）会使整个序列的学习难度一致地简单（低噪声）或一致地困难（高噪声），这与 Chen 等人 (10) 的发现相呼应。

总结来说，将 DiT 动作头表示为 v_θ ，时间步 t 元组表示为 $\xi_t = (l, o_t, q_t, A_t)$ ，我们通过最小化以下目标，利用序列动作强制训练 RoboTTT

$$\mathcal{L}_{fm}(\xi; W_0) = \frac{1}{T} \sum_{t=1}^T \ell_t(\xi_t; W_{t-1}) = \frac{1}{T} \sum_{t=1}^T \mathbb{E}_{\tau_t, \epsilon} \left[\|v_\theta(\Phi_t, A_t^{\tau_t}, q_t; W_{t-1}) - (A_t - \epsilon)\|^2 \right], \quad (5)$$

其中每个 τ_t 独立采样为 $\tau_t = s(1 - u)$, $u \sim \text{Beta}(1.5, 1)$, $s = 0.999$ 。

截断的时间反向传播 使用完整的时间反向传播（BPTT）训练长序列时，需要为每个时间步存储激活，因此 GPU 内存随序列长度增长。我们改用截断的时间反向传播（TBPTT）：将输入序列划分为若干段，梯度仅在每段内部流动（图 4）。关键的是，快速权重跨段边界传递，因此 TTT 在整个序列上持续进行，而它们的梯度在边界处被截断。因此，GPU 内存由段长度而非总序列长度决定，从而在固定内存预算下允许任意长的训练上下文。注意，快速权重初始化 W_0 仍通过第一段接收梯度，其更新直接源自 W_0 。




图 4: TBPTT。梯度在段边界处截断；快速权重跨段传递，因此 TTT 在整个序列上持续进行。

推理 如图 2 所示，RoboTTT 每次 rollout 从学习到的初始化 W_0 开始，根据当前观测更新快速权重，并将其传播到下一个时间步。在每个时间步，动作块通过 k 步去噪生成。

Pup Go Car (T_{avg} : 2 mins)






 Circuit (T_{avg} : 1 min)

 Gear Bot (T_{avg} : 5 mins)


图 5：评估任务。在 YAM 双臂装置上的三个长时程装配任务；每行展示一次执行过程。顶部，Pup Go Car：玩具车装配，平均每回合 2 分钟。中部，Circuit：目标配置由语言提示或一次性人类视频演示指定；每回合 1 分钟。底部，Gear Bot：十阶段装配，持续五分钟，是我们最长时程的任务。

3.3 从上下文中有有效学习

RoboTTT 将快速权重更新与慢速权重更新解耦：通过在选定的时间步上屏蔽流匹配损失，这些时间步仅作为纯上下文，更新快速权重而不提供模仿目标。这种灵活性使 RoboTTT 能够从异构上下文学习，例如人类视频演示或机器人自身的次优执行过程。

从上下文视频演示中模仿 我们将同一任务的人类视频演示序列 ξ^{video} 与机器人轨迹 ξ^{robot} 配对：视频序列仅更新快速权重（其流匹配损失被屏蔽），而动作损失在基于更新后的快速权重的机器人轨迹上计算。通过在这种配对数据上训练，模型学会从上下文视频中提取任务信息；在测试时，仅需一段未见任务配置的人类视频即可实现一次性模仿。

DAgger 蒸馏 考虑一个机器人执行过程，其中人类纠正按照 DAgger (57) 的方式收集：每当机器人出错时，人类操作员介入并给出纠正动作，从而产生一条轨迹 $\xi^{\text{DAgger}} = \{(l, o_t, a_t, A_t)\}_{t=1}^T$ ，其中每个执行的动作块 A_t 要么是机器人动作 A_t^R ，要么是人类纠正 A_t^H 。这种交错的执行过程勾勒出在线策略改进的自然模式。标准 DAgger 在人类纠正上进行微调，并丢弃次优的机器人动作；然而，恰恰是这些动作揭示了每次纠正所应对的失败。RoboTTT 则同时利用两者，但角色不对称：在序列训练期间，快速权重根据完整的交互历史进行更新，不仅包括已执行的纠正，还包括次优的机器人动作本身，而流匹配损失仅被屏蔽到人类纠正上。




图 6：DAgger 蒸馏。在序列训练期间，所有执行的动作都会更新快速权重，但流匹配损失仅在人类纠正上计算。

我们将此过程称为 DAgger 蒸馏 (DAgger Distillation) (图 6)。这种不对称性——失败作为上下文、修正作为目标——正是将人类的失败到修正映射蒸馏到快速权重中的方式：模型学习在响应失败时产生修正，而不是孤立地模仿修正，从而更充分地利用所收集的相同数据。我们将其视为算法蒸馏 (Algorithm Distillation) (39) 在机器人学中的一个实例：




图 7：主要评估：三个装配任务上的任务完成得分。得分基于评分标准，以百分比报告；越高越好。

由人类干预引发的改进过程被蒸馏到策略的快速权重适应中。在测试时，模型在没有人类干预的情况下在线执行此类修正；其自身的修正随后进入历史并被吸收到快速权重中，与训练期间人类修正的方式完全相同。正如我们在第 4 节中所示，DAgger 蒸馏比标准 DAgger 训练产生更强的失败恢复能力和更高的任务性能。

3.4. 实现细节

我们在预训练的 GR00T N1.7 (51) 上实例化 RoboTTT，在其 16 个 DiT 层中的每一层添加一个 TTT 层；每个快速模型是一个两层 MLP。我们在桌面双臂机器人数据和以自我为中心的人类数据 (81) 的混合数据上进行预训练，逐步将预训练上下文长度增加到目标值（例如，RoboTTT-8K 为 8K 时间步），在 16 个 NVIDIA GB200 GPU 上进行 30K 步。然后，我们在每个下游任务上以 1K 上下文长度进行 20K 步的后训练。更多细节见附录 A。

4. 实验

实验设置 我们在三个需要双臂操作和灵巧性的长时程、多阶段装配任务上进行评估（图 5）：Pup Go Car、Circuit 和 Gear Bot。所有实验均使用 YAM 双臂设置，配备四个 RGB 摄像头：顶部、底部、左手腕和右手腕。对于每个任务，我们分别收集 8 小时、6 小时和 5 小时的真实机器人数据，平均回合长度分别为 2 分钟、1 分钟和 5 分钟。Circuit 任务有 80 种装配配置，组件、装配顺序和零件数量各不相同；目标配置通过语言提示（或一次性人类视频演示）指定。我们在 20 种配置上训练，在其余 60 种配置上测试。我们将 RoboTTT 与三个基线进行比较：具有单步上下文的 GR00T N1.7 (51)；GR00T N1.7

历史记录，GR00T N1.7 带一个历史帧；以及 GDN，其中 RoboTTT 的 TTT 层被替换为门控 DeltaNet 层 (74)，这是一种线性复杂度循环记忆，无需测试时梯度下降即可更新状态。所有方法均在相同任务数据上进行后训练：序列模型使用 1K 时间步上下文，非序列模型训练至匹配的计算预算。每个策略在多种配置下评估 20 次试验（Gear Bot 因其显著更长的时域仅评估 10 次）。我们报告完全成功的试验次数以及归一化到 [0, 1] 的基于评分标准的任务完成分数（以百分比报告）。超参数和评分标准见附录 B。

RoboTTT 在灵巧、长时域任务上始终优于基线。如图 7 和表 1 所示，**RoboTTT** 的平均任务完成分数达到 79%，比单步上下文基线 GR00T N1.7 (42%) 高 87%，比最佳基线 GDN (56%) 高 41%，并且在每项任务上拥有最多的完全成功试验。值得注意的是，在平均需要五分钟才能完全完成的 Gear Bot 任务上，**RoboTTT**




图 8：闭环性能随预训练上下文长度扩展。随着预训练上下文长度从 128 增长到 8K 时间步，三个任务的平均任务完成分数。RoboTTT 稳步提升，从 1K 起超越最佳短上下文基线且无饱和迹象；GDN 未从更长上下文中受益。单步上下文和短上下文分别表示 GR00T N1.7 和 GR00T N1.7 Hist.。本图中所有评估均早于主要结果中用于 Pup Go Car 的 DAgger 训练。

实现了完全成功（10 次中 2 次），而所有基线方法均未实现。定性来看，RoboTTT 在三个方面表现突出。首先，它能够跟踪任务进度：在多阶段装配中，视觉上相似的阶段会导致状态混淆，使基线方法执行错误动作或跳过阶段，而快速权重在运行中更新，保留了历史中的显著特征，从而消除当前阶段的歧义。其次，它展现出策略性恢复能力：在 Pup Go Car 上进行车顶钻孔时，如果钻头未对准车顶螺丝，RoboTTT 会抬起机械臂、重新对准并再次尝试，而基线方法则直接进入下一阶段，仿佛前一阶段已成功。第三，在精细阶段（如插入和卡扣电路元件）中更为精确；我们将此归因于长上下文缓解了部分可观测性，因为当目标物体当前被遮挡时，过去的观测信息可为动作提供依据。相关观测窗口难以事先指定；RoboTTT 则学习保留哪些信息，这表明在序列模型具有足够表达能力的情况下，长上下文的使用可以通过学习获得，而非手工设计。

仅靠历史信息能否与 RoboTTT 匹敌？简单拼接过去观测并不可靠：

在 Pup Go Car 上，GR00T N1.7 Hist. 得分为 39.5%，而其无历史版本 GR00T N1.7 为 57%，因为附加的历史可能引入虚假相关性，并使机器人在推理时处于时间分布之外。GDN 将历史压缩为循环状态，在 Circuit 和 Gear Bot 上优于 GR00T N1.7，但在 Pup Go Car 上无提升。

值得注意的是，GDN 和 RoboTTT 都维护固定大小的状态；区别在于更新规则。我们假设门控增量规则是一种线性联想更新，无需测试时梯度下降，难以从数千个时间步的密集、重复机器人流中提取结构，而 RoboTTT 的非线性快速模型在测试时通过梯度下降更新，是更具表达能力的压缩器。

Method	Pup Go Car	Circuit	Gear Bot
RoboTTT	9 / 20	13 / 20	2 / 10
GR00T N1.7	3 / 20	3 / 20	0 / 10
GR00T N1.7 Hist.	0 / 20	8 / 20	0 / 10
GDN	3 / 20	8 / 20	0 / 10

表 1：主要评估：三个装配任务中完全成功的试验次数，每项任务共 20 次（Gear Bot 为 10 次）。RoboTTT 是唯一在 Gear Bot 上实现完全成功的方法。

扩展预训练上下文长度可稳定提升闭环性能。我们在 128 个时间步（几秒钟）到 8K（超过四分钟）的上下文长度上预训练 RoboTTT 和 GDN，然后在所有三个任务上进行后训练并评估闭环性能（图 8）。作为参考，单步上下文表示 GR00T N1.7，仅以当前观测为条件；短上下文表示 GR00T N1.7 Hist.，额外包含一个历史帧。RoboTTT 展现出明显的扩展趋势：闭环性能提升




图 9：基于上下文人类视频的一次性模仿。连续画面：人类演示未见过的配置（第 1–3 帧），场景重置（第 4 帧），RoboTTT 复现装配过程（第二行）。提示在各配置间保持一致，因此目标仅能通过视频识别。

随着预训练上下文长度的增加而稳步提升，在 8K 时达到 71.5%，比在 1K 预训练的同一模型（43.9%）高出 63%，比最佳短上下文基线 GR00T N1.7 Hist.（45.6%）高出 57%，且没有饱和迹象。GDN 没有表现出这种趋势。我们将这种差异归因于两种更新规则：RoboTTT 的快速权重通过梯度下降更新，外部损失元学习其初始化 W_0 和更新动态，更长的训练序列在更多更新步骤中塑造这些动态；而 GDN 的线性关联状态无法进行这种元学习。在 1K 以下，RoboTTT 仍具有竞争力（在匹配长度下仍优于 GDN），但不及更长上下文的变体。我们将此归因于展开长度超过训练上下文：1K 时间步大约半分钟，短于我们最短的任务回合，因此在推理时快速权重的更新远超训练中看到的窗口，位置嵌入也扩展到未见过的位。

长上下文条件化解锁一次性模仿与扰动鲁棒性。我们首先评估单样本模仿。对于电路任务，我们收集了额外的人类演示视频，其中机器人保持空闲，由人类手工组装电路。对于训练集中的每个组装配置，我们收集了 5 到 20 个具有不同初始布局的人类视频。在训练过程中，我们采样一个人类视频和同一配置的机器人轨迹，并将它们拼接成一个单一的训练序列，在视频部分上屏蔽流匹配损失（第 3.3 节）。我们对所有配置使用相同的任务提示“组装电路”，因此目标配置只能从上下文视频中识别。由于 GR00T N1.7 无法以上下文为条件，且人类视频远超 GR00T N1.7 Hist. 的历史窗口，我们将其与 GDN 进行比较。

如表 2 所示，RoboTTT 遵循上下文演示（图 9），在十次试验中实现了六次成功组装，而 GDN 完全失败，拾取了错误的组件或以错误的顺序组装。这表明，尽管循环记忆策略可以编码上下文信息，但它们难以利用这些信息；RoboTTT 则查询一个通过历史梯度下降更新的快速模型，在需要时检索演示的配置。

	Task Completion Score	Number of Successful Rollouts
RoboTTT	65%	6 / 10
GDN	33%	0 / 10

表 2：电路任务上的单样本模仿。任务完成分数和完全成功试验次数，以未见配置的一个上下文人类视频为条件。

我们接下来评估扰动鲁棒性：除了跨回合的条件化，RoboTTT 还在回合内进行条件化。在 Pup Go Car 任务中，人类在机器人安装黄色车顶后将其移除，或在插入轮胎后将其移除；一个以自身推演为条件的策略应返回到扰动前的阶段并重新安装该部件。我们收集了 30 分钟的扰动数据，并将其与任务数据共同训练。如表 3 所示，所有方法都表现出一定的鲁棒性，可能源于这种共同训练，但长上下文方法的反应成功

Method	Roof Perturbation	Tire Perturbation
RoboTTT	15 / 20	18 / 20
GR00T N1.7	10 / 20	11 / 20
GR00T N1.7 Hist.	3 / 20	5 / 20
GDN	13 / 20	18 / 20

表 3：对外部扰动的鲁棒性。每个条目报告成功恢复次数，即在每种条件下 20 次试验中策略重新组装被移除部件的次数。




图 10: Pup Go Car 上的 DAgger 蒸馏结果。在 100 条 DAgger 轨迹池（50 条由 RoboTTT 收集，50 条由 GR00T N1.7 收集）上微调后的任务完成情况。DAgger 蒸馏适用于序列模型 RoboTTT 和 GDN。




图 11: 通过 DAgger 蒸馏学习到的即时恢复。在 Pup Go Car 上拧车顶螺丝时，RoboTTT 未对准螺丝（帧 1-3），抬起手臂重新尝试，更接近但仍未对准（帧 4-5），随后再次调整并成功（帧 6-8）。

更频繁地成功恢复：RoboTTT 在 20 次车顶扰动试验中恢复 15 次，而 GDN 为 13 次，短上下文基线最多为 10 次；RoboTTT 和 GDN 在 20 次轮胎试验中均恢复 18 次。这支持了视觉运动上下文改善回合内条件作用的观点；示例恢复见图 1。

RoboTTT 学会即时恢复并优于标准 DAgger。在 Pup Go Car 上，我们研究了 DAgger 蒸馏与 DAgger 数据的其他使用方式的对比（图 10）。我们分别以 **RoboTTT** 和 GR00T N1.7 为基础策略收集了 50 条 DAgger 轨迹，并使用合并的 100 条轨迹训练所有方法。标准 DAgger 仅基于人类纠正进行微调，在四种方法上平均将基础策略提升 9%，在两种序列模型上提升 13%。DAgger 蒸馏适用于序列模型 **RoboTTT** 和 GDN，它将包含次优机器人动作的完整轨迹作为上下文，仅对人类纠正计算模仿损失（第 3.3 节）。从相同的 DAgger 数据中，它带来了 33% 的平均提升：**RoboTTT** 提升 36%，GDN 提升 29%。值得注意的是，次优机器人动作作为模仿目标没有价值：在完整轨迹（包括机器人动作）上微调 GR00T N1.7 与仅使用纠正的表现相同（两者均为 57%）。它们的价值在于作为上下文：定性来看，DAgger 蒸馏的大部分收益来自错误动作后的恢复（图 11），这表明蒸馏到快速权重中的失败到纠正的映射在部署过程中表现为即时改进。GDN 也大幅提升，表明 DAgger 蒸馏普遍适用于序列模型策略，尽管 **RoboTTT** 受益最大。

重要的设计选择 RoboTTT 的性能。我们消融了关键设计选择。首先，我们比较两个变体：不带序列动作强制的 **RoboTTT**（无序列动作强制）和将快速模型替换为线性层的 **RoboTTT**（TTT 线性）。其次，我们追溯 **RoboTTT** 的发展路线图：TTT 层仅处理状态令牌（状态令牌），然后额外将动作令牌传入 TTT 层（+ 动作令牌），最后插入学习到的寄存器令牌（+ 寄存器令牌），得到完整的 **RoboTTT**。由于寄存器令牌增加了独立于 TTT 的容量，我们还为 GR00T N1.7 增加相同数量的寄存器令牌，以便比较隔离 TTT 机制与额外令牌的影响。




图 12: Pup Go Car 任务上的消融结果。我们消融了序列动作强制和快速模型架构（MLP 与线性），并追踪了开发过程中添加的每个组件（状态令牌、动作令牌、寄存器令牌）。包含寄存器令牌的 GR00T N1.7 用于匹配令牌数量的比较。

如图 12 所示，在训练期间移除序列动作强制会显著损害闭环性能：由此产生的不准确动作使机器人无法取得有意义的进展。这强调了在序列训练中对不同噪声动作块应用不同噪声水平的重要性。TTT 线性变体优于 GR00T N1.7 基线，但仍非最优，比 MLP 快速模型差 27%，这表明表达性强的非线性快速模型最为重要，与视觉和语言建模任务中的发现相呼应（78）。

从仅处理状态令牌的 TTT MLP 开始，我们通过逐步添加令牌来提升性能。添加动作令牌带来 23% 的相对改进：模型意识到自身过去的动作，能更好地捕捉环境动态。添加寄存器令牌进一步带来 18% 的相对改进。相比之下，寄存器令牌对 GR00T N1.7 没有帮助。这表明学习到的寄存器令牌仅在搭配 TTT 的时间建模时才有益，帮助模型编码上下文信息。

5. 相关工作

长上下文策略 大多数最先进的机器人基础模型使用单步或短历史上下文。大多数视觉-语言-动作模型（VLA）和一些世界动作模型（WAM）仅采用当前观测（5；29；36；37；51；60；76）或少数连续观测（通常为 2 到

8）（7；8；41；47；67；75）。部分工作通过视觉提供运动轨迹（80）、压缩视觉-语言令牌（31）、预测过去动作（68）或缓存并门控历史令牌（23）等方式扩展观察窗口。然而，这些模型仍受限于固定的上下文大小。对于更长的视野，历史可被委托给更高层次的语义，如关键帧（50；61）和语言（44；69），但长视觉运动上下文对于上下文学习（18；22）、即时策略改进（39）和适应（38；55；66）等能力仍然重要。

另一条研究路线以自回归方式处理整个轨迹历史（6；22；32；40；56）。尽管这些模型能很好地捕捉长上下文依赖，但在真实机器人长期部署中计算代价过高，因为带键值缓存的解码延迟随上下文长度线性增长。循环神经网络策略（49）提供了恒定推理复杂度的替代方案，但长短期记忆网络等传统架构（26）的扩展性不如全注意力对应模型（34）。RoboTTT 也可视为一种循环神经网络策略，其循环状态为快速权重，通过测试时训练损失上的梯度下降进行更新。关键在于，这种循环结构使我们能够扩展上下文长度，并且我们证明，一旦上下文长度得到充分扩展，RoboTTT 始终优于最佳单步和短上下文基线。

构建长上下文策略需要解决由历史引入的虚假相关性（15；70），其中策略过度拟合了过去观测中隐式编码的过去动作。先前的工作缓解了这一问题

通过总结上下文历史（50；61）、引入辅助目标（68）或选择性地绕过上下文（23）。RoboTTT 则通过学习的 TTT 快速权重来解决这一问题，这些权重动态地将相关信息编码到参数空间中，同时擦除冗余特征。

测试时训练 测试时训练（Test-Time Training, TTT）（63）是一种范式，其中神经网络在训练和推理过程中，利用自监督目标快速更新其参数的一小部分（称为快速权重），从而能够持续存储和检索上下文信息。近期研究开发了改进的测试时优化和在线学习目标（3；4；35；78），实现了与语言和视觉模型更紧密的架构集成（20；24；65；79），并提出了更高效的训练策略（42；43）。TTT 最初在语言建模中得到验证（77），此后在视频生成（13）、计算机视觉（24）和三维重建（11）中展现出有前景的结果。这些模态本质上是序列化的，TTT 在这些领域的成功表明其在机器人领域具有强大的潜力，因为智能体同样以连续、流式的方式与环境交互。

虽然近期有几项工作（2；45；82）在机器人领域使用了“测试时训练”这一术语，但它们并未采用快速权重，而是通过在测试任务上收集额外数据来微调整个模型。与我们的设置最接近的是 Ziakas 和 Russo（83）的工作，该工作为视觉语言模型（Vision-Language Models, VLMs）配备快速权重，以适应机器人任务中的价值函数。相比之下，RoboTTT 在 TTT 层之上构建机器人视觉运动策略。通过扩展训练上下文长度，我们证明 RoboTTT 展现出新的能力，例如从上下文人类演示视频中进行一次性模仿和在线策略改进，同时在长时程任务上实现更强的闭环性能。

机器人基础模型 近年来，机器人基础模型取得了快速进展，这些模型建立在大规模视觉语言预训练之上，并将其适配到机器人控制中（5；7；8；19；29；32；36；51；67；72；80）。一种常见的范式是从预训练的视觉语言模型初始化，并添加一个动作生成模块，将多模态表示映射为机器人动作。现有方法的主要区别在于动作的表示和预测方式。一类方法将控制形式化为自回归序列建模，将动作离散化为通过下一词元预测生成的词元（36；54；72）。另一类方法通过将预训练的视觉语言模型与扩散或流匹配策略头相结合来保留连续动作空间（5；17；51；67），从而更富表现力地建模多模态动作分布。虽然 RoboTTT 原则上可以作为任何机器人基础模型架构的即插即用模块，但本文将其实例化在流匹配 GR00T-N1.7（51）策略上，该策略是本文默认的主干网络。值得注意的是，尽管 GR00T-N1.7 仅使用单步或短上下文进行训练，RoboTTT 将其上下文扩展到 8K 时间步（在 30 Hz 控制下约五分钟），并且本文发现，只有当上下文长度充分扩展时，长上下文条件化等能力才会出现。

6. 局限性与结论

本研究存在若干局限性。首先，扩展训练上下文长度会增加训练成本；未来工作可以采用更近期的 TTT 训练技术，如 TNT（42）。其次，虽然本文开发了一种将 TTT 集成到机器人基础模型中的原则性方法，但未来工作可以探索面向机器人学的 TTT 层目标（如针对视觉所探索的（24））。最后，尽管 RoboTTT 显著提升了任务性能，但它并不能处理部署中遇到的所有失败模式；将其与强化学习相结合以直接优化任务成功率是一个自然的下一步。

我们提出 RoboTTT，一种将机器人策略的视觉运动上下文扩展到 8K 时间步的机器人模型与训练方案。在此上下文长度下，RoboTTT 解锁了新的机器人能力：从上下文人类视频演示中进行一次性模仿、策略的即时改进、对外部扰动的鲁棒性，以及在多阶段、长时程任务上更强的闭环性能。其核心在于，RoboTTT 将测试时训练集成到机器人基础模型中，作为沿时间维度的序列建模机制，而其训练方案结合了序列动作强制与时间截断反向传播，使得长序列训练变得可行。我们首次观察到，扩展预训练上下文长度能够持续提升闭环性能，这表明上下文长度是机器人基础模型的一个新扩展轴。

致谢

我们感谢 Frederik Ebert、Letian Fu、Abhishek Gupta、Joel Jang、Hanjung Kim、Dantong Niu、Rutav Shah、You Liang Tan、Josiah Wong、Haoyu Xiong、Ruohan Zhang、Tianyuan Zhang 和 Chuning Zhu 的建设性讨论。我们感谢 Zhe Zhang 和 Connor Pedersen 提供的计算集群支持。我们感谢 Amy Nguyen、Matin Furutan、Matin Nikoui、Mona Abbas、Lion Park、Ramanpreet Singh、Alaa Eltayeb、Dona Alhabibi、Marcelo Kulik、Nachiket Timmanagoudar 和 Josiah Minor 在真实机器人操作、数据收集和评估方面的工作。我们感谢 Tri Cao 和 Yuqi Xie 在发布方面的帮助。最后，我们感谢 NVIDIA GEAR 团队和斯坦福视觉与学习实验室的持续支持。

参考文献

- [1] Jean-Baptiste Alayrac, Jeff Donahue, Pauline Luc, Antoine Miech, Iain Barr, Yana Hasson, Karel Lenc, Arthur Mensch, Katie Millican, Malcolm Reynolds, Roman Ring, Eliza Rutherford, Serkan Cabi, Tengda Han, Zhitao Gong, Sina Samangooei, Marianne Monteiro, Jacob Menick, Sebastian Borgeaud, Andrew Brock, Aida Nematzadeh, Sahand Sharifzadeh, Mikolaj Binkowski, Ricardo Barreira, Oriol Vinyals, Andrew Zisserman, and Karen Simonyan. Flamingo: a visual language model for few-shot learning. *arXiv preprint arXiv: 2204.14198*, 2022. 4
- [2] Zechen Bai, Chen Gao, and Mike Zheng Shou. Evolve-vla: Test-time training from environment feedback for vision-language-action models. *arXiv preprint arXiv: 2512.14666*, 2025. 12
- [3] Ali Behrouz, Peilin Zhong, and Vahab Mirrokni. Titans: Learning to memorize at test time. *arXiv preprint arXiv: 2501.00663*, 2024. 12
- [4] Ali Behrouz, Meisam Razaviyayn, Peilin Zhong, and Vahab Mirrokni. It’s all connected: A journey through test-time memorization, attentional bias, retention, and online optimization. *arXiv preprint arXiv: 2504.13173*, 2025. 12
- [5] Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, et al. $\pi 0$: A vision-language-action flow model for general robot control, 2024. URL <https://arxiv.org/abs/2410.24164>, 2024. 2, 11, 12
- [6] Konstantinos Bousmalis, Giulia Vezzani, Dushyant Rao, Coline Devin, Alex X. Lee, Maria Bauzá Villalonga, Todor Davchev, Yuxiang Zhou, Agrim Gupta, A. Raju, Antoine Laurens, Claudio Fantacci, Valentin Dalibard, Martina Zambelli, M. F. Martins, Rugile Pevceviciute, M. Blokzijl, Misha Denil, Nathan Batchelor, Thomas Lampe, Emilio Parisotto, Konrad Zolna, Scott E. Reed, Sergio Gómez Colmenarejo, Jon Scholz, A. Abdolmaleki, Oliver Groth, Jean-Baptiste Regli, Oleg O. Sushkov, Thomas Rothörl, José Enrique Chen, Yusuf Aytar, Dave Barker, Joy Ortiz, M. Riedmiller, Jost Tobias Springenberg, R. Hadsell, F. Nori, and N. Heess. Robocat: A self-improving generalist agent for robotic manipulation. *Trans. Mach. Learn. Res.*, 2024. 11
- [7] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Joseph Dabis, Chelsea Finn, K. Gopalakrishnan, Karol Hausman, Alexander Herzog, Jasmine Hsu, Julian Ibarz, Brian Ichter, A. Irpan, Tomas Jackson, Sally Jesmonth, Nikhil J. Joshi, Ryan C. Julian, Dmitry Kalashnikov, Yuheng Kuang, Isabel Leal, Kuang-Huei Lee, S. Levine, Yao Lu, U. Malla, D. Manjunath, Igor Mordatch, Ofir Nachum, Carolina Parada, Jodilyn Peralta, Emily Perez, Karl Pertsch, Jornell Quiambao, Kanishka Rao, M. Ryoo, Grecia Salazar, Pannag R. Sanketi, Kevin Sayed, Jaspiar Singh, S. Sontakke, Austin Stone, Clayton Tan, Huong Tran, Vincent Vanhoucke, Steve Vega, Q. Vuong, F. Xia, Ted Xiao, Peng Xu, Sichun Xu, Tianhe Yu, and Brianna Zitkovich. Rt-1: Robotics transformer for real-world control at scale. *Robotics: Science and Systems*, 2022. doi: 10.48550/arXiv.2212.06817. URL <https://arxiv.org/abs/2212.06817v2>. 2, 11, 12
- [8] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, K. Choromanski, Tianli Ding, Danny Driess, Kumar Avinava Dubey, Chelsea Finn, Peter R. Florence, Chuyuan Fu, Montse Gonzalez Arenas, K. Gopalakrishnan, Kehang Han, Karol Hausman, Alexander Herzog, Jasmine Hsu, Brian Ichter, A. Irpan,

- Nikhil J. Joshi, Ryan C. Julian, Dmitry Kalashnikov, Yuheng Kuang, Isabel Leal, S. Levine, H. Michalewski, Igor Mordatch, Karl Pertsch, Kanishka Rao, Krista Reymann, M. Ryoo, Grecia Salazar, Pannag R. Sanketi, P. Sermanet, Jaspiar Singh, Anikait Singh, Radu Soricut, Huong Tran, Vincent Vanhoucke, Q. Vuong, Ayzaan Wahid, Stefan Welker, Paul Wohlhart, Ted Xiao, Tianhe Yu, and Brianna Zitkovich. Rt-2: Vision-language-action models transfer web knowledge to robotic control. *Conference on Robot Learning*, 2023. doi: 10.48550/arXiv.2307.15818. URL <https://arxiv.org/abs/2307.15818v1>. 2, 11, 12
- [9] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel M. Ziegler, Jeffrey Wu, Clemens Winter, Christopher Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever, and Dario Amodei. Language models are few-shot learners. *arXiv preprint arXiv: 2005.14165*, 2020. 2
- [10] Boyuan Chen, Diego Marti Monso, Yilun Du, Max Simchowitz, Russ Tedrake, and Vincent Sitzmann. Diffusion forcing: Next-token prediction meets full-sequence diffusion. *arXiv preprint arXiv: 2407.01392*, 2024. 5
- [11] Xingyu Chen, Yue Chen, Yuliang Xiu, Andreas Geiger, and Anpei Chen. Ttt3r: 3d reconstruction as test-time training, 2026. URL <https://arxiv.org/abs/2509.26645>. 12
- [12] Yinpei Dai, Hongze Fu, Jayjun Lee, Yuejiang Liu, Haoran Zhang, Jianing Yang, Chelsea Finn, Nima Fazeli, and Joyce Chai. Robomme: Benchmarking and understanding memory for robotic generalist policies. *arXiv preprint arXiv:2603.04639*, 2026. 2
- [13] Karan Dalal, Daniel Kocaja, Jiarui Xu, Yue Zhao, Shihao Han, Ka Chun Cheung, Jan Kautz, Yejin Choi, Yu Sun, and Xiaolong Wang. One-minute video generation with test-time training. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 17702–17711, June 2025. 12
- [14] Timothée Darcet, Maxime Oquab, Julien Mairal, and Piotr Bojanowski. Vision transformers need registers. In *The Twelfth International Conference on Learning Representations, ICLR 2024, Vienna, Austria, May 7-11, 2024*. OpenReview.net, 2024. URL <https://openreview.net/forum?id=2dn03LLiJ1>. 4
- [15] Pim de Haan, Dinesh Jayaraman, and Sergey Levine. Causal confusion in imitation learning. In H. Wallach, H. Larochelle, A. Beygelzimer, F. d’Alché-Buc, E. Fox, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 32. Curran Associates, Inc., 2019. URL https://proceedings.neurips.cc/paper_files/paper/2019/file/947018640bf36a2bb609d3557a285329-Paper.pdf. 11
- [16] Yiran Ding, Li Lyna Zhang, Chengruidong Zhang, Yuanyuan Xu, Ning Shang, Jiahang Xu, Fan Yang, and Mao Yang. Longrope: Extending LLM context window beyond 2 million tokens. In Ruslan Salakhutdinov, Zico Kolter, Katherine A. Heller, Adrian Weller, Nuria Oliver, Jonathan Scarlett, and Felix Berkenkamp, editors, *Forty-first International Conference on Machine Learning, ICML 2024, Vienna, Austria, July 21-27, 2024*, volume 235 of *Proceedings of Machine Learning Research*, pages 11091–11104. PMLR / OpenReview.net, 2024. URL <https://proceedings.mlr.press/v235/ding24i.html>. 2
- [17] Danny Driess, Jost Springenberg, Brian Ichter, Lili Yu, Adrian Li-Bell, Karl Pertsch, Allen Ren, Homer Walke, Quan Vuong, Lucy Xiaoyang Shi, et al. Knowledge insulating vision-language-action models: Train fast, run fast, generalize better. *Advances in Neural Information Processing Systems*, 38:102867–102888, 2026. 12
- [18] Yan Duan, Marcin Andrychowicz, Bradley Stadie, OpenAI Jonathan Ho, Jonas Schneider, Ilya Sutskever, Pieter Abbeel, and Wojciech Zaremba. One-shot imitation learning. *Advances in neural information processing systems*, 30, 2017. 2, 11

-
- [19] Haoquan Fang, Jiafei Duan, Donovan Clay, Sam Wang, Shuo Liu, Weikai Huang, Xiang Fan, Wei-Chuan Tsai, Shirui Chen, Yi Ru Wang, Shanli Xing, Jaemin Cho, Jae Sung Park, Ainaz Eftekhari, Peter Sushko, Karen Farley, Angad Wadhwa, Cole Harrison, Winson Han, Ying-Chun Lee, Eli VanderBilt, Rose Hendrix, Suveen Ellawela, Lucas Ngoo, Joyce Chai, Zhongzheng Ren, Ali Farhadi, Dieter Fox, and Ranjay Krishna. Molmoact2: Action reasoning models for real-world deployment, 2026. URL <https://arxiv.org/abs/2605.02881>. 12
 - [20] Guhao Feng, Shengjie Luo, Kai Hua, Ge Zhang, Wenhao Huang, Di He, and Tianle Cai. In-place test-time training. In *The Fourteenth International Conference on Learning Representations*, 2026. URL <https://openreview.net/forum?id=dTWfCLSoyl>. 12
 - [21] Chelsea Finn, Pieter Abbeel, and Sergey Levine. Model-agnostic meta-learning for fast adaptation of deep networks. *arXiv preprint arXiv: 1703.03400*, 2017. 5
 - [22] Letian Fu, Huang Huang, Gaurav Datta, Lawrence Yunliang Chen, William Chung-Ho Panitch, Fangchen Liu, Hui Li, and Ken Goldberg. In-context imitation learning via next-token prediction. *arXiv preprint arXiv:2408.15980*, 2024. 3, 11
 - [23] Yihuai Gao, Jinyun Liu, Shuang Li, and Shuran Song. Gated memory policy. *arXiv preprint arXiv: 2604.18933*, 2026. 11, 12
 - [24] Dongchen Han, Yining Li, Tianyu Li, Zixuan Cao, Ziming Wang, Jun Song, Yu Cheng, Bo Zheng, and Gao Huang. Vit³: Unlocking test-time training in vision. *arXiv preprint arXiv: 2512.01643*, 2025. 12
 - [25] Dan Hendrycks and Kevin Gimpel. Gaussian error linear units (gelus). *arXiv preprint arXiv: 1606.08415*, 2016. 20
 - [26] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural Comput.*, 9(8):1735–1780, November 1997. ISSN 0899-7667. doi: 10.1162/neco.1997.9.8.1735. URL <https://doi.org/10.1162/neco.1997.9.8.1735>. 11
 - [27] Cheng-Ping Hsieh, Simeng Sun, Samuel Krizan, Shantanu Acharya, Dima Rekeshe, Fei Jia, Yang Zhang, and Boris Ginsburg. Ruler: What’s the real context size of your long-context language models? *arXiv preprint arXiv: 2404.06654*, 2024. 2
 - [28] Shengding Hu, Yuge Tu, Xu Han, Chaoqun He, Ganqu Cui, Xiang Long, Zhi Zheng, Yewei Fang, Yuxiang Huang, Weilin Zhao, Xinrong Zhang, Zheng Leng Thai, Kaihuo Zhang, Chongyi Wang, Yuan Yao, Chenyang Zhao, Jie Zhou, Jie Cai, Zhongwu Zhai, Ning Ding, Chao Jia, Guoyang Zeng, Dahai Li, Zhiyuan Liu, and Maosong Sun. Minicpm: Unveiling the potential of small language models with scalable training strategies. *arXiv preprint arXiv: 2404.06395*, 2024. 20
 - [29] Physical Intelligence, Kevin Black, Noah Brown, James Darpinian, Karan Dhabalia, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Manuel Y. Galliker, Dibya Ghosh, Lachy Groom, Karol Hausman, Brian Ichter, Szymon Jakubczak, Tim Jones, Liyiming Ke, Devin LeBlanc, Sergey Levine, Adrian Li-Bell, Mohith Mothukuri, Suraj Nair, Karl Pertsch, Allen Z. Ren, Lucy Xiaoyang Shi, Laura Smith, Jost Tobias Springenberg, Kyle Stachowicz, James Tanner, Quan Vuong, Homer Walke, Anna Walling, Haohuan Wang, Lili Yu, and Ury Zhilinsky. $\pi_{0.5}$: a vision-language-action model with open-world generalization, 2025. URL <https://arxiv.org/abs/2504.16054>. 2, 11, 12
 - [30] Andrew Jaegle, Felix Gimeno, Andrew Brock, Andrew Zisserman, Oriol Vinyals, and Joao Carreira. Perceiver: General perception with iterative attention. *arXiv preprint arXiv: 2103.03206*, 2021. 4
 - [31] Huiwon Jang, Sihyun Yu, Heeseung Kwon, Hojin Jeon, Younggyo Seo, and Jinwoo Shin. Contextvla: Vision-language-action model with amortized multi-frame context. *arXiv preprint arXiv: 2510.04246*, 2025. 11
-

-
- [32] Yunfan Jiang, Agrim Gupta, Zichen Zhang, Guanzhi Wang, Yongqiang Dou, Yanjun Chen, Li Fei-Fei, Anima Anandkumar, Yuke Zhu, and Linxi Fan. Vima: General robot manipulation with multimodal prompts. *arXiv preprint arXiv: 2210.03094*, 2022. 3, 11, 12
 - [33] Keller Jordan, Yuchen Jin, Vlado Boza, Jiacheng You, Franz Cesista, Laker Newhouse, and Jeremy Bernstein. Muon: An optimizer for hidden layers in neural networks, 2024. URL <https://kellerjordan.github.io/posts/muon/>. 20
 - [34] Jared Kaplan, Sam McCandlish, Tom Henighan, Tom B. Brown, Benjamin Chess, Rewon Child, Scott Gray, Alec Radford, Jeffrey Wu, and Dario Amodei. Scaling laws for neural language models. *arXiv preprint arXiv: 2001.08361*, 2020. 11
 - [35] Mahdi Karami, Razvan Pascanu, and Vahab Mirrokni. Lattice: Learning to efficiently compress the memory. *arXiv preprint arXiv: 2504.05646*, 2025. 12
 - [36] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan P Foster, Pannag R Sanketi, Quan Vuong, Thomas Kollar, Benjamin Burchfiel, Russ Tedrake, Dorsa Sadigh, Sergey Levine, Percy Liang, and Chelsea Finn. OpenVLA: An open-source vision-language-action model. In *8th Annual Conference on Robot Learning*, 2024. URL <https://openreview.net/forum?id=ZMnD6QZAE6>. 2, 11, 12
 - [37] Moo Jin Kim, Yihuai Gao, Tsung-Yi Lin, Yen-Chen Lin, Yunhao Ge, Grace Lam, Percy Liang, Shuran Song, Ming-Yu Liu, Chelsea Finn, and Jinwei Gu. Cosmos policy: Fine-tuning video models for visuomotor control and planning. *arXiv preprint arXiv: 2601.16163*, 2026. 2, 11
 - [38] Ashish Kumar, Zipeng Fu, Deepak Pathak, and Jitendra Malik. Rma: Rapid motor adaptation for legged robots. *arXiv preprint arXiv:2107.04034*, 2021. 11
 - [39] Michael Laskin, Luyu Wang, Junhyuk Oh, Emilio Parisotto, Stephen Spencer, Richie Steigerwald, DJ Strouse, Steven Stenberg Hansen, Angelos Filos, Ethan Brooks, Maxime Gazeau, Himanshu Sahni, Satinder Singh, and Volodymyr Mnih. In-context reinforcement learning with algorithm distillation. In *The Eleventh International Conference on Learning Representations, ICLR 2023, Kigali, Rwanda, May 1-5, 2023*. OpenReview.net, 2023. URL <https://openreview.net/forum?id=hy0a5MMPUv>. 2, 6, 11
 - [40] Lin Li, Qihang Zhang, Yiming Luo, Shuai Yang, Ruilin Wang, Fei Han, Mingrui Yu, Zelin Gao, Nan Xue, Xing Zhu, Yujun Shen, and Yinghao Xu. Causal world modeling for robot control. *arXiv preprint arXiv: 2601.21998*, 2026. 11
 - [41] Shuang Li, Yihuai Gao, Dorsa Sadigh, and Shuran Song. Unified video action model. *arXiv preprint arXiv: 2503.00200*, 2025. 2, 11
 - [42] Zeman Li, Ali Behrouz, Yuan Deng, Peilin Zhong, Praneeth Kacham, Mahdi Karami, Meisam Razaviyayn, and Vahab Mirrokni. Tnt: Improving chunkwise training for test-time memorization. *arXiv preprint arXiv:2511.07343*, 2025. 12
 - [43] Yi Heng Lim, Qi Zhu, Joshua Selfridge, and Muhammad Firmansyah Kasim. Parallelizing non-linear sequential models over the sequence length. In *The Twelfth International Conference on Learning Representations, ICLR 2024, Vienna, Austria, May 7-11, 2024*. OpenReview.net, 2024. URL <https://openreview.net/forum?id=E34AlVLN0v>. 12
 - [44] Fanqi Lin, Ruiqian Nai, Yingdong Hu, Jiacheng You, Junming Zhao, and Yang Gao. Onetwovla: A unified vision-language-action model with adaptive reasoning. *arXiv preprint arXiv:2505.11917*, 2025. 11
 - [45] Changyu Liu, Yiyang Liu, Taowen Wang, Qiao Zhuang, James Chenhao Liang, Wenhao Yang, Renjing Xu, Qifan Wang, Dongfang Liu, and Cheng Han. On-the-fly vla adaptation via test-time reinforcement learning. *arXiv preprint arXiv:2601.06748*, 2026. 12
-

-
- [46] Nelson F Liu, Kevin Lin, John Hewitt, Ashwin Paranjape, Michele Bevilacqua, Fabio Petroni, and Percy Liang. Lost in the middle: How language models use long contexts. *Transactions of the association for computational linguistics*, 12:157–173, 2024. 2
 - [47] Songming Liu, Lingxuan Wu, Bangguo Li, Hengkai Tan, Huayu Chen, Zhengyi Wang, Ke Xu, Hang Su, and Jun Zhu. RDT-1B: a diffusion foundation model for bimanual manipulation. In *The Thirteenth International Conference on Learning Representations, ICLR 2025, Singapore, April 24-28, 2025*. OpenReview.net, 2025. URL <https://openreview.net/forum?id=yAzN4tz7oI>. 2, 11
 - [48] I. Loshchilov and F. Hutter. Decoupled weight decay regularization. *International Conference on Learning Representations*, 2017. 20
 - [49] Ajay Mandlekar, Danfei Xu, Josiah Wong, Soroush Nasiriany, Chen Wang, Rohun Kulkarni, Li Fei-Fei, S. Savarese, Yuke Zhu, and Roberto Martín-Martín. What matters in learning from offline human demonstrations for robot manipulation. *Conference on Robot Learning*, 2021. 11
 - [50] Max Sobol Mark, Jacky Liang, Maria Attarian, Chuyuan Fu, Debidatta Dwibedi, Dhruv Shah, and Aviral Kumar. Bpp: Long-context robot imitation learning by focusing on key history frames. *arXiv preprint arXiv: 2602.15010*, 2026. 2, 11, 12
 - [51] NVIDIA, Johan Bjorck, Fernando Castañeda, Nikita Cherniadev, Xingye Da, Runyu Ding, Linxi "Jim" Fan, Yu Fang, Dieter Fox, Fengyuan Hu, Spencer Huang, Joel Jang, Zhenyu Jiang, Jan Kautz, Kaushil Kundalia, Lawrence Lao, Zhiqi Li, Zongyu Lin, Kevin Lin, Guilin Liu, Edith Llonet, Loic Magne, Ajay Mandlekar, Avnish Narayan, Soroush Nasiriany, Scott Reed, You Liang Tan, Guanzhi Wang, Zu Wang, Jing Wang, Qi Wang, Jiannan Xiang, Yuqi Xie, Yinzhen Xu, Zhenjia Xu, Seonghyeon Ye, Zhiding Yu, Ao Zhang, Hao Zhang, Yizhou Zhao, Ruijie Zheng, and Yuke Zhu. Gr00t n1: An open foundation model for generalist humanoid robots. *arXiv preprint arXiv: 2503.14734*, 2025. 2, 4, 7, 11, 12, 20, 22
 - [52] William Peebles and Saining Xie. Scalable diffusion models with transformers. *arXiv preprint arXiv: 2212.09748*, 2022. 4, 20
 - [53] Bowen Peng, Jeffrey Quesnelle, Honglu Fan, and Enrico Shippole. Yarn: Efficient context window extension of large language models. In *The Twelfth International Conference on Learning Representations, ICLR 2024, Vienna, Austria, May 7-11, 2024*. OpenReview.net, 2024. URL <https://openreview.net/forum?id=wHBfxhZu1u>. 2
 - [54] Karl Pertsch, Kyle Stachowicz, Brian Ichter, Danny Driess, Suraj Nair, Quan Vuong, Oier Mees, Chelsea Finn, and Sergey Levine. Fast: Efficient action tokenization for vision-language-action models, 2025. URL <https://arxiv.org/abs/2501.09747>. 12
 - [55] Haozhi Qi, Ashish Kumar, Roberto Calandra, Yi Ma, and Jitendra Malik. In-hand object rotation via rapid motor adaptation. In *Conference on Robot Learning*, pages 1722–1732. PMLR, 2023. 11
 - [56] Scott E. Reed, Konrad Zolna, Emilio Parisotto, Sergio Gómez Colmenarejo, Alexander Novikov, Gabriel Barth-Maron, Mai Gimenez, Yury Sulsky, Jackie Kay, Jost Tobias Springenberg, Tom Eccles, Jake Bruce, Ali Razavi, Ashley Edwards, Nicolas Heess, Yutian Chen, Raia Hadsell, Oriol Vinyals, Mahyar Bordbar, and Nando de Freitas. A generalist agent. *Trans. Mach. Learn. Res.*, 2022, 2022. URL <https://openreview.net/forum?id=1ikK0kHvj>. 3, 11
 - [57] Stephane Ross, Geoffrey Gordon, and Drew Bagnell. A reduction of imitation learning and structured prediction to no-regret online learning. In Geoffrey Gordon, David Dunson, and Miroslav Dudík, editors, *Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics*, volume 15 of *Proceedings of Machine Learning Research*, pages 627–635, Fort Lauderdale, FL, USA, 11–13 Apr 2011. PMLR. URL <https://proceedings.mlr.press/v15/ross11a.html>. 3, 6
 - [58] Imanol Schlag, Kazuki Irie, and Jürgen Schmidhuber. Linear transformers are secretly fast weight programmers. In *International conference on machine learning*, pages 9355–9366. PMLR, 2021. 2
-

-
- [59] Min Shi, Fuxiao Liu, Shihao Wang, Shijia Liao, Subhashree Radhakrishnan, De-An Huang, Hongxu Yin, Karan Sapra, Yaser Yacoob, Humphrey Shi, Bryan Catanzaro, Andrew Tao, Jan Kautz, Zhiding Yu, and Guilin Liu. Eagle: Exploring the design space for multimodal llms with mixture of encoders. In *ICLR*, 2025. 20
 - [60] Mustafa Shukor, Dana Aubakirova, Francesco Capuano, Pepijn Kooijmans, Steven Palma, Adil Zouitine, Michel Aractingi, Caroline Pascal, Martino Russi, Andres Marafioti, Simon Alibert, Matthieu Cord, Thomas Wolf, and Remi Cadene. Smolvla: A vision-language-action model for affordable and efficient robotics. *arXiv preprint arXiv: 2506.01844*, 2025. 2, 11
 - [61] Ajay Sridhar, Jennifer Pan, Satvik Sharma, and Chelsea Finn. Memer: Scaling up memory for robot control via experience retrieval. *arXiv preprint arXiv: 2510.20328*, 2025. 11, 12
 - [62] Jianlin Su, Yu Lu, Shengfeng Pan, Ahmed Murtadha, Bo Wen, and Yunfeng Liu. Roformer: Enhanced transformer with rotary position embedding. *arXiv preprint arXiv: 2104.09864*, 2021. 20
 - [63] Yu Sun, Xiaolong Wang, Zhuang Liu, John Miller, Alexei A. Efros, and Moritz Hardt. Test-time training with self-supervision for generalization under distribution shifts. In *Proceedings of the 37th International Conference on Machine Learning, ICML'20*. JMLR.org, 2020. 12, 20
 - [64] Yu Sun, Xinhao Li, Karan Dalal, Jiarui Xu, Arjun Vikram, Genghan Zhang, Yann Dubois, Xinlei Chen, Xiaolong Wang, Sanmi Koyejo, Tatsunori Hashimoto, and Carlos Guestrin. Learning to (learn at test time): Rnns with expressive hidden states. *arXiv preprint arXiv: 2407.04620*, 2024. 2, 3
 - [65] Arnub Tandon, Karan Dalal, Xinhao Li, Daniel Kocaja, Marcel Rød, Sam Buchanan, Xiaolong Wang, Jure Leskovec, Sanmi Koyejo, Tatsunori Hashimoto, Carlos Guestrin, Jed McCaleb, Yejin Choi, and Yu Sun. End-to-end test-time training for long context. *arXiv preprint arXiv: 2512.23675*, 2025. 5, 12
 - [66] Adaptive Agent Team, Jakob Bauer, Kate Baumli, Satinder Baveja, Feryal Behbahani, Avishkar Bhoopchand, Nathalie Bradley-Schmieg, Michael Chang, Natalie Clay, Adrian Collister, et al. Human-timescale adaptation in an open-ended task space. *arXiv preprint arXiv:2301.07608*, 2023. 11
 - [67] Octo Model Team, Dibya Ghosh, Homer Walke, Karl Pertsch, Kevin Black, Oier Mees, Sudeep Dasari, Joey Hejna, Tobias Kreiman, Charles Xu, Jianlan Luo, You Liang Tan, Pannag R. Sanketi, Quan Vuong, Ted Xiao, Dorsa Sadigh, Chelsea Finn, and Sergey Levine. Octo: An open-source generalist robot policy. *ROBOTICS*, 2024. doi: 10.48550/arXiv.2405.12213. URL <https://arxiv.org/abs/2405.12213v2>. 2, 3, 11, 12
 - [68] Marcel Torne, Andy Tang, Yuejiang Liu, and Chelsea Finn. Learning long-context diffusion policies via past-token prediction. *arXiv preprint arXiv: 2505.09561*, 2025. 11, 12
 - [69] Marcel Torne, Karl Pertsch, Homer Walke, Kyle Vedder, Suraj Nair, Brian Ichter, Allen Z. Ren, Haohuan Wang, Jiaming Tang, Kyle Stachowicz, Karan Dhabalia, Michael Equi, Quan Vuong, Jost Tobias Springenberg, Sergey Levine, Chelsea Finn, and Danny Driess. Mem: Multi-scale embodied memory for vision language action models. *arXiv preprint arXiv: 2603.03596*, 2026. 2, 11
 - [70] Chuan Wen, Jierui Lin, Trevor Darrell, Dinesh Jayaraman, and Yang Gao. Fighting copycat agents in behavioral cloning from observation histories. *arXiv preprint arXiv: 2010.14876*, 2020. 11
 - [71] Guangxuan Xiao, Yuandong Tian, Beidi Chen, Song Han, and Mike Lewis. Efficient streaming language models with attention sinks. In *The Twelfth International Conference on Learning Representations, ICLR 2024, Vienna, Austria, May 7-11, 2024*. OpenReview.net, 2024. URL <https://openreview.net/forum?id=NG7sS51zVF>. 2
 - [72] Jianwei Yang, Reuben Tan, Qianhui Wu, Ruijie Zheng, Baolin Peng, Yongyuan Liang, Yu Gu, Mu Cai, Seonghyeon Ye, Joel Jang, Yuquan Deng, Lars Liden, and Jianfeng Gao. Magma: A foundation model for multimodal ai agents, 2025. URL <https://arxiv.org/abs/2502.13130>. 12
-

-
- [73] Songlin Yang and Yu Zhang. Fla: A triton-based library for hardware-efficient implementations of linear attention mechanism, January 2024. URL <https://github.com/fla-org/flash-linear-attention>. 22
 - [74] Songlin Yang, Jan Kautz, and Ali Hatamizadeh. Gated delta networks: Improving mamba2 with delta rule. *International Conference on Learning Representations*, 2024. doi: 10.48550/arXiv.2412.06464. 7
 - [75] Seonghyeon Ye, Yunhao Ge, Kaiyuan Zheng, Shenyuan Gao, Sihyun Yu, George Kurian, Suneel Indupuru, You Liang Tan, Chuning Zhu, Jiannan Xiang, et al. World action models are zero-shot policies. *arXiv preprint arXiv:2602.15922*, 2026. 2, 11
 - [76] Tianyuan Yuan, Zibin Dong, Yicheng Liu, and Hang Zhao. Fast-wam: Do world action models need test-time future imagination? *arXiv preprint arXiv: 2603.16666*, 2026. 2, 11
 - [77] Mert Yuksekgonul, Daniel Kocaja, Xinhao Li, Federico Bianchi, Jed McCaleb, Xiaolong Wang, Jan Kautz, Yejin Choi, James Zou, Carlos Guestrin, and Yu Sun. Learning to discover at test time, 2026. URL <https://arxiv.org/abs/2601.16175>. 12
 - [78] Tianyuan Zhang, Sai Bi, Yicong Hong, Kai Zhang, Fujun Luan, Songlin Yang, Kalyan Sunkavalli, William T. Freeman, and Hao Tan. Test-time training done right. *arXiv preprint arXiv: 2505.23884*, 2025. 2, 3, 11, 12, 20
 - [79] Tianyu Zhao and Llion Jones. Fast-weight product key memory. *arXiv preprint arXiv: 2601.00671*, 2026. 12
 - [80] Ruijie Zheng, Yongyuan Liang, Shuaiyi Huang, Jianfeng Gao, Hal Daumé III, Andrey Kolobov, Furong Huang, and Jianwei Yang. TraceVLA: Visual trace prompting enhances spatial-temporal awareness for generalist robotic policies. In *The Thirteenth International Conference on Learning Representations*, 2025. 11, 12
 - [81] Ruijie Zheng, Dantong Niu, Yuqi Xie, Jing Wang, Mengda Xu, Yunfan Jiang, Fernando Castañeda, Fengyuan Hu, You Liang Tan, Letian Fu, Trevor Darrell, Furong Huang, Yuke Zhu, Danfei Xu, and Linxi Fan. Egoscale: Scaling dexterous manipulation with diverse egocentric human data. *arXiv preprint arXiv: 2602.16710*, 2026. 7, 20
 - [82] Shaoting Zhu, Baijun Ye, Jiaxuan Wang, Jiakang Chen, Ziwen Zhuang, Linzhan Mou, Runhan Huang, and Hang Zhao. Ttt-parkour: Rapid test-time training for perceptive robot parkour. *arXiv preprint arXiv:2602.02331*, 2026. 12
 - [83] Christos Ziakas and Alessandra Russo. VITA: Zero-shot value functions via test-time adaptation of vision-language models. In *The Fourteenth International Conference on Learning Representations*, 2026. URL <https://openreview.net/forum?id=V35oo1SVGH>. 12
-

A. 模型架构、训练与部署细节

A.1. 模型架构

我们在预训练的 GR00T N1.7 (51) 上实例化 RoboTTT，该模型由作为视觉语言模型（VLM）骨干的 Eagle 模型 (59) 和作为动作头的扩散 Transformer（DiT）(52) 组成。我们向其 16 个 DiT 层中的每一层添加一个 TTT 层。原始 DiT 具有 5.38 亿参数；每个 TTT 层大约增加 1000 万参数，总计 6.9 亿。每个 TTT 层包含一个快速模型，即一个带有 GeLU 激活 (25) 的两层 MLP，在测试时通过标准梯度下降进行更新；更复杂的测试时优化器（如 Muon (33; 78)）留待未来工作。遵循 TTT 的标准做法，我们在 0.1 的恒定基础学习率之上学习内部测试时学习率 (63)。我们使用 RoPE (62) 进行位置嵌入，其中 $\theta_{\text{rope}} = 10000$ 。

A.2. 训练

我们在桌面双臂机器人数据与以自我为中心的人类视频数据 (81) 的混合数据上进行预训练，数据经过筛选以强调长轨迹；轨迹长度分布如图 A.1 所示。所有模型均在 NVIDIA GB200 GPU 上训练，每次预训练运行使用 16 块 GPU，每次任务特定后训练运行使用 8 块 GPU。预训练仅调整新增的序列建模层（TTT 或 GDN），并冻结 GR00T N1.7 的其他组件；后训练则微调所有参数。在预训练期间，对于 4K 及以下上下文长度，我们使用每设备批大小 4（全局批大小 64），对于更长上下文使用每设备批大小 1（全局批大小 16）。后训练使用 1K 上下文长度和每设备批大小 1。我们预训练 30K 步，后训练 20K 步。所有模型均使用 AdamW 优化器 (48)，并带有权重衰减 1×10^{-5} 。预训练使用 Warmup-Stable-Decay（WSD）调度 (28)，峰值学习率为 2×10^{-5} ；后训练使用余弦调度，峰值学习率为 5×10^{-5} 。




Figure A.1: Trajectory length distribution of the pretraining mixture.

A.3. 部署

我们将训练好的模型部署在 YAM 双臂桌面机器人上，该机器人配备四个 RealSense D405 摄像头（顶部、底部、左腕、右腕），以 480p RGB 流式传输观测数据。推理在配备 NVIDIA RTX 5090 GPU 的工作站上运行，控制频率为 30 Hz。

B. 任务定义与实验细节

本节提供任务定义和实验细节。

B.1. 任务定义

所有任务均通过任务特定的评分标准在 $[0, 1]$ 任务完成量表上进行评分，详见下文。

Pup Go Car 如图 A.2 所示，机器人组装了模型车“Pup Go Car”的黄色车顶和第一个车轮。它抬起车顶，将螺丝与车身上的孔对齐，并放置车顶。然后它抓取




图 A.2: “Pup Go Car”任务。机器人在多个阶段中组装模型车的车顶和第一个车轮，包括拧螺丝、钻孔、双手交接和翻车。




图 A.3: “Gear Bot”任务。机器人在底盘两侧安装齿轮和车轮，翻转两次，安装机器人头部，并用遥控器驱动它。

电钻，将其与车顶螺丝对齐并拧紧，然后将电钻交给右手。接着机器人用一只手翻转车身，用右手抬起一个车轮，将车轮插入车身。然后再次抬起电钻并拧紧车轮，最后将电钻交给左手。

评分标准如下：抬起车顶得 0.05 分；将车顶放置在车身上得 0.1 分；车顶螺丝正确插入车身得 0.25 分；抬起电钻得 0.3 分；电钻头接触螺丝得 0.35 分；车顶螺丝完全拧紧得 0.45 分；将电钻交给右手得 0.5 分；车身翻转并稳定得 0.55 分；抬起轮胎得 0.6 分；轮胎插入车身得 0.75 分；抬起电钻得 0.8 分；电钻与车轮螺丝对齐并接触得 0.85 分；车轮完全拧紧得 0.9 分；将电钻交给左手得 1.0 分。车轮组装最多允许尝试两次。


Gear Bot 如图 A.3 所示，机器人组装了整个玩具模型“Gear Bot”。它在底盘两侧各安装一个齿轮和两个车轮，翻转底盘两次使轴朝上。然后抬起红色“机器人头部”并将其插入底盘。最后，抬起遥控器并推动操纵杆，使 Gear Bot 移动。评分标准如下：每次底盘翻转+0.1 分，每个齿轮或车轮安装+0.1 分，“机器人头部”安装+0.1 分，成功使用遥控器+0.1 分。

Circuit 如图 A.4 所示，机器人在电路板上组装电路元件。元件包括红色发光二极管、绿色发光二极管、彩色发光二极管、灯泡、电机、按扣导线、按钮和开关。机器人组装两到三个元件，左右两侧元件的组装顺序不同。考虑到元件组合和组装顺序，大约有 80 种配置。如果组装中包含开关或按钮，

Two Pieces: Left then right



Two Pieces: Right then left



Three Pieces: Bottom, left, then right




图 A.4: “电路”任务。机器人在电路板上组装两到三个电路元件，并在存在开关或按钮时接通电路。

机器人还必须在组装后将其打开。评分标准如下。对于不含开关或按钮的两件组装，每正确安装一个元件得 0.5 分。对于含开关或按钮的两件组装，每正确安装一个元件得 0.33 分，若电路被接通则额外得 0.33 分。对于不含开关或按钮的三件组装，每正确安装一个元件得 0.33 分。对于含开关或按钮的三件组装，每正确安装一个元件得 0.25 分，若电路被接通则额外得 0.25 分。若组装顺序错误，则不给部分分。

B.2. 实验细节

基线 对于 GR00T N1.7 和 GR00T N1.7 Hist.基线，我们使用官方实现（51），并扩展以支持 GR00T N1.7 Hist.的历史帧输入。对于 GDN 基线，我们将每个 TTT 层替换为来自 Flash Linear Attention 库（73）的门控 DeltaNet 层，保持层位置、门控和参数数量与 RoboTTT 匹配。

评估 我们将训练好的模型部署到 YAM 双臂桌面机器人上。为确保各方法初始条件一致，我们记录每个任务的初始物体摆放位置，并在评估时复现这些位置。我们对 Pup Go Car 和 Circuit 任务评估 20 次 rollout，对 Gear Bot 任务以及一次性人类视频设置下的 Circuit 任务评估 10 次 rollout，因为后者的评估时间显著更长。