

ROVER: 机器人奖励模型作为视觉-语言-动作模型的测试时间验证器

戴明通^{1,2,6}刘凌波^{2,†}白永杰^{2,3}刘杨³王周霞⁴苏锐⁵陈春杰¹林良^{2,3,7}吴新宇¹

1中国科学院深圳先进技术研究院²鹏程实验室³中山大学计算机科学与工程
学院⁴南洋理工大学计算与数据科学学院⁵上海人工智能实验室⁶中
国科学院大学⁷X-Era人工智能实验室[†]通讯作者

抽象的

视觉-语言-动作（VLA）模型已成为体现智能的重要范例，但进一步的性能改进通常依赖于扩大训练数据和模型大小——这种方法对于机器人技术来说成本高昂，并且从根本上受到数据收集成本的限制。我们通过 **RoVer** 解决了这一限制，这是一个具体的测试时间扩展框架，它使用 **Robot** 进程奖励模型（PRM）作为测试时间 **Verifier** 来增强现有 VLA 模型的功能，而无需修改其架构或权重。具体来说，RoVer (i) 分配基于标量的过程奖励来评估候选动作的可靠性，以及 (ii) 预测候选扩展/细化的动作空间方向。在推理过程中，RoVer 根据基本策略同时生成多个候选动作，将它们沿着 PRM 预测的方向扩展，然后用 PRM 对所有候选动作进行评分，以选择最佳动作来执行。值得注意的是，通过缓存共享感知特征，它可以分摊感知成本并在相同的测试时间计算预算下评估更多候选者。本质上，我们的方法有效地将可用的计算资源转化为更好的行动决策，实现测试时间扩展的好处，而无需额外的训练开销。大量实验表明，RoVer 不断提高各种操作任务的成功率。我们的贡献有三个：(1) 一个通用的、即插即用的 VLA 测试时间扩展框架；(2) 联合提供标量过程奖励和指导探索的动作空间方向的 PRM；(3) 一种高效的方向引导采样策略，利用共享感知缓存来实现推理过程中可扩展的候选生成和选择。

1 简介

嵌入式人工智能领域取得了重大进展，从 ACT、DP 和 DP3 (Zhao 等人, 2023; Chi 等人, 2024; 2023; Ze 等人, 2024) 等专业模型到 OpenVLA、 $\pi 0$ 和 RDT 等通用 VLA 系统 (Kim 等人, 2024; Black 等人, 2024; Liu 等人) 等, 2025c)。这些 VLA 模型通常在配对的视觉-语言-动作数据上进行端到端训练，迄今为止的大部分收益都来自训练时间扩展策略，即使用更大的主干、使演示数据多样化以及增强数据管理流程。然而，即使在相同的设置下，VLA 的成功率也会由于随机解码和操作脆弱性而经常波动，并且这个问题在长期任务中变得尤其明显。这种现象促使我们重新分配部分工作量，从训练时间缩放到推理时间计算，目的是稳定结果并释放现有 VLA 模型的潜在功能。

受到大型语言模型（LLM）和视觉语言模型（VLM）中尺度法则 (Kaplan et al., 2020) 巨大成功的启发，实体人工智能领域的许多研究工作都旨在

通过收集大规模训练数据集，例如 Open-X-Embodiment、Agi World、Fourier ActionNet 和 ARIO (Collaboration et al., 2023; AgiBot-World-Contributors et al., 2025; Fourier ActionNet Team, 2025; Wang et al., 2024) 并增加模型参数大小（例如 RT-X (Collaboration et al., 2024) 来复制这一进展2023）、OpenVLA (Kim 等人, 2024)、RDT (Liu 等人, 2025c)）。然而，与 LLM/VLM 的互联网规模语料库不同，获取多样化、高质量的机器人体验数据仍然是一个资源密集型且耗时的过程，为具体人工智能领域的训练时间扩展造成了重大瓶颈。

为了在无需进一步训练的情况下提高 VLA 的表现，研究人员已经开始增加测试时“思考”的比例。一些具体方法采用快慢思维设计，将深思熟虑的高级“大脑”与低延迟“小脑”控制器分开，从而能够为更具挑战性的任务实现规划与执行解耦 (Kahneman, 2011; Zhang et al., 2025; Shentu et al., 2025; Bu et al., 2025a)。后续工作通过将思想链注释注入数据集来扩展监督信号，以训练可在推理过程中调用的复杂的高级推理模块 (Zawalski et al., 2025; Ji et al., 2025; Zhou et al., 2025)。这些途径已经在 LLM 和 VLM 中展示了它们的潜力，通常被称为测试时间缩放 (Liu 等人, 2025b; Ma 等人, 2025)。然而，上述大多数方法都需要使用补充注释来扩展原始数据集。

在这种情况下，我们提出了一个基本问题：我们能否利用测试时间扩展机制来增强需要额外数据或模型重新训练的 VLA 性能 *without*？这个问题引导我们探索一种有前途的范式，该范式侧重于在推理过程中最大化现有 VLA 模型的效用，而不是追求越来越大的数据集和架构。为此，我们引入了 RoVer，这是一种新颖的外部过程奖励模型，旨在纯粹在推理时增强冻结 VLA 策略的功能。特别是，我们的 RoVer 不仅评估大量候选动作的可靠性分数，而且还预测动作空间中精确的 6D 细化方向。这种设计可以实现智能候选评估和方向引导采样，同时保持原始主干架构和权重完好无损。至关重要的是，我们的方法将额外的测试时计算资源转化为改进的决策能力，有效地规避了数据收集和模型重新训练的传统限制。RoVer 的另一个优雅之处在于它能够有效地利用共享计算。通过缓存和重用感知管道中的中间特征，我们的框架可以以最小的额外计算开销评估多个候选动作。这种设计选择确保以合理的计算成本提高决策能力，使其适用于现实世界的机器人应用。总之，我们的工作对该领域做出了三项重大贡献：

- 通用的即插即用测试时间扩展框架，纯粹在推理时增强冻结的 VLA 策略，展示了一种提高 VLA 性能的新范例，而无需传统的数据收集和模型再训练成本。
- 一个紧凑而强大的过程奖励模型，可同时生成标量过程奖励和候选操作的细化方向，从而在操作空间中实现有效的验证者引导探索。
- 一种有效的方向引导采样策略，利用共享的 *perception cache*，有效地摊销感知成本并能够在相同的计算预算内评估更多的候选者。

2 相关工作

视觉-语言-行动模型。VLA 模型是从专门的、针对特定任务的政策演变而来的。(2023)；池等人。(2024 年；2023 年)；泽等人。(2024) 到耦合感知、语言 and 控制的通用系统 Kim 等人。(2024)；布莱克等人。(2024)；刘等人。(2025c)，受人类认知双过程理论 Kahneman (2011) 启发，探索分层架构的最新进展；申屠等人。(2025)；张等人。(2025)；布等人。(2025a)；崔等人。(2025)；刘等人。(2025a)；英伟达等人。(2025)。迄今为止，大多数性能提升都来自 *training-time scaling*——更大的主干网、更广泛的演示和改进的数据管理。

法学硕士的测试时间缩放。大语言模型 (LLM) 的最新进展凸显了测试时间缩放 (TTS) 技术在提高推理能力方面的功效

在推理阶段。TTS 方法通常可分为两种主要类型 (Liu et al., 2025b)：内部和外部。内部 TTS 方法，例如自我反思和思想链 (CoT)，涉及模型生成和完善其自身的中间推理步骤，例如 OpenAI o1 和 DeepSeek-R1 等模型 (OpenAI et al., 2024; DeepSeek-AI, 2025)。相比之下，外部 TTS 利用过程奖励模型 (PRM) 来提供反馈并监督生成过程，从而促进 Best-of-N (BoN) 和 Beam Search 等搜索策略。值得注意的是，研究表明，在外部 TTS 的帮助下，即使是较小的模型，在某些任务中也可以达到或超越较大模型的性能。该范式主张战略性地重新分配计算资源，从广泛的预训练到推理阶段，从而实现更有效的性能提升。自我一致性和蒙特卡罗树搜索等进一步的策略也利用 PRM 来产生多样化和集成的输出。

视觉-语言-动作模型中的测试时间缩放。 *Internal test-time scaling*: 最近的工作增加了 VLA 在推理方面的内部审议：Embodied Chain-of-Thought (Zawalski et al., 2025; Ji et al., 2025; Sun et al., 2024; Zhou et al., 2025) 方法在动作生成之前强制执行多步骤推理，以改进任务分解和规划，通常通过使用推理注释扩展训练数据集。CoT-VLA 和 UniVLA (Zhao et al., 2025; Bu et al., 2025b; Wang et al., 2025) 在推理过程中结合了未来帧预测；OneTwo-VLA (Lin et al., 2025) 使用 [BOR] 和 [BOA] 令牌来自适应地决定何时推理和何时行动。然而，上述大部分工作需要训练数据集进行额外注释。 *External test-time scaling*: 与内部 TTS 不同，内部 TTS 会推理 *within* 策略，外部 TTS *decouples* 通过引入单独的奖励/值验证器来根据策略进行搜索和评分，该奖励/值验证器在推理时评估候选操作，指导候选生成而不修改主干权重。同期的工作探索了这个方向：Hume (Song et al., 2025) 增强了双系统 VLA，具有价值头来驱动重复采样和级联去噪（具有固定的候选计数），而 RoboMonkey (Kwok et al., 2025) 研究了具有大规模主干和合成数据的奖励建模。我们的工作使用紧凑的流程奖励模型实例化外部 TTS，并系统地检查候选预算的扩展性和跨主干网的兼容性；参见第 3.2 节。

3 方法

概述 我们用外部过程奖励模型 (PRM) 增强了冻结的 VLA，该模型根据观察结果、语言和候选动作，输出标量分数和改进方向。在推理时，通过在角度范围内沿预测方向采样来扩展策略建议，并执行 PRM 下得分最高的动作。观察、语言和状态特征每一步计算一次并缓存，并在候选者之间重用（见图 1）。

3.1 初步

策略模型我们考虑通过观察 o_t (进行顺序决策，例如 RGB-D 图像、本体感觉) 和自然语言目标 g 以及历史 $h_t = (o_{\leq t}, g)$ 。预训练的 VLA 策略 π_θ 将历史记录 h_t 映射到低级操作 $a_t \in A$ 的分布：

$$\pi_\theta(a_t | h_t) \in \Delta(A), \quad (1)$$

我们将末端执行器 *delta* 动作与夹具命令 $a_t = [\Delta p_t, \Delta q_t, g_t] \in \mathbb{R}^{d_a}$ 一起使用，在我们的设置中使用 $d_a = 7$ ($\Delta p_t \in \mathbb{R}^3, \Delta q_t \in \mathbb{R}^3, g_t \in \mathbb{R}$)。在推理时，可以执行 $a_t = \arg \max_a \pi_\theta(a | h_t)$ 。

奖励模型为了在测试时解锁额外的功能，我们引入了一种奖励模型，该模型可以预测 (i) 标量 *process reward* 和 (ii) 从当前操作指向可能更好的操作的 *action-space direction*：

$$R_\phi(h_t, a_t^i) \rightarrow r_t^i, d_t^i, \quad r_t^i \in \mathbb{R}, d_t^i \in \mathbb{R}^{d_{\text{dir}}}. \quad (2)$$

我们预测控件的可操作子空间的方向（不包括存在的离散夹具）。维度 d_{dir} 匹配动作子空间；在实践中，我们使用归一化方向 $\hat{u}_t^i = \text{归一化}(d_t^i)$ 。

符号 从本节开始，除非另有说明，否则为了清楚起见，我们将省略时间索引 t 。下标表示操作源： a^i 表示第 i 个候选， a_e 表示训练数据集中的专家操作， a_p 表示策略操作， a_{anc} 表示训练期间围绕 a_e 采样的锚点操作。




图 1: RoVer 概览。冻结的 VLA 提出 N 操作；外部流程奖励模型 (PRM) 对候选人进行评分并预测改进方向。候选者沿着引导方向展开，并执行得分最高的动作。感知特征被缓存一次并在候选者之间重复使用以分摊计算。

测试时间缩放给定基本策略 π_θ 和验证者 R_ϕ ，我们从 π_θ 获得策略动作 a_p ，并通过高斯噪声采样将其扩展为候选集 $\mathcal{A} = \{a^0 = a_p, a^1, a^2, \dots\}$ 。PRM 验证器 R_ϕ 使用 $r^i = R_\phi(h, a^i)$ 对每个候选进行评分，然后我们执行 $a^* = \arg \max_{a \in \mathcal{A}} r(h, a)$ 。我们在第 3.2.3 节中详细说明了这个框架。

3.2 漫游者

RoVer 使用紧凑的过程奖励模型 (PRM) 实例化外部测试时间缩放，该模型对候选动作进行评分并预测动作子空间中的细化方向。对于本地框架中定义的策略，在扩展和评分之前，动作会映射到世界框架。以下小节详细介绍了架构、训练目标和推理过程。

3.2.1 模型架构

R_ϕ 采用同步多模态输入 o_t (例如第三人称和手眼 RGB、机器人状态和语言标记) 以及候选动作 a^i ，并输出标量过程奖励 r^i 和动作空间方向 d^i 。模型架构遵循 GPT-2 风格 (Radford et al., 2019)，并使用 GR-1 的预训练权重进行初始化 (Wu et al., 2023)。具体来说，图像编码器从 MAE (He et al., 2021) 预训练模型初始化，文本编码器从 CLIP 文本编码器 (Radford et al., 2021) 初始化。该架构原则上支持最多 10 个时间步的历史记录作为输入。然而，为了更好的即插即用使用和更快的推理，我们将输入限制为当前时间步观察。用于奖励和方向预测的附加头被添加到初始化主干的顶部。由于所有候选动作在控制步骤中共享相同的观察、语言和状态，因此我们计算这些感知特征一次，并将它们作为共享 *perception cache* 跨候选重用，同时对每个候选动作进行编码以分摊计算。与 RoboMonkey 中微调 7B 参数的骨干网络相比 (Kwok et al., 2025)，RoVer 总共需要 0.2B 参数，仅 40M 进行训练。见图2。

动作放大器为了使候选动作之间的微小差异更加明显，我们在将其与观察/语言标记融合之前将轻量级的 *action amplifier* 应用于动作嵌入。该放大器是一个紧凑的 MLP，具有 GELU 和 LayerNorm 映射 $\mathbb{R}^H \rightarrow \mathbb{R}^{2H} \rightarrow \mathbb{R}^H$ ，重新调节动作通道，以便动作子空间中的细粒度增量在强大的冻结感知/语言骨干下保持显著。这种对比度增强器提高了 PRM 区分附近动作并对其进行排名的能力，同时保持推理开销最小。为了




图 2: 左: 验证器架构。共享感知缓存和每个候选动作编码器（带有动作放大器）通过奖励/方向令牌为 GPT-2 主干提供反馈，产生标量过程奖励和动作空间细化方向。右图: PushT 基准上的方向可视化，其中 PRM 在预先训练的扩散策略上进行训练并预测 2D (x, y) 动作方向；对于 CALVIN，PRM 预测 6D 位姿方向。注：在 PushT 上，DP 预训练策略已经取得了接近 100% 的成功；我们在这里主要使用 PushT 来实现直观的方向可视化，而不是性能提升。

凭直觉，图 2 的右图可视化了当底层基本策略输出平面 (x, y) 动作时 PushT 上预测的 2D 方向场。

3.2.2 模型训练

奖励模型 R_ϕ 的训练目标是使其具备区分两个候选动作中哪一个更好的能力。在 RoVer 中，如果一个操作与专家操作的均方根误差 (RMSE) 距离小于另一个操作的距离，则认为该操作更好。为了准备训练数据，我们首先分析策略操作 A_p 和专家操作样本 A_e (附录 A.2) 之间的分布差距。基于此分析，我们设置基本噪声尺度 $\sigma_{\text{base}} = 0.1$ ，用于构造锚点动作 a_{anc} 。给定专家演示 $h, a_e = [a_e^{\text{pose}}, g_e]$ ，然后我们围绕 a_e 构建本地动作元组，以获得信息丰富的偏好标签和方向监督。

方向引导和以锚点为中心的采样在早期实验中，我们观察到简单地对 a_e 周围的嘈杂专家操作 a_{en} 进行采样会产生较差的性能。为了更好地模拟测试时采样行为，我们引入了 *anchor action* 的概念。我们通过扰乱 6D 姿态子空间中的专家动作来形成锚噪声（对于 CALVIN）：

$$a_{\text{anc}}^{\text{pose}} = a_e^{\text{pose}} + \mathbf{n}, \quad \mathbf{n} \sim \mathcal{N}(\mathbf{0}, \sigma_{\text{base}}^2 I_6), \quad g_{\text{anc}} = g_e. \quad (3)$$

然后，我们定义从锚点动作到专家动作的地面实况方向向量：

$$u_{\text{gt}} = \frac{a_e^{\text{pose}} - a_{\text{anc}}^{\text{pose}}}{\|a_e^{\text{pose}} - a_{\text{anc}}^{\text{pose}}\|_2} \in \mathbb{R}^6. \quad (4)$$

使用 u_{gt} ，我们定义正交超平面

$$\mathcal{H} = \{a \in \mathbb{R}^6 \mid (a - a_{\text{anc}}^{\text{pose}})^\top u_{\text{gt}} = 0\} \quad (5)$$

它将空间分为两个半空间：

$$\mathcal{H}^+ = \{a \in \mathbb{R}^6 \mid (a - a_{\text{anc}}^{\text{pose}})^\top u_{\text{gt}} > 0\}, \quad (6)$$

$$\mathcal{H}^- = \{a \in \mathbb{R}^6 \mid (a - a_{\text{anc}}^{\text{pose}})^\top u_{\text{gt}} < 0\}. \quad (7)$$

令 $d_0 = \sqrt{\frac{1}{6} \|a_e^{\text{pose}} - a_{\text{anc}}^{\text{pose}}\|_2^2}$ 为 6D 姿态子空间中 a_{anc} 和 a_e 之间的 RMSE 距离。我们将自适应噪声尺度定义为

$$\sigma_{\text{adapt}} = \text{clip}(k d_0, \sigma_{\text{min}}, \sigma_{\text{base}}), \quad k > 0, \sigma_{\text{min}} > 0, \quad (8)$$

控制候选动作在 a_{anc} 周围的传播。在我们的实现中，我们对 $\epsilon_b, \epsilon_w \sim \mathcal{N}(\mathbf{0}, \sigma_{\text{adapt}}^2 I_6)$ 进行采样并将它们投影到正确的半空间中：

$$\text{better: if } \epsilon_b^\top u_{\text{gt}} \leq 0, \epsilon_b \leftarrow -\epsilon_b; \quad \text{worse: if } \epsilon_w^\top u_{\text{gt}} \geq 0, \epsilon_w \leftarrow -\epsilon_w. \quad (9)$$

这产生

$$a_{\text{better}}^{\text{pose}} = a_{\text{anc}}^{\text{pose}} + \epsilon_b, \quad a_{\text{worse}}^{\text{pose}} = a_{\text{anc}}^{\text{pose}} + \epsilon_w \quad (10)$$

夹具状态继承自 a_{anc} 。根据构造, a_{better} 更有可能比 a_{anc} 更接近专家操作, 而 a_{worse} 则更远。

监督和目标 从每个以锚为中心的元组{锚,更好,更差}, 我们监督两个信号。对于方向监督, 从采样动作 a_x 到专家的真实单位向量为

$$u_{\text{gt}}(a_e, a_x) = \frac{a_e^{\text{pose}} - a_x^{\text{pose}}}{\|a_e^{\text{pose}} - a_x^{\text{pose}}\|_2}. \quad (11)$$

让 $\hat{u}$ = 归一化($d_\phi(h, a_x)$) 表示预测方向。我们最小化余弦偏差

$$\mathcal{L}_{\text{dir}} = \mathbb{E}[1 - \langle \hat{u}, u_{\text{gt}} \rangle], \quad (12)$$

对元组中所有采样动作进行平均。对于奖励监督, 让 $r(a) = R_\phi(h, a)$ 表示 PRM 分数。对于元组中的每个有序对 $i \succ j$, 其中 a_i 比 a_j 更接近专家操作, 我们应用 Bradley-Terry 偏好损失 (Bradley & Terry, 1952) :

$$\mathcal{L}_{\text{rew}}(i \succ j) = -\log \sigma(r(a_i) - r(a_j)), \quad (13)$$

并将 $\mathcal{L}_{\text{rew}}$ 定义为所有此类对的平均值。

最终的训练目标结合了这两个术语:

$$\mathcal{L}_{\text{total}} = \lambda_{\text{dir}} \mathcal{L}_{\text{dir}} + \lambda_{\text{rew}} \mathcal{L}_{\text{rew}}, \quad (14)$$

其中 λ_{dir} 和 λ_{rew} 平衡两个损失。我们在优化期间使用标准梯度裁剪。为了进行验证, 我们跟踪余弦对齐、角度误差以及 PRM 分数相对于动作与专家距离的单调性。

3.2.3 方向引导的测试时间缩放

在推理时, RoVer 通过将策略操作扩展为一组候选操作并在 PRM 下选择最佳操作来增强冻结的 VLA 策略。与训练的主要区别在于, 候选者是根据策略操作 a_p 而不是专家操作 a_e 生成的, 并且仅在预测方向 $\hat{u}$ 的指导下探索操作空间的“更好”一侧。我们实施两种采样策略并进行比较: i) 随机采样: 在没有指导的情况下用高斯噪声扰动 a_p ; ii) 方向引导采样: 通过沿 PRM 预测方向采样来扩展 a_p 。

该过程将额外的测试时间计算转换为改进的动作选择。随机抽样探索范围广泛但效率低下, 而方向引导抽样则利用 PRM 的预测方向将候选者集中在有前景的区域, 从而在相同的预算下产生更好的性能。

4 实验

我们在模拟和真实机器人平台上评估 RoVer。对于模拟, 我们在 ABC→D 设置下采用 CALVIN 基准: 模型在三个环境 (A、B、C) 中进行训练, 并在不可见的环境 (D) 中进行测试。我们从 VLA 研究的不同阶段选择了三个具有代表性的最先进基线——GR-1 (Wu et al., 2023)、Dita (Hou et al., 2025) 和 MoDE (Reuss et al., 2025)——来证明 RoVer 持续改进不同容量的策略。对于真实的机器人实验, 我们使用扩散策略 (DP) (Chi et al., 2024; 2023) 作为基本策略, 并表明 RoVer 还增强了物理操作任务的性能。

4.1 卡尔文基准实验

CALVIN 是一种广泛使用的长视野机器人操作仿真基准 (Mees 等人, 2022)。它提供了具有语言条件任务的多阶段环境, 能够评估技能构成和对未见过的配置的概括。ABC→D 分割尤其具有挑战性, 因为它需要在三个训练环境 (A、B、C) 中训练的模型才能转移到保留环境 (D)。

表 1: ABC→D 分割的 CALVIN 基准结果。列报告连续完成 k 任务的概率和平均链长度。除 GR-1* 外, 所有基线数字均取自官方排行榜 (<http://calvin.cs.uni-freiburg.de/>)。排行榜上报告的 GR-1 基线平均链长度为 3.06, 但在我们的本地复制中, 我们观察到更强的性能 (平均长度 3.19); 因此, 我们将本地评估的 GR-1* 报告为基本政策。† 表示通过在相应的基本策略之上应用 RoVer 测试时间缩放来实现的最佳性能。

Method	1	2	3	4	5	Avg. Len.
GR-1*	85.1	73.7	63.2	53.7	43.4	3.19
3D Diffuser Actor	92.2	78.7	63.9	51.2	41.2	3.27
GR-1†	86.1	75.3	66.8	56.2	48.7	3.33
Dita	94.5	82.5	72.8	61.3	50.0	3.61
RoboUniView	94.2	84.2	73.4	62.2	50.7	3.64
GHIL-Glue	95.2	88.5	73.2	62.5	49.8	3.69
Dita†	94.8	83.2	76.8	70.0	59.2	3.84
MoDE	96.2	88.9	81.1	71.8	63.5	4.01
MoDE†	97.1	90.9	82.5	74.9	66.6	4.12




图 3: 方向引导的测试时间扩展: 平均链长度与 $N+M$ (N 策略建议、 M 引导扩展)。面板对应于 GR-1、Dita 和 MoDE。红色: 无引导 (随机) 扩展; 蓝色: 方向引导 (DG)。由于第二季度讨论的块步不匹配, MoDE 显示出广泛但不太稳定的增益。

实验设置: 对于 RoVer, 我们重用 GR-1 骨干架构作为验证器, 用奖励令牌和方向令牌替换原始的动作令牌。总参数大小为 0.2B, 只有 40M 参数可训练 - 其余部分从 MAE 和 CLIP 文本编码器冻结。奖励模型在 CALVIN ABC→D 训练分割上训练 100 个 epoch, 我们使用最终检查点对所有主干网进行评估。重要的是, 我们只对训练集的 20% 进行了采样, 这表明 RoVer 的训练效率也很高。我们研究以下问题: Q1 (与骨干网无关的增益): RoVer 是否持续改进不同的预训练基线 (GR-1、Dita、MoDE; 以及真实机器人上的 DP)? Q2 (扩展和采样效率): 性能如何随着政策提案数量 N 和每个提案的引导扩展预算 M 进行扩展; 在固定候选预算 $K=N+M$ 下, 方向引导采样是否比无引导高斯扩展更有效? Q3 (推理效率): 共享感知缓存是否可以分摊计算并提高测试时的吞吐量/延迟?

基线方法: 我们总结了三个基线, 并强调了将它们与 RoVer 集成时的测试时间注意事项。除非另有说明, RoVer 在主干上应用统一的候选处理: (i) 扩展噪声仅注入 6D 手臂姿势组件; (ii) 夹具尺寸没有噪声, 并且是通过将 N 基本提案进行简单投票来选择的; (iii) 感知特征每一步预编码一次 (预编码) 并在候选者之间重复使用。

GR-1 (Wu 等人, 2023) 是一种 GPT 式轨迹模型, 以多视图 RGB 和语言为条件, 以自回归预测末端执行器增量 (6D 手臂姿势增量加上夹具标量)。在推理时, 我们为每个控制步骤绘制 N 个随机提议, 可选择在 PRM 预测方向周围的有界角区域内扩展每个动作, 并按 PRM 对所有候选者进行排名。由于 GR-1 本身在世界坐标系增量中运行, 因此不需要额外的坐标系转换。




图 4: GR-1: SR@k ($k=1 \dots 5$) 作为 N (政策建议) 的函数。增加 N 可以提高所有 k 的成功率, 揭示提案多样性的价值; 与图 3 一起, 这表明在重要的 N 之上添加方向引导扩展 M 会产生进一步的增益。

表 2: 有/没有共享感知缓存的推理效率。当每个步骤缓存一次感知特征时, 每个控制步骤的延迟会大大减少; 加速随着候选人数量的增加而增加。

#Actions	w/o cache (s)	w cache (s)	Speedup ($\times$)	Per-action (ms)
10	0.4140	0.0929	4.46	9.29
100	4.1400	0.6174	6.71	6.17
1000	41.4748	5.7384	7.23	5.74
10000	418.1795	58.2168	7.18	5.82

Dita (Hou 等人, 2025) 是一种扩散变换器策略, 可预测本地末端执行器坐标系中的相对运动 (位置和欧拉角增量), 并使用当前末端执行器姿势将其转换为世界坐标系增量。在 RoVer 下, 我们首先在本地图像中对 N 策略操作进行采样, 将每个操作转换为世界框架操作, 然后在世界框架中执行噪声扩展以与 PRM 的世界框架方向指导保持一致。

MoDE (Reuss 等人, 2025) 是一个具有 Mixture-of-Expert 降噪器的扩散变换器, 可输出一个短动作块 (一系列未来动作)。在使用 RoVer 进行测试时缩放期间, 我们绘制多个候选块, 并通过对每个块的第一个动作进行评分 (可选地在其 6D 手臂组件的方向引导扩展之后) 与 PRM 进行交互, 以选择执行的动作。替代块执行策略是正交的, 此处省略。

Q1: 与主干网无关的收益无需对基本策略进行任何重新训练, 将相同的 RoVer 验证器插入不同的主干网即可产生一致的改进 (表 1)。对于平均链长, GR-1 从 3.19 提高到 3.33, *Dita* 从 3.61 提高到 3.84, *MoDE* 从 4.01 提高到 4.12。从长期成功 (SR@5) 来看, GR-1 从 41.5% 上升到 48.7% (+17.4%), 而 *Dita* 从 50.0% 上升到 59.2% (+18.4%)。

Q2: 方向引导的测试时间扩展我们在统一的计算视图下研究扩展: 给定总候选预算 $K=N+M$ (策略建议 N 和方向引导的扩展 M), 性能通常随着 K 的增加而提高, 方向引导 (DG) 通过集中探索进一步提高样本效率。根据经验 (图 3 和图 4), 增加 N 首先通过多样化的政策模式以小预算产生巨大收益; 添加适度的 M 然后完善有希望的提案并产生额外的改进。在相同的 K 下, DG 可靠地优于 GR-1 和 *Dita* 上的无引导高斯展开, 这与方向头的预期作用一致。

然而, 对于 *MoDE*, 所有设置的增益并非始终较高 (图 3 的右图)。我们将此归因于块-步不匹配: *MoDE* 输出短动作块, 而我们的 PRM 是按时间步进行训练和应用的。为了维护统一的评估管道, 我们仅对每个块的第一个动作进行扩展和评分, 然后执行选定的块; 块内的后续步骤不会收到进一步的指导。这限制了我们干预块的能力, 并且随着 $N+M$ 的增加会产生非单调趋势。尽管如此, 该方法仍然有效 - 大多数 $N+M$ 设置仍然显示出积极的改进。

Q3: 共享感知缓存的影响 我们通过测量增加候选预算下每个控制步骤的挂钟延迟来评估缓存感知特征对候选的影响。如表 2 所示, 缓存大大减少了每步延迟, 并且加速比随着候选数量的增加而增长: 对于 10 个候选, 延迟从 0.414 秒下降到 0.0929 秒 (4.46 $\times$); 对于 100 和 1000 个候选者, 加速分别达到 6.71 $\times$ 和 7.23 $\times$ 。通过缓存,

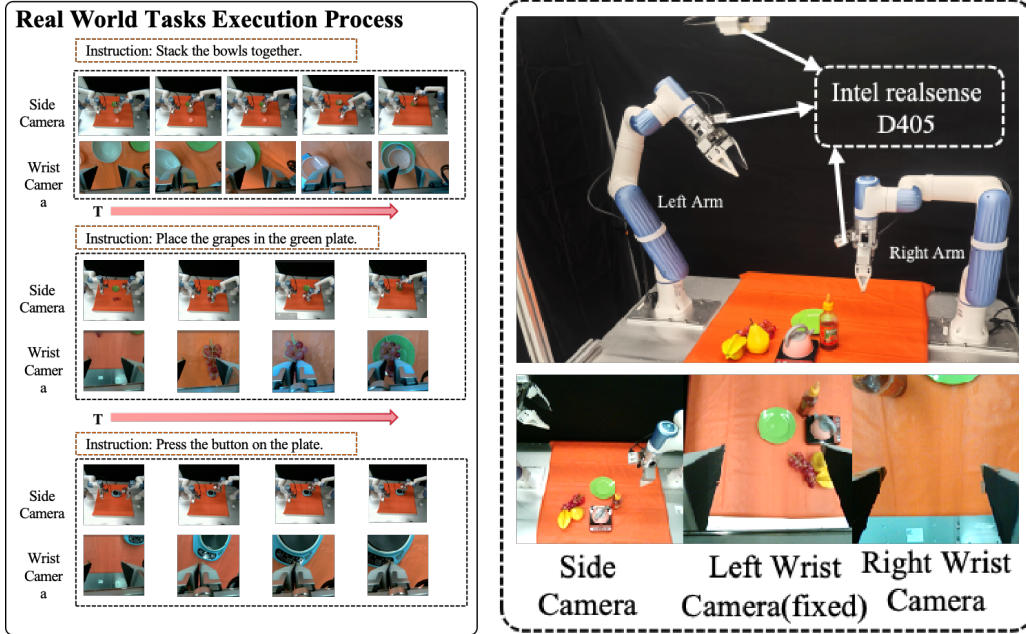


图 5: 左: 我们真实机器人实验的可视化。右: 我们评估中使用的双臂Dobot测试平台。

表 3: 真实机器人资源its: 成功率 (%)。每个条目均经过 10 次试验计算得出 r 条件。

Method	Pick and place			Push button		Stack bowls		Avg.
	Seen	Unseen object	Unseen position	Seen	Unseen position	Seen	Unseen position	
DP	100%	90%	50%	100%	50%	80%	40%	72.9%
DP†	100%	100%	70%	100%	80%	100%	70%	88.6%

每个动作的成本稳定在 5.7–6.2 毫秒左右（例如，100 个候选者为 6.17 毫秒，1000 个候选者为 5.74 毫秒），从而实现单个感知编码的候选者数量的近线性缩放。这些结果验证了通过共享感知缓存摊销感知对于测试时间扩展效率至关重要。所有延迟测量均在单个 NVIDIA V 100 GPU 上进行。

4.2 真实机器人实验

我们在双臂 Dobot 平台上评估 RoVer（图 5）。由于我们的任务是单臂的，因此左臂保持静止，而右臂执行。Perception 使用右臂上的手眼腕部摄像头和头顶的第三人称摄像头。我们考虑三个操作任务——拾取和放置、按钮和堆叠碗——每个任务在“已见”、“未见”对象和“未见”位置条件下进行评估。具体来说：取放是指抓起一件家居小物品，将其放置在指定位置；按钮需要移至并启动面板按钮；堆叠碗需要将一个碗放在另一个碗上并正确对齐。如表 3 所示，RoVer (DP†) 在所见案例上与 DP 相匹配，同时在泛化方面提供了明显的收益。

5 结论

RoVer 是一个外部测试时间扩展框架，通过引入紧凑的流程奖励模型来对候选操作进行评分和指导，从而升级冻结的 VLA 策略。在不重新训练骨干网络的情况下，RoVer 能够持续提高不同策略的性能 (Q1)，根据候选预算有效扩展——尤其是在方向指导下 (Q2)——并通过共享感知缓存实现大幅推理加速 (Q3)。虽然限制仍然存在（例如，分块策略的步骤块不匹配以及使用专家邻近度作为监督代理），但 RoVer 证明，将计算从训练重新分配到推理可以可靠地解锁具体策略中的附加功能，而无需额外的预训练或数据。

道德声明

我们的工作仅涉及机器人模拟和真实机器人实验，不包括人类或动物受试者。所有数据集都是从机器人操作试验中收集的，不包含个人信息。所提出的方法旨在用于实体人工智能和机器人技术的学术研究。我们不知道直接误用风险，但与任何通用学习方法一样，如果部署在安全关键或对抗性环境中，建议谨慎行事。

再现性声明

我们在主论文和附录中提供了模型架构、训练过程和评估协议的详细描述。文本和表格中指定了超参数、网络大小和任务设置。其他培训细节、数据处理步骤和评估脚本将在接受后开源。

参考

AgiBot-World-Contributors, 卜庆文, 蔡继松, 等人。Agibot world colosseo: 用于可扩展和智能体现系统的大型操纵平台, 2025。URL <https://arxiv.org/abs/2503.06669>。

凯文·布莱克、诺亚·布朗、丹尼·德里斯、阿德南·埃斯梅尔等。 π_0 : 通用机器人控制的视觉-语言-动作流模型, 2024 年。URL <https://arxiv.org/abs/2410.24164>。

R.A.布拉德利和M.E.特里。不完全区组设计的等级分析: 一、配对比较法。 *Biometrika*, 39 (3-4): 324–345, 1952。doi: 10.1093/biomet/39.3-4.324。

卜清文、李红阳、陈力、蔡继松、曾家、崔鹤明、姚茂清和乔宇。迈向协同、通用、高效的机器人操作双系统, 2025a。网址 <https://arxiv.org/abs/2410.08001>。

卜庆文、杨彦婷、蔡继松、高申元、任光辉、姚茂庆、罗平和李红阳。Univla: 学习通过以任务为中心的潜在行动在任何地方采取行动, 2025b。网址 <https://arxiv.org/abs/2505.06111>。

池成、冯思源、杜逸伦、徐振佳、Eric Cousineau、Benjamin Burchfiel 和宋舒然。扩散政策: 通过行动扩散进行视觉运动政策学习。在 *Proceedings of Robotics: Science and Systems (RSS)*, 2023 年。

迟诚、徐振佳、冯思源、Eric Cousineau、杜逸伦、Benjamin Burchfiel、Russ Tedrake 和 Shuran Song。扩散政策: 通过行动扩散进行视觉运动政策学习。 *The International Journal of Robotics Research*, 2024 年。

开放 X 实施例协作, Abby O’Neill、Abdul Rehman 等人。Open X-Embodiment: 机器人学习数据集和 RT-X 模型。 <https://arxiv.org/abs/2310.08864>, 2023。

崔灿、丁鹏翔、宋文轩、白双豪、童新阳、葛子瑞、索润泽、周万琪、刘阳、贾博芳、赵涵、黄思腾和王东林。Openhelix: 机器人操作的简短调查、实证分析和开源双系统 vla 模型, 2025 年。URL <https://arxiv.org/abs/2505.03912>。

DeepSeek-AI。Deepseek-r1: 通过强化学习激励 llms 的推理能力, 2025 年。URL <https://arxiv.org/abs/2501.12948>。

姚木傅立叶 ActionNet 团队。Actionnet: 用于灵巧双手操作的数据集。 2025 年。

何凯明、陈新雷、谢赛宁、李阳浩、Piotr Dollár 和 Ross Girshick。蒙面自动编码器是可扩展的视觉学习器, 2021 年。URL <https://arxiv.org/abs/2111.06377>。

侯志、张天一、熊宇文、段浩南、浦恒军、佟荣蕾、赵成阳、朱喜洲、乔宇、戴继峰和陈云涛。Dita: 通用视觉-语言-行动政策的扩展扩散变压器。 *arXiv preprint arXiv:2503.19757*, 2025 年。

季宇恒, 谭华杰, 石家宇, 郝小帅, 张元, 张恒元, 王鹏伟, 赵梦迪, 穆姚, 安鹏举, 等。Robobrain: 用于从抽象到具体的机器人操作的统一大脑模型。*arXiv preprint arXiv:2502.21257*, 2025 年。

丹尼尔·卡内姆一个。Thinking, Fast and Slow。Farrar, Straus 和 Giroux, 2011。

贾里德·卡普兰、萨姆·麦坎德利什、汤姆·赫尼根、汤姆·B·布朗、本杰明·切斯、瑞旺·柴尔德、斯科特·格雷、亚历克·雷德福、杰弗里·吴和达里奥·阿莫迪。神经语言模型的缩放定律。*arXiv preprint arXiv:2001.08361*, 2020。

Moo Jin Kim、Karl Pertsch、Siddharth Karamcheti 等。Openvla: 开源视觉语言动作模型, 2024 年。URL <https://arxiv.org/abs/2406.09246>。

Jacky Kwok、Christopher Agia、Rohan Sinha、Matt Foutter、Shulu Li、Ion Stoica、Azalia Mirosaeini 和 Marco Pavone。Robomongo: 缩放视觉语言动作模型的测试时间采样和验证, 2025 年。URL <https://arxiv.org/abs/2506.17811>。

林凡琪、奈瑞茜、胡英东、游家成、赵俊明、高阳。Onetwovla: 具有自适应推理的统一视觉-语言-动作模型, 2025。URL <https://arxiv.org/abs/2505.11917>。

刘家明、陈浩、安鹏举、刘卓阳、张仁瑞、谷晨阳、李晓琪、郭子宇、陈思祥、刘孟震、侯成凯、赵孟迪、KC alex Zhou、Pheng-Ann Heng 和张尚航。Hybridvla: 统一视觉-语言-动作模型中的协作扩散和自回归, 2025a。网址 <https://arxiv.org/abs/2503.10631>。

刘润泽、高俊奇、赵健、张凯彦、李秀、齐碧清、欧阳万里和周博文。1b llm能超越405b llm吗? 重新思考计算最优测试时间扩展, 2025b。网址 <https://arxiv.org/abs/2502.06703>。

刘松明、吴令轩、李邦国、谭恒凯、陈华宇、王正义、徐科、苏航和朱军。Rdt-1b: 用于双手操作的扩散基础模型, 2025c。网址 <https://arxiv.org/abs/2410.07864>。

马南野、童尚元、贾浩林、胡鹤翔、苏玉川、张明达、杨轩、李彦东、Tommi Jaakkola、贾旭辉和谢赛宁。超出缩放去噪步骤的扩散模型的推理时间缩放, 2025。URL <https://arxiv.org/abs/2501.09732>。

奥伊尔·米斯、卢卡斯·赫尔曼、埃里克·罗塞特-比亚斯和沃尔夫拉姆·布尔加德。Calvin: 用于长视野机器人操作任务的语言条件策略学习的基准。IEEE Robotics and Automation Letters (RA-L), 7(3): 7327–7334, 2022。

NVIDIA、Johan Bjorck、Fernando Castañeda 等人。Gr00t n1: 通用人形机器人的开放基础模型, 2025 年。URL <https://arxiv.org/abs/2503.14734>。

OpenAI, :, Aaron Jaech, Adam Kalai, Adam Lerer 等人。Openai o1 系统卡, 2024 年。URL <https://arxiv.org/abs/2412.16720>。

亚历克·雷德福、杰夫·吴、Rewon Child、大卫·卢安、达里奥·阿莫代和伊利亚·苏茨克弗。语言模型是无监督的多任务学习者。2019。

Alec Radford、Jong Wook Kim、Chris Hallacy、Aditya Ramesh、Gabriel Goh、Sandhini Agarwal、Girish Sastry、Amanda Askell、Pamela Mishkin、Jack Clark、Gretchen Krueger 和 Ilya Sutskever。从自然语言监督中学习可转移的视觉模型, 2021。URL <https://arxiv.org/abs/2103.00020>。

莫里茨·罗伊斯 (Moritz Reuss)、乔西什·帕里 (Jyothish Pari)、普尔基特·阿格拉瓦尔 (Pulkit Agrawal) 和鲁道夫·利乌蒂科夫 (Rudolf Lioutikov)。高效的扩散变压器策略与专家降噪器的混合, 用于多任务学习。在 The Thirteenth International Conference on Learning Representations, 2025 年。URL <https://openreview.net/forum?id=nDmwloEl3N>。

一德·申屠、Philipp Wu、Aravind Rajeswaran 和 Pieter Abbeel。从 llms 到行动：潜在代码作为分层机器人控制中的桥梁，2025 年。URL <https://arxiv.org/abs/2405.04798>。宋浩明、屈德林、姚远奇、陈其志、吕奇、唐一文、史莫迪、任光辉、姚茂清、赵斌、王东和李雪龙。休谟：在视觉语言动作模型中引入系统 2 思维，2025 年。URL <https://arxiv.org/abs/2505.21432>。Qi Sun、Pengfei Hong、Tej Deep Pala、Vernon Toh、U-Xuan Tan、Deepanway Ghosal 和 Soujanya Poria。Emma-x：一种具有扎根思想链和前瞻空间推理的具体多模式行动模型，2024 年。URL <https://arxiv.org/abs/2412.11974>。王雨琪、李星航、王文轩、张俊波、李英艳、陈云涛、王新龙和张兆祥。统一视觉-语言-行动模型，2025。URL <https://arxiv.org/abs/2506.19850>。王志强、郑浩、聂云双、徐文军、王庆伟、叶华、李喆、张凯东、程学文、董万喜、蔡昌、林亮、郑峰和梁晓丹。所有机器人合而为一：用于多功能、通用具体代理的新标准和统一数据集，2024 年。URL <https://arxiv.org/abs/2408.10899>。吴洪涛、静亚、Chilam Cheung、陈光增、徐嘉峰、李星航、刘明焕、李航和孔涛。为视觉机器人操作释放大规模视频生成预训练，2023 年。URL <https://arxiv.org/abs/2312.13139>。米哈乌·扎瓦尔斯基 (Micha Zawalski)、威廉·陈 (William Chen)、卡尔·佩奇 (Karl Pertsch)、奥伊尔·梅斯 (Oier Mee s)、切尔西·芬恩 (Chelsea Finn) 和谢尔盖·莱文 (Sergey Levine)。通过体现的思想链推理进行机器人控制，2025。URL <https://arxiv.org/abs/2407.08693>。泽艳杰、张谷、张康宁、胡陈元、王木涵和徐华哲。3d 扩散政策：通过简单 3d 表示进行通用视觉运动政策学习，2024 年。URL <https://arxiv.org/abs/2403.03954>。张建科、郭彦江、陈晓宇、王彦仁、胡玉成、施成明和陈建宇。Hirt：利用分层机器人变压器增强机器人控制，2025 年。URL <https://arxiv.org/abs/2410.05273>。赵青青、姚路、Moo Jin Kim、Zipeng Fu、Zhuoyang 张、Ye Cheng Wu、Zhaoshuo Li、Qianli Ma、Song Han、Chelsea Finn、Ankur Handa、Ming-Yu Liu、Donglai Xiang、Gordon Wetzstein 和 Tsung-Yi Lin。Cot-vla：视觉语言动作模型的视觉思想链推理，2025。URL <https://arxiv.org/abs/2503.22020>。托尼·赵、维卡什·库马尔、谢尔盖·莱文和切尔西·芬恩。使用低成本硬件学习细粒度双手操作，2023 年。URL <https://arxiv.org/abs/2304.13705>。周忠义、朱一辰、朱敏杰、文俊杰、刘宁、徐志远、孟伟斌、程然、彭雅欣、沉超民和冯飞飞。Chatvla：使用视觉语言动作模型统一多模态理解和机器人控制，2025 年。URL <https://arxiv.org/abs/2502.14420>。

附录

A.1 大语言模型的使用

大型语言模型（LLM）不参与所提出方法的设计、实现或评估。它们在这项工作中的唯一用途是提供较小的语言帮助，例如润色写作风格和提高手稿的可读性。所有技术想法、实验和分析均完全由作者构思和实施。

A.2 动作分布分析

为了校准偏好奖励模型（PRM）和我们的测试时间采样所使用的扰动尺度，我们量化了 CALVIN 验证集上的策略操作 A_p 和专家操作 A_e 之间的分布差距。遵循 GR-1 中的分析脚本（可视化 3D 偏差及其投影），我们收集每步偏差 $\Delta a = A_p - A_e$ 并总结平移的坐标统计数据（XYZ）和欧几里得距离 $\|\Delta a_{xyz}\|_{2\circ}$ 。

汇总统计数据的主要发现如下：

- 接近零偏差：所有轴的平均平移偏差都很小（X/Y/Z：0.0009/0.0048/-0.0013 m）。中位数同样接近于零。
- 各向异性扩散：标准差为（X/Y/Z：0.184/0.116/0.165 m），表明沿 Y 的扩散稍窄，沿 X 和 Z 的尾部更宽。
- 重尾距离：欧氏距离平均值为 0.215 m，中位数为 0.170 m，具有长尾（最小 0.003 m，最大 1.708 m）。这与大多数样本聚集在原点附近且有一小部分大异常值的可视化结果相匹配。

对培训和抽样的影响。我们设置了一个保守的基础噪声尺度 $\sigma_{\text{base}} = 0.1$ 来构建以锚为中心的对：它小于策略与专家差距的中值（0.17 m），这（i）使大多数合成的“更好/更差”对在政策建议周围保持流形，（ii）避免用罕见的、遥远的异常值对验证者进行过度惩罚。测试时，以同样的规模作为围绕政策行动进行候选扩展的初始半径；我们将其与 PRM 的方向指导相结合，使样本偏向专家流形，同时保持多样性。

与定性 3D 散点图和投影图一起，该分析支持我们选择一个虽小但重要的扰动半径，并激发了整篇论文中使用的方向感知、以锚点为中心的采样。

A.3 实施细节

使用动作放大器稳定训练在 PRM 的早期训练期间，我们观察到一种退化现象，即奖励头向输入方向几乎恒定的输出崩溃，并且损失趋于稳定。我们的假设是，强大的冻结主干（从 GR-1 初始化）主导了特征融合，导致动作嵌入的微小差异被减弱，从而为奖励头提供弱梯度。因此，我们引入了一个 *Action Amplifier* - 一个带有 GELU 和 LayerNorm 的轻量级 MLP $H \rightarrow 2H \rightarrow H$ - 放置在动作嵌入之后和令牌融合之前。这会重新调整动作通道，保留附近候选者之间的细粒度增量，并恢复有用的梯度。添加放大器后，训练变得稳定，损失可靠下降。

用于鲁棒偏好学习的基于锚的动态采样使用单个固定噪声尺度围绕专家动作生成噪声动作对产生了狭窄的训练分布和次优的测试时间缩放。为了在匹配测试时行为的同时实现监督多样化，我们采用了 *anchor-centered* 动态方案（参见第 3.2 节）：（i）通过将 6D 姿态子空间中的基础高斯噪声添加到专家动作中来对锚动作进行采样；（ii）计算从锚点到专家的真实方向 u_{gt} 并定义正交超平面；（iii）使用由锚-专家距离裁剪的自适应噪声尺度对两个半空间（“更好”和“更差”）上的附加动作进行采样；（iv）使用 Bradley-Terry 对有序对的偏好损失（更接近专家的偏好）以及将预测方向与 u_{gt} 对齐的方向损失进行训练。在




图 6: GR-1 政策行动与专家行动之间分布差距的可视化。

算法 1: RoVer 测试时间扩展框架 输入: 观察 h 、策略 π_θ 、验证者 R_ϕ 、策略操作数量

N 、扩展候选 M 、角度边界 α 输出: 最终执行的操作 a^*

1. 策略步骤: 查询 N 操作

$\{a_p^1, a_p^2, \dots, a_p^N\} \leftarrow \pi_\theta(h)$ 的基本策略

2. 扩展步骤: 对于每个策略操作 a_p^j , 将其扩展为 $\frac{M}{N}$

候选者: 预测方向 $\hat{u}^j = R_\phi(h, a_p^j).dir$ (维度 d_{dir} 与动作子空间匹配) 对于 $k = 1, \dots, \frac{M}{N}$

: 采样随机向量 $v \sim \mathcal{N}(0, I_{d_{dir}})$, 投影 $p = v - (v^\top \hat{u}^j) \hat{u}^j$, 标准化 $p \leftarrow p / \|p\|$. 采样角度

$\theta \sim \text{Unif}(0, \alpha)$ 和幅度 $m \sim |\mathcal{N}(0, \sigma^2)|$. 构造扰动 $\epsilon = m(\cos \theta \hat{u}^j + \sin \theta p)$. 更新可操作

子空间中的候选者, 使离散夹具在存在时保持不变。收集

$\mathcal{A} = \{a_p^j\}_{j=1}^N \cup \{a_j^k\}_{j=1, \dots, N, k=1, \dots, \frac{M}{N}}$

3. 编码步骤: 计算共享感知特征 $z_{obs} \leftarrow f_{obs}(h)$ (预编

码) 4. 候选评分: 对每个 $a \in \mathcal{A}$ (动作进行编码) $(r, d) \leftarrow R_\phi(z_{obs}, z_{act})$

5. 动作选择: $a^* \leftarrow$

$z_{act} \arg \max_{a \in \mathcal{A}} r(a)$ 返回 a^*

在实践中, 这产生的 PRM 比使用固定尺度高斯对训练的模型更好地推广到方向引导的 TTS

。

模型架构验证器 R_ϕ 是一个轻量级的 GPT-2 式转换器, 具有冻结的 CLIP 文本和 MAE 视觉编码器。感知器重采样器压缩图像标记; 机器人状态和 7D 动作是线性嵌入的, 并且 *action amplifier* MLP ($H \rightarrow 2H \rightarrow H$) 突出显示了微小的动作差异。两个学习的查询标记在动作子空间中产生标量过程奖励和标准化方向 (通常在 CALVIN 上为 6D, 在 PushT 上为 2D)。为了效率, 我们分开




图 7: PRM 的训练（左）和验证（右）日志。使用动作放大器，损失稳定减少，奖励头避免退化（恒定）输出。

表 4: 验证者架构超参数（键 = 值）。

Key	Value
Hidden size	$H = 384$
Layers	12
Attention heads	12
FFN	$4H$
Dropout	0.1
Positions	1024
Seq. length	$L = 10$
Text encoder dim	$512 \rightarrow H$
Vision patch size	16
Resampler latents	9
Resampler depth	3
Resampler dim_head	128
Resampler heads	4
State dim	6 (pose) + 2 (one-hot gripper)
Action dim	7
Amplifier	$H \rightarrow 2H \rightarrow H$
Reward head	$H \rightarrow H/2 \rightarrow H/4 \rightarrow 1$
Direction head	$H \rightarrow H/2 \rightarrow d_{\text{dir}}$

计算分为共享的“预编码”步骤（感知/语言/状态）和快速的“动作编码”步骤（每个候选），从而实现候选数量的近线性缩放。表 4 总结了关键超参数。

A.4 卡尔文基准

我们在标准 ABC→D 泛化设置下对 CALVIN 基准（Mees et al., 2022）进行评估：我们在环境 A、B 和 C 上训练奖励模型，并在未见过的环境 D 上进行评估。CALVIN 具有长视野、语言条件桌面操作，具有多对象场景和组合目标。每集都配有自然语言指令；当指示的行为在固定范围内完成时，即算成功（见图 8）。

任务集包括旋转和推动彩色块、打开/关闭抽屉和滑块、提升/放置/堆叠/拆开块、切换灯泡/LED 以及将块推入抽屉。遵循每个骨干网的官方评估协议，我们对 GR-1 和 MoDE 执行 1,000 个多步序列，每个序列包含 5 种语言指令，对 Dita 执行 250 个序列。对于每个子任务，我们允许最多 360 个控制步骤，并在特定于任务的预言机检测到完成时计数成功。



图 8: CALVIN 基准测试和 $ABC \rightarrow D$ 拆分概述。