

ROVER: 作为视觉-语言-动作模型测试时验证器的机器人奖励模型

Mingtong Dai^{1,2,6} Lingbo Liu^{2,†} Yongjie Bai^{2,3} Yang Liu³ Zhouxia Wang⁴
Rui Su⁵ Chunjie Chen¹ Liang Lin^{2,3,7} Xinyu Wu¹

¹Shenzhen Institute of Advanced Technology, Chinese Academy of Sciences

²Peng Cheng Laboratory

³School of Computer Science and Engineering, Sun Yat-sen University

⁴College of Computing and Data Science, Nanyang Technological University

⁵Shanghai AI Laboratory

⁶University of Chinese Academy of Sciences ⁷X-Era AI Lab

[†]Corresponding Author

摘要

视觉-语言-动作（VLA）模型已成为具身智能的重要范式，然而进一步的性能提升通常依赖于扩大训练数据和模型规模——这种方法对机器人技术而言成本过高，且从根本上受限于数据采集成本。本文通过 **RoVer** 解决这一局限性，**RoVer** 是一种具身测试时扩展框架，使用机器人过程奖励模型（PRM）作为测试时验证器，在不修改现有 VLA 模型架构或权重的情况下增强其能力。具体而言，**RoVer** (i) 分配基于标量的过程奖励来评估候选动作的可靠性，并 (ii) 预测动作空间方向以进行候选扩展/细化。在推理过程中，**RoVer** 从基础策略并生成多个候选动作，沿 PRM 预测的方向扩展它们，然后用 PRM 对所有候选进行评分，以选择最优动作执行。值得注意的是，通过缓存共享感知特征，它可以分摊感知成本，并在相同的测试时计算预算下评估更多候选。本质上，本文方法有效地将可用计算资源转化为更好的动作决策，实现了测试时扩展的益处，而无需额外的训练开销。大量实验表明，**RoVer** 在各种操作任务中持续提高成功率。本文贡献有三方面：（1）一个通用的、即插即用的 VLA 测试时扩展框架；（2）一个 PRM，联合提供标量过程奖励和动作空间方向以指导探索；（3）一种高效的方向引导采样策略，利用共享感知缓存实现推理期间可扩展的候选生成与选择。

1 引言

具身智能（Embodied AI）领域已取得显著进展，从 ACT、DP 和 DP3 等专用模型（Zhao 等，2023；Chi 等，2024；2023；Ze 等，2024）发展到 OpenVLA、 $\pi 0$ 和 RDT 等通用视觉-语言-动作（VLA）系统（Kim 等，2024；Black 等，2024；Liu 等，2025c）。这些 VLA 模型通常在成对的视觉-语言-动作数据上进行端到端训练，迄今为止的大部分收益来自训练时扩展策略，即使用更大的骨干网络、多样化演示数据以及改进数据策展流程。然而，即使在相同设置下，VLA 的成功率也常因随机解码和操作脆弱性而波动，这一问题在长时程任务上尤为突出。该现象促使将部分努力从训练时扩展重新分配到推理时计算，旨在稳定结果并释放现有 VLA 模型的潜在能力。

受缩放定律（Scaling Laws）（Kaplan 等，2020）在大语言模型（Large Language Models）和视觉语言模型（Vision-Language Models）中巨大成功的启发，具身智能（Embodied AI）领域的许多研究工作旨在

通过收集大规模训练数据集（如开放跨实体数据集（Open-X-Embodiment）、智元世界（Agi World）、傅利叶动作网（Fourier ActionNet）和 ARIO（Collaboration et al., 2023; AgiBot-World-Contributors et al., 2025; Fourier ActionNet Team, 2025; Wang et al., 2024）），并增大模型参数量（例如 RT-X（Collaboration et al., 2023）、OpenVLA（Kim et al., 2024）、RDT（Liu et al., 2025c）），可以复制这一进展。然而，与用于大语言模型（LLM）/视觉语言模型（VLM）的互联网规模语料库不同，获取多样化、高质量的机器人经验数据仍然是一个资源密集且耗时的过程，这为具身智能（Embodied AI）领域的训练时扩展带来了显著瓶颈。

为了在不进一步训练的情况下提升视觉语言动作（VLA）性能，研究人员开始增加测试时的“思考”比例。一些具身方法采用快慢思考设计，将深思熟虑的高层“大脑”与低延迟的“小脑”控制器分离，从而为更具挑战性的任务实现规划与执行的解耦（Kahneman, 2011; Zhang et al., 2025; Shentu et al., 2025; Bu et al., 2025a）。后续工作通过向数据集中注入思维链标注来扩展监督信号，以训练可在推理时调用的复杂高层推理模块（Zawalski et al., 2025; Ji et al., 2025; Zhou et al., 2025）。这些途径已在大型语言模型（LLMs）和视觉语言模型（VLMs）中展现出潜力，通常被称为测试时扩展（Liu et al., 2025b; Ma et al., 2025）。然而，上述大多数方法都需要用补充标注来扩展原始数据集。

在这种情况下，我们提出一个根本性问题：能否利用测试时扩展机制来提升视觉-语言-动作模型的性能，而无需额外数据或模型重训练？这一问题引导我们探索一个有前景的范式，该范式专注于在推理过程中最大化现有视觉-语言-动作模型的效用，而非追求越来越大的数据集和架构。为此，我们引入了 RoVer，一种新颖的外部过程奖励模型，旨在仅在推理时增强冻结的视觉-语言-动作策略的能力。具体而言，我们的 RoVer 不仅评估大量候选动作的可靠性分数，还预测动作空间中精确的六自由度细化方向。这种设计在保持原始骨干架构和权重不变的同时，实现了智能候选评估和方向引导采样。关键的是，我们的方法将额外的测试时计算资源转化为改进的决策能力，有效规避了数据收集和模型重训练的传统约束。RoVer 的另一个优雅之处在于其高效利用共享计算的能力。通过缓存和重用感知流程中的中间特征，我们的框架能够以最小的额外计算开销评估多个候选动作。这一设计选择确保了决策能力的提升以合理的计算成本实现，使其适用于实际的机器人应用。总之，我们的工作为该领域做出了三项重要贡献：

- 一个通用的、即插即用的测试时扩展框架，仅在推理时增强冻结的视觉-语言-动作策略，展示了一种无需传统数据收集和模型重训练成本即可提升视觉-语言-动作模型性能的新范式。
- 一个紧凑而强大的过程奖励模型，同时生成标量过程奖励和候选动作的细化方向，实现了动作空间中有效的验证器引导探索。
- 一种高效的方向引导采样策略，利用共享感知缓存，有效分摊感知成本，并在相同的计算预算内评估更多候选。

2 相关工作

视觉-语言-动作模型。视觉-语言-动作（VLA）模型已从专用、任务特定的策略（Zhao 等人，2023; Chi 等人，2024; 2023; Ze 等人，2024）演变为耦合感知、语言 and 控制的通用系统（Kim 等人，2024; Black 等人，2024; Liu 等人，2025c），近期进展探索了受人类认知双过程理论启发的分层架构（Kahneman, 2011; Shentu 等人，2025; Zhang 等人，2025; Bu 等人，2025a; Cui 等人，2025; Liu 等人，2025a; NVIDIA 等人，2025）。迄今为止，大部分性能提升来自训练时扩展——更大的骨干网络、更广泛的演示以及改进的数据策展。

大语言模型中的测试时扩展。大语言模型（LLM）的最新进展凸显了测试时扩展（TTS）技术在推理阶段提升其推理能力的有效性。

TTS 方法通常可分为两大类 (Liu 等人, 2025b)：内部方法和外部方法。内部 TTS 方法，如自我反思和思维链 (CoT)，涉及模型生成并优化自身的中间推理步骤，典型模型包括 OpenAI o1 和 DeepSeek-R1 (OpenAI 等人, 2024; DeepSeek-AI, 2025)。相比之下，外部 TTS 利用过程奖励模型 (PRM) 提供反馈并监督生成过程，从而支持最佳-N (BoN) 和束搜索等搜索策略。值得注意的是，研究表明，借助外部 TTS，即使是规模小得多的模型，在某些任务中也能达到或超越大得多的模型的性能。这一范式主张将计算资源从大规模预训练战略性地重新分配到推理阶段，从而实现更高效的性能提升。自治性和蒙特卡洛树搜索等进一步策略也利用 PRM 生成多样化且集成的输出。

视觉-语言-动作模型中的测试时扩展。内部测试时扩展：近期工作通过在推理时增加视觉-语言-动作模型 (VLA) 的内部思考来提升性能：具身思维链 (Embodied Chain-of-Thought) (Zawalski 等, 2025; Ji 等, 2025; Sun 等, 2024; Zhou 等, 2025) 方法在动作生成前强制进行多步推理，以改善任务分解与规划，通常通过扩展带有推理标注的训练数据集来实现。CoT-VLA 和 UniVLA (Zhao 等, 2025; Bu 等, 2025b; Wang 等, 2025) 在推理过程中融入未来帧预测；OneTwo-VLA (Lin 等, 2025) 使用 [BOR] 和 [BOA] 标记来自适应地决定何时推理、何时行动。然而，上述大多数工作都需要对训练数据集进行额外标注。外部测试时扩展：与在策略内部进行推理的内部测试时扩展 (TTS) 不同，外部测试时扩展通过引入独立的奖励/价值验证器，在推理时评估候选动作，从而将搜索和评分与策略解耦，在不修改骨干网络权重的情况下指导候选生成。同期工作探索了这一方向：Hume (Song 等, 2025) 为双系统 VLA 增加了一个价值头，以驱动重复采样和级联去噪（候选数量固定），而 RoboMonkey (Kwok 等, 2025) 研究了大规模骨干网络和合成数据下的奖励建模。我们的工作通过一个紧凑的过程奖励模型实例化外部测试时扩展，并系统地研究了候选预算的扩展性以及跨骨干网络的兼容性；见第 3.2 节。

3 方法

概述 我们为冻结的 VLA 增加一个外部过程奖励模型 (PRM)，该模型在给定观测、语言和候选动作时，输出一个标量分数和一个改进方向。在推理时，通过沿预测方向在角度界限内采样来扩展策略提议，并执行在 PRM 下得分最高的动作。观测、语言和状态特征在每个步骤计算一次并缓存，供所有候选动作复用（见图 1）。

3.1 预备知识

策略模型 我们考虑具有观测 o_t （例如 RGB-D 图像、本体感觉）、自然语言目标 g 和历史 $h_t = (o_{\leq t}, g)$ 的顺序决策问题。预训练的 VLA 策略 π_θ 将历史 h_t 映射到低级动作 $a_t \in A$ 上的分布：

$$\pi_\theta(a_t | h_t) \in \Delta(A), \quad (1)$$

我们使用带有夹爪指令的末端执行器增量动作， $a_t = [\Delta p_t, \Delta q_t, g_t] \in \mathbb{R}^{d_a}$ ，在我们的设置中 $d_a = 7$ ($\Delta p_t \in \mathbb{R}^3, \Delta q_t \in \mathbb{R}^3, g_t \in \mathbb{R}$)。在推理时，可以执行 $a_t = \arg \max_a \pi_\theta(a | h_t)$ 。

奖励模型 为了在测试时解锁额外能力，本文引入一个奖励模型，该模型预测 (i) 标量过程奖励和 (ii) 从当前动作指向潜在更优动作的动作空间方向：

$$R_\phi(h_t, a_t^i) \rightarrow r_t^i, d_t^i, \quad r_t^i \in \mathbb{R}, d_t^i \in \mathbb{R}^{d_{\text{dir}}}. \quad (2)$$

本文为控制的可操作子空间（当存在时排除离散夹爪）预测方向。维度 d_{dir} 与动作子空间匹配；实践中使用归一化方向 $\hat{u}_t^i = \text{归一化}(d_t^i)$ 。

符号说明 从本节起，除非另有说明，为清晰起见省略时间索引 t 。下标表示动作来源： a^i 表示第 i 个候选动作， a_e 表示训练数据集中的专家动作， a_p 表示策略动作， a_{anc} 表示训练期间围绕 a_e 采样的锚动作。




图 1: RoVer 概览。冻结的视觉-语言-动作模型提出 N 个动作；外部过程奖励模型对候选动作评分并预测细化方向。候选动作沿引导方向扩展，得分最高的动作被执行。感知特征仅缓存一次并在候选动作间复用，以分摊计算成本。

测试时扩展 给定基础策略 π_θ 和验证器 R_ϕ ，从 π_θ 获得策略动作 a_p ，并通过高斯噪声采样将其扩展为候选集 $\mathcal{A} = \{a^0 = a_p, a^1, a^2, \dots\}$ 。过程奖励模型验证器 R_ϕ 使用 $r^i = R_\phi(h, a^i)$ 对每个候选动作评分，并执行 $a^* = \arg \max_{a \in \mathcal{A}} r(h, a)$ 。本文在 3.2.3 节详细阐述该框架。

3.2 ROVER

RoVer 通过一个紧凑的过程奖励模型（Process Reward Model, PRM）实例化外部测试时扩展，该模型对候选动作进行评分，并在动作子空间中预测细化方向。对于在局部坐标系中定义的策略，动作在扩展和评分之前被映射到世界坐标系。以下小节详细介绍了架构、训练目标和推理过程。

3.2.1 模型架构

R_ϕ 接收同步的多模态输入 o_t （例如，第三人称和眼在手 RGB 图像、机器人状态和语言标记）以及候选动作 a^i ，并输出标量过程奖励 r^i 和动作空间方向 d^i 。模型架构遵循 GPT-2 风格（Radford 等人，2019），并使用 GR-1（Wu 等人，2023）的预训练权重进行初始化。具体来说，图像编码器由 MAE（He 等人，2021）预训练模型初始化，文本编码器由 CLIP 文本编码器（Radford 等人，2021）初始化。该架构原则上支持最多 10 个时间步的历史作为输入。然而，为了更好的即插即用性和更快的推理，我们将输入限制为当前时间步的观测。在初始化的主干网络之上添加了用于奖励和方向预测的额外头。由于所有候选动作在一个控制步骤中共享相同的观测、语言和状态，我们计算这些感知特征一次，并在候选动作之间重用它们作为共享感知缓存，同时为每个候选动作编码动作以分摊计算。与在 RoboMonkey（Kwok 等人，2025）中微调 70 亿参数主干网络相比，RoVer 总共只有 2 亿参数，训练时仅需 4000 万参数。参见图 2。

动作放大器 为了使候选动作之间的微小差异更易辨别，我们在将动作嵌入与观测/语言标记融合之前，对其应用一个轻量级的动作放大器。该放大器是一个紧凑的多层感知机（MLP），带有 GELU 激活和层归一化，映射 $\mathbb{R}^H \rightarrow \mathbb{R}^{2H} \rightarrow \mathbb{R}^H$ ，以重新调整动作通道，使得在强大的冻结感知/语言主干网络下，动作子空间中的细粒度增量仍然显著。这种对比增强器提高了 PRM 区分和排序邻近动作的能力，同时将推理开销降至最低。对于




图 2: 左: 验证器架构。共享感知缓存和逐候选动作编码器（带动作放大器）通过奖励/方向令牌馈入 GPT-2 骨干网络，产生标量过程奖励和动作空间细化方向。右: PushT 基准上的方向可视化，其中 PRM 在预训练的扩散策略之上训练，并预测 2D (x, y) 动作方向；对于 CALVIN，PRM 预测 6D 姿态方向。注：在 PushT 上，DP 预训练策略已实现近 100% 成功率；此处主要使用 PushT 进行直观的方向可视化，而非性能提升。

直觉上，图 2 右面板可视化了当底层基础策略输出平面 (x, y) 动作时，PushT 上预测的 2D 方向场。

3.2.2 模型训练

奖励模型 R_ϕ 的训练目标是使其具备区分两个候选动作优劣的能力。在 RoVer 中，若一个动作与专家动作的均方根误差（RMSE）距离小于另一个，则认为该动作更优。为准备训练数据，首先分析策略动作 A_p 与专家动作样本 A_e 之间的分布差距（附录 A.2）。基于该分析，设定基础噪声尺度 $\sigma_{\text{base}} = 0.1$ ，用于构造锚动作 a_{anc} 。给定专家演示 $h, a_e = [a_e^{\text{pose}}, g_e]$ ，随后在 a_e 周围构造局部动作元组，以获得信息丰富的偏好标签和方向监督。

方向引导与锚中心采样 在早期实验中，观察到仅在 a_e 周围采样带噪专家动作 a_{en} 性能较差。为更好地模拟测试时采样行为，引入锚动作的概念。通过在 6D 姿态子空间（针对 CALVIN）扰动专家动作来构造锚噪声：

$$a_{\text{anc}}^{\text{pose}} = a_e^{\text{pose}} + \mathbf{n}, \quad \mathbf{n} \sim \mathcal{N}(\mathbf{0}, \sigma_{\text{base}}^2 I_6), \quad g_{\text{anc}} = g_e. \quad (3)$$

然后定义从锚动作到专家动作的真值方向向量：

$$u_{\text{gt}} = \frac{a_e^{\text{pose}} - a_{\text{anc}}^{\text{pose}}}{\|a_e^{\text{pose}} - a_{\text{anc}}^{\text{pose}}\|_2} \in \mathbb{R}^6. \quad (4)$$

利用 u_{gt} ，定义正交超平面

$$\mathcal{H} = \{a \in \mathbb{R}^6 \mid (a - a_{\text{anc}}^{\text{pose}})^\top u_{\text{gt}} = 0\} \quad (5)$$

将空间划分为两个半空间：

$$\mathcal{H}^+ = \{a \in \mathbb{R}^6 \mid (a - a_{\text{anc}}^{\text{pose}})^\top u_{\text{gt}} > 0\}, \quad (6)$$

$$\mathcal{H}^- = \{a \in \mathbb{R}^6 \mid (a - a_{\text{anc}}^{\text{pose}})^\top u_{\text{gt}} < 0\}. \quad (7)$$

Let $d_0 = \sqrt{\frac{1}{6} \|a_e^{\text{pose}} - a_{\text{anc}}^{\text{pose}}\|_2^2}$ 为 a_{anc} 与 a_e 在六维姿态子空间中的均方根误差距离。本文定义自适应噪声尺度为

$$\sigma_{\text{adapt}} = \text{clip}(k d_0, \sigma_{\text{min}}, \sigma_{\text{base}}), \quad k > 0, \sigma_{\text{min}} > 0, \quad (8)$$

以控制候选动作在 a_{anc} 周围的散布。在实现中，本文采样 $\epsilon_b, \epsilon_w \sim \mathcal{N}(\mathbf{0}, \sigma_{\text{adapt}}^2 I_6)$ 并将其投影到正确的半空间：

$$\text{better: if } \epsilon_b^\top u_{\text{gt}} \leq 0, \epsilon_b \leftarrow -\epsilon_b; \quad \text{worse: if } \epsilon_w^\top u_{\text{gt}} \geq 0, \epsilon_w \leftarrow -\epsilon_w. \quad (9)$$

This yields

$$a_{\text{better}}^{\text{pose}} = a_{\text{anc}}^{\text{pose}} + \epsilon_b, \quad a_{\text{worse}}^{\text{pose}} = a_{\text{anc}}^{\text{pose}} + \epsilon_w \quad (10)$$

夹爪状态继承自 a_{anc} 。通过构造， a_{better} 比 a_{anc} 更可能靠近专家动作，而 a_{worse} 则更远。

监督与目标 从每个以锚点为中心的元组 { 锚点, 较好, 较差 } 中，本文监督两个信号。对于方向监督，从采样动作 a_x 指向专家的真实单位向量为

$$u_{\text{gt}}(a_e, a_x) = \frac{a_e^{\text{pose}} - a_x^{\text{pose}}}{\|a_e^{\text{pose}} - a_x^{\text{pose}}\|_2}. \quad (11)$$

Let $\hat{u}$ $(d_\phi(h, a_x)) =$ 归一化表示预测方向。本文最小化余弦偏差

$$\mathcal{L}_{\text{dir}} = \mathbb{E}[1 - \langle \hat{u}, u_{\text{gt}} \rangle], \quad (12)$$

在元组中所有采样动作上取平均。对于奖励监督，令 $r(a) = R_\phi(h, a)$ 表示过程奖励模型分数。对于元组内每一有序对 $i \succ j$ ，其中 a_i 比 a_j 更接近专家动作，本文应用布拉德利-特里偏好损失 (Bradley & Terry, 1952)：

$$\mathcal{L}_{\text{rew}}(i \succ j) = -\log \sigma(r(a_i) - r(a_j)), \quad (13)$$

并将 $\mathcal{L}_{\text{rew}}$ 定义为所有此类对的平均值。

最终训练目标结合了这两项：

$$\mathcal{L}_{\text{total}} = \lambda_{\text{dir}} \mathcal{L}_{\text{dir}} + \lambda_{\text{rew}} \mathcal{L}_{\text{rew}}, \quad (14)$$

其中 λ_{dir} 和 λ_{rew} 平衡两种损失。我们在优化过程中使用标准梯度裁剪。对于验证，我们跟踪余弦对齐、角度误差以及 PRM 分数相对于动作-专家距离的单调性。

3.2.3 方向引导的测试时扩展

在推理时，RoVer 通过将策略动作扩展为候选动作集，并在 PRM 下选择最佳动作来增强冻结的 VLA 策略。与训练的关键区别在于，候选动作是从策略动作 a_p 生成的，而不是从专家动作 a_e 生成的，并且仅在预测方向 $\hat{u}$ 的引导下探索动作空间的“更好”一侧。我们实现了两种采样策略并进行比较：**i)** 随机采样：在没有引导的情况下用高斯噪声扰动 a_p ；**ii)** 方向引导采样：通过沿 PRM 预测方向采样来扩展 a_p 。

该过程将额外的测试时计算转化为改进的动作选择。随机采样探索范围广但效率低，而方向引导采样利用 PRM 的预测方向将候选集中在有前景的区域，在相同预算下产生更好的性能。

4 实验

我们在仿真和真实机器人平台上评估 RoVer。对于仿真，我们采用 ABC $\rightarrow$ D 设置下的 CALVIN 基准：模型在三个环境 (A、B、C) 中训练，并在未见过的环境 (D) 中测试。我们选择了来自 VLA 研究不同阶段的三个代表性最先进基线——GR-1 (Wu 等人, 2023)、Dita (Hou 等人, 2025) 和 MoDE (Reuss 等人, 2025)——以证明 RoVer 持续改进不同容量的策略。对于真实机器人实验，我们使用扩散策略 (DP) (Chi 等人, 2024; 2023) 作为基础策略，并展示 RoVer 也增强了物理操作任务的性能。

4.1 CALVIN 基准实验

CALVIN 是一个广泛使用的仿真基准，用于长时程机器人操作 (Mees 等人, 2022)。它提供了具有语言条件任务的多阶段环境，能够评估技能组合和对未见配置的泛化能力。ABC $\rightarrow$ D 划分尤其具有挑战性，因为它要求模型在三个训练环境 (A、B、C) 中训练后，迁移到一个留出的环境 (D)。

表 1: CALVIN 基准在 $ABC \rightarrow D$ 划分上的结果。列报告了连续完成 k 个任务的概率和平均链长。所有基线数字均取自官方排行榜 (<http://calvin.cs.uni-freiburg.de/>)，GR-1*除外。GR-1 基线在排行榜上报告的平均链长为 3.06，但在我们的本地复现中观察到更强的性能（平均链长 3.19）；因此，我们报告本地评估的 GR-1*作为基础策略。† 表示在相应基础策略之上应用 RoVer 测试时缩放所达到的最佳性能。

Method	1	2	3	4	5	Avg. Len.
GR-1*	85.1	73.7	63.2	53.7	43.4	3.19
3D Diffuser Actor	92.2	78.7	63.9	51.2	41.2	3.27
GR-1†	86.1	75.3	66.8	56.2	48.7	3.33
Dita	94.5	82.5	72.8	61.3	50.0	3.61
RoboUniView	94.2	84.2	73.4	62.2	50.7	3.64
GHIL-Glue	95.2	88.5	73.2	62.5	49.8	3.69
Dita†	94.8	83.2	76.8	70.0	59.2	3.84
MoDE	96.2	88.9	81.1	71.8	63.5	4.01
MoDE†	97.1	90.9	82.5	74.9	66.6	4.12




图 3: 方向引导的测试时缩放: 平均链长与 $N+M$ (N 策略提议、 M 引导扩展的关系。面板对应于 GR-1、Dita 和 MoDE。红色: 无引导 (随机) 扩展; 蓝色: 方向引导 (DG)。由于 Q2 中讨论的块-步不匹配, MoDE 显示出广泛但不稳定的增益。

实验设置: 对于 RoVer, 我们重用 GR-1 骨干架构作为验证器, 将原始动作标记替换为奖励标记和方向标记。总参数规模为 0.2B, 仅 40M 参数可训练——其余参数从 MAE 和 CLIP 文本编码器冻结。奖励模型在 CALVIN $ABC \rightarrow D$ 训练划分上训练 100 个训练轮次, 我们使用最终检查点对所有骨干进行评估。重要的是, 我们仅采样 20% 的训练集, 表明 RoVer 在训练上也是高效的。我们研究以下问题:

Q1 (骨干无关的增益): RoVer 是否一致地改进不同的预训练基线 (GR-1、Dita、MoDE; 以及真实机器人上的 DP)? **Q2 (缩放和采样效率):** 性能如何随策略提议数量 N 和每个提议的引导扩展预算 M 而扩展; 在固定候选预算 $K=N+M$ 下, 方向引导采样是否比无引导高斯扩展更有效? **Q3 (推理效率):** 共享感知缓存是否摊销计算并提高测试时的吞吐量/延迟?

基线方法: 本文总结三种基线方法, 并重点说明将其与 RoVer 集成时的测试时注意事项。除非另有说明, RoVer 对所有骨干网络采用统一的候选处理方式: (i) 仅在 6D 手臂姿态分量中注入扩展噪声; (ii) 夹爪维度不加噪, 通过对 N 个基础提议进行简单投票来选择; (iii) 感知特征每步预编码一次 (预编码), 并在所有候选中复用。

GR-1 (Wu 等, 2023) 是一种 GPT 风格的轨迹模型, 以多视角 RGB 和语言为条件, 自回归地预测末端执行器增量 (6D 手臂姿态增量加一个夹爪标量)。在推理时, 每个控制步采样 N 个随机提议, 可选地在 PRM 预测方向周围的有界角度区域内扩展每个动作, 并由 PRM 对所有候选进行排序。由于 GR-1 原生使用世界坐标系增量, 无需额外的坐标系转换。




图 4: GR-1: SR@k ($k=1 \dots 5$) 随 N (策略提议数) 的变化。增加 N 在所有 k 上均提升成功率, 揭示了提议多样性的价值; 结合图 3, 表明在非平凡的 N 之上加入方向引导扩展 M 可带来进一步增益。

表 2: 有无共享感知缓存的推理效率。每步缓存一次感知特征可显著降低每控制步延迟; 加速比随候选数量增加而增大。

#Actions	w/o cache (s)	w cache (s)	Speedup ($\times$)	Per-action (ms)
10	0.4140	0.0929	4.46	9.29
100	4.1400	0.6174	6.71	6.17
1000	41.4748	5.7384	7.23	5.74
10000	418.1795	58.2168	7.18	5.82

Dita (Hou 等, 2025) 是一种扩散 Transformer 策略, 在局部末端执行器坐标系中预测相对运动 (位置和欧拉角增量), 并使用当前末端执行器姿态将其转换为世界坐标系增量。在 RoVer 下, 首先在局部坐标系采样 N 个策略动作, 将每个动作转换为世界坐标系动作, 然后在世界坐标系中执行噪声扩展, 以与 PRM 的世界坐标系方向引导对齐。

MoDE (Reuss 等, 2025) 是一种具有专家混合去噪器的扩散 Transformer, 输出短动作块 (未来动作序列)。在使用 RoVer 进行测试时扩展时, 采样多个候选块, 并通过评分每个块的第一个动作 (可选地对其 6D 手臂分量进行方向引导扩展后) 与 PRM 交互, 以选择执行动作。其他块执行策略是正交的, 此处省略。

问题 1: 骨干无关的增益 在不重新训练基础策略的情况下, 将相同的 RoVer 验证器插入不同的骨干网络可带来一致的改进 (表 1)。就平均链长而言, GR-1 从 3.19 提升至 3.33, Dita 从 3.61 提升至 3.84, MoDE 从 4.01 提升至 4.12。就长程成功率 (SR@5) 而言, GR-1 从 41.5% 上升至 48.7% (+17.4%), 而 Dita 从 50.0% 上升至 59.2% (+18.4%)。

问题 2: 方向引导的测试时扩展 我们在统一的计算视角下研究扩展: 给定总候选预算 $K=N+M$ (策略提议 N 和方向引导扩展 M), 性能通常随 K 增加而提升, 且方向引导 (DG) 通过聚焦探索进一步提高了样本效率。实验表明 (图 3 和图 4), 增加 N 首先通过多样化策略模式在小预算下带来较大增益; 随后加入适度的 M 可进一步细化有前景的提议并带来额外改进。在相同 K 下, DG 在 GR-1 和 Dita 上均可可靠地优于无引导的高斯扩展, 这与方向头部的预期作用一致。

然而, 对于 MoDE, 在所有设置下增益并非始终更高 (图 3 右图)。我们将此归因于块-步不匹配: MoDE 输出短动作块, 而我们的 PRM 是按时间步训练和应用的。为保持统一的评估流程, 我们仅扩展并评分每个块的第一个动作, 然后执行所选块; 块内后续步骤未获得进一步引导。这限制了我们干预块内动作的能力, 并可能随着 $N+M$ 增加产生非单调趋势。尽管如此, 该方法仍然有效——大多数 $N+M$ 设置仍显示出正向改进。

问题 3: 共享感知缓存的影响 我们通过测量在不断增加候选预算下每个控制步的墙钟延迟来评估跨候选缓存感知特征的影响。如表 2 所示, 缓存显著降低了每步延迟, 且加速比随候选数量增加而增长: 对于 10 个候选, 延迟从 0.414 秒降至 0.0929 秒 (4.46 $\times$); 对于 100 和 1000 个候选, 加速比分别达到 6.71 $\times$ 和 7.23 $\times$ 。使用缓存后,




图 5：左：真实机器人实验可视化。右：评估中使用的双臂 Dobot 测试平台。

表 3：真实机器人结果：成功率（%）。每个条目为每种条件下 10 次试验的计算结果。

Method	Pick and place			Push button		Stack bowls		Avg.
	Seen	Unseen object	Unseen position	Seen	Unseen position	Seen	Unseen position	
DP	100%	90%	50%	100%	50%	80%	40%	72.9%
DP [†]	100%	100%	70%	100%	80%	100%	70%	88.6%

单次动作成本稳定在 5.7 – 6.2 毫秒左右（例如，100 个候选时为 6.17 毫秒，1000 个候选时为 5.74 毫秒），使得在单次感知编码下候选数量近似线性扩展。这些结果验证了通过共享感知缓存摊销感知成本对于测试时扩展效率至关重要。所有延迟测量均在单个 NVIDIA V100 图形处理器上完成。

4.2 真实机器人实验

我们在双臂 Dobot 平台上评估 RoVer（图 5）。由于任务为单臂操作，左臂保持静止，右臂执行动作。感知同时使用右臂的眼在手腕相机和顶视第三人称相机。我们考虑三个操作任务——抓取放置、按压按钮和叠碗——每个任务均在已见、未见物体和未见位置条件下评估。具体而言：抓取放置要求抓取一个小型家居物品并将其放置到指定位置；按压按钮要求移动到面板按钮并触发；叠碗要求将一个碗正确对齐地叠放在另一个碗上。如表 3 所示，RoVer (DP[†]) 在已见场景中与 DP 相当，同时在泛化方面提供明显提升。

5 结论

RoVer 是一种外部测试时扩展框架，通过引入紧凑的过程奖励模型对候选动作进行评分和方向引导，从而升级冻结的视觉语言动作策略。无需重新训练骨干网络，RoVer 在不同策略上持续提升性能（问题 1），在候选预算下有效扩展——尤其在方向引导下（问题 2）——并通过共享感知缓存实现显著推理加速（问题 3）。尽管仍存在局限性（例如，分块策略的步骤-块不匹配以及使用专家接近度作为监督代理），RoVer 表明将计算从训练重新分配到推理可以可靠地释放具身策略的额外能力，而无需额外的预训练或数据。

伦理声明

我们的工作仅涉及机器人仿真和真实机器人实验，不包含人类或动物受试者。所有数据集均来自机器人操作试验，不包含任何个人信息。所提出的方法旨在用于具身智能和机器人学的学术研究。我们未发现直接的滥用风险，但与任何通用学习方法一样，在安全关键或对抗性环境中部署时建议谨慎。

可复现性声明

我们在正文和附录中提供了模型架构、训练流程和评估协议的详细描述。超参数、网络规模和任务设置均在正文和表格中说明。额外的训练细节、数据处理步骤和评估脚本将在论文接收后开源。

参考文献

- AgiBot-World-Contributors, Qingwen Bu, Jisong Cai, et al. Agibot world colosseo: A large-scale manipulation platform for scalable and intelligent embodied systems, 2025. URL <https://arxiv.org/abs/2503.06669>.
- Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, et al. π_0 : A vision-language-action flow model for general robot control, 2024. URL <https://arxiv.org/abs/2410.24164>.
- R. A. Bradley and M. E. Terry. Rank analysis of incomplete block designs: I. the method of paired comparisons. *Biometrika*, 39(3-4):324–345, 1952. doi: 10.1093/biomet/39.3-4.324.
- Qingwen Bu, Hongyang Li, Li Chen, Jisong Cai, Jia Zeng, Heming Cui, Maoqing Yao, and Yu Qiao. Towards synergistic, generalized, and efficient dual-system for robotic manipulation, 2025a. URL <https://arxiv.org/abs/2410.08001>.
- Qingwen Bu, Yanting Yang, Jisong Cai, Shenyuan Gao, Guanghui Ren, Maoqing Yao, Ping Luo, and Hongyang Li. Univla: Learning to act anywhere with task-centric latent actions, 2025b. URL <https://arxiv.org/abs/2505.06111>.
- Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin Burchfiel, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. In *Proceedings of Robotics: Science and Systems (RSS)*, 2023.
- Cheng Chi, Zhenjia Xu, Siyuan Feng, Eric Cousineau, Yilun Du, Benjamin Burchfiel, Russ Tedrake, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. *The International Journal of Robotics Research*, 2024.
- Open X-Embodiment Collaboration, Abby O’Neill, Abdul Rehman, et al. Open X-Embodiment: Robotic learning datasets and RT-X models. <https://arxiv.org/abs/2310.08864>, 2023.
- Can Cui, Pengxiang Ding, Wenxuan Song, Shuanghao Bai, Xinyang Tong, Zirui Ge, Runze Suo, Wanqi Zhou, Yang Liu, Bofang Jia, Han Zhao, Siteng Huang, and Donglin Wang. Openhelix: A short survey, empirical analysis, and open-source dual-system vla model for robotic manipulation, 2025. URL <https://arxiv.org/abs/2505.03912>.
- DeepSeek-AI. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning, 2025. URL <https://arxiv.org/abs/2501.12948>.
- Yao Mu Fourier ActionNet Team. Actionnet: A dataset for dexterous bimanual manipulation. 2025.
- Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners, 2021. URL <https://arxiv.org/abs/2111.06377>.
- Zhi Hou, Tianyi Zhang, Yuwen Xiong, Haonan Duan, Hengjun Pu, Ronglei Tong, Chengyang Zhao, Xizhou Zhu, Yu Qiao, Jifeng Dai, and Yuntao Chen. Dita: Scaling diffusion transformer for generalist vision-language-action policy. *arXiv preprint arXiv:2503.19757*, 2025.

-
- Yuheng Ji, Huajie Tan, Jiayu Shi, Xiaoshuai Hao, Yuan Zhang, Hengyuan Zhang, Pengwei Wang, Mengdi Zhao, Yao Mu, Pengju An, et al. Robobrain: A unified brain model for robotic manipulation from abstract to concrete. *arXiv preprint arXiv:2502.21257*, 2025.
- Daniel Kahneman. *Thinking, Fast and Slow*. Farrar, Straus and Giroux, New York, 2011.
- Jared Kaplan, Sam McCandlish, Tom Henighan, Tom B Brown, Benjamin Chess, Rewon Child, Scott Gray, Alec Radford, Jeffrey Wu, and Dario Amodei. Scaling laws for neural language models. *arXiv preprint arXiv:2001.08361*, 2020.
- Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, et al. Openvla: An open-source vision-language-action model, 2024. URL <https://arxiv.org/abs/2406.09246>.
- Jacky Kwok, Christopher Agia, Rohan Sinha, Matt Foutter, Shulu Li, Ion Stoica, Azalia Mirhoseini, and Marco Pavone. Robomongo: Scaling test-time sampling and verification for vision-language-action models, 2025. URL <https://arxiv.org/abs/2506.17811>.
- Fanqi Lin, Ruiqian Nai, Yingdong Hu, Jiacheng You, Junming Zhao, and Yang Gao. Onetwovla: A unified vision-language-action model with adaptive reasoning, 2025. URL <https://arxiv.org/abs/2505.11917>.
- Jiaming Liu, Hao Chen, Pengju An, Zhuoyang Liu, Renrui Zhang, Chenyang Gu, Xiaoqi Li, Ziyu Guo, Sixiang Chen, Mengzhen Liu, Chengkai Hou, Mengdi Zhao, KC alex Zhou, Pheng-Ann Heng, and Shanghang Zhang. Hybridvla: Collaborative diffusion and autoregression in a unified vision-language-action model, 2025a. URL <https://arxiv.org/abs/2503.10631>.
- Runze Liu, Junqi Gao, Jian Zhao, Kaiyan Zhang, Xiu Li, Biqing Qi, Wanli Ouyang, and Bowen Zhou. Can 1b llm surpass 405b llm? rethinking compute-optimal test-time scaling, 2025b. URL <https://arxiv.org/abs/2502.06703>.
- Songming Liu, Lingxuan Wu, Bangguo Li, Hengkai Tan, Huayu Chen, Zhengyi Wang, Ke Xu, Hang Su, and Jun Zhu. Rdt-1b: a diffusion foundation model for bimanual manipulation, 2025c. URL <https://arxiv.org/abs/2410.07864>.
- Nanye Ma, Shangyuan Tong, Haolin Jia, Hexiang Hu, Yu-Chuan Su, Mingda Zhang, Xuan Yang, Yandong Li, Tommi Jaakkola, Xuhui Jia, and Saining Xie. Inference-time scaling for diffusion models beyond scaling denoising steps, 2025. URL <https://arxiv.org/abs/2501.09732>.
- Oier Mees, Lukas Hermann, Erick Rosete-Beas, and Wolfram Burgard. Calvin: A benchmark for language-conditioned policy learning for long-horizon robot manipulation tasks. *IEEE Robotics and Automation Letters (RA-L)*, 7(3):7327–7334, 2022.
- NVIDIA, :, Johan Bjorck, Fernando Castañeda, et al. Gr00t n1: An open foundation model for generalist humanoid robots, 2025. URL <https://arxiv.org/abs/2503.14734>.
- OpenAI, :, Aaron Jaech, Adam Kalai, Adam Lerer, et al. Openai o1 system card, 2024. URL <https://arxiv.org/abs/2412.16720>.
- Alec Radford, Jeff Wu, Rewon Child, David Luan, Dario Amodei, and Ilya Sutskever. Language models are unsupervised multitask learners. 2019.
- Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision, 2021. URL <https://arxiv.org/abs/2103.00020>.
- Moritz Reuss, Jyothish Pari, Pulkit Agrawal, and Rudolf Lioutikov. Efficient diffusion transformer policies with mixture of expert denoisers for multitask learning. In *The Thirteenth International Conference on Learning Representations*, 2025. URL <https://openreview.net/forum?id=nDmwloEl3N>.

-
- Yide Shentu, Philipp Wu, Aravind Rajeswaran, and Pieter Abbeel. From llms to actions: Latent codes as bridges in hierarchical robot control, 2025. URL <https://arxiv.org/abs/2405.04798>.
- Haoming Song, Delin Qu, Yuanqi Yao, Qizhi Chen, Qi Lv, Yiwen Tang, Modi Shi, Guanghui Ren, Maoqing Yao, Bin Zhao, Dong Wang, and Xuelong Li. Hume: Introducing system-2 thinking in visual-language-action model, 2025. URL <https://arxiv.org/abs/2505.21432>.
- Qi Sun, Pengfei Hong, Tej Deep Pala, Vernon Toh, U-Xuan Tan, Deepanway Ghosal, and Soujanya Poria. Emma-x: An embodied multimodal action model with grounded chain of thought and look-ahead spatial reasoning, 2024. URL <https://arxiv.org/abs/2412.11974>.
- Yuqi Wang, Xinghang Li, Wenxuan Wang, Junbo Zhang, Yingyan Li, Yuntao Chen, Xinlong Wang, and Zhaoxiang Zhang. Unified vision-language-action model, 2025. URL <https://arxiv.org/abs/2506.19850>.
- Zhiqiang Wang, Hao Zheng, Yunshuang Nie, Wenjun Xu, Qingwei Wang, Hua Ye, Zhe Li, Kaidong Zhang, Xuewen Cheng, Wanxi Dong, Chang Cai, Liang Lin, Feng Zheng, and Xiaodan Liang. All robots in one: A new standard and unified dataset for versatile, general-purpose embodied agents, 2024. URL <https://arxiv.org/abs/2408.10899>.
- Hongtao Wu, Ya Jing, Chilam Cheang, Guangzeng Chen, Jiafeng Xu, Xinghang Li, Minghuan Liu, Hang Li, and Tao Kong. Unleashing large-scale video generative pre-training for visual robot manipulation, 2023. URL <https://arxiv.org/abs/2312.13139>.
- Michał Zawalski, William Chen, Karl Pertsch, Oier Mees, Chelsea Finn, and Sergey Levine. Robotic control via embodied chain-of-thought reasoning, 2025. URL <https://arxiv.org/abs/2407.08693>.
- Yanjie Ze, Gu Zhang, Kangning Zhang, Chenyuan Hu, Muhan Wang, and Huazhe Xu. 3d diffusion policy: Generalizable visuomotor policy learning via simple 3d representations, 2024. URL <https://arxiv.org/abs/2403.03954>.
- Jianke Zhang, Yanjiang Guo, Xiaoyu Chen, Yen-Jen Wang, Yucheng Hu, Chengming Shi, and Jianyu Chen. Hirt: Enhancing robotic control with hierarchical robot transformers, 2025. URL <https://arxiv.org/abs/2410.05273>.
- Qingqing Zhao, Yao Lu, Moo Jin Kim, Zipeng Fu, Zhuoyang Zhang, Yecheng Wu, Zhaoshuo Li, Qianli Ma, Song Han, Chelsea Finn, Ankur Handa, Ming-Yu Liu, Donglai Xiang, Gordon Wetstein, and Tsung-Yi Lin. Cot-vla: Visual chain-of-thought reasoning for vision-language-action models, 2025. URL <https://arxiv.org/abs/2503.22020>.
- Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware, 2023. URL <https://arxiv.org/abs/2304.13705>.
- Zhongyi Zhou, Yichen Zhu, Minjie Zhu, Junjie Wen, Ning Liu, Zhiyuan Xu, Weibin Meng, Ran Cheng, Yaxin Peng, Chaomin Shen, and Feifei Feng. Chatvla: Unified multimodal understanding and robot control with vision-language-action model, 2025. URL <https://arxiv.org/abs/2502.14420>.

A 附录

A.1 大语言模型的使用

大语言模型（LLMs）未参与所提方法的设计、实现或评估。它们在本工作中的唯一用途是提供轻微的语言辅助，例如润色写作风格和提高稿件的可读性。所有技术思想、实验和分析完全由作者构思和完成。

A.2 动作分布分析

为了校准偏好奖励模型（PRM）和我们的测试时采样所使用的扰动尺度，我们量化了策略动作 A_p 与专家动作 A_e 在 CALVIN 验证集上的分布差距。按照 GR-1 中的分析脚本（可视化三维偏差及其投影），我们收集每步偏差 $\Delta a = A_p - A_e$ ，并总结平移（XYZ）的逐坐标统计量以及欧氏距离 $\|\Delta a_{xyz}\|_2$ 。

聚合统计的主要发现如下：

- 近零偏差：所有轴上的平均平移偏差都很小（X/Y/Z: 0.0009/0.0048/-0.0013 米）。中位数同样接近零。
- 各向异性散布：标准差为（X/Y/Z: 0.184/0.116/0.165 米），表明沿 Y 轴的散布略紧，沿 X 轴和 Z 轴的尾部更宽。
- 重尾距离：欧氏距离的平均值为 0.215 米，中位数为 0.170 米，具有长尾（最小值 0.003 米，最大值 1.708 米）。这与可视化结果一致，即大多数样本聚集在 origin 附近，少数样本为较大的离群值。

对训练和采样的启示。我们设置了一个保守的基础噪声尺度 $\sigma_{\text{base}} = 0.1$ ，用于构建以锚点为中心的对：它小于策略-专家差距的中位数（0.17 米），这（i）使大多数合成的“更好/更差”对保持在策略提议附近的流形上，并且（ii）避免用罕见、远离的离群值过度惩罚验证器。在测试时，相同的尺度作为围绕策略动作进行候选扩展的初始半径；我们将其与来自 PRM 的方向引导相结合，使样本偏向专家流形，同时保持多样性。

结合定性的 3D 散点图和投影图，该分析支持我们选择一个小但非平凡的扰动半径，并推动了本文中使用的方向感知、以锚点为中心的采样方法。

A.3 实现细节

使用动作放大器稳定训练 在 PRM 的早期训练中，我们观察到一种退化现象：奖励头在输入上几乎坍塌为恒定输出，损失趋于平稳。我们的假设是，强大的冻结骨干网络（从 GR-1 初始化）主导了特征融合，导致动作嵌入中的微小差异被衰减，从而为奖励头提供了微弱的梯度。因此，我们引入了一个动作放大器——一个轻量级的 MLP $H \rightarrow 2H \rightarrow H$ ，带有 GELU 和 LayerNorm——放置在动作嵌入之后、令牌融合之前。这重新调整了动作通道，保留了邻近候选之间的细粒度差异，并恢复了有用的梯度。添加放大器后，训练变得稳定，损失可靠地下降。

基于锚点的动态采样用于鲁棒偏好学习 使用单一固定噪声尺度在专家动作周围生成噪声动作对，导致训练分布狭窄且测试时扩展效果欠佳。为了在匹配测试时行为的同时丰富监督信号，我们采用以锚点为中心的动态方案（见第 3.2 节）：(i) 在 6D 位姿子空间中对专家动作添加基础高斯噪声，采样一个锚点动作；(ii) 计算从锚点指向专家的真实方向 u_{gt} ，并定义正交超平面；(iii) 使用以锚点-专家距离为上限的自适应噪声尺度，在两个半空间（“更好”和“更差”）中采样额外动作；(iv) 使用有序对上的布拉德利-特里偏好损失（更接近专家的动作被偏好）以及方向损失进行训练，方向损失使预测方向与 u_{gt} 对齐。在




图 6: GR-1 策略动作与专家动作之间分布差距的可视化。

Algorithm 1: RoVer Test-Time Scaling Framework

Input: Observation h , policy π_θ , verifier R_ϕ , number of policy actions N , expanded candidates M , angular bound α

Output: Final executed action a^*

1. Policy step: Query the base policy for N actions

$$\{a_p^1, a_p^2, \dots, a_p^N\} \leftarrow \pi_\theta(h)$$

2. Expansion step: For each policy action a_p^j , expand it into $\frac{M}{N}$ candidates:

Predict direction $\hat{u}^j = R_\phi(h, a_p^j).dir$ (dimension d_{dir} matches the action subspace)

For $k = 1, \dots, \frac{M}{N}$:

Sample random vector $v \sim \mathcal{N}(0, I_{d_{dir}})$, project $p = v - (v^\top \hat{u}^j) \hat{u}^j$, normalize $p \leftarrow p / \|p\|$.

Sample angle $\theta \sim \text{Unif}(0, \alpha)$ and magnitude $m \sim |\mathcal{N}(0, \sigma^2)|$.

Construct perturbation $\epsilon = m(\cos \theta \hat{u}^j + \sin \theta p)$.

Update candidate in the actionable subspace, leaving the discrete gripper unchanged when present.

Collect $\mathcal{A} = \{a_p^j\}_{j=1}^N \cup \{a_j^k\}_{j=1..N, k=1.. \frac{M}{N}}$

3. Encoding step: Compute shared perception features

$$z_{obs} \leftarrow f_{obs}(h) \quad (\text{pre_encode})$$

4. Candidate scoring: For each $a \in \mathcal{A}$

$$z_{act} \leftarrow f_{act}(a) \quad (\text{action_encode})$$

$$(r, d) \leftarrow R_\phi(z_{obs}, z_{act})$$

5. Action selection:

$$a^* \leftarrow \arg \max_{a \in \mathcal{A}} r(a)$$

return a^*

实践中，与使用固定尺度高斯对训练的模型相比，这产生了一个对方向引导的测试时扩展具有更好泛化能力的 PRM。

模型架构 验证器 R_ϕ 是一个轻量级的 GPT-2 风格变换器，带有冻结的 CLIP 文本编码器和 MAE 视觉编码器。感知器重采样器压缩图像令牌；机器人状态和 7D 动作被线性嵌入，动作放大器 MLP ($H \rightarrow 2H \rightarrow H$) 突出小的动作差异。两个学习到的查询令牌产生一个标量过程奖励和动作子空间中的归一化方向（通常在 CALVIN 上为 6D，在 PushT 上为 2D）。为了提高效率，我们拆分




图 7: PRM 的训练（左）和验证（右）日志。使用动作放大器后，损失稳定下降，奖励头避免了退化（恒定）输出。

表 4: 验证器架构超参数（关键=值）。

Key	Value
Hidden size	$H = 384$
Layers	12
Attention heads	12
FFN	$4H$
Dropout	0.1
Positions	1024
Seq. length	$L = 10$
Text encoder dim	$512 \rightarrow H$
Vision patch size	16
Resampler latents	9
Resampler depth	3
Resampler dim_head	128
Resampler heads	4
State dim	6 (pose) + 2 (one-hot gripper)
Action dim	7
Amplifier	$H \rightarrow 2H \rightarrow H$
Reward head	$H \rightarrow H/2 \rightarrow H/4 \rightarrow 1$
Direction head	$H \rightarrow H/2 \rightarrow d_{\text{dir}}$

计算过程被划分为共享的“预编码”步骤（感知/语言/状态）和快速的“动作编码”步骤（针对每个候选动作），从而在候选动作数量上实现近线性扩展。关键超参数总结于表 4。

A.4 CALVIN 基准

我们在 CALVIN 基准（Mees 等人，2022）上按照标准的 ABC $\rightarrow$ D 泛化设置进行评估：在环境 A、B 和 C 上训练奖励模型，并在未见过的环境 D 上进行评估。CALVIN 具有长时程、语言条件下的桌面操作任务，包含多物体场景和组合目标。每个回合配有一条自然语言指令；当指令行为在固定时间范围内完成时，记为成功（见图 8）。

任务集涵盖彩色方块的旋转与推动、抽屉和滑轨的开关、方块的提起/放置/堆叠/拆解、灯泡/LED 的开关，以及将方块推入抽屉。遵循各骨干网络的官方评估协议，对于 GR-1 和 MoDE，我们执行 1,000 多个步序列，每个序列包含 5 条语言指令；对于 Dita，执行 250 个序列。对于每个子任务，我们允许最多 360 个控制步骤，并在任务特定的判定器检测到完成时记为成功。



图 8: CALVIN 基准及 ABC $\rightarrow$ D 划分概览。