

SafeDiffuser: 基于扩散概率模型的安全规划


Wei Xiao*, Tsun-Hsuan Wang, Chuang Gan, Daniela Rus

Massachusetts Institute of Technology (MIT)

基于扩散模型的方法在数据驱动规划中展现出潜力，但缺乏安全保障，因此难以应用于安全关键型场景。为应对这些挑战，本文提出一种新方法，称为 SafeDiffuser，通过使用一类控制屏障函数确保扩散概率模型满足规范。该方法的核心思想是将所提出的有限时间扩散不变性嵌入去噪扩散过程，从而实现可信的扩散数据生成。此外，本文证明，通过生成模型实现的有限时间扩散不变性方法不仅保持了泛化性能，还增强了安全数据生成的鲁棒性。本文在一系列安全规划任务上测试了该方法，包括迷宫路径生成、腿式机器人运动以及三维空间操作，结果表明相较于普通扩散模型[†]，该方法在鲁棒性和保障性方面具有优势。

1. 引言

数据驱动方法因其表示灵活性而受到越来越多的关注。扩散模型 (Diffusion Model) Sohl-Dickstein 等人 (2015)、Ho 等人 (2020) 是数据驱动的生成模型，其主要应用在图像生成领域 Dhariwal 和 Nichol (2021)、Zhang 和 Du 等人 (2020b)、q(τⁱ|τⁱ⁻¹) Saharia 等人 (2022)。最近，被称为 (SafeDiffuser) 的扩散模型 Janner 等人 (2022) 在多种机器人任务的轨迹规划中展现出潜力。扩散模型支持灵活的行为综合，使其在新环境中具有良好的泛化能力。然而，在安全规划中，扩散器以当前状态和为目标为条件，从高斯噪声开始生成干净的规划轨迹，基于这些轨迹可得到控制策略。将该控制策略向前应用一步后，得到新状态，再次运行扩散过程以获得新的规划轨迹。重复此过程直到目标达成。然而，该方法的一个重大挑战是缺乏安全保证。例如，规划轨迹在迷宫中可能轻易违反安全约束 (如图 1 所示)。这一缺陷要求对扩散模型进行根本性修正，以图 1: 本文提出的 SafeDiffuser (下方) 能够生成具有保障的安全轨迹，而扩散器 (上方) 失败 (从 ⊙ 到 ⊗)。



* 通讯邮箱: weixy@mit.edu †视频可在匿名网站查看: <https://safediffuser.github.io/safediffuser/>

本文提出利用有限时间扩散不变性来确保扩散模型满足规范保证。不变集是一种规范形式，主要由规划任务中的安全约束组成。我们确保扩散模型对扩散过程中的不确定性具有不变性。通过将滚动时域控制与稳定扩散相结合来实现安全性。在滚动时域控制中，我们增量地计算安全路径。关键洞见在于用基于扩散的路径生成替代每次路径计算，从而能够更广泛地探索路径空间，并相对容易地纳入额外约束。计算得到的路径与仿真相结合，以验证其能够被安全执行。为确保扩散器具有规范保证，我们首先为去噪扩散过程建立扩散动力学。然后，利用基于李雅普诺夫的方法以及前向不变性性质，例如一类控制屏障函数（CBFs）Ames 等人（2017）、Glotfelter 等人（2017）、Nguyen 和 Sreenath（2016）、Xiao 和 Belta（2019），在扩散过程结束时正式保证规范的满足。控制屏障函数在利用机器人动力学进行规划时表现良好。然而，在扩散模型中这样做会带来额外挑战，因为生成的数据与机器人动力学没有直接关联，这使得控制屏障函数的使用并非易事。与现有文献不同，

1. 我们提出将不变性嵌入到扩散器的扩散时间中。因此，扩散器中需要有限时间不变性，因为轨迹初始为高斯噪声时规范通常会被违反。
2. 我们提出在不变性中加入扩散时间分量，以解决规划中突出的局部陷阱问题。
3. 我们提出一种二次规划方法，将有限时间扩散不变性融入扩散过程，以最大程度地保持性能。

总之，我们做出了以下新的贡献：

- 我们通过控制论意义上的不变性，为扩散概率模型提出形式化保证。
- 我们提出一种新颖的有限时间扩散不变性概念，并利用一类控制障碍函数将其纳入扩散过程的时间中。我们提出了三种不同的安全扩散器，并展示了如何解决规划任务中常见规范带来的局部陷阱问题。
- 我们在多种使用扩散模型的规划任务上验证了方法的有效性，包括迷宫中的安全规划、机器人运动与操作。

2. 预备知识

本节介绍扩散模型与控制论中前向不变性的背景知识。

扩散概率模型。 扩散概率模型（Diffusion Probabilistic Models）由 Sohl-Dickstein 等人（2015）、Ho 等人（2020）及 Janner 等人（2022）提出，属于潜变量模型，将数据生成过程表示为迭代去噪程序 $p_\theta(\tau^{i-1}|\tau^i), i \in \{1, \dots, N\}$ ，其中 $\tau^1, \dots, \tau^N$ 为与干净（无噪声）数据 $\tau^0 \sim q(\tau^0)$ 维度相同的隐变量， N 为总去噪步数。该去噪程序是正向扩散过程 $q(\tau^i|\tau^{i-1})$ 的逆过程，正向过程通过逐步添加噪声来逐渐破坏干净数据。去噪数据生成表示为

$$p_\theta(\tau^0) = \int p_\theta(\tau^{0:N}) d\tau^{1:N} = \int p(\tau^N) \prod_{i=1}^N p_\theta(\tau^{i-1}|\tau^i) d\tau^{1:N}, \quad (1)$$

其中 $p(\tau^N)$ 为标准高斯先验分布，联合分布 $p_\theta(\tau^{0:N})$ 定义为以 $p(\tau^N)$ 为起点的具有学习高斯转移的马尔可夫链。参数 θ 通过最小化逆过程负对数似然的常用变分下界进行优化： $\theta^* = \arg \min_\theta \mathbb{E}_{\tau^0}$ 前向扩散过程 $q(\tau^i|\tau^{i-1})$ 通常预先指定。逆过程通常参数化为具有时间相关均值和方差的高斯分布。

符号说明。 本文涉及两种“时间”：扩散过程的时间与规划时域的时间。我们使用上标（未指定时为 i ）表示轨迹（状态）的扩散时间，使用下标（未指定时为 k ）表示轨迹上状态的规划时间。例如， τ^0 表示去噪扩散时间步 0 处的规划轨迹（即无噪声轨迹）， x_k^0 表示去噪扩散时间步 0 期间规划时间步 k 处轨迹上的状态（即无噪声状态）。在无歧义时，我们也将记为 $x_k = x_k^0 (\tau = \tau^0)$ 。此外，轨迹 τ^i 定义为离散状态的规划时间序列，即 $\tau^i = (x_0^i, x_1^i, \dots, x_k^i, \dots, x_H^i)$ ，其中 $H \in \mathbb{N}$ 为规划时域。在去噪扩散过程中，扩散时间从 N 变化到 0，而规划时间从 0 变化到 H 。

控制理论中的前向不变性。 考虑如下形式的仿射控制系统：

$$\dot{x}_t = f(x_t) + g(x_t)u_t \quad (2)$$

其中 $x_t \in \mathbb{R}^n$, $f: \mathbb{R}^n \rightarrow \mathbb{R}^n$ 和 $g: \mathbb{R}^n \rightarrow \mathbb{R}^{n \times q}$ 是局部利普希茨连续的， $u_t \in U \subset \mathbb{R}^q$ ，其中 U 表示控制约束集。 $\dot{x}_t$ 表示状态 x_t 的（规划）时间导数。

定义 1。（集合不变性）：如果系统 (2) 从任意 $x_0 \in C$ 出发的某些 $u \in U$ 的解满足 $x_t \in C, \forall t \geq 0$ ，则集合 $C \subset \mathbb{R}^n$ 对于系统 (2) 是前向不变的。

定义 2。（扩展类 $\mathcal{K}$ 函数 Khalil (2002)）：利普希茨连续函数 $\alpha: [-b, a) \rightarrow (-\infty, \infty), b > 0, a > 0$ 属于扩展类 $\mathcal{K}$ ，如果它是严格递增的且 $\alpha(0) = 0$ 。

Consider a safety constraint $b(x_t) \geq 0$ for system (2), where $b: \mathbb{R}^n \rightarrow \mathbb{R}$ is continuously differentiable, we define a safe set in the form: $C := \{x_t \in \mathbb{R}^n : b(x_t) \geq 0\}$.

定义 3。（控制屏障函数 (Control Barrier Function, CBF) Ames 等人 (2017)）：函数 $b: \mathbb{R}^n \rightarrow \mathbb{R}$ 是一个 CBF，如果存在一个扩展类 $\mathcal{K}$ 函数 α ，使得

$$\sup_{u_t \in U} [L_f b(x_t) + [L_g b(x_t)]u_t + \alpha(b(x_t))] \geq 0, \quad (3)$$

对于所有 $x_t \in C$ 。 L_f , L_g 表示沿 f 和 g 关于 x 的李导数。

定理 1 (Ames 等人 (2017))。给定定义 3 中的 CBF $b(x_t)$ ，若 $x_0 \in C$ ，则任何满足 (3) 中约束的利普希茨连续控制器 u_t ， $\forall t \geq 0$ 使 C 对系统 (2) 前向不变。

如果我们需要沿动力学 (2) 对 $b(x_t)$ 多次求导，直到控制 u_t 显式出现，我们使用高阶 CBF (Nguyen 和 Sreenath (2016); Xiao 和 Belta (2019)) 作为 CBF 的一般形式来保证 (2) 的安全性。在这项工作中，我们将控制理论中的前向不变性映射到扩散模型中的有限时间扩散不变性，将 CBF 纳入扩散时间，而不是其在规划时间中的常规应用。此外，我们展示了如何解决扩散过程中的局部陷阱。

3. 安全扩散器

在本节中，我们提出三种不同的安全扩散器，以确保扩散中数据的安全生成，即确保满足规范 $b(x_k) \geq 0, \forall k \in \{0, \dots, H\}$ 。所提出的每种安全扩散器都有其自身的灵活性，例如避免规划中的局部陷阱。我们在后续考虑离散化的系统状态。连续规划时间中的安全性可以通过使用其他 CBF 的下层分层控制框架来保证，如 Ames 等人 (2017); Nguyen 和 Sreenath (2016); Xiao 和 Belta (2019) 所述。

在去噪扩散过程中，由于学习到的高斯转移从 $p(\mathbf{x}^N) \sim \mathcal{N}(0, \mathbf{I})$ 开始，规范很可能最初被违反，即 $\exists k \in \{0, \dots, H\}, b(\mathbf{x}_k^N) < 0$ 。为了安全的数据生成，我们希望有 $b(\mathbf{x}_k^0) \geq 0$ (i.e., $b(\mathbf{x}_k) \geq 0$), $\forall k \in \{0, \dots, H\}$ 。由于最大去噪扩散步数 N 是有限的，这需要在有限的扩散时间步内得到保证。因此，我们提出扩散过程的有限时间扩散不变性如下：

定义 4 (有限时间扩散不变性)。若存在 $i \in \{0, \dots, N\}$ 使得 $b(\mathbf{x}_k^i) \geq 0, \forall k \in \{0, \dots, H\}, \forall j \leq i$ ，则去噪扩散过程 $p_\theta(\tau^{i-1} | \tau^i), i \in \{1, \dots, N\}$ 关于规范 $b(\mathbf{x}_k) \geq 0, \forall k \in \{0, \dots, H\}$ 是有限时间扩散不变的。

上述定义可解释为：若 $b(\mathbf{x}_k^N) \geq 0, k \in \{0, \dots, H\}$ ，则要求 $b(\mathbf{x}_k^i) \geq 0, \forall i \in \{0, \dots, N\}$ （类似于定义 1 中的前向不变性）；否则，要求 $b(\mathbf{x}_k^j) \geq 0, \forall j \in \{0, \dots, i\}, i \in \{0, \dots, N\}$ ，其中 i 为有限扩散时间。

在下文中，我们提出三种不同方法以实现有限时间扩散不变性。第一种方法是安全扩散器的一般形式，另外两种是解决规划中局部陷阱的变体。

3.1. 鲁棒安全扩散器

在每个扩散步骤中考虑安全去噪扩散过程。根据 (1)，扩散时间 $j \in \{0, \dots, N-1\}$ 处的数据生成由下式给出：

$$p_\theta(\tau^j) = \int p(\tau^N) \prod_{i=j+1}^N p_\theta(\tau^{i-1} | \tau^i) d\tau^{j+1:N} \quad (4)$$

样本 $\tau^j, j \in \{0, \dots, N-1\}$ 遵循 (4) 中的数据分布，即我们有

$$\tau^j \sim p_\theta(\tau^j). \quad (5)$$

去噪扩散动力学则由下式给出：

$$\dot{\tau}^j = \lim_{\Delta\tau \rightarrow 0} \frac{\tau^j - \tau^{j+1}}{\Delta\tau} \quad (6)$$

其中 $\dot{\tau}$ 是 (扩散) 时间导数 $\dot{\tau}$ 。 $\Delta\tau > 0$ 是实现过程中足够小的扩散时间步长，并且 τ^{j+1} 可从上一个扩散步骤获得。为了在扩散过程中施加有限时间扩散不变性，我们希望使扩散动力学 (6) 可控。我们将 (6) 重新表述为

$$\dot{\tau}^j = \mathbf{u}^j, \quad (7)$$

其中 $\mathbf{u}^j$ 是与 τ^j 维度相同的控制变量。另一方面，我们希望 $\mathbf{u}^j$ 保持接近，以最大程度地保留扩散模型 $\frac{\tau^j - \tau^{j+1}}{\Delta\tau}$ 型的性能。上述模型可以按照轨迹上的每个状态重写为 $\tau^j: \dot{\mathbf{x}}_k^j = \mathbf{u}_k^j$ ，其中 $\mathbf{u}_k^j$ 是 k^{th} 的第 $\mathbf{u}^j$ 个分量。

然后，我们可以定义控制障碍函数 (CBF) 以确保在有限扩散时间内满足 $b(\mathbf{x}_k^j) \geq 0$ ：
 $h(\mathbf{u}_k^j | \mathbf{x}_k^j) := \frac{db(\mathbf{x}_k^j)}{d\mathbf{x}_k^j} \mathbf{u}_k^j + \alpha(b(\mathbf{x}_k^j)) \geq 0, k \in$ ，其中 $\alpha(\cdot)$ 是扩展类 $\mathcal{K}$ 函数。我们有以下定理来证明有限时间扩散不变性 (证明见附录)：




图 2：所提出的安全扩散器工作流程。安全扩散器在扩散动力学中执行额外的不变性二次规划求解器步骤以确保安全。最终控制信号从安全规划轨迹中推断得出。

定理 2. 设扩散动力学如 (6) 所定义, 其可控形式如 (7) 所定义。如果存在一个扩展类 $\mathcal{X}$ 函数 α , 使得

$$h(\mathbf{u}_k^j | \mathbf{x}_k^j) \geq 0, \forall k \in \{0, \dots, H\}, \forall j \in \{0, \dots, N-1\}, \quad (8)$$

其中 $h(\mathbf{u}_k^j | \mathbf{x}_k^j) = \frac{db(\mathbf{x}_k^j)}{d\mathbf{x}_k^j} \mathbf{u}_k^j + \alpha(b(\mathbf{x}_k^j))$, 则扩散过程 $p_\theta(\boldsymbol{\tau}^{i-1} | \boldsymbol{\tau}^i), i \in \{1, \dots, N\}$ 以几乎概率 1 满足有限时间扩散不变性。

鲁棒安全扩散过程中一个可能的问题是, 如果当 j 接近初始扩散步骤 N 时 $b(\mathbf{x}_k^j) \geq 0$, 那么状态 $\mathbf{x}_k^j$ 在扩散步骤 $j < N$ 之后永远不会违反规范。当规范存在局部陷阱时, 状态 $\mathbf{x}_k^j$ 可能在去噪扩散过程中陷入其中, 从而对性能产生不利影响。为了解决这个问题, 我们在以下小节中提出了松弛安全扩散器和时变安全扩散器。

3.2. 松弛安全扩散器

为了解决去噪扩散过程中由规范引起的局部陷阱问题, 我们提出了一种鲁棒安全扩散器的变体。我们将扩散动力学及其可控形式定义为 (6) - (7)。控制屏障函数的修改版本形式如下:

$$h(\mathbf{u}_k^j, r_k^j | \mathbf{x}_k^j) := \frac{db(\mathbf{x}_k^j)}{d\mathbf{x}_k^j} \mathbf{u}_k^j + \alpha(b(\mathbf{x}_k^j)) - w_k(j) r_k^j \geq 0, k \in \{0, \dots, H\}, j \in \{0, \dots, N-1\}, \quad (9)$$

其中 $r_k^j \in \mathbb{R}$ 是一个待确定的松弛变量 (将在下一节展示)。 $w_k(j) \geq 0$ 是松弛变量上的扩散时变权重, 使其随着 $j \rightarrow 0$ 逐渐减小到 0。当 $w_k(j)$ 减小到 0 时, 条件 (9) 变为硬约束。这种情况下的一个问题是, 这种硬约束可能会对扩散性能产生不利影响。为了解决这个问题, 我们可以运行额外的 $N_a \in \mathbb{N}$ 扩散步骤, 同时在反向过程中当 $j < 0$ 时将扩散时间设为 0。与 (9) 对应的控制屏障函数条件是将 j 的定义域改为 $j \in \{-N_a, \dots, N-1\}$ 。我们还有以下定理来证明有限时间扩散不变性 (证明见附录):

定理 3. 设扩散动力学如 (6) 所定义, 其可控形式如 (7) 所定义。如果存在一个扩展类 $\mathcal{X}$ 函数 α 、一个足够大的额外扩散步骤 $N_a \in \mathbb{N}$, 以及一个时变权重 $w_k(j)$, 其中对于所有 $j \leq 0$ 有 $w_k(j) = 0$, 使得

$$h(\mathbf{u}_k^j, r_k^j | \mathbf{x}_k^j) \geq 0, \forall k \in \{0, \dots, H\}, \forall j \in \{-N_a, \dots, N-1\}, \quad (10)$$

其中 $h(\mathbf{u}_k^j, r_k^j | \mathbf{x}_k^j) = \frac{db(\mathbf{x}_k^j)}{d\mathbf{x}_k^j} \mathbf{u}_k^j + \alpha(b(\mathbf{x}_k^j)) - w_k(j) r_k^j$, 则扩散过程 $p_\theta(\boldsymbol{\tau}^{i-1} | \boldsymbol{\tau}^i), i \in \{-N_a, \dots, N\}$ 以几乎概率 1 满足有限时间扩散不变性。

在步骤 $-N_a$ 完成去噪扩散过程后, 我们将 $\boldsymbol{\tau}^{-N_a}$ 设为扩散模型的输出数据, 即 $\boldsymbol{\tau}^0 = \boldsymbol{\tau}^{-N_a}$ 。

3.3. 时变安全扩散器

作为松弛安全扩散器的替代方案, 我们在本小节提出另一种安全扩散器, 称为时变安全扩散器。所提出的时变安全扩散器也能解决由规范引起的局部陷阱问题。

在这种情况下，我们直接通过扩散时变函数 $\gamma_k: j \rightarrow \mathbb{R}$ 修改规范 $b(\mathbf{x}_k^j) \geq 0$ ，形式如下：

$$b(\mathbf{x}_k^j) - \gamma_k(j) \geq 0, k \in \{0, \dots, H\}, j \in \{0, \dots, N\}, \quad (11)$$

其中 $\gamma_k(j)$ 是连续可微的，并且定义使得 $\gamma_k(N) \leq b(\mathbf{x}_k^N)$ 然后，可以使用控制 $\gamma_k(0) = 0$.

屏障函数（CBF）来强制执行修改后的时变规范： $h(\mathbf{u}_k^j | \mathbf{x}_k^j, \gamma_k(j)) := \frac{db(\mathbf{x}_k^j)}{d\mathbf{x}_k^j} \mathbf{u}_k^j - \dot{\gamma}_k(j) + \alpha(b(\mathbf{x}_k^j) - \gamma_k(j)) \geq 0, k \in \{0, \dots, H\}, j \in \{0, \dots, N-1\}$, 其中 $\dot{\gamma}_k(j)$ 是 $\gamma_k(j)$ 的扩散时间导数。

最后，我们提出以下定理来证明有限时间扩散不变性（证明见附录）：

定理 4. 设扩散动力学如 (6) 所定义，其可控形式如 (7) 所定义。如果存在一个扩展类

$\mathcal{H}$ 函数 α 和一个时变函数 $\gamma_k(j)$ ，其中 $\gamma_k(N) \leq b(\mathbf{x}_k^N)$ 且 $\gamma_k(0) = 0$

使得

$$h(\mathbf{u}_k^j | \mathbf{x}_k^j, \gamma_k(j)) \geq 0, \forall k \in \{0, \dots, H\}, \forall j \in \{0, \dots, N-1\}, \quad (12)$$

其中 $h(\mathbf{u}_k^j | \mathbf{x}_k^j, \gamma_k(j)) = \frac{db(\mathbf{x}_k^j)}{d\mathbf{x}_k^j} \mathbf{u}_k^j - \dot{\gamma}_k(j) + \alpha(b(\mathbf{x}_k^j) - \gamma_k(j))$ ，则扩散过程 $p_\theta(\tau^{i-1} | \tau^i), i \in \{0, \dots, N\}$ 是有限时间扩散不变的。

4. 在扩散器中强制执行不变性

在本节中，我们展示如何将上一节提出的三种不变性方法融入扩散模型。在扩散模型中强制执行有限时间不变性等价于确保在扩散过程中满足定理 2-4 中的条件。在本节中，我们提出一种最小偏差二次规划（QP）方法来实现这一目标。我们希望在扩散的每一步（如图 2 所示）强制执行这些条件，因为那些远离规范边界 $b(\mathbf{x}^j)$ 的状态也可以据此进行优化，从而使模型能够生成更为连贯的轨迹。

为鲁棒安全（RoS）和时变安全扩散器施加不变性。 在实现过程中，式 (6) 中的扩散时间步长 $\Delta\tau$ 被选取为足够小，并且我们希望控制量 $\mathbf{u}^j$ 保持接近式 (6) 的右端。因此，我们可以构造如下基于二次规划（QP）的优化问题，以求得满足定理 2 或定理 4 中条件的最优控制量 $\mathbf{u}^j$ ：

$$\mathbf{u}^{j*} = \arg \min_{\mathbf{u}^j} \left\| \mathbf{u}^j - \frac{\boldsymbol{\tau}^j - \boldsymbol{\tau}^{j+1}}{\Delta\tau} \right\|^2, \text{ s.t., (8) if RoS diffuser else s.t., (12),} \quad (13)$$

其中 $\|\cdot\|$ 表示向量的 2-范数。若存在多个规范，则可将定理 2 中对应的条件逐一加入上述二次规划。求解上述二次规划得到 $\mathbf{u}^{j*}$ 后，我们在该时间步内令 $\mathbf{u}^j = \mathbf{u}^{j*}$ 更新式 (7)，从而获得扩散过程的新状态。注意，所有这些操作均发生在每个扩散步骤的末尾。

为松弛安全扩散器施加不变性。 在这种情况下，由于每个安全规范均设有松弛变量，我们希望在代价函数中最小化这些松弛量，以促使所有状态趋向于满足规范。换言之，我们得到如下二次规划：

$$\mathbf{u}^{j*}, \mathbf{r}^{j*} = \arg \min_{\mathbf{u}^j, \mathbf{r}^j} \left\| \mathbf{u}^j - \frac{\boldsymbol{\tau}^j - \boldsymbol{\tau}^{j+1}}{\Delta\tau} \right\|^2 + \|\mathbf{r}^j\|^2, \text{ s.t., (10),} \quad (14)$$

其中 $\mathbf{r}^j$ 是所有 $k \in \{0, \dots, H\}$ 对应的 $\mathbf{r}^j$ 与 $\mathbf{r}_k$ 的拼接。作为替代方案，上述所有约束可以共享同一个松弛变量，即 $\mathbf{r}^j$ 的维度仅为 1。求解上述二次规划得到 $\mathbf{u}^{j*}$ 后，我们在该时间步内令 $\mathbf{u}^j = \mathbf{u}^{j*}$ 更新式 (7)，从而获得新状态。

Algorithm 1 Enforcing invariance in diffusion models

Input: the last trajectory of diffusion τ^{j+1} at diffusion step $j \in \{0, \dots, N\}$

Output: safe diffusion state τ^{j*} .

(a) Run diffusion procedure (4) and sample (5) as usual at step j and get τ^j .

(b) Find diffusion dynamics as in (6) - (7).

if *Robust-safe diffuser* **then**

Formulate the QP (13), solve it and get u^{j*} .

else if *Relaxed-safe diffuser* **then**

Define the time-varying weight $w_k(j)$ in (9), formulate the QP (14), solve it and get u^{j*}, r^{j*} .

else

Design the time-varying function $\gamma_k(j)$ in (11), formulate the QP (13), solve it and get u^{j*} .

end if

(c) Update dynamics (7) with $u^j = u^{j*}$ and get τ^{j*} . Finally, $\tau^j \leftarrow \tau^{j*}$.




图 3: 迷宫规划 (蓝色到红色) 去噪扩散过程, 采用基于分类器的引导 (从左至右: 扩散时间步分别为 256、4、3、-50)。红色椭圆和外部超椭圆表示安全规范。基于安全分类器的引导方法在缺乏保证的情况下对扩散过程产生不利影响。

强制不变性的复杂度 二次规划 (QP) 的计算复杂度为 $\mathcal{O}(q^3)$, 其中 q 为决策变量的维度。当存在一组规范 S 时, 只需为每个规范向二次规划中添加相应的约束。所提出的三种安全扩散器的复杂度相近。

用于强制不变性的算法是直接的, 包括构造适当的条件、求解二次规划 (QP) 以及更新扩散状态。我们在算法 1 中总结了该算法。

5. 实验

本文设置实验以回答以下问题:

- 我们的方法在各种任务中是否在定量和定性上匹配理论潜力?
- 在强制执行安全规范方面, 本文方法如何与最先进的方法进行比较?
- 本文所提方法在保证规范下如何影响扩散的性能?

5.1. 迷宫中的安全规划

本实验旨在对迷宫的规划路径施加轨迹约束。训练数据公开来源于 Janner 等人 (2022), 其中迷宫的初始位置和目的地随机生成。扩散模型以初始位置和目的地为条件。

表 1: 迷宫安全规划与基准方法的比较。各项分别简称为简单规范满足度 (S-SPEC)、复杂规范满足度 (C-SPEC)、规划任务得分 (SCORE)、每个扩散步骤的计算时间 (TIME, 单位: 秒)。在方法列中, 各项分别简称为鲁棒安全扩散器 (RoS-DIFFUSER)、松弛安全扩散器 (ReS-DIFFUSER) 和时变安全扩散器 (TVS-DIFFUSER)。分类器引导 $-\epsilon$ 方法在状态 $\epsilon > 0$ 接近边界时对模型施加 (安全) 梯度。

METHOD	S-SPEC($\uparrow$ & ≥ 0)	C-SPEC($\uparrow$ & ≥ 0)	SCORE ($\uparrow$)	TIME
DIFFUSER (BASELINE) JANNER ET AL. (2022)	-0.983	-0.894	1.016 $\pm$ 0.712	0.007
TRUNCATE BROCKMAN ET AL. (2016)	-1.192 e^{-7}	-0.759	0.754 $\pm$ 0.779	0.024
CLASSIFIER GUIDANCE DHARIWAL AND NICHOL (2021)	-0.789	-0.979	0.502 $\pm$ 0.328	0.053
CLASSIFIER GUIDANCE- ϵ DHARIWAL AND NICHOL (2021)	-0.853	-0.995	0.470 $\pm$ 0.366	0.061
RoS-DIFFUSER (OURS)	-2.384 e^{-7}	-5.960 e^{-7}	0.770 $\pm$ 0.782	0.106
ReS-DIFFUSER (OURS)	-2.384 e^{-7}	-4.768 e^{-7}	0.762 $\pm$ 0.746	0.107
TVS-DIFFUSER (OURS)	-2.384 e^{-7}	-5.364 e^{-7}	0.806 $\pm$ 0.783	0.107

如图 1 所示, 扩散器无法保证任何规范的满足。当在扩散中使用基于分类器的引导来满足安全规范时, 性能可能受到显著影响 (图 3)。因此, 生成的轨迹将大幅偏离期望轨迹且不具备安全性。所提出的鲁棒安全扩散器 (RoS-diffuser)、松弛安全扩散器 (ReS-diffuser) 和时变安全扩散器 (TVS-diffuser) 均能保证规范的满足, 即使规范是复杂的 (只要它们可微), 如表 1 所示。所提出方法的满足度得分并非严格为正, 这可能是由于计算误差或采样间效应, 因为即使截断方法也无法严格满足简单规范。所提出的方法还能最大程度地保留扩散模型的性能, 如表 1 中的得分以及图 4 所示。ReS-diffuser 和 TVS-diffuser 能够解决规范带来的局部陷阱问题, 如附录中的图所示。

5.2. 机器人运动的安全规划

对于机器人运动 (在 MuJoCo 中), 我们希望机器人避免与障碍物 (如屋顶) 发生碰撞。在这种情况下, 由于不存在局部陷阱问题, 我们仅考虑鲁棒安全扩散器 (RoS-diffuser)。其他方法类似。训练数据集可从 Janner 等人 (2022) 公开获取。如表 2 所示, 由于缺乏保证, 使用扩散器时, 步行者和跳跃者很可能与屋顶发生碰撞。截断方法适用于简单规范 (S-spec), 但不适用于复杂规范 (C-spec)。基于分类器的引导可以提高规范的满足率, 但缺乏保证。使用所提出的鲁棒安全扩散器可以保证无碰撞, 图 5 展示了一个扩散过程示例。




图 4: 使用所提出的时变安全扩散器进行迷宫规划（从蓝色到红色）的去噪扩散过程（从左到右：扩散时间步分别为 256、4、3、-50）。红色椭圆和外部超椭圆表示安全规范。所提出的时变安全扩散器能够在扩散结束时保证规范，同时不会显著影响扩散过程。




图 5: 使用所提出的鲁棒安全扩散器进行 Walker2D 规划的去噪扩散过程（从上到下：扩散时间步分别为 20、10、0）。红线表示步行者在运动过程中需要安全避开的屋顶（安全规范）。在时间步 20 时安全被违反，因为轨迹初始为高斯噪声，但最终得到保证（时间步 0）。

5.3. 面向操作的安全规划

在操作任务（基于 Pybullet 物理仿真器）中，扩散模型为机器人（机械臂）生成关节轨迹（作为控制量），并以待抓取和放置物体的位置为条件。训练数据集由 Janner 等人（2022）公开提供。约束条件为关节限制，以避免关节空间中的碰撞。在此场景下，截断方法仍无法处理复杂约束（如依赖速度的关节限制）。本文提出的 RoS-diffuser 只要约束可微，即可适用于所有约束。一个有趣的发现是，如表 3 所示，所提出的 RoS-diffuser 甚至能在此场景下提升扩散模型的性能（奖励值）。这可能是因为满足关节限制能够避免机器人在 Pybullet 物理仿真器的关节空间中发生碰撞。所提出的 RoS-diffuser 的计算时间与其他方法相当。安全扩散与操作过程的示意图如图 6 所示。

表 2: 机器人安全规划与基准方法的比较。各项分别表示: 简单约束满足率 (S-SPEC)、复杂约束满足率 (C-SPEC)、规划任务得分 (SCORE)、每个扩散步骤的计算时间 (TIME, 单位: 秒)。

EXPERIMENT	METHOD	S-SPEC($\uparrow$ & ≥ 0)	C-SPEC($\uparrow$ & ≥ 0)	SCORE ($\uparrow$)	TIME
WALKER2D	DIFFUSER (BASELINE) JANNER ET AL. (2022)	-9.375	-4.891	0.346 ± 0.106	0.037
	TRUNCATE BROCKMAN ET AL. (2016)	0.0	$\times$	0.286 ± 0.180	0.105
	CLASSIFIER GUIDANCE DHARIWAL AND NICHOL (2021)	-0.575	-0.326	0.208 ± 0.140	0.053
	ROS-DIFFUSER (OURS)	0.0	$-6.706e^{-8}$	0.312 ± 0.782	0.183
HOPPER	DIFFUSER (BASELINE) JANNER ET AL. (2022)	-2.180	-1.862	0.455 ± 0.038	0.038
	TRUNCATE BROCKMAN ET AL. (2016)	0.0	$\times$	0.436 ± 0.067	0.046
	CLASSIFIER GUIDANCE DHARIWAL AND NICHOL (2021)	-0.894	-0.524	0.478 ± 0.038	0.047
	ROS-DIFFUSER (OURS)	0.0	$-5.960e^{-8}$	0.430 ± 0.040	0.170

6. 相关工作

扩散模型与规划 扩散模型 (Diffusion Models) Sohl-Dickstein 等人 (2015) Ho 等人 (2020) 是数据驱动的生成建模工具, 广泛应用于图像生成 Dhariwal 和 Nichol (2021) Du 等人 (2020b)、规划 Hafner 等人 (2019) Janner 等人 (2021) Ozair 等人 (2021) Janner 等人 (2022) 以及语言 Saharia 等人 (2022) Liu 等人 (2023) 等应用。生成模型与强化学习相结合, 以卷积 U 型网络 Kaiser 等人 (2019)、随机循环网络 Ke 等人 (2019)、神经常微分方程 Du 等人 (2020a)、生成对抗网络 Eysenbach 等人 (2022)、神经辐射场 Li 等人 (2022) 和变换器 Chen 等人 (2022) 的形式探索动态模型。此外, 规划任务对扩散模型 Lambert 等人 (2021) Ozair 等人 (2021) Janner 等人 (2022) 日益重要, 因为它们能够在各类机器人问题中良好泛化。然而, 目前尚无方法为扩散模型配备规范保证, 这对于安全关键型应用尤为重要。本文利用所提出的有限时间扩散不变性来解决这一问题。

集合不变性与控制屏障函数。不变集已被广泛用于表示动态系统的安全行为 Preindl (2016) Rakovic 等人 (2005) Ames 等人 (2017) Glotfelter 等人 (2017) Xiao 等人 (2023a)。在控制领域的最新进展中, 控制屏障函数 (Control Barrier Functions, CBFs) 也被广泛用于证明集合不变性 Aubin (2009)、Prajna 等人 (2007)、Wisniewski 和 Sloth (2013)。控制屏障函数可追溯至优化问题 Boyd 和 Vandenberghe (2004), 并且是类李雅普诺夫函数 Wieland 和 Allgöwer (2007)。对于时变系统, 控制屏障函数也可相应调整 Lindemann 和 Dimarogonas (2018)。现有的控制屏障函数方法通常应用于规划时间, 因为它们与系统动力学紧密耦合。在其他空间 (如扩散模型中的扩散时间范围) 中, 关于控制屏障函数的研究很少。我们的工作

表 3: 操作安全规划与基准的比较。各项分别简称为简单规范满足 (S-SPEC)、复杂规范满足 (C-SPEC)、规划任务奖励 (REWARD)、每个扩散步骤的计算时间 (TIME, 单位: 秒)。在方法列中, 该项简称为鲁棒安全扩散器 (RoS-DIFFUSER)。

METHOD	S-SPEC($\uparrow$ & ≥ 0)	C-SPEC($\uparrow$ & ≥ 0)	REWARD ($\uparrow$)	TIME
DIFFUSER (BASELINE) JANNER ET AL. (2022)	-0.057	-0.065	0.650 ± 0.107	0.038
TRUNCATE BROCKMAN ET AL. (2016)	$1.631e^{-8}$	$\times$	0.575 ± 0.112	0.069
CLASSIFIER GUIDANCE DHARIWAL AND NICHOL (2021)	-0.050	-0.053	0.800 ± 0.328	0.075
RoS-DIFFUSER (OURS)	0.072	0.069	0.925 ± 0.107	0.088




图 6: 采用所提出的鲁棒安全扩散器的操作规划去噪扩散过程 (从左至右: 扩散时间步分别为 1000、100、0, 以及执行时间步 100)。红点表示末端执行器的规划轨迹。

解决了所有这些局限性。

神经网络中的保证。可微优化方法为具有保证的神经网络控制器展现了前景 Amos 等人 (2018); Pereira 等人 (2020); Xiao 等人 (2023a)。它们通常作为神经网络中的一个层 (滤波器) 使用。在 Amos 和 Kolter (2017) 中, 引入了一种称为 OptNet 的可微二次规划 (QP) 层。带有控制障碍函数 (CBF) 的 OptNet 已被用作神经网络中的滤波器以实现安全控制 Pereira 等人 (2020), 其中 CBF 不可训练, 因此可能限制系统的学习性能。在 Deshmukh 等人 (2019); Ferlez 等人 (2020); Zhao 等人 (2021) 中, 通过验证闭环训练学习了具有安全保证的神经网络控制器。验证方法无法确保覆盖整个状态空间。最近, CBF 已被纳入神经微分方程中, 以赋予其规范保证 Xiao 等人 (2023b)。然而, 这些方法均无法应用于扩散模型, 这正是本文所解决的问题。

7. 结论、讨论与未来工作

本文提出了扩散模型的有限时间扩散不变性，以确保安全关键应用中的安全规划。我们已在一系列机器人规划任务上证明了所提方法的有效性。尽管如此，我们的方法仍面临一些不足，这为未来工作提供了动力。具体而言，扩散模型的规范应表示为连续可微约束，而这些约束在规划任务中可能是未知的。进一步的工作可以探索如何从历史轨迹数据中学习规范。此外，使用扩散模型进行规划与控制之间仍存在差距。我们可能会进一步研究在机器人动力学已知或待学习的情况下，利用扩散实现安全控制策略。

更广泛影响。本文提出的有限时间扩散不变性除规划外，还可应用于其他任务中的保证，例如图像生成。在此类情况下，我们可以确保生成所需的模式/对象，例如生成图像中的猫。我们将在未来工作中进一步研究这些方向。

8. 致谢

本研究部分由凯捷工程公司（Capgemini Engineering）资助。同时，本研究还获得了美国空军研究实验室（United States Air Force Research Laboratory）和美国空军人工智能加速器（United States Air Force Artificial Intelligence Accelerator）的部分赞助，并在合作协议编号 FA8750-19-2-1000 下完成。本文所含观点和结论均为作者个人观点，不应被解释为代表美国空军或美国政府的官方政策（无论明示或暗示）。美国政府有权为政府目的复制和分发重印本，不受本文中任何版权标记的限制。本研究还部分得到了施密特未来基金会（Schmidt Futures）AI2050 项目的支持（资助编号 G-965 22-63172）。

参考文献

- A. D. Ames, X. Xu, J. W. Grizzle, and P. Tabuada. Control barrier function based quadratic programs for safety critical systems. *IEEE Transactions on Automatic Control*, 62(8):3861–3876, 2017.
- B. Amos and J. Z. Kolter. Optnet: Differentiable optimization as a layer in neural networks. In *Proceedings of the 34th International Conference on Machine Learning - Volume 70*, pages 136–145, 2017.
- B. Amos, I. D. J. Rodriguez, J. Sacks, B. Boots, and J. Z. Kolter. Differentiable mpc for end-to-end planning and control. In *Proceedings of the 32nd International Conference on Neural Information Processing Systems*, page 8299–8310. Curran Associates Inc., 2018.
- J.-P. Aubin. *Viability theory*. Springer, 2009.
- S. P. Boyd and L. Vandenberghe. *Convex optimization*. Cambridge university press, New York, 2004.
- G. Brockman, V. Cheung, L. Pettersson, J. Schneider, J. Schulman, J. Tang, and W. Zaremba. Openai gym, 2016.
- C. Chen, Y.-F. Wu, J. Yoon, and S. Ahn. Transdreamer: Reinforcement learning with transformer world models. *arXiv preprint arXiv:2202.09481*, 2022.

- J. V. Deshmukh, J. P. Kapinski, T. Yamaguchi, and D. Prokhorov. Learning deep neural network controllers for dynamical systems with safety guarantees: Invited paper. In *2019 IEEE/ACM International Conference on Computer-Aided Design (ICCAD)*, pages 1–7, 2019.
- P. Dhariwal and A. Nichol. Diffusion models beat gans on image synthesis. *Advances in Neural Information Processing Systems*, 34:8780–8794, 2021.
- J. Du, J. Futoma, and F. Doshi-Velez. Model-based reinforcement learning for semi-markov decision processes with neural odes. *Advances in Neural Information Processing Systems*, 33:19805–19816, 2020a.
- Y. Du, S. Li, and I. Mordatch. Compositional visual generation with energy based models. *Advances in Neural Information Processing Systems*, 33:6637–6647, 2020b.
- B. Eysenbach, A. Khazatsky, S. Levine, and R. R. Salakhutdinov. Mismatched no more: Joint model-policy optimization for model-based rl. *Advances in Neural Information Processing Systems*, 35:23230–23243, 2022.
- J. Ferlez, M. Elnaggar, Y. Shoukry, and C. Fleming. Shieldnn: A provably safe nn filter for unsafe nn controllers. *preprint arXiv:2006.09564*, 2020.
- P. Glotfelter, J. Cortes, and M. Egerstedt. Nonsmooth barrier functions with applications to multi-robot systems. *IEEE control systems letters*, 1(2):310–315, 2017.
- D. Hafner, T. Lillicrap, I. Fischer, R. Villegas, D. Ha, H. Lee, and J. Davidson. Learning latent dynamics for planning from pixels. In *International conference on machine learning*, pages 2555–2565. PMLR, 2019.
- J. Ho, A. Jain, and P. Abbeel. Denoising diffusion probabilistic models. *Advances in Neural Information Processing Systems*, 33:6840–6851, 2020.
- M. Janner, Q. Li, and S. Levine. Offline reinforcement learning as one big sequence modeling problem. *Advances in neural information processing systems*, 34:1273–1286, 2021.
- M. Janner, Y. Du, J. Tenenbaum, and S. Levine. Planning with diffusion for flexible behavior synthesis. In *International Conference on Machine Learning*, pages 9902–9915. PMLR, 2022.
- L. Kaiser, M. Babaeizadeh, P. Milos, B. Osinski, R. H. Campbell, K. Czechowski, D. Erhan, C. Finn, P. Koza-kowski, S. Levine, et al. Model-based reinforcement learning for atari. *arXiv preprint arXiv:1903.00374*, 2019.
- N. R. Ke, A. Singh, A. Touati, A. Goyal, Y. Bengio, D. Parikh, and D. Batra. Modeling the long term future in model-based reinforcement learning. In *International Conference on Learning Representations*, 2019.
- H. K. Khalil. *Nonlinear Systems*. Prentice Hall, third edition, 2002.
- N. Lambert, A. Wilcox, H. Zhang, K. S. Pister, and R. Calandra. Learning accurate long-term dynamics for model-based reinforcement learning. In *2021 60th IEEE Conference on Decision and Control (CDC)*, pages 2880–2887. IEEE, 2021.
- Y. Li, S. Li, V. Sitzmann, P. Agrawal, and A. Torralba. 3d neural scene representations for visuomotor control. In *Conference on Robot Learning*, pages 112–123. PMLR, 2022.
- L. Lindemann and D. V. Dimarogonas. Control barrier functions for signal temporal logic tasks. In *Proc. of 57th IEEE Conference on Decision and Control*, 2018. to appear.

- H. Liu, Z. Chen, Y. Yuan, X. Mei, X. Liu, D. Mandic, W. Wang, and M. D. Plumbley. Audioldm: Text-to-audio generation with latent diffusion models. *arXiv preprint arXiv:2301.12503*, 2023.
- M. Nagumo. Über die lage der integralkurven gewöhnlicher differentialgleichungen. In *Proceedings of the Physico-Mathematical Society of Japan. 3rd Series*. 24:551-559, 1942.
- Q. Nguyen and K. Sreenath. Exponential control barrier functions for enforcing high relative-degree safety-critical constraints. In *2016 American Control Conference (ACC)*, pages 322–328. IEEE, 2016.
- S. Ozair, Y. Li, A. Razavi, I. Antonoglou, A. Van Den Oord, and O. Vinyals. Vector quantized models for planning. In *International Conference on Machine Learning*, pages 8302–8313. PMLR, 2021.
- M. A. Pereira, Z. Wang, I. Exarchos, and E. A. Theodorou. Safe optimal control using stochastic barrier functions and deep forward-backward sdes. In *Conference on Robot Learning*, 2020.
- S. Prajna, A. Jadbabaie, and G. J. Pappas. A framework for worst-case and stochastic safety verification using barrier certificates. *IEEE Transactions on Automatic Control*, 52(8):1415–1428, 2007.
- M. Preindl. Robust control invariant sets and lyapunov-based mpc for ipm synchronous motor drives. *IEEE Transactions on Industrial Electronics*, 63(6):3925–3933, 2016.
- S. V. Rakovic, E. C. Kerrigan, K. I. Kouramas, and D. Q. Mayne. Invariant approximations of the minimal robust positively invariant set. *IEEE Transactions on automatic control*, 50(3):406–410, 2005.
- C. Saharia, W. Chan, S. Saxena, L. Li, J. Whang, E. L. Denton, K. Ghasemipour, R. Gontijo Lopes, B. Karagol Ayan, T. Salimans, et al. Photorealistic text-to-image diffusion models with deep language understanding. *Advances in Neural Information Processing Systems*, 35:36479–36494, 2022.
- J. Sohl-Dickstein, E. Weiss, N. Maheswaranathan, and S. Ganguli. Deep unsupervised learning using nonequilibrium thermodynamics. In *International Conference on Machine Learning*, pages 2256–2265. PMLR, 2015.
- P. Wieland and F. Allgöwer. Constructive safety using control barrier functions. In *Proc. of 7th IFAC Symposium on Nonlinear Control System*, 2007.
- R. Wisniewski and C. Sloth. Converse barrier certificate theorem. In *Proc. of 52nd IEEE Conference on Decision and Control*, pages 4713–4718, Florence, Italy, 2013.
- W. Xiao and C. Belta. Control barrier functions for systems with high relative degree. In *Proc. of 58th IEEE Conference on Decision and Control*, pages 474–479, Nice, France, 2019.
- W. Xiao, T.-H. Wang, R. Hasani, M. Chahine, A. Amini, X. Li, and D. Rus. Barriernet: Differentiable control barrier functions for learning of safe robot control. *IEEE Transactions on Robotics*, 2023a.
- W. Xiao, T.-H. Wang, R. Hasani, M. Lechner, Y. Ban, C. Gan, and D. Rus. On the forward invariance of neural odes. In *International conference on machine learning*, *arXiv preprint arXiv:2210.04763*, 2023b.
- H. Zhao, X. Zeng, T. Chen, Z. Liu, and J. Woodcock. Learning safe neural network controllers with barrier certificates. *Form Asp Comp*, 33:437–455, 2021.

S1. 证明

S1.1. 定理 3.2 的证明

证明: 给定一个连续可微约束 $h(x_t) \geq 0$ ($h(x_0) \geq 0$) , 根据纳古莫定理 (Nagumo's theorem) Nagumo (1942), 满足 $h(x_t) \geq 0, \forall t \geq 0$ 的充要条件是

$$\dot{h}(x_t) \geq 0, \text{ when } h(x_t) = 0,$$

若 $b(x_k^N) \geq 0, k \in \{0, \dots, H\}$, 则条件 (8) 等价于

$$\frac{db(x_k^j)}{dx_k^j} \dot{x}_k^j + \alpha(b(x_k^j)) \geq 0,$$

其中 $\dot{x}_k^j$ 是扩散时间导数。最后一个方程等价于

$$\dot{b}(x_k^j) + \alpha(b(x_k^j)) \geq 0,$$

由于 α 是扩展类 $\mathcal{K}$ 函数, 我们有

$$\alpha(b(x_k^j)) \rightarrow 0, \text{ as } b(x_k^j) \rightarrow 0,$$

换句话说, 当 $b(x_k^j) = 0$ 时, 我们有 $\dot{b}(x_k^j) \geq 0$ 。由于 $b(x_k^N) \geq 0, k \in \{0, \dots, H\}$, 根据 Nagumo 定理, 我们有 $b(x_k^j) \geq 0, \forall j \in \{0, \dots, N-1\}$ 。因此, 扩散过程 $p_\theta(\tau^{i-1}|\tau^i), i \in \{1, \dots, N\}$ 是有限时间扩散不变的, 且扩散不变性的有限时间为 N 。

另一方面, 如果 $b(x_k^N) < 0, k \in \{0, \dots, H\}$, 那么我们可以定义一个李雅普诺夫函数:

$$V(x_k^j) = -b(x_k^j), k \in \{0, \dots, H\}, j \in \{0, \dots, N\}, \quad (S1)$$

$V(x_k^N) > 0$. 并且由于 α 是扩展类 $\mathcal{K}$ 函数, 将 $b(x_k^j)$ 替换为 $V(x_k^j)$, 条件 (8) 等价于

$$\frac{dV(x_k^j)}{dx_k^j} \dot{x}_k^j + \alpha(V(x_k^j)) \leq 0,$$

这等价于

$$\dot{V}(x_k^j) + \alpha(V(x_k^j)) \leq 0,$$

由于 $\dot{V}(x_k^j) \leq -\alpha(V(x_k^j)) < 0$, 根据李雅普诺夫稳定性理论, 我们有 $V(x_k^j)$ 将被稳定到 0。在 other words, the state x_k^j will be stabilized to the boundary $b(x_k^j) = 0$. Specifically, when α is a linear function, the last equation can be rewritten as

$$\dot{V}(x_k^j) + \varepsilon V(x_k^j) \leq 0, \quad (S2)$$

其中 $\varepsilon > 0$ 。假设我们有

$$\dot{V}(x_k^j) + \varepsilon V(x_k^j) = 0,$$

上述方程的解为

$$V(x_k^j) = V(x_k^N) e^{-\varepsilon(N-j)},$$

利用比较引理 Khalil (2002), 方程 (S2) 表明

$$V(\mathbf{x}_k^j) \leq V(\mathbf{x}_k^N) e^{-\varepsilon(N-j)}, j \in \{0, \dots, N\},$$

因此,

如果 N 足够大, , 则状态 $\mathbf{x}_k^j V(\mathbf{x}_k^j) \rightarrow 0$, as $j \rightarrow 0$, 将被指数稳定到边界 $b(\mathbf{x}_k^j) = 0$ 。如果在扩散时间 $j \in \{0, \dots, N-1\}$, 状态 $\mathbf{x}_k^j$ 接近边界, 并且状态 $\mathbf{x}_k^j$ 跳入集合: $\{\mathbf{x}_k^j : b(\mathbf{x}_k^j) \geq 0\}$ 的概率为 p (由于扩散过程中的高斯转移), 则 $\mathbf{x}_k^0$ 进入集合 $\{\mathbf{x}_k^j : b(\mathbf{x}_k^j) \geq 0\}$ 的概率为 $1 - (1-p)^j$ 。当 j 足够大时, $b(\mathbf{x}_k^0) \geq 0$ 的概率几乎为 1。当 $b(\mathbf{x}_k^l) \geq 0$ 在步骤 $l \leq j$ 时, 则 $b(\mathbf{x}_k^r) \geq 0$ 对所有 $r \leq l$ 成立, 遵循 Nagumo 定理 (如证明的第一种情况)。因此, 扩散过程 $p_\theta(\boldsymbol{\tau}^{i-1} | \boldsymbol{\tau}^i), i \in \{1, \dots, N\}$ 是几乎概率 1 的有限时间扩散不变。 ■

S1.2. 定理 3.3 的证明

证明: 假设权重 $w_k(j)$ 被选择使得当 $j = 0$ 时 $w_k(j) = 0$, 则当 $j < 0$ 时条件 (10) 变为硬约束。换句话说, 方程 (10) 变为:

$$h(\mathbf{u}_k^j | \mathbf{x}_k^j) := \frac{db(\mathbf{x}_k^j)}{d\mathbf{x}_k^j} \mathbf{u}_k^j + \alpha(b(\mathbf{x}_k^j)) \geq 0, k \in \{0, \dots, H\}, j \in \{-N_a, \dots, 0\},$$

然后, 证明与定理 3.2 的证明类似, 我们得到扩散过程 $p_\theta(\boldsymbol{\tau}^{i-1} | \boldsymbol{\tau}^i), i \in \{-N_a, \dots, N\}$ 是几乎概率 1 的有限时间扩散不变。 ■

S1.3. 定理 3.4 的证明

证明: 由于 $\gamma_k(N) \leq b(\mathbf{x}_k^N)$, 当 $j = N$ 时, 有 $s(\mathbf{x}_k^j, \gamma_k(j)) := b(\mathbf{x}_k^j) - \gamma_k(j) \geq 0$ 。条件 (12) 等价于

$$\frac{\partial s(\mathbf{x}_k^j, \gamma_k(j))}{\partial \mathbf{x}_k^j} \mathbf{u}_k^j + \frac{\partial s(\mathbf{x}_k^j, \gamma_k(j))}{\partial j} + \alpha(s(\mathbf{x}_k^j, \gamma_k(j))) \geq 0,$$

可改写为

$$\dot{s}(\mathbf{x}_k^j, \gamma_k(j)) + \alpha(s(\mathbf{x}_k^j, \gamma_k(j))) \geq 0,$$

利用定理 3.2 证明中给出的 Nagumo 定理, 可得

$$s(\mathbf{x}_k^j, \gamma_k(j)) \geq 0, \forall j \in \{0, \dots, N\}$$

since $s(\mathbf{x}_k^N, \gamma_k(N)) \geq 0$.

由于 $\gamma_k(0) = 0$ 且 $s(\mathbf{x}_k^j, \gamma_k(j)) := b(\mathbf{x}_k^j) - \gamma_k(j)$, 有 $b(\mathbf{x}_k^0) \geq 0, \forall k \in \{0, \dots, H\}$ 。因此, 扩散过程 $p_\theta(\boldsymbol{\tau}^{i-1} | \boldsymbol{\tau}^i), i \in \{0, \dots, N\}$ 是有限时间扩散不变的, 且扩散不变性的有限时间为 0。 ■

S2. 实验细节

S2.1. 迷宫中的安全规划

本实验旨在对迷宫的规划路径施加轨迹约束。训练数据公开来源于 Janner 等人 (2022)，其中迷宫的初始位置和目的地随机生成。扩散模型以初始位置和目的地为条件。

规格说明。规划轨迹的简单安全规范被定义为一个超椭圆形状的障碍物：

$$\left(\frac{x-x_0}{a}\right)^2 + \left(\frac{y-y_0}{b}\right)^2 \geq 1, \quad (\text{S3})$$

其中 $(x,y) \in \mathbb{R}^2$ 是规划轨迹上的状态， $(x_0,y_0) \in \mathbb{R}^2$ 是障碍物的位置。 $a > 0, b > 0$ 。由于状态 (x,y) 在扩散模型中被归一化，我们也需要相应地归一化上述约束。换句话说，我们根据 (x,y) 沿 x 轴和 y 轴的归一化，分别归一化 x_0, a 和 y_0, b 。

规划轨迹的复杂安全规范被定义为一个椭圆形状的障碍物：

$$\left(\frac{x-x_0}{a}\right)^4 + \left(\frac{y-y_0}{b}\right)^4 \geq 1, \quad (\text{S4})$$

我们也像简单情况一样归一化上述约束。在这种情况下，截断规划轨迹以满足约束并非易事。当我们有更复杂的规范时，截断方法很难奏效。

模型设置、训练和测试。扩散模型结构与 Janner 等人 (2022) 提供的开源模型 (Maze2Dlarge-v1) 相同。我们将规划时域设为 384，扩散步数设为 256，并为所提出的方法额外增加 $N_a = 50$ 个扩散步骤。学习率为 $2e^{-4}$ ，训练步数为 $2e^6$ 。模型训练在 Nvidia RTX-3090 GPU 上大约需要 10 小时。更多参数见所附代码：“safediffuser/config/maze2d.py”。测试中不同（提出的）方法的切换可以通过“GaussianDiffusion.p_sample()”函数在“safediffuser/diffuser/models/diffusion.py”中修改。

在图 S1 中，我们展示了使用扩散器的扩散过程，在这种情况下，生成的轨迹很容易违反安全约束。使用所提出的鲁棒安全扩散器，生成的轨迹可以保证安全，但轨迹上的某些点可能会陷入局部陷阱，如 S2 所示。使用所提出的松弛安全扩散器和时变安全扩散器，可以解决局部陷阱问题。


S2.2. 机器人运动的安全规划

对于机器人运动（在 MuJoCo 中），我们希望机器人避免与障碍物（如屋顶）发生碰撞。在这种情况下，由于不存在局部陷阱问题，我们仅考虑鲁棒安全扩散器（RoS-diffuser）。其他方法类似。训练数据集由 Janner 等人 (2022) 公开提供。


规格说明。Walker2D 和 Hopper 的简单安全规范均为避免与屋顶碰撞。换言之，机器人头部高度 $z \in \mathbb{R}$ 应满足以下约束：

$$z \leq h_r, \quad (\text{S5})$$

其中 $h_r > 0$ 为屋顶高度。我们还需根据扩散模型中状态 z 的归一化方式对 h_r 进行归一化。

**Fig**

S1: 迷宫规划（蓝色到红色）使用扩散器进行去噪扩散过程（从左到右：扩散时间步分别为 256、4、3、0）。红色椭圆和外部超椭圆表示安全规范。扩散器生成的轨迹违反了这两种规范。



图。S2: 迷宫规划（蓝色到红色）在扩散时间步 0 使用鲁棒安全扩散器进行去噪扩散过程。红色椭圆和外部超椭圆表示安全规范。尽管具有安全保证，但某些轨迹点可能陷入局部陷阱。

Walker2D 和 Hopper 的复杂安全规范为速度相关的碰撞避免约束：

$$z + \phi v_z \leq h_r, \quad (\text{S6})$$

其中 $\phi > 0$, $v_z \in \mathbb{R}$ 为机器人头部沿 z 轴的速度。速度相关的安全约束对于机器人避免与屋顶碰撞更为鲁棒，因为当机器人跳跃更快时，我们需要确保与屋顶之间更大的安全距离，以应对各种不确定性或扰动。在这种情况下，简单的截断方法难以奏效，因为不清楚如何同时截断 z 和 v_z 。

模型设置、训练和测试。 扩散模型结构与 Janner 等人（2022）提供的开源版本（Walker2D-Medium-Expert-v2 和 Hopper-Medium-Expert-v2）相同。本文将规划时域设为 600，扩散步数设为 20。学习率为 $2e^{-4}$ ，训练步数为 $2e^6$ 。模型训练在 Nvidia RTX-3090 GPU 上约需 16 小时。更多参数见所附代码：“safediffuser/config/locomotion.py”。测试中不同方法的切换可通过修改

“safediffuser/diffuser/models/diffusion.py”中的“GaussianDiffusion.p_sample()”函数实现。

S2.3. 操作任务的安全规划

对于操作任务（在 Pybullet 中），扩散模型生成机器人的关节轨迹（作为控制量），并以抓取和放置物体的位置为条件。训练数据集可从 Janner 等人（2022）公开获取。安全规范为关节限制，以避免关节空间中的碰撞。

规格说明。机器人的简单安全规范定义在关节空间中，本文尝试将机器人的关节角度限制在允许范围内：

$$x_{min} \leq x \leq x_{max}, \quad (S7)$$

其中 $x \in \mathbb{R}^7$ 为 7 个关节角度的状态， $x_{min} \in \mathbb{R}^7$ 和 $x_{max} \in \mathbb{R}^7$ 分别表示关节角度的最小和最大限制。需要根据扩散模型中状态 x 的归一化方式对限制进行归一化。

复杂安全规范为与速度相关的关约束：

$$x_{min} \leq x + \phi v \leq x_{max}, \quad (S8)$$

其中 $\phi > 0$, $v \in \mathbb{R}^7$ 为与关节角度 x 对应的关节速度。在此示例中，由于扩散模型不直接预测 v ，本文沿规划时域利用 $x(k)$ 和 $x(k+1)$ 评估 v 。关节限制的归一化方式与简单规范情况相同。

模型设置、训练和测试。扩散模型结构与 Janner 等人（2022）提供的开源模型相同，在与其他方法比较时，我们使用其预训练模型来评估本文方法。