

SAIL: 基于视觉语言模型的上下文模仿学习测试时扩展

Makoto Sato¹, Yusuke Iwasawa¹, Yujin Tang², and So Kuroki²




图 1: 左图: 我们利用蒙特卡洛树搜索对视觉语言模型提出的轨迹进行测试时扩展, 使用基于相似度的检索从成功回滚存档中获取信息, 并由视觉语言模型评估器提供逐步反馈。右图: 随着扩展的蒙特卡洛树搜索节点 (测试时计算) 增多, 成功率不断提高; 随机检索和弱反馈会较早饱和, 而我们的检索和逐步反馈则持续带来增益。

摘要——上下文模仿学习使机器人能够从演示中获取技能, 然而一次性轨迹生成在环境变化下仍然脆弱。我们提出 SAIL, 一个将机器人模仿重新定义为能够随测试时计算扩展的迭代优化问题的框架。SAIL 利用蒙特卡洛树搜索, 其中每个节点是一条完整轨迹, 边对应轨迹优化。该过程由三个核心组件引导: 一个自动化的成功轨迹存档, 用于上下文相关的检索; 一个基于视觉语言模型的评分机制, 用于轨迹评估; 以及一个逐步反馈, 为迭代优化提供轨迹对齐的分数。在仿真中的六项多样化操作任务和真实世界验证中的实验清楚地表明, 增加测试时计算能够持续提高成功率, 在复杂任务上达到高达 95%。我们的结果表明, 轨迹级别的测试时扩展是通往更具泛化能力的机器人智能体的稳健路径。

一、引言

上下文学习已成为机器人直接从少量视觉提示和轨迹演示中获取复杂技能的一种引人注目的范式 [1], [2], [3]。然而, 一个根本性的瓶颈仍然存在, 因为当机器人遇到新的初始条件时, 单条已实现的轨迹往往无法泛化。尽管当前的视觉语言模型 (VLM) 能够生成轨迹 [4], [5], 但它们通常将其视为一次性预测任务。这一局限性意味着系统的成功受限于模型的初始猜测, 无法在推理过程中针对环境变化进行调整。

本文提出, 机器人模仿应被重新定义为一种迭代搜索问题, 其性能可通过扩展测试时计算来提升。通过将完整轨迹作为搜索对象, 系统能够在执行前于匹配的模拟器中探索潜在解决方案。这一方法将焦点从静态模仿转向动态范式, 使机器人能够有效延长思考时间, 以解决新任务中的歧义。依赖基础模型的一次性推理存在问题, 因为机器人轨迹的高维空间对初始状态估计或目标定位中的微小误差极为敏感。即使预测的末端执行器姿态存在轻微偏差, 也可能在执行过程中引发级联失败, 而模型若无外部评估回路则无法纠正。近期研究试图通过将程序性推理蒸馏为更鲁棒的视觉表征 [6]、[7], 或采用检索机制从成功的历史演示中为模型提供更丰富的上下文 [8], 以缓解这种脆弱性。然而, 这些方法通常侧重于提升单次预测的质量, 而非使系统能够系统地探索和细化连续运动空间本身。尽管一些框架引入外部验证器来指导修正 [9]、[10], 但它们往往局限于符号规划, 并未解决在完整机器人轨迹层面进行测试时扩展的根本需求。为应对这些挑战, 本文提出 **SAIL** (Scaling In-context Imitation Learning), 一种新颖的框架, 使上下文模仿能够通过测试时计算实现扩展。

*这项工作是在佐藤真在 Sakana AI 实习期间完成的。¹ 东京大学, 日本东京。² Sakana AI, 日本东京。

(见图 1 左)。SAIL 并未依赖视觉语言模型的单一预测，而是将轨迹生成视为一个精炼问题，并引入三个关键组件来引导精炼过程走向成功。首先，我们在蒙特卡洛树搜索 (Monte Carlo Tree Search, MCTS) 框架下构建轨迹生成，其中每个节点代表一条完整的机器人轨迹。这使得系统能够系统地探索连续运动空间，而非依赖单一的一次性规划。其次，我们维护一个自动化的成功轨迹档案，通过检索为新环境配置提供上下文相关的演示。该检索机制使系统能够利用视觉相似场景中的过往经验来引导搜索。最后，我们提出一种步骤级反馈，利用轨迹对齐分数对轨迹进行标注。这使得生成器能够识别具体的失败点，并基于细粒度批评迭代地精炼其运动。我们在仿真环境中对六项不同的操作任务评估了 SAIL，并在真实机器人系统上验证了完整流程。我们的结果展示出清晰的扩展特性：增加测试时计算预算会持续提升所有任务的成功率（见图 1 右）。值得注意的是，系统在 HandOverBanana 任务上达到了 95% 的成功率，并成功迁移到物理世界，在使用试验匹配的数字孪生的方块移动任务上取得了高成功率。这些发现表明，在轨迹层面扩展搜索是实现更鲁棒、更可泛化机器人智能体的可行路径。我们的贡献可总结如下：（1）我们将上下文机器人模仿重新表述为轨迹级测试时精炼问题，使性能能够超越一次性轨迹预测。（2）为实现这一表述，我们开发了 SAIL，它结合了轨迹级 MCTS、检索增强演示以及来自视觉语言模型的步骤级评估，用于迭代精炼。（3）我们通过仿真和真实世界的大量实验证明，增加测试时计算会带来任务成功率的持续提升。

II. 相关工作

A. 使用大语言模型和视觉语言模型的轨迹生成

近期研究表明，大语言模型 (LLMs) 和视觉语言模型 (VLMs) 不仅可用于高层规划，还可直接生成可执行的机器人轨迹。早期方法表明，现成的大语言模型可在单次前向传播中生成完整轨迹，产生密集的位姿序列，可直接在仿真或真实机器人上执行 [11]。这种直接但无约束的生成往往较为脆弱，促使后续工作引入更结构化的表示以提升鲁棒性，例如将观测和动作标记化，或将演示转换为结构化文本模板，用于上下文轨迹或动作预测 [2], [12]。相关研究进一步强调结构条件化，从密集轨迹生成转向受物体运动学显式约束的航点级表示 [13]。与此同时，轨迹编辑方法解决

通过使用语言衍生的航点更新或几何约束修改现有轨迹，而非从头生成新轨迹，解决了类似的鲁棒性问题 [14], [15]。总体而言，这些研究确立了使用基础模型直接生成轨迹是可行的，并且可以通过表示设计和输出空间约束来稳定；然而，轨迹生成通常仍作为单一环境实例的一次性或轻度迭代过程执行，跨多个初始条件的系统性测试时扩展在很大程度上仍未探索，这正是本文所解决的问题。

B. 规划与测试时扩展

近期机器人规划研究日益将大语言模型 (LLM) 与外部评估模块及搜索过程相结合，而非将大语言模型视为独立的规划生成器。在此设定下，规划被构建为一个迭代过程：生成的计划需经过可行性检验，并根据检测到的失败或不一致进行修正，而非在单次前向传递中直接定稿 [16], [17]。对于长时程任务，通过约束满足或运动规划来验证计划，并将反馈融入后续生成过程，已被证明能显著提升可执行性 [16]。除自然语言计划外，多项研究提出以结构化且可验证的中间表示形式生成计划，例如符号代码或约束程序，使外部验证器能够引导修正，并将规划构建为优化过程 [18], [19]。基于检索的设计进一步扩展了这些方法，在推理时复用过去的成功经验，通过上下文检索适应新环境 [20]。在这些基础上，若干工作探索了测试时扩展，引入外部评分函数或搜索机制，例如基于外部评估的候选选择 [21]、由大语言模型输出引导的蒙特卡洛树搜索 (MCTS) 系统化扩展候选解 [22]，以及由结构化环境表示支持的迭代重规划 [23]。尽管这些方法提升了规划的鲁棒性与可扩展性，但它们主要关注任务级决策或规划结构，而非连续运动生成。相比之下，本文工作针对连续机器人轨迹生成层面的测试时扩展，将完整轨迹作为搜索与评估的对象。

C. 使用视觉语言模型进行评分

随着视觉语言模型 (VLM) 的发展，将机器人执行过程作为视频进行评估的研究不断扩展，从成功检测转向捕捉执行过程的连续评分。早期工作利用视觉语言模型通过检查执行后观测与自然语言任务描述之间的一致性来判断成功或失败，表明机器人执行视频可作为直接的评估目标 [9], [10]。后续研究将视频序列作为输入，沿时间维度估计任务进度或价值。例如，生成式价值学习器 (GVL) 证明，将帧

对上下文中的序列及其时间顺序进行推理，可以在执行过程中产生与进展和价值相关的分数 [24]。其他基于视觉语言模型的奖励与评估模型明确关注操作过程和阶段结构，包括面向长程操作的工作阶段识别、针对机器人执行视频的视觉语言奖励模型系统研究，以及操作轨迹的过程级评估 [25]、[26]、[27]。此外，若干研究利用视觉语言模型从执行视频中检测规划或执行错误并分类失败类型，将视频评估视为诊断信号而非二元结果 [28]、[29]。在这些工作脉络中，一个重要问题不仅是如何为整个视频分配单一标量分数，还包括如何在适当的时间分辨率下沿执行时间线提取和利用信息。在此背景下，ROVER 通过显式建模时间结构来处理长机器人执行视频，递归地将视频分割为与子任务对齐的区间，并在时间步级别分配分数 [30]。遵循这一趋势，我们使用基于视觉语言模型的评分器，在机器人轨迹生成过程中同时获得用于搜索的轨迹级分数和用于反馈的时间步级分数。

三、背景

A. 问题表述

我们考虑一个目标操作任务（例如递送香蕉或笔），该任务在多种初始环境条件下进行，并以随机种子进行索引。设 $\omega \in \Omega$ 表示一个种子，设 $\mathbf{I}_\omega$ 为种子 ω 的初始 RGB 观测。对于一小部分种子 $\Omega' \subset \Omega$ ，我们假设每个种子可获取一条成功轨迹演示，记为 $\tau_{\omega \in \Omega'} \in \Omega'$ 。我们的目标是通过利用这些初始演示，为未见过的种子生成一条成功的机器人轨迹 $\tau_{\omega \in \Omega \setminus \Omega'} \in \Omega \setminus \Omega'$ 。轨迹空间定义在机器人末端执行器状态 $\mathbf{e}_\omega$ 上，表示为笛卡尔位置 $\mathbf{p}_\omega \in \mathcal{R}^3$ 、姿态四元数 $\mathbf{q}_\omega \in \mathcal{R}^4$ 和夹爪状态 $g_\omega \in \{\text{打开}, \text{关闭}\}$ 的元组。种子 ω 的序列 $\tau_\omega = (\mathbf{e}_\omega^{(1)}, \dots, \mathbf{e}_\omega^{(T)})$ 的完整轨迹。为了实现超越单次预测的上下文模仿，我们将推理形式化为一个按种子独立运行的迭代细化过程。对于固定种子 ω ，在细化步骤 v^1 ，策略 VLM 提出一条完整轨迹 $\tau_\omega^{(v)}$ ，其条件包括：（1）初始状态 $\mathbf{s}_\omega$ ，（2）在步骤 v 插入提示中的一组上下文参考演示 $\{\tau_{\omega_k}\}_{k=1}^K$ ，以及（3）从当前搜索路径上先前执行的轨迹中获得的反馈。策略 VLM 随后生成 $\tau_\omega^{(v)}$ ，该轨迹被执行并评估，以驱动后续细化，直到获得成功轨迹 τ_ω^* 。为了构建初始状态表示 $\mathbf{s}_\omega$ ，我们从初始 RGB 观测 $\mathbf{I}_\omega$ 中提取任务相关物体的空间信息。具体而言，检测 VLM 预测任务相关物体的二维关键点，并将其提升到

使用标定相机参数转换到三维世界坐标。我们通过将三维关键点与初始机器人状态 $\mathbf{e}_\omega$ 拼接来形成 $\mathbf{s}_\omega$ 。

B. 蒙特卡洛树搜索

我们将轨迹细化建模为蒙特卡洛树搜索（MCTS）问题，其中每个节点对应一条完整轨迹，边对应修改先前轨迹的细化操作。对于每个评估种子 $\omega \in \Omega$ ，我们构建一棵独立的搜索树。每个节点对应一条完整的轨迹提案 $\tau_\omega^{(v)}$ ，由策略视觉语言模型（VLM）基于初始状态 $\mathbf{s}_\omega$ 和节点特定的上下文演示集生成。我们在仿真中执行每个提案并获得评估信号。我们采用标准的 MCTS 循环，包括选择、扩展、评估和回溯。对于节点 n ，令 $N(n)$ 表示其访问次数，令 $\bar{R}(n)$ 表示其经验均值。在选择过程中，从根节点开始，我们反复选择使置信上界（UCB）得分最大化的子节点 $c \in \text{Ch}(n)$ ，该得分平衡了利用与探索。本文采用先验加权 UCB（PUCB [31]）变体，该变体结合节点特定的先验，以进一步增强对有前景分支的探索：

$$c^* = \arg \max_{c \in \text{Ch}(n)} \left(\bar{R}(c) + c_{\text{pucb}} * P(c) \sqrt{\frac{\ln N(n)}{N(c)}} \right), \quad (1)$$


其中 $c_{\text{pucb}} > 0$ 是探索系数， $P(c)$ 表示与节点得分成正比的先验项。在扩展过程中，我们从选定的叶节点生成 B 个子节点，方法是从策略 VLM 中采样 B 条细化轨迹（我们将 B 称为分支因子）。每条子轨迹被执行并评分以获得标量奖励（第 IV-B 节），然后这些奖励沿选定路径回溯以更新 $N(\cdot)$ 和 $\bar{R}(\cdot)$ 。当测试时计算预算耗尽时（或一旦找到成功轨迹则提前停止），我们终止搜索并返回遇到的最佳轨迹。

四、方法


SAIL 在仿真器中迭代地提出、评估和细化完整轨迹。图 2 展示了方法概览。在高层次上，策略 VLM 接收 $\mathbf{s}_\omega$ 的离散化数值编码，以及上下文参考演示和先前尝试的反馈，并输出候选轨迹 $\tau_\omega^{(v)}$ 。逆运动学（IK）控制器按顺序执行航点。然后，评分机制评估生成的运行过程，并返回标量节点值和步骤级信号，这些信号用于指导下一步的迭代细化。在轨迹细化的测试时扩展方面，SAIL 包含以下组件，使其能够跨种子重用成功轨迹，评估每个候选以指导节点选择，并返回密集反馈以细化后续提案。

1 请注意， $t \in [1, T]$ 表示轨迹执行步骤， $v \in [1, V]$ 是测试时扩展细化迭代。

1. Trajectory Archive for MCTS



2. VLM Scoring



3. Step-Level Dense Feedback




图 2：方法概览。 SAIL 在测试时通过蒙特卡洛树搜索（MCTS）细化轨迹，其中每个节点是由策略视觉语言模型（VLM）为某个种子提出的完整轨迹。（1）共享轨迹档案存储跨种子的成功执行记录，并检索视觉上相似的轨迹作为上下文演示。（2）每个提议被执行并由评分视觉语言模型打分，该模型（i）从单个演示中将任务分解为有序子任务，并（ii）估计逐帧完成度以产生标量节点值。（3）评分视觉语言模型将进度分数对齐到相应的路径点，为下一次细化提供步骤级反馈。

1) 用于上下文演示的档案检索（第 IV-A 节）：我们维护一个跨种子的成功轨迹共享档案，并为每个节点检索视觉上相似的轨迹。2) 用于节点评估的轨迹评分（第 IV-B 节）：我们在模拟器中执行生成的轨迹，并使用评分视觉语言模型计算标量奖励作为节点值。3) 用于轨迹细化的步骤级反馈（第 IV-C 节）：我们从均匀采样的执行视频帧中计算进度信号，并将这些分数对齐到相应的路径点，为下一次细化提供密集反馈。

A. 用于上下文演示的档案检索

在上下文模仿学习中，性能在很大程度上取决于所提供的演示与测试时场景的匹配程度。因此，我们维护一个成功轨迹档案，该档案随着系统跨种子搜索而增长，从而能够随时间检索与场景兼容的参考。我们将档案定义为一组成功的执行记录：

$$\mathcal{A} = \{(\mathbf{I}_i, \tau_i)\}_{i=1}^{|\mathcal{A}|}, \quad (2)$$

其中 $\mathbf{I}_i \in \mathcal{R}^{H \times W \times 3}$ 是初始 RGB 观测， τ_i 是对应的成功轨迹。我们用跨种子提供的演示初始化档案，即对于每个 $\omega \in \Omega$ ， $(\mathbf{I}_\omega, \tau_\omega) \in \mathcal{A}$ 。在搜索过程中，每当发现某个种子 ω 的成功轨迹时，我们将其追加

到 $\mathcal{A}$ 。因此， $\mathcal{A}$ 包含来自多个种子的成功轨迹，并且可以在搜索其他种子时重用。当为目标种子 ω 扩展节点时，其初始观测为 $\mathbf{I}_\omega$ ，我们检索一小部分视觉上相似的档案条目以形成上下文示例。我们使用 LPIPS 距离 [32] 计算感知相似度，并通过最小化总距离选择 K 个最近邻：

$$\mathcal{S}^*(\mathbf{I}_\omega) = \arg \min_{\substack{S \subseteq \{1, \dots, |\mathcal{A}|\} \\ |S|=K}} \sum_{i \in S} \text{LPIPS}(\mathbf{I}_\omega, \mathbf{I}_i). \quad (3)$$

Let $\mathcal{S}^*(\mathbf{I}_\omega) = \{i_1, \dots, i_K\}$ 。我们定义 $\tau_{\omega_k}^{(v)} := \tau_{i_k}$ 对 $k = 1, \dots, K$ ，并使用 $\{\tau_{\omega_k}^{(v)}\}_{k=1}^K$ 作为上下文参考。

B. 节点评估的轨迹评分

为多样化的操作任务设计特定任务的奖励函数既费力又难以扩展。本文采用一种基于通用视觉语言模型（VLM）的评分机制，该机制评估执行后的回放视频并输出一个标量奖励用于搜索。对于长时程任务，二元成功信号往往过于稀疏。遵循为捕捉执行过程而分配时间步级分数的趋势 [30]，本文通过有序的中间子任务序列（例如，递笔任务中的接近、抓取、举起、交接）来评估进展。为获得这些子任务，本文利用一个可用的演示，为每个任务预先生成一个按时间排序的子任务列表。

τ_ω 从种子 $\omega \in \Omega$ 。具体而言，我们向评分视觉语言模型提供最终目标规范和 τ_ω 的演示视频，并提示其将任务分解为 M 个有序的自然语言子任务 $\{\ell_m\}_{m=1}^M$ 。给定 $\{\ell_m\}_{m=1}^M$ ，我们通过在仿真中执行 $\tau_\omega^{(v)}$ 并顺序查询视觉语言模型来估计当前子任务的完成进度，从而为种子 ω 的候选轨迹评分。对于每个子任务 ℓ_m ，我们将该子任务的第一帧视为起始参考（0% 完成度），并按时间顺序评估后续帧。我们沿已执行轨迹的时间轴均匀采样 N 个演示视频帧。在每个被评估的演示视频帧 $f \in [1, N]$ 处，我们使用当前子任务、起始参考帧和当前帧查询视觉语言模型，并将其输出解析为完成百分比 $\text{VLM}(\ell_m, \tau_\omega^{(v)}, f) \in [0, 100]$ （即，我们提示视觉语言模型直接输出完成百分比）。当 $\text{VLM}(\ell_m, \tau_\omega^{(v)}, f)$ 达到 100% 时，我们将该子任务标记为完成，并继续处理 ℓ_{m+1} 。如果演示在完成前结束，我们停止并将该轨迹视为在该子任务处失败。我们将此子任务级进度转换为逐帧进度分数 $r_\omega^{(v)}(f) \in [0, 1]$ ：

$$r_\omega^{(v)}(f) = \frac{1}{M} \left((m_\omega^{(v)}(f) - 1) + \frac{\text{VLM}(\ell_m, \tau_\omega^{(v)}, f)}{100} \right), \quad (4)$$

其中 $m_\omega^{(v)}(f) \in \{1, \dots, M\}$ 表示种子 ω 在展开视频帧 f 处的当前子任务索引。随后，本文通过对 N 个展开视频帧的进度取平均来计算标量奖励，并将其用作蒙特卡洛树搜索中的节点值。

C. 轨迹细化的步骤级反馈

为了有效优化轨迹，策略视觉语言模型（VLM）受益于能够定位进展停滞位置的反馈。我们通过使用评分器产生的进度分数对提议轨迹进行标注，从而提供步骤级反馈。给定来自第 IV-B 节的采样进度曲线 $\{r_\omega^{(v)}(f)\}_{f=1}^N$ ，我们根据均匀采样时间表将每个采样分数对齐到生成轨迹中对应的路径点 $\tau_\omega^{(v)} = (\mathbf{e}_\omega^{(1)}, \dots, \mathbf{e}_\omega^{(T)})$ 。这产生了一条带标注的轨迹，其中选定的路径点被标记了完成分数。在针对同一种子 ω 的下次扩展步骤中，我们将这条带标注的轨迹作为密集反馈包含在提示中，同时包含检索到的演示集 $\{\tau_{\omega_k}^{(v)}\}_{k=1}^K$ 。策略视觉语言模型被指示保留高分段并修改低分段，从而在迭代优化过程中实现有针对性的修正。

五、实验

在本节中，我们在仿真和真实世界中通过实验评估我们的方法。通过实验，我们旨在回答以下研究问题：• 增加测试时计算预算（蒙特卡洛树搜索节点数）是否提高任务成功率？（第 V-B 节）

- 自动档案检索和步骤级反馈如何促进迭代轨迹优化？

（第 V-C 节）• 在仿真中优化的轨迹能否成功迁移到真实世界？（第 V-D 节）

A. 任务与实验设置

在仿真中，我们在 ALOHA 操作仿真器 [33] 中考虑六项操作任务：HandOverBanana（HOB）、HandOverPen（HOP）、BowlOnRack（BOR）、DrawerOpen（DO）、LaptopClose（LC）和 MarkerRemoveLid（MRL）。每个任务实例使用随机种子确定初始物体配置。对于每项任务，我们提供一条或几条成功的参考轨迹演示，这些演示由不同于评估种子的种子生成。我们评估每项任务的 20 个不同种子，并使用仿真器的真值验证函数确定成功与否。我们使用俯视相机视图和 gemini-robotics-er-1.5-preview 模型完成所有基于 VLM 的任务，包括 2D 关键点检测、轨迹生成和轨迹评分。在 MCTS 过程中，我们设置分支因子 $B = 3$ 。除非另有说明，我们检索 $K = 1$ 条演示用于自动存档检索。对于轨迹评分，我们从 rollout 视频中以固定间隔采样 $N = 50$ 帧。我们将任务成功率定义为 20 个评估种子中我们的方法生成成功轨迹的百分比。在第五-D 节中，我们使用 LeRobot SO-101 [34] 机械臂在真实世界的 BlockIntoBowl 任务上评估我们的流程。我们进行 6 次随机桌面试验。对于每次试验，我们在特定于试验的 Real-to-Simulation（Real2Sim）环境中选择一条经过优化的轨迹。然后，我们通过 Simulation-to-Real（Sim2Real）迁移在物理机器人上执行该轨迹，并报告成功率。我们保持与仿真实验中相同的超参数设置。

B. 测试时计算的扩展

我们研究增加测试时计算预算是否提高任务成功率。表 I 总结了我们的结果。

扩展测试时计算： 我们将轨迹搜索扩展到最多 45 个节点的预算，并将其与传统的单次 rollout 生成进行比较。总体而言，随着分配更多计算资源，成功率持续提高。所有任务的平均成功率从单次 rollout 的 25% 提高到 45 个 MCTS 节点的 73%。这一显著提升表明，通过测试时计算进行迭代优化能有效增强轨迹生成。特别是，多项任务的成功率上升——例如，DO 从 10% 提高到 50%，LC 从 15% 提高到 70%，MRL 从 5% 提高到 45%。同时，一些任务较早达到平台期；BOR 在 6 个节点时达到 100% 成功率，并在更大预算下保持 100%。

搜索策略比较： 我们进一步在固定预算为 15 个节点的条件评估不同的搜索策略。广度优先搜索并行扩展 15 个节点，没有反馈回路；而深度优先搜索通过 15 个顺序细化步骤，每次扩展一个节点。在此预算下，

表一：在 20 个随机种子下，不同测试时计算预算（以扩展的蒙特卡洛树搜索节点数衡量）的成功率。灰色行表示用于公平比较的 15 节点预算。粗体表示 15 节点方法中的最佳结果，下划线表示整体最佳结果。

Method	Nodes	Success Rate						
		<i>HOB</i>	<i>HOP</i>	<i>BOR</i>	<i>DO</i>	<i>LC</i>	<i>MRL</i>	Avg
Single rollout	1	0.40	0.40	0.40	0.10	0.15	0.05	0.25
Breadth-search	15	0.85	0.50	0.60	0.35	0.60	0.15	0.51
Depth-search	15	0.45	0.50	0.80	0.05	0.30	0.10	0.37
Ours	6	0.80	0.55	1.00	0.20	0.50	0.25	0.55
	15	0.90	0.70	1.00	0.40	0.50	0.40	0.65
	30	0.95	0.80	1.00	0.50	0.55	0.45	0.71
	45	0.95	0.80	1.00	0.50	0.70	0.45	0.73

我们的蒙特卡洛树搜索方法平均成功率达到 65%，相比之下，广度优先搜索为 51%，深度优先搜索为 37%。虽然蒙特卡洛树搜索平均表现最佳，但广度优先搜索在笔记本电脑闭合任务上取得了更高的成功率。关闭笔记本电脑需要精细的位置调整，以使夹爪安全地越过屏幕薄薄的上边缘，而广度优先搜索的随机探索很好地处理了这一特定的几何要求。总体而言，这些结果表明，我们的方法之所以成功，是因为它有效地结合了广泛的轨迹探索与纵向的步骤级反馈。

三、检索策略与反馈模态的影响

为了评估检索策略和反馈机制的影响，我们在固定搜索预算为 15 个节点的条件进行了消融实验。表二总结了结果。

检索策略：为评估归档与检索策略对性能的影响，本文将所提方法与两种基线进行对比。固定示例基线禁用归档，仅使用原始上下文示例。随机检索基线从归档中均匀随机选取 K 条条目。表 II 显示，在 $K = 1$ 条件下，本文基于相似度的检索方法（Ours）相较于固定示例与随机检索基线均提升了平均成功率，并在多数任务上表现更优。具体而言，本文方法平均成功率达到 65%，而固定示例为 45%，随机检索为 50%。这些结果表明，在相同上下文规模下，基于相似度的检索性能优于固定示例与随机检索基线。进一步观察发现，仅增加上下文示例数量并不能可靠地缩小这一性能差距。当固定示例的上下文规模从 $K = 1$ 增至 $K = 3$ 时，平均成功率仅从 45% 小幅提升至 49%。随机检索也呈现类似趋势，平均成功率从 50% 升至 53%。两者均低于仅使用单个检索示例的基于相似度检索方法，后者平均成功率为 65%。这一规律同样体现在单个任务上；例如，在 DO 任务中，固定示例

从 5% 提升至 10%，而基于相似度的检索在 $K = 1$ 条件下达到 40%。总体而言，这些结果表明性能对上下文示例的相关性比对单纯数量更为敏感，将上下文预算分配给更相似的示例比简单增加示例数量更有效。

反馈模态：为评估本文的步骤级反馈，将其与三种基线进行对比：（i）仅轨迹：仅提供前一次尝试的文本动作序列；（ii）仅图像：提供与轨迹步骤对应的下采样展开帧序列；以及

（iii）图像与轨迹：同时提供轨迹文本和对应的回放帧，但不包含逐步评分标注。逐步反馈（本文方法）在所有任务中均取得了最强的细化性能。与仅提供原始历史记录而无显式评分的密集基线相比，本文的逐步反馈变体实现了更高的平均成功率（65% 对比 45 – 48%）。这一改进也体现在各个任务上；例如，在 LC 任务上，逐步反馈达到 50% 成功率，而密集基线仅达到 30 – 35%。这些结果表明，仅靠视觉或文本回放不足以可靠地指导细化；显式的逐步评分有助于模型定位轨迹首次偏离成功的位置以及需要纠正的内容。本文还与仅提供最终评分的稀疏反馈进行了比较。虽然稀疏反馈在某些情况下有所帮助，但其效果始终弱于逐步反馈。例如，稀疏反馈在 DO 上达到 15%，在 MRL 上达到 30%，而逐步反馈在这两个任务上均达到 40%。总体而言，消融实验表明，细化最受益于密集且与评分对齐的反馈。由于逐步标注由用于评估回放的同一评分函数生成，细化信号与目标直接对齐，从而比无评分历史或稀疏的轨迹末端反馈带来更可靠的改进。本文进一步将若干消融实验扩展到 45 个节点，SAIL 明显展现出优越性能（详见右图 1）。

D. 真实世界验证

本文在真实世界的 BlockIntoBowl 任务上使用 LeRobot SO-101 机械臂验证了所提方法。图 3 展示了实验设置。任务是将目标积木放入红色碗中。首先，本文使用 Real2Sim 流程在仿真中重建物理工作空间。接着，在该仿真中应用搜索方法生成成功轨迹。然后通过 Sim2Real 迁移在物理机器人上执行该轨迹。本文进行了六次试验。每次试验中，手动随机化桌面上积木和碗的初始位置，并运行从感知到执行的完整流程。1) Real2Sim 流程：为在仿真中重建物理工作空间，本文的 Real2Sim 流程处理来自固定 Intel RealSense D435i 相机的同步 RGB-D 观测，以估计

表二：在蒙特卡洛树搜索预算固定为 15 个节点的条件下进行的消融实验（成功率）。我们比较了用于细化的检索策略与反馈模式。

Setting	Success Rate						
	HOB	HOP	BOR	DO	LC	MRL	Avg
Ours ($K=1$)	0.90	0.70	1.00	0.40	0.50	0.40	0.65
<i>Retrieval Strategy ($K=1$)</i>							
Fixed demonstration	0.75	0.40	0.85	0.05	0.50	0.15	0.45
Random retrieval	0.75	0.50	0.90	0.15	0.55	0.15	0.50
<i>Retrieval Strategy ($K=3$)</i>							
Fixed demonstration	0.80	0.35	0.95	0.10	0.45	0.30	0.49
Random retrieval	0.90	0.60	0.85	0.15	0.45	0.20	0.53
<i>Feedback Modality (Dense)</i>							
Trajectory-only	0.85	0.50	0.95	0.10	0.35	0.10	0.48
Image-only	0.75	0.45	0.95	0.10	0.35	0.10	0.45
Image & trajectory	0.80	0.35	0.95	0.15	0.30	0.20	0.46
<i>Feedback Modality (Sparse)</i>							
Final score	0.80	0.40	0.90	0.15	0.40	0.30	0.49




图 3：面向“将方块放入碗中”任务的数字孪生实验装置。该任务包含三个顺序步骤：（1）抓取蓝色方块，（2）移动到碗的位置，（3）将方块释放到碗中。左侧面板展示仿真环境，右侧面板展示对应的真实世界装置。

目标物体。首先，我们使用文本提示“蓝色方块”和“红色碗”通过 GroundingDINO [35] 在 RGB 帧中定位目标物体，并利用 SAM2 [36] 将检测结果细化为实例掩码。随后，我们利用对齐的深度数据将每个掩码提升为三维点集。为了将这些点映射到机器人坐标系，我们应用离线标定的相机内参以及通过固定在机器人基座已知位置（沿 X 轴 0.1 米处）的 ArUco 标记估计的运行时效参。利用这些参数，我们聚合掩码深度点并拟合三维包围盒以计算六自由度物体位姿。最后，我们通过将相应的仿真资产放置在这些估计位姿处，并使仿真相机视点与真实装置匹配，来实例化场景匹配的仿真器。

2) 仿真到现实：轨迹与策略部署：在构建特定于试验的数字孪生之后，我们在仿真中生成一条成功轨迹，并在真实机器人上执行。我们评估了两种生成该轨迹的方法：基于蒙特卡洛树搜索的搜索方法，以及从蒙特卡洛树搜索推演中蒸馏出的策略。我们报告每种方法在六次真实世界试验中的成功率。如果机器人将目标方块放入红色碗内，则认为该试验成功。

表三：真实世界“将方块放入碗中”任务在 6 次试验中的成功率。

Method	Success Rate
MCTS-based Trajectory Refinement	5 / 6
Sim2Real Policy Distillation	5 / 6

表三展示了结果。

基于蒙特卡洛树搜索的轨迹细化：在该方法中，我们在通过真实到仿真（Real2Sim）构建的仿真环境中直接运行蒙特卡洛树搜索（MCTS）方法。我们分配的最大搜索节点预算为 15 个。在每个节点处，策略视觉语言模型（VLM）根据当前场景观测和检索到的上下文演示提出候选轨迹。一旦找到成功轨迹，我们便提前终止搜索，并在真实机器人上执行该轨迹。该方法在 6 次真实世界试验中成功了 5 次。这一高成功率表明，在数字孪生中验证过的轨迹能够有效迁移到物理世界。我们将唯一一次失败归因于仿真到真实（Sim2Real）的差距，具体包括 RGB-D 姿态估计的轻微误差以及未建模的真实世界接触动力学。仿真到真实策略

蒸馏：虽然基于蒙特卡洛树搜索（MCTS）的搜索实现了高性能，但迭代轨迹生成过程耗时较长。为解决这一局限性，我们将基于 MCTS 的搜索蒸馏为学习策略。首先，通过在仿真中随机化初始物体摆放并运行 MCTS 过程，我们收集了 120 条成功轨迹的数据集。然后，我们通过行为克隆在该数据集上训练一个基于变换器的动作分块（Action Chunking with Transformers, ACT）[37] 模型。在部署期间，我们在针对特定试验的真实到仿真（Real2Sim）场景中多次展开训练好的策略，选择一条成功实现目标的展开轨迹，并在真实机器人上执行该轨迹。该方法在 6 次真实世界试验中成功了 5 次，同时将平均执行时间从基于 MCTS 搜索的 644.72 秒显著降低到使用我们策略的 72.306 秒。最终，这些结果表明，我们的 MCTS 框架可以作为一个自动数据收集引擎，用于训练快速、可部署的机器人策略。

六、结论

我们提出了 SAIL，将机器人模仿重新定义为一种能够随测试时计算扩展的迭代精炼过程。通过在蒙特卡洛树搜索架构中将完整轨迹视为搜索对象，SAIL 使机器人能够“思考更久”以解决环境歧义。在六个操作任务上的实验表明，增加计算预算显著提高了平均成功率。虽然这项工作依赖传统物理模拟器进行数据收集，但 SAIL 与底层环境无关。一项重大进展是将该框架与通过高斯泼溅（Gaussian Splatting）构建的数字孪生环境集成 [38]。通过生成更贴近真实世界视觉统计的数据集，我们旨在实现零样本适应，并弥合视觉保真度和接触动力学方面剩余的仿真到现实差距。

参考文献

- [1] R. Shah, S. Liu, Q. Wang, Z. Jiang, S. Kumar, M. Seo, R. Martín-Martín, and Y. Zhu, “Mimicdroid: In-context learning for humanoid robot manipulation from human play videos,” *arXiv preprint arXiv:2509.09769*, 2025.
- [2] N. Di Palo and E. Johns, “Keypoint action tokens enable in-context imitation learning in robotics,” in *Robotics: Science and Systems (RSS)*, 2024.
- [3] L. Fu, H. Huang, G. Datta, L. Y. Chen, W. C.-H. Panitch, F. Liu, H. Li, and K. Goldberg, “In-context imitation learning via next-token prediction,” *arXiv preprint arXiv:2408.15980*, 2024.
- [4] B. Zitkovich, T. Yu, S. Xu, P. Xu, T. Xiao, F. Xia, J. Wu, P. Wohlhart, S. Welker, A. Wahid *et al.*, “Rt-2: Vision-language-action models transfer web knowledge to robotic control,” in *Conference on Robot Learning*. PMLR, 2023, pp. 2165–2183.
- [5] G. Puthumanaim, P. Padrao, J. Fuentes, P. Thangeda, W. E. Schafer, L. H. Song, K. Jagdale, L. Bobadilla, and M. Ornik, “Trace: A self-improving framework for robot behavior forecasting with vision-language models,” in *2025 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. IEEE, 2025, pp. 11 128–11 135.
- [6] J. Gu, S. Kirmani, P. Wohlhart, Y. Lu, M. G. Arenas, K. Rao, W. Yu, C. Fu, K. Gopalakrishnan, Z. Xu *et al.*, “Rt-trajectory: Robotic task generalization via hindsight trajectory sketches,” *arXiv preprint arXiv:2311.01977*, 2023.
- [7] Q. Lv, H. Li, X. Deng, R. Shao, M. Y. Wang, and L. Nie, “Robomp²: A robotic multimodal perception-planning framework with multimodal large language models,” *arXiv preprint arXiv:2404.04929*, 2024.
- [8] Y. Kuang, J. Ye, H. Geng, J. Mao, C. Deng, L. Guibas, H. Wang, and Y. Wang, “Ram: Retrieval-based affordance transfer for generalizable zero-shot robotic manipulation,” *arXiv preprint arXiv:2407.04689*, 2024.
- [9] Y. Du *et al.*, “Vision-language models as success detectors,” in *Conference on Lifelong Learning Agents (CoLLAs)*, 2023.
- [10] S. A. Sontakke *et al.*, “Roboclip: One demonstration is enough to learn robot policies,” 2023.
- [11] T. Kwon, N. Di Palo, and E. Johns, “Language models as zero-shot trajectory generators,” *IEEE Robotics and Automation Letters*, vol. 9, no. 7, pp. 6728–6735, 2024.
- [12] Y. Yin, Z. Wang, Y. Sharma, D. Niu, T. Darrell, and R. Herzig, “In-context learning enables robot action prediction in llms,” in *IEEE International Conference on Robotics and Automation (ICRA)*, 2025.
- [13] W. Xia, D. Wang, X. Pang, Z. Wang, B. Zhao, D. Hu, and X. Li, “Kinematic-aware prompting for generalizable articulated object manipulation with llms,” in *IEEE International Conference on Robotics and Automation (ICRA)*, 2024.
- [14] A. Maurya, T. Ghosh, and R. Prakash, “Trajectory adaptation using large language models,” *arXiv preprint arXiv:2504.12755*, 2025.
- [15] J. Huang *et al.*, “Gelato: Multi-instruction trajectory reshaping via geometry-aware multiagent-based orchestration,” *arXiv preprint arXiv:2509.06031*, 2025.
- [16] A. Curtis, N. Kumar, J. Cao, T. Lozano-Pérez, and L. P. Kaelbling, “Trust the proc3s: Solving long-horizon robotics problems with llms and constraint satisfaction,” in *Conference on Robot Learning (CoRL)*, 2024. [Online]. Available: <https://openreview.net/forum?id=r6ZhiVYriY>
- [17] S. Wang, M. Han, Z. Jiao, Z. Zhang, Y. N. Wu, S.-C. Zhu, and H. Liu, “LLM3: Large language model-based task and motion planning with motion failure reasoning,” *arXiv preprint arXiv:2403.11552*, 2024, IROS 2024. [Online]. Available: <https://arxiv.org/abs/2403.11552>
- [18] Y. Chen, Y. Hao, Y. Zhang, and C. Fan, “Code-as-symbolic-planner: Foundation model-based robot planning via symbolic code generation,” *arXiv preprint arXiv:2503.01700*, 2025. [Online]. Available: <https://arxiv.org/abs/2503.01700>
- [19] H. Chi, Z. Feng, Y. Lyu, C. Zheng, L. Luo, Y.-S. Ong, I. Tsang, H. Chen, Y. Chang, and H. Yin, “Instructflow: Adaptive symbolic constraint-guided code generation for long-horizon planning,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2025. [Online]. Available: <https://openreview.net/forum?id=nzwjvpCO4F>
- [20] K. Sridhar, S. Dutta, D. Jayaraman, and I. Lee, “Regent: A retrieval-augmented generalist agent that can act in-context in new environments,” in *International Conference on Learning Representations (ICLR)*, 2025, oral. [Online]. Available: <https://openreview.net/forum?id=NxyfSW6mLK>
- [21] M. Ahn, A. Brohan *et al.*, “Do as i can, not as i say: Grounding language in robotic affordances,” *arXiv preprint arXiv:2204.01691*, 2022. [Online]. Available: <https://arxiv.org/abs/2204.01691>
- [22] D. Lee, S. Joo, K. Lee, and B. Kim, “Prime the search: Using large language models for guiding geometric task and motion planning by warm-starting tree search,” *arXiv preprint arXiv:2506.07062*, 2025. [Online]. Available: <https://arxiv.org/abs/2506.07062>
- [23] K. Rana *et al.*, “Sayplan: Grounding large language models using 3d scene graphs for scalable robot task planning,” *arXiv preprint arXiv:2307.06135*, 2023. [Online]. Available: <https://arxiv.org/abs/2307.06135>
- [24] Y. J. Ma *et al.*, “Vision language models are in-context value learners,” 2024.
- [25] Q. Chen *et al.*, “Sarm: Stage-aware reward modeling for long horizon robot manipulation,” 2025.
- [26] T. Lee *et al.*, “Roboreward: General-purpose vision-language reward models for robotics,” 2026.
- [27] H. Tan *et al.*, “Robo-dopamine: General process reward modeling for high-precision robotic manipulation,” 2025.
- [28] P. Pacaud *et al.*, “Guardian: Detecting robotic planning and execution errors with vision-language models,” 2025.
- [29] J. Duan *et al.*, “Aha: A vision-language-model for detecting and reasoning over failures in robotic manipulation,” 2024.
- [30] P. Schroeder *et al.*, “Rover: Recursive reasoning over videos with vision-language models for embodied tasks,” 2025.
- [31] C. D. Rosin, “Multi-armed bandits with episode context,” *Annals of Mathematics and Artificial Intelligence*, vol. 61, no. 3, pp. 203–230, 2011.
- [32] R. Zhang, P. Isola, A. A. Efros, E. Shechtman, and O. Wang, “The unreasonable effectiveness of deep features as a perceptual metric,” in *CVPR*, 2018.
- [33] Gemini Robotics Team *et al.*, “Gemini Robotics: Bringing AI into the physical world,” *arXiv preprint arXiv:2503.20020*, 2025. [Online]. Available: <https://arxiv.org/abs/2503.20020>
- [34] R. Cadene, S. Alibert, F. Capuano, M. Aractingi, A. Zouitine, P. Kooijmans, J. Choghari, M. Russi, C. Pascal, S. Palma, M. Shukor, J. Moss, A. Soare, D. Aubakirova, Q. Lhoest, Q. Gallouédec, and T. Wolf, “Lerobot: An open-source library for end-to-end robot learning,” in *International Conference on Learning Representations (ICLR)*, 2026, poster. [Online]. Available: <https://openreview.net/forum?id=CiZMMAFQR3>
- [35] S. Liu, Z. Zeng, T. Ren, F. Li, H. Zhang, J. Yang, Q. Jiang, C. Li, J. Yang, H. Su, J. Zhu, and L. Zhang, “Grounding DINO: Marrying DINO with grounded pre-training for open-set object detection,” *arXiv preprint arXiv:2303.05499*, 2023. [Online]. Available: <https://arxiv.org/abs/2303.05499>
- [36] N. Ravi, V. Gabeur, Y.-T. Hu, R. Hu, C. Ryali, T. Ma, H. Khedr, R. Rädle, C. Rolland, L. Gustafson, E. Mintun, J. Pan, K. V. Alwala, N. Carion, C.-Y. Wu, R. Girshick, P. Dollár, and C. Feichtenhofer, “SAM 2: Segment anything in images and videos,” *arXiv preprint arXiv:2408.00714*, 2024. [Online]. Available: <https://arxiv.org/abs/2408.00714>
- [37] T. Z. Zhao, V. Kumar, S. Levine, and C. Finn, “Learning fine-grained bimanual manipulation with low-cost hardware,” *arXiv preprint arXiv:2304.13705*, 2023. [Online]. Available: <https://arxiv.org/abs/2304.13705>
- [38] G. Jiang, H. Chang, R.-Z. Qiu, Y. Liang, M. Ji, J. Zhu, Z. Dong, X. Zou, and X. Wang, “GSWorld: Closed-loop photo-realistic simulation suite for robotic manipulation,” *arXiv preprint arXiv:2510.20813*, 2025. [Online]. Available: <https://arxiv.org/abs/2510.20813>